국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서

K-22-IR-0407-R

과학기술 텍스트 분석을 위한 지능 기술 연구

(Research on the Intelligent Technology for Scientific Text Data Analysis)

한국과학기술정보연구원

2022

과학기술정보통신부

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

한국과학기술정보연구원장 귀하

본 보고서를 “과학기술 텍스트 분석을 위한지능 기술 연구” 사업의 최종보고서로 제출합니다.

2022년 12월 23일

주관연구기관명 : 한국과학기술정보연구원
주관연구책임자 : 인공지능기술연구단 이 혁 로
참 여 연 구 원 : 인공지능기술연구단 성 원 경
인공지능기술연구단 황 명 권
인공지능기술연구단 이 민 호
인공지능기술연구단 김 은 희
인공지능기술연구단 정 유 나
인공지능기술연구단 양 동 헌
인공지능기술연구단 박 선 경
부원장 조 민 수
과학기술디지털융합본부전략팀 노 민 기
과학기술디지털융합본부전략팀 이 현 아
국가과학기술데이터본부전략팀 이 경 하
국가과학기술데이터본부전략팀 박 정 현
국가과학기술데이터본부전략팀 유 주 연
정보화전략실 선 형 주
슈퍼컴퓨팅응용센터 조 금 원
DataOn개발팀 신 영 호

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서 초록

과제관리번호	K-22-L04-C07		
대과제명	과학기술 디지털 융합 서비스 체계 구축		
중과제명	디지털 전환 기술 연구 및 기술 활용 활성화		
세부과제명	과학기술 텍스트 분석을 위한 지능 기술 연구		
	Research on the intelligent technology for scientific text data analysis		
연구책임자	이혁로	참여연구원	총 17명 (내부17명, 외부0 명)
연구기관명	한국과학기술정보연구원	소속부서명	인공지능기술연구단
연구개발기간	전체	2018. 01. 01 - 2022. 12. 31(60개월)	
	1단계	2018. 01. 01 - 2020. 12. 31(36개월)	
	2단계	2021. 01. 01 - 2022. 12. 31(24개월)	

연구개발비 현황 (단위: 천원)

단계		정부출연금 (A)	연구개발기관 부담금			정부외 지원금 (E)	합계 (G=A+D+E)
			현금 (B)	현물 (C)	소계 (D=B+C)		
1단계	1차 연도	1,014,000					1,014,000
	2차 연도	776,000					776,000
	3차 연도	826,000					826,000
2단계	1차 연도	1,005,000					1,005,000
	2차 연도	926,000					926,000
합계		4,547,000					4,547,000

해당단계 참여기관	기관명	책임자	직급(직위)	국가연구자번호
공동연구기관				
위탁연구기관				
국제공동연구기관				
참여기업				
	참여기관 중 중소기업 ( )개, 중견기업 ( )개, 대기업·공기업 ( )개			

요약	보고서 Page	90

■ 과학기술 텍스트에 특화된 언어이해모델 개발

- DeBERTa모델을 응용하여 과학기술 텍스트 이해에 특화된 언어모델 SciDeBERTa 개발
- 과학기술분야에 범용적 활용이 가능한 SciDeBERTa뿐아니라 CS (Computer Science), BIO (Biomedical) 지식을 추가로 학습하여 각 분야에 더 특화된 SciDeBERTa(CS)와 SciDeBERTa(Bio) 모델을 개발함.

■ 과학기술 텍스트 대상 지식 추출 태스크에서 세계최고수준 달성

- 컴퓨터공학 분야의 SciERC 데이터 셋을 활용한 NER, Joint RE, Coreference 세부 태스크 성능 검증을 수행하였으며 NER 태스크에서 세계 1위, Joint RE에서 세계 4위 성능을 달성함.
- 의공학분야 벤치마크 BLURB에서 동급의 세계 최고 수준 모델의 97%에 달하는 성능을 달성.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

요 약 문

<table>
<tr><td>국가과학기술표준분류</td><td colspan="2">EE</td><td>70%</td><td>EI</td><td>20%</td><td>EB</td><td>10%</td></tr>
<tr><td>대과제명</td><td colspan="7">과학기술 디지털 융합 서비스 체계 구축</td></tr>
<tr><td>중과제명</td><td colspan="7">디지털 전환 기술 연구 및 기술 활용 활성화</td></tr>
<tr><td>세부과제명</td><td colspan="7">과학기술 텍스트 분석을 위한 지능 기술 연구</td></tr>
<tr><td>과제유형</td><td colspan="7">■기초・미래선도형 □공공・인프라형 □산업화형 □정책연구・지원형</td></tr>
<tr><td rowspan="2">연구개발기간</td><td>전체</td><td colspan="6">2018. 01. 01 - 2022. 12. 31(60개월)</td></tr>
<tr><td>해당연도</td><td colspan="6">2022. 01. 01 - 2022. 12. 31(12개월)</td></tr>
<tr><td rowspan="2">총 연구개발비</td><td>전체</td><td colspan="6">총 4,810 천원</td></tr>
<tr><td>해당연도</td><td colspan="6">총 1,046 천원</td></tr>
<tr><td>연구개발단계</td><td colspan="3">기초[√], 응용[ ], 개발[ ]</td><td colspan="2">기술성숙도
(해당시 기재)</td><td colspan="2">착수시점 기준( )
종료시점 목표( )</td></tr>
<tr><td rowspan="5">연구개발
목표 및
내용</td><td colspan="2">최종 목표</td><td colspan="6">과학기술 데이터의 지능적 처리를 위한 AI 기술 연구</td></tr>
<tr><td colspan="2">전체 내용</td><td colspan="6">• AI 학습과정 효율화를 위한 모델·데이터 경량화 기술 연구
• 과학기술 텍스트 분석을 위한 기계이해(machine understanding) 핵심 기술 연구</td></tr>
<tr><td rowspan="2">1단계</td><td>목표</td><td colspan="6">AI 학습 과정의 효율화를 위한 모델·데이터 경량화 기술 연구</td></tr>
<tr><td>내용</td><td colspan="6">• weight / activation quantization 기반 모델 경량화 기술 연구
• core dataset 구성을 통한 학습데이터 경량화 기술 연구</td></tr>
<tr><td rowspan="2">2단계</td><td>목표</td><td colspan="6">과학기술 텍스트 분석을 위한
기계이해(machine understanding) 핵심 기술 연구</td></tr>
<tr><td>내용</td><td colspan="6">• 과학기술 분야 서비스에 특화된 딥 러닝 언어 모델 연구
• 과학기술 분야 지식 추출을 위한 개체명 인식, 관계 추출, 상호참조 해결, 의미 중의성 해소, 다단계 추론 기반 질의응답 기술 연구</td></tr>
<tr><td>연구개발성과</td><td colspan="7">• 과학기술 텍스트 대상 지식 추출 기술의 세계 최고 성능 (이하 SOTA) 확보 (2단계 완료 시점 기준)</td></tr>
<tr><td>연구개발성과
활용계획 및
기대 효과</td><td colspan="7">• 범용의 언어 모델과 기계 이해 모델의 개발을 통한 신규 서비스 창출에 활용
• 과학기술 데이터 분석을 위한 기계 독해 및 데이터 마이닝 등 다양한 서비스 개발을 위한 핵심 기술 요소로서 활용</td></tr>
<tr><td>국문핵심어
(5개 이내)</td><td>자연어 처리</td><td>언어 모델</td><td>딥 러닝</td><td>정보 추출</td><td colspan="3">기계 독해</td></tr>
<tr><td>영문핵심어
(5개 이내)</td><td>Natural Language Processing</td><td>Language Model</td><td>Deep Learning</td><td>Information Extraction</td><td colspan="3">Machine Reading&Comprehension</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 위탁연구 현황

- 해당 없음.

□ 용역사업 현황

- 해당 없음.

□ 국제공동연구 현황

- 해당 없음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Summary

Ⅰ. Objectives

○ AI technology research for intelligent processing of science and technology data

- Research on model and data compression for efficient and effective AI learning process
- Research on machine understanding core technology for science and technology text analysis

II. Research topics and scope

○ Research on model and data compression technology for efficiency of AI learning process

- Weight / activation quantization-based model compression technology research
- Research on data compression through core dataset composition

○ Machine understanding core technology research for science and technology text analysis

- Research on deep learning language models specialized for services in the field of science and technology
- Research on object name recognition, relation extraction, cross-reference resolution, semantic ambiguity resolution, and question-answering technology based on multi-level reasoning for science and technology knowledge extraction

III. Research results

○ Development of a language understanding model specialized for science and technology texts

- Development of SciDeBERTa, a language model specialized in understanding science and technology texts based on the DeBERTa model
- Development of SciDeBERTa (CS) and SciDeBERTa (Bio) models that are more specialized for each field by additionally learning CS (Computer Science) and BIO (Biomedical) knowledge as well as SciDeBERTa, which can be used universally in the field of science and technology.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ Achieving the world's highest level in science and technology text knowledge extraction tasks

- Performance verification of NER, Joint RE, and Coreference tasks using SciERC data set in the field of computer science. Ranked #1 in the world in the NER task and #4 in the world in the Joint RE.
- Achieved 97% of the performance of the world's best model in its class in BLURB, a benchmark in the field of biomedical engineering.

IV. Application schemes of the Results

○ Utilizing S&T language model and its technology to improve KIST services

- Advancement of work areas carried out by the Dept. of Data-centric Problem Solving Research and Dept. of Machine Learning Data Research of Div. of S&T Digital Convergence Headquarters by utilizing the deep learning technology and its capabilities (plan in 2022)
- Improving the performance of ScienceOn and NTIS, the representative services of the KISTI National Science and Technology Data Center. the S&T language model is capable to improve the ability to understand literature such as papers, patents, and reports (plain in 2023)
- Advancement of S&T document analysis skills by applying a language model to services such as MIRIAN and COMPAS of Div. of Data Analysis.

○ Dissemination and utilization of domestic and foreign technologies

- Disseminating KISTI's original technologies through providing S&T language model and using OpenAPI to domestic and international research groups
- Contributing to the improvement of national expertise (R&D researchers, developers, and students) through programs of Sciende Data Education Center and AI specialized educations.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Contents

Chapter 1 Overview of R&D Tasks ····· 1

Section 1 R&D Goal ····· 1

Section 2 Technology Trend ····· 2

(1) Trend of latest language model based on the transformer ····· 2

(2) Analysis of data augmentation for generalization of language model ····· 9

Section 3 R&D Roadmap ····· 18

Section 4 R&D project goals and contents ····· 19

Chapter 2 R&D Project Process and Contents ····· 25

(1) Development of LM specialized in S&T data analysis ····· 25

(2) Development of S&T knowledge extraction technology ····· 51

(3) Mid- to long-term development plan for AI technology ····· 67

Chapter 3 Results and Achievement ····· 76

1절 Quantitative achievement ····· 76

2절 Qualitative achievement ····· 81

Chapter 4 Contributions ····· 84

Chapter 5 R&D Plan ····· 85

Chapter 6 References ····· 86

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

목 차

1장 연구개발과제의 개요 ····· 1

1절 연구개발 최종 목표 ····· 1

2절 국내·외 기술개발 현황 ····· 2

(1) 트랜스포머 기반의 최신 언어모델 발전 동향 ····· 2

(2) 언어모델 일반화를 위한 데이터 증강 기법 분석 ····· 9

3절 단계별 연구개발 로드맵 ····· 18

4절 단계별 연구개발과제 목표 및 내용 ····· 19

2장 연구개발과제의 수행 과정 및 수행 내용 ····· 25

(1) 과학기술데이터 분석에 특화된 딥러닝 기반 언어 모델 개발 ····· 25

(2) 과학기술 지식 추출 기술 개발 ····· 51

(3) 인공지능 기술의 중장기 발전 계획 수립 ····· 67

3장 연구개발과제의 수행 결과 ····· 76

1절 정성적 연구개발성과 ····· 76

2절 정량적 연구개발성과 ····· 81

4장 연구개발성과의 관련 분야에 대한 기여 정도 ····· 84

5장 연구개발성과의 관리 및 활용 계획 ····· 85

6장 참고문헌 ····· 86

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

표목차

[표 1] 주어진 예산에서 최적의 언어모델 학습을 위한 모델 크기와 토큰 수 ····· 5
[표 2] 대표적 최신 언어모델의 GLUE 벤치마크 성능 비교 결과 ····· 6
[표 3] LinkBERT와 DeBERTaV3모델의 QA 태스크 성능 비교 ····· 7
[표 4] BioLinkBERT의 BLURB 벤치마크 성능 비교 결과 ····· 7
[표 5] 응용성, 의존성 및 필요성 등 측면에서 데이터 증강 방법 선택 비교. ····· 10
[표 6] 자연어 처리 분야 데이터 증강기술의 차이점에 대한 개관 [Chen2021b]. ····· 11
[표 7] 4종류 데이터 셋에서 EDA, SSMBA, MixUP, LINDA 데이터 증강기술의 성능 비교 ····· 16
[표 8] ID와 OOD를 고려한 6종류 데이터 셋에서 EDA, SSMBA, MixUP, LINDA 데이터 증강기술의 성능 비교 ····· 17
[표 9] 각 모델별 사전학습용 코퍼스 비교 ····· 26
[표 10] 사전학습 언어모델의 biomedical 분야 태스크별 성능 비교 표 [Gu2020] ····· 26
[표 11] PubMedBERT의 학습 데이터 형태(abstract, abstract+full-text)에 따른 성능 비교 결과 [Gu2020] ····· 27
[표 12] BioBERT모델의 사전학습 코퍼스 및 step 수와 Biomedical 분야 NER 태스크 성능 측정 결과 [Lee2020] ····· 28
[표 13] PubMedBERT의 vocab과 사전학습 방법에 따른 성능 차이 비교 [Gu2020] ····· 30
[표 14] roberta base 모델과 large모델의 architecture 차이 ····· 36
[표 15] 개체명 인식 F1 점수 ····· 42
[표 16] 관계추출 F1점수 ····· 43
[표 17] SciDeBERTa-BIO 모델 기반 태스크 모델에서 IFT 기법 적용 시 성능 개선 결과 ····· 46
[표 18] SuperGLUE 벤치마크 SOTA 언어 모델 ····· 47
[표 19] SciDeBERTa 모델의 사전학습 방안 요약 ····· 48
[표 20] SciDeBERTa-BIO 예비 모델들의 학습 방안 비교 ····· 49
[표 21] SciDeBERTa-BIO 예비 모델의 BLURB 벤치마크 성능 비교 결과 ····· 49
[표 22] 자체 개발한 SciDeBERTa 모델의 SciERC 및 GENIA 벤치마킹 결과 ····· 51
[표 23] 의공학분야 대표적 벤치마크 데이터셋인 BLURB에서의 성능평가 결과 ····· 52
[표 24] Neural Sequence Learning Model을 이용한 WSD 태스크의 성능 비교 ····· 55
[표 25] GlossBERT에 입력되는 문장 형식 (상단은 문맥 문장과 정의 문장 페어를 입력, 하단은 타깃 단어를 하이라이팅하고, 정의 문장에 한 번 더 입력하는 Weak Supervision 적용) ····· 56
[표 26] WSD 벤치마킹 데이터 셋을 활용한 성능 비교 결과 ····· 57
[표 27] Sense Vocabulary Compression 방법을 통한 압축률 ····· 59
[표 28] Sense Vocabulary Compression 방법의 성능 비교 ····· 59
[표 29] Extractive Sense Comprehension 방법의 성능 비교 ····· 60

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

그림목차

[그림 1] 인공지능기술연구단 연구 내용 구성도 ····· 1
[그림 2] 2018년에서부터 2020년까지 언어모델 규모의 변화 ····· 2
[그림 3] 모델 성능과 각 scale factor와의 거듭제곱 관계 ····· 3
[그림 4] OpenAI에서 2020년 제안한 언어모델의 규모의 법칙 ····· 3
[그림 5] DeepMind에서 최근 발표한 언어모델의 규모의 법칙 ····· 4
[그림 6] 최적의 언어모델 학습 조합을 찾기 위한 실험 결과 ····· 4
[그림 7] LinkBERT 모델의 사전학습 수행과정 ····· 5
[그림 8] ELECTRA의 모델 학습 구조 ····· 8
[그림 9] Vanilla embedding sharing ····· 8
[그림 10] Gradient-disentangled embedding sharing ····· 9
[그림 11] EDA를 통한 적은 데이터셋에서의 과적합 방지 효과와 성능개선 ····· 13
[그림 12] 역번역 기술 [chaudhary2020] ····· 14
[그림 13] 다양한 언어를 통한 역번역 기술을 통한 데이터 증강 예시[chaudhary2020] ····· 14
[그림 14] LINDA 프레임워크 아키텍쳐 ····· 16
[그림 15] 논문 데이터 연구 분야 분포 ····· 29
[그림 16] 비전분야 딥뉴럴 네트워크의 표현 학습 ····· 31
[그림 17] 언어모델 분야 딥 뉴럴 네트워크의 표현 학습 ····· 32
[그림 18] 재초기화를 통한 학습 손실로 확인되는 과적합 해소 효과 ····· 33
[그림 19] 계층별 재초기화를 통한 NER 태스크 성능 변화 ····· 33
[그림 20] 계층별 재초기화를 통한 RE 태스크 성능 변화 ····· 34
[그림 21] 학습데이터에 따른 모델의 성능 변화 ····· 35
[그림 22] 대소문자 구분에 따른 성능 변화 ····· 35
[그림 23] SciERC 데이터셋 IE 태스크에 대한 모델 크기에 따른 성능 비교 ····· 36
[그림 24] 학습 방법 및 데이터셋 크기 변화에 따른 성능 변화 ····· 37
[그림 25] Optimizer변화에 따른 정보추출 파인튜닝 태스크 성능 비교 ····· 38
[그림 26] 딥러닝 모델 optimizer의 발전 과정 ····· 39
[그림 27] AdamW optimizer 알고리즘 ····· 39
[그림 28] RAdam optimizer 알고리즘 ····· 40
[그림 29] AdamP optimizer 알고리즘 ····· 40
[그림 30] DYGIE++ framework ····· 41
[그림 31] Dygie++ 모델의 성능 개선 (타겟 : JRE) ····· 43
[그림 32] Dygie++ 모델의 성능 개선 (타겟 : NER) ····· 43
[그림 33] 의공학분야에서 IFT 기법의 검증 실험 결과. ····· 45
[그림 34] 일반적 언어 모델의 사전학습과 파인튜닝 수행 과정 ····· 46
[그림 35] 도메인 특화 언어 모델 학습을 위한 두 가지 방안 ····· 47
[그림 36] DeBERTa 모델의 구조 ····· 47
[그림 37] S2ORC 데이터셋의 구성요소와 분야별 분포 ····· 48

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그림 38] 배치크기 변화에 따라 throughput 및 정확률 성능 향상 ····· 50
[그림 39] Node 개수 증가에 따른 batch 크기 증가에 따라 throughput과 정확률 성능 향상 ····· 50
[그림 40] SciDeBERTa 모델의 SciERC 기준 세계 1위 달성 (2022.10.24. 기준 Paperswithcode 페이지 캡쳐) ····· 52
[그림 41] WSD 태스크를 위한 Bidirectional LSTM 기반의 Neural Sequence Learning Model 구조도 ····· 53
[그림 42] WSD 태스크를 위한 Attention 층을 추가한 Bidirectional LSTM 기반의 Neural Sequence Learning Model 구조도 ····· 54
[그림 43] WSD 태스크를 위한 Attention 층을 추가한 인코더-디코더 기반의 Neural Sequence Learning Model 구조도 ····· 54
[그림 44] WSD 태스크를 위한 Attention 층을 추가한 인코더-디코더 기반의 Neural Sequence Learning Model 구조도 ····· 54
[그림 45] BERT 모델을 활용한 GlossBERT 구조도 ····· 56
[그림 46] 워드넷 센스를 신셋 번호로 압축하는 방법 개요도 ····· 58
[그림 47] 워드넷의 상하위 개념 관계를 이용한 압축 방식 ····· 58
[그림 48] Extractive Sense Comprehension 방법 개요도 ····· 60
[그림 49] DeBERTa 모델을 활용한 ConSec의 상대적 위치 추가 방식 ····· 61
[그림 50] ConSec의 성능 평가 결과(최고 성능 달성) ····· 61
[그림 51] BEM과 ESR을 동시에 활용한 하이브리드 모형 ····· 65
[그림 52] SACE 아키텍처+DeBERTa, ESR 방식의 후보 문장 증강을 활용한 하이브리드 모형 · 67
[그림 53] QAngaroo의 질문/답변 예시 ····· 68
[그림 54] QAngaroo 리더보드 (2021년 12월) ····· 68
[그림 55] HotpotQA 리더보드 (2021년 12월) ····· 69
[그림 56] BigBird의 어텐션 메카니즘 ····· 70
[그림 57] SAE 시스템 구조 ····· 70
[그림 58] HopRetriever의 추론과정 ····· 71
[그림 59] Data2Vec의 Multi-Modal 통합 학습 방식 ····· 72
[그림 60] VilBert의 변형 트랜스포머 사용 모델 구조 ····· 73
[그림 61] 호주의 데이터 공유 검색 서비스 (Research Data Australia) ····· 74

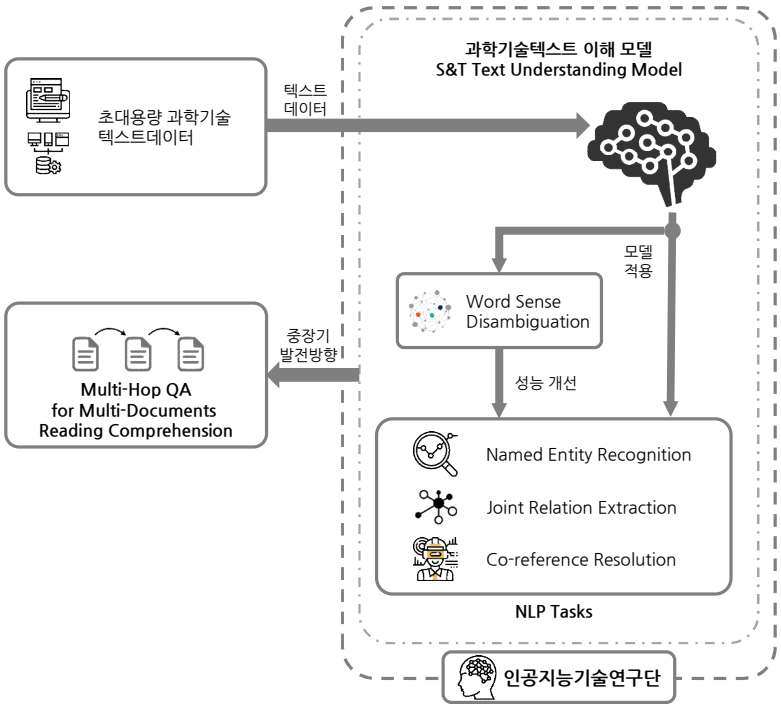
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1장 연구개발과제의 개요

1절 연구개발 최종 목표

과학기술 데이터 분석을 위한 기계 이해(Machine Understanding) 핵심 기술 개발
1 과학기술 텍스트로부터의 지능화된 정보 추출 및 그 결과의 지식화
2 과학기술 데이터의 통합 이해 모델 고도화 및 활용 체계 개발

주요 연구 내용	**1 과학기술 텍스트에 특성화된 딥러닝 기반 정보 추출 기술 개발('21~'22)** · 과학기술 분야 서비스에 특화된 딥 러닝 언어 모델 연구 · 과학기술 분야 지식 추출을 위한 개체명 인식(Named Entity Recognition), 개체명 관계 추출(Joint Entity and Relation Extraction), 상호참조 해소(Co-Reference Resolution), 단어 중의성 해소(Word Sense Disambiguation)를 위한 기술 연구 · 중장기 연구 방향성 수립을 위한 다단계 추론 기반 질의응답(Multi-Hop Q&A) 기술 조사 및 기획보고서 작성
	2 과학기술 데이터의 통합 이해 모델 고도화 및 활용 체계 개발 ('23~'25) · 다중 문서의 정보를 상호 연계 분석 · 이해 · 추론할 수 있는 다단계 질의응답(Multi-Hop Q&A) 모델 연구 · KISTI 서비스 및 업무 영역으로 활용을 위한 현장 적용 및 고도화 방안 연구



[그림 1] 인공지능기술연구단 연구 내용 구성도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

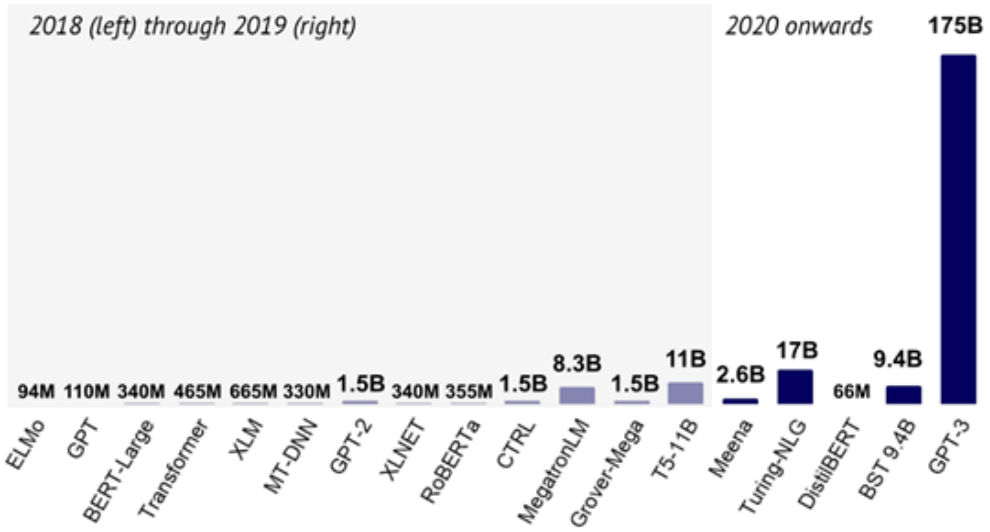
2절 국내·외 기술개발 현황

(1) 트랜스포머 기반의 최신 언어모델 발전 동향

□ 언어 모델의 규모 변화

○ 언어 모델의 규모의 법칙

- BERT를 시작으로하는 언어 모델의 발전과정에서 언어 모델의 규모는 짧은 시간만에 크게 증가되어왔음. 언어모델이 커질수록 더 좋은 성능을 보여왔고 이에 언어모델 규모가 큰 경쟁력이자 중요요소로 여겨져 왔음.



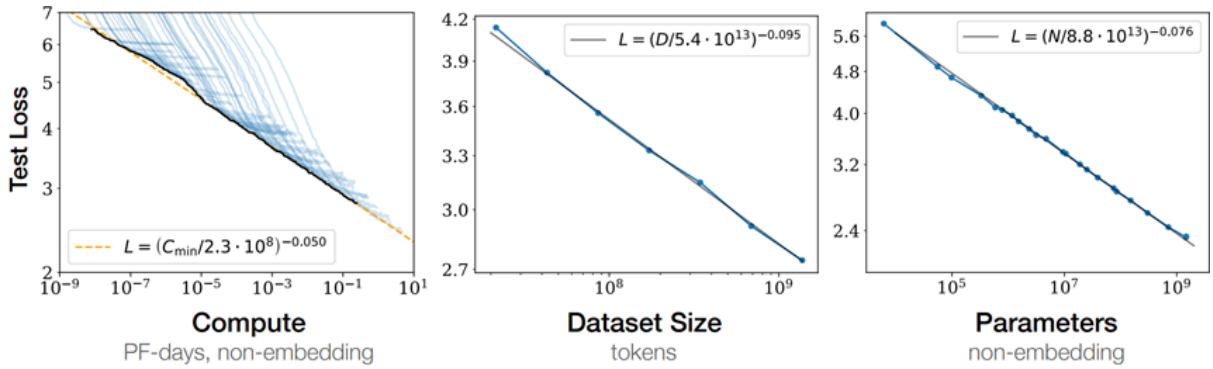
[그림 2] 2018년에서부터 2020년까지 언어모델 규모의 변화

- 그러나 모델 학습을 위한 자원은 한정적이기에, 특정양의 컴퓨팅이 정해져있다면 최상의 성능을 얻기 위해서는 얼마나 큰 모델을 훈련해야하는 지는 항상 논의되어온 주제임. 이때 항상 큰 모델만이 좋은 성능을 보장하지 않았음. 고정된 양의 컴퓨팅에서 모델 크기를 키울수록 학습 데이터 규모가 적어지기 때문임.
  - 예: 1M parameter model on 10 books = 10M parameter model on one book
- 이에따라 고정된 예산(FLOP)이 주어진다면 모델크기와 데이터크기(토큰수)를 어떻게 조정해야하는지에 관한 연구가 수행되어옴.
- OpenAI에서는 2020년 실험을 통해 얻은 결과로서 언어모델 성능을 예측하기 위한 규모의 법칙을 발표함. 이는 학습시간, 컨텍스트 길이, 모델 사이트, 연산 비용을 변수로 고려하여 수행된 실험임.
- 실험결과 모델 성능은 모델 shape보다 scale에 더 강한 영향을 받았음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

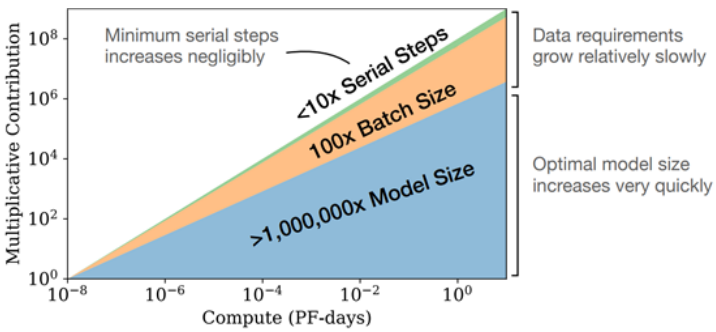
- Scale: 모델 파라미터 수, 데이터셋 사이즈, 컴퓨팅량
- Shape: depth나 width같은 모델 아키텍쳐

- 또한 성능은 scale factor가 서로 다른 두 요인에 의해 병복 현상이 발생하지 않는 이상 각기 거듭제곱 관계를 가짐.



[그림 3] 모델 성능과 각 scale factor와의 거듭제곱 관계

- 대형 모델은 소형모델보다 샘플 효율성이 높으며, 더 적은 최적화 단계와 더 적은 데이터 포인트를 사용하여 동일한 수준의 성능에 도달할 수 있음을 주장함. 따라서 convergency는 비효율적이고 대형모델을 학습하고 convergency에 미치지 않는 지점에서 멈추어 최적의 성능을 얻을 수 있음을 주장함.
- 또한 모델 크기를 8배 늘릴 때마다 데이터를 약 5배 늘려야한다고 제안하며, 만약 컴퓨팅 예산이 10배 증가한다면 모델 크기는 5.5배, 학습 토큰 수는 1.8배 늘려야한다는 아래 그래프와 같은 규모의 법칙을 제안함.

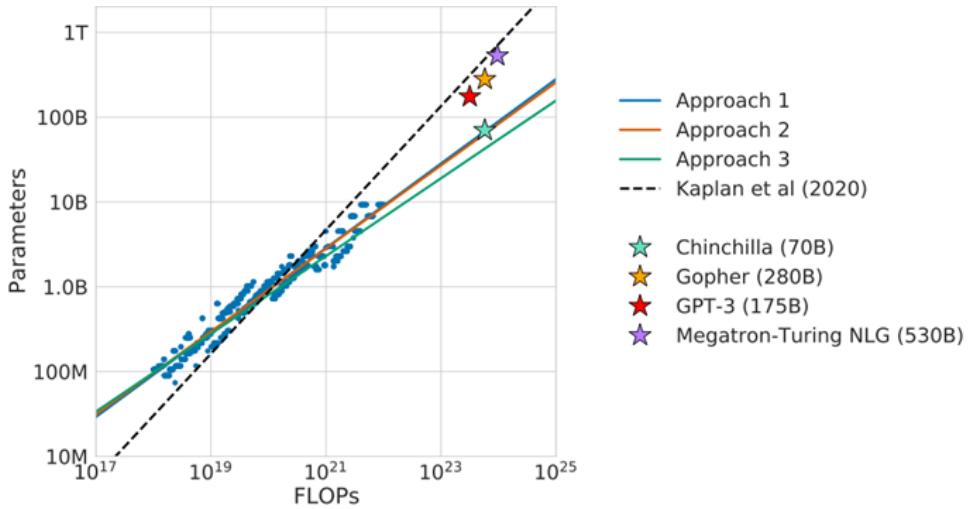


[그림 4] OpenAI에서 2020년 제안한 언어모델의 규모의 법칙

- 그러나 최근 2022년 DeepMind에서는 이런 OpenAI의 규모의 법칙과 조금 다른 실험 결과를 보이는 연구 결과를 발표함. OpenAI의 주장보다 모델 사이즈를 더 줄이고 학습 토큰 수를 늘려야한다는 주장으로 이를 뒷받침하기 위해 찾아낸 규칙에 따라 70B의 파라미터를 가진 모델을 1.4T의 토큰으로 학습한 Chinchilla 모델을 소개하고 기존 대규모 언어 모델 대비 좋은 성능을 얻었음을 확인함.

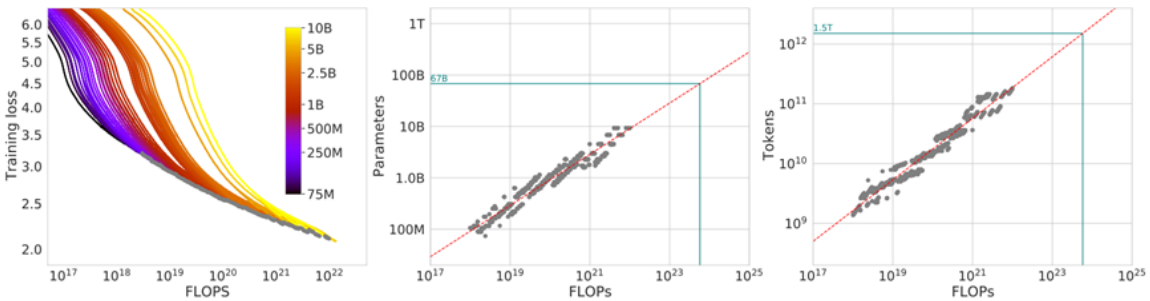
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 아래 그래프에서 Approach 1,2,3은 DeepMind가 새로운 법칙을 찾아내기 위해 수행한 각 실험 방법의 결과를 보이며 이는 OpenAI의 결과(점선)가 다른 양상을 보임.



[그림 5] DeepMind에서 최근 발표한 언어모델의 규모의 법칙

- 이러한 결과에 의하면 현재 대표적 언어모델들인 Gopher, GPT-3, Megatron-Turing NLG 등은 상당히 언더피팅 되어있음. 따라서 Chinchilla와 마찬가지로 더 작은 규모의 모델을 더 많은 수의 토큰으로 훈련함으로써 더 큰 대규모 언어 모델보다 높은 성능을 얻을 수 있음을 보임.
- 실험에서는 모델 사이즈를 70M에서 10B까지 예산인 FLOPS를 변화시키며 학습을 통해 loss의 수렴점을 이어서 아래 그림의 왼쪽 그래프를 획득함. 그리고 각 FLOP별로 최소 loss값을 추출하고 그 지점에서부터 모델 사이즈를 유추(가운데 그림)하고 학습을 위한 토큰 수를 유추(오른쪽 그림)함.



[그림 6] 최적의 언어모델 학습 조합을 찾기 위한 실험 결과

- 최종적으로 아래 표와 같은 최적의 예산, 모델크기, 토큰 수의 조합을 제시함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

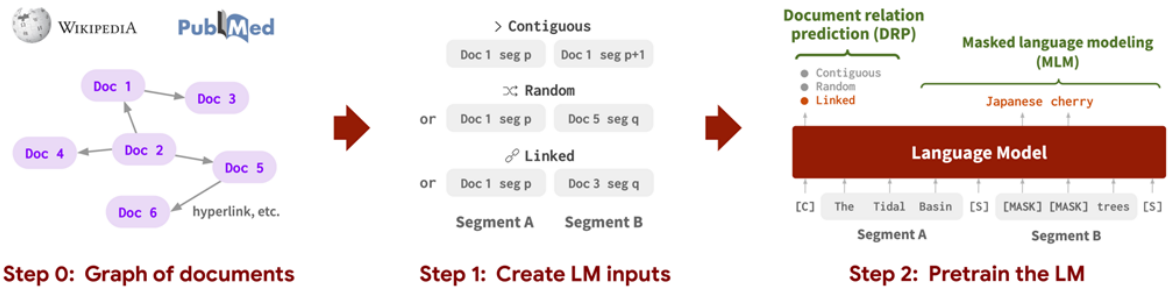
Parameters	FLOPs	FLOPs (in *Gopher* unit)	Tokens
400 Million	1.92e+19	1/29,968	8.0 Billion
1 Billion	1.21e+20	1/4,761	20.2 Billion
10 Billion	1.23e+22	1/46	205.1 Billion
67 Billion	5.76e+23	1	1.5 Trillion
175 Billion	3.85e+24	6.7	3.7 Trillion
280 Billion	9.90e+24	17.2	5.9 Trillion
520 Billion	3.43e+25	59.5	11.0 Trillion
1 Trillion	1.27e+26	221.3	21.2 Trillion
10 Trillion	1.30e+28	22515.9	216.2 Trillion

[표 1] 주어진 예산에서 최적의 언어모델 학습을 위한 모델 크기와 토큰 수

□ 트랜스포머 기반의 최신 언어 모델

○ LinkBERT[Yasunaga2020]

- BERT를 개선한 모델로, 여러 문서간 나타나는 하이퍼링크나 참조링크와 같은 문서간 연결 지식을 학습함. 이는 지식 추론을 요구하는 QA와 같은 태스크나 문서간 연결이 필요한 reading comprehension, document retrieval 태스크에서 뛰어난 성능을 보임.
- LinkBERT는 먼저 텍스트 코퍼스에서 문서간 링크를 추출하여 document graph를 구축하며, link를 인지할 수 있도록하는 training instance를 graph로부터 추출함. 마지막으로 이를 self-supervised 태스크로 학습하면서 next sentence prediction 태스크에서 추가적으로 document relation 또한 추축하도록 추가함.



[그림 7] LinkBERT 모델의 사전학습 수행과정

- Step 0: 문서간 연결을 나타내는 graph는 자유롭게 정의할 수 있지만 본 연구에서는 하이퍼링크와 참조 링크를 기준으로 생성해냄. 이는 문서간 하이퍼링크나 참조 링크가 있는 경우 두 문서가 높은 확률로 상관관계가 있기때문임. 각 문서를 node로, 그리고 link 관계를 directed edge로 나타내어 graph를 구성함.
- Step 1: 먼저 각 문서를 BERT의 최대 입력 길이의 절반인 256 토큰의

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세그먼트로 나누고, document graph의 link에 따라서 두 개의 세그먼트를 이은다음 이를 link관계에 있는 입력으로함. 따라서 기존 BERT의 contiguous, random 관계의 segment에 위 link관계의 segment가 추가됨.

- Step 2: LM은 BERT와 동일하게 MLM방식으로 학습되며 이때 기존 BERT의 NSP를 확장하여 문서간 관계 예측을 추가한 DRP를 수행함.
- LinkBERT는 기존 BERT와 유사하게 위키피디아, 책, 기사 등의 일반 도메인에서 학습한 LinkBERT와 의공학 분야의 PubMedBERT와 유사하게 PubMed의 논문 데이터로 학습한 BioLinkBERR 두 가지를 모두 동시에 제안함.
- 일반 도메인 모델의 GLUE 벤치마크 성능 비교결과 (아래 그림) LinkBERT가 BERT와 유사한 수준의 성능을 보임을 확인. 유사하게 최근에 제시된 언어모델인 DeBERTaV3에 비해서는 낮은 벤치마킹 성능을 보임. 그러나 QA 태스크 성능 결과를 보면 더 우수한 성능을 달성했음을 확인할 수 있었음.
- 의공학분야 도메인 언어모델인 BioLinkBERT의 대표적 의공학분야 벤치마크 BLRUB에서 비교해보았을 때, 일반 도메인에서와 유사하게 특히 QA관련 태스크에서 높은 성능향상을 보임을 확인.

BERT

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	**Average** -
$\text{BERT}_{\text{BASE}}$	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
$\text{BERT}_{\text{LARGE}}$	**86.7/85.9**	**72.1**	**92.7**	**94.9**	**60.5**	**86.5**	**89.3**	**70.1**	**82.1**

DeBERTaV3 (large)

Model #Train	CoLA Mcc 8.5k	QQP Acc 364k	MNLI-m/mm Acc 393k	SST-2 Acc 67k	STS-B Corr 7k	QNLI Acc 108k	RTE Acc 2.5k	MRPC Acc 3.7k	Avg.
$\text{BERT}_{\text{large}}$	60.6	91.3	86.6/-	93.2	90.0	92.3	70.4	88.0	84.05
$\text{RoBERTa}_{\text{large}}$	68.0	92.2	90.2/90.2	96.4	92.4	93.9	86.6	90.9	88.82
$\text{XLNet}_{\text{large}}$	69.0	92.3	90.8/90.8	**97.0**	92.5	94.9	85.9	90.8	89.15
$\text{ELECTRA}_{\text{large}}$	69.1	92.4	90.9/-	96.9	92.6	95.0	88.0	90.8	89.46
$\text{DeBERTa}_{\text{large}}$	70.5	92.3	91.1/91.1	96.8	92.8	95.3	88.3	91.9	90.00
$\text{DeBERTaV3}_{\text{large}}$	**75.3**	**93.0**	**91.8/91.9**	96.9	**93.0**	**96.0**	**92.7**	**92.2**	**91.37**

LinkBERT

	GLUE score
$\text{BERT}_{\text{tiny}}$	64.3
$\text{LinkBERT}_{\text{tiny}}$	**64.6**
$\text{BERT}_{\text{base}}$	79.2
$\text{LinkBERT}_{\text{base}}$	**79.6**
$\text{BERT}_{\text{large}}$	80.7
$\text{LinkBERT}_{\text{large}}$	**81.1**

[표 2] 대표적 최신 언어모델의 GLUE 벤치마크 성능 비교 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

LinkBERT

	HotpotQA	TriviaQA	SearchQA	NaturalQ	NewsQA	SQuAD	Avg.
$\text{BERT}_{\text{tiny}}$	49.8	43.4	50.2	58.9	41.3	56.6	50.0
$\text{LinkBERT}_{\text{tiny}}$	**54.6**	**50.0**	**58.6**	**60.3**	**42.8**	**58.0**	**54.1**
$\text{BERT}_{\text{base}}$	76.0	70.3	74.2	76.5	65.7	88.7	75.2
$\text{LinkBERT}_{\text{base}}$	**78.2**	**73.9**	**76.8**	**78.3**	**69.3**	**90.1**	**77.8**
$\text{BERT}_{\text{large}}$	78.1	73.7	78.3	79.0	70.9	91.1	78.5
$\text{LinkBERT}_{\text{large}}$	**80.8**	**78.2**	**80.5**	**81.0**	**72.6**	**92.7**	**81.0**

DeBERTaV3

Model	MNLI-m/mm Acc	SQuAD v2.0 F1/EM	RACE Acc	ReCoRD F1/EM	SWAG Acc	NER F1
$\text{BERT}_{\text{large}}$	86.6/-	81.8/79.0	72.0	-	86.6	92.8
$\text{ALBERT}_{\text{large}}$	86.5/-	84.9/81.8	75.2	-	-	-
$\text{RoBERTa}_{\text{large}}$	90.2/90.2	89.4/86.5	83.2	90.6/90.0	89.9	93.4
$\text{XLNet}_{\text{large}}$	90.8/90.8	90.6/87.9	85.4	-	-	-
$\text{ELECTRA}_{\text{large}}$	90.9/-	-/88.1	-	-	-	-
$\text{Megatron}_{\text{336M}}$	89.7/90.0	88.1/84.8	83.0	-	-	-
$\text{DeBERTa}_{\text{large}}$	91.1/91.1	90.7/88.0	86.8	91.4/91.0	90.8	93.8
$\text{DeBERTaV3}_{\text{large}}$	**91.8/91.9**	**91.5/89.0**	**89.2**	**92.3/91.8**	**93.4**	**93.9**
$\text{ALBERT}_{\text{xxlarge}}$	90.8/-	90.2/87.4	86.5	-	-	-
$\text{Megatron}_{\text{1.3B}}$	90.9/91.0	90.2/87.1	87.3	-	-	-
$\text{Megatron}_{\text{3.9B}}$	91.4/91.4	91.2/88.5	89.5	-	-	-
$\text{DeBERTa}_{\text{1.5B}}$	91.7/91.9	92.2/89.7	90.8	94.5/94.0	92.3	-

[표 3] LinkBERT와 DeBERTaV3모델의 QA 태스크 성능 비교

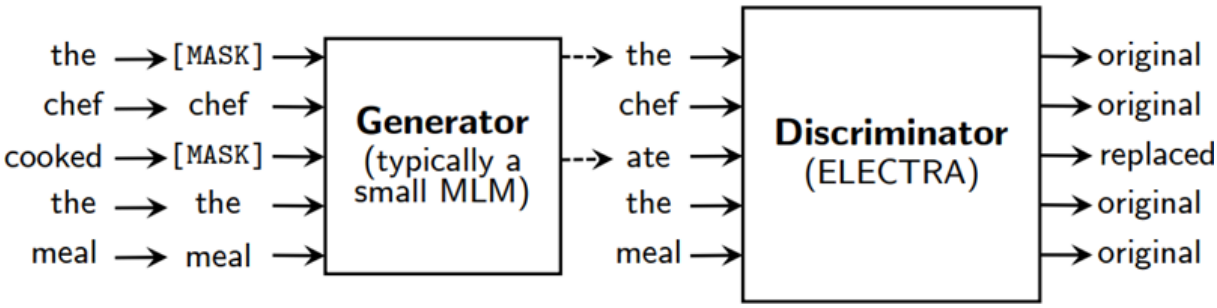
	PubMed-$\text{BERT}_{\text{base}}$	BioLink-$\text{BERT}_{\text{base}}$	BioLink-$\text{BERT}_{\text{large}}$
Named entity recognition			
BC5-chem (Li et al., 2016)	93.33	**93.75**	**94.04**
BC5-disease (Li et al., 2016)	85.62	**86.10**	**86.39**
NCBI-disease (Doğan et al., 2014)	87.82	**88.18**	**88.76**
BC2GM (Smith et al., 2008)	84.52	**84.90**	**85.18**
JNLPBA (Kim et al., 2004)	**80.06**	79.03	**80.06**
PICO extraction			
EBM PICO (Nye et al., 2018)	73.38	**73.97**	**74.19**
Relation extraction			
ChemProt (Krallinger et al., 2017)	77.24	**77.57**	**79.98**
DDI (Herrero-Zazo et al., 2013)	82.36	**82.72**	**83.35**
GAD (Bravo et al., 2015)	82.34	**84.39**	**84.90**
Sentence similarity			
BIOSSES (Soğancıoğlu et al., 2017)	92.30	**93.25**	**93.63**
Document classification			
HoC (Baker et al., 2016)	82.32	**84.35**	**84.87**
Question answering			
PubMedQA (Jin et al., 2019)	55.84	**70.20**	**72.18**
BioASQ (Nentidis et al., 2019)	87.56	**91.43**	**94.82**
BLURB score	81.10	**83.39**	**84.30**

[표 4] BioLinkBERT의 BLURB 벤치마크 성능 비교 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

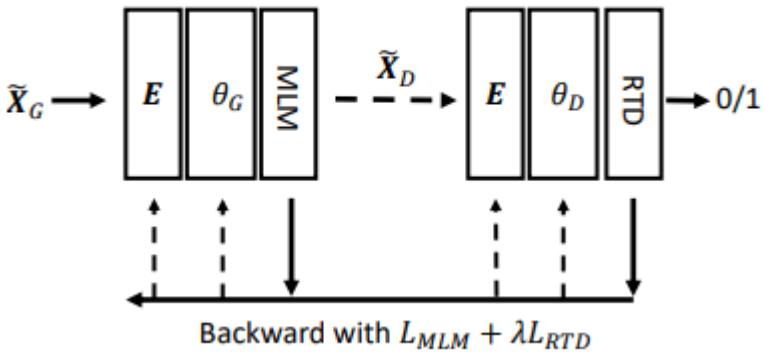
○ DeBERTaV3[He2021]

- 기존 DeBERTa 모델을 더욱 개선한 모델로, ELECTRA 스타일의 사전학습 방식과 gradient-disentangled embedding sharing 두 가지 기법을 새로 적용함.
- ELECTRA 학습 방법은 생성된 토큰으로 다음 discriminator의 입력 토큰을 대체하는 generator와 이를 교체된 토큰인지 감지(RTD; Replaced Token Detection)하는 discriminator로 구성되어 학습하는 방안임.



[그림 8] ELECTRA의 모델 학습 구조

- ELECTRA의 학습 방법에서는 Loss의 계산이 generator의 MLM loss와 discriminator의 RTD loss의 합으로 계산됨.
- 또한 generator와 discriminator가 token embedding을 서로 공유할수록 있도록 함. 이는 discriminator가 generator로부터 샘플링된 토큰만 업데이트하는 반면 generator는 모든 토큰 임베딩을 업데이트하기 때문에 성능 향상에 도움이 됨.



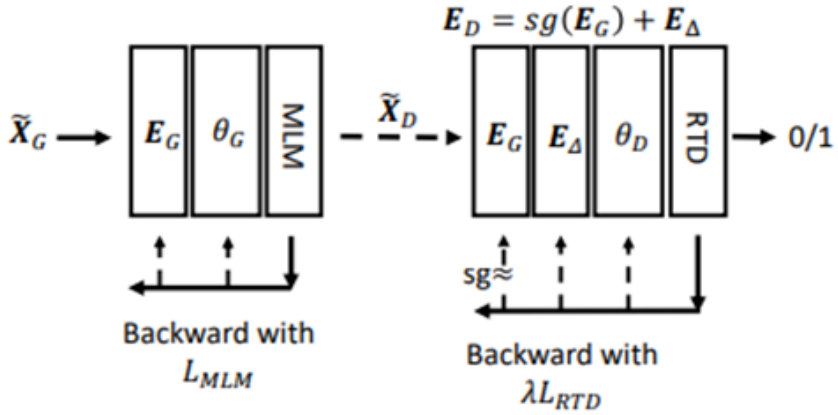
[그림 9] Vanilla embedding sharing

- 그러나 이러한 학습 방안에서 generator와 discriminator의 MLM과 RTD 태스크의 최적점이 서로 다르기에 각자의 최적점으로 서로 향하려는 작용이 서로를 방해하게됨. MLM은 서로 의미적으로 유사한

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

토큰을 가까이하려는 태스크지만 RTD는 의미론적으로 유사한 토큰들을 식별하고 분류하기 위해 서로를 멀리 밀어내는 태스크임.

- DeBERTaV3에서는 gradient-disentangled embedding sharing (GDES)으로 이를 해결함. GDES는 한방향으로만 embedding을 sharing함.
- MLM은 generator와 discriminator의 embedding을 업데이트하는 데 모두 사용되지만 RTD는 discriminator의 embedding의 업데이트만에 사용됨.



[그림 10] Gradient-disentangled embedding sharing

(2) 언어모델 일반화를 위한 데이터 증강 기법 분석

□ 자연어 처리 데이터 증강의 기술적 배경

○ 자연어 처리 데이터 증강의 기술적 배경

- 언어 모델의 발전으로 BERT의 등장과 함께 자연어 처리 분야에서의 획기적인 성공이 가능하게 됨. SQuAD 1.1 벤치마크[Rajpurkar2016a]의 경우 F1 스코어 91.2가 사람이 낼 수 있는 성능이라 여겨졌는데, 2019년 4월 처음 딥러닝 기반 모델들이 이 성능치를 넘음. 또한 GLUE 벤치마크[Wang2019]의 경우 87.1을 사람 성능이라 여겨졌는데 이 또한 2019년 7월부터 딥러닝 기반 모델들이 이를 상회함[KyonghaLee2021].
- 비전 영역은 딥러닝 모델 발전과 함께 2015년 ILSVRC 챌린지[Russakovsky& Deng2015]에서 인간의 인지 성능을 넘어서며 산업계에서 다양한 영역에 비전 인공지능 기술을 적용 중임. 비전 영역에서 데이터 증강은 모델의 성능 향상과 더불어 노이즈 강인화의 중요한 요소임. 같은 맥락으로 자연어 처리 영역에서도 데이터 증강은 중요한 기술임. BERT 이후의 언어 모델의 성능 향상은 학계를 포함한 산업계의 큰 관심 영역이 되었고, 텍스트 영역의 데이터 증강기술이 큰

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

관심의 영역이 되고 있음.

- 기계학습 측면에서 데이터 증강기술은 더 다양하고 풍부한 학습 데이터를 늘이는 데이터 클리닝 작업 중의 일부임. 기계학습 처리 과정의 두 번째 단계인 데이터 수집 분석단계에 해당됨. 딥러닝 알고리즘은 기계학습 모델로 결국 모델의 성능은 데이터가 중요함. 데이터 증강기술은 딥러닝 알고리즘 성공을 위한 기본 기술임.
- 데이터 증강기술을 기계학습 측면에서 딥러닝 알고리즘의 성능개선을 위한 방법인 일반화, 정규화, 특징 평균화 및 분산 감소로 해석한 연구들이 있음. 모델 데이터셋의 균형을 맞추거나 모델의 범용성을 높이고자 일반화 성능 향상을 위해 데이터 증강을 함. 보통 정규화는 데이터에 비해 모델 크기의 크기가 클 때 사용되며, 특징 평균화 및 분산 감소는 데이터 전처리 과정에서 기계적인 해석이 가능하도록 입력 데이터를 가공할 때 이뤄지는 작업임.

DA Method	Ext.Know	Pretrained	Preprocess	Level	Task-Agnostic
SYNONYM REPLACEMENT (Zhang et al., 2015)	✓	×	tok	Input	✓
RANDOM DELETION (Wei and Zou, 2019)	×	×	tok	Input	✓
RANDOM SWAP (Wei and Zou, 2019)	×	×	tok	Input	✓
BACKTRANSLATION (Sennrich et al., 2016)	×	✓	Depends	Input	✓
SCPN (Wieting and Gimpel, 2017)	×	✓	const	Input	✓
SEMANTIC TEXT EXCHANGE (Feng et al., 2019)	×	✓	const	Input	✓
CONTEXTUALAUG (Kobayashi, 2018)	×	✓	-	Input	✓
LAMBADA (Anaby-Tavor et al., 2020)	×	✓	-	Input	×
GECA (Andreas, 2020)	×	×	tok	Input	×
SEQMIXUP (Guo et al., 2020)	×	×	tok	Input	×
SWITCHOUT (Wang et al., 2018b)	×	×	tok	Input	×
EMIX (Jindal et al., 2020a)	×	×	-	Emb/Hidden	✓
SPEECHMIX (Jindal et al., 2020b)	×	×	-	Emb/Hidden	Speech/Audio
MIXTEXT (Chen et al., 2020c)	×	×	-	Emb/Hidden	✓
SIGNEDGRAPH (Chen et al., 2020b)	×	×	-	Input	×
DTREEMORPH (Şahin and Steedman, 2018)	×	×	dep	Input	✓
Sub^2 (Shi et al., 2021)	×	×	dep	Input	Substructural
DAGA (Ding et al., 2020)	×	×	tok	Input+Label	×
WN-HYPERS (Feng et al., 2020)	✓	×	const+KWE	Input	✓
SYNTHETIC NOISE (Feng et al., 2020)	×	×	tok	Input	✓
UEDIN-MS (DA part) (Grundkiewicz et al., 2019)	✓	×	tok	Input	✓
NONCE (Gulordava et al., 2018)	✓	×	const	Input	✓
XLDA (Singh et al., 2019)	×	✓	Depends	Input	✓
SEQMIX (Zhang et al., 2020)	×	✓	tok	Input+Label	×
SLOT-SUB-LM (Louvan and Magnini, 2020)	×	✓	tok	Input	✓
UBT & TBT (Vaibhav et al., 2019)	×	✓	Depends	Input	✓
SOFT CONTEXTUAL DA (Gao et al., 2019)	×	✓	tok	Emb/Hidden	✓
DATA DIVERSIFICATION (Nguyen et al., 2020)	×	✓	Depends	Input	✓
DIPS (Kumar et al., 2019a)	×	✓	tok	Input	✓
AUGMENTED SBERT (Thakur et al., 2021)	×	✓	-	Input+Label	Sentence Pairs

[표 5] 응용성, 의존성 및 필요성 등 측면에서 데이터 증강 방법 선택 비교.

- 데이터 증강은 노이즈 샘플 추가한 학습을 Tikhonov regularization(L2 정규화 합)임 [Bishop1995].
- 데이터 증강은 특징들의 평균화 과정 및 분산 정규화 과정으로

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

해석하는 커널 차용 효과임 [Rajput2019].

- 데이터 증강은 데이터 분포의 분산을 감소시키는 것과 같음 [Chen2020].

- 자연어 처리 분야에서 응용성, 의존성 및 필요성 등 다양한 측면에서 데이터를 증강하는 방법을 선택하는 기준은 위 표와 같음.
- Ext. Know는 외부 지식(External Knowledge), KWE는 키워드 추출(keyword extraction), tok는 토큰화(tokenization), const는 후원 구문 분석(constituency parsing), dep는 의존성 분석(dependency parsing)을 각각 나타냄.
- 두 번째 열인 Ext. Know는 WordNet과 같은 외부지식을 활용 여부를, Pretrained는 BERT와 같은 사전학습 모델을 활용 여부를 나타냄.
- Preprocess는 전처리 필요 여부를, Level은 데이터증강(DA)에 의해 수정된 데이터의 깊이를 나타내며, Task-Agnostic은 DA 방법이 서로 다른 태스크에 적용 가능 여부를 나타냄.
- 자연어 처리 분야에서 데이터를 증강하고 이에 대한 성능을 평가하는 방법은 태스크에 따라 그 성능이 다름. 아래 표는 각 텍스트 데이터 증강기법과 이에 대한 평가 방법을 정리한 것임.

방법	언어레벨	다양성	태스크	참조 논문
유사어 대체	토큰	저	텍스트 분류 시퀀스 레이블링	[Wei2019]
LM기반 단어 교체	토큰	중	텍스트 분류 시퀀스 레이블링 기계번역	[Gao2019] [Wu2019]
임의 삽입, 삭제, 교체	토큰	저	텍스트 분류 시퀀스 레이블링 기계번역 대화 생성	[Wei2019] [XIE2020]
두 문장 혼합	토큰	고	텍스트 분류 시퀀스 레이블링 언어 모델링 텍스트 생성	[Andreas2020] [Guo2020]
의역(paraphrasing)	문장	고	텍스트 분류 기계번역 질의응답 대화 생성 텍스트 요약	[XIE2020] [Cai2020] [Chen2019] [Chen2020b]
조건부생성	문장	고	텍스트 분류 질의응답	[Kumar2020]
white-box 공격	토큰 혹은 문장	중	텍스트 분류 시퀀스 레이블링 기계번역	[Chen2019]

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

black-box 공격	토큰 혹은 문장	중	텍스트 분류 시퀀스 레이블링 기계번역 대화 생성 텍스트 함의 대화 생성 텍스트 요약	[Min2020] [Tan2020]
은닉 공간 변화 (hidden-space perturbation)	토큰 혹은 문장	고	텍스트 분류 시퀀스 레이블링 음성 인식	[Shen2020] [Chen2021]
보간(interpolation)	토큰	고	텍스트 분류 시퀀스 레이블링 기계번역	[Guo2020] [Yekyung2021]

[표 6] 자연어 처리 분야 데이터 증강기술의 차이점에 대한 개관 [Chen2021b].

□ 자연어 처리 데이터 증강의 연구 트렌드

○ 데이터 증강기술은 크게 토큰 레벨의 데이터 증강과 문장 레벨의 데이터 증강으로 나눌 수 있음.

○ 토큰 레벨의 데이터 증강기술 중 가장 쉽게 접근하는 방법으로 다음 기술들이 있음.

- 임의의 단어들을 유사어로 교체하거나 일부 단어를 삭제하는 등의 방법
- 성능이 좋으면서도 쉬운 접근 방법으로 문장들을 파싱 후 문법 트리의 어휘 머리(lexical head)들의 하위 부분 트리들을 생성 후, WordNet에서 유사어를 대체하여 증강기술. 데이터 증강셋을 학습 시 어떻게 활용하는지도 성능에 크게 영향을 미침을 실험을 통해 검증한 사례도 있음[Kim2022].
- 언어 모델의 발전과 함께 BERT에서 일부 단어들을 가리고(Masking) 해당 단어가 무엇이었는지를 맞추는 MLM(Masked Language Model) 태스크를 활용하여 학습된 언어 모델로 단어 맞추기 태스크의 상위 랭킹 된 단어를 대체하여 문장을 확대하는 형태의 연구가 최근 활발히 활용되고 있음 [FengandVarun2021].
- 언어 모델 학습 시 과적합 해소를 위한 정규화 방법 중 하나인 드랍아웃(Drop-Out)을 Contrastive Learning 모델에서 데이터 증강기술로 활용하여 큰 성능 향상을 확인한 사례도 있음 [Gao2021SimCSE].

○ 문장 레벨의 데이터 증강기술 중 고전적으로 사용되어온 기술로 역 번역 기술이 있고 최근 언어 모델 발전과 함께 두 문장을 혼합하여 새로운 문장을 구성하고 이를 통해 데이터셋 구성의 일반화 성능을 향상하는 방향의 연구가 있음.

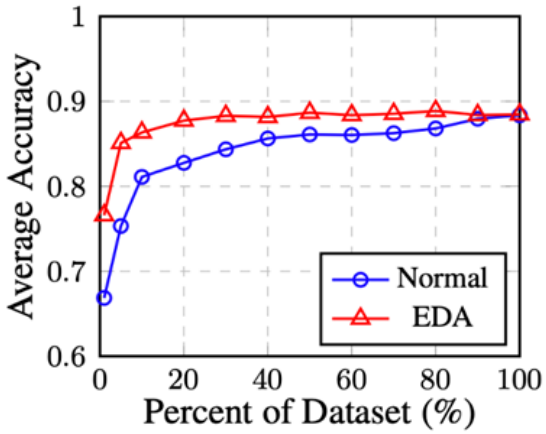
- 역 번역 기술은 문장을 다른 나라 언어로 번역하였다가 이를 다시 다른 본 언어로 번역하면서 나오는 다양한 문장들을 취하는 방식임.
- 두 문장을 혼합하는 기술은 최근 Mix-Up기술 및 BART와 같은

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

인코더와 디코더를 혼합한 구조의 트랜스포머의 예측(Prediction) 기술을 활용한 방법 등이 있음.

□ 자연어 처리 분야 데이터 증강기술

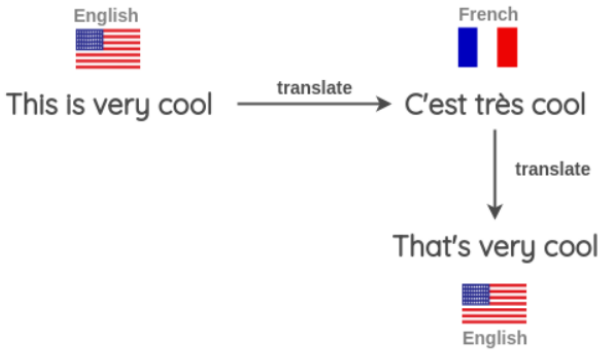
- 쉬운 데이터 증강기술 : EDA(Easy Data Augmentation)은 유사어 대체, 임의 삽입, 임의 두 단어 위치 교체, 임의 삭제 등의 방법들로 구성됨[Wei2019].
  - Synonym Replacement(SR) : 불용어(stop words)를 제외한 문장의 일부 n개의 단어를 유사어로 대체.
  - Random Insertion(RI) : 불용어가 제외된 문장의 일부 n개의 일부 유사 단어를 찾음. 유사어를 문장 내 임의 위치에 삽입. 이를 n번 반복.
  - Random Swap(RS) : 문장 내 임의 두 단어를 찾아서 그 위치를 교환, 이를 n번 반복.
  - Random Deletion(RD) : 문장 내 각 단어에 대해 확률 p에 기반 이를 임의로 제거.



[그림 11] EDA를 통한 적은 데이터셋에서의 과적합 방지 효과와 성능개선

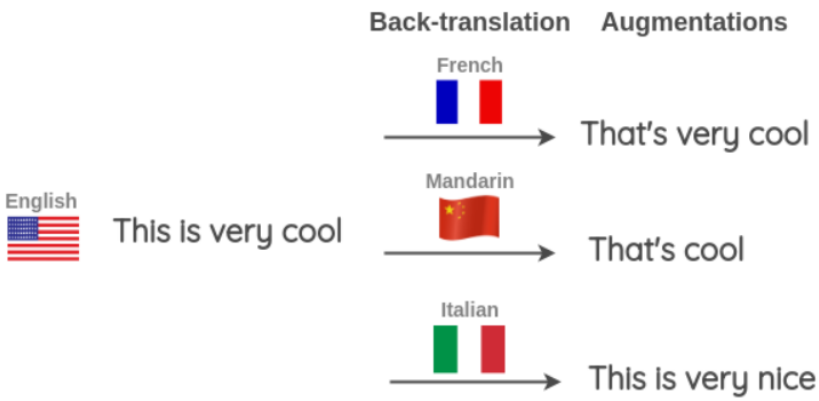
  - 적은 데이터셋에서 쉽게 학습 중에 과적합 되기 쉬운데 EDA 방법을 통해 이에 대한 방지 효과가 보임을 그림을 통해 확인할 수 있음.
- 역 번역 기술 (Back-Translation)
  - 역 번역 기술은 텍스트를 증강하기 위해 신경망 기계 번역(Neural Machine Translation, NMT) 기법을 활용함[Sennrich2016].
  - 역 번역 기술은 원문을 증가시키는 방식으로 목표 언어 텍스트-원문 텍스트로 학습된 NMT 모델을 활용하고, 목표 텍스트를 입력하여 생성된 엉성한 텍스트를 증강 원문으로 활용하는 방식임.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 12] 역번역 기술 [chaudhary2020]

- 데이터량과 역 번역 기술을 통한 데이터 증강의 효과성을 입증한 연구 결과에 따르면, 원문이 640,000개 이상 확보하였을 경우 역 번역 기법이 효과적으로 작동함[Edunov2018].



[그림 13] 다양한 언어를 통한 역번역 기술을 통한 데이터 증강 예시[chaudhary2020]

- ALP (data Augmentation using Lexicalized PCFGs for few-shot text classification) [Kim2022]
  - 파싱한 여러 트리들의 어휘 머리를 기준으로 하위트리들을 생성하여 구문트리를 만들고, WordNet[George1995]의 유사어를 대체하여 데이터를 증강함
  - 데이터 증강 후 증강 데이터를 기준으로 학습과 검증 데이터셋 분리에 대한 다양한 전략을 제시. 일반적으로 데이터 증강 이전에 원 데이터를 반으로 나누어 학습 데이터는 데이터 증강기술을 적용하여 학습을 시키고, 검증데이터는 원 데이터로 학습시키는 전략을 AugTrain-Val이라 지칭함. 제시된 다양한 전략 중 원 데이터를 증강 시킨 데이터를 모두 학습 데이터로 사용하고 데이터 증강하지 않은 원 데이터를 검증데이터로 그대로 사용하는

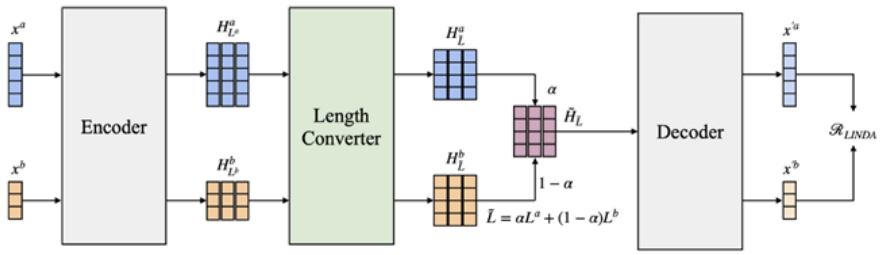
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

AugTrain-Train 전략이 가장 우수한 성능을 보임.

- 데이터 증강 후 이를 검증하는 방법으로 지도학습 방법(Semi-Supervised Learning: SSL) 방법인 자가 학습(Self Training: ST) 방법이 사용됨.
- 6종류의 학습 검증데이터 분리 전략을 제시함. 원본 데이터 셋은 클래스별로 10개의 샘플들을 보유함. 증강된 데이터 셋은 클래스별로 200개의 샘플을 보유함. 메타러닝 기술기반 이름을 “train-val”, “train-train”과 같은 전략을 차용함 [Bai2021ICML].
- ST 방법은 전통적인 SSL 방법으로 레이블이 있는 데이터로 학습한 teacher 모델이 과적합 방지 및 일반화 성능을 높이기 위해 레이블이 없는 데이터로 학습한 student 모델을 학습시키는 방법임[Yarowsky1995unsupervised].
- 데이터 증강기술을 비교하여 보았을 때, 쉬운 데이터 증강 방법 및 SSMBA는 일부 데이터셋에서 데이터 증강이 없을 때보다 성능이 떨어지는 경우가 발생함. 반면, 역 번역 방법(BT) 및 제시된 ALP 방법은 데이터 증강을 통해 데이터 증강기술의 효과성을 입증함. 특히 ALP가 가장 좋은 성능을 보임.

- SSMBA(Self-Supervised Manifold based Data Augmentation) [Kim2022]
  - 기본 데이터가 더 낮은 차원의 매니폴드(manifold) 영역에 군집 된다고 가정을 함. 손상 함수(corruption function)를 이용하여 학습 샘플들을 흩은 후, 재구성 함수(reconstruction function)를 이용하여 매니폴드 영역에 재투영하는 과정으로 데이터 증강이 이뤄짐
  - SSMBA는 BERT를 기반으로 MLM(Masked Language Model) 모델로 단어들을 재구성(reconstruction)한 상위 랭크 10개(top-10)의 단어들을 데이터 증강에 활용함
- LINDA(Unsupervised Learning to interpolate in Natural Language Processing) [Yekyung2021]
  - 서로 다른 길이의 두 입력 문장을 인코딩한 두 은닉 벡터를 mix-up 비율 α로 보간(interpolation) 하고 이를 다시 디코딩하여서 새로운 문장을 생성하는 데이터 증강기법임.
  - LINDA는 가변 길이의 입력 텍스트 xa, xb는 encoder를 거치고 길이 전환기(Length converter)를 거쳐서 보간 된 L 길이로 표현 전환됨. H^a_L, H^b_L은 믹스업 비율(mix-up ratio) α로 H_L로 보간됨. 디코더는 H_L을 위험부담 R_{LINDA}와 함께 x_a, x_b로 생성됨. 그림 예시는 x_a와 x_b 각각 길이 5와 3인 경우이고 은닉 차원이 3인 경우임.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 14] LINDA 프레임워크 아키텍쳐

- 개념은 이러하고 학습에는 BART-Large 모델을 활용하여 학습하고, 파인튜닝하여 보간함. 그런데 BART의 인코더(encoder)와 디코더(decoder)를 활용하여서 두 입력 문장에 대해 인코딩한 입력에 대한 생성 문장(prediction)을 활용하여 데이터 증강(DA) 활용이 가능함. 보간 기술(interpolation)과 생성 문장(Prediction) 결과를 비교하였을 때, TREC 데이터 셋을 제외하고 생성 문장 성능이 5개의 데이터 셋에서 더 나은 성능을 보임.
- 아래 표는 네 종류의 데이터 셋에서 전체 데이터(full)인 경우와 일부 데이터(5shot, 10shot: low) 환경에서 BERT-base로 각 DA 기술의 정확도 성능의 비교 분석(%). 모든 결과는 5번씩 실험한 평균±표준편차로 표현됨. 가장 우수한 결과를 볼드체로 표현함.

Data Profile	Method	TREC-Coarse	TREC-Fine	SST-2	IMDB
Low	Vanilla	61.2±7.63 / 81.0±1.99	53.7±2.46 / 66.8±2.33	59.8±6.75 / 63.1±4.24	61.8±2.41 / 67.8±2.94
	EDA	57.0±6.54 / 72.0±4.64	**54.7**±1.73 / 66.5±4.19	62.3±3.18 / 60.5±2.81	62.5±3.00 / 69.0±3.04
	SSMBA	60.0±5.38 / 80.6±1.53	53.9±1.42 / 66.5±4.66	60.3±6.26 / 64.8±5.78	64.1±2.10 / 69.9±2.63
	Mixup	59.9±4.94 / 81.6±2.57	52.3±2.12 / 67.9±3.03	59.7±4.64 / 62.1±4.38	62.2±1.86 / 67.4±2.37
	LINDA	**62.2**±3.09 / **83.4**±2.30	54.2±1.50 / **69.2**±2.60	**63.5**±4.44 / **66.5**±3.84	**67.3**±2.60 / **71.0**±1.61
Full	Vanilla	97.2±0.36	87.9±1.05	92.3±0.06	89.2±0.59
	EDA	96.4±0.77	90.6±0.84	92.2±0.52	**89.5**±0.18
	SSMBA	96.9±0.41	90.2±0.71	92.3±0.38	89.2±0.17
	$SSMBA_{soft}$	97.3±0.23	88.3±0.54	92.3±0.35	89.4±0.13
	Mixup	97.5±0.30	86.4±1.23	92.4±0.41	89.1±0.18
	LINDA	**97.6**±0.36	**91.6** ±0.75	**92.8**±0.34	89.3 ±0.18

[표 7] 4종류 데이터 셋에서 EDA, SSMBA, MixUP, LINDA 데이터 증강기술의 성능 비교

- 두 문장을 믹스업 비율 α로 혼합할 때, 문장 완성도가 각 문장 혼합 비율에 맞춰 그 정확도가 단조 증가, 단조 감소함을 확인함. 즉, α 이 0일 때, 첫 번째 문장에 대한 정확도가 최대치이고, α 이 1.0일 때, 첫 번째 문장에 대한 정확도가 최솟값이 나타남.
- 아래 표는 5번 수행한 BERT-base의 데이터 증강 성능을 비교한 것임. 처음 세 열은 NLI 데이터셋에 대한 정확도 성능 비교이고, 다음 세 열은 AR, Movie, Yelp 세 종류의 데이터셋에서 도메인

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

내(ID), 교차 도메인(OOD) 성능 비교임. 모든 결과는 5번 실험하여 평균±표준편차로 표현됨.

Method	RTE	QNLI	MNLI-m/m	$AR_{clothing}$		Movie		Yelp	
				ID	OOD	ID	OOD	ID	OOD
Vanilla	68.2±1.78	88.0±0.77	77.0±0.50 / 77.6 ±0.46	73.1±2.85	73.0±2.86	90.8±0.33	84.8±0.74	66.0±0.88	65.4±1.49
EDA	65.6±2.22	86.6±0.70	76.4±0.27 / 77.1±0.39	72.6±2.86	72.6±2.79	90.8±0.35	84.8±0.88	64.9±0.97	64.8±1.26
SSMBA	66.8±2.18	87.6±0.58	76.4±1.18 / 77.3±0.51	72.6±2.85	72.8±2.70	90.8±0.27	84.7±0.79	65.7±1.13	65.3±1.00
$SSMBA_{soft}$	69.4±2.36	88.5±1.08	77.0±0.10 / 77.7±0.29	73.2±2.85	**73.6**±2.92	90.8±0.24	85.5±0.86	**66.5**±1.03	**65.8**±1.31
Mixup	70.9±0.94	87.6±1.13	76.8±0.22 / 77.6±0.31	72.9±2.77	72.9±2.80	90.7±0.30	83.9±1.71	65.6±0.88	65.2±1.20
LINDA	**71.9**±1.87	**88.6**±0.25	**77.4**±0.27 / **78.0**±0.29	**73.5**±2.87	73.2±2.82	**91.0**±0.25	**85.7**±0.86	66.2±1.19	65.6±1.20

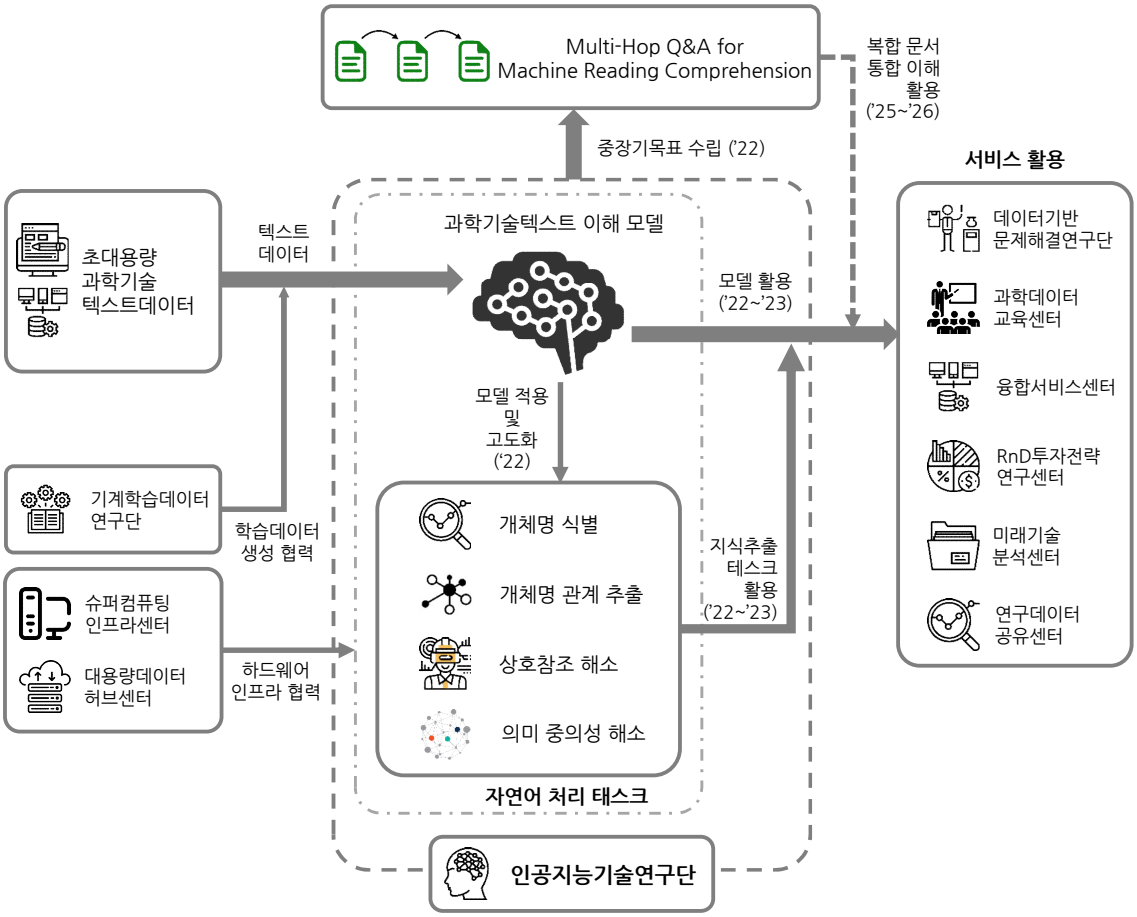
[표 8] ID와 OOD를 고려한 6종류 데이터 셋에서 EDA, SSMBA, MixUP, LINDA 데이터 증강기술의 성능 비교

- 도메인 내(In-Domain : ID), 교차 도메인(Out-Of-Domain : OOD) 성능 확인을 위해 3종류의 데이터셋인 ARclothing, Movie, Yelp를 활용함. 각 영역 별 학습 후, ID 성능과 OOD 성능을 비교 검증함. ARclothing은 5개의 분류 레이블(옷, 여성 옷, 남성 옷, 아기 옷, 신발), Movie는 두 종류 긍정 부정 레이블로 시맨틱을 확인하는 SST-2와 IMDB 데이터셋, Yelp는 4개의 그룹 음식으로 미국, 중국, 이탈리안, 일본으로 구성됨.
- 위 표를 통해 확인할 수 있듯이 AR 및 Yelp의 경우 교차 도메인(OOD)에서 DA를 한 데이터셋을 활용하여 성능 검증을 하였을 때 약간의 성능 향상이 있지만, Movie에서 교차 도메인(OOD)에서 DA를 한 데이터셋을 활용하여 성능 검증을 하였을 경우 대략 10% 정확률 성능 하락이 보임.

- SimCSE(Simple Contrastive Learning of Sentence Embeddings) [Gao2021SimCSE]
  - Contrastive 학습 방법을 사용하여 STS 태스크 성능 향상을 학습 검증함. 비지도 학습에서 한 문장에 대해 서로 다른 drop-out 초기화를 적용한 두 입력을 긍정 쌍(positive pair)으로 간주하는 형태로 데이터 증강기술로 활용함. 이때, in-batch negative(배치 내 나머지 문장들을 부정 쌍(negative pair)으로 간주)를 적용하여 학습시킴.
  - 반지도 contrastive 학습에서는 STS 태스크에 NLI 데이터셋의 모순 쌍(contradiction pair)을 hard-negative로 학습시켜, 직접 데이터를 추가 적용한 데이터 증강을 통해 학습하여 성능개선을 확인함.
  - Spearman의 상관관계 기반 STS(Semantic Textual Similarity) 태스크에서 비지도 학습 모델을 통해 기존 최고 성능(SOTA) 모델대비 10% 상회한 성능을, 비지도 학습에서 기존 BERT 모델대비 6.7% 향상된 성능을 확인함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3절 단계별 연구개발 로드맵



국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4절 단계별 연구개발과제 목표 및 내용

1. 성과지표 및 연차별 목표

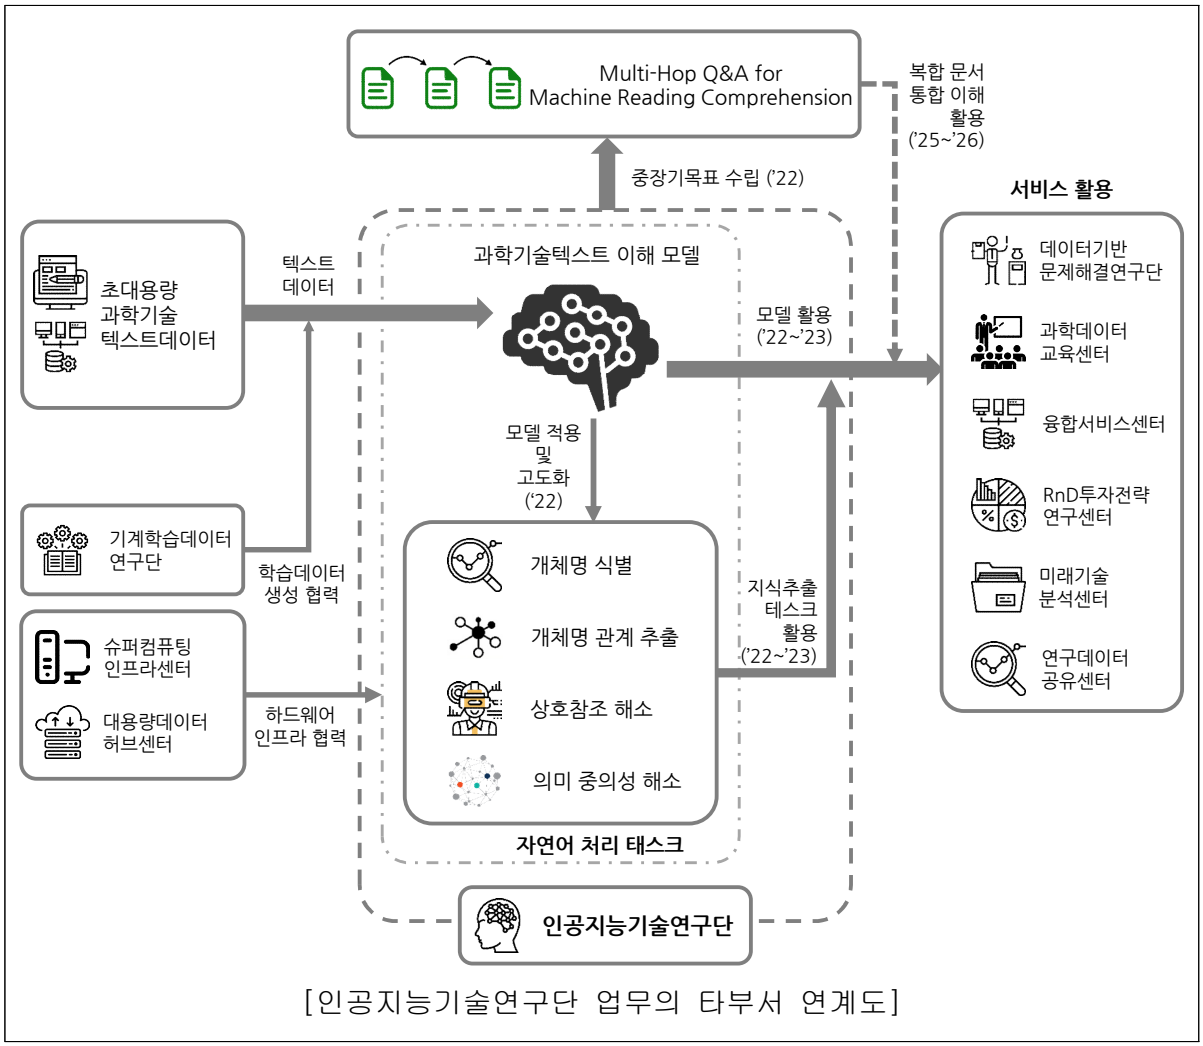
성과 지표		2단계 목표		최종 목표 (2026년 기준)	가중치
		'21년	'22년		
자체	1-1. 과학기술데이터 분석에 특화된 딥러닝 기반 언어 모델 개발 (독립형)	과학기술데이터 분석을 위한 지식증강 언어 모델 확보	지식 증강 언어 모델의 성능 개선	과학기술데이터 분석 분야를 위해 스스로 발전하는 지속 성장 학습 모델 개발	40%
자체	1-2. 과학기술 지식 추출 기술 개발 (독립형)	언어 모델 기반 NER, (J)RE, Co-Ref, WSD 태스크 모델 개발	NER, JRE, Co-Ref, WSD 태스크 모델의 성능 개선 - CS분야 NER, JRE, Co-Ref 100% 이상 달성 - Bio 분야 NER 95% 이상 달성 - WSD 95% 이상 달성	과학기술텍스트에 특성화된 딥러닝 기반 정보 추출 기술 확보 (세계 최고 수준)	50%
자체	1-3. 인공지능 기술의 중장기 발전 계획 수립 (독립형)	Multi-Hop Q&A 기술 동향 조사	Multi-Hop Q&A 기술 개발 연구 기획보고서 작성	Multi-Hop Q&A 전문 모델 개발	10%

2. 성과지표 달성도: 100%

성과 지표	가중치	달성도	실적	평가방법(평가 시 착안점)
1-1. 과학기술데이터 분석에 특화된 딥러닝 기반 언어 모델 개발	40%	100%	▪ 과학기술 텍스트 이해에 특화된 언어모델 SciDeBERTa 모델 개발	- SpERT를 baseline으로 하여 NER, RE, Co-Ref 태스크의 성능(F1 기준) 비교 - Biaffine을 baseline으로 하여 NER 태스크 성능(F1기준) - SVC를 baseline으로 하여 WSD 태스크 성능(F1 기준) 비교
1-2. 과학기술 지식 추출 기술 개발	50%	100%	▪ NER, RE 태스크 SOTA 달성 ▪ Co-Ref 태스크 세계 4위 달성 ▪ WSD 100% 이상 달성	
1-3. 인공지능 기술의 중장기 발전 계획 수립	10%	100%	▪ 중장기 발전을 위한 최신 동향 조사 및 보고서 작성	- 중장기 연구 기획보고서
계		100%		

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4. 전략목표(대과제)-성과목표(중과제)-성과지표(세부과제) 성과 연계도

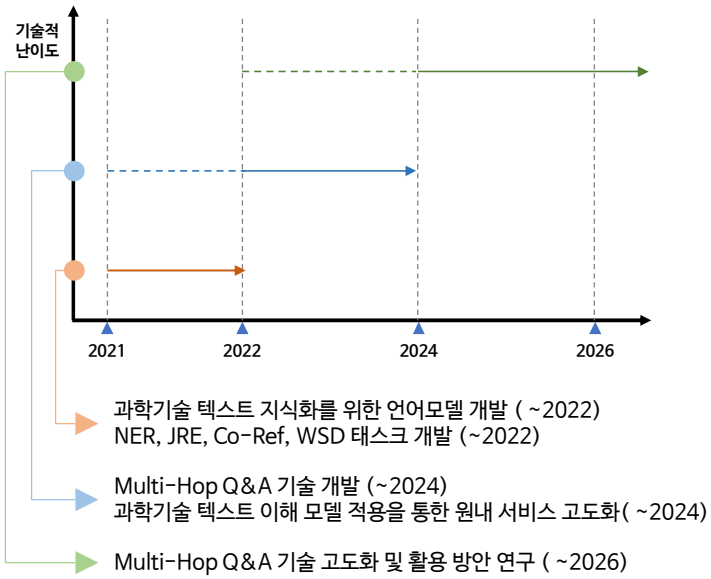


[인공지능기술연구단 업무의 타부서 연계도]

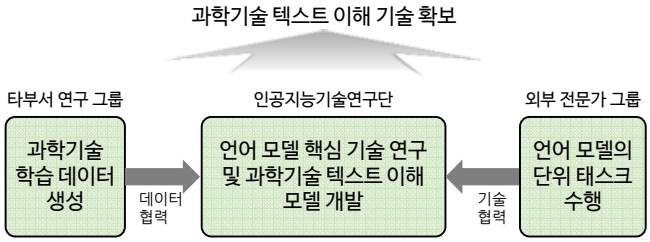
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

5. 추진전략 및 협력 네트워크

1) 연구사업 추진전략 및 방법

<table>
<tr><th>연구사업 내용</th><th>추진전략 및 방법</th></tr>
<tr><td>과학기술데이터 분석을 위한 기계 이해 핵심 기술 개발</td><td>
◦ 단계적 전진 전략
– 장기적으로는 Multi-Hop Q&A 기술 개발을 통한 과학기술 텍스트의 통합적인 이해 및 응답 기술 확보
– 중기적으로는 개체명 인식, 개체명 관계 추출, 상호참조 해소, 의미 중의성 해소 기술 확보 및 기관 내부로 기술 확산
– 단기적으로는 과학기술 텍스트의 지식화를 위한 언어모델 개발 및 NLP 태스크 우수성 확보


[기술적 난이도에 따른 단계적 연구 추진]

◦ 대내외 협력을 통한 연구 수행 전략
– 내부적으로 언어 모델 핵심 기술 및 활용을 위한 전문성을 확보하고 과학기술 텍스트 이해에 특성화된 딥러닝 기술 개발
– 다만 업무의 효율화를 위해 학습 데이터 생성과 언어 모델의 단위 태스크들은 내/외부 협력을 통하여 진행


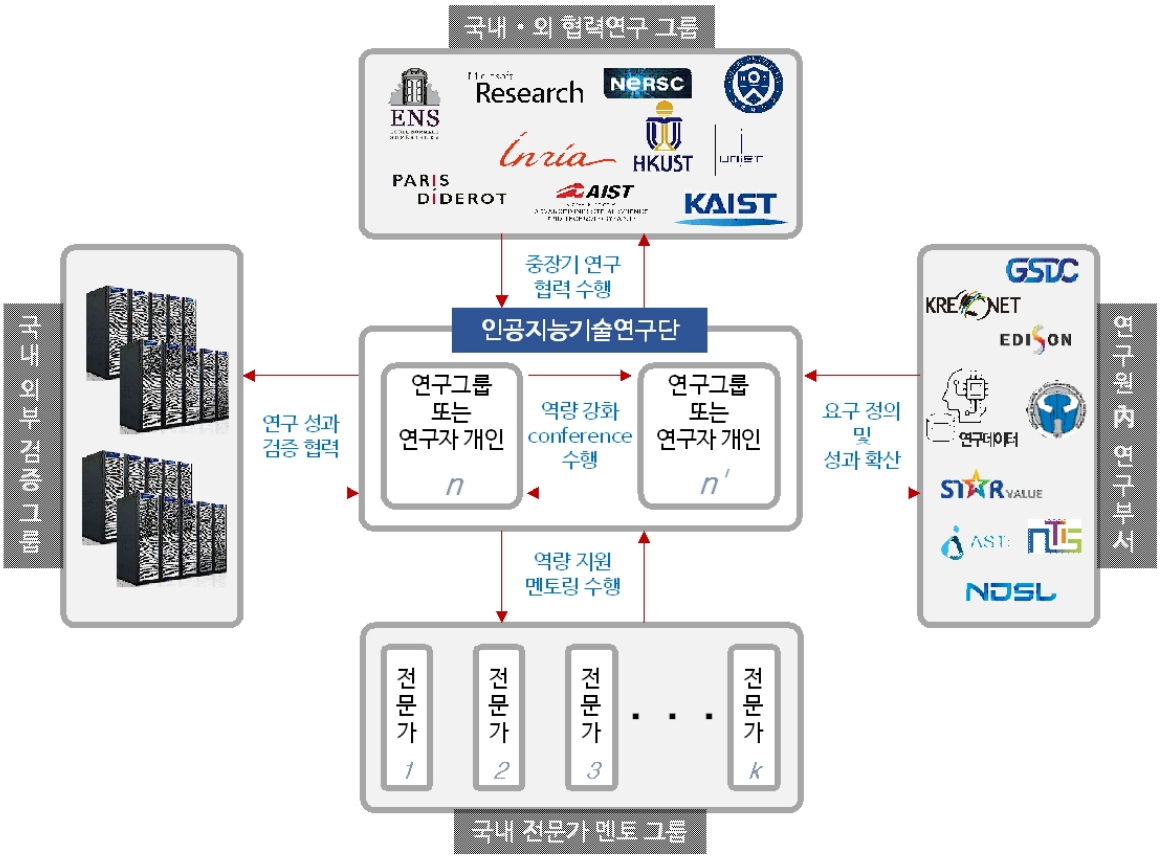
[연구 협력 추진 전략]
</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 대내외 추진 체계도

◦ **대내외 협력·추진 체계**

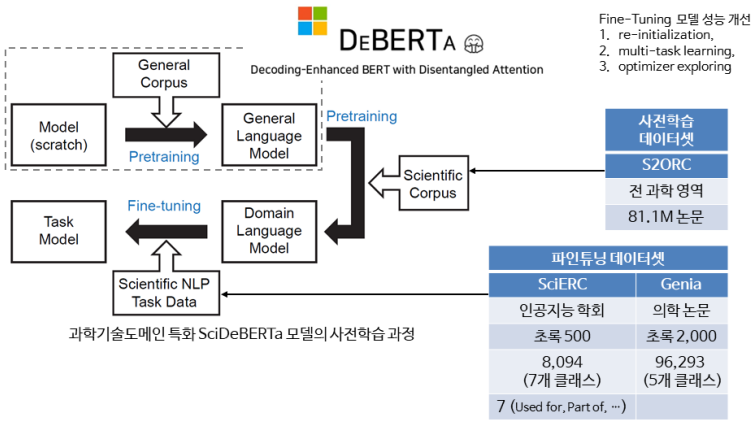
- (내적 역량 강화) 참여 연구진들 간의 기술·노하우 교류 강화를 위해 정기적 내부 컨퍼런스를 개최함으로써 연구진의 내적 역량 강화 유도
- (외적 역량 보완) 연구 분야의 국내 전문가들로 구성된 자문단을 구성·운영하여 연구진의 외적 역량 보완 추진
- (역량 교류·확산) 국내외 전문연구기관들과의 교류 및 협력을 통해 고난이도의 중장기 연구 주제들에 대한 공동 연구 추진
- (성과 검증 강화) 연구 성과의 성능 및 실효성에 대한 객관적 실증을 위한 외부 협력 그룹 구성·운영
- (요구 수집 및 성과 적용) 연구원 내의 유관 연구부서들과 협력 체계를 구성하고 연구 대상 기술에 대한 요구사항을 수집·반영하여 향후 기술 수용성을 제고

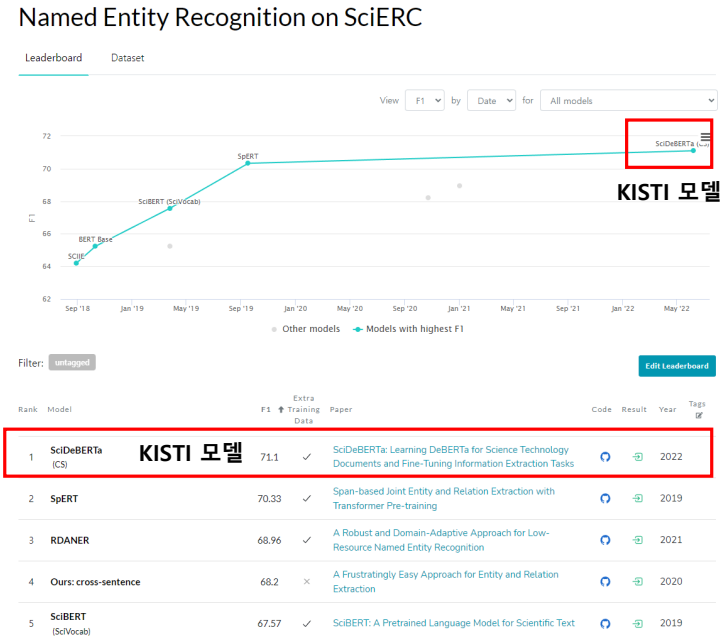


[연구사업 추진 체계]

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

6. 대표성과

<table>
<tr><th colspan="2">과학기술 텍스트 이해에 특화된 SciDeBERTa 언어모델 개발</th></tr>
<tr><td>주요
내용</td><td>
- 최신의 PLM 모델 세부 분석 및 일반 언어 도메인에서 가장 좋은 효율을 보인 DeBERTa 모델을 기반 모델로 선정
- DeBERTa 모델의 내부 코드 분석 및 과학기술(S&T) 텍스트 이해를 위한 최적의 하이퍼파라미터 파악(Re-Initialization, Multi-Task Learning, Optimizer Exploring 등 적용)
- Allen AI와의 협력을 통한 S&T 데이터셋인 S2ORC 전체 확보(81.1M 영어 논문)
- DeBERTa 모델에 S2ORC 데이터 추가 학습을 통한 S&T 특화 언어모델 개발


과학기술도메인 특화 SciDeBERTa 모델의 사전학습 과정
- 위의 과정을 통해 SciDeBERTa 모델이 파인튜닝을 통해 SciERC 벤치마킹 데이터셋 기준 NER 태스크 세계 1위, GENIA 데이터셋 기준 NER 태스크 세계 2위 달성


</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>파급효과</td><td colspan="3">□ KISTI 서비스로의 활용을 위한 SciDeBERTa 적용
- 국가과학기술데이터본부 디지털큐레이션센터의 해외보고서 분석을 위해 SciDeBERTa 모델 적용 예정(2023)
- 슈퍼컴퓨팅본부의 슈퍼컴퓨팅응용센터 바이오의료팀의 의료정보 분석을 위해 SciDeBERTa-Bio 모델 활용(협의 후 결정)
- 데이터분석본부 미래기술분석센터의 과학기술텍스트 분석을 위해 SciDeBERTa 모델 적용 예정(2023)
- 과학기술디지털융합본부
- 기계학습데이터연구단의 AIDA 서비스에 SciDeBERTa 모델 공개 및 학습데이터 생성을 위한 모델 활용(2023)
- 데이터기반문제해결연구단의 의료정보 분석 연구팀에서 SciDeBERTa-BIO 모델 활용(협의 후 결정)

□ 국내외 활용확산을 위한 모델 및 코드 공개
- Github에 SciDeBERTa 모델 코드 공개 (2022.10.01. 오픈) (https://github.com/Eunhui-Kim/SciDeBERTa-Fine-Tuning)
- SciDeBERTa 모델 활용도 증강을 위한 Huggingface 커뮤니티에 모델 공개 (2022.10.01. 공개, 2022.10.26. 현재 누적 사용자 209명)
- (https://huggingface.co/KISTI-AI/scideberta)</td></tr>
<tr><td>핵심정량 성과</td><td>SciDeBERTa: Learning DeBERTa for Science Technology Documents and Fine-Tuning Information Extraction Tasks, IEEE Access 논문 게재 (관련 내용으로 PaperswithCode의 SciERC NER 태스크 SOTA 달성)</td><td>성과 유형</td><td>논문</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2장 연구개발과제의 수행 과정 및 수행 내용

(1) 과학기술데이터 분석에 특화된 딥러닝 기반 언어 모델 개발

□ 과학기술 특화 데이터 셋 및 모델에 관한 기존 연구 분석

○ SciBERT 모델

- SciBERT[Beltagy2019]는 Semantic Scholar의 1백14만 논문들에서 랜덤 샘플한 데이터를 학습데이터로 사용함. 해당 데이터의 18%는 computer science 논문이고, 82%는 biomedical 도메인 데이터로 구성됨. SciBERT에서는 학습 시 abstract가 아닌 논문 전문을 학습 데이터로 사용함. 논문 평균 길이는 154문장(2,769토큰)으로 전체 코퍼스의 토큰개수는 31억 7천만 개로 이는 BERT학습에 사용한 33억 토큰 개수와 유사함.
- SciBERT[Beltagy2019]는 TPU v3(8 코어)를 이용하여 BERT기반의 모델을 일주일동안 학습시킴.
- SciBERT 사전학습 언어모델의 성능 검증에 사용된 태스크는 NER(개체명 인식), RE(관계추출), PICO(룰 기반의 구조적 환자 건강상태 및 처방 등에 대한 정보 레이블), DEP(POS 태깅과 같은 dependency parsing), CLS(문장 별 분류)로 Bio데이터와 Computer Science 영역의 도메인 특화 데이터(과학기술데이터)로 성능 검증이 진행됨.
- CLS 및 DEP 태스크에 파인 튜닝 시 SciBERT 사전학습 모델에 Bi-LSTM 2계층을 추가하여 성능 검증이 진행됨.
- SciBERT 모델에서 파인튜닝에 사용한 학습 파라미터들은 dropout 0.1, Adam optimizer를 cross entropy로 사용, 배치 크기 32, learning rate 5e-6, 1e-5, 2e-5 혹은 5e-5를 slanted triangular schedule을 이용하여 linear warmup을 적용한 모델과 유사한 learning scheduler를 적용함.

○ BioBERT와 PubMedBERT

- BioBERT[Lee2020]는 biomedical 분야 데이터를 다루기 위해 제안된 모델로, 일반 도메인으로 사전학습된 BERT 모델에 PubMed와 PMC에서 수집한 biomedical 분야 논문 데이터를 추가 사전학습함.
- 유사하게 PubMedBERT[Gu2020] 또한 biomedical 분야 데이터를 다루기 위한 모델로, BioBERT와 동일하게 BERT 모델에 기반 하지만 일반 도메인에 대한 사전학습 없이 랜덤하게 초기화된 모델을 PubMed와 PMC에서 수집한 논문 데이터로 처음부터 학습함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	Pretraining Corpus	Consecutive Pretraining Corpus
BERT	Wiki + Books	-
RoBERTa	Web Crawl	-
PubMedBERT	PubMed	-
BioBERT	Wiki + Books	PubMed

[표 9] 각 모델별 사전학습용 코퍼스 비교

- BioBERT와 PubMedBERT는 모두 biomedical 분야 13개 태스크에 대해서 기존 BERT, RoBERTa 모델에 비해 성능이 향상되었으며 과학기술분야에 특화된 SciBERT 모델에 비해서도 좋은 성능을 보임. 또한 PubMedBERT는 11개 태스크에서, BioBERT는 2개의 태스크에 대해서 각기 최고 성능을 보임.

	BERT		RoBERTa	BioBERT	SciBERT		ClinicalBERT	BlueBERT	PubMedBERT
	Uncased	Cased	Cased	Cased	Uncased	Cased	Cased	Cased	Uncased
BC5-chem	89.25	89.99	89.43	92.85	92.49	92.51	90.80	91.19	**93.33**
BC5-disease	81.44	79.92	80.65	84.70	84.54	84.70	83.04	83.69	**85.62**
NCBI-disease	85.67	85.87	86.62	**89.13**	88.10	88.25	86.32	88.04	87.82
BC2GM	80.90	81.23	80.90	83.82	83.36	83.36	81.71	81.87	**84.52**
JNLPBA	77.69	77.51	77.86	78.55	78.68	78.51	78.07	77.71	**79.10**
EBM PICO	72.34	71.70	73.02	73.18	73.12	73.06	72.06	72.54	**73.38**
ChemProt	71.86	71.54	72.98	76.14	75.24	75.00	72.04	71.46	**77.24**
DDI	80.04	79.34	79.52	80.88	81.06	81.22	78.20	77.78	**82.36**
GAD	80.41	79.61	80.63	82.36	82.38	81.34	80.48	79.15	**83.96**
BIOSSES	82.68	81.40	81.25	89.52	86.25	87.15	91.23	85.38	**92.30**
HoC	80.20	80.12	79.66	81.54	80.66	81.16	80.74	80.48	**82.32**
PubMedQA	51.62	49.96	52.84	**60.24**	57.38	51.40	49.08	48.44	55.84
BioASQ	70.36	74.44	75.20	84.14	78.86	74.22	68.50	68.71	**87.56**
BLURB score	76.11	75.86	76.46	80.34	78.86	78.14	77.29	76.27	**81.16**

[표 10] 사전학습 언어모델의 biomedical 분야 태스크별 성능 비교 표 [Gu2020]

- PubMedBERT와 BioBERT의 경우를 보았을 때, 전문분야 도메인 특화 태스크 언어모델은 언어모델을 처음부터 학습하는 방식이 더 좋은 성능을 얻을 수 있음이 보여짐. 그러나 성능 차이가 소폭인 점을 미루어 보아 사전학습 구조보다 목표 도메인 코퍼스에 대한 학습이 성능향상 더 크게 기여함. 이에 데이터의 수와 자원이 충분하며 성능을 가장 중요하게 여기는 경우, 목표 도메인 데이터로 처음부터 특화 모델을 학습하는 전략을, 반면 목표 도메인 데이터가 부족하거나 자원이 제한적인 경우에는 adaptive pre-training을 전략적으로 선택할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 과학기술 논문 활용 학습 데이터

- 일반적으로 가장 용이하게 수집할 수 있는 과학기술데이터는 S2ORC 데이터 셋과 같은 논문 데이터 셋에 해당함. 논문 데이터는 abstract와 full-text의 2가지로 형태로 나누어 볼 수 있으며 abstract는 보통 정형화된 구조로 낮은 복잡도를 지니지만 full-text는 수식 등의 복잡한 노이즈를 더 많이 포함함. 기존 대부분의 과학기술분야 태스크들은 수준의 복잡도로 주어지기에 full-text가 태스크의 domain을 벗어날 수 있음. 그러나 full-text의 학습은 목표 도메인 전체에 대한 학습이므로 잠재적으로 도움이 될 수 있으며 복잡한 데이터를 충분히 이해하려면 더 많은 학습을 요구함.
- PubMedBERT는 PubMed의 abstract 데이터만으로 학습한 base 모델과 PuBMed의 abstract, PMC의 full-text 데이터를 모두 학습한 large 모델을 제공함. 두 종류를 모두 학습하는 large 모델의 경우 base 모델과 동일 시간 학습 시 13개의 태스크 중 5개의 태스크는 성능이 향상했지만 나머지의 경우 동일하거나 성능이 더 하락함. 전반적으로 향상된 성능을 얻기 위해서는 base 모델 대비 약 1.6배가량 많은 학습을 수행해야함.

Abstract (3.1B words/21GB)

Abstract + full-text (16.8B words/107GB)

	PubMed	PubMed + PMC	PubMed + PMC (longer training)	
BC5-chem	93.33	**93.36**	93.34	x1.6
BC5-disease	85.62	85.62	**85.76**	(62,500 steps → 100K steps)
NCBI-disease	87.82	**88.34**	88.04	
BC2GM	**84.52**	84.39	84.37	
JNLPBA	79.10	78.90	**79.16**	
EBM PICO	73.38	73.64	**73.72**	
ChemProt	**77.24**	76.96	76.80	
DDI	82.36	**83.56**	82.06	
GAD	83.96	**84.08**	82.90	
BIOSSES	92.30	90.39	**92.31**	
HoC	82.32	82.16	**82.62**	
PubMedQA	55.84	**61.02**	60.02	
BioASQ	**87.56**	83.43	87.20	
BLURB score	81.16	81.01	**81.50**	

[표 11] PubMedBERT의 학습 데이터 형태(abstract, abstract+full-text)에 따른 성능 비교 결과 [Gu2020]

- BioBERT 또한 PubMed와 PMC, 그리고 둘을 모두 학습 데이터로 사용한 경우에 대한 성능을 보였으며, 각각의 경우 최적의 성능을 내기 위한 학습 step수를 200K, 270K, 470K로 사용함. PubMedBERT의 결과와 마찬가지로 full-text를 사용하는 경우에는 더 오랜 학습이 수행되어야 모델이 복잡한 논문 데이터를 이해함으로써 학습에 좋은 영향을 미치는 것으로 나타남.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

PubMed: abstract 4.5B words
PMC: full-text 13.5B words

Corpus	PubMed	PMC	PubMed+PMC
#steps	200K	270K	470K

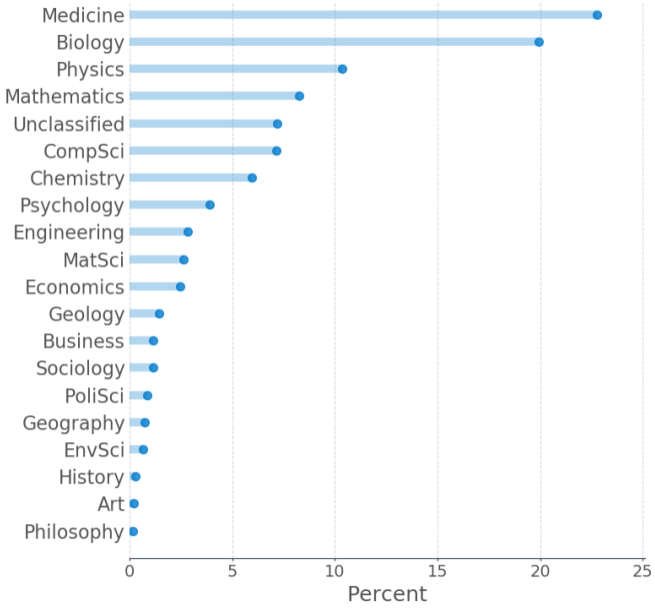
				BERT	BioBERT v1.0		
Type	Datasets	Metrics	SOTA	(Wiki + Books)	(+ PubMed)	(+ PMC)	(+ PubMed + PMC)
Disease	NCBI disease	P	88.30	84.12	86.76	86.16	**89.04**
		R	89.00	87.19	88.02	89.48	89.69
		F	88.60	85.63	87.38	87.79	89.36
	2010 i2b2/VA	P	87.44	84.04	85.37	85.55	**87.50**
		R	86.25	84.08	85.64	85.72	85.44
		F	**86.84**	84.06	85.51	85.64	86.46
	BC5CDR	P	**89.61**	81.97	85.80	84.67	85.86
		R	83.09	82.48	86.60	85.87	87.27
		F	86.23	82.41	86.20	85.27	86.56
Drug/chem.	BC5CDR	P	**94.26**	90.94	92.52	92.46	93.27
		R	92.38	91.38	92.76	92.63	**93.61**
		F	93.31	91.16	92.64	92.54	93.44
	BC4CHEMD	P	92.29	91.19	91.77	91.65	92.23
		R	90.01	88.92	90.77	90.30	90.61
		F	91.14	90.04	91.26	90.97	91.41
Gene/protein	BC2GM	P	81.81	81.17	81.72	82.86	**85.16**
		R	81.57	82.42	83.38	84.21	83.65
		F	81.69	81.79	82.54	83.53	84.40
	JNLPBA	P	**74.43**	69.57	71.11	71.17	72.68
		R	83.22	81.20	83.11	82.76	83.21
		F	**78.58**	74.94	76.65	76.53	77.59
Species	LINNAEUS	P	92.80	91.17	91.83	91.62	**93.84**
		R	**94.29**	84.30	84.72	85.48	86.11
		F	**93.54**	87.60	88.13	88.45	89.81
	Species-800	P	**74.34**	69.35	70.60	71.54	72.84
		R	75.96	74.05	75.75	74.71	**77.97**
		F	74.98	71.63	73.08	73.09	**75.31**

[표 12] BioBERT모델의 사전학습 코퍼스 및 step 수와 Biomedical 분야 NER 태스크 성능 측정 결과 [Lee2020]

○ S2ORC 데이터 셋

- S2ORC 데이터셋은 전체 논문 2억 개의 클러스터 크기의 논문 중 데이터의 품질을 고려하여 ScienceParse와 GROBID를 기반 하여 학위논문, 보고서, 슬라이드 등을 제외시킨 3천5만개의 PDF논문들과, 접근의 편리성을 고려한 150만 Latex논문들, 즉 3천 2백만 개의 논문데이터를 추출하고 이 중 타이틀이 없는 논문, 저자가 표기되지 않은 논문, text의 크기가 100자 이하의 논문, 영어가 아닌 논문들을 후처리하여 결국 8천1백1십만 논문 데이터들을 추림.
- S2ORC의 데이터셋의 학문분야는 Scibert에서 BioMedical 분야가 82%, Computer Science 분야가 18%를 비율로 구성된 것과 달리, BioMedical 분야가 42.7%, Computer Science분야가 7.2%의 비율로 구성됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 16] 논문 데이터 연구 분야 분포

- S2ORC-SciBERT 논문 학습 전체 토큰 수는 164억개로 Scibert 학습에 사용한 전체 토큰수의 5배임. Vocabulary구성은 3만1천개로 구성되는데 Jaccard index기준 Scibert와 S2orc-Scibert간의 유사도는 0.536임.

○ SciERC 데이터셋

- SciERC 데이터 셋은 12개의 인공지능 컨퍼런스의 요약문 데이터를 활용한 정보 추출 학습데이터임. 전체 500개의 논문 요약문을 ACL RD-Tec2.0(2016)의 가이드에 따라 개체명(entity), 관계정보(relation information), 동일지시어(coreferences)에 대한 정보가 태깅(혹은 주석처리) 되어 있음[Luan2018].
- SciERC 데이터 셋은 일반적인 지식정보(Knowledge Information)가 인명, 지리 정보 등을 포함하는 것과는 달리, 과학기술 데이터에 초점을 맞추어진 태깅 가이드에 따름.
- SciERC 데이터 셋은 3종류의 정보를 추출하는 정보(Information Extraction)가 포함되어 있으며, 이는 개체명(Named Entity), 개체관의 관계정보(Relation), 상호참조 (Coreference) 정보임.
- SciERC 데이터 셋의 개체명 정보는 7종류로 태스크, Method, Evaluation Metric, Material, Other Scientific Terms, Generic으로 구분지어짐. 즉, SciERC 데이터 셋에서 개체명 인식(NER: Named Entity Recognition) 태스크는 토큰의 Entity 타입을 8종류로 분류하는 문제임.
- 전체 500개의 요약문은 2,867개의 문장으로 구성되어 있으며, 전체 개체명은 8,094개로 기 학습 데이터 셋에 비해 매우 작은 데이터 셋임.
- SciERC 데이터셋에서 구분하는 관계 추출(RE: Relation Extraction)관계는 Used-for, Feature-of, Hyponym-of, Part-of,

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Compare, Conjunction과 같은 6종류로 구분 지어짐. 즉, RE 태스크는 두 Entity간의 관계를 7종류로 분류하는 문제임.

- Entity간의 관계를 추출하는 Relation Extraction의 Annotation 범주는 문장 단위임.
- 대명어 해소 문제(Coref:Coreference Resolution)의 상호 참조에 있는 대명사 및 대명어에 대한 범주는 Paragraph(단락)단위임.

○ 과학기술특화 vocabulary

- 단어를 빈도수 순으로 정렬한 단어 집합인 vocabulary는 사용되는 코퍼스에 따라 다르게 구성될 수 있음. PubMedBERT는 wiki등의 일반 도메인 코퍼스에서 추출한 vocab과 PubMed 데이터에서 생성한 특화 vocab을 사용한 경우에 대한 성능을 비교함.
- 그 결과 일반 도메인 사전학습 모델에 과학기술 도메인 데이터를 추가 사전학습 하는 경우에는 일반 도메인 vocab과 특화 도메인 vocab 사용이 성능에 영향을 거의 미치지 않는 것으로 나타남. 반면 모델을 처음부터 특화 데이터로 학습하는 경우에는 일반 도메인 vocab보다 특화 도메인 vocab을 사용하는 것이 더 좋은 효율과 성능을 얻을 수 있었음.
- 마찬가지로 BERT 모델을 처음부터 과학기술데이터로 학습하는 SciBERT 또한 특화 데이터로 생성한 vocab으로 학습 시에 다소의 성능 향상을 확인됨.

Pretraining	Wiki + Books → PubMed		PubMed (half time)	PubMed
Vocab	Wiki + Books	PubMed	PubMed	PubMed
BC5-chem	92.85	**93.41**	93.05	93.33
BC5-disease	84.70	85.43	85.02	**85.62**
NCBI-disease	**89.13**	87.60	87.77	87.82
BC2GM	83.82	84.03	84.11	**84.52**
JNLPBA	78.55	79.01	78.98	**79.10**
EBM PICO	73.18	**73.80**	73.74	73.38
ChemProt	76.14	77.05	76.69	**77.24**
DDI	80.88	81.96	81.21	**82.36**
GAD	82.36	82.47	82.8	**83.96**
BIOSSES	89.52	89.93	92.12	**92.30**
HoC	81.54	**83.14**	82.13	82.32
PubMedQA	**60.24**	54.84	55.28	55.84
BioASQ	84.14	79.00	79.43	**87.56**
BLURB score	80.34	80.03	80.23	**81.16**

[표 13] PubMedBERT의 vocab과 사전학습 방법에 따른 성능 차이 비교 [Gu2020]

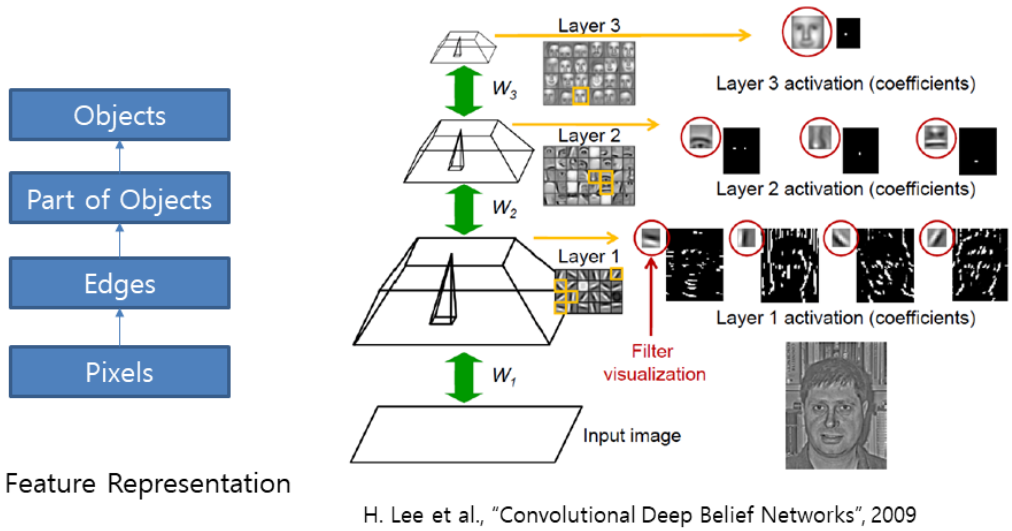
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 언어모델 파인튜닝 성능 개선에 대한 연구

- BERT계열의 언어모델은 Self Masked Language Modeling 과정을 거쳐 범용 언어모델을 생성하고 특정 자연어 처리 태스크에 대해 추가적으로 학습하는 방식(파인 튜닝)을 거침.
- 본 연구에서는 전문 학술 분야 과학기술 데이터셋으로 학습된 기 학습 언어모델인 scibert를 기반으로 함.
- Scibert 언어모델에 대해 과학기술 데이터 정보 추출 태깅 데이터셋인 SciERC데이터 셋에 대해 개체명 인식에 관한 태스크 성능 향상을 위한 기술에 대해 서술함.

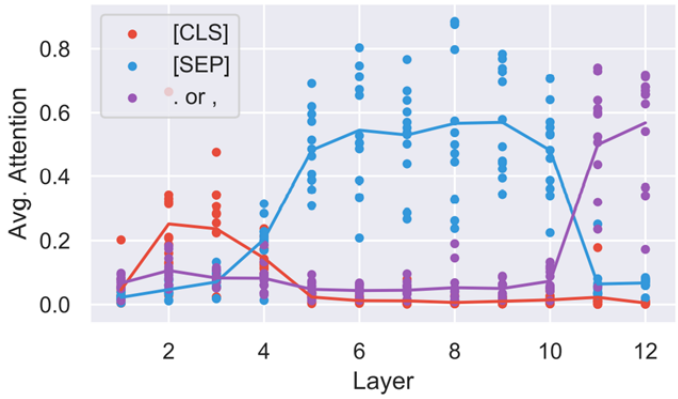
○ 하이퍼파라미터 재초기화 과정을 통한 성능 개선

- Vision 분야에서 각 Layer별 특징을 분석한 연구에 따르면, 낮은 계층은 이미지를 구성하는 방향과 선 등의 구성요소를 인식하고 상위 계층으로 올라갈수록 하나의 객체로 인식 처리됨.
- NLP 분야에서 각 Layer별 특징을 분석한 연구에 따르면, 문장 전체 특징을 분류하는 CLS 토큰은 저 계층에, 두 문장을 분류하는 SEP 토큰은 중 계층에 '.' 혹은 ',' 와 같은 다빈도 단어는 깊은 계층에서 Attention 값이 평균적으로 높게 나오는 것으로 해석 됨.



[그림 17] 비전분야 딥뉴럴 네트워크의 표현 학습

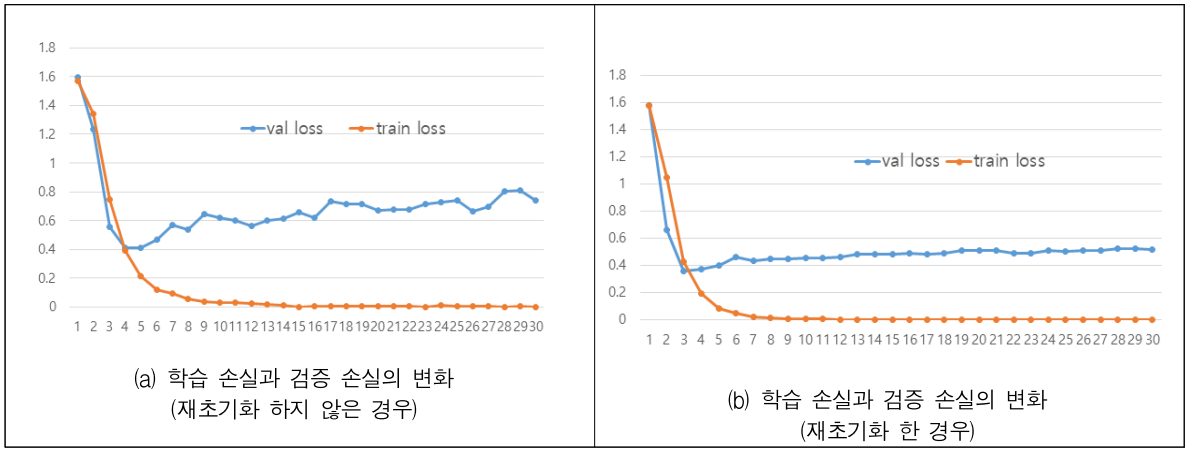
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 18] 언어모델 분야 딥 뉴럴 네트워크의 표현 학습

- 본 연구에서는 이러한 특징들을 고려하여서 과학기술 데이터 셋으로 기 학습된 SciBert모델과 Scivocab으로 학습을 시작하되 상위 계층의 파라미터를 재초기화 하는 방법을 적용하여 학습 성능을 향상시킬 수 있는 접근 방법으로 SciERC 데이터 셋에서 NER 태스크 수행 시 성능을 향상시켜 과학기술 데이터 셋에서 언어모델의 기본 태스크 성능 향상을 확인함.
- 본 연구에서는 재초기화 과정이 과 적합 방지에 어떤 효과를 가져 오는지 확인하기 위하여, SciBert 기본 12 계층, Scivocab 기 학습 파라미터를 이용하여 재초기화 없이 학습한 경우와 재초기화 하여 학습한 경우 학습 손실과 검증 손실을 전체 데이터 셋의 70%와 30%로 나누어서 그 성능을 비교함.
- (a)는 재초기화 없이 SciBert, Scivocab 기 학습 파라미터를 학습한 경우이고, (b)는 SciBert, Scivocab 기 학습 파라미터 중 마지막 12번째 계층을 xavier normalization으로 재초기화 하여 학습한 경우를 비교한 것임.
- 실험을 통해 확인할 수 있듯이 재초기화 과정은 과 적합 해소 효과가 있음을 확인할 수 있음.
- 관련 연구에서 비전 및 자연어처리 분야에서 딥러닝의 각 계층의 역할에 대한 분석을 통해 모델의 상위 계층으로 갈수록 지엽적인 데이터의 특징을 표현 학습하고 있음을 미루어 짐작할 수 있음.
- 이를 통해 재 초기화 과정은 특정 데이터 셋의 지엽적인 특징들에 임의의 특징을 부여 하게 되므로, 특정 태스크에 기 학습 파라미터의 영향을 줄이고 새로운 데이터 셋에 맞춘 향상된 성능을 기대할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

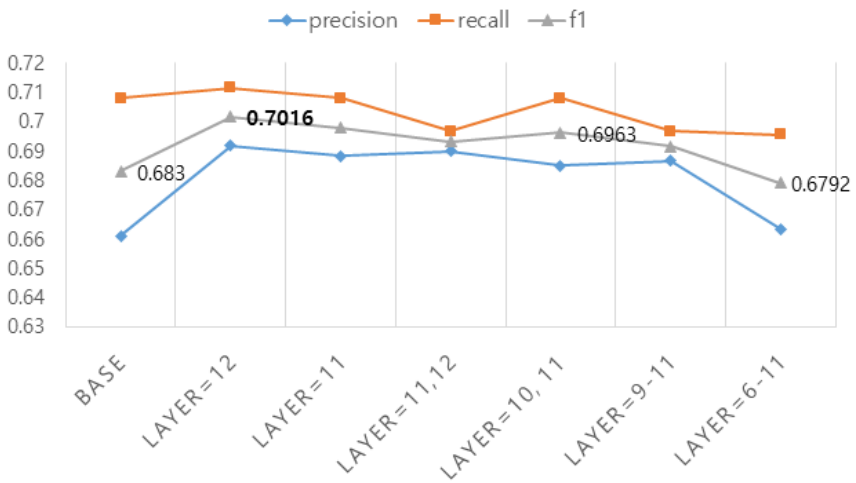


(a) 학습 손실과 검증 손실의 변화
(재초기화 하지 않은 경우)

(b) 학습 손실과 검증 손실의 변화
(재초기화 한 경우)

[그림 19] 재초기화를 통한 학습 손실로 확인되는 과적합 해소 효과

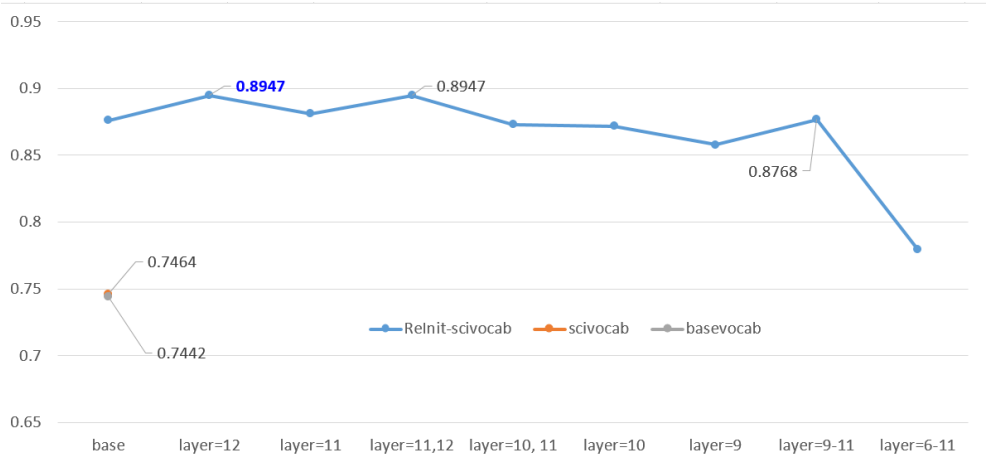
- 예상 분석과 일치하게 실험 결과는 SciERC 데이터 셋에 대해 개체명 인식(NER) 태스크에서 재초기화를 통해 재초기화 과정이 없는 학습에 비해 1.76%향상된 성능으로, 현재 SciERC 리더 보드의 SOTA 모델인 SpERT의 70.33%의 F1 score보다 0.17%차이로 70.16%의 정확도로 2위의 성능을 보임을 확인 할 수 있음.



[그림 20] 계층별 재초기화를 통한 NER 태스크 성능 변화

- 예상 분석과 일치하게 실험 결과는 SciERC 데이터 셋에 대해 관계 추출(RE) 태스크에서 재초기화를 통해 재초기화 과정이 없는 학습에 비해 14.83%향상된 성능으로, 2021년 12월 현재 PaperWithCode의 SciERC-RE 태스크 리더 보드의 SOTA 모델인 SciVocab SciBERT 모델을 앞서 89.47%로 SOTA모델을 기록함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



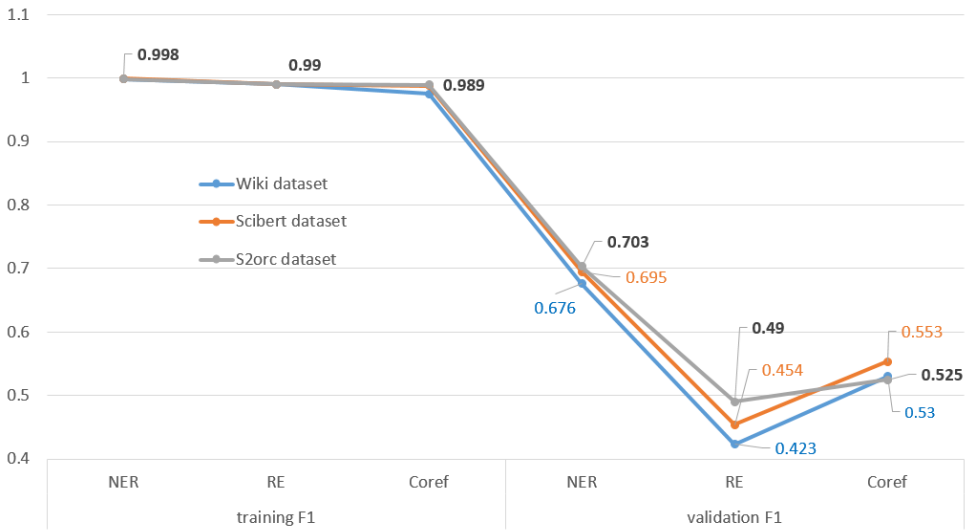
[그림 21] 계층별 재초기화를 통한 RE 태스크 성능 변화

- PLM fine-tuning시 모델 파라미터 재초기화 기술을 적용할 때 절대 위치 임베딩만 사용하는 BERT, RoBERTa 모델이 마지막 두 계층 재초기화시 최적화 되는 것과 달리, 위에서 세 번째 계층 재 초기화 시 최적화된 성능을 보임.
- 이는 DeBERTa 모델 구조상 Disentangled Attention에서 상대 위치 임베딩을 마지막 2계층을 제외한 계층까지 같은 구조가 반복되고, 마지막 두 계층은 Enhanced Mask Decoder 구조에서 절대 위치 임베딩을 사용하는 구조적 차이에 기인함.

○ 사전학습 언어모델에 따른 성능 개선

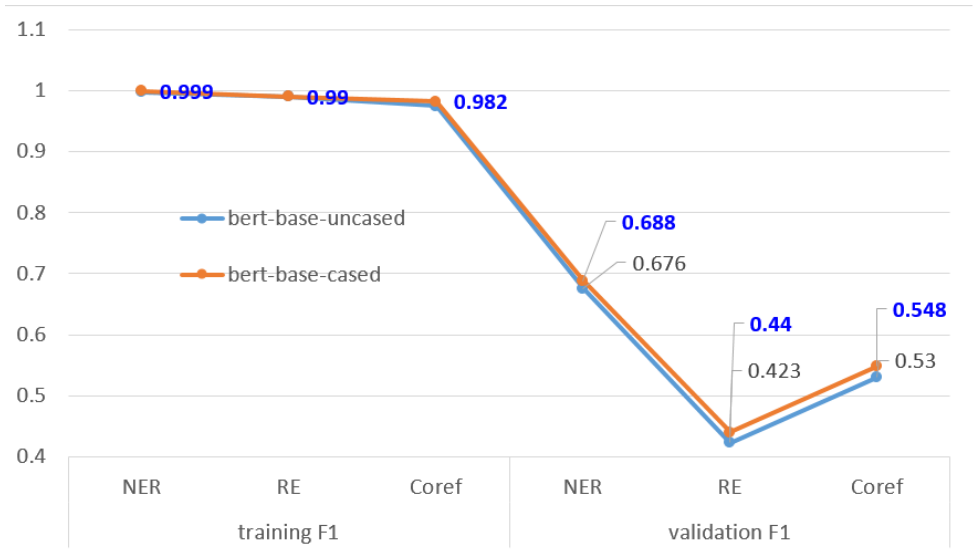
- 데이터와 코드의 공개 연구로 사전학습 언어모델에 접근이 용이하므로, 기 공개된 사전학습들을 기반으로 과학기술 데이터 셋인 SciERC 데이터 셋의 NER, RE, CoREF 세 종류의 태스크성능 검증을 통해 과학기술 정보추출 태스크에 있어 용이한 언어모델을 비교함.
- 모델 학습을 위해 multi-task 모델인 dygie++을 사용하였으며, 앞서 소개된 것과 같이 과 적합 방지를 위해 재초기화를 적용함. SciERC 데이터 셋에 대해 학습, 검증, 평가 데이터를 80%, 10%, 10%로 나누어 학습 적용함. 3종류의 태스크인 NER, RE, Coref에 대해 손실 가중치를 0.2, 1.0, 1.0으로 적용하고, optimizer로 radam을 구현 적용 하였으며, 목표 태스크는 relation으로 함.
- 사전학습 언어모델 중 그 크기가 bert-base인 모델들에 대해 (1) 범용 데이터셋 book corpus와 english Wikipedia dataset을 기반으로 학습한 사전학습모델과, (2) 과학기술 논문데이터 셋에서 82%를 bio데이터, 12%를 CS데이터로 학습한 사전학습 모델과, (3) 과학기술 논문 데이터 셋에서 데이터 셋 분포의 균형을 이룬 45%를 bio데이터, 7.5%를 CS데이터로 학습한 사전학습 모델에 대해 SciERC 데이터셋에 대한 3종류의 정보추출 태스크 성능을 비교함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 22] 학습데이터에 따른 모델의 성능 변화

- SciERC 데이터셋에 대한 정보 추출 태스크에 대해 과학기술 논문데이터 셋 중에 S2ORC 데이터셋을 사용한 경우 가장 성능이 좋은데, 특히 RE 정보 추출에 있어 3.6% 성능향상을 확인할 수 있음.
- 과학기술데이터에서 개체명 인식, 관계추출, 상호참조 정보 추출에 있어 대소문자 구분이 성능에 미치는 영향을 확인하기 위해 bert-base모델의 cased(대소문자 구분)와 un-cased(대소문자 미 구분) 모델에 대한 성능을 비교함.



[그림 23] 대소문자 구분에 따른 성능 변화

- 학습과정 중 cased와 uncased의 전처리 과정 차이는, uncased인 경우 전체 단어를 모두 소문자로 변경시킨 후 WPM(WordPiece) 알고리즘에 따라 토크나이징함. cased 모델의 tokenizer의 전체 token의 개수는

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

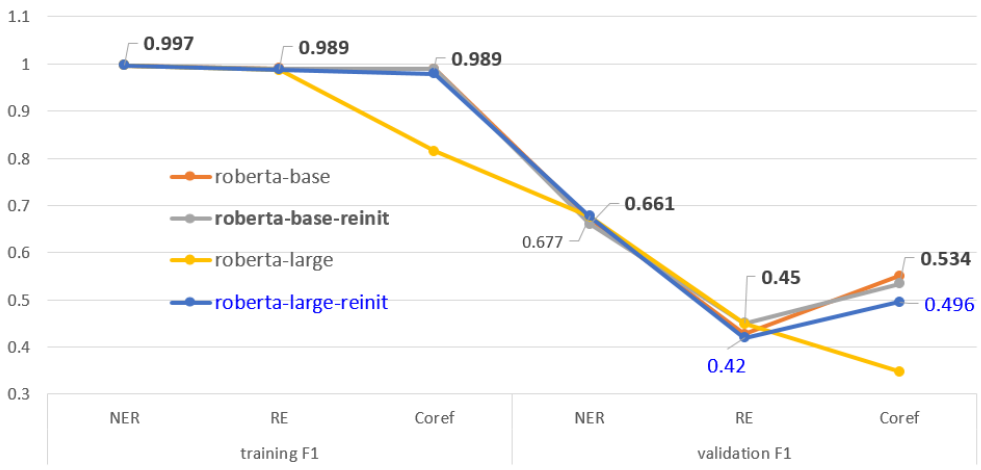
28,995개인 반면, uncased 모델의 tokenizer의 전체 token의 개수는 30,521개임.

- 위를 통해 확인할 수 있듯이, SciERC데이터와 같이 과학기술 전문용어들의 개체명인식, 관계추출, 상호 참조 관계에 대해 대소문자 구분 시 성능이 향상되는 것을 확인할 수 있음.

[표 14] roberta base 모델과 large모델의 architecture 차이

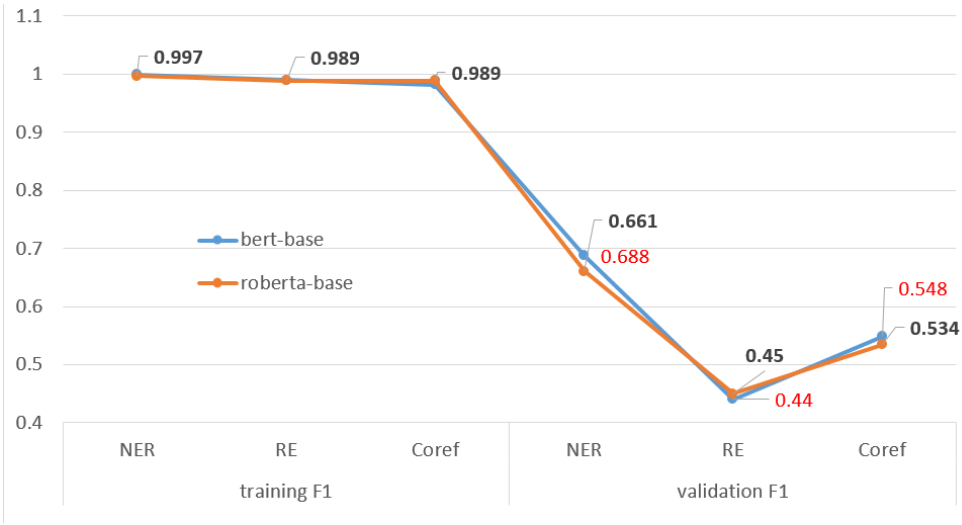
	architectures	roberta-base	roberta-large
1	hidden-size	768	1024
2	intermediate-size	3072	4096
3	max position embeddings	514	514
4	num attention heads	12	16
5	num hidden layers	12	24
6	vocab isze	50265	50265

- roberta 모델은 bert 모델과 달리 학습 방법의 변화를 달리한 모델인데 자세한 내용은 다음 ④단락의 학습 방법에 따른 성능변화에 서술함. base모델과 large 모델의 architecture의 차이는 표를 참조.
- 아래 그림을 통해 확인할 수 있듯이, SciERC 과학기술 데이터 셋의 정보 추출 태스크에 대해 모델 크기가 커진 경우 성능이 저하되는 현상을 확인할 수 있음. 똑같이 50 epoch에 대해 학습한 결과를 고려할 때, 상대적으로 적은 크기의 데이터셋에 대해 학습 모델 파라미터가 많은 경우 오히려 파인튜닝 학습에 성능저하 초래를 확인한 결과임.



[그림 24] SciERC 데이터셋 IE 태스크에 대한 모델 크기에 따른 성능 비교

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



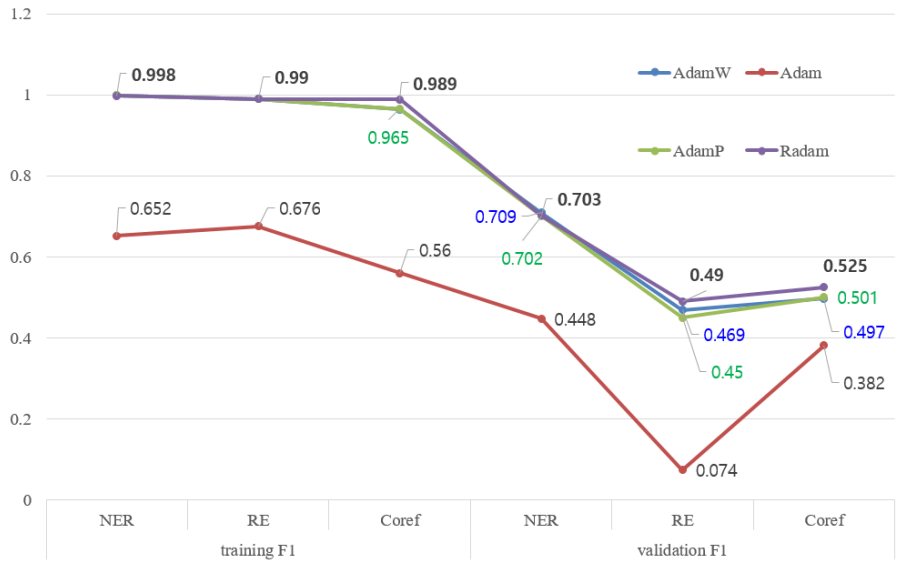
[그림 25] 학습 방법 및 데이터셋 크기 변화에 따른 성능 변화

- 데이터 셋 크기를 10배로 늘이고 학습 방법을 달리한 RoBERTa모델이 BERT모델에 비해 SciERC 데이터셋의 3종류의 정보 추출 태스크에서도 향상된 성능을 보임을 확인할 수 있음. 그러나, 그 성능 차이가 미미한 것을 볼 수 있는데, 데이터셋 크기를 10배로 늘였으나 해당 데이터의 종류가 과학기술 데이터셋과 크게 연관이 없는 데이터셋인 점이 있음.

○ Optimizer에 따른 성능 개선

- Adam optimizer 이후 최근 ICLR학회를 통해 발표되어온 optimizer인 AdamW[Loshchilv2019], RAdam[Lui2020], AdamP[Heo2021]는 그 성능의 우수성이 학회 발표 외에 여러 경진대회에서 우수성이 입증됨.
- SciERC 데이터 셋에 대해 정보 추출 태스크 파인튜닝에 대해 S2ORC를 기준으로 scibert-base로 학습하되 optimizer를 달리하여 성능 변화를 비교한 결과임. learning rate scheduler는 warm-up 구간이 존재하는 slanted-triangular를 적용함. 최대 learning rate은 1e-3임.
- Adam optimizer에 비해 최근 발표된 AdamW, Radm, AdamP optimizer가 태스크 성능변화에 큰 긍정적인 영향을 미침을 확인할 수 있음.
- AdamP, AdamW, RAdam모두 향상된 성능을 보이나, 관계 추출 태스크를 기준으로 RAam이 가장 우수한 성능을 보임을 확인할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 26] Optimizer변화에 따른 정보추출 파인튜닝 태스크 성능 비교

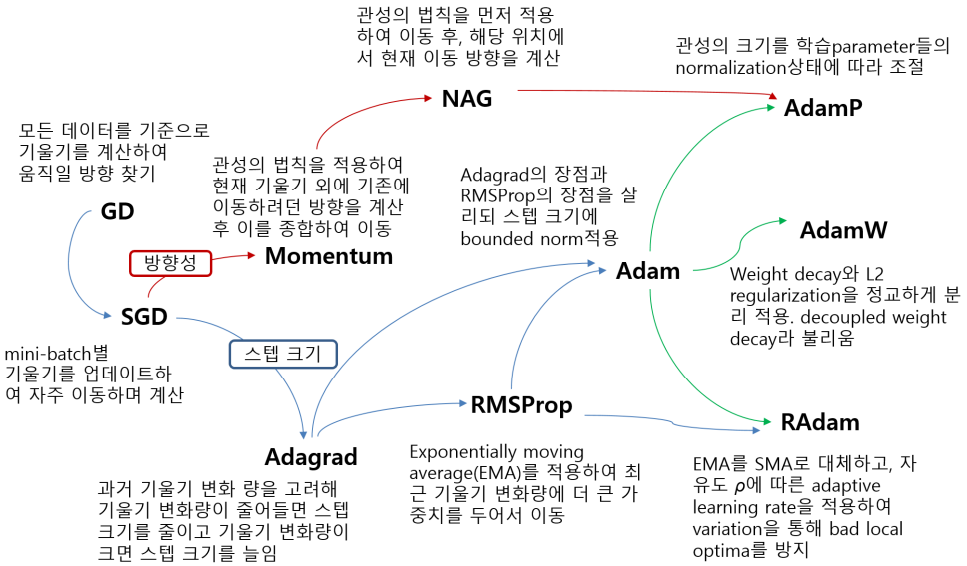
- Neural network의 학습 중 back propagation 과정은 loss function 값에 따라 parameter를 업데이트함. 이 때 optimizer의 역할은 loss 값을 최소화하고 학습 파라미터가 global minimum area를 잘 찾도록 하는 것임. 이는 딥러닝 알고리즘 학습 문제를 optimization 문제로 변환하는 가장 간단한 방법이 training set에 대한 loss를 최소화하는 것이기 때문으로 결과적으로 다음과 같이 정의할 수 있음:

$$\left\{L(\Theta) \coloneqq \frac{1}{N}\sum_{i=1}^{N} f(\Theta;\, x_i, y_i) + \lambda\|\Theta\|_p\right\}$$

  - $\{(x_i, y_i)\}_{i=1}^{N}$: training elements x_i and corresponding labels y_i
  - Θ : network parameters
  - $f(\Theta;\, x_i, y_i)$: objective loss function with parameter Θ by (x_i, y_i)
  - $\|\Theta\|_p$: p-norm regularization function
  - λ : regularization weight

- 딥러닝 모델은 일반적으로 많은 양의 parameter와 데이터를 사용함 (예: BERT 모델의 1.1x108개 파라미터, 33x108개 토큰). 이는 Hessian(second order derivatives) 계산을 어렵게 하며 전체 데이터를 사용한 gradient descent 계산 또한 많은 시간을 요구함. 따라서 딥러닝 모델의 optimization 방법은 objective function과 gradient만을 갱신하는 Hessian free(first order)로 이루어져야함.
- 딥러닝 모델의 optimizer는 GD(Gradient Descent)와 SGD(Stochastic Gradient Descent) 알고리즘에서부터 스텝 방향(방향성)과 스텝 사이즈 관점에서 아래 그림과 같이 개선되어 왔음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 27] 딥러닝 모델 optimizer의 발전 과정

- AdamW(Adam with decoupled Weight decay)는 Adam optimizer가 SGD에 비해 일반화 성능이 더 낮게 나타나는 경우에 대한 개선을 위해 weight decay와 L2 regularization를 분리하여 loss value에 따라 weight decay를 다르게 적용함.
- RAdam(Rectified Adam)은 Adam optimizer가 bad local optima에 도달하는 원인으로 학습 초기 adaptive learning rate의 분산이 크고 샘플 수가 적을수록 분산이 더 커지기 때문이라고 지적함. RAdam은 warm-up과정 없이 adaptive learning rate의 분산을 수정하는 기법을 제안하였는데 EMA를 SMA(Simple Moving Average)로 대체하였으며, 자유도(ρ)가 증가하면 분산이 감소된다는 이론을 적용하여 일정 시간마다 variance rectification term을 수정함.

input: α**(lr),** β_1,β_2**(betas),** θ_0**(params),** $f(\theta)$**(objective),**
ε**(epsilon),** λ**(weight decay/**L_2 **regularization)**

initialize: $m_0 \leftarrow 0$**(first moment),** $v_0 \leftarrow 0$**(second moment),**
$\hat{v}_0^{max} \leftarrow 0$, $\eta_0 \leftarrow 0(Schedule\ multiplier)$

for $t = 1$ *to* ... ***do***
$g_t \leftarrow \nabla_\theta f_t(\theta_{t-1}) + \boldsymbol{\lambda\theta_{t-1}}$ **(Adam with L2 regularization)**
$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1-\beta_1) \cdot g_t$
$v_t \leftarrow \beta_2 \cdot v_{t-1} + (1-\beta_2) \cdot g_t^2$
$\hat{m}_t \leftarrow m_t / (1-\beta_1^t)$
$\hat{v}_t \leftarrow v_t / (1-\beta_2^t)$
$\eta_t \leftarrow SetScheduleMultiplier(t)$
$\theta_t \leftarrow \theta_{t-1} - \eta_t \left(\alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} + \boldsymbol{\lambda\theta_{t-1}} \right)$
(Adam with decoupled weight decay(AdamW))

return optimized parameter θ_t

[그림 28] AdamW optimizer 알고리즘

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

input: $\{\alpha_t\}_{t=1}^{T}$(lr), β_1,β_2(betas), θ_0(params), f(θ)(objective), ε(epsilon)

initialize: $m_0 \leftarrow 0$(first moment), $v_0 \leftarrow 0$(second moment), $\rho_\infty \leftarrow 1/(1-\beta_2) - 1(\boldsymbol{max\ length\ of\ the\ SMA})$

for $t = \{1 \dots T\}$ *do*
  $g_t \leftarrow \nabla_\theta f_t(\theta_{t-1})$
  $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1-\beta_1) \cdot g_t$
  $v_t \leftarrow \beta_2 \cdot v_{t-1} + (1-\beta_2) \cdot g_t^2$
  $\hat{m}_t \leftarrow m_t/(1-\beta_1^t)$
  $\rho_t \leftarrow \rho_\infty - 2t\beta_2^t/(1-\beta_2^t)$**(** $\boldsymbol{the\ length\ of\ the\ SMA}$**)**
  If the variance is tractable, i.e., $\rho_t > 4$ ***then***
    $\hat{v}_t \leftarrow v_t/(1-\beta_2^t)$**)**
    $\boldsymbol{r_t} \leftarrow \sqrt{\frac{(\rho_t-4)(\rho_t-2)\rho_\infty}{(\rho_t-4)(\rho_t-2)\rho_t}}$ $(\boldsymbol{the\ variance\ rectification\ term})$
  $\theta_t \leftarrow \theta_{t-1} - \alpha_t r_t \hat{m}_t/\sqrt{\hat{v}_t}$
  else
  $\theta_t \leftarrow \theta_{t-1} - \alpha_t \hat{m}_t$

return optimized parameter θ_t

[그림 29] RAdam optimizer 알고리즘

- AdamP(Adam with Projection)는 optimizer들이 일반적으로 momentum으로 학습 방향의 가속도를 추가하지만, 학습이 덜 이루어진 상태에서 momentum의 크기가 커지면 학습이 안정적으로 수렴점에 도달하지 못함을 지적함. 이를 개선하고자 normalization state에 따라 momentum을 조정하여 안정적으로 수렴할 수 있도록 함. 하지만 normalization state에 분석으로 연산이 추가되어 학습 속도가 느려지는 제약이 있음.

input: α(lr), β_1,β_2(betas), θ_0(params), f(θ), ε(epsilon),

initialize: $m_0 \leftarrow 0$(first moment), $v_0 \leftarrow 0$(second moment),

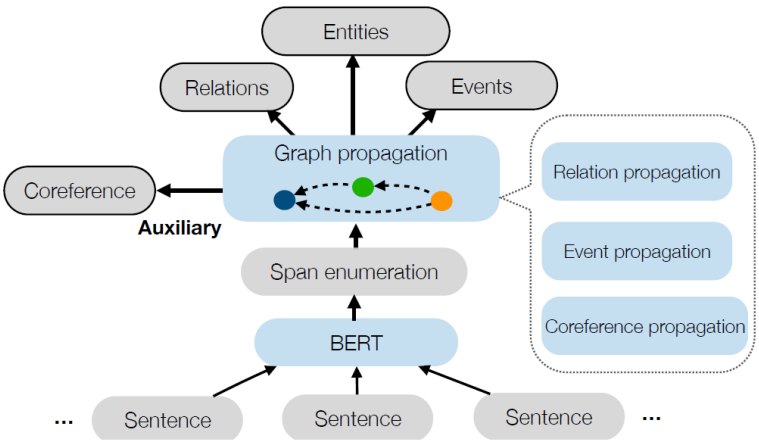
for $t = 1$ *to* ... ***do***
  $g_t \leftarrow \nabla_\theta f_t(\theta_{t-1})$
  $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1-\beta_1) \cdot g_t$ (1st moment estimate)
  $v_t \leftarrow \beta_2 \cdot v_{t-1} + (1-\beta_2) \cdot g_t^2$ (2nd moment estimate)
  $\hat{m}_t \leftarrow m_t/(1-\beta_1^t)$ (1st moment bias correction)
  $\hat{v}_t \leftarrow v_t/(1-\beta_2^t)$ (2nd moment bias correction)
 If $\cos(\theta_{t-1}, \nabla_\theta f_t(\theta_{t-1})) < \boldsymbol{\delta/\sqrt{dim(\theta)}}$
  $\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \boldsymbol{\Pi}_{\theta_t}\left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\varepsilon}\right)$
  else
  $\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\varepsilon}$
return optimized parameter θ_t

[그림 30] AdamP optimizer 알고리즘

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 정보추출 Multi-task학습을 통한 성능 개선

- DYGIE++모델은 SciERC 데이터셋을 만들고 이를 초기 모델화하여 성능을 검증한 Washington 대학교 Hannaneh Hajishirzi교수 랩실에서 SciERC 데이터셋의 사전학습 모델을 BERT계열로 전환하고 multi-task학습 방식과 events task를 적용시켜 파인 튜닝 성능을 향상시킨 결과물임. 2019년 EMNLP 게제 당시 SOTA모델임.
- Dygie++모델은 span기반의 정보 추출 방법을 확장하여, candidate text spans들을 생성하고 BERT(contextual language model)로 이를 encode한 후, text span 그래프에 태스크 특정 message를 업데이트하는 형태를 지님.
- Dygie++모델에서 BERT를 기반으로 한 encoding을 적용할 때, 입력 window크기를 증가시킴으로써 인접 문장 간의 context를 잘 추출하여 향상된 성능을 검증함.
- Dygie++모델은 multi-task간 message passing update를 적용하여 문장 간 의존 관계를 더 잘 해석하여 BERT자체만의 성능을 향상시킴. 특히, 특정 도메인의 정보 추출 태스크들에 있어서 향상된 성능을 검증함.



[그림 31] DYGIE++ framework

- BERT를 기반으로 생성한 Span Embedding을 4종류의 태스크를 수행하면서 relation, event, coreference 정보에 대한 message passing(propagation)을 통해 span graph 및 span word embedding이 업데이트 되면서 3종류의 정보 추출 태스크에 대한 loss함수에 전달됨.
- co-reference resolution 시 cross-sentence dependency를 표현하여 IE 태스크에서 향상된 성능을 보임.
- SciIE에 event extraction task를 추가하였고, event trigger를 연결하는 graph에 따라 span update를 수행함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- SciERC dataset에는 event trigger가 labeling이 따로 되어있지 않으나, event trigger를 entity type으로 annotate하고 event arguments를 event trigger와 argument사이의 관계로 태깅함. 즉, event trigger는 entity type, event argument는 relation이 됨.
- event extraction 과정은 한 token $d\ i$ 에 대해 entity label $t\ i$ 을 예측하여 할당하고, 한 문장 내의 모든 span $s\ j$ 에 대한 argument role $a\ i\ j$ 를 예측함. 즉, token 별 span에 대한 각 NER, RE, Coref 태스크를 수행함.
- Token encoding: Bert encoding을 사용하되, 입력 고정 크기 L의 sliding-window형태로 입력을 넣음.
- span enumeration: span의 시작과 끝을 나타내는 token들을 연결하여서 span width embedding과 함께 text내 span들을 enumeration함.
- 전 과정이 end-to-end로 모델 학습과 span들 사이의 주요 연결 관계 파악과 span사이의 정보 공유가 함께 업데이트 됨.
- 반복 횟수 t에 span $s\ t\ \in R\ d$ 에 대한 모델은 다음과 같이 update $u_x^t(i)$를 수행함:

$$u_x^t(i) = \sum_{j \in B_x(i)} V_x^t(i,j) \odot \mathrm{g}_j^t$$

- $V_x^t(i,j)$는 태스크 x에 대한 i, j의 score함수임. 예를 들어 span i의 span j에 대한 상호 참조 상위 개념이 될 점수. g_j^t 는 span을 표현함.
- Dygie++모델의 개별 태스크에 대한 성능 대비, 개체명 인식과 관계추출에 있어 관계 추출 정보 및 상호 참조 정보의 추출 정보를 추가한 경우 성능의 영향을 검증한 실험 결과는 아래 표와 같음.
- 표를 통해 확인할 수 있듯이, 개체명 인식에 상호참조 정보 전달이 도움이 되며, 관계 추출에 있어서도 상호 참조에 대한 정보 전달이 성능향상에 도움이 됨을 확인할 수 있음. 특히 과학기술 데이터인 SciERC 데이터 셋에 대해 그 성능을 확인할 수 있음.

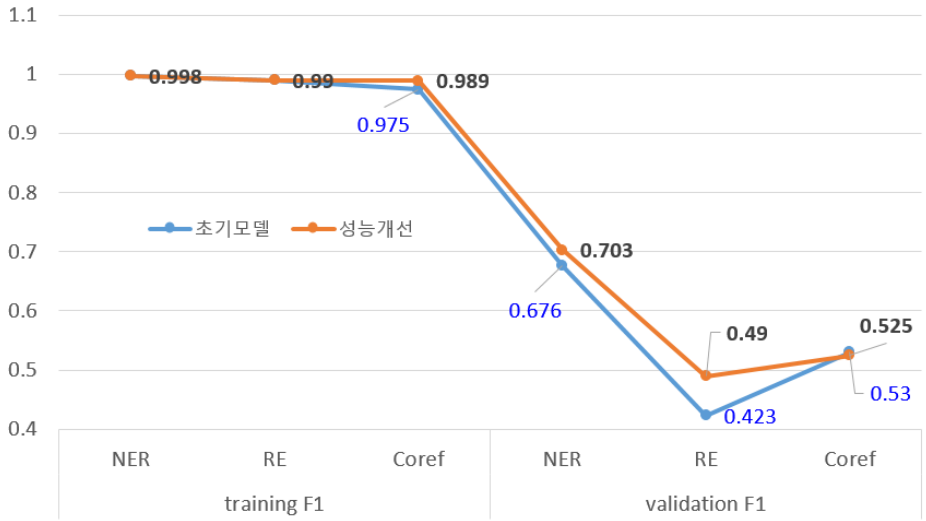
[표 15] 개체명 인식 F1 점수

	ACE05	SciERC	GENIA	WLPC
BERT + LSTM	85.8	69.9	78.4	**78.9**
+RelProp	85.7	70.5	-	78.7
+CorefProp	86.3	**72.0**	78.3	-
BERT Finetune	87.3	70.5	78.3	78.5
+RelProp	86.7	71.1	-	78.8
+CorefProp	**87.5**	71.1	**79.5**	-

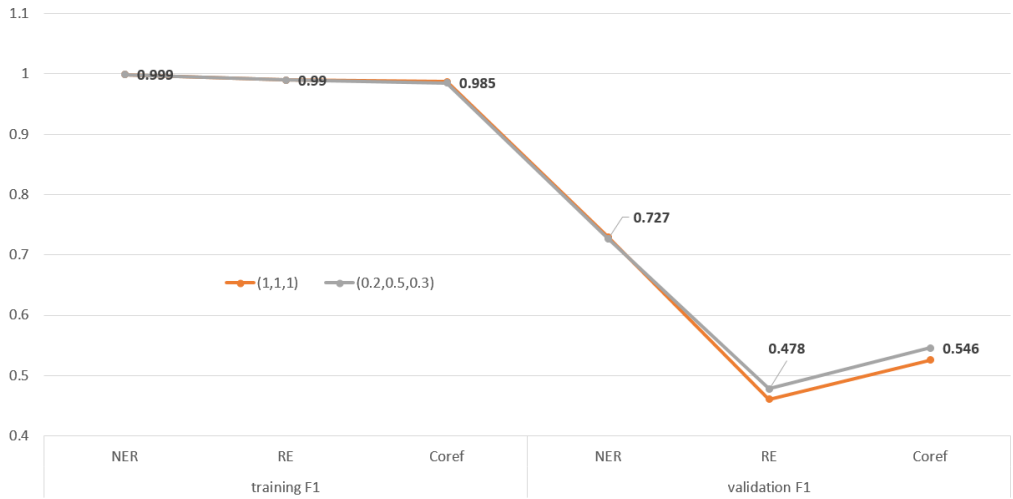
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[표 16] 관계추출 F1점수

	ACE05	SciERC	WLPC
BERT + LSTM	60.6	40.3	65.1
+RelProp	61.9	41.1	65.3
+CorefProp	59.7	42.6	-
BERT FineTune	**62.1**	44.3	65.4
+RelProp	62.0	43.0	**65.5**
+CorefProp	60.0	**45.3**	-



[그림 32] Dygie++ 모델의 성능 개선 (타겟 : JRE)



[그림 33] Dygie++ 모델의 성능 개선 (타겟 : NER)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 개선 모델 성능은 현재 paperswithcode의 leaderboard에서 SciERC NER 태스크 1위, SciERC Joint Entity and Relation Extraction 태스크 4위에 해당됨.

○ Intermediate Fine-tuning을 통한 성능 개선

- 최근 사전학습언어모델을 목표 태스크로 바로 파인튜닝하기 전에 중간 태스크에 대한 파인 튜닝을 수행하는 IFT(Intermiedate Fine-Tuning) 기법이 제안됨. 이는 중간 태스크 파인튜닝을 통해서 도메인 또는 태스크 지식을 추가적으로 학습하여 목표 태스크로 파인 튜닝 시 더 성능 향상을 이룰 것으로 기대함 [Phang2018].
- 그러나 IFT가 항상 더 나은 성능을 보장하지는 않음. 또한 언제 왜 좋은 성과를 내는 지 정확한 설명이 어려움. 이에 일부 연구에서는 일반 도메인에 속하는 태스크들을 가지고 목표 태스크-중간 태스크 페어를 지어 성능 향상이 이루어지는 지에 대한 실험을 수행함[Pruksachatkun2020,Vu2020].
- 연구결과로 IFT의 성능은 대상 데이터의 크기, 태스크 간 도메인 차이, 태스크 유사성, 태스크 복잡성과 같은 다양한 요인에 영향을 받는 다는 것이 알려짐.
- 그러나 이와 같은 연구결과는 대부분 일반 도메인 태스크들에서 검증되었기에 먼저 의공학과 같은 과학기술분야에서도 IFT가 잘 동작하는 지 먼저 실험을 통해 검증함.
- 구체적으로 의공학분야의 대표적 벤치마크인 BLURB의 3가지 태스크(NER, PICO extraction, RE, QA)의 11개 데이터세트로부터 100개의 목표 태스크-중간 태스크 페어를 지어 실험을 수행함. 파인튜닝의 사전학습 언어모델로는 일반 도메인의 BERT와 의공학 도메인의 PubMedBERT를 비교군으로 사용하였음.
- 표에서 열은 중간 태스크를 나타내며 행은 목표 태스크임. Baseline은 중간 태스크의 파인튜닝 없이 목표 태스크로 바로 파인 튜닝된 성능이며 기본적으로 의공학 특화 모델인 PubMedBERT가 모든 의공학 태스크에서 더 나은 성능을 보여줌. Baseline대비 성능이 향상되었다면 파란색 배경으로, 저하되었다면 주황색 배경으로 표기함. 채도가 높을수록 더 높은 변화량을 뜻함.
- 두 표를 비교해보면 의공학분야 태스크에 대해 IFT를 사용했을 때 PubMedBERT보다 BERT의 성능 향상이 더 빈번한 것으로 확인됨. 이는 의공학 지식이 없던 일반도메인 언어모델 BERT가 도메인 지식을 학습함에 따라 얻는 이득으로 분석됨. PubMedBERT는 이미 의공학 분야에 특화된 지식을 이미 습득하였기에 이러한 이득이 적지만 그럼에도 일부 태스크에서는 성능 향상을 보임. 이는 태스크 지식 전이로 얻어지는 이득으로 판단됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Table 3 Experimental results of the STILT method in PubMedBERT. The resulting value is the average of three runs.

			Intermediate Task										
		Baseline	BC5-chem	BC5-disease	NCBI-disease	BC2GM	JNLPBA	EBM PICO	ChemProt	DDI	GAD	PubMedQA	BioASQ
Target task	BC5-chem	92.97	-	92.99	93.11	93.46	93.20	93.22	92.88	92.88	93.05	93.28	93.00
	BC5-disease	84.61	85.41	-	85.91	85.73	85.71	85.52	85.24	85.38	85.63	85.38	85.29
	NCBI-disease	87.73	87.46	88.10	-	87.57	88.01	88.27	88.06	87.99	87.77	88.81	87.72
	BC2GM	83.91	83.86	84.27	84.17	-	84.00	84.13	84.24	83.87	84.52	83.98	84.25
	JNLPBA	79.02	78.93	78.94	78.77	78.84	-	79.25	79.25	79.18	79.26	79.00	78.99
	EBM PICO	73.20	74.00	73.86	73.90	73.58	73.66	-	73.66	73.85	73.96	73.88	73.83
	ChemProt	77.28	77.29	77.11	77.44	75.14	76.65	76.97	-	76.80	76.70	77.08	77.42
	DDI	82.96	82.72	81.67	82.28	79.50	82.21	81.47	82.40	-	82.59	82.70	83.22
	GAD	82.17	81.63	81.73	82.22	83.62	81.98	82.42	82.62	83.02	-	81.53	83.57
	PubMedQA	55.00	57.80	51.60	54.40	55.00	50.80	52.90	62.30	61.80	50.40	-	65.40
	BioASQ	84.29	88.22	83.93	82.86	78.22	86.07	80.72	80.00	92.15	83.22	86.79	-

Table 2 Experimental results of the STILT method in BERT. The resulting value is the average of three runs.

			Intermediate Task										
		Baseline	BC5-chem	BC5-disease	NCBI-disease	BC2GM	JNLPBA	EBM PICO	ChemProt	DDI	GAD	PubMedQA	BioASQ
Target task	BC5-chem	88.92	-	89.37	89.46	89.47	89.66	89.40	89.38	89.54	89.23	89.27	89.27
	BC5-disease	80.74	80.69	-	81.35	81.32	80.93	80.33	80.32	80.38	80.80	80.58	80.70
	NCBI-disease	85.33	86.19	85.93	-	86.37	85.32	85.64	85.76	86.05	86.12	86.60	85.53
	BC2GM	80.83	80.64	81.02	81.43	-	81.28	81.44	80.80	80.95	81.27	81.65	80.97
	JNLPBA	77.32	77.16	77.61	77.52	77.63	-	77.58	77.51	77.62	77.63	77.64	77.84
	EBM PICO	72.15	72.55	72.32	72.44	72.16	72.49	-	71.95	72.49	72.55	72.26	72.26
	ChemProt	71.23	71.00	71.06	70.86	69.82	71.05	71.11	-	70.96	71.47	71.82	71.68
	DDI	77.01	77.32	78.38	77.87	74.57	77.71	78.57	79.03	-	78.91	78.29	78.23
	GAD	78.93	77.21	78.40	78.79	80.56	79.12	80.21	78.91	78.59	-	79.70	77.97
	PubMedQA	50.6	50.20	51.10	50.80	50.90	51.80	49.20	58.30	58.50	51.10	-	53.40
	BioASQ	61.43	66.91	68.33	71.90	62.86	67.38	71.67	75.48	76.66	70.48	66.66	-

[그림 34] 의공학분야에서 IFT 기법의 검증 실험 결과.

- 본 연구에서는 DeBERTa모델을 기반으로 과학기술특화 언어모델인 SciDeBERTa를 개발하며, DeBERTa는 이전 BERT와 달리 next sentence prediction을 수행하지 않고 대신 더 긴 문자열을 입력받도록하는 RoBERTa의 기법을 사용함. 입력의 길이가 길어짐에 따라 더 멀리있는 단어로부터의 context의 파악이 가능하지만 next sentence prediction을 수행할 때 얻어지는 문장 간 관계 파악에 대한 학습이 덜 이루어짐. 따라서 문장을 처리하는 태스크에 대해서 성능이 낮게 나타나는 경우가 있음.
- 따라서 이러한 DeBERTa 모델을 기반으로하는 SciDeBERTa 모델 또한 문장 관련 태스크에서 낮은 성능을 보이므로 문장 처리 관련 태스크 지식을 습득할 수 있도록 관련 중간 태스크를 학습하여 성능을 향상시킴.
- 목표 태스크는 BLURB에서 semantic sentence similarity (SS)를 수행하는 BIOSSES와 document classification (DC)를 수행하는 Hoc이며, 중간 태스크로는 clinical semantic textual similarity 데이터셋인 clinicalSTS2018/2019를 사용함. IFT를 통해 아래 표와 같은 성능향상을 확인할 수 있었음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

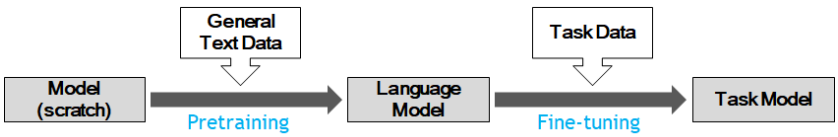
Task	Dataset	without IFT	with IFT
SS	BIOSSES	57.68	87.30
DC	Hoc	61.09	65.36

[표 17] SciDeBERTa-BIO 모델 기반 태스크 모델에서 IFT 기법 적용 시 성능 개선 결과

□ 과학기술 텍스트 이해에 특화된 SciDeBERTa 모델 개발

○ 도메인 특화 언어 모델의 개발 방안

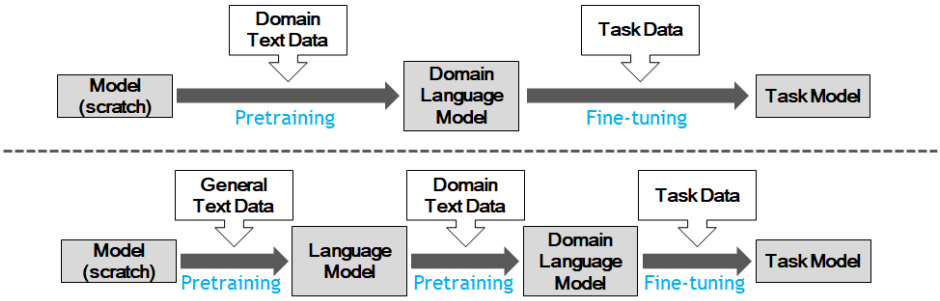
- 자연어 처리에서 도메인은 일관된 유형의 말뭉치를 나타내며 주제, 스타일, 장르 또는 언어 유형 등을 들 수 있음. BERT를 대표로하는 자연어 처리 분야의 언어 모델은 주로 위키피디아, 책 등의 일반 도메인 데이터로 학습되어 일반적인 문제 해결을 목표로 하여왔음.
- 언어 모델은 먼저 대규모 텍스트 데이터로 사전학습되어 언어에 대한 전반적인 지식을 습득하게 되고 그 후 특정 문제 해결에 성공적으로 동작하기 위해 해당 태스크 데이터로 학습하는 파인튜닝 단계를 거침.



[그림 35] 일반적 언어 모델의 사전학습과 파인튜닝 수행 과정

- 이러한 사전학습과 파인튜닝의 구조는 언어 모델들이 자연어 처리 분야의 다양한 태스크에서 성공적인 결과를 얻게 함. 그러나 사전학습에서 학습된 지식이 일반 도메인에 한정되었기에 일반 도메인을 벗어나는 태스크의 경우 성능이 낮게 나타남.
- 특정 도메인의 태스크를 해결하기 위한 도메인 특화 언어 모델 개발 방식으로는 크게 ① 일반적 언어 모델 학습 과정과 동일하게 모델을 학습하면서 도메인 특화 데이터를 사용하는 것과 ② 이미 일반적 도메인 지식을 학습한 언어 모델에 추가적으로 특화 도메인 데이터를 사전학습하는 두 가지 방식을 들 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 36] 도메인 특화 언어 모델 학습을 위한 두 가지 방안

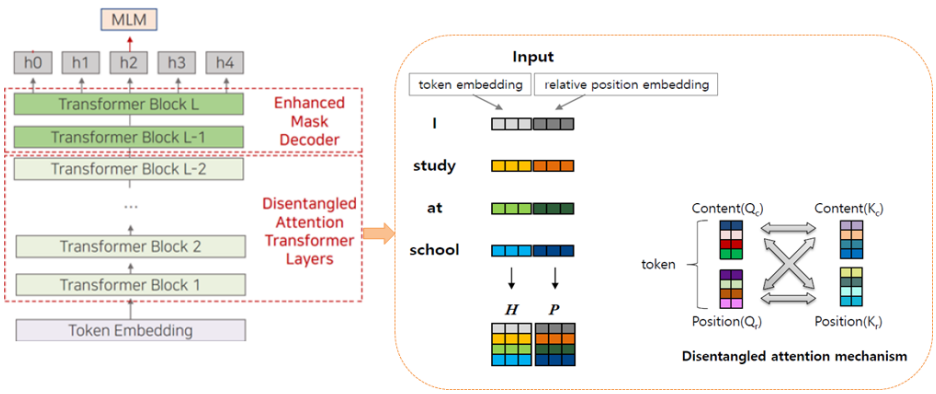
○ 과학기술 텍스트 이해 특화 언어 모델 SciDeBERTa 개발 방안

- 과학기술 텍스트 이해에 특화된 언어 모델 개발을 위한 기반 모델로 DeBERTa 모델을 선정함. 선정 사유는 자연어 처리 대표적 벤치마크인 SuperGLUE의 리더보드를 기준으로 상위 5위안에 있는 모델 중에서 가장 모델 사이즈 대비 높은 성능을 보임.

	Name	Model	Score	Model Size
1	Liam Fedus	ST-MOE-32B	91.2	32B
2	Microsoft Alexander v-team	Turing NLR v5	90.9	5.4B
3	ERNIE Team – Baidu	Ernie3.0	90.6	10B
4	Zirul Wang	T5+ UDG, Single model	90.4	11B
5	DeBERTa Team- Microsoft	DeBERTa Turing NLRv4	90.3	1.5B

[표 18] SuperGLUE 벤치마크 SOTA 언어 모델

- DeBERTa는 BERT의 향상모델인 RoBERTa에 추가적인 학습 알고리즘인 분리된 어탠션(disentangled attention)과 향상된 마스크 디코더(enhanced mask decoder)를 적용하여 RoBERTa보다 더 적은 학습 데이터만으로도 더 높은 성능을 달성함.



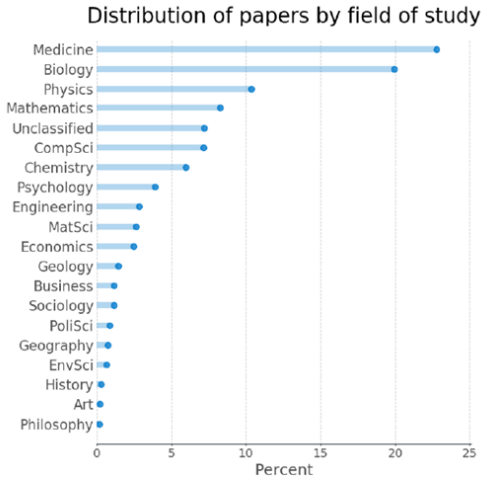
[그림 37] DeBERTa 모델의 구조

- 언어 모델 학습을 위해서 사용될 데이터로는 과학기술분야 논문

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

데이터셋인 S2ORC(Science Technology Dataset for Pre-training)을 선정하였으며 이는 기존 과학기술분야 언어 모델의 사전학습에 사용된 데이터들에 비해서 더 많은 분야를 포함하였기에 더 광범위한 문제를 다룰 수 있을 것으로 판단함.

Total papers	81.1M
Papers w/ PDF	28.9M (35.6%)
Papers w/ bibliographies	27.6M (34.1%)
Papers w/ GROBID full text	8.1M (10.0%)
Papers w/ LaTeX full text	1.5M (1.8%)
Papers w/ publisher abstract	73.4M (90.4%)
Papers w/ DOIs	52.2M (64.3%)
Papers w/ Pubmed IDs	21.5M (26.5%)
Papers w/ PMC IDs	4.7M (5.8%)
Papers w/ ArXiv IDs	1.7M (2.0%)
Papers w/ ACL IDs	42k (0.1%)



[그림 38] S2ORC 데이터셋의 구성요소와 분야별 분포

- DeBERTa 모델과 S2ORC 데이터셋을 기반으로 다음과 같이 과학기술분야 특화 언어 모델인 SciDeBERTa의 개발을 수행.

[표 19] SciDeBERTa 모델의 사전학습 방안 요약

Model	Method	Corpus Type	Text size	Dataset Type
SciDeBERTa	continual learning	general +science (20 category)	69GB	abstract
SciDeBERTa(full)	from scratch	science (20 category)	258GB	full-text
SciDeBERTa(CS)	continual learning	general +computer science	7GB	abstract
SciDeBERTa(Bio)	continual learning (from SciDeBERTa(full))	biology, medicine	12GB	abstract

- SciDeBERTa와 SciDeBERTa(full) 모델은 과학기술분야에 범용적으로 사용 될 수 있는 것을 목표로 하여 20개 과학기술분야 데이터를 모두 학습에 사용함. 두 모델은 학습 데이터에 논문 요약과 논문 전문을 사용하는 것에서 차이를 보임.
- SciDeBERTa(CS)와 SciDeBERTa(Bio)는 각각 과학기술분야에서도 컴퓨터공학과 의공학 분야에 사용되는 것을 목표로 한 특화 모델임.
- SciDeBERTa(Bio)모델은 성능 개선을 위해 학습 기법, 파라미터, 데이터유형등을 달리하는 5개의 예비 모델을 학습하였으며 그 중 가장

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

높은 성능을 보인 모델을 SciDeBERTa(Bio)로 확정함.

- 예비 모델들은 아래 표와 같은 조건으로 데이터는 바이오분야 데이터로만 학습되었음. 성능 비교는 의공학분야 대표적 벤치마크인 BLURB으로 평가됨.

모델 번호	학습기법	기반모델
#1	continual learning	SciDeBERTa-v2
#2	continual learning	$DeBERTa_{base}v3$
#3	from scratch	SciDeBERTa-v2
#4	from scratch	SciDeBERTa-v2
#5	continual learning	#4

[표 20] SciDeBERTa-BIO 예비 모델들의 학습 방안 비교

Task	Dataset	BioLinkBERT(SOTA)	#1 (최종모델)	#2	#3	#4	#5
NER	BC5-chem	93.38	93.04	93.11	92.39	91.79	92.05
	BC5-disease	85.45	85.13	82.18	84.51	84.21	84.68
	NCBI-disease	88.12	89.08	89.19	89.05	88.78	88.23
	BC2GM	84.39	83.94	84.10	83.27	83.20	83.46
	JNLPBA	78.78	80.23	80.13	79.76	79.80	79.79
PICO	EMB PICO	74.20	73.73	74.12	73.59	73.67	73.75
RE	ChemProt	78.10	77.80	74.27	75.53	74.02	74.95
	DDI	81.82	80.47	80.75	79.35	79.81	80.07
	GAD	82.51	82.23	81.79	78.32	80.17	79.93
SS	BIOSSES	92.50	87.30	66.56	62.78	85.56	81.87
DC	Hoc	84.73	65.36	68.74	70.28	69.13	69.81
QnA	PubMedQA	58.32	56.84	49.84	52.00	59.36	58.12
	BioASQ	91.57	93.14	71.71	85.14	81.71	85.57
평균 성능		82.61	80.64	76.65	77.38	79.32	79.41

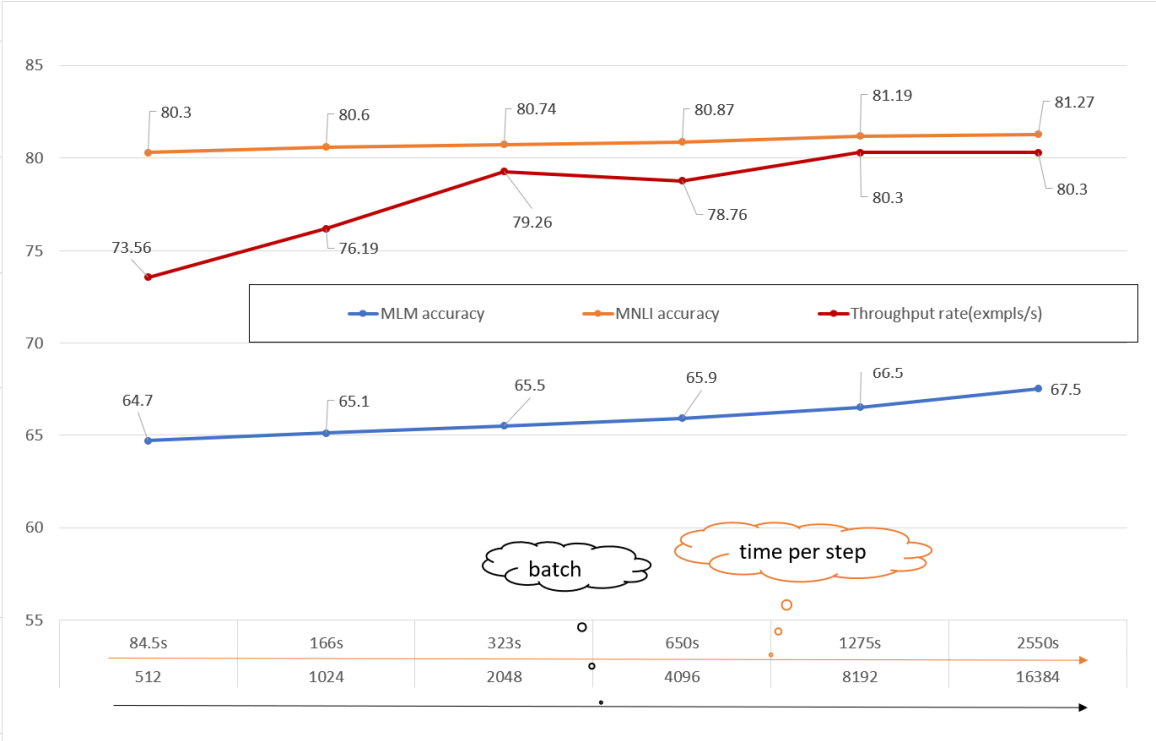
[표 21] SciDeBERTa-BIO 예비 모델의 BLURB 벤치마크 성능 비교 결과

□ 거대 모델 확장 및 대량 데이터 학습을 위해 multi-node 환경의 최적 학습 알고리즘 탐색

○ 거대 모델 확장 및 대량의 데이터 학습을 위해 multi-node, multi-gpu를 통한 최적 학습 알고리즘 탐색

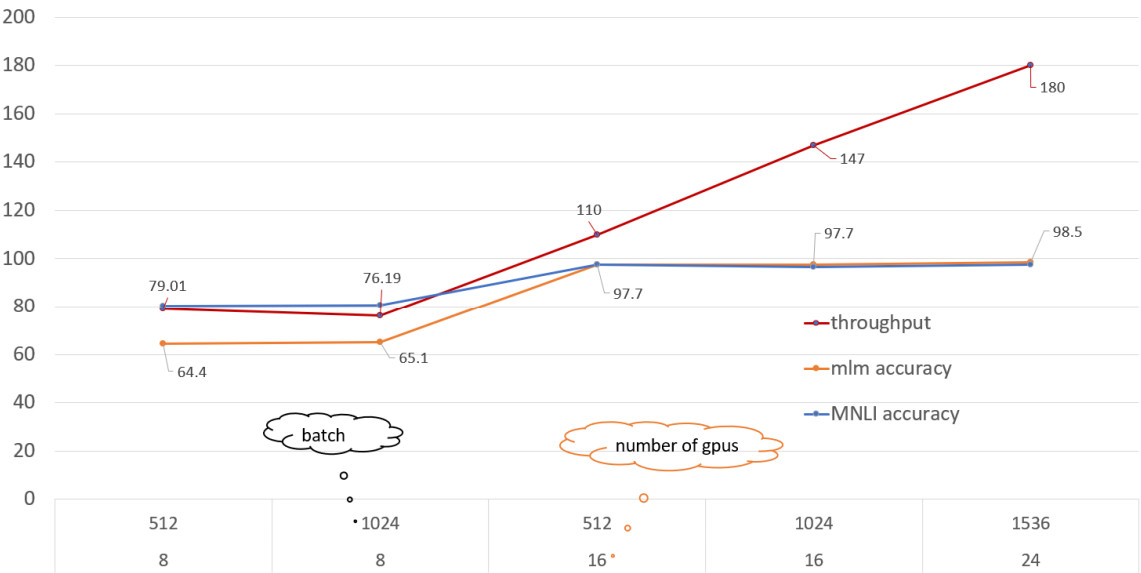
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 배치크기 변화에 따른 정확도 성능이 개선되면서 데이터 처리 성능 향상 확인.



[그림 39] 배치크기 변화에 따라 throughput 및 정확률 성능 향상

- 1 노드, 8개 GPU로 학습하는 것에 비해 2 노드 16개 GPU일 때 throughput 2배 개선 및 3 노드 24개 GPU일 때 throughput 2.5배 개선 확인



[그림 40] Node 개수 증가에 따른 batch 크기 증가에 따라 throughput과 정확률 성능 향상

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 과학기술 지식 추출 기술 개발

□ SciDeBERTa 기반 NLP 태스크 수행 모델 개발

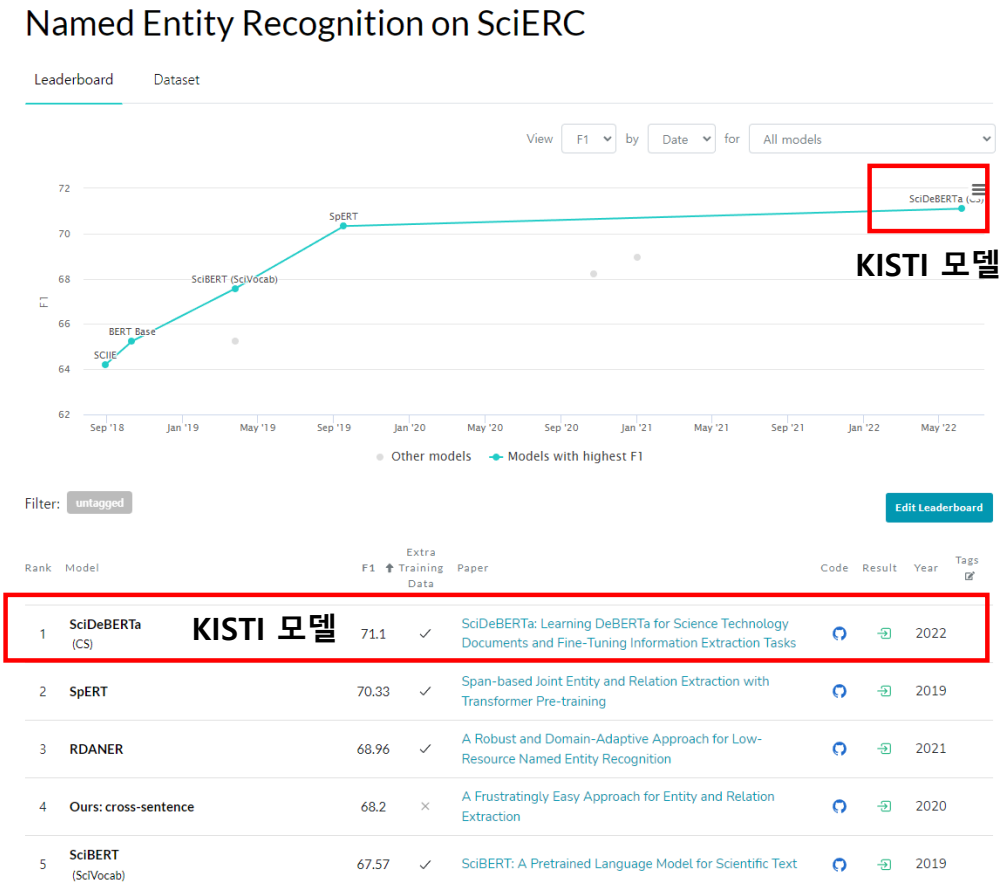
○ SciDeBERTa 모델을 과학기술 텍스트 처리 분야의 공식 벤치마킹 데이터 셋인 SciERC, 의료 분야의 데이터 셋인 GENIA에 적용하여 자연어처리의 세부 태스크인 NER, JRE, Coref 수행

- PLM fine-tuning 시 모델 파라미터 재 초기화 기술, multi-task 학습 방식 그리고 optimizer 탐색 기법 적용
- SciDeBERTa 모델을 컴퓨터공학, 바이오 분야로 개별 fine-tuning 한 결과가 세계적인 수준의 정확도를 보이며, 과학기술의 세부 도메인에 대한 텍스트 처리로의 일반화가 잘 되는 것을 확인함.
- 컴퓨터공학 분야 태스크 데이터셋인 SciERC와 바이오분야 데이터셋인 GENIA의 성능 결과: SciERC 기준 NER 태스크 세계 1위, GENIA 기준 세계 2위 달성

Model	SciERC			GENIA	
	NER	JRE	Coref	NER	Coref
BERT	67.9±0.5	44.7±0.8	55.0±0.2	76.6±0.2	449.±0.3
DeBERTa	68.9±0.6	44.6±0.7	**59.3±0.7**	77.8±0.1	46.5±0.8
SCIIE	64.2	39.3	48.2	-	-
SciBERT	67.57	-	-	78.0±0.2	44.9±1.0
S2ORC-SciBERT	68.93 ±0.19	-	-	78.1±0.2	45.7±0.2
SpERC	70.33	-	-	-	-
SciDeBERTa	70.8±0.5	45.5±0.8	56.5±0.8	**78.7±0.3**	**47.0±0.7**
SciDeBERTa(full)	**72.4±0.4**	**47.4±1.2**	56.9±0.8	78.6±0.2	45.4±1.0
SciDeBERTa(CS)	71.1±0.6	46.0±0.8	57.4±0.6	77.8±0.3	46.3±0.3

[표 22] 자체 개발한 SciDeBERTa 모델의 SciERC 및 GENIA 벤치마킹 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 41] SciDeBERTa 모델의 SciERC 기준 세계 1위 달성 (2022.10.24. 기준 Paperswithcode 페이지 캡쳐)

- 의공학분야 대표적 벤치마크 데이터셋인 BLURB의 성능 결과:

Task	Dataset	metric	BioLinkBERT(SOTA)	SciDeBERTa(CS)	SciDeBERTa(full)	SciDeBERTa(Bio)
NER	BC5-chem	F1	93.38	92.21	92.75	93.04
	BC5-disease		85.45	83.25	84.27	85.13
	NCBI-disease		88.12	87.92	89.89	89.08
	BC2GM		84.39	84.72	83.97	83.94
	JNLPBA		78.78	78.83	66.20	80.23
PICO	EMB PICO	Macro F1	74.20	73.37	73.69	73.73
RE	ChemProt	Micro F1	78.10	75.50	76.86	77.80
	DDI		81.82	75.61	78.75	80.47
	GAD		82.51	-	-	82.23
SS	BIOSSES		92.50	-	-	87.30
DC	Hoc		84.73	-	61.42	65.36
QnA	PubMedQA	Accuracy	58.32	55.8	51.99	56.84
	BioASQ		91.57	76.43	67.86	93.14

[표 23] 의공학분야 대표적 벤치마크 데이터셋인 BLURB에서의 성능평가 결과

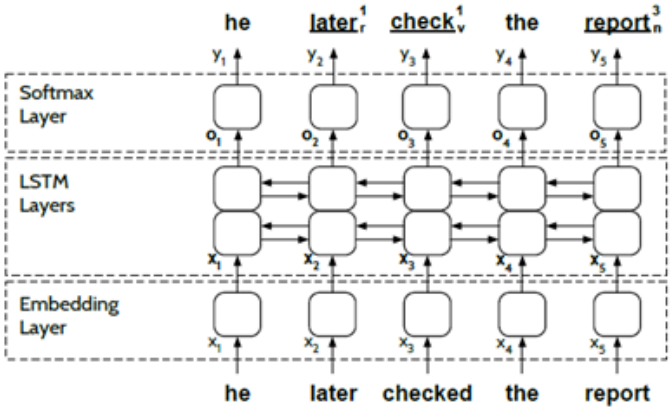
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- BLURB 벤치마크에서 동일 크기 모델 중 세계최고 수준 모델인 BioLinkBERT(base)와 비교하였을 때 13개 태스크 중 11개 태스크에서 성능달성도가 97%를 넘는 성능을 달성함.

□ 언어 이해 표준화를 위한 WSD 기술

○ Neural Sequence Learning Model 연구

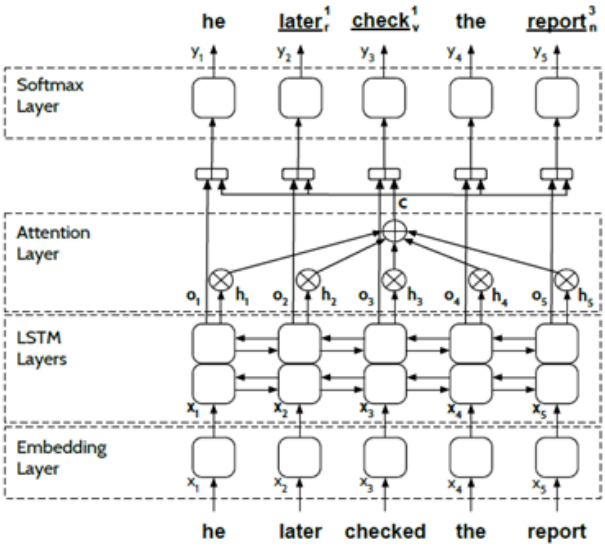
- 전통적으로 WSD는 문맥과 함께 주어진 타겟 단어에 대해, WordNet 사전에서 그 의미에 맞는 개념으로 분류하는 문제로 접근하였으나, Neural Sequence Learning Model에서는 Sequence Learning 문제로 접근한 기법임.
- 이를 위해 기본적인 접근으로 Bidirectional LSTM 모델을 2-Layer로 구성하고, 입력으로는 레이블링 되지 않은 문장을, 출력은 워드넷의 개념으로 레이블링된 개념으로 구성하여 학습함.



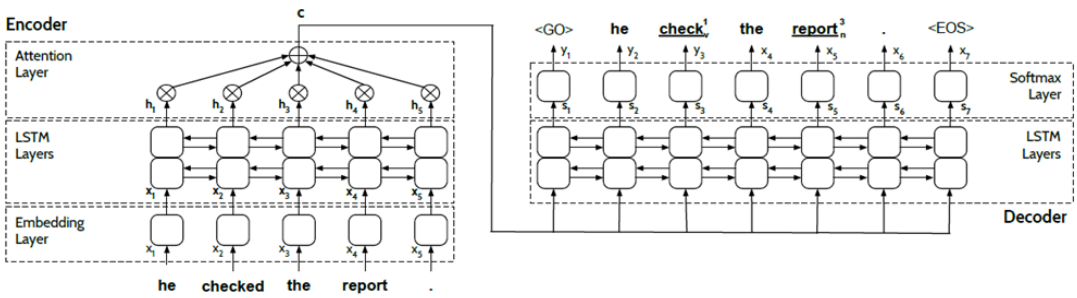
[그림 42] WSD 태스크를 위한 Bidirectional LSTM 기반의 Neural Sequence Learning Model 구조도

- Attention은 DNN 모델을 구성하는 Neuron 보다 문맥으로 주어진 단어들과의 상관성을 더욱 잘 학습할 수 있음이 검증되어 있기 때문에, 기본 Bidirectional LSTM 모델에 Attention 층을 추가하여 학습함으로써 그 성능의 차이를 비교함.
- 또한 번역 모델에서 성능이 우수함으로 알려져 있는 인코더-디코더 모델인 Sequence-to-Sequence 구조를 활용하여 WSD 태스크를 수행함. 인코더와 디코더는 각각 2 Layer의 LSTM으로 구성하고, 인코더와 디코더 사이에 Attention 계층을 둠으로써 상호 연관성(의존성)을 더욱 잘 학습할 수 있도록 함.

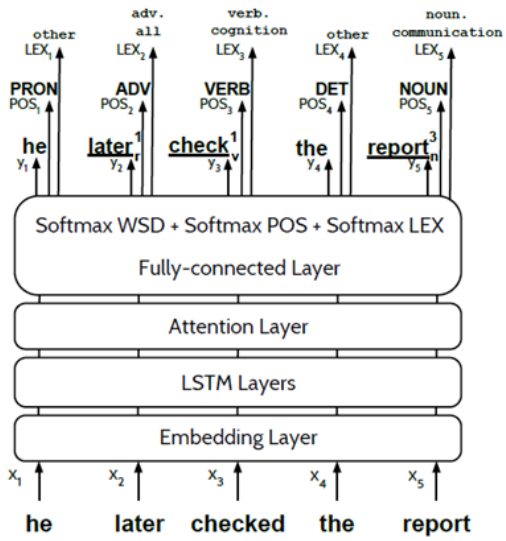
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 43] WSD 태스크를 위한 Attention 층을 추가한 Bidirectional LSTM 기반의 Neural Sequence Learning Model 구조도



[그림 44] WSD 태스크를 위한 Attention 층을 추가한 인코더-디코더 기반의 Neural Sequence Learning Model 구조도



[그림 45] WSD 태스크를 위한 Attention 층을 추가한 인코더-디코더 기반의 Neural Sequence Learning Model 구조도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 위와 같이 구성한 각 WSD 학습 모델에 Multi-Task Learning(MTL)을 추가로 반영함. 다수의 태스크를 동시에 학습하는 MTL은 모델의 일반화 성능을 높이는 것으로 검증됨. 본 연구에서는 WSD에 Part-Of-Speech (POS) 태스크와 LEX (워드넷에 정의된 상위 분류) 태스크를 추가하여 동일한 모델 학습을 추가함.
- 각 모델을 테스트하기 위해 SemCor 3.0 데이터 셋을 이용하여 학습, SemEval-2017 데이터를 이용한 검증, 그리고 SensEval-2, SensEval-3, SemEval-2013, SemEval-2015를 이용하여 실험을 진행함.
- Attention을 적용한 Bidirectional LSTM 모델이 가장 우수함을 보였으며, 특히 MTL을 적용한 모델(특히, LEX 태스크)의 성능이 그렇지 않은 것보다 우수한 성능을 보일 수 있음을 확인함.

	Dev	Test Datasets				Concatenation of All Test Datasets				
	SE07	SE2	SE3	SE13	SE15	Nouns	Verbs	Adj.	Adv.	All
BLSTM	61.8	71.4	68.8	65.6	69.2	70.2	56.3	75.2	**84.4**	68.9
BLSTM + att.	62.4	71.4	**70.2**	66.4	70.8	71.0	**58.4**	75.2	83.5	69.7
BLSTM + att. + LEX	63.7	**72.0**	69.4	66.4	**72.4**	**71.6**	57.1	**75.6**	83.2	**69.9**
BLSTM + att. + LEX + POS	**64.8**	**72.0**	69.1	**66.9**	71.5	71.5	57.5	75.0	83.8	**69.9**
Seq2Seq	60.9	68.5	67.9	65.3	67.0	68.7	54.5	74.0	81.2	67.3
Seq2Seq + att.	62.9	69.9	69.6	65.6	67.7	69.5	57.2	74.5	81.8	68.4
Seq2Seq + att. + LEX	64.6	70.6	67.8	66.5	68.7	70.4	55.7	73.3	82.9	68.5
Seq2Seq + att. + LEX + POS	63.1	70.1	68.5	66.5	69.2	70.1	55.2	75.1	84.4	68.6
IMS	61.3	70.9	69.3	65.3	69.5	70.5	55.8	75.6	82.9	68.9
IMS+emb	**62.6**	**72.2**	**70.4**	65.9	71.5	**71.9**	56.6	**75.9**	**84.7**	**70.1**
Context2Vec	61.3	71.8	69.1	65.6	**71.9**	71.2	**57.4**	75.2	82.7	69.6
Lesk_{ext}+emb	⋆56.7	63.0	63.7	66.2	64.6	70.0	51.1	51.7	80.6	64.2
UKB_{gloss} w2w	42.9	63.5	55.4	⋆62.9	63.3	64.9	41.4	69.5	69.7	61.1
Babelfy	51.6	⋆67.0	63.5	**66.4**	70.3	68.9	50.7	73.2	79.8	66.4
MFS	54.5	65.6	⋆66.0	63.8	⋆67.1	67.7	49.8	73.1	80.5	65.5

[표 24] Neural Sequence Learning Model을 이용한 WSD 태스크의 성능 비교

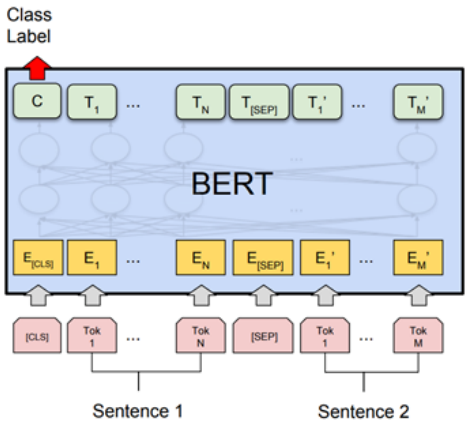
- 본 연구는 WSD 태스크를 위한 기존의 접근이 Classification의 문제였다면, 이를 Sequence Learning으로 접근하여 그 결과를 비교하고자 하는 목표가 있었음. 그 결과에서 최근 제시된 분류 방식보다 복잡도는 낮으나 유사한 성능을 보이는 것을 확인할 수 있었음.

○ GlossBERT 모델 연구

- 대용량 텍스트를 입력으로 트랜스포머의 인코더 부분을 활용한 사전학습 언어모델(Pre-trained Language Model)인 BERT는 기존의 다른 임베딩 모델보다 자연어의 문맥을 잘 이해함. BERT 모델을

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

그대로 활용하고 문맥문장과 워드넷의 Gloss를 함께 입력하여 이진 분류로 WSD를 해결하는 연구를 분석함.



[그림 46] BERT 모델을 활용한 GlossBERT 구조도

- 기본적인 접근으로 타깃 단어의 여러 가지 정의 문장을 페어로 입력함으로써, 문맥과 맞는 정의 문장을 맞추면서 GlossBERT는 학습됨. 또한 타깃 단어를 하이라이팅(따옴표 이용)하고, 정의 문장에 타깃 단어를 한번 더 입력하여 주는 Weak Supervision 방식을 추가로 적용함.

Sentence with four targets:
Your research stopped when a convenient assertion could be made.

Context-Gloss Pairs of the target word [research]	Label	Sense Key
[CLS] Your research ... [SEP] systematic investigation to ... [SEP]	Yes	research%1:04:00::
[CLS] Your research ... [SEP] a search for knowledge [SEP]	No	research%1:09:00::
[CLS] Your research ... [SEP] inquire into [SEP]	No	research%2:31:00::
[CLS] Your research ... [SEP] attempt to find out in a ... [SEP]	No	research%2:32:00::
Context-Gloss Pairs with weak supervision of the target word [research]	**Label**	**Sense Key**
[CLS] Your "research" ... [SEP] research: systematic investigation to ... [SEP]	Yes	research%1:04:00::
[CLS] Your "research" ... [SEP] research: a search for knowledge [SEP]	No	research%1:09:00::
[CLS] Your "research" ... [SEP] research: inquire into [SEP]	No	research%2:31:00::
[CLS] Your "research" ... [SEP] research: attempt to find out in a ... [SEP]	No	research%2:32:00::

[표 25] GlossBERT에 입력되는 문장 형식 (상단은 문맥 문장과 정의 문장 페어를 입력, 하단은 타깃 단어를 하이라이팅하고, 정의 문장에 한 번 더 입력하는 Weak Supervision 적용)

- BERT 모델은 [CLS] 토큰을 포함하는데, 이 토큰의 출력을 이용하여 학습하는 방식과 타깃 단어의 출력을 이용하여 학습하는 방식으로 구분하여 진행함.
- WSD 벤치마킹 데이터 셋을 활용한 학습과 실험에서 전체 평균 77.0%의 F1-Score를 기록하면서 Paperswithcode의 여러 WSD 태스크에서 SOTA를 달성함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

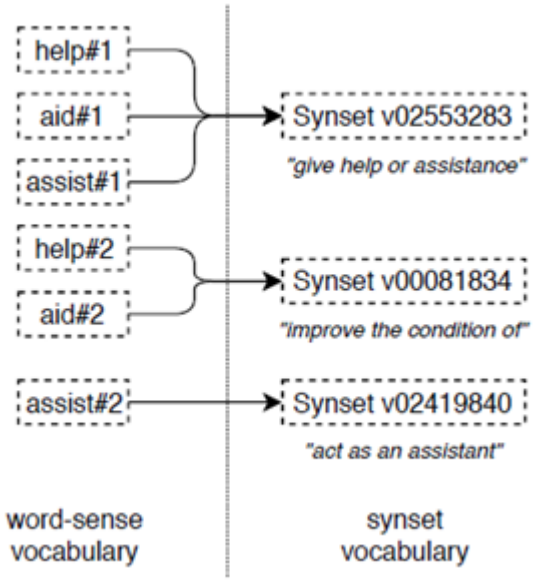
	Dev	Test Datasets				Concatenation of Test Datasets				
System	SE07	SE2	SE3	SE13	SE15	Noun	Verb	Adj	Adv	All
MFS baseline	54.5	65.6	66.0	63.8	67.1	67.7	49.8	73.1	80.5	65.5
$Lesk_{ext+emb}$	56.7	63.0	63.7	66.2	64.6	70.0	51.1	51.7	80.6	64.2
Babelfy	51.6	67.0	63.5	66.4	70.3	68.9	50.7	73.2	79.8	66.4
IMS	61.3	70.9	69.3	65.3	69.5	70.5	55.8	75.6	82.9	68.9
IMS_{+emb}	62.6	72.2	70.4	65.9	71.5	71.9	56.6	75.9	84.7	70.1
Bi-LSTM	-	71.1	68.4	64.8	68.3	69.5	55.9	76.2	82.4	68.4
$Bi\text{-}LSTM_{+att.+LEX+POS}$	64.8	72.0	69.1	66.9	71.5	71.5	57.5	75.0	83.8	69.9
GAS_{ext} (Linear)	-	72.4	70.1	67.1	72.1	71.9	58.1	76.4	84.7	70.4
GAS_{ext} (Concatenation)	-	72.2	70.5	67.2	72.6	72.2	57.7	76.6	85.0	70.6
CAN^a	-	72.2	70.2	69.1	72.2	73.5	56.5	76.6	80.3	70.9
HCAN	-	72.8	70.3	68.5	72.8	72.7	58.2	77.4	84.1	71.1
SemCor, hypernyms (single)	-	-	-	-	-	-	-	-	-	75.6
SemCor, hypernyms (ensemble)†	69.5	77.5	77.4	76.0	78.3	79.6	65.9	79.5	85.5	76.7
SemCor+WNGC, hypernyms (single)‡	-	-	-	-	-	-	-	-	-	77.1
SemCor+WNGC, hypernyms (ensemble)† ‡	73.4	79.7	77.8	78.7	82.6	81.4	68.7	83.7	85.5	79.0
BERT(Token-CLS)	61.1	69.7	69.4	65.8	69.5	70.5	57.1	71.6	83.5	68.6
GlossBERT(Sent-CLS)	69.2	76.5	73.4	75.1	79.5	78.3	64.8	77.6	83.8	75.8
GlossBERT(Token-CLS)	71.9	77.0	**75.4**	74.6	79.3	78.3	66.5	**78.6**	84.4	76.3
GlossBERT(Sent-CLS-WS)	**72.5**	**77.7**	75.2	**76.1**	**80.4**	**79.3**	**66.9**	78.2	**86.4**	**77.0**

[표 26] WSD 벤치마킹 데이터 셋을 활용한 성능 비교 결과

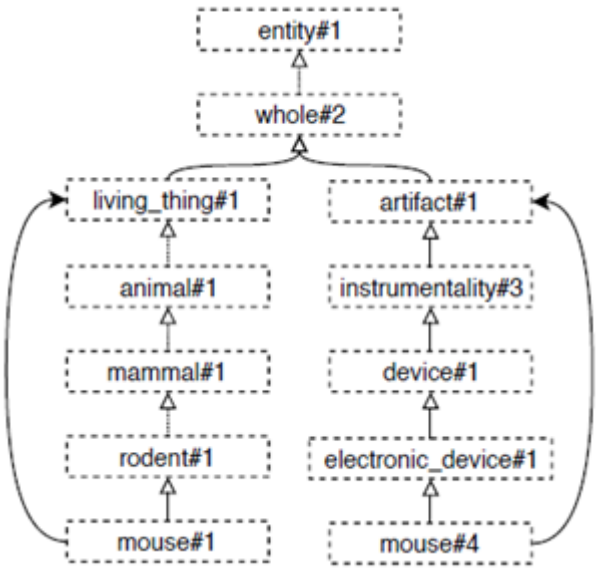
○ Sense Vocabulary Compression 기법 연구

- 워드넷에 정의된 어휘는 20만개가 넘기 때문에, WSD 태스크는 그 분류 복잡도가 다른 NLP 태스크, 특히 한정된 클래스로 분류하는 NER, RE 등 보다 높음. 이를 줄이기 위해 개념 레벨에서 압축을 시도하여 성능을 올리기 위한 연구를 수행함.
- 전체적으로 3단계 압축과정으로 진행됨. 1단계는 워드넷 센스(개념을 구분하기 위해 단어에 번호를 부여한 것)를 신셋(Synset, Synonym Set으로 동의어 셋을 의미)으로 압축하는 과정을 진행함. 예로, help#1, aid#1, assist#1은 '돕다'라는 동일한 의미를 갖는데, 워드넷에서는 이를 신셋 번호 'v02553283'으로 정의하고 있어 3개의 센스를 1개의 신셋으로 압축할 수 있는 효과가 있음. 또한 help#1이 사용된 문장은 aid#1, assist#1의 개념으로 바꿔 학습량을 높일 수 있다는 강점으로 활용될 수 있음. 1단계 신셋으로 압축하는 방식을 통해 전체 206,941개의 센스를 117,659개의 신셋으로 약 43%를 축소할 수 있음.
- 2단계 압축 방법은, WSD에 특화된 방식으로 워드넷의 상하위 관계를 활용해 압축함. WSD는 다의성이 있는 단어를 문맥에 맞는 개념으로 매칭하는 것으로, 모든 단어가 고유 개념을 가질 필요가 없다는 부분에서 고안됨. 예를 들어, mouse는 여러 가지 의미를 가질 수 있는데, 그 중 설치류와 전자 장치 영역에서의 정의가 있음. 개별적으로 상위 개념으로 올라가면, 'whole#2'에서 만날 수 있는데, 첫 번째 공통 상위 개념을 만나기 직전 개념으로 압축하는 방식이라 할 수 있음. 즉, 'mouse#1'은 'living_thing#1'로, 'mouse#4'는 'artifact#1'로 변경해 압축함. 이 방식으로 'mouse#1', 'rodent#1', 'mammal#1' 등 개념은 'living_thing#1'로 압축하여 압축된 하나의 타깃 개념을 이용해 다양한 문장을 이용한 학습이 가능함. 2단계 압축하는 방식으로 전체 206,941개의 센스를 39,147개의 센스로 약 81% 축소할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 47] 워드넷 센스를 신셋 번호로 압축하는 방법 개요도



[그림 48] 워드넷의 상하위 개념 관계를 이용한 압축 방식

- 3단계 압축 방법은 워드넷의 모든 관계를 이용한 방식이며, 11,885개 센스로 94%까지 압축할 수 있지만, WSD 성능의 개선에서 이득이 없음으로 확인됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Method	Vocabulary size	Compres-sion rate	SemCor Coverage
No compression	206 941	0%	16%
Synonyms	117 659	43%	22%
Hypernyms	39 147	81%	32%
All relations	11 885	94%	39%

[표 27] Sense Vocabulary Compression 방법을 통한 압축률

- Sense Vocabulary Compression에서 제시한 3가지 방법을 WSD 벤치마킹 데이터 셋에 적용하고, BERT Large 모델을 이용하여 학습한 결과 워드넷의 상하위 관계를 이용한 방식이 F1-Score 79.0%로 SOTA를 달성함.

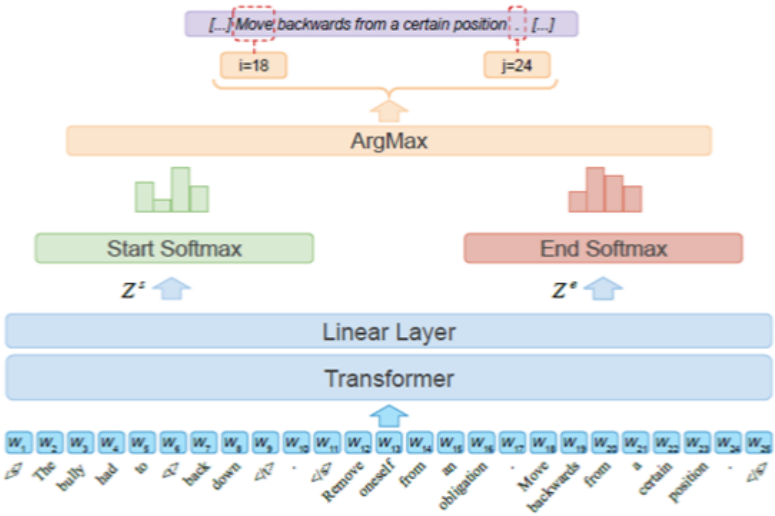
System	SE2	SE3	SE07 17	SE13	SE15	ALL (concat. of previous tasks) nouns	verbs	adj.	adv.	total	SE07 07
First sense baseline	65.6	66.0	54.5	63.8	67.1	67.7	49.8	73.1	80.5	65.5	78.9
HCAN (Luo et al., 2018a)	72.8	70.3	-	68.5	72.8	72.7	58.2	77.4	84.1	71.1	-
LSTMLP (Yuan et al., 2016)	73.8	71.8	63.5	69.5	72.6	†73.9	-	-	-	†71.5	83.6
SemCor, baseline	77.2	76.5	70.1	74.7	77.4	78.7	65.2	79.1	85.5	76.0	87.7
SemCor, hypernyms	77.5	77.4	69.5	76.0	78.3	79.6	65.9	79.5	85.5	76.7	87.6
SemCor, all relations	76.6	76.9	69.0	73.8	75.4	77.2	66.0	80.1	85.0	75.4	86.7
SemCor+WNGC, baseline	**79.7**	76.1	**74.1**	78.6	80.4	80.6	68.1	82.4	86.1	78.3	90.4
SemCor+WNGC, hypernyms	**79.7**	77.8	73.4	**78.7**	**82.6**	81.4	68.7	83.7	85.5	**79.0**	90.4
SemCor+WNGC, all relations	79.4	**78.1**	71.4	77.8	81.4	80.7	68.6	82.8	85.5	78.5	**90.6**

[표 28] Sense Vocabulary Compression 방법의 성능 비교

○ Extractive Sense Comprehension 기법 연구

- 입력된 문맥을 더 잘 이해하는 Span Prediction 기법에 대한 연구를 수행함. 기존의 분류 문제와 달리, 타깃 단어의 여러 가지 정의구문을 한 번에 입력하고, 문맥에 맞는 정의구문의 시작과 끝을 예측하는 방식으로, 트랜스포머를 활용하여 SOTA를 달성함.
- 트랜스포머의 입력으로 타깃 단어를 포함한 문맥 문장과 타깃 단어의 여러 가지 정의 문장을 한 번에 입력함으로써, 문맥에 어울리는 정의 문장의 Span을 예측함으로써 모델을 학습함. 기존의 센스를 예측하는 방식보다 문장 전체의 영향력을 파악 할 수 있다는 점에서 성능 개선을 유도함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 49] Extractive Sense Comprehension 방법 개요도

- 이 방식은 기존의 GlossBERT, SVC(Sense Vocabulary Compression) 등의 방법보다 우수한 성능을 보이며, 80.7%의 F1-Score를 달성함.

		Dev Set	Test Sets				Concatenation of all Datasets				
	Model	SE07	SE2	SE3	SE13	SE15	Nouns	Verbs	Adj.	Adv.	ALL
Baselines	MFS SemCor	54.5	65.6	66.0	63.8	67.1	67.7	49.8	73.1	80.5	65.5
	$BERT_{base}$	68.6	75.9	74.4	70.6	75.2	75.7	63.7	78.0	85.8	73.7
	$BART_{large}$	63.5	75.0	72.2	69.3	74.2	74.0	61.6	76.9	86.1	72.2
Prior work	EWISE‡	67.3	73.8	71.1	69.4	74.5	74.0	60.2	78.0	82.1	71.8
	GLU	68.1	75.5	73.6	71.1	76.2	—	—	—	—	74.1
	LMMS††	68.1	76.3	75.6	75.1	77.0	—	—	—	—	75.4
	SVC	—	—	—	—	—	—	—	—	—	75.6
	GlossBERT†	72.5	77.7	75.2	76.1	80.4	79.8	67.1	79.6	87.4	77.0
	ARES††	71.0	78.0	77.1	78.7	75.0	80.6	68.3	80.5	83.5	77.9
	EWISER‡	71.0	78.9	**78.4**	78.9	79.3	81.7	66.3	81.2	85.8	78.3
	BEM†	74.5	79.4	77.4	79.7	81.7	81.4	68.5	83.0	**87.9**	79.0
Ours	$ESCHER_{No\text{-}GN}$†	75.0	80.5	76.9	81.1	83.0	83.0	68.5	81.9	86.1	79.7
	ESCHER†	**76.3**	**81.7**	77.8	**82.2**	**83.2**	**83.9**	**69.3**	**83.8**	86.7	**80.7**

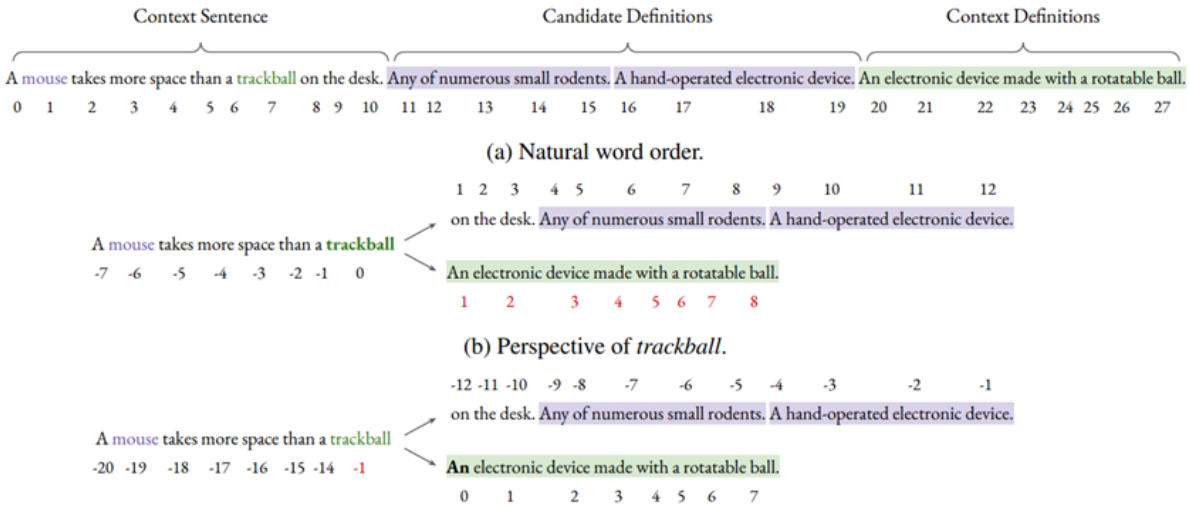
[표 29] Extractive Sense Comprehension 방법의 성능 비교

○ ConSec 기법 연구

- 2021년에 발표된 논문으로 WSD 분야에서 최고 F1 Score를 달성한 연구임.
- Microsoft에서 공개한 초대형 언어모델인 DeBERTa 모델을 활용하며, Feedback loop strategy를 제안하여 성능을 개선함. (Feedback loop strategy : 단의어(또는 중의성이 낮은 어휘)를 먼저 결정하고, 결정된 의미를 점진적으로 문맥에 추가하여 WSD를 수행하는 방식임)
- DeBERTa 모델은 절대적인 위치 정보를 입력 벡터로 활용하는 기본 BERT 모델에 상대적인 위치 정보를 추가로 입력 벡터로 활용하는 방식으로, WSD를 위해 주어진 문맥정보, 타겟 어휘의 정의 구문들,

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

그리고 이미 결정된 정의구문 순서로 입력하여 타겟 어휘를 중심으로 상대적인 위치 정보를 계산하여 입력함.



[그림 50] DeBERTa 모델을 활용한 ConSec의 상대적 위치 추가 방식

- Feedback loop strategy를 위해 이미 결정된 타겟 어휘의 의미를 활용하여 상관성이 높은 다음 타겟 어휘를 결정하기 위한 전략을 추가함. 이를 위해 위키피디아에서 10만 개의 문서를 선택하고 Positive Nmalized Pointwise Mutual Information 기법을 통해 단어들의 상관성을 미리 계산함. 이를 활용하여 다음 WSD 타겟 어휘를 결정함으로써 타겟의 의미 식별 정확도를 높이는 방식임.

		Dev Set	Test Sets				Concatenation of all Datasets				
	Model	SE07	SE2	SE3	SE13	SE15	Nouns	Verbs	Adj.	Adv.	ALL
SemCor	MFS - SemCor	54.5	65.6	66.0	63.8	67.1	67.7	49.8	73.1	80.5	65.5
	BERT$_{base}$	68.6	75.9	74.4	70.6	75.2	75.7	63.7	78.0	85.8	73.7
	SVC	-	-	-	-	-	-	-	-	-	75.6
	SVC - *Ensemble*	69.5	77.5	77.4	76.0	78.3	79.6	65.9	79.5	85.5	76.7
	GlossBERT	72.5	77.7	75.2	76.1	80.4	79.8	67.1	79.6	87.4	77.0
	ARES	71.0	78.0	77.1	78.7	75.0	80.6	68.3	80.5	83.5	77.9
	EWISER	71.0	78.9	78.4	78.9	79.3	81.7	66.3	81.2	85.8	78.3
	WMLC	72.2	78.4	77.8	76.7	78.2	80.1	67.0	80.5	86.2	77.6
	BEM	74.5	79.4	77.4	79.7	81.7	81.4	68.5	83.0	**87.9**	79.0
	ESCHER	76.3	81.7	77.8	82.2	83.2	83.9	69.3	83.8	86.7	80.7
	ConSeC	**77.4**	**82.3**	**79.9**	**83.2**	**85.2**	**85.4**	**70.8**	**84.0**	87.3	**82.0**
+ WNGE	SVC	-	-	-	-	-	-	-	-	-	77.1
	SVC - *Ensemble*	73.4	79.7	77.8	78.7	82.6	81.4	68.7	83.7	85.5	79.0
	EWISER	75.2	80.8	79.0	80.7	81.8	82.9	69.4	83.6	87.3	80.1
	WMLC	76.2	80.4	77.8	81.8	83.3	82.9	70.3	83.4	85.5	80.2
	ESCHER	77.6	82.5	78.5	82.7	85.1	84.6	71.5	83.7	86.7	81.6
	ConSeC	**78.5**	**82.7**	**81.0**	**85.2**	**87.5**	**86.4**	**72.4**	**85.4**	**89.0**	**83.2**

[그림 51] ConSec의 성능 평가 결과(최고 성능 달성)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ Pretrained Language Model(PLM) 기반의 WSD 태스크 정리
- Paperswithcode의 WSD 태스크를 중심으로 BERT 발표 이후에 제안된 PLM 기반의 WSD 모델들을 총정리하고 그들의 핵심 아이디어를 요약함.

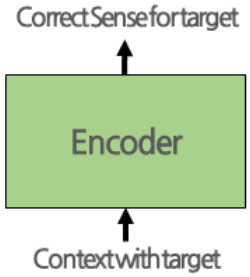
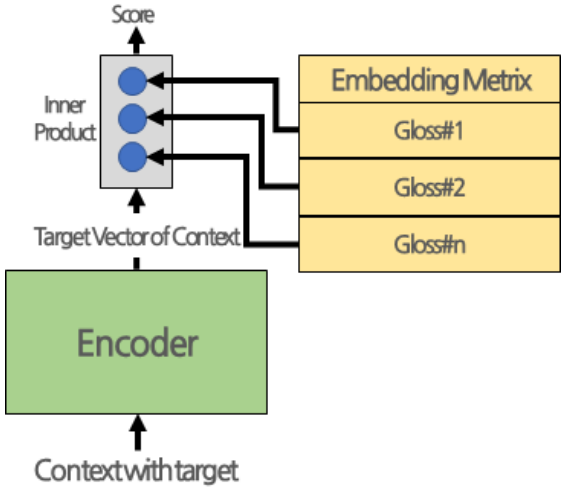
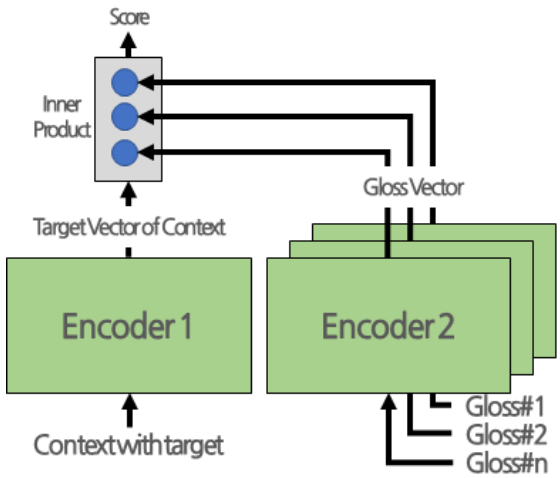
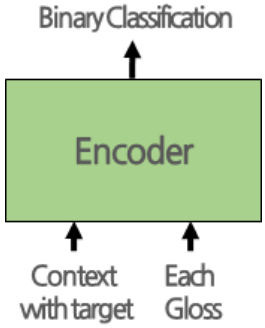
Model	Based PLM	Additional Data	Key Idea
CSI	BERT	-	Coarse Sense Inventory, Roget's the saurus, three expert linguists do re-cluster and label, experts map synset and csi label
ConSeC	DeBERTa	WNGE, Gloss	Extended version of ESCHER, Feedback loop strategy that assign sense for previous target Modified relative positional embedding of DeBERTa, Disambiguation order using PNPM with WIKI
SACE	RoBERTa	Gloss	Extended version of BEM, Interactive and iterative sense embedding, Use surrounding sentence for context embedding, Globally related sentence for context embedding using TF-IDF, Try-again Mechanism (TAM) with Coarse Sense Inventory in inference time
ESR	RoBERTa	WNGC, Wordnet	Sense representation embellishment with all lemmas, wordnet example, and hypernym gloss, of the synset
SemEq	Sentence BERT RoBERTa	6 Dictionaries	Get sentence embedding of 6 dictionaries with pretrained SentenceBERT, Gloss alignment algorithm with 6 dictionaries, Contrastive learning using P-SBERT with pair of context and gloss of 6 dictionaries, Transfer learning for semcor dataset to BEM, but objective function is similar with SentenceBERT
ESCHER	BART*	WNGC	Add gloss Noise for mitigating the bias of MFS into each training data, k frequent definitions that are not related to the target word
WMLC	BERT	WNGC, Wordnet, examples	Swish, Multi label classification with BCE Loss on the BERT, Knolwedge integration with related sense using wordnet

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

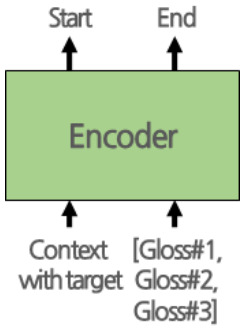
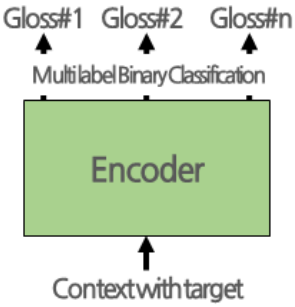
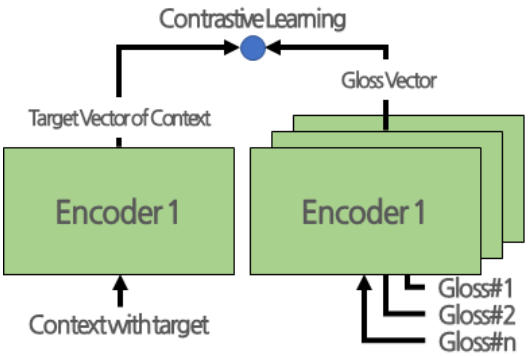
Model	Based PLM	Additional Data	Key Idea
SREF (TAM)	BERT	Gloss, WordNet	Gloss augmentation with gloss, examples, and retrieved sentences on web, Sense embedding enhancement summing with all directly connected sense, Try-again mechanism (TAM) after 1st WSD for top 2 sense (some time using super sense)
EWISER	BERT	WNGC, WordNet. Gloss	Swish, Adjacency matrix (hyper) of a sense and all sense with above result to calculate final score of all sense, Chain-thaw,
SensEm BERT	BERT	BableNet. Wikipedia. Gloss	Retrieve knowledge from bablenet and Wikipedia for sense embedding with NASARI lexical vectors, Only Noun
SemCor	BERT	WNGC	Sense Vocabulary Compression using Synsets, or using Hypernymy, or using all relationships
SparseLMMS	BERT (No train)	WNGC, Synset	BERT Sparse Contextualized Word Representations
BEM	BERT	Gloss	Bi-Encoder
ARES	BERT (No train)	SyntagNet, Gloss	Extended version of CluBERT, BERT representation of the sentences and sense, K-means clustering and PPR
CluBERT	BERT (No train)	BabelNet	BERT representation of the sentences and sense, K-means clustering, Personalized Page Range algorithm (PPR) (UKB)
GlossBERT	BERT	Gloss	Context-Gloss Pair, Weak supervision (WS), Binary classification
LMMS	BERT (No train)	WordNet(synset, sense, lemma, relation, lexname, gloss), WNGC	Synset embedding, hypernym embedding, lexname embedding, gloss embedding, fastText
BERTglu	BERT	앞뒤 문장 wordnet(Pos Lemma)	Linear Projection of Hidden Layers (Simple), Weighted Sum of Hidden Layers (LW), Gated Linear Unit (GLU)
EWISE	Bi-LSTM	Gloss, Wordnet	Bi-encoder(BILSTM), ConvE with wordnet relation, Bert도 실험했지만 ConvE 보다 안좋았음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 각 모델들이 활용한 PLM 아키텍처를 정리하여 7가지의 모델로 정리함.

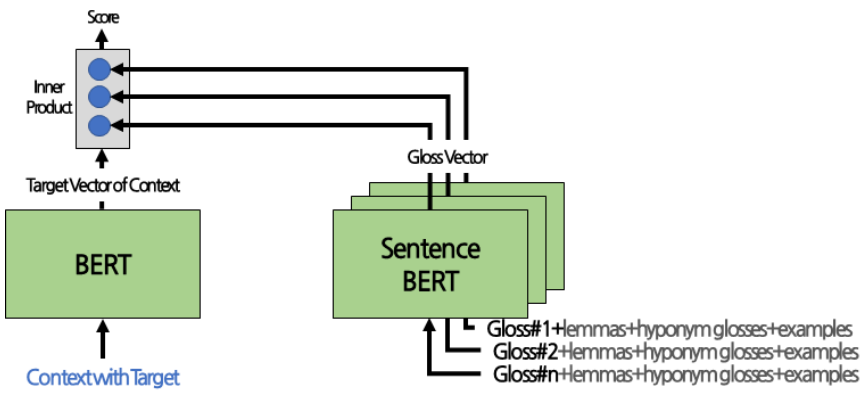
유형	모델 구조도
Predict Sense Directly	
Inner Product	
Bi-Encoder	
Binary Classification	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

유형	모델 구조도
Span Prediction	
Multi-label Binary Classification	
Contrastive Learning	

○ 기존에 제안된 모델 중심으로 하이브리드 형 모델 제안

- 두 개의 서로 다른 언어모델 인코더를 활용하는 BEM의 아키텍처를 기본으로, 문맥 정보를 풍부하게 만들기 위해 WordNet의 Lemma, 정의 예제, 상위어의 정의구문 등을 추가로 활용한 구조 제안.



[그림 52] BEM과 ESR을 동시에 활용한 하이브리드 모형

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 가능성을 검증하기 위해 진행한 SenseVal-2007 벤치마킹 데이터 셋 기반의 토이 테스트에서 하이브리드 모형이 가장 우수함을 확인함.

모델 성능 및 비교 (하이브리드 모델의 성능이 가장 우수함을 확인)

Model	Learning Rate	Best Epc	Best F1
BEM	1.00E-05		72.7/72.5
	5.00E-05		73.4
	1.00E-06		74.5
BEM (1target)	1e-06 (bsz 12)	17	74.5
BEM (1target+DataLoader)	5e-05 (bsz 12)	2	69
	1e-05 (bsz 12)	16	73.6
	5e-06 (bsz 12)	10	74.5
	1e-06 (bsz 12)	14	74.3
	5e-07 (bsz 12)	16	74.1
	1e-07 (bsz 12)	16	70.1
+s_bert	1e-05 (bsz 12)	10	72.5
	5e-06 (bsz 12)	18	73
	1e-06 (bsz 12)	11	71.4
	5e-07 (bsz 12)	18	71.2
	1e-07 (bsz 12)	20	63.3
+ Retrieved From TC	1e-05 (bsz 12)	2	71.9
+Retrieved From TC To tr and te	5e-05 (bsz 12)	1	64.8
	1e-05 (bsz 12)	1	65.5
BEM(1target+ DataLoader) + ESR	5e-06 (bsz 12)	3	73.4
	1e-06 (bsz 12)	8	75.8
+SVC	5e-05 (bsz 12)	20	66.2
	1e-05 (bsz 12)	20	73.4
	5e-06 (bsz 12)	12	72.1
	1e-06 (bsz 12)	10	70.8

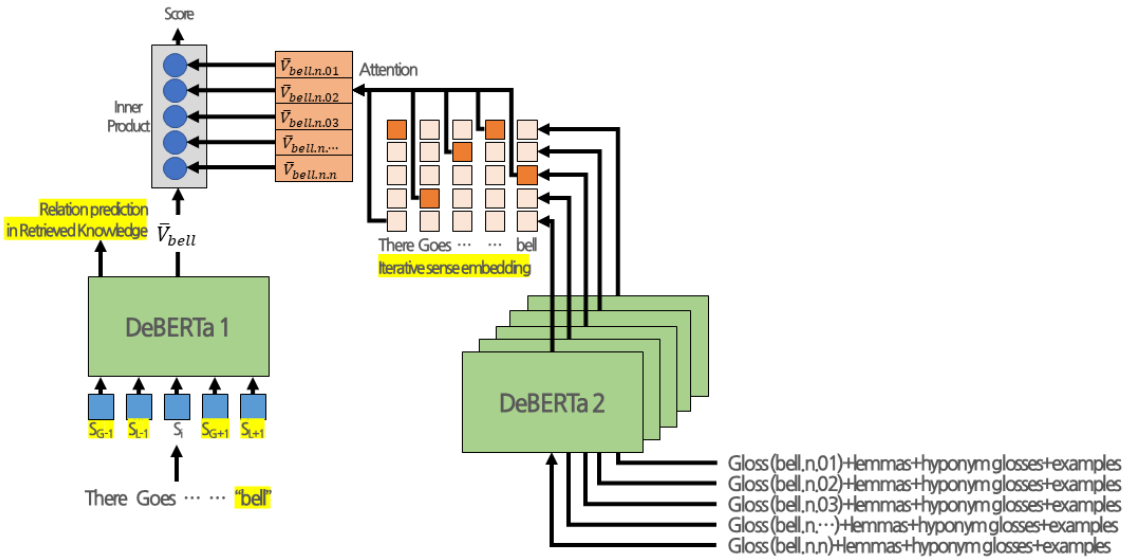
○ SOTA 달성을 위한 최적의 하이브리드 모형 제안 및 실험 진행

- SACE 아키텍처를 기본으로 활용 : RoBERTa 모델 활용, Bi-Encoder 유형, Knowledge(Wikipedia)를 활용한 Microsoft의 DeBERTa 모델을 활용하고, Feedback loop strategy를 채용
- ESR 방식 활용 : 타겟 어휘의 후보 정의 구문을 풍부하게 하기 위해

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

WordNet의 Lemma, 정의 구문 예제, 상위어의 정의구문 등을 추가로 활용

- DeBERTa 모델 채용 : Microsoft에서 공개한 PLM 모델로 GLUE 기준 세계 3위하는 모델 활용
- 2022년 10월 25일 기준 실험을 WSD 벤치마킹 데이터셋 5종을 활용하여 실험 진행 중임.



[그림 53] SACE 아키텍처+DeBERTa, ESR 방식의 후보 문장 증강을 활용한 하이브리드 모형

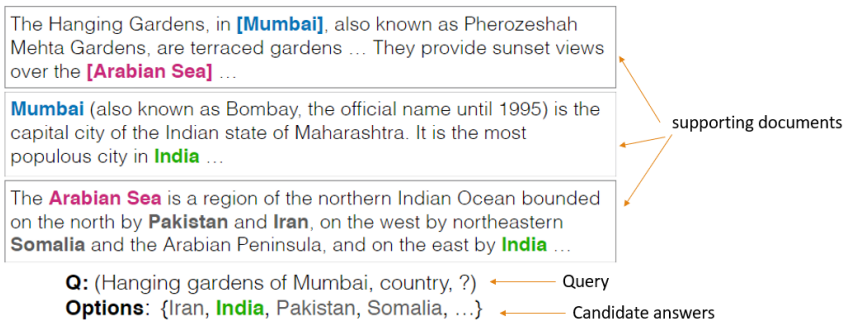
(3) 인공지능 기술의 중장기 발전 계획 수립

□ Multi-Hop Q&A 기술 동향 조사

○ 멀티홉 질의응답시스템을 위한 데이터 셋

- 질의응답시스템의 평가를 위한 데이터 셋은 많이 존재하나, 대부분 하나의 문서에서 답을 찾을 수 있거나, 특정 주제로 제한되는 등 진정한 멀티홉 질의응답시스템을 위한 데이터 셋은 다음 2가지 정도임.
- QAngaroo는 도메인 제한없는 위키피디아를 기반으로 5만 개 이상의 질문, 답변 및 문단으로 구성된 WikiHop과 의약학 데이터베이스인 MEDLINE을 기반으로 2천 5백 개 이상의 질문, 답변 및 문단으로 구성된 MedHop으로 이루어져있음.
- 질문은 주제 엔티티와 관계 및 답변으로 나와야 할 엔티티 트리플로 제시되며, 답변은 정답을 포함한 여러 개의 보기로 주어짐.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 54] QAngaroo의 질문/답변 예시

WikiHop

#	Model / Reference	Affiliation	Date	Accuracy[%]
1	RealFormer-large (single)	[anonymized]	January 2021	84.4
2	ETC-large (single)	[anonymized]	May 2020	82.3
3	Longformer (single)	AI2	March 2020	81.9
4	Path-based GCN (ensemble)	Zhejiang University (ZJU)	September 2019	78.3
5	Chen et al. (2019)	UT Austin	September 2019	76.5
6	ChainEx (single)	[anonymized]	May 2019	74.9
7	JDReader (ensemble)	JD AI Research	March 2019	74.3
8	DynSAN (ensemble)	Samsung Research (SRC-B)	March 2019	73.8
9	CEG (single)	Beijing University of Posts and Telecommunications	December 2019	73.6
10	[anonymized]	[anonymized]	October 2020	73.1

MedHop

#	Model / Reference	Affiliation	Date	Accuracy [%]
1	MedKGQA	[anonymized]	November 2020	64.8
2	EPAr	UNC-NLP	February 2019	60.3
3	Most Frequent Given Candidate	Initial Benchmarks	September 2017	58.4
4	Vanilla CoAttention Model	Nanyang Technological University	December 2017	58.1
5	BiDAF (Seo et al. '17)	Initial Benchmarks	September 2017	47.8
6	ClueReader v1	Qufu Normal University	September 2020	46.0
7	Document-cue	Initial Benchmarks	September 2017	44.9
8	FastQA (Weissenborn et al. '17)	Initial Benchmarks	September 2017	23.1
9	Random Candidate	Initial Benchmarks	September 2017	13.9
10	TF-IDF	Initial Benchmarks	September 2017	9.0

[그림 55] QAngaroo 리더보드 (2021년 12월)

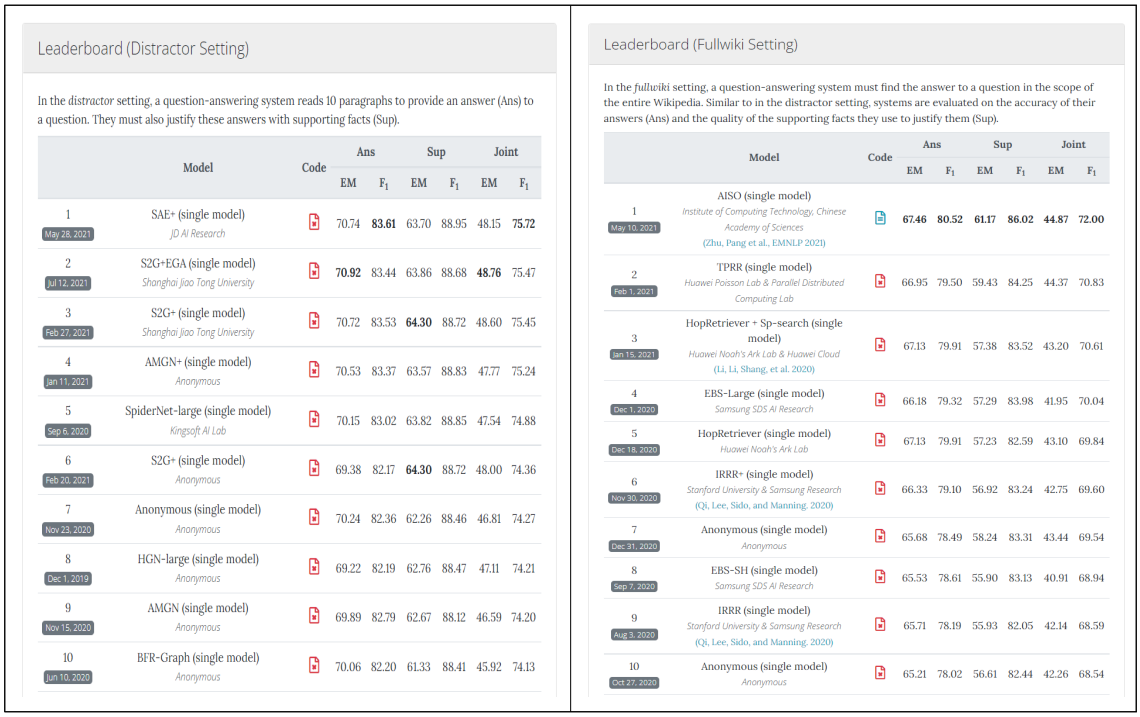
- 기본 데이터베이스뿐 아니라 WikiData와 Drugbank의 속성 정보를 이용해 엔티티들을 따라가기 위한 관계를 추출해 데이터셋을 구축하여 신뢰성을 높였음.
- QAngaroo를 사용한 멀티홉 질의응답시스템들의 성능 비교를 위해 리더보드를 제공함 (https://qangaroo.cs.ucl.ac.uk/).

- HotpotQA는 위키피디아 문서를 기반으로 11만 3천 개의 질문, 답변, 근거 문장들로 구성된 데이터 셋임.
- 다른 데이터 셋들과는 다르게 문장 단위로 근거를 제시하도록 되어있으며, 여러 가지 질의응답시스템을 통해 데이터 셋을 구축하였기 때문에 기존 지식데이터베이스의 제약 없이 대규모 데이터 셋을 구축하였음.
- 엔티티 답변 이외에 긍/부정이나 크고 작은지를 묻는 비교 질문도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

포함되어있다는 것이 차별됨.

- 질의응답시스템이 정확히 근거문장을 추출하는지를 보기 위하여 관련 없는 문장들을 섞어놓은 distractor와 전체 위키피디아 문서에서 근거문장들을 추출하여야 하는 fullwiki로2가지 세팅이 있음 (https://hotpotqa.github.io/).



Leaderboard (Distractor Setting)

In the *distractor* setting, a question-answering system reads 10 paragraphs to provide an answer (Ans) to a question. They must also justify these answers with supporting facts (Sup).

	Model	Code	Ans		Sup		Joint	
			EM	F_1	EM	F_1	EM	F_1
1 May 28, 2021	SAE+ (single model) *JD AI Research*		70.74	**83.61**	63.70	88.95	48.15	**75.72**
2 Jul 12, 2021	S2G+EGA (single model) *Shanghai Jiao Tong University*		**70.92**	83.44	63.86	88.68	**48.76**	75.47
3 Feb 27, 2021	S2G+ (single model) *Shanghai Jiao Tong University*		70.72	83.53	**64.30**	88.72	48.60	75.45
4 Jan 11, 2021	AMGN+ (single model) *Anonymous*		70.53	83.37	63.57	88.83	47.77	75.24
5 Sep 6, 2020	SpiderNet-large (single model) *Kingsoft AI Lab*		70.15	83.02	63.82	88.85	47.54	74.88
6 Feb 20, 2021	S2G+ (single model) *Anonymous*		69.38	82.17	**64.30**	88.72	48.00	74.36
7 Nov 23, 2020	Anonymous (single model) *Anonymous*		70.24	82.36	62.26	88.46	46.81	74.27
8 Dec 1, 2019	HGN-large (single model) *Anonymous*		69.22	82.19	62.76	88.47	47.11	74.21
9 Nov 15, 2020	AMGN (single model) *Anonymous*		69.89	82.79	62.67	88.12	46.59	74.20
10 Jun 10, 2020	BFR-Graph (single model) *Anonymous*		70.06	82.20	61.33	88.41	45.92	74.13

Leaderboard (Fullwiki Setting)

In the *fullwiki* setting, a question-answering system must find the answer to a question in the scope of the entire Wikipedia. Similar to in the distractor setting, systems are evaluated on the accuracy of their answers (Ans) and the quality of the supporting facts they use to justify them (Sup).

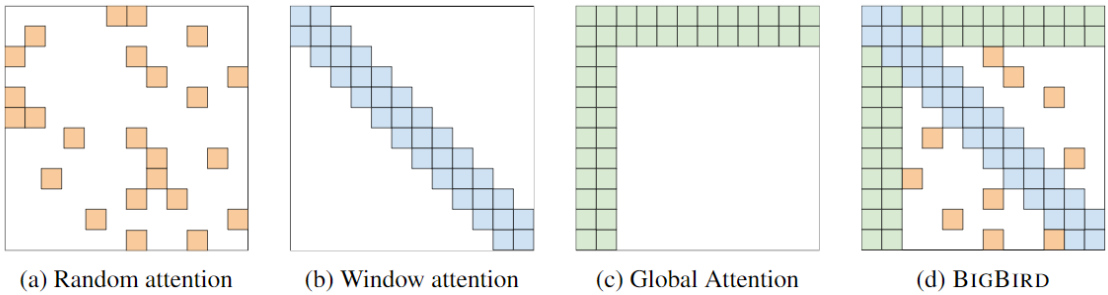
	Model	Code	Ans		Sup		Joint	
			EM	F_1	EM	F_1	EM	F_1
1 May 10, 2021	AISO (single model) *Institute of Computing Technology, Chinese Academy of Sciences* (Zhu, Pang et al., EMNLP 2021)		**67.46**	**80.52**	**61.17**	**86.02**	**44.87**	**72.00**
2 Feb 1, 2021	TPRR (single model) *Huawei Poisson Lab & Parallel Distributed Computing Lab*		66.95	79.50	59.43	84.25	44.37	70.83
3 Jan 15, 2021	HopRetriever + Sp-search (single model) *Huawei Noah's Ark Lab & Huawei Cloud* (Li, Li, Shang, et al. 2020)		67.13	79.91	57.38	83.52	43.20	70.61
4 Dec 1, 2020	EBS-Large (single model) *Samsung SDS AI Research*		66.18	79.32	57.29	83.98	41.95	70.04
5 Dec 18, 2020	HopRetriever (single model) *Huawei Noah's Ark Lab*		67.13	79.91	57.23	82.59	43.10	69.84
6 Nov 30, 2020	IRRR+ (single model) *Stanford University & Samsung Research* (Qi, Lee, Sido, and Manning. 2020)		66.33	79.10	56.92	83.24	42.75	69.60
7 Dec 31, 2020	Anonymous (single model) *Anonymous*		65.68	78.49	58.24	83.31	43.44	69.54
8 Sep 7, 2020	EBS-SH (single model) *Samsung SDS AI Research*		65.53	78.61	55.90	83.13	40.91	68.94
9 Aug 3, 2020	IRRR (single model) *Stanford University & Samsung Research* (Qi, Lee, Sido, and Manning. 2020)		65.71	78.19	55.93	82.05	42.14	68.59
10 Oct 27, 2020	Anonymous (single model) *Anonymous*		65.21	78.02	56.61	82.44	42.26	68.54

[그림 56] HotpotQA 리더보드 (2021년 12월)

○ Multi-Hop QA 구현 모델 및 기술 동향 조사

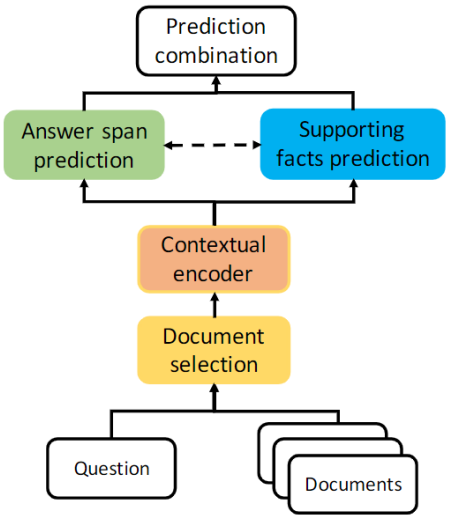
- HotpotQA 및 QAngaroo의 리더보드에서 상위 랭킹된 모델들 중 논문으로 출판된 모델 및 기술들 조사 수행
  가. 여러 문서를 입력으로 하는 문제의 특성상 트랜스포머 기반 모델의 한계인 매우 많은 어텐션의 계산량을 희소 어텐션을 이용하여 해결하려는 모델들이 제안됨(Longformer, BigBird 등)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 57] BigBird의 어텐션 메카니즘

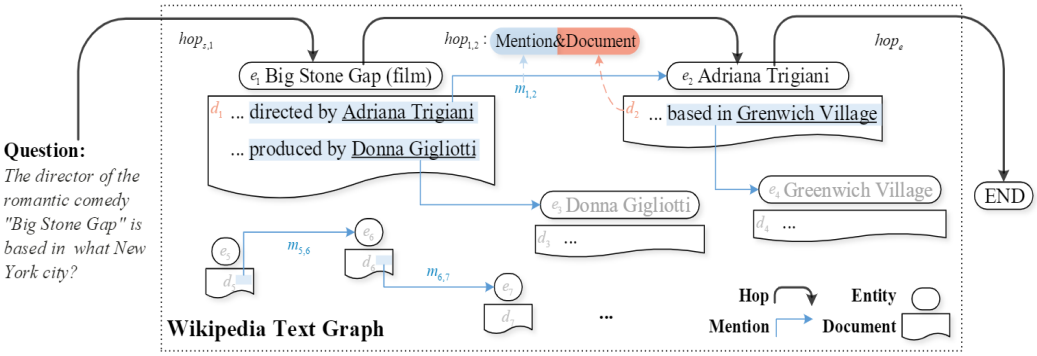
나. 어텐션만을 사용하는 모델들은 HotpotQA 데이터 셋과 같이 근거문장을 찾아야 하는 응용에는 적용하기가 어렵기때문에, 어텐션은 후보 문서 및 후보 근거문장을 찾는 곳에 사용하고, 그래프 신경망과 피드포워드 네트워크를 이용해 정답 부분과 근거문장을 동시에 훈련하는 방법이 제안됨(SAE 등)



[그림 58] SAE 시스템 구조

다. 인간의 추론방식을 모사하여, 문서들의 연결 부분과 문서 전체를 임베딩한 후 RNN을 사용하여 문서들을 연속적으로 찾아가거나, 질문 엔티티와 답변 후보를 인지그래프로 만들어 연속적으로 추론하는 방식도 제안됨(HopRetriever, CogQA 등)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 59] HopRetriever의 추론과정

라. Multi-Hop 질문을 단일 질문으로 나누어 후보 답변을 찾아낸 후, 통합하여 Multi-Hop의 답변으로 채택하는 방법 (DecompRC 등)

- 어텐션 기반 모델은 어텐션의 계산량을 줄이는 것이 핵심이므로, 여러가지 모델 경량화 기법의 적용 연구를 추진해 볼만함

- 하지만 추론 대상이 되는 다중문서가 많은 경우, 경량화를 해도 어텐션 모델로는 한계가 있으므로, 어텐션을 통해 후보 문서를 필터링한 후 인간의 추론 과정을 모사하는 방법을 적용하는 것이 적합하다고 판단됨

- 텍스트 뿐만 아니라 표, 그림 등의 다른 형태를 가진 데이터가 공존하는 과학기술문헌 특성상 다형 데이터(Multi-Modal)의 학습 방법 연구가 필요 (DataOn에서 제공되고 있는 국내 과학기술문헌에 삽입된 표/그림만 5백6십만 건 이상)

○ Multi-Modal 개요 및 이슈 조사

- Multi-Modal 학습은 다양한 형태(Modality)의 데이터를 사용하여 학습 및 추론하는 것으로 Modality는 자연어, 이미지나 비디오 등의 시각적 데이터, 음성, 소리 등의 오디도 데이터, 촉각, 후각 , 전자기파 등 종류가 매우 다양하며, 응용 가능한 범위도 매우 넓음
- 주로 많이 사용되는 응용으로는 감정 인지, 미디어 설명, 이벤트 탐지, 멀티미디어 정보 검색 등이며, KISTI가 수행하고 있는 정보서비스를 고려할때, 이미지, 비디오 설명, 시각적 질의응답, 컨텐트 기반 혹은 크로스 미디어 기반 멀티미디어 정보 검색 등을 하려면 Multi-Modal 학습 기술이 적용되어야 함
- Multi-Modal 학습의 주된 연구 분야를 분류하면 다음과 같음

가. Representation : 다양한 형태의 데이터를 모델내에서 공통된 형식으로 표현하는 연구

나. Alignment : 같은 객체, 같은 시간을 표현하는 다른 Modality를

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

동기화하는 연구

다. Translation : Modality의 형태를 변환하는 연구

라. Fusion : 여러 Modality를 하나로 합치는 연구

마. Co-Learning : 모델의 목표 성능을 달성 위해 여러 Modality를 같이 학습시키는 연구

- Multi-Modal Learning에서의 최근 주요 이슈는 다음과 같음

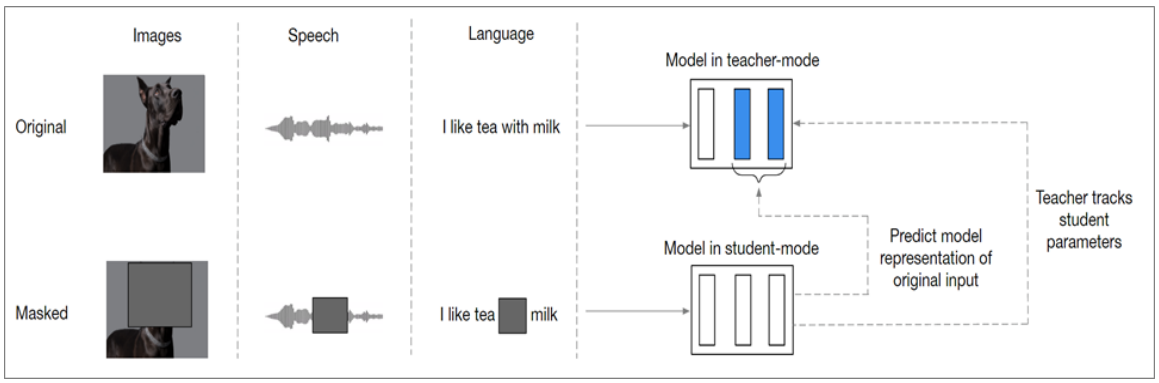
가. 표현 형식이 서로 달라서 다른 Modality끼리 단순 연산이 불가능하며 문제 혹은 Modality마다 별도의 연산 방법이 필요함

나. 일반적으로 Modality별로 데이터 양의 차이가 커서 원활한 학습이 이루어지지 않음

다. Co-learning 시 모델이 하나의 Modality에 의존하는 현상이 발생함

○ Multi-Modal 학습 방법에서의 최신 기술 조사

- Multi-Modal 학습 분야에서도 텍스트 분야와 마찬가지로 Self-Supervised Learning을 통한 사전학습 연구가 주로 이루어지고 있음
- 하지만 사전학습을 위한 데이터 전처리가 Modality마다 다르게 수행되며, 모델 예측값의 손실 계산도 Modality마다 별도로 한다는 문제가 있음
- 모델 내에서의 Representation을 Contrastive Learning방법을 이용하여 Multi-Modal 데이터도 하나의 통일된 방식으로 학습하는 연구가 여럿 진행됨 (Data2Vec 등)



[그림 60] Data2Vec의 Multi-Modal 통합 학습 방식

- 여전히 Masking 방식 등은 통일되지 않아 별도의 전처리가 필요하므로 이에 대한 연구를 추진해 볼만함

○ Multi-Modal 학습 응용 분야에서의 최신 기술 조사

- 이미지 혹은 비디오 등의 Vision 데이터와 텍스트 데이터 2가지만

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

사용하는 연구는 Multi-Modal 분야에서도 가장 많고 활발히 연구되고 있는 응용임. 세분화된 응용은 다음과 같은 것들이 있음

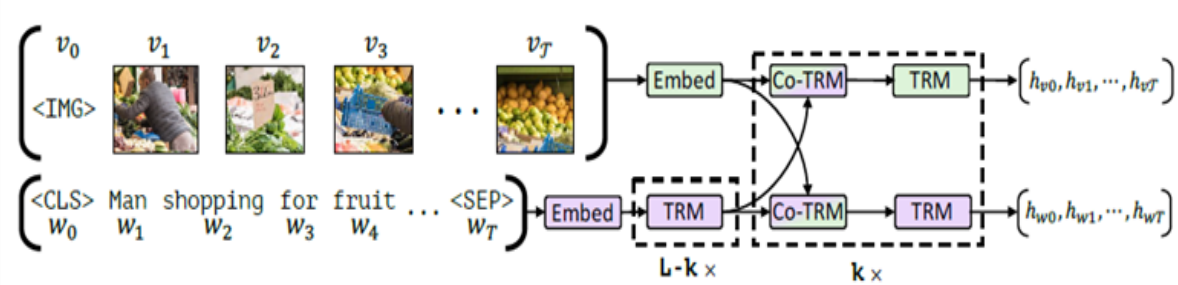
가. VQA (Vision Question Answering) : 텍스트 질의와 참조 이미지가 주어지고 질문에 대한 텍스트 답변을 하는 응용 분야

나. VCR (Vision Commonsense Reasoning) : 텍스트 질의와 참조 비디오가 주어지고 질문에 대한 선택형 답변을 고르되, 답변 선택의 이유도 선택하는 응용 분야

다. Referring Expression : 텍스트 설명을 기반으로 이미지에서 해당되는 부분을 지칭하거나 여러 이미지에서 해당하는 이미지만을 선택하는 응용 분야

라. Phrase Grounding : 이미지에서 원하는 부분만을 제한하면, 문장 내에서 해당되는 부분 혹은 단어를 추출하는 응용 분야

- NLP에서 사용되는 트랜스포머 기반 모델들이 Visual 분야에서도 널리 사용되는 추세에 따라 이 분야에서도 많이 사용되고 있음
- Text 처리를 위한 트랜스포머와 Vision 데이터 처리를 위한 트랜스포머를 별도로 학습시켜 사용하거나, 중간 레이어에서 어텐션 값을 교환하는 트랜스포머 변형 방법등이 제안되고 있음 (VLBert, VilBert 등)



[그림 61] VilBert의 변형 트랜스포머 사용 모델 구조

- KISTI는 많은 텍스트 데이터를 보유하고 있으며, 트랜스포머 기반 자연어 처리 모델 개발 등의 경험이 있으므로, Vision + 텍스트 데이터 처리 연구에 강점을 가지고 있다고 판단되며, 단기적으로 현재 텍스트 기반 서비스에서 이미지 데이터만 추가되는 VQA, Referring Expression 응용 연구를 수행하고, 중장기적으로 비디오 데이터 혹은 이미지 기반 질의 서비스가 추가되는 VCR, Phrase Grounding 응용 연구로 확장하는 것이 적합하다고 판단됨

□ 학습데이터 구축 및 확산을 위한 호주의 데이터 공유 동향 조사

○ 호주 데이터 공유 동향 조사 필요성

- 현재 인공지능 모델은 거대화 모델 연구가 주류를 이루고 있으며, 매우

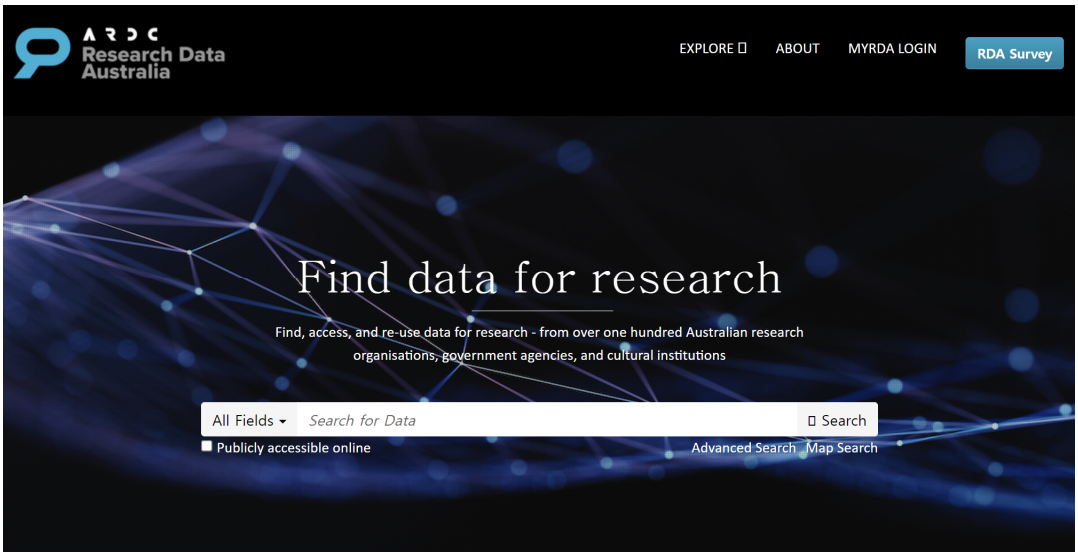
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

많은 학습 데이터가 필요함

- 대용량 학습 데이터 셋을 구축하기 위해 여러 연구팀/기관/국가 등의 개별적으로 구축한 데이터셋들을 공유하고 병합할 필요가 증가하고 있음
- 유럽, 호주 등의 국가는 20여년 전부터 데이터 자원의 중요성을 인식하고 데이터 공유 정책, 기술 개발 등을 수행해오고 있어, 데이터 공유 선진 국가의 정책 및 기술 동향을 조사함

○ 호주의 연구데이터 공유 정책 및 기술 현황

- 2004년 연구인프라 구축계획 NCRIS를 통해 데이터 공유 정책, 인프라 구축을 시작함
- 호주 연구위원회 ARC의 관리하에 여러 프로젝트가 진행되어오다가, 2019년 ARDC라는 전담 기관 설립 및 단일 프로젝트로 통합됨
- 다음과 같은 5가지 실행 전략으로 운영
  - 가. Storage and Compute : 데이터 저장소 및 분석 컴퓨팅 인프라 제공
  - 나. Software and Platforms : 협업을 위한 플랫폼과 도구 개발 지원
  - 다. Data and Services : 데이터 및 서비스 표준 및 프레임워크 개발
  - 라. People and Policy : 협업을 위한 커뮤니티 구성, 문화, 인센티브 제도 개발 및 지원
  - 마. Coordination and Coherence : 이해관계자들 협력을 위한 정부의 노력



[그림 62] 호주의 데이터 공유 검색 서비스 (Research Data Australia)

- 데이터 구축은 장기간에 걸쳐 중요 데이터 식별, 공유 가능 데이터 식별, 데이터 관리 인프라 구축, 공유 인프라 구축, 공유 데이터 확대 등을 점진적으로 시행함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 정부는 정책, 제도를 강제적으로 수행하기보다는 자발적 협력이 이루어지도록, 데이터 공유 문화 확산, 표준화 및 준수 노력 등 코디네이터로의 역할을 수행하는데 많은 노력을 기울임
- 우리나라의 과학기술 협업 현실을 고려할 때, KISTI가 대용량 학습 데이터 구축을 위한 활동을 하려면, 소프트웨어 인프라 구축도 중요하지만, 협업 커뮤니티 구성과 데이터 공유 문화 확산에 우선 노력을 기울여야 할 것으로 판단됨

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3장 연구개발과제의 수행 결과

1절 정성적 연구개발성과

□ 지식 확산

○ 원외 지식 확산

- 2022.10.19. 경기과학고 KISTI 기관탐방 프로그램에서 인공지능 기술 강의 (김은희)
- 2022.10.06. IITP의 지능정보화 시스템 개선 및 구축을 위한 언어모델 활용 방안 강의 (황명권)
- 2022.09.30. 2022 Korea Supercomputing Conference에서 SciDeBERTa 최적 병렬화 강의 (김은희)
- 2022.09.27.~30. 소방공무원 대상 인공지능 및 빅데이터 분석 강의 (이민호, 황명권)
- 2022.08.01.~03. 쿠웨이트 고등학생 대상 인공지능 캠프 강의 (이민호, 황명권)
- 2022.05.25. 국립재난안전연구원 뉴스 분석을 위한 언어모델 활용 방안 강의 (김은희)
- 2021.12.20. 한국계산과학공학회 2021 Machine Learning Winter School AI 강의 및 연구 결과물 확산
- UST 2021년 상/하반기 박사/석박통합과정 빅데이터 예비교육 (PROUD 프로그램)
- UST 2021년 석사/석박통합과정 인공지능 예비교육(X+AI 프로그램)
- 과학데이터스쿨 인력양성 교육 (소재플랫폼 인력양성, 4차산업 인재양성 교육)
- KISTI-충북대학교 HPC·AI 겨울학교 교육
- 2020.10.21. 2020년 한국전산유체공학회 통합학술대회 튜토리얼 진행(제목: Deep Learning for Beginners)
- UST 2020년 상/하반기 박사/석박통합과정 빅데이터 예비교육 (PROUD 프로그램)
- UST 2020년 석사/석박통합과정 인공지능 예비교육(X+AI 프로그램)
- 2019.6.25.~26. KISTI-Intel-JNU 데이터스쿨 행사(AI 주제 강연),
- 한국인터넷진흥원, 서울대학교 MBRC 사업단, 조선대학교 IT융합대학, 국립중앙과학관 문화기술포럼, 전북인재개발원, 중앙교육연수원, 대전인재개발원, 울산시청 등 기계학습 연구결과물 확산

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 원내 지식 확산

번호	세미나 제목	연사	일자
1	비전분야 딥러닝 모델 경량화 및 강인화	배성호교수(경희대)	2022.04.13
2	Large Scale 병렬처리 컴퓨팅	고현웅(튜닙)	2022.04.26
3	딥러닝 기반 정보검색	서민준교수(KAIST)	2022.05.02
4	금융권 AI 적용 사례	김민수상무(신한은행)	2022.05.27
5	Neural Radiation Field 최신 연구동향	양서연(서울대)	2022.06.03
6	초거대 AI의 현재와 미래(하이퍼클로바)	하정우소장(네이버)	2022.07.08
7	초거대 모델의 효율적인 추론	전병곤교수(서울대)	2022.09.14
8	로제타폴드를 활용한 단백질 모델링과응용	백민경교수(서울대)	2022.09.23
9	인공지능 기반 언어모델 소개	국가보안기술연구소 고우영 선임	2021.02.04.
10	개체명 인식을 위한 자연어 처리 및 임베딩 기법	군산대학교 김장원 교수	2021.03.04.
11	인공지능 기반 언어모델 활용	국가보안기술연구소 고우영 선임	2021.03.11.
12	그래프 임베딩, 뉴럴 네트워크 및 요약	KAIST AI 대학원 신기정 교수	2021.03.18.
13	대화 모델 평가와 확장성 (Evaluation and Scaling laws of Conversation models)	성균관 대학교 박진영 교수	2021.08.20.
14	LargeScale data 병렬처리 컴퓨팅	튜닙 고현웅	2021.10.28.
15	다국어 의미 분석을 위한 FrameNet과 프레임 의미분석	테디섬 함영균 대표	2021.11.25.
16	Knowledge Extraction	건국대학교 김학수 교수	2021.12.14
17	딥러닝 모델 경량화 동향	삼성전자 이진원 책임연구원	2020.01.16
18	Knowledge for Language Understanding	연세대 황승원 교수	2020.06.23
19	적은 학습데이터로 더 좋은 성능을 낼 수 있는 의존구조 분석 모델 연구	한국원자력연구원 임경태 박사	2020.07.01
20	Graph Embedding with Applications	중앙대 정재은 교수	2020.07.15
21	Accurate, Reliable, and Cherically Reasonable AI-driven Drug Discovery	AITRICS 류성옥 박사	2020.07.28
22	Understanding Video Contents with Deep Learning Techniques	ETRI 손정우 박사	2020.09.01
23	NL2SQL: Where are we now?	포항공대 한욱신 교수	2020.09.18
24	People Identification in Large-Scale Camera Networks Using Image Sequences	전남대 조영준	2020.09.22
25	자연어 처리 기술을 이용한 정보 추출 기술	고려대 임희석	2020.11.18
26	설명가능한 AI 개요 및 최신 기술 소개	UNIST 최재식 교수	2019.05.27
27	그래프 표현 학습	충남대 임성수 교수	2019.06.03
28	Towards Next AI beyond Deep Learning	고려대 임희석 교수	2019.07.09
29	Oracle Enterprise AI	오라클 장성우 전무	2019.10.01
30	Throughput prediction for cluster tools with machine learning	미국 Xilinx 정태희 박사	2019.10.10

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 원외협력

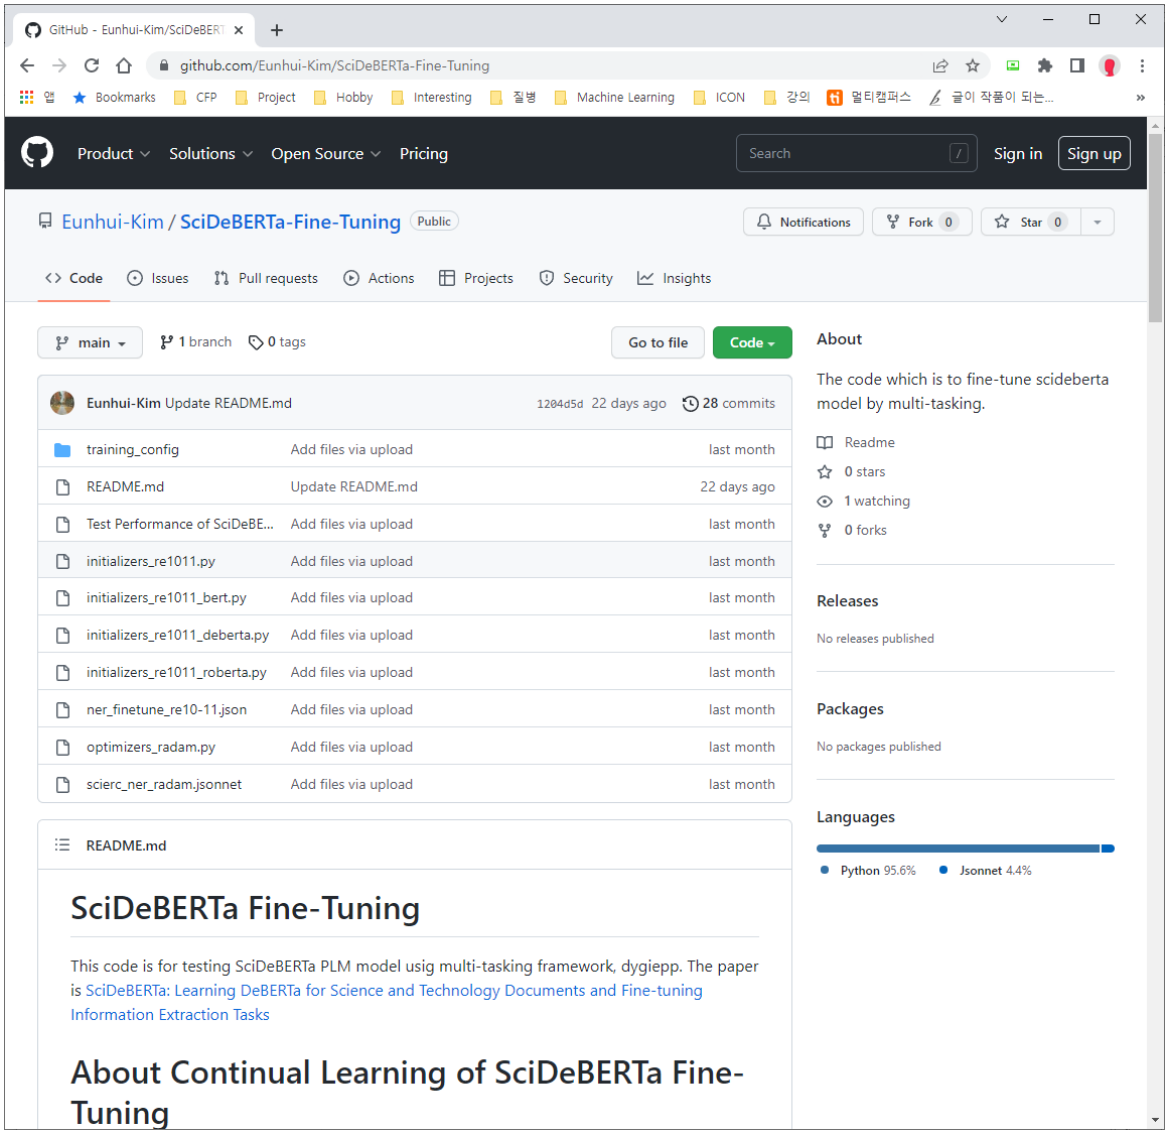
- 2022.10.19.~22. International Conference on Smart Media and Applications (SMA 2022) 국제학술대회 공동주최
- 2022.06.23.~25. 한국스마트미디어학회 종합학술대회 공동주최
- 2022.06.14.~15. 국립재난안전연구원 공동워크숍 개최
- 2022.04.01.~06.30 KISTI-ETRI 융합연구기획
- 2021.09.01.~12.31. 한밭대학교 컴퓨터공학과(임경태 교수)와 공동연구 진행
- 2021.07.19.~09.30. KIST 치매 DTC 융합연구단과 공동연구 진행을 통한 SCIE 저널 및 AAAI 논문 게재 및 발표
- 2021.07.01.~12.31. 군산대학교 소프트웨어융합공학과(김장원 교수)와 공동연구 진행
- 2019.07.18.~19 한국정보과학회 DB소사이어티&한국전자거래학교 여름학교 프로그램 구성 및 공동 주관(주제: 기계학습과 데이터 기술의 융합)
- 한국스마트미디어학회 상임 이사 활동(황명권)
- 한국콘텐츠학회 상임 이사 활동(이민호)
- 한국정보통신기술협회 메타데이터분과(PG606) 표준화위원(이민호)
- 정보과학회 데이터베이스 소사이어티 상임 이사 활동(이경하)
- 2020.9.24.~27. CS우수학술대회인 DASFAA 2020 국제학술대회 공동주관
- 2020년 9월 24~25. 정보과학회 KDBC 2020 Program Committee 활동 (이경하)
- 2020년 국가과학기술연구회(NST) 의료재난 대응 연구기획 참여(성원경)
- TvN 드라마 “반의반” 드라마 제작에 대한 기술 및 소품(인공지능 프로그래머 직업 관련) 협찬
- 2020.07.01.~12.31. 중앙대학교 소프트웨어학부(정재은 교수)와 공동연구 진행
- 2020.10.01.~12.31. 고려대학교 컴퓨터공학과(임희석 교수)와 공동연구 진행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 개발결과 언어모델 공개

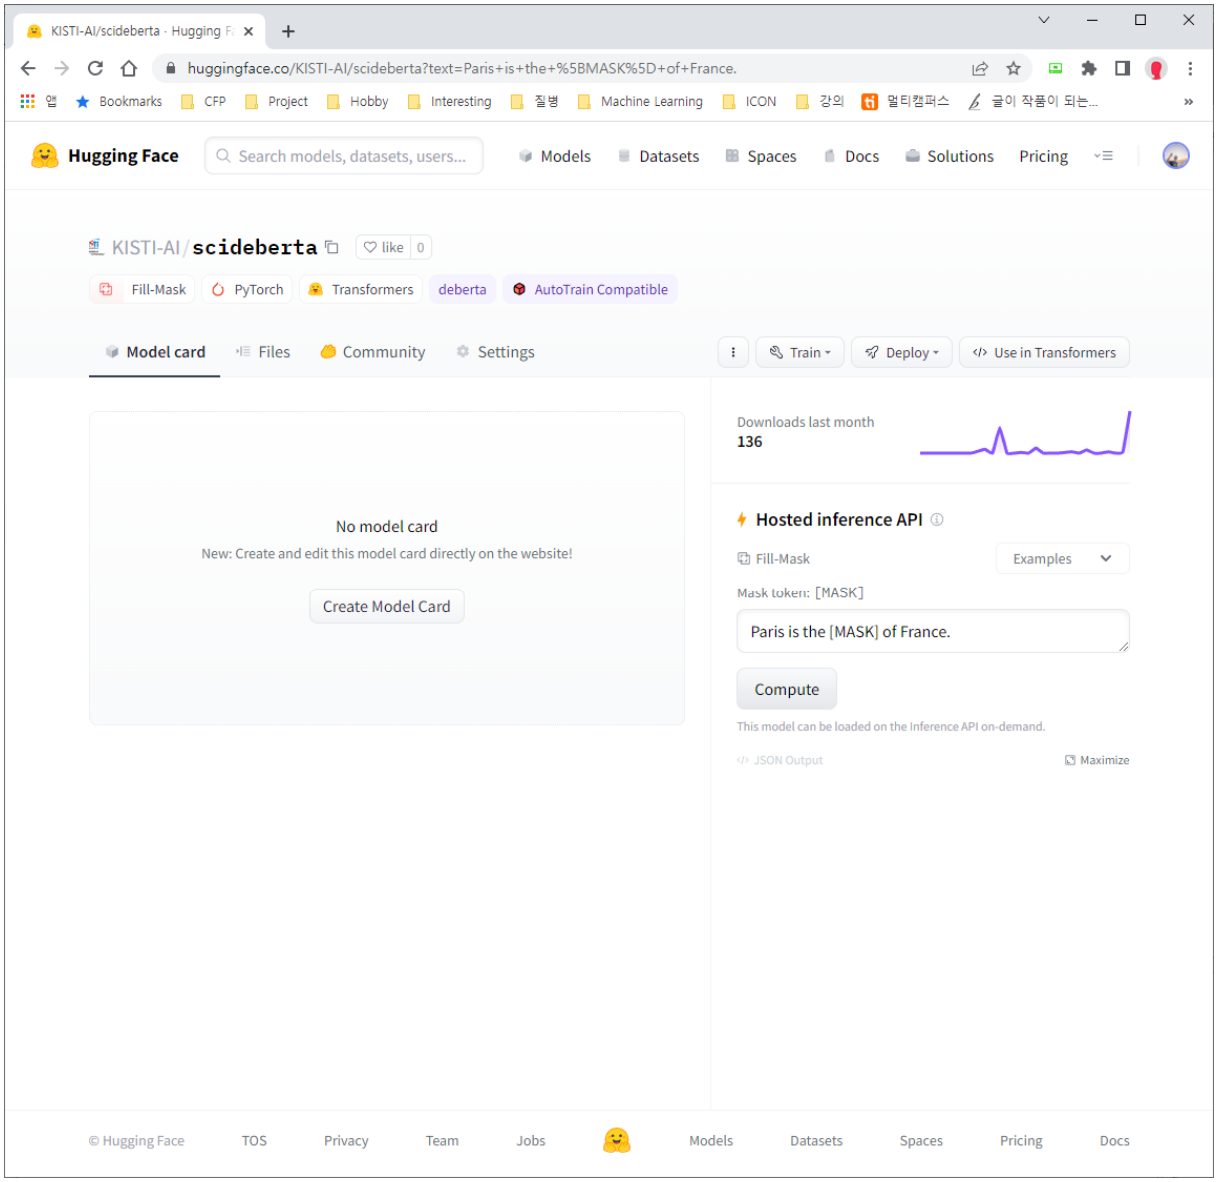
○ 활용 활성화를 위한 SciDeBERTa 모델에 대한 소스코드 및 모델 공개

- Github에 SciDeBERTa 모델 코드 공개 (2022.10.01. 오픈)
(https://github.com/Eunhui-Kim/SciDeBERTa-Fine-Tuning)



국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- SciDeBERTa 모델 활용도 증강을 위한 Huggingface 커뮤니티에 모델 공개 (2022.10.01. 공개, 2022.10.26. 현재 누적 사용자 136명) (https://huggingface.co/KISTI-AI/scideberta)



국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2절 정량적 연구개발성과

[과학적 성과]

□ 논문(국내외 전문 학술지) 게재

번호	논문명	학술지명	주저자명	호	국명	발행기관	SCIE 여부 (SCIE/비SCIE)	게재일	등록번호 (ISSN)	기여율
1	Training data selection based on dataset distillation for rapid deployment in machine-learning workflows	MTAP	정유나	-	스위스	Springer	SCIE	2022.09.05.	1573-7721	100%
2	SciDeBERTa: Learning DeBERTa for Science Technology Documents and Fine-Tuning Information Extraction Tasks	IEEE Access	정유나	Vol.10	미국	IEEE	SCIE	2022.06.08.	2169-3536	100%
3	지리적 인접성을 이용한 아파트 가격변화율 예측 모델 개발	한국정보과학회지	이민호	Vol.49	한국	한국정보과학회	비SCIE	2022.06.	1229-6821	100%
4	Automated Classification of Normal Control and Early-Stage Dementia Based on Activities of Daily Living (ADL) Data Acquired from Smart Home Environment	IJERPH	권이남 (황명권)	Vol.18	스위스	MDPI	SCIE	2021.12.15.	1660-4601	30%
5	Finding the best suited autoencoder for reducing model complexity	스마트미디어저널	황명권	Vol.10	한국	한국스마트미디어학회	비SCIE	2021.09	2287-1322	100%
6	Optimizing Spatial Shift Point-Wise Quantization	IEEE Access	김은희	Vol.9	미국	IEEE	SCIE	2021.05.05.	2169-3536	100%
7	학습 데이터 선별을 위한 오토인코더 기반 학습 개선도 측정 방안	한국정보과학회지	정유나	Vol.48	한국	한국정보과학회	비SCIE	2021.02	1229-6821	100%
8	Ensemble-Based Out-of-Distribution Detection	Electronics	황명권	Vol.10	스위스	MDPI	SCIE	2021.02.28.	2079-9292	100%
9	Analysis of Learning Influence of Training Data Selected by Distribution Consistency	Sensors	황명권	Vol.21	스위스	MDPI	SCIE	2021.02.04.	1424-8220	100%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 국내 및 국제 학술회의 발표

번호	회의 명칭	발표자	발표 일시	장소	국명
1	KCC 2021	정유나	2021.06.24.	제주 씨에스호텔	한국
2	KCC 2021	양동헌	2021.06.24.	제주 씨에스호텔	한국
3	한국스마트미디어학회 추계학술대회	정유나	2021.11.12.	김대중컨벤션센터	한국
4	한국스마트미디어학회 추계학술대회	김은희	2021.11.12.	김대중컨벤션센터	한국
5	한국콘텐츠학회 2022 종합학술대회	이민호	2022.07.13.	전남대학교 여수캠퍼스	한국
6	ICCC 2021	김은희	2021.12.20.	라마다 플라자 제주	한국
7	AAAI 2022	양동헌	2022.03.01.	온라인	-
8	SMA 2022	이민호	2022.10.20.	사이판	미국
9	SMA 2022	정유나	2022.10.20.	사이판	미국
10	SMA 2022	황명권	2022.10.20.	사이판	미국
11	SMA 2022	김은희	2022.10.20.	온라인 (사이판)	미국

□ 기술 요약 정보

- 해당사항없음.

□ 보고서 원문

연도	보고서 구분	발간일	등록 번호
2021	ISBN 기술조사 보고서	2021.10.05.	978-89-294-1187-9
2022	ISBN 기술조사 보고서	2022.01.28.	978-89-294-1228-9
2022	ISBN 기술조사 보고서	2022.07.01.	978-89-294-1323-1

□ 생명자원(생물자원, 생명정보)/화합물

- 해당사항없음.

[기술적 성과]

□ 지식재산권(특허, 실용신안, 의장, 디자인, 상표, 규격, 신품종, 프로그램)

번호	지식재산권 등 명칭 (건별 각각 기재)	국명	출원				등록			기여율	활용 여부
			출원인	출원일	출원 번호	등록 번호	등록인	등록일	등록 번호		
1	뉴럴 네트워크 연산 방법 및 이를 위한 장치	대한민국					김은희/ 이경하/ 성원경	2021.02.09	10-2021-0018472	100	-
2	뉴럴 네트워크 연산 방법 및 이를 위한 장치	대한민국	김은희/ 이경하/ 성원경	2021.11.15	PCT/KR2021/016682					100	-
3	압축벡터를 이용한 다차원 행렬곱셈 연산 가속화 방법	대한민국					김은희/ 이경하/ 성원경	2021.04.02	10-2021-0045330	100	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

ㅇ 지식재산권 활용 유형

번호	제품화	방어	전용실시	통상실시	무상실시	매매/양도	상호실시	담보대출	투자	기타
										√

□ 저작권(소프트웨어, 서적 등)

- 해당사항없음.

□ 신기술 지정

- 해당사항없음.

□ 기술 및 제품 인증

- 해당사항없음.

□ 표준화

- 해당사항없음.

[경제적 성과]

- 해당사항없음.

[사회적 성과]

□ 전문 연구 인력 양성 - 해당사항없음.

[인프라 성과]

- 해당사항없음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4장 연구개발성과의 관련 분야에 대한 기여 정도

□ 과학기술 텍스트에 특화된 언어이해모델의 보급

○ 과학기술분야에서 활용 가능한 특화 언어모델 SciDeBERTa 보급

- 과학기술 언어모델 자체의 보급으로 KISTI의 원천 기술을 국내외에 보급하는데 활용 할 수 있음.
- 개발된 모델은 Huggingface와 Github을 통해 공개되었으며 이에따라 향후 국내외 연구 개발진들이 과학기술분야 문제를 다루고자 할 때 유용하게 활용 될 수 있을 것으로 기대됨.
- 기존 과학기술분야 특화 언어모델보다 더 광범위한 과학기술분야를 포함함으로써 여러 분야에서 범용적 활용이 가능함.
- 또한 원하는 분야에 맞춘 추가 학습을 통해 해당 분야 최고 수준 모델과 유사한 성능을 달성할 수 있는 우수성을 보여 (예: SciDeBERTa-CS, SciDeBERTa-BIO) 국가적 전문성 향상에 기여함.

□ 과학기술 지식 추출 기술 개발

○ 과학기술 분야 지식 추출을 위한 태스크 최적화 기법 개발

- SciDeBERTa 모델의 파인튜닝을 통한 태스크 모델 개발 과정에서 과학기술 텍스트 이해 최적화를 위한 추가적인 개선 방안 적용 (Re-Initialization, Multi-Task Learning, Optimizer Exploring, Intermediate Fine-tuning 등)
- 컴퓨터공학 분야의 NER(Named Entity Recognition) 태스크에서 1위를 달성, 의공학분야의 NER 태스크에서 세계 2위 성능을 달성.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

5장 연구개발성과의 관리 및 활용 계획

□ KISTI 서비스로의 활용을 위한 SciDeBERTa 적용

○ 국가과학기술데이터본부 디지털큐레이션센터의 해외보고서 분석을 위해 SciDeBERTa 모델 적용 예정(2023)

○ 슈퍼컴퓨팅본부의 슈퍼컴퓨팅응용센터 바이오의료팀의 의료정보 분석을 위해 SciDeBERTa-Bio 모델 활용(협의 후 결정)

○ 데이터분석본부 미래기술분석센터의 과학기술텍스트 분석을 위해 SciDeBERTa 모델 적용 예정(2023)

○ 과학기술디지털융합본부

- 기계학습데이터연구단의 AIDA 서비스에 SciDeBERTa 모델 공개 및 학습데이터 생성을 위한 모델 활용(2023)
- 데이터기반문제해결연구단의 의료정보 분석 연구팀에서 SciDeBERTa-BIO 모델 활용(협의 후 결정)

□ 국내외 활용확산을 위한 모델 및 코드 공개

○ Github에 SciDeBERTa 모델 코드 공개 (2022.10.01. 오픈)
(https://github.com/Eunhui-Kim/SciDeBERTa-Fine-Tuning)

○ SciDeBERTa 모델 활용도 증강을 위한 Huggingface 커뮤니티에 모델 공개 (2022.10.01. 공개, 2022.10.26. 현재 누적 사용자 136명)
(https://huggingface.co/KISTI-AI/scideberta)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

6장 참고문헌

[Andreas2020] Jacob Andreas. Good-enough compositional data augmentation. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 7556?7566, Online. 2020.

[Bai2021ICML] Yu Bai et. al., “How Important is the Train-Validation Split in Meta-Learning,” ICML pp.543-553, 2021.

[Beltagy2019] Beltagy, Iz, Kyle Lo, and Arman Cohan, “SciBERT: A Pretrained Language Model for Scientific Text”, EMNLP-IJCNLP. 2019. pp. 3615-3620.

[Beltagy2019] Iz Beltagy, Kyle Lo, Arman Cohan, “SciBERT: A Pretrained Language Model for Scientific Text,” EMNLP 2019.

[Bishop1995] Christopher Bishop, “Pattern Recognition and Machine Learning,” 1995 Springer Press.

[Cai2020] Hengyi Cai, Hongshen Chen, Yonghao Song, Cheng Zhang, Xiaofang Zhao, and Dawei Yin. “Data manipulation: Towards effective instance learning for neural dialogue generation via learning to augment and reweight,” In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 6334?6343, 2020.

[Chen2019] Mingda Chen et. al., “Controllable paraphrase generation with a syntactic exemplar,” In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 5972?5984, 2019.

[Chen2020] Shuxiao Chen et. al., “A group-theoretic framework for data augmentation,” NIPS, 2020.

[Chen2020b] Xinyun Chen et. al., “Compositional generalization via neural-symbolic stack machines,” NIPS, 2020.

[Chen2021] Jiaao Chen, Dinghan Shen, Weizhu Chen, and Diyi Yang., “Hiddencut: Simple data augmentation for natural language understanding with better generalization,” In ACL. 2021.

[Chen2021b] Jiaao Chen et. al. "An empirical survey of data augmentation for limited data learning in nlp," arXiv preprint arXiv:2106.07499, 2021.

[Cheng 2019b] Cheng, Yong, Lu Jiang, and Wolfgang Macherey. "Robust neural

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

machine translation with doubly adversarial inputs." arXiv preprint arXiv:1906.02443 (2019).

[Clark2020a] Clark, Keven et al., “ELECTRA: Pre-training text encoders as discriminators rather than generators”, In Proceedings of the ICLR Conference, 2020.

[Devlin2019] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding”, In North American Association for Computational Linguistics (NAACL), 2019. pp. 4171-4186.

[Edunov 2018] Edunov, Sergey et al. “Understanding Back-Translation at Scale.” In Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, pages 489?500, Brussels, Belgium. Association for Computational Linguistics. 2018.

[FengandVarun2021] Steven Y. Feng and Varun Gangal et. al., “A Survey of Data Augmentation Approaches for NLP,“ ACL-IJCNLP 2021, pp.968-988, 2021.

[Gao2019] Fei Gao et. al. "Soft contextual data augmentation for neural machine translation." Proceedings of the 57th Annual Meeting of the ACL. 2019.

[Gao2021SimCSE] Gao, Tianyu et al., SimCSE: Simple Contrastive Learning of Sentence Embeddings, Prceedings of the 2021 Conf. on EMNLP, 2021.

[George1995] George A. Miller. WordNet: A Lexical Database for English. Communications of the ACM Vol. 38, No. 11: 39-41, 1995.

[Gu2021] Gu, Yu, et al. "Domain-specific language model pretraining for biomedical natural language processing." ACM Transactions on Computing for Healthcare (HEALTH) 3.1 (2021): 1-23.

[Guo2020] Demi Guo, Yoon Kim, and Alexander Rush. “Sequence-level mixed sample data augmentation,” In Proceedings of the 2020 Conference on EMNLP, 2020.

[He2021] He, Pengcheng, et al. "DeBERTa: Decoding-enhanced BERT with Disentangled Attention." International Conference on Learning Representations. 2021.

[He2021] He, Pengcheng, Jianfeng Gao, and Weizhu Chen. "Debertav3: Improving deberta using electra-style pre-training with gradient-disentangled embedding sharing." arXiv preprint arXiv:2111.09543 (2021).

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[Heo2021] H. Heo, S. Chun, S. Oh, D. Han, S. Yun, G. Kim, Y. Uh, J.W. Ha, “AdamP: Slowing Down the Slowdown for Momentum Optimizers on Scale-invariant Weights,” ICLR 2021.

[Joshi2020] Joshi, Mandar, et al. "SpanBERT: Improving pre-training by representing and predicting spans." Transactions of the Association for Computational Linguistics 8 (2020): 64-77.

[Kim2022] Hzel Kim et. al. “ALP: Data Augmentation using Lexicalized PCFGs for Few-Shot Text Classification.” Proceedings of the Thirty-Sixth AAAI Conference on Artificial Intelligence (AAAI). 2022.

[KingMa&Ba2014] KINGMA, Diederik P.; BA, Jimmy. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014.

[Kingma2015] D.P. Kingma, J. Ba, “Adam: A Method for Stochastic Optimization,” ICLR 2015.

[Kudo2018] Kudo, T., Subword regularization: Improving neural network translation models with multiple subword candidates. arXiv preprint arXiv:1804.10959 (2018)

[Kumar2020] Varun Kumar, Ashutosh Choudhary, and Eunah Cho, “Data augmentation using pre-trained transformer models,” In Proceedings of the 2nd Workshop on Life-long Learning for Spoken Language Systems, pages 18?26, Suzhou, China. Association for Computational Linguistics, 2020.

[KyonghaLee2021] 이경하, 김은희, “트랜스포머 기반 최신 언어 모델 기법 분석,” ISBN 978-89-294-1187-9, Oct. 2021.

[Lan2020] Lan, Zhenzhong, et al. Albert: A lite bert for self-supervised learning of language representations. In Proceedings of ICLR Conference, 2020.

[Lee2020] Lee, Jinhyuk, et al., “BioBERT: a pre-trained biomedical language representation model for biomedical text mining”, Bioinformatics. Vol.36 No.4, 2020. pp.1234-1240.

[Liu2019] Liu, Yinhan, et al., “RoBERTa: A robustly optimized bert pretraining approach”, arXiv preprint arXiv:1907.11692. 2019.

[Liu2019] Yinhan Liu et al.. 2019. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692.

[Meng2021] Meng, Yu, et al. "Coco-lm: Correcting and contrasting text sequences

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

for language model pretraining." Advances in Neural Information Processing Systems 34 (2021): 23102-23114.

[Min2020] Junghyun Min, R. Thomas McCoy, Dipanjan Das, Emily Pitler, and Tal Linzen.,“Syntactic data augmentation increases robustness to inference heuristics,” In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 2339?2352, Online. Association for Computational Linguistics. 2020.

[Pruksachatkun2020] Yada Pruksachatkun et al.. 2020. Intermediate-task transfer learning with pretrained models for natural language understanding: When and why does it work?. arXiv preprint arXiv:2005.00628.

[Rajput2019] Shashank Rajput et. al., “Does data augmentation lead to positive margin?,” In International Conference on Machine Learning, pp. 5321?5330. PMLR, 2019.

[Russakovsky&Deng2015]Olga Russakovsky*, Jia Deng* et. al., “ImageNet Large Scale Visual Recognition Challenge,” IJCV, 2015.

[Sennrich 2016] Sennrich, Rico et al. “Improving neural machine translation models with monolingual data.” In Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, Berlin, Germany, pages 86?96. 2016.

[Shen2020] Dinghan Shen, Mingzhi Zheng, Yelong Shen, Yanru Qu, and Weizhu Chen. “A simple but tough to beat data augmentation approach for natural language understanding and generation,” arXiv preprint arXiv:2009.13818. 2020.

[Tan2020] Samson Tan, Shafiq Joty, Min-Yen Kan, and Richard Socher.,“It’s morphin’ time! Combating linguistic discrimination with inflectional perturbations,” In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pp. 2920?2935, 2020.

[Vu2020] Tu Vu et al.. 2020. Exploring and Predicting Transferability across NLP Tasks. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP).

[Wang2018] Wang, Alex, et al. "GLUE: A multi-task benchmark and analysis platform for natural language understanding." arXiv preprint arXiv:1804.07461 (2018).

[Wang2019] Alex Wang et. al. "GLUE: A multi-task benchmark and analysis platform for natural language understanding." ICLR 2019.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[Wu2019] Xing WU, et al., “Conditional bert contextual augmentation. In: International Conference on Computational Science,” Springer, Cham, p. 84-95. 2019.

[XIE2020] Qizhe XIE et. al. “Unsupervised data augmentation for consistency training. Advances in Neural Information Processing Systems,” V. 33: pp. 6256-6268, 2020.

[Yarowsky1995unsupervised] David Yarowsky, “Unsupervised word sense disambiguation rivaling supervised methods,” 33rd ACL meeting, pp189-196, 1995.

[Yasunaga2022] Yasunaga, Michihiro, Jure Leskovec, and Percy Liang. "LinkBERT: Pretraining Language Models with Document Links." arXiv preprint arXiv:2203.15827 (2022).

[Yekyung2021] Yekyung Kim et. al.“LINDA: Unsupervised Learning to interpolate in Natural Language Processing,” arXiv:2112.13969, Dec., 2021.

Jason Phang, Thibault Fevry, and Samuel R. Bowman. 2018. Sentence encoders on stilts: Supplementary training on intermediate labeled-data tasks. arXiv preprint arXiv:1811.01088.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 주 의 -

1. 이 보고서는 한국과학기술정보연구원에서 수행한 기본사업의 최종보고서입니다.

2. 이 보고서의 내용을 발표 또는 인용할 때에는 반드시 한국과학기술정보연구원에서 발행한 보고서임을 밝혀야 합니다.

3. 국가과학기술 기밀유지에 필요한 내용은 대외적으로 발표 또는 공개하여서는 아니됩니다.