국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

보안 과제( ), 일반 과제(○) / 공개( ), 비공개( ), 발간등록번호( )

2019사업 제 3차 연도 최종 보고서

과제번호 2019-0-00067

대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술개발

최종보고서

2022. 02 . 21 .

주관연구기관 / 숭실대학교산학협력단

과학기술정보통신부
정보통신기획평가원

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서

보안등급: 일반[○], 보안[ ]

중앙행정기관명	과학기술정보통신부	사업명	사업명	SW컴퓨팅산업원천	
전문기관명(해당 시 작성)	정보통신기획평가원		내역사업명 (해당 시 작성)	유망기술선도기술 확보형	
공고번호	2018-0568	총괄연구개발 식별번호 (해당 시 작성)			
		연구개발과제번호		2019-0-00067	

기술분류	국가과학기술 표준분류	1순위 소분류 코드명 (EE0108)	90%	2순위 소분류 코드명 (EE0202)	5%	3순위 소분류 코드명 (EE0110)	5%	
	ICT기술분류	1순위 소분류 코드명 (SWAI0202)	100 %	2순위 소분류 코드명	%	3순위 소분류 코드명	%	

총괄연구개발명 (해당 시 작성)	국문				
	영문				
연구개발과제명	국문	대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술 개발			
	영문	Semantic Analysis Reasoning Methods for Automatic Completion of Large Scale Knowledge Graph			
주관연구개발기관	기관명	숭실대학교산학협력단	사업자등록번호	108-82-06264	
	주소	(우)06978	법인등록번호	115071-0004435	
연구책임자	성명	박영택	직위	교수	
	연락처 직장전화	02-820-0678	휴대전화	*******	
	연락처 전자우편	park@ssu.ac.kr	국가연구자번호	1012-4112	

연구개발기간	전체		2019. 04. 01 - 2021. 12. 31(2년9개월)
	단계 (해당 시 작성)	1단계	2019. 04. 01 - 2021. 12. 31(2년9개월)
		n단계	

연구개발비 (단위: 천원)		정부지원 연구개발비	기관부담 연구개발비		그 외 기관 등의 지원금				합계			연구개발비 외 지원금
					지방자치단체		기타( )					
		현금	현금	현물	현금	현물	현금	현물	현금	현물	합계	
총계		916,000	0	38,600	0	0	0	0	916,000	38,600	954,600	
1단계	1년차	250,000	0	8,600	0	0	0	0	250,000	8,600	258,600	
	2년차	333,000	0	28,800	0	0	0	0	333,000	28,800	361,800	
	3년차	333,000	0	1,200	0	0	0	0	333,000	1,200	334,200	
n단계	1년차											
	n년차											

공동연구개발기관 등 (해당 시 작성)	기관명	책임자	직위	휴대전화	전자우편	비고	
						역할	기관유형
공동연구개발기관							
위탁연구개발기관							
연구개발기관 외 기관							

연구개발담당자 실무담당자					
성명		박현규	직위	전임연구원	
연락처	직장전화	*******	휴대전화	*******	
	전자우편		국가연구자번호	1120-6843	

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재처분 등의 불이익도 감수하겠습니다.

2022 년 02 월 21 일

연구책임자: 박영택 (인)

주관연구개발기관의 장:이진욱 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서

보안등급: 일반[○], 보안[ ]

중앙행정기관명	과학기술정보통신부	사업명	사업명	SW컴퓨팅산업원천	
전문기관명(해당 시 작성)	정보통신기획평가원		내역사업명 (해당 시 작성)	유망기술선도기술 확보형	
공고번호	2018-0568	총괄연구개발 식별번호 (해당 시 작성)			
		연구개발과제번호		2019-0-00067	

기술분류	국가과학기술 표준분류	1순위 소분류 코드명 (EE0108)	90%	2순위 소분류 코드명 (EE0202)	5%	3순위 소분류 코드명 (EE0110)	5%
	ICT기술분류	1순위 소분류 코드명 (SWAI0202)	100 %	2순위 소분류 코드명	%	3순위 소분류 코드명	%

총괄연구개발명 (해당 시 작성)	국문				
	영문				
연구개발과제명	국문	대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술 개발			
	영문	Semantic Analysis Reasoning Methods for Automatic Completion of Large Scale Knowledge Graph			
주관연구개발기관	기관명	숭실대학교산학협력단	사업자등록번호	108-82-06264	
	주소	(우)06978	법인등록번호	115071-0004435	
연구책임자	성명	박영택	직위	교수	
	연락처 직장전화	02-820-0678	휴대전화	*******	
	연락처 전자우편	park@ssu.ac.kr	국가연구자번호	1012-4112	

연구개발기간	전체		2019. 04. 01 - 2021. 12. 31(2년9개월)
	단계 (해당 시 작성)	1단계	2019. 04. 01 - 2021. 12. 31(2년9개월)
		n단계	

연구개발비 (단위: 천원)		정부지원 연구개발비	기관부담 연구개발비		그 외 기관 등의 지원금				합계			연구개발비 외 지원금
					지방자치단체		기타( )					
		현금	현금	현물	현금	현물	현금	현물	현금	현물	합계	
총계		916,000	0	38,600	0	0	0	0	916,000	38,600	954,600	
1단계	1년차	250,000	0	8,600	0	0	0	0	250,000	8,600	258,600	
	2년차	333,000	0	28,800	0	0	0	0	333,000	28,800	361,800	
	3년차	333,000	0	1,200	0	0	0	0	333,000	1,200	334,200	
n단계	1년차											
	n년차											

공동연구개발기관 등 (해당 시 작성)	기관명	책임자	직위	휴대전화	전자우편	비고	
						역할	기관유형
공동연구개발기관							
위탁연구개발기관							
연구개발기관 외 기관							

연구개발담당자 실무담당자	성명	박현규	직위	전임연구원	
	연락처 직장전화	*******	휴대전화	*******	
	연락처 전자우편		국가연구자번호	1120-6843	

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재처분 등의 불이익도 감수하겠습니다.

2022 년 02 월 21 일

연구책임자: 박영택 (인)

주관연구개발기관의 장:이진욱 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

< 요 약 문 >

※ 요약문은 5쪽 이내로 작성합니다.

<table>
<tr><td colspan="2">사업명</td><td colspan="3">과학기술정보통신부</td><td colspan="2">총괄연구개발 식별번호
(해당 시 작성)</td><td colspan="2"></td></tr>
<tr><td colspan="2">내역사업명
(해당 시 작성)</td><td colspan="3">정보통신기획평가원</td><td colspan="2">연구개발과제번호</td><td colspan="2">2019-0-00067</td></tr>
<tr><td rowspan="2">기술분류</td><td>국가과학기술 표준분류</td><td>1순위 소분류 코드명
(EE0108)</td><td>90 %</td><td>2순위 소분류 코드명
(EE0202)</td><td>5%</td><td>3순위 소분류 코드명
(EE0110)</td><td>5%</td></tr>
<tr><td>ICT기술분류</td><td>1순위 소분류 코드명
(SWAI0202)</td><td>100%</td><td>2순위 소분류 코드명</td><td>%</td><td>3순위 소분류 코드명</td><td>%</td></tr>
<tr><td rowspan="3">연구개발과제 특성
(해당 시 작성)</td><td>기술료징수</td><td>○</td><td>사회문제해결</td><td></td><td>혁신도약형</td><td>○</td><td>경쟁형과제</td><td></td><td>표준화연계</td><td></td></tr>
<tr><td>공개SW</td><td>○</td><td>SW자산뱅크</td><td></td><td>연구데이터공개</td><td></td><td>일자리연계</td><td></td><td>규제샌드박스</td><td></td></tr>
<tr><td>정책지정</td><td></td><td>국제공동</td><td></td><td>사업화연계</td><td></td><td>소재부품장비</td><td></td><td>수요기업</td><td></td></tr>
<tr><td colspan="2">연구개발과제명</td><td colspan="6">대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술 개발</td></tr>
<tr><td colspan="2">전체 연구개발기간</td><td colspan="6">2019. 04. 01 - 2021. 12. 31</td></tr>
<tr><td colspan="2">총 연구개발비</td><td colspan="6">총 916,000 천원
(정부지원연구개발비:916,000 천원, 기관부담연구개발비 : 천원,
지방자치단체: 천원, 그 외 지원금: 천원)</td></tr>
<tr><td colspan="2">연구개발단계</td><td colspan="2">기초[ ] 응용[○] 개발[ ]
기타(위 3가지에 해당되지 않는 경우)[ ]</td><td colspan="2">기술성숙도
(해당 시 기재)</td><td colspan="2">착수시점 기준( )
종료시점 목표( )</td></tr>
<tr><td colspan="2">연구개발과제 특성
(해당 시 작성)</td><td colspan="6">기술료비징수,공개SW,혁신도약형</td></tr>
<tr><td rowspan="2">연구개발
목표
및 내용</td><td>최종 목표</td><td colspan="6">근래에 들어서 가장 대표적인 빅데이터는 지식 그래프이며, 대용량 지식 그래프의 활용도가 증대되면서 지식 그래프의 시맨틱스를 증대하기 위한 다양한 추론 연구가 진행되고 있음. 본 연구에서는 온톨로지 기반의 빅데이터의 추론을 수행하는 연구와 딥러닝 기반의 알고리즘을 이용하여 지식 그래프 완성을 위한 연구를 병행하였으며, 두 연구를 효율적으로 융합하는 뉴로 심볼릭 방식의 연구를 목표로 수행하였음. 본 연구는 각 연차별 세부 연구 목표를 지정하여 연구 개발을 수행하였으며, 아래와 같은 연구 목표에 대한 연구 개발을 수행하였음.
• 심볼릭 방식을 이용한 Spark 기반 OWL-Horst 및 SWRL 분산 추론 엔진 개발 프레임워크 연구
• 딥러닝 방식을 이용한 지식그래프 자동 완성을 위한 경로 기반 관계 네트워크 모델 구축
• 심볼릭 방식과 딥러닝 방식을 융합한 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법</td></tr>
<tr><td>전체 내용</td><td colspan="6">지식 그래프는 일반적으로 온톨로지를 보유하고 있으며, 또한 많은 그래프 데이터로 구성되어 있으므로 온톨로지 기반의 빅데이터 추론 연구와 대용량 그래프 데이터 기반의 딥러닝 추론 연구에 대한 요구 사항이 증대되고 있음. 따라서 본 연구 개발은 온톨로지 기반 빅데이터 시맨틱 분석 추론 연구 개발과 대용량 지식 그래프 데이터를 이용한 딥러닝 기반 시맨틱 분석 추론 연구를 수행하였고, 두 연구를 효율적으로 결합한 뉴로 심볼릭 방식의 연구를 수행하였음. 이를 위해 본 연구는 각 연차별 세부 연구 목표를 지정하여 연구 개발을 수행하였으며, 세부 연구 목표에 대한 자체점검 결과 목표 대비 적절한 실적을 산출하였음. 아래는 연차별 연구 목표 및 본 연구의 목표를 도식화한 내용을 보여줌
• 심볼릭 방식을 이용한 Spark 기반 OWL-Horst 및 SWRL 분산 추론 엔진 개발 및 프레임워크 연구
• 딥러닝 방식을 이용한 지식그래프 자동 완성을 위한 경로 기반 관계 네트워크 모델 구축</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 심볼릭 방식과 딥러닝 방식을 융합한 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법



그림 2 본 연구에 대한 지식완성 핵심 기술 연구 목표

아래는 각 연차별 연구 목표 및 본 연구의 목표를 도식화한 내용을 보여줌

- 온톨로지 기반 대용량 심볼릭 추론을 통한 지식 완성 연구
  - Spark 기반 온톨로지 추론(RDFS/OWL-Horst) 엔진 설계
  - Spark 기반 SWRL 추론 엔진 설계
  - 대규모 온톨로지 추론을 위한 Spark 추론 엔진 설계
  - 효율적인 추론을 위한 규칙 재정의 및 최적화
  - 효율적인 추론을 위한 분산 병렬 추론 엔진 구축
  - Spark Dataframe을 활용하여 대용량 지식그래프 추론 통합 시스템 구축
  - Github을 활용하여 W3C 표준 언어로 제작된 공개 데이터를 이용한 빅데이터 추론 벤치마크 데이터 생성 및 공개

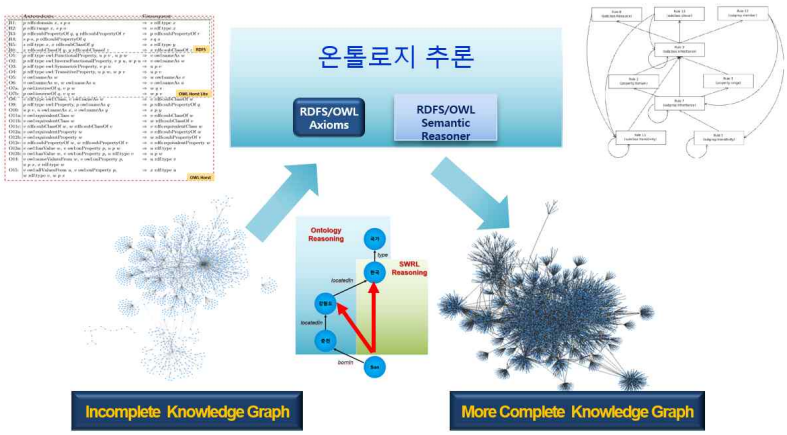


그림 3 온톨로지 기반 대용량 심볼릭 추론 기반 지식 완성

- 데이터 기반 대용량 딥러닝 추론 기반 지식 완성 연구
  - 딥러닝방식을 활용하기 위한 지식그래프 임베딩 설계
  - Random Walk 방식을 이용한 경로 탐색 기법 개발
  - PRA 기반 경로 추출 기법 개발
  - 경로 기반 Story 데이터 생성 및 이를 이용한 관계 네트워크 학습 방식 설계
  - 지식그래프 자동 완성을 위한 경로 기반 관계 네트워크 모델 구축 및 성능 평가

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- Attention 및 Bidirectional LSTM 기반 지식 그래프 학습 모델 방식 개발

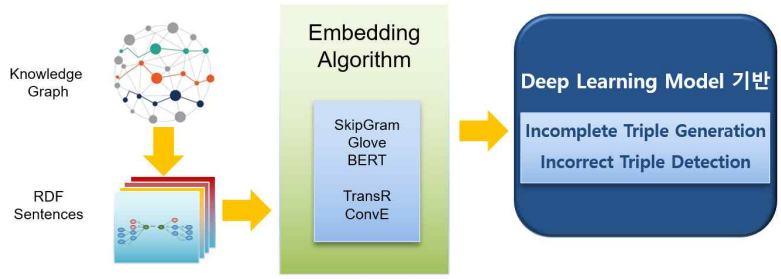


그림 4 딥러닝 추론 기반 지식 완성

- 심볼릭과 딥러닝 방식을 융합한 지식 완성 연구
  - 지식그래프 완성을 위한 심볼릭 방식 추론 엔진 설계
  - 심볼릭 추론을 위한 규칙 정의 및 추론 방식 설계
  - 임베딩을 위한 규칙 및 지식그래프의 데이터 정의 및 데이터에 대한 전처리 학습
  - 뉴로 심볼릭 방식의 Unification 모델 학습 및 지식그래프 임베딩 학습 방식을 결합한 통합 시스템 설계
  - 뉴로 심볼릭 기반 규칙 추론을 통한 지식 완성 성능 평가

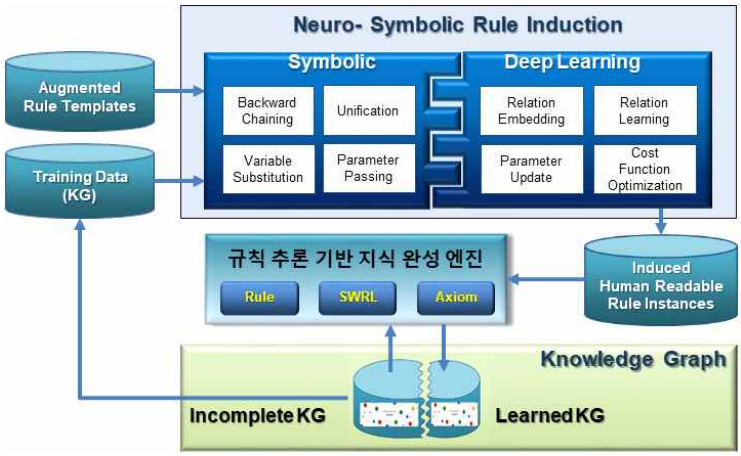


그림 5 뉴로 심볼릭 기반 지식 완성

1단계 (해당 시 작성)	목표	빅데이터 시맨틱 분석 추론 개선 기술 연구를 위해서 심볼릭 및 딥러닝 융합 방식을 이용한 대용량 지식그래프 추론 기술 연구
	내용	본 연구 개발은 지식 그래프의 불완전성을 해결하기 위한 시맨틱 추론으로써, 지식 완성을 수행하기 위한 연구 개발을 수행하였음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

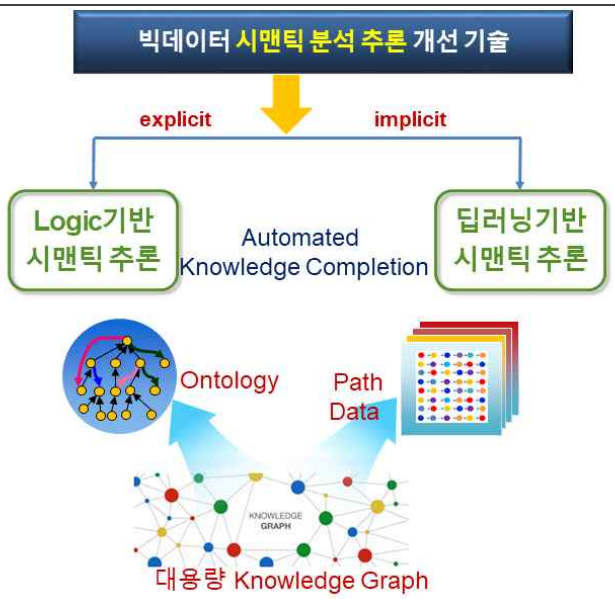


그림 6 시맨틱 분석을 통한 지식 완성

심볼릭 방식과 딥러닝 방식을 이용한 지식 완성 핵심 기술 개발

- OWL 및 SWRL 대용량 추론 연구
- 딥러닝 기반 지식 완성 연구
- 심볼릭 추론과 딥러닝 추론의 융합 방식의 연구 추진

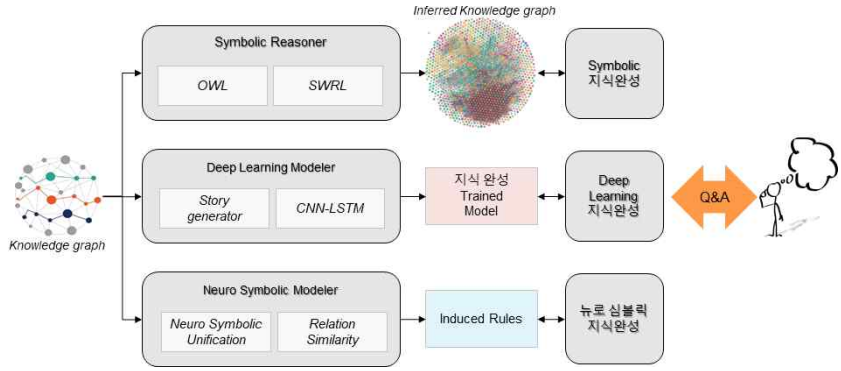


그림 7 수행한 연구 과제의 개념적 구조도

본 연구는 각 년차별 연구 개발을 수행하여 지식 완성 분야의 도전적 원천 기술 확보로 시작하여, 글로벌 경쟁력있는 기술 개발을 목표로 연구 개발을 수행함

1차년도	원천, 핵심 기술 확보와 개념 검증	심볼릭 추론기술: Spark 기반 분산 클러스터 환경 RDFS/OWL 추론 기술 개발
		딥러닝 원천기술: Attentive Bi-LSTM 기술 기반 지식완성 핵심 기술 연구
		표준데이터: 국외 표준 데이터 기반 테스트
2차년도	대용량 지식그래프 지식 완성 기반 기술 연구	분산 심볼릭 추론 지식 완성 기술: 대용량 분산추론 기반 RDFS/OWL 및 SWRL 추론 시스템 구축
		딥러닝 지식 완성 기반기술: CNN/LSTM 기반 자동 지식 완성 시스템 구축
		뉴로 심볼릭 기반 기술: 심볼릭 및 딥러닝 융합 방식 기반 자동 지식 완성 기반 기술
3차년도	글로벌 경쟁력 수준의 지식 완성 기술 개발	뉴로 심볼릭 추론 기반 지식완성: 뉴로 심볼릭 추론 기반 지식 완성 기술 개발
		Relation Network 기반 지식완성: 관계 추론 기반 딥러닝 자동 지식 완성 기술 개발
		데이터 및 SW 공개: 국제 수준의 한국어 데이터 및 SW 공개

n단계 (해당 시 작성)	목표	
	내용	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구개발성과

본 연구를 수행을 통한 결과로써 연구 성과 및 실적은 수행한 연구 기간에 대하여 각 년차별 주요 결과물을 도출하였으며, 목표대비 정량적 실적은 아래와 같음.

정량적 실적

구 분		목 표	실 적	비 고
특허 출원(등록)	국 내	6(4)	10(2)	
	국 외	6(2)	7(0)	
	계	12(6)	17(2)	
논 문	국 내(국 외)	-	7(4)	SCIE 저널 2편 (Impact Factor : 6.954)
등록·기탁 대상 성과물	소프트웨어 등록	13	14	
	기술 문서	15	15	

본 연구 결과물의 기술 개발 성과의 공정성을 위해서 다음의 두 항목은 한국정보통신기술협회(TTA) 소프트웨어 시험 인증 연구소의 공인 인증을 받아서 연구 결과물 성과를 판정하였음.

- 빅데이터 시맨틱 분산 추론 속도
- 빅데이터 Link Prediction 추론 증강도

또한 본 연구에서 연구 개발하는 지식그래프에 대하여 표준 언어로 제작된 공개데이터를 이용한 빅데이터 추론을 위한 벤치마크 데이터를 생성 및 공개 수행함.

다음은 공개한 6종류의 빅데이터 추론 벤치마크 데이터를 공개한 Github 주소를 보여줌

- NELL-995 데이터 Github :
  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/NELL-995

FB15K-237 데이터 Github :

  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/FB15K-237
- NDSL 데이터 Github :
  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/NDSL
- DBpedia 데이터 Github :
  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/DBpedia
- DBpia 데이터 Github :
  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/DBpia
- KData 데이터 Github :
  - https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/KData

연구개발성과 활용계획 및 기대 효과

①불완전 지식그래프 자동 완성

- 본 연구의 결과물은 불완전 지식그래프의 자동 환성에 활용이 가능하다. 근래에 들어서 대용량 지식 그래프의 활용이 다양한 분야 (금융기관, 행정기관, 법률 분야, 검색)에 활용되는 추세이므로 다양한 지식 그래프가 출현할 것이고 이에 대한 자동 완성의 요구 사항이 증대되는 추세임
- 불완전한 지식그래프를 자동 완성함으로써 지식그래프 활용도의 향상에 기여 할 것으로 예상함
- 이를 활용하여 대용량 지식그래프 자동 완성 모듈의 사업화로 확장 가능

②지식그래프 오류 발견 및 자동 보완

- 지식그래프는 사람이나 기계학습 프로그램에 의해서 생성되므로 많은 오류를 가지고 있음. 이러한 오류는 지식 그래프 활용 시스템의 성능을 떨어뜨리는 요소가 됨. 본 연구 결과물을 활용하면 지식 그래프의 오류를 발견할 수 있는 프로그램을 작성할 수 있음
- 본 연구 결과물을 활용하여 지식그래프의 오류를 발견하고 이를 자동으로 보완하는 프로그램은 시스템의 효율성을 증대하는 목적으로 활용이 가능함

③지식그래프 모순성 발견 및 자동 보완

- 지식그래프에는 많은 모순성을 가지고 있음. 즉 하나의 Proposition에 대해서 True와 False 값을 동시에 추론되는 경우가 있음. 본 연구 결과물은 지식그래프의 모순을 발견하고 정확한 값을 보정하는 데 활용이 가능함

④지식그래프 임베딩 기술

- 본 연구에서 제안하고 있는 지식그래프 임베딩 기술은 다양한 분야에 활용이 가능함
- RDF2Vec을 이용한 엔티티 임베딩 기술, Partial Embedding 기술 및 Relation Embedding 기술 등의 활용이 다양한 분야에 가능함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구개발성과의 비공개여부 및 사유													
연구개발성과의 등록·기탁 건수	논문	특허	보고서 원문	연구시설·장비	기술요약정보	소프트웨어	표준	생명자원		화합물	신품종	
								생명정보	생물자원		정보	실물
	11	19	15			14						

연구시설·장비 종합정보시스템 등록 현황	구입기관	연구시설·장비명	규격(모델명)	수량	구입연월일	구입가격(천원)	구입처(전화)	비고(설치장소)	ZEUS 등록번호

국문핵심어 (5개 이내)	지식완성	온톨로지 기반 지식 완성	딥러닝 기반 지식 완성	뉴로 심볼릭 기반 지식 완성	
영문핵심어 (5개 이내)	Knowledge Completion	Ontology-based Knowledge Completion	Deep Learning-based Knowledge Completion	Neuro Symbolic Knowledge Completion	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<목 차>

1. 연구개발과제의 개요 ····· 1

2. 연구개발과제의 수행 과정 및 수행 내용 ····· 7

3. 연구개발과제의 수행 결과 및 목표 달성 정도 ····· 50

4. 목표 미달 또는 미흡한 사항에 대한 분석 ····· 65

5. 연구개발성과의 관련 분야에 대한 기여 정도 ····· 66

6. 연구개발성과의 관리 및 활용 계획 ····· 67

7. 연구개발성과에 대한 후속연구 및 추가 개발 계획 ····· 77

8. 연구개발비 사용실적 ····· 78

붙임1. 사업화대상기술별 기술명세서 ····· 71

붙임2. 자체 보안관리 진단표 ····· 79

붙임3. 공개 SW 요약서 *(공개SW과제만 작성)* ····· 80

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1. 연구개발과제의 개요

1-1. 대용량 지식그래프의 필요성

- 기존의 빅데이터 중에서 가장 활용도가 높은 빅데이터는 지식그래프이며, Google의 Knowledge Graph, Amazon Product Graph, Facebook Graph API, IBM Watson. Microsoft Satori의 Project Hanover/Literome, LinkedIn Knowledge Graph, Yandex Object Answer 등과 같이 대용량의 Knowledge Graph가 활용되는 추세임

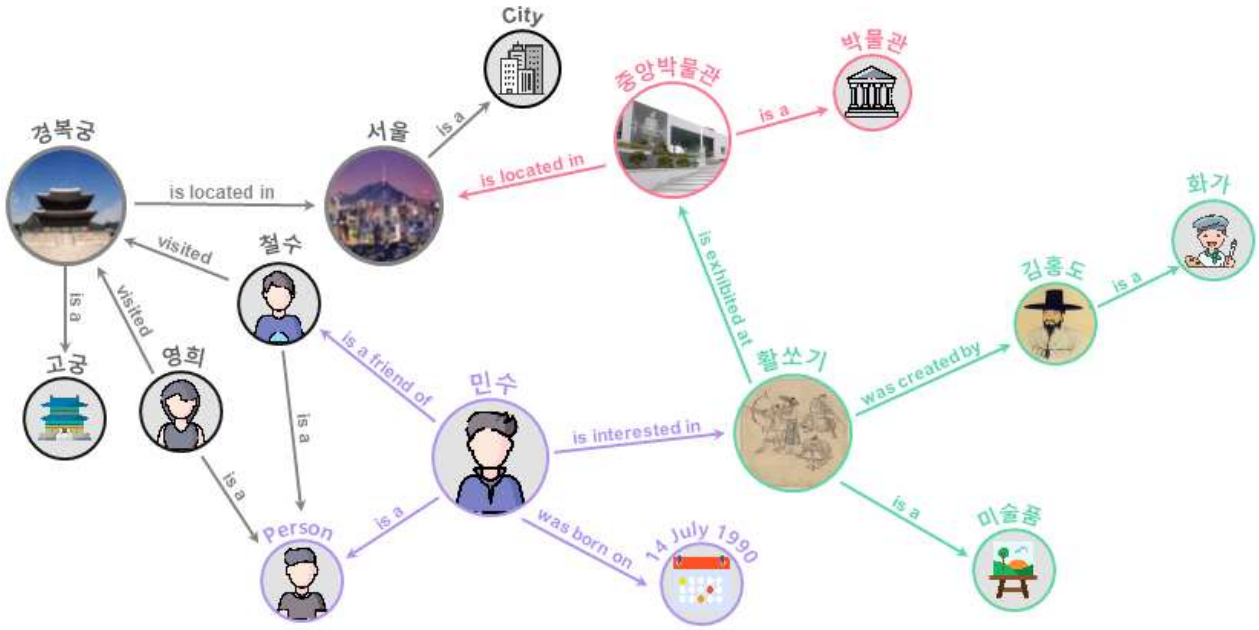


그림 1-1 지식그래프의 예

- 지식그래프는 그래프의 기본 구성과 동일한 2개의 노드와 이를 연결하는 edge로 구성이 되며, 이는 Triple의 지식표현과 동일하여 지식을 subject, predicate, object 형태로 구성할 수 있음. Triple 형태의 지식표현을 통해 기존의 지식그래프에는 대용량 Triple이 활용됨

Subject	Predicate	Object
entity:00006a33abd6426fb7ac	mso:type.object.type	mso:people.person
entity:00006a33abd6426fb7ac	mso:type.object.name	"James Cameron"@en
entity:00006a33abd6426fb7ac	mso:people.person.marriage	entity:92029f0be77b449894f77
entity:92029f0be77b449894f77	mso:type.object.type	mso:people.marriage
entity:92029f0be77b449894f77	mso:people.marriage.spouse	entity:00006a33abd6426fb7ac
entity:92029f0be77b449894f77	mso:people.marriage.spouse	entity:920270b3da6d404cb4f42

Name	Instances	Facts	Types	Relations
DBpedia (English)	4,806,150	176,043,129	735	2,813
YAGO	4,595,906	25,946,870	488,469	77
Freebase	49,947,845	3,041,722,635	26,507	37,781
Wikidata	15,602,060	65,993,797	23,157	1,673
NELL	2,006,896	432,845	285	425
OpenCyc	118,499	2,413,894	45,153	18,526
Google's Knowledge Graph	570,000,000	18,000,000,000	1,500	35,000
Google's Knowledge Vault	45,000,000	271,000,000	1,100	4,469
Yahoo! Knowledge Graph	3,443,743	1,391,054,990	250	800

그림 1-2 Triple 구성과 이를 활용한 지식그래프의 예

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 다양한 분야에서 활용되는 지식그래프의 예는 아래와 같음.

회사	데이터 모델	그래프 크기	개발 단계
Microsoft (검색, Chat)	Entities/relations/attributes 가 활용 됨	~2 billion entities ~55 billion facts	상품화 수준
Google (검색)	Strong typed entities /relations 활용 되고 domain/range 추론 가능	1 billion entities 70 billion asserts	상품화 수준
Facebook (소셜 그래프)	모든 attributes/relations 는 type이 있고 search를 위한 index 가능	~50 billion entities ~500 billion assertions	상품화 수준
eBay (Product KG)	Entities/relations가 잘 구조화된 강력한 type	100 million products >1 billion triples	개발 초기 단계
IBM (Watson, Debator)	Entities/relations와 관련된 evidence 정보	다양한 크기 보유 >100 million documents >5 billion relationships >100 million entities	상품화 수준 이고 많은 고객도 활용

그림 1-3 다양한 분야에서 활용되는 지식그래프의 예

1-2. 지식그래프의 불완전성

- 지식그래프는 다양한 소스로부터 수집된 정보를 시맨틱 관계로 표현하기 때문에 대부분의 지식그래프는 정보가 누락되어 불완전성을 보임. 이는 지식그래프를 Human curator 또는 자연어처리 기반의 Machine Leaning 방식을 이용하여 구축하기 때문에 지식그래프는 많은 불완전성을 보유하고 있음. 따라서 불완전한 지식그래프를 완성하고자하는 연구를 많은 분야에서 활발히 진행 중임.

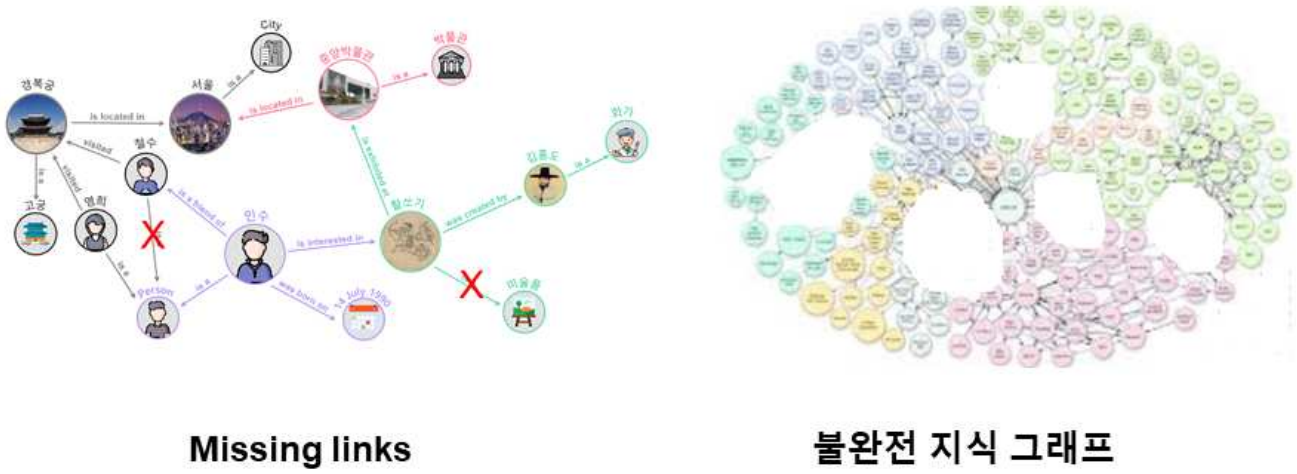


그림 1-4 지식그래프의 불완전서의 예

- Yago, Freebase, DBpedia, NELL과 같이 수십억 개의 지식을 포함하고 있는 대용량 지식 그래프들은 불완전한 데이터를 보유하고 있음. 지식 그래프는 본질적으로 불완전성을 내포함. Freebase의 경우 인물의 출생지 정보는 71%, 국적 정보는 75%가 누락되어 있음. 따라서, 지식 그래프의 불완전성을 보완이 절실함
- Human 전문가가 누락 정보를 추론할 수 있는 경험적 규칙을 정의하여 knowledge graph completion을 수행할 수 있지만, 방대한 knowledge graph에 대한 모든 규칙을 정의하는 것이 불가능함

- 지식그래프의 불완전한 지식을 자동으로 완성하기 위하여 Link Prediction이라는 방식으로 Missing된 지식그래프의 트리플을 자동 추론하는 기술을 많이 활용함. 또한 주어진 지식그래프로부터 지식그래프를 반영하는 규칙을 생성하고 생성된 규칙을 통해 새로운 트리플을 추론하여 지식을 완성하는 기술이 지식완성을 위하여 대표적으로 활용되고 있음.

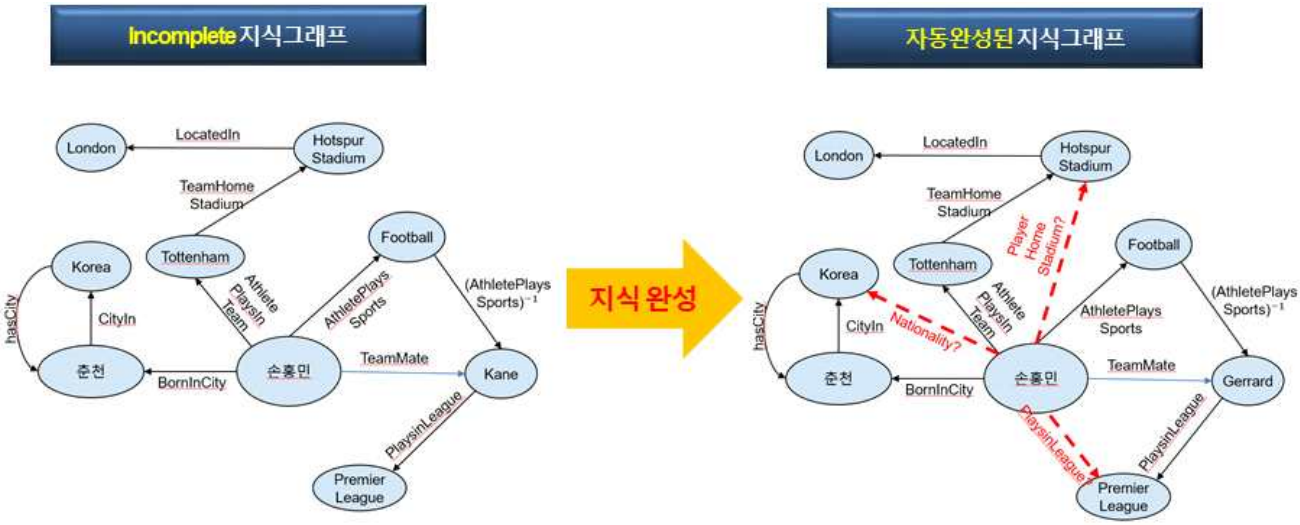


그림 1-5 지식의 불완전성을 해결하기 위한 자동 지식 완성 기술의 예

1-3. 대용량 지식그래프 분석을 통한 지식 완성연구

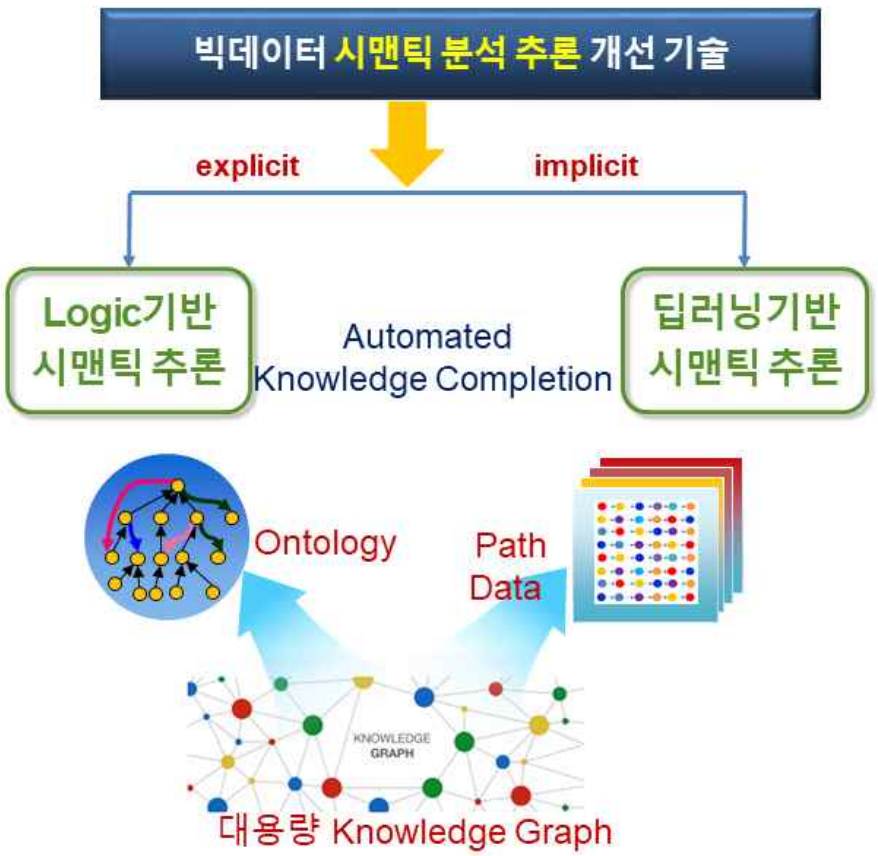


그림 1-6 지식그래프 불완전성 해결을 위한 지식완성 연구

- 대용량 지식그래프는 수많은 트리플을 보유하고 있으므로, 딥러닝 연구에 필요한 데이터 확보에 용이한 장점을 가지고 있음. 따라서 기존의 딥러닝 연구를 활용하여 지식그래프 완성에 대한 연구가 가능하고 이러한 연구가 국외에서는 현재 시작 중이므로 국제 경쟁력 있는 연구 성과를 얻을 수 있을 것으로 판단됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 대용량 지식 그래프를 대상으로 시맨틱 분석 및 추론을 수행하기 위해서는 분산 처리 프레임워크에 대한 설계 및 구축이 요구됨. Spark 기반의 분산 처리 프레임워크는 클러스터의 각 노드의 메모리를 활용하여, 낮은 지연시간으로 대용량 지식 그래프 처리가 가능함.

- 하둡은 단계별로 처리되는 데이터의 중간 결과를 클러스터에 파일로 저장하지만, Spark 기반의 분산 처리 프레임워크는 대용량 지식 그래프를 파티셔닝을 통해 각 노드의 메모리에 적재하므로 이를 활용한 대용량 지식 그래프 추론이 필요함.

- 근래에 많이 활용되는 대용량 지식그래프의 심볼릭 추론 기반 시맨틱 분석 추론을 위해서는 RDFS/OWL (Web Ontology Language)추론, SWRL(Semantic Web Rule Language)를 통해 문제를 해결하는 함. 이와 같은 심볼릭 추론은 대용량 트리플 데이터를 온톨로지 기반 방식으로 추론하므로 대용량 트리플 데이터를 처리하기 위한 Spark 기반의 프레임워크에 대안 연구가 필요함

- 현재 많은 심볼릭 지식그래프가 존재하고 있고, 이를 보다 완전하게 만드는데 많은 노력을 경주하고 있음. 또한 데이터 기반의 딥러닝 기술이 어느 정도 성숙되고 있으므로, 심볼릭 지식그래프의 자동 완성을 위해서 다양한 딥러닝 기술을 융합하는 연구가 필요함.

- 본 연구는 심볼릭 지식그래프 완성을 위해서 온톨로지기반 추론 및 SWRL 추론과 딥러닝의 임베딩 기술, LSTM기반 스토리 인코딩, Relation Network, Attention 및 Bidirectional LSTM 연구를 수행하였음. 또한 심볼릭 방식과 딥러닝 방식의 장점을 효율적으로 결합한 뉴로 심볼릭 방식을 활용한 지식 완성 연구를 수행하였음.

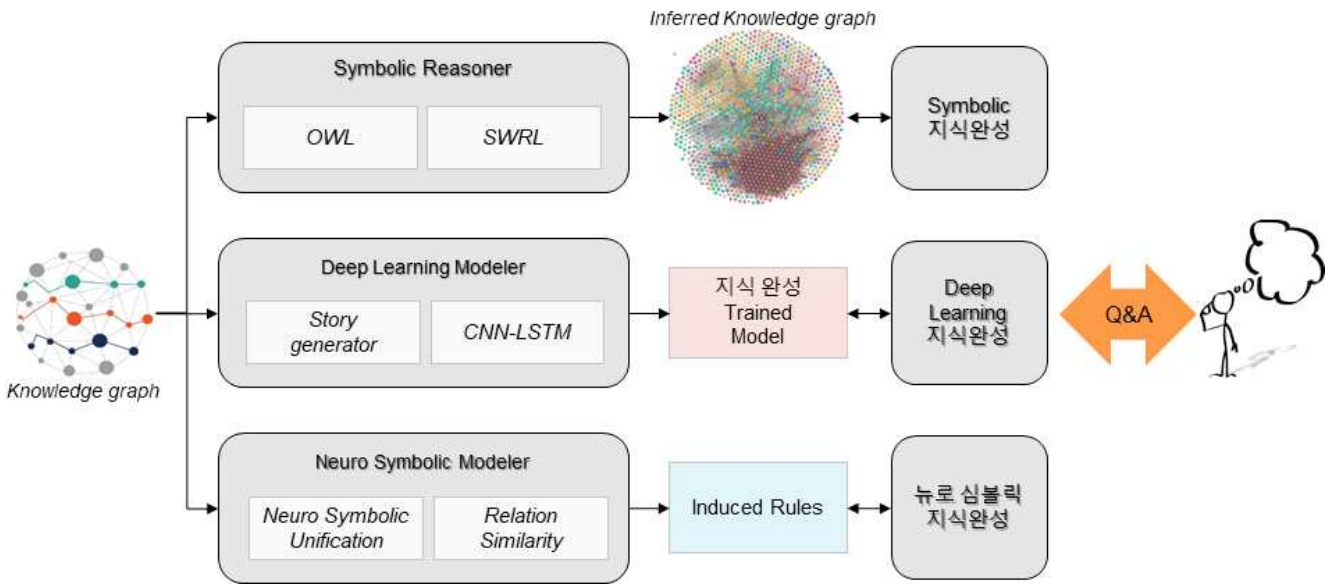


그림 1-7 수행한 연구 과제의 개념적 구조도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1-4. 뉴로 심볼릭 연구의 필요성

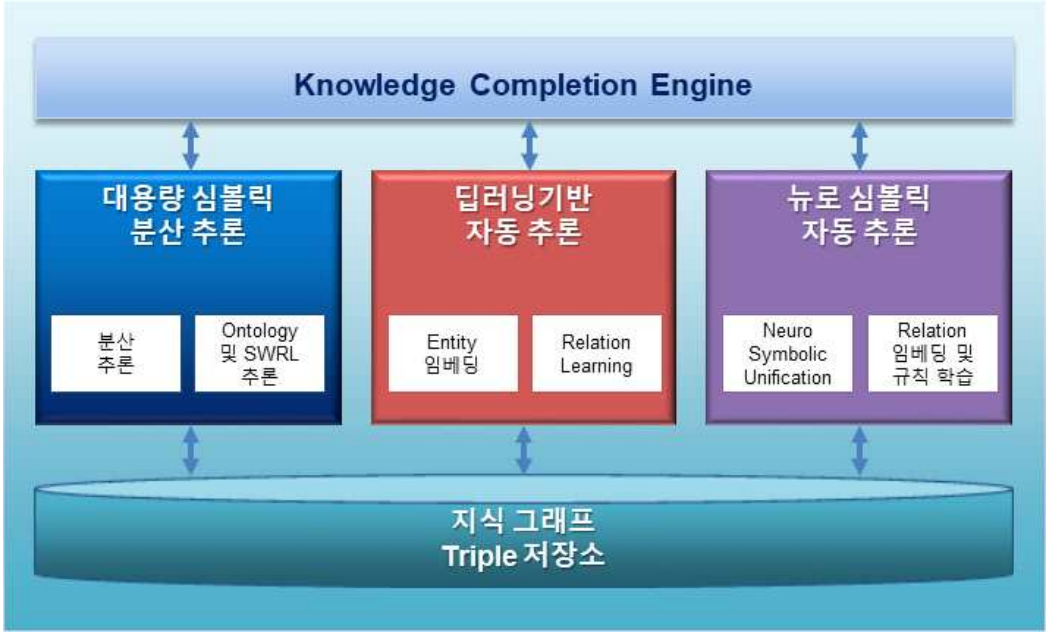


그림 1-8 심볼릭 방식과 딥러닝 방식을 결합한 뉴로 심볼릭 연구

- 데이터기반 딥러닝 연구가 괄목할 성과를 얻고 있지만 많은 컴퓨팅 리소스를 소요하는 문제로 인해 심볼릭 연구와 딥러닝 연구를 융합하는 뉴로 심볼릭 연구의 필요성이 증대되고 있음

- MIT-IBM Watson 연구소에서는 Visual QA에 심볼릭 방식과 딥러닝 방식을 융합하는 연구와 아울러 뉴로 심볼릭 추론을 위한 데이터셋도 공개하였음

- 딥러닝이 좋은 결과를 얻고 있는 Perception을 넘어서는 분야인 Commonsense 추론과 같이 뉴로 심볼릭 연구가 많은 관심을 끌고 있는 추세임

- 심볼릭 추론의 장점과 딥러닝 추론의 장점을 융합하는 연구에서는 딥러닝 방식에서 학습데이터로부터 자동 추론을 할 때 넓은 검색 공간의 효율적인 관리를 위해서 심볼릭 추론 방식을 활용하는 연구들이 많이 진행되고 있음

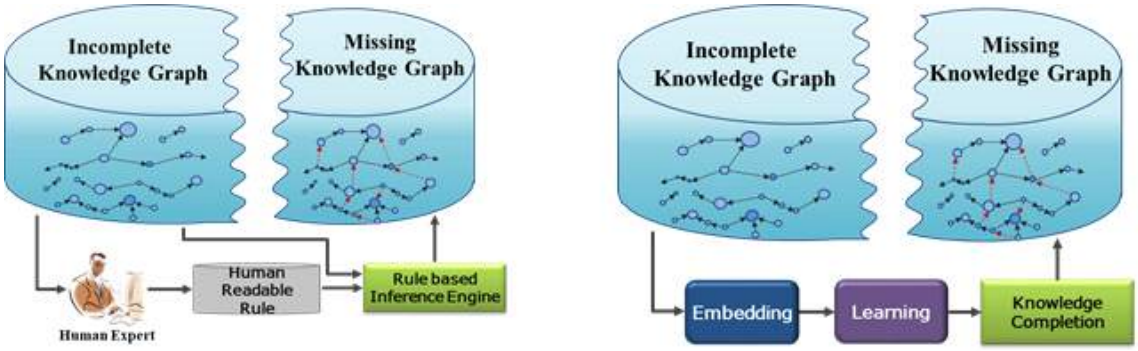
1-5. 심볼릭 추론 기반 지식그래프 완성 및 장단점

- 그림의 (a)와 같이 심볼릭 기반 방식은 Human이 불완전한 지식그래프를 완전한 지식그래프로 구축하기 위해서 Rules을 구축하고 추론엔진이 이를 추론하여 완전한 지식그래프를 구축함 예를 들어 if man(X), bornIn(X, City), contains(City,Country) -> nationality(X,Country)와 같은 규칙을 만들어 철수가 서울에서 태어났고 서울이 한국에 있으므로 철수의 국적은 한국이다 하는 지식을 추론하게 됨

- 심볼릭 추론 방식의 장점은 Human Expert가 자신의 전문 지식을 활용하여 Missing 지식그래프를 추론할 수 있는 규칙을 생성함으로써 매우 빠르게 지식그래프 완성을 수행할 수 있음

- 심볼릭 추론 방식의 단점은 Human Expert가 지속적으로 지식 완성에 개입해야하는 문제점이 있고 Human Expert가 인지하지 못한 규칙은 생성하지 못하는 단점이 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



(a) 심볼릭 추론 방식 (b) 딥러닝 추론 방식

그림 1-9 심볼릭 추론 방식과 딥러닝 추론 방식의 지식 완성

1-6. 딥러닝 기반 지식그래프 완성 및 장단점

- Relation Network와 Key Value Memory Network와 같은 딥러닝 시스템 기반 방식은 그림의 (b)와 같이 지식그래프의 Entity 및 Relation을 Embedding하여 Vector로 표현하고 Vector로 표현된 Entity 및 Relation 간의 유사도 학습을 통해 Missing된 데이터 추론함

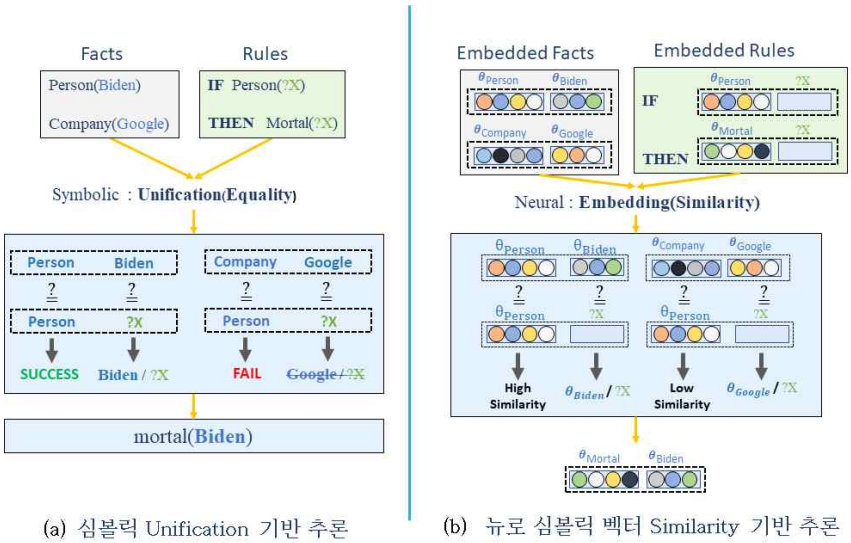
- 딥러닝 방식의 장점은 Human Expert의 개입 없이 기계가 학습하여 수행할 수 있으며, Vector 간의 연산을 통해 유사한 의미의 Entity 및 Relation를 고려하여 지식 완성을 수행할 수 있음

- 딥러닝 방식의 단점은 Vector 간의 연산을 통한 학습 방식이기 때문에 많은 컴퓨팅 리소스를 필요로 하는 문제점과 예측된 결과에 대한 설명이 불가능함

1-7. 지식그래프 완성을 위한 뉴로 심볼릭 추론 연구

- Unification은 심볼릭 추론에서만 가능하고 딥러닝에서는 Unification 개념이 없음. 그러므로 심볼릭 추론과 딥러닝 추론 방식을 결합하기 위해서 본 연구에서는 뉴로 심볼릭 추론을 제안하고자 함

- 뉴로 심볼릭 추론에서는 심볼릭 추론의 Unification과 딥러닝의 임베딩 백터를 같이 활용하는 방안을 제안함. 그림(a), 그림(b)는 기존의 심볼릭 Unification과 본 연구에서 제안하는 심볼릭 Unification과 딥러닝의 Embedding을 융합하는 뉴로 심볼릭 추론 아이디어를 보여 주고 있음.



(a) 심볼릭 Unification 기반 추론 (b) 뉴로 심볼릭 벡터 Similarity 기반 추론

그림 1-10 뉴로 심볼릭 추론 아이디어방식의 개념

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2. 연구개발과제의 수행 과정 및 수행 내용

2-1. 연구개발과제의 최종 목표

가. 최종 목표



그림 2-1 본 연구에 대한 지식완성 핵심 기술 연구 목표

○ 온톨로지 기반 지식 완성
- RDFS 기반 지식그래프 완성
- OWL 기반 지식그래프 완성
- SWRL 기반 지식그래프 완성

○ 딥러닝 기반 지식 완성
- 지식그래프 Embedding 방식 연구
- Memory Network 기반 딥러닝 연구
- Relation Network 기반 지식 완성 연구

○ 뉴로 심볼릭 기반 지식 완성
- 심볼릭 및 딥러닝 방식을 결합한 하이브리드 방식 연구
- Relation 유사도 학습 기반 Rule Induction 방식
- 뉴로 심볼릭 방식 기반 지식 완성 연구

○ 빅데이터 시맨틱 분석 추론 개선 기술 연구를 위해서 심볼릭 및 딥러닝 융합 방식을 이용한 대용량 지식그래프 추론 기술 연구
- 최소 500M 트리플 보유하는 빅 지식그래프에 대한 250K Triple/sec 추론 속도 및 지식 완성도 자동 추론 정확도 95% 이상

○ End Product
- 분산 인메모리 기반 Spark 환경에서 빅데이터 처리 엔진
- 심볼릭 및 딥러닝 융합 기반 대용량 지식그래프 자동 추론 알고리즘(SW)
- 자동 지식 추론을 위한 데이터 셋 (Data)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 당해(연도) 연구 개발 목표 및 결과

세부연구명	연구개발 수행 내용	연구 결과
십볼릭 기반 지식 그래프 자동 완성 연구	• 기존의 십볼릭 방식의 대규모 추론 연구 수행 • Spark 기반 온톨로지 추론 엔진 설계 • Spark 기반 SWRL추론 엔진 설계 • 대규모 온톨로지 추론용 Spark 엔진 설계	- Spark 프레임워크에서 동작하는 대규모 휴리스틱 규칙 추론 엔진 개발을 성공적으로 수행함 - 대규모 규칙을 분산처리하기 위한 구조 개발을 효율적으로 수행함 - 휴리스틱 규칙에 대한 partial order를 구하여 효율적으로 추론하는 기술개발을 성공적으로 수행함 - Incremental 방식으로 휴리스틱 규칙 추론 기술 개발을 성공적으로 수행함
	• 효율적인 OWL-Horst 추론을 위한 규칙 순서 재정의 • 효율적인 SWRL 추론을 위한 분산 병렬 SWRL 추론 구축 • 최적화를 위한 온톨로지 추론 방식 활용 • Spark DataFrame을 활용하여 대용량 지식 그래프 추론 통합 시스템 구축	- Spark DataFrame을 활용한 대용량 지식 그래프를 추론하기 위한 분산 추론 시스템 개발을 성공적으로 수행함 - 최적화를 위해 브로드캐스트 및 check point 활용을 통해 효율적인 최적화 방식 정의 및 설계를 통한 개발을 성공적으로 수행함
	• Github에 W3C 표준 언어로 제작된 공개 데이터를 이용한 빅데이터 추론 벤치마크 데이터 생성 및 공개	- Incomplete 지식 그래프 추론을 위한 학습 데이터와 테스트 데이터를 Github을 통하여 공개 수행 - 6종류의 빅데이터 추론 벤치마크 데이터 생성 및 공개 수행
딥러닝 기반 지식 그래프 자동 완성 연구	• 딥러닝을 위한 지식그래프 임베딩 설계 • 딥러닝을 위한 관계 임베딩 설계	- Path 임베딩과 관계 학습을 위한 딥러닝 시스템 아키텍쳐 설계 및 개발을 성공적으로 수행함 - 딥러닝 기반으로 지식 그래프 완성을 위

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	• 딥러닝 기반 지식 완성 시스템 설계	한 양방향 LSTM과 Attention 학습 모델 개발을 성공적으로 수행함 - 지식 완성이 필요한 missing entity 추론을 위해 target relation의 우회 경로추출 작업을 수행함
	• Random Walk를 이용한 경로 탐색 • Feature Matrix 생성 및 Random Walk Probability 계산 • 경로 기반 Story 데이터 생성	- PRA(Path Ranking Algorithm)을 이용해 target relation의 relation path 추출 방식 개발을 성공적으로 수행함 - 추출된 relation path 중 학습에 도움이 될 수 있는 path들을 필터링하는 작업 수행 - 학습 트리플과 추출된 우회경로들을 이용해 story 형태의 학습 데이터 생성 - 학습 및 테스트 데이터인 트리플 <h, r, t>의 h와 r을 question으로 사용하고, t를 answer로 변경하고, question에 대한 answer를 예측할 수 있는 근거에 해당하는 context에 path 정보를 포함하는 Story 데이터 생성
	• Story 데이터를 이용한 관계 네트워크 학습 • 지식 그래프 자동 완성을 위한 경로 기반 관계 네트워크의 성능 실험	- 추출된 path를 이용해 context 데이터를 구성할 때, 중간 entity는 제거하여 데이터의 효율성을 향상시키고, 학습 효과를 강화하는 방식의 네트워크 학습 개발을 성공적으로 수행함 - 2개의 MLP인 g-theta와 f-phi로 구성된 relation network를 통해 missing link를 예측할 수 있는 relation 모델 학습을 성공적으로 수행함 - f-phi MLP를 통해 question과 각 우회 경로들 사이의 관계 학습을 수행함 - g-theta MLP를 통해 각 question, 우회경로들과 누락된 entity인 answer를 예측할 수 있는 관계 학습을 성공적으로 수행함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		- 최근 논문 중 높은 성능을 보이는 KG-BERT에 비해 평균 11% 높은 MR성능을 도출함 - Hits@10의 경우 평균 29% 높은 성능을 나타내었음
십볼릭 및 딥러닝 융합 방식 기반 지식 그래프 자동 완성 연구	• 지식그래프 완성을 위한 심볼릭 추론 엔진 설계 • 심볼릭 추론을 위한 규칙 및 데이터 정의 • 임베딩을 위한 규칙 및 지식 그래프의 각 데이터 전처리 학습	- 심볼릭 방식의 추론 메커니즘인 backward chaining 방식을 통해 지식 그래프에 대한 unification 수행 기술 개발을 성공적으로 수행함 - 규칙 Template 정의 및 지식그래프의 데이터 구조 정의 - 규칙의 릴레이션에 대한 임베딩을 위한 규칙 설계 및 개발을 성공적으로 수행함 - 임베딩 학습의 성능 향상을 위한 Augmentation 및 Negative 데이터 생성을 위한 방안 설계 및 개발을 성공적으로 수행함
	• 뉴로 심볼릭 unifica tion 모델 학습을 위한 심볼릭 • unification과 지식그래프 임베딩 통합환경 설계 • 유사도 학습을 위한 Function 정의 및 설계 • 뉴로 심볼릭 기반 규칙 추론을 통한 지식 완성 성능 평가 실험 수행	- 기존 방식을 개선하기 위한 릴레이션 기반의 임베딩 방식 개발을 성공적으로 수행함 - 규칙 추론 학습시 오차 계산에 필요한 negative log-likelihood 오차 함수 사용 및 학습 데이터 정의 - 기존 뉴로 심볼릭 기반 연구인 NTP에 비하여 3배~7배 많은 규칙을 추출하는 성능을 보임 - 추출된 규칙을 통해 추론된 트리플의 경우 기존 연구 대비 13%~66% 만큼 더 많은 수의 트리플 추론 성능을 보임

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2-2. 연구개발과제의 연구 내용

가. 1차년도 개발 내용 및 범위

1) 개발 목표

대용량 지식 그래프 시맨틱 추론 기반 지식 자동 완성 핵심 기술 연구

- Spark 기반 대용량 Incomplete 지식그래프 완성을 위한 심볼릭 추론 엔진 구축
  - 대용량 지식 그래프를 대상으로 하는 RDFS/OWL-Horst 추론 연구
  - Spark 프레임워크를 활용한 지식그래프 처리
  - 대용량 불완전 지식그래프 기반 분산 SWRL 추론 엔진 개발
- Incorrect 트리플 검출 연구
  - 딥러닝 기반의 대용량 지식그래프 오류 검출 모델 연구

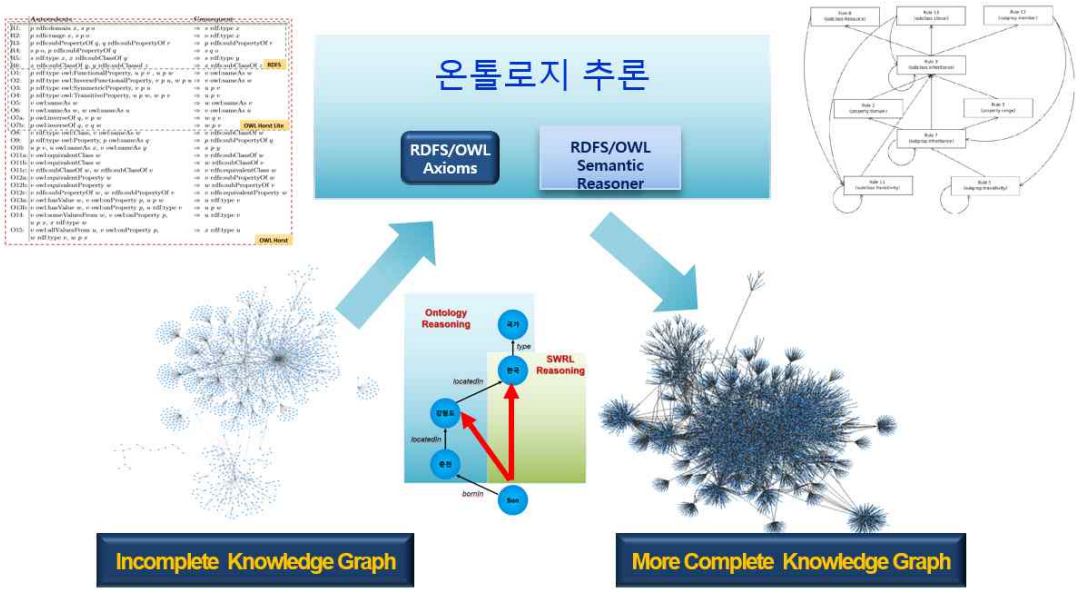


그림 2-2 온톨로지 기반 대용량 심볼릭 추론 기반 지식 완성

2) 개발 내용 및 범위

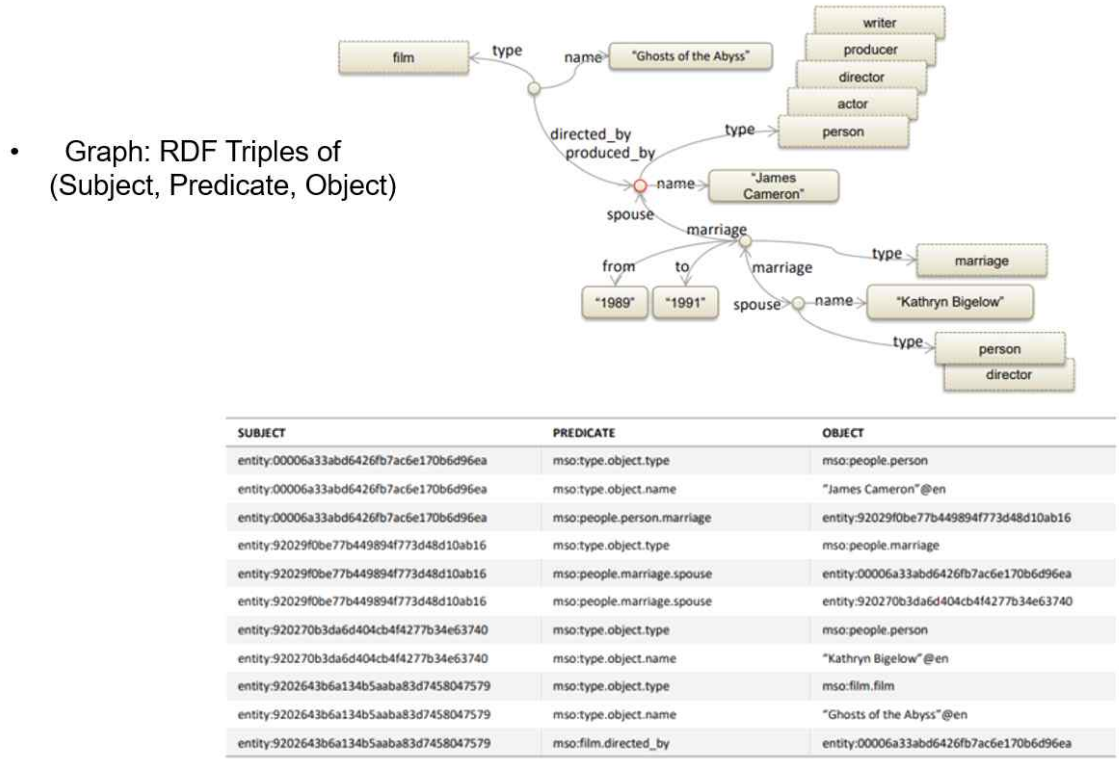
(1) Spark 기반 대용량 Incomplete 지식 그래프 완성을 위한 심볼릭 추론 엔진 구축

- Spark 기반 대용량 지식그래프를 대상으로 하는 RDFS 추론
  - W3C는 웹의 자원 정보를 표현하기 위한 RDFS(RDF Schema)를 제안하면서 특별한 의미를 갖고 있는 몇 가지 어휘를 정의하였음. RDFS 추론 규칙은 스키마인 T-Box와 인스턴스인 A-Box로 구성된 온톨로지 모델에서 각 요소간의 관계를 통해서 새로운 데이터를 추론할 수 있는 13가지의 정의된 규칙임. 아래 그림과 표는 RDFS의 13가지 추론 규칙을 나타냄.

표 1 RDFS 추론 규칙

Rule	If	Then
rdfs2	*p rdfs:domain x*, *s p o*	*s rdf:type x*
rdfs3	*p rdfs:range x*, *s p o*	*o rdf:type x*
rdfs5	*p rdfs:subPropertyOf q*, *q rdfs:subPropertyOf r*	*q rdfs:subPropertyOf r*
rdfs7	*s p o*, *p rdfs:subPropertyOf q*	*s q o*
rdfs9	*s rdf:type x*, *x rdfs:subClassOf y*	*s rdf:type y*
rdfs11	*x rdfs:subClassOf y*, *y rdfs:subClassOf z*	*x rdfs:subClassOf z*

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



SUBJECT	PREDICATE	OBJECT
entity:00006a33abd6426fb7ac6e170b6d96ea	mso:type.object.type	mso:people.person
entity:00006a33abd6426fb7ac6e170b6d96ea	mso:type.object.name	"James Cameron"@en
entity:00006a33abd6426fb7ac6e170b6d96ea	mso:people.person.marriage	entity:92029f0be77b449894f773d48d10ab16
entity:92029f0be77b449894f773d48d10ab16	mso:type.object.type	mso:people.marriage
entity:92029f0be77b449894f773d48d10ab16	mso:people.marriage.spouse	entity:00006a33abd6426fb7ac6e170b6d96ea
entity:92029f0be77b449894f773d48d10ab16	mso:people.marriage.spouse	entity:920270b3da6d404cb4f4277b34e63740
entity:920270b3da6d404cb4f4277b34e63740	mso:type.object.type	mso:people.person
entity:920270b3da6d404cb4f4277b34e63740	mso:type.object.name	"Kathryn Bigelow"@en
entity:9202643b6a134b5aaba83d7458047579	mso:type.object.type	mso:film.film
entity:9202643b6a134b5aaba83d7458047579	mso:type.object.name	"Ghosts of the Abyss"@en
entity:9202643b6a134b5aaba83d7458047579	mso:film.directed_by	entity:00006a33abd6426fb7ac6e170b6d96ea

그림 2-3 지식 그래프 표현의 예

- RDFS 규칙을 이용하여 온톨로지 추론을 진행할 때, 추론 규칙의 순서는 성능에 직접적인 영향을 주기 때문에 매우 중요함. 따라서 여러 규칙들 사이의 독립성과 종속성을 분석하고, 루프가 생기지 않도록 효율적인 추론순서를 결정하는 작업이 반드시 필요함.

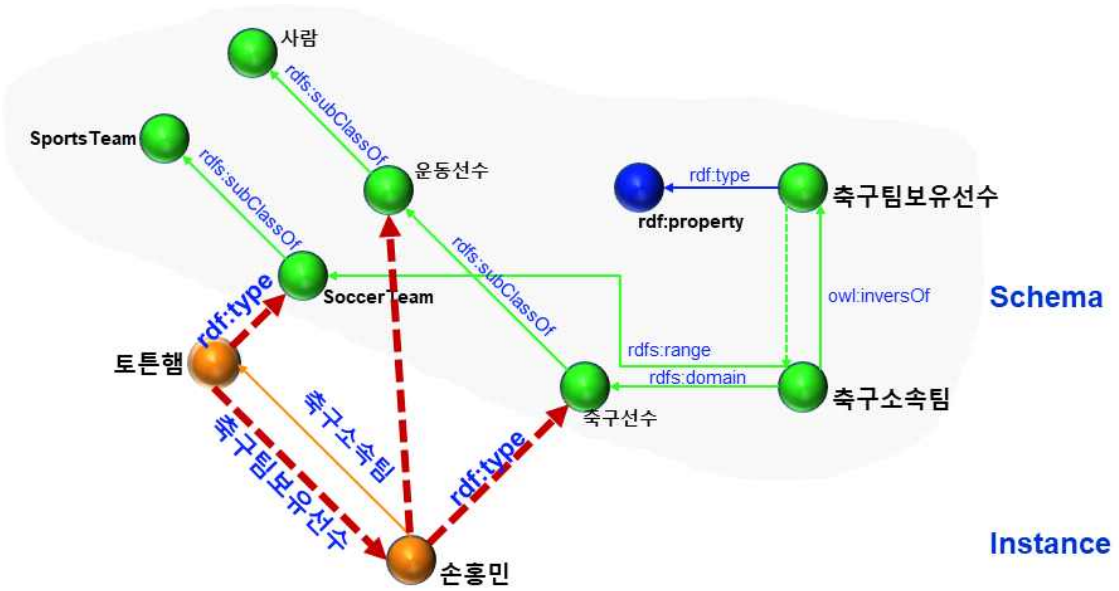


그림 2-4 온톨로지 스키마 추론의 예

- RDFS 추론에서는 한 규칙을 통해 추론된 새로운 트리플이 다른 규칙의 조건을 만족하여, 또 다른 트리플이 추론될 수 있음. 따라서 규칙 간의 종속성을 파악하여, 적용 순서를 정하는 것이 중요함. 다른 규칙에 영향을 줄 수 있는 규칙들을 먼저 처리하고, 서로 독립적인 규칙들은 같은 단계에서 처리하였음.

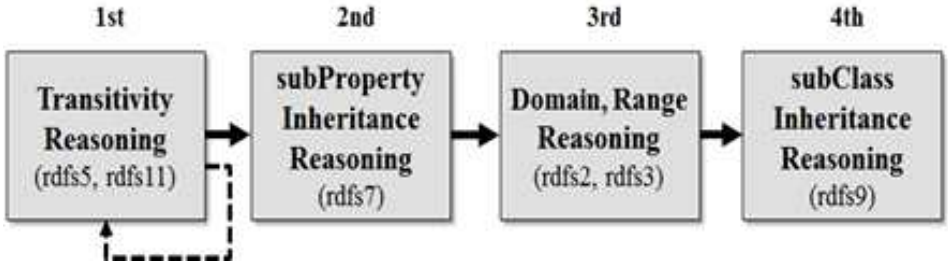


그림 2-5 RDFS 추론 순서

- Spark 프레임워크를 활용한 지식그래프 처리
  - 대용량 지식 그래프 완성을 위한 분산처리를 위해 빅데이터 처리를 위한 고성능 분산 클러스터링 플랫폼인 Spark를 사용하였음. 기존의 빅데이터 처리 플랫폼인 Hadoop은 Map-Reduce 작업을 Disk I/O 기반으로 수행하기 때문에 성능의 한계가 있음. Spark는 Disk I/O의 한계와 복잡한 데이터 처리를 요구하는 기계학습과 그래프 구조처리의 한계를 극복하기 위해 인메모리 기반으로 개발 되었으며 본 과제에서 이를 활용한 연구를 진행하였음.

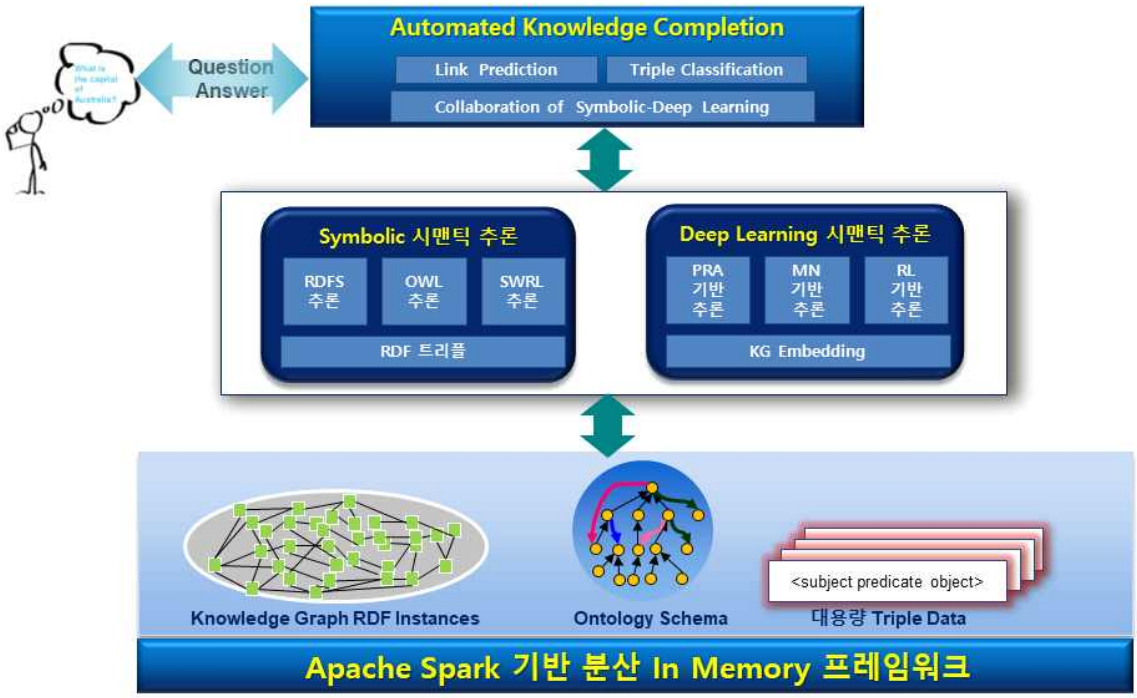


그림 2-6 Apache 스파크 기반 분산 인메모리 프레임워크

  - 스파크는 빅데이터 처리를 위해 RDD(Resilient Distributed Dataset)라는 데이터셋을 지원함. 여러 종류의 리소스로 부터 만들어 질 수 있고, 분산 노드에 최적화된 데이터의 집합으로 Fault-tolerant를 위해 변형 불가능한(immutable) 특징이 있으며, 복구를 위해 히스토리를 기록할 수 있음. 본 과제에서는 지식 그래프를 여러 개의 RDD로 구성하여 분산 추론 및 Incomplete 지식 완성에 사용하였음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

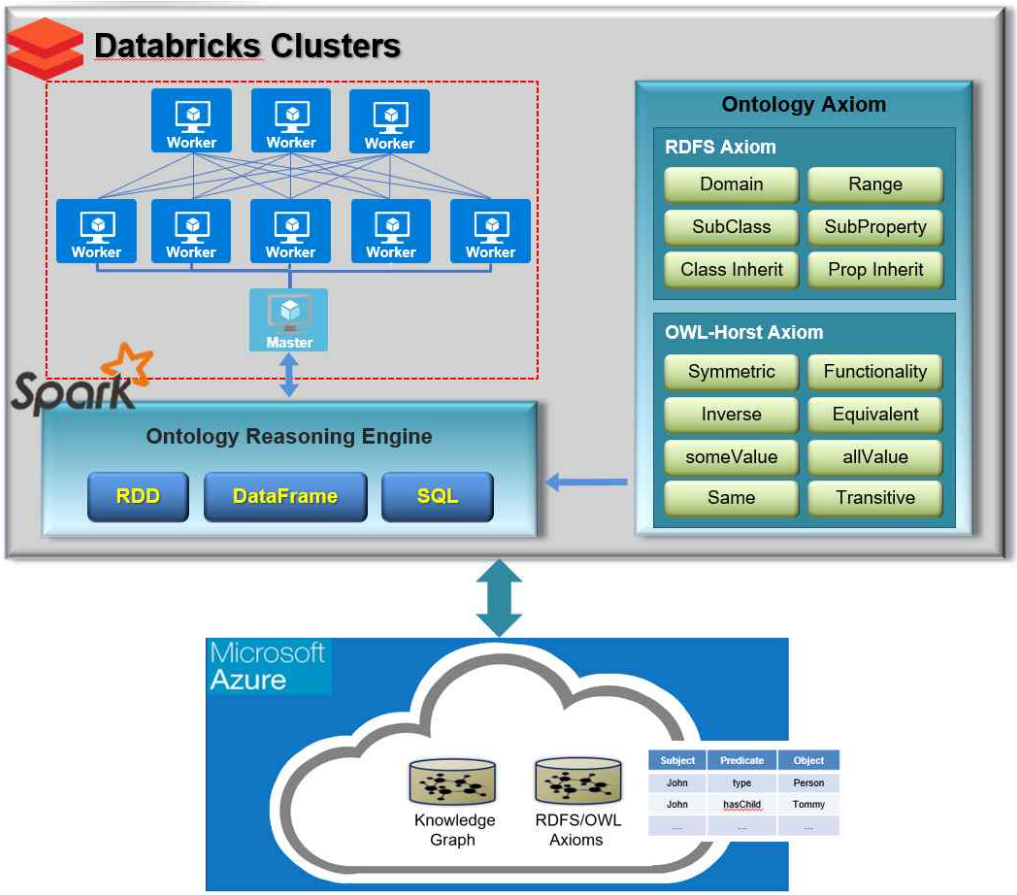


그림 2-7 대용량 지식그래프 분산 추론 엔진 구조도

- Spark DataFrame 기반 OWL-Horst 추론 엔진 구축
  - Spark는 범용적이고 빠른 빅데이터 연산 작업을 수행하도록 설계된 분산 클러스터링 플랫폼이며, 여러 가지 엔진을 제공함. 본 과제에서는 다양한 엔진 중 DataFrame을 활용하여 OWL-Horst 추론 엔진을 구축함. 하나의 마스터 노드와 여러 개의 슬레이브 노드로 구성된 Spark cluster를 사용하여 분산 추론을 수행함.

  - Spark DataFrame은 기존 데이터베이스 테이블과 같이 행과 열로 이루어져 있으며, 열은 해당 테이블의 속성을 의미하고, 행은 한 객체에 대한 정보를 가지고 있음. Spark RDD와 비교했을 때, RDD는 스키마 개념이 없기 때문에 구조화된 데이터와 구조화 되지 않은 데이터를 함께 저장하여 DataFrame 보다 효율성이 매우 떨어짐. 지식 그래프는 주어, 술어, 목적어 형태인 트리플로 구조화되어 있음. 따라서 지식 그래프 추론을 수행하기 위해 RDD에 비해 DataFrame이 훨씬 효율적으로 처리할 수 있으며 성능 차이의 가장 큰 이유가 됨. 또한 DataFrame은 최적화 엔진인 카탈리스트 옵티마이저를 사용하여 데이터를 효율적으로 처리함. 예를 들어 두 개의 데이터를 조인 연산을 수행하고 필터링 연산을 수행한다고 했을 때, 조인할 데이터의 양을 줄이기 위해 필터링 연산을 조인 연산보다 먼저 수행하도록 함.

  - OWL-Horst 추론에서는 각 추론 항목에 대한 구조가 중요함. 따라서 22가지 모든 규칙 간의 독립성과 종속성을 고려하여 다음과 같이 추론 순서를 배치함. 먼저 스키마 추론의 규칙들은 다른 규칙들의 결과가 조건으로 사용되지 않으므로 가장 먼저 수행함. 인스턴스 추론은 추론 결과가 인스턴스 추론 규칙들의 조건으로 다시 사용되기 때문에 더 이상 추론되는 트리플이 없을 때까지 반복 수행함. Type 추론에서는 추론된 인스턴스 트리플을 통해 Type 추론을 수행하여 Type과 관련된 트리플을 추론하며, sameAs 추론을 통해 sameAs 트리플을 추론함. 예외 인스턴스 추론은 관련된 추론과 같이 수행하면 비효율적인 반복이 이루어지는 규칙들로 묶었으며 조건으로 Type과 sameAs 트리플을 받기 때문에 가장 마지막에 수행함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

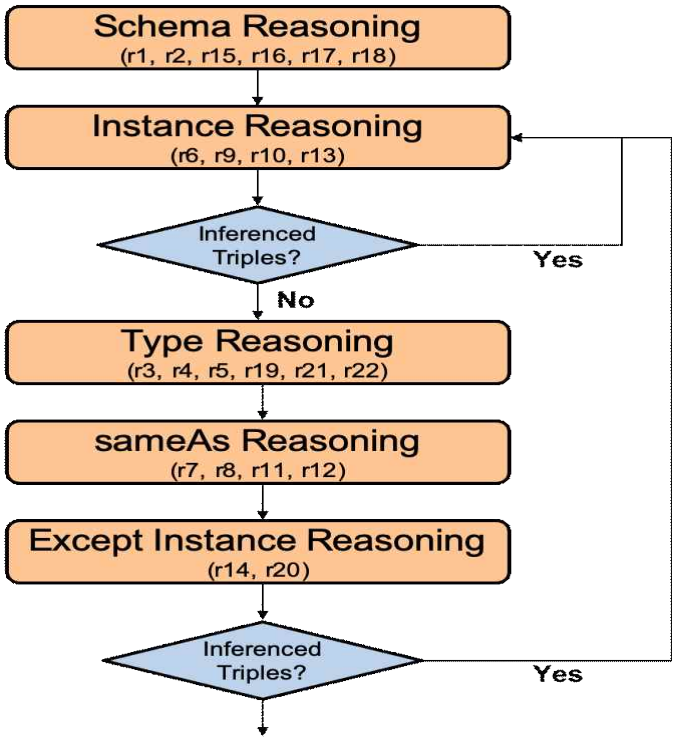


그림 2-8 OWL Horst 추론 구조

- Transitive Closure 연산은 내부적으로 더 이상 추론되는 트리플이 없을 때 까지 반복함. 예를 들어 조건은 (p type Transitive_Property), (u, p, ω) (ω, p, υ) 이고 결론은 (u, p, υ)인 규칙이 있을 때, Transitive Closure의 특징을 보면 (u, p, w), (w, p, v) 트리플에서 첫 번째 트리플의 목적어와 두 번째 트리플의 주어가 같아야 하고, 첫 번째 트리플의 주어와 두 번째 트리플의 목적어와는 달라야 Transitive Closure를 통한 (u, p, v) 트리플이 추론될 수 있음. 이를 토대로 Transitive Closure 연산은 데이터프레임의 조인 연산을 통해 효율적으로 수행할 수 있음.

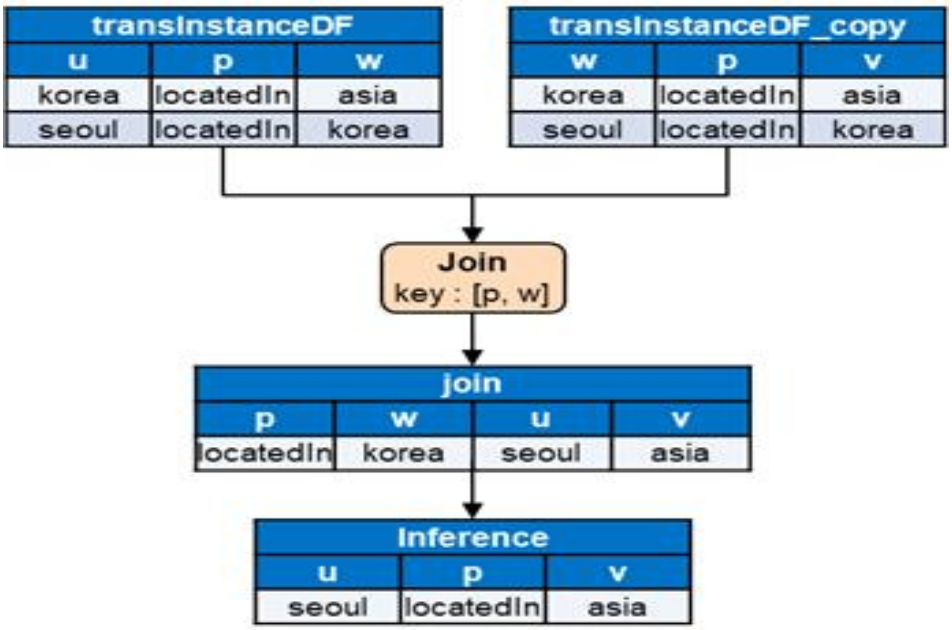


그림 2-9 조인 기반 Transitive Closure 연산 예

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 대용량 불완전 지식 그래프를 경험적 지식을 바탕으로 정의된 규칙들을 사용하여 분산 추론할 수 있는 SWRL 추론 엔진 개발
  - 추론 시스템의 입력은 SWRL 형태로 작성된 규칙들과 N-Triple 형태의 온톨로지 데이터가 사용되고, 규칙 분석(Compile) 단계에서는 입력된 규칙들을 분석하여 각 규칙별로 수행이 필요한 작업들의 순서를 결정하고, 분산 추론에 적합한 형태로 저장함. Deliberation에서는 분석된 규칙 정보를 이용하여 추론될 수 있는 데이터들을 같은 노드에 그룹화하고, 파티셔닝하는 작업을 수행함. 마지막으로 분석된 규칙들을 통해 네트워크 셔플링 없이 각 노드에 존재하는 데이터들로 새로운 트리플을 추론함.

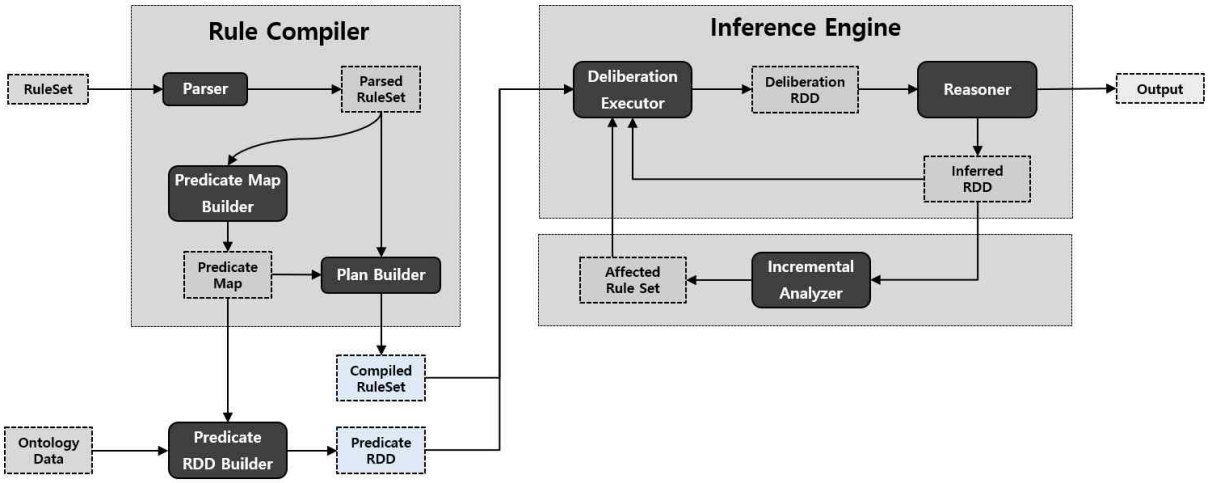


그림 2-10 Spark 기반 대용량 SWRL 추론 상세 흐름도

  - 추론되거나 추가된 새로운 데이터가 존재하는 경우 해당 데이터를 분석하여 점증적 추론을 위한 데이터와 규칙들을 선별함. 새로운 데이터로 인해 추가적인 추론이 필요하지 않을 때 까지 추론 작업이 반복 수행됨. 실제 추론을 수행하기 위해서는 인간이 읽을 수 있는 SWRL 형태의 규칙을 기계가 이해할 수 있는 형태로 변형이 필요하다. 대용량 데이터를 대상으로 하기 때문에 후보군의 크기를 가장 크게 줄여줄 수 있는 조건들을 선택하는 것이 효율적임.

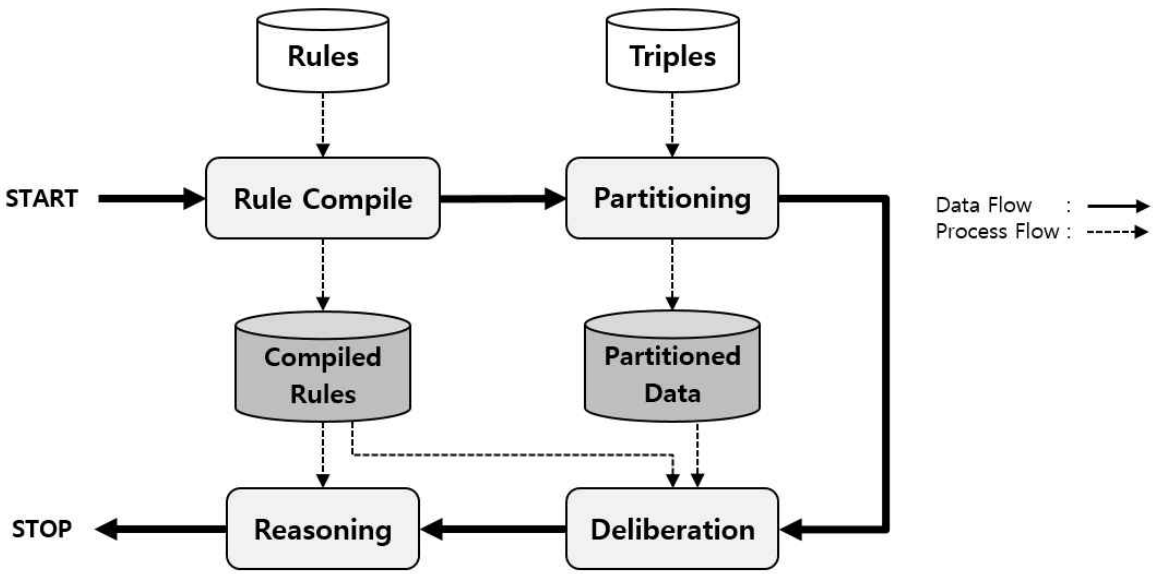


그림 2-11 Spark 기반 SWRL 분산 추론 엔진 흐름도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 주어, 술어, 목적어로 구성된 트리플 데이터는 추론 규칙의 조건부에서 사용되는 특정 값들과의 비교를 통해 추론될 가능성이 있는 데이터들을 선별할 수 있음. SWRL 기반의 추론 규칙에서는 변수가 아닌 값으로 표현된 술어가 가장 많은 비교 대상임. 따라서 온톨로지 데이터를 술어를 기준으로 데이터를 그룹화하고, 파티셔닝하면 높은 성능을 기대할 수 있음. 술어 별로 데이터를 저장함으로써 추가적인 추론 작업 등에서 데이터 선택이 용이하며, 점진적 추론에서는 특정 술어에 해당하는 데이터만 메모리에 적재하거나 디스크에 저장하여 효율적인 관리가 가능함.
-

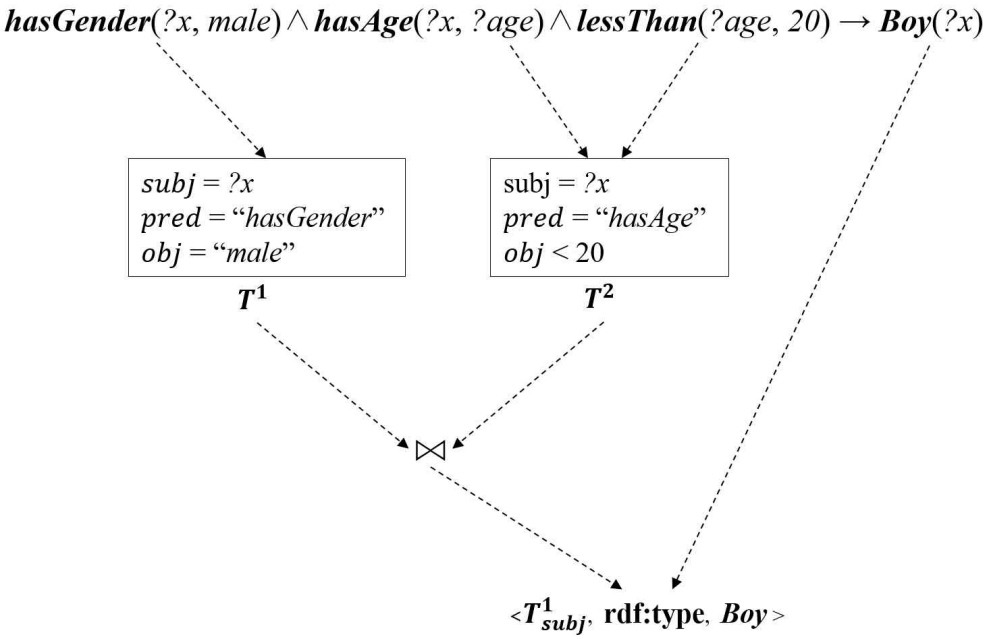


그림 2-12 SWRL 규칙 분석의 예

- 술어를 기준으로 그룹화된 데이터의 파티션은 여러 노드에 저장되기 때문에 그룹화된 데이터를 파티셔닝 할 때 분석이 완료된 추론 규칙의 조건 정보를 통해 특정 규칙 추론에 필요한 파티션들을 하나의 노드에 저장하여 이후 추론을 위한 작업에서 네트워크 셔플링을 감소시킬 수 있음. 분산 환경의 클러스터를 구성하고 있는 각 노드는 특정 규칙에서 요구되는 데이터들을 파티션 형태로 저장함. 추론 가능성이 있는 데이터는 하나의 노드에 저장되어 있고, 앞서 분석이 완료된 추론 규칙들은 각 노드의 메모리에 브로드 캐스팅하여 적재할 수 있음. 따라서 실제 추론 단계에서 각 규칙마다 조건부에 해당하는 데이터들을 찾는 Deliberation과 그 결과를 통해 실제 새로운 데이터를 생성하는 추론 단계에서는 네트워크 셔플링 없이 진행이 가능함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

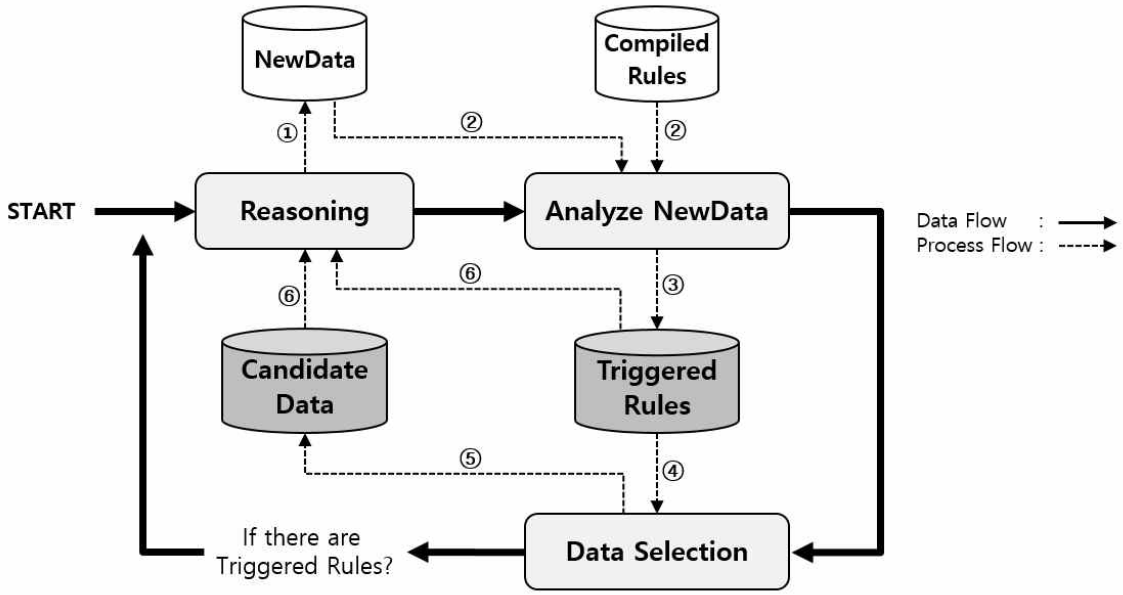


그림 2-13 Incremental 분산 추론 흐름도

- 점진적 추론은 새로운 트리플 데이터가 추론되거나 추론 후에 새로운 데이터가 추가 되었을 때 기존 데이터와 추가된 데이터를 이용하여 더 이상 새로운 데이터가 추론되지 않을 때까지 반복적으로 추론하는 것임.

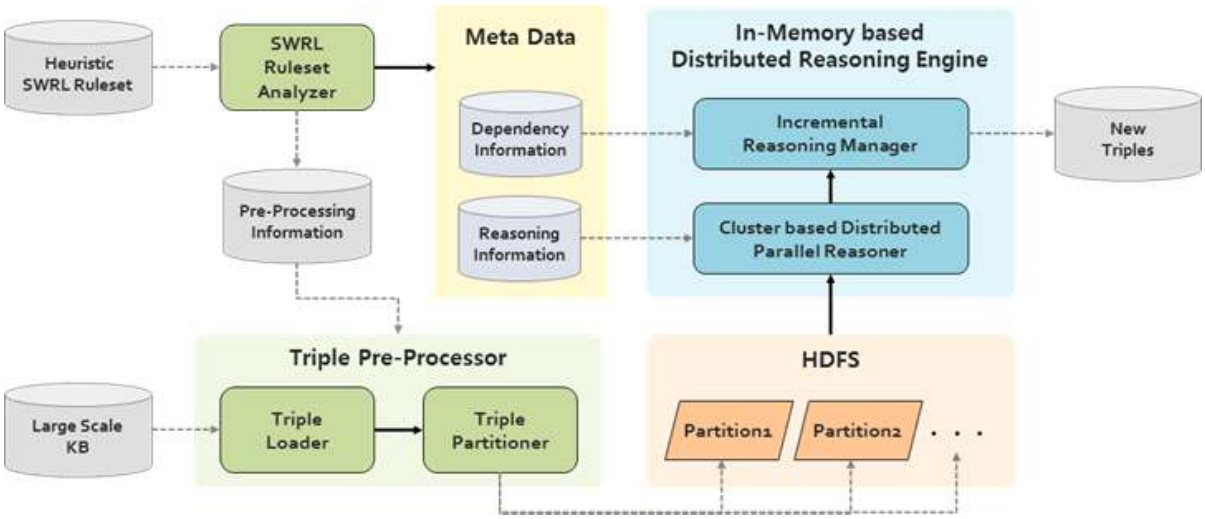


그림 2-14 대용량 지식 그래프 SWRL 추론 엔진의 전체 흐름도

- Spark DataFrame 기반의 SWRL 추론 엔진 구축
  - 클라우드 컴퓨팅 환경에서 분산 추론을 위해 Microsoft Azure Cloud Services 플랫폼에서 SWRL 추론을 수행함. 구조화된 대용량 지식 그래프를 효율적으로 처리하기 위해 Spark DataFrame을 활용하였으며, 지식 그래프의 인스턴스 트리플과 추론 수행에 요구되는 형태로 변형한 SWRL 규칙 정보들을 DataFrame으로 표현함. 이러한 DataFrame을 1개의 마스터 노드와 4개의 슬레이브 노드로 구성된 Spark cluster를 사용하여 분산 추론을 수행하여 종래 기술보다 월등한 추론 성능을 얻음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

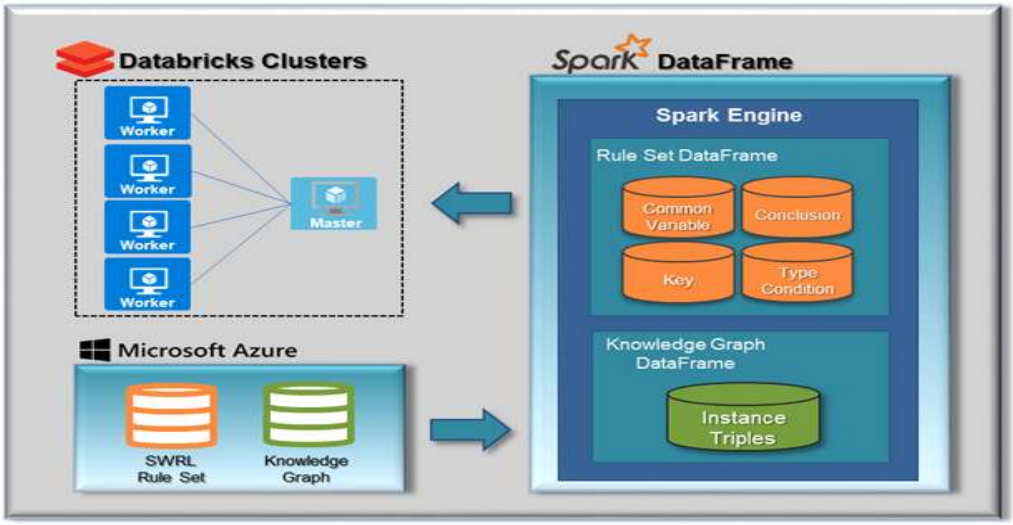


그림 2-15 Spark DataFrame을 활용한 분산 SWRL 추론 구조도

- SWRL추론에서는 SWRL Rule set을 분석하여 Pre-Processing DataFrame, Reasoning DataFrame을 생성하는 단계와 생성된 DataFrame을 참조하여 추론을 수행하는 추론 단계로 이루어짐. 참조 DataFrame 생성 단계는 SWRL 규칙만을 사용하여 추론을 수행할 때 참조할 5가지의 DataFrame을 생성하고 이를 참조하여 입력 트리플에 대한 전처리 작업을 수행함. 이 후 추론 DataFrame을 참조하여 조건의 개수에 따라 반복 추론하고, 각 반복마다 새로운 트리플을 추론함.

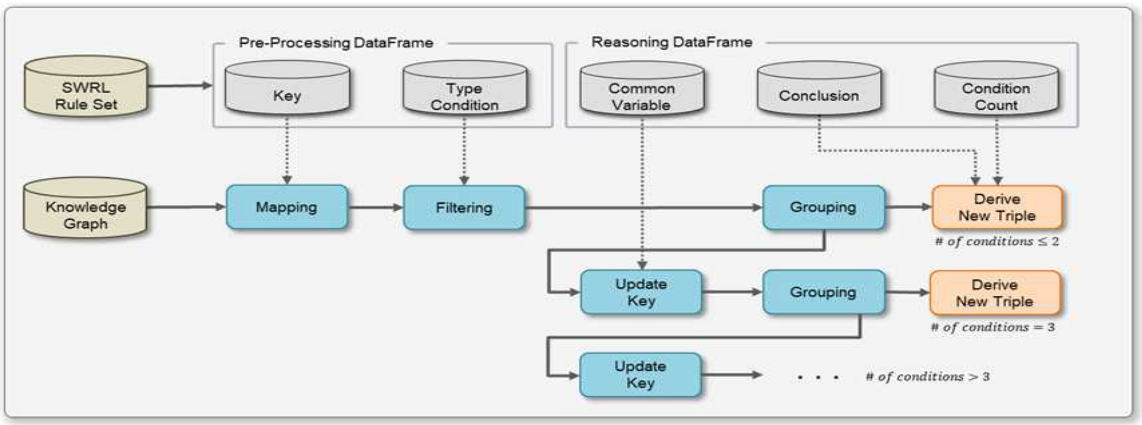


그림 2-16 SWRL 추론 엔진 흐름도

- 여러 참조 DataFrame 중 Key DataFrame은 모든 규칙에 대해 각 조건마다 술어를 기준으로 정보를 저장하며 규칙 번호, 공통 변수 위치, 조건의 인덱스 정보를 담고 있음. 예를 들어 아래와 같은 규칙에 대한 Key DataFrame을 생성한다고 하면 다음과 같음. 다음 표에서 첫 번째 행을 예를 들어 보면 'hasSibling'은 Rule 1의 조건으로 속해있고 목적어와 두 번째 조건의 주어가 공통 변수이므로 공통 변수의 위치는 object로 표현되며 Rule 1의 첫 번째 조건이기 때문에 조건 인덱스는 1로 표현됨.

Rule 1 :

$$hasSibling(?x, ?y) \wedge hasFather(?y, ?z) \wedge spouse(?z, ?w) \rightarrow hasMother(?x, ?w)$$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Predicate	Rule#	ComVar	CondIdx
hasSibling	1	object	1
hasFather	1	subject	2
spouse	1	subject	3

- 효과적인 추론을 수행하기 위한 최적화 방법
  - OWL-Horst 추론엔진 및 SWRL 추론 엔진은 Spark DataFrame의 Join 연산을 통해 추론을 수행함. 하지만 Join 연산을 수행하면 각 노드 간의 셔플링이 발생하여 성능이 저하됨. 이를 해결하기 위해 브로드캐스트를 사용하여 셔플링 문제를 해결함. 브로드캐스트를 사용했을 경우에 아래 오른쪽 그림과 같이 상대적으로 작은 데이터를 분산하지 않고 미리 지정한 파티션 개수에 따라 각 파티션에 복제하여 연산을 수행함. 이를 통해 셔플링에 의한 성능 저하를 방지할 수 있음. 이외에도 최적화 방법으로 checkpoint 등이 있음.

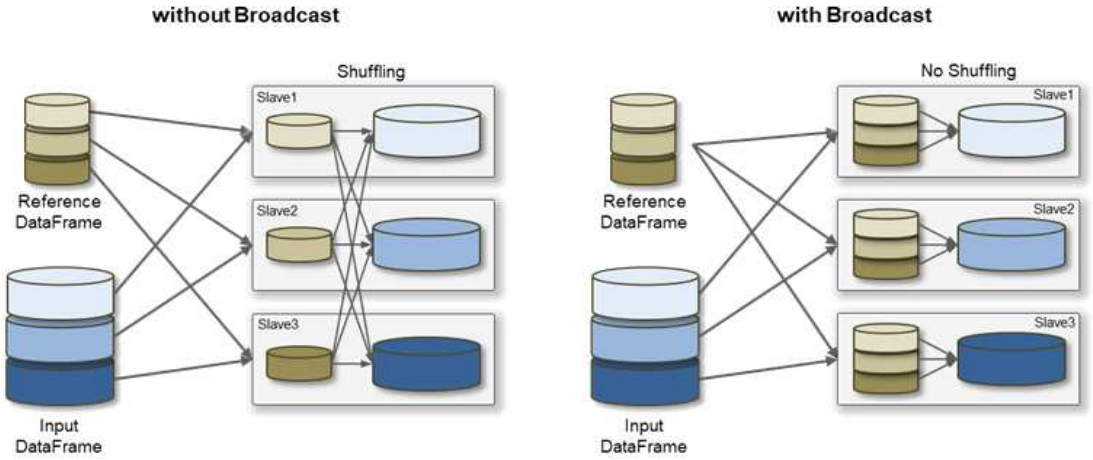


그림 2-17 브로드캐스트 매커니즘 구조

- Spark DataFrame을 이용한 대용량 지식 그래프 추론 통합 시스템 구축
  - OWL-Horst 추론 엔진과 SWRL 추론 엔진을 통합한 시스템을 구축함. 트리플 형태로 표현되어 있는 대용량 지식 그래프를 입력으로 OWL-Horst 추론을 우선 수행하며, 더 이상 추론되는 트리플이 없을 때 까지 반복 추론함. OWL-Horst 추론이 완료되면 대용량 지식 그래프와 추론된 트리플을 통합하여 SWRL 추론을 수행함. SWRL 추론은 사용자가 정의한 규칙들을 분석하고 업데이트 된 트리플을 받아 추론을 수행할 수 있도록 전처리 과정을 거친 후 더 이상 추론되는 트리플이 없을 때까지 반복 추론함.

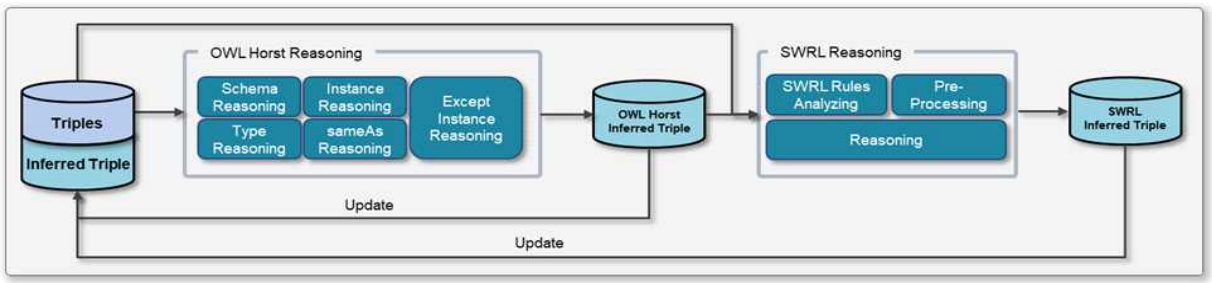


그림 2-18 통합 시스템 구조도.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) Incorrect 트리플 검출 연구

● 딥러닝 기반의 대용량 지식 그래프 오류 검출 모델 연구

- 대용량 지식 그래프를 대상으로 딥러닝 기반의 Incorrect 트리플을 검출하는 연구는 1차년도 Entity Embedding, 2차년도 Relation Embedding, 3차년도 Language Model을 통해 진행될 계획이며 당해 연도에는 Entity Embedding을 통해 대용량 지식 그래프의 오류 트리플을 검출할 수 있는 클러스터링 모델과 딥러닝 모델을 연구 개발하였음.

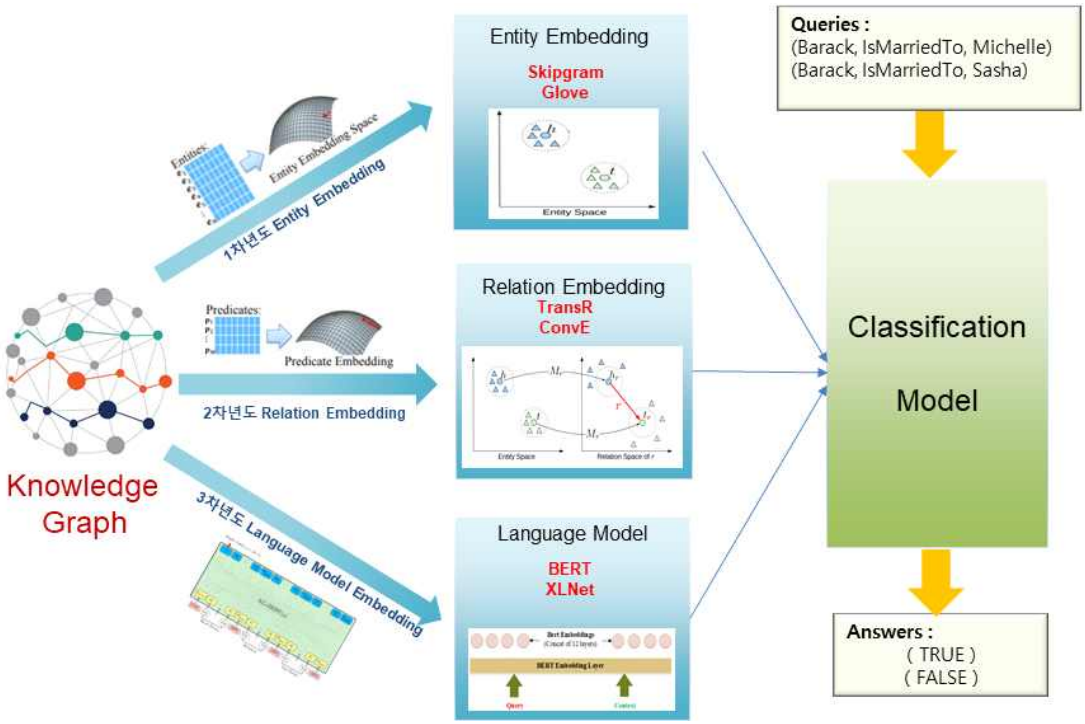


그림 2-19 대용량 지식 그래프의 오류 트리플 검출 모델 연구

- 오류 트리플 검출이 필요한 source class와 유사한 class 선정.'+'표시는 테스트 엔티티 벡터의 Correct Triple의 엔티티 벡터이며, '-'표시는 오류 트리플의 엔티티 벡터를 의미함. '*' 표시는 Correct Triple의 학습 엔티티 벡터 이며, 해당 학습 엔티티 벡터를 사용하여 K-means 클러스터링을 진행함. 학습 엔티티 벡터에 K-means 알고리즘을 사용하여 Centroid Point를 구하여 각 k개의 클러스터의 Centroid Point와 Centroid Point로부터 가장 먼 거리에 위치한 클러스터 내 엔티티 벡터를 연결하여 클러스터의 범위를 설정함.

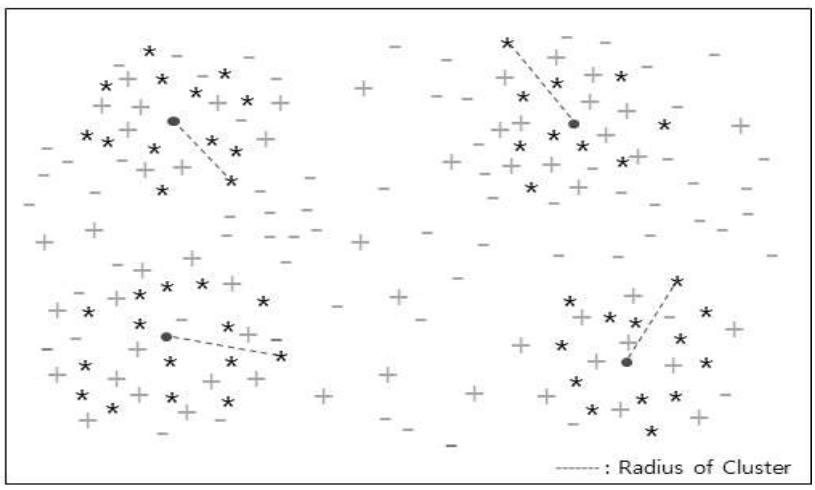


그림 2-20 오류 트리플 검출을 위한 데이터의 예

- 이러한 방법을 사용한 임베딩 모델은 모든 클러스터 내에 학습 임베딩 벡터(*)가 전부 포함되기 때문에 클러스터 범위에 Threshold(δ)를 적용하여 모델의 정규화 작업을 수행함.

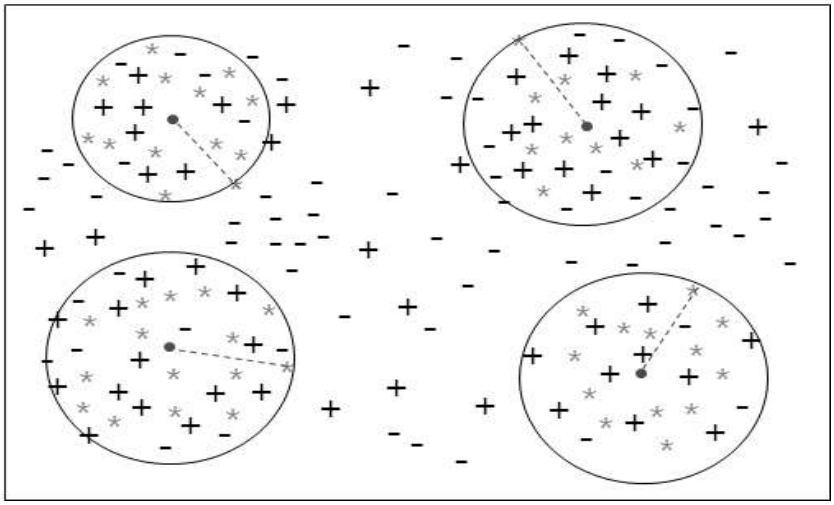


그림 2-21 클러스터링을 통한 오류 트리플 검출의 예

- 최적의 Error Base F1-Measure를 계산하기 위해 k Cluster 범위 r에 Threshold를 곱 연산하는 방법을 도식화한 내용임.

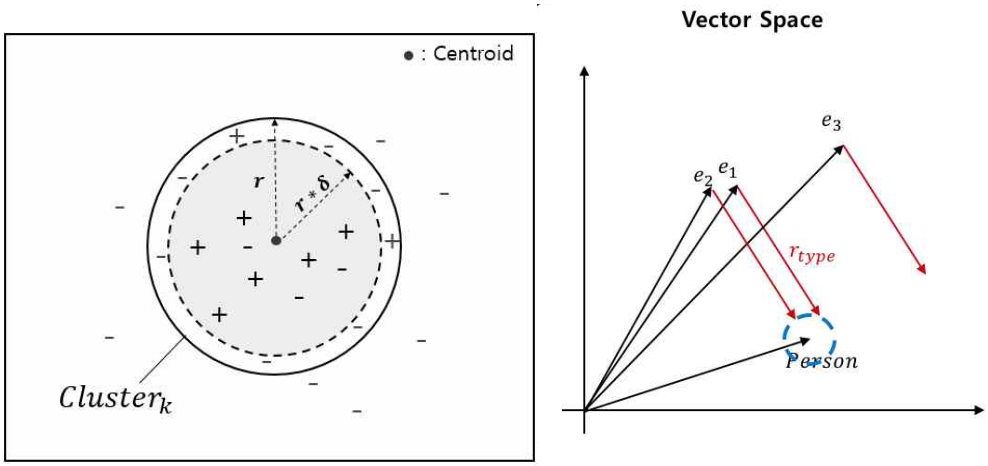


그림 2-22 클러스터링을 통한 최적의 오류 검출을 위한 방법의 예

- 릴레이션 모델을 활용한 오류 트리플 검출 방식은 트리플과 엔티티 벡터를 입력으로 다양한 지식완성 모델을 통해 릴레이션 모델을 구축함. 본 발명은 오류 트리플 검출을 위해 싱글 릴레이션 모델과 앙상블 모델을 제안함. 싱글 릴레이션 모델은 학습 데이터를 4가지 지식 완성 모델(TransE, TransR, NTN, HolE)을 통해 학습하여 릴레이션 모델을 구축함. TransE를 통한 오류 트리플을 검출하는 방법을 나타내며, 트리플이 주어졌을 때, 임베딩 공간에 엔티티를 벡터로 표현하게 되고, 표현된 벡터간의 연산을 통해 트리플의 스코어를 측정하게 된다. 두 개의 엔티티 e1과 e2의 경우, Threshold 범위를 의미하는 점선으로 표현된 원안에 존재하는 것을 볼 수 있고, e3 엔티티는 원의 외부에 존재하는 것을 볼 수 있음. 결과적으로 (e3, type, Person) 트리플은 Threshold보다 큰 값의 스코어를 도출하므로 오류 트리플로 검출됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 2차년도 개발 내용 및 범위

1) 개발 목표

대용량 지식 그래프 자동 완성을 위한 경로기반 관계 네트워크 모델 구축

- 대용량 지식그래프 자동 완성을 위한 딥러닝 요소 기술 개발
  - BiLSTM과 Attention기반 대용량 지식그래프 자동 완성을 위한 딥러닝 기반 추론 모델 학습 알고리즘 개발
  - 지식 완성을 위한 경로 기반 관계 네트워크 모델 개발
- 대용량 지식그래프 추론을 위한 데이터 확보
  - 지식그래프 추론을 위한 정제된 데이터셋의 공개

2) 개발 내용 및 범위

(1) 대용량 지식그래프 자동 완성을 위한 딥러닝 요소 기술 개발

- BiLSTM과 Attention기반 대용량 지식그래프 자동 완성을 위한 딥러닝 기반 추론 모델 학습 알고리즘 개발

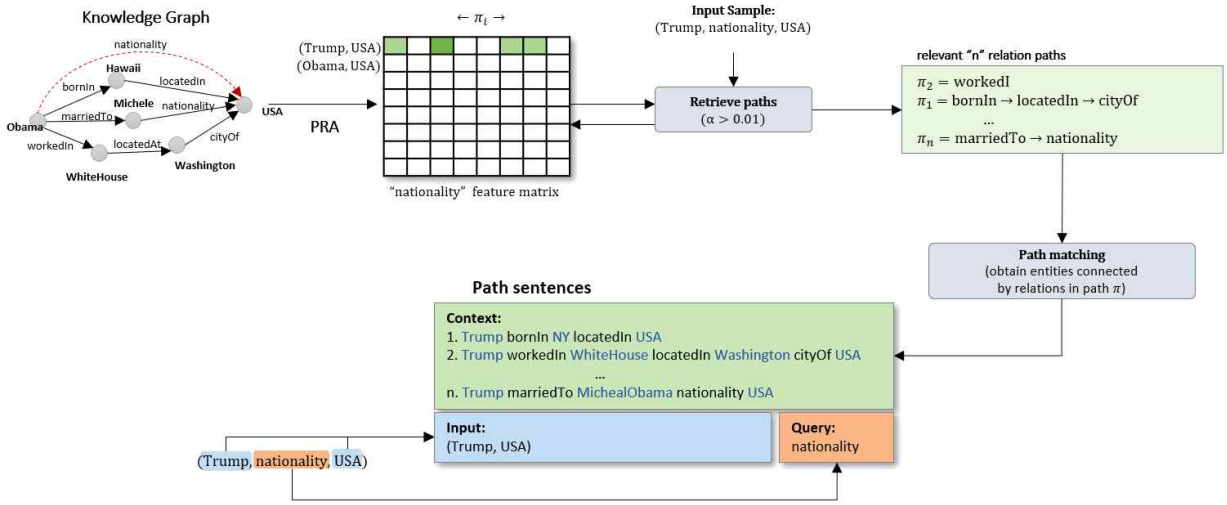


그림 2-23 Training 데이터 전처리 흐름도

- 학습 데이터 생성은 지식 그래프 자동 완성을 위한 질의문으로부터 경로 feature를 추출을 통해 이루어짐. source 노드 s와 target 노드 t 사이의 relation 경로들을 찾아 이로부터 training을 위한 학습 스토리를 생성할 수 있음
- 추출된 relation 경로들은 matrix 형태로 표현하여 추후 학습될 자동 완성 모델에 보다 유리한 경로들을 선별하는 과정을 수행함. 추출된 경로를 기반으로 주어진 질의문의 정답을 도출할 수 있는 sentence 형태의 context들을 생성하게 되고 각 질의문에 사용될 수 있는 모든 context들을 story 형태로 학습에 사용하는 것이 가능함

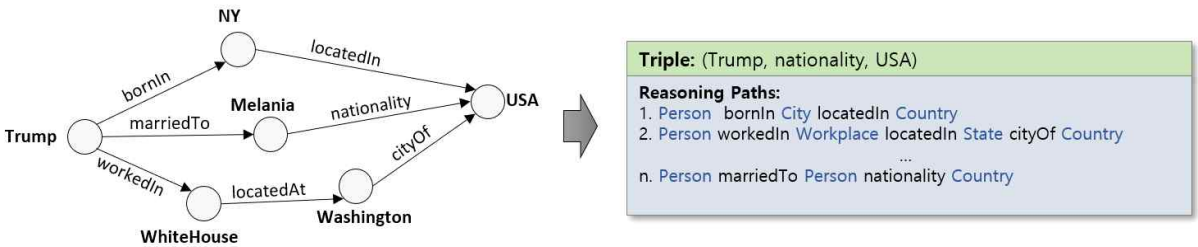


그림 2-24 Entity를 클래스 정보로 대체한 학습 데이터의 예

- 기존 방식의 지식 그래프 자동완성 모델들은 학습에 사용되지 않은 entity에 대한 처리가 불가능함. 따라서 이를 해결하기 위해 entity를 추출된 경로상의 relation들의 domain과 range를 활용하여 클래스 정보로 대체함. 예를 들어 'nationality'의 domain 자리에 위치한 entity는 'Person', range 자리에 위치한 entity는 'Country'로 대체하는 것이 가능함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

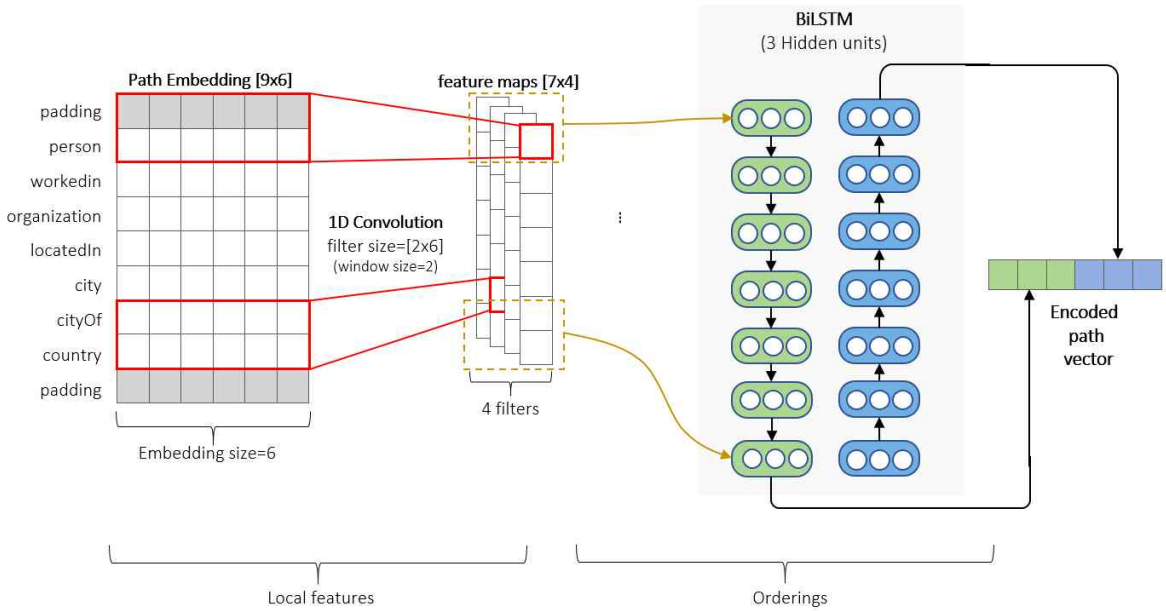


그림 2-25 Context의 Convolution과 BiLSTM 과정

- BiLSTM과 Attention 기반 지식 그래프 자동완성 모델은 추출된 경로를 기반으로 생성된 학습 데이터의 각 경로의 임베딩 벡터를 다중 필터를 통해 1차원 컨볼루션 레이어의 입력으로 사용함. 이를 Bidirectional LSTM을 통해 경로의 특징을 임베딩하고, 이를 후보 relation들과 함께 attention layer로 학습하여 유사도가 가장 높은 relation의 score가 가장 높을 수 있도록 각 레이어의 가중치들을 학습하는 구조임

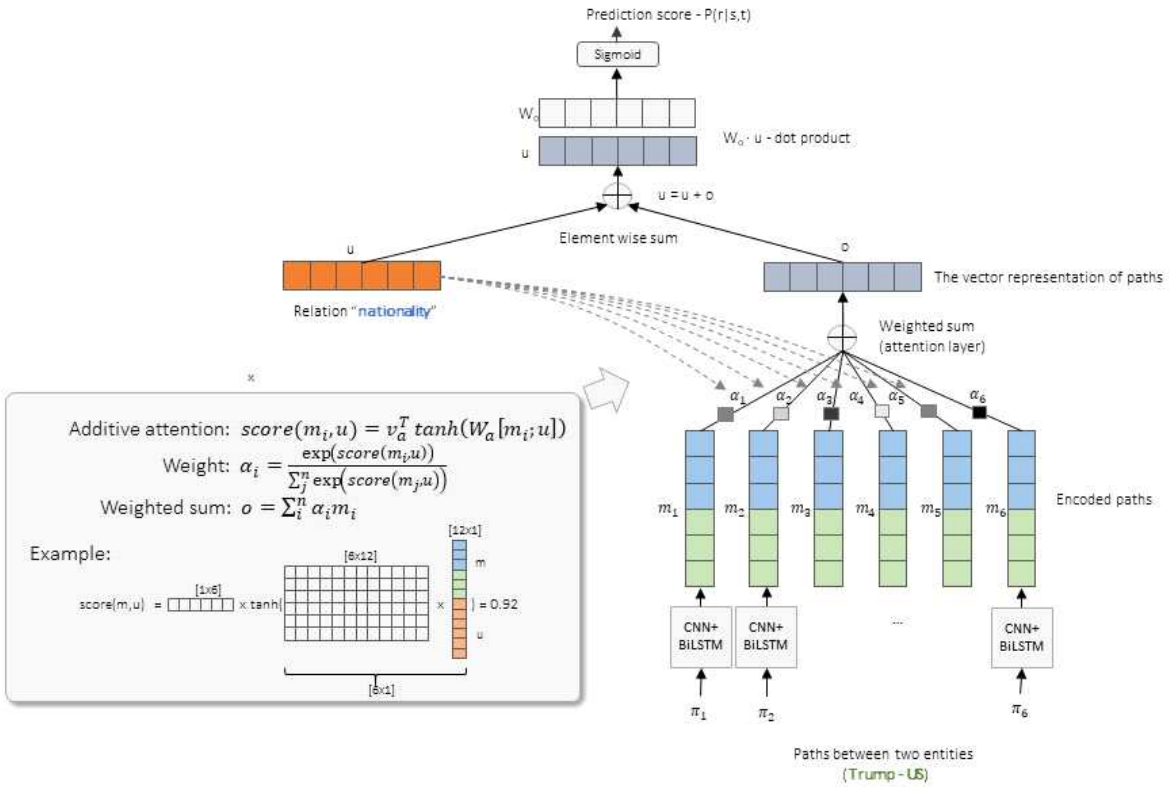


그림 2-26 BiLSTM과 Attention 기반 지식 그래프의 출력 레이어

- 학습데이터인 스토리의 각 context는 다중 필터를 사용하는 1차원 convolution을 통해 feature map을 생성하고, 이는 BiLSTM의 입력으로 사용됨. Feature map은 forward LSTM과 backward LSTM에 입력되어 양방향의 임베딩 값을 통합하여 임베딩된 경로 벡터로 학습되는 것이 가능함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

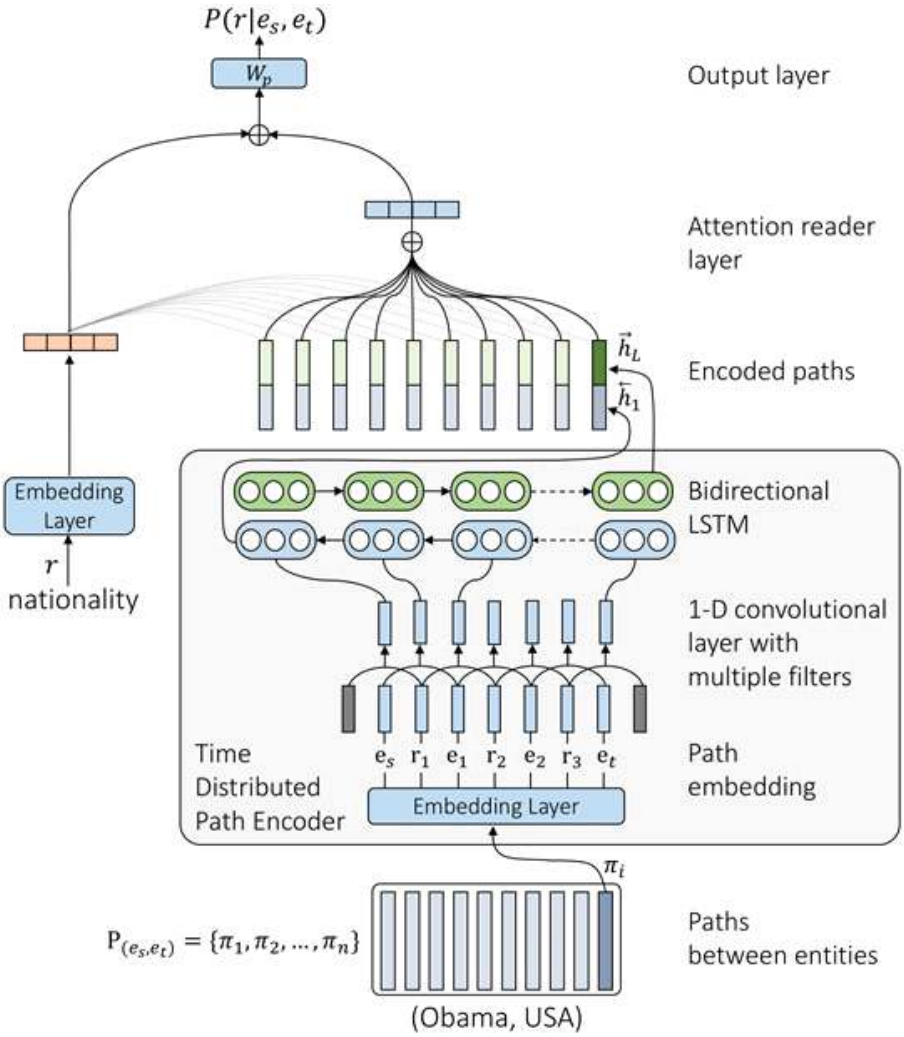


그림 2-27 BiLSTM과 Attention 기반의 자동완성 모델의 구조도

- Entity를 relation의 domain과 range를 활용하여 클래스 정보로 표현하는 경우, 대부분의 지식 그래프는 entity가 속하는 클래스 정보가 다수이기 때문에 다중 클래스에 속하는 entity를 표현할 때 문제가 발생할 수 있음. 다중 클래스에 대한 문제를 해결하기 위해 다중 클래스 정보를 한 개의 single 벡터로 표현하는 방법을 사용하였음. 한 개의 entity가 여러 개의 클래스 정보를 갖는 경우 여러 개의 클래스 벡터를 한 개의 single 벡터로 합하여 표현할 수 있음. 이는 다양한 기존 연구들에서 동일 문제를 해결하기 위해 사용되었고, 문제 해결에 좋은 성능을 보였음. 예를 들어 Trump의 타입이 'Person', 'President', 'CEO', 'Male'인 경우 Trump를 표현하는 vector는 4가지 클래스 vector를 합한 값으로 표현하여 다중 클래스의 특징을 한 개의 벡터로 나타내었음.

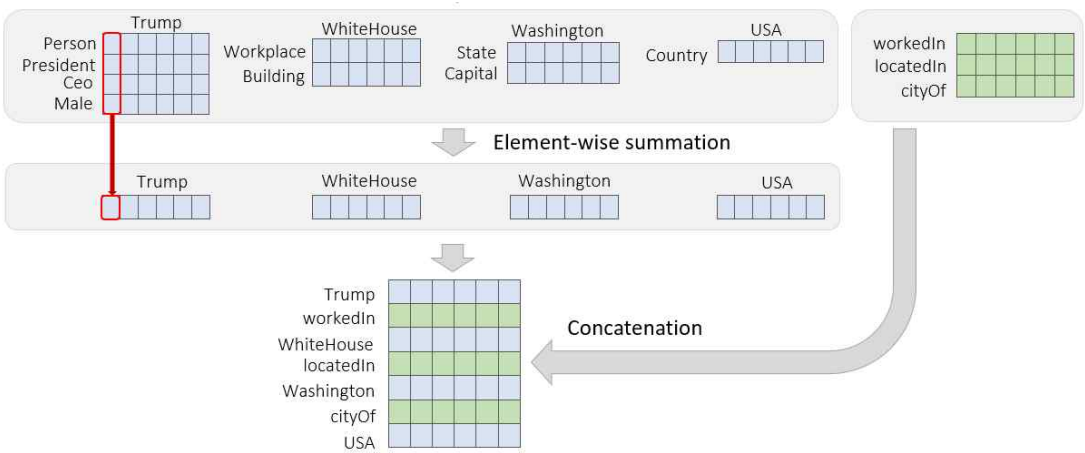


그림 2-28 클래스 Vector 병합의 예

● 지식 완성을 위한 경로 기반 관계 네트워크 모델 개발

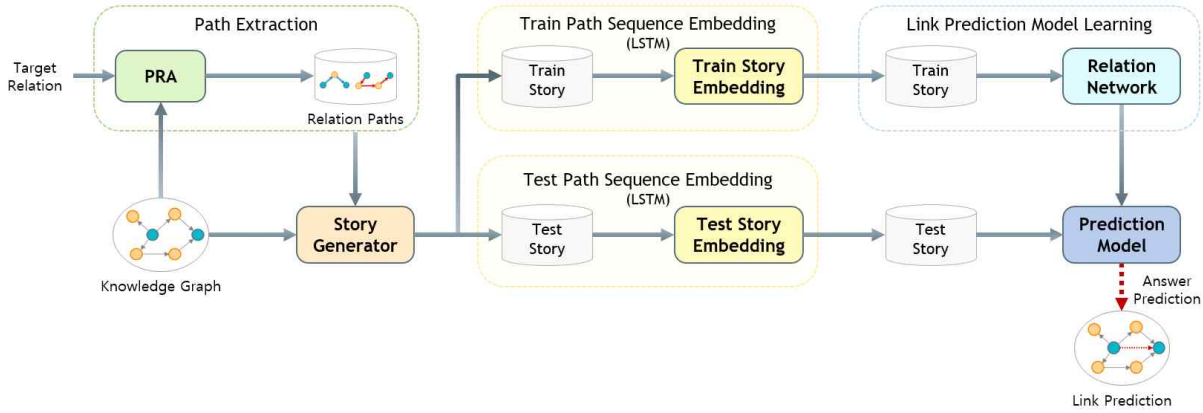


그림 2-29 지식 완성을 위한 경로 기반 관계 네트워크 모델

● Path Ranking Algorithm 기반 경로 추출

- RN을 지식 그래프 완성에 적용하기 위해서는 학습 데이터의 생성과 지식 그래프에 적합한 RN 구성이 요구됨. 이를 위한 첫번째 단계로 PRA를 기반으로 한 경로 추출 과정을 통해 RN 모델을 학습하기 위한 학습 데이터를 생성함. 목적 관계에 r_1에 대한 트리플 $< x, r_1, y >$가 주어지면, PRA의 random walks를 통해 head 노드 x로부터 tail 노드 y로 연결되는 r_1이 아닌 다른 관계 연결을 최대 길이 2~3으로 탐색함. head 노드와 tail 노드로 구성된 학습 데이터의 노드 쌍을 대상으로 모든 경로에 대한 random walks 확률을 계산하여 경로 매트릭스를 생성함.

ID	Extracted Relation Path for '*nationality*' by PRA
π_1	$c \xrightarrow{placeOfBirth} c \xrightarrow{placeOfBirth^{-1}} c \xrightarrow{nationality} c$
π_2	$c \xrightarrow{placeOfBirth} c \xrightarrow{contains} c \xrightarrow{country} c$
π_3	$c \xrightarrow{placeOfBirth} c \xrightarrow{artistOrigin^{-1}} c \xrightarrow{nationality} c$
π_4	$c \xrightarrow{artistOrigin} c \xrightarrow{placeOfBirth^{-1}} c \xrightarrow{nationality} c$

그림 2-30 PRA 알고리즘 기반 경로 추출

- 경로 매트릭스의 각 셀 값은 head 노드 s_i가 경로를 통해 tail 노드 t_i에 도달할 확률을 의미하며, 이를 통해 학습에 도움이 되는 경로와 도움이 되지 않는 경로를 구분하는 것이 가능함. 예를 들어 표1의 π_2는 π_1에 비해 상대적으로 대부분의 노드 쌍에 대해서 낮은 확률을 갖고 있기 때문에 좋지 못한 경로로 분류될 수 있음. 또는 π_1과 같이 일부 노드 쌍에 대한 확률이 높더라도 과반수의 노드 쌍들이 연결되지 못하거나 낮은 확률을 갖는 경우도 학습에 도움이 되는 경로로 분류되긴 어렵다고 판단할 수 있음. 또한 추출되는 경로의 수가 매우 많기 때문에 모든 경로들을 학습에 사용하는 것은 매우 비효율적임.
- 따라서 학습에 사용될 수 있는 경로를 선별하는 과정이 반드시 필요함. 이를 위해 학습에 좋은 영향을 줄 수 있는 경로들을 2가지 기준으로 선택하였음. 먼저 각 경로를 통해 연결되는 노드 쌍의 비율이 전체의 70% 이상을 차지하는 경로들을 선정하였음. 예를 들어 주어진 관계에 대한 모든 트리플 중에서 path π_1을 통해 연결되는 비중이 50% 이하인 경우 경로 매트릭스에서 경로 π_1에 대한 열을 제외하였음. 두 번째로는 각 경로에 대한 random walk 확률인 경로 매트릭스의 셀 값 평균 5% 이하인 경로들은 제외하고 노드 쌍에 존재하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

는 대부분의 엔티티들이 연결될 수 있는 경로들을 선택하였음.

ID		Sentence Examples
π_1	Relation Path	Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{placeOfBirth^{-1}}$ Chris_Pine $\xrightarrow{nationality}$ USA Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{placeOfBirth^{-1}}$ Angelina_Jolie $\xrightarrow{nationality}$ USA
	Sentence	Adam_Levine $\xrightarrow{placeOfBirth}$ - $\xrightarrow{placeOfBirth^{-1}}$ - $\xrightarrow{nationality}$ USA
π_2	Relation Path	Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{contains}$ LA_City_College $\xrightarrow{country}$ USA Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{contains}$ Occidental_College $\xrightarrow{country}$ USA
	Sentence	Adam_Levine $\xrightarrow{placeOfBirth}$ - $\xrightarrow{contains}$ - $\xrightarrow{country}$ USA
π_3	Relation Path	Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{artistOrigin^{-1}}$ Ne-Yo $\xrightarrow{nationality}$ USA Adam_Levine $\xrightarrow{placeOfBirth}$ LA $\xrightarrow{artistOrigin^{-1}}$ Flea $\xrightarrow{nationality}$ USA
	Sentence	Adam_Levine $\xrightarrow{placeOfBirth}$ - $\xrightarrow{artistOrigin^{-1}}$ - $\xrightarrow{nationality}$ USA
π_4	Relation Path	Adam_Levine $\xrightarrow{artistOrigin}$ LA $\xrightarrow{placeOfBirth^{-1}}$ Angelina_Jolie $\xrightarrow{nationality}$ USA Adam_Levine $\xrightarrow{artistOrigin}$ LA $\xrightarrow{placeOfBirth^{-1}}$ Angelina_Jolie $\xrightarrow{nationality}$ USA
	Sentence	Adam_Levine $\xrightarrow{artistOrigin}$ - $\xrightarrow{placeOfBirth^{-1}}$ - $\xrightarrow{nationality}$ USA

그림 2-31 PRA 알고리즘을 통한 경로 추출의 예

- 경로 기반 학습 데이터 생성
  - RN의 학습 데이터는 반드시 컨텐스트, 질문, 정답로 구성되는 이야기 형태가 요구됨. 컨텍스트는 문장들의 집합이며, PRA로 부터 추출한 관계 경로를 사용하여 트리플로 연결된 문장을 생성할 수 있음. 추출된 각 경로의 모든 관계들이 연결될 수 있는 중간 엔티티 노드들을 지식 그래프에서 탐색하여 여러 트리플이 연결된 문장을 생성함. 예를 들어 그림1에서 target 관계가 'nationality'인 경우 추출된 관계 경로 'placeOfBirth → _placeOfBirth → nationality'를 확인할 수 있음.('_'는 head와 tail이 반대로 연결된 inverse 관계를 나타내는 기호). 지식 그래프에서 위 경로의 각 관계들로 연결될 수 있는 트리플들을 연결하면 아래와 같은 문장을 생성할 수 있음.

'Adam_Levine placeOfBirth Los_Angeles _placeOfBirth Chris_Pine nationality United_States_of_America'

  - 그러나 전체 지식 그래프를 대상으로 위와 같은 문장들을 생성하게 되면, head 노드와 tail 노드를 제외한 중간 노드의 개수가 매우 많은 경우 문장의 수가 기하급수적으로 증가함. 이로 인해 학습 속도가 저하되며, 고용량의 메모리를 필요로 하게 되는 문제가 발생함. 따라서 각 관계를 추론할 수 있는 경로에 특징 자체에 집중하기 위해 head 노드와 tail 노드를 제외한 중간 노드를 모두 제거한 문장을 사용하였음. 그 결과 위 문장은 아래와 같이 변경되었고, 이를 직접 학습에 사용하였음. 생성된 문장들의 집합은 컨텍스트가 되고, 질문은 주어진 head 노드와 목적 관계를 통해 'Adam_Levine nationality ?'로 생성되고, 정답은 실제 tail 노드인 'United_States_of_America'가 되어 한 개의 이야기 데이터가 생성됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

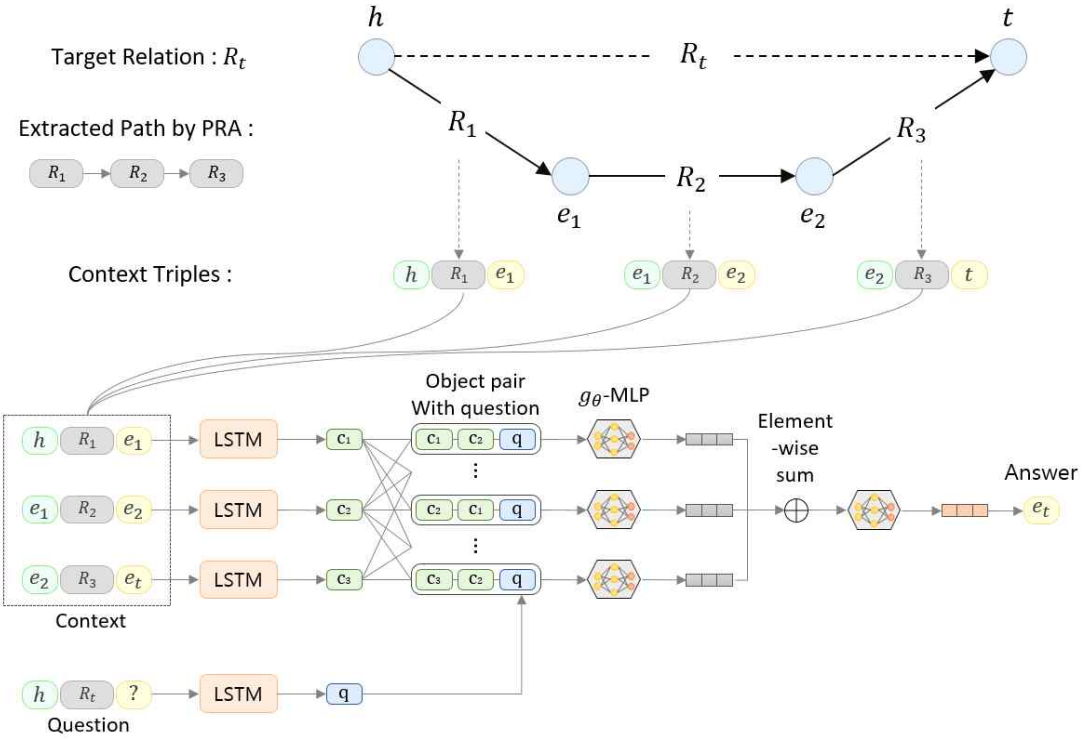


그림 2-32 관계 네트워크와 입력데이터의 예

● 지식 그래프 자동 완성을 위한 관계 네트워크 학습

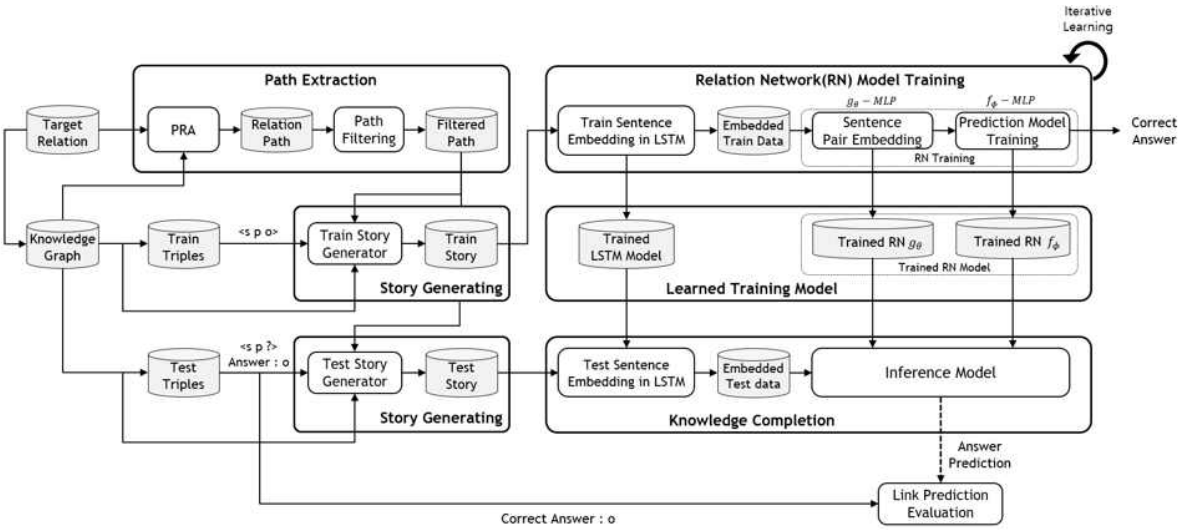


그림 2-33 관계 네트워크 모델의 구성도

- 텍스트 질의응답을 위한 관계 네트워크의 입력 형태와 동일한 지식 그래프의 이야기 데이터를 통해 관계 모델을 학습한다. 트리플 형태의 질문과 컨텍스트는 LSTM의 최종 출력 값으로 임베딩되고, 모든 문장들을 조합 쌍으로 병합한다. 예를 들어 문장의 개수가 총 5개인 경우, ${}_5C_2$=10 개의 조합 쌍을 생성한다. 이후 조합 쌍과 질문을 병합하고, 이를 RN의 입력으로 사용된다. 따라서 RN의 인공 신경망 모듈은 다음과 같이 2개의 문장과 질문이 조합 쌍으로 구성되어 g_θ와 f_ϕ를 통해 학습이 진행됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

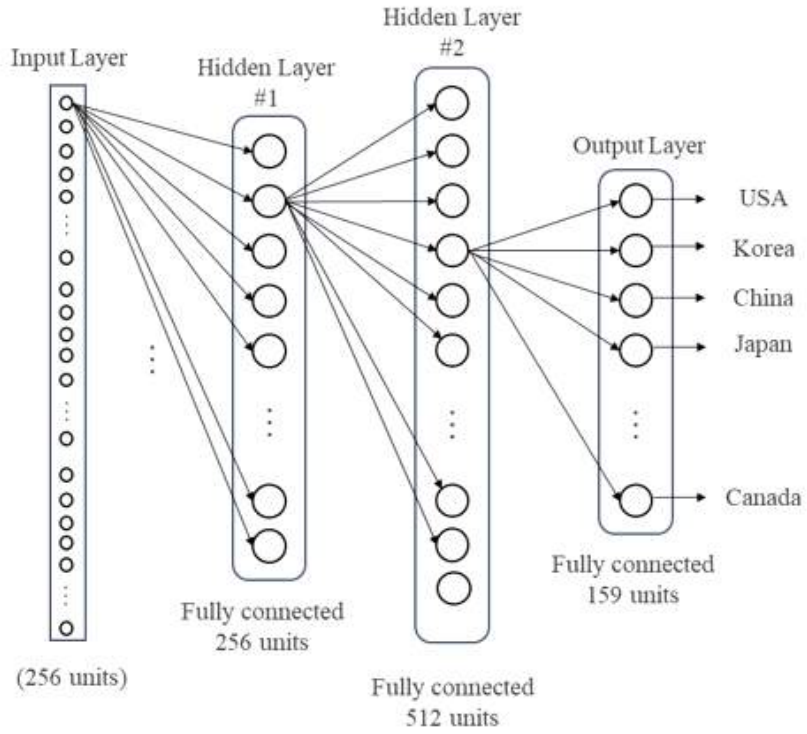


그림 2-34 관계 네트워크에 대한 레이어 구성

- 이후 컨텍스트의 트리플들과 질문은 head, relation, tail에 대한 순서 정보의 특징을 담을 수 있도록 LSTM을 통해 임베딩을 수행한다. RN의 첫번째 MLP인 g_θ는 질문과 컨텍스트의 관계를 학습하는 단계이다. 따라서 LSTM을 통해 임베딩된 컨텍스트의 트리플들과 질문을 조합하여 g_θ의 입력으로 사용한다. 먼저 컨텍스트에 존재하는 모든 트리플에 대한 조합 쌍을 조합하고, 이에 질문을 추가로 병합하여 RN의 입력 데이터를 생성한다. g_θ에는 총 4개의 완전 연결 레이어가 존재하며, 각 레이어는는 256개의 유닛으로 구성된다. 모든 입력 데이터들이 g_θ를 통과하면서 컨텍스트와 질문이 함께 임베딩 되었다고 간주할 수 있다. 이후 각 g_θ의 출력 벡터들은 element-wise 합계를 통해 f_ϕ의 입력으로 사용됨.

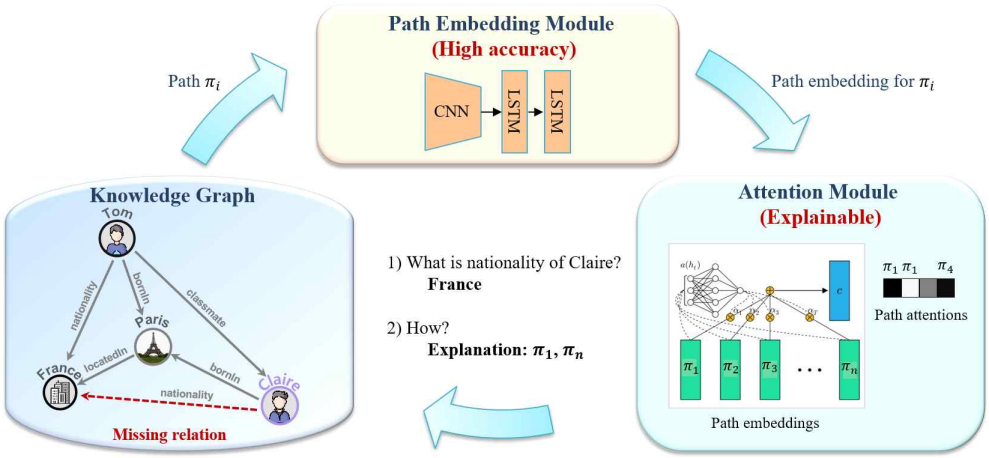


그림 2-35 딥러닝 기반 지식 완성 모델의 구조도

- f_ϕ는 총 3개의 완전 연결 레이어가 존재하며, 첫 번째 레이어는 256 유닛, 두 번째 레이어는 512 유닛으로 구성된다. 마지막 레이어는 전체 어휘 크기로 설정되어 정답에 대한 softmax 값을 출력하게 된다. 모든 학습 이야기 데이터에 대해서 위 과정에 대한 forward/backward propagation이 반복되면서 컨텍스트의 트리플들과 질문에 대한 관계가 학습되어 질문 트리플의 tail 엔티티를 예측 할 수 있는 모델이 학습됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다. 3차년도 개발 내용 및 범위

1) 개발 목표 :

심볼릭 방식과 딥러닝 방식을 융합한 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법

- 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법
  - 뉴로 심볼릭 Unification기반 대용량 지식그래프 자동 완성 기술 개발
  - 심볼릭 Unification을 이용한 지식 완성 방식
  - 뉴로 심볼릭 Unification을 이용한 지식 완성 방식
  - 뉴로 심볼릭 Unification 모델 학습을 위한 cost function 정의
  -

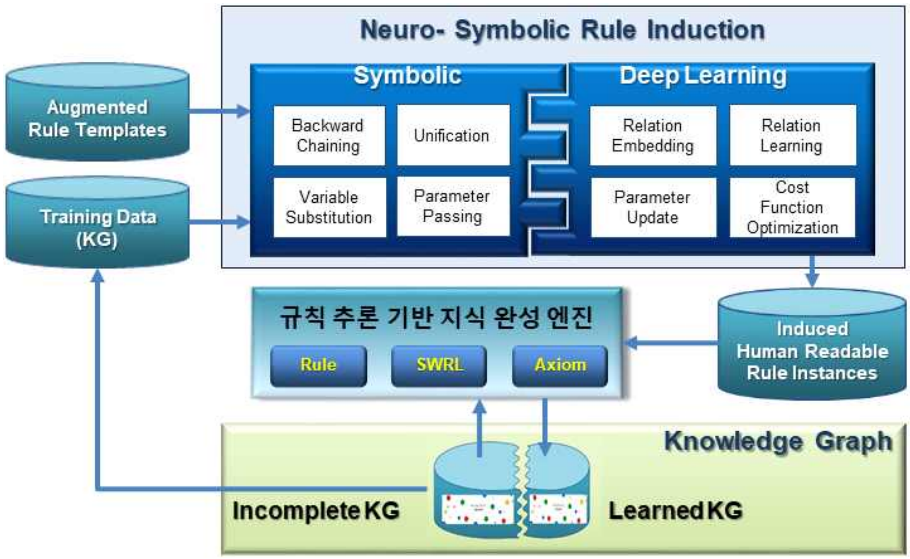


그림 2-36 뉴로 심볼릭 기반 지식 완성

- 관계 네트워크 모델을 이용한 지식 그래프 자동 완성 기법
  - PRA를 이용한 경로 추출 및 선별 기술 개발
  - 우회 경로 기반의 딥러닝 모델 학습 데이터 생성기 개발
  - 관계 네트워크를 이용한 지식 그래프 자동완성 모델 설계 및 개발

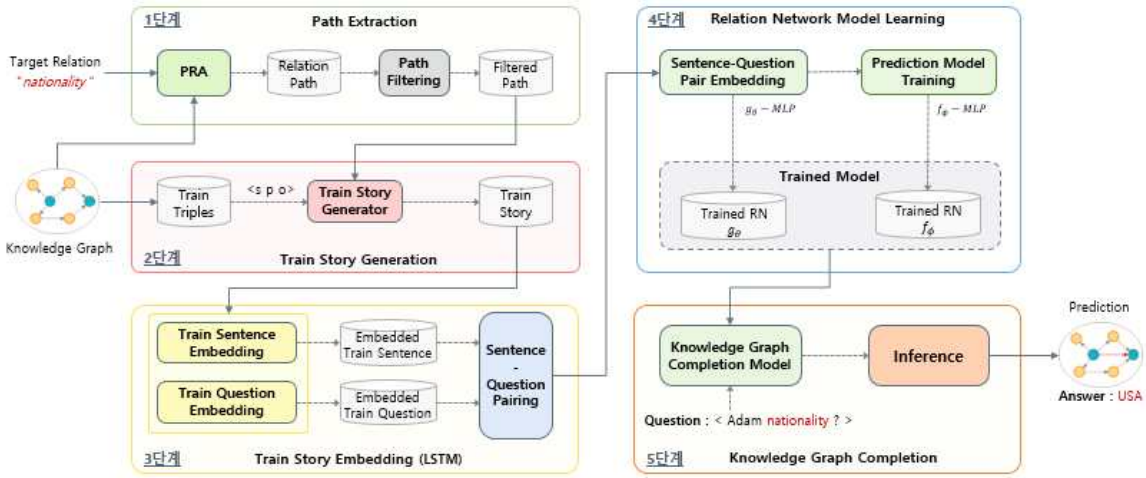


그림 2-37 관계 네트워크기반 지식 완성

- 지식 그래프 완성 시스템 검증을 위한 Visualization 도구
  - 딥러닝 기반 지식 완성 모델 Visualization 도구의 사용 범위
  - 규칙 추론 기반 지식 완성 시스템 검증을 위한 Visualization 도구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 개발 내용 및 범위

(1) 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법 :

● 뉴로 심볼릭 unification 기반 대용량 지식 그래프 자동 완성 기술 개발

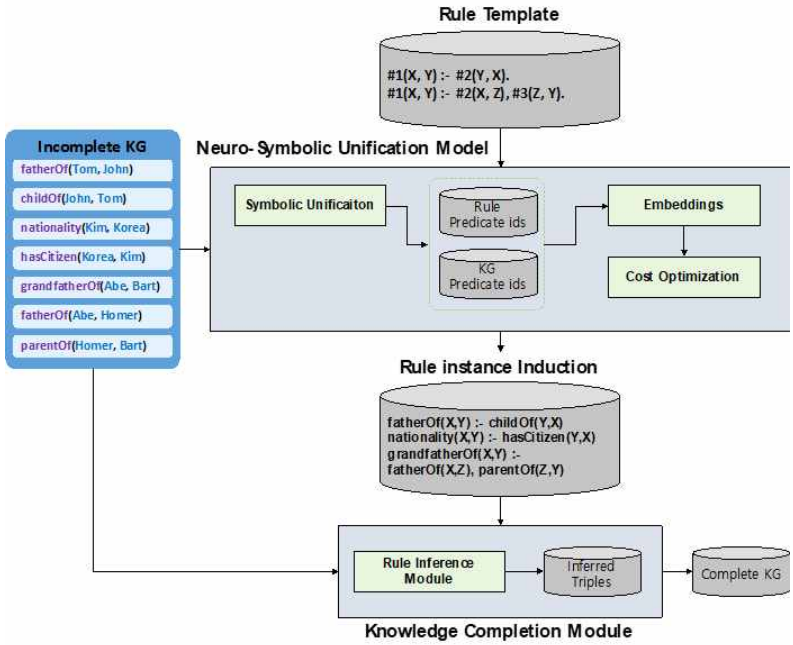


그림 2-38 뉴로 심볼릭 unification 시스템 구조도

- 시스템은 크게 2가지 과정으로 이루어져 있으며, 첫 번째 과정에서는 지식 완성을 수행하고자하는 불완전한 지식 그래프와 추출하고자하는 규칙 template을 입력으로 하여 뉴로 심볼릭 Unification 모델을 학습함.
- 두 번째 과정은 학습된 뉴로 심볼릭 모델로부터 규칙을 추출하여 규칙 추론을 수행함으로써 지식 완성을 수행이 가능함.

● 지식그래프 기반 뉴로 심볼릭 방식의 규칙 추론 학습

- 누락 정보를 추론할 수 있는 경험적 규칙을 정의하여 Knowledge Graph Completion을 수행할 수 있지만, 방대한 Knowledge Graph에 대한 모든 규칙을 정의하는 것이 불가능하기 때문에 지식 Embedding과 Deep Learning을 활용하여 지식 그래프의 불완전성을 자동적으로 해결할 수 있는 자동 지식 그래프 완성 연구를 수행함
- 지식그래프로부터 지식의 특징을 반영하는 규칙을 추출하는 방법은 매우 어렵고 불가능하기 때문에 본 연구에서는 규칙에 대한 스키마를 정의하여 Relation에 대한 Embedding하여 유사도 학습을 통해 규칙 추론
- 심볼릭 방식의 Backward Chaining 기반 뉴로 심볼릭 Unification을 수행하고 정의한 규칙 스키마를 이용하여 지식그래프로부터 규칙 인스턴스를 추론할 수 있음

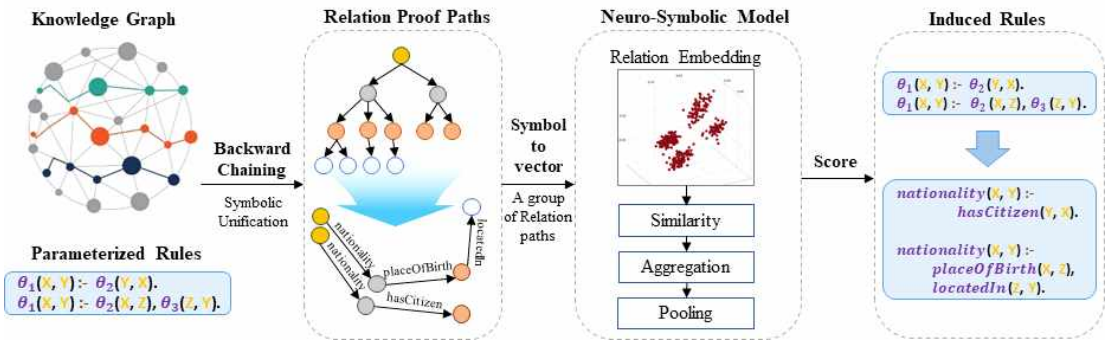


그림 2-39 뉴로 심볼릭 추론 기반 Rule Instance 학습 과정의 예

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 심볼릭 Unification을 이용한 지식 완성 방식
  - 심볼릭 Unification은 지식 그래프에 존재하는 두 logic atom간의 동일성을 확인하고 substitution을 통해 Variable에 symbol을 binding함으로써 질의 트리플에 대한 규칙을 추론함. 이는 유사한 의미의 symbol을 고려하지 못한다는 단점이 있음.

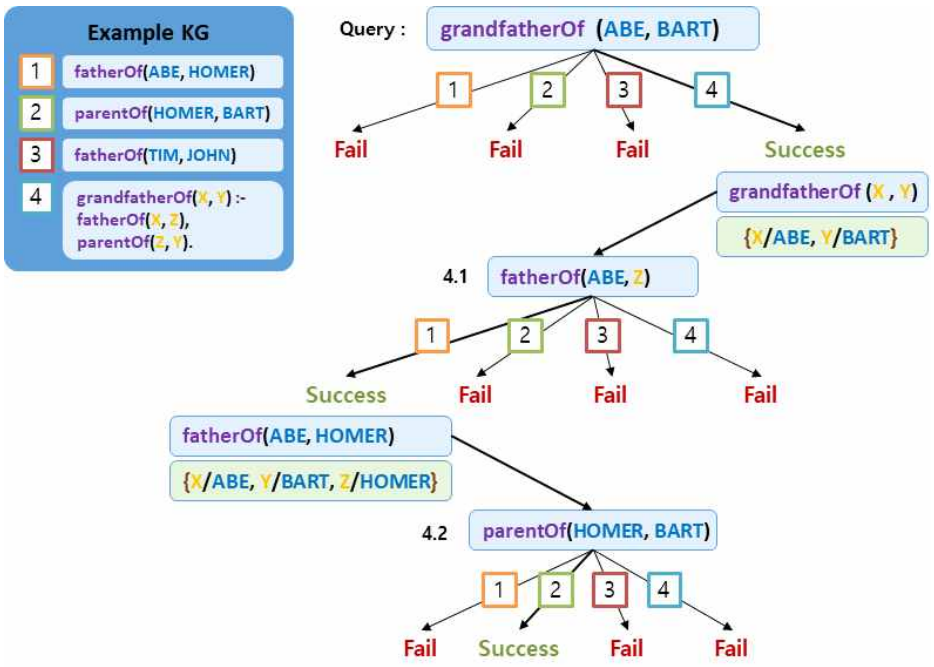


그림 2-40 심볼릭 Unification 수행 과정 예

- 뉴로 심볼릭 Unification을 이용한 지식 완성 방식
  - 뉴로 심볼릭 Unification 방식은 symbol을 parameter화 하여 유사한 의미의 symbol에 대한 고려가 가능하지만, 규칙의 각 항마다 Unification 과정을 통해 지식그래프 내의 도출된 엔티티와 릴레이션을 모두 고려하여 엔티티-엔티티, 릴레이션-릴레이션에 대한 임베딩을 수행하기 때문에 지식 그래프의 크기가 커짐에 따라 네트워크의 크기가 증가하는 문제점이 존재함.
  -

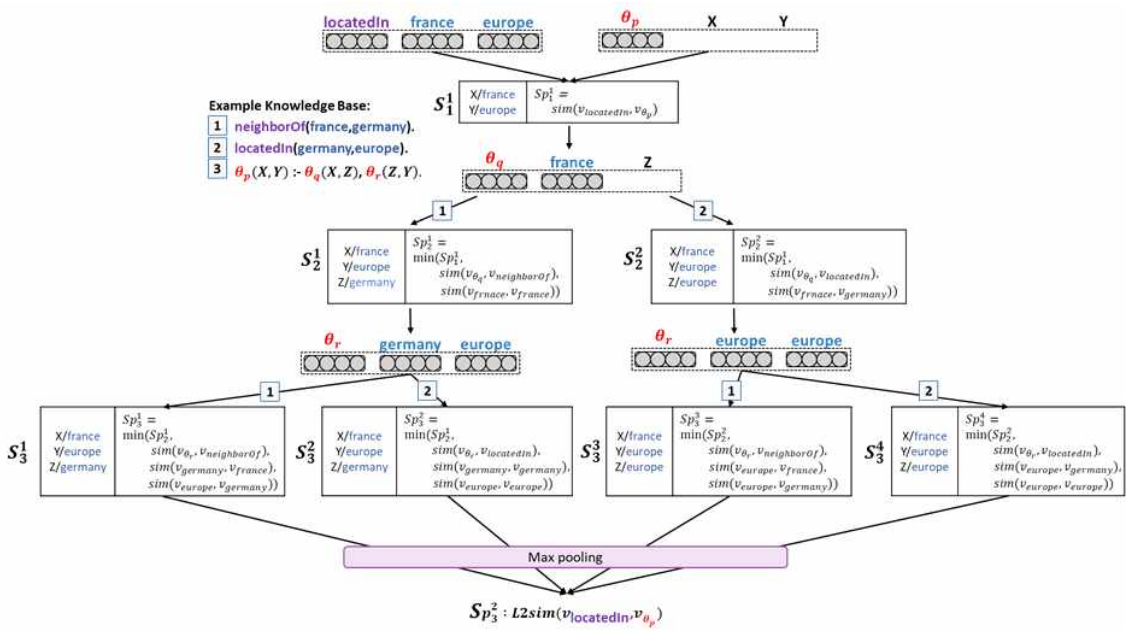


그림 2-41 뉴로 심볼릭 Unification 예

- 규칙 생성을 위한 Unification과정은 엔티티 간의 유사도 계산 없이 릴레이션 간의 유사도 계산만으로 가능함. 따라서 엔티티 임베딩을 고려할 필요 가 없으므로 parameter 효율성이 증가하고 parameter passing을 통한 relation selection을 이용하여 계산 그래프 또한 효율적으로 감소할 수 있음.

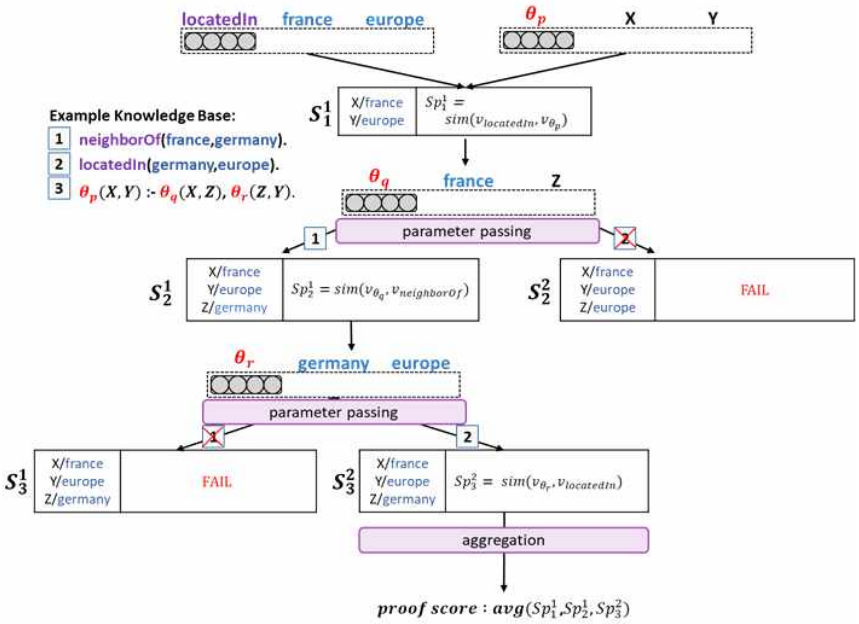


그림 2-42 규칙 생성을 위한 뉴로 심볼릭 Unification 예

● 뉴로 심볼릭 Unification 모델 학습을 위한 cost function 정의

- 지식 완성을 위한 규칙 추론 학습을 하기 위해 오차(loss)를 최소화하는 cost function과 학습 데이터에 대한 정의가 필요함. 학습 데이터는 릴레이션의 경로에 대한 임베딩 학습을 수행함. 때문에 지식 그래프에서 임의의 한 개의 트리플을 목표 트리플로 선택하여 심볼릭 unification 과정을 수행함.

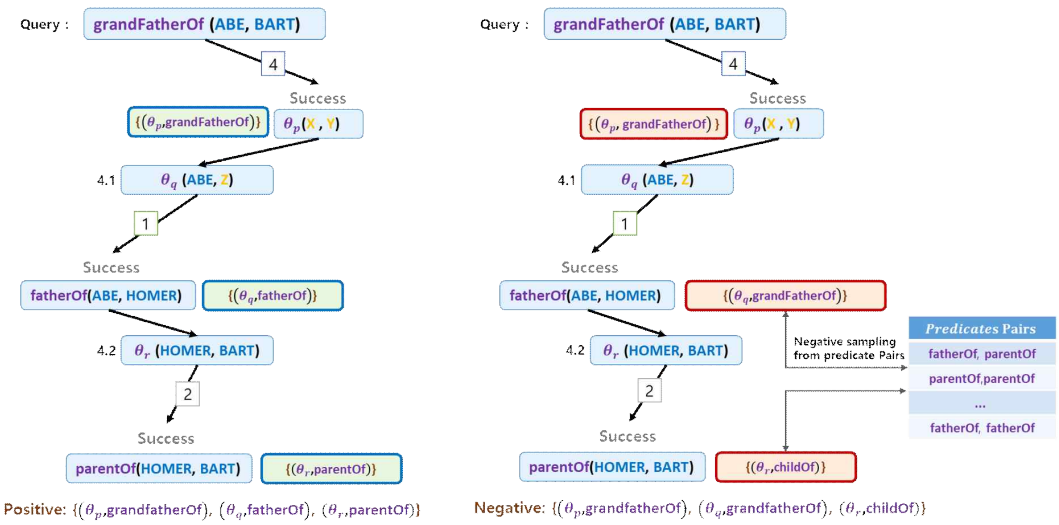


그림 2-43 positive와 negative 데이터 예

- 지식 완성을 위한 규칙 추론을 하기 위해 opsitive 데이터와 negative데이터에 대한 cost function을 다음과 같이 정의함.

$$Loss_{u_ntp} = \sum_{(l_i \in L, y)} -y\log(u_ntp(l_i)) - (1-y)\log(1-u_ntp(l_i))$$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 릴레이션 Path에 대한 전처리과정을 통해 생성된 릴레이션 Path 유사도 학습을 수행
- 생성된 Positive/Negative Relation Path를 통해 규칙-KG 릴레이션에 대한 유사도 계산
- 각 릴레이션 Path에 대하여 Aggregation 과정을 통해 릴레이션 유사도에 대한 평균 도출
- Max Pooling : 가장 높은 유사도를 가지는 Augmented Relation Path를 도출
- Min Pooling : Max Pooling으로 도출된 릴레이션 Path 중 학습을 위해 낮은 유사도 Path 도출
- 생성된 Relation Path에 대한 유사도 학습 과정을 통하여 임베딩된 릴레이션 벡터에 대한 유사도 학습을 수행

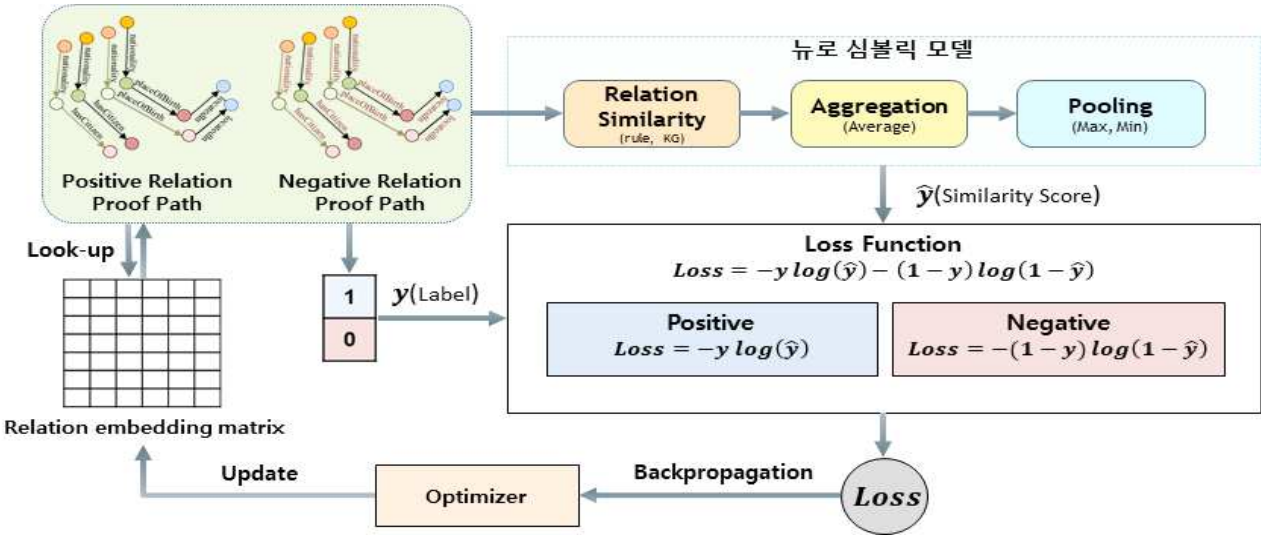


그림 2-44 Rule Induction을 위한 학습 모델

● 릴레이션 유사도 기반 Rule Induction 추론 연구
- 뉴로 심볼릭 Unification을 활용하여 관련된 릴레이션을 추출하고, 추출된 릴레이션에 대한 유사도 학습을 통한 규칙 추론 연구를 수행함
- 지식그래프로부터 지식의 특징을 반영하는 규칙을 추출하는 방법은 매우 어렵고 불가능하기 때문에 규칙에 대한 스키마를 정의하여 뉴로 심볼릭 Unification을 통해 관련된 릴레이션을 수집하여 릴레이션을 Embedding하여 유사도 학습을 통해 규칙 추론
- 주어진 Query와 지식그래프, 정의된 규칙 스키마에 대하여 뉴로 심볼릭 Unification을 활용하여 Relation Path 생성을 수행하고, 동일한 규칙 스키마로부터 생성된 Relation Path에 대하여 유사도 학습을 통해 Relation에 대한 높은 유사도의 규칙을 추론

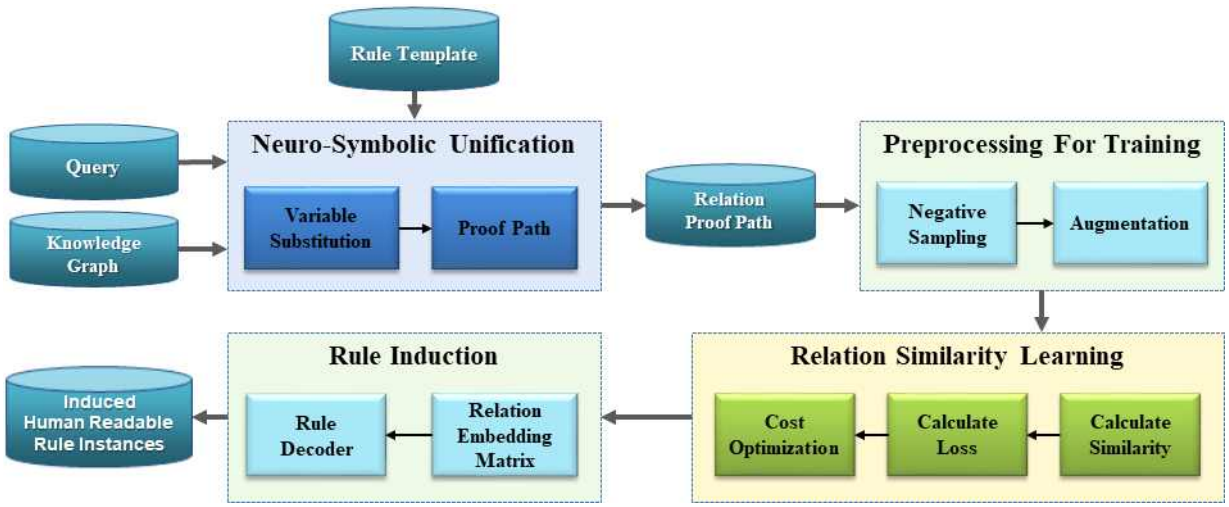


그림 2-45 릴레이션 유사도 기반 규칙 추론 연구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 릴레이션에 대한 파라미터 표현 규칙
  - 규칙의 릴레이션을 파라미터 형태로 변경하여 표현하며, 학습의 효율성을 위한 Augmentation을 지정하여 학습을 위한 규칙을 생성
  - 규칙의 릴레이션은 #i_j_k의 형태로 표현이 되며, I는 규칙에서 사용되는 릴레이션을 구분하며, j는 각 규칙을 구분하기 위해 사용하고 k는 Augmentation을 위한 규칙의 릴레이션을 구분하는 형태로 표현
  - 예를 들어, nationality(X,Y) :- bornIn(X,Y)와 같은 규칙에 대하여 2번의 Augmentation을 수행한다면 먼저 #1(X,Y) :- #2(X,Y)와 같은 형태로 규칙의 릴레이션을 파라미터 형태로 변경하여 표현
  - 이후 #1(X,Y) :- #2(X,Y)의 규칙에 대하여 Augmentation을 수행하여 #1_0_0(X,Y) :- #2_0_0(X,Y)과 #1_0_1(X,Y) :- #2_0_1(X,Y)의 형태로 Augmentation을 수행한 2개의 규칙을 생성하여 학습 수행

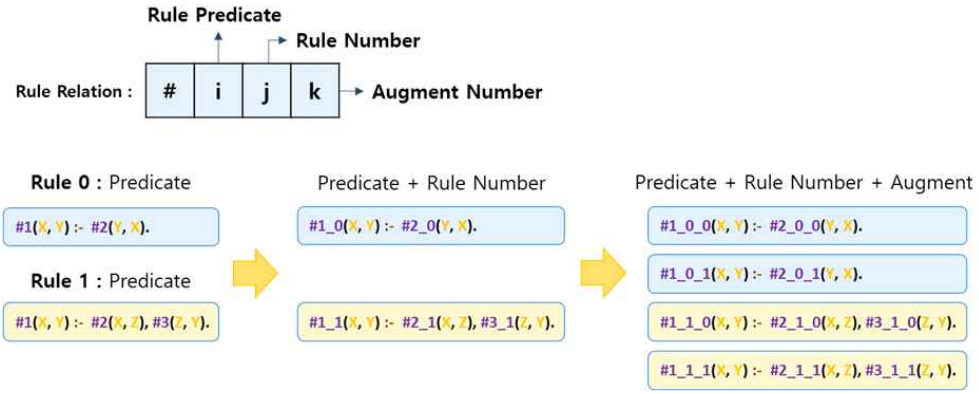


그림 2-46 규칙 릴레이션에 대한 파리미터 표현의 예

- 뉴로 심볼릭 Unification기반 Relation Path와 Augmentation 생성 연구
  - 뉴로 심볼릭 Unification을 활용하여 Relation Path를 생성하고, 릴레이션에 대한 유사도 학습을 위해 Relation Path에 대한 Augmentation 및 Negative Sampling 과정을 수행함
  - 동일한 규칙스키마로부터 여러 종류의 Rule 인스턴스를 추론하기 위해 Augmentation 과정 수행
  - 유사도 학습을 위한 Negative Relation Path를 생성하기 위한 Negative Sampling과정 수행
  - 데이터 호출의 최적화를 위한 Relation에 대한 인덱싱을 수행하는 Encoding 과정 수행

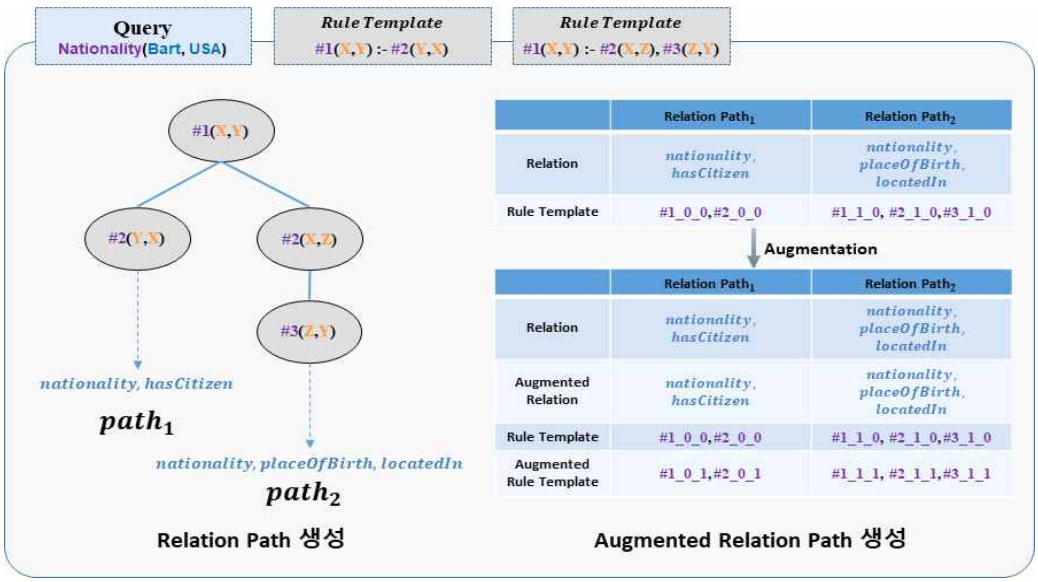


그림 2-47 Relation Path 생성 및 Augmentation 수행 과정의 예

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 릴레이션 유사도 학습을 통한 Rule Induction 연구

- 릴레이션 Path를 이용하여 모든 릴레이션에 대한 유사도 학습을 수행하여 Relation Embedding Matrix를 학습하고, 학습된 릴레이션을 통해 Rule Induction 추론 수행
- 학습된 Relation Embedding Matrix를 통해 주어진 규칙 스키마의 릴레이션과 높은 유사도의 릴레이션을 K개 선택하여 추출(K는 Augment 개수에 따라 변경)
- 추출된 릴레이션 중 높은 유사도의 릴레이션을 선택하여 Rule Inductive Decoder를 통해 정의된 규칙 스키마에 대하여 규칙을 추론
- Decoder를 통해 변환된 릴레이션을 통하여 새로운 Induced Rule 추론 수행

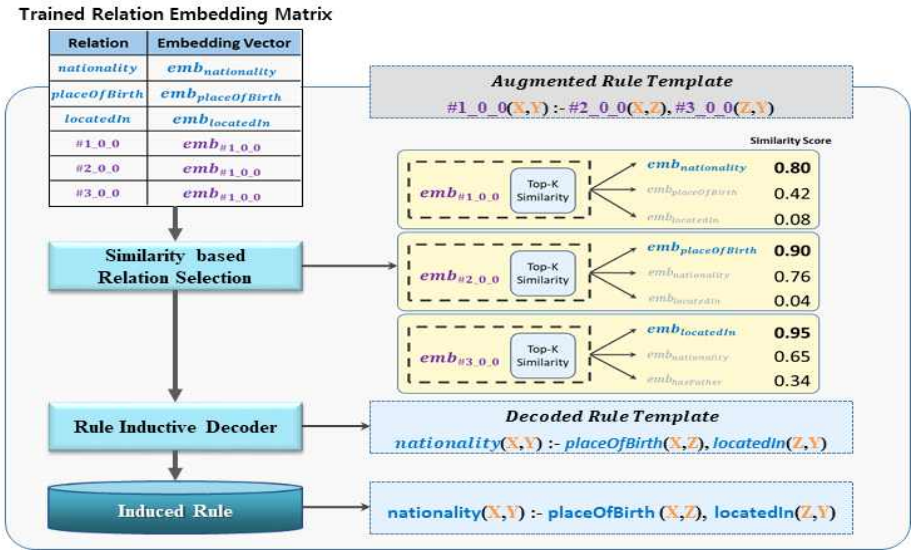


그림 2-48 릴레이션 유사도 학습을 통한 Rule Indiction의 예

● **지식완성을 위한 SWRL 기반 생성된 규칙 추론**

- Rule Induction을 통해 생성된 규칙은 SWRL 형태의 규칙으로 생성되며, 생성된 규칙을 활용한 추론을 통해 지식완성을 수행함.
- 지식 완성을 위해 SWRL 기반 규칙과 지식그래프를 입력받아 규칙에 대한 분석 과정을 수행하고 입력된 규칙에서 필요한 정보를 데이터 프레임 형태의 메타 테이블을 생성하여 메타 테이블을 참고하여 필요한 데이터를 그룹화하여 결합(JOIN)하는 과정을 통해 새로운 정보를 추론
- 규칙 기반의 추론은 선별과정에서 새롭게 추론되는 정보로부터 또 다른 새로운 정보가 파생될 수 있기 때문에 필요한 과정이며, 본 논문의 추론 방안은 추가적으로 새로운 정보에 대한 추론이 발생하지 않을 때까지 재귀적으로 추론 과정을 수행

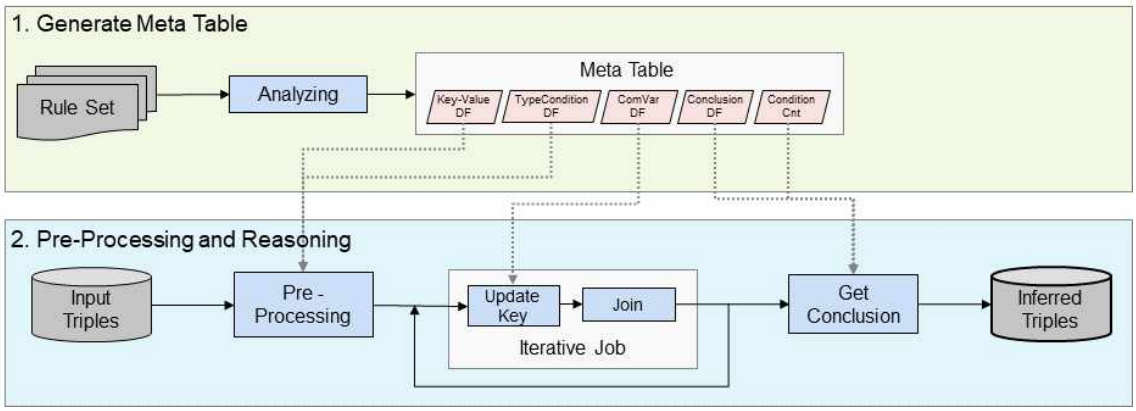


그림 2-49 SWRL 규칙 기반 추론 구조의 예

(2) 경로 기반의 관계 네트워크 모델을 이용한 지식 그래프 자동 완성 기법

- Relation network 기반의 지식 그래프 자동 완성을 위한 5단계
  - 1단계 : PRA를 통해 Target Relation에 대한 Relation Path 추출
  - 2단계 : 추출된 Path를 기반으로 Story 형태의 학습 데이터 자동 생성
  - 3단계 : LSTM 모델을 기반으로 Story 학습 데이터의 각 Sentence를 임베딩
  - 4단계 : Relation Network를 통해 Sentence와 Question 관계를 학습하여 추론 모델 생성
  - 5단계 : 학습된 Relation Network 모델을 통해 지식그래프의 Missing link를 추론

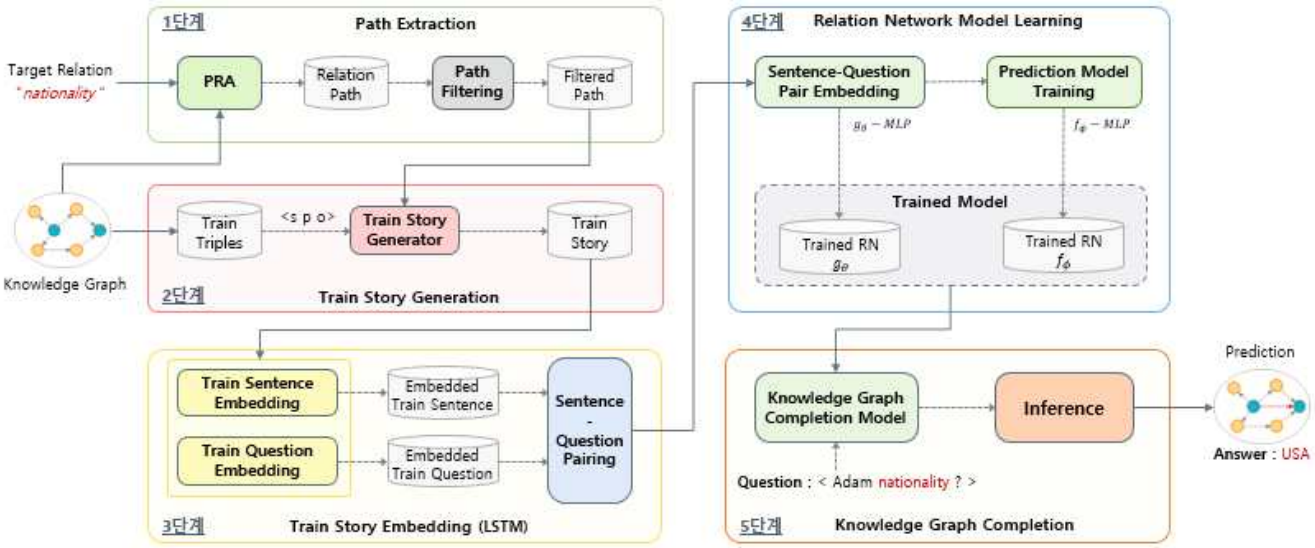


그림 2-50 경로기반 관계 네트워크의 구성

- **학습 데이터 생성을 위한 Path Ranking Algorithm 기반의 경로 추출**
  - RN을 지식 그래프 완성에 적용하기 위해서는 학습 데이터의 생성과 지식 그래프에 적합한 RN 구성이 요구됨. 이를 위한 첫번째 단계로 PRA를 기반으로 한 경로 추출 과정을 통해 RN 모델을 학습하기 위한 학습 데이터를 생성함. 목적 관계에 r_1에 대한 트리플 $< x, r_1, y >$가 주어지면, PRA의 random walks를 통해 head 노드 x로부터 tail 노드 y로 연결되는 r_1이 아닌 다른 관계 연결을 최대 길이 2~3으로 탐색함. head 노드와 tail 노드로 구성된 학습 데이터의 노드 쌍을 대상으로 모든 경로에 대한 random walks 확률을 계산하여 경로 매트릭스를 생성함
  -

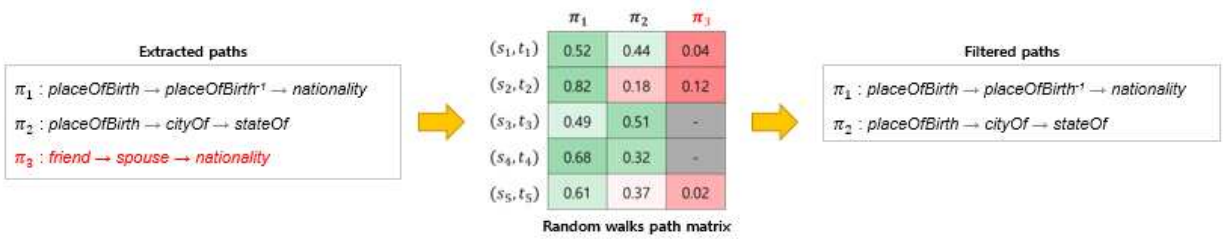


그림 2-51 경로 추출의 예

  - 경로 매트릭스의 각 셀 값은 head 노드 s_i가 경로를 통해 tail 노드 t_i에 도달할 확률을 의미하며, 이를 통해 학습에 도움이 되는 경로와 도움이 되지 않는 경로를 구분하는 것이 가능함. 예를 들어 표1의 π_2는 π_1에 비해 상대적으로 대부분의 노드 쌍에 대해서 낮은 확률을 갖고 있기 때문에 좋지 못한 경로로 분류될 수 있음. 또는 π_1과 같이 일부 노드 쌍에 대한 확률이 높더라도 과반수의 노드 쌍들이 연결되지 못하거나 낮은 확률을 갖는 경우도 학습에

도움이 되는 경로로 분류되긴 어렵다고 판단할 수 있음. 또한 추출되는 경로의 수가 매우 많기 때문에 모든 경로들을 학습에 사용하는 것은 매우 비효율적임. 따라서 학습에 사용될 수 있는 경로를 선별하는 과정이 반드시 필요함. 이를 위해 학습에 좋은 영향을 줄 수 있는 경로들을 2가지 기준으로 선택하였음. 먼저 각 경로를 통해 연결되는 노드 쌍의 비율이 전체의 70% 이상을 차지하는 경로들을 선정하였음. 예를 들어 주어진 관계에 대한 모든 트리플 중에서 path π_1을 통해 연결되는 비중이 50% 이하인 경우 경로 매트릭스에서 경로 π_1에 대한 열을 제외하였음. 두 번째로는 각 경로에 대한 random walk 확률인 경로 매트릭스의 셀 값 평균 5% 이하인 경로들은 제외하고 노드 쌍에 존재하는 대부분의 엔티티들이 연결될 수 있는 경로들을 선택하였음.

- **학습 데이터 생성**
  - RN의 학습 데이터는 반드시 컨텐스트, 질문, 정답로 구성되는 이야기 형태가 요구됨. 컨텍스트는 문장들의 집합이며, PRA로 부터 추출한 관계 경로를 사용하여 트리플로 연결된 문장을 생성할 수 있음. 추출된 각 경로의 모든 관계들이 연결될 수 있는 중간 엔티티 노드들을 지식 그래프에서 탐색하여 여러 트리플이 연결된 문장을 생성함. 예를 들어 그림1에서 target 관계가 ‘nationality’인 경우 추출된 관계 경로 ‘placeOfBirth → _placeOfBirth → nationality’를 확인할 수 있음.(‘_’는 head와 tail이 반대로 연결된 inverse 관계를 나타내는 기호). 지식 그래프에서 위 경로의 각 관계들로 연결될 수 있는 트리플들을 연결하면 아래와 같은 문장을 생성할 수 있음.

    ‘Adam_Levine placeOfBirth Los_Angeles _placeOfBirth Chris_Pine nationality United_States_of_America’

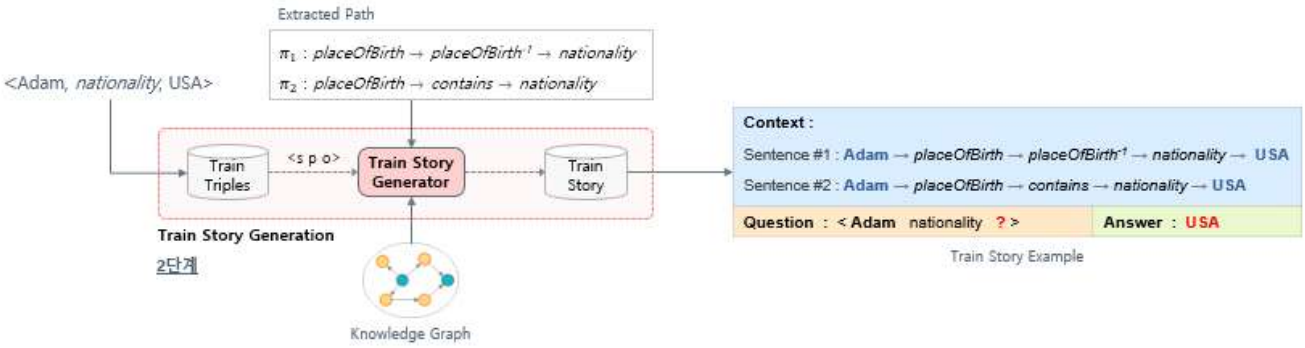


그림 2-52 이야기 기반 지식완성의 예

  - 그러나 전체 지식 그래프를 대상으로 위와 같은 문장들을 생성하게 되면, head 노드와 tail 노드를 제외한 중간 노드의 개수가 매우 많은 경우 문장의 수가 기하급수적으로 증가하게 됨. 이로 인해 학습 속도가 저하되며, 고용량의 메모리를 필요로 하게 되는 문제가 발생함. 따라서 각 관계를 추론할 수 있는 경로에 특징 자체에 집중하기 위해 head 노드와 tail 노드를 제외한 중간 노드를 모두 제거한 문장을 사용하였음. 그 결과 위 문장은 아래와 같이 변경되었고, 이를 직접 학습에 사용하였음. 생성된 문장들의 집합은 컨텍스트가 되고, 질문은 주어진 head 노드와 목적 관계를 통해 ‘Adam_Levine nationality ?’로 생성되고, 정답은 실제 tail 노드인 ‘United_States_of_America’가 되어 한 개의 이야기 데이터가 만들어지게 됨.

Relation Path	placeOfBirth	_placeOfBirth	nationality
Sentences	Adam_Levine placeOfBirth Los_Angeles Adam_Levine placeOfBirth Los_Angeles Adam_Levine placeOfBirth Los_Angeles ... Adam_Levine placeOfBirth Los_Angeles	_placeOfBirth Chris_Pine nationality _placeOfBirth Walter_H._Tyler _placeOfBirth Rashida_Jones nationality ... _placeOfBirth Angelina_Jolie nationality	United_States_of_America nationality United_States_of_America United_States_of_America Cambodia
Sentences (Intermediate Relation Removed)	Adam_Levine placeOfBirth _placeOfBirth nationality United_States_of_America Adam_Levine placeOfBirth _placeOfBirth nationality Cambodia		

Context	Adam_Levine placeOfBirth _placeOfBirth nationality United_States_of_America Adam_Levine artistOrigin _placeOfBirth nationality United_States_of_America Adam_Levine placeOfBirth contains country United_States_of_America Adam_Levine placeOfBirth _artistOrigin nationality United_States_of_America
Question	Adam_levine nationality ?
Answer	United_States_of_America

그림 2-53 관계 경로와 이야기 데이터의 예

● **관계 네트워크 학습**

- Relation network는 여러 object 사이의 관계를 추론할 수 있는 QA 모델임. CNN(Convolution Neural Network)를 통해 image를 처리하여 RN의 입력으로 사용될 수 있는 set of object를 생성하고, text 형태의 question은 LSTM을 통해 embedding 될 수 있음. 이후 CNN으로 처리된 object를 2개씩 combination하여 object pair를 생성하고, question을 추가하여 RN의 첫 번째 MLP인 g-theta에 입력됨. g-theta가 학습되면서 image에 등장한 object 사이의 관계와 object와 question 사이의 관계가 학습 될 수 있음. 이후 g-theta의 결과 값들을 통합하여 두 번째 MLP인 f-phi에 입력되고, question에 대한 answer를 예측 할 수 있는 모델이 학습되는 구조를 아래와 같이 설계하였음.

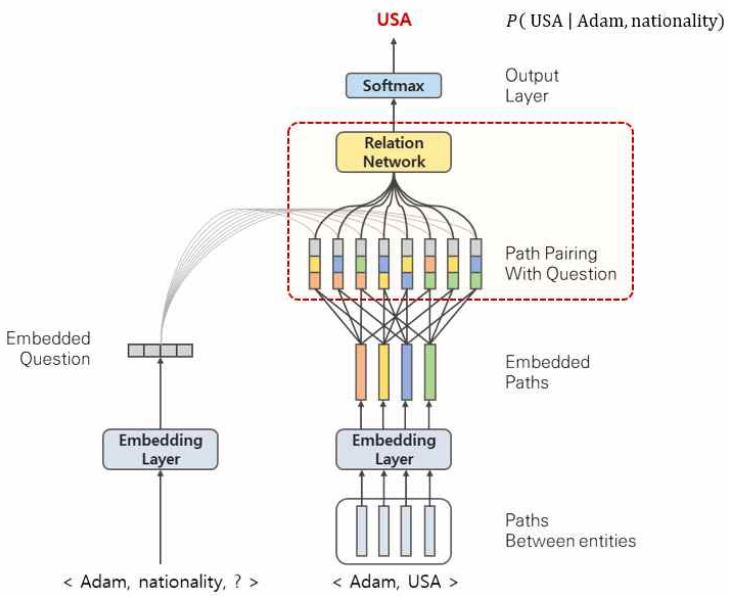


그림 2-54 관계 네트워크의 구조

- 텍스트 질의응답을 위한 관계 네트워크의 입력 형태와 동일한 지식 그래프의 이야기 데이터를 통해 관계 모델을 학습함. 트리플 형태의 질문과 컨텍스트는 LSTM의 최종 출력 값으

로 임베딩되고, 모든 문장들을 조합 쌍으로 병합함. 예를 들어 문장의 개수가 총 5개인 경우, ${}_5C_2$=10 개의 조합 쌍을 생성함. 이후 조합 쌍과 질문을 병합하고, 이를 RN의 입력으로 사용됨. 따라서 RN의 인공 신경망 모듈은 다음과 같이 2개의 문장과 질문이 조합 쌍으로 구성되어 g_θ와 f_ϕ를 통해 학습이 진행됨.

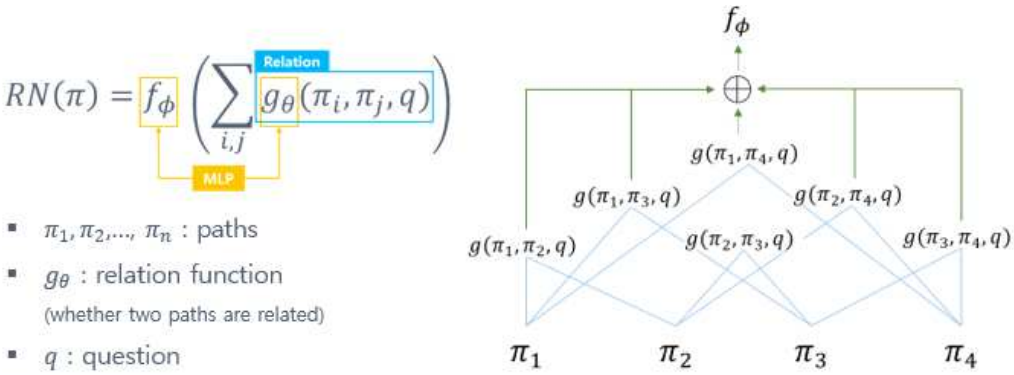


그림 2-55 관계 네트워크의 학습 함수

$$a = f_\phi\left(\sum_{i,j} g_\theta(sentence_i, sentence_j, q)\right)$$

- 예를 들어 목적 관계 R_t를 대상으로 PRA를 통해 경로 $P = R_1, R_2, R_3$가 추출되었을 때, 학습 노드 쌍은 경로 P를 통해 맵핑된 중간 엔티티들로 연결될 수 있음. 이 경우 경로 P의 각 관계를 기준으로 중간 엔티티인 e_1과 e_2로 연결된 트리플을 추출할 수 있음. 추출된 트리플들은 이야기 데이터의 컨텍스트의 문장으로 사용되고, 질문은 tail 노드인 t를 '?'으로 대체하고, 정답은 t로 설정됨. 이후 컨텍스트의 트리플들과 질문은 head, relation, tail에 대한 순서 정보의 특징을 담을 수 있도록 LSTM을 통해 임베딩을 수행함. RN의 첫번째 MLP인 g_θ는 질문과 컨텍스트의 관계를 학습하는 단계임. 따라서 LSTM을 통해 임베딩된 컨텍스트의 트리플들과 질문을 조합하여 g_θ의 입력으로 사용함.

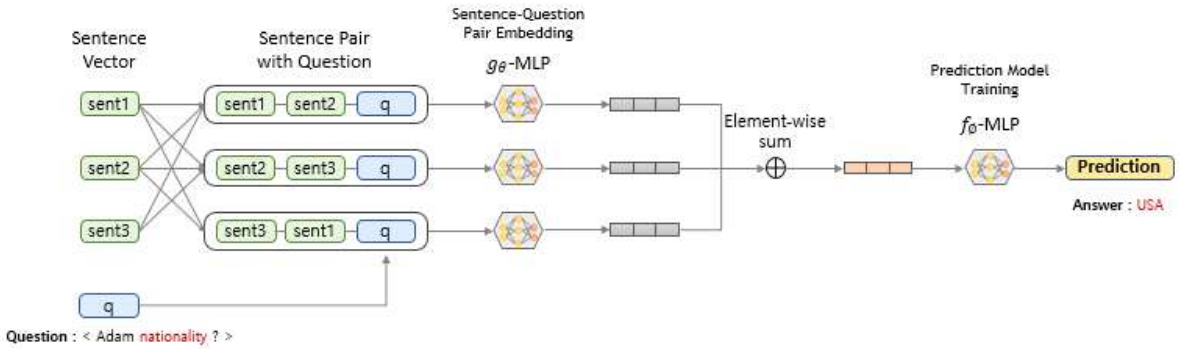


그림 2-56 질문과 컨텍스트의 관계에 따른 지식 완성

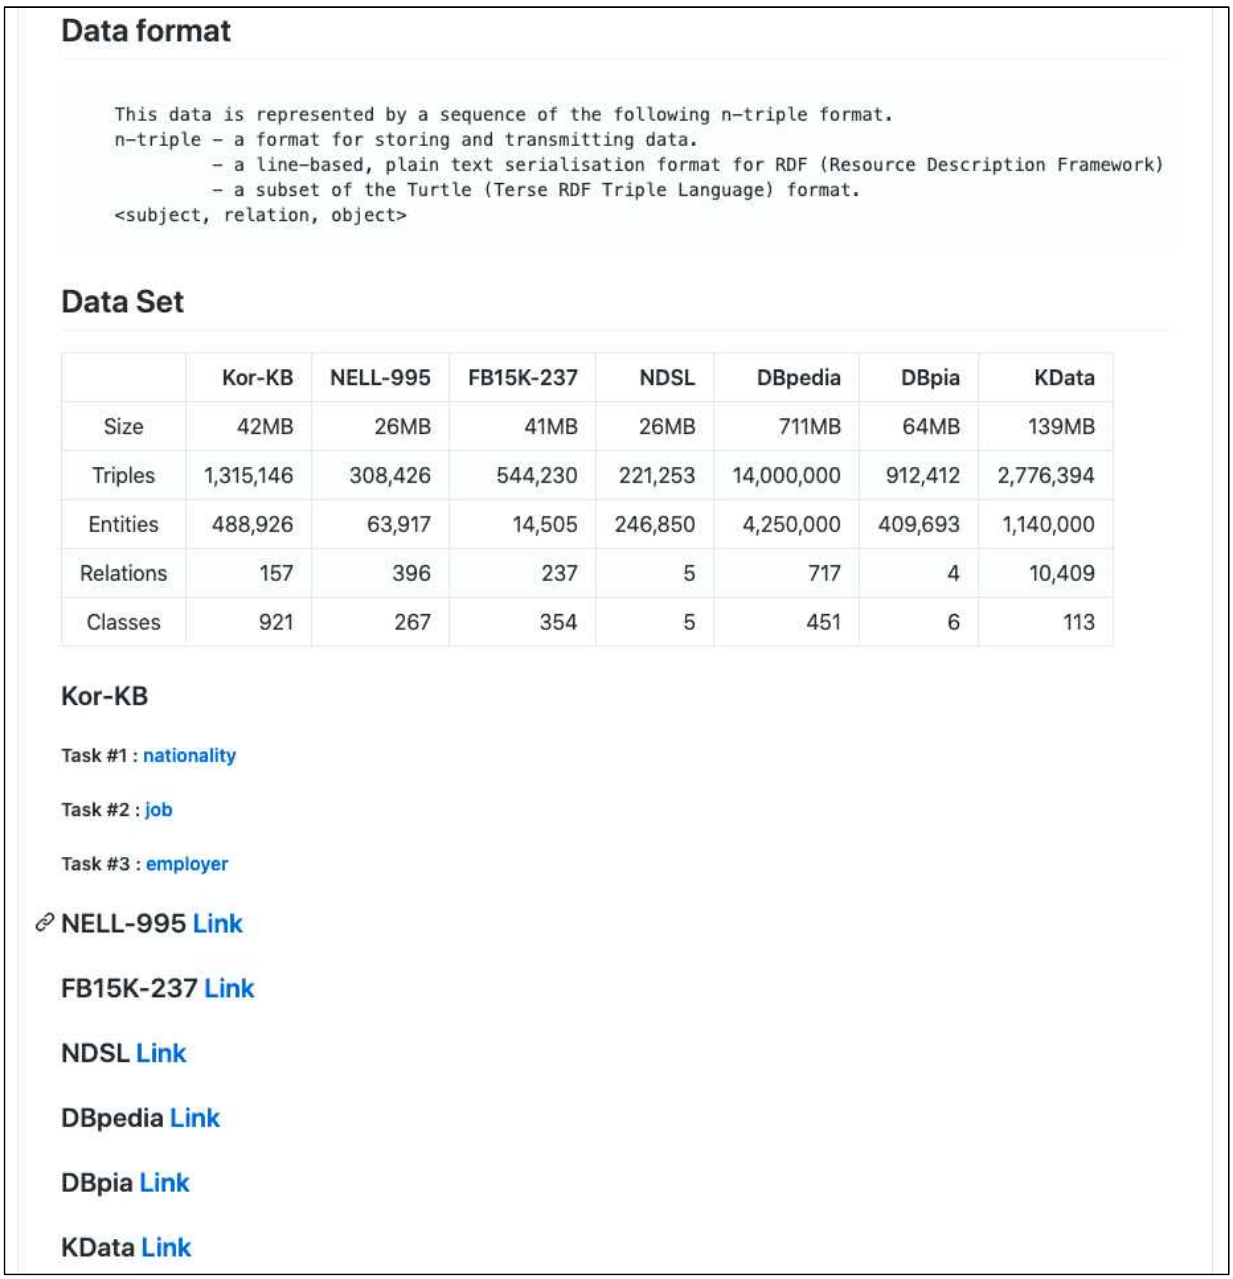
- 먼저 컨텍스트에 존재하는 모든 트리플에 대한 조합 쌍을 조합하고, 이에 질문을 추가로 병합하여 RN의 입력 데이터를 생성함. g_θ에는 총 4개의 완전 연결 레이어가 존재하며, 각 레이어는는 256개의 유닛으로 구성됨. 모든 입력 데이터들이 g_θ를 통과하면서 컨텍스트와 질문이 함께 임베딩 되었다고 간주할 수 있음. 이후 각 g_θ의 출력 벡터들은 element-wise 합계를 통해 f_ϕ의 입력으로 사용됨. f_ϕ는 총 3개의 완전 연결 레이어가 존재하며, 첫 번째 레이어는 256 유닛, 두 번째 레이어는 512 유닛으로 구성됨. 마지막 레이어는 전체 어휘 크기로 설정되어 정답에 대한 softmax 값을 출력하게 됨. 모든 학습 이야기 데이터에 대해서 위 과정에 대한 forward/backward propagation이 반복되면서 컨텍스트의 트리플들과 질문에 대한 관계가 학습되어 질문 트리플의 tail 엔티티를 예측 할 수 있는 모델이 학습될 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑶ 대용량 지식그래프 추론을 위한 데이터 확보

● 지식그래프 추론을 위한 정제된 데이터셋의 공개

- 공개된 데이터셋은 한국어 데이터인 Kor-KB와 벤치마크 데이터셋인 NELL-995, FB15K-237, 학술 논문 데이터셋인 NDSL, 여러 도메인을 갖고 있는 DBpedia, 학술 논문 데이터셋인 DBpia, 위키로부터 한국어 데이터들로 정제한 KData으로 총 7개의 데이터셋으로 구성
- 각 데이터셋은 학습 대상이 되는 Task(Relation)별로 Train, Test, Graph 로 구성되어져 있으며 Train과 Test는 8:2의 비율로 분리되어 공유함. 상대적으로 File Size가 큰 Graph는 압축하여 Zip File 형태로 공개하였음.



Data format

```
This data is represented by a sequence of the following n-triple format.
n-triple - a format for storing and transmitting data.
         - a line-based, plain text serialisation format for RDF (Resource Description Framework)
         - a subset of the Turtle (Terse RDF Triple Language) format.
<subject, relation, object>
```

Data Set

	Kor-KB	NELL-995	FB15K-237	NDSL	DBpedia	DBpia	KData
Size	42MB	26MB	41MB	26MB	711MB	64MB	139MB
Triples	1,315,146	308,426	544,230	221,253	14,000,000	912,412	2,776,394
Entities	488,926	63,917	14,505	246,850	4,250,000	409,693	1,140,000
Relations	157	396	237	5	717	4	10,409
Classes	921	267	354	5	451	6	113

Kor-KB

Task #1 : nationality

Task #2 : job

Task #3 : employer

NELL-995 Link

FB15K-237 Link

NDSL Link

DBpedia Link

DBpia Link

KData Link

그림 2-57 벤치마크 공개 데이터 셋

● 공개하는 지식그래프의 속성

- korKB 데이터셋은 한국어 데이터로 구성되어 있으며 그 중에서 지식 그래프 완성 시스템 사용에 적합한 도메인인 nationality, job, employer와 관련된 데이터들을 분류하여 생성 되었음. nationality 데이터셋은 총 1,235,060개의 트리플로 구성되어 있으며, job 데이터셋은 1,941,580개 employer 데이터셋은 1,057,470개의 트리플로 구성되어 있음.
- NELL-995 데이터셋은 NELL 시스템을 통해 995번째로 학습된 데이터에 대하여 추론에 영

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

향을 주지 않는 불필요한 트리플들을 제거함으로써 multi-hop reasoning에 적합하도록 생성된 NELL 데이터셋의 서브 셋임. 총 308,426개의 트리플로 구성되어 있음.

- FB15K-237 데이터셋은 Freebase 데이터셋에서 237개의 Relation기준으로 생성된 서브셋이며 Freebase는 메타데이터로 구성된 다양한 도메인의 지식 베이스임. FB15K-237 데이터셋은 총 544,230개의 트리플로 구성되어 있음.
- NDSL 데이터셋은 한국 과학기술 정보 연구원(KISTI)에서 제공되는 국내 학술 DB 검색 엔진으로부터 생성 되었음. 논문, 특허, 보고서, 동향, 표준, 사실정보 등 약 1억건 이상의 콘텐츠에 대한 전문 검색 서비스를 제공하며 이중 국내 논문을 도메인으로 하여 지식 그래프 추론에 필요한 데이터들로 총 221,253개의 트리플로 구성되어 있음.
- DBpedia 데이터셋은 위키백과 프로젝트에서 만든 정보로부터 구조화된 내용을 추출하기 위한 프로젝트임. 사용자가 기타 관련 데이터셋에 대한 연결을 포함하여 위키백과 자원의 관계와 속성을 시맨틱하게 질의할 수 있게 함. 이중 지식 그래프 완성에 필요한 데이터를 정제하여 서브셋으로 생성하였으며 총 15,000,000개의 트리플로 구성되어 있음.
- DBpia 데이터셋은 각 논문의 월별 시용추이 그래프와 표, 80여개 주제분류 별 많이 이용된 논문 저널 저자 등을 확인할 수 있고 국내 학술지와 학위논문을 검색할 수 있는 학술정보 포털로부터 생성된 데이터임. 이중 논문을 도메인으로 하여 지식 그래프 추론에 필요한 데이터들로 총 912,412개의 트리플로 구성되어 있음.
- KData 데이터셋은 ㈜리스트에서 wiki로부터 한국어 데이터셋을 정제하여 생성된 데이터이며 총 38,113,175개의 트리플로 구성되어 있음. 이중 지식 그래프 완성에 사용할 도메인을 선정하여 지식 그래프 완성에 필요한 데이터들로 서브셋을 생성 하였으며 총 2,776,394개의 트리플로 구성되어 있음.

● 데이터 공개 주소

- 정제된 데이터셋은 <subject, predicate, object> 형태의 N-Triple 포맷으로 공개 하였으며, 아래 URL에서 무료로 다운로드 받는 것이 가능함. 각 데이터셋 별로 바로가기 링크가 설정되어 해당 데이터셋의 정보와 다운로드를 받을 수 있음.
  공개 주소 : https://github.com/leewangon/KnowledgeGraphCompletionDataSet
  각 데이터셋별로 바로가기 링크가 설정되어 있으며 해당 데이터셋 별 페이지 이동시 비교적 데이터셋 용량의 크기가 큰 경우 업로드가 불가하여 외부 저장소로부터 다운로드 받을 수 있게 하였음. 또한 각 데이터셋별로 다운로드 받게 될 데이터의 예시를 확인할 수 있음.

● 공개하는 지식그래프의 내용

- KorKB 데이터셋의 크기는 42MB이며 총 트리플 수는 1,315,146개 총 엔티티 수는 488,926개 총 릴레이션의 수는 157개 그리고 921개의 클래스로 구성되어 있음.
  서브셋 지식 그래프로 nationality, job, employer 세가지가 있으며 nationality 데이터셋은 1,235,060개의 트리플로 구성되어 있음. 학습을 위한 train, test 데이터를 구성하였으며 train은 58,893개 test는 14,727개의 데이터셋으로 생성 함. job 데이터셋은 1,941,580개의 트리플로 구성되어 있으며 학습을 위한 train 데이터셋은 288,437개 test 데이터셋은 79,500개로 생성함. 마지막 employer 데이터셋은 1,057,470개의 트리플로 구성되어 있으며 학습을 위한 train 데이터셋은 42,309개 test 데이터셋은 14,268개로 생성함. 지식 그래프는 <subject, relation, object> 형태의 트리플로 구성 되며 train, test 데이터셋은 subejct와 object 그리고 label로 구성되어 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	subject	relation	object
1	김을동	education	중앙대학교
2	미국	diedIn_inv	재키 로빈슨
...	...	...	...

	subject	object	label
1	김경민	대한민국	+
2	김경민	미국	-
...	...	...	...

그림 2-58 공개 데이터셋 KorKB 데이터셋의 예

- NELL-995 데이터셋의 크기는 26MB이며 총 트리플 수는 308,426개 총 엔티티 수는 63,917개 총 릴레이션의 수는 396개 그리고 267개의 클래스로 구성되어 있음. 대용량 지식 그래프 추론 및 벤치마크 데이터셋으로 다양한 연구에서 사용되고 있는 CMU의 NELL (http://rtw.ml.cmu.edu/rtw/) 데이터셋을 활용하여 정제된 데이터를 생성하였음. NELL 데이터 중 모호성을 갖는 지식들을 제거하고, 추론 성능 측정에 관여하지 않는 데이터 클리닝을 수행하여 보다 지식 그래프 추론에 적합한 데이터를 생성함. Coordinates, time, dates와 관련된 트리플들을 제거하여 지식그래프 완성에서 활용되지 않는 정보들을 제외하였음. NELL의 대학 스포츠팀들의 대한 정보가 오류를 갖고 있어서 정확성과 일관성에 문제가 있는 정보들을 추가로 삭제하였음.
-

	subject	relation	object
1	concept_person_molly_moore	concept:worksfor	concept_city_washington_d_c
2	concept_hotel_pullman	concept:atlocation	concept_city_washington_d_c
...	...	...	...

	subject	object	label
1	thing$concept_athlete_adam_bostick	thing$concept_sportsleague_mlb	+
2	thing$concept_athlete_adam_bostick	thing$concept_sportsleague_nba	-
...	...	...	...

그림 2-59 NELL 데이터셋의 예

- FB15K-237 데이터셋의 크기는 41MB이며 총 트리플 수는 544,230개 총 엔티티 수는 14,505개 총 릴레이션의 수는 237개 그리고 354개의 클래스로 구성되어 있음. Freebase의 서브셋으로 약 15,000개의 엔티티와 1,300개의 릴레이션으로 구성된 FB15K 데이터셋에서 정제된 데이터셋임. FB15K-237에 대해 앞서 언급된 공개 주소를 통하여 다운로드 받을 수 있음 또한 상세 내용으로 예시 데이터셋과 학습에 필요한 272,115개의 train 데이터셋과 20,466개의 test 데이터셋 또한 받을 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

FB15K-237

Graph.txt

```
This data is represented by a sequence of the following format.
subject, relation, object

# of Triples : 544,230
```

Sample

	subject	relation	object
1	/m/05hs4r	/music/genre/artists	/m/01pbxb
2	/m/018dnt	/film/actor/film./film/performance/film	/m/050r1z
...	...	...	...

그림 2-60 FB15K-237 데이터셋의 예

- NDSL 데이터셋의 크기는 26MB이며 총 트리플 수는 221,253개 총 엔티티 수는 246,850개 총 릴레이션의 수는 5개 그리고 5개의 클래스로 구성되어 있음. 과학에 관련된 DB를 검색하고 학술지나 논문과 같은 다양한 정보들의 원본을 볼수 있는 국가과학기술정보센터로부터 생성된 데이터이며 앞서 언급된 공개 주소를 통하여 다운로드 받을 수 있음 또한 상세 내용으로 예시 데이터셋을 확인할 수 있음.

NDSL

NDSL_graph.nt

```
This data is represented by a sequence of the following format.
subject, relation, object

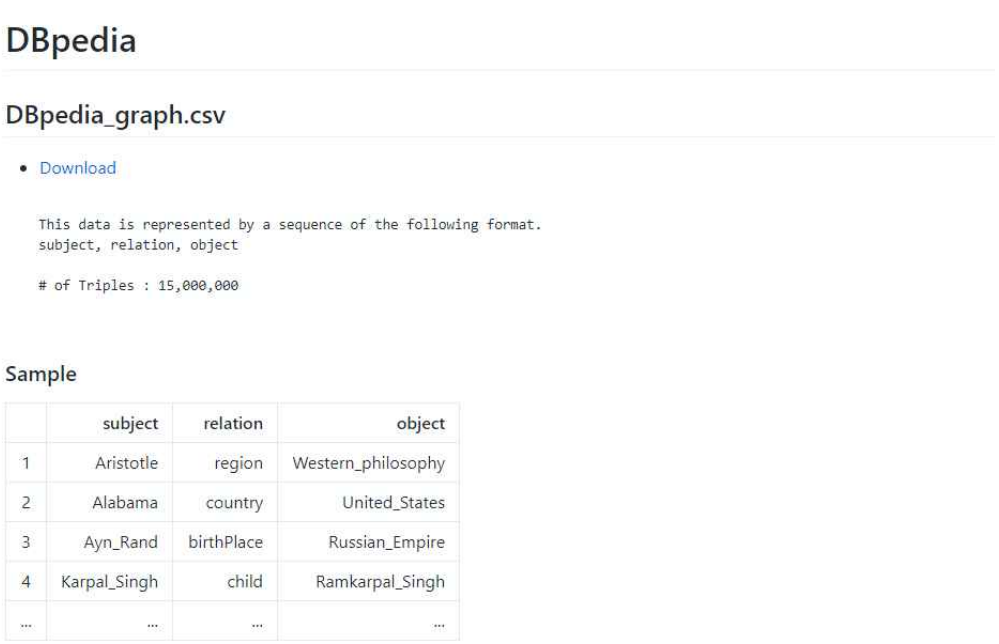
# of Triples : 221,253
```

Sample

	subject	relation	object
1	ADPER0000138165	belongTo	신흥대학 경상정보계열
2	ADPER0000138165	create	JAKO200833337682226
3	동국대학교 행정학과	_belongTo	ADPER1000030099
4	중앙대학교 문헌정보학과	_belongTo	ADPER1000000042
...	...	...	...

그림 2-61 NDSL 데이터셋의 예

- DBpedia 데이터셋의 크기는 711MB이며 총 트리플 수는 14,000,000개 총 엔티티 수는 4,250,000개 총 릴레이션의 수는 717개 그리고 451개의 클래스로 구성되어 있음. 다양한 도메인을 주제로 구조화된 정보들을 갖고 있으며 시맨틱하게 질의 할 수 있는 프로젝트로부터 생성된 데이터이며 앞서 언급된 공개 주소를 통하여 다운로드 받을 수 있음 또한 해당 주소를 통해 다운로드 받게 될 데이터의 예시를 확인할 수 있음. DBpedia와 같이 비교적 큰 데이터셋은 언급된 공개 주소에 업로드가 불가하여 Download 링크를 통해 외부 저장소로부터 다운로드 받게 되어 있음.



DBpedia

DBpedia_graph.csv

- Download

This data is represented by a sequence of the following format.
subject, relation, object

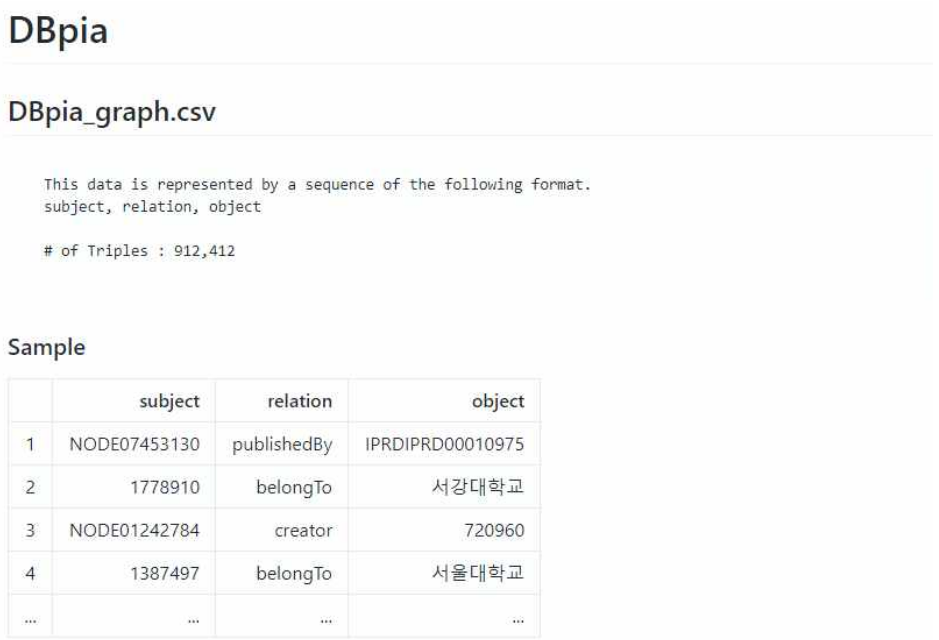
of Triples : 15,000,000

Sample

	subject	relation	object
1	Aristotle	region	Western_philosophy
2	Alabama	country	United_States
3	Ayn_Rand	birthPlace	Russian_Empire
4	Karpal_Singh	child	Ramkarpal_Singh
...	...	...	...

그림 2-62 DBpedia 데이터셋의 예

- DBpia 데이터셋의 크기는 64MB이며 총 트리플 수는 912,412개 총 엔티티 수는 409,693개 총 릴레이션의 수는 4개 그리고 6개의 클래스로 구성되어 있음. 200만여 편의 논문을 수록하고, 매월 1만여 편의 논문을 업데이트하며 웹 DB 멀티 미디어, 문집 등을 포괄하는 지식 콘텐츠로부터 생성되었으며, 앞서 소개한 NDSL 데이터셋과 같이 국내 논문지를 도메인으로 정제한 데이터셋 임. 앞서 언급된 공개 주소를 통하여 압축된 형태로 다운로드 받을 수 있음. 또한 해당 주소를 통해 다운로드 받게 될 데이터의 예시를 확인할 수 있음.



DBpia

DBpia_graph.csv

This data is represented by a sequence of the following format.
subject, relation, object

of Triples : 912,412

Sample

	subject	relation	object
1	NODE07453130	publishedBy	IPRDIPRD00010975
2	1778910	belongTo	서강대학교
3	NODE01242784	creator	720960
4	1387497	belongTo	서울대학교
...	...	...	...

그림 2-63 DBpia 데이터셋의 예

- KData 데이터셋의 크기는 139MB이며 총 트리플 수는 2,776,394개 총 엔티티 수는 1,140,000개 총 릴레이션의 수는 10,409개 그리고 113개의 클래스로 구성되어 있음. KData는 불특정 다수가 협업을 통해 직접 내용과 구조를 수정할 수 있는 웹 백과사전 프로젝트로부터 한국데이터를 정제해 생성한 데이터셋임 앞서 언급된 공개 주소를 통해 실 데이터의 예시를 확인할 수 있으며 비교적 큰 데이터셋이므로 공개 주소에 업로드가 불가하여 Download 링크를 통해 외부 저장소로부터 다운로드 받게 되어 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

KData

KData_graph.nt

- Download
- KData의 라이센스는 (주)리스트 에 있음

```
This data is represented by a sequence of the following format.
subject, relation, object

# of Triples : 2,776,394
```

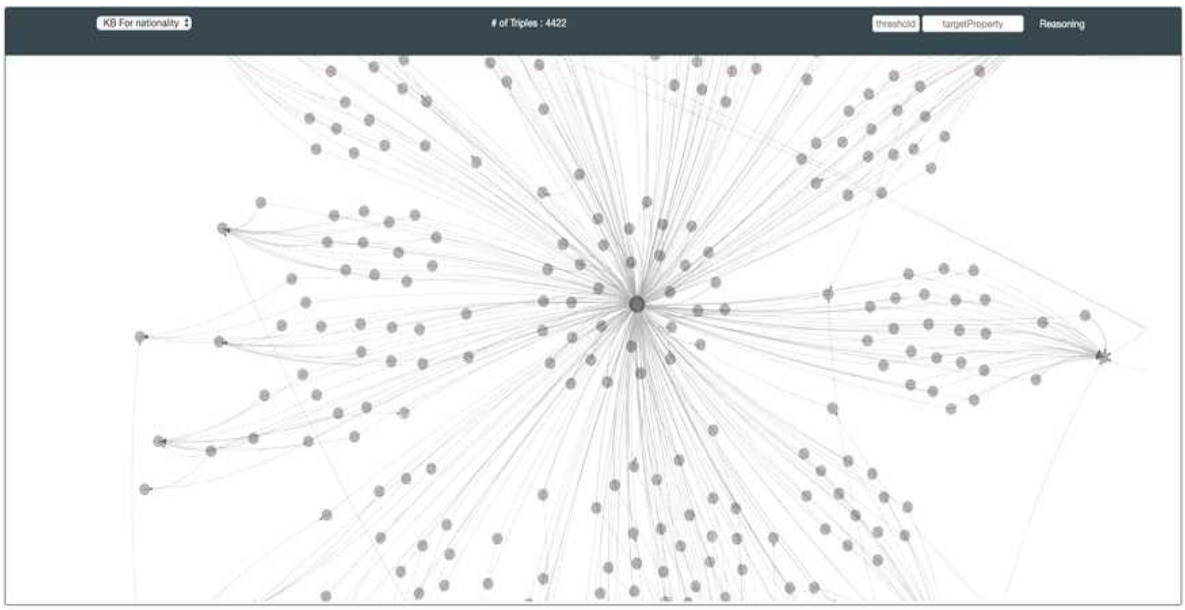
Sample

	subject	relation	object
1	백남준	직업	아티스트
2	함석헌	자녀	함국용
3	김수철	출생지	서울특별시
4	황현주	국적	대한민국
...	...	...	...

그림 2-64 KData 데이터 셋의 예

(4) 지식 그래프 완성 시스템 검증을 위한 Visualization 도구

- 딥러닝 기반 지식 완성 모델 Visualization 도구의 사용 범위
  - 학습이 완료된 딥러닝 기반 지식 완성 모델의 성능과 추론 결과를 확인하기 위한 Visualization 도구를 개발
  - 딥러닝 기반 지식 완성 모델을 통해 실제 추론된 결과를 확인하는 것이 가능함.
- 딥러닝 기반 지식 완성 모델 Visualization 도구의 기능 활용
  - 도구는 지식 완성에 사용된 지식 그래프를 선택하고, 해당 지식 그래프를 대상으로 지식 완성 모델이 추론한 지식의 Score가 주어진 Threshold 보다 큰 경우를 추론할 수 있도록 구성되었음.
  - 아래 예는 Kor-KB를 대상으로 Score가 0.9보다 큰 경우를 추론하였을 때, 추론 전과 추론 후를 나타냄.



추론 전

그림 2-65 Visualization 도구를 통한 지식그래프 출력의 예

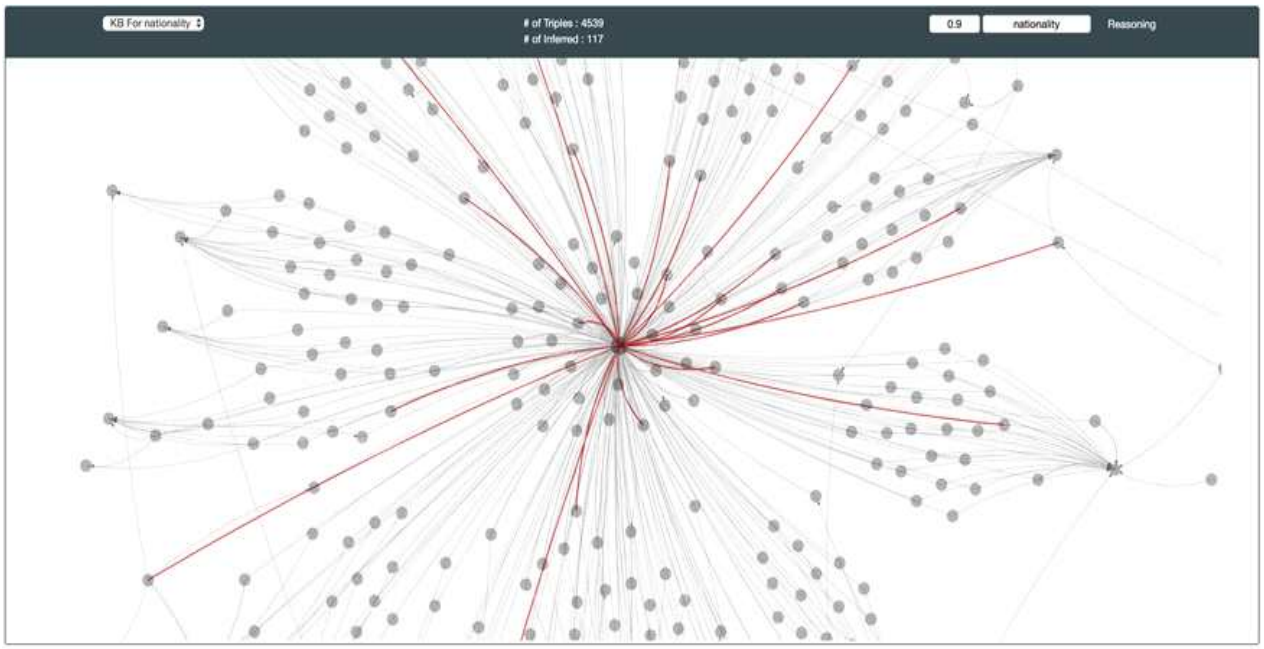


그림 2-66 Visualization 도구를 통한 추론된 지식그래프 출력의 예

- Target Relation과 Threshold를 설정하고 추론을 수행하면, Red Color로 추론된 Link가 표시되며, 해당 링크로 연결된 지식 노드의 Score를 확인하는 것이 가능함. 추론된 링크와 연결된 Entity 후보 각각의 예측 점수를 확인할 수 있음.
-

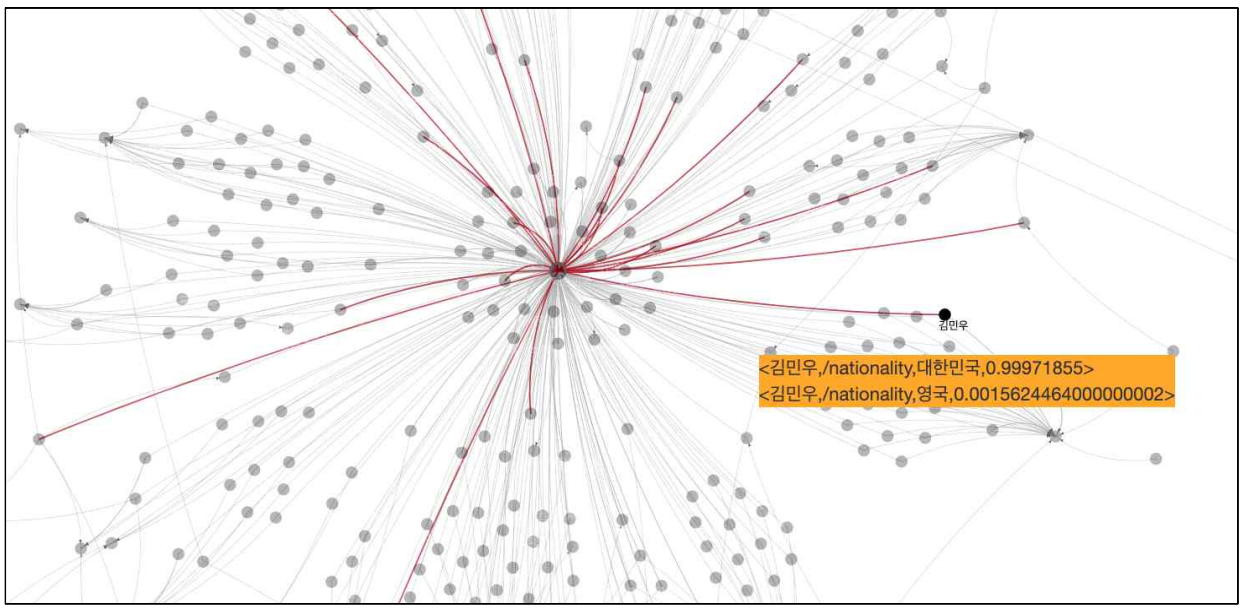


그림 2-67 지식 완성 모델로부터 추론된 지식의 Score 정보

- 지식 그래프의 노드를 탐색하면서 추론된 정보를 확인하면서 해당 노드의 정의를 확인하기 위해 Wikipedia 지식을 확인할 수 있는 편의 기능을 제공함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



그림 2-68 지식 그래프의 위키피디아 정보 확인

- 규칙 추론 기반 지식 완성 시스템 검증을 위한 Visualization 도구
  - 분산테이블 구조를 활용한 규칙 추론 기반 OWL-Horst/SWRL 추론 시스템의 성능과 추론 결과를 확인하기 위한 Visualization 도구를 개발
  - Display Graph 버튼을 통해 추론전 지식그래프를 볼 수 있으며 왼쪽에는 Ontology Schema, 오른쪽에는 Ontology Instance가 표현.

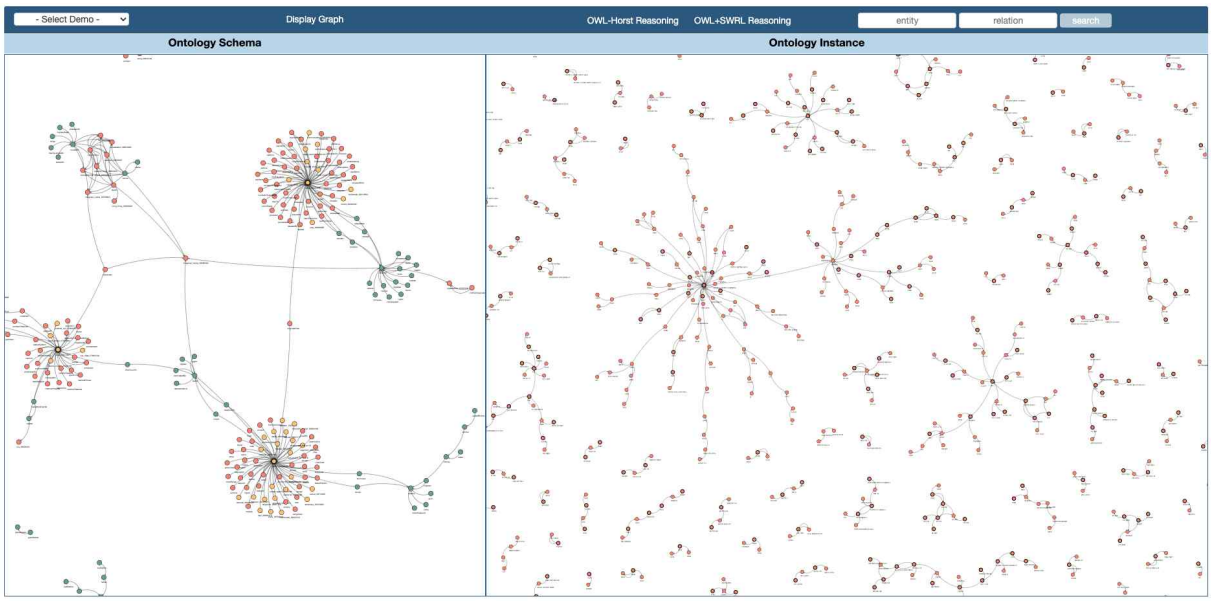


그림 2-69 추론 전 지식 그래프

  - OWL-Horst Reasoning 버튼을 통해 OWL-Horst 규칙 추론을 하고 OWL+SWRL Reasoning 버튼을 통해 SWRL 규칙 추론을 진행.
  - 붉은 선은 OWL-Horst 규칙 추론을 통해 추론된 트리플을 의미하며 파란 선은 SWRL 규칙 추론을 통해 추론된 트리플을 의미함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

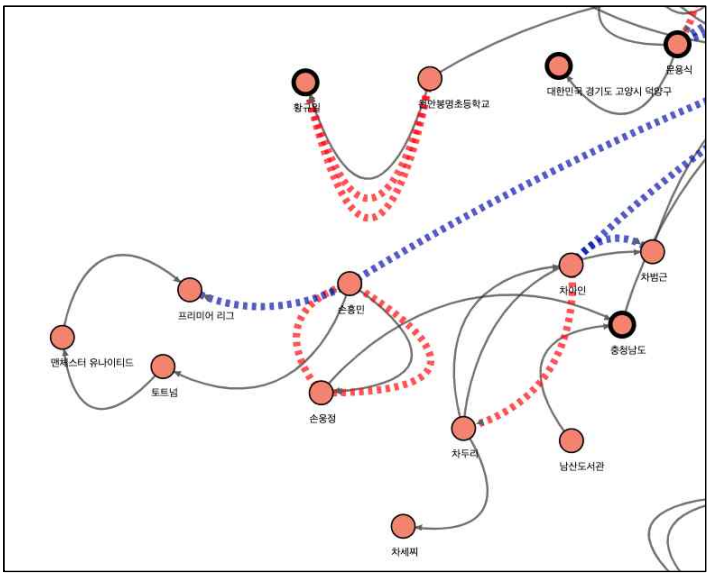


그림 2-70 추론 후 지식 그래프

- 추론된 트리플의 추론 과정을 확인하는 기능으로 각 추론 트리플 대시 선을 클릭하게되면 추론 과정을 확인할 수 있음.

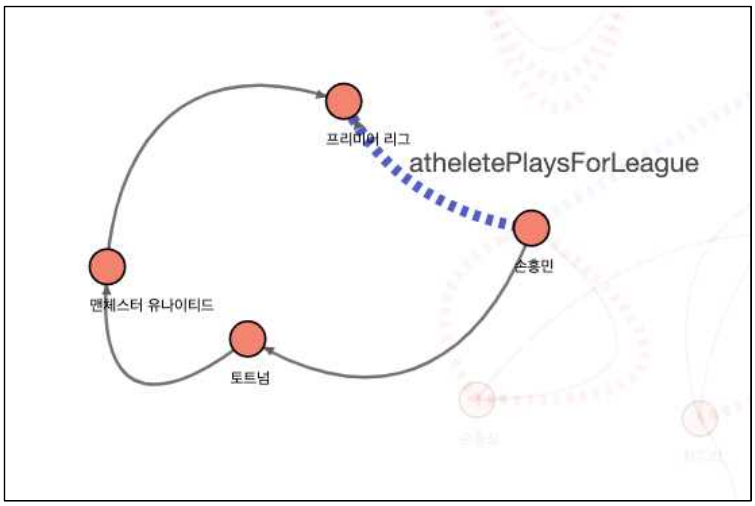


그림 2-71 SWRL 규칙 추론 결과

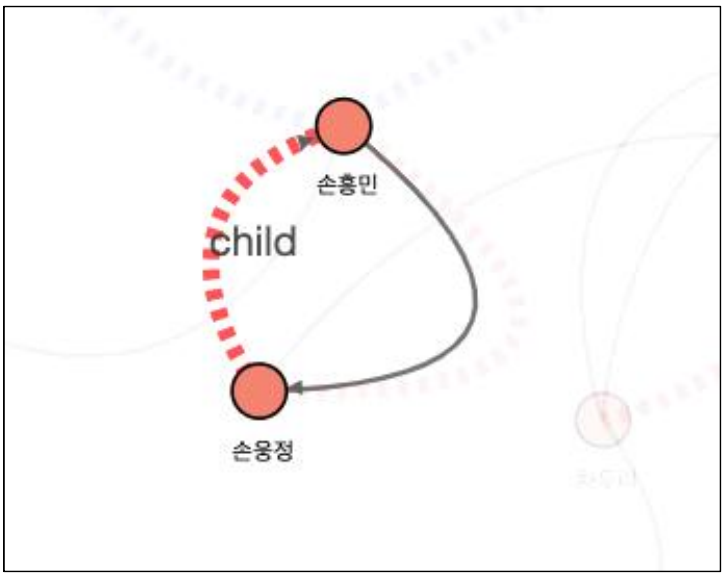


그림 2-72 OWL-Horst 규칙 추론 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3. 연구개발과제의 수행 결과 및 목표 달성 정도

1) 연구수행 결과

(1) 정성적 연구개발성과

< 연구개발성과 성능지표 >

평가 항목 (주요성능[1])	단위	전체 항목에서 차지하는 비중[2] (%)	세계 최고		연구개발 전 국내 성능수준	연구개발 목표치			목표설정 근거	추진실적
			보유국/보유기관	성능수준	성능수준	1차년도 (2019년)	2차년도 (2020년)	3차년도 (2021년)		
1. 빅데이터 시맨틱 분산 추론 속도	트리플/초	20 %	네덜란드 / VU	170,000	160,000	150,000	170,000	250,000	공인평가	**428,414** (71%초과)
2. 빅데이터 시맨틱 추론 증강도	증강도(%)	15 %	네덜란드 / VU	70%	55%	60%	70%	80%	자체평가	**91.43%** (11%초과)
3. 대용량 지식그래프 자동 완성도	Accuracy (%)	15 %	미국 / NDU	87%	75%	82%	87%	90%	자체평가	**92.2%** (2%초과)
4. 빅데이터 Link Prediction 정확도	MAP	20 %	미국 / CMU	0.88	0.79	0.75	0.80	0.85	공인평가	**0.97** (12%초과)
5. 빅데이터 오류 자동 완성도	F1-Score	15 %	미국 / Stanford	0.75	0.70	0.73	0.76	0.80	자체평가	**0.86** (6%초과)
6. 빅데이터 시맨틱 추론 정확도	Accuracy (%)	15 %	영국/ABDN	91%	85%	87%	90%	93%	자체평가	**94.03%** (1%초과)

* 1」 정밀도, 인장강도, 내충격성, 작동전압, 응답시간 등 기술적 성능판단기준이 되는 것을 의미합니다.

* 2」 비중은 각 구성성능 사양의 최종목표에 대한 상대적 중요도를 말하며 합계는 100%이어야 합니다.

가. 공인인증 평가 진행 결과

한국정보통신기술협회(TTA) 소프트웨어시험인증연구소의 확인 및 검증 시험(V&V)를 통해 '빅데이터시맨틱 분산추론 속도'와 '빅데이터 Link Prediction 추론 증강도'에 대한 공인인증평가를 진행함.

● 빅데이터 시맨틱 분산 추론 속도

- Spark 기반의 OWL-Horst 분산 추론 시스템의 초당 처리 가능한 트리플 수 측정

ID	구분	내용
TC1	시험 항목명	빅데이터시맨틱 분산추론 속도 (트리플 / 초)
	시험 목표	지식베이스 기반의 애플리케이션 벤치마크를 위한 LUBM100 데이터셋을 대상으로 OWL-Horst 수준의 추론을 수행하고, 초당 처리할 수 있는 데이터의 양을 측정함. Throughput = Input 데이터의 트리플 수 / 추론 시간
	사전 조건	Microsoft Azure Databricks Cloud
	시료	LUBM(Lehigh University Benchmark) 데이터셋 - LUBM100 Ex) <FullProfessor7> <teacherOf> <GraduateCourse11> <FullProfessor7> <doctoralDegreeFrom> <http://www.University241.edu> <FullProfessor7> <worksFor> <http://www.Department0.University0.edu> <FullProfessor7> <teacherOf> <Course10> <FullProfessor7> <researchInterest> "Research3"
	반복시험 횟수	3회
	시험 절차	1. Microsoft Azure Databricks 로그인 2. Databricks Workspace 실행 3. Workspace 메뉴를 통해 다음 경로의 main 파일을 선택 'Workspace / Users / youngtackpark@gmail.com / owl_reasoner / main' 4. 상단 메뉴의 Run 아이콘 클릭 5. 시험 종류 후 출력되는 'Throughput' 값 확인
	예상결과	아래와 같이 계산되는 Throughput 값이 150,000 이상을 기록 Throughput = Input 데이터의 트리플 수 / 추론 시간
	예외사항	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 빅데이터 Link Prediction 추론 증강도
- BiLSTM과 Attention 기반의 경로 임베딩 시스템의 MAP 증강도(%) 측정

ID	구분	내용
TC1	시험 항목명	빅데이터 Link Prediction 추론 증강도
	시험 목표	시험대상 제품(Knowledge Completion Model)로 Knowledge Graph ‘Kinship‘ 데이터에 대한 학습/테스트 실행 시 MAP(Mean Average Prediction)값 확인 - BiLSTM 기반의 Knowledge Completion Model을 사용함 - Knowledge Graph ‘Kinship‘ 데이터: 10개 term으로 구성된 말뭉치 데이터
	사전 조건	1) conda 4.7.10 2) python 3.6 3) python libarary (keras 2.2.4, pandas 0.25.0, scikit-learn 0.21.2) 4) 테스트용 데이터가 [~/Desktop/conv_bilstm_model/data]에 위치 5) 데이터 학습에 관련된 프로그램 소스코드 리뷰가 가능해야 함 6) 학습/테스트 대상 데이터에 대한 세부내용 리뷰가 가능해야 함
	시료	1) 10개 task에 대한 데이터 디렉토리(term1, term2, ..., term10) a) 각 task에 대한 term# 디렉토리에는 8개의 파일 존재 - 지식 그래프 파일 graph.txt - 학습용 파일 train.pairs, train_pos, train.txt, dev.txt - 테스트용 파일 sort_test.pairs, test.pairs, test.txt
	반복시험 횟수	5회
	시험 절차	1. Anaconda 다운로드 > wget https://repo.anaconda.com/archive/Anaconda3-2019.07-Linux-x86_64.sh 2. Anaconda 설치 > bash Anaconda3-2019.07-Linux-x86_64.sh 3. Anaconda 환경변수 적용 > source ~/.bashrc 4. Anaconda 환경 생성 > conda create -n tta python=3.6 5. Anaconda 환경 실행 > conda activate tta 6. 제공된 프로젝트 ‘conv_bilstm_model.zip’ 파일의 압축 해제 > unzip conv_bilstm_model.zip 7. 프로젝트 디렉토리로 이동 > cd conv_bilstm_model

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 연구 개발 성과

● 빅데이터시맨틱 분산추론 속도

- 클라우드 환경에서 분산추론 속도가 목표치인 170,000 트리플/초를 초과하여 평균 428,414 트리플/초의 성능을 얻었으며, TTA를 통한 제 3자 인증을 통해 공인 평가를 진행하였음

No.	트리플 입력 수	분석시간	처리량(건/초)
1	68,843,799 건	128.365 초	563,310
2	68,843,799 건	155.629 초	442,360
3	68,843,799 건	198.253 초	347,250
4	68,843,799 건	165.258 초	416,580
5	68,843,799 건	172.295 초	399,570
최대 처리량(건/초)			536,310
최소 처리량(건/초)			347,250
평균 처리량(건/초)			428,414

- 산정수식(처리량) = Input 데이터의 트리플 수 / 추론 시간
- 시험대상제품으로 LUBM500 데이터셋에 대한 OWL-Horst 수준의 시맨틱 추론 수행시, 초당 처리량을 확인한 결과임.

● 빅데이터시맨틱 추론 증강도

- 경험적 지식을 바탕으로 작성된 규칙을 통해 목표치인 70%를 초과하여 91.43% 증강도를 달성함

Class 규칙 개수	Property 규칙 개수	SWRL 규칙 개수	지식 베이스 개수	추론된 지식 개수 (개)			지식 증강도
				기본스키마 추론 지식	SWRL 추론 지식	총 합계	
1개	1개	35개	1,708,761개	1,306,420	255,967	1,562,387	91.43%

- Spark 기반 추론 엔진에서 기본 스키마(지식의 Class, Property 관계) 추론, 사용자 정의(SWRL) 규칙 추론 수행 시, 기존 지식 대비 새롭게 추론된 지식의 증강도(비율)이 91.43%로 확인되었음
- 결과로 추론된 지식 1,562,387개는 기본 스키마에서 추론된 지식 1,306,420개와 SWRL규칙(35개)에서 추론된 지식 255,967개로 구성됨

● 대용량 지식그래프 자동 완성도

- 자동 완성도의 정확도를 나타내는 Accuracy가 목표치인 87%보다 높은 92.2%를 달성함. NELL995의 릴레이션 athletePlaysInLeague, athletePlaysSport, teamPlaysInLeague, athleteHomeStadium, athletePlaysfForTeam 에 대한 지식 그래프 자동 완성을 수행하여 테스트 데이터에 대한 accuracy를 측정하였으며, 아래 각 표는 릴레이션 별 accuracy를 나타냄.

Relation	# of query	Accuracy
athletePlaysInLeague	381	96.1
athletePlaysSport	603	95.3
teamplaysinleague	309	89.2
athletehomestadium	201	91.3
athleteplaysforteam	387	89.1
Avg.	1,881	92.2

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 빅데이터 Link Prediction 추론 증강도

- 최대 정밀도의 평균을 의미하는 MAP 증강도가 목표치인 75%를 초과하여 97.12%를 달성하였고, TTA를 통한 제 3자 인증을 통해 공인 평가 진행 완료

반복회차	결과(단어1~5에 대한 MAP)				
	단어#1 (term0)	단어#2 (term1)	단어#3 (term2)	단어#4 (term3)	단어#5 (term4)
1	95.24%	96.96%	94.12%	96.56%	96.21%
2	95.24%	96.96%	94.12%	96.56%	96.97%
3	95.24%	96.96%	94.12%	96.56%	96.97%
4	95.24%	96.96%	94.12%	96.56%	96.21%
5	95.24%	96.96%	94.12%	96.56%	96.21%
6	95.24%	96.96%	94.12%	96.56%	96.21%
7	95.24%	96.96%	94.12%	96.56%	96.21%
8	95.24%	96.96%	94.12%	96.56%	96.21%
9	95.24%	96.96%	94.12%	96.56%	96.21%
10	95.24%	96.96%	94.12%	96.56%	96.21%

반복회차	결과(단어6~10에 대한 MAP)				
	단어#6 (term5)	단어#7 (term6)	단어#8 (term7)	단어#9 (term8)	단어#10 (term9)
1	100.00%	98.44%	97.49%	97.87%	97.67%
2	100.00%	98.44%	97.71%	97.87%	97.67%
3	100.00%	98.44%	97.17%	98.07%	97.67%
4	100.00%	100.00%	97.44%	98.17%	97.67%
5	100.00%	98.44%	97.45%	97.73%	97.67%
6	100.00%	100.00%	96.96%	97.87%	97.67%
7	100.00%	98.44%	97.55%	97.73%	97.67%
8	100.00%	100.00%	97.65%	97.73%	97.67%
9	100.00%	98.44%	98.02%	98.03%	97.67%
10	100.00%	98.44%	97.45%	97.73%	97.67%

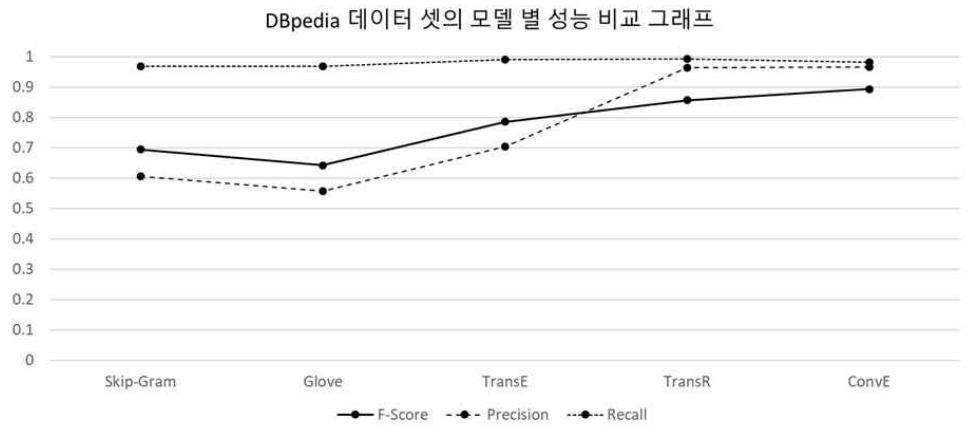
- 지식그래프 ‘Kinship’ 데이터중 10개 단어(term)을 기준으로 학습/테스트 실행 시 MAP(Mean Average Precision)은 97.12%로 확인되었음

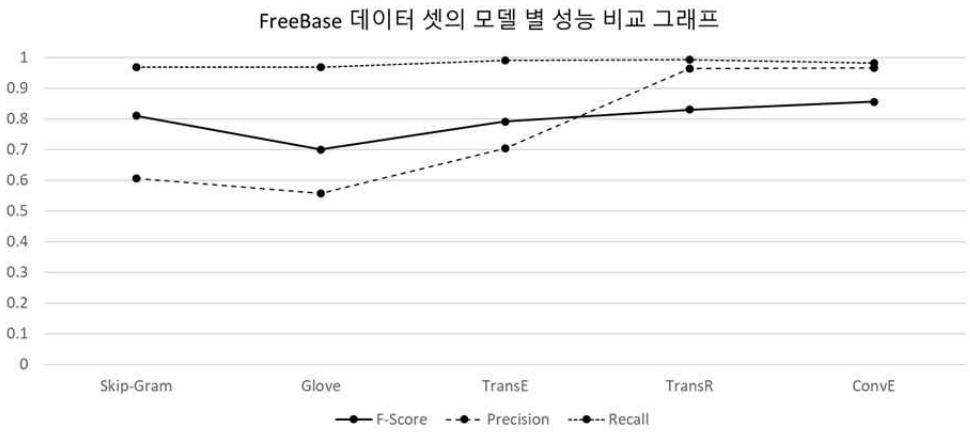
● 빅데이터 오류 자동 완성도

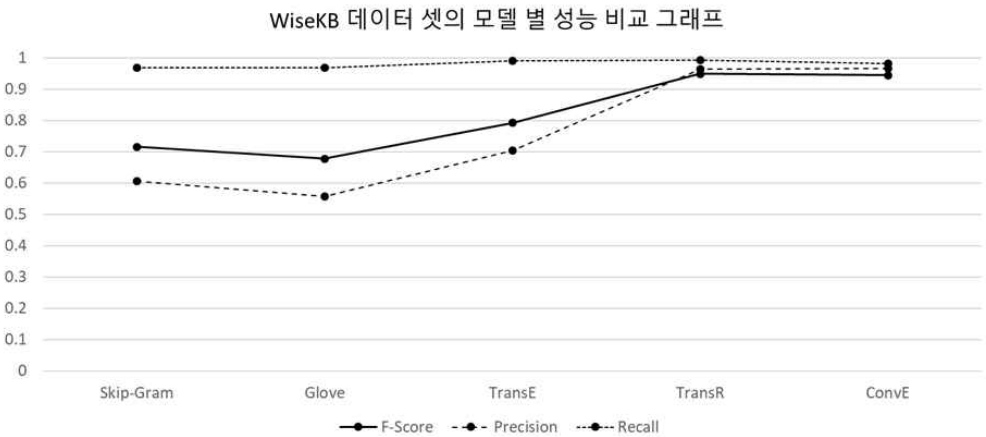
- 정밀도와 재현율 사이의 조화평균값인 F1-Score가 목표치 0.76보다 높은 0.79을 기록하였음

Data Set	평가 지표	Entity Embedding		Relation Modeling		
		Skip-Gram	Glove	TransE	TransR	ConvE
DB pedia	F-Score	0.695	0.642	0.786	0.857	**0.894**
	Precision	0.582	0.511	0.696	0.816	0.859
	Recall	0.959	0.981	0.986	0.971	0.999
Free base	F-Score	0.810	0.700	0.791	0.830	**0.856**
	Precision	0.772	0.557	0.705	0.771	0.804
	Recall	0.920	0.974	0.983	0.972	0.986
WiseKB	F-Score	0.716	0.678	0.792	**0.949**	0.945
	Precision	0.607	0.558	0.704	0.965	0.967
	Recall	0.969	0.969	0.990	0.993	0.982

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다







● 빅데이터 시맨틱 추론 정확도
- 제거한 지식을 올바르게 추론할 수 있는 능력을 측정한 추론 정확도가 목표치 91%를 달성함

Relation	Total	Removed	Prediction Result		
			Correct	Incorrect	Accuracy
athletePlaysInLeague	1,150	230	208	22	90.57
athletePlaysSport	1,070	214	200	14	93.52
teamplaysinleague	1,033	207	187	20	90.37
athletehomestadium	644	129	110	19	85.41
athleteplaysforteam	1,024	205	185	20	90.3
				Avg.	90.03

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다. 평가 방법

- MAP(Mean Average Precision)
  - 학습된 모델의 정확도를 측정하는 기준으로 서로 다른 횟수 값에서 최대 정밀도(Precision)의 평균을 의미함.

- F1-Score
  - 정밀도와 재현율 사이의 조화평균이며, 분류 모델의 성능 비교 기준.

$$F1-score=\frac{precision \bullet recall}{precision+recall}$$

- 빅데이터 시맨틱 추론 정확도
  - 지식 그래프의 일부를 제거하여 빅데이터 시맨틱 추론을 진행하고, 제거한 지식을 올바르게 추론하는 정확도를 측정함

(2) 정량적 연구개발성과

구분		특허				논문				기술료(백만원)	성과홍보	시제품	S/W 등록	기술문서
		국제		국내		국제			국내					
		출원	등록	출원	등록	SCI(E)	비SCI(E)	Impact Factor						
1차년도 (2019년)	목표	2		2									3	5
	실적	1		2									3	5
2차년도 (2020년)	목표	2	1	2	2							1	5	5
	실적	5		6		1		6.954	4			2	6	5
3차년도 (2021년)	목표	2	1	2	2							1	5	5
	실적	2		2	2		2	6.954	4				5	5
합계	목표/**실적**	6/8	2/**0**	6/**10**	4/**2**	0/3			0/8			2/**2**	13/**14**	15/**15**

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(3) 세부 정량적 연구개발성과(해당되는 항목만 선택하여 작성하되, 증빙자료를 별도 첨부해야 합니다)

[과학적 성과]

□ 논문(국내외 전문 학술지) 게재

번호	논문명	학술지명	주저자명	호	국명	발행기관	SCIE 여부 (SCIE/비SCIE)	게재일	등록번호 (ISSN)	기여율
1	Path-reasoning approach for knowledge graph completion using CNN-BiLSTM with attention mechanism	Expert Systems with Applications	Batselem Jagvaral, Wan-Kon Lee, Jea-Seung Roh, Min-Sung Kim, Young-Tack Park	142	국제	Elsevier	SCIE	2020.03	112960	100
2	다중 클래스 멤버쉽 처리를 위한 Bi-LSTM 기반 지식 그래프 완성 기법	정보과학회 논문지	노재승,바트셀렘,이완곤,박영택	6호	국내	정보과학회	비SCI	2020.06		100
3	클라우드 컴퓨팅 환경에서 분산 테이블 구조를 활용한 OWL-Horst 온톨로지 추론 엔진	정보과학회 논문지	김민성,이민호,이완곤,박영택	7호	국내	정보과학회	비SCI	2020.07		100
4	경로 임베딩 기반 지식 그래프 완성 방식	정보과학회 논문지	바트셀렘,김민성,박영택	8호	국내	정보과학회	비SCI	2020.08		100
5	지식그래프 임베딩 및 적응형 클러스터링을 활용한 오류 트리플 검출	정보과학회 논문지	신원철,노재승,박영택	10호	국내	정보과학회	비SCI	2020.10		100
6	뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법	정보과학회 논문지	노재승,신원철,박현규,박영택	4호	국내	정보과학회	비SCI	2021.04		100
7	Explanation segments 기반 설명 가능한 지식 완성 모델	정보과학회 논문지	이민호,이완곤,바트셀렘,박영택	6호	국내	정보과학회	비SCI	2021.06		100
8	질의문과 지식 그래프 관계 학습을 통한 지식 완성 시스템	정보과학회 논문지	김민성,이민호,이완곤,박영택	6호	국내	정보과학회	비SCI	2021.06		100
9	뉴로 심볼릭 기반 규칙 유도 및 추론엔진을 활용한 지식 완성 시스템	정보과학회 논문지	신원철,박현규,박영택	11호	국내	정보과학회	비SCI	2021.11		100

□ 국내 및 국제 학술회의 발표

번호	회의 명칭	발표자	발표 일시	장소	국명
1	International Conference on AI and Soft Computing	박현규	2020.12	서울(online)	대한민국
2	Integrated System for Large-Scale Knowledge Graph Inferencing Using Spark DataFrame	이민호	2021.07.29	MGM Resorts International in Las Vegas, Nevada, USA(online)	USA

□ 기술 요약 정보

연도	기술명	요약 내용	기술 완성도	등록 번호	활용 여부	미활용사유	연구개발기관 외 활용여부	허용방식

□ 보고서 원문

연도	보고서 구분	발간일	등록 번호

□ 생명자원(생물자원, 생명정보)/화합물

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	생명자원(생물자원, 생명정보)/화합물 명	등록/기탁 번호	등록/기탁 기관	발생 연도

[기술적 성과]

□ 지식재산권(특허, 실용신안, 의장, 디자인, 상표, 규격, 신품종, 프로그램)

번호	지식재산권 등 명칭 (건별 각각 기재)	국명	출원				등록			기여율	활용 여부
			출원인	출원일	출원 번호	등록 번호	등록인	등록일	등록 번호		
1	다중타입 엔티티에 기반한 지식 보완 방법 및 장치	국내	박영택, 바트셀렘,이완곤, 노재승	2019-11-14	10-2019-0146102		박영택	2021-02-26	10-2223382	100	
2	릴레이션 네트워크에 기반한 지식 보완 방법 및 장치	국내	박영택, 바트셀렘,이완곤, 노재승	2019-12-10	10-2019-0163590		박영택	2021-03-26	10-2234850	100	
3	Method and Apparatus for complementing knowledge based on multi-type entity (다중타입 엔티티에 기반한 지식 보완 방법 및 장치)	PCT	박영택, 바트셀렘,이완곤, 노재승	2019-12-30	PCT/KR2019/018701					100	
4	A method for knowledge graph completion using a path based relation network (릴레이션 네트워크에 기반한 지식 보완 방법 및 장치)	PCT	박영택, 바트셀렘,이완곤, 노재승	2020-05-12	PCT/KR2020/006239					100	
5	OWL-Horst ontology inference method and apparatus using distributed table struture in cloud computing environment (클라우드 컴퓨팅 환경에서 분산 테이블 구조를 활용한 OWL-Horst 온톨로지 추론 방법 및 장치)	PCT	박영택, 이완곤, 이민호, 김민성	2020-07-31	PCT/KR2020/010115					100	
6	LSTM-based future threat prediction method and apparatus (LSTM 기반 미래 위협 요소 예측 방법 및 장치)	PCT	박영택, 전명중, 김민성, 이민호	2020-08-11	PCT/KR2020/010594					100	
7	클라우드 컴퓨팅 환경에서 분산 테이블 구조를 활용한 OWL-Horst 온톨로지 추론 방법 및 장치	국내	박영택, 이완곤, 이민호, 김민성	2020-03-18	10-2020-0033056					100	
8	뉴럴 심볼릭 기반 규칙생성을 통한 지식완성 방법	국내	박영택, 박현규, 신원철, 노재승	2020-08-25	10-2020-0106770					100	
9	시드를 이용한 지식 그래프 생성 방법 및 그 장치	국내	박영택, 이민호, 김상운	2020-11-06	10-2020-0147640					100	
10	질의문과 지식 그래프 관계 학습을 통한 지식 완성 시스템	국내	박영택, 이완곤, 김민성, 이민호	2020-11-23	10-2020-0157981					100	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

11	설명 가능한 지식 그래프 완성 모델	국내	박영택, 바트셀렘,이완곤, 이민호	2020-11-19	10-2020-0155501					100	
12	설명 가능한 지식그래프 완성 방법 및 장치	국내	박영택, 바트셀렘,이완곤, 이민호	2021-02-05	10-2021-0016548					100	
13	뉴로 심볼릭 기반 릴레이션 임베딩을 통한 지식 완성 기법	국내	박영택, 박현규, 노재승, 신원철	2020-11-27	10-2020-0162934					100	
14	상식적인 질문 답변 추론 방법 및 장치	국내	박영택, 바트셀렘,이민호, 김민성	2021-02-08	10-2021-0017327					100	
15	뉴로 심볼릭 기반 릴레이션 임베딩을 통한 지식 완성 방법 및 장치	PCT	박영택, 박현규, 노재승, 신원철	2020-12-23	PCT/KR 2020/018970					100	
16	질의문과 지식 그래프 관계 학습을 통한 지식 완성 시스템	PCT	박영택, 이완곤, 김민성, 이민호	2020-12-23	PCT/KR 2020/018966					100	
17	설명 가능한 지식그래프 완성 방법 및 장치	PCT	박영택, 바트셀렘,이완곤, 이민호	2021-11-05	PCT/KR 2021/015999					100	
18	뉴럴 심볼릭 기반 규칙생성을 통한 지식완성 방법	PCT	박영택, 박현규, 신원철, 노재승	2021-12-22	PCT/KR 2020/018903					100	

○ 지식재산권 활용 유형

※ 활용의 경우 현재 활용 유형에 √ 표시, 미활용의 경우 향후 활용 예정 유형에 √ 표시합니다(최대 3개 중복선택 가능).

번호	제품화	방어	전용실시	통상실시	무상실시	매매/양도	상호실시	담보대출	투자	기타

□ 저작권(소프트웨어, 서적 등)

번호	저작권명	창작일	저작자명	등록일	등록 번호	저작권자명	기여율
1	CNN-BiLSTM과 Attention을 활용한 경로 기반 추론을 통한 지식 그래프 완성	2019-08-06	숭실대학교 산학협력단	2019-10-18	C-2019-029301	숭실대학교 산학협력단	100%
2	지식 그래프 도식화 툴	2019-08-17	숭실대학교 산학협력단	2019-10-18	C-2019-029297	숭실대학교 산학협력단	100%
3	딥러닝 기반 주식시장 변동 예측 모델	2019-09-1	숭실대학교 산학협력단	2019-10-18	C-2019-029298	숭실대학교 산학협력단	100%
4	뉴로심볼릭기반 지식 완성 모델	2020-06-16	숭실대학교 산학협력단	2020-09-24	C-2020-032232	숭실대학교 산학협력단	100%
5	위키피디아 지식 그래프 생성 프로그램	2020-08-27	숭실대학교 산학협력단	2020-09-24	C-2020-032231	숭실대학교 산학협력단	100%
6	분산 테이블 구조 기반	2020-06-01	숭실대학교	2020-09-25	C-2020-032468	숭실대학교	100%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	OWL-Horst 온톨로지 추론 엔진		산학협력단			산학협력단	
7	임베딩 및 적응형 클러스터링 기반 지식베이스의 오류트리플 검출 시스템	2020-05-01	숭실대학교 산학협력단	2020-09-24	C-2020-032230	숭실대학교 산학협력단	100%
8	Spark 데이터프레임을 활용한 SWRL 추론 엔진	2020-07-01	숭실대학교 산학협력단	2020-09-25	C-2020-032467	숭실대학교 산학협력단	100%
9	뉴로 심볼릭 유니피케이션 기반 매개변수 전달(parameter passing)을 통한 효율적 규칙추출 및 지식 추론 방법	2020-11-13	숭실대학교 산학협력단	2020-11-19	C-2020-004435	숭실대학교 산학협력단	100%
10	질의문 지식 그래프 관계 학습을 통한 지식 완성 시스템	2021-03-08	숭실대학교 산학협력단	2021-10-08	C-2021-039985	숭실대학교 산학협력단	100%
11	릴레이션 규칙 학습을 위한 뉴로 심볼릭 기반 자식 완성 시스템	2021-02-21	숭실대학교 산학협력단	2021-10-08	C-2021-039986	숭실대학교 산학협력단	100%
12	설명가능한 지식그래프 완성모델	2021-03-10	숭실대학교 산학협력단	2021-10-08	C-2021-039984	숭실대학교 산학협력단	100%
13	심볼릭 유니피케이션 및 시퀀스 투 시퀀스 모델을 활용한 규칙 배열 학습을 통한 규칙 추출	2021-02-20	숭실대학교 산학협력단	2021-10-08	C-2021-039987	숭실대학교 산학협력단	100%
14	심볼릭 유니피케이션 및 백워드 체이닝을 활용한 입증 경로 생성 프로그램	2021-10-05	숭실대학교 산학협력단	2021.12.01	C-2021-052035	숭실대학교 산학협력단	100%

□ 신기술 지정

번호	명칭	출원일	고시일	보호 기간	지정 번호

□ 기술 및 제품 인증

번호	인증 분야	인증 기관	인증 내용		인증 획득일	국가명
			인증명	인증 번호		

□ 표준화

ㅇ 국내표준

번호	인증구분[1」]	인증여부[2」]	표준명	표준인증기구명	제안주체	표준종류[3」]	제안/인증일자

* 1」 한국산업규격(KS) 표준, 단체규격 등에서 해당하는 사항을 기재합니다.
* 2」 제안 또는 인증 중 해당하는 사항을 기재합니다.
* 3」 신규 또는 개정 중 해당하는 사항을 기재합니다.

ㅇ 국제표준

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	표준화단계구분[1]」	표준명	표준기구명[2]」	표준분과명	의장단 활동여부	표준특허 추진여부	표준개발 방식[3]」	제안자	표준화 번호	제안일자

* 1」 국제표준 단계 중 신규 작업항목 제안(NP), 국제표준초안(WD), 위원회안(CD), 국제표준안(DIS), 최종국제표준안(FDIS), 국제표준(IS) 중 해당하는 사항을 기재합니다.
* 2」 국제표준화기구(ISO), 국제전기기술위원회(IEC), 공동기술위원회1(JTC1) 중 해당하는 사항을 기재합니다.
* 3」 국제표준(IS), 기술시방서(TS), 기술보고서(TR), 공개활용규격(PAS), 기타 중 해당하는 사항을 기재합니다.

[경제적 성과]

□ 시제품 제작

번호	시제품명	출시/제작일	제작 업체명	설치 장소	이용 분야	사업화 소요 기간	인증기관 (해당 시)	인증일 (해당 시)

□ 기술 실시(이전)

번호	기술 이전 유형	기술 실시 계약명	기술 실시 대상 기관	기술 실시 발생일	기술료 (해당 연도 발생액)	누적 징수 현황

* 내부 자금, 신용 대출, 담보 대출, 투자 유치, 기타 등

□ 사업화 투자실적

번호	추가 연구개발 투자	설비 투자	기타 투자	합계	투자 자금 성격*

□ 사업화 현황

번호	사업화 방식[1]」	사업화 형태[2]」	지역[3]」	사업화명	내용	업체명	매출액		매출 발생 연도	기술 수명
							국내 (천원)	국외 (달러)		

* 1」 기술이전 또는 자기실시
* 2」 신제품 개발, 기존 제품 개선, 신공정 개발, 기존 공정 개선 등
* 3」 국내 또는 국외

□ 매출 실적(누적)

사업화명	발생 연도	매출액		합계	산정 방법
		국내(천원)	국외(달러)		
합계					

□ 사업화 계획 및 무역 수지 개선 효과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

성과					
사업화 계획	사업화 소요기간(년)				
	소요예산(천원)				
	예상 매출규모(천원)		현재까지	3년 후	5년 후
	시장 점유율	단위(%)	현재까지	3년 후	5년 후
		국내			
		국외			
	향후 관련기술, 제품을 응용한 타 모델, 제품 개발계획				
무역 수지 개선 효과(천원)	수입대체(내수)		현재	3년 후	5년 후
	수출				

□ 고용 창출

순번	사업화명	사업화 업체	고용창출 인원(명)		합계
			yyyy년	yyyy년	
합계					

□ 고용 효과

구분			고용 효과(명)
고용 효과	개발 전	연구인력	
		생산인력	
	개발 후	연구인력	
		생산인력	

□ 비용 절감(누적)

순번	사업화명	발생연도	산정 방법	비용 절감액(천원)
합계				

□ 경제적 파급 효과

(단위: 천원/년)

구분	사업화명	수입 대체	수출 증대	매출 증대	생산성 향상	고용 창출 (인력 양성 수)	기타
해당 연도							
기대 목표							

□ 산업 지원(기술지도)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

순번	내용	기간	참석 대상	장소	인원

□ 기술 무역

(단위: 천원)

번호	계약 연월	계약 기술명	계약 업체명	계약업체 국가	기 징수액	총 계약액	해당 연도 징수액	향후 예정액	수출/ 수입

[사회적 성과]

□ 법령 반영

번호	구분 (법률/시행령)	활용 구분 (제정/개정)	명 칭	해당 조항	시행일	관리 부처	제정/개정 내용

□ 정책활용 내용

번호	구분 (제안/채택)	정책명	관련 기관 (담당 부서)	활용 연도	채택 내용

□ 설계 기준/설명서(시방서)/지침/안내서에 반영

번호	구 분 (설계 기준/설명서/지침/안내서)	활용 구분 (신규/개선)	설계 기준/설명서/ 지침/안내서 명칭	반영일	반영 내용

□ 전문 연구 인력 양성

번호	분류	기준 연도	현황										
			학위별				성별		지역별				
1		2020	박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
			2	2	2		5	1	6				
2		2021	박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
			2	3			5		5				

□ 산업 기술 인력 양성

번호	프로그램명	프로그램 내용	교육 기관	교육 개최 횟수	총 교육 시간	총 교육 인원

□ 다른 국가연구개발사업에의 활용

번호	중앙행정기관명	사업명	연구개발과제명	연구책임자	연구개발비

□ 국제화 협력성과

번호	구분 (유치/파견)	기간	국가	학위	전공	내용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 홍보 실적

번호	홍보 유형	매체명	제목	홍보일

□ 포상 및 수상 실적

번호	종류	포상명	포상 내용	포상 대상	포상일	포상 기관

[인프라 성과]

□ 연구시설・장비

구축기관	연구시설/ 연구장비명	규격 (모델명)	개발여부 (○/×)	연구시설・장비 종합정보시스템* 등록여부	연구시설・장비 종합정보시스템* 등록번호	구축일자 (YY.MM.DD)	구축비용 (천원)	비고 (설치 장소)

* 「과학기술기본법 시행령」 제42조제4항제2호에 따른 연구시설・장비 종합정보시스템을 의미합니다.

[그 밖의 성과](해당 시 작성합니다)

(4) 계획하지 않은 성과 및 관련 분야 기여사항(해당 시 작성합니다)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 목표 달성 수준

추 진 목 표	달 성 내 용	달성도(%)
1. 국내외 특허 출원 및 등록	1.1 본 연구를 통해서 1차년도부터 3차년도까지 국제 특허 7건을 출원하여 목표치인 6건을 약 16% 초과 달성함.(현재 출원된 7건의 특허에 대하여 등록을 위한 심사 또한 진행중)	*100%* *(16%초과)*
	1.2 국내특허를 10건 출원하여 목표치인 6건을 약 66% 초과 달성하였으며, 2건의 국내 특허가 등록됨. (출원된 10건의 특허에 대하여 등록을 위한 심사 진행중)	*100%* *(66%초과)*
2. 국내외 논문	2.1 mrnIF지수 : 표준화된 순위 보정 영향력지수 (Modified Rank Normalized Impact Factor)로써, 순위보정지수의 최소값을 0, 최대값을 100으로 표준화한 것으로서 지수 값이 큰 저널일수록 해당분야 내에서 위상이 높은 저널을 의미하며 본 연구 결과인 논문에 대한 지수를 구하기 위해 해당 학술지의 카테고리 내 순위를 통해 표준 순위 보정 영향력 지수를 구할 수 있음. **국외 논문 실적** • 국외 논문 (SCI-E) • 학술지 : Expert Systems with Applications 논문 명 : Path-reasoning approach for knowledge graph completion using CNN-BiLSTM with attention mechanism 발간 일자(Online): 19.09 Impact Factor : 6.954 논문 명 : A Path-based Relation Networks Model for Knowledge Graph Completion 발간 일자(Online): 21.05 Impact Factor : 6.954 해당 학술지의 카테고리 내 순위(N = 139, R = 23)를 통해 아래와 같은 계산 방법으로 mrnIF 지수를 측정할 수 있음. $mrnIF = \frac{(N \times rnIF - 1)}{N - 1} \times 100$ $rnIF = \frac{(N - R + 1)}{N}$ • N = 카테고리 내 학술지(SCI) 수 • R = 해당 학술지(SCI)의 카테고리 내 Impact Factor 순위 • rnIF = 해당 학술지(SCI)의 순위 보정 영향력 지수 • mrnIF = 해당 학술지(SCI)의 표준화된 순위 보정 영향력 지수 • rnIF = (139–23 +1) / 139 = 0.84 • mrnIF = {(139 * 0.84–1) / (139–1)} * 100 = 84.06 따라서 본 연구의 결과인 SCI 논문의 표준 순위 보정 영향력지수는 Computer Science, Artificial Intelligence 분야에서 84.06의 영향력 지수를 나타냄	*100%* *(초과성과)*

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4. 목표 미달 또는 미흡한 사항에 대한 분석

1) 목표 미달 또는 미흡한 연구결과에 대한 원인(사유) 자체분석 내용

해당사항 없음

2) 미달 또는 미흡한 결과물에 대한 보완 활동

해당사항 없음

3) 연구개발 과정의 성실성

본 연구는 각 연차별 세부 연구 목표를 지정하여 연구 개발을 수행하였으며, 아래와 같은 연구 목표에 대하여 세부 연구 개발을 수행하였음

- Spark 기반 OWL-Horst 및 SWRL 분산 추론 엔진 개발
- 지식그래프 자동 완성을 위한 경로 기반 관계 네트워크 모델 구축
- 뉴로 심볼릭 기반 규칙 생성을 통한 지식 완성 기법

세부 연구에 대한 목표를 수행하기 위해 연구 개발 과정에서 산출된 정량적 목표 성과는 국제 특허를 7건 출원하여 목표치인 6건을 약 16% 초과 달성을 함. (현재 1건에 대한 국제 특허를 진행 준비 중이며, 출원된 7건의 특허에 대하여 등록을 위한 심사 또한 진행중) 또한 국내특허를 10건 출원하여 목표치인 6건을 약 66% 초과 달성하였으며, 2건의 국내 특허가 등록됨. (출원된 10건의 특허에 대하여 등록을 위한 심사 진행중)

또한 계획에는 없었지만 본 연구를 통해서 SCI급 논문 2편, 국제 학회 논문 2건 , 국내 정보과학회 논문 7건을 발표함

연구 개발 과정에서 생성된 기술개발 성과의 공정성을 위해서 한국정보통신기술협회(TTA) 소프트웨어 시험 인증 연구소의 확인 및 검증 시험을 통해 ‘빅데이터 시맨틱 분산 추론 속도’와 ‘빅데이터 Link Prediction 추론 증강도’에 대하여 연구개발한 부분에 대해서는 공인인증을 받았음. 아래는 한국정보통신기술협회(TTA) 소프트웨어 시험 인증 연구소의 확인 및 검증 시험에 대한 결과서를 보여줌.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

5. 연구개발성과의 관련 분야에 대한 기여 정도

- 기술 개발 결과의 기업체 사용 방안
  - 본 연구 결과물은 지식그래프 활용을 하는 기업에서는 활용이 가능한 결과물이므로 3차년도 최종 연구 결과물을 활용할 수 있는 국내 기업을 알아보도록 함
  - 현재, 국내 기업은 삼성, KT와 같은 대기업 카카오, 솔트룩스, 리스트와 같은 중견 및 중소 기업에서 지식그래프를 활용하고 있는 단계임
  - 1차년도 연구물이 프로토타입으로 개발되어 기업체에서 활용이 가능하게 될 시점인 2차년도에는 본 연구 결과물 활용에 관심이 있는 기업을 섭외하여 2차년도부터 참여, 위탁의 형태로 본 제에 참여토롤 하여 본 기술 개발 결과물을 사업화 하는데 최선을 다 할 예정임

- Spark 기반 빅데이터 처리 프레임워크 연구
  - 본 연구에서는 대용량 데이터의 분산 In Memory 프레임워크인 Spark에서 처리하고 심볼릭 추론 및 딥러닝 추론을 수행하는 방법론을 연구하므로 효율적인 빅데이터 처리 프레임워크 결과물에 대한 활용이 가능함

- 불완전 지식그래프 자동 완성 연구
  - 본 연구의 결과물은 불완전 지식그래프의 자동 환성에 활용이 가능함. 대용량 지식 그래프의 활용이 다양한 분야 (금융기관, 행정기관, 법률 분야, 검색)에 활용되는 추세이므로 다양한 지식 그래프가 출현할 것이고 이에 대한 자동 완성의 요구 사항이 증대되는 추세임
  - 불완전한 지식그래프를 자동 완성함으로써 지식 그래프활용도의 향상에 기여할 것으로 예상함

- 지식그래프 오류 발견 및 자동 보완
  - 지식그래프는 사람이나 기계학습 프로그램에 의해서 생성되므로 많은 오류를 가지고 있음. 이러한 오류는 지식 그래프 활용 시스템의 성능을 떨어뜨리는 요소가 됨. 본 연구 결과물을 활용하면 지식 그래프의 오류를 발견할 수 있는 프로그램을 작성할 수 있음
  - 본 연구 결과물을 활용하여 지식그래프의 오류를 발견하고 이를 자동으로 보완하는 프로그램은 시스템의 효율성을 증대하는 목적으로 활용이 가능함

- 지식그래프 모순성 발견 및 자동 보완
  - 지식그래프에는 많은 모순성을 가지고 있음. 즉 하나의 Proposition에 대해서 True와 False 값을 동시에 추론되는 경우가 있음. 본 연구 결과물은 지식그래프의 모순을 발견하고 정확한 값을 보정하는 데 활용이 가능함

- 지식그래프 임베딩 기술
  - 본 연구에서 제안하고 있는 지식그래프 임베딩 기술은 다양한 분야에 활용이 가능함
  - RDF2Vec을 이용한 엔티티 임베딩 기술, Partial Embedding 기술 및 Relation Embedding 기술 등의 활용이 다양한 분야에 가능함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

6. 연구개발성과의 관리 및 활용 계획

- 공개SW R&D 전략
  - 본 연구는 빅데이터를 활용하는 연구를 수행하므로 연구에 활용된 대용량 지식그래프를 공개하고 대용량 지식그래프 자동완성 SW를 공개함으로써 국내의 빅데이터 시맨틱스 연구에 기여하고자 함
- 공개SW R&D 결과물의 활성화 방안
  - 본 연구에서 공개되는 지식그래프는 오류가 없는 데이터이므로 많은 지식완성 연구에 활용성이 매우 높을 것으로 판단됨, Spark 기반의 빅데이터 시맨틱스 추론 엔진은 이 분야의 연구진에게 좋은 도구로 활용될 것임
- 공개SW 공개방법과 운영계획
  - 본 연구의 결과물은 빅데이터 시맨틱 분석 추론 개선 기술에 사용된 가공 데이터, 추론된 데이터, 학습된 추론 모델임. 가공 데이터와 추론된 데이터는 다양한 연구에 활용될 수 있는 자원이 될 수 있으며, 향후 지식 서비스를 제공하는 시스템 개발에 사용될 수 있음
  - W3C 표준 형식 중 N-Triple 데이터 유형의 대용량 지식베이스인 Freebase, NELL, Wordnet, Wikipedia를 대상으로 추론 연구가 진행될 것임. 공개된 지식 베이스들을 본 연구에 적합 형태로 변형하기 위해 클리닝 작업이 포함된 전처리가 수행될 예정임. 빅데이터 시맨틱 분석 추론 개선 기술을 통해 추론된 새로운 데이터는 N-Triple 형태로 저장되며, 학습된 추론 모델은 기존 연구들과의 정확도 및 성능 비교를 통해 기술 검증이 수행됨. 추론된 데이터 및 학습된 추론 모델은 다양한 지식 서비스에서 활용될 수 있으며, 사용자에게 의미 있는 정보를 제공할 수 있는 기반이 될 수 있음.
  - 본 연구의 공동 활용 가능 데이터 github.com에 보존되며, 연구가 종료된 후 3개월 이내 본 공개 SW 결과물(SW, 소스코드, 데이터)를 github.com에 업로드 하여 공개하고 공유할 예정임. 연구데이터 중 대용량 데이터인 지식 베이스의 공유를 원하는 경우 관리책임자에게 연락하여 의도하는 사용에 대해 설명하면 됨. 데이터에 대한 요청은 제시된 이용에 대한 검토 후 연구자들에 의해 승인될 예정임. 제안된 프로젝트는 빅데이터 시맨틱 추론과 관련된 연구들이 활용할 수 있는 가공된 지식베이스 및 추론된 데이터를 제공하며, 지식서비스에 활용할 수 있는 시맨틱 분석 추론 모델을 만드는 것임. SW는 오픈소스이며 무료로 제공될 것임.
- 공개SW R&D 공개 데이터 및 소프트웨어
  - Github에 다음과 같은 데이터와 소프트웨어를 년차별로 공개
  - W3C 표준 언어로 제작된 공개 데이터를 이용한 빅데이터 추론 벤치마크 데이터 생성 및 공개

데이터 (Freebase, Wordnet, NELL, LUBM, 액소브레인 데이터)		소프트웨어	
Link Prediction 테스트용 데이터	• 5개의 데이터셋을 이용하여 Link Prediction을 수행하기 이전과 이후의 데이터 셋 제공하여 벤치마크 테스트에 활용할 수 있도록 함	추론 엔진	• Spark 기반 RDFS/OWL-horst 추론 엔진 • Spark 기반 SWRL 추론 엔진
Triple Classification 테스트용 데이터	• 5개의 데이터셋을 이용하여 Triple Classification을 검증할 수 있는 테스트 데이터 제공	심볼릭 지식 완성 엔진	• 온톨로지 및 SWRL 기반 Link Prediction 엔진 • 온톨로지 및 SWRL 기반 Triple Classfication 엔진 • 심볼릭 방식의 Incorrect 검증 엔진
Incomplete 지식그래프 테스트용 데이터	• 5개의 데이터셋을 대상으로 Incomplete한 데이터와 Complete한 정답데이터를 제공	딥러닝 데이터 생성 엔진	• PRA 기반 5개의 데이터셋에 대한 스토리 기반 학습 데이터 생성 엔진
Incorrect 지식그래프 테스트용 데이터	• 5개의 데이터셋을 대상으로 Incorrect한 데이터와 Correct한 정답 데이터를 제공	딥러닝 기반 지식 완성 엔진	• MM기반 지식 완성 엔진 • RN기반 지식 완성 엔진 • 임베딩 기반 Incorrect 검증 엔진

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

< 연구개발성과 활용계획표 >

구분(정량 및 정성적 성과 항목)		연구개발 종료 후 5년 이내
국외논문	SCIE	매년 목표치
	비SCIE	
	계	
국내논문	SCIE	
	비SCIE	1
	계	
특허출원	국내	1
	국외	
	계	1
특허등록	국내	1
	국외	1
	계	2
인력양성	학사	
	석사	
	박사	
	계	
사업화	상품출시	
	기술이전	
	공정개발	
제품개발	시제품개발	
국제 표준화	기고서 제출	
	기고서 채택	
	표준안 채택	
국내 표준화	기고서 제출	
	기고서 채택	
	표준안 채택	
성과홍보		
포상 및 수상실적		
정성적 성과 주요 내용		

1) 향후 5년간 성과활용·확산 활용방안 및 계획(활동계획)

o 본 연구의 개발 성과는 인공지능 기술의 심볼릭 추론 기술과 딥러닝 추론 기술을 활용하여 지식완성을 수행하며, 두가지 방식을 접목하여 보다 효율적인 지식 완성 추론을 수행할 수 있는 지능형 서비스를 제공하는 기반 기술로 적용 가능함으로, 다음과 같은 다양한 분야에 활용 가능할 것으로 예상됨

- 불완전 지식그래프의 자동 완성에 활용이 가능함. 대용량 지식 그래프의 활용이 다양한 분야 (금융기관, 행정기관, 법률 분야, 검색)에 활용되는 추세이므로 다양한 지식 그래프가 출현할 것이고 이에 대한 자동 완성의 요구 사항이 증대되는 추세임

<연도별 주요 활동계획(요약표)>

구분	종료+1 (2022년)	종료+2 (2023년)	종료+3 (2024년)	종료+4 (2025년)	종료+5 (2026년)
뉴로 심볼릭 기술 상용화 추진계획	기초 연구 및 실험	기술에 대한 데모 시연	기술에 대한 성능평가	시제품 인증 및 제작	사업화 준비

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 주요 성과활용 (기대)성과목표

(1) 정성적 목표

< 연구개발성과 성능지표 >

평가 항목 (주요성능[1])	단위	전체 항목에서 차지하는 비중[2] (%)	세계 최고		연구개발 전 국내 성능수준	연구개발 목표치			목표설정 근거	추진실적
			보유국/보유기관	성능수준	성능수준	1차년도 (2019년)	2차년도 (2020년)	3차년도 (2021년)		
1. 빅데이터 시맨틱 분산 추론 속도	트리플/초	20 %	네덜란드 / VU	170,000	160,000	150,000	170,000	250,000	공인평가	**428,414** (71%초과)
2. 빅데이터 시맨틱 추론 증강도	증강도(%)	15 %	네덜란드 / VU	70%	55%	60%	70%	80%	자체평가	**91.43%** (11%초과)
3. 대용량 지식그래프 자동 완성도	Accuracy (%)	15 %	미국 / NDU	87%	75%	82%	87%	90%	자체평가	**92.2%** (2%초과)
4. 빅데이터 Link Prediction 정확도	MAP	20 %	미국 / CMU	0.88	0.79	0.75	0.80	0.85	공인평가	**0.97** (12%초과)
5. 빅데이터 오류 자동 완성도	F1-Score	15 %	미국 / Stanford	0.75	0.70	0.73	0.76	0.80	자체평가	**0.86** (6%초과)
6. 빅데이터 시맨틱 추론 정확도	Accuracy (%)	15 %	영국/ABDN	91%	85%	87%	90%	93%	자체평가	**94.03%** (1%초과)

o 평가방법

- MAP(Mean Average Precision) : 학습된 모델의 정확도를 측정하는 기준으로 서로 다른 횟수 값에서 최대 정밀도의 평균을 의미함.
- F1-Score : 정밀도와 재현율 사이의 조화 평균이며, 분류 모델의 성능 비교 기준

$$F1-score = \frac{precision \bullet recall}{precision + recall}$$

- 빅데이터 시맨틱 추론 정확도 : 지식그래프의 일부를 제거하여 빅데이터 시맨틱 추론을 진행하고, 제거한 지식을 올바르게 추론하는 정확도를 측정함.

(2) 정량적 목표

상태	국내 특허		국제 특허		국내 논문		국제 논문	
	출원 계획	등록 계획	출원 계획	등록 계획	SCI	비SCI	SCI	비SCI
향후 성과 계획	1	1	1			1		
합계	1	1	1			1		

<연도별 성과활용 (기대)성과목표(요약표)>

구분	종료+1 (2022년)	종료+2 (2023년)	종료+3 (2024년)	종료+4 (2025년)	종료+5 (2026년)
예상매출액			1,000만원	2,000만원	3,000만원

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3) 성과활용·관리 추진체계

● 연구데이터 관리 계획

- 공개된 벤치 마크 데이터셋을 정제하고 필터링하여 목적에 맞는 실험을 할 수 있도록 데이터셋을 가공하여, 자동 지식 완성 모델을 사용하여 새로운 지식을 추론하고 해당 지식 데이터를 수집되도록 하여 지속적으로 데이터의 생산 및 수집이 가능하도록 함

● 연구데이터 보존 및 백업

- 생상된 연구데이터를 공개하여 게시하도록하며, 사용 의도에 대한 검토 후 연구 책임자에 의한 승인 후 무료 제공

4) 기타

7. 연구개발성과에 대한 후속연구 및 추가 개발 계획

해당사항 없음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8. 연구개발비 사용실적

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용금액 ⑥	사용잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	50,835,640	258,550,000			309,385,640	309,295,339	90,301	99.97	
	현물		1,200,000			1,200,000	1,200,000	0	100	
	소계						310,495,339	90,301	99.97	
1) 인건비	현금		138,500,000	-6,300,000		132,200,000	132,200,000	0	100	
	현물		1,200,000			1,200,000	1,200,000	0	100	
2) 학생인건비	현금		21,900,000	-3,600,000		18,300,000	18,300,000	0	100	
3) 연구시설・장비비	현금	40,691	1,000,000	-1,000,000		40,691	0	40,694	0	
	현물		0			0	0	0	0	
4) 연구재료비	현금	52,780	36,700,000	30,332,000		67,084,780	67,084,700	80	99.99	
	현물		0			0	0	0	0	
5) 위탁연구개발비 [1」]	현금		0			0	0	0	0	
6) 국제공동연구개발비	현금		0			0	0	0	0	
7) 연구개발부담비	현금		0			0	0	0	0	
8) 연구활동비	현금	49,502,169	28,740,000	-15,282,000		62,960,169	62,910,639	49,530	99.92	
	현물		0			0	0	0	0	
9) 연구수당	현금	1,240,000	31,710,000	-4,150,000		28,800,000	28,800,000	0	100	
나. 간접비	현금		74,450,000			74,450,000	74,450,000	0	100	
	소계		74,450,000			74,450,000	0	0	100	
합계	현금	50,835,640	333,000,000	0		383,835,640	383,745,339	90,301	99.97	
	현물		1,200,000			1,200,000	1,200,000	0	100	
	합계		334,200,000			385,035,640	384,945,339	90,301	99.97	

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	176,283.847			176,283.847
연구개발기간 후 발생이자	32.153			32.153
합계	176,316			176,316

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액				연구개발기간 중		
불인정 사용금액				연구개발기간 후		
소계(A)				소계(D)		
정부지분율(B)				정부지분율(B)		
정부지분액(C=A×B)				정부지분액(E=D×B)		

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 1. 사업화대상기술별 기술명세서

1. 과제정보

과 제 명	국문	뉴로 심볼릭 기반 지식완성				
	영문	Knowledge Completion based on Neuro-Symbolic Method				
기술분류	대분류	정보통신	중분류	정보이론	소분류	인공지능
주관기관	숭실대학교		연구책임자	박영택		
연락처(책임자)	사무실 : 02) 820-0678		이메일(책임자)	park@ssu.ac.kr		

2 사업화대상기술 목록

순번	개발기술(Product)명 (관련 기술의 Know-how 및 특허 등)		보유특허(기술별로 중복기재 가능)		
			특허		발명의 명칭
			출원번호	등록번호	
1	국문	다중타입 엔티티에 기반한 지식 보완 방법 및 장치		10-2223382	다중타입 엔티티에 기반한 지식 보완 방법 및 장치
	영문	Method and Apparatus for complementing knowledge based on multi-type entity	PCT/KR2019/018701		Method and Apparatus for complementing knowledge based on multi-type entity
2	국문	릴레이션 네트워크에 기반한 지식 보완 방법 및 장치		10-2234850	릴레이션 네트워크에 기반한 지식 보완 방법 및 장치
	영문	A method for knowledge graph completion using a path based relation network	PCT/KR2020/006239		A method for knowledge graph completion using a path based relation network

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3. 사업화 대상기술

개발기술 1	국문	대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술 개발
	영문	Semantic Analysis Reasoning Methods for Automatic Completion of Large Scale Knowledge Graph

공개	▣	비공개	□ (사유)

① (예상) 결과물

개발목표 시기	2023.02		기술성숙도 (TRL)	개발 전	개발 후
결과물 형태	SW-System		검증방법	시범사업, 시험인증	
색인어 (Keywords)	국문	지식완성, 온톨로지 기반 지식완성, 딥러닝 기반 지식완성, 뉴로 심볼릭 기반 지식완성			
	영문	Knowledge Completion, Ontology-based Knowledge Completion, Deep Learning-based Knowledge Completion, Neuro Symbolic Knowledge Completion			
외부 기술요소	해당사항없음		권리성	특허	

② 기술의 개념(Concept) 및 구성

영문				
	Title	Semantic Analysis Reasoning Methods for Automatic Completion of Large Scale Knowledge Graph		
	Concept	 ○ 빅데이터 시맨틱 분석 추론 개선 기술 연구를 위해서 심볼릭 및 딥러닝 융합 방식을 이용한 대용량 지식그래프 추론 기술 연구		
	Service Offering	SW-System		
	Comparative Advantage	Combination of Symbolic and Neuro approaches for automated knowledge		
	Patents (Domestics)	Application(10) Registration(2)	Patents (International)	Application(7) Registration( )

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

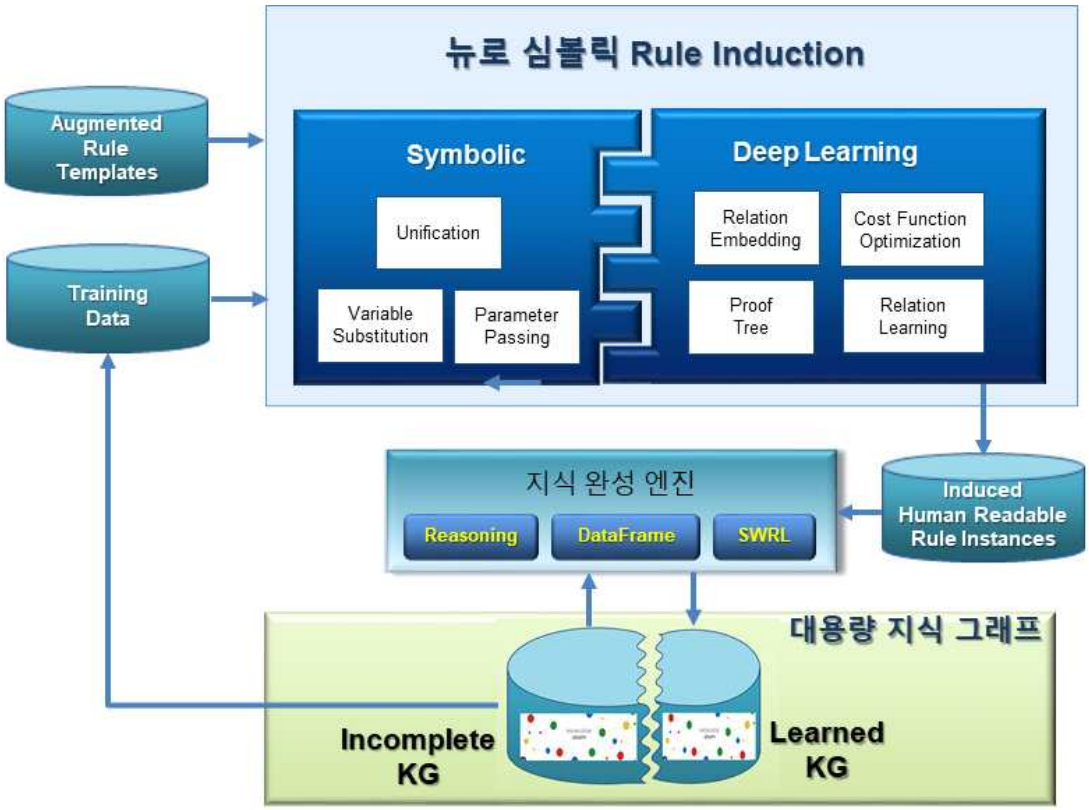
국문

□ (기술의 개념)

○ 뉴로 심볼릭 기반 자동 지식그래프 완성 기법

- 불완전 지식 그래프를 완성하기 위해 심볼릭 추론에서는 human curator가 직접 heuristic 규칙을 정의하여 처리하여 높은 성능을 보이지만, 방대한 지식 그래프를 대상으로 한계점이 존재함.
- 또한 딥러닝 추론은 지식 그래프로부터 누락된 지식에 대하여 학습을 통해 자동 완성이 가능하지만 탐색 공간이 매우 커서 컴퓨팅 리소스를 필요로 하는 문제점이 존재함.
- 규칙 스키마로부터 규칙 인스턴스를 학습하기 위해서 심볼릭 추론의 Unification 개념과 딥러닝의 Embedding Vector 학습 방식을 융합 활용하는 방식을 제안함.
- 뉴로 심볼릭 추론 방식으로 지식 완성 규칙 인스턴스를 학습하고 이를 활용하여 Incomplete 지식그래프를 Complete한 지식그래프로 완성하기 위한 자동적으로 해결할 수 있는 자동 지식그래프 완성을 목표로 함.

<기술개념도>



국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

③ 기술적 경쟁력

○ 기술의 특성 및 성능

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
• 불완전 지식 그래프를 완성하기 위해 심볼릭 추론 방식을 이용한 온톨로지 기반 추론에서는 human curator가 직접 heuristic 규칙을 정의하여 처리하여 높은 성능을 보이지만, 방대한 지식 그래프를 대상으로 한계점이 존재함. • 딥러닝 추론은 지식 그래프로부터 누락된 지식에 대하여 학습을 통해 자동 완성이 가능하지만 탐색 공간이 매우 커서 컴퓨팅 리소스를 필요로 하는 문제점이 존재함.	• 뉴로 심볼릭 추론 방식은 심볼릭 추론과 딥러닝 추론 방식의 장점을 융합한 방식으로써 지식 완성 규칙 인스턴스를 학습하고 이를 활용하여 Incomplete 지식그래프를 Complete한 지식그래프로 완성하기 위한 자동적으로 해결할 수 있는 **자동 지식그래프 완성**을 수행하여 기존의 연구 방식에 비해 우수한 성능을 보임

④ 표준화 및 특허

○ 관련 보유특허

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	대한민국	10-2223382(21.02.26)	등록	다중타입 엔티티에 기반한 지식보완 방법 및 장치
2	대한민국	10-2234850(21.03.26)	등록	릴레이션 네트워크에 기반한 지식 보완 방법 및 장치
3	PCT	PCT/KR2020/010115(20.07.31)	출원	OWL-Horst ontology inference method and apparatus using distributed table structure in cloud computing environment
4	PCT	PCT/KR2020/010594(20.08.11)	출원	LSTM-based future threat prediction method and apparatus
5	대한민국	10-2020-0147640(20.11.06)	출원	시드를 이용한 지식 그래프 생성 방법 및 그 장치
6	대한민국	10-2020-0157981(20.11.23)	출원	질의문과 지식 그래프 관계 학습을 통한 지식 완성 시스템
7	대한민국	10-2020-0155501(20.11.19)	출원	설명 가능한 지식 그래프 완성 모델
8	대한민국	10-2020-0162934(20.11.27)	출원	뉴로 심볼릭 기반 릴레이션 임베딩을 통한 지식 완성 기법
9	대한민국	10-2020-0033056(20.03.18)	출원	클라우드 컴퓨팅 환경에서 분산 테이블 구조를 활용한 OWL-Horst 온톨로지 추론 방법 및 장치
10	대한민국	10-2020-0106770(20.08.25)	출원	뉴럴 심볼릭 기반 규칙생성을 통한 지식완성 방법

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑤ 시장성

○ 국내외 시장동향 및 전망

○ 제품화 및 활용분야

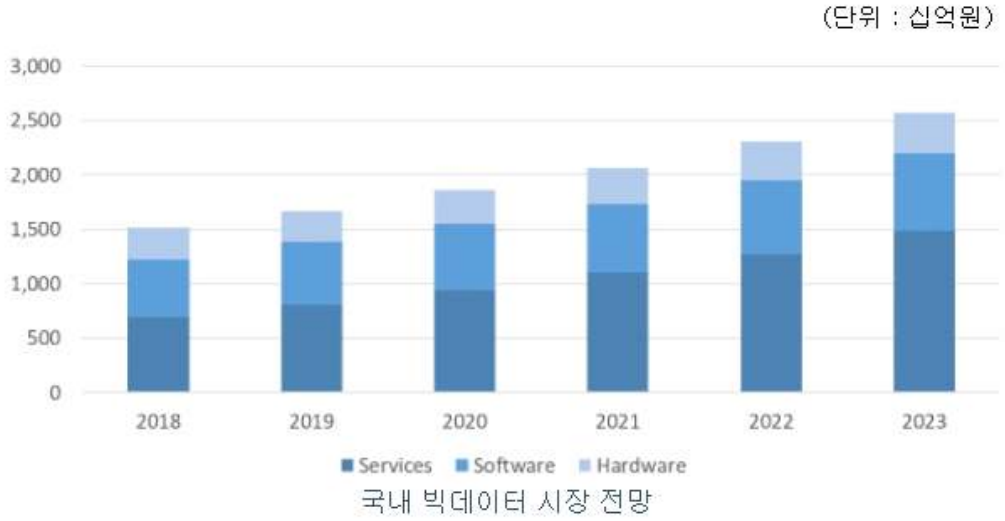
활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	지식그래프 자동 완성	본 연구의 결과물은 불완전 지식그래프의 자동 완성에 활용이 가능함. 대용량 지식 그래프의 활용이 다양한 분야 (금융기관, 행정기관, 법률 분야, 검색)에 활용되는 추세이므로 다양한 지식 그래프가 출현할 것이고 이에 대한 자동 완성의 요구 사항이 증대되는 추세임 불완전한 지식그래프를 자동 완성함으로써 지식 그래프활용도의 향상에 기여할 것으로 예상함
2	뉴로 심볼릭 기반 지식 완성	본 개발 연구의 수행을 통해 심볼릭 방식과 딥러닝 기술의 장점을 결합한 뉴로 심볼릭 기반 지식 완성 기술의 원천 기술을 확보함으로써 이를 활용한 다양한 분야에 적용이 가능함

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 조원				
		2020	2021	2022	2023	2024
1	머신러닝	0.81	1.13	1.57	2.19	3.04
2	자연어처리	0.51	0.7	0.96	1.32	1.81
3	상황인지컴퓨팅	0.26	0.35	0.47	0.63	0.85

출처 : 한국 신용 정보원, BCC(2020), MarketsandMarkets(2018)

[국내 빅데이터 시장 전망]



출처 : IDC, 국내 빅데이터 및 분석 2019-2023 시장 전망

출처 : 한국 신용 정보원, BCC(2020), MarketsandMarkets(2018)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑥ 기술이전 조건 및 고려사항

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
			√					
기술이전 금액	무료 -5백만원 이하	5백만원 초과 -1천만원 이하	1천만원 초과 -2천만원 이하	2천만원 초과 -3천만원 이하	3천만원 초과 -5천만원 이하	5천만원 초과 -1억원 이하	1억원 초과	기타
							√	

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	√					

○ 고려사항

⑦ 기대효과

○ 기술도입으로 인한 경제적 효과

- **기술적 측면**

본 연구에서 제안하는 온톨로지 기반 추론 과 딥러닝 추론을 융합하는 경우는 위와 같이 두 방식의 장점을 충분히 반영하므로 기술적인 기대효과와 아울러 실제 응용에도 그 활용도가 높을 것으로 판단됨

- **경제적 산업적 측면**

본 연구의 결과물 지식그래프 자동완성을 위한 핵심 기술을 국산화하는 작업을 포함하므로 기술적인 기대 효과가 매우 크며 이를 기반으로 산업화하는 데 크게 기여할 것으로 판단됨

- **사회적 측면**

지식 완성 기술은 지식 서비스에 직접적으로 연결될 수 있기 때문에 기존 지식 큐레이터들이 보다 고도화된 영역에 집중하여 기업의 성장이라는 효과가 있음

○ 기술사업화로 인한 파급효과

- **불완전 지식 그래프 자동 완성**

- 본 연구의 결과물은 불완전 지식그래프의 자동 환성에 활용이 가능함. 대용량 지식 그래프의 활용이 다양한 분야 (금융기관, 행정기관, 법률 분야, 검색)에 활용되는 추세이므로 다양한 지식 그래프가 출현할 것이고 이에 대한 자동 완성의 요구 사항이 증대되는 추세임
- 불완전한 지식그래프를 자동 완성함으로써 지식 그래프활용도의 향상에 기여할 것으로 예상함

- **지식그래프 임베딩 기술**

- RDF2Vec을 이용한 엔티티 임베딩 기술, Partial Embedding 기술 및 Relation Embedding 기술 등의 활용이 다양한 분야에 가능함

⑧ 기술사업화 적용 및 제약사항

○ 사업화 적용실적

○ 사업화 제약사항

○ 지원 필요사항

⑨ 기타

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

기술세미나 발표 가능 여부(O/X)	o	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	x

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	박영택	숭실대학교	교수	02) 820-0678	park@ssu.ac.kr
	연구자					

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 2. 자체 보안관리 진단표

구분	체크항목	결과 체크 (√표)	비고 (미실시 사유)
보안관리 체계	o 기관 내 보안관리규정을 제정/적용하고 있다	O(√), X( )	
	o 보안관리 조직이 있으며, 자체 보안점검실시 등 잘 운영되고 있다	O(√), X( )	
	o 보안교육을 정기적(1회이상/연)으로 실시하고 있다	O(√), X( )	
	o 보안사고에 대한 방지대책 및 비상시 대응계획이 준비되어 있다	O(√), X( )	
참여연구원 관리	o 참여연구원에 대하여 보안서약서를 받았다	O(√), X( )	
	o 참여연구원에게 보안관리의 중요성 등을 인식시키고 있다	O(√), X( )	
연구개발 내용/결과 관리	o 주요 연구자료 및 성과물의 무단유출 방지대책을 수립하고 있다	O(√), X( )	
	o 보안성 검토 방법 및 절차를 이행하고 있다	O(√), X( )	
	o 기술이전 관련 내부규정 및 절차를 준수하고 있다	O(√), X( )	
연구시설 관리	o 연구시설 보안관련 내부규정 또는 지침을 이행하고 있다	O(√), X( )	
	o 주요 시설에는 보안장비가 설치되어 있다	O(√), X( )	
	o 보호구역이 지정되어 있다	O(√), X( )	
정보통신망 관리	o 정보통신망 보안관련 내부규정 또는 지침이 구비되어 있다	O(√), X( )	
	o 보안관리 책임자의 승인 항목이 구분되어 있다	O(√), X( )	
	o 주요 데이터에 대해 백업을 실시하고 있다	O(√), X( )	
	o 개인용 정보통신장비(노트북, USB메모리)에 대하여 인가/관리중이다	O(√), X( )	
	o 전산망 보호를 위한 HW 및 SW 등을 도입하여 적용하고 있다	O(√), X( )	
	o 직책, 임무별 열람 권한을 차등화하여 부여하고 있다	O(√), X( )	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 3. 공개 SW 요약서 (공개SW과제만 작성)

<table>
<tr><td colspan="2">공개 SW명</td><td colspan="5">대용량 지식 그래프 자동완성을 위한 시맨틱 추론 기술</td></tr>
<tr><td colspan="7">분류</td></tr>
<tr><td colspan="2">기술분류</td><td colspan="5">ICT 연구개발기술 대분류/중분류/소분류/세분류</td></tr>
<tr><td colspan="2">최종 업데이트일</td><td colspan="5"></td></tr>
<tr><td colspan="7">공개 SW 정보</td></tr>
<tr><td colspan="2">개요
(공개 SW요약)</td><td colspan="5">지식그래프에 대하여 표준언어로 제작된 공개데이터를 이용한 빅데이터 추론을 위한 벤치마크데이터</td></tr>
<tr><td colspan="2">저장소별 주소</td><td colspan="5">• NELL-995 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/NELL-995
• FB15K-237 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/FB15K-237
• NDSL 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/NDSL
• DBpedia 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/DBpedia
• DBpia 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/DBpia
• KData 데이터 Github :
– https://github.com/leewangon/KnowledgeGraphCompletionDataSet/tree/master/DataSet/KData</td></tr>
<tr><td colspan="2">구글 등 검색여부</td><td colspan="5">Y</td></tr>
<tr><td rowspan="2">버전</td><td>안정화 버전</td><td>버전명</td><td></td><td>날짜</td><td colspan="2"></td></tr>
<tr><td>최종 버전</td><td>버전명</td><td></td><td>날짜</td><td colspan="2"></td></tr>
<tr><td colspan="2">라이선스</td><td colspan="5"></td></tr>
<tr><td rowspan="6">공개SW
실적</td><td>Commit</td><td colspan="2">목표 : 00건(누적)</td><td colspan="3">실적 : 00건(누적)</td></tr>
<tr><td>Fork</td><td colspan="2">목표 : 00건(누적)</td><td colspan="3">실적 : 8건(누적)</td></tr>
<tr><td>Star</td><td colspan="2">목표 : 00건(누적)</td><td colspan="3">실적 : 9건(누적)</td></tr>
<tr><td>Issue(closed)</td><td colspan="2">목표 : 00건(누적)</td><td colspan="3">실적 : 00건(누적)</td></tr>
<tr><td>Pull request
(closed)</td><td colspan="2">목표 : 00건(누적)</td><td colspan="3">실적 : 00건(누적)</td></tr>
<tr><td>실적 관리자</td><td colspan="5">소속 : , 이름: , 연락처 : ,E-Mail :</td></tr>
<tr><td colspan="7">활용 사례1</td></tr>
<tr><td colspan="2">활용 기관명</td><td colspan="5"></td></tr>
<tr><td colspan="2">활용 목적</td><td colspan="5"></td></tr>
<tr><td colspan="2">활용 상세</td><td colspan="5"></td></tr>
<tr><td colspan="7">활용 사례N</td></tr>
<tr><td colspan="2">활용 기관명</td><td colspan="5"></td></tr>
<tr><td colspan="2">활용 목적</td><td colspan="5"></td></tr>
<tr><td colspan="2">활용 상세</td><td colspan="5"></td></tr>
</table>

* 실적치에 대한 깃허브 등 저장소에 대한 증빙자료 필수 제출(캡쳐 등)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

NELL-995

Graph.txt

```
This data is represented by a sequence of the following format.
subject, relation, object

# of Triples : 308,426
```

Sample

	subject	relation	object
1	concept_person_molly_moore	concept:worksfor	concept_city_washington_d_c
2	concept_hotel_pullman	concept:atlocation	concept_city_washington_d_c
...	...	...	...

KData

KData_graph.nt

- Download
- KData의 라이센스는 (주)리스트 에 있음

```
This data is represented by a sequence of the following format.
subject, relation, object

# of Triples : 2,776,394
```

Sample

	subject	relation	object
1	백남준	직업	아티스트
2	함석헌	자녀	함국용
3	김수철	출생지	서울특별시
4	황현주	국적	대한민국
...	...	...	...

SWRL_Reasoner

This is an SWRL Inference Engine Using Distributed Table Structure in Cloud Computing Environment.
If you have any questions or comments, please fell free to contact us by email [alsgh9963@naver.com].

Data Format

Data for this model is in `nt` format - basically Prolog syntax:

```
GraduateStudent47 type GraduateStudent
GraduateStudent47 name "GraduateStudent47"
GraduateStudent47 memberOf University7
GraduateStudent47 emailAddress "GraduateStudent47@Department16.University7.edu"
GraduateStudent47 telephone "xxx-xxx-xxxx"
GraduateStudent47 takesCourse GraduateCourse5
GraduateStudent47 undergraduateDegreeFrom University10
GraduateStudent47 advisor AssistantProfessor6
```

rules.txt:

```
FullProfessor(?x)^worksFor(?x,?d)^subOrganizationOf(?d,?u)->worksFor(?x,?u)
FullProfessor(?x)^worksFor(?x,?d)^subOrganizationOf(?d,?u)^FullProfessor(?y)^worksFor(?y,?u)->workMateOf(?x,
publicationAuthor(?p,?x)^publicationAuthor(?p,?y)->coauthor(?x,?y)
takesCourse(?x,?c)^GraduateCourse(?c)->GradStudent(?x)
takesCourse(?x,?c)^takesCourse(?y,?c)^GraduateCourse(?c)->grateClassMate(?x,?y)
Student(?x)^advisor(?x,?p)^Student(?y)^advisor(?y,?p)^Professor(?p)->fellow(?x,?y)
```

Path-based reasoning approach for knowledge graph completion using CNN-BiLSTM with attention mechanism

This is an implementation of Knowledge graph completion using CNN-BiLSTM with attention Model.
If you have any questions or comments, please fell free to contact us by email [alsgh9963@naver.com].

Data description

- `data/<DATASETS>/ontology.txt` : 각 dataset에 대한 Ontology file
- `data/<DATASETS>/paths/`
  - `<RELATIONS>.txt` : Path Ranking Algorithm을 통해 추출된 Relation Paths
- `data/<DATASETS>/tasks/graph.txt` : Knowledge Graphs
- `data/<DATASETS>/tasks/<RELATIONS>/`
  - `train.pair` : Correct, Corrupt Train Data
  - `train_pos` : Correct Train Data
  - `test.pairs` : Correct, Corrupt Test Data
  - `sort_test.pairs` : 정렬된 Test Data

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

주 의

1. 이 보고서는 과학기술정보통신부에서 시행한 정보통신 · 방송연구개발사업의 ○○연구 개발과제 최종보고서이다.

2. 이 연구개발내용을 대외적으로 발표할 때에는 반드시 과학기술정보통신부(정보통신기획평가원)에서 시행한 정보통신 · 방송연구개발사업의 결과임을 밝혀야 한다.

3. 국가과학기술 기밀 유지에 필요한 내용은 대외적으로 발표 또는 공개하여서는 안 된다.