국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

보안 과제( ), 일반 과제(v) / 공개( ), 비공개( ), 발간등록번호( )

SW컴퓨팅산업원천기술개발 사업 제3차 연도 최종보고서

2020-0-00121

데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발 최종보고서

2023. 02. 28.

주관연구개발기관 부산대학교 산학협력단

공동연구개발기관 서울대학교 산학협력단
공동연구개발기관 서울시립대학교 산학협력단
공동연구개발기관 이화여자대학교 산학협력단
공동연구개발기관 한성대학교 산학협력단
공동연구개발기관 ㈜프람트테크놀로지
공동연구개발기관 ㈜아이소프트

과학기술정보통신부

정보통신기획평가원

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서

보안등급
일반[v], 보안[ ]

중앙행정기관명	과학기술정보통신부	사업명	사업명	SW컴퓨팅산업원천기술개발
전문기관명(해당 시 작성)	정보통신기획평가원		내역사업명 (해당 시 작성)	데이터기반핵심기술개발(빅데이터)
공고번호	제2019-0654호	총괄연구개발 식별번호 (해당 시 작성)		
		연구개발과제번호		2020-0-00121

기술분류	국가과학기술 표준분류	EE0105	50 %	EE0112	30%	EE0202	20 %
	부처기술분류 (해당 시 작성)	빅데이터 수집/저장/관리/분석(마이닝)/예측	50 %	DBMS	30%	지식/직관추출	20 %

총괄연구개발명 (해당 시 작성)	국문			
	영문			
연구개발과제명	국문	데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발		
	영문	Development of data improvement and dataset correction technology based on data quality assessment		
주관연구개발기관	기관명	부산대학교 산학협력단	사업자등록번호	621-82-06530
	주소	(46241)부산광역시 금정구 부산대학로63번길 2 (장전동)	법인등록번호	184771-0000478

연구책임자	성명	권준호	직위	교수
	연락처 직장전화	051-510-3149	휴대전화	*******
	연락처 전자우편	jhkwon@pusan.ac.kr	국가연구자번호	*******

연구개발기간	전체		2020. 04. 01 - 2022. 12. 31(2년 9개월)
	단계 (해당 시 작성)	1단계	2020. 04. 01 - 2021. 12. 31(1년 9개월)
		2단계	2022. 01. 01 - 2022. 12. 31(1년 0개월)

연구개발비 (단위: 천원)		정부지원 연구개발비	기관부담 연구개발비		그 외 기관 등의 지원금				합계			연구개발비 외 지원금
					지방자치단체		기타( )					
		현금	현금	현물	현금	현물	현금	현물	현금	현물	합계	
총계		3,000,000		362,421					3,000,000	362,421	3,362,421	
1단계	1년차	600,000		81,812					600,000	81,812	681,812	
	2년차	800,000		120,082					800,000	120,082	920,082	
2단계	1년차	1,600,000		160,527					1,600,000	160,527	1,760,527	

공동연구개발기관 등 (해당 시 작성)	800,000		120,082				
						역할	기관유형
공동연구개발기관	서울대학교 산학협력단	성주헌	교수	*******	jsung@snu.ac.kr	*공동*	*대학*
	서울시립대학교 산학협력단	김한준	교수	*******	khj@uos.ac.kr	*공동*	*대학*
	이화여자대학교 산학협력단	반효경	교수	*******	bahn@ewha.ac.kr	*공동*	*대학*
	한성대학교 산학협력단	장재영	교수	*******	jychang@hansung.ac.kr	*공동*	*대학*
	㈜프람트테크놀로지	전종훈	대표이사	*******	*******	*수요*	*중소기업*
	㈜아이소프트	최동규	대표이사	*******	dgchoi@i-soft.kr	*수요*	*중소기업*

연구개발담당자 실무담당자	성명	김구	직위	참여연구원	
	연락처 직장전화	051-510-2877	휴대전화	*******	
	연락처 전자우편	*******	국가연구자번호	*******	

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재처분 등의 불이익도 감수하겠습니다.

2023년 02월 28일

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

최종보고서

보안등급: 일반[v], 보안[ ]

중앙행정기관명	과학기술정보통신부	사업명	사업명	SW컴퓨팅산업원천기술개발	
전문기관명(해당 시 작성)	정보통신기획평가원		내역사업명 (해당 시 작성)	데이터기반핵심기술개발(빅데이터)	
공고번호	제2019-0654호	총괄연구개발 식별번호 (해당 시 작성)			
		연구개발과제번호		2020-0-00121	

기술분류								
국가과학기술 표준분류	EE0105	50 %	EE0112	30%	EE0202	20 %		
부처기술분류 (해당 시 작성)	빅데이터 수집/저장/관리/분석(마이닝)/예측	50 %	DBMS	30%	지식/직관추출	20 %		

총괄연구개발명 (해당 시 작성)	국문			
	영문			
연구개발과제명	국문	데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발		
	영문	Development of data improvement and dataset correction technology based on data quality assessment		
주관연구개발기관	기관명	부산대학교 산학협력단	사업자등록번호	621-82-06530
	주소	(46241)부산광역시 금정구 부산대학로63번길 2 (장전동)	법인등록번호	184771-0000478
연구책임자	성명	권준호	직위	교수
	연락처 직장전화	051-510-3149	휴대전화	*******
	연락처 전자우편	jhkwon@pusan.ac.kr	국가연구자번호	*******

연구개발기간	전체		2020. 04. 01 - 2022. 12. 31(2년 9개월)
	단계 (해당 시 작성)	1단계	2020. 04. 01 - 2021. 12. 31(1년 9개월)
		2단계	2022. 01. 01 - 2022. 12. 31(1년 0개월)

연구개발비 (단위: 천원)		정부지원 연구개발비	기관부담 연구개발비		그 외 기관 등의 지원금				합계			연구개발비 외 지원금
					지방자치단체		기타( )					
		현금	현금	현물	현금	현물	현금	현물	현금	현물	합계	
총계		3,000,000		362,421					3,000,000	362,421	3,362,421	
1단계	1년차	600,000		81,812					600,000	81,812	681,812	
	2년차	800,000		120,082					800,000	120,082	920,082	
2단계	1년차	1,600,000		160,527					1,600,000	160,527	1,760,527	

공동연구개발기관 등 (해당 시 작성)	800,000		120,082			역할	기관유형
공동연구개발기관	서울대학교 산학협력단	성주헌	교수	*******	jsung@snu.ac.kr	*공동*	*대학*
	서울시립대학교 산학협력단	김한준	교수	*******	khj@uos.ac.kr	*공동*	*대학*
	이화여자대학교 산학협력단	반효경	교수	*******	bahn@ewha.ac.kr	*공동*	*대학*
	한성대학교 산학협력단	장재영	교수	*******	jychang@hansung.ac.kr	*공동*	*대학*
	㈜프람트테크놀로지	전종훈	대표이사	*******	*******	*수요*	*중소기업*
	㈜아이소프트	최동규	대표이사	*******	dgchoi@i-soft.kr	*수요*	*중소기업*

연구개발담당자 실무담당자	성명	김구	직위	참여연구원	
	연락처 직장전화	051-510-2877	휴대전화	*******	
	연락처 전자우편	*******	국가연구자번호	*******	

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재처분 등의 불이익도 감수하겠습니다.

2023년 02월 28일

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니디

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규 (직인)

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니디

연구책임자: 권 준 호 (인)

주관연구개발기관의 장: 최 경 민 (직인)

공동연구개발기관의 장: 김 재 영 (직인)

공동연구개발기관의 장: 김 정 현 (직인)

공동연구개발기관의 장: 이 준 성 (직인)

공동연구개발기관의 장: 노 광 현 (직인)

공동연구개발기관의 장: 전 종 훈 (직인)

공동연구개발기관의 장: 최 동 규

과학기술정보통신부장관 귀하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

< 요 약 문 >

<table>
<tr><td colspan="2">사업명</td><td colspan="3"></td><td>총괄연구개발 식별번호
(해당 시 작성)</td><td colspan="2"></td></tr>
<tr><td colspan="2">내역사업명
(해당 시 작성)</td><td colspan="3"></td><td>연구개발과제번호</td><td colspan="2"></td></tr>
<tr><td rowspan="2">기술분류</td><td>국가과학기술 표준분류</td><td>EE0105</td><td>50 %</td><td>EE0112</td><td>30 %</td><td>EE0202</td><td>20%</td></tr>
<tr><td>부처기술분류
(해당 시 작성)</td><td>빅데이터 수집/저장/관리/분석(마이닝)/예측</td><td>50 %</td><td>DBMS</td><td>30 %</td><td>지식/직관추출</td><td>20%</td></tr>
<tr><td colspan="2">총괄연구개발명
(해당 시 작성)</td><td colspan="6">-</td></tr>
<tr><td colspan="2">연구개발과제명</td><td colspan="6">데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발</td></tr>
<tr><td colspan="2">전체 연구개발기간</td><td colspan="6">2020. 04. 01 - 2022. 12. 31(2년 9개월)</td></tr>
<tr><td colspan="2">총 연구개발비</td><td colspan="6">총 3,333,976 천원
(정부지원연구개발비: 3,000,000 천원, 기관부담연구개발비 : 333,976 천원)</td></tr>
<tr><td colspan="2">연구개발단계</td><td colspan="3">기초[ ] 응용[v] 개발[ ]
기타(위 3가지에 해당되지 않는 경우)[ ]</td><td>기술성숙도
(해당 시 작성)</td><td colspan="2">착수시점 기준(4)
종료시점 목표(6)</td></tr>
<tr><td colspan="2">연구개발과제 유형
(해당 시 작성)</td><td colspan="6">-</td></tr>
<tr><td colspan="2">연구개발과제 특성
(해당 시 작성)</td><td colspan="6">기술료비징수, 경쟁형과제, 공개SW</td></tr>
<tr><td rowspan="2">연구개발
목표 및 내용</td><td>최종 목표</td><td colspan="6">[자동화된 대용량 데이터 품질 고도화/개선 및 공정성 확보 프레임워크 개발]
 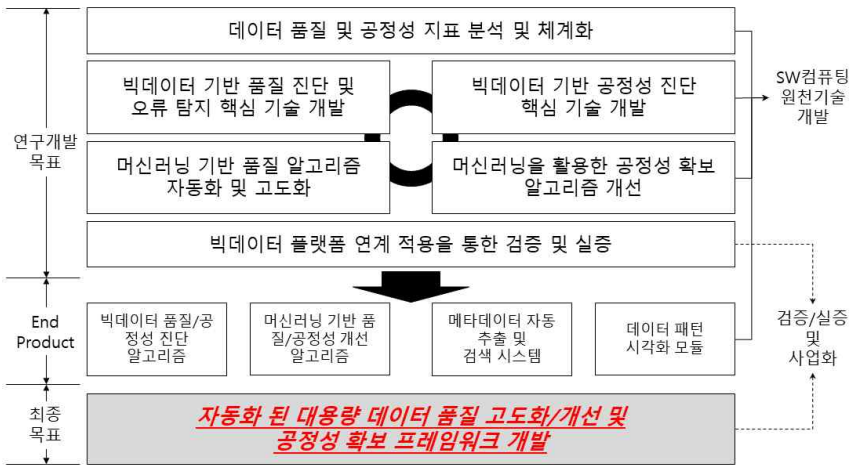
</td></tr>
<tr><td>전체 내용</td><td colspan="6">▪ 빅데이터 기반 데이터 품질/공정성 진단 기술 및 솔루션 개발
• 빅데이터 기반 정형·비정형 데이터 정제 자동화 기술 개발
• 빅데이터 기반 공정성 진단 기술 개발
▪ 머신러닝 기반 데이터 품질/공정성 개선 기술 및 솔루션 개발
• 머신러닝 기반 빅 데이터 오류 보정 자동화 기술 개발
• 머신러닝 기반 공정성 개선 기술 개발
▪ 데이터 패턴 시각화 기술
• Supervised and unsupervised 패턴:
- supervised: ground truth를 통해서 training된 loss값의 주요 요인별 영향 graph를 통한 visualization
- unsupervised: Principal component 추출과 10개 정도의 PC 축에서 주요 요인들의 패턴 시각화
• 관계형 이상값 시각화: correlogram 및 multivariate-correlogram 상의 편차 (s.d. 단위) 시각화</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td rowspan="16"></td><td rowspan="2"></td><td colspan="3">• 공정성 지표의 시각화: 주요 계층별 (성, 연령군, 지역 및 인구집단 등)의 시각화 지표와 공정성지표 제시

[기술 개발 개념도]
 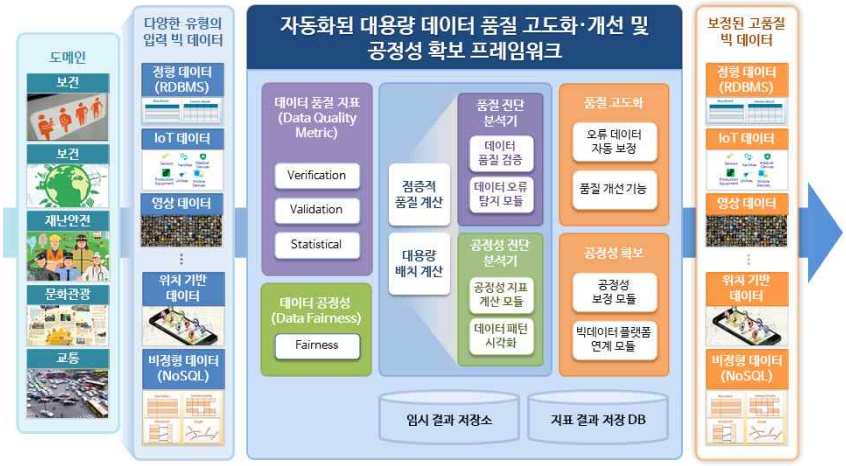
</td></tr>
<tr><td rowspan="15">1단계 (해당 시 작성)</td><td>목표</td><td colspan="3">▪ 데이터 품질 및 공정성 지표 분석 및 체계화
▪ 빅데이터 기반 품질 진단 및 오류 탐지 핵심 기술 개발
▪ 빅데이터 기반 공정성 진단 핵심 기술 개발
▪ 데이터 패턴 시각화 기술 개발</td></tr>
<tr><td rowspan="14">내용</td><td rowspan="2">부산대학교</td><td>1차년</td><td>▪ 교통 데이터 품질 지표 분석
▪ 비정형 이미지 데이터 품질 지표 평가 모델링
▪ 품질성능지표 체계화</td></tr>
<tr><td>2차년</td><td>▪ 데이터셋 구성 요소 분석
▪ 품질 보정 기술 비교 분석
▪ 배치 기반 데이터 셋 공정성 보정 기술</td></tr>
<tr><td rowspan="2">서울대학교</td><td>1차년</td><td>▪ 보건 데이터 품질 지표 분석
▪ AI 기반 비정형 데이터 품질 지표 평가 모델링</td></tr>
<tr><td>2차년</td><td>▪ 공정성 지표 분석 및 정의
▪ 데이터 패턴 시각화</td></tr>
<tr><td rowspan="2">서울시립대학교</td><td>1차년</td><td>▪ 문화 관광 분야 데이터 품질 지표 분석
▪ 품질 지표 평가 방법 모델링</td></tr>
<tr><td>2차년</td><td>▪ 데이터 품질 개선 자동화 기반 설계
▪ 정형 데이터 품질 개선 알고리즘 개발</td></tr>
<tr><td rowspan="2">이화여자대학교</td><td>1차년</td><td>▪ 환경 데이터 품질 지표 분석
▪ 통계 기반 특징 변환 알고리즘 개발
▪ 머신러닝 기반 특징공학 알고리즘 개발</td></tr>
<tr><td>2차년</td><td>▪ 특징 공학(feature engineering) 연산자 고도화
▪ 오류 탐지 및 보정 기술 개발</td></tr>
<tr><td rowspan="2">한성대학교</td><td>1차년</td><td>▪ 재난안전 분야 데이터 품질 지표 분석
▪ 데이터 프로파일링을 위한 메타데이터 분류 및 관리체계 설계</td></tr>
<tr><td>2차년</td><td>▪ 메타데이터 수집 기술 개발
▪ 메타데이터 변환 및 편집, 저장 기술 개발</td></tr>
<tr><td>㈜아이소프트</td><td>1차</td><td>▪ 빅데이터 품질 수준 현황 조사
▪ 공정성 분석기 및 패턴 시각화 도구 설계</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

				2차년	▪ 공정성 분석기 도구 개발 ▪ 데이터 패턴 시각화 도구 개발 ▪ 공정성 도구 통합
			㈜프람트테크놀로지	1차년	▪ 피드백 지원 품질 평가 도구 개발
				2차년	▪ 데이터 품질 분석 도구 제품화 ▪ 데이터 오류 보정 도구 설계 및 개발 ▪ 데이터 품질 개선 솔루션 통합
	2단계 (해당 시 작성)	목표	▪ 머신러닝 기반 품질 알고리즘 자동화 및 고도화 ▪ 머신러닝을 활용한 공정성 확보 알고리즘 개선 ▪ 빅데이터 플랫폼 연계 적용을 통한 검증 및 실증		
		내용	부산대학교		▪ 점증적 데이터 셋 보정 기술 개발 및 고도화 ▪ 공정성 보정 기술 통합 ▪ 빅데이터 플랫폼 연계 통합 관리
			서울대학교		▪ 보건데이터의 공정성 평가 자동화 ▪ 데이터 시각화 API 고도화
			서울시립대학교		▪ 비정형 데이터 품질 개선 기술 개발 ▪ AI기반 품질 개선 기술 개발
			이화여자대학교		▪ AI기반 오류 탐지 기술 고도화 ▪ AI기반 오류 보정 기술 개발
			한성대학교		▪ 메타데이터 검색 및 활용 기술 개발
			㈜아이소프트		▪ 공정성 도구 고도화 및 통합 ▪ 빅데이터 플랫폼 연계 검증
			㈜프람트테크놀로지		▪ 데이터 품질 개선 솔루션 통합 및 고도화 ▪ 데이터 맵 기술 개발

연구개발성과

- ▪ 공개 대표 SW 5건 (대용량 데이터 품질 고도화/개선 및 공정성 확보 프레임워크에 포함)
  - • 빅데이터 품질/공정성 진단 알고리즘 (SW)
  - • 머신러닝 기반 품질/공정성 개선 알고리즘 (SW)
  - • 메타데이터 자동 추출 및 검색 시스템 (SW)
  - • 데이터 패턴 시각화 모듈 (SW)
  - • 산출물의 최종 통합 (SW)
- ▪ 예상되는 연구개발성과 유형

구분	논문	특허	보고서 원문	연구시설・장비	기술 요약 정보	소프트웨어
예상성과 (N/Y)	Y	Y	Y	N	N	Y

연구개발성과 활용계획 및 기대 효과

[활용 계획]

- ▪ 연구개발 결과물을 클라우드 서비스化 하여 사업화: 빅데이터 품질 고도화 및 데이터셋 공정성 검증/보정 기술 개발로부터 도출된 다수의 핵심 모듈은 클라우드 서비스가 가능하도록 상용화하여 사업화를 이행
- ▪ 사업화를 위한 시장환경 및 경쟁력 분석
- ▪ 고품질 초고속 데이터 정체 서비스의 사업화: 도메인별 데이터 정제 서비스에 대한 레퍼런스를 구축
- ▪ 사업화 추진 계획 (국내외 사업화 전술): 과제 종료 시점 2년 이후에 매출 달성할 수 있는 규모의 사업으로 추정, 기술의 상용화 및 사업화를 위해 지속적이 고도화 개발

[기대 효과]

(1) 기술적 측면

- ▪ 빅데이터 품질평가 기술 기반 분석의 발전에 따른 자동 분석 및 예측 서비스의 빠른

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

상용화
- 빅데이터의 성공적 적용 사례로 활용 가능
- 딥러닝을 포함한 머신러닝 기반 시스템의 상용화 촉진

(2) 경제적, 산업적 측면
- 신시장 창출 및 수입대체 효과 기대
- 국산 빅데이터 솔루션의 수준 향상에 따른 기업 및 산업 경쟁력 제고
- 데이터 경제의 확산 기여를 통한 국가 경쟁력 증대
- 선진기술과의 격차해소에 따른 차세대 성장 동력원 효과 기대

(3) 사회적 측면
- 시민급 빅데이터 분석가 양성 효과를 통한 전문가 증가 예상
- 데이터 과학자 인력의 양성 효과 기대
- 빅데이터 관리 전문 인력의 양성 효과
- 지능형 빅데이터 기술의 사회적 영향력 증대
- 단순 빅데이터 저장소를 넘어선 고품질 빅데이터 관리 서비스의 실현을 기반한 새로운 서비스 창출

[공개 SW R&D 전략과 활성화 방안]
- 공개 SW R&D 전략: 아래 3개 항목에 대한 각 년도 세부 전략 수립
  - 공개 SW의 철학과 개발 환경에 이해도에 따라 수준별 교육 및 글로벌 프로젝트 참여를 확대
  - 공개SW기반 최신 SW 프로젝트 개발 및 고급 개발자 양성
  - 공개SW 라이선스 관리체계 고도화
- 공개 SW 활성화 방안
  - 빅데이터 처리 및 관리와 연관된 국내외 공개SW 프로젝트 커뮤니티에 적극적인 홍보를 할 수 있도록 해당 커뮤니티 개발자 행사에 참여를 독려하고 1차년도 이후부터 본 과제에서 개발하는 초기 단계 공개SW 프로젝트 결과물에 대한 개발 및 관리 노하우 습득을 위해 개발자 초청행사를 개최할 수 있도록 추진

연구개발성과의 비공개여부 및 사유	해당사항 없음

연구개발성과의 등록·기탁 건수	논문	특허	보고서 원문	연구시설·장비	기술요약정보	소프트웨어	표준	생명자원		화합물	신품종	
								생명정보	생물자원		정보	실물
	28	24	42			16						

연구시설·장비 종합정보시스템 등록 현황	구입기관	연구시설·장비명	규격(모델명)	수량	구입연월일	구입가격(천원)	구입처(전화)	비고(설치장소)	ZEUS 등록번호

국문핵심어 (5개 이내)	데이터 품질 진단	데이터 보정	품질 개선	데이터셋 공정성	빅 데이터
영문핵심어 (5개 이내)	data quality assessment	data correction	data quality improvement	dataset fairness	big data

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<목 차>

1. 연구개발과제의 개요..... 1

2. 연구개발과제의 수행 과정 및 수행 내용..... 5

3. 연구개발과제의 수행 결과 및 목표 달성 정도..... 118

4. 목표 미달 또는 미흡한 사항에 대한 원인분석 142

5. 연구개발성과의 관련 분야에 대한 기여 정도..... 142

6. 연구개발성과의 관리 및 활용 계획..... 145

7. 연구개발성과에 대한 후속연구 및 추가 개발 계획 148

8. 연구개발비 사용실적 149

붙임1. 사업화대상기술별 기술명세서..... 156

붙임2. 자체 보안관리 진단표..... 183

붙임3. 공개 SW 요약서 *(공개SW과제만 작성)*..... 190

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1. 연구개발과제의 개요

1) 기술 개발의 필요성

(1) 머신러닝 기술의 발전에 따라 데이터 품질 이슈와 공정성 이슈가 제기됨

- ✓ 머신러닝 진행을 위해서는 그림 1과 같이 많은 양의 엄선된 훈련 데이터가 필요함
- ✓ 또한 아래 그림 2와 같이 머신러닝 파이프라인의 각 단계에서 인간의 편견(human bias)이 개입하여 올바르지 못한 결과를 초래할 수 있음

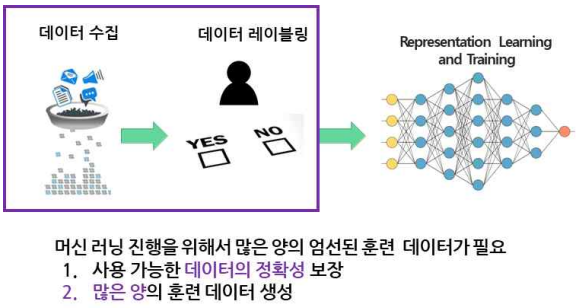

[그림 1] 품질 이슈

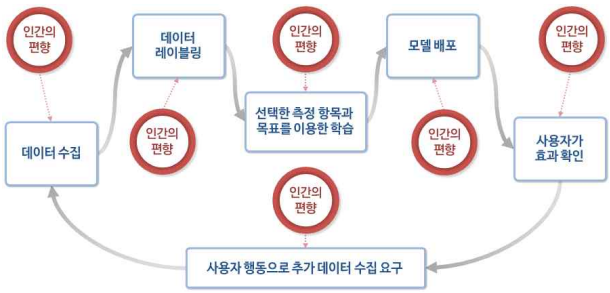

[그림 2] 공정성 이슈

(2) 다양한 데이터 품질 관련 지표들이 존재하나 SW품질의 일부로서 데이터의 일반적 성질을 기반으로 작성되어 있거나 추상적인 경우가 많음

- ✓ ISO/IEC 25012 (이후 ISO/IEC 25024)에서 소프트웨어 품질에 영향을 미치는 데이터 품질 모델을 정확성, 완전성, 일관성, 신뢰성, 현재성과 같은 데이터의 고유 성질과, 가용성, 이식성, 복구성, 유용성, 적합성, 기밀성, 효율성, 정밀성, 추적성, 이해성과 같은 소프트웨어 종속적 성질로 구분함
- ✓ 2016년도부터 사용되고 있는 행정안전부의 지표는 유효성과 적합성을 그 평가 척도로 사용.
- ✓ 한국정보화진흥원에서는 준비성, 완전성, 일관성, 정확성, 보안성, 적시성, 유용성의 7개 지표 및 24개 세부 품질 지표를 제시
- ✓ 빅 데이터를 AI의 학습 데이터로 사용하려는 요구 증대되고 있으나, 빅 데이터가 AI에 학습 데이터로서의 유용성과 결과의 공정성에 대한 지표 부족

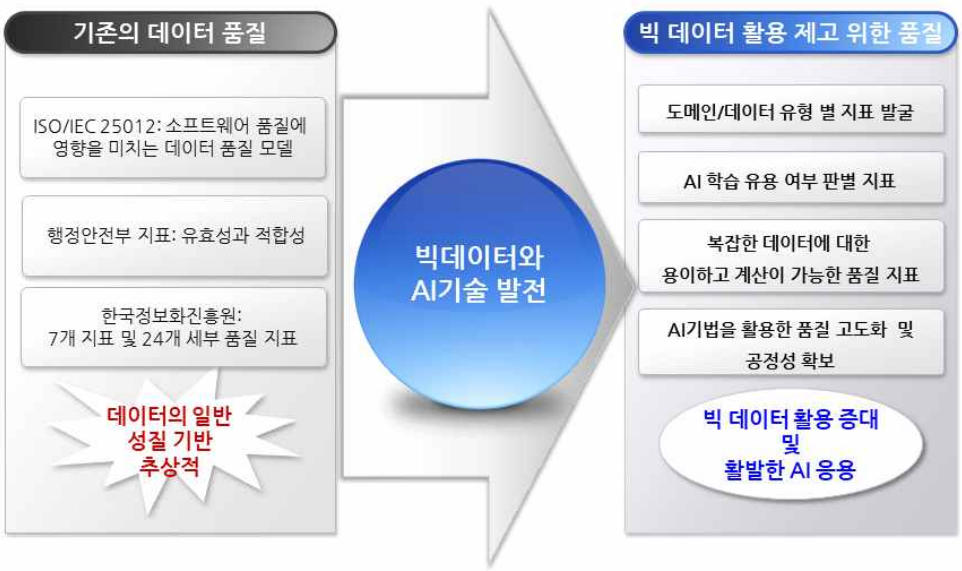

[그림3] 산업혁명 시대를 위한 새로운 품질 지표 개발 필요성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 기술 개발의 개요

(1) 본 사업의 목표는 그림 4와 같이 자동화된 대용량 데이터 품질 고도화, 공정성 확보 및 보정 프레임워크 개발을 목표로 함

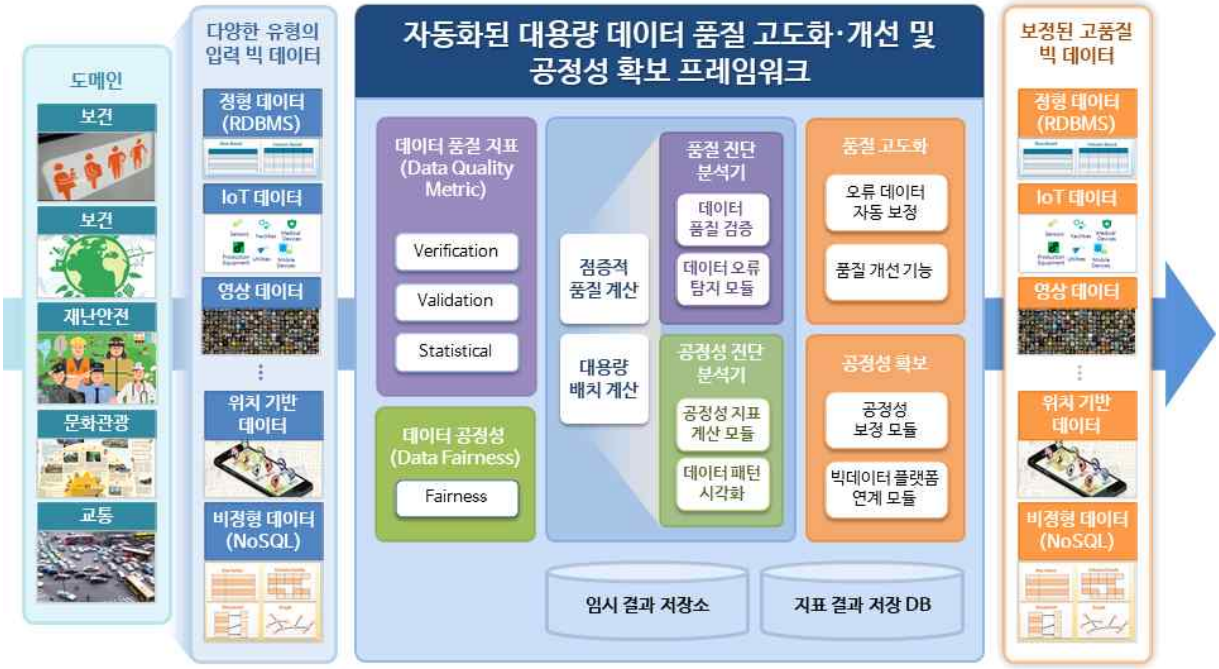

[그림 4] 기술 개발의 개념도

- ✓ 제시하는 프레임워크는 빅 데이터의 신뢰성을 보장하고 활용성 증대를 위해 2가지 영역인 데이터 품질과 데이터 공정성 구성요소로 나누어짐
- ✓ 데이터 품질 구성요소는 체계적이고 합리적인 품질 지표 정의, 점증이나 배치처리 형태의 데이터 품질 분석기, 자동 보정이나 AI기반 품질 개선을 제공하는 품질 고도화 연구 수행
- ✓ 공정성 구성 요소는 빅 데이터의 AI 학습데이터로의 유용성과 공정성을 판단하는 공정성 지표 정의, 점증식이나 배치 방식의 공정성 분석 기능, 공정성 자동 보정 기능과 빅데이터 플랫폼 연계를 제공하는 공정성 고도화 기술 등을 연구 개발함
- ✓ 이를 통하여 5개 도메인에서 발생하는 다양한 형태의 입력 빅 데이터를 공정성과 신뢰성이 보정된 고품질의 데이터로 변환하여 제공

3) 기술 개발의 방향 및 범위

(1) (품질 구성 요소) 빅 데이터 활용 주기에 맞는 명확하고 계산이 용이한 데이터 품질 지표 설정 및 평가 검증 모델 개발

- ✓ 빅데이터 생애 주기 분석(그림 5)를 통하여 그림 6와 같이 밸류 체인을 고려한 전주기적 품질 지표 및 전주기적 품질 관리/검증 모델 제시. 피드백 지원 평가 도구 개발

[그림 5] 빅 데이터 생애 주기

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

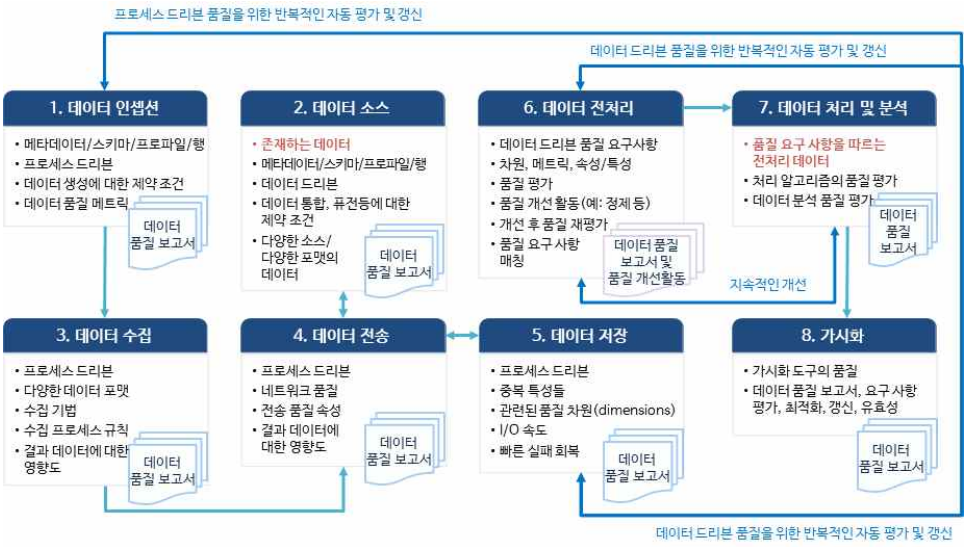

[그림 6] 빅 데이터 밸류 체인을 위한 전주기적 품질 관리 모델

✓ 정형/비정형 데이터 유형을 고려한 품질 진단 지표 기반의 AI기술을 활용한 품질 고도화 기법 제시: 머신러닝 기반의 품질 개선 프로세스 정의를 통한 빅데이터 품질 개선 기술 개발

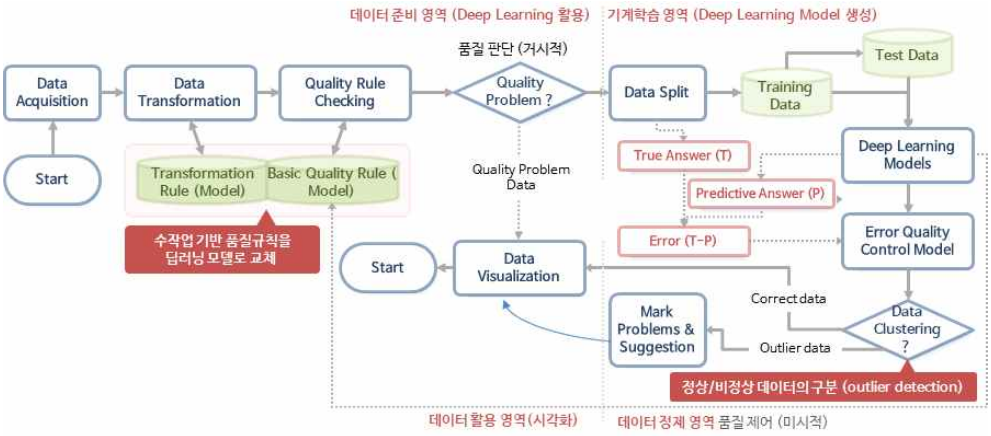

[그림 7] AI (머신러닝) 기반 품질 개선 프로세스

(2) (공정성 구성 요소) 모든 사람에게 공정하고 포용적인 AI를 위한 빅 데이터 공정성 지표 정의 및 딥러닝 기반 보정 기술 개발

✓ AI 활용을 위한 빅 데이터 기반의 데이터셋을 분석하여 활용할 시 데이터/AI알고리즘/사용자 피드백시 발생할 수 있는 편견(bias)을 파악하고 가장 효과적이라고 생각한 루프의 화살표에 그룹화함. 데이터 내의 편견들은 서로 얽혀 있으므로, 상호 영향성을 고려한 공정성 지표 개발 필요

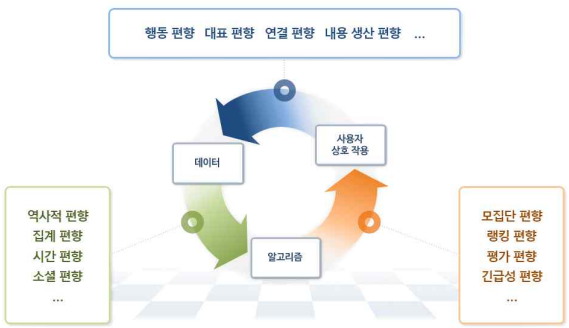

[그림 8] 데이터/AI/사용자 피드백에 나타나는 편견

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 명확하고 용이하게 계산 가능한 공정성 지표의 예

지표명	설명	계산 방법
균등한 승률 (Equalized Odds)	보호된 그룹과 보호되지 않은 그룹은 참 긍정(true positive)과 오탐지(false negative)에 대해 동일한 비율을 가져야함	C is independent of A conditional on Y: $P_0[C = r \mid Y = y] = P_1[C = r \mid Y = y] \; \forall r, y$
균등 기회 (Equal Opportunity)	보호 그룹과 보호되지 않은 그룹은 동일한 참 긍정(true positive)의 비율을 가져야 함	$P_0[C = 1 \mid Y = 1] = P_1[C = 1 \mid Y = 1]$ which is called **Equality of Opportunity**.
인구통계 패리티 (Demographic Parity)	긍정적인 결과의 가능성은 개인이 보호된(예: 여성) 그룹에 있는지 여부에 관계없이 동일해야 함	C is independent of A: $P_0[C = c] = P_1[C = c] \; \forall c \in \{0,1\}$
인식을 통한 공정성 (Fairness Through Awareness)	특정 작업을 위해 정의된 유사성 (역거리) 척도에서 유사한 두 개인은 유사한 결과를 받아야 함	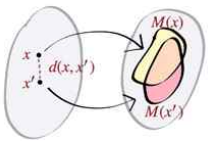
average odds difference	권한이 없고 권한이 있는 그룹에 대한 FPR과TPR의평균 차이	$\frac{1}{2}[(FPR_{D=\text{unprivileged}} - FPR_{D=\text{privileged}}) + (TPR_{D=\text{unprivileged}} - TPR_{D=\text{privileged}}))]$
Generalized Entropy index	일반화된 엔트로피 지수는 통합 개인 및 그룹 공정성 척도	$\mathcal{E}(\alpha) = \begin{cases} \frac{1}{n\alpha(\alpha-1)} \sum_{i=1}^{n} \left[\left(\frac{b_i}{\mu}\right)^{\alpha} - 1\right], & \alpha \neq 0, 1, \\ \frac{1}{n} \sum_{i=1}^{n} \frac{b_i}{\mu} \ln \frac{b_i}{\mu}, & \alpha = 1, \\ -\frac{1}{n} \sum_{i=1}^{n} \ln \frac{b_i}{\mu}, & \alpha = 0. \end{cases}$
Disparate Impact	권한이 없는 그룹과 권한 있는그룹의 두 그룹에 대해 긍정적인 결과를 받는 개인의 비율 비교	$\frac{Pr(Y = 1 \mid D = \text{unprivileged})}{Pr(Y = 1 \mid D = \text{privileged})}$

✓ 데이터 셋의 공정성 확보를 위한 확률론적 처리 기법 연구

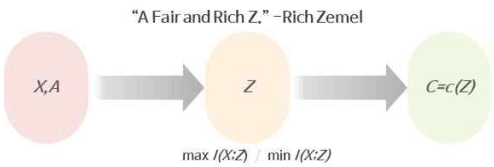

[그림 9] 공정성 확보 기본개념

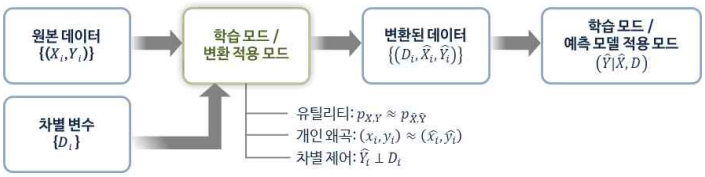

[그림 10] 확률론적 처리 기법

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2. 연구개발과제의 수행 과정 및 수행 내용

1) 연구개발 수행 과정

(1) 공개SW를 위한 저장소 및 채널 구축

가) 공개SW 기반의 연구수행 결과물의 사업화(상용화)를 위한 브랜드 化

- QuFa: Data Quality and Fairness
- Identity: 데이터 품질/공정성 원천기술 개발에 따른 개선/보정을 우직하고 충실하게 수행하겠다는 모티브를 통해 데이터 분야의 거대한 공룡으로 거듭나겠다는 목표로 형상화
- Supported by ㈜프람트테크놀로지, 공동연구기관(수요-사업화 기업)

[그림 11] QuFa CI

나) Vendor Lock-in 없는 공개 S/W 추진

- 순수 공개 S/W 기반 도구 및 개발 환경 적용
  - ✓ 특정 제품, 기존 솔루션에 의존적이지 않는 순수한 공개 S/W 도구 활용
  - ✓ 검증된 공개 S/W 유틸리티 활용, 상용/Dual 라이선스 도구 배제
- 완성도 높은 공개 S/W 제품 개발
  - ✓ 추가 개발없이 즉시 활용 가능한 높은 품질의 공개 S/W 제공
  - ✓ 코딩 가이드라인 준수, 테스트 기반 개발, CI/CD 적용
- 공개SW 저장소(깃랩): https://gitlab.com/qufa/qufa

[그림 12] Vendor Lock-in 없는 공개 S/W 추진

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다) 공개SW 저장소 라이선스 적용 전략 수립

- 라이선스의 종류 및 조건의 분석
- 라이선스 조건 분석에 따라 모든 사용자의 자유로운 수정/재사용/배포를 위한 Apache License 2.0 적용

구분	GPL	AGPL	LGPL	Apache	MIT
필수 사항	▪ 수정한 소스코드 및 프로그램 모두 GPL로 공개 ▪ 라이센스 및 저작권 명시 ▪ 변경사항 공지	▪ 수정한 소스코드 및 프로그램 모두 AGPL로 공개 ▪ 라이센스 및 저작권 명시 ▪ 변경사항 공지 ▪ 네트워크내의 프로그램 사용자에게 소스코드 공개	▪ 수정한 소스코드 및 프로그램 모두 LGPL로 공개 ▪ 라이센스 및 저작권 명시 ▪ 라이브러리에만 적용	▪ 라이센스 및 저작권 명시 ▪ 변경사항 공지	▪ 라이센스 및 저작권 명시
사용허가 조건	▪ 상업적 이용 가능 ▪ 수정 및 배포 가능 ▪ 특허 가능 ▪ 사적 이용 가능	▪ 상업적 이용 가능 ▪ 수정 및 배포 가능 ▪ 특허 가능 ▪ 사적 이용 가능	▪ 상업적 이용 가능 ▪ 수정 및 배포 가능 ▪ 특허 가능 ▪ 사적 이용 가능	▪ 상업적 이용 가능 ▪ 수정 및 배포 가능 ▪ 특허 가능 ▪ 사적 이용 가능	▪ 상업적 이용 가능 ▪ 수정 및 배포 가능 ▪ 특허 가능 ▪ 사적 이용 가능
제약조건 난이도	상	최상	중	하	하

라) 공식 유튜브 채널에 따른 일반 사용자와의 소통 및 피드백 수집

- 공개SW 산출물 정보의 개방을 통해 일반 사용자 댓글 등에 소통 의견 수집
- 수집 된 의견의 수렴 및 피드백/반영에 따른 연구개발 산출물의 고도화 수행

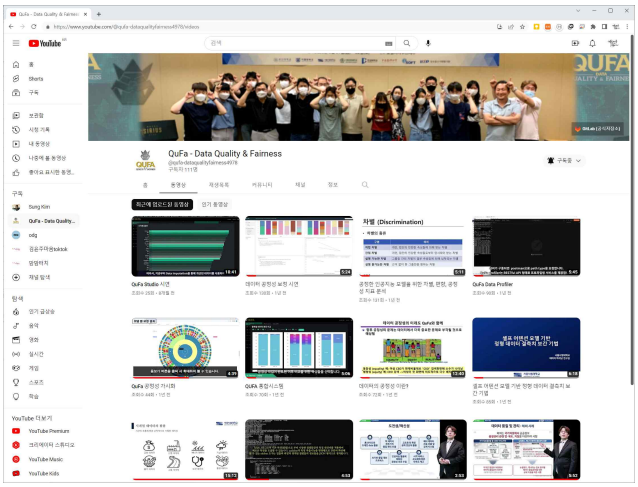

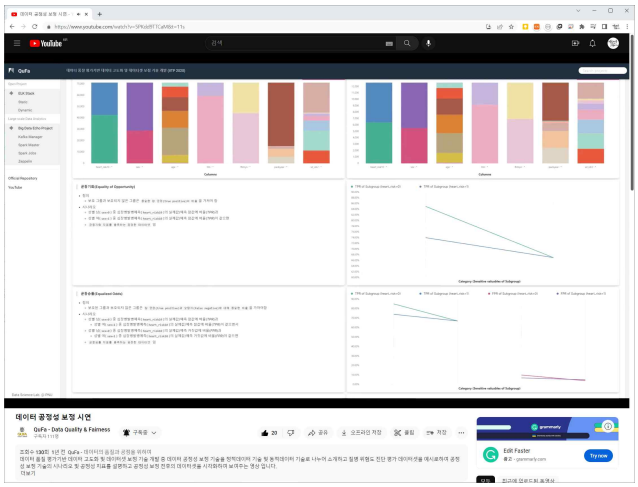

[그림 13] 쿠파 공식 유튜브 채널 (https://www.youtube.com/@qufa-dataqualityfairness4978)

(2) 기관별 체계적인 역할 구분에 따른 선순환적인 연구개발 수행

가) 참여기관의 역할 분담

- 데이터품질/공정성/사업화(제품화, 상용화)의 3개의 팀으로 구분
- 팀(원)별 주요 개발내용 및 역할 정의에 따른 체계적 기술개발 추진/수행

나) 선순환적인 연구개발 수행 구조적용

- 사업화(상용화)를 위해 연구개발한 원천기술 적용 및 검증
- 기술적 요구사항의 피드백 수집에 따른 상용화(제품화) 전략 고도화 수행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그림 14] 원천기술 적용/검증 – 피드백 – 사업화(고도화)를 위한 선순환 구조 적용 및 수행

(3) 정기적/지속적 책임자(실무자) 전체 협의 회의를 통한 연구개발 수행

가) 연구개발 산출물의 적용/검증 및 사업화(상용화)를 위한 협력 수행

- 원천기술 연구개발과 병행하여 산출물의 검증 및 사업화를 위한 협력과정 진행
- (공공기관) 한국공항공사 협업
  - ✓ 2차년 4~11월: MOU를 시작으로 한국공항공사의 데이터 수집 및 항공기 출/도착 시간 데이터의 품질보정 실시, 항공기 도착 예정시간 예측을 위한 모델 설계 구현
- (민간기관) ㈜그리드위즈 협업
  - ✓ 2차년 3~10월: MOU를 시작으로 그리드위즈의 데이터 수집 및 태양광 발전기 시계열 데이터의 품질보정을 위한 모델 제시 및 결측치 보정 및 이상치 대체/제거 실시

(공공기관) 한국공항공사 협업

• MOU를 시작으로 한국공항공사의 운항 데이터 수집, 항공기 출·도착 시간 데이터의 품질 개선 및 도착시간 예측모델 구축을 위한 온·오프라인 협력 진행

구분	날짜	내용	장소(방법)	비고
1	4월	협력을 위한 사전 미팅	온라인	공항공사-쿠파팀
2	4월 30일	품질/공정성 자료 전달	이메일	-
3	5월 20일	검증 방법 논의	온라인	쿠파팀 자체
4	6월 9일	활용 데이터셋 선정	온라인	공항공사-쿠파팀
5	6월 29일	공항공사 데이터 수집 분석	이메일	쿠파팀 자체
6	8월 5일	공항공사 품질 보정 모델 및 예측 정의 (1,2차)	온라인	쿠파팀 자체(1차), 공항공사-쿠파팀(2차)
7	9월 14일	보정 데이터셋의 추가 특징 정의 (항공 날씨 데이터)	온라인	공항공사-쿠파팀
8	10월 8일	MOU 체결	서면	-
9	11월 18일	협력 산출물 점검회의 (품질 보정, 예측)	오프라인 (서울-공항공사)	공항공사-쿠파팀

(민간기관) ㈜그리드위즈 협업

• MOU를 시작으로 그리드위즈의 태양광 발전 시계열 데이터 수집, 데이터의 품질 개선 수행을 위한 온라인 협력 진행

구분	날짜	내용	장소(방법)	비고
1	3~6월	협력 타당성 검토	온라인	쿠파팀 자체
2	7월 6일	품질/공정성 자료 전달	이메일	-
3	7월 6일	활용 데이터셋 정의 (1차)	온라인	그리드위즈-쿠파팀
4	7월 22일	데이터 제공 위한 NDA 협의	온라인	그리드위즈-쿠파팀
5	8월 17일	MOU, NDA 체결	서면	-
6	8월 18일	시계열 데이터 스펙 1차 분석	온라인	쿠파팀 자체
7	9월 8일	그리드위즈 데이터 수집 및 분석	온라인	쿠파팀 자체
8	9월 27일	예측 Feature, 모델 상세 논의	온라인	그리드위즈-쿠파팀
9	10월 1일	데이터 스펙 및 추가 데이터 분석 (장비에 기상 센싱값)	이메일	쿠파팀 자체
10	10월25일	협력 산출물 점검회의 (시계열 타임밴드 보정 및 예측)	온라인	그리드위즈-쿠파팀

[그림 15] 산출물 적용/검증을 위한 (공공/민간)기관 협력 진행
(좌) 한국공항공사 / (우) 주식회사 그리드위즈

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 연구개발 수행 내용

(1) 개별 연구개발 산출물의 RESTful API 化 에 따른 통합 프레임워크 구현

가) 기관별 원천기술 알고리즘, 모델, 가시화를 위한 연구 및 구현/개발 수행

- **총괄(부산대)**: 데이터 품질/공정성의 지표 체계화
- **품질팀(서울시립대, 이화여대, 한성대)**: 데이터 프로파일링, 품질 분석/개선, 특징공학 기반 오류 보정을 위한 원천 알고리즘 연구개발 및 구현
- **공정성팀(부산대, 서울대)**: 데이터 공정성 보정을 위한 원천 알고리즘 연구 및 개발
- **사업화/상용화팀(프람트테크놀로지, 아이소프트)**: 품질/공정성 가시화를 위한 연구 및 기관별 연구개발 원천기술의 사업화(상용화)를 위한 통합 프레임워크 설계 및 구현/개발

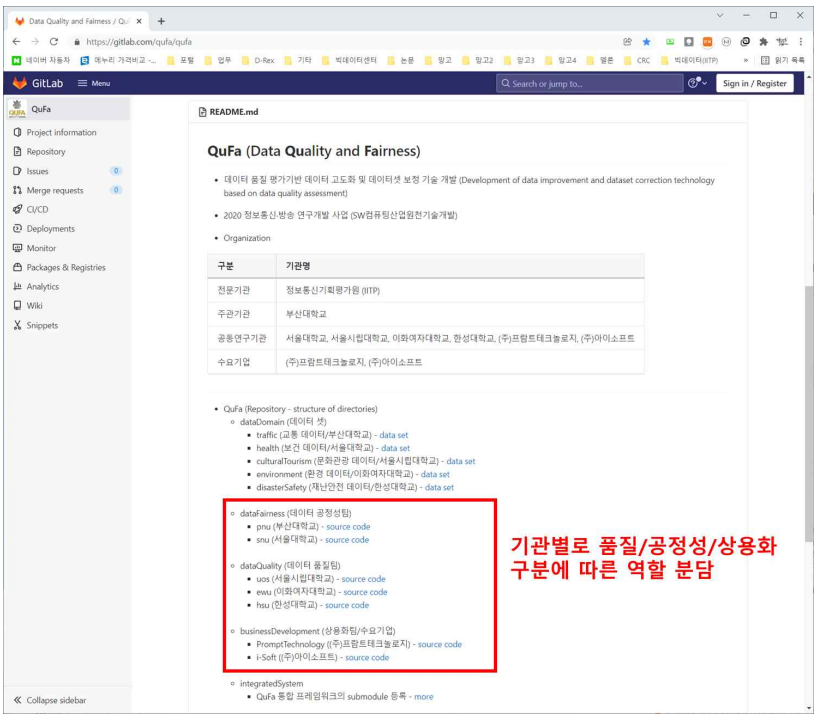

[그림 16] 공개SW 공식 저장소(https://gitlab.com/qufa/qufa)

나) 공개SW 저장소의 기관별 원천 알고리즘(모델, 가시화) 통합을 위한 API 서버 설계/구축

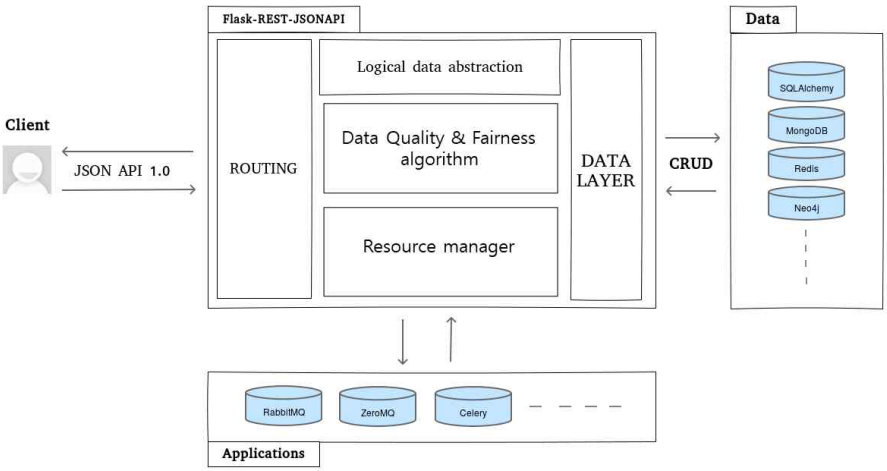

[그림 17] 원천기술 통합을 위한 API 서버 아키텍처

- Flask 기반의 REST-JSON API 제공
- 사용자의 API 호출에 따라 품질/공정성 원천 알고리즘을 통한 데이터셋의 분석 및 보정 수행 후 검증 모델 기반의 보정 결과 제공

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다) 기관별 산출물의 통합 연동을 위한 솔루션의 프로토타입 개발

- 2단계 연구개발 수행 목표인 솔루션의 실증/제품화(상용화)에 기반 마련을 위한 솔루션 프로토타입 설계 및 구현

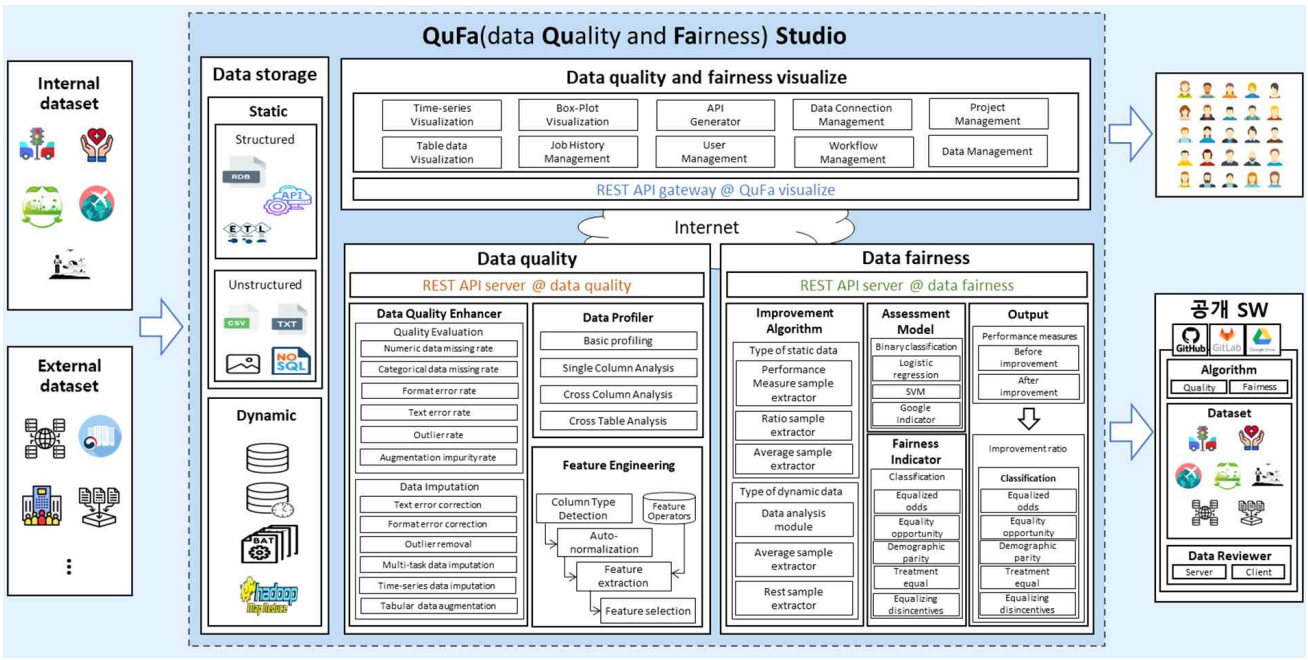

[그림 18] 통합 솔루션의 시스템 아키텍처

- 기관별 산출물(원천기술 알고리즘, 품질/공정성/프로파일링/특징공학 모델, 사용자 친화적 가시화 모듈 등)의 RESTful API 化에 따른 원천기술의 재사용성 제고 및 통합 용이성/효율성 확보
- 공동연구 및 수요기업인 ㈜프람트테크놀로지의 솔루션 통합 및 프로토타입

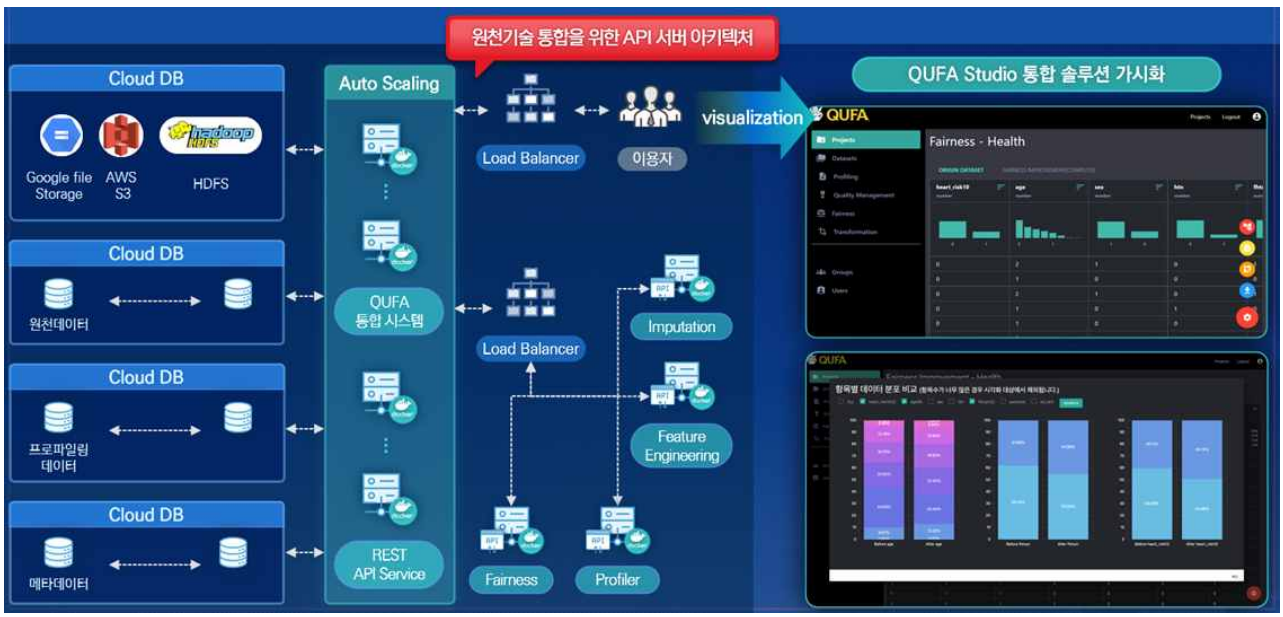

[그림 19] 쿠파 통합 프레임워크 솔루션

(2) 사업화(상용화)를 위해 공개SW 연구수행 결과의 적용 및 검증 실시 (MOU 완료)

가) (공공기관) 한국공항공사 데이터의 품질보정 및 항공기 도착 예측

- **(공항 데이터 응용)** 공항 도메인 데이터 셋 중 비행 소요 시간 예측에 영향을 주는 요소 분석 및 연구
  - ✓ 비행 소요 시간에 영향을 주는 특성을 분석하고, 도메인 이외의 외부 데이터 수집하

여 학습 데이터 셋 구축

- 데이터 품질 향상을 위해 이상치 수정 및 결측치 제거
- Q1 : 1분위수, Q3 : 3분위수, IQR : Q3-Q1
- (Q1 - 1.5 * IQR) 보다 작거나 (Q3 + 1.5 * IQR) 클 경우 이상치로 판단

– 데이터 품질 보정 전

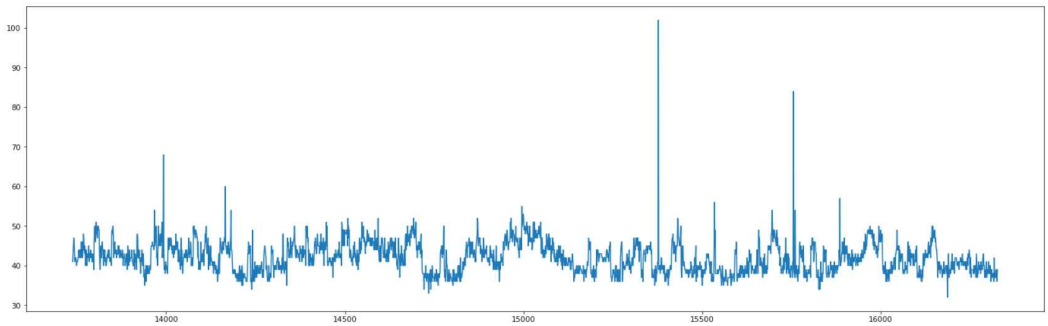

– 데이터 품질 보정 후

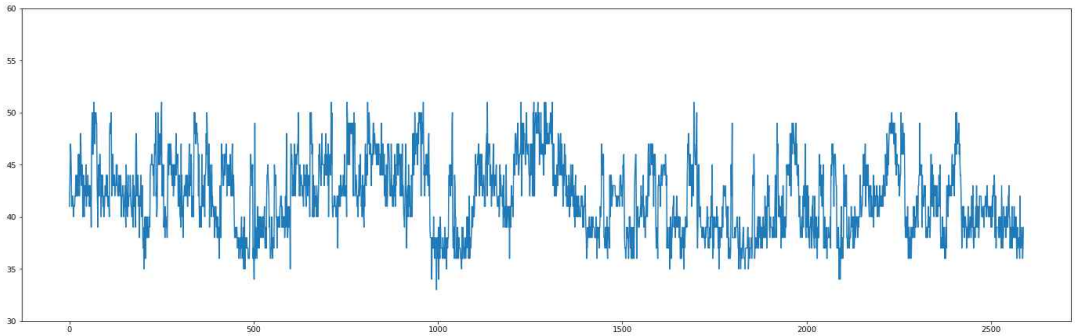

▪ **(기계학습 기반 소요시간 예측 모델)** 구축된 데이터셋을 활용하여 기계학습 기반 운행 소요시간 예측 모델 설계

✓ 앙상블 모델 기반 예측 모델 설계 및 검증 실시

- 앙상블 모델 수식 – XGBoost

$$y'_i = \sum_{k=1}^{K} f_k(x_i)\ , f_k \in F \qquad * where\ y'_i = \text{predict score corresponding to } x_i,$$

$$f_k = k\ th\ decision\ tree\ in\ function\ space\ F,$$

$$\text{Obj} = \sum_{i=1}^{n} l(y_i, y'_i) + \sum_{k=1}^{K} \Omega(f_k) \qquad l = loss\ function,$$

$$\Omega = regularization\ term (= complexity\ of\ Trees)$$

- 기존 모델 대비 부산대 모델 예측 결과

– 데이터 품질 보정 전

- 오차 평균 약 1분 이상 감소

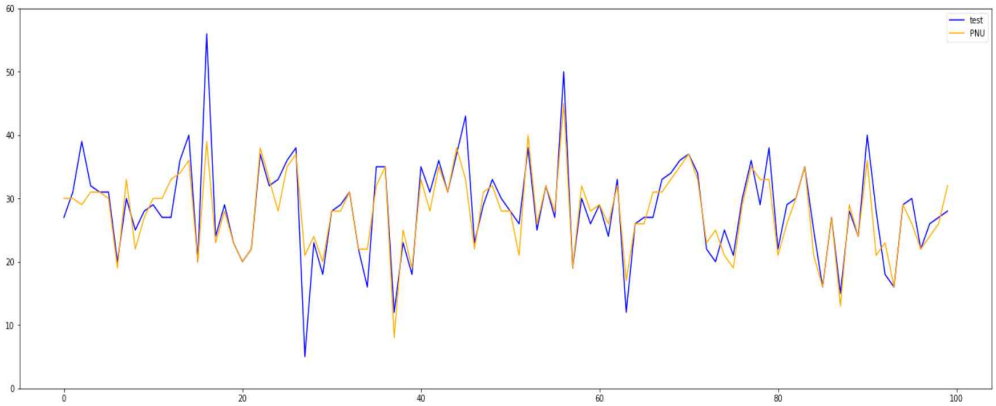

– 데이터 품질 보정 후

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 오차 평균 약 4분 이상 감소

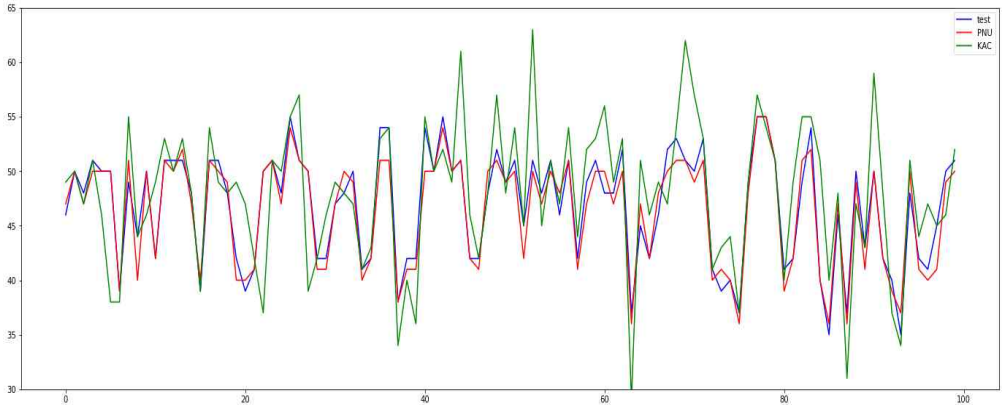

✓ 시각화 및 API 설계

- 논리설계에 따른 동작 시나리오

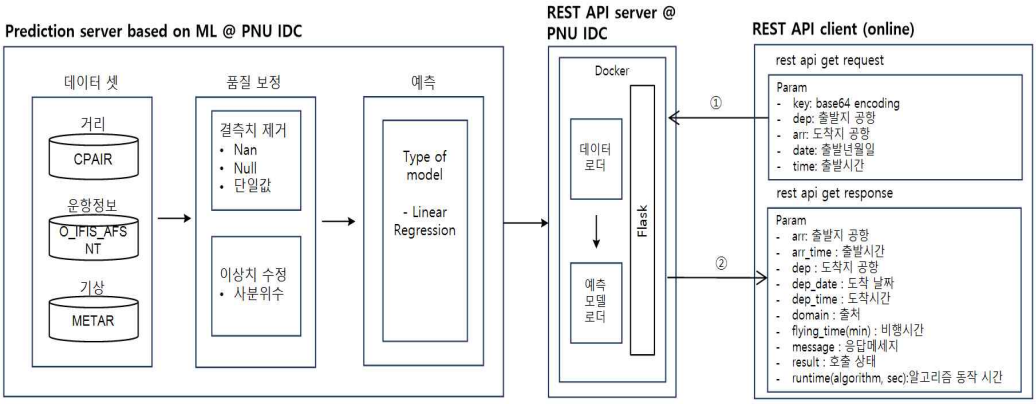

나) (민간기관) 주식회사 그리드위즈 데이터의 품질 분석 및 보정

▪ 데이터 전처리 및 분석 준비

✓ 데이터 준비

- 태양광 환경에서 매우 짧은 주기 단위로 수집된 대용량의 시계열 데이터
- 환경정보 수집 센서와 전력 관련 감지 센서들로부터 수집된 센서 데이터
- 시간 축을 기준으로 관측 센서 데이터와 환경 센서 데이터의 데이터 융합
- 결측 구간 탐지 및 결측 정보 사전 Labeling
- 순간적 시점의 이상값에 대한 강건성 향상을 위한 시간 단위 리샘플링 적용

✓ 입력 데이터 전처리

- 목표 속성들 모두와의 상관성이 낮은 속성 제외
- 관측 시간 데이터는 시간 종속성 분석을 위해 각 속성(년, 월, 요일, 시) 추출
- 범주형 입력 데이터는 각 범주를 0, 1로 표현 하는 원-핫 인코딩 기법 적용
- 수치형 입력 데이터는 -1과 1 사이의 값을 갖도록 Min-Max Scaler 적용

✓ 인코드-디코드 데이터셋 구성

- 관측에 활용되는 환경 속성 등 다변량 속성들은 인코드셋으로 구성
- 분석의 대상이 되는 목표 속성들은 디코드셋으로 구성

✓ 슬라이딩 윈도 기법 적용

- 미시적인 패턴 정보 학습을 위해 연속된 시간 구간의 집합인 윈도 구성
- 인코드셋을 이용하여 직접적인 관측 구간 집합인 관측 윈도 구성
- 디코드셋을 이용하여 직접적인 예측 구간 집합인 예측 윈도 구성
- 각 시점에 대해서 관측 윈도와 예측 윈도 맵핑(Mapping)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

▪ 데이터의 특성 학습

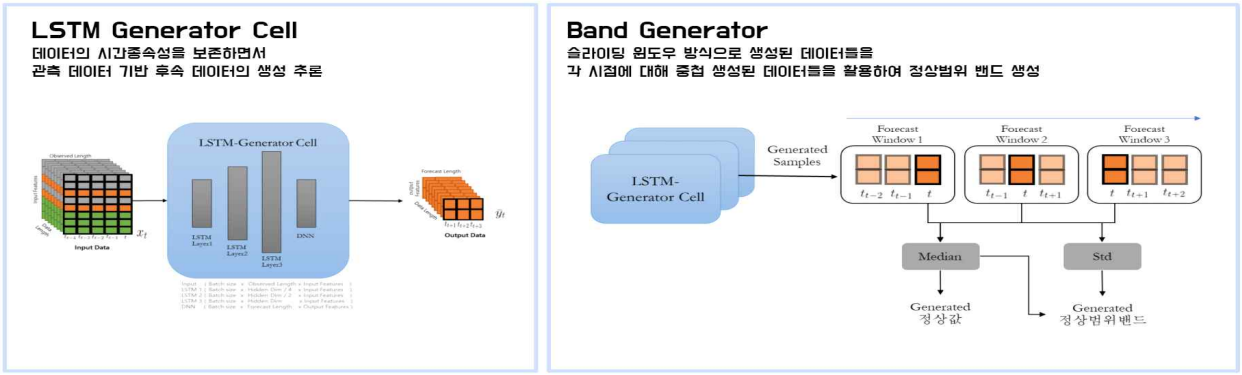

[그림 20] (좌측) 관측값의 후속 값을 예측하는 LSTM 기반 생성자 구조
(우측) 중첩 예측된 값을 이용해 정상범위 밴드를 생성하는 생성자 구조

✓ 딥러닝 기반 정상범위 밴드 생성
- 관측값의 이상 탐지를 위하여 품질 고도화 기법 적용
- LSTM 모델을 통해 입력된 관측 윈도 인코드 셋의 시간적 속성을 보전하면서 예측 윈도의 디코드 셋으로 출력하여 후속 값 예측
- GAN 모델을 통해 관측된 값의 실제 후속 등장 값과 유사한 후속 예측값 다중 생성
- 슬라이딩 윈도 구간이 지나가는 동안 중첩된 정보 생성
- 중첩 생성된 정보들의 중앙값과 편차를 이용해 정상범위 밴드 생성

✓ 정상값 예측을 위한 데이터의 특성 학습
- 중첩 생성된 정보들의 중앙값을 예측 정상값으로 활용하여 결측값 대체
- 실제 값과 예측값 사이의 L1, L2 거리 및 Gradient Penalty를 적용하여 조정 학습
- 적대적 생성구조로 생성한 예측값들이 실제값들과 유사해지도록 학습

✓ 품질 고도화 기법의 적용
- 시간적 특성 및 변수간 상관성을 고려한 생성값을 기반으로 결측값 및 구간정보를 대체함
- 관측값의 후속으로 등장할 데이터에 대해서 생성된 정상범위를 벗어난 이상값을 탐지
- 대체된 결측값에 대한 정보 및 탐지된 이상값에 대한 정보 반환

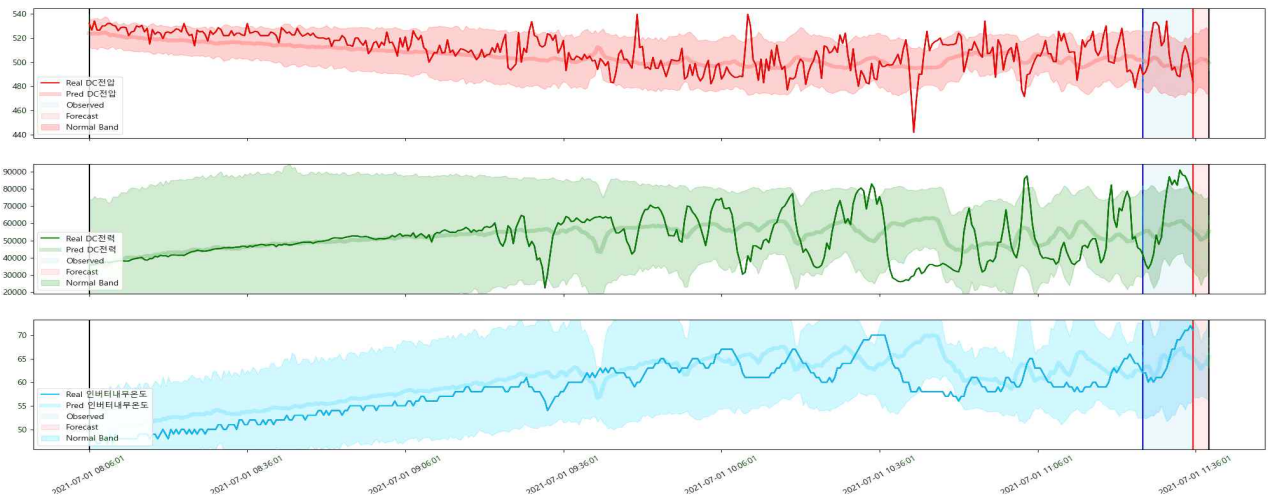

[그림 21] 그리드위즈 데이터 시각화 일부 (전압, 전력, 온도 센서)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다) QUFA Studio 통합 솔루션 개발

- 사용자 중심의 설치/운용 용이성 제공
  - ✓ Docker Hub의 공개된 이미지를 통한 손쉬운 설치 가능
  - ✓ Docker 기반의 배포환경으로 다양한 운영체제에서 구동 가능
  - ✓ 환경변수 기반으로 유연한 설정 정보 등록 가능

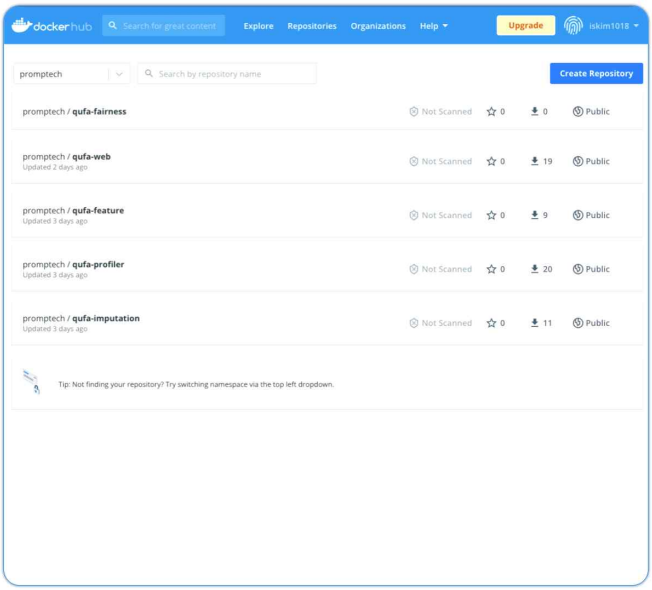

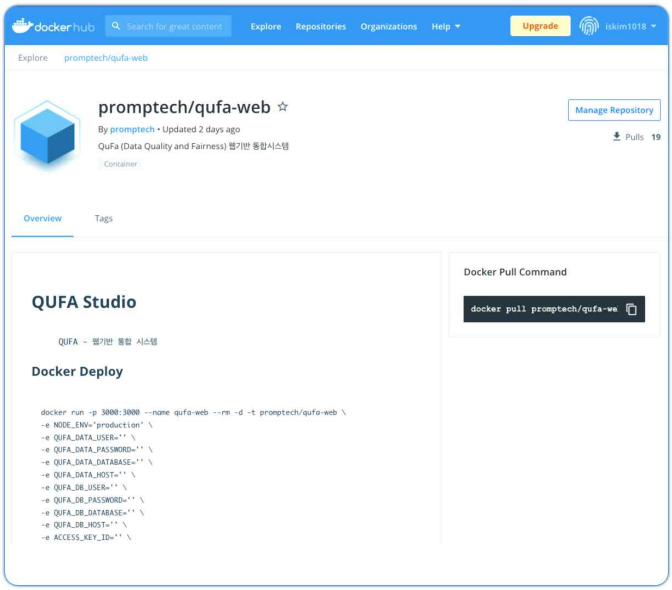

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(3) 1단계 1차년도 - 원천기술 연구 및 개발

[그림 22] 1단계 1차년도 기관별 연구개발 내용 및 산출물

가) 1단계 1차년도 기관별 개발 목표

수행기관	개발목표
주관기관 (부산대학교)	▪ 교통 데이터 품질 지표 분석 ▪ 비정형 이미지 데이터 품질 지표 평가 모델링 ▪ 품질성능지표 체계화
공동연구기관 1 (서울대학교)	▪ 보건 데이터 품질 지표 분석 ▪ AI 기반 비정형 데이터 품질 지표 평가 모델링
공동연구기관 2 (서울시립대학교)	▪ 문화 관광 분야 데이터 품질 지표 분석 ▪ 품질 지표 평가 방법 모델링
공동연구기관 3 (이화여자대학교)	▪ 환경 데이터 품질 지표 분석 ▪ 통계 기반 특징 변환 알고리즘 개발 ▪ 머신러닝 기반 특징공학 알고리즘 개발
공동연구기관 4 (한성대학교)	▪ 재난안전 분야 데이터 품질 지표 분석 ▪ 데이터 프로파일링을 위한 메타데이터 분류 및 관리체계 설계
공동연구기관 5 / 수요기업 (아이소프트)	▪ 빅데이터 품질 수준 현황 조사 ▪ 공정성 분석기 및 패턴 시각화 도구 설계
공동연구기관 6 / 수요기업 (프람트테크놀로지)	▪ 피드백 지원 품질 평가 도구 개발

나) 1단계 1차년도 연구개발 세부 내용

[부산대학교]

■ 교통 데이터 품질지표 분석

▪ 교통 영역에서의 데이터 소스/타입/응용 분석

✓ **(교통 데이터 응용)** 교통 도메인 데이터 셋 중 공공 교통정보 반복 및 비 반복 정체 분석 방법 연구

• 반복 정체 구간에 대한 정의를 기반으로 반복 정체 구간을 선정하고, 해당 구간의 이력 자료를 활용하여 표준노드링크 중 정체 구간의 현황 특성을 분석

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 반복 및 비 반복 정체 구간은 품질평가 대상 선정 시 활용

▪ 정체구간 선정 기준 분석

구분	통행속도	지속시간	발생빈도
반복 정체 (평일 대상)	고속국도 40km/h 이하 일반국도 30km/h 이하 특별광역시·시군도 15km/h 이하	1시간/일 이상	8일/월 이상
비반복 정체 (주말 대상)		2시간/일 이상	4일/월 이상

✓ **(교통 데이터 소스/타입)** 선정 기준 분석에 따른 공공 및 민간 교통정보 데이터 타입으로 구분하여 품질평가 대상 선정 분석

- 공공 및 민간 교통정보 품질평가 대상은 정체 유형, 도로 등급, 정체 지속시간, 정체 시 평균속도 등과 같은 평가지표를 설정한 후 전문가를 대상으로 해당 지표에 대한 AHP 분석을 실시하여 평가 대상을 선정함

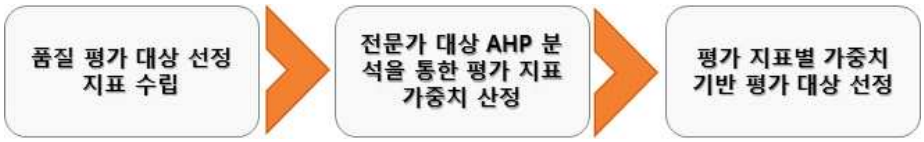

■ 비정형 이미지 데이터 품질지표 평가 모델링

▪ 이미지 데이터 품질 진단 기법 분석

✓ 참조(SSIM) 맵의 픽셀 값들을 평균하여 최종 품질 전수 산출

- 원본 이미지와 왜곡된 이미지를 이용해 휘도(Luminance), 대비(Contrast), 구조(Structure) 기반의 에러값 비교에 따른 품질 진단

✓ Deep CNN 기반의 NIMA 모델을 통한 이미지 품질 진단 예측

- 이미지에 대해 1~10점의 척도로 평점 분포 산출
- 동일 피사체 화질 비교 실시(technical classifications)

▪ 참조 기반 및 블라인드 기반 품질 진단 실시

✓ 참조(SSIM) 기반 품질 진단 실시 결과

- 테스트 데이터

원본이미지(A)	왜곡된 이미지(B)	왜곡된 이미지(C)
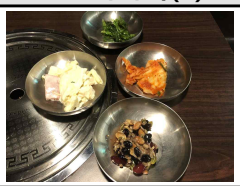	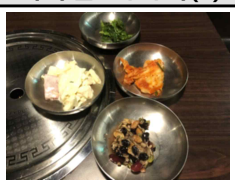	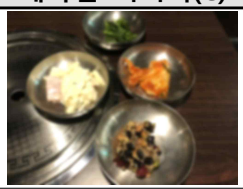
원본이미지(D)	**왜곡된 이미지(E)**	

- 테스트 결과

: 점수가 낮은 C가 B보다 이미지의 품질이 좋지 않음

: 원본이미지D 대비한 왜곡 된 이미지 E의 품질 점수(0.7690)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	입력		품질 점수 (픽셀들 값의 평균)
	원본이미지	왜곡된 이미지	
테스트1	A	B	0.7179
테스트2		C	0.6394
테스트3	D	E	0.7690

[테스트1: SSIM index map - mean ssim value is 0.7179]

[테스트2: SSIM index map - mean ssim value is 0.6394]

[테스트3: SSIM index map - mean ssim value is 0.7690]

✓ 블라인드(NIMA) 기반 품질 진단 실시 결과

- 테스트 데이터

d3	d2	d1	c	b
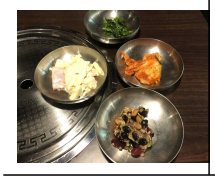	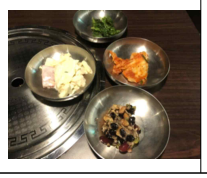	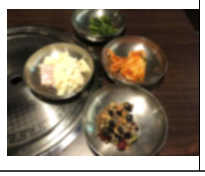	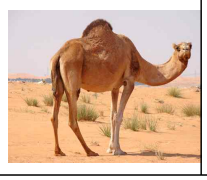	

- 테스트 결과

테스트1			테스트2	
d3	d2	d1	c	b
	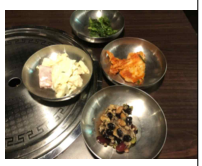	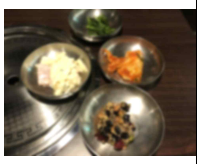		
5.1421	4.7601	4.2326	4.9390	3.8998

: 결과 비교

구분	입력 이미지	NIMA score	품질 결과 (좋음~나쁨)
테스트1	d3	5.1421	d3 > d2 > d1
	d2	4.7601	
	d1	4.2326	
테스트2	c	4.9390	c > b
	b	3.8998	

■ 품질 성능지표 체계화

▪ 도메인별 품질지표 요구사항 분류 및 체계화

✓ 데이터 품질지표 평가 모델의 일반적인 방법론 정의

✓ 신뢰성 분석 평가척도 정의(교통 도메인 예시)

평가항목	신뢰성	주체	주행시기
정확성 (Accuracy)	실제 현장에서 조사된 자료와의 부합성 - 검지자료의 시: %오차	현장	주기적
완전성 (Completeness)	교통량, 속도, 점유율, 차량길이 등 항목별 수집여부	센터	실시간

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

유효성 (Validity)	각 항목별 허용 요구수준을 만족하는 정도 - 유효 수집율 :필터링을 거쳐 남는 자료의 비율	센터	실시간
적시성 (TimeLiness)	해당 수집단위주기의 자료가 수집되는 비율	센터	실시간
접근성 (Accessibility)	일정시간 동안의 자료수집 비율 -검지기 가동률 : Online 비율	센터	실시간
포괄성 (Coverage)	시스템 설치범위 중 자료수집 범위의 비율	센터	실시간

- 데이터 유형별 품질지표 분류 및 정립 **(전체참여기관 공동 연구)**
  - ✓ 기관별 해당 도메인 데이터셋의 품질 질표 분류 및 정립 위한 분석 실시
  - ✓ 해당 데이터셋의 품질 지표 별 개발방안 연구
  - ✓ 데이터셋의 품질측정 및 개선 방안분석
- 데이터 품질지표에 대한 요구사항 조사 분석 **(전체참여기관 공동 연구)**
  - ✓ 기관별 해당 도메인 데이터셋의 품질 지표 요구사항 조사 및 분석 실시
  - ✓ 일반 및 인공지능형 자료에 따른 지표 분류 연구
  - ✓ 해당 데이터셋 별 품질지표 평가 모델링의 필요성 분석
  - ✓ 품질평가 기준 분석 및 정의(교통 도메인 예시)

구분	적용	지역적 상황	전국적 상황
속도의 정확성	교통관리 (Traffic Management)	5-10%	5-10%
	여행자 정보제공 (Traveler Information)	20%	20%
교통량의 정확성	교통관리 (Traffic Management)	10%	-
	여행자 정보제공 (Traveler Information)	-	-
적시성	모든 경우(ALL)	지체(Delay) < 1분	지체(Delay) < 5분
유용성	모든 경우(ALL)	99.9% (dir 10시간/1년)	99.9% (dir 10시간/1년)

■ 데이터셋 공정성 보정

- 공정성 보장을 위한 데이터셋 보정 모듈 구현
  - ✓ Data Compensation v1.0
    - 데이터 컬럼값의 편향이 확인/분석된 원본 데이터셋을 입력
    - 해당 속성별 편향을 보정(필터링)할 수 있는 수량의 레코드 값을 변수로 받음
    - 다수 속성에 대해 보정 목록 형식의 입력 기능
    - 보정 완료된 데이터셋의 local storage로의 다운로드
  - ✓ 논리설계에 따른 동작 시나리오

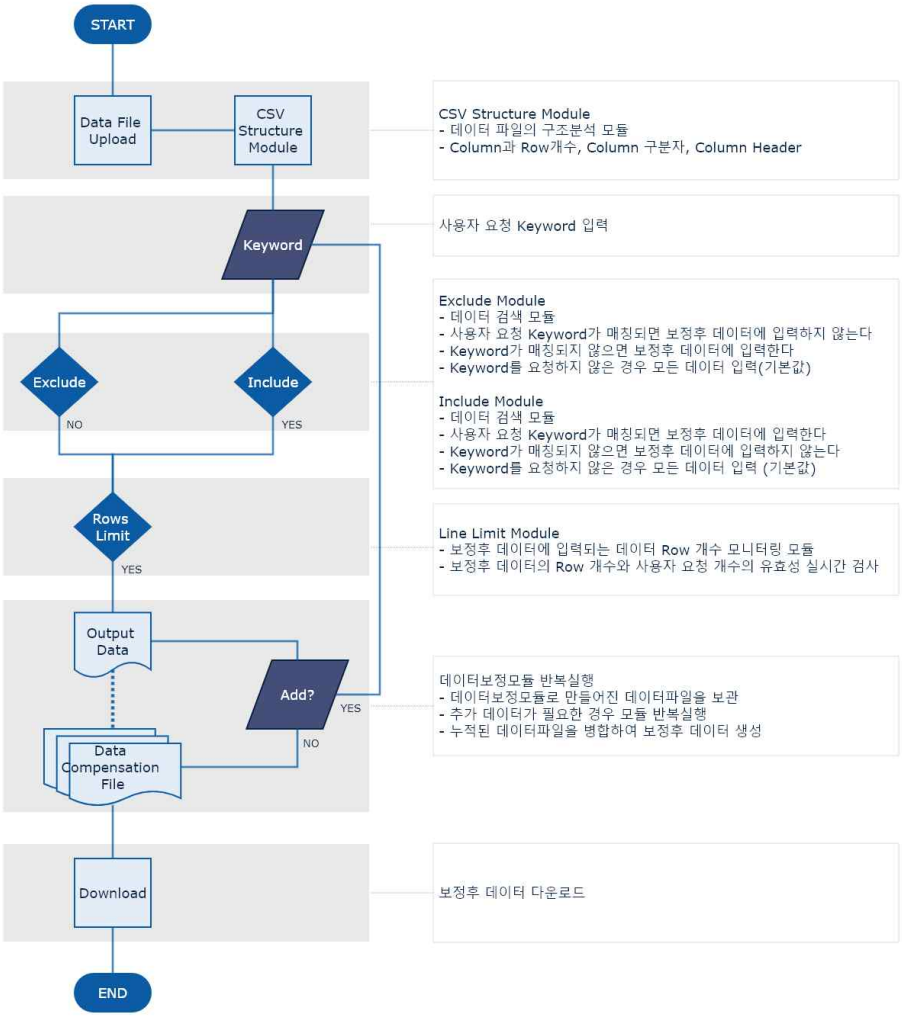

✓ 구현 화면 및 실행

시작화면	보정 필터링 조건	보정 목록	실행	저장
	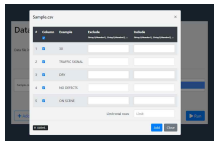	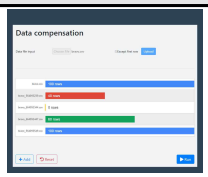	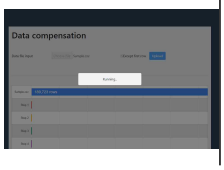	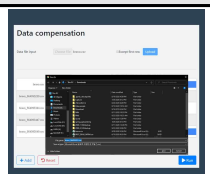

[서울대학교]

■ 보건데이터 및 AI 기반 품질지표 분석 및 평가

▪ 보건데이터 품질지표 분석

✓ 식이조사 데이터의 품질지표 개발 및 분석

✓ 유전체 데이터의 품질지표 분석

✓ 보건분야 품질관리를 위한 지표데이터

- 텍스트 기반과 정형데이터의 식이조사 자료 구축을 진행
- 텍스트 기반과 정형 및 비정형데이터의 유전체 자료 구축을 진행
- 구축된 자료의 품질을 관리할 수 있는 지표를 선정

■ AI 기반 비정형 데이터 품질지표 평가 모델링

▪ 식이 이미지 데이터의 품질 및 공정성 지표개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[표] 인공지능형자료 진단 방법 예시

품질지표	방법 설명
성편차	ㅇ 층간의 표본빈도 분포와 보정된 빈도를 비교 ㅇ 주요변수의 층간 분포 편차를 비교하고 종합적인 층간 변이지표를 확인 ㅇ 층간의 precision-recall과 true/false positive 곡선 사이의 gap을 평가
연령편차	
인구집단 편차	

- 보건분야 인공지능형 분석을 위한 모델링
  - ✓ 비정형 데이터 품질측정 및 개선방안 연구진행
  - ✓ 공정성 지표의 범주를 확인하고 구분하여 지표를 선정
    - 독립/통계 패리티 (Independence / Statistical Parity): $\hat{Y} \perp\!\!\!\perp S$: 데이터 편향 제거
    - 균등한 승률(Equalized Odds): $\hat{Y} \perp\!\!\!\perp S \mid Y$: 귀납 편향 제거

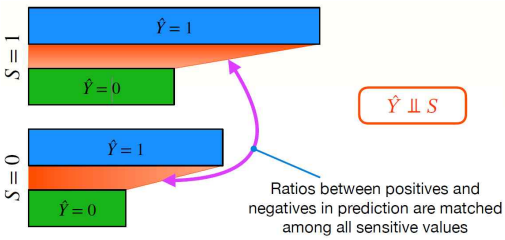

[그림23] 독립/통계 패리티

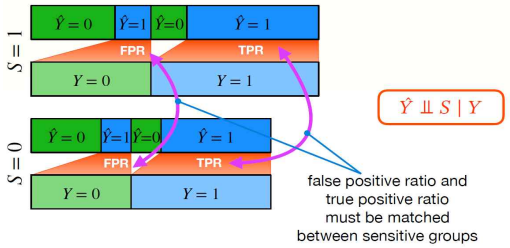

[그림24] 균등한 승률(Equalized Odds)

■ 품질지표 구축

- 데이터 품질지표 및 공정성 지표구축
- 품질의 수준을 측정하기 위한 지표선정
- 일반자료와 인공지능형 자료에 따른 지표분류

자료분류	지표	지표 정의
일반자료 품질지표	완전성	공공데이터의 저장소인 데이터베이스 구축에 있어 논리적인 설계와 물리적인 구조를 갖추고, 업무요건에 맞게 데이터가 저장되는지를 측정하는 지표
	일관성	같은 의미를 갖는 데이터는 논리적 속성 단위, 물리적 컬럼 단위에서 일관된 이름과 형식을 갖도록 표준을 준수하고 있는지, 공공 데이터의 공동 활용을 위해 공유·연계하는 데이터는 누락이 없이 상호간의 일관성을 유지하는지를 측정하는 지표
	정확성	정확한 데이터 제공을 위해 데이터의 입력 단계부터 오류가 입력되지 않도록 하고, 저장된 데이터가 정의된 기준에 맞게 유효한 값의 범위와 형식으로 되어있는지, 저장된 데이터가 현실에 가장 가까운 최신 값을 반영하고 있는지를 측정하는 지표
	보안성	지속적인 품질확보를 위해 운영되는 데이터의 관리 주체가 관리되고 있는지, 권한에 따른 데이터 접근이 적절히 통제되고 개인정보 등 중요 데이터에 대해서는 암호화 등 보안 조치가 이루어져 있는지를 측정하는 지표
인공지능형 자료 품질관리지표	성편차	남, 녀 간에 인식률의 차이를 가져올 수 있는 자료 편향존재 여부
	연령편차	특정연령 층에서 인식률 차이를 가져올 수 있는 편향존재 여부
	인구집단 편차	특정한 인구집단 및 민족, 인종에서 인식률의 차이를 가져올 수 있는 편향여부
	Feature 선별	원시자료에서 feature 추출한 전후 데이터의 존재 및 관리방식
	Feature 추출관리	정보력을 가진 feature의 추출, 원시자료와 적절한 결합여부

- 품질지표에 근거한 진단 방법 제시
- 이에 근거한 품질지표 평가 모델링 기술문서 작성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[서울시립대학교]

■ 자동화된 데이터 품질 분석 및 개선

▪ 문화관광데이터 품질 지표 분석

✓ 공공데이터 포탈에서 문화관광 분야 데이터 총 401개를 수집하였으며, csv 포맷 387개, xlsx 포맷 12개, pdf 포맷 1개, hwp 포맷 1개로서 테이블 형태의 데이터가 대부분을 차지함

✓ 수집한 문화관광 데이터의 특성을 파악해본 결과 결측값이 다수 존재하고, 비정형인 텍스트 도메인의 필드가 많은 것을 확인함

▪ 품질 지표 평가 방법 모델링

✓ 문화관광 데이터의 품질을 분석한 결과, 해당 데이터의 품질 측정 및 개선을 수행하기 위한 척도로서, 4개 품질 척도 (수치 데이터 결측률, 범주 데이터 결측률, 텍스트 오류율, 이상치 비율)를 정의하였음

- $\text{수치 데이터 결측률}(\%) = \frac{\text{수치형 데이터의 결측값 개수}}{\text{전체데이터 개수}} \times 100(\%)$
- $\text{범주 데이터 결측률}(\%) = \frac{\text{범주형 데이터의 결측값 개수}}{\text{전체 데이터 개수}} \times 100(\%)$
- $\text{텍스트 오류율}(\%) = \frac{\text{오류단어 개수}}{\text{전체단어 개수}} \times 100(\%)$
- $\text{이상치 비율}(\%) = \frac{\text{이상치 데이터 개수}}{\text{전체데이터 개수}} \times 100(\%)$

✓ 시험 데이터의 특성 분석을 통해 도출한 4개 데이터 품질척도에 대한 측정 및 개선 작업을 진행하였으며, 품질척도 별로 데이터 품질 향상을 위한 알고리즘의 연구 개발을 수행함

- 수치데이터 결측률, 범주데이터결측률, 이상치비율 척도 관련하여, 각 척도 기준의 품질 개선을 위해regression, classification, outlier detection 기술을 활용함
- 텍스트오류율 척도 관련하여, 해당 척도 기준의 품질 개선을 위해 자연어처리 기술을 활용함

[이화여자대학교]

■ 특징 공학 기반 오류 탐지 및 보정 기술

▪ 환경 데이터 품질 지표 분석

✓ 환경 분야 8종 데이터 수집(대기, 수질 등)

✓ 환경 분야 데이터 특성 분석

- IoT 장비로부터 수집한 센서 측정값 형태의 수치 데이터
- 시간별 주기적으로 측정된 시계열 데이터 형태 다수
- 증분 데이터 관리에 유리한 정형 데이터이며, 포맷은 CSV나 엑셀 자료 위주의 파일 데이터임

✓ 일반 데이터 품질 지표로부터 환경 분야 데이터 특성을 반영하고, 정량적 지표화가 가능한 환경 분야 품질 지표 도출

품질 지표	산출 방식	설 명
결측율	(미측정 데이터값 개수) / (전체 측정 데이터값 개수)	- 수치형 측정값 데이터 누락 비율, 빈컬럼값 혹은 NaN - 고품질 데이터를 위해서는 1% 미만 유지 필요

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

규칙 준수율	(규칙 준수 데이터값 개수) / (규칙 적용 가능 데이터값 개수)	- 컬럼 기준 적용가능한 규칙이 존재하는 경우, 해당 규칙에 위배되는 데이터값의 비율 - 고품질 데이터를 위해서는 0.2% 미만 유지 필요
코드 정규화 율	(코드화 컬럼 수) / (코드화 가능 전체 컬럼 수)	- 코드로 정규화된 컬럼의 비율 - 해당 컬럼에서 목격되는 구분가능한 값의 개수가 전체 인스턴스 값 개수의 1% 이하인 경우 코드화 가능으로 판단 - 고품질의 데이터를 위해서는 5% 미만 유지 필요

- 통계 기반 특징 변환 알고리즘 개발
  - ✓ 오픈소스인 featuretool 기반으로 특징 공학 단계별 상위 기능 설계
  - ✓ 전처리 단계에서 데이터 결측, 오류값 보정 수행
    - 수치형 데이터에 대한 결측치 보정 도구 개발
    - 서울시 상수도 시간별 수질 데이터에 대한 결측치 보정 약 70% 향상
  - ✓ 특징 추출 단계를 위한 40여종의 변환 및 취합(Aggregation) 통계 연산자 설계
    - 변환 연산자는 단일 Entity(테이블)내의 단위 변환이나 조건값 등의 특징 추출
    - 취합 연산자는 여러 Entity간의 관계로 부터 Group-by 결과 등의 특징 추출
- 머신러닝 기반 특징공학 알고리즘 개발
  - ✓ 자동화 특징 추출 알고리즘 설계
    - One-to-many 관계의 Entity들간의 계층구조 형성
    - 특징 연산자들 간의 Transitive 연산 지원
    - 정의된 Entity와 Relation 및 적용 가능한 특징 연산자로 부터 임의로 조합하여 파생된 특징들을 자동 추출
  - ✓ 특징 탐색 공간 최적화를 위한 평가지표 기반 탐색 기법 설계
    - 임의 조합에 따른 특징 공간(차원)의 급속한 팽창을 방지하기 위하여 특징에 대한 평가에 기반하여 최적의 특징들을 선택
    - 추출 특징과 기존 Entity의 속성들간의 상관성 분석, -0.3~0.3 사이의 경우 배제하는 방안
    - 오토인코더(Autoencoder) 인공신경망을 활용하여 차원축소를 통한 특징 대표성을 평가지표로 활용
  - ✓ 기계 학습 모델 자동 평가를 통한 특징 랭킹 모델 설계
    - 기계 학습 모델이 제시된 경우, 추출된 특징들을 효과적으로 선택하기 위한 방안으로 특징을 활용하고자 하는 학습 모델에 직접 적용하여 특징의 우선순위를 결정
    - 추출 특징 집합으로 부터 최대 N개까지의 특징을 임의 선택하여 주어진 기계 학습 모델의 입력을 확장하여 정확도 산출
    - 학습 정확도에 따라 추출 특징들의 우선순위 선정

[한성대학교]

■ 재난안전 데이터 품질지표분석

- **(재난데이터 조사/수집)** 재난안전 도메인은 빅데이터 플랫폼에서 2020년에 화재 플랫폼을 신규구축 중이라 확보가 불가능한 상황임. 따라서 1차년도에서는 공공데이터포털에서 확보가능한 데이터 중에서 타 도메인과 중복되지 않은 화재와 감염병 위주로 데이터 수집
- **(재난데이터 품질분석)** 화재 데이터 25종, 감염병 데이터 16종에 대한 수집을 완료하였으며, 이들 데이터에 대한 품질분석을 수행 (참조: 재난안전 데이터 품질평가 보고서)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

조사 데이터명	레코드 수	필드 수	품질 평가 요약
소방청_화재인명피해 지역별 성별인원 현황	17	24	다량의 결측치, 성별 등 표준화 코드 미비
광주광역시 소방항공대 헬기 출동현황	85	7	데이터 형식의 비일관성 및 오류 기입 다량의 결측치
광주광역시_광산구_소방서 활동실적(화재)	294	6	다량의 결측치
광주광역시 동구 화재발생 현황	5	4	파편화된 지역정보로 인한 완성성 결여
총화재대비 전기화재현황	18	13	일부시기만 공개(완성성 결여), 단순 통계자료
산업통상자원부_해외전기화재 통계	12	18	샘플 데이터 수준, 다량의 결측치, 단순 통계자료
지역별전기화재현황	6	3	단순 통계자료
서울시 화재 출동현황	11495	8	일부시기만 공개(완전성 결여)
울산광역시_년화재발생현황분석	5	17	일부지역만 공개(완전성 결여)
울산광역시_년화재활동통계	12	7	일부지역만 공개(완전성 결여)

[그림 25] 재난데이터 품질분석 요약 보고서(일부)

■ 데이터 프로파일링 분류 및 관리체계 설계

▪ 데이터 프로파일러 관리체계 절차

[그림 26] 데이터 프로파일 관리체계 구축을 위한 프로세스

▪ **(메타데이터 표준현황조사)** 국제표준 중심의 메타 데이터 현황을 조사하고, 데이터 품질 및 공정성 관련 명세에 활용가능한 항목조사(참조: 메타데이터 표준 분석보고서)

: (DCAT v2) 여러 사이트 간에 데이터를 통합 검색하고 상호운용을 지원하는 가장 잘 알려진 국제 표준으로 W3C의 Data Exchange WG에서 표준화가 진행중

※ DCAT v2는 DataSet이나 DataService(API 등)에 대한 기본 정보(상품명, 소유권, 업데이터 주기 등)는 물론 품질, 유통 등 다양한 정보를 서술하고 공유 가능

: (schema.org) 데이터에 대한 메타데이터를 서술하기 위해 필요한 다양한 어휘사전을 제공 중

※ 구글, MS, 야후 등에서 영화, 이미지 등 웹 컨텐츠에 대한 정보를 서술하기 위해 만든 표준 그룹으로 최근 데이터셋에 대한 메타데이터 서술을 위한 어휘도 제공

▪ **(프로파일링 S/W 기술분석)** 대표적인 오픈소스 데이터 프로파일링 S/W를 조사하고 본 연구에 활용가치가 있는 프로파일링 S/W를 검토 (참조: 데이터 프로파일링 기술분석 보고서)

[표] 오픈소스 프로파일링 S/W 비교 결과 요약

	Talend for DQ	Aggregate Profiler	Quadient DataCleaner
장점	▪ 사용 편리성 ▪ 다양한 분석 결과 지원	▪ 고급 분석 및 변환 기능 지원 ▪ 분석 결과를 다양한 형	▪ Job을 XML로 표현하여 편집가능 ▪ Console 및 자바 API 기

		태로 export 가능	능 지원으로 타 application과의 연동
단점	▪ API, export 등 자동화 기능 미지원 ▪ 제한적인 자동 type 인식 기능	▪ Talend와 같이 개별 파일 또는 DB에 대한 수동적인 프로파일링만 가능	▪ CSV 파일의 자동 타입 인식 기능 미흡
시사점	▪ 개별 파일에 대한 수동적인 프로파일링만 가능하므로 타 시스템과의 자동 연계 및 통합은 불가능	▪ 수동적인 export기능을 제외하고는 타시스템과의 자동 연계 및 통합이 현재로서는 불가능	▪ 타시스템과의 연동이 가능하며, JAVA API를 통한 연동도 지원됨 ▪ Kaggle에서 제공되는 수준의 프로파일링 기능 적용 가능

- **(프로파일링 항목 정의)** 품질개선 및 공정성 확보를 지원하기 위한 데이터 프로파일링 항목 정의. 데이터셋 및 필드수준의 프로파일링 항목으로 분리하여 정의하였으며, 차년도 연구결과에 따라 각 세부연구분야에서 요구되는 프로파일링 항목들을 추가적으로 정의하여 확정 예정 (참조: 데이터 프로파일링 기술분석 보고서)
- **(프로파일 저장 및 관리구조 설계)** 데이터 프로파일링 결과를 저장하기 위한 데이터 구조설계를 진행하였으며, 프로파일링 정보관리 및 서비스를 위한 아키텍처 설계를 완료 (참조: 프로파일링 관리체계 설계 결과보고서)

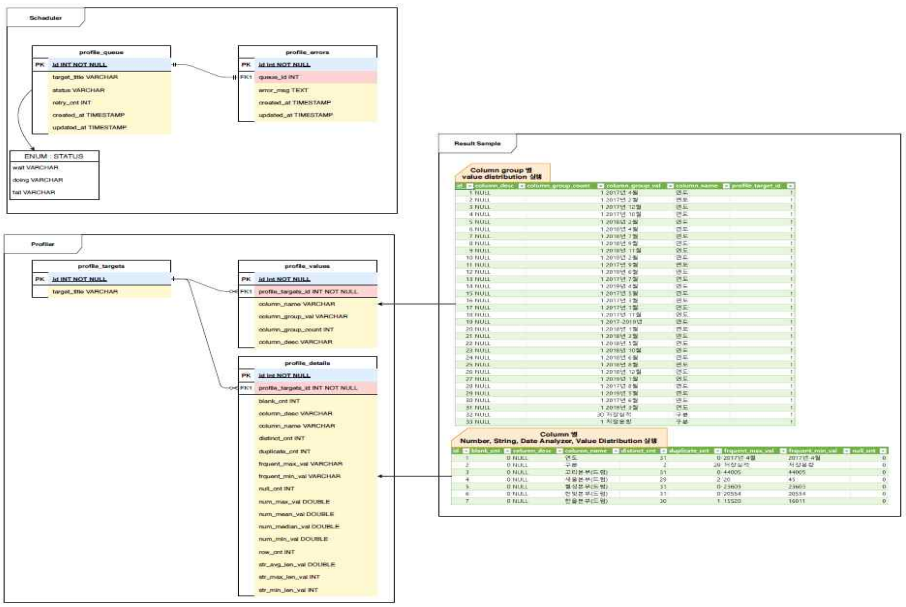

[그림27] 데이터 프로파일링 저장구조

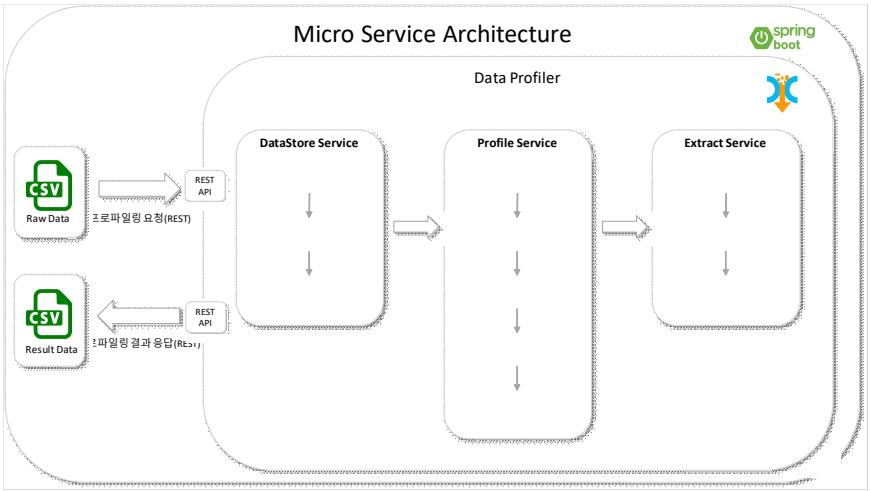

[그림28] 서비스 아키텍처

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[프람트테크놀로지]

■ 피드백 지원 품질 평가 모델 설계

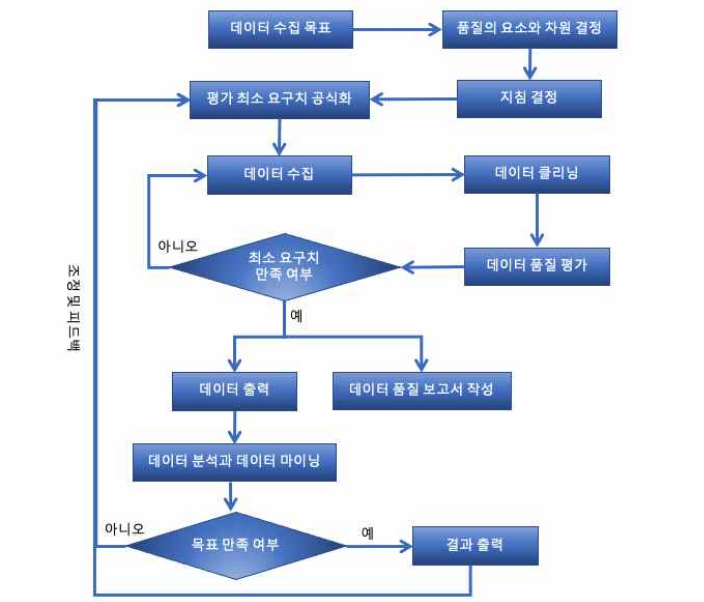

- 데이터 품질평가 프로세스 설계
  - ✓ 최소기준 만족 여부를 확인하고, 최소 기준이 만족된다면 데이터를 활용하여 분석 등의 추가적인 작업을 실시하고 만족하지 못하는 결과를 얻을 경우 조정 및 피드백 단계를 거쳐 최소기준 설정 단계부터 동일한 작업을 재수행하는 프로세스를 정립하고 이를 기반으로 시스템을 설계
  - ✓ 데이터 수집 후에 최초 품질개선 및 평가를 수행하여 사전에 설정한 최소기준을 만족하지 못할 경우, 데이터 개선이나 수정, 보완 추가적인 데이터 수집을 통하여 최소기준을 만족할 때까지 품질 평가 및 보완 등을 반복하는 Closed-loop 기법으로 프로세스 운영이 가능한 형태
  - ✓ 품질 평가 프로세스에서 최종 목표 만족 여부는 품질 평가 대상 데이터셋의 종류나 분야 등의 특성에 따라 다를 수 있으며 이는 여타 세부과제의 결과물을 취합하여 반영해야 하므로, 이번년도 연구개발 수행 내용에서는 포함하지 않음
- 피드백을 지원하는 품질평가 모델 설계
  - ✓ 공동연구기관에 의해 정의된 도메인별 품질평가 지표를 통합하여 수집된 데이터에 대해 품질평가 지표 및 최소 기준을 정의하고 관리하는 기능 구현을 위한 설계
  - ✓ 아래는 원천 데이터에서부터 적재된 데이터 품질 분석 및 개선 작업에 필요한 데이터 흐름도임

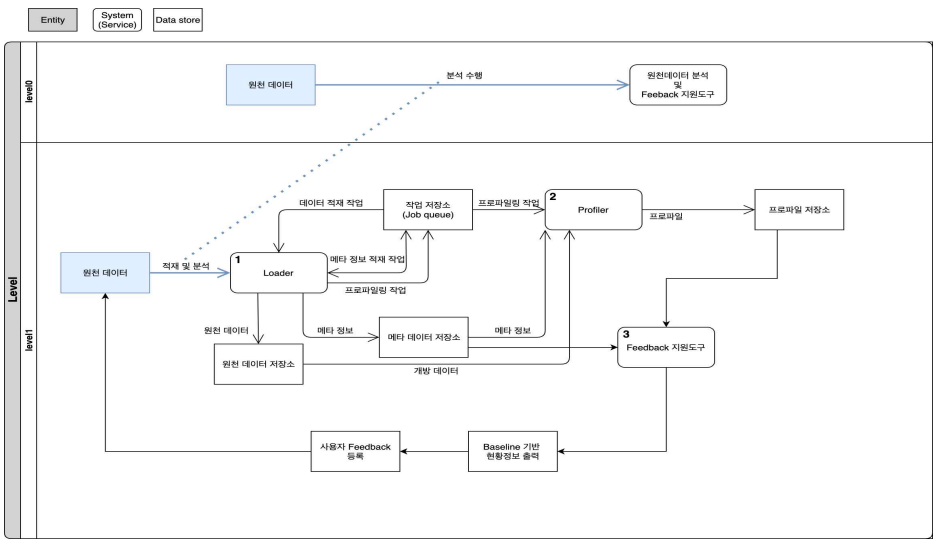

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 품질평가 프로세스 모델의 시퀀스 다이어그램
  - ✓ 아래는 데이터 품질 파악의 기초라 할 수 있는 데이터 프로파일링 결과 생성을 위한 시퀀스 다이어그램 및 품질 평가 대상인 데이터셋의 메타데이터를 자동 추출하고 이를 저장하는 기능에 대한 시퀀스 다이어그램임

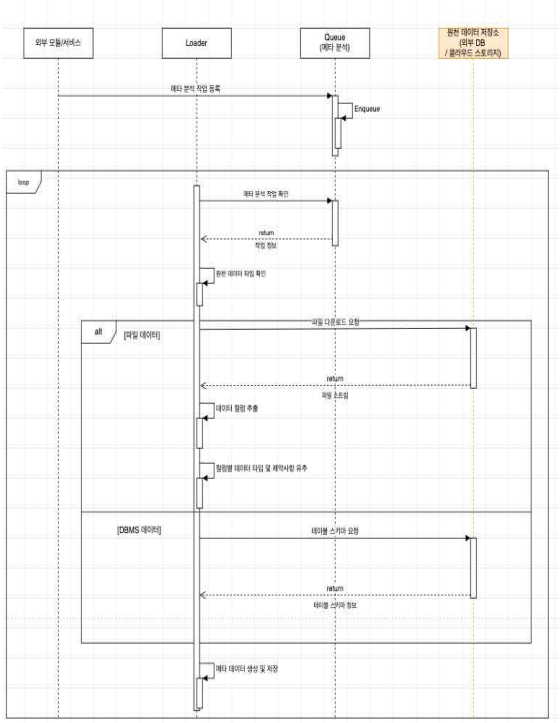

[그림29] 데이터 프로파일러 시퀀스 다이어그램

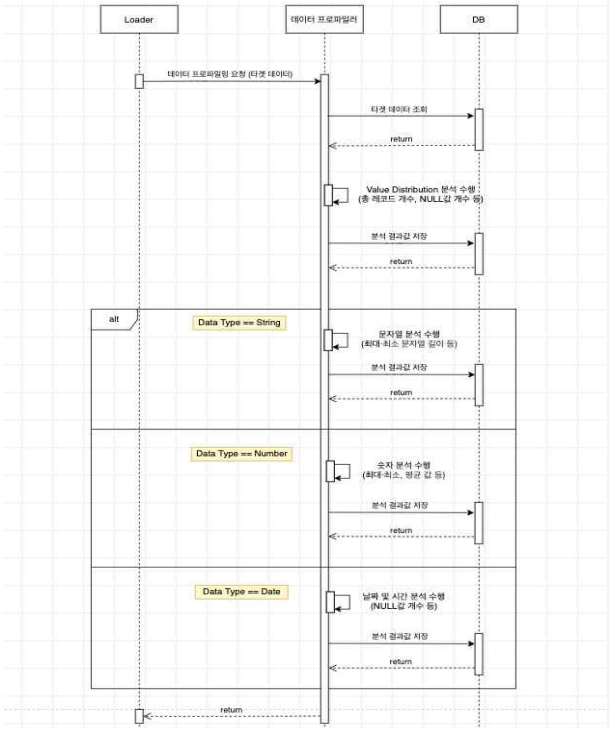

[그림30] 메타데이터 추출 및 저장 시퀀스 다이어그램

  - ✓ 데이터 프로파일러는 타겟 데이터에 대하여 먼저 Value Distribution을 수행하여 총 레코드 개수, Null 값의 개수 등을 분석하여 데이터베이스에 저장함
  - ✓ 기타 문자열 분석, 숫자 분석, 날짜 및 시간 분석 등 데이터 타입별로 추가 분석을 수행하여 타겟 데이터에 대한 프로파일링을 수행하고 이의 결과를 데이터베이스에 저장하고 사용자에게 제공함으로써 필요시 추가적인 개선 작업등을 위한 피드백을 요청하도록 함
- 데이터 프로파일러에 대한 인터페이스 명세
  - ✓ 데이터 프로파일러는 전체 피드백 지원 품질 평가 도구의 주요 기능 중의 하나로 기타 추가적인 품질지표 분석 및 확인, 비교 등을 수행하는 모듈들이 설계·구현되면 이들을 gRPC*를 통한 loosely-coupled 방식으로 통합하여 차년도 결과물로써 오픈소스로 개방할 예정임

  [* gRPC : gRPC는 구글이 최초로 개발한 오픈 소스 원격 프로시저 호출 시스템으로, 전송을 위해 HTTP/2를, 인터페이스 정의 언어로 프로토콜 버퍼를 사용하며 인증, 양방향 스트리밍 및 흐름 제어, 차단 및 비차단 바인딩, 취소 및 타임아웃 등의 기능을 제공함]
  - ✓ 아래 <표>의 좌측은 Application 정보를 보여주기 위하여 Application 목록을 제공하는 원격 프로시져 호출, 네임스페이스 검색과 페이지네이션 기능을 제공하는 gRPC의 IDL**임

  [** IDL(Interface Description Language) : 인터페이스 정의 언어는 소프트웨어 컴포넌트의 인터페이스를 묘사하기 위한 명세언어]
  - ✓ 아래 <표>의 우측은 API 호출을 위한 서비스로, API 응답을 위한 데이터 요청 원격 프로시져를 호출하는 gRPC의 IDL임

[표] gRPC IDL 정의: designer_application 및 executor_api_result

```
syntax = "proto3";

option go_package = "proto/designer;grpc_designer";

package designer;

service ApplicationService {
    rpc ListApplication (ListApplicationRequest) returns (ApplicationList) {}
}

message Application {
  int32 id = 1;
  string name_space = 2;
  string title = 3;
  string description = 4;
  string status = 5;
  int32 user_id = 6;
  string created_at = 7;
  string updated_at = 8;
}

message ApplicationList {
  int32 total_count = 1;
  int32 page = 2;
  int32 per_page = 3;
  repeated Application applications = 4;
}

message ListApplicationRequest {
  int32 per_page = 1;
  int32 page = 2;
  string name_space = 3;
}
```

```
syntax = "proto3";

option go_package = "proto/executor;grpc_executor";

package executor;


service ApiResultService {
  rpc getApiResult (ApiRequest) returns (ApiResult) {}
}


message ApiResult {
  int32 page = 1;
  int32 perPage = 2;
  int32 currentCount = 3;
  int32 matchCount = 4;
  int32 totalCount = 5;
  repeated string data = 6;
}

message ApiRequest {
  int32 stageId = 1;
  int32 serviceId = 2;
  int32 page = 3;
  int32 perPage = 4;
  map<string, string> cond = 5;
}
```

■ 피드백 지원 품질 평가 도구 개발

▪ 품질평가 결과를 시각화하여 사용자에게 제공하는 기능 구현

✓ 사용자는 데이터 프로파일링 수행 및 결과를 조회할 수 있고, 프로파일링 결과에 대한 피드백을 작성할 수 있음

✓ 데이터 프로파일링 결과를 확인하여 결과값이 최소 기준을 충족하지 못하는 경우, 출력 화면에 색을 다르게 표현하여 사용자가 해당 결과를 직관적으로 확인할 수 있도록 함 (예 : null값의 개수가 특정 기준을 초과하면 빨간색으로 표시)

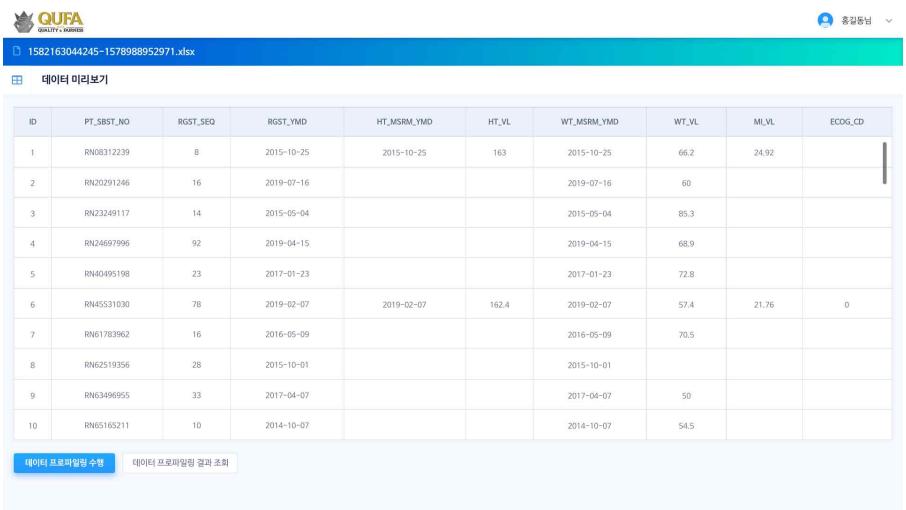

[그림 31] 데이터 프로파일링 결과 조회 사용자 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그림 32] 프로파일링 결과 피드백 작성 화면

✓ 최소 기준을 만족하지 못한 결과에 대해서는 사용자가 작성한 피드백을 분석한 뒤, 분석결과에 따라 품질 평가 기준을 수정하고 프로파일링 및 품질 평가를 재수행할 수 있도록 함

[아이소프트]

■ 데이터 품질 수준 및 척도

- 5종 데이터 도메인별, 데이터 품질 수준 현황 조사 분석
- 교통 도메인의 공공/민간 데이터의 활용 방안 또는 사례 분석
- 보건 도메인의 개방/연계현황 및 품질 수준/척도 분석
- 화재, 감염병 등의 재난 도메인 데이터의 분석
- 기후부터 폐기물에 이르기까지, 환경 도메인 데이터의 분석
- 문화관광 도메인 데이의 제공현황 분석

■ 빅데이터 품질 진단 프로젝트의 운영

- 도메인별 데이터셋의 제고 및 정보화 시스템 분석

■ 도메인별 데이터 공정성 품질지표 기반의 분석기 설계

- 교통 데이터셋을 대표로 하여 공정성 확보를 위한 데이터 분석기 설계
- 데이터셋(csv) 로딩에 따른 컬럼 분석 기능
- 분석 된 데이터셋의 가시화 기능 구현

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

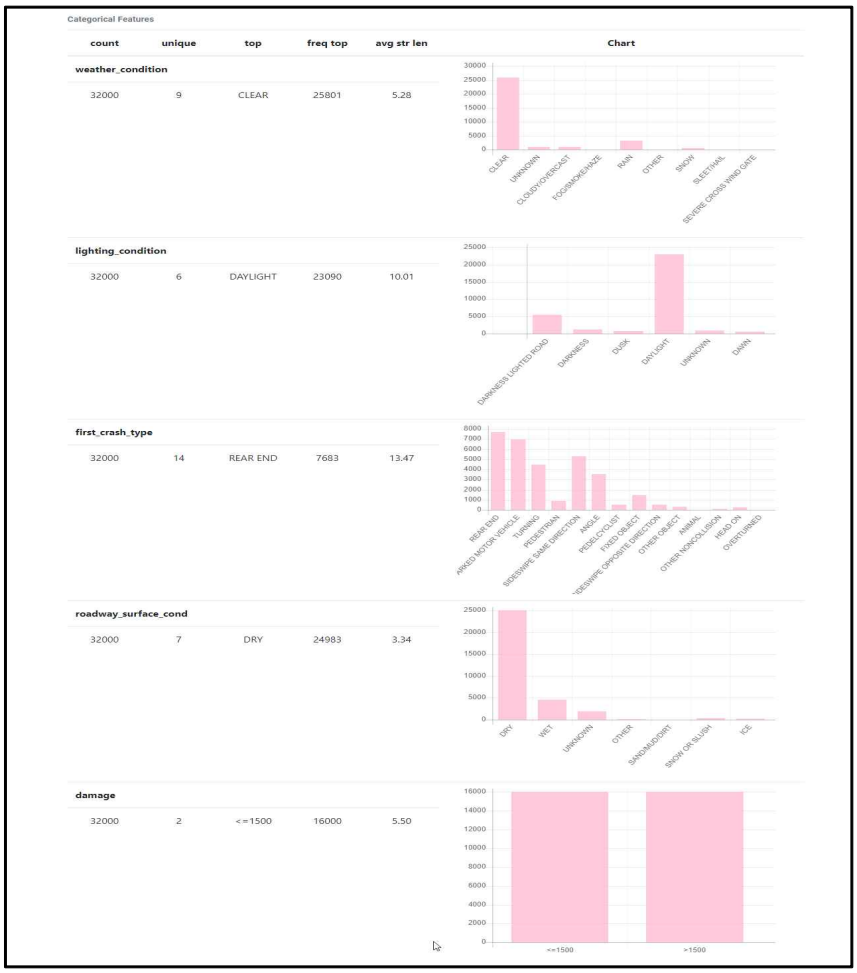

[그림 33] 데이터셋 분석 및 데이터 가시화

■ ROC curve 등을 활용한 패턴 시각화 도구 설계

- 분석 된 데이터의 컬럼 기반으로 패턴 시각화 도구 설계
- 데이터의 패턴 시각화 기능 구현

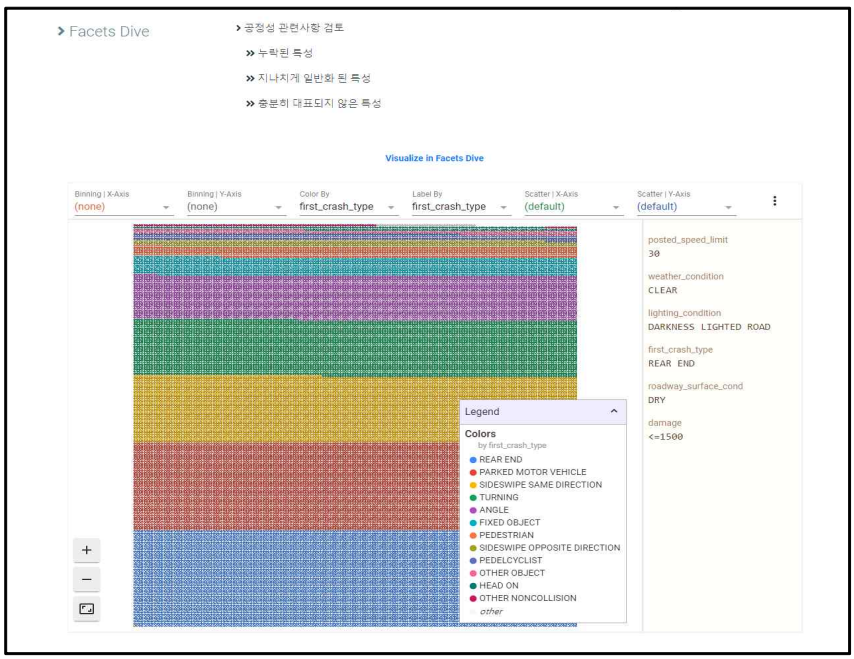

[그림 34] 데이터 패턴 시각화 도구 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 데이터의 패턴 시각화 도구의 flow chart

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(4) 1단계 2차년도 - 원천기술의 고도화 개발 및 통합

[그림 35] 1단계 2차년도 기관별 연구개발 내용 및 산출물

가) 1단계 2차년도 기관별 개발 목표

수행기관	개발목표
주관기관 (부산대학교)	▪ 데이터셋 구성 요소 분석 ▪ 데이터셋 공성정 보정 고도화 ▪ 배치 기반 데이터 셋 공정성 보정 기술
공동연구기관 1 (서울대학교)	▪ 공정성 지표 분석 및 정의 ▪ 데이터 패턴 시각화
공동연구기관 2 (서울시립대학교)	▪ 데이터 품질 개선 자동화 기반 설계 ▪ 정형 데이터 품질 개선 알고리즘 개발
공동연구기관 3 (이화여자대학교)	▪ 특징 공학(feature engineering) 연산자 고도화 ▪ 오류 탐지 및 보정 기술 개발
공동연구기관 4 (한성대학교)	▪ 메타데이터 수집 기술 개발 ▪ 메타데이터 변환 및 편집, 저장 기술 개발
공동연구기관 5 / 수요기업 (아이소프트)	▪ 공정성 분석기 도구 개발 ▪ 데이터 패턴 시각화 도구 개발 ▪ 공정성 도구 통합
공동연구기관 6 / 수요기업 (프람트테크놀로지)	▪ 데이터 품질 분석 도구 제품화 ▪ 데이터 오류 보정 도구 설계 및 개발 ▪ 데이터 품질 개선 솔루션 통합

나) 1단계 2차년도 연구개발 세부 내용

[부산대학교]

■ 데이터셋 구성 요소 중 공정성에 영향을 주는 요소 파악

▪ **(공정성 구성 요소 분석)** 데이터 공정성에 영향을 주는 요소 파악

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	정의
타겟변수	의사 결정의 목표 또는 예측 대상이 되는 변수
민감특징	사회적으로 민감한 정보 또는 타겟 변수 (성별, 인종) 타겟에서 민감 변수에 대한 영향을 줄이기 위한 목적
비 민감 특징	민감한 특징 이외의 모든 특징 벡터

- **(공정성 지표 분석)** 데이터 공정성 지표 분석
  - ✓ 인구 통계적 패리티 (Demographic Parity)
    - 공정성을 위한 가장 잘 알려진 기준 중 하나, 두 그룹의 지원자들의 합격률이 같아야 함을 의미함

표기	의미
$P_0[C=c] = P_1[C=c] \ \forall \ c \in \{0, 1\}$	▪ 이진 예측 결과가 주요 이진 속성으로부터 독립적이어야 함

  - ✓ 균등확률 (Equalized odds)
    - 보호된 그룹과 보호되지 않은 그룹은 참 긍정(True Positive)과 오탐지(False Negative)에 대해 동일한 비율을 가져야 한다는 것을 의미함

표기	의미
$P_0[C=r\|Y=y] = P_1[C=r\|Y=y] \forall r,y$ $:= P_0[C \neq Y] = P_1[C \neq Y]$	▪ 대상 변수가 주어진 주요 이진 속성에 대한 이진 예측 결과는 독립적이어야 함

    -

  - ✓ 예측 비율 동등성 (Predictive Rate Parity)
    - 후보자에 대한 예측 알고리즘(후보자의 직무 적격 여부를 결정하는 데 사용)에서 반환된 점수가 후보자의 실제 업무 능력을 반영함을 의미

표기	의미
$P_0[Y=y\|C=c] = P_1[Y=y\|C=C]$ $\forall \ y, \ c \in \{0, 1\}$	▪ 이진 예측 결과가 주어진 주요 이진 속성에 대해 대상 변수가 독립적이어야 함

  - ✓ 개별 공정성 (Individual Fairness)
    - 개별 공정성은 그룹 기반과 달리 개인 기반으로 유사한 독립은 유사하게 다루어야 한다는 것을 의미함

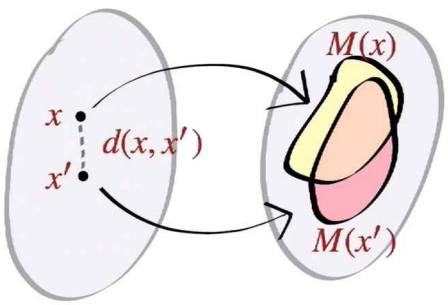

  - ✓ 반사실적 공정성 (Counterfactual Fairness)
    - 일부 구조 방정식을 통해 인과 그래프를 "다운스트림"으로 전파하여 반사실 값은 중요한 속성의 원래 값을 대체함을 의미

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

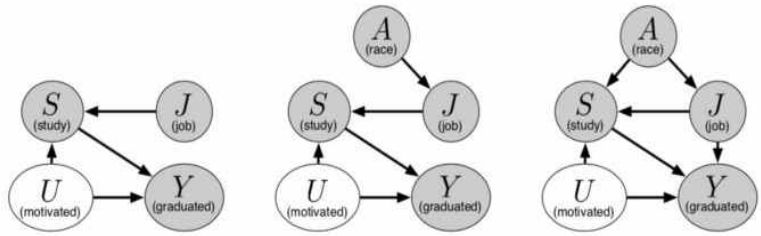

■ 데이터 셋에서 나타날 수 있는 편향에 대한 분석 파악

▪ 데이터셋 내의 편향의 종류 분석 및 정의

✓ 편향의 종류 정의

구분	정의
역사적 편향 (Historical bias)	이미 존재하는 편향
대표 편향 (Representation bias)	모집단을 정의하고 표본을 추출하는 방식에서 발생하는 편향
측정 편향 (Measurement bias)	특정한 특색을 선택, 활용, 측정하는 방식에서 발생하는 편향
평가 편향 (Evaluation Bias)	모델을 평가할 때 발생하는 편향
취합(집합) 편향 (Aggregation Bias)	하위 그룹에 잘못된 결과를 넣게 되거나 일반적으로 모집단이 모델의 출력과 정의에 영향을 미치는 것에 대해 잘못된 가정을 할 때 발생하는 편향
모집단(인구) 편향 (Population Bias)	통계, 인구통계, 대표, 사용자 특성이 원래 목표 모집단의 데이터 집합 또는 플랫폼에서 표현된 사용자 모집단과 다를 때 발생하는 편향
표본 편향 (Sampling Bias)	하위 그룹들의 랜덤하지 않은 표본 추출에 의해 발생하는 편향
행동적 편향 (Behavioral Bias)	사용자의 행동이 플랫폼, 상황들 또는 다른 데이터 집합들에 따라 다를 때 발생하는 편향
콘텐츠 제작 편향 (Content Production Bias)	사용자들로부터 생산된 콘텐츠에서 구조적, 용어적, 의미적, 통어적 차이로 인해 발생하는 편향
연결 편향 (Linking Bias)	사용자의 연결, 활동, 상호작용에서 얻은 네트워크 속성이 다르고 사용자의 실제 행동을 잘못 나타낼 때 발생하는 편향
시간적 편향 (Temporal Bias)	모집단과 행동의 차이가 시간이 지남에 따라 발생하는 편향
인기 편향 (Popularity Bias)	인기가 더 많은 아이템이 더 노출되는 경향
알고리즘적 편향 (Algorithmic Bias)	입력 데이터에서 편향이 표현되지 않거나 순전히 알고리즘을 통해 편향이 추가될 때 발생하는 편향
사용자 상호작용 편향 (User Interaction Bias)	웹에서 관찰할 수 있을 뿐만 아니라 사용자 인터페이스와 스스로 선택한 편향된 행동과 상호작용에 의해 발생할 수 있는 편향
사회적 편향 (Social Bias)	다른 사람들의 행동이나 콘텐츠가 우리의 판단에 영향을 미칠 때 발생하는 편향
우발적 편향 (Emergent Bias)	실제 사용자들의 사용, 상호작용으로 인해 발생하는 편향
자가 선택 편향 (Self-Selection Bias)	연구자 스스로 선택한 선택 또는 표본 편향의 하위 형태
누락 변수 편향 (Omitted Variable Bias)	하나 이상의 중요한 변수들이 모델에서 제외될 때 발생하는 편향
인과 편향 (Cause-Effect Bias)	상관관계가 인과관계를 암시한다는 오류의 결과로 인해 발생하는 편향
관찰자 편향 (Observer Bias)	연구자들이 연구에 대한 자신들의 기대를 무의식적으로 투영할 때 발생하는 편향

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

재원 편향 (Funding Bias)	연구의 재정적 지원자나 재원 기관이 만족하는 편향된 결과를 보고하고자 할 때 발생하는 편향

- 데이터셋 내의 차별의 종류 분석 및 정의
  - ✓ 차별의 종류 정의

구분	정의
직접 차별 (Direct Discrimination)	개인의 보호된 속성들이 그들에게 좋지 않은 결과를 불러오는 것
간접 차별 (Indirect Discrimination)	보호된 그룹이나 개인이 보호된 속성들로부터 암시되는 영향으로 부당하게 대우받는 것
조직적 차별 (Systemic Discrimination)	모집단의 확실한 하위 그룹들에 대한 차별을 영구히 지속할 수 있는 조직 문화나 구조의 일부인 정책, 관습 행동
통계적 차별 (Statistical Discrimination)	의사 결정자들이 그룹의 평균 통계로 그룹에 속한 개인을 판단하는 것
설명 가능한 차별 (Explainable Discrimination)	경우에 따라 그룹들 간의 대우와 결과의 차이는 일부 속성들을 통해 설명 가능
설명 불가한 차별 (Unexplainable Discrimination)	한 그룹만을 향하는 차별은 정당하지 않기 때문에 불법으로 간주되고 설명 불가한 차별

■ 데이터셋의 편향성 제거에 따른 공정성 보정 고도화

- 데이터셋의 편향 확인 및 검증
  - ✓ 서브 그룹간의 TPR 차이를 입력으로 사용하며 서브 그룹 편향 검증
    - 논리 설계에 따른 동작 시나리오

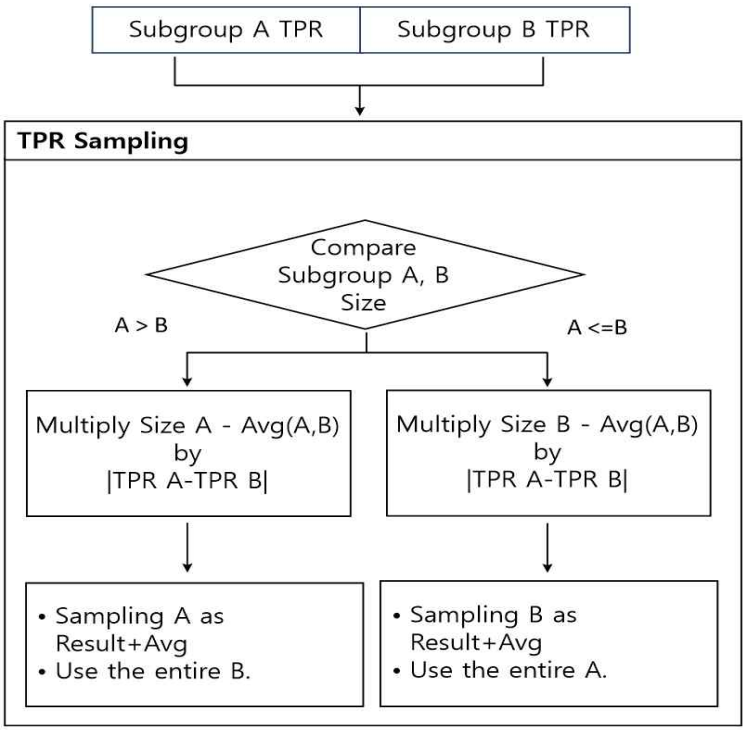

  - ✓ 각 상위 서브셋의 원본과 결과 간의 비율을 기준으로 편향 검증
    - 논리 설계에 따른 동작 시나리오

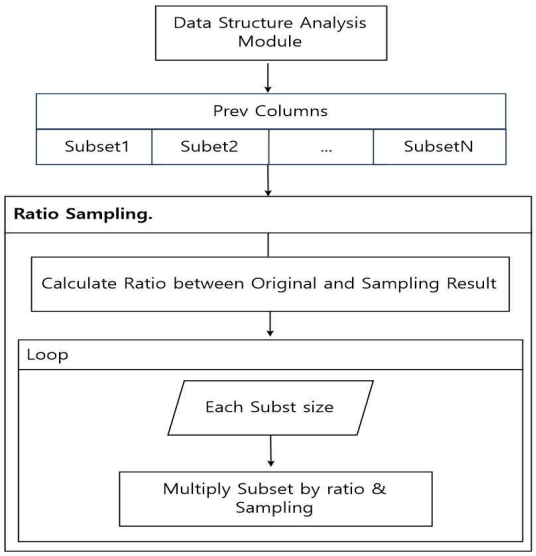

- 편향 제거를 위한 공정성 보정기 고도화 설계 및 구현
  - ✓ 데이터셋의 편향 검증 및 보정
    - 데이터셋의 편향 검증 및 보정
    - 업로더 모듈을 통해 데이터 세트의 민감한 속성의 값(이진)을 기준으로 서브 그룹 A, 서브 그룹 B로 나눔
    - 각 서브 그룹의 TPR(참긍정 비율)의 차이 값 도출 및 추출
    - Data Structure Analysis Module을 통해 각 서브 그룹의 서브셋 도출
    - Ration value Sampling 및 Average value Sampling을 통해 2차 샘플링
    - 샘플링이 끝난 서브셋들은 Dataset Associates Module을 통해 Fair Dataset으로 통합
    - 논리 설계에 따른 동작 시나리오

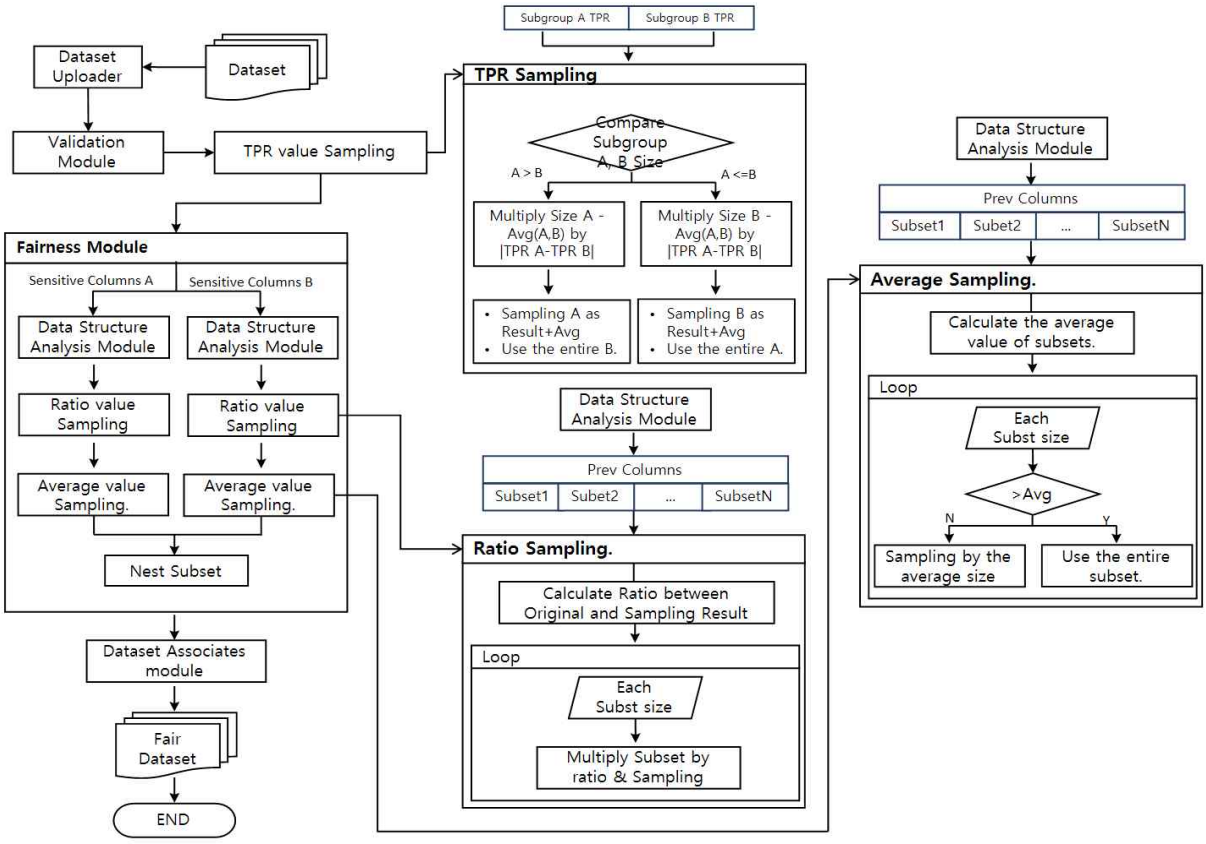

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 데이터 보정을 통한 공정성 보정 기술 접근 개념

▪ 배치 데이터셋의 편향 확인 및 검증

✓ 데이터 셋의 각 서브그룹 내의 서브셋 간의 편향 확인

• 논리 설계에 따른 동작 시나리오

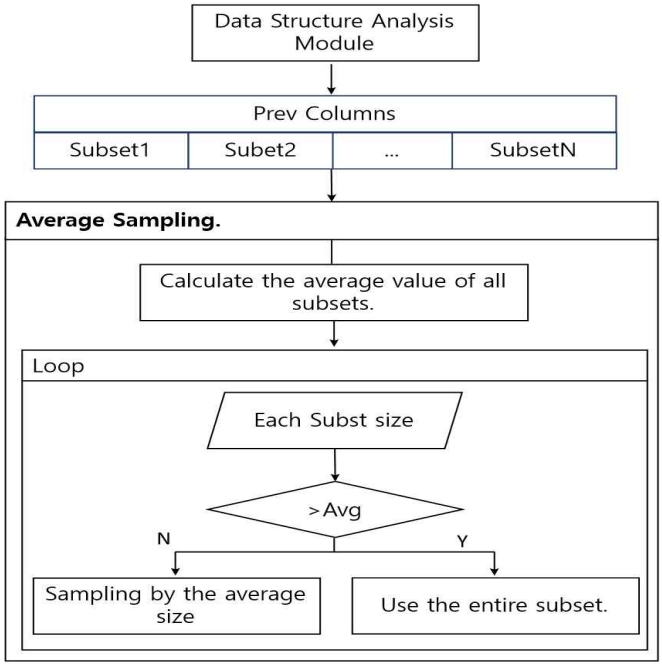

✓ 데이터 셋의 각 서브그룹 내의 서브셋 간의 편향 확인

• 논리 설계에 따른 동작 시나리오

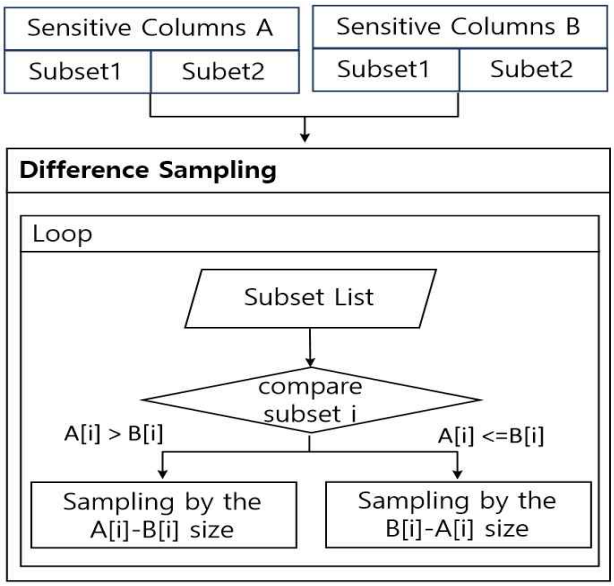

▪ 배치 데이터셋의 편향 제거를 위한 공정성 보정기 설계 및 구현

✓ 배치 데이터셋의 편향 검증 및 보정

• 배치 데이터셋의 편향 검증 및 보정

- 업로더 모듈을 통해 배치기반 데이터 세트를 수집
- 데이터 구조 분석 모듈을 통해 민감한 속성의 값(이진)을 기준으로 서브 그룹 A, 서브 그룹 B로 분할
- 각 서브그룹 내의 서브셋의 평균값을 기준으로 샘플링
- 차이 샘플링을 통해 각 서브그룹 간의 서브셋 차이만큼 샘플링

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 최소 샘플링을 통해 샘플링 후 남은 데이터셋에서 서브셋의 최소 크기만큼 샘플링
- 샘플링이 끝난 서브셋들은 Dataset Associates Module을 통해 Fair Dataset으로 통합
- 공정성 보정 후 남은 서브셋들은 Dataset Associates Module 통해 Reamin Dataset으로 통합 후 다음 배치와 병합

• 논리설계에 따른 동작 시나리오

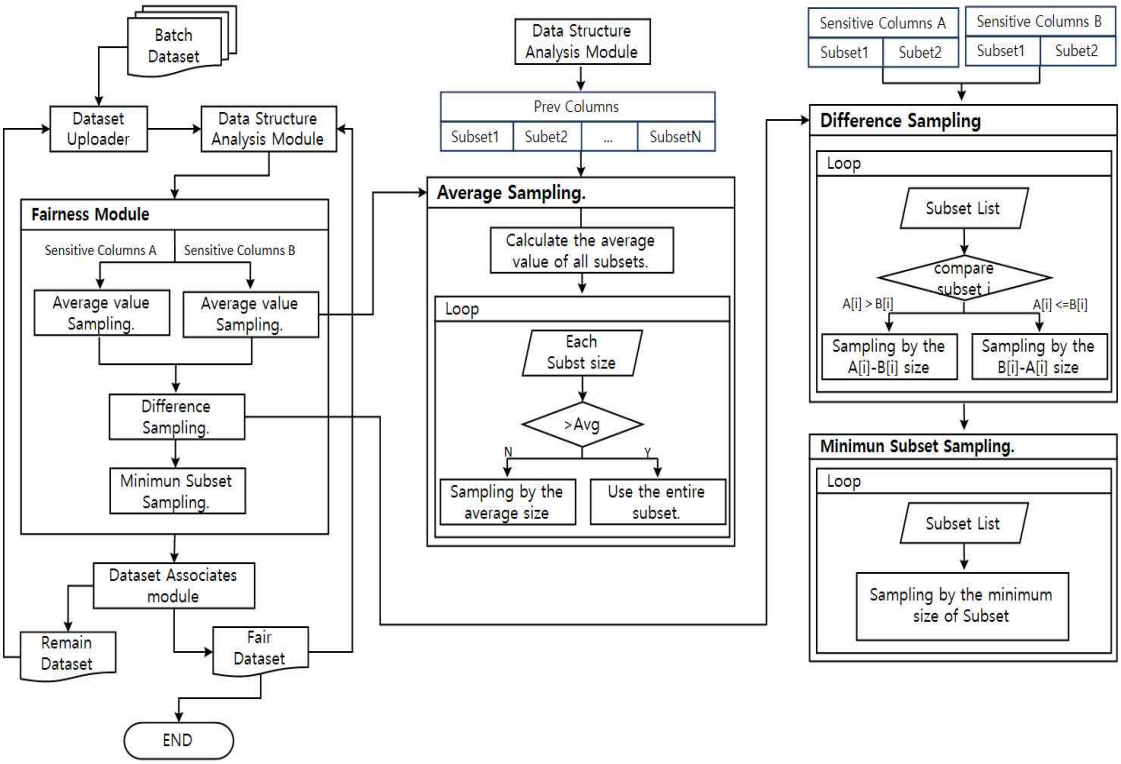

■ 대량의 데이터에 대한 공정성 보정을 효율적으로 처리하기 위한 맵리듀스(Hadoop)이나 스파크 기반의 배치 처리 기법 설계 및 구현

- 배치 기반 데이터를 Kafka로 수집
- Spark를 통해서 kafka의 Queue를 Streaming 전송
- Spark를 통해서 데이터를 Client로 전송

✓ 배치 처리 기법 시나리오

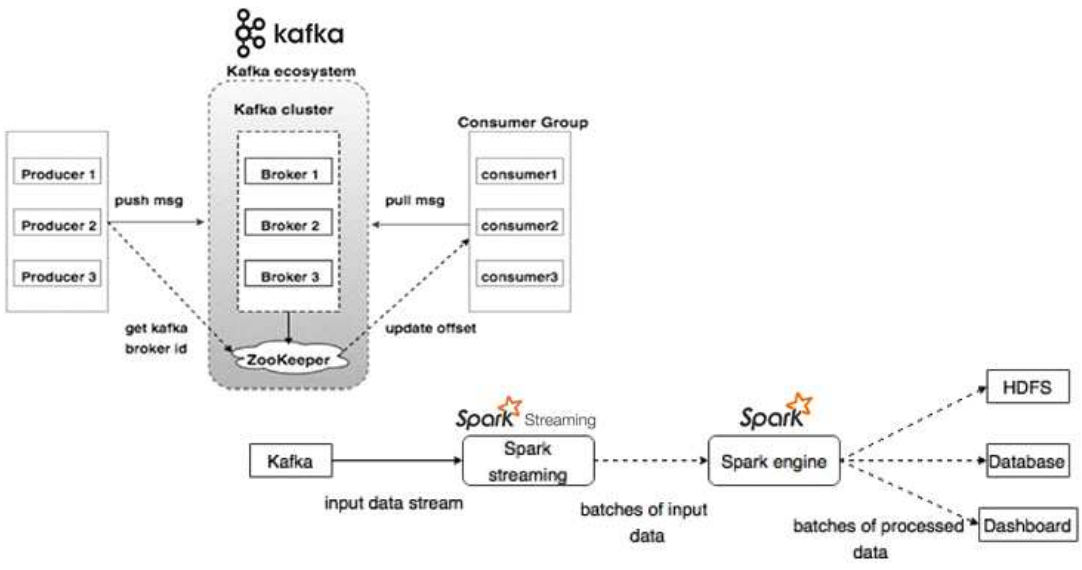

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 배치 처리 기법 실행화면

• Spark 실행화면

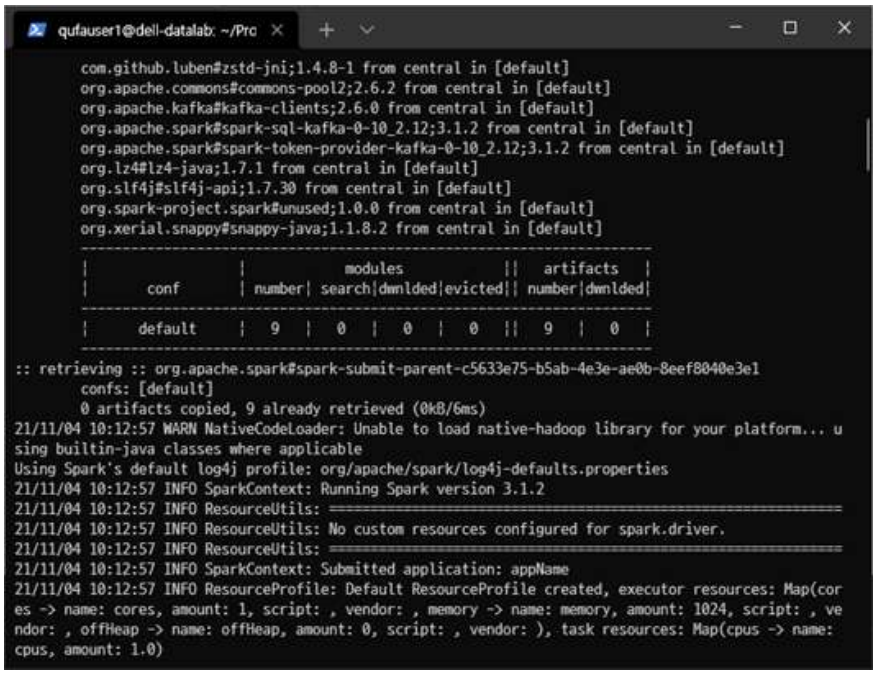

• Kafka 실행화면

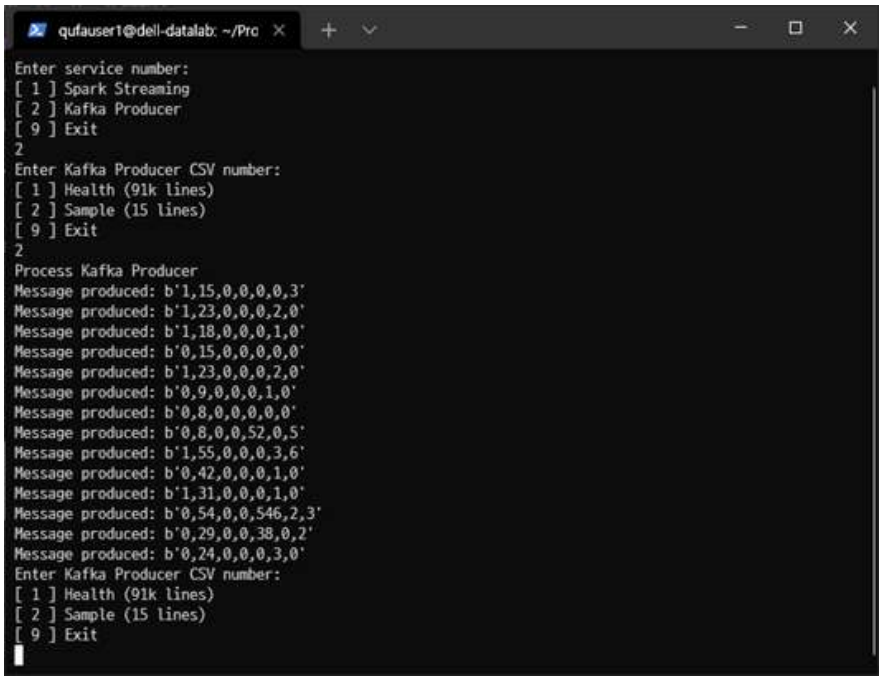

▪ 공정성 보정기와 결합 및 웹서비스 구현, 가시화 설계

✓ 논리설계에 따른 동작 시나리오

• Zeppelin 기반 API 설계 및 시각화

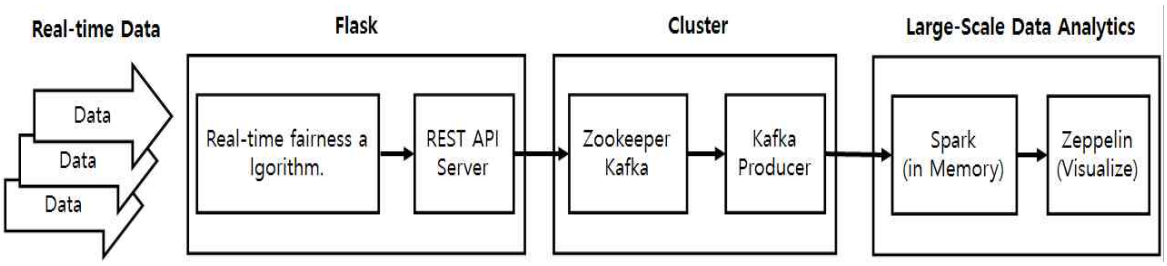

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 구현 화면 및 실행

- 시작화면

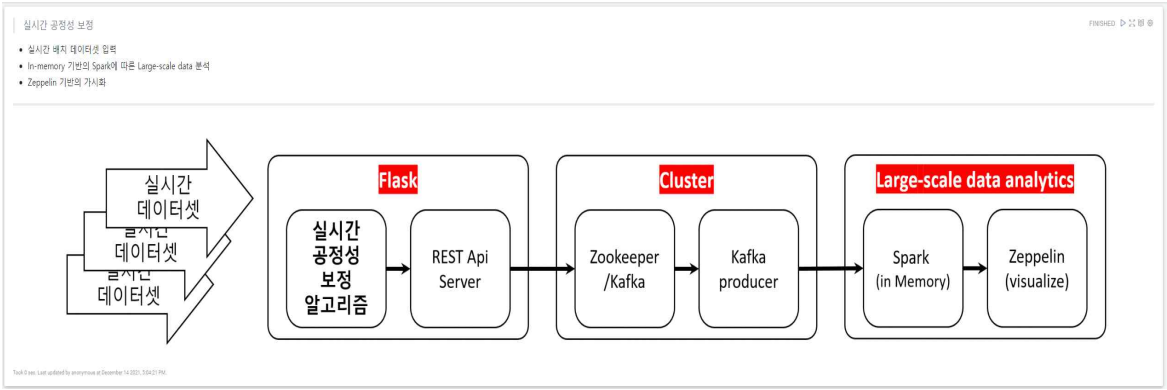

- 실행화면

```
Batch: 1
-------------------------------------------
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+
|DP                 |DPA                |DPB                |FPR                |FPRA               |FPRB               |TPR                |TPRA               |TPRB               |message|result|running_time|step|timestamp          |
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+
|0.42833974756533477|1.0211024978466838|1.4494422454120186|0.008051140665814083|0.15928853754940471|0.15123739688359303|0.019817535604666592|0.8871937124364309|0.8673761768317643|ok     |success|11.947549819946289|2   |2021-12-14 17:16:12|
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+

-------------------------------------------
Batch: 2
-------------------------------------------
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+
|DP                 |DPA                |DPB                |FPR                |FPRA               |FPRB               |TPR                |TPRA               |TPRB               |message|result|running_time|step|timestamp          |
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+
|0.41691206958996421|1.0150279089738086|1.4319399785637728|0.006361064114222381|0.16126482213438736|0.15490375802016498|0.019104846155782231|0.8881183541377716|0.8690135079819894|ok     |success|18.777556896209717|3   |2021-12-14 17:16:32|
+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------------------+-------+------+------------+----+-------------------+
```

- 시각화

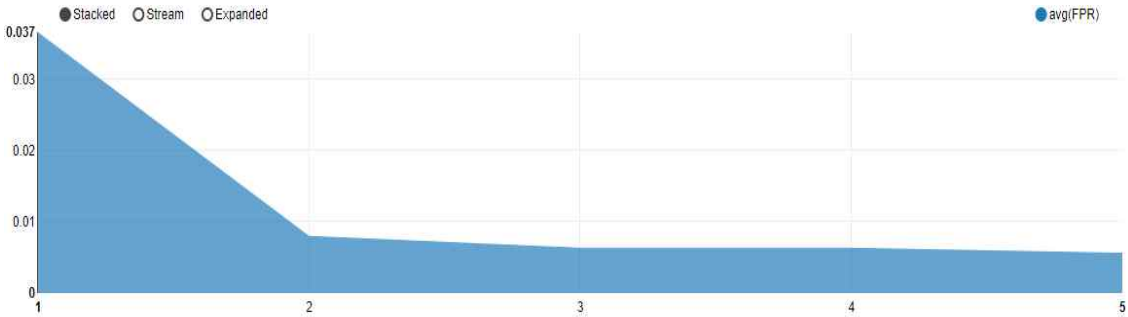

[서울대학교]

■ 공정성 지표 분석 및 정의

▪ 공정성의 개념과 지표 조사

✓ 공정성은 철학적-윤리적인 개념이면서도 동시에 데이터과학에서 품질의 형평성을 보장하는 새로운 지표임

✓ 품질의 형평성 제고는 결과적으로 전반적인 데이터의 품질향상에서도 중요

✓ 공정성은 정량적인 평가지표로 평가가 가능하며, 개별적인 지표들은 공정성의 특정한 특성을 반영함

▪ 헬스케어 분야의 공정성 문제 사례 수집

✓ 인공지능 분석 시 데이터가 특정 성별과 연령 및 인구집단 등에 집중되어 특정 계층 자료에 대한 인식율 등이 저하되는 문제로 공정성을 확인

- 대표적으로 만성질환의 위험도 평가 알고리듬, 자동화된 ICT기반 웨어러블진단 도구 중 혈압, 맥박수 등의 측정 정확도의 인종별 차이 등이 큰 문제가 되었음
- 우리나라에서도 널리 활용되는 심혈관 질환의 예측알고리듬의 성별 차이가 중요한 문제가 될 수 있을 것으로 평가되어 향후 이에 대한 해결책 제시가 필요함

▪ 공정성 지표의 구분

✓ 핵심지표 및 보조지표 구분 제시

- 결과지표: 인식율, 정답율 등 계층간의 결과지표 비교
- 변이지표: 계층간의 특성간 빈도 및 변이의 차이로서, 잠재적으로 불공정성이 나타날 수 있는 가능성 제시
- training 성능지표: 계층별로 ”전체인구집단 중의 빈도“ 개념이 포함된 ROC와 빈도 개념이 포함되지 않은 precision-recall간의 격차를 통한 지표

■ 데이터 패턴 시각화

▪ 정의한 공정성 지표를 용이하게 파악하기 위한 패턴 시각화 방안 제시

✓ python 기반의 시각화 알고리듬 구현

✓ 전체 데이터 패턴 및 이상값의 시각화: 인공지능 분석에서의 loss값에 대한 영향력 시각화, PC분석을 통한 unsupervised 시각화

✓ 관계형 이상값 시각화: 전체 변수 간의 상관성 시각화

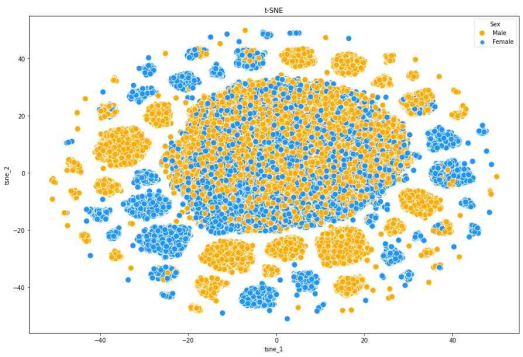

[그림 36] t-sne를 활용한 변수간 상관성 패턴

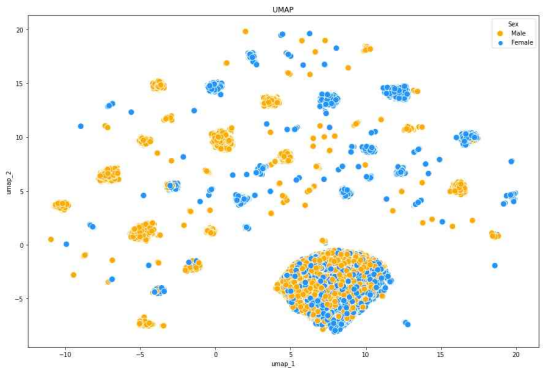

[그림 37] U-map 활용한 변수간 상관성 패턴

✓ 공정성 지표의 시각화: 전체와 주요 계층별 공정성 지표 그래프 개발을 통한 빅데이터의 공정성 지표의 시각화

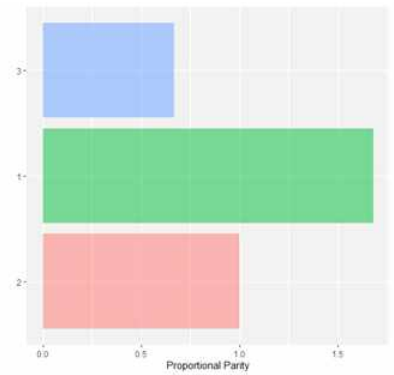

[그림 38] 그룹 간 proportional pairty 비교

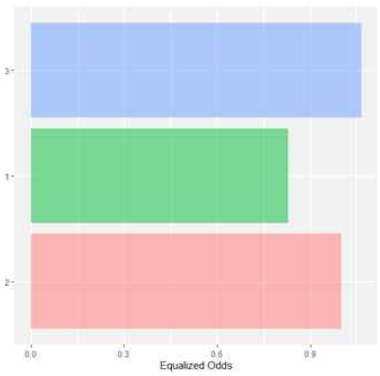

[그림 39] 그룹 간 Equlized odds 비교

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[서울시립대학교]

■ 데이터 품질 개선 자동화 기반 설계

▪ 학습 데이터셋 개선 자동화 기반 설계

✓ 미가공 입력 빅데이터 대한 분석을 위한 클라우드 서비스 설계

- 가공되지 않은 상태의 데이터들을 클라우드에 업로드 하면, 중앙 서버에서 데이터를 분석하여 데이터의 타입과 분포, 세부특성 등을 고려해 전/후처리 작업을 거쳐 개선된 품질의 데이터로 가공하여 반환하는 기술 구현이 목표

✓ 클라우드 기반 학습 데이터셋 개선 자동화 서비스 프로토타이핑

- 데이터 준비, 정제, 증강, 특성공학 등 단계에서 사용자의 개입과 자동화 결합한 데이셋 품질개선 서비스 프로토타이핑

Step		Description	Actor
Data Preparation	Gathering	목적에 맞는 데이터를 수집한다.	User
	Schema Analyzing	데이터 Schema의 각 feature들을 분석한다.	Cloud
	Option Setting	각 feature들에 대한 타입 분석을 검토하고 Nullable, imputation, Sampling 등의 옵션 허용 여부를 결정한다.	User
Data Cleaning	Duplicate cleaning	중복 값을 제거한다.	Cloud
	Outlier cleaning	이상치를 제거한다.	Cloud
	Inconsistency cleaning	불일치를 제거한다.	Cloud
Data Augmentation	Null Handling	결측치들을 처리한다.	Cloud
	Sampling	불균형 데이터들에 대해서 Sampling을 진행한다.	Cloud
	Generating / Synthesis	기존 데이터를 바탕으로 새로운 데이터를 추가 생성 혹은 합성한다.	Cloud
Feature Engineering	Feature Selecting	학습에 필요한 데이터들을 선택한다. (학습에 영향을 주지 않는 feature들을 제외한다)	Cloud
	Feature Extracting	Feature들에서 학습에 유의미한 새로운 Feature를 합성/추출한다.	Cloud
	Feature Scaling	Feature들의 scale정도를 조정한다.	Cloud
Data Extra-process	Add Noise Filter	학습에 적절한 수준의 mild noise를 추가한다.	Cloud
	Add Privacy Mask	개인 특정 정보들에 대해서 Masking을 적용한다.	Cloud
Performance Analyzing	Model Setting	데이터 셋의 성능 비교를 위해, 학습에 사용할 기본 모델을 선택한다.	User
	Model Evaluation	각 데이터 셋 별 학습 데이터에 대한 평가한다.	Cloud

[그림 40] 데이터셋의 품질 개선 프로젝트의 자동화 단계별 수행

✓ 데이터 준비(Data Preparation)단계

- CSV 포맷으로 입력되는 다변량의 정형 데이터 개선을 목표로 함
- 입력되는 데이터 각각의 Column들의 데이터 형태에 대해서 수치형(연속형, 이산형) 및 범주형(개념형 및 순서형)으로 크게 구분하고 기술 통계량 확인 후, 사용자에게 사전 검토를 받음

✓ 데이터 정제(Data Cleaning)단계

- 사용자 정의 데이터 항목 규칙들을 입력받아, 위배하는 항목에 대한 검토를 진행
- 데이터 특성과 분포 바탕으로 중복 값의 허용 여부, 이상치 제거, 도메인 불일치 제거 등의 작업을 진행

✓ 데이터 증강(Data Augmentation)단계

- 분석에 필요하지만 부족한 값들을 채우면서, 데이터 불균형 문제와 결측값들을 해결하는 등 입력된 실제 데이터의 형태를 유지하면서 실제와 유사한 데이터를 추가로 생성함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

```
2021-03-30 13:34.55 [info     ]  - Check Numeric value data...
2021-03-30 13:34.55 [info     ]
```

	Features	Skew	S(L)	S(S)	S(LS)	Kurt	K(L)	K(S)	K(LS)
35	YrSold	0.10	0.10	0.10	0.10	-1.19	-1.19	-1.19	-1.19
6	YearRemodAdd	-0.50	-0.51	-0.51	-0.51	-1.27	-1.26	-1.27	-1.26
5	YearBuilt	-0.61	-0.64	-0.63	-0.64	-0.44	-0.38	-0.41	-0.38
27	WoodDeckSF	1.54	0.15	0.49	0.14	2.99	-1.90	-1.21	-1.91
11	TotalBsmtSF	1.52	-5.15	-1.27	-5.21	13.25	27.74	6.32	28.20
22	TotRmsAbvGrd	0.68	-0.06	0.25	-0.06	0.88	0.35	0.38	0.38
31	ScreenPorch	4.12	3.15	3.35	3.14	18.44	8.02	9.91	7.97
36	SalePrice	1.88	0.12	0.94	0.12	6.54	0.81	1.96	0.81

[그림 41] 클라우드 상에서 분석의 에: 연속형 데이터의 왜도(Skew) 첨도(Kurt) 분석

✓ 특징공학(Feature Engineering) 단계
- 앞선 단계들을 통해 다양한 전처리 작업을 거치며 충분한 규모로 각 Column 데이터 분포들이 적절하게 균형잡힌 데이터가 되었을때, 이를 실제 학습에 유의미한 결과를 얻을 수 있도록 왜도, 첨도, 정규화, 합성성분 추출, 상관계수 분석 등의 작업을 진행

✓ 후처리(Extra-process) 단계
- 사용자 선택에 따라 정제된 데이터셋을 의도적으로 훼손하는 작업들을 포함
- 개인정보를 식별할 수 있는 정보들을 Masking 하거나 가공·정제된 데이터셋을 현실 데이터 환경에 유사한 Mild noise를 의도적으로 포함하는 과정을 거치면서 오히려 데이터의 안정성을 향상시키는 과정을 포함

✓ 성능분석(Performance Analyzing) 단계
- 데이터셋 가공절차를 통해서, 개선된 데이터 품질을 측정하기 위해 동일한 parameter 설정값을 지니는 여러 Sample 머신러닝 및 딥러닝 모델들을 대상으로 원본 데이터셋과 개선된 데이터셋을 비교, 평가할 수 있는 환경 제공

✓ 본 학습 데이터셋 개선 서비스 제공은 현 단계에서는 Web은 아직 미구현되어 있고, 클라우드를 통한 사용자 입력을 받고 있으나 사용자 접근의 편의성을 위해 Cloud Web을 통해서 접근할 수 있게 개발 진행 중

■ **정형 데이터 품질 개선 알고리즘 개발**

▪ **딥러닝 기반 정형데이터 결측치 보완 알고리즘 및 모듈 개발**

✓ 정형 데이터의 특성 분석
- 정형 데이터는 전자상거래 추천, 모바일 광고 분야 등 가장 흔히 사용하고 발생되어지는 데이터 유형임
- 정형 데이터는 일반적으로 수치형, 범주형 변수를 같이 포함하며, 품질 개선을 위해 이를 처리할 수 있는 다양한 기법의 적용이 필요함
- IoT 센서 산업의 확산으로 인하여 시계열 데이터 역시 많이 생성되고 있으며 이에 대한 이상치 탐색의 연구 필요성 존재

✓ 이상치 제거 알고리즘 개발
- 오토 인코더 기반의 이상치 탐지 알고리즘을 활용
- 정상 데이터의 경우 복원 오류가 적고 비정상 데이터의 경우 복원 오류가 커지는 현상을 이용
- 정상 데이터를 학습시킨 오토인코더를 이용하여 복원 오류가 일정 임계치를 넘는 경우 이상치로 판단 및 제거

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 셀프 어텐션 기반 정형 데이터 결측치 보간 딥러닝 모델 개발

- 수치형/범주형 변수가 혼합되어 있는 정형 데이터를 대상으로 결측 보간을 위한 셀프 어텐션 기반 딥러닝 모델을 개발
- 본 연구는 수치형/범주형 변수가 혼합되어 있는 테이블 데이터를 대상으로 결측 보간을 위한 셀프 어텐션(Self-Attention) 기반 딥러닝 모델을 제안함

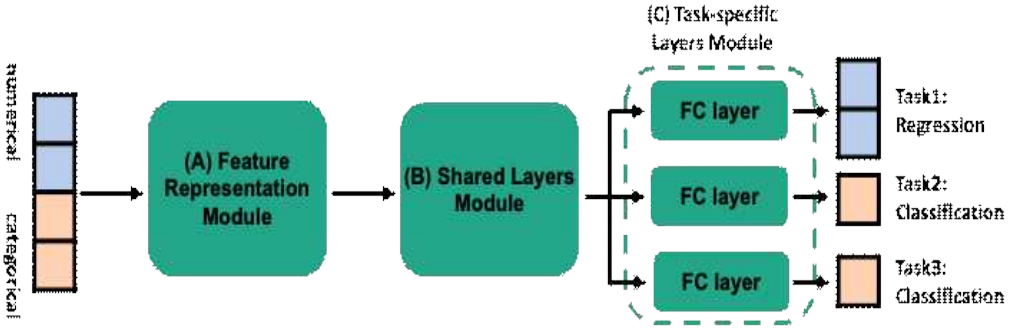

[그림 42] 셀프 어텐션 기반 테이블 데이터 결측치 보간 모델

- 셀프 어텐션을 통해 수치, 범주, 결측 변수 값에 대한 상관성을 바탕으로 적절한 대체값을 예측
- 멀티 태스크 러닝을 활용하여 수치형 변수 예측인 회귀 문제와 범주형 변수 예측인 분류 문제를 동시에 처리할 수 있도록 함

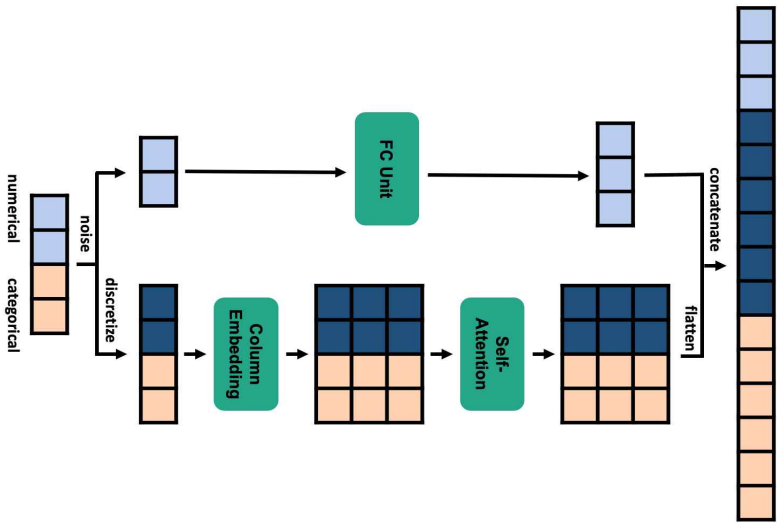

[그림 43] 특징 표현 모듈

- 수치형 변수의 경우 이산화 처리를 통하여, 결측값의 경우 결측 여부에 대해서 범주형 변수 값과 같이 간주하고 임베딩 벡터를 학습 → 각 변수 값(수치형/범주형/결측 변수)들 간의 상관성을 셀프 어텐션 레이어를 통해 학습하여 결측값 보간에 필요한 특징을 추출
- 통계량 기반 보간 기법 대비 낮은 오차를 갖는 대체값을 예측함 (성능 향상율 22.05~86.66%)
- 측값이 존재하지 않는 완벽한 테이블 데이터에 대해 MCAR(Missing Completely At Random) 방식으로 5~20%의 결측값을 생성 → 결측 처리된 값에 대해 결측값 보간을 수행하고 보간된 값과 본래 값간의 오차를 측정 → 보간된 데이터셋을 이용해 이진 분류기를 학습하여 원본 데이터셋을 학습한 분류기와의 성능 비교
- 원본 데이터와 제안 알고리즘을 통해 개선된 데이터를 이용해 이진 분류 실험을 수행한 결과 성능 차이가 0.001 미만으로 유의한 결과를 보임

- Adult 데이터 셋의 경우 86.66%의 성능 향상을 보였고, Bank 데이터셋의 경우 55.68%의 성능 향상을 보임으로서 제안 모델이 준수한 성능을 보이는 것을 알 수 있음

[표] 보간된 데이터를 학습한 이진 분류기 성능

데이터셋	보간 기법	평균 AUC-ROC
Adult	원본 데이터	0.9052
	보간된 데이터	0.9048
Bank	원본 데이터	0.9030
	보간된 데이터	0.9026

- 이진 분류기 성능을 평가하기 위해 AUC-ROC를 평가척도로 하며 값이 높을수록 분류기가 좋은 성능을 보임으로 해석할 수 있음. 이 경우 원래 데이터를 학습한 이진 분류기의 성능이 상한(upper bound)이 되며, 보간된 데이터를 학습한 모델의 성능과의 차이가 적을수록 제안 모델이 좋은 성능을 보임을 해석할 수 있음
- Adult, Bank 데이터셋 모두 성능 차이가 0.001 미만이며 제안 모델이 보간한 데이터가 유용하게 사용될 수 있음을 보임

▪ **딥러닝 기반 시계열 데이터 결측값 보완 및 이상치 제거 알고리즘 및 모듈 개발**

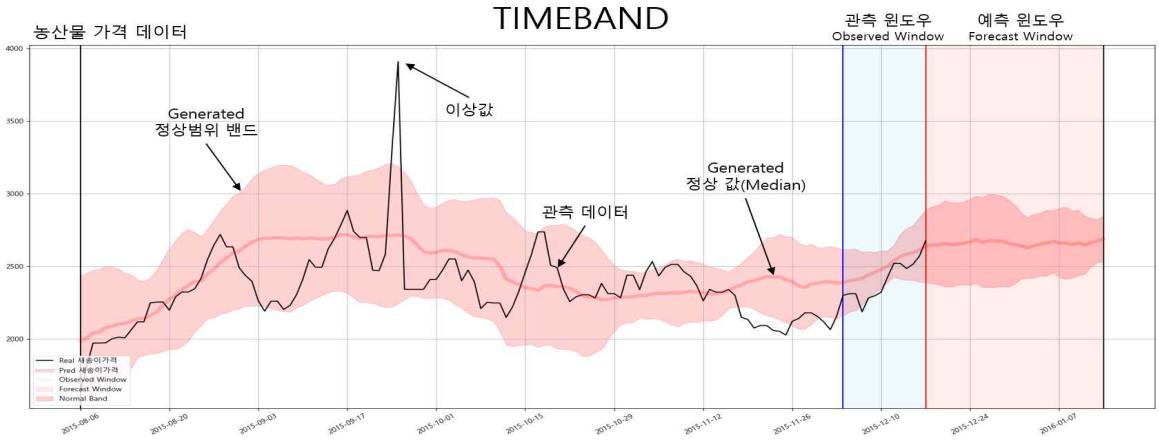

[그림 44] TIMEBAND 기법을 적용한 농수산물 가격 예측 모델의 시각화

✓ 시계열 데이터의 특성을 고려한 품질 개선 방안

- IoT 기반 시계열 데이터에 대한 이상치 탐지를 위해 머신러닝 기법을 적용한 연구 필요: 제조 시스템에서 비정상적인 동작이 일어날 때, 시계열의 데이터를 분석하기 위하여 시퀀스 데이터에 적합한 Locality Density Cluster, LSTM, GRU 등의 최신 머신러닝 지도/비지도 학습 알고리즘 활용
- 정형 데이터에 대한 이상치 탐지 알고리즘 대비 시계열 또는 IoT 센서 데이터에 대한 이상치 탐지에 적합한 기존 통계 및 머신러닝 기법을 조사하고, 이를 기반으로 수집 데이터에 대한 실시간 이상치 탐지 서비스 모듈을 개발
- 전통적 통계 및 비지도 학습 기법 관련 연구: 시계열 데이터 이상치 탐지는 로컬 영역에서 클러스터링 또는 정상분포 등을 자동 도출하고, 정상 클러스터와 정상 분포를 벗어나는 데이터를 이상치로 간주

✓ 시계열 데이터의 품질 개선을 위한 GAN 기반의 신경망 기술 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

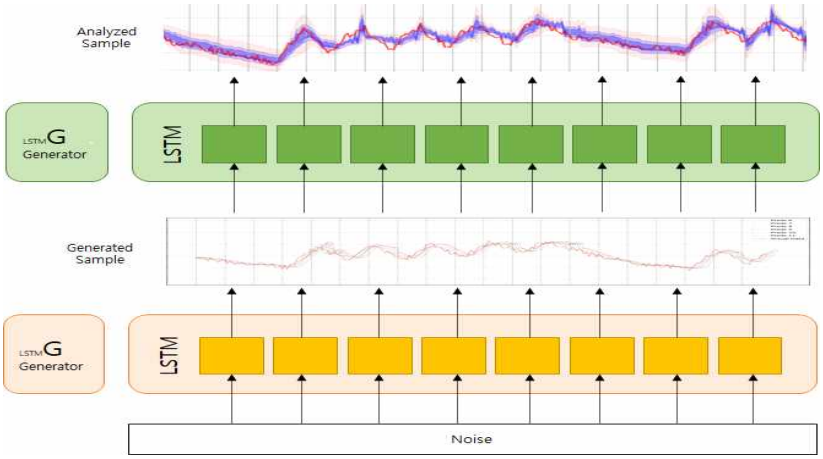

[그림 45] 시계열 데이터 품질 개선을 위한 LSTM-GAN 기본 구조

✓ 본 연구는 기존의 대용량의 시계열 데이터에서 결측치(Missing Value)와 이상치(Anomaly value)를 높은 품질로 보정 및 개선하기 위한 목적을 지님
- 시계열의 특성을 보존하기 위해 LSTM 기반의 GAN을 이용해 관측된 기준 패턴(pivot pattern)을 바탕으로 예측 패턴(predicted pattern)을 생성
- 이는 기존 전통적인 시계열 예측 방법론에서 모델의 주기적인 패턴을 선형적인 모형을 기반으로 예측하는 것보다 더 높은 예측 정확도를 보임

$$L = \underset{\tilde{\boldsymbol{x}}\sim\mathbb{P}_g}{\mathbb{E}}[D(\tilde{\boldsymbol{x}})] - \underset{\boldsymbol{x}\sim\mathbb{P}_r}{\mathbb{E}}[D(\boldsymbol{x})] + \lambda \underset{\hat{\boldsymbol{x}}\sim\mathbb{P}_{\hat{\boldsymbol{x}}}}{\mathbb{E}}\left[(\|\nabla_{\hat{\boldsymbol{x}}} D(\hat{\boldsymbol{x}})\|_2 - 1)^2\right].$$

[그림 46] Wasserstein Loss

✓ GAN 모델 학습 안전성을 위해 최신 기법들이 도입됨. 생성자와 판별자 사이의 균형이 붕괴되는 Mode Collapse를 방지하기 위해 학습 균형을 위한 Critic 구조가 적용
- GAN의 Loss 값으로 합성 데이터 진위판정 loss와 함께 원본 데이터-생성 데이터 사이의 기울기 차 및 거리에 따른 추가적인 penalty 값을 활용한 Loss를 구성

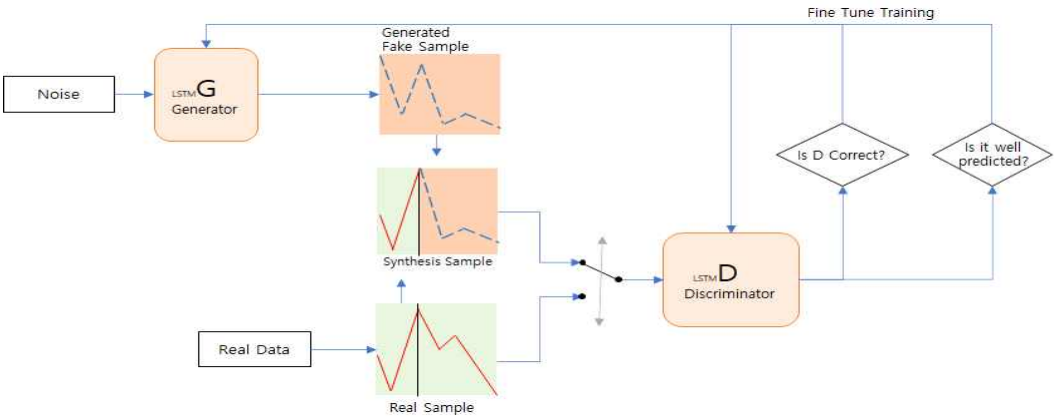

[그림 47] 기준 패턴을 기반으로 하는 데이터 합성 및 적대적 신경망 구성

✓ LSTM 기반 구조의 GAN에 의해 생성된 데이터는 전후 시계열 데이터의 시간적 의존성을 고려하면서 pivot pattern의 값을 기반으로 이후의 값을 예측하는 값이므로, 출력되는 예측값들이 왜 이렇게 분포하는가? 에 대하여 해석 가능한 결과를 제공

✓ 본 모델은 새로운 데이터가 등장하더라도, 새로운 학습된 모델을 필요로 하지않는 학습 모델(Incremental/Online Learning)임
- 따라서 연속적으로 데이터를 받고 이상현상 발생 등 빠른 변화에 민감하게 대응해야 하는 스마트 팩토리의 센서 및 금융과 같은 도메인에서도 적합

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그림 48] LSTM-GAN 기반 품질 개선 기법의 흐름도

- LSTM-GAN 기반 구조: LSTM 모델을 통해 입력된 데이터의 시간적 속성을 보전하면서 후속값 예측, 그리고 GAN 모델을 통해 관측된 값의 실제 후속 등장 값과 유사한 후속 예측값 다중 생성

✓ 다변량 데이터의 처리
- 인코드 셋(Encode Set) 및 디코드 셋(Decode Set) 구조
- 모델 자체적으로 시점별 시간 종속성 및 속성 간 상관관계의 영향력 고려

✓ 슬라이딩 윈도 기법 적용

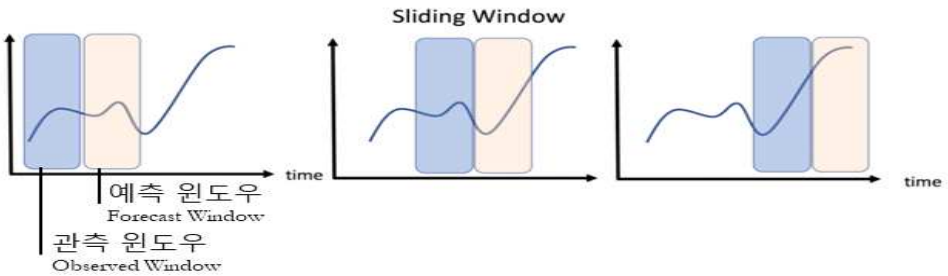

[그림 49] 슬라이딩 윈도(관측 윈도 및 예측 윈도) 구성

- 미시적인 패턴 정보 학습을 위해 연속된 시간 구간의 집합인 윈도 구성
- 인코드 셋을 이용하여 직접적인 관측 구간 집합인 관측 윈도 구성
- 디코드 셋을 이용하여 직접적인 예측 구간 집합인 예측 윈도 구성
- 각 시점에 대해서 관측 윈도와 예측 윈도 맵핑(Mapping)

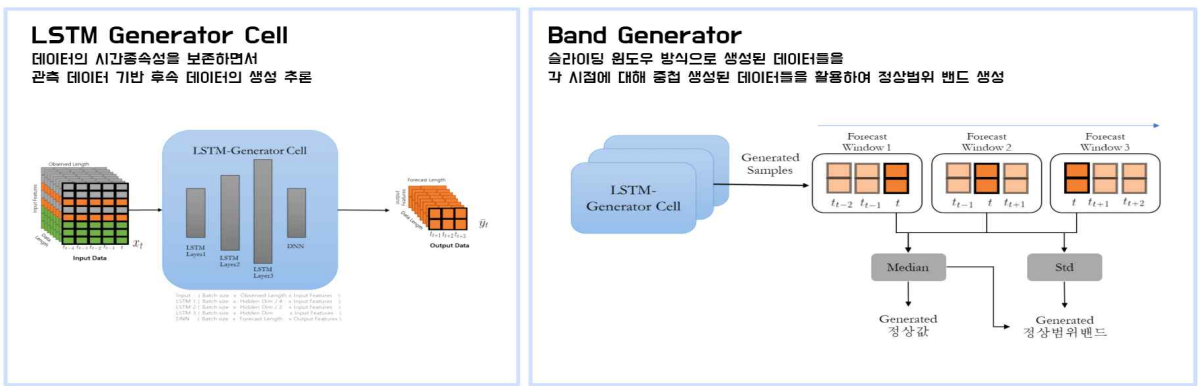

[그림 50] (좌측) 관측값의 후속 값을 예측하는 LSTM 기반 생성자 구조
(우측) 중첩 예측된 값을 이용해 정상범위 밴드를 생성하는 생성자 구조

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ TIMEBAND의 학습

- LSTM 생성 셀(Generator Cell): 각 셀은 3개의 LSTM Layer와 출력 DNN Layer의 구조이며, 전체 맥락의 시간 의존적 정보를 보전하면서 정보 전달 및 예측, 그리고 입력된 관측 윈도의 인코드 셋을 예측 윈도의 디코드 셋으로 출력하여 후속값 예측
- Band 생성자: 각 시점에 대해 슬라이딩 윈도 구간이 지나가는 동안 중첩된 정보 생성 그리고 중첩 생성된 정보들의 중앙값과 편차를 이용해 정상범위 밴드 생성

✓ 적대적 생성 학습

- Band 생성자를 거쳐 생성된 정상범위 내의 중앙값이 실제와 유사한지 판정
- GAN을 기반으로 생성된 데이터가 원본과 판별할 수 없을 정도로 적대적 학습진행

[이화여자대학교]

■ 특징 공학(feature engineering) 연산자 고도화

▪ 특징생성 연산 다양성을 위한 메커니즘 실현

✓ 자체 확장 개발된 공개 S/W인 qufafeat에 활용가능한 87개 특징연산자 개발

구분	특징 연산자 기능
특징 변환 (43개)	AbsoluteDiff, AgeOverN, AgeOver18, AgeOver25, AgeOver65class AgeUnderN, AgeUnder18, AgeUnder65, CountString, CumulativeTimeSinceLastFalse, CumulativeTimeSinceLastTrue, DateToTimeZone, DayName, GreaterThanPrevious, IsFirstOccurrence, IsLastOccurrence, IsMaxSoFar, IsMinSoFar, IsWholeNumber, IsZero, Lag, LessThanPrevious, MeanCharactersPerWord, NaturalLanguageToYear, NthWeekOfMonth, PartOfDay, PercentChange, PhoneNumberToCountry, PolarityScore, PunctuationCount, Quarter, SameAsPrevious, SavgolFilter, ScorePercentile, Season, Sign, StopwordCount, SubRegionCodeToRegion, TitleWordCount, UpperCaseCount, UpperCaseWordCount, URLToProtocol, ZIPCodeToState
특징 취합 (44개)	Autocorrelation, Correlation, CountAboveMean, CountBelowMean, CountGreaterThan, CountInsideNthSTD, CountInsideRange, CountLessThan, CountOutsideNthSTD, CountOutsideRange, DateFirstEvent, HasNoDuplicates, IsMonotonicallyDecreasing, IsMonotonicallyIncreasing, IsUnique, Kurtosis, MaxConsecutiveFalse, MaxConsecutiveNegatives, MaxConsecutivePositives, MaxConsecutiveTrue, MaxConsecutiveZeros, MaxCount, MaxMinDelta, MedianCount, MinCount, NMostCommonFrequency, NUniqueDays, NUniqueDaysOfCalendarYear, NUniqueDaysOfMonth, NUniqueMonths, NUniqueWeeks, NumConsecutiveGreaterMean, NumConsecutiveLessMean, NumFalseSinceLastTrue, NumPeaks, NumTrueSinceLastFalse, NumZeroCrossings, PathLength, PercentUnique, TimeSinceLastFalse, TimeSinceLastMax, TimeSinceLastMin, TimeSinceLastTrue, Variance

▪ 특징공학 온톨로지 구축

✓ 특징 연산자에 대한 설명, 예시 주석 기능 추가

✓ 특징 연산자 사용자 정의 및 연산자 동적로딩으로 외부 온톨로지와의 연동 지원

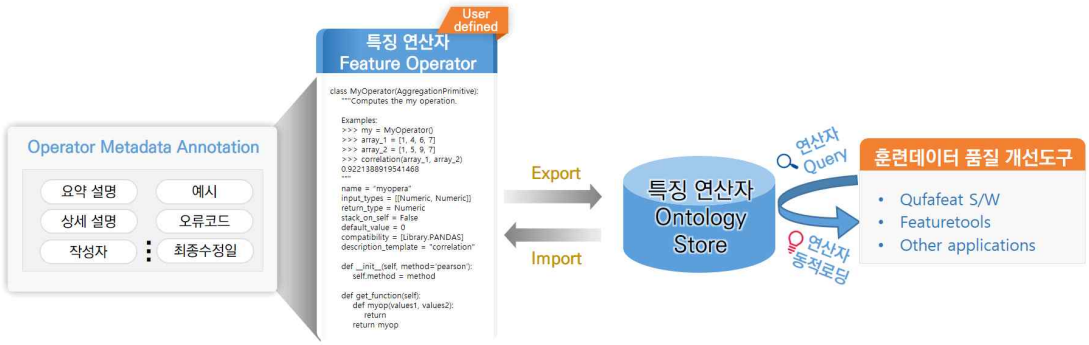

[그림 51] 온톨로지에 저장된 특징연산자 동적로딩을 통한 훈련데이터 품질 개선도구 구성 방식

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 오류 탐지 및 보정 기술 개발

▪ 딥러닝 기반 이상치 제거 알고리즘 개발

✓ 기계학습용 훈련데이터로부터 추출된 다양한 파생 특징에 대하여 이상치를 제거한 최적의 특징을 자동으로 선택하여 예측엔진의 정확도와 학습성능을 개선

✓ 지도학습용 목표값이 있는 경우, 자동화된 그라디언트 부스팅(Gradient boosting)기법을 적용하여 목표값 상관성을 기반으로 특징 선별

✓ 목표값이 없는 비지도학습 데이터의 경우, 엔트로피 정보량이 많은 특징들을 자동으로 선별

✓ Kaggle의 NYC Taxi 운행 시간 예측 컨테스트에 적용한 경우, 자동화된 방식으로 훈련데이터를 생성함에도 불구하고 570위(1,207참가팀)를 기록함

훈련 데이터 생성 방식	Kaggle 점수	순위(전체 1,207팀 중)
Featuretool(대표적 특징공학도구) + 사용자 개발 Customized 연산자	0.39256	415
qufafeat (본과제의 자동화 특징공학 도구)	0.42283	570
Featuretool Only	0.45291	679
훈련데이터 원본 (특징 공학 미적용)	0.54209	846

▪ 반복 샘플링 기반 데이터 테이블 자동 정규화(Auto Normalization) 기술 개발

✓ 비정규화(Denormalization)된 CSV나 엑셀 데이터는 내재된 모델의 특성을 파악할 수 없으므로 추출된 특징상에서 이상치가 다수 발생

✓ 변환된 정규화 데이터 테이블에 대하여 특징 연산자를 적용하여 훈련데이터의 품질을 개선시킬 수 있음

✓ 대규모 데이터에 대한 성능상의 문제점을 보이는 기존 자동 정규화 기술과 달리, 부분 데이터 샘플링을 반복하는 방식으로 컬럼 종속성을 빠르게 확인하는 본 기술은 99%이상의 정확도로 100배 이상의 성능을 달성함

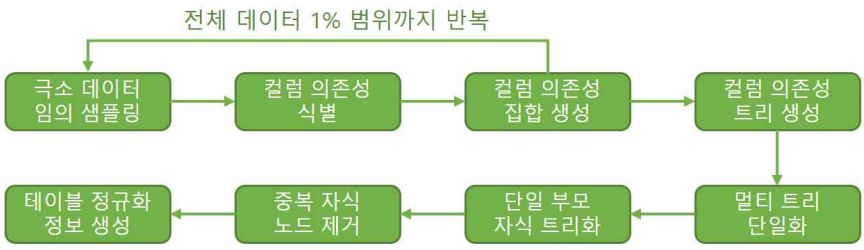

[그림 52] 반복 샘플링 기반 데이터 테이블 자동정규화 기술(국내특허출원)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[한성대학교]

■ 메타데이터 수집 기술 개발

▪ **(프로파일링 시스템 구성도)** 메타 데이터 자동 생성 및 서비스 모듈 개발

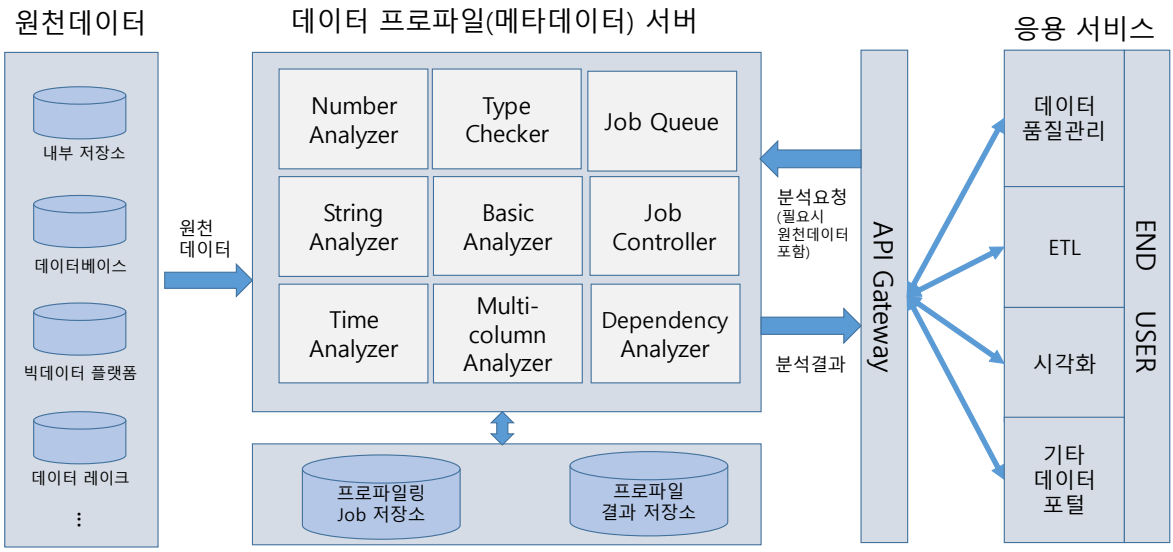

[그림 53] 데이터 프로파일 서비스 아키텍처

✓ 작업 큐(job queue)와 작업 컨트롤러(job controller): API를 통해 요청되는 프로파일링 서비스의 부하와 작업순서를 제어

✓ 타입 검사기(type checker): 원천 데이터의 각 컬럼에 대한 타입을 자동으로 결정

✓ 기본 분석기(basic analyzer): 원천 데이터의 기본적인 정보, 예를 들어 레코드나 컬럼의 수, 크기, 각 컬럼의 값 분포 등의 요약 정보를 생성

✓ 수치 분석기(number analyzer), 문자열 분석기(string analyzer), 시간 분석기(time analyzer): 단일 컬럼에 대한 프로파일을 생성하는 모듈들로 각각 수치형, 문자형, 시간형 타입의 컬럼에 대한 프로파일 정보를 생성

✓ 다중 컬럼 분석기(multi-column analyzer): 2개 이상의 다중 컬럼에 대한 연관된 분석

✓ 의존성 분석기(dependency analyzer): 컬럼 간의 의존 또는 포함 관계에 대한 분석정보를 생성

▪ **(원천데이터 관리)** 원천 데이터 관리 기술 개발

✓ 프로파일링 서버의 내부 저장소, 내/외부의 데이터베이스, 빅데이터 플랫폼이나 데이터 레이크 환경 등 다양한 환경의 원천 데이터에 대한 관리 기술 개발

✓ 데이터 사전이 제공되지 않은 환경에 대응하기 이한 데이터 유형 자동 인식 기능 개발

■ 메타데이터 변환 및 편집, 저장 기술 개발

▪ **(메타데이터 저장소)** 프로파일 데이터 저장 및 관리기술 개발: 1차년도에 설계된 프로파일 저장소의 설계 결과를 바탕으로 개발을 완료

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

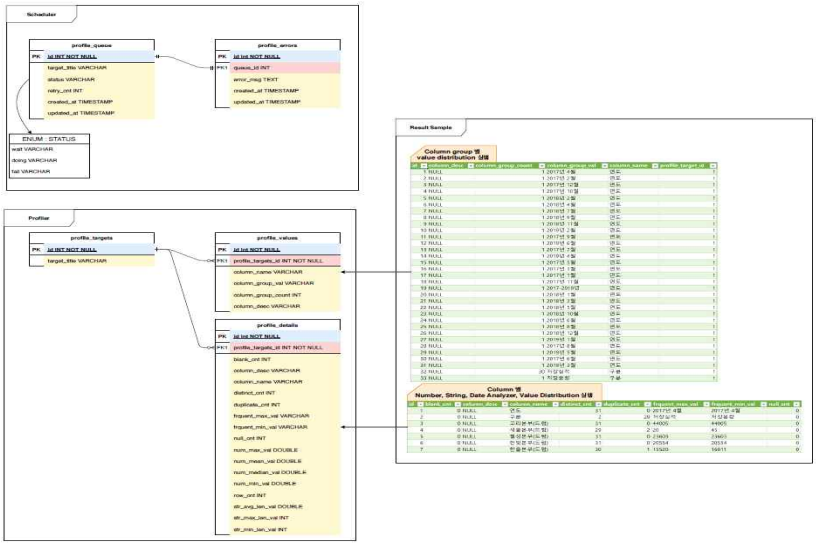

[그림 54] 프로파일 저장소 구조

- **(프로파일 정보제공 서비스)** 오픈포맷을 지원하는 데이터 프로파일 서비스 기술 개발
  - ✓ 자동 생성된 데이터 프로파일은 JSON과 같은 오픈포맷 형태로 서비스할 수 있도록 자동 변환됨. 다음은 JSON으로 저장된 데이터 프로파일 구조와 실제 프로파이링 결과의 예시임(참조: 데이터 프로파일러 개발 보고서)

<표> 데이터 프로파일 명세

항목명				설명
dataset_name				데이터셋 이름
dataset_type				데이터셋 타입
dataset_size				데이터셋 크기
dataset_column_cnt				데이터셋 열 수
dataset_row_cnt				데이터셋 행 수
results				profiling 결과
	column_name			컬럼 이름
	column_type			컬럼 타입
	profiles			프로파일 결과 목록
		basic_profile		basic 프로파일
			null_cnt	결측치 수
			value_distributuion	값들의 분포정보
			…	…
		number_profile		number 프로파일
			min	최소값
			max	최대값
			…	…
		string_profile		string 프로파일
			blank_cnt	빈칸의 수
			min_len	최소 길이
			…	…
		date_profile		date 프로파일
			highest_date	가장 최신 시간
			lowest_date	가장 과거 시간
			…	…

```
{
  "dataset_name": "sample.csv
  "dataset_type": "csv",
  "dataset_size": 300,
```

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다


```
  "dataset_column_cnt": 2,
  "dataset_row_cnt": 20,
  "results": [
   {  "column_name": "name",
      "column_type": "string",
      "profiles": {
            "basic_profile": {
              "row_cnt": 20,
              "distinct_cnt": 6,
              "null_cnt": 2,
              "value_distribution": {
                "Jason": 3,
                "Paul": 4},
            ...},
            "string_profile": {
              "blank_cnt": 0,
              "min_len": 3
              ... }}},
    { "column_name": "age
      "column_type": "number",
      “profiles”: {
            "basic_profile": {
              "row_cnt": 20,
              "value_distribution": {
                "50": 3,
                "51": 4 },
              .....},
            "number_profile": {
              "min": 25
              "max": 75
              ... }}}]
}
```


[그림 49] JSON으로 정의된 데이터 프로파일 예

- **(마이크로 서비스 아키텍처 지원)** 특정 환경에 종속되지 않고 타 시스템과 연계가 원활하도록 프로파일링 서비스 지원
  - ✓ 마이크로 서비스 아키텍처에 쉽게 연계할 수 있도록 스프링부트(Spring Boot) 환경에서 개발
  - ✓ 외부 환경과의 원활한 연동을 지원하기 위해 restful API로 프로파일링 서비스의 요청과 응답이 가능하도록 개발
  - ✓ API 명세를 스웨거(swagger)로 정의하여 누구나 쉽게 사용할 수 있는 환경 및 매뉴얼 제공(https://app.swaggerhub.com/apis/jee101kr/QuFa/1.0.0)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

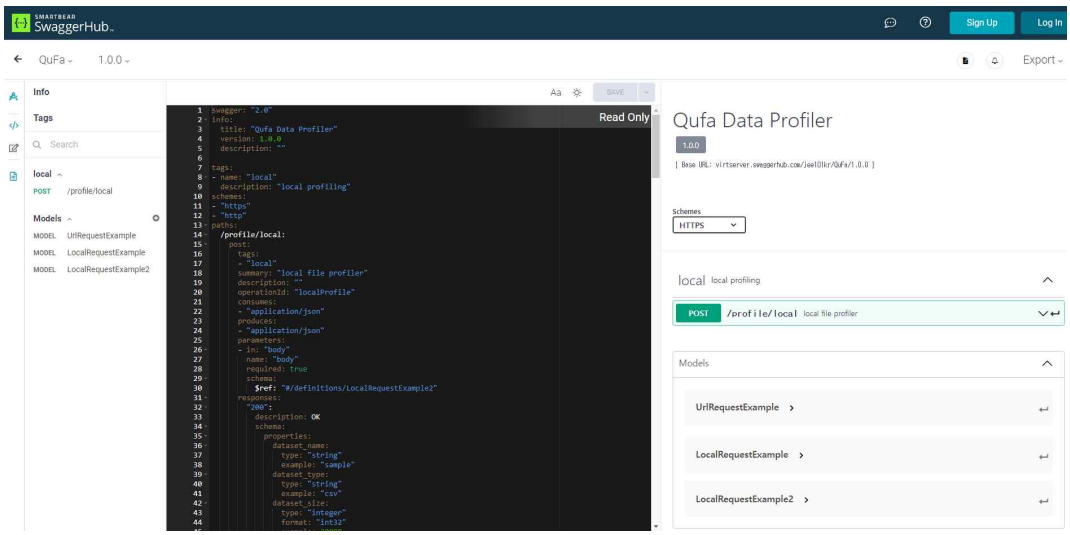

[그림 55] 스웨거로 정의된 데이터 프로파일링 API 명세

[프람트테크놀로지]

■ 데이터 품질 분석 도구 제품화

▪ 데이터 품질 대시보드 구현

✓ 데이터 품질 개선 프로젝트 생성

- 프로젝트 관리 메뉴를 통하여 신규 프로젝트를 생성하거나 기존 프로젝트에 접근 이전 작업에 이어서 추가적인 데이터 품질 개선 등의 작업을 수행할 수 있도록 구성함.
- 생성한 프로젝트에서 다양한 품질개선 기능(task)을 drag & drop 형태로 조합하여 실행할 수 있도록 함.

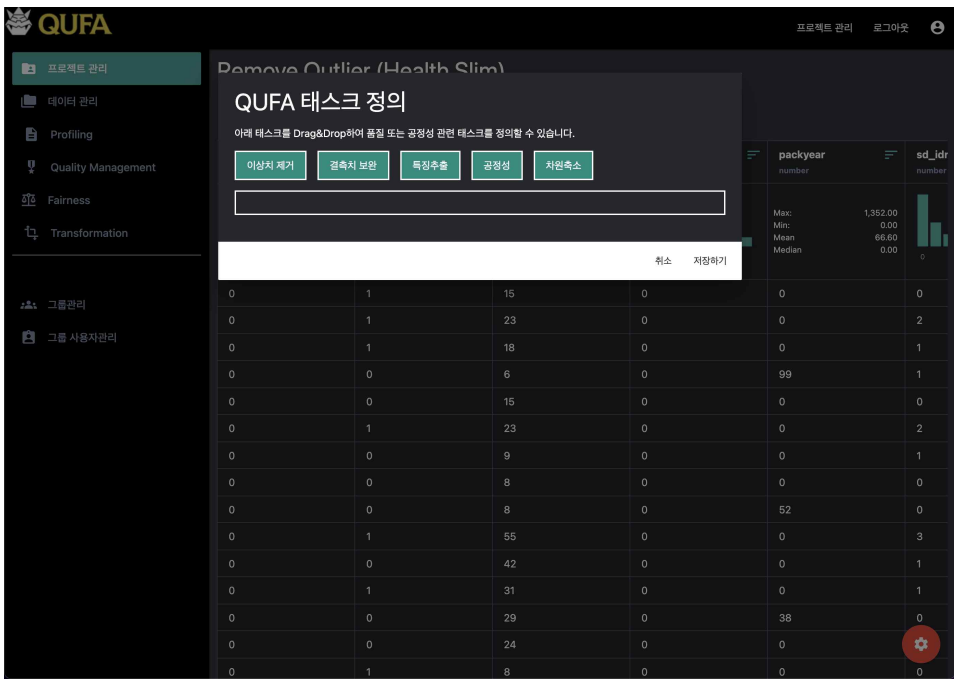

[그림 56] 프로젝트 태스크 정의 화면

✓ 프로파일링 대시보드

- 선택한 프로젝트별 데이터셋의 컬럼별 row의 개수, distinct value의 개수, 기타 unique, null, min, max 등의 개수를 상세 결과 확인 메뉴를 통해 검색이 가능하며, raw data 컬럼 별 시각화 기능을 통해 프로파일링 결과 현황을 직관적인 대시보드 형태로 제공함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

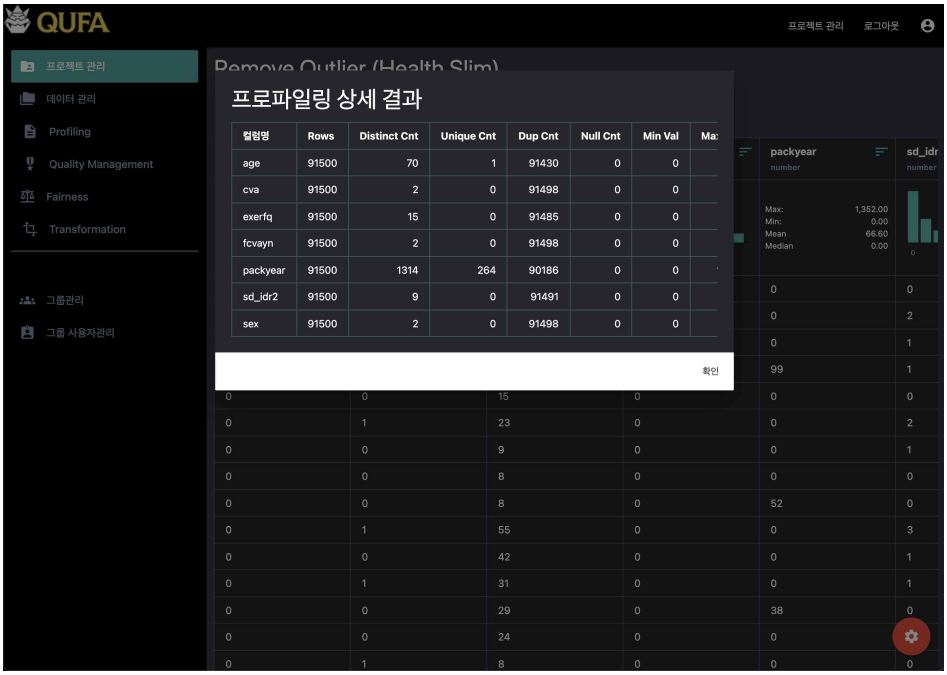

[그림 57] 프로파일링 상세결과 확인 사용자 화면

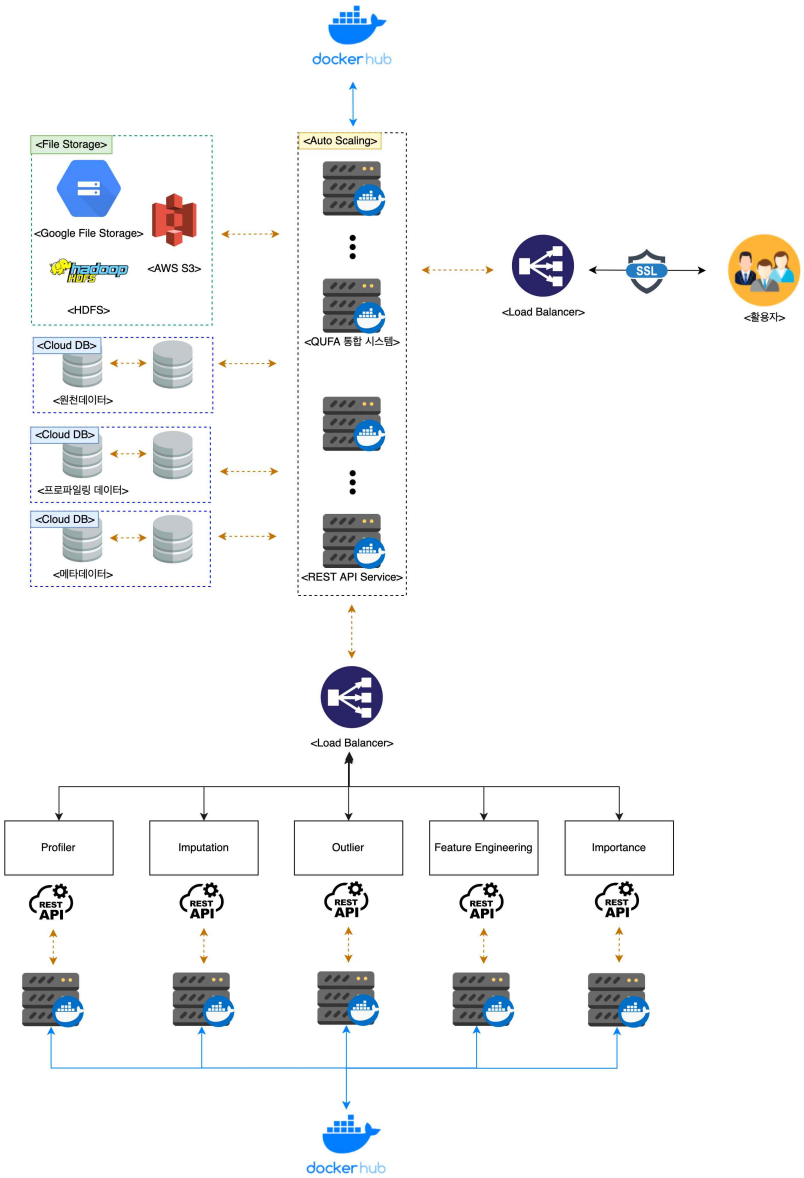

[그림 58] 품질 개선 통합 솔루션 Technical Architecture

✓ 품질 현황 디스플레이

- 프로젝트 단계별 품질 현황을 디스플레이 하는 기능 구현.

▪ 데이터 품질 도구에서의 데이터 프로파일링 자동 수행 구현

✓ 메타데이터 자동 추출

- 품질 분석 및 개선 대상 데이터 파일을 원천 데이터 클라우드 DB에 적재하고, 메타데이터를 자동으로 추출하여 메타데이터 저장을 위한 전용 클라우드 DB에 별도로 저장·관리함.

✓ 프로파일링 자동 수행

- 저장된 원천 데이터 클라우드 DB와 메타데이터 pair를 사용하여 프로파일링 API를 호출하여 프로파일링을 자동 수행하고 프로파일링 결과를 데이터베이스에 저장하여 관리.

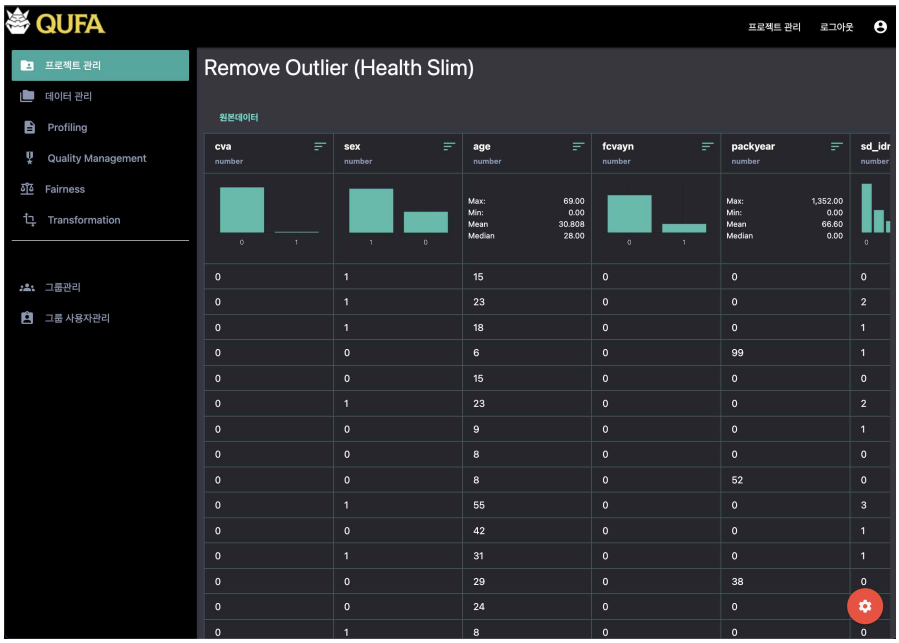

[그림 59] 프로파일링 자동수행 결과 사용자 화면

■ 데이터 오류 보정 도구 설계 및 개발

▪ 오류 보정 도구 기능 분석

✓ 품질 개선을 위한 오류 보정 도구 기능 분석

- 데이터 품질관리 및 개선을 위한 오류 보정 관련 기능들을 분석함.

✓ 오류 보정 기능 설계 및 개발

- 데이터 품질관리 및 개선을 위한 오류 보정 관련 기능을 리스트업하고 이를 데이터품질 통합 솔루션 메뉴에 반영하여 설계함.

대메뉴	중메뉴	소메뉴
Data Profiling (데이터 프로파일링)	Batch Profiling	N/A
	Basic Profiling	N/A
	Number Profiling	N/A
	String Profiling	N/A
	Date Profiling	N/A
Quality Management (품질관리)	Quality Improvement (품질개선)	Missing Value Imputation (결측치 대치)
		Outliner Detection (이상치 탐색)
		Feature Engineering (특징 공학)
	Fairness	Fairness Execution (공정성 보정실행)

	(공정성)	Fairness Visualization (공정성 결과시각화)
Data Transformation (데이터 변환)	Encoding (인코딩)	Label Encoding (레이블 인코딩)
		One-Hot Encoding (원핫 인코딩)
	Scaling (범위변환)	Standarization (표준화)
		Normalization (정규화)
		Regularization (균일화)
	Categorization (범주화)	Discretization (이산형화)
		Binarization (이항변수화)
	Dimension reduction(차원축소)	Principal Component Analysis (주성분분석)
		Factor Analysis (요인분석)

■ 데이터 품질 개선 솔루션 통합

▪ 데이터 품질 개선 솔루션 API 기반 통합 구현

✓ 데이터프로파일링 기능 통합

- 데이터 품질 개선 솔루션 통합을 위한 TA(Technical Architecture)를 수립함.
- 클라우드 기반의 빅데이터 프래임워크를 적용하고 docker 이미지를 활용하여 데이터프로파일링, 품질 분석 및 개선 기능, 특징공학 기능을 통합.
- 각각을 별도로 docker image pull 형태로 손쉽게 설치하고 실행해볼 수 있도록 하는 오픈소스 환경의 실질적인 de facto standard 형태의 검증된 best practice 환경으로 구성.
- 데이터 프로파일링 기능을 RestAPI 형태로 연계·통합하고 load balancer를 통하여 프로파일링 결과를 클라우드 DB에 저장하며, 각 기능 통합 시 RestAPI 명세는 실질적인 de facto standard인 swagger를 사용함으로써 독립성과 향후 확장성을 동시에 보장.

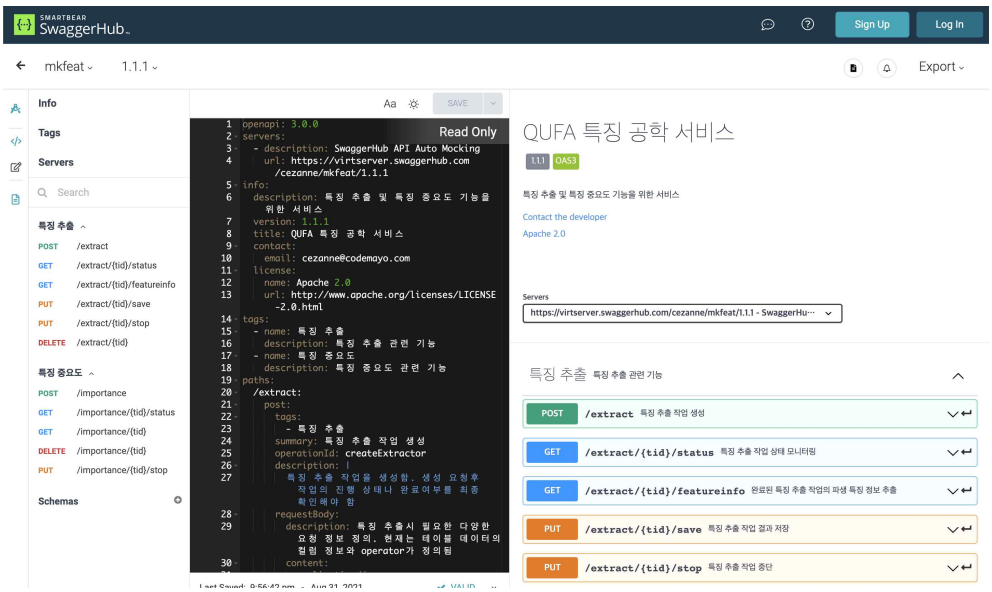

[그림 60] 기능 통합을 위한 Swagger API 명세 사례

✓ 데이터품질 분석 및 개선 기능 통합

- 데이터 품질분석을 통한 결측치 및 이상치 탐지 결과를 분석하고 이를 대체 및 제거하는 기능을 RestAPI 형태로 연계·통합하고 원천 데이터와 품질 개선된 데이터를 클라우드 DB에 저장.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

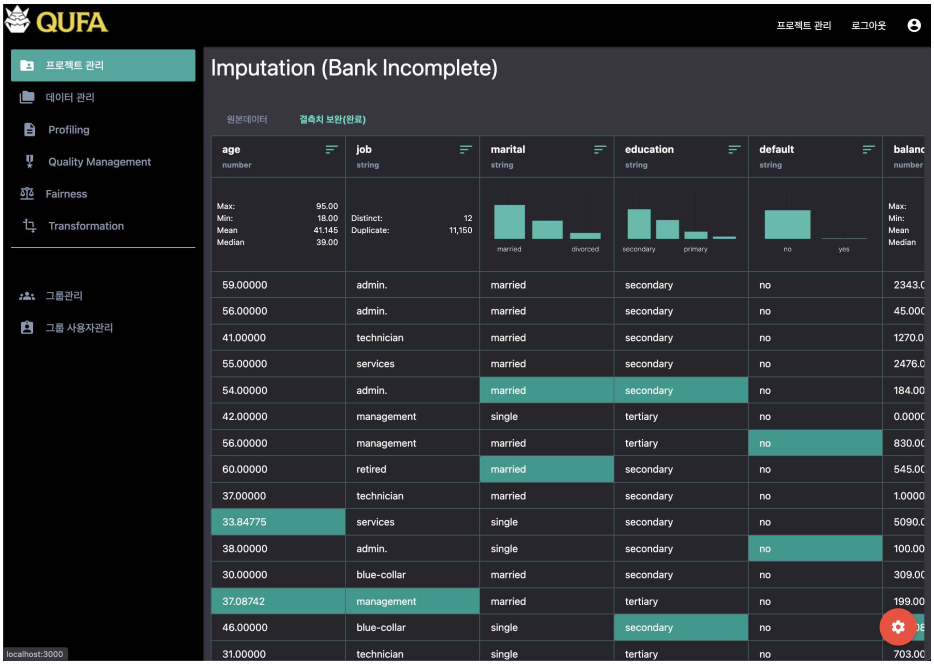

[그림 61] 데이터 품질 개선 결측치 대체 화면

✓ 특징공학 기능 통합

- 특징공학 기능을 RestAPI 형태로 연계·통합하고 특징 공학을 통하여 신규로 생성된 컬럼에 대한 프로파일링을 자동 수행하고 결과를 클라우드 DB에 저장.
- 특징공학 수행 시, 컬럼의 중요도를 시각화하여 사용자에게 제공함으로써, 특징공학 수행 결과의 직관적인 설명이 가능.

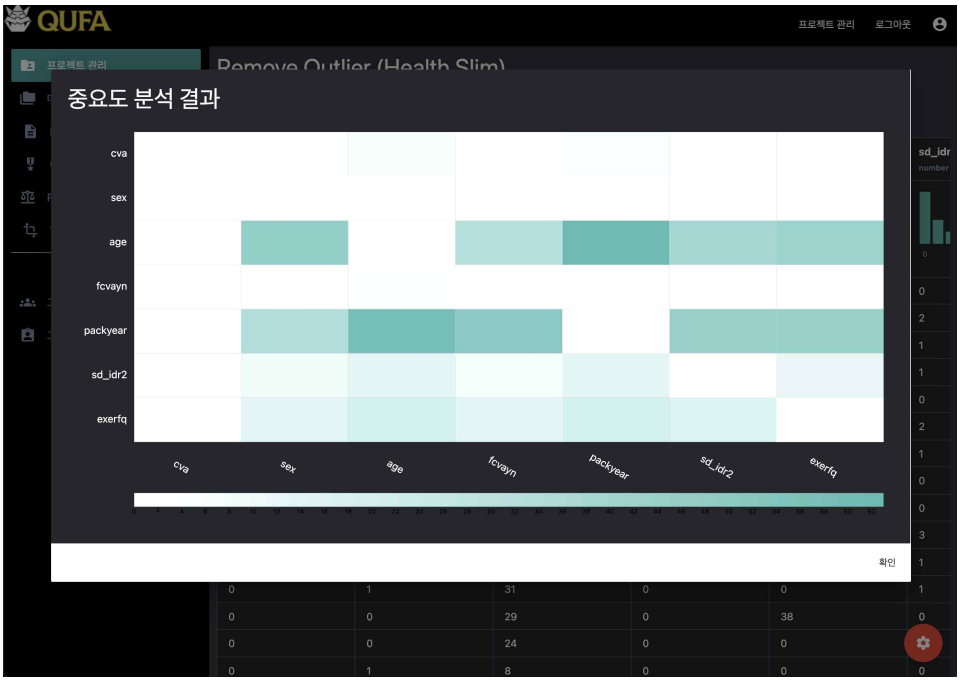

[그림 62] 특징공학 수행 중요도 분석 결과 화면

✓ 공정성 보정 및 시각화 기능 통합

- 데이터 공정성 보정 결과를 시각화하는 기능을 sunburst 챠트 형태로 visualization 하여 공정성 보정 이전과 이후를 비교할 수 있도록 구현.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그림 63] 공정성 보정 이전 이후 비교 sunburst chart 시각화

[아이소프트]

■ 공정성 분석기 도구개발

▪ 웹기반(장고) 인공지능 학습 데이터 처리 구현

개발환경	개발자	서버 셋팅
OS	Win 10	Ubuntu
개발툴	Visual studio code	-
개발 언어	Python / html+ javascript	Python
웹서비스 프레임워크	Django	Django
딥러닝 라이브러리	sklearn	sklearn

✓ 개발 프로젝트 폴더 구조 및 설명

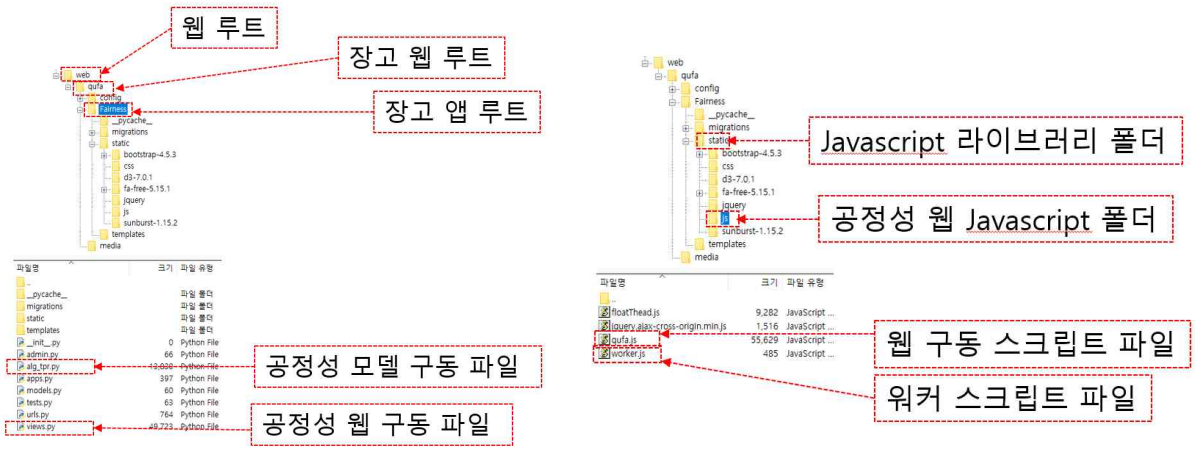

- 공정성 가시화 서비스를 위한 웹서버를 부산대학교에 구축

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

▪ 검증 모델 선택 및 파일 로딩기능

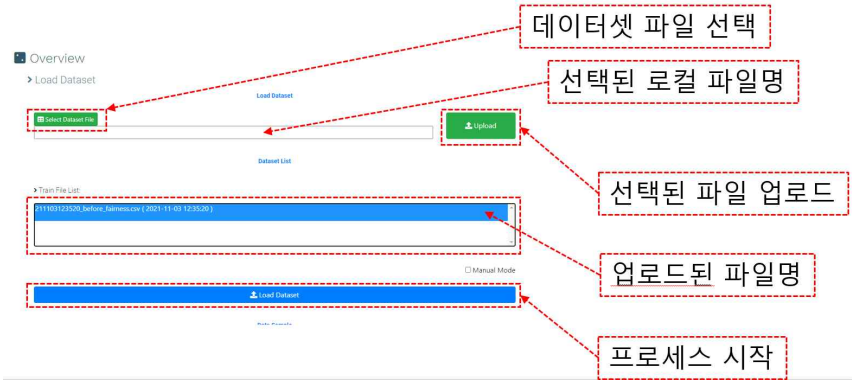

▪ 데이터 구조분석 가시화 기능모듈 개발

✓ 보정 전/후 데이터 오버뷰 기능

✓ 보정 전/후 컬럼 별 유니크 별 데이터 분포 차트

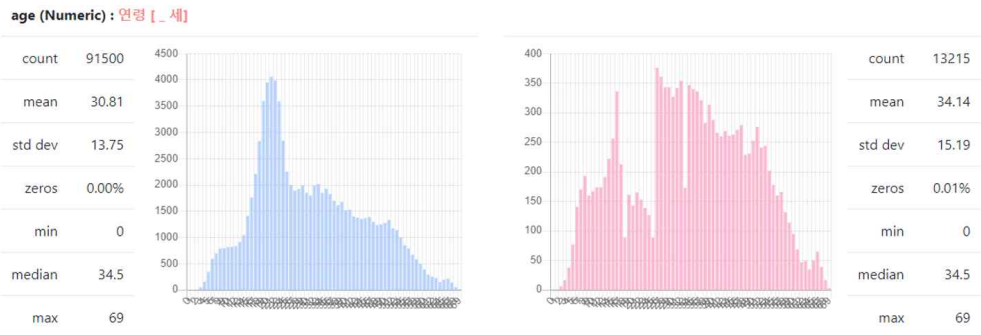

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 보정 전/후 데이터 오버뷰 (해당 컬럼의 [개수/평균/표준편차/0의수/중앙/최대])
✓ 컬럼명 및 설명

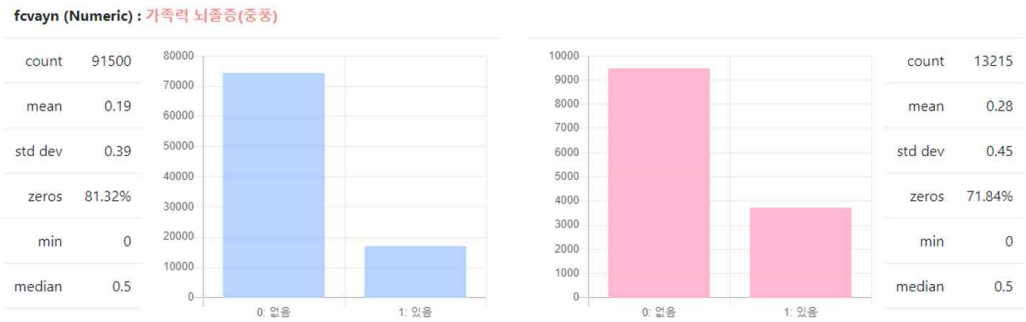

- 데이터 검증모듈 탑재
  ✓ 검증 모델 선택(이진 분류 [균등기회/균등승률/인구통계패리티])
  ✓ 선택된 검증 모델에 대한 설명

- 데이터 공정성 보정 알고리즘 연동
  ✓ 파라미터 설정 (ML Model:[Logistic Regression/SGD Classifier/Linear SVC])
  ✓ 보정 전/후 예측수치 표시
  ✓ Group 별 TPR 등 수치 표시
  ✓ Group 별 Confusion Matrix 히트맵

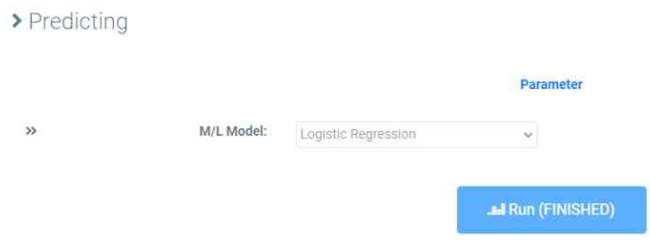

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

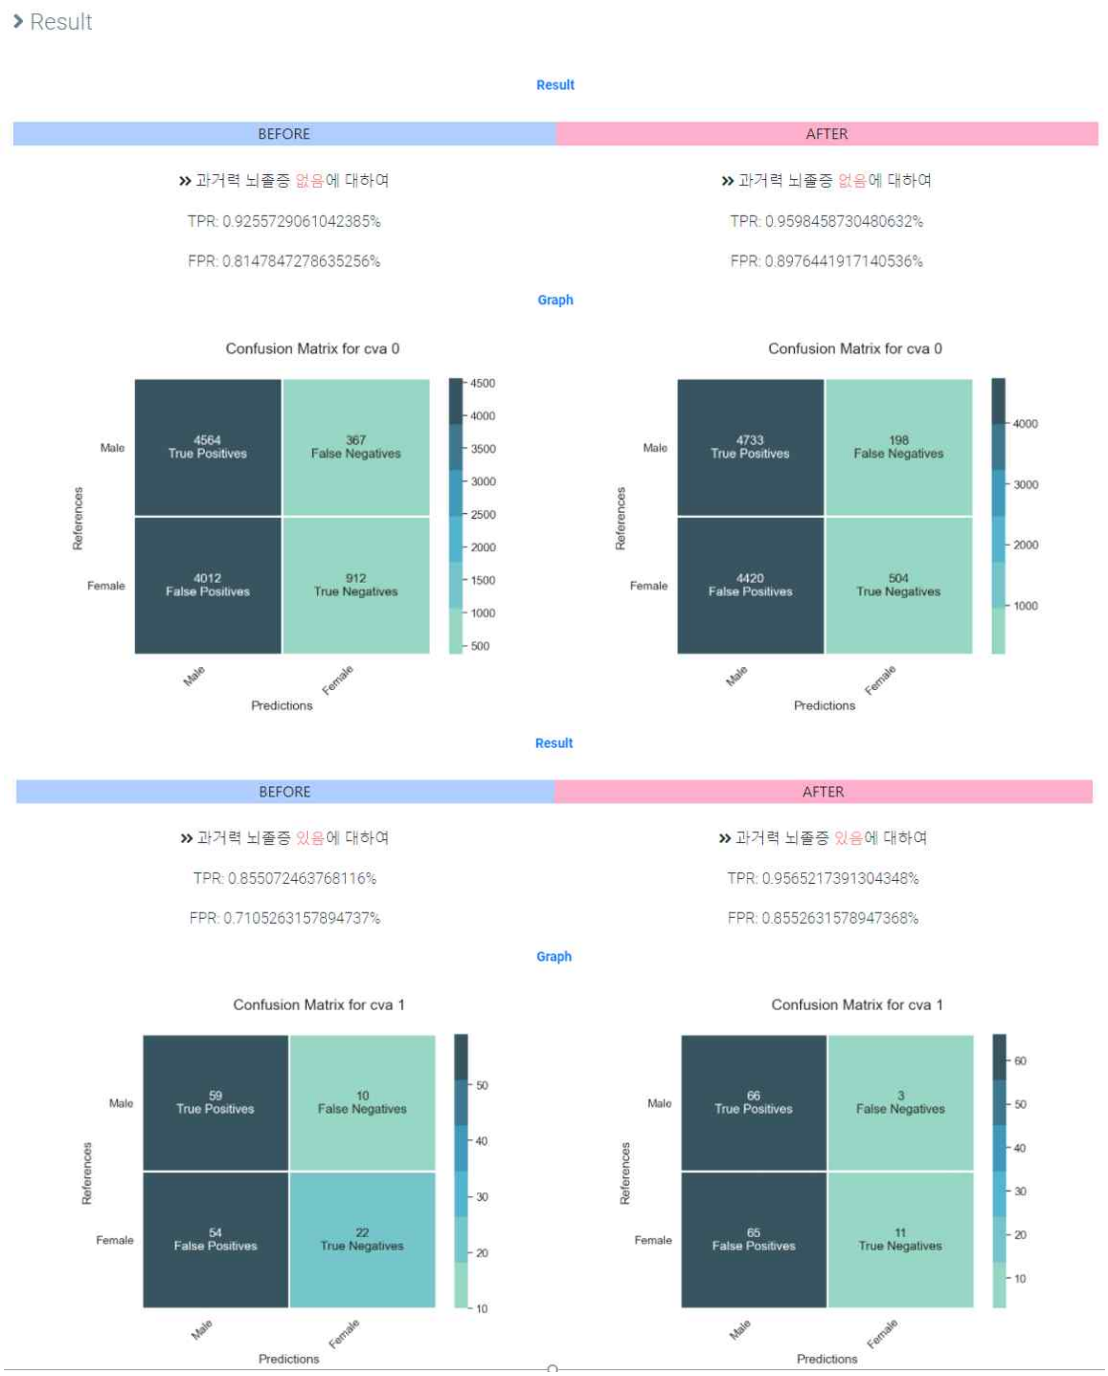

■ 데이터 패턴 시각화 도구 개발

- 자바스크립트를 이용한 교통 및 의료 데이터 구조 가시화(sunburst) 기능 모듈 설계 및 구현

✓ 파라미터 지정

- Classification Column : 기준 컬럼 지정
- Classification Labels : CM 히트맵 라벨
- Sub Group Column : 서브 그룹 지정

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

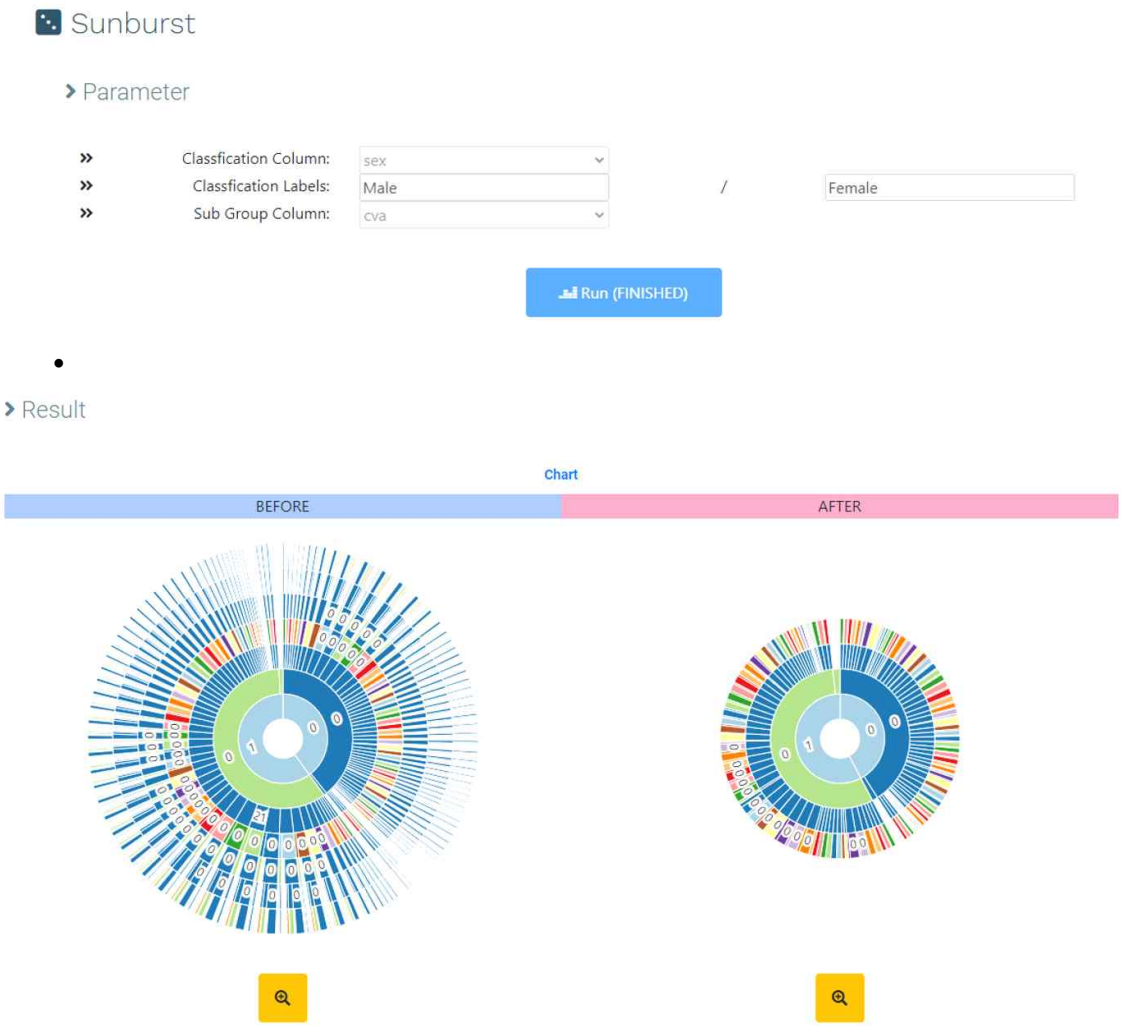

- t-SNE 및 UMAP 차트 구현

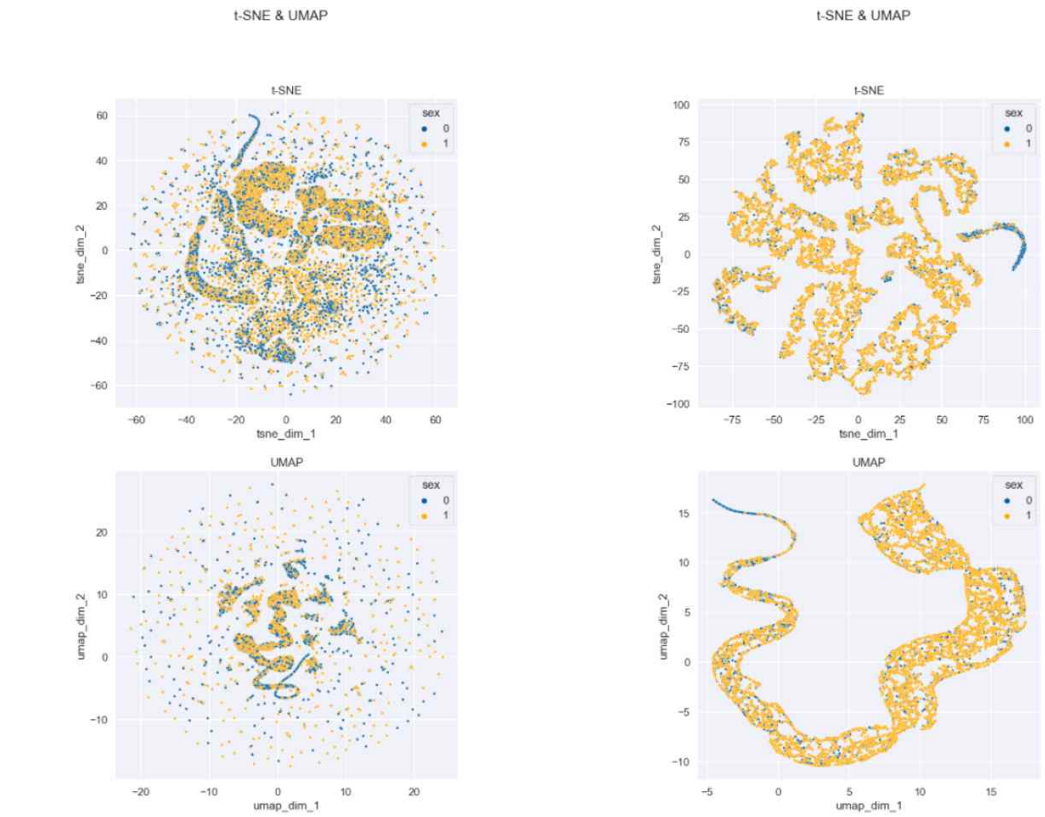

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 공정성 데이터의 직관적 가시화를 위한 차트 개발
  - ✓ 검증 모델 별 예측 차 표시 차트
  - ✓ 검증 모델 별 보정 성능 수치 표시
  - ✓ 보정률 계산 수식 표시

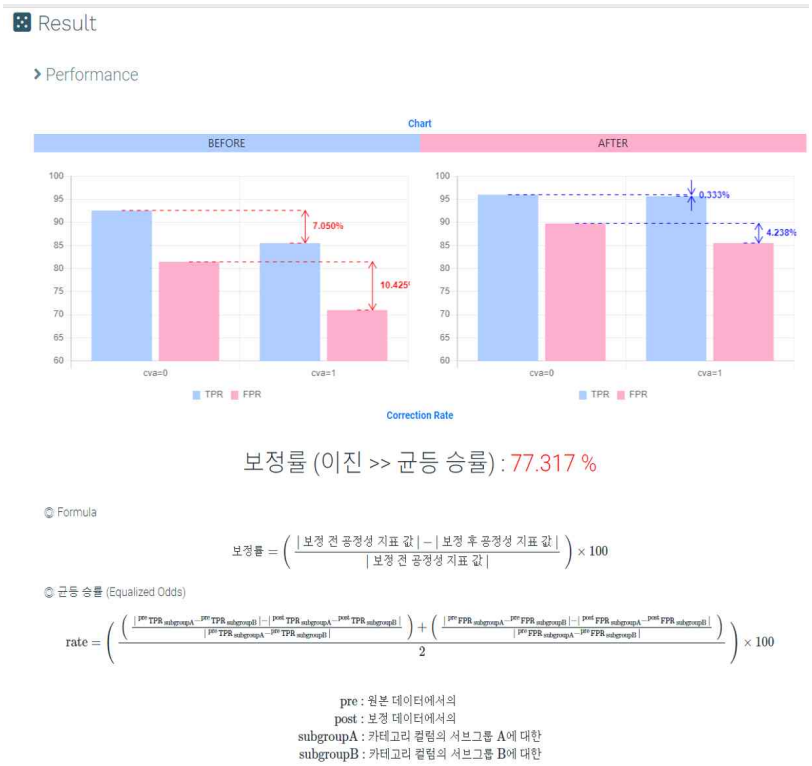

■ 공정성 도구 통합

- 공정성 가시화 통합 UI/UX 개발
  - ✓ Traffic 데이터 & Health 데이터 분석 가시화 통합 디자인

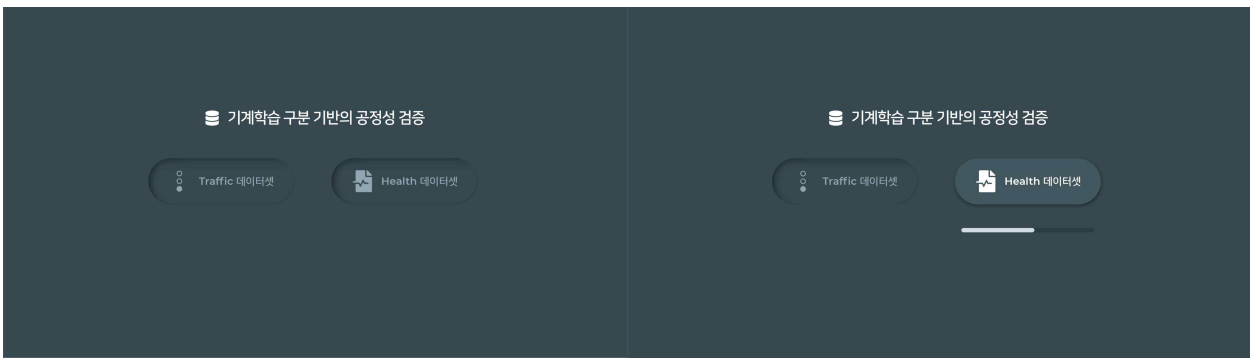

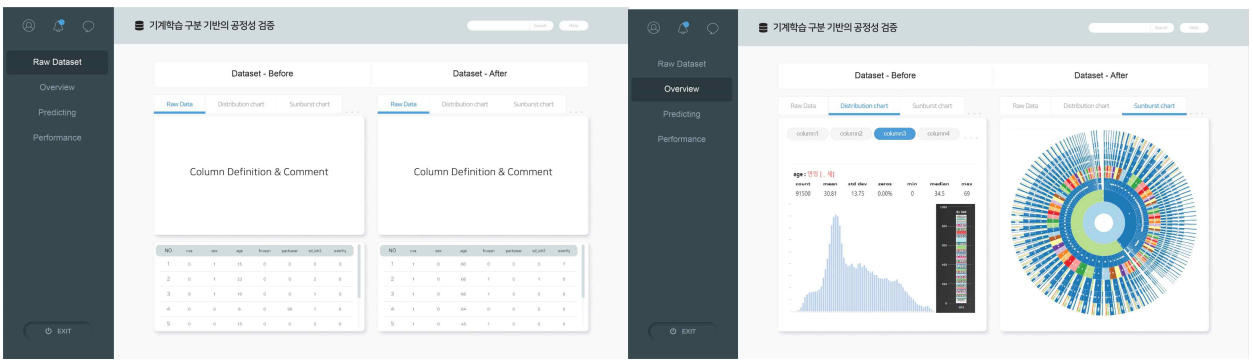

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

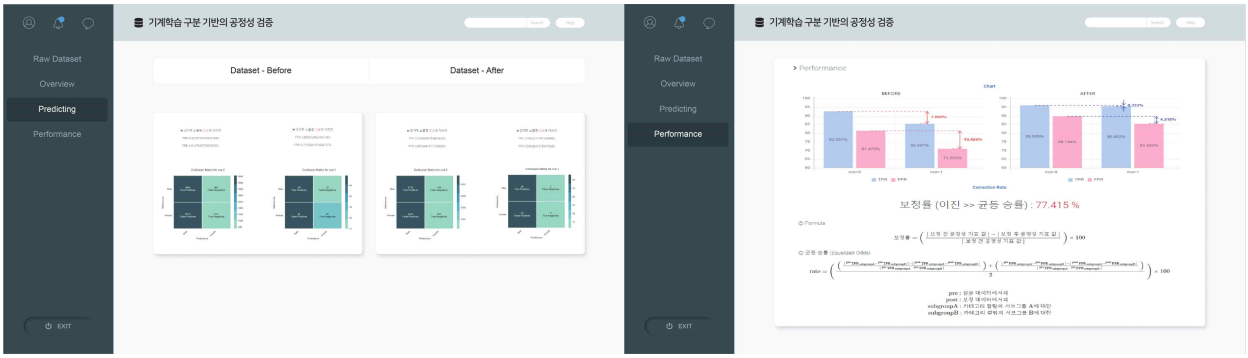

✓ 공정성 진단 도구와 데이터 패턴 시각화 도구의 통합

views.py	getkey	세션 키 생성 및 반환
	upload	선택된 파일을 서버에 업로드
	getcount	세션 별 업로드 된 파일의 수 반환
	getlist	세션 별 업로드 된 파일 리스트 반환
	loading	업로드된 파일 로딩
	overview	로딩된 파일의 데이터 파싱 및 오버뷰 데이터 생성
	sunburst	데이터 선버스트 데이터 생성
	isrunning	알고리즘 동작 중 확인
	getresult	결과 데이터 계산 및 반환
alg_tpr.py	run_alg	데이터 예측 및 TPR 등 수치 추출

[주요 클래스 정의 및 함수]

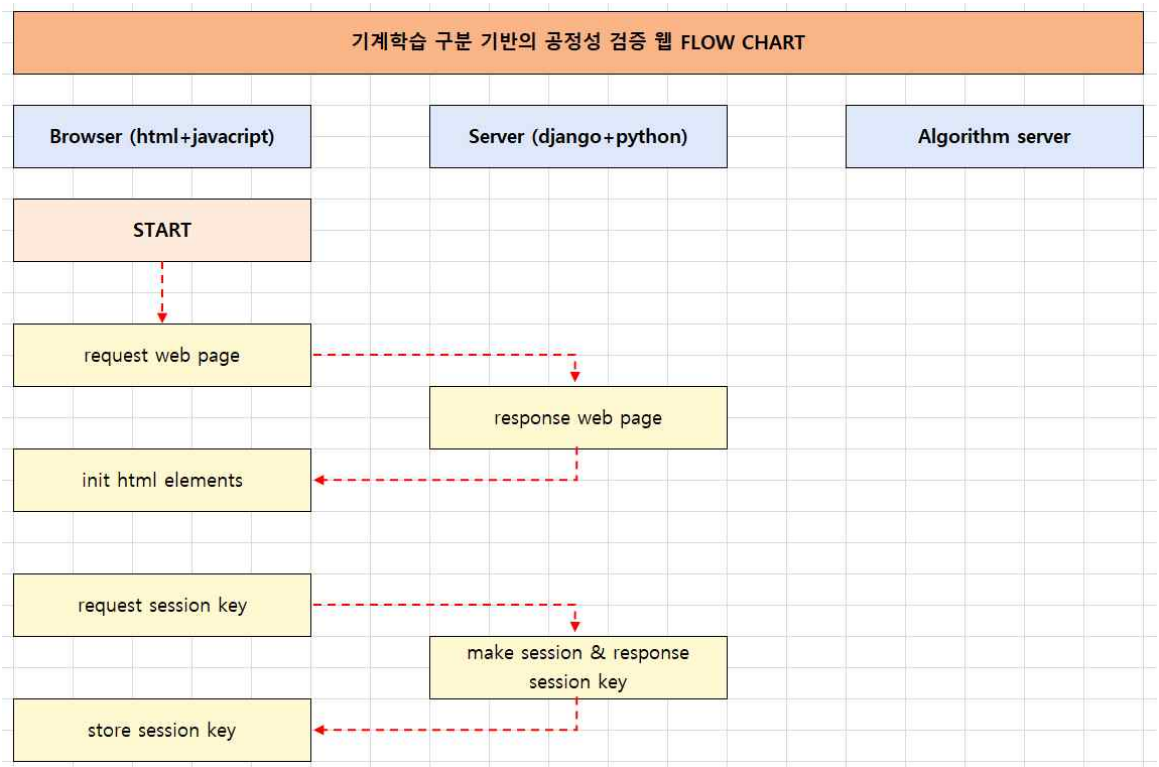

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

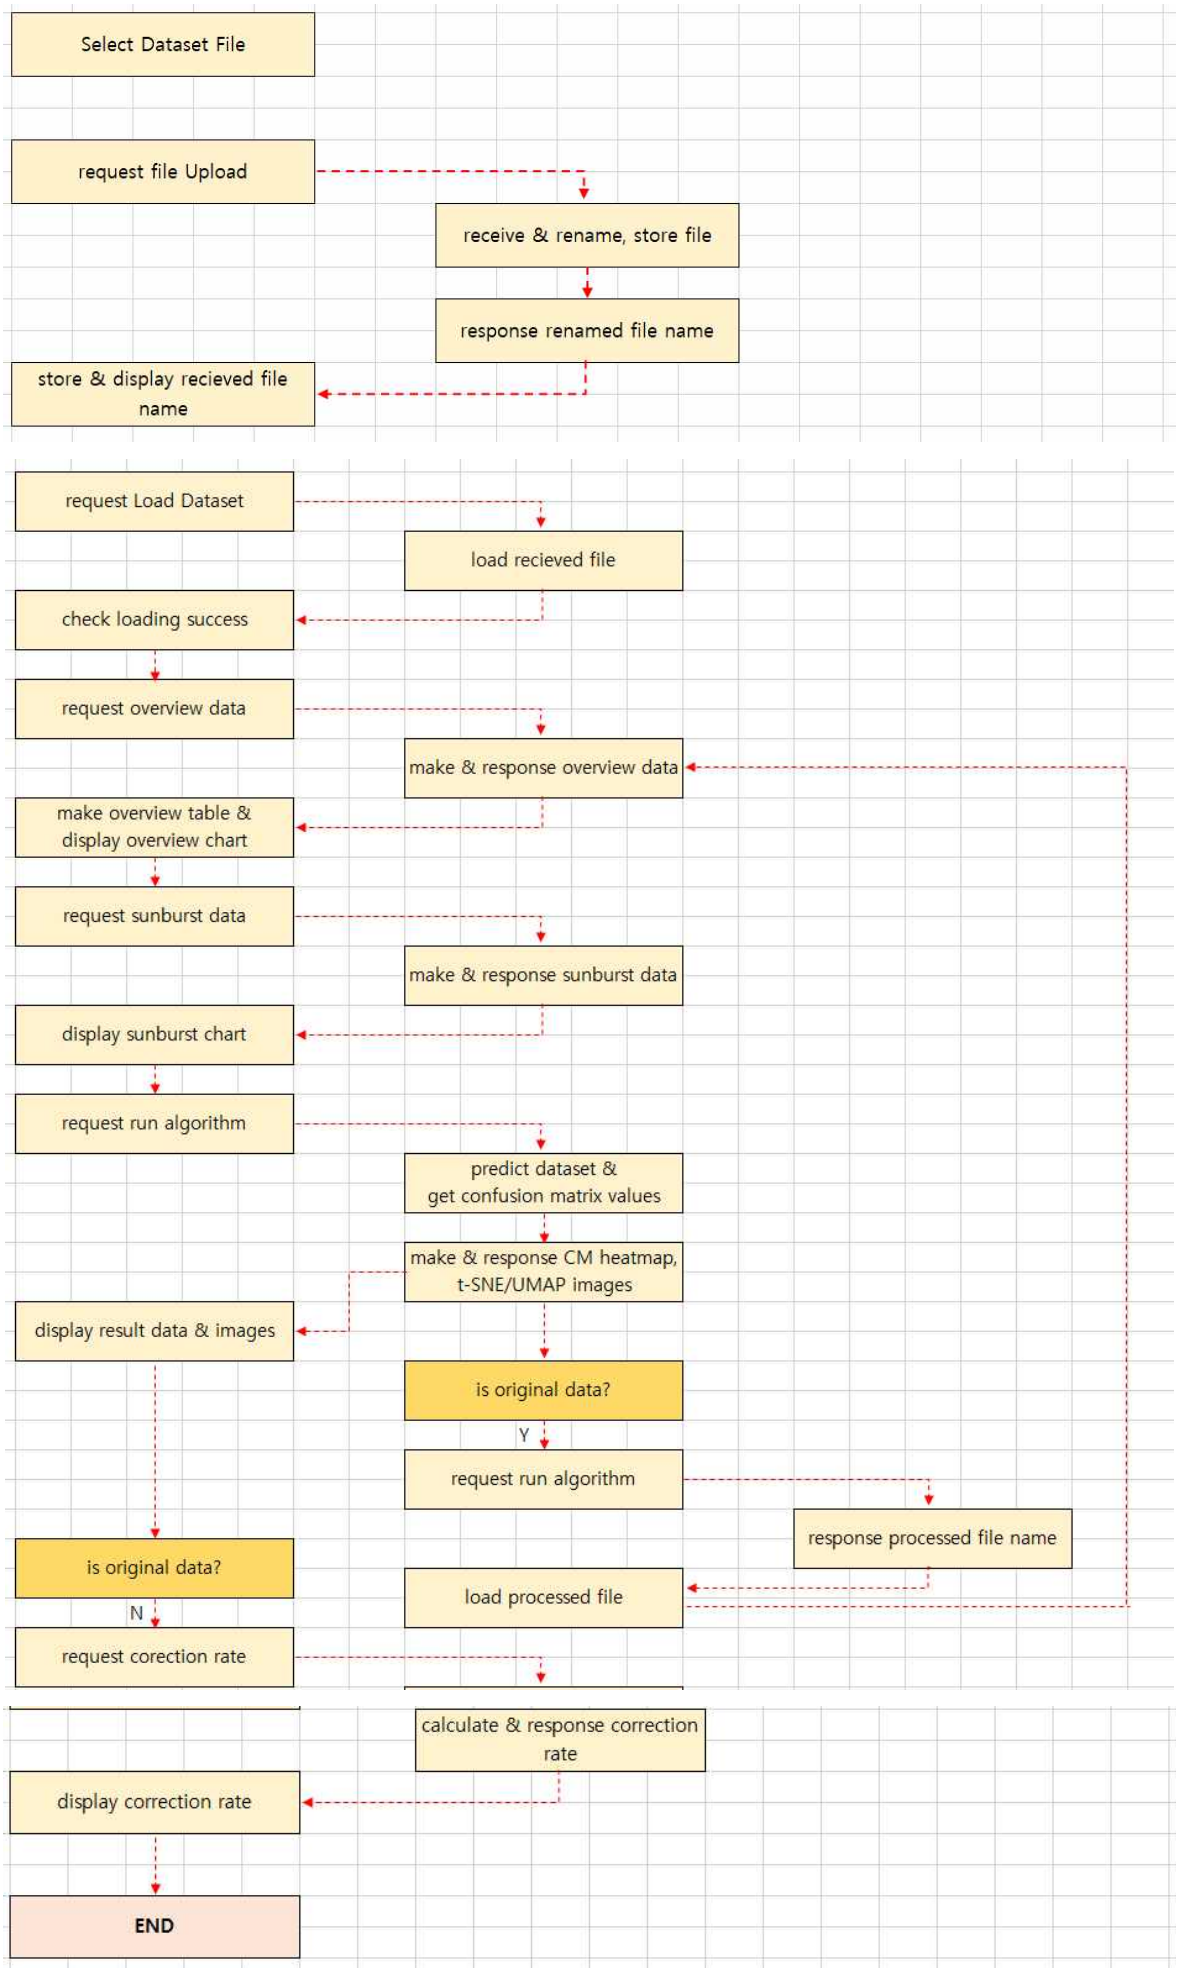

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 공정성 개선 웹 연동 API 정의

공정성 개선 웹 연동 API 정의

	api url	param	return	comment
0	http://164.125.37.214:8000/Fairness/getkey/	NONE	'success', 'key'	POST / api 요청 시 필요한 키 값 반환
1	http://164.125.37.214:8000/Fairness/upload/	key', ''url'	'success', 'filename'	POST / 파일 업로드 (to 공정성 웹서버)
2	http://164.125.37.214:8000/Fairness/run/	key', 'filename'	'success'	POST / 공정성 개선 프로세스 구동 시작
3	http://164.125.37.214:8000/Fairness/isrunning/	key'	'success', 'running'	POST / 공정성 개선 프로세스 구동 유/무 반환
4	http://164.125.37.214:8001/Fairness/sunburst/	key'	'success', 'data[]'	POST / Sunburst Chart 구성을 위한 데이터 반환
5	http://164.125.37.214:8000/Fairness/getresult/	key'	'success', 'result{}'	POST / 공정성 개선율 및 Confusion Matrix의 HeatMap 구성을 위한 데이터 반환

* 순서 : 0 -> 1 -> 2 -> '4 and or 5'

API 파라미터 정의

api name		input param				output param			
		name		value	comment	name		value	comment
0	getkey	NONE				0	'success'	'true' / 'false'	JSON
						1	'key'	32자리 문자열	
1	upload	0	'key'	(string)	api 0번 'getkey'로 받은 값	0	'success'	'true' / 'false'	JSON
		1	'url'	file url	JSON / 파일 url	1	filename'	(string)	
2	run	0	'key'	(string)	api 0번 'getkey'로 받은 값	0	'success'	'true' / 'false'	JSON
		1	'filename'	uploaded file name	JSON / upload의 리턴 값으로 받은 파일명				
3	isrunning	0	'key'	(string)	api 0번 'getkey'로 받은 값	0	'success'	'true' / 'false'	JSON
						1	'running'	'true' / 'false'	
4	sunburst	0	'key'	(string)	api 0번 'getkey'로 받은 값	0	'success'	'true' / 'false'	JSON / 아래 항목 참조
						1	'data'	[{}, {}]	
5	getresult	0	'key'	(string)	api 0번 'getkey'로 받은 값	0	'success'	'true' / 'false'	JSON / 아래 항목 참조
						1	'data'	{}	

'getresult' - 'data' JSON

JSON 구조					comment
'data':					결과값
	'corrate'	[{}, {}, {}, {}, {}]			공정성 개선율 (총 5개 / 이진분류[균등기회,균등승률,인구통계], 회귀분류[2개 미구현])
			key':	(string)	상기 분류 및 지표에 대한 키
			name':	(string)	상기 분류 및 지표에 대한 이름
			'rate':	(string)	공성성 개선율
	'heatmap':	[2][{}, {}]			컨퓨전 매트릭스 히트맵 구성을 위한 값 (총 2x2개 / 보정전 A,B / 보정후 A,B)
			'title':	(string)	컨퓨전 매트릭스 히트맵 타이틀
			'axislable':	['Predictions', 'References']	x/y축 별 라벨 (고정값)
			'ticklable':	[]	x/y축 별 틱 라벨 (2개, x/y 축 동일)
			'axisvalue'	{}	confusion matrix 값 (4개)
	'htmlimg':	[2]["","",""]			PNG 이미지 태그 (총 2x3개 / 보정 전,후의 0: ConfusionMatrix A, 1: CM B, 2: t-SNE&UMAP)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(5) 2단계 1차년도 – 통합, 고도화, 검증 및 실증

[그림 64] 2단계 1차년도 기관별 연구개발 내용 및 산출물

가) 2단계 1차년도 기관별 개발 목표

수행기관	개발목표
주관기관 (부산대학교)	▪ 점증적 데이터 셋 보정 기술 개발 및 고도화 ▪ 공정성 보정 기술 통합 ▪ 빅데이터 플랫폼 연계 통합 관리
공동연구기관 1 (서울대학교)	▪ 보건데이터의 공정성 평가 자동화 ▪ 데이터 시각화 API 고도화
공동연구기관 2 (서울시립대학교)	▪ 비정형 데이터 품질 개선 기술 개발 ▪ AI기반 품질 개선 기술 개발
공동연구기관 3 (이화여자대학교)	▪ AI기반 오류 탐지 기술 고도화 ▪ AI기반 오류 보정 기술 개발
공동연구기관 4 (한성대학교)	▪ 메타데이터 검색 및 활용 기술 개발
공동연구기관 5 / 수요기업 (아이소프트)	▪ 공정성 도구 고도화 및 통합 ▪ 빅데이터 플랫폼 연계 검증
공동연구기관 6 / 수요기업 (프람트테크놀로지)	▪ 데이터 품질 개선 솔루션 통합 및 고도화 ▪ 데이터 맵 기술 개발

나) 2단계 1차년도 연구개발 세부 내용

[부산대학교]

■ 점증적 데이터 셋 보정 기술 개발 및 고도화

▪ 점증적 데이터 셋을 위한 람다 기반 아키텍처 구축

✓ Kafka. Spark 기반 람다 아키텍처 구축

• 논리 설계에 따른 동작 시나리오

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

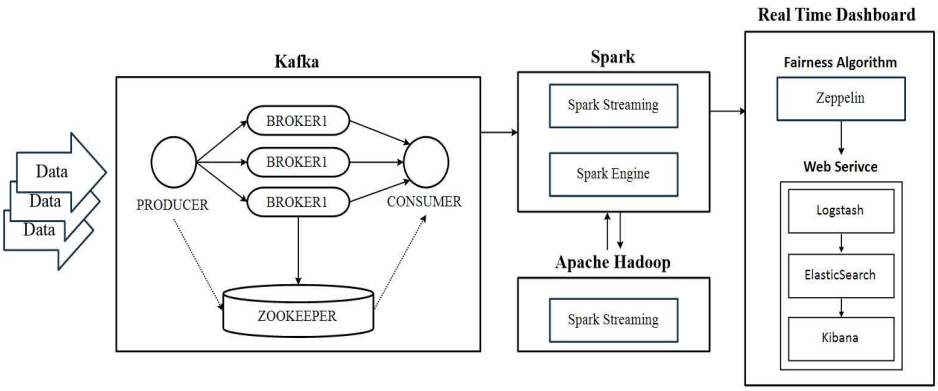

[그림 65] 전체 아키텍처 (람다 아키텍처)

✓ 람다 아키텍처 내 점층적 데이터 셋 편향 보정 알고리즘 구축

- 논리 설계에 따른 동작 시나리오

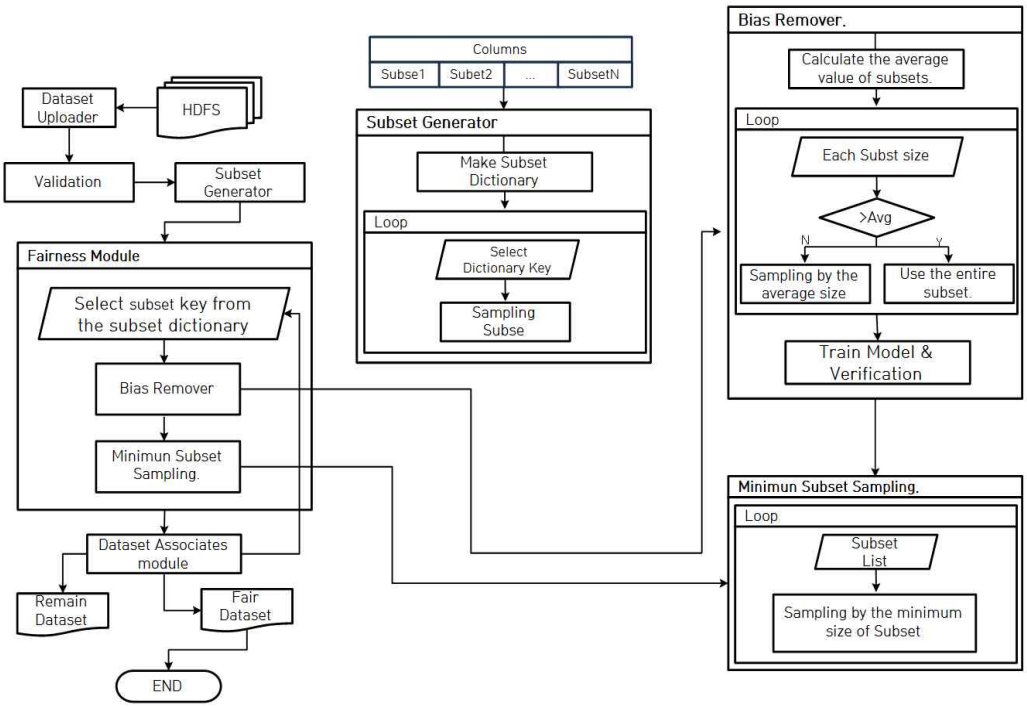

[그림 66] 람다 아키텍처 내 알고리즘 구조도

▪ 점층적 데이터 셋의 편향 검증 및 보정

✓ 데이터 셋 내 고윳값 기준 서브셋 생성

- 논리 설계에 따른 동작 시나리오

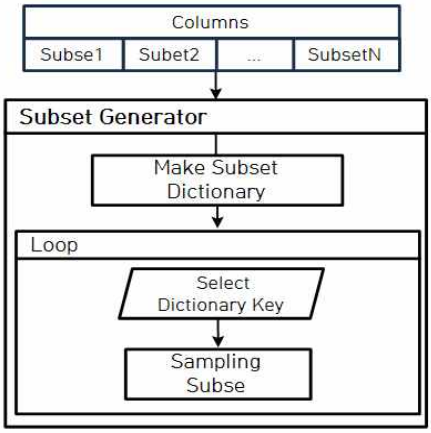

[그림 67] 서브셋 생성기 구조도

✓ 서브셋 기반 샘플링 및 편향 보정

• 논리 설계에 따른 동작 시나리오

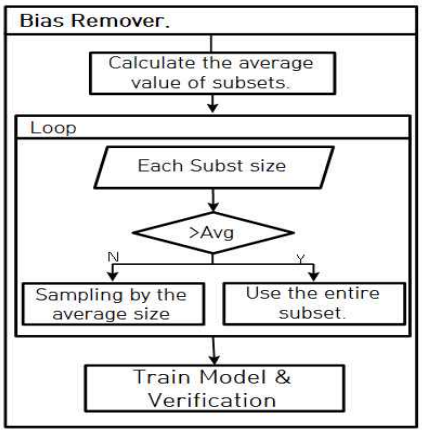

[그림 68] 편향 제거기 구조도

✓ 최솟값 기반 서브셋 샘플링 및 편향 보정

• 논리 설계에 따른 동작 시나리오

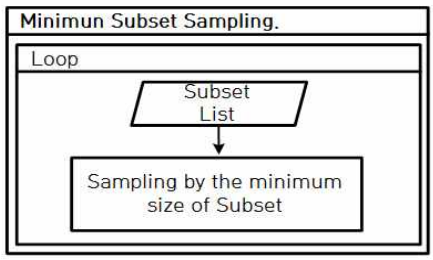

[그림 69] 최소 샘플링 구조도

▪ 점층적 데이터 셋의 편향 제거를 위한 람다 아키텍처 및 공정성 보정기 구현

✓ 점층적 데이터 셋의 편향 검증 및 보정

• 점층적 데이터 셋 기반 서브셋 생성기

– 서브셋 생성기에서는 분리된 부분 집합의 크기가 서브셋으로 나누기에 너무 작지 않도록 자질선별 수행

– 선택된 특성의 고윳값을 기반으로 고윳값 사전이 생성되고, 사전의 값에 따라 데이터를 분리하여 서브셋 생성하여 저장

• 주요 소스코드

```
def make_subset(data, target, uniq_list, group_list) :
    result_list=[]
    for tg in data[target].unique() :
        df_list=dict()
        for tr in uniq_list :
            tmp = data[data[target]==tg].copy()
            for col, uniq in zip(group_list, tr)  :
                tmp=tmp[tmp[col]==uniq].copy()
            df_list[tr]=tmp
        result_list.append(df_list)
    return result_list
```

[그림 70] 서브셋 생성기 알고리즘 코드

• 서브셋 기반 점층적 데이터셋의 편향 검증 및 보정

– 편향 제거기는 서브셋은 레이블과 민감한 속성으로 분리하며, 상반되는 민감한 속성

을 가지는 서브셋 쌍을 선택하여 입력

- 서브셋 쌍 중 크기가 큰 서브셋을 우세 서브셋, 작은 서브셋을 약세 서브셋
- 서브셋 간의 평균값을 구하고 우세 서브셋에서 평균값만큼 샘플링
- 약세 서브셋은 전체 크기가 평균값보다 클 경우, 평균값으로 샘플링하고 작을 경우, 서브셋 전체를 사용
- 검증은 모델의 학습결과를 공정성 지표를 기반으로 평가하여 초기 데이터 셋 보다 지표 값이 향상되었을 경우 다음 서브셋 쌍으로 진행

• 주요 소스코드

```
for uniq in uniq_list :
    tmp = result_list[0][uniq]

    if len(tmp) >= avg_0 :
        avg_sample=tmp.sample(avg_0)
    else :
        avg_sample=tmp.copy()

    df_list[uniq]=avg_sample
    re_list[uniq]=pd.DataFrame()
    result_list[0][uniq].drop(avg_sample.index, inplace=True)

batch_list.append(df_list)
remain_result_list.append(re_list)


for uniq in uniq_list :
    tmp = result_list[1][uniq]

    if len(tmp) >= avg_1 :
        avg_sample=tmp.sample(avg_1)
    else :
        avg_sample=tmp.copy()

    df_list[uniq]=avg_sample
    re_list[uniq]=pd.DataFrame()
    result_list[1][uniq].drop(avg_sample.index, inplace=True)

batch_list.append(df_list)
remain_result_list.append(re_list)
```

[그림 72] 편향 제거기 알고리즘 코드

• 서브셋의 최솟값 기반 점층적 데이터셋의 편향 추가 검증 및 보정

- 최소 샘플링은 편향 제거기를 통해 제거된 데이터 세트를 입력으로 사용 및 배치가 진행됨에 따라 축적
- 남은 데이터셋 내 각 서브셋의 최소 크기가 0보다 클 경우, 최솟값만큼 모든 서브셋에서 샘플링하여 공정성 보정 데이터셋에 추가
- 추가로 샘플링된 데이터 세트는 남은 데이터 세트에서 제거

• 주요 소스코드

```
if min_size > 0 :
    for i in range(len(remain_result_list)) :
        for j in min_list[i] :
            tmp = remain_result_list[i][j].sample(min_size)
            remain_result_list[i][j].drop(tmp.index, inplace=True)
            batch_list[i][j] = pd.concat([batch_list[i][j], tmp])
```

[그림 73] 최소 샘플링 알고리즘 코드

■ 점증적 데이터 셋 보정 기술 고도화

▪ 모조 데이터셋 생성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 반전 데이터 셋 기반 모조 데이터 생성 아키텍처

• 논리 설계에 따른 동작 시나리오

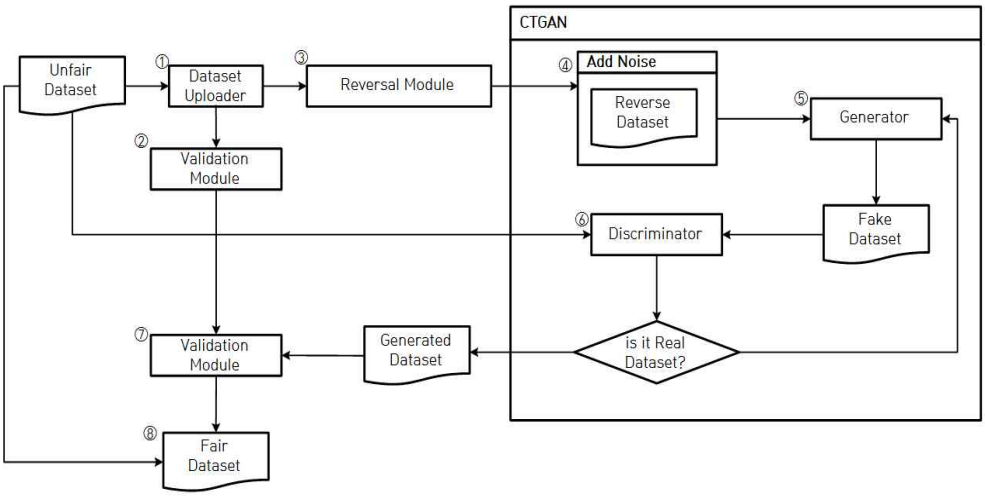

[그림 74] 모조 데이터 생성기 시스템 구조도

✓ 반전 데이터 셋 생성

- 반전 모듈에서는 수집된 초기 데이터를 입력으로 사용
- 초기 데이터의 레이블 및 서브그룹을 반전시켜 레이블 반전 데이터, 서브그룹 반전 데이터, 레이블 및 서브그룹 반전 데이터를 생성
- 모조 데이터 생성 시 초기데이터의 분포를 그대로 사용할 경우 생성된 모조 데이터의 분포 또한 초기 데이터와 유사하므로 편향이 오히려 가중
- 따라서 분포를 완화하기 위함

• 논리 설계에 따른 동작 시나리오

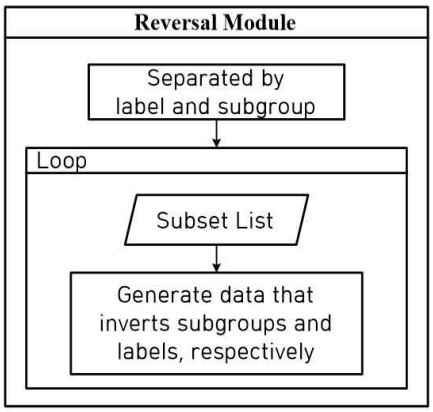

[그림 75] 데이터 반전 모듈 구조도

✓ 반전 데이터 셋 기반 모조 데이터 생성

- 반전 데이터 셋 생성 모듈은 모조 데이터를 생성하는 생성기(Generator)와 생성된 모조 데이터를 검증하는 판별기(Distriminator)로 구성
- 반전 모듈로부터 생성된 반전 데이터셋을 입력으로 사용
- 반전 데이터셋은 CTGAN 내부의 생성기를 학습하는 데 사용
- 생성기를 통해 생성된 모조 데이터는 판별기를 통해 검증
- 반전 데이터는 임의로 생성한 데이터이므로 판별기는 반전 데이터셋이 아닌 초기 데이터셋을 기반으로 하여 검증
- 검증이 끝난 데이터셋은 초기 데이터셋과 결합하여 공정한 데이터셋으로 활용

• 논리 설계에 따른 동작 시나리오

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

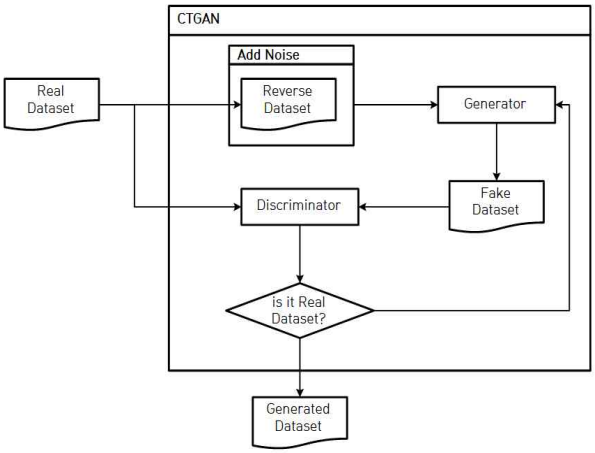

[그림 76] 모조 데이터 생성 모듈 구조도

- 반전 데이터 셋 기반 모조 데이터 생성 실시 예

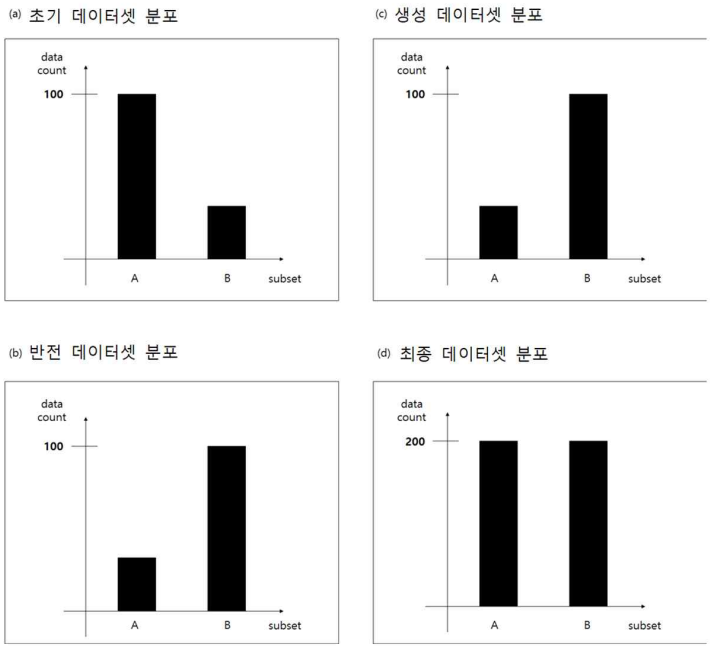

[그림 77] 초기 데이터, 반전 데이터 및 데이터 생성 실시 예

■ 공정성 보정 기술 통합

▪ 공정성 보정 기술 통합 설계 및 구축

✓ 공정성 보정 기술 통합 설계

- 논리 설계에 따른 동작 시나리오

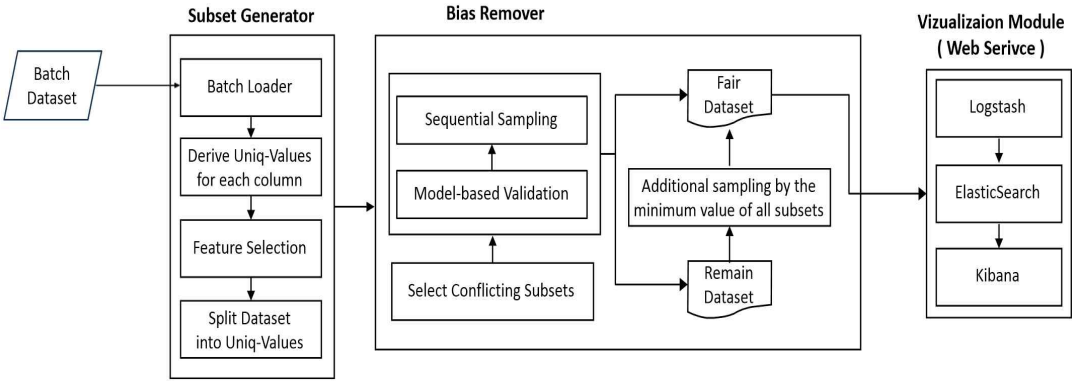

[그림 78] 공정성 보정 기술 통합 시스템 구조도

- 알고리즘 아키텍처

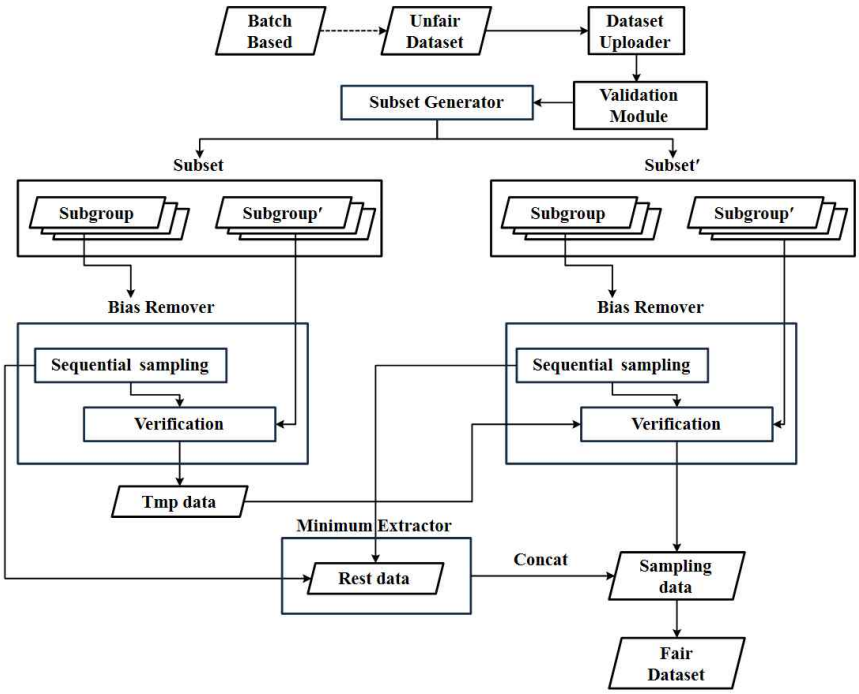

[그림 79] 공정성 보정 기술 통합 알고리즘 구조도

✓ 데이터 셋 내 고윳값 기준 서브셋 생성

- 서브셋 생성기에서는 분리된 부분 집합의 크기가 알고리즘을 진행하기에 너무 작지 않도록 자질선별 수행
- 선택된 특성의 고유값을 기반으로 고유값 사전이 생성되고, 사전의 값에 따라 데이터를 분리하여 서브셋 생성
- 편향 제거 시 하위 특성을 고려하지 않고 데이터를 제거할 경우 특정 값을 가진 일부 데이터 전체를 제거할 수 있어 모델 학습에 악영향을 주는 경우를 방지하는 목적

- 서브셋 사전 및 서브셋 구조

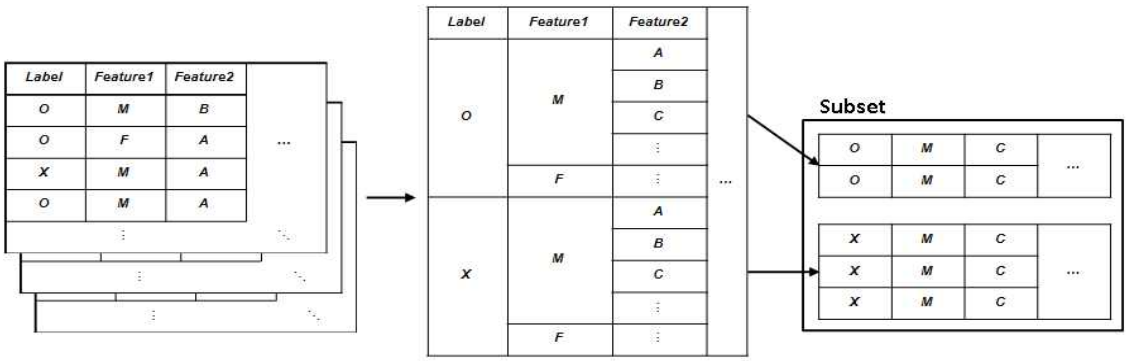

[그림 80] 서브셋 사전 및 서브셋 구조도

✓ 서브셋 기반 편향 제거 및 보정

- 서브셋 생성기로부터 생성된 서브셋 집합을 입력으로 사용
- 서브셋은 레이블과 민감한 속성으로 분리하며, 상반되는 민감한 속성을 가지는 서브셋 쌍을 선택
- 서브셋 쌍 중 크기가 큰 서브셋을 우세 서브셋, 작은 서브셋을 열세 서브셋이라 하며 편향 제거는 우세 서브셋을 대상으로만 진행

- 우세 서브셋에서 내림차순으로 순차적 샘플링을 반복하면서 열세 서브셋과 합쳐 검증 모델을 학습
- 검증은 모델의 학습결과를 공정성 지표를 기반으로 평가하여 초기 데이터 셋보다 지표 값이 향상되었을 경우 다음 서브셋 쌍으로 진행

• 논리 설계에 따른 동작 시나리오

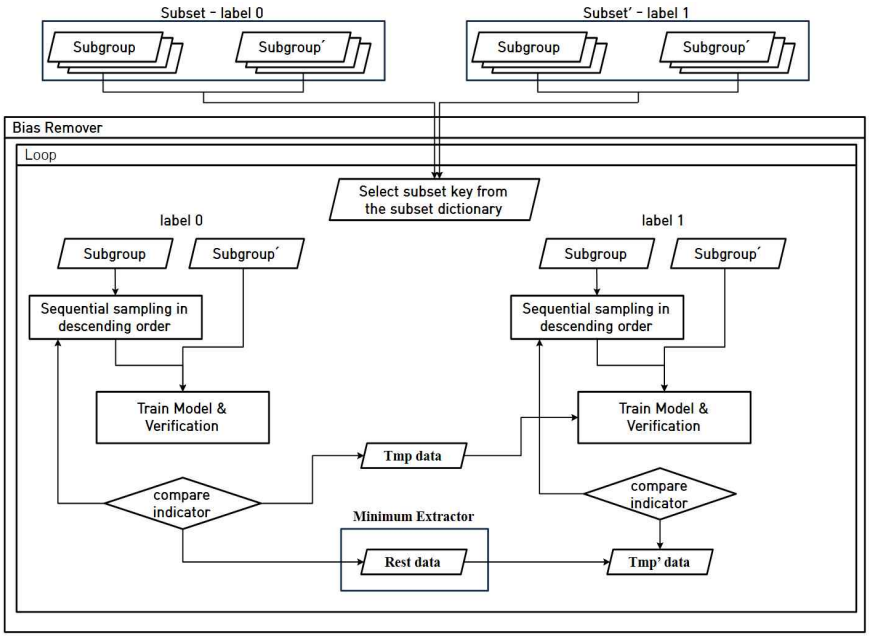

[그림 81] 편향 제거기 구조도

✓ 최솟값 기반 서브셋 샘플링 및 편향 보정

• 논리 설계에 따른 동작 시나리오

- 편향 제거 후 남은 데이터셋을 입력으로 사용
- 남은 데이터셋 내 각 서브그룹 및 서브셋의 최소 크기만큼 모든 서브셋에서 샘플링하여 공정성 보정 데이터셋에 추가

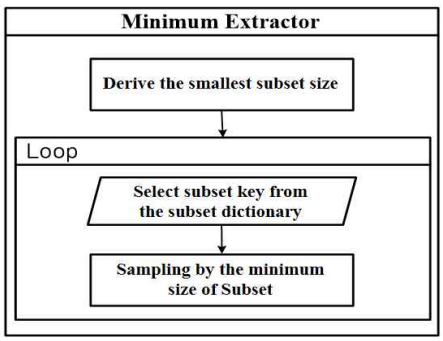

[그림 82] 최소 샘플링 구조도

✓ 배치 처리

- 배치 처리는 배치 기반으로 데이터 셋이 입력될 때마다 공정성 보정 기술을 적용
- 공정성 보정이 끝난 잔여 데이터 셋의 경우 다음 배치의 최소 샘플링에 추가하여 사용

• 아키텍처

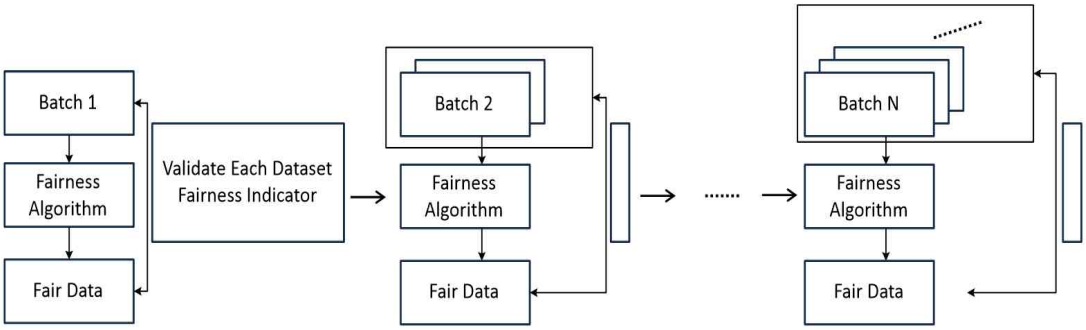

[그림 83] 배치 처리 실시 예

- 실행예시

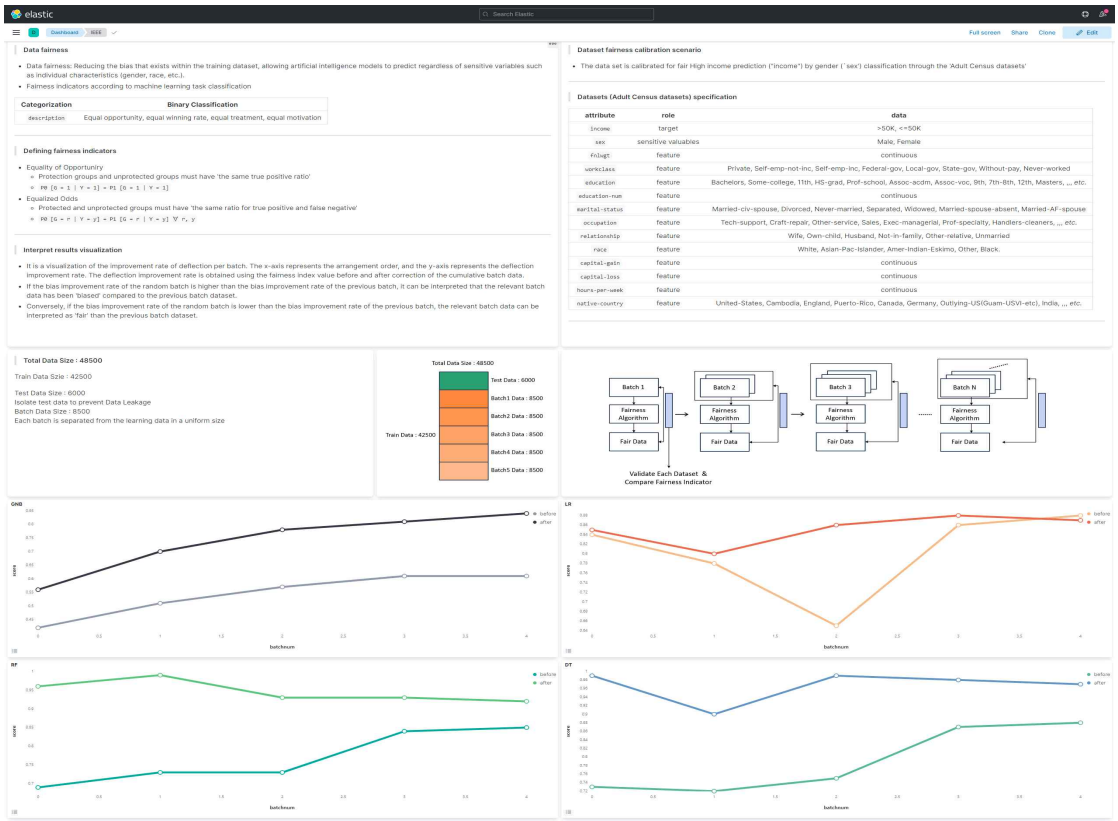

[그림 84] 공정성 보정 기술 통합 모델 시각화

■ 빅데이터 플랫폼 연계 통합 관리

▪ 빅데이터 플랫폼 연계 통합 관리 아키텍처 설계 및 구축

✓ H/W 설계

- 사양

구분	내용
CPU	Intel(R) Xeon(R) Bronze 3204 CPU @ 1.90GHz
Memory	32,395,452 kB
Disk	/dev/sdb: 500.1 GB + /dev/sda: 71997.6 GB
VGA	ASPEED Graphics Family (rev 41)
Ethernet	Intel Corporation I350 Gigabit Network Connection

✓ S/W 설계

- 사양

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	내용
Language	Java
Server	Apache/2.4.6 (CentOS)
Type	REST API
Library	spring-boot-starter, spring-boot-starter-web, spring-boot-devtools, RestController, UUID, Gradle
Response	JSON

- 논리 설계에 따른 동작 시나리오

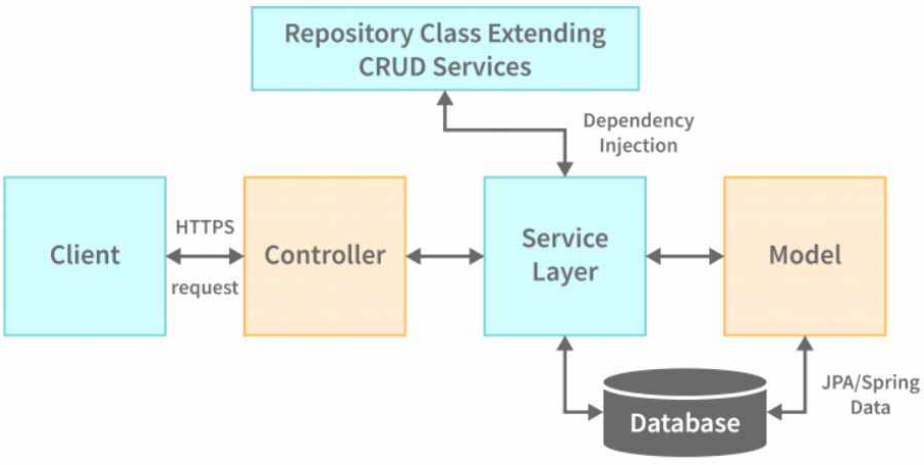

[그림 85] API 정의 및 서버 구조도

▪ 빅데이터 플랫폼 연계 통합 관리 명세

✓ 기능명세

- 구성

경로		명세
/qufa/api/v1	/api1-qufa-2022-0.0.1-SNAPSHOT.jar	메인실행파일, # nohup java -jar apiXXX.jar &
	/api1-qufa-2022-0.0.2-SNAPSHOT.jar	
	/api1-qufa-2022-0.0.3-SNAPSHOT.jar	
	/data/*.csv	보정 전 (원본 & 모조)데이터 및 명세 파일

✓ QuFa Studio API 호출명세

- URI

No	Method	Host	URI	Descrition
1	GET	http://cancerpreventionsnu.kr:3317	/api/v1/cva	알고리즘실행및결과호출 (뇌졸증)
2	GET	http://cancerpreventionsnu.kr:3317	/api/v1/cva_spec	뇌졸증 데이터셋의 명세
3	GET	http://cancerpreventionsnu.kr:3317	/api/v1/heart	알고리즘실행및결과호출 (심장병)
4	GET	http://cancerpreventionsnu.kr:3317	/api/v1/heart_gan	알고리즘실행및결과호출 (심장병 모조데이터)
5	GET	http://cancerpreventionsnu.kr:3317	/api/v1/heart_spec	심장병 데이터셋의 명세

- Request

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

No	URI	Parameter	Name	Type	Optional	Description
1	/api/v1/cva	key	인증키	String	-	API 연동 인증키
2	/api/v1/cva_spec	key	인증키	String	-	API 연동 인증키
3	/api/v1/heart	key	인증키	String	-	API 연동 인증키
4	/api/v1/heart_gan	key	인증키	String	-	API 연동 인증키
5	/api/v1/heart_spec	key	인증키	String	-	API 연동 인증키

- Response

No.	URI	Parameter	Name	Type	보정전/후	Description
1	/api/v1/cva	cva	과거력_뇌졸증	String	보정전	0: 없음 / 1: 있음
		sex	성별			0: 남성 / 1: 여성
		age	연령			_ 세
		fcvayn	가족력_뇌졸증(중풍)			0: 없음 / 1: 있음
		packyear	하루흡연량(갑) * 흡연기간(년)			-
		sd_idr2	일주일에 술을 마시는 횟수			_ 일
		exerfq	일주일간 운동한 총 일수			_ 일
2	/api/v1/cva_spec	name	속성명칭	String	-	cva
		definition	속성정의			과거력_뇌졸증
		description	컴럼 값 설명			0: 없음 / 1: 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3	/api/v1/heart	heart_risk10	심장발병예측	String	보정전	0:심장발병확률 낮음 / 1:심장발병확률 높음
		age	연령대			0:10대 / 1:20대 / 2:30대 / 3:40대 / 4:50대 / 5:60대 / 6:70대 / 7:80대 /
		sex	성별			0:남성 / 1:여성
		htn	심장질환과거력			0:없음 / 1:있음
		fhtnyn	심장질환가족력			0:없음 / 1:있음
		packyear	연평균흡연량			_갑
		sd_idr2	일주일간음주빈도			_회
4	/api/v1/heart_gan	heart_risk10	심장발병예측	String	보정전	0:심장발병확률 낮음 / 1:심장발병확률 높음
		age	연령대			0:10대 / 1:20대 / 2:30대 / 3:40대 / 4:50대 / 5:60대 / 6:70대 / 7:80대 /
		sex	성별			0:남성 / 1:여성
		htn	심장질환과거력			0:없음 / 1:있음
		fhtnyn	심장질환가족력			0:없음 / 1:있음
		packyear	연평균흡연량			_갑
		sd_idr2	일주일간음주빈도			_회
5	/api/v1/heart_spec	name	속성명칭	String	-	htn
		definition	속성정의			심장질환과거력
		description	컴럼값설명			0:없음 / 1:있음

✓ 호출예시

- QuFa Studio API

No.	Name	API	Example
1	알고리즘실행 및 결과호출 (뇌졸증)	Request	http://cancerpreventionsnu.kr:3317/api/v1/cva?key=7F531E98-018F-4B82-80D4-ACE525B1AE11

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		Response	{
			"result": "success",
			"data": [
			[
			"cva",
			"sex",
			"age",
			"fcvayn",
			"packyear",
			"sd_idr2",
			"exerfq"
			],
			[
			"0",
			"1",
			"15",
			"0",
			"0",
			"0",
			"3"
			],
			[
			...
			],
			[
			"0",
			"0",
			"6",
			"0",
			"0",
			"3",
			"0"
			]
			],
			"header": [
			"cva",
			"sex",
			"age",
			"fcvayn",
			"packyear",
			"sd_idr2",
			"exerfq"
			],
			"rows":91501,
			"message":"ok",
			"timestamp":"2022-10-18 10:43:00"
			}

2	뇌졸증 데이터	Request	http://cancerpreventionsnu.kr:3317/api/v1/cva_spec?k

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

			ey=7F531E98-018F-4B82-80D4-ACE525B1AE11
	셋의 명세	Response	{ "result": "success", "data": [[" name", "definition", "description"], ["cva", "과거력_뇌졸증", "0: 없음 / 1: 있음"], ["sex", "성별", "0: 남성 / 1: 여성"], ["age", "연령", "_ 세"], ["fcvayn", "가족력_뇌졸증(중풍)", "0: 없음 / 1: 있음"], ["packyear", "pack year(하루흡연량(갑) * 흡연기간 (년))", "_"], ["sd_idr2", "일주일에 술을 마시는 횟수(일주일 간 음주빈도)", "_ 일"], ["exerfq", "일주일간 운동한 총 일수", "_ 일"]],

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td></td><td></td><td></td><td>"header": [
" name",
"definition",
"description"
],
"rows": 8,
"message": "ok",
"timestamp": "2022-10-18 10:38:40"
}</td></tr>
<tr><td rowspan="2">3</td><td rowspan="2">알고리즘실행 및 결과호출 (심장병)</td><td>Request</td><td>http://cancerpreventionsnu.kr:3317/api/v1/heart?key=7F531E98-018F-4B82-80D4-ACE525B1AE11</td></tr>
<tr><td>Response</td><td>{
"result": "success",
"data": [
[
"heart_risk10",
"age",
"sex",
"htn",
"fhtnyn",
"packyear",
"sd_idr2"
],
[
"1",
"5",
"0",
"0",
"0",
"0",
"4"
],
[
…
],
[
"1",
"6",
"0",
"0",
"1",
"13",
"9"
]
],
"header": [
"heart_risk10",
"age",</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td></td><td></td><td></td><td>"sex",
"htn",
"fhtnyn",
"packyear",
"sd_idr2"
],
"rows": 33496,
"message": "ok",
"timestamp": "2022-10-18 10:26:05"
}</td></tr>
<tr><td rowspan="2">4</td><td rowspan="2">알고리즘실행 및 결과호출 (심장병 모조 데이터)</td><td>Request</td><td>http://cancerpreventionsnu.kr:3317/api/v1/heart_gan?key=7F531E98-018F-4B82-80D4-ACE525B1AE11</td></tr>
<tr><td>Response</td><td>{
"result": "success",
"data": [
[
"heart_risk10",
"age",
"sex",
"htn",
"fhtnyn",
"packyear",
"sd_idr2"
],
[
"1",
"5",
"0",
"0",
"0",
"0",
"4"
],
[
…
],
[
"1",
"6",
"0",
"0",
"1",
"13",
"9"
]
],
"header": [
"heart_risk10",</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td></td><td></td><td></td><td>"age",
"sex",
"htn",
"fhtnyn",
"packyear",
"sd_idr2"
],
"rows": 33496,
"message": "ok",
"timestamp": "2022-10-18 10:26:05"
}</td></tr>
<tr><td rowspan="2">5</td><td rowspan="2">심장병 데이터셋의 명세</td><td>Request</td><td>http://cancerpreventionsnu.kr:3317/api/v1/heart_spec?key=7F531E98-018F-4B82-80D4-ACE525B1AE11</td></tr>
<tr><td>Response</td><td>{
"result": "success",
"data": [
[
" name",
"definition",
"description"
],
[
"heart_risk10",
"심장발병예측",
"0:심장발병확률 낮음 /
1:심장발병확률 높음"
],
[
"sex",
"성별",
"0:남성 / 1:여성"
],
[
"age",
"연령대",
"0:10대 / 1:20대 / 2:30대 /
3:40대 / 4:50대 / 5:60대 /
6:70대 / 7:80대 /"
],
[
"htn",
"심장질환과거력",
"0:없음 / 1:있음"
],
[
"fhtnyn",
"심장질환가족력",
"0:없음 / 1:있음"</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다


```
                                ],
                                [
                                "packyear",
                                "연평균흡연량",
                                "_갑"
                                ],
                                [
                                "sd_idr2",
                                "일주일간음주빈도",
                                "_회"
                                ]
                        ],
                "header": [
                        " name",
                        "definition",
                        "description"
                        ],
                "rows": 8,
                "message": "ok",
                "timestamp": "2022-10-18 10:35:02"
}
```


[서울대학교]

■ 보건데이터의 공정성 평가 자동화

- 성별, 연령별 및 인구집단별 공정성 지표 평가의 자동화
- 공정성 품질 지표 기반의 알고리즘 고도화 기반의 API 고도화 구현
  - ✓ 공정성 품질 지표 알고리즘 분석을 통한 시각화 API 설계 및 구현
  - ✓ 알고리즘 공식 기반의 시각화 API 프로토콜 정의 및 구현
  - ✓ 시각화 API 고도화를 통한 기존 운영 데이터센터와의 호환성 확보
- 주요 공정성의 지표는 1단계에서 연구·개발된 아래의 개념들을 활용함

구분	설명
Unawareness	민감한 속성을 학습 데이터의 특징으로 포함하지 않아야함
Demographic Parity	독립적, 통계적 패리티라고도하며, 가장 잘 알려진 공정성 품질 지표 중 하나임
Equalized odds	한 그룹의 FPR을 다른 그룹의 FNR로 교환할 수 있음
Predictive Rate Parity	정확 또는 참 예측값(참 긍정의 값을 모든 예측된 긍정의 값으로 나눈 값)이 서로 근접하면 Predictive Rate Parity가 달성됨
Individual Fairness	유사한 개인을 유사하게 대우해야 함
Counterfactual fairness	실제 세계와 개인이 다른 인구 통계 그룹에 속한 반 사실적 세계에서 동일한 경우 개인에 대한 결정이 공정함

[표] 핵심 공정성 품질의 개념범주

- 공정성 평가의 자동화를 위한 공정성 지표 선별
  - ✓ 공정성 지표의 자동화를 위해서는 지표화하여 계산 가능한 값들을 산출해야 함
  - ✓ 다음의 핵심 지표들을 중심으로 공정성 지표의 산출과 자동화 수행
    1) 민감도 =recall, =true positive rate(TPR) / 특이도 =true negative rate(TNR)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN} = 1 - FNR \quad / \quad TNR = \frac{TN}{N} = \frac{TN}{TN + FP} = 1 - FPR$$

2) 정밀도 =precision, =positive predictive value(PPV) / negative predictive value(NPV)

$$PPV = \frac{TP}{TP + FP} = 1 - FDR \quad / \quad NPV = \frac{TN}{TN + FN} = 1 - FOR$$

3) 정밀도 accuracy(ACC)

$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN}$$

4) F1 score(precision과 민감도의 조화 평균)

$$F_1 = 2 \times \frac{PPV \times TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN}$$

5) 진단 우도비 Diagnostic odds ratio(DOR)

$$DOR = \frac{LR+}{LR-}$$

- 공정성 지표의 자동화된 계산을 위해서, 위에서 계산된 지표를 민감변수(예: 성별 및 연령군 등)별로 산출된 지표간의 균일화가 필요함
  - ✓ 지표의 균일화는 크게 pre- in- post-processing 과정에서 수행이 가능하며,
  - ✓ 각 단계별 지표보정의 원리는 아래의 표와 같다.

알고리즘 단계	Pre-processing	In-processing	Post-processing
보정방법 사례	• labels를 변경 • input data를 변경 • label/data의 조합을 변경 • label/data 조합별 가중치 변경	• 반사실적 학습 (GAN 등의 adversarial training) • 공정성을 위한 regularization 조건화 • 공정성 지표의 동등성을 강제한 모형 구현	• 자료 추가 수집 (혹은 simulation으로 추가 생성)

[표] 알고리즘의 구현 이전, 구현 중 및 구현 이후의 단계별 공정성 보정의 기본원리

■ 데이터 시각화

- 직관적인 특성 제시의 필요성
- 빅데이터는 크기, 복잡성, 변이성 등을 특성으로 하고 있고, 건강분야의 헬스빅데이터는 특히 변수간의 상호의존성을 특징으로 함
  - ✓ 건강문제의 경우 하나하나의 변수와 지표들이 독립적인 경우보다 복잡한 인과성-상관성으로 인해 상호의존성을 갖는 경우가 많음
  - ✓ 예를 들어 비만도, 허리둘레, 혈중지질농도, 염증지표, 심혈관질환 위험도 등은 상관관계가 높음
  - ✓ 이러한 고차원의존성은 데이터의 품질관리면에서도 특수한 문제를 야기시킴
- 합리적인 차원 축소의 필요성
  - ✓ rank기반, Chernoff faces, pixel-based techniques 등이 제안되어 왔음
  - ✓ 고차원 특성을 2차 혹은 3차원으로 최소한의 정보 손실을 통해서 차원을 축소하는 것이 핵심
- 데이터 특성의 시각화를 위해서는 non-linear manifold에 대한 방법 적용이 필요함. 특히 다음의 시각화 방법을 검토하였음
  - ✓ CCA (Curvilinear Component Analysis)
  - ✓ SNE (Stochastic Neighbour Embedding)/t-SNE
  - ✓ Maximum Variance Unfolding (MVU)

✓ Locally Linear Embedding (LLE)

- SNE 방법의 개념
  - ✓ SNE 방법은 고차원 hyperplane 상의 데이터 관찰값 간의 거리를 유사도를 조건으로한 조건부 함수로 바꾸는 것에서 출발한다. **고차원복합자료에서의 조건부 함수** $p_{j|i}$는 다음과 같이 표현된다. xi에 **대응되는 저차원**의 데이터값을 yi라고 한다면, yi간의 거리는 유사한 조건부 확률의 개념을 사용하여 $q_{j|i}$로 표현될 수 있다.

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_i - x_k\|^2 / 2\sigma_i^2\right)} \quad \text{(수식 1)} \qquad q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)} \quad \text{(수식 2)}$$

(σi – 데이터포인트의 분산)

  - ✓ 핵심은 변수간의 pair-wise similarity에 있으므로, 가장 이상적인 차원 축소가 이루어졌다면 $p_{j|i} = q_{j|i}$가 된다. SNE는 지정된 Pi값을 산출하는 σi를 찾으면서 계산을 시작한다. 여기서 Perplexity는 다음과 같이 정의된다.

$$Perp(P_i) = 2^{H(P_i)} \quad \text{(수식 3)}$$, 여기서 H(Pi)는 Pi의 Shannon entropy

  - ✓ gradient descent 방법을 통해서 $p_{j|i} = q_{j|i}$가 최소화되는 함수를 구하면 수식 4와 같은 cost function이 됨

$$\frac{\delta C}{\delta y_i} = 2\sum_j (p_{j|i} - q_{j|i} + p_{i|j} - q_{i|j})(y_i - y_j) \quad \text{(수식 4)}$$

- t-SNE 방법의 개념
  - ✓ 실제의 자료값을 자료의 t-분포값으로 대체하면, 수식 4 cost function의 계산이 매우 용이해짐. 즉, t-분포를 사용할 경우, qij는 다음 수식 5와 같이 간략화 될 수 있다.

$$q_{ij} = \frac{\left(1 + \|y_i - y_j\|^2\right)^{-1}}{\sum_{k \neq l} \left(1 + \|y_k - y_l\|^2\right)^{-1}} \quad \text{(수식 5)}$$

  - ✓ 또한 SNE의 수식 4 (gradient descent식)는 t분포 사용시 수식 6과 같이 간략화된다.

$$\frac{\delta C}{\delta y_i} = 4\sum_j (p_{ij} - q_{ij})(y_i - y_j)\left(1 + \|y_i - y_j\|^2\right)^{-1} \quad \text{(수식 6)}$$

  - ✓ QUFA의 시각화에서는 t-SNE 방법의 사용이 현실적으로 가장 강력하면서 좋은 시각화 방법으로 제안

■ 데이터 시각화에 따른 API화

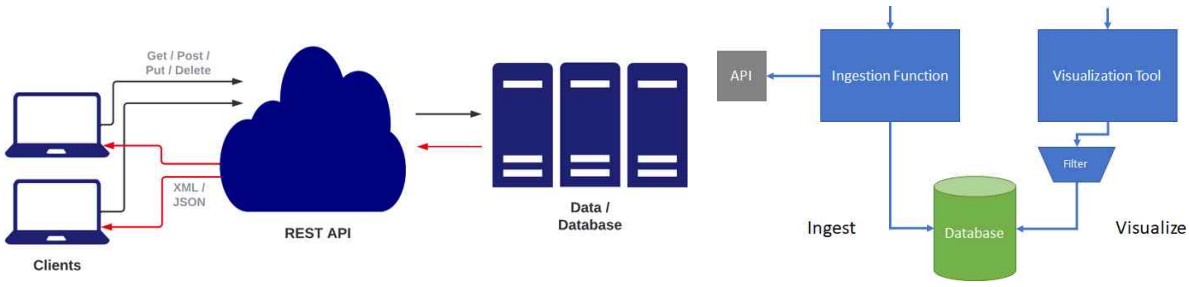

[그림 86] RestAPI의 기본개념과 시각화 모듈의 API화를 위한 기본개념

■ 시각화 모듈의 API화를 위한 library

- QUFA의 기본 개발 방향인 open source 프로그램에서 지원되는 주요 시각화 API 라이브러리들과 기반 언어는 다음과 같다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	GOOGLE CHART TOOLS	JAVASCRIPT INFOVIS TOOLKIT	D3.JS	MATPLOTLIB	BOKEH
LOGO	Google Charts	JavaScript InfoVis Toolkit		matplotlib	bokeh
TYPE	API	Library			
PROGRAMMING LANGUAGE	Javascript			Python	
EXTENSIONS	Java, ChartWeapper or ChartEditor	RGraph, Sunburst or ForceDirected	c3, d3-timeseries, plotly.js, d3-carto-map, among other	Basemap, brokenaxes, animatplot, mpl_interactions, among other	node.js, html_button.py, jsmol-bokeh-extension, among other

✓ 3차년도에는 토큰방식의 시각화 모듈 API화를 수행하였으며, 다음과 같은 개요로 구성됨

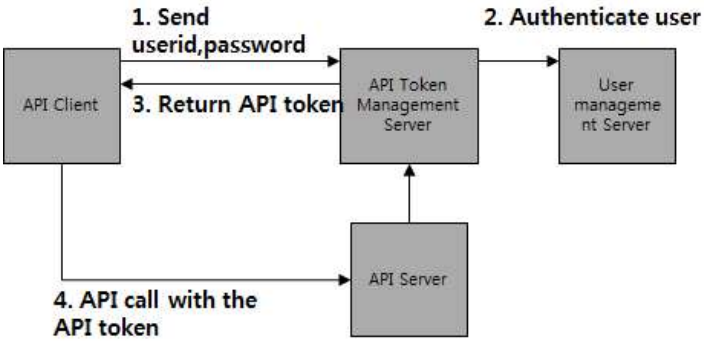

[그림 87] 토큰 방식을 이용한 데이터 시각화 API 고도화

[서울시립대학교]

■ 텐서공간모델 기반 텍스트 데이터 품질 개선 기술

▪ Contextual embedding ELMo를 활용한 텍스트 큐보이드 모델 개선 기술

✓ 텍스트 품질 개선을 위한 Contextual embedding

- 문서를 분류할 때, 컴퓨터가 자연어를 인식할 수 있도록 하는 방법 중 임베딩 기법이 있음
- 임베딩 기법 중 문맥을 고려하여 임베딩하는 ELMo 모델은 같은 단어라도 상황에 따라 달라지는 의미를 반영하여 다른 벡터값으로 임베딩 됨
- ELMo 모델을 통해 텍스트 데이터를 임베딩할 때, 임베딩 벡터를 효율적으로 활용할 기법이 필요

✓ ELMo, 품사 태깅을 활용한 텍스트 큐보이드 생성

- 텍스트 큐보이드는 문서에서 단어가 가지는 의미적인 정보를 담도록 제안된 모델로 'Bag of Words(BOW)' 혹은 'TF-IDF'에서는 document by term 2차원 행렬 형태로 표현되지만 'Text cuboid'에서는 의미를 담은 concept 축을 추가해 3차원으로 표현된 구조

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

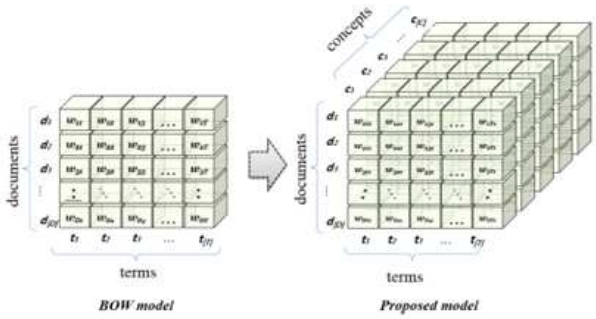

[그림88] BOW 표현 모델과 Text cuboid 표현 모델의 비교

- 각 문서마다 Term by Concept의 매트릭스 구조가 모여 이루어진 Text cuboid에서 ELMo의 임베딩 벡터가 컨셉축이 됨
- 분류하고자 하는 문서집합에서 각, 문서 별로 특수문자들을 제거
- 텍스트 큐보이드를 생성하는데 필요한 임베딩 벡터를 얻기 위해 사전 학습된 ELMo 임베딩으로 [문서길이 * ELMo 임베딩 차원(1024차원)] 형태 2차원 Matrix 형태의 넘파이 배열을 생성하고 npy 확장자로 저장

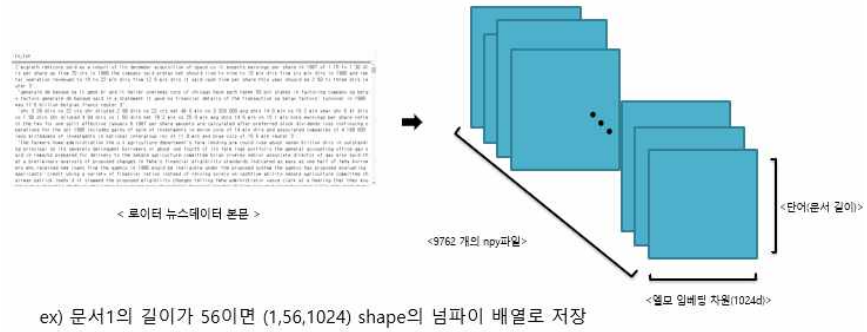

ex) 문서1의 길이가 56이면 (1,56,1024) shape의 넘파이 배열로 저장

[그림 89] (위) 엘모 임베딩으로 문장의 단어가 벡터화 되는 과정
(아래) 로이터 뉴스데이터의 각 문서가 임베딩 되어 넘파이 배열로 저장되는 구조 시각화

- 특수문자를 제거해 전처리된 문서에서 품사태깅을 하고 불용어를 제거한 뒤 Chi2 통계량을 이용해 500개의 단어를 Feture Selection
- 각, 문서마다 np.zeros(500,1024)로 텍스트 큐보이드를 만들기 위한 틀을 만들고 선별된 500개의 단어에 대한 임베딩 벡터값을 할당시켜 Train 텍스트 큐보이드와 Test 텍스트 큐보이드를 생성
- 특정 문서에서 선별된 단어가 존재하면 해당 위치의 임베딩 벡터를 저장했던 npy 파일에서 불러와 할당하고 존재하지 않으면 0 벡터가 입력되는 방식
- 품사태깅과 엘모 임베딩 벡터를 활용하여 품사에 따라 달라지는 의미를 반영이 가능

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

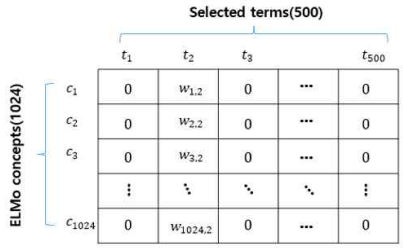

[그림 90] 특정문서에서 t_2 단어가 존재할 경우 생성되는 Term by Concept Matrix

✓ 텍스트 큐보이드를 활용해 문서 분류 모델의 성능 개선

- 텍스트 큐보이드를 효과적으로 학습하기 위해 제안된 구조인 TSM DNN과 Concept-wise TSM DNN 구조로 텍스트 큐보이드를 학습(위조 리뷰 검출을 위한 텐서 공간 모델 기반 심층 인공 신경방 알고리즘, 임푸름)

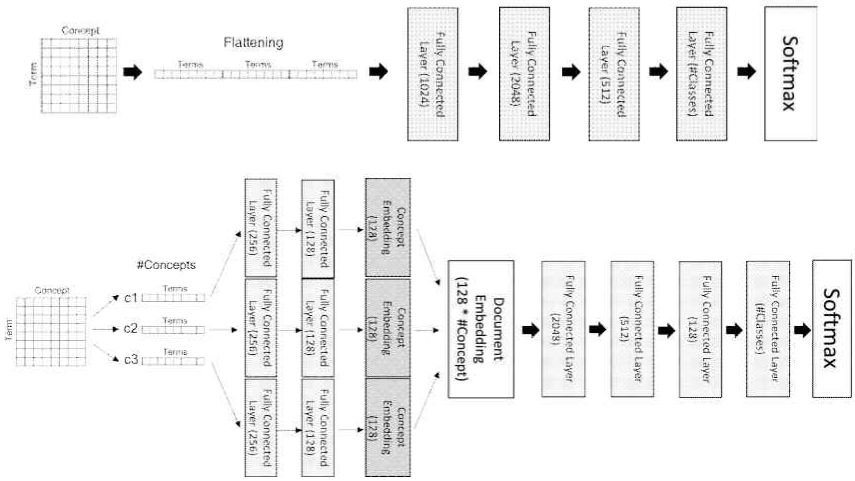

[그림 91] (위) TSM DNN 아키텍처 시각화
(아래) Concept-wise TSM DNN 아키텍처 시각화

- 텍스트 큐보이드를 활용한 모델을 전통 머신러닝 알고리즘들과 LSTM 모델의 분류 성능과 비교 평가척도는 정확도(Accuracy)
- 로이터 뉴스 데이터셋과 IMDB 영화 리뷰 데이터셋으로, 로이터 뉴스 데이터는 46개의 뉴스 카테고리로 이루어진 label 중에서 샘플수가 100개 이상인 12개의 클래스만 추출하여 분류하였고 train_data 7828개 test_data 1934개를 사용. IMDB 영화 리뷰 데이터는 영화 리뷰가 긍정적인 리뷰의 경우 1, 부정적인 경우 0인 label을 가진 이진 분류 데이터로 기존 5만개의 데이터에서 일부만 사용하여 train_data 8000개 test_data 2000개를 사용

Accuracy(%)

model / data	Naïve Bayes	SVM	Logistic Regression	LSTM	TSM DNN	CTSM DNN
Reuter news	57 %	77 %	79 %	79 %	**86 %**	**87 %**
IMDB	80 %	82 %	83 %	83%	**86 %**	**87 %**

[표] 머신러닝 모델들과 제안된 모델 성능 비교

- 텍스트 큐보이드를 활용한 모델이 다른 모델들보다 더 높은 정확도를 보이는 것을 확인
- ELMo와 텍스트 큐보이드를 결합한 기법이 효과적임을 보임

■ 정형테이블 학습데이터 증강 기술

▪ 오토인코터 기반 수치형 학습데이터 증강 기법

✓ 제안 배경

- 빅데이터 시대를 맞이하여, 우리는 방대한 데이터를 AI 학습데이터로 활용하려 노력하지만, 적정 수준의 학습모델을 생성하지 못하는 저품질 데이터를 자주 경험
- 대부분의 저품질 데이터는 클래스(레이블)간의 불균형 문제를 가지는 사례가 많음
- 불균형 데이터로 학습을 수행하는 경우, 소수 클래스는 무시되고 다수 클래스에 편향되는데, 이는 머신러닝 기반 학습모델의 성능을 저하시키는 주요 요인임
- AI 학습데이터로 활용될 수 있는 저품질 데이터의 클래스 불균형 문제점을 해결하기 위해서, 수치형 테이블 데이터에 대한 자동 증강(Data Augmentation) 기법 연구 진행
- 충분하지 않은 데이터로 학습을 진행하면, 과소 적합(Underfitting)이나 과적합(Overfitting)이 발생할 위험이 높은데, 편향성이 낮은 다량의 학습데이터를 확보하려면 시간과 비용이 들지만, 자동 증강을 통해 이 문제를 극복 가능

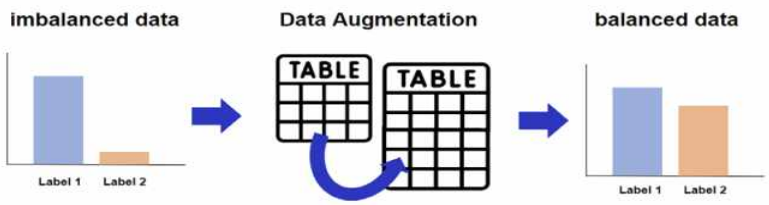

✓ 기대 효과

- 자동 증강(Data Augmentation)의 목적은 학습데이터를 양을 늘려 클래스 불균형을 해결하고 학습 성능을 향상
- 인간의 개입 없이 자동으로 데이터를 확장하여, 초기 주어진 충분하지 않은 데이터로부터 얻지 못한 패턴을 확보하는 데 도움을 줌
- 데이터 자동 증강 기법은 충분한 학습데이터를 확보하는 시간과 노력을 줄여, 비즈니스 측면에서 경제적이므로 고부가가치를 생산하는데 크게 기여
- 자동 증강 기법에서는 원본 데이터의 맥락을 파악하여, 분석에 사용 가능한 고품질 데이터를 생성
- D-VAE에서는 수치형 정형 데이터의 값의 분포를 학습한 후 증강하여 성능을 향상시켜 원본 데이터를 기반으로 양질의 샘플 데이터 생성

✓ D-VAE 프로세스 및 특징

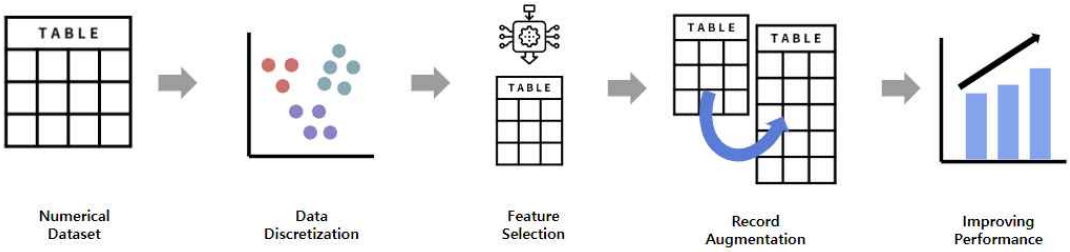

[그림 92] D-VAE 프로세스

- 본 연구는 딥러닝 기반 변분 오토인코더(Variational Autoencoder)를 활용하여 수치형 학습데이터 내 클래스 불균형 문제를 해결하여 학습데이터를 증강하고 학습모델의 성능을 향상
- 최적의 데이터 증강을 지원하기 위해 이산화와 특징선택을 수반한 전처리 과정을 수행

✓ D-VAE 학습 과정
- 데이터 전처리 시 k-means로 클러스터링한 결과를 바탕으로 이산화와 특징선택을 거침
- 이산화 과정에서 최솟값과 최댓값을 구하여 균일한 너비를 지정한 구간만큼 그룹화를 진행
- 연속형 변수에서 이산화한 값을 변화하기 위해 원-핫 인코딩(one-hot encoding)으로 원-핫 벡터(one-hot vector)로 변환
- 원-핫 인코딩의 단점을 보완하여 특징선택의 REFCV(Recursive Feature Elimination with Cross Validation) 알고리즘 사용
- 데이터 전처리의 최적화 과정을 거친 후, 변분 오토인코더로 학습데이터의 분포와 유사한 분포를 갖는 샘플 데이터를 생성

✓ D-VAE 단계별 학습 과정
- 4단계를 순차적으로 수행

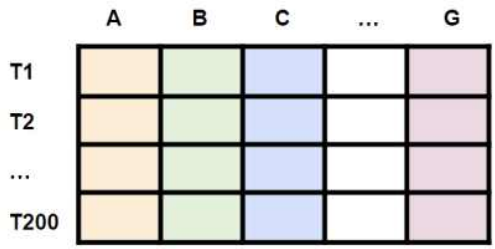

[그림 93] D-VAE 프로세스 1단계

- [1단계]그림은 초기 입력되는 학습데이터이며, 학습 과정을 설명하기 위한 예시 데이터이다. 이는 A부터 G까지 총 7개의 변수와 200개의 레코드로 이루어진 수치형 정형 데이터셋이다.

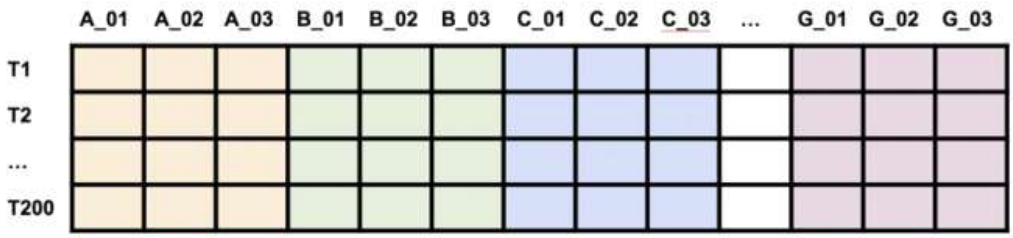

[그림 94] D-VAE 프로세스 2단계

- [2단계] 원본 데이터를 전처리 과정을 거쳐 최적화한다. 우선, 클러스터링 과정을 거쳐 그룹화하고, 이산화하여 원-핫 인코딩으로 원-핫 벡터를 생성한다. 구간을 3개로 지정했다고 가정할 때, 그림과 같이 한 변수당 원-핫 벡터 변수가 3개씩 늘어난다.

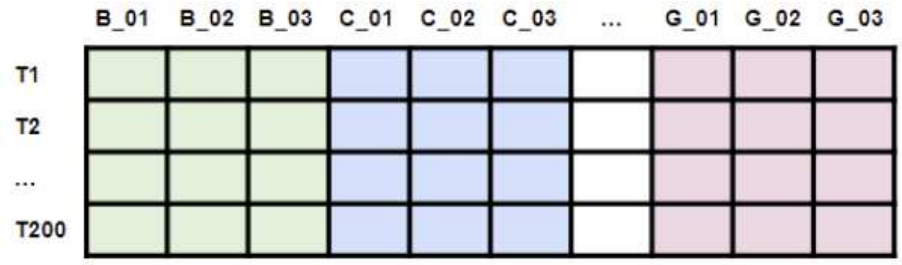

[그림 95] D-VAE 프로세스 3단계

- [3단계] 이산화한 데이터로 특징선택 과정을 거친다. REFCV 기법으로 레이블 예측 중요도가 낮은 변수를 제거한다. 레이블 예측 시 변수 'A'가 중요도가 낮다고 가정하면, 그림과 같이 변수 'A'가 제거된다.

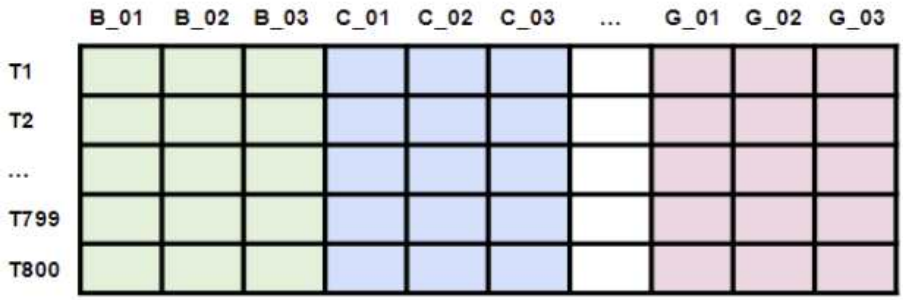

[그림 96] D-VAE 프로세스 4단계

- [4단계] 그림 12는 전처리 과정을 마친 데이터로, 변분 오코인코더를 활용하여 200개의 레코드에서 800개로 증강했다. 이처럼 D-VAE는 학습데이터의 레코드를 증강하여 양질의 데이터를 얻는다.

✓ 실험 데이터셋

데이터셋	변수 개수	레코드 개수
유방암	32	569
당뇨병	9	768
수질 측정	10	3,276
신용카드	31	284,807

✓ 실험 조건

- 실험 진행 시 부여한 조건으로는, 결측치는 평균대치법을 적용하고 레코드 고유번호는 학습모델에 도움이 되지 않아 삭제
- 성능 평가 척도는 정확도와 F1-score이며, 예측 모델 구성을 위해 Logistic Regression, XGBoost, Random Forest 알고리즘을 사용
- 데이터 증강 비율은 원본 데이터, +20%,+40%,+60%,+80%,+100%로 구분하여 성능분석 진행
- D-VAE를 통해 제안 기법이 VAE에 비해 적은 양의 레코드 수를 증강해도 성능 향상 되었다는 결과를 입증

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 실험 결과 : 데이터셋의 원본 데이터와 샘플 데이터(+100%) 모델 성능 비교

유방암 데이터		
Number of Records : 569 → 1,138		
Logistic Regression	XGBoost	Random Forest
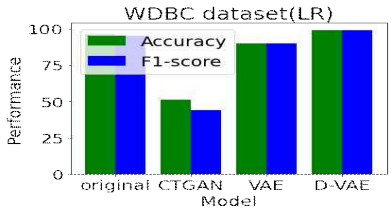	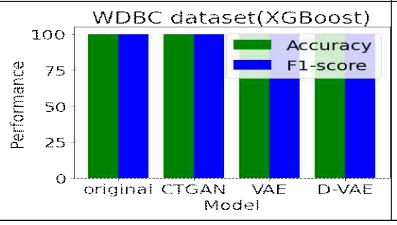	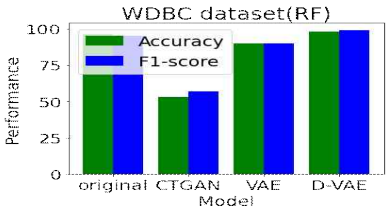

당뇨병 데이터		
Number of Records : 768 → 1,536		
Logistic Regression	XGBoost	Random Forest
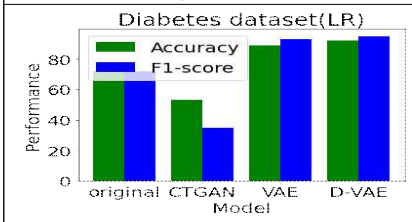	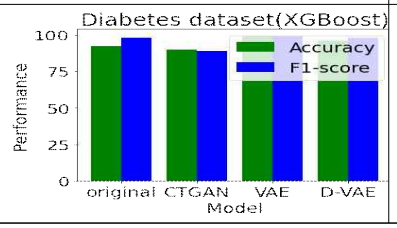	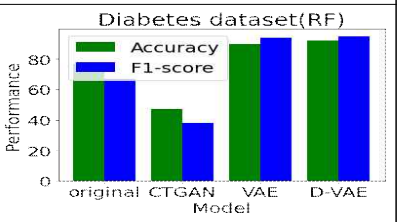

수질 측정 데이터		
Number of Records : 3,276 → 6,552		
Logistic Regression	XGBoost	Random Forest
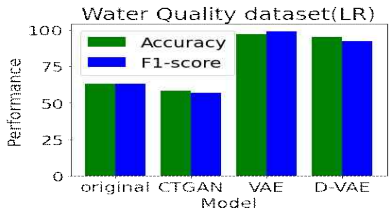	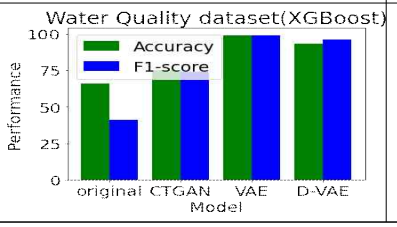	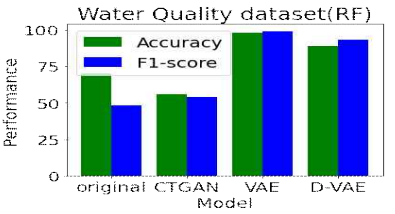

신용카드 데이터		
Number of Records : 284,807 → 569,614		
Logistic Regression	XGBoost	Random Forest
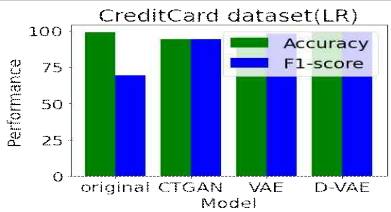	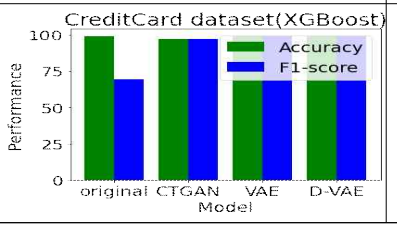	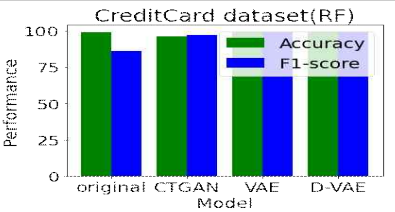

✓ 실험 결과 : 특징 선택 전/후 소요시간 비교(단위 : 초)

데이터셋	전(변수 개수)	후(변수 개수)
유방암	13.2903 (151)	7.4577 (64)
당뇨병	12.6607 (37)	12.1015 (32)
수질 측정	23.3419 (46)	16.3832 (44)
신용카드	18.4951 (151)	11.0394 (102)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 시계열 데이터 이상치 탐지 및 정상화 기술

▪ 딥러닝 기반 시계열 데이터 결측값 보완 및 이상치 제거 알고리즘 TIMEBAND 개발

✓ 제안 배경 및 기대 효과

- IoT 센서 기반 시계열 데이터는 센서 오염, 고장 등의 다양한 이유로 이상치 및 결측치가 포함됨
- 이상치와 결측치를 포함하는 저품질의 데이터로 딥러닝 기반 시계열 예측 모델을 구축하는 경우 모델의 신뢰도는 낮음
- 데이터의 품질 개선 문제는 인공지능 모델의 신뢰도에 큰 영향을 미치므로 이러한 문제를 해결하기 위해 시계열 데이터로 딥러닝 모델을 학습하여 정상값의 범위 밴드(Band)를 생성하고, 밴드를 이용하여 결측치와 이상치의 보정을 동시에 처리하는 TIMEBAND 기법 제안

✓ TIMEBAND : 시계열 데이터의 정상범위 밴드로 데이터 품질 개선 기술 개발

- 다변량 시계열 데이터들 간의 시간적인 특성 및 변수 간의 상관관계를 고려하여 결측치와 이상치가 포함된 데이터를 높은 품질의 데이터로 보정 및 개선하기 위한 목적을 지님
- 입력되는 다변량 시계열 데이터는 3개의 은닉층으로 구성된 인코더(Encoder)를 거쳐 컨텍스트 공간(Context Space)을 형성하고, 컨텍스트 공간은 1개의 은닉층으로 구성된 디코더(Decoder)를 거쳐 품질 개선의 대상이 되는 목적변수들을 출력하며 다변량 데이터의 입출력 구조를 구성됨

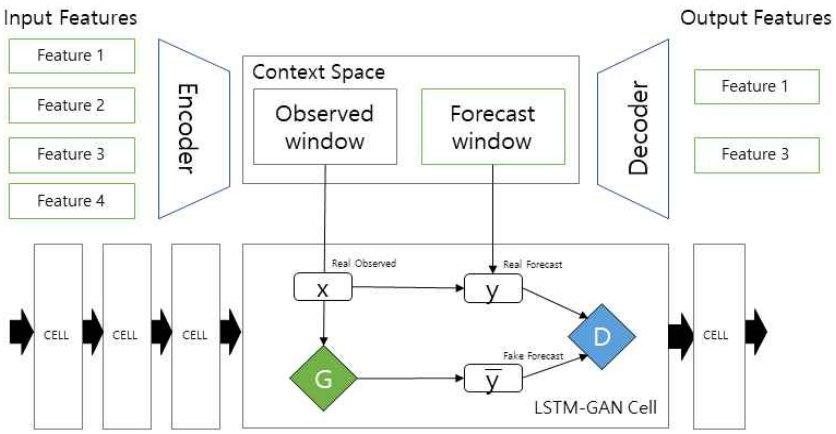

[그림 97] LSTM-GAN 기반 TIMEBAND 구조

✓ 학습한 TIMEBAND를 이용하여 시계열 데이터의 정상범위 밴드 시각화

- 결측값은 정상범위의 중앙값(Median)으로 대체하고, 이상값은 정상범위 밴드의 경계값으로 보정하고 밴드의 폭은 예측된 값들의 중앙값(Median)을 기준으로 3(표준편차)의 폭을 사용함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

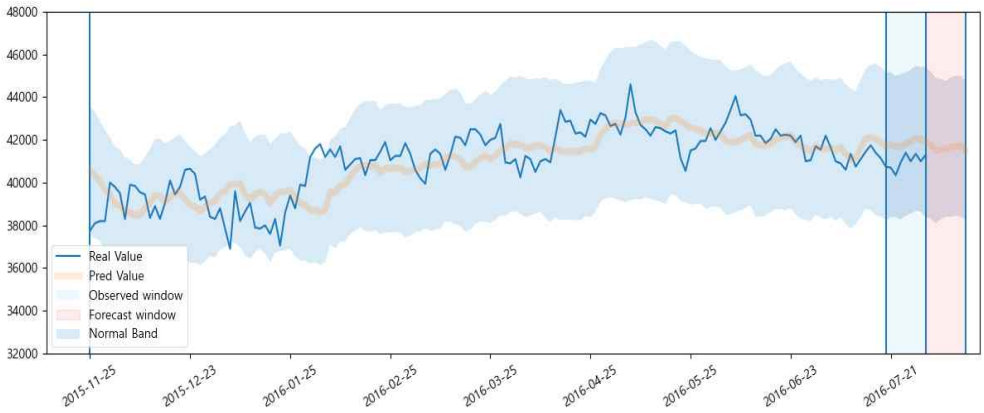

[그림 98] TIMEBAND 기법을 적용하여 예측한 값과 정상 밴드 시각화

✓ 실험 및 결과

- 한국농수산식품공사에서 제공하는 2015년부터 2020년까지 전국 도매시장의 21개 농산물 품목 및 품종의 거래량 및 거래가격 데이터 이용
- 거래가격 정보에 대해 7일, 14일, 28일 후의 농산물 물가 예측 실험 진행
- TIMEBAND 기법을 통해 높은 품질로 보정 및 개선된 데이터에 대한 예측 모델의 신뢰도 평가를 위해 평균 오차율(NMAE: Normalized Mean Absolute Error)을 활용함

$$NMAE = Mean\left(\frac{|True - \mathrm{Pred}|}{True}\right)$$

[수식 9] NMAE Score

- 원본 데이터와 보정된 데이터에 대한 평가를 위해 Seq2Seq모델과 LightGBM 모델로 성능 비교

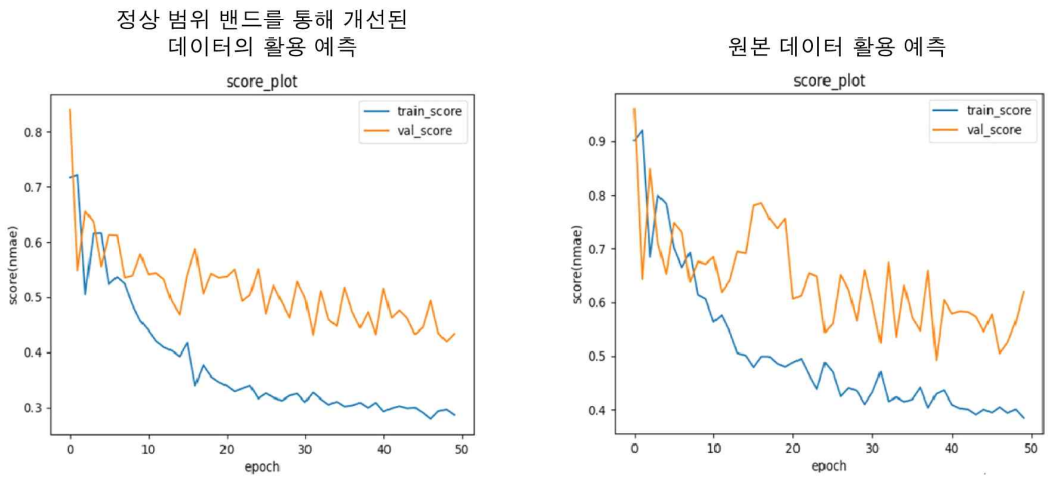

[그림 99] 품질이 개선된 데이터와 원본 데이터의 모델 학습 학습 곡선

- 실험 데이터는 (1) 원본 데이터, (2) 결측값을 직전 값으로 대체한 데이터, (3) 결측값에 대해 품질을 개선한 데이터, (4) 결측값과 이상값에 대해 품질을 개선한 데이터로 총 4개의 데이터를 활용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[표] 데이터별 예측모델들의 평균오차율

실험 데이터		데이터 처리		예측모델	
		결측값 처리	이상값 처리	Seq2Seq	LightGBM
원본 데이터	(1)	x	x	0.3225	0.2295
	(2)	o	x	0.2976	0.2187
TIMEBAND 데이터	(3)	o	x	0.2633	0.2119
	(4)	o	o	**0.2564**	**0.2058**

- 본 연구에서 제안하는 TIMEBAND 기법을 통해 결측치와 이상치 모두 보정하여 데이터의 품질을 개선했을 때, 예측 모델의 신뢰도 향상에 크게 기여함을 확인할 수 있음

▪ LSTM-GAN 이상 탐지 모델 기반 시계열 데이터 이상값 보정 기술 개발

✓ 제안 배경 및 기대 효과

- 다양한 산업 분야에서 센서의 발전으로 대량의 시계열 데이터들이 생성되지만 주변 환경 및 다양한 원인으로 이상값이 발생함
- 결측값 및 이상값이 많이 포함된 데이터로 딥러닝 모델을 학습하면 예측 모델의 성능은 저하될 수 있음
- 본 연구는 적대적 생성기법인 GAN 구조를 응용하여 데이터의 이상값 탐지하고 탐지된 이상값을 정밀하고 품질이 우수한 데이터로 보정하는 품질개선 연구임

✓ 딥러닝 GAN 기반 이상값 탐지 및 데이터 품질 개선 기술 개발

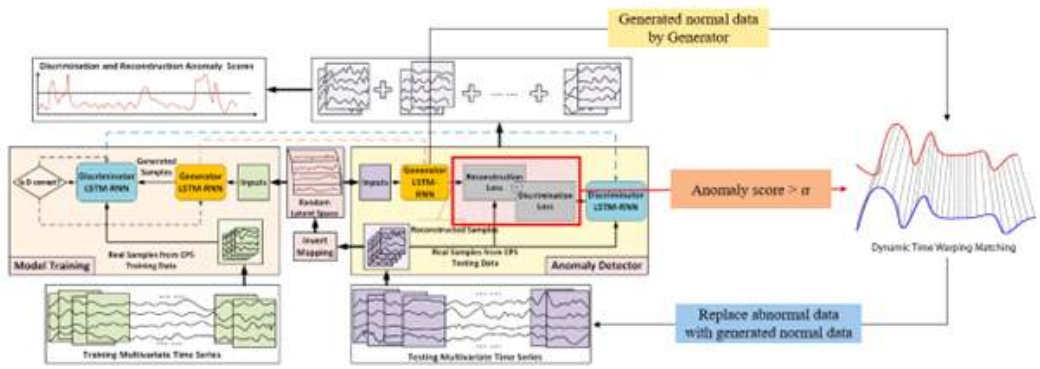

[그림 100] 이상징후 탐지를 위한 GAN 기반 품질개선 기법 구조

- 정상 데이터를 이용하여 GAN의 생성자(Generator)와 판별자(Discriminator) 정상 데이터의 분포를 학습
- 정상 분포를 학습한 생성자와 판별자를 이용하여 실제 데이터의 Anomaly score를 계산하여 score가 일정 임계값(threshold)보다 큰 경우 이상 징후로 분류
- 탐지된 이상값은 이상값과 가장 거리가 가까운 정상값의 분포를 학습하여 생성된 값으로 이상값을 대체함
- 정상 분포와 유사한 값을 생성하기 위해 동적 시간 워핑(DTW: Dynamic Time Warping) 기법을 활용함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

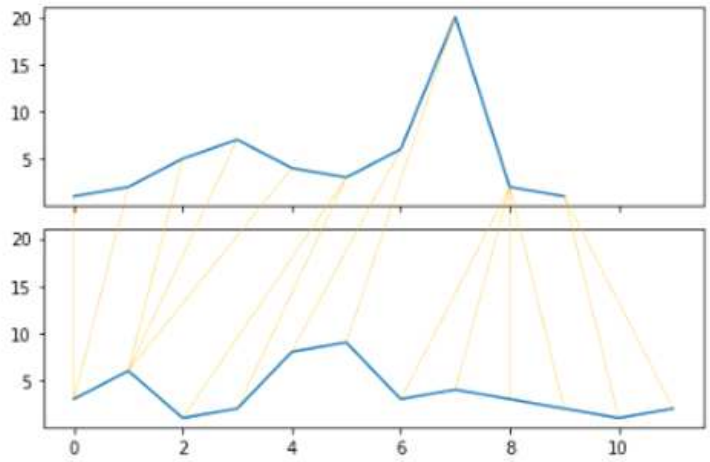

[그림 101] DTW 기법을 통해 시계열 데이터들 간의 유사한 값으로 매핑 결과 시각화

✓ 이상값 보정을 위한 이상 탐지

- 다양한 분야를 포괄하는 오픈 소스 데이터인 Numenta Anomaly Benchmark(NAB) 데이터 셋을 이용하여 GAN 기반 이상탐지 모델의 Anomaly score를 사용

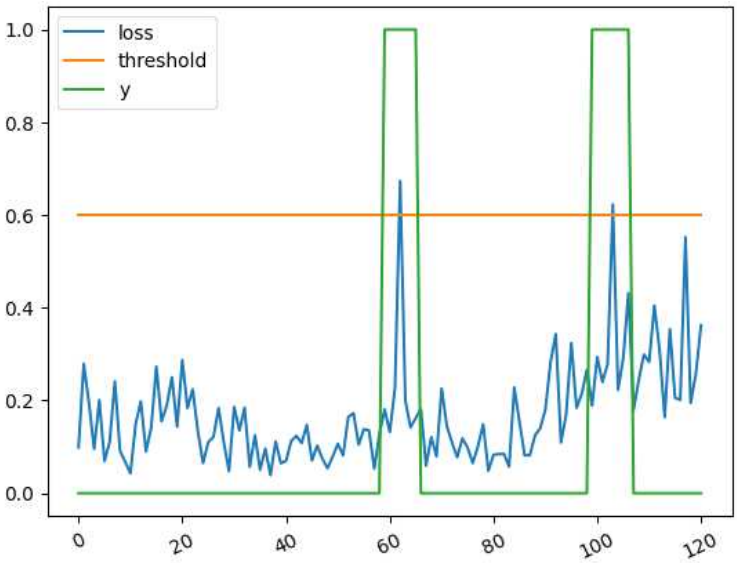

[그림 102] 실제 데이터들로부터 계산된 손실함수 값을 이용하여 Anomaly score 계산 결과

- 정상분포를 학습한 GAN 모델에서 계산되어지는 Anomaly score를 이용하여 이상값으로 정의된 값을 실제 데이터에 맵핑한 결과 모델이 실제 이상값을 잘 탐지하는 것을 확인할 수 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

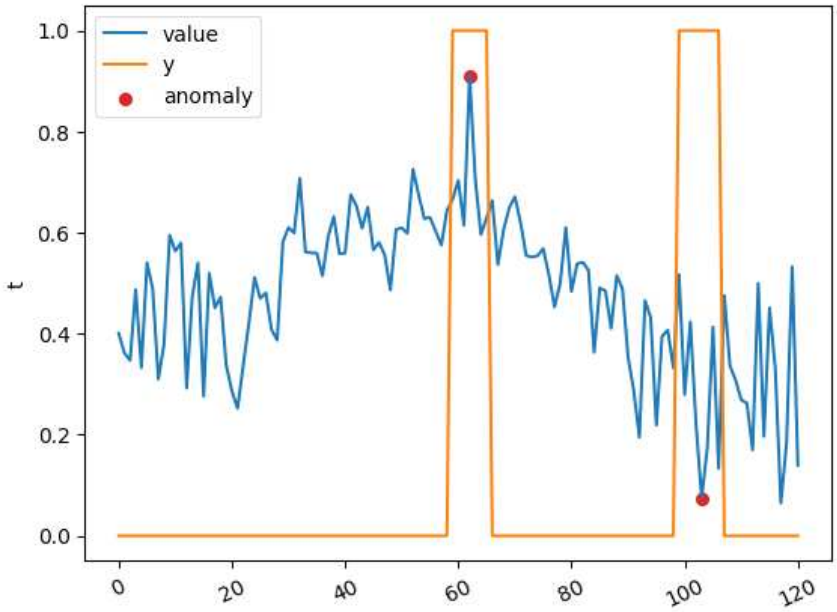

[그림 103] 이상 탐지 결과를 실제 데이터에 맵핑한 결과

- 본 연구에서 제안하는 GAN 모델로 데이터의 품질을 개선하기 위해 이상값을 제대로 탐지하는 것이 중요함
- 현재 정상분포를 학습한 탐지 모델로 탐지된 이상값 보정을 위해 이상값과 가장 유사하면서 정상적인 값으로 보정하기 위해 LSTM-GAN 구조를 개선 개발 진행 중
- 해당 보정기법으로 데이터의 품질 개선을 실시할 경우, 기존 보정 기법들의 결과보다 질 좋은 데이터로 품질 개선이 될 것으로 기대됨

[이화여자대학교]

■ AI 기반 오류 탐지 기술 고도화

▪ 딥러닝 학습에 기반한 데이터 내의 내용특성(Value Constraints, VC)과 데이터간의 관계특성(Functional Dependency, FD)을 통하여 데이터 오류를 탐지하는 기술을 개발

✓ 내용특성과 관계특성에 해당하는 후보군들을 상정

✓ 데이터셋과 특성 후보군과의 괴리정도 특성에 대한 최적 후보 선택 알고리즘을 학습

▪ 내용특성과 관계특성 대상 후보군은 아래와 같이 정의

분 류	특성 후보군	내용	괴리도(disparity) 산출
내용특성	유일분포(Uniqueness)	- 데이터셋이 단일값으로 구성	- 최빈항목 결정 - 최빈항목과의 차를 최대, 최소로 정규화한 평균값
	균등분포(Uniform)	- 데이터셋이 균등하게 분포	- 데이터셋의 산포간격 결정 - 산포값에 대한 평균빈도 산출 - 각 빈도차에 대해 최대, 최소로 정규화한 평균값
	정규분포	- 데이터셋의 정규분포 준수 여부 - 통상의 많은 데이터셋들은 정규분포를 따르는 것으로 매우 유용	- 데이터셋의 평균과 분산으로부터 표준정규분포 산출 - 표준정규분포와의 오차값 - 확률밀도함수 가중치 반영
	파레토 분포	- 사회과학분야에서 많이 사용되	- 근사 파레토 분포 산출

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		는 80대 20법칙 - 파레토 분포 준수 여부	- 파레토 분포와의 오차값을 정규화한 값
	프와송 분포	- 도착시간 관련 등에서 많이 활용 - 프와송 분포 준수 여부 확인	- 근사 프와송 분포 산출 - 프와송 분포와의 오차값을 정규화한 값
관계특성	포함관계	- 특정 컬럼 데이터셋이 다른 컬럼 데이터셋에 포함 여부 - 행별 비교가 아닌, 데이터셋 전체 비교	- 데이터셋 중 상위 데이터셋 결정 - 공통항목 제외 독자 항목수가 많은 데이터셋을 상위 데이터셋으로 결정 - 포함관계 미해당 데이터셋 비율
	함수의존성	- 두 컬럼간의 함수 의존성 존재 여부 확인 - A 컬럼의 모든 값이 함수적으로 B 컬럼값에 의해 결정되는 경우	- 두 컬럼간의 함수의존성 파악 - 함수의존성 미해당 항목 비율
	상호연관성	- 두 컬럼간의 연관성 여부 판별	- 두 컬럼간의 correlation 산출 - correlation값

- uniqueness, 함수의존성과 같은 경우는 규칙 기반(rule-based)으로 특성 판별이 간단하나, 딥러닝 학습에 기반하여 특성들을 종합적으로 판단하는 모델로 오류 탐지 성능을 개선
  - ✓ 수치형으로 바로 적용이 불가한 문자열의 경우, 유의어 사전을 통한 워드 임베딩 기반 학습을 통해 수치화 변환을 시도
  - ✓ 10개 미만의 문자열 종류는 열거형으로 처리하여 매핑
- 데이터셋에 대해 최대 5개의 컬럼을 선택하여 내용특성에 대한 괴리도 5개, 관계특성에 대한 괴리도 10개를 추출하여 총 15개의 괴리도에 대해 학습
  - ✓ 학습데이터는 특성 후보군을 임의선택하여, 0~2% 오차로 데이터셋을 10,000개 임의생성하여 학습
  - ✓ 목표값(Label)은 선택된 특성 후보군의 오차에 비례하여 설정
- 학습모델은 순방향신경망(Feed Forward Network)을 사용하였으며, 3개 은닉계층으로 특성학습이 충분

계층수	Loss	Accuracy(%)	Sensitivity(%)
1	0.451	89.23	98.42
2	0.125	93.11	99.12
3	0.103	94.22	99.32
4	0.104	93.48	99.30

■ AI 기반 오류 보정 기술 고도화

- 데이터셋에 대한 내용특성이나 관계특성이 확인된 경우, 적용 가능한 오류 보정 연산자 후보군에 대하여 최적 보정 연산자를 학습을 통하여 결정
- 오류 보정 연산자 후보군을 다음과 같이 설정
  - ✓ 보정연산자들은 내용특성 중 경험적으로 선호되는 항목이 존재함

보정연산자 종류	내용	선호 내용특성
Mean	평균값을 기반으로 Imputation	정규분포
Median	중앙값을 기반으로 imputation	유일분포
Mode	최빈값을 기반으로 Imputation	
Null	미정의값을 기반으로 Imputation	균등분포
Random	가능한 범위에서 임의 선택하는 방식	

- 학습 데이터는 내용특성과 관계특성에 기반한 데이터셋 10,000개를 인위적으로 생성하여, 보정연산자별로 오차 5% 미만의 값으로 오류를 주입하여 학습
  - ✓ 분류된 특성과 특성 모델의 오차를 기반으로 보정연산자를 목표로 학습 진행
  - ✓ 학습패턴 존재여부를 확인하기 위해 내용특성 중 최적 보정연산자에 대한 가중치 비율을 반영하여 학습 데이터를 생성함
- 학습모델은 순방향신경망(Feed Forward Network)을 사용하였으며, 은닉계층 개수에 무관하게 학습이 가능하나, 정확도가 80% 정도로 기계학습을 통한 특성 기반 보정 기술에 대한 가능성을 확인함

계층수	Loss	Accuracy(%)	Sensitivity(%)
1	0.891	81.02	77.25
2	0.913	79.24	78.29
3	0.929	78.60	77.82
4	0.911	79.41	76.05

[한성대학교]

■ 메타데이터 검색 및 활용 기술 개발

- **(프로파일링 고도화)** 프로파일링 시스템 구성도 및 2단계 주요 고도화 내용

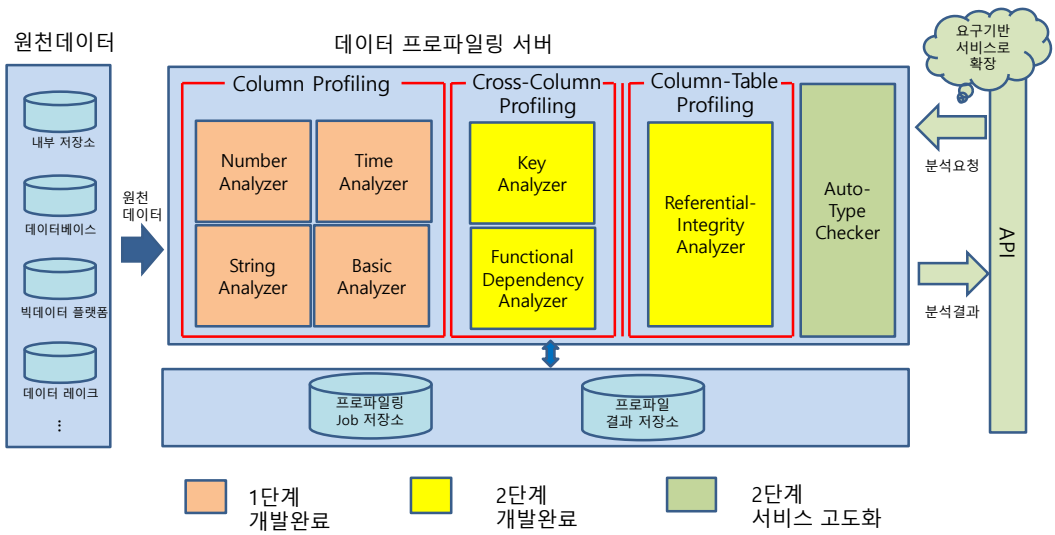

[그림 104] 고도화된 프로파일링 시스템 구성도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- ✓ 메타데이터 검색이 지원되는 주문형(요구기반) 프로파일링 서비스 개발
- ✓ 다중 컬럼(cross-column), 다중 테이블(cross-table)에 대한 프로파일링 서비스 확장 개발
- ✓ 컬럼 데이터에 대한 타입 자동인식 기능 개발 및 성능 개선
- ✓ 오픈 API 명세 확장 및 관련 서비스 개발

▪ **(프로파일링 검색 서비스 지원)** 메타데이터에 대한 상세 검색이 가능하도록 주문형 프로파일링 서비스 개발

- ✓ 1단계에서 개발 완료한 배치형 프로파일링 서비스를 기반으로, 프로파일링 세부 항목에 대한 검색 서비스가 가능하도록 프로파일링 편집 및 검색 기능 개발
- ✓ 편집된 프로파일링 명세에 따라 프로파일 결과를 생성 또는 검색하여 그 결과를 제공하도록 확장 개발

▪ **(프로파일링 서비스 고도화)** 다중 컬럼, 다중 테이블에 대한 프로파일링 기능 제공

- ✓ 1단계에서는 단일 컬럼 프로파일링을 단순 제공함. 2단계에서는 테이블 내의 컬럼 간의 관계를 분석하는 다중 컬럼 프로파일링과 테이블 간의 관계를 분석하는 다중 테이블 프로파일링 기능을 확장 개발함
- ✓ 다중 컬럼 프로파일링은 크게 후보키를 탐색하는 키 분석(key analysis)과 컬럼 간의 함수적 종속관계를 분석하는 의존성 분석(dependency analysis) 기능을 개발
- ✓ 다중 테이블 프로파일링은 테이블 간의 참조 무결성을 분석하는 기능을 개발
- ✓ 다중 컬럼, 다중 테이블에 대한 확장된 프로파일링 요청 API 명세 (일부)

[표] 확장된 요청 API

항목명(영문)	항목구분	샘플데이터	항목설명
key_analysis	0	true, false	기본키가 될 수 있는 후보키 컬럼을 탐색할지의 여부 결정하는 boolean값 (default:false)
dependency_ analysis	0..n	-	여러개의 함수적 종속을 동시에 검사할 수 있도록 결정자와 의존자 쌍의 배열 형태로 명세함. 현 버전에서는 결정자와 의존자는 단일 컬럼만 지원 (determinant->dependency 의 리스트)
determinant	0	1, 2 또는 “id”	컬럼번호 또는 컬럼명
dependency	0	1, 2 또는 “id”	컬럼번호 또는 컬럼명
fk_analysis	0..n	-	현재 테이블의 컬럼과 타 테이블의 컬럼간 참조무결성의 유효성 여부를 검사. 배열 형식을 여러개의 무결성을 동시에 검사할 수 있도록 명세 지원
foreign_key	0	1, 2 또는 “id”	컬럼번호 또는 컬럼명
referenced_file	0	http://qufa.com/sample.csv	프로파일링 대상 파일의 URL 경로. 원격 파일일 경우 "http://" + 파일 url 로컬 파일일 경우 "file:///" + 파일 경로
referenced_column	0	1, 2 또는 “id”	참조되는 컬럼명 이름

- ✓ 다중 컬럼, 다중 테이블에 대한 프로파일링 응답 API 명세 (일부)

[표] 확장된 응답(결과) API

항목명	항목구분	샘플데이터	항목설명
key_analysis_results	0..n	[1, 3, 5] 또는 [“id”, “name”]	후부키 대상이 되는 컬럼 배열 (컬럼번호 또는 컬럼명)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

dependency_analysis_results		0..n	-	
	determinant	0	1, 2 또는 “id”	결정자(컬럼번호 또는 컬럼명)
	dependency	0	1, 2 또는 “id”	의존자(컬럼번호 또는 컬럼명)
	is_valid	0	true or false	함수적 종속 만족여부
	invalid_values	0..n	[1, 4, 6]	결정자 컬럼 중 함수적 종속을 위배해는 컬럼값의 배열 is_valid가 false일 경우에만 해당 값들을 배열로 명시하고, true면 생략
fk_analysis_results		0..n	-	
	foreign_key	0	1, 2 또는 “id”	참조하는 컬럼번호 또는 컬럼명
	referenced_table	0	“customer.csv” 또는 “customer”	참조되는 파일명 또는 테이블명
	referenced_column	0	“id”	참조되는 컬럼명(외부 테이블이므로 컬럼번호는 허용안함)
	is_valid	0	true or false	참조무결성 준수여부
	invalid_values	0..n	[1, 4, 6]	참조무결성을 위배하는(참조되는 값이 존재하지 않는) 컬럼 값들의 배열 is_valid가 false일 경우에만 해당 값들을 배열로 명시하고, true면 생략

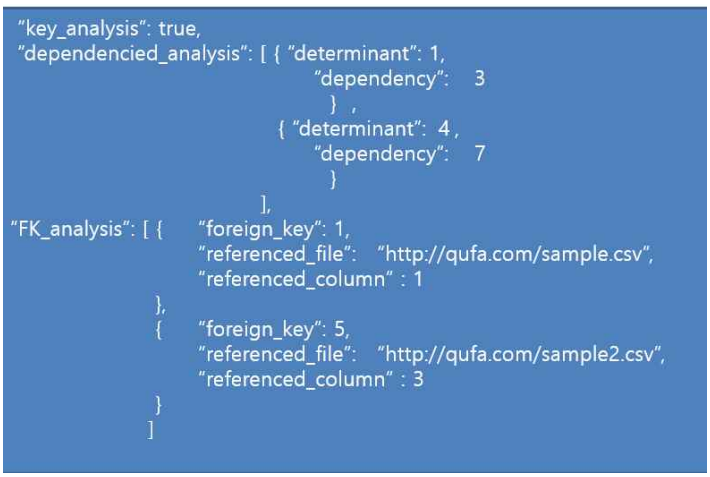

(a) 요청 API

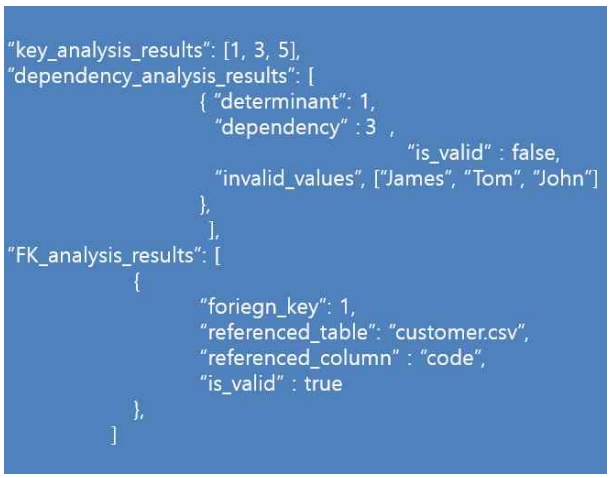

(b) 응답 API

[그림 105] 확장된 요청 및 응답API 예

- **(프로파일링 성능 개선)** 프로파일링 성능 개선을 위한 샘플링 기술 개발
  - ✓ 타입 자동 인식의 성능을 개선하기 위한 적응형 샘플링 방법 적용 개발
  - ✓ 일정 크기 이상의 원천 데이터에 대해서 샘플링 크기를 적정 수준으로 유지하기 위한 기술 적용

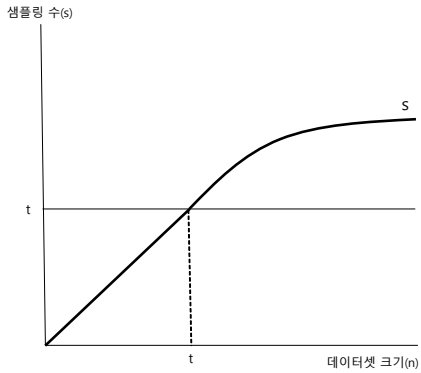

샘플수 $s = n \quad (n \leq t)$
$s = t + \log(n-t) \quad (n > t)$

[그림 106] 샘플링 크기 결정방식

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[프람트테크놀로지]

■ 데이터 품질 개선 솔루션 통합 및 고도화

▪ 데이터 품질개선 솔루션 통합: 사용자가 데이터맵을 통하여 시스템에 탑재된 특정 범위의 데이터셋을 검색·프로파일링을 수행하여, 그 대상 데이터에 대한 품질 측정·개선을 통하여 적정 수준 이상의 품질을 가지는 데이터셋을 fabricate하는 전 life cycle을 통합 구현함

✓ 데이터 품질개선 시스템 기능 통합

- 데이터 품질 프로세스의 시발점인 데이터 품질 및 적재모듈(이하: Data Hunter)을 재설계 구현하고 이를 QuFa Studio에 통합
- Data Hunter는 원천데이터 등록 후 메타데이터 자동추출 및 추출된 메타데이터와 원천데이터를 DB에 적재하는 기능을 담당하는 모듈임

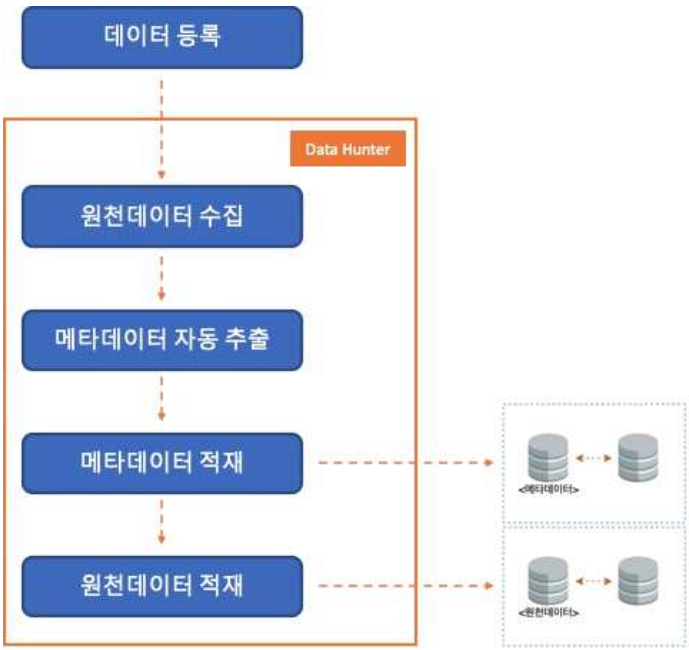

[그림 107] Data Hunter 프로세스 흐름

- 타대학 연구진(서울시립대, 한성대, 이화여대)의 신규 알고리즘 개발 결과를 테스트 및 검증하고 데이터 품질 측정, 오류 탐지·보정·개선 모듈을 통합 구현 하였음
- MSA(MicroService Architecture)로 구축되어 데이터 프로파일링 수행 전 원천데이터 및 메타데이터 수집 결과를 연계 데이터베이스에 적재함으로써 프로파일러는 보다 데이터 프로파일링 수행에 집중하며 모듈 간 독립성과 향후 확장성을 동시에 보장
- 신규 알고리즘의 모듈화 및 MSA(Micro-Service Architecture) 적용으로 연계 유연성을 확보함과 동시에 독립성과 이식성을 강화해 다양한 형태의 by-product를 양산할 수 있는 체제를 갖춤
- Data Hunter의 경우도, 여타 모듈과 마찬가지로 Docker image pull 형태로 손쉽게 설치하고 실행할 수 있도록 오픈소스 환경의 실질적인 de facto standard 형태의 검증된 best practice 환경으로 구성

✓ 데이터 맵 모듈 신규 구현 및 통합

- 융합 가능한 데이터셋을 검색하여 융합 분석이 가능하도록 키워드 기반 검색 기능을 구현 하여, 이를 데이터맵 형태로 시각화 하는 기능을 구현하고 통합 하였음
- 데이터 프로파일링 모듈을 통합 구현하며, 이를 통한 메타데이터 기반 유사도분석 알고리즘을 적요하여 궁극적으로는 데이터맵 활용을 통한 융합분석이 가능하도록 통합 구현 하였음

▪ 데이터 품질 개선 솔루션 고도화: 데이터 품질개선 시스템 기타 기능을 개발하고 기존의 시각화 기능을 개선하고 보완함

✓ Parameter 및 Configuration 정보 설정 기능

- 데이터 이상치 제거 등 사용자가 원하는 정제·보정 기능을 Parameter를 통해 간편하게 설정할

수 있도록 함

- Parameter 및 Configuration 정보 설정을 위한 사용자 최적화 UI/UX를 추가로 설계하고 구현함

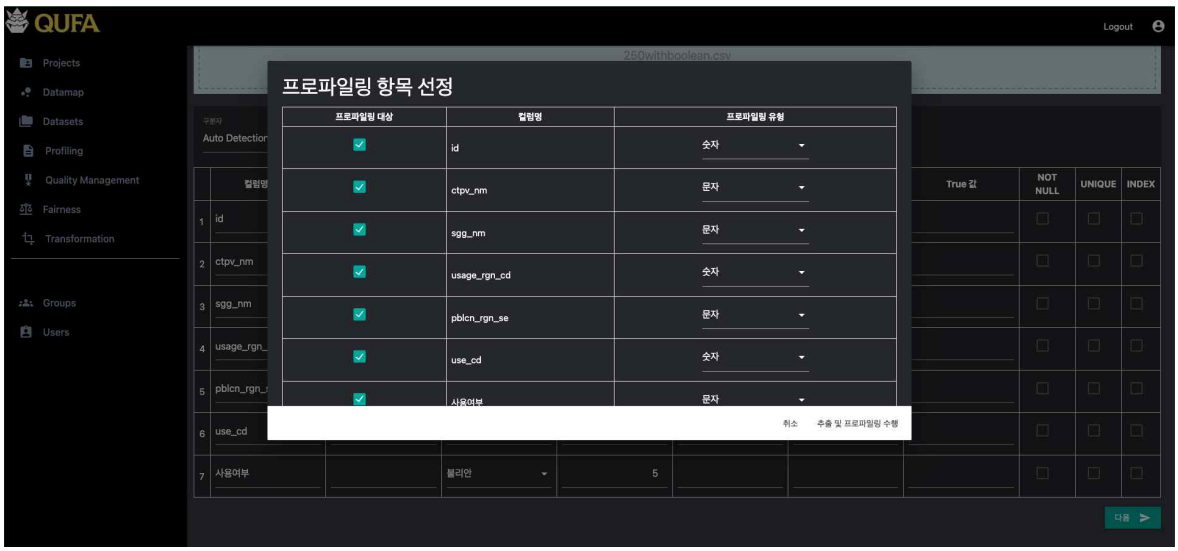

[그림 108] 데이터 프로파일링 항목 사용자 설정 UI/UX

✓ 시각화 기능 개선 및 보완

- Data 품질 진단/보정 및 Profiling 결과 시각화 기능 개선 및 고도화를 수행함
- 프로파일링을 항목별로 수행할 수 있도록 기능을 추가 구현하고 프로파일링 대상 컬럼의 타입을 사용자가 지정할 수 있도록 함
- 신규 알고리즘을 적용하여 융합이 가능한 데이터셋을 초기 검색에 이어 추가로 검색하는 기능을 보강하여 통합하고 추천 결과를 표출하는 UI/UX를 구현
- Data 품질 Life Cycle을 사용자가 제어하고 Life Cycle 단계별 모니터링 기능을 구현하여 고도화 작업을 수행함

[그림 109] 프로파일링 결과 시각화

▪ QuFa Studio 오픈소스 개방 및 AWS Market Place 탑재

✓ Data 품질 모듈, Profiling 모듈, Feature Engineering 모듈, Data 공정성 모듈 전체를 API를 이용한 MSA 방식으로 시스템 통합

✓ QuFa GITLAB 을 통한 오픈소스화 및 AWS Market Place 탑재

■ 데이터 맵 기술 개발

▪ 융합 데이터셋 검색 및 시각화 기능 개발: 초기 검색 데이터셋과 융합 가능한 데이터셋을 준자동으로 검색하고 이를 시각화 함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 데이터맵 모듈 설계

- 데이터셋 업로드를 통해 메타데이터 추출, 유사도 알고리즘 적용을 통한 연관도 분석, 결과 저장 후 데이터맵 렌더링 과정까지의 프로세스 정립

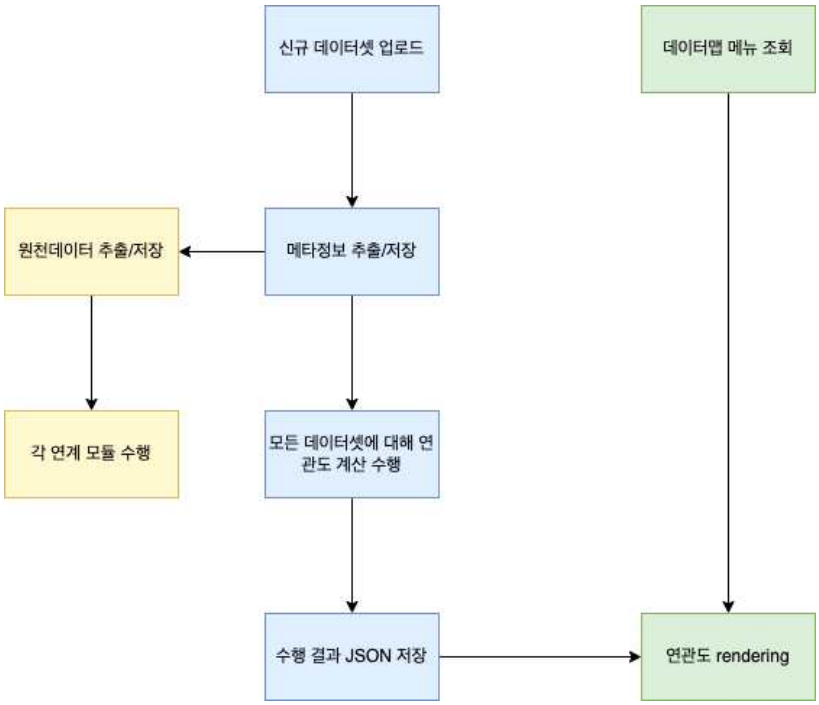

[그림 110] 데이터맵 프로세스 흐름도

- Euclidean Distance 측정 방식을 메타데이터에 적용하기 위해서 각 Vector point에 해당하는 요소를 결정해야 하는데, Qufa Studio 에서는 키워드 요소(키워드들의 집합)를 각 point의 요소로 지정하고, 이를 기반으로 유사도 측정을 수행하는 방식을 취함
- 국내에 공개된 데이터셋중 10개를 임의로 선정하여 메타데이터 키워드 요소 값으로 활용하였으며,이는 동적으로 변경 가능하도록 구현함

✓ 메타데이터 기반 유사도 산출 알고리즘 적용 및 시각화

- 메타데이터 및 프로파일링 결과를 활용하여 데이터셋간의 유사도를 측정하고, 유사도 측정 결과를 바탕으로 데이터맵 형태로 표출함
- 메타데이터 형식 및 요소를 기반으로, 메타데이터 간의 유사도 측정을 위해 Euclidean Distance 측정 방식을 사용함
- Euclidean n-space의 p=(p1,p2,...,pn) 과 q=(q1,q2,...,qn) 간의 거리 측정은 다음과 같이 계산

$$d(p,q) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \cdots + (q_n - p_n)^2}$$

- 대량의 데이터셋을 효율적으로 브라우징 및 검색하기 위하여 서클 뷰 (circle view) 형태로 전체 또는 검색결과를 조망할 수 있도록 UI/UX를 구성하여 구현
- 유사도에 기반한 데이터 시각화는 각 메타데이터간의 추출된 유사도를 기반으로, 데이터간의 유사성을 한눈에 볼 수 있도록 하는 Visualization 기법으로써, 사용자에 의해 검색되는 데이터셋을 중심이 되는 노드, 즉 root로 가지는 tree형태의 데이터 구조를 취하도록 설계함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

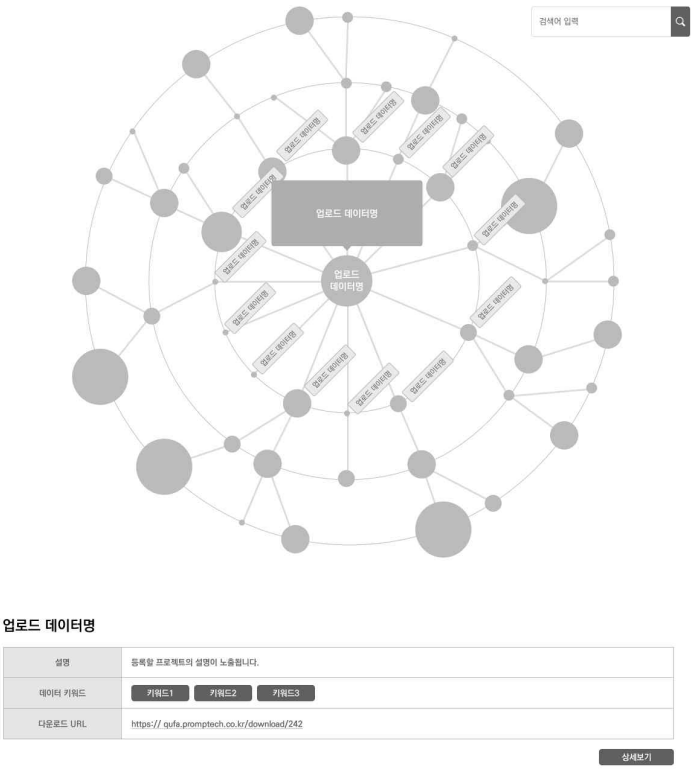

[그림 111] 데이터맵 시각화 화면 설계

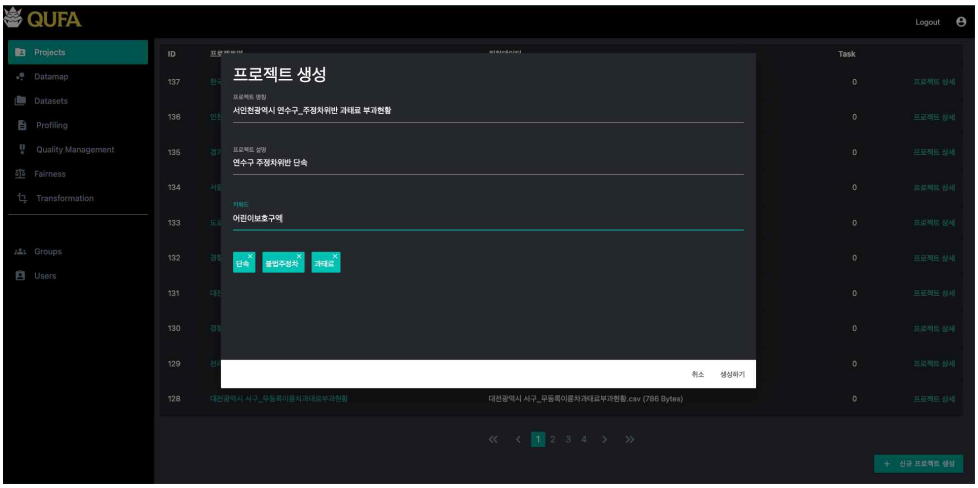

[그림 112] 데이터 셋 검색을 위한 프로젝트 생성 UI/UX

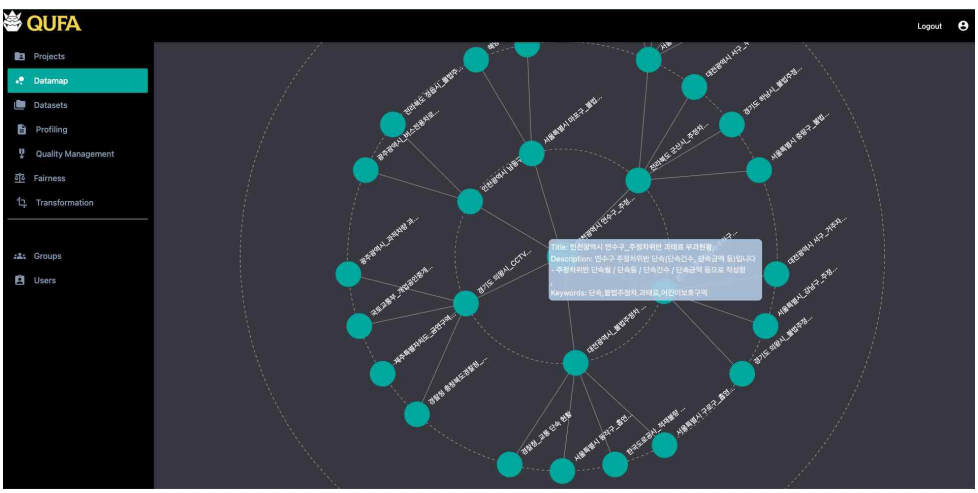

[그림 113] 데이터맵 시각화 구현 결과 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[아이소프트]

- 공정성 도구 고도화 및 통합 UI/UX

✓ 공정성 도구 고도화 및 통합을 위한 가시화 시스템 구조

- 정적 데이터 보상을 위한 시스템과 동적 보상을 위한 시스템 설계
- 정적 데이터 및 동적 데이터를 수집하여 전처리 및 가시화를 위한 시스템 설계
- 오픈 소스에서 많이 사용하는 최신 기술인 Docker, ELK stack 및 가시화를 위한 Kibana 등을 활용하여 시스템 설계

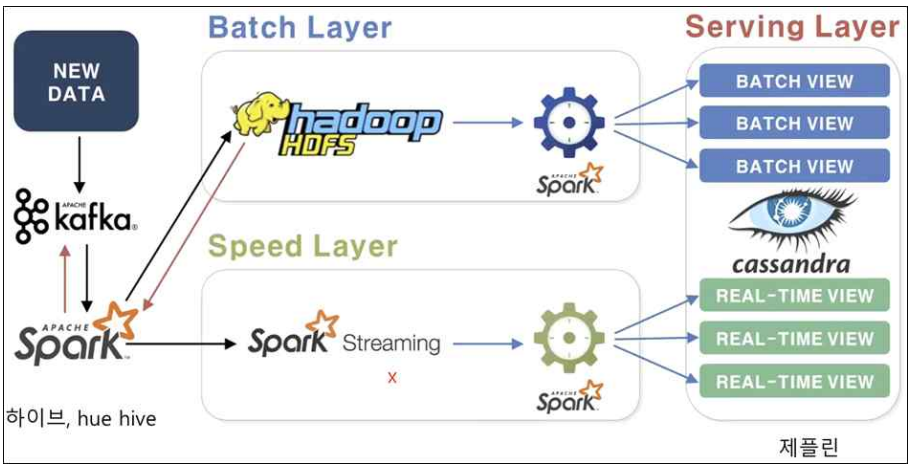

[그림 114] 통합 시스템 구조도

✓ 공정성 도구 고도화 및 통합을 위한 인터페이스 설계

- 부산대와 아이소프트간 공정성 지표별 보정 요청 및 응답 인터페이스 설계
- 보라매 병원에서 공정성 보정을 위한 보건데이터 분석을 위한 인터페이스 설계
- 항만물류 데이터의 공정성 보정을 위한 인터페이스 설계

✓ 공정성 도구 고도화 및 통합을 위한 데이터 흐름도 설계

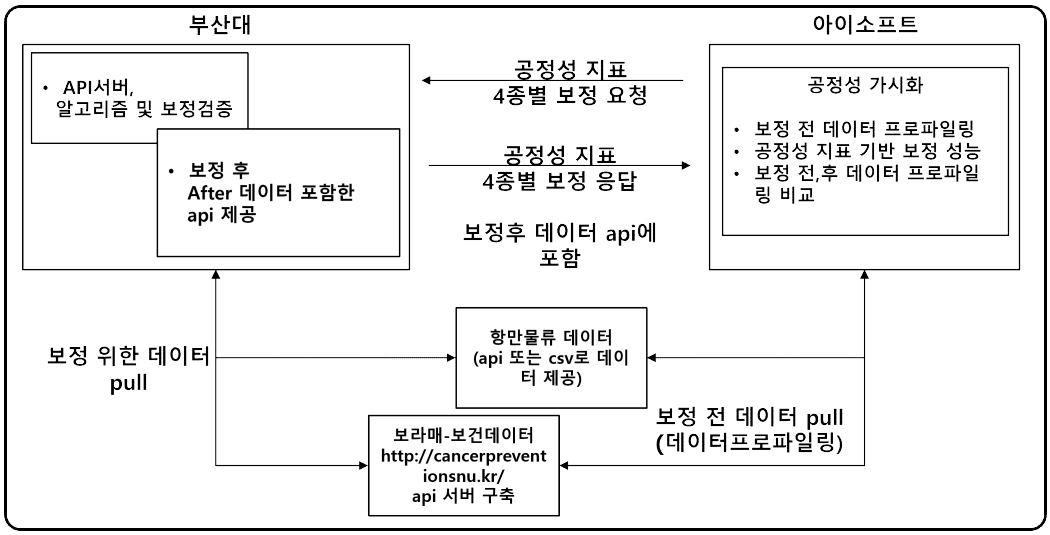

[그림 115] 공정성 도구 고도화 및 통합을 위한 데이터 흐름도

✓ 공정성 도구 가시화 통합 화면

- ELK Stack 으로 정적 보상과 동적 보상 메뉴에 따른 각각의 결과 화면으로 구성
- Big Data Echo Project는 Hadoop, Spark, Zeppelin으로 구성
- 데이터 공정성 정의를 서술하며 인공지능 모델에 따른 조건과 예측에 대한 가시화
- 정적데이터 공정성 보정 기술 알고리즘을 가시화
- 동적데이터(배치기반) 공정성 보정 기술 알고리즘을 가시화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

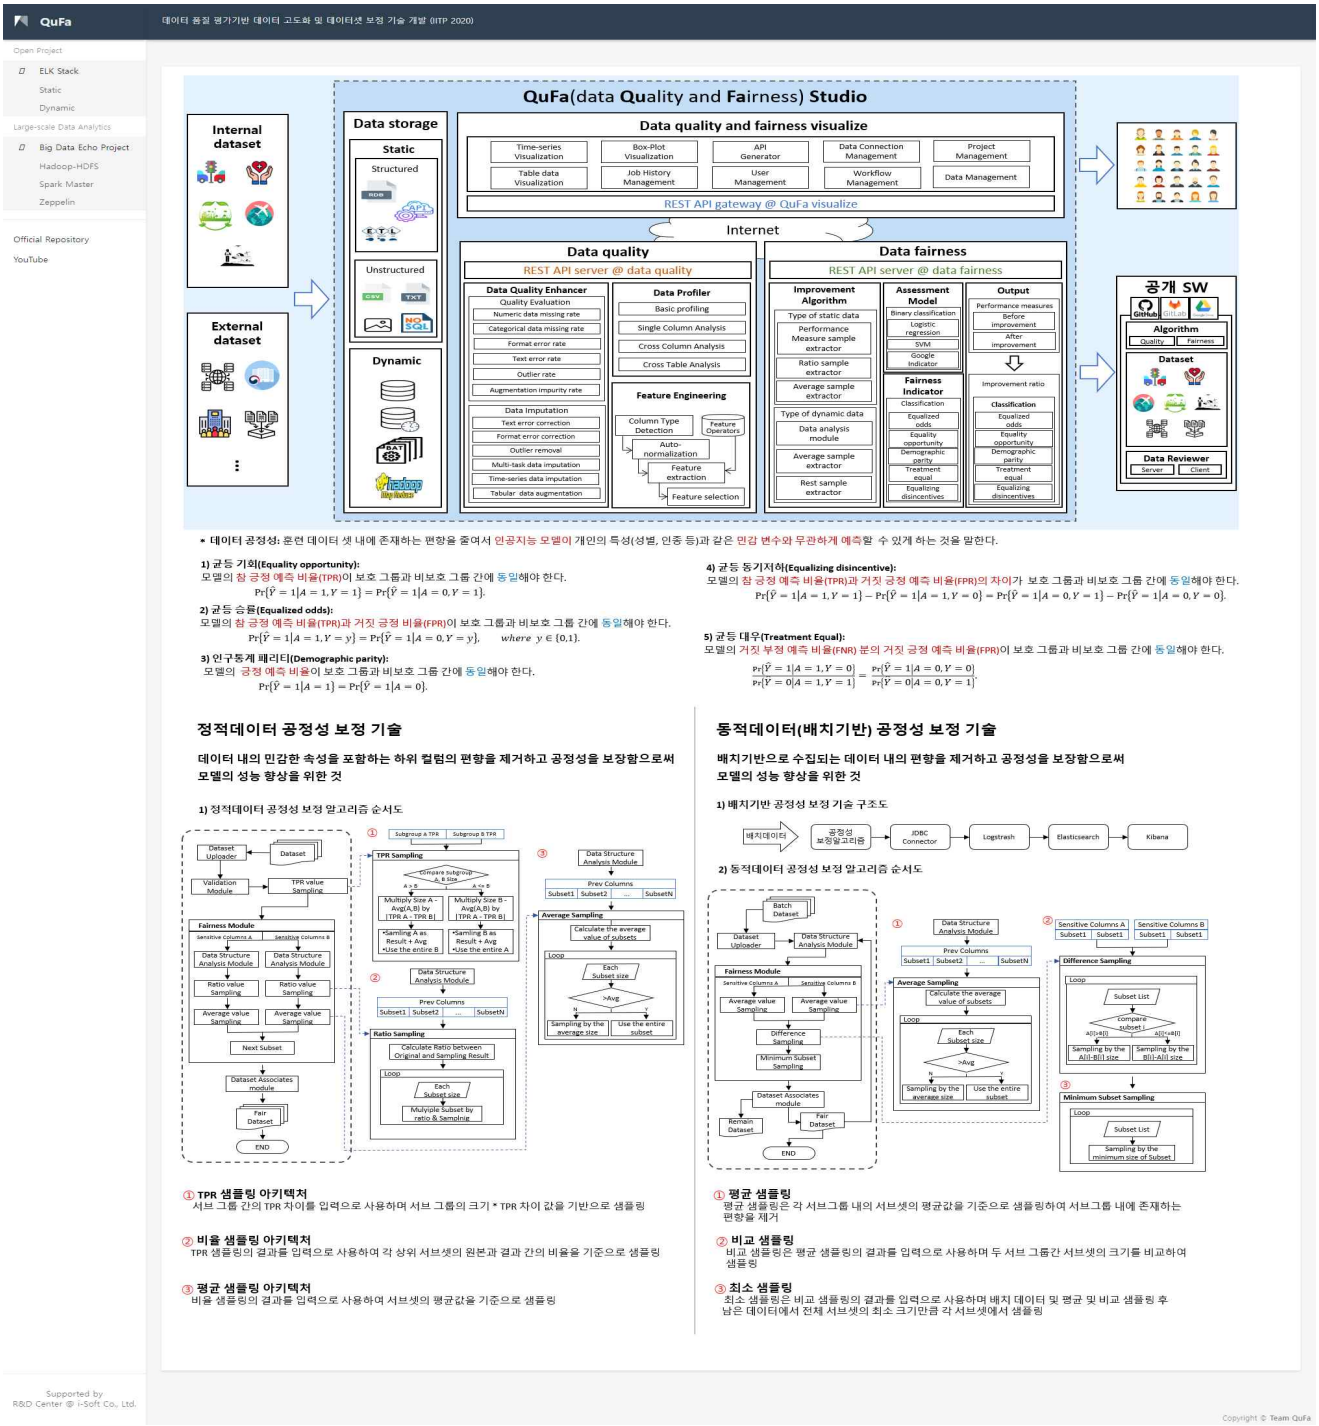

* **데이터 공정성:** 훈련 데이터 셋 내에 존재하는 편향을 줄여서 인공지능 모델이 개인의 특성(성별, 인종 등)과 같은 민감 변수와 무관하게 예측할 수 있게 하는 것을 말한다.

1) 균등 기회(Equality opportunity):
모델의 참 긍정 예측 비율(TPR)이 보호 그룹과 비보호 그룹 간에 동일해야 한다.

$$\Pr\{\hat{Y}=1|A=1,Y=1\}=\Pr\{\hat{Y}=1|A=0,Y=1\}.$$

2) 균등 승률(Equalized odds):
모델의 참 긍정 예측 비율(TPR)과 거짓 긍정 비율(FPR)이 보호 그룹과 비보호 그룹 간에 동일해야 한다.

$$\Pr\{\hat{Y}=1|A=1,Y=y\}=\Pr\{\hat{Y}=1|A=0,Y=y\}, \quad where\ y\in\{0,1\}.$$

3) 인구통계 패리티(Demographic parity):
모델의 긍정 예측 비율이 보호 그룹과 비보호 그룹 간에 동일해야 한다.

$$\Pr\{\hat{Y}=1|A=1\}=\Pr\{\hat{Y}=1|A=0\}.$$

4) 균등 동기저하(Equalizing disincentive):
모델의 참 긍정 예측 비율(TPR)과 거짓 긍정 예측 비율(FPR)의 차이가 보호 그룹과 비보호 그룹 간에 동일해야 한다.

$$\Pr\{\hat{Y}=1|A=1,Y=1\}-\Pr\{\hat{Y}=1|A=1,Y=0\}=\Pr\{\hat{Y}=1|A=0,Y=1\}-\Pr\{\hat{Y}=1|A=0,Y=0\}.$$

5) 균등 대우(Treatment Equal):
모델의 거짓 부정 예측 비율(FNR) 분의 거짓 긍정 예측 비율(FPR)이 보호 그룹과 비보호 그룹 간에 동일해야 한다.

$$\frac{\Pr\{\hat{Y}=1|A=1,Y=0\}}{\Pr\{\hat{Y}=0|A=1,Y=1\}}=\frac{\Pr\{\hat{Y}=1|A=0,Y=0\}}{\Pr\{\hat{Y}=0|A=0,Y=1\}}.$$

정적데이터 공정성 보정 기술

데이터 내의 민감한 속성을 포함하는 하위 컬럼의 편향을 제거하고 공정성을 보장함으로써 모델의 성능 향상을 위한 것

1) 정적데이터 공정성 보정 알고리즘 순서도

① TPR 샘플링 아키텍처
서브 그룹 간의 TPR 차이를 입력으로 사용하며 서브 그룹의 크기 * TPR 차이 값을 기반으로 샘플링

② 비율 샘플링 아키텍처
TPR 샘플링의 결과를 입력으로 사용하여 각 상위 서브셋의 원본과 결과 간의 비율을 기준으로 샘플링

③ 평균 샘플링 아키텍처
비율 샘플링의 결과를 입력으로 사용하여 서브셋의 평균값을 기준으로 샘플링

동적데이터(배치기반) 공정성 보정 기술

배치기반으로 수집되는 데이터 내의 편향을 제거하고 공정성을 보장함으로써 모델의 성능 향상을 위한 것

1) 배치기반 공정성 보정 기술 구조도

2) 동적데이터 공정성 보정 알고리즘 순서도

① 평균 샘플링
평균 샘플링은 각 서브그룹 내의 서브셋의 평균값을 기준으로 샘플링하여 서브그룹 내에 존재하는 편향을 제거

② 비교 샘플링
비교 샘플링은 평균 샘플링의 결과를 입력으로 사용하며 두 서브 그룹간 서브셋의 크기를 비교하여 샘플링

③ 최소 샘플링
최소 샘플링은 비교 샘플링의 결과를 입력으로 사용하며 배치 데이터 및 평균 및 비교 샘플링 후 남은 데이터에서 전체 서브셋의 최소 크기만큼 각 서브셋에서 샘플링

[그림 116] 통합 가시화 첫 페이지

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 정적데이터 공정성 보정 기술 가시화 화면

- 정적데이터 보상 가시화 메인 화면
- 심장질환 예측서비스를 위한 원본데이터(보건: 총13만건) 기초 분석
- 약 13만건 = 원본데이터 약 10만건과 GAN 기반 모조데이터 (원본의 33.3%)
- 모조 데이터 추가에 따른 공정성 보정 후의 인공지능 학습데이터셋 수량 보완
- 심장발병예측 분포비율(%), 성별 분포비율(%), 연령대 분포비율(%), 심장질환과거력 분포비율(%), 심장질환가족력 분포비율(%), 연평균흡연량 분포비율(%), 일주일간 음주빈도 분포비율(%)을 가시화

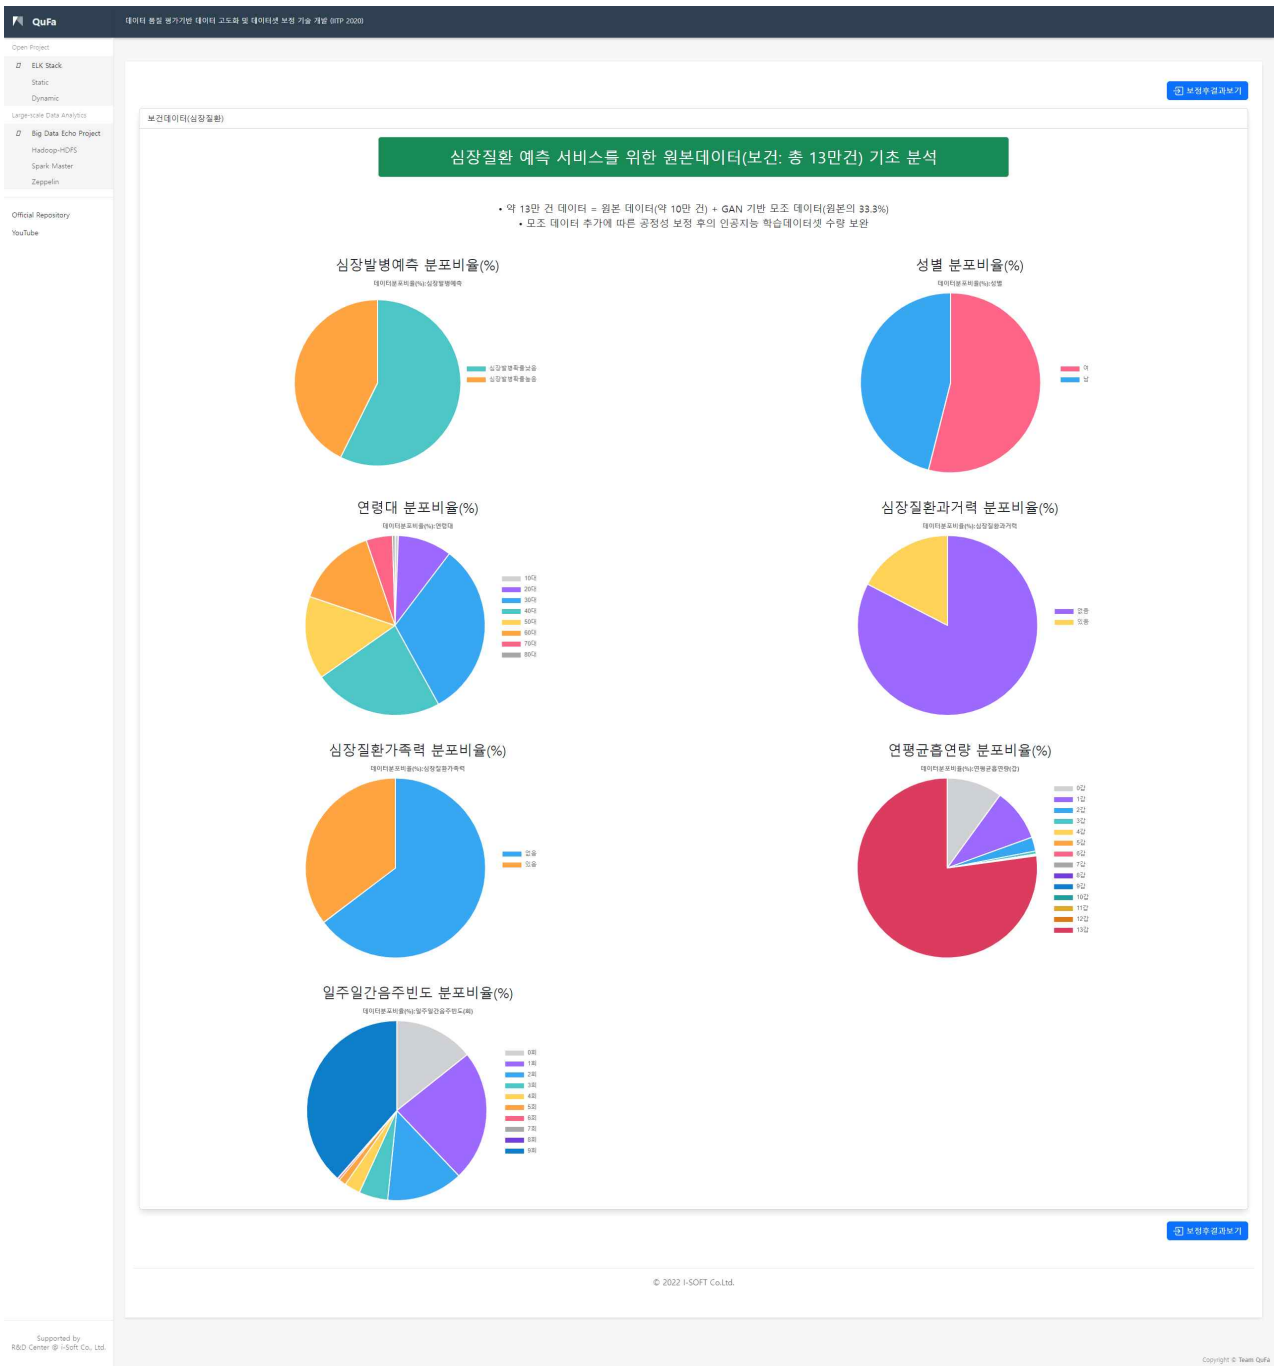

[그림 117] 정적데이터 보정 가시화 첫 화면

✓ 정적데이터 공정성 보정 후 가시화 (균등기회)

- 균등기회에 따른 보정률과 보정전, 보정후 차이를 가시화
- 균등기회(Equality opportunity): 모델의 참 긍정 예측 비율(TPR)이 보호 그룹과 비

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

보호 그룹간에 동일해야 함을 의미

- 심장발병예측의 보정전과 보정후 분포비율(%), 성별 보정전, 후 분포비율(%), 연령대 보정전, 후 분포비율(%), 심장질환과거력 보정전,후 분포비율(%), 심장질환가족력 보정전, 후 분포비율(%), 연평균흡연량 보정전, 후 분포비율(%), 일주일간 음주빈도 보정전, 후 분포비율(%)차이를 가시화

[그림 118] 정적데이터 보정 가시화 – (균등기회) 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 정적데이터 공정성 보정 후 가시화 (균등승률)

- 균등승률에 따른 보정률과 보정전, 후 TPR, FPR 차이를 가시화
- 균등승률(Equalized odds): 모델의 참 긍정 예측 비율(TPR)과 거짓 긍정 비율(FPR)이 보호 그룹과 비 보호 그룹간에 동일해야 함을 의미
- 심장발병예측의 보정전, 후 분포비율(%), 성별 보정전, 후 분포비율(%), 연령대 보정전, 후 분포비율(%), 심장질환과거력 보정전, 후 분포비율(%), 심장질환가족력 보정전, 후 분포비율(%), 연평균흡연량 보정전, 후 분포비율(%), 일주일간 음주빈도 보정전, 후 분포비율(%)차이를 가시화

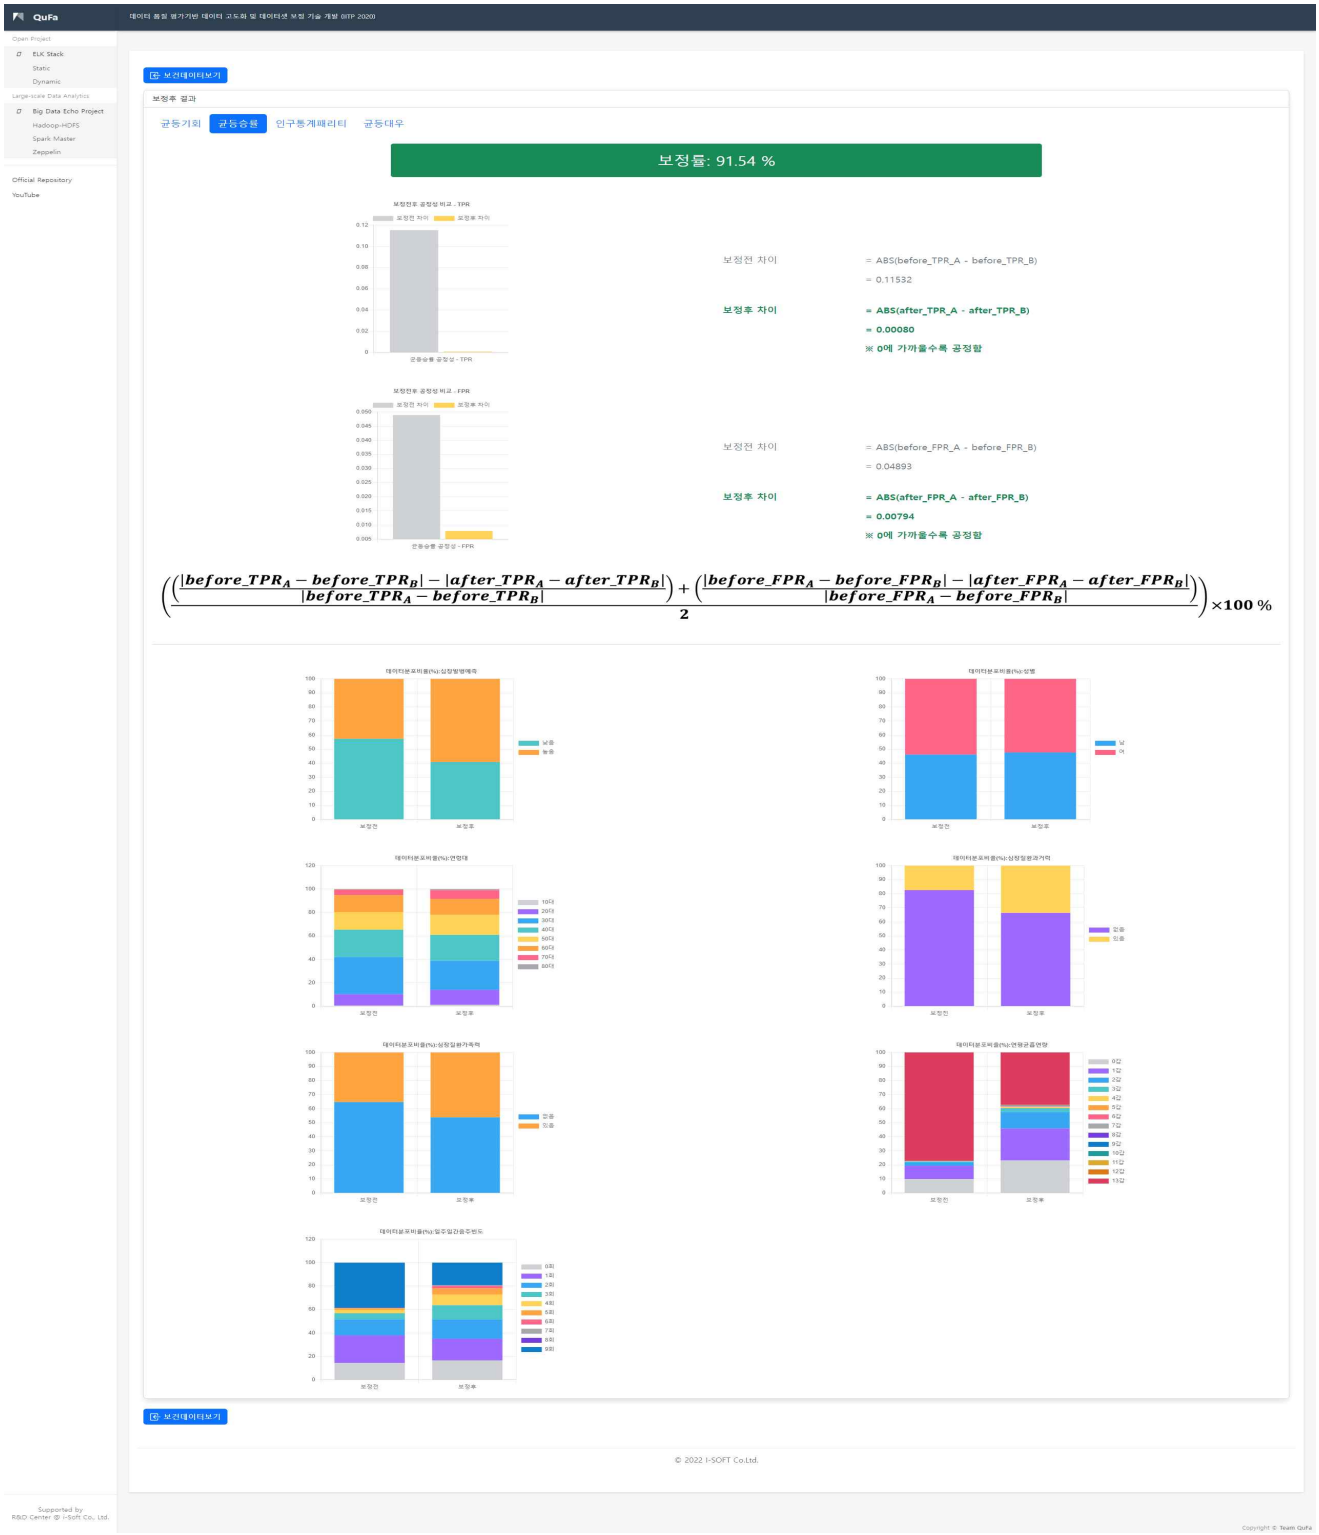

[그림 119] 정적데이터 보정 가시화 – (균등승률) 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 정적데이터 공정성 보정 후 가시화 (인구통계패리티)

- 인구통계패리티에 따른 보정률과 보정전, 후 차이를 가시화
- 인구통계패리티(Demographic parity): 모델의 긍정 예측 비율이 보호 그룹과 비보호 그룹 간에 동일해야 함을 의미
- 심장발병예측의 보정전, 후 분포비율(%), 성별 보정전, 후 분포비율(%), 연령대 보정전, 후 분포비율(%), 심장질환과거력 보정전, 후 분포비율(%), 심장질환가족력 보정전, 후 분포비율(%), 연평균흡연량 보정전, 후 분포비율(%), 일주일간 음주빈도 보정전, 후 분포비율(%)차이를 가시화

[그림 120] 정적데이터 보정 가시화 – (인구통계패리티) 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 정적데이터 공정성 보정 후 가시화 (균등 대우)

- 균등 대우에 따른 보정률과 보정전, 후 차이를 가시화
- 균등 대우(Treatment Equal): 모델의 거짓 부정 예측 비율(FNR)분의 거짓 긍정 예측 비율(FPR)의 보호 그룹과 비보호 그룹 간에 동일해야 함을 의미
- 심장발병예측의 보정전, 후 분포비율(%), 성별 보정전, 후 분포비율(%), 연령대 보정전, 후 분포비율(%), 심장질환과거력 보정전, 후 분포비율(%), 심장질환가족력 보정전, 후 분포비율(%), 연평균흡연량 보정전, 후 분포비율(%), 일주일간 음주빈도 보정전, 후 분포비율(%)차이를 가시화

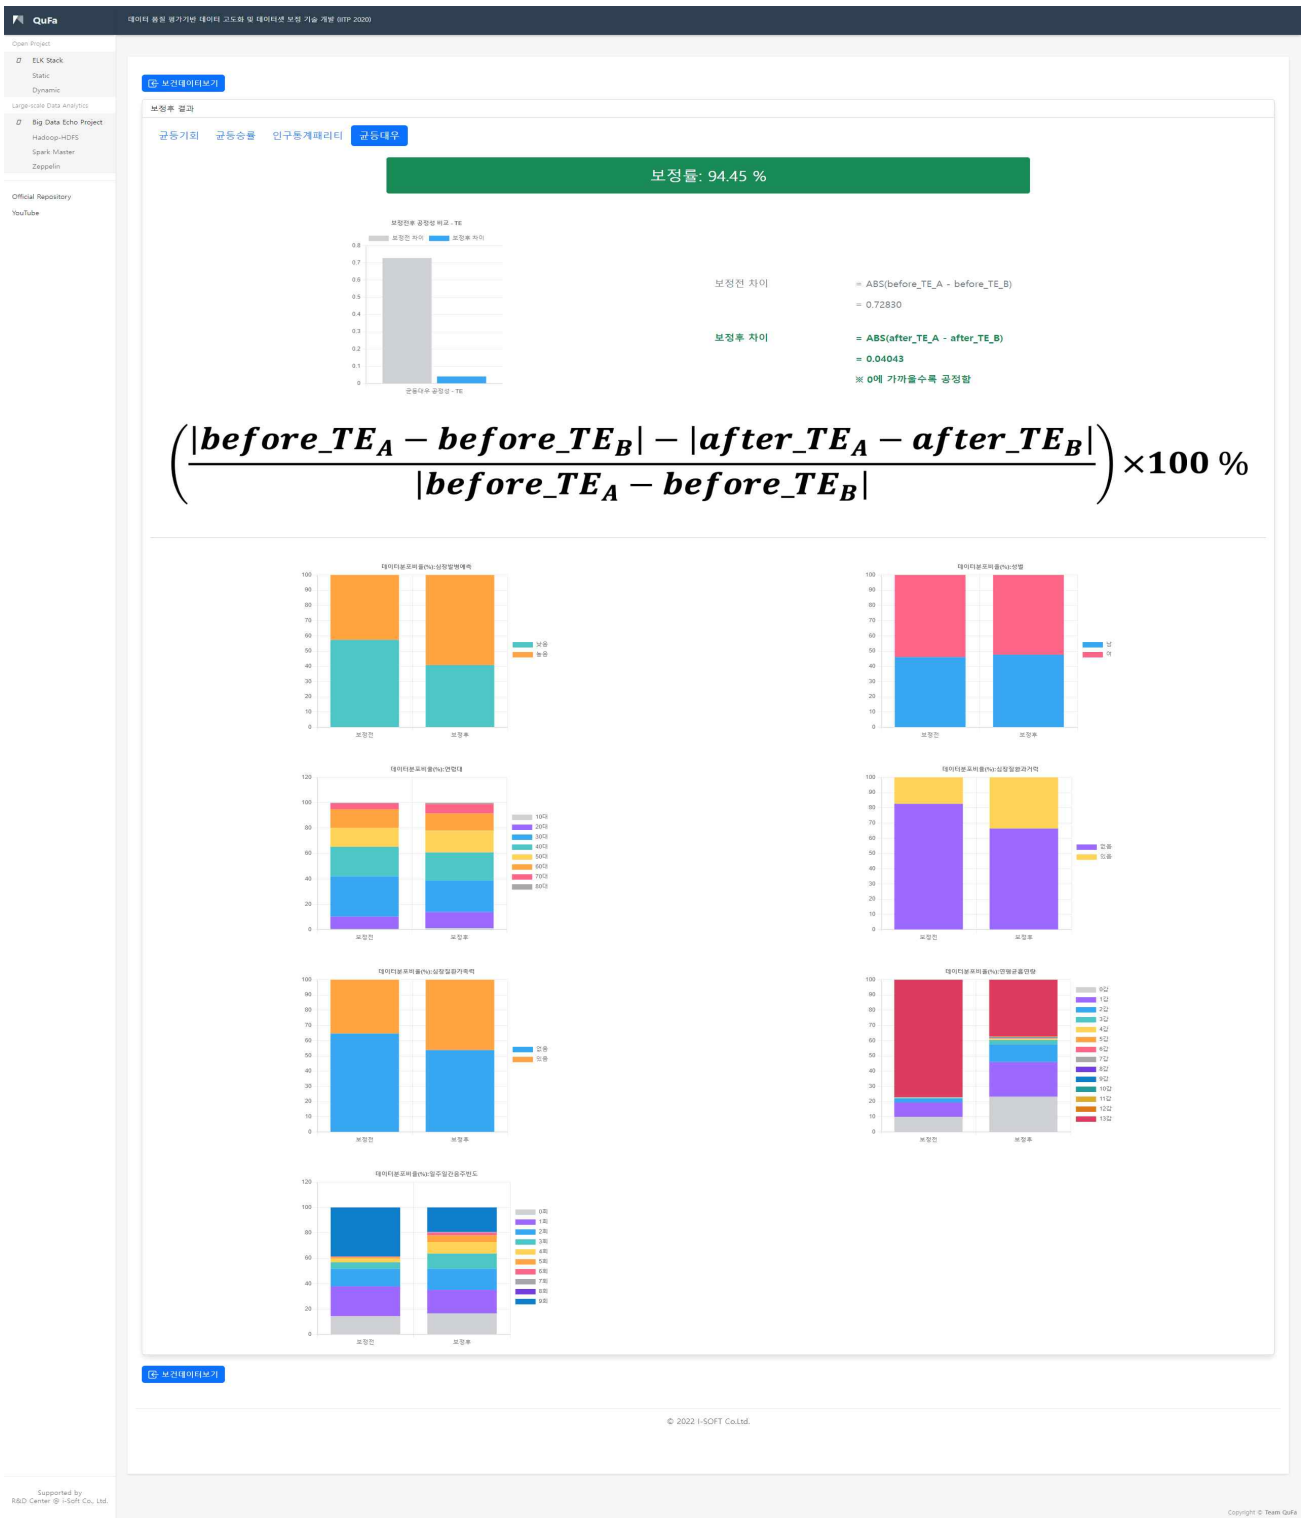

[그림 121] 정적데이터 보정 가시화 – (균등대우) 화면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 동적데이터 보정 가시화 시스템 구조 및 가시화

- Batch Data를 공정성 보정 알고리즘으로 처리 후 가시화
- 오픈 소스에서 많이 사용하고 있는 Docker, ELK stack Kibana 시스템으로 구성하여 가시화 지원

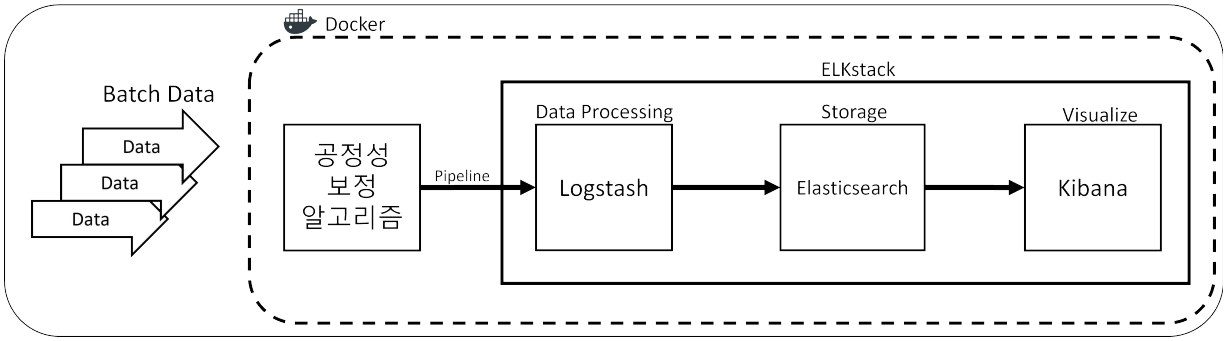

[그림 122] 동적데이터 보정 가시화 시스템 구조도

✓ 동적데이터 공정성 보상 화면 구성

- 동적데이터 공정성 보상 처리 절차 가시화
- 동적 보상 정의 및 지표별로 정의 및 결과 해석을 가시화

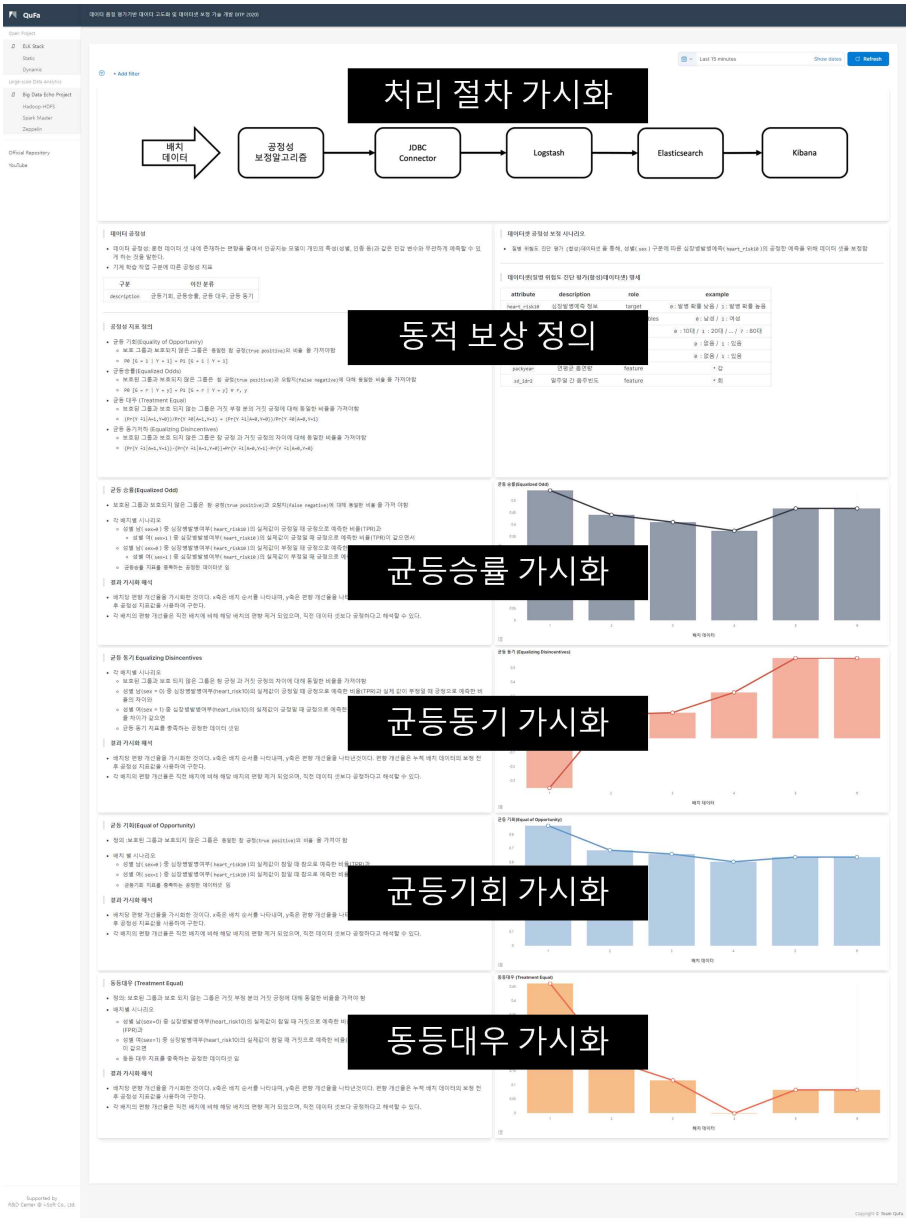

[그림 123] 동적데이터 보정 가시화 화면 구성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 동적데이터 공정성 보정 후 가시화 (균등 승률)

- 동적 배치 데이터별로 시나리오 서술, 결과 가시화 해석 및 개선율을 가시화
- 균등승률(Equalized Odd): 보호된 그룹과 보호되지 않은 그룹은 참 긍정(true positive)과 오탐지(false negative)에 대해 동일한 비율을 가져야 함을 의미

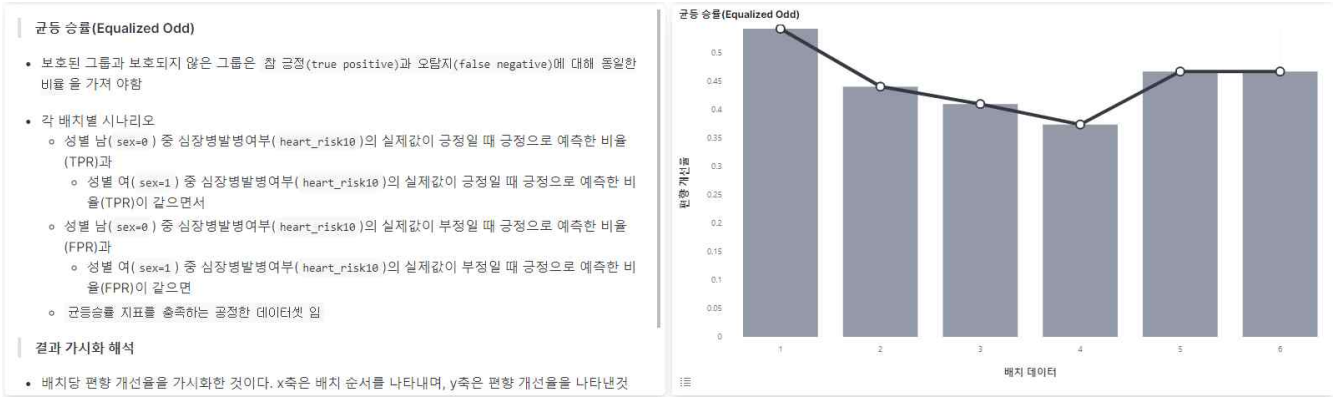

[그림 124] 동적데이터 보정 후 가시화(균등승률)

✓ 동적데이터 공정성 보정 후 가시화 (균등 동기)

- 동적 배치 데이터별로 시나리오 서술, 결과 가시화 해석 및 개선율을 가시화
- 균등동기(Equalizing Disincentives): 보호된 그룹과 보호되지 않은 그룹은 참 긍정(true positive)과 거짓 긍정의 차이에 대해 동일한 비율을 가져야 함을 의미

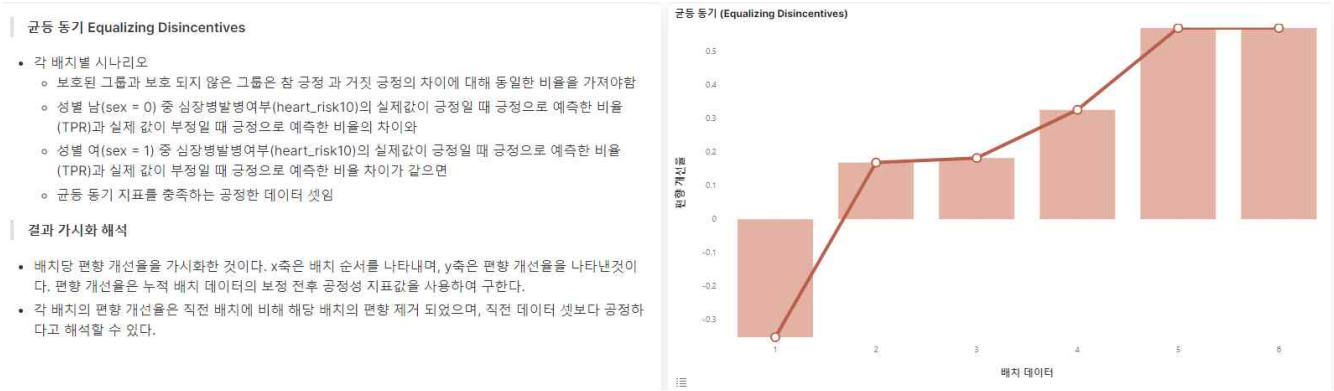

[그림 125] 동적데이터 보정 후 가시화(균등동기)

✓ 동적데이터 공정성 보정 후 가시화 (균등 기회)

- 동적 배치 데이터별로 시나리오 서술, 결과 가시화 해석 및 개선율을 가시화
- 균등기회(Equal of Opportunity): 보호된 그룹과 보호되지 않은 그룹은 동일한 참 긍정 (true positive)의 비율을 가져야 함을 의미

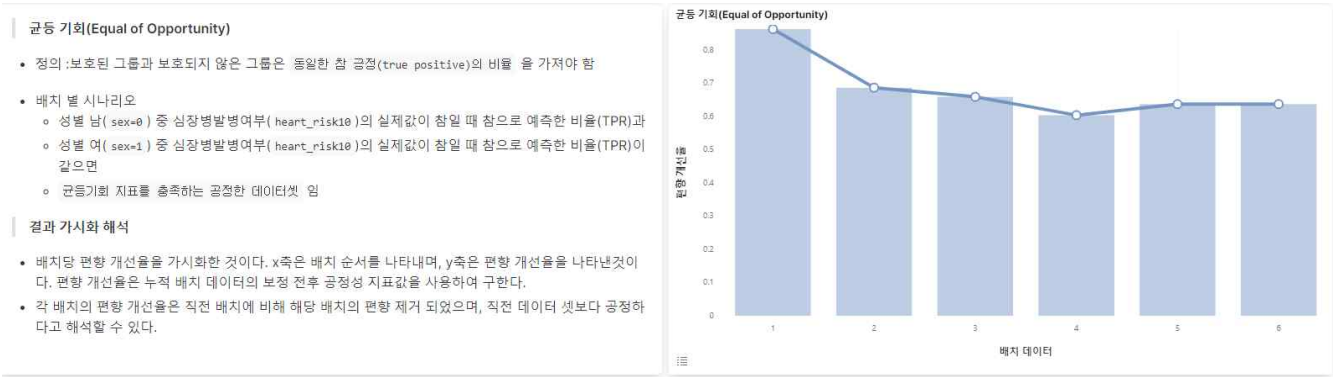

[그림 126] 동적데이터 보정 후 가시화(균등기회)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 동적데이터 공정성 보정 후 가시화 (동등 대우)

- 동적 배치 데이터별로 시나리오 서술, 결과 가시화 해석 및 개선율을 가시화
- 동등 대우(Treatment Equal): 보호된 그룹과 보호되지 않은 그룹은 거짓 부정 분의 거짓 긍정에 대한 동일한 비율을 가져야 함을 의미

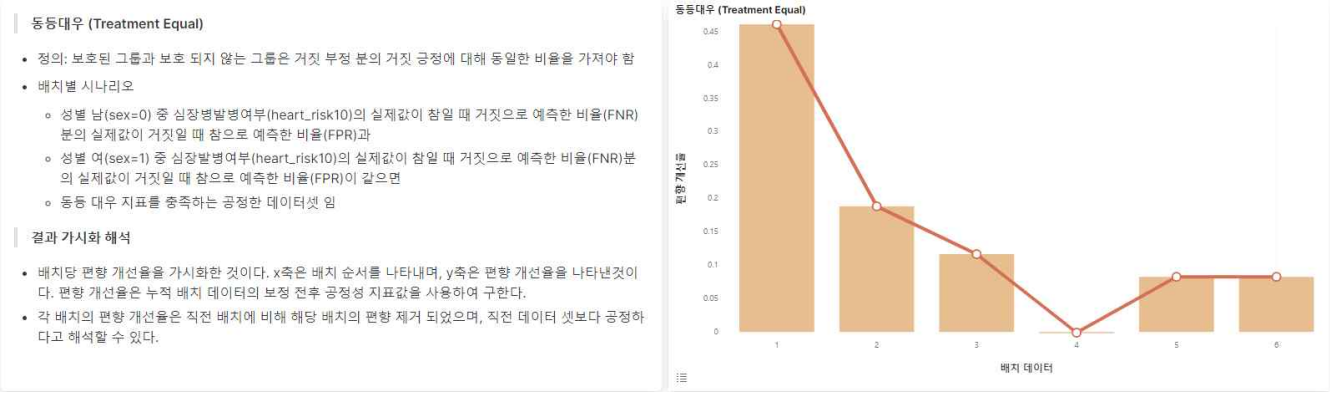

[그림 127] 동적데이터 보정 후 가시화(동등대우)

✓ QUFA Studio 통합 위한 공정성 API 연동

- QUFA Studio 통합 지원을 위한 API 연동 시스템 설계

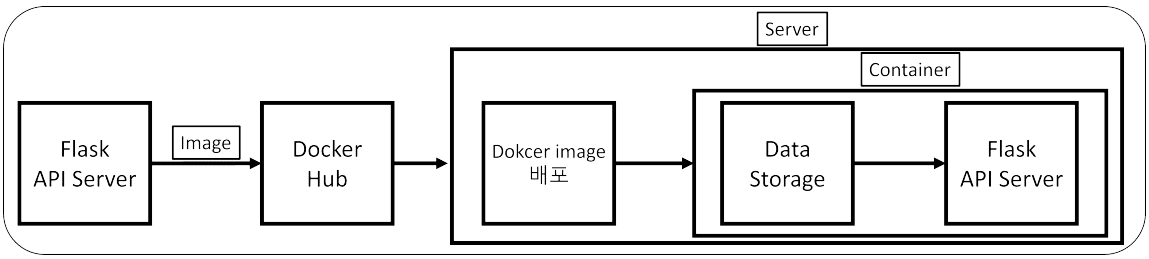

[그림 128] QUFA Studio 통합을 위한 공정성 API 연동 시스템

✓ QUFA Studio 통합 위한 지표별 API 연동

- 각 지표별로 key, param, value 방식으로 API URL link를 지원

[그림 129] QUFA Studio 통합을 위한 지표별 공정성 API 연동 설계 예

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ QUFA Studio 통합 위한 지표별 API 연동 결과

- 각 지표별로 key, param, value 방식으로 API URL link를 지원

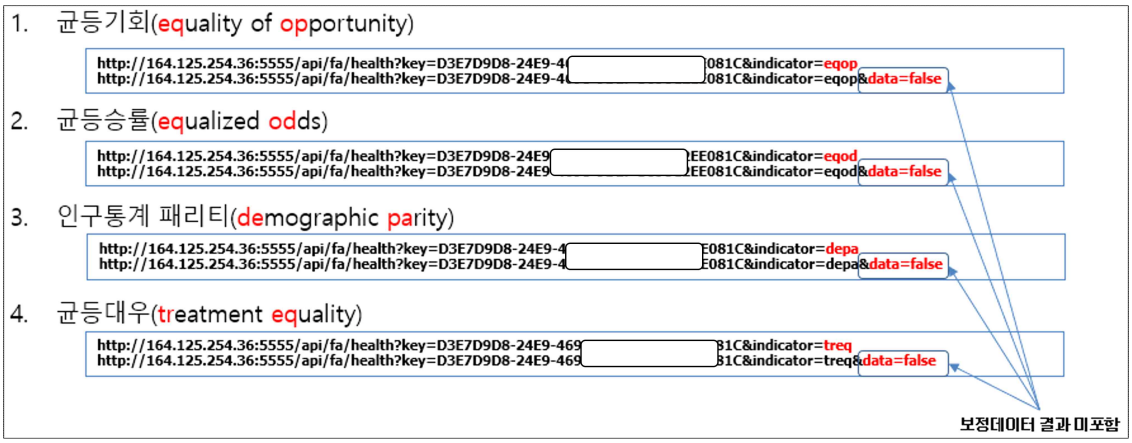

[그림 130] QUFA Studio 통합을 위한 지표별 공정성 API 연동 URL

- 각 지표별로 API URL link에 따른 결과 확인 화면

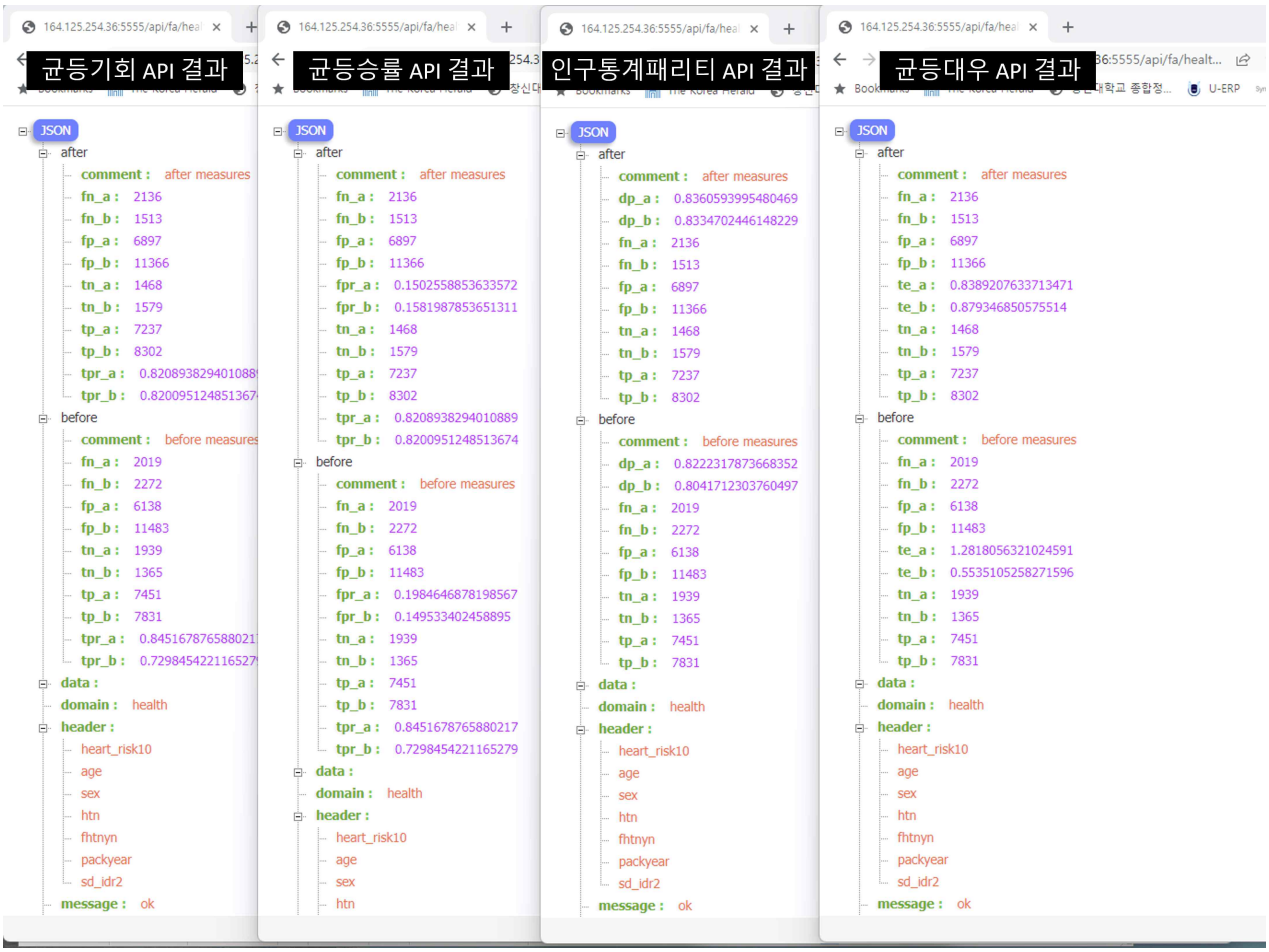

[그림 131] QUFA Studio 통합을 위한 지표별 공정성 API 연동 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 빅데이터 플랫폼 연계 검증

▪ **(소제목)** 빅데이터 플랫폼 연계 구조

✓ 보라매 데이터 센터 연계와 항만물류 데이터 센터 연계

• 아이소프트, 부산대의 데이터 센터 연계와 데이터 흐름 개념

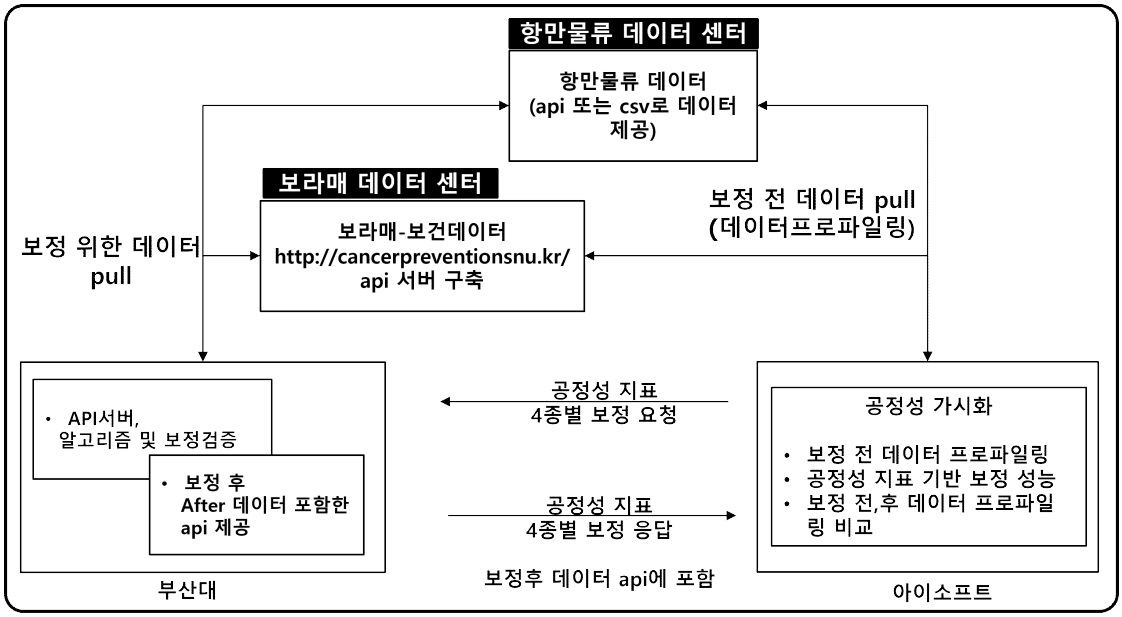

[그림 132] 데이터 센터 연계와 데이터 흐름 개념

✓ 보라매 데이터 센터 연계

• 보라매 데이터 센터에 API 서버 구축하여 약 10만건의 보건 데이터 연계

보라매 데이터 센터 연계 URL

http://cancerpreventionsnu.kr:3317/api/v1/heart/?key=7F531E[redacted]80D4-ACE525B1AE11


```
{
  "result": "success",
  "data": [
    [
      "heart_risk10",
      "age",
      "sex",
      "htn",
      "fhtnyn",
      "packyear",
      "sd_idr2"
    ],
    [
      "0",
      "2",
      "1",
      "0",
      "1",
      "13",
      "2"
    ],
    [
      "1",
      "7",
      "1",
      "0",
      "0",
      "13",
      "0"
    ]
  ],
  "header": [
    "heart_risk10",
    "age",
    "sex",
    "htn",
    "fhtnyn",
    "packyear",
    "sd_idr2"
  ],
  "rows": 101501,
  "message": "ok",
  "timestamp": "2023-02-22 17:15:46"
}
```


[그림 133] 보라매 데이터 센터 연계 URL과 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

✓ 항만물류 데이터 센터 연계

- 항만물류 데이터 센터는 현재 파일 형태로 공유하였으며 해당 파일을 아이소프트에서 구축한 API 서버에서 제공
- 항만물류에서 제공하는 파일은 key, param, value 방식의 API 서비스로서 사용자 접근이 제한되어 있음

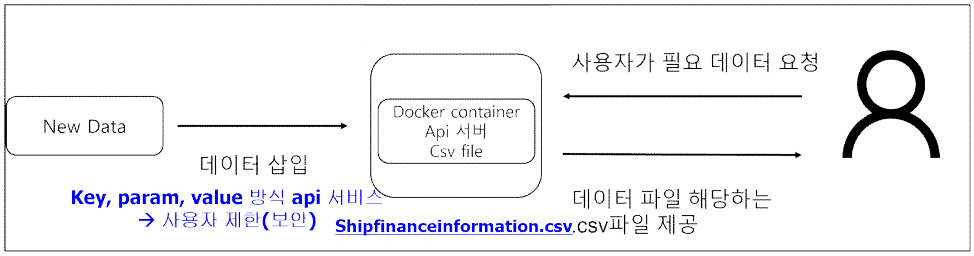

[그림 134] 항만물류 데이터 센터 연계 파일 API 연계 개념

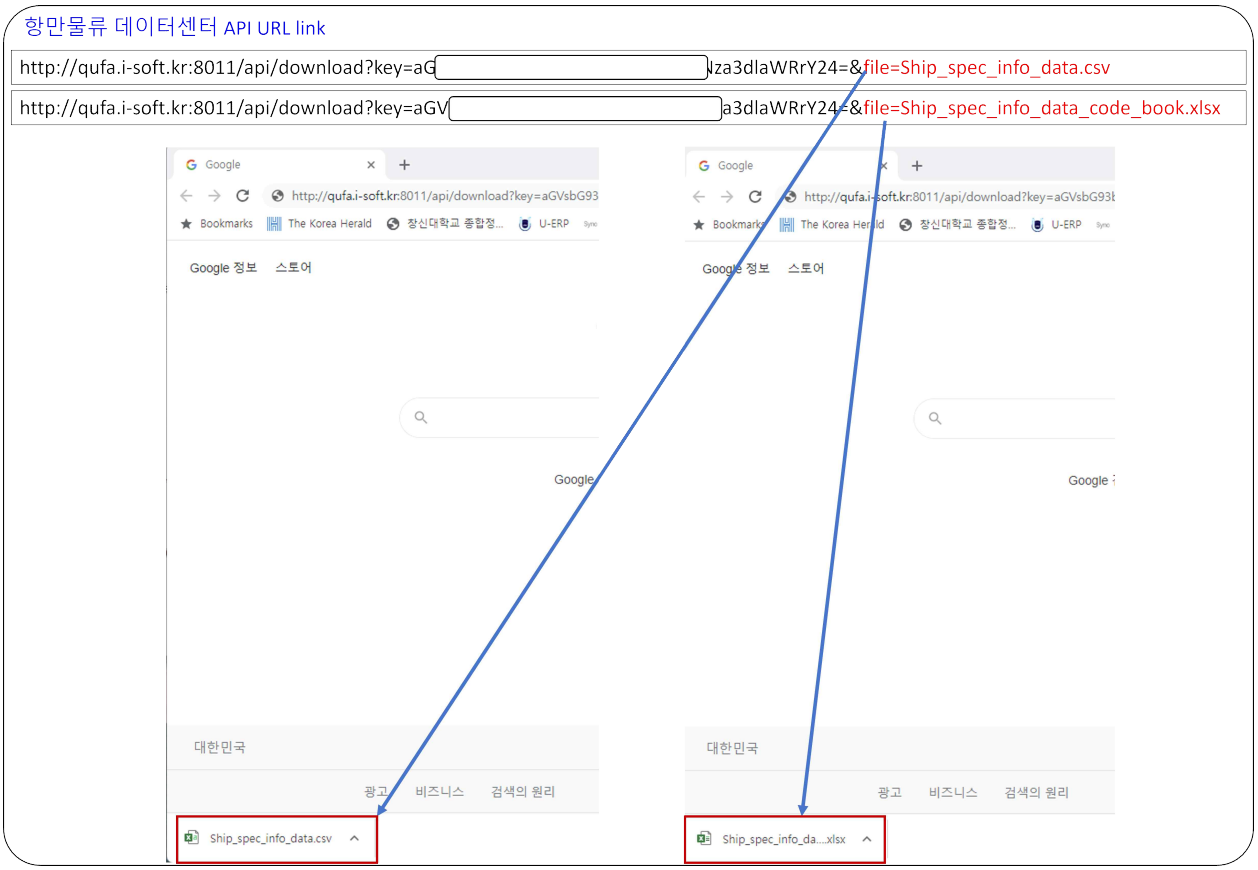

[그림 135] 항만물류 데이터 센터 연계 API URL 및 파일 다운로드 결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3. 연구개발과제의 수행 결과 및 목표 달성 정도

1) 연구수행 결과

(1) 정성적 연구개발성과

가) 1단계 1차년도 연구개발 목표 및 결과

세부연구명	세부 연구 목표	연구개발 수행 내용	연구개발성과
교통 데이터 품질 지표 분석	교통 영역에서의 데이터 소스/타입/응용 분석	- 교통 분야 데이터의 사례 분석	- **(부산대)데이터 품질지표 분석서.pdf**
비정형 이미지 데이터 품질 지표 평가 모델링	이미지 데이터 품질 진단 기법 분석	- SSIM, NIMA 모델 분석	- **(부산대)비정형 이미지데이터 품질평가 모델링.pdf**
	참조 기반 및 블라인드 기반 품질 진단 실시	- 참조(SSIM) 및 블라인드(NIMA) 기반 품질진단 및 테스트 실시	
품질성능지표 체계화	도메인 별 품질 지표 요구 사항 분류 및 체계화	- 도메인별 지표 분류 및 체계화	- (전 참여기관 공동 연구)교통 도메인을 포함하는 총 다섯 종의 데이터셋에 대한 품질분석 등을 수행 및 취합 - **(부산대)데이터 품질지표 분석서.pdf**
	데이터 유형별 품질 지표 분류 및 정립	- 5종의 도메인별 품질지표 분류 및 정립	
	데이터 품질 지표에 대한 요구 사항 조사 분석	- 도메인별 지표에 대한 조사 분석	
데이터셋 공정성 보정	데이터셋의 편향성 제거에 따른 공정성 보장	- 데이터셋의 편향 확인/분석 - 편향 제거를 위한 공정성 보정기 설계 및 구현	- **(부산대)공정성 보정 모듈 설계서.pdf**
보건데이터 및 AI 기반 품질지표 분석 및 평가	보건데이터 품질지표 분석	데이터 품질지표 분석	- **(서울대)보건 데이터 품질지표 평가 모델링.pdf**
	AI 기반 비정형 데이터 품질 지표 평가 모델링	데이터의 품질 및 공정성 지표개발	
자동화된 데이터 품질 분석 및 개선	문화관광데이터 품질 지표 분석	- 문화관광 분야 빅데이터 활용 사례 조사 및 분석	- **(서울시립대) 문화관광 데이터 품질 지표.pdf**
		- 문화관광 분야 데이터 확보 및 특성 분석	
		- 문화관광 분야 데이터 품질 지표 수립 및 검증	
	품질 지표 평가 방법 모델링	- 문화관광 데이터 품질척도 분석	- **(서울시립대)품질 지표 평가 방법 모델링.pdf**
		- 품질척도 강화를 위한 대체 척도 개발	
특징 공학 기반 오류 탐지 및 보정 기술	환경 데이터 품질 지표 분석	- 환경 분야 관련 데이터 수집 및 데이터 특성 분석 - 환경 데이터 품질 지표 설계 및 검증	- **(이화여대)환경 분야 데이터 품질 지표 분석서.pdf**
	통계 기반 특징 변환 알고리즘 개발	- 수치형 데이터 결측치 보정 도구 개발 - 특징 추출을 위한 변환 및 취합 통계 연산자 설계	- **(이화여대)특징 공학 알고리즘 설계서.pdf**
	머신러닝 기반 특징공학 알고리즘 개발	- 특징 탐색 공간 최적화를 위한 평가지표 기반 탐색	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		기법 설계 - 학습 모델 자동 평가를 통한 특징 랭킹 모델 설계	
데이터 프로파일링을 위한 메타데이터 분류 및 관리체계 설계	재난안전 데이터 품질지표분석	- 공공데이터 위주의 관련 데이터를 조사/수집 - 재난 데이터에 대한 품질측면의 특징분석	- **(한성대) 재난안전데이터 품질평가보고서**
	데이터 프로파일링 분류 및 관리체계 설계	- 메타데이터 국제표준에 대한 조사 - 오픈소스 데이터 프로파일링 S/W 조사 및 활용방안 연구 - 프로파일링 항목정의 및 관리구조 설계	- **(한성대)메타데이터 표준분석보고서** - **(한성대)데이터 프로파일링 기술분석 보고서** - **(한성대) 데이터 프로파일링 SW 개발보고서**
피드백 지원 품질 평가 도구 개발	피드백 지원 품질 평가 모델 설계	- 데이터 흐름도, 시퀀스 다이어그램, 인터페이스 명세 등을 통하여 품질 평가 모델을 설계	- 피드백 기능을 통하여 지속적인 데이터 품질 향상이 가능한 품질평가 모델 설계 - 데이터 프로파일링 결과조회 및 피드백 작성을 위한 사용자 기능을 개발함 - **(프람트테크놀로지) 피드백 지원 품질평가 도구 설계서.pdf**
	피드백 지원 품질 평가 도구 개발	- 품질평가 결과를 사용자에게 제공하고 피드백을 수렴하는 기능을 개발	
빅데이터 품질 수준 현황 조사	데이터 품질 척도의 정의	- 5종의 데이터 도메인별 품질척도 및 품질 수준 현황 조사	- **(아이소프트)데이터 품질수준 현황 조사서.pdf** - **(부산대)데이터 품질지표 분석서.pdf**
	빅데이터 품질 진단 프로젝트의 운영	- 5종의 데이터 도메인별 품질 진단 위한 모델링 등의 방법 분석	
공정성 분석기 및 패턴 시각화 도구 설계	도메인별 데이터 공정성 품질지표 기반의 분석기 설계	- 1차년 교통 데이터셋 분석 및 분석결과 가시화 웹페이지 개발	- **(아이소프트)공정성 분석기 및 패턴 시각화 도구 설계.pdf**
	ROC curve 등을 활용한 패턴 시각화 도구 설계	- 데이터셋의 로드 및 로드된 데이터의 컬럼 및 컬럼값 기반의 분석 결과 웹서비스 가시화 설계	

나) 1단계 2차년도 연구개발 목표 및 결과

세부연구명	세부 연구 목표	연구개발 수행 내용	연구개발성과
데이터셋 구성 요소 분석	데이터셋 구성 요소 중 공정성에 영향을 주는 요소 파악	- 데이터셋 공정성에 영향을 주는 요소 분석 - 데이터 공정성 지표 분석	- **(부산대)공정성 기술문서.pdf**
	데이터셋에서 나타날 수 있는 편향에 대한 분석 파악	- 데이터셋 내의 편향의 종류 분석 및 정의	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

데이터셋 공정성 보정 고도화	데이터셋의 편향성 제거에 따른 공정성 보정 고도화	- 데이터셋의 편향 확인/분석 - 편향 제거를 위한 공정성 보정기 고도화 설계 및 구현	**- (부산대)알고리즘 기술 문서.pdf**
배치 기반 데이터 셋 공정성 보정 기술	데이터 보정을 통한 공정성 보정 기술 접근 개념	- 배치 데이터셋의 편향 확인 및 검증 - 배치 데이터셋의 편향 제거를 위한 공정성 보정기 설계 및 구현	**- (부산대)배치 알고리즘 기술 문서.pdf**
	대량의 데이터에 대한 공정성 보정을 효율적으로 처리하기 위한 맵리듀스(Hadoop)이나 스파크 기반의 배치 처리 기법 설계 및 구현	- 스파크 및 카프카를 활용한 배치 처리 기법 설계 - 공정성 보정기와 결합 및 웹서비스 구현, 가시화 설계	
공정성 지표 분석 및 정의	공정성 위한 기초 개념 정리와 지표의 개발 및 검증	- 헬스케어 분야의 공정성 문제 사례 수집 - 실제 보건의료 데이터분석 시 인종 및 성별에 따른 알고리듬 적용 차이 확인	**- (서울대)공정성 지표 정의서 V.2.PDF**
	공정성 향상을 위한 접근 방법 분석 및 정의	- 공정성을 위한 기초 개념을 정리하고 헬스케어 데이터에 적합한 지표 검증	
데이터 패턴 시각화	전체 데이터 패턴 및 이상값의 시각화: Supervised (ground truth와의 loss값 시각화) 및 unsupervised 패턴 (principal component 10개 축 상의 주요 변수 관계 제시	- PCA,SNE,UMAP등의 차원축소 방식을 이용한 데이터 패턴 시각화	**- (서울대)데이터 패턴 시각화 설계서 V.2.PDF**
	관계형 이상값 시각화: 전체 변수간의 상관성 시각화 (multivariate correlogram)	- 보건의료 데이터 내 고차원 특성을 최소한의 정보 손실을 통해서 2차 혹은 3차원으로 차원을 축소하여 변수간의 상관성 패턴 시각화	
	공정성 지표의 시각화: 주요 계층별 (성, 연령군, 지역 및 인구집단 등)의 공정성 지표 (계층간-계층내 Fst, unvalanced odds, AUROC-PRC 편차 값 등)	- 주요 공정성 지표(Equalized odds, calibration plot 등)의 집단별 차이 시각화	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

데이터 품질 개선 자동화 기반 설계	프로파일링, 품질개선, 파이프라인 병렬/고속화의 3개 기능구분 및 설계	- 학습 데이터셋 개선 자동화 기반 설계	- (서울시립대) **학습데이터개선클라우드.pdf**
	정제 및 특징공학, 융합의 단계로 데이터 품질개선	- 딥러닝 기반 정형데이터 결측치 보완 알고리즘 및 모듈 개발	- (서울시립대) **정형데이터품질개선.pdf**
정형 데이터 품질 개선 알고리즘 개발	이상치 제거 알고리즘 개발	- 딥러닝 기반 시계열 데이터 이상치 제거 알고리즘 및 모듈 개발	- (서울시립대) **시계열데이터품질개선.pdf**
특징 공학(feature engineering) 연산자 고도화	특징생성 연산 다양성 위한 메커니즘 실현	- 다양한 특징 추출 연산자 지원 - qufafeat 기반의 87개 특징 연산자 구현	- (이화여대) qufafeat: **특징공학 자동화도구 S/W**
	특징공학 온톨로지 구축	- 특징 연산자별 설명, 예시 주석 기능 보강 - 특징 연산자 사용자 정의 및 외부 연동	- (이화여대) **특징공학서비스 설계서.pdf**
오류 탐지 및 보정 기술 개발	딥러닝 기반 이상치 제거 알고리즘 개발	- 자동 테이블 정규화(Normalization)를 통한 특징 추출 오류 보완 - 딥러닝 기반 특징 중요도 선별을 통한 기계학습용 훈련 데이터 보정 기술 개발	- (이화여대) **대규모 테이블 데이터 정규화 방법 및 장치, 특허** - (이화여대) **오류탐지보정설계서.pdf**
메타데이터 수집 기술 개발	메타데이터에 대한 extractor, enrichment, validation, Parsing, Mapping 기능 개발	- 원천 데이터 관리 기술 개발 - 메타정보 항목 자동 결정 기술 개발 - 원천 데이터로부터 프로파일 추출 및 자동생성 기술 개발	- (한성대) **데이터 프로파일링 SW 개발보고서**
메타데이터 변환 및 편집, 저장 기술 개발	이기종 데이터를 지원하는 메타데이터 저장 및 편집 기능 개발	- 이기종 데이터로부터 생성된 프로파일 저장 및 관리모듈 기술 개발	
	오픈 포맷을 지원하는 메타데이터 변환기능개발	- 오픈 포맷을 지원하는 메타데이터 서비스 기술 개발 - 마이크로 아키텍처를 지원하기 위한 스프링부트 환경의 restful API 서비스 기술 개발	
공정성 분석기 도구 개발	공정성 품질지표 기반의 알고리즘 구현	- 웹기반(장고) 인공지능 학습 데이터 처리 구현 - 검증 모델 선택 및 파일 로딩기능 - 데이터 구조분석 가시화	- (아이소프트) **서버구축-부산대 서버구축**

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		기능모듈 개발 - 데이터 검증모듈 탑재 - 데이터 공정성 보정 알고리즘 연동	
데이터 패턴 시각화 도구 개발	추론 결과 및 기능 속성 시각화 구현	- 자바스크립트를 이용한 교통 및 의료 데이터 구조 가시화(sunburst) 기능 모듈 설계 및 구현 - t-SNE 및 UMAP 차트 구현 - 공정성 데이터의 직관적 가시화를 위한 차트 개발	**- (아이소프트) 웹 프로젝트 파일.Zip**
공정성 도구 통합	데이터 분석 가시화 통합 UI/UX 디자인	- Traffic 데이터 & Health 데이터 분석 가시화 통합 디자인	**- (아이소프트) 공정성 통합디자인 시안.pdf**
	공정성 진단 도구와 데이터 패턴 시각화 도구의 통합	- 기계학습 구분 기반의 공정성 검증 웹 FLOWCHART - 공정성 가시화 API 개발	**- (아이소프트) 공정성 검증 웹 FLOWCHART.pdf** **- 공정성 가시화 API.pdf**
데이터 품질 분석 도구 제품화	데이터 품질 대시보드 구현	- 데이터 품질 개선 프로젝트 생성 - 프로파일링 대시보드 - 품질 현황 디스플레이	- 데이터 품질 개선을 위한 프로젝트 생성에서부터 대시보드를 통한 품질 지표 현황 디스플레이 기능 구현 **- (프람트테크놀로지) 데이터셋 품질을 고려한 메타데이터 기반 연관 데이터셋 검색방법 특허 출원증.pdf**
	데이터 품질 도구에서의 데이터 프로파일링 자동 수행 구현	- 메타데이터 자동 추출 및 프로파일링 자동 수행	- 클라우드에 데이터를 업로드와 동시에 프로파일링을 자동 수행, 저장 및 디스플레이 기능 구현
데이터 오류 보정 도구 설계 및 개발	오류 보정 도구 기능 분석	- 품질 개선을 위한 오류 보정 도구 기능 분석 기반 설계 반영	- 결측치, 이상치 자동 보정 기능 등 기존 데이터품질 분석 솔루션 대비 신규 기능 설계 반영
데이터 품질 개선 솔루션 통합	데이터 품질 개선 솔루션 API 기반 통합 구현	- 데이터프로파일링 기능 통합 - 데이터품질 분석 및 개선 기능 통합 - 특징공학 기능 통합 - 기타 공정성 보정 기능 통합	- 데이터 프로파일링, 품질 분석 및 개선, 특징공학 기능 등 품질 관련 기능 및 공정성 보정 기능을 API 방식으로 통합하여 확장성 보장

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

			- (프람트테크놀로지) 데이터 품질 분석 도구 설계서.pdf - (프람트테크놀로지) 데이터품질 및 공정성 통합 시스템 소프트웨어 등록증.pdf

다) 2단계 1차년도 연구개발 목표 및 결과

세부연구명	세부 연구 목표	연구개발 수행 내용	연구개발성과
점증적 데이터 셋 보정 기술 개발 및 고도화	추가되는 부분 데이터에 적용되는 점증적 공정성 보정 기술 개발	- 점진적 데이터 기반 람다 아키텍처 구축 - 람다 아키텍처 내 공정성 보정 알고리즘 설계 및 구현	- (부산대) 쿠파_람다아키텍처 기반_기술문서.pdf
공정성 보정 기술 통합	공정성 지표 계산 및 보정을 위한 고도화	- 데이터 반전 모듈 및 모조 데이터 생성기 설계 및 개발	- (부산대) 쿠파_모조데이터생성_기술문서.pdf
	람다 아키텍처에 기반한 배치/점증적인 알고리즘 통합	- 배치 기반 데이터 처리 아키텍서 구축 - 배치 기반 공정성 알고리즘 설계 및 구현	- (부산대) 쿠파_통합기반_기술문서.pdf
빅데이터 플랫폼 연계 통합 관리	데이터 연계를 위한 api 정의 및 서버 구축	- 빅데이터 플랫폼 연계 및 통합 관리를 위한 API 정의 및 서버구축	- (부산대) 쿠파_API기술문서.pdf
공정성 지표의 정의와 보정 자동화 기술 연구	공정성 지표 산출 방식의 정의와 자동화	- 20여개의 공정성 지표의 산출 방법 표준화 - 핵심 공정성 지표 8개의 산출 방법 개발	- (서울대) 공정성관련 지표의 개념적 정의와 개별 진단지표.pdf - (서울대) 헬스케어 분야 공정성의 사례연구.pdf
	민감변수간, 특히 연령 및 성별변수간의 공정성 지표의 보정방식의 단계별 정의와 수행	- pre- in- post-processing단계별 데이터 공정성 보정 방법 제시 - 단계별 보정 방법에 따른 민감변수간 균일화 검증	
고차원 특성 시각화 방법과 API화 방안	고차원 특성 시각화 방법의 고찰과 핵심시각화 방안 개발	- SNE/t-SNE, UMAP등 고차원 특성 시각화 방법의 알고리즘 연구 개발	- 의료영상 시각화 방법의 특허 출원
	t-SNE 등의 API화를 위한 표준프로그램과 DB연계	- jsp 및 python기반의 시각화 방안 - 개발된 알고리즘의 DB연계 및 REST API화 방안 제시	
비정형 데이터 품질 개선 기술 개발	2차원 큐보이드 모델 기반 비정형 데이터 품질 강화 기술 개발	- 텍스트 데이터에 대한 개념 임베딩 모듈 개발 - 자동문서분류모델의 성능 개선 - 임베딩 기반 텍스트 데이터 Noise 제거(정제)	- (서울시립대) 쿠파_기술문서_텐서공간모델 기반 텍스트 데이터 품질개선 기술.hwp

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		기술	
AI기반 품질 개선 기술 개발	시계열 데이터 품질 개선 기술 개발	- 딥러닝 기반 TIMEBAND 알고리즘 개발 - 시계열 데이터 이상치 탐지 및 정상화 기술 개발	- (서울시립대) 쿠파_기술문서_시계열 데이터이상치탐지및정상화기술.hwp
	정형 학습데이터 증강 기술 개발	- 학습데이터로서 수치형 테이블 데이터에 대한 자동 증강 알고리즘 개발 - 증강된 정형테이블에 대한 예측모델의 성능 개선	- (서울시립대) 쿠파_기술문서_정형테이블 학습데이터 증강기술_서울시립대.hwp
AI 기반 오류 탐지 기술 고도화	기계학습을 통하여 예측한 데이터셋 특성을 기반으로 오류 데이터 탐지	- 내용특성, 관계특성 후보군 선정 - 괴리정도 모델 설계 - 특성기반 오류탐지용 학습 데이터 확보 및 학습 모델 구현	- (이화여대) 기계 학습 모델의 학습 데이터 품질 향상을 위한 특징 공학 파이프라인 방법 및 장치, 특허 - (이화여대) qufafeat 1.5: 특징공학 자동화도구 S/W
AI 기반 오류 보정 기술 고도화	기계학습을 통하여 예측한 최적화 연산자를 기반으로 데이터 보정	- 보정연산자 후보군 선정 - 특성별,오류범위별 보정연산자 예측 학습 데이터 확보 및 모델 구현	
메타데이터 검색 및 활용 기술 개발	프로파일링 검색 서비스 지원	- 메타데이터 검색 지원을 위한 주문형 프로파일링 서비스 개발 - 프로파일링 편집 및 검색 기능	- (한성대) 데이터 프로파일링 지원도구 개발보고서(3차년).pdf
	프로파일링 서비스 고도화	- 다중 컬럼, 다중 테이블에 대한 프로파일링 기능 제공 - 키 분석 및 의존성 분석 기능 개발 - 참조 무결성 분석 기능	
	프로파일링 성능 개선	- 타입 자동인식의 성능을 개선하기 위한 적응형 샘플링 방법 개발	
데이터 품질 개선 솔루션 통합 및 고도화	데이터 품질 개선 솔루션 통합	- 데이터 품질개선 시스템 기능 통합 - 데이터 맵 모듈 신규 구현 및 통합	- (프람트테크놀로지) 데이터헌터 설계서.pdf
	데이터 품질 개선 솔루션 고도화	- Parameter 및 Config 정보 설정 기능 - 시각화 기능 개선 및 보완	- QuFa Studio 오픈소스 개방 및 AWS Market Place 탑재
데이터맵 기술 개발	융합 데이터셋 검색 및 시각화 기능 개발	- 데이터맵 모듈 설계 -메타데이터 기반 유사도 산출 알고리즘 적용 및 시각화 모듈 구현	- (프람트테크놀로지) 데이터맵 설계서.pdf
공정성 도구 고도화 및 통합	정적데이터 공정성 보정 기술 가시화	- 지표별로 정적 데이터 공정성 보정 가시화 통합	- (아이소프트) 정적보상 공정성 시각화 기술문서.pdf 공정성 통합 시각화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

			기술문서.pdf
	동적데이터 공정성 보정 기술 가시화	- 배치데이터를 지표별로 동적 데이터 공정성 보정 가시화 통합	**- (아이소프트) 공정성 통합 시각화 기술문서.pdf**
빅데이터 플랫폼 연계 검증	보라매 데이터 센터 연계	- 보건 데이터 API로 연계	- 보건 데이터 API서버 연계하여 보건 데이터 수집 및 보정 요청
	항만물류 데이터 센터 연계	- API 서버 구축하여 항만물류 데이터 연계	**- (아이소프트) API Server 구축 기술문서.pdf**

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 정량적 연구개발성과

[정량적 연구개발성과표]

■ 정량적 연구개발 성과표

▪ 제안 목표치 대비 정량 및 일부항목의 초과 달성

구분	특허				논문		학술대회		기술이전	상용화(백만원)	기술료(백만원)	성과홍보	시제품	S/W등록	기술문서
	국제		국내												
	출원	등록	출원	등록	KCI	SCI	국내	해외							
목표치	0	0	19	5	15	5	19	5	2	20	0	1	3	13	21
실적치	**2**	**0**	**19**	**3**	**18**	**10**	**19**	**7**	**2**	**156**	**20**	**3**	**2**	**15**	**42**

■ 세부사업 질적 성과표

성과지표	가중치	구분	목표치	실적치	비고
논문	0.4	KCI등재	10+5	**18**	**목표치 대비 초과 달성**
		SCI등재	2+3	**10**	**목표치 대비 초과 달성**
학술대회	0.3	국내	12+7	**19**	**목표치 대비 초과 달성**
		해외	3+2	**7**	
특허질적평가값	0.3	K-PEG	B2	**B2**	목표치 정량 달성
			B1	**BB**	Smart5 대체 달성
합계	1.0				

[연구개발성과 성능지표]

	평가 항목 (주요성능[1])	단위	전체 항목에서 차지하는 비중[2] (%)	세계 최고		연구개발 전 국내 성능수준	연구개발 목표치		목표설정 근거
				보유국/보유기관	성능수준	성능수준	1단계 (2020~2021)	**2단계 (2022)**	
1	데이터셋 공정성 보정 성능	%	20	미국/IBM	90	-	≥80	**≥90**	사업RFP
2	데이터 품질 성능	%	20	-	-	-	≥89	**≥99**	사업RFP
3	데이터셋 공정성 검증 지표 유형	종	20	미국/IBM	4	-	≥3	**≥4**	사업RFP
4	데이터 품질 평가 지표 유형	종	10	ISO/IEC 25012	5	NIA 7	≥5	**≥7**	사업RFP
5	적용/검증 도메인	종	10	-	-	-	≥2	**≥3**	사업RFP
6	데이터쓰기 향상도	IOPS	10	Kafka (오픈소스)	-	-	5	**10**	사업RFP
7	데이터 품질 향상도	%	10	미국/Talend (오픈소스)	-	-	89	**99**	사업RFP

* 1」 정밀도, 인장강도, 내충격성, 작동전압, 응답시간 등 기술적 성능판단기준이 되는 것을 의미합니다.

* 2」 비중은 각 구성성능 사양의 최종목표에 대한 상대적 중요도를 말하며 합계는 100%이어야 합니다.

■ 시험평가 수행

▪ 부산IT융합부품연구소: KOLAS 국제공인소프트웨어 시험성적서 발행 공인기관

■ 평가 항목별 목적 및 기준

평가 항목		목적	기준
1	데이터셋 공정성 보정 성능	▪ 데이터셋 공정성 보정기(알고리즘)를 이용하여 공정성 보정 후 데이터셋을 생성한 후 공정성 검증 모듈을 통해 보정 전/후 데이터의 3가지 공성정 지표(균등 기회, 균등승률, 인구통계 패리티)에 따른 데이터셋 공정 개선 여부(평균 보정률)를 확인	▪ 지표별 공정성 보정 성능 평균 90% 이상
2	데이터 품질 성능	▪ 데이터셋 품질 보정(알고리즘)을 이용하여 수치형 데이터 결측률, 범주형 데이터 결측률, 이상치 비율, 텍스트 오류율, 포맷 오류율 관점의 데이터	▪ 지표별 공정성 품질 성능 99% 이상

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		품질 보정 성능 수준 검증	
3	데이터셋 공정성 검증 지표 유형	▪ 데이터셋의 공정성 개선을 위한 공정성 검증 지표 유형 3종 이상 확인	▪ 공정성 검증 지표 4종 이상
4	데이터 품질 평가 지표 유형	▪ 데이터셋의 품질 측정 및 개선을 위한 품질평가 지표 5종 이상 확인	▪ 품질평가 지표 7종 이상
5	적용/검증 도메인	▪ 데이터셋의 공정성 개선을 위해 활용하는 2종의 데이터 도메인의 적용 및 검증 확인 ▪ (※ 1단계 누적 총 2종)	▪ 공정성 개선 위해 적용 검증 된 데이터 도메인 3종 이상
6	데이터쓰기 향상도	▪ 데이터 처리 요청에 따른 메타정보 추출부터 데이터 저장까지의 IOPS(IO per Second)를 측정하여 성능을 확인	▪ IOPS 10 이상
7	데이터 품질 향상도	▪ 누락 데이터 보정 기능을 통한 결측률 관점의 수치형 데이터 품질 향상 수준 검증	▪ 99% 이상

■ 평가 항목별 종합 시험결과

▪ 시험성적서 관련 증빙자료 중 일부 발취

▪ 모든 시험항목(과제 RFP 5종 + 수행기관 추가제안 2종 = 총 7종)에 대해, 목표치 대비 초과(&정량)적인 “우수한 시험결과 달성”

시 험 결 과

동의대학교 산학협력단 | 성적서 번호 : SW-23-0002a 페이지 (4) / 총 (26) | cidi 부산IT융합부품연구소

2.2. 시험대상 제품의 구성과 용도

구 성	용 도	비 고
Data fairness improvement	데이터셋 공정성 보정 성능 및 데이터셋 공정성 개선 지표 유형을 확인하기 위함.	-
QUFA – Data Loader	파일데이터를 Database에 저장하기 위함.	-
Data Quality Enhancer	데이터 품질평가 지표 유형을 확인하기 위함.	-
수치데이터 결측률 측정 (get_numerical_missing_rate.py)	데이터 파일의 수치형 데이터 결측률을 측정하기 위함.	-
범주데이터 결측률 측정 (get_categorical_missing_rate.py)	데이터 파일의 범주형 데이터 결측률을 측정하기 위함.	-
결측률 개선 (data_imputation.py)	데이터 파일의 수치형, 범주형 데이터 결측률을 개선하기 위함.	-
이상치 비율 측정 (get_outlier_rate.py)	데이터 파일의 이상치 비율을 측정하기 위함.	-
이상치 비율 개선 (outlier_detection.py)	데이터 파일의 이상치 비율을 개선하기 위함.	-
텍스트 오류율 측정 (get_text_error_rate.py)	데이터 파일의 텍스트 오류율을 측정하기 위함.	-
텍스트 오류율 개선 (text_correction.py)	데이터 파일의 텍스트 오류율을 개선하기 위함.	-
포맷 오류율 측정 및 개선 (format_validation.py)	데이터 파일의 포맷 오류율을 측정하고 개선하기 위함.	-
증강 불순율 측정 및 개선 (calc_data_augmentation.py)	데이터 파일의 증강 불순율을 측정하고 개선하기 위함.	-
check_normality.ipynb	데이터 파일의 정규성 위배율을 측정하고 개선하기 위함.	-

[그림 59] 시험대상 제품의 구성과 용도

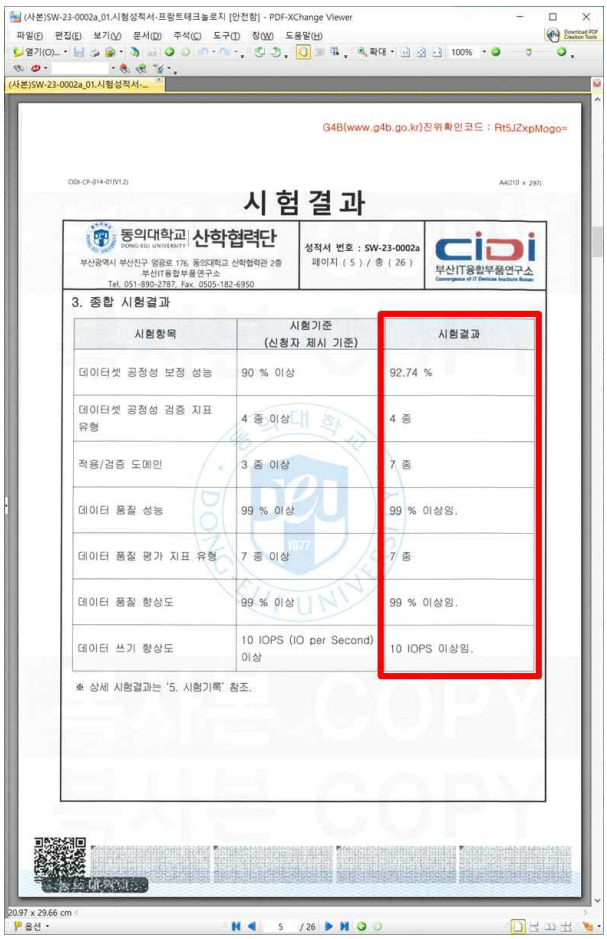

시 험 결 과

동의대학교 산학협력단 | 성적서 번호 : SW-23-0002a 페이지 (5) / 총 (26) | cidi 부산IT융합부품연구소

3. 종합 시험결과

시험항목	시험기준 (신청자 제시 기준)	시험결과
데이터셋 공정성 보정 성능	90 % 이상	92.74 %
데이터셋 공정성 검증 지표 유형	4 종 이상	4 종
적용/검증 도메인	3 종 이상	7 종
데이터 품질 성능	99 % 이상	99 % 이상임.
데이터 품질 평가 지표 유형	7 종 이상	7 종
데이터 품질 향상도	99 % 이상	99 % 이상임.
데이터 쓰기 향상도	10 IOPS (IO per Second) 이상	10 IOPS 이상임.

※ 상세 시험결과는 '5. 시험기록' 참조.

[그림 60] 종합 시험결과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(3) 세부 정량적 연구개발성과(해당되는 항목만 선택하여 작성하되, 증빙자료를 별도 첨부해야 합니다)

[과학적 성과]

□ 논문(국내외 전문 학술지) 게재

번호	논문명	학술지명	주저자명	호	국명	발행기관	SCIE 여부 (SCIE/비SCIE)	게재일	등록번호 (ISSN)	기여율
1	A Stacked Denoising Autoencoder and Long Short-Term Memory Approach With Rule-Based Refinement to Extract Valid Semantic Trajectories	IEEE Access	Yoga Yustiawan	VOLUME 9, 2021	미국	IEEE	SCIE	May 14, 2021	2169-3536	100
2	A Three-Dimensional Microstructure Reconstruction Framework for Permeable Pavement Analysis Based on 3D-IWGAN with Enhanced Gradient Penalty	Sensors	Ludia Eka Feri	Volume 21, Issue 11,3603	미국	MDPI	SCIE	21 May 2021	1424-8220	100
3	Exploring the causal inference of migraine on stroke: A Mendelian randomization study	EUROPEAN JOURNAL OF NEUROLOGY	Keon-Joo Lee, Soo Ji Lee, Hee-Joon Bae, Joohon Sung	29(1)	미국	WILEY	SCIE	2022.01	1351-5101	30
4	머신러닝 기반 시각화 추천을 위한 메타특징 공학	데이터베이스 연구	최희원	36(2)	한국	한국정보과학회	비SCI	2020.08	1598-9798	70
5	혼합형 데이터 보간을 위한 디노이징 셀프 어텐션 네트워크	한국콘텐츠학회 논문지	이도훈	21(11)	한국	한국콘텐츠학회	비SCI	2021.11	1598-4877	70
6	공간 정보를 가지는 데이터셋의 준자동 융합기법	한국전자거래학회 논문지	윤종찬	26(4)	한국	한국전자거래학회	비SCI	2021.11	2288-3908	70
7	A Tensor Space Model-Based Deep Neural Network for Text Classification	Applied Sciences	김한준	11(20)	미국	MDPI	SCI	2021.10	2076-3417	50
8	Design and Implementation of a Distributed Versioning File System for Cloud Rendering	IEEE Access	조경운, 반효경	9	미국	IEEE	SCIE	2021.10.08	2169-3536	50
9	Characterizing Fine-Grained Resource Utilization for Multitasking GPGPU in Cloud Systems	IEEE Access	조경운, 반효경	9	미국	IEEE	SCIE	2021.12.03	2169-3536	50
10	Characterizing File Accesses in Android Applications and Caching Implications	IEEE Access	임수정, 반효경	9	미국	IEEE	SCIE	2021.11.08	2169-3536	50
11	고속 스토리지를 이용한 실시간 IoT 시스템의 전력 절감 최적화 기술	The Journal of The Institute of Internet, Broadcasting and Communication	윤수지, 반효경	21	대한민국	IIBC	비SCIE	2021.12.31	2289-0238	50
12	모바일 앱의 메모리 쓰기 참조 패턴 분석	The Journal of The Institute of Internet, Broadcasting and Communication	이소윤, 반효경	21	대한민국	IIBC	비SCIE	2021.12.31	2289-0238	50
13	Analyzing Input Patterns of Smartphone Applications in Touch Interfaces	International Journal of Advanced Smart Convergence	반효경	10	대한민국	IIBC	비SCIE	2021.12.31	2288-2847	50
14	지능형 객체 인식 기술을 이용한 실시간 동영상 검색시스템	한국인터넷방송통신학회논	장재영	제20권 6호	한국	한국인터넷방송통신학회	비SCI	2020년 12월 31일	2289-0238	100

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		문지								
15	마이크로 서비스 아키텍처를 지원하는 데이터 프로파일링 소프트웨어의 개발	한국인터넷방송통신학회논문지	장재영	제21권 5호	한국	한국인터넷방송통신학회	비SCI	2021년 10월 31일	2289-0238	100
16	Whole-Genome Sequencing Reveals Age-Specific Changes in the Human Blood Microbiota	JOURNAL OF PERSONALIZED MEDICINE	이은주, 김한나	12(6)	스위스	MDPI	SCIE	2022.06	2075-4426	50%
17	An automated deep learning method and novel cardiac index to detect canine cardiomegaly from simple radiography	SCIENTIFIC REPORTS	정여진, 성주헌	12(1)	영국	NATURE PORTFOLIO	SCIE	2022.08	2045-2322	40%
18	오토인코더 기반 수치형 학습데이터의 자동 증강 기법	JIIBC	정주은	22(5)	대한민국	한국인터넷방송통신학회	비SCIE	2022.10	2289-0246	90%
19	데이터 융합을 위한 관계형 테이블 임베딩 기법	The Journal of Society for e-Business Studie	윤종찬	27(3)	대한민국	한국전자거래학회	비SCIE	2022.08	2765-3846	70%
20	상세 자원 이용률에 기반한 병렬 가속기용 스레드 블록 스케줄링	한국인터넷방송통신학회 논문지	반효경	22	한국	한국인터넷방송통신학회ㅁ	비SCIE	2022.10	2289-0238	50%
21	모바일 기기의 실시간 작업 지원을 위한 종단간 자원 관리 기술	한국인터넷방송통신학회 논문지	반효경	22	한국	한국인터넷방송통신학회	비SCIE	2022.10	2289-0238	50%
22	Effect of Caching and Prefetching Techniques to Accelerate Channel Search Latency in IPTVs	The Journal of The Institute of Internet, Broadcasting and Communication (IIBC)	반효경	14	한국	한국인터넷방송통신학회	비SCIE	2022.05	2288-4920	50%
23	Version-Aware Cooperative Caching for Multi-Node Rendering	The Journal of The Institute of Internet, Broadcasting and Communication (IIBC)	조경운	14	한국	한국인터넷방송통신학회	비SCIE	2022.05	2288-4920	50%
24	Energy-Efficient Last-Level Cache Management for PCM Memory Systems	International Journal of Internet, Broadcasting and Communication	반효경	14	한국	한국인터넷방송통신학회	비SCIE	2022.02	2288-4920	50%
25	Optimality of Interval Caching Policies in Multimedia Streaming Systems	International Journal of Internet, Broadcasting and Communication	조경운	14	한국	한국인터넷방송통신학회	비SCIE	2022.02	2288-4920	50%
26	고속 스토리지 환경의 메모리 관리를 위한 TLB 미스율 및 페이지 폴트율 모델링	한국인터넷방송통신학회 논문지	박윤주	22	한국	한국인터넷방송통신학회	비SCIE	2022.02	2289-0238	50%
27	영속 메모리를 이용한 스마트폰 버퍼 캐시의 선별적 플러시 정책	한국인터넷방송통신학회 논문지	임수정	22	한국	한국인터넷방송통신학회	비SCIE	2022.02	2289-0238	50%
28	Supporting Swap in Real-Time Task Scheduling for Unified Power-Saving in CPU and Memory	IEEE access	Yoon, Suji	10	미국	IEEE	SCIE	2022.01	2169-3536	50

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 국내 및 국제 학술회의 발표

번호	회의 명칭	발표자	발표 일시	장소	국명
1	2020 한국소프트웨어종합학술대회 (KSC2020)	변경수	2020.12.21-23	강원도 평창	대한민국
2	2020 IEEE International Conference on Big Data	라마단 하니	2020.12.10-13	미국 (온라인 발표)	미국
3	2021년 제73차 대한예방의학회 가을학술대회	성주헌	2021.10.21.	온라인(E-포스터)	대한민국
4	한국인터넷정보학회추계학술대회	이길재	2020.10.31	여수 엑스포컨벤션	대한민국
5	2020년도 한국정보시스템학회 추계학술대회	조새롬	2020.11.14	제주 제주대학교	대한민국
6	2020년도 한국정보시스템학회 추계학술대회	이도훈	2020.11.14	제주 제주대학교	대한민국
7	The 12th International Conference on Computer Science and its Applications (CSA2020)	이길재	2020.12.14	제주 매종글래드호텔	대한민국
8	2021 한국통신학회 동계종합학술대회	조새롬	2021.02.04	강원도 용평리조트	대한민국
9	2021 한국전자거래학회 춘계학술대회	이도훈	2021.07.02	강원도 강릉 경포	대한민국
10	2021 한국전자거래학회 춘계학술대회	조새롬	2021.07.02	강원도 강릉 경포	대한민국
11	2021한국전자거래학회춘계학술대회	윤종찬	2021.07.02	강원도 강릉 경포	대한민국
12	2021 한국통신학회 인공지능학술대회	이도훈	2021.09.30	제주 신라스테이호텔	대한민국
13	2021 한국통신학회 추계종합학술대회	한상일	2021.11.18	여수 디오션리조트	대한민국
14	한국반도체학술대회	윤혜정, 반효경	2021.1.25	온라인	대한민국
15	IEEE RTSS	류수현, 반효경	2021.12.09	도르트문트/온라인	독일
16	IEEE CSDE	임수정, 반효경	2021.12.10	호주/온라인	호주
17	2022 IEEE International Conference on Big Data (Big Data)	변경수, 권준호, 김구	2022-12-19	오사카	일본
18	Korean DataBase Conference 2022	강대원, 권준호	2022-11-04	대전	대한민국
19	한국전자거래학회 2022 춘계학술대회	정주은	2022.07.01	곤지암 리조트	대한민국
20	한국전자거래학회 2022 춘계학술대회	윤종찬	2022.07.01	곤지암 리조트	대한민국
21	한국전자거래학회 2022 춘계학술대회	최윤석	2022.07.01	곤지암 리조트	대한민국
22	한국전자거래학회 2022 춘계학술대회	정한석	2022.07.01	곤지암 리조트	대한민국
23	2022 IEEE International Conference on Big Data (Big Data)	정주은	2022.12.17	Osaka International Convention Center	일본
24	9th IEEE Asia-Pacific Conference on Computer Science and Data Engineering (CSDE)	박소연	2022.12.18	Gold Coast	오스트레일리아
25	8th Int`l Congress on Energy Efficiency and Energy Related Materials (ENEFM)	조경운	2022.10.15	Oludeniz	튀르키예
26	2022년 융합학술발표대회 및 학부논문경진대회	이병영	2022년 7월 11일	국립부경대학교	한국

□ 기술 요약 정보

연도	기술명	요약 내용	기술 완성도	등록 번호	활용 여부	미활용사유	연구개발기관 외 활용여부	허용방식

□ 보고서 원문

연도	보고서 구분	발간일	등록 번호

□ 생명자원(생물자원, 생명정보)/화합물

번호	생명자원(생물자원, 생명정보)/화합물 명	등록/기탁 번호	등록/기탁 기관	발생 연도

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[기술적 성과]

□ 지식재산권(특허, 실용신안, 의장, 디자인, 상표, 규격, 신품종, 프로그램)

번호	지식재산권 등 명칭 (건별 각각 기재)	국명	출원				등록			기여율	활용 여부
			출원인	출원일	출원 번호	등록 번호	등록인	등록일	등록 번호		
1	다차원 부분집한 연관 분석에 기반한 인공지능 학습 데이터셋 고정성을 보장하는 장치 및 이를 이용한 인공지능 학습 데이터셋 종정성을 보장하는 방법	한국	부산대학교 산학협력단	2020.12.29	10-2020-0185398	-	부산대학교 산학협력단	2021.10.29	10-2321735	100	여
2	다차원 부분집한 연관 분석에 기반한 인공지능 학습 데이터셋 고정성을 보장하는 장치 및 이를 이용한 인공지능 학습 데이터셋 종정성을 보장하는 방법	PCT	부산대학교 산학협력단	2021.11.16	PCT/KR2021/016695	-				100	여
3	실시간 배치셋 기반으로 인공지능 학습 데이터셋의 공정성을 보정하는 장치 및 그 방법	한국	부산대학교 산학협력단	2021.11.01	10-2021-0147606	-				100	여
4	유방암 위험도 평가 시스템 및 방법	대한민국	서울대학교산학협력단	2021.08.12	10-2021-0106592	-				30	여
5	유방암 위험도 평가 시스템 및 방법	PCT	서울대학교산학협력단	2021.10.07	PCT/KR2021/013806	-				30	여
6	시맨틱 텐서공간모델과 어텐션 메커니즘을 활용한 자동 문서분류	한국	서울시립대학교 산학협력단	2020.12.29	10-2020-0185534	-				100	여
7	수치형 변수 및 범주형 변수를 포함하는 혼합형 결측 데이터에 대한 데이터 보간을 수행하는 장치 및 방법	한국	서울시립대학교 산학협력단	2021.11.04	10-2021-0150649	-	서울시립대학교 산학협력단	2022.06.09	10-2408655	100%	여
8	센서 데이터의 누락값 보정 방법 및 누락값 보정 장치	대한민국	이화여자대학교산학협력단	20.11.27	10-2020-0163181	-				100	여
9	대규모 테이블 데이터 정규화 방법 및 장치	대한민국	이화여자대학교산학협력단	21.11.15	10-2021-0156851	-				100	여
10	사용자와 객체 간의 거리를 측정하기 위한 단말 및 방법	한국	한성대학교 산학협력단	2021.11.30	10-2021-0168743	-				100	여
11	고품질 데이터 서비스를 위한 에이피아이 자동 생성 방법	대한민국	㈜프람트테크놀로지	2020.11.17	제10-2020-0153462호	-				100	활용 예정
12	데이터셋 품질을 고려한 메타데이터 기반 연관 데이터셋 검색 방법	대한민국	㈜프람트테크놀로지	2021.10.13	제10-2021-0135704호	-				100	활용 예정
13	대용량 분석 데이터의 다차원 시각화 시스템 및 이를 이용한 대용량 분석 데이터의 다차원 시각화 방법	한국	(주)아이소프트	2020.12.15	10-2020-0175786	-	㈜아이소프트	2022년 8월 23일	10-2437184	100	여
14	인공지능 학습 데이터의 공정한 보장을 위한 대칭 구조 기반 모조 데이터 생성 장치 및 방법	한국	부산대학교 산학협력단	2022-12-13	10-2022-0173278	-				60	여
15	심장 윤곽 예측 모델 생성 방법 및 장치, 이를 이용한 동물의 심비대 판단 방법 및 시스템	대한민국	서울대학교산학협력단	2022.12.02	10-2022-0166576	-	-	-	-	60%	여
16	수치형 학습 데이터를 증강시키는 서버, 방법 및 컴퓨터 프로그램	대한민국	서울시립대학교 산학협력단	2022.11.16	10-2022-0153486		-	-	-	100%	-
17	시계열 데이터의 품질을 개선하는 장치 및 방법	대한민국	서울시립대학교 산학협력단	2022.11.17	10-2022-0154168		서울시립대학교 산학협력단	-	-	100%	-
18	기계 학습 모델의 학습 데이터 품질 향상을 위한 특징 공학 파이프라인 방법 및 장치	한국	이화여자대학교 산학협력	22.11.04	10-2022-0146508					50	미활용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

			단								
19	데이터 프로파일링 서비스를 제공하는 서버 및 방법	한국	한성대학교 산학협력단	2022.10.26	10-2022-0138955					100	-
20	메타데이터 표준을 준용한 메타데이터 제공 에이피아이 자동생성 방법	대한민국	㈜프람트테크놀로지	2022.12.29.	10-2022-0188252	-	-	-	-	100%	활용
21	인공지능 학습 데이터셋의 공정성 시각화 장치 및 방법	한국	김구, 최동규, 서형윤, 변경수	2022년 10월 20일	10-2022-0135781						-

ㅇ 지식재산권 활용 유형

※ 활용의 경우 현재 활용 유형에 √ 표시, 미활용의 경우 향후 활용 예정 유형에 √ 표시합니다(최대 3개 중복선택 가능).

번호	제품화	방어	전용실시	통상실시	무상실시	매매/양도	상호실시	담보대출	투자	기타
1	✓				✓					

□ 저작권(소프트웨어, 서적 등)

번호	저작권명	창작일	저작자명	등록일	등록 번호	저작권자명	기여율
1	데이터 보정기 v1.0	2020.10.07	부산대학교 산학협력단	2020.11.30	C-2020-046343	부산대학교 산학협력단	100
2	데이터 입력기 v1.0	2020.10.12	부산대학교 산학협력단	2020.12.01	C-2020-046929	부산대학교 산학협력단	100
3	데이터 보정기 v2.0	2021.08.30	부산대학교 산학협력단	2021.10.12	C-2021-040002	부산대학교 산학협력단	100
4	데이터 공정성 검증기 v1.0	2021.08.30	부산대학교 산학협력단	2021.10.12	C-2021-040003	부산대학교 산학협력단	100
5	디노이징 셀프 어텐션 네트워크 기반 결측값 보간기	2021.05.01	서울시립대학교 산학협력단	2021.09.29	C-2021-038712	서울시립대학교 산학협력단	100
6	qufafeat(특징 공학자동화도구)	21.10.1	이화여자대학교 산학협력단	21.10.26	C-2021-043015	이화여자대학교 산학협력단	100%
7	데이터 프로파일링 소프트웨어	2021.10.01	한성대학교 산학협력단	2021.11.02	C-201-044692	한성대학교 산학협력단	100
8	데이터 품질 및 공정성 통합 시스템	2021.10.07	㈜프람트테크놀로지	2021.10.18	제C-2021-041074호	㈜프람트테크놀로지	100
9	기계학습 구분 기반의 공정성 검증	2021.12.28	주식회사 아이소프트	2022.01.04	C-2022-000595	주식회사 아이소프트	100
10	데이터 보정기 v3.0 (Data corrector v3.0)	2022-08-30	부산대학교 산학협력단	2022-09-23	C-2022-036620	부산대학교 산학협력단	100
11	수치형 테이블 데이터 증강기	2022.09.10	서울시립대학교 산학협력단	2022.12.07	C-2022-051201	서울시립대학교 산학협력단	100
12	딥러닝 기반 시계열 데이터 품질 개선기	2022.09.10	서울시립대학교 산학협력단	2022.12.22	C-2022-055914	서울시립대학교 산학협력단	100
13	데이터 품질진단 소프트웨어	2022.12.01	한성대학교 산학협력단	2023.01.03	C-2023-000434	한성대학교 산학협력단	100
14	데이터 품질 및 공정성 통합 시스템 고도화	2022.12.09	㈜프람트테크놀로지	2022.12.28	C-2022-057226	㈜프람트테크놀로지	100%
15	원천데이터 적재 시스템	2022.11.23	㈜프람트테크놀로지	2022.12.28.	C-2022-057227	㈜프람트테크놀로지	100%
16	데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정기술	2022년 9월 30일	주식회사 아이소프트	2020년 10월 19일	C-2022-040095	주식회사 아이소프트	100%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 신기술 지정

번호	명칭	출원일	고시일	보호 기간	지정 번호

□ 기술 및 제품 인증

번호	인증 분야	인증 기관	인증 내용		인증 획득일	국가명
			인증명	인증 번호		

□ 표준화

ㅇ 국제표준 및 사실표준

번호	표준화 기구명	표준화 분과명[1]	표준 종류[2]	표준 단계[3]		제안(기고)한 표준[4]		반영(채택)된 표준[5]		제안자	승인(채택) 일자
				구분	단계명	표준번호	표준명	표준번호	표준명		
1	*ITU-T*	*SG5/WP1/Q2*	*제정*	*제안*	*NWI*	*C.xxxx*		*TD.xxxx*			

* 1」 해당 표준을 진행한 표준화기구 분과명 및 분과번호를 하위 조직까지 기재합니다.
* 2」 제정 또는 개정 중 해당하는 사항을 기재합니다.
* 3」 국제표준 진행 단계 중 해당하는 사항을 기재합니다.
(예) ITU-T의 경우, 신규 작업항목 제안 채택(NWI), 표준문서개발(Draft Recommendation), 국제표준승인(Recommendation)
* 4」 제안(기고)한 표준문서가 제안/개발/승인 문서에 반영(채택)되었을 경우, 제안(Contribution)한 표준문서 정보를 기재합니다.
* 5」 제안(기고)한 표준문서가 제안/개발/승인 문서에 반영(채택)되었을 경우, 반영(TD/Recommendation)된 표준문서 정보를 기재합니다.

ㅇ 국가표준 및 단체표준

번호	표준화 기구명[1]	표준종류[2]	표준명	표준번호	제안자	승인(채택) 일자
1	*TTA*	*제정*				

* 1」 제정 또는 개정한 표준화기구를 국립전파연구원(RRA), 국가기술표준원(KATS), 한국정보통신기술협회(TTA) 등에서 해당하는 사항으로 기재합니다.
* 2」 제정 또는 개정 중 해당하는 사항을 기재합니다.

ㅇ 국제표준 정책기고

번호	표준화 기구명	표준화 정책위원회명[1]	문서종류[2]	문서반영 단계구분[3]	결의안/기고명	문서번호	제안자	승인(채택) 일자
1	*ITU-T*	*ITU-T WTSA*	*제정*	*ITU-T WTSA Resolution*				

* 1」 정책위원회에 해당하는 ITU PP, ITU-T WTSA, ITU-T TSAG, ITU-R RA/WRC, ITU-R RAG/WP5D, ITU-D WTDC, ITU-D TDAG, APT, MC/APG/AWG/WTSA/ASTAP, JTC 1 총회 및 산하 자문그룹, ISO 총회, ISO TMB, IEC 총회, IEC SMB, 3GPP PCC/OP/TSGs, W3C 자문위원회 등에서 해당하는 사항으로 기재합니다.
* 2」 제정 또는 개정 중 해당하는 사항을 기재합니다.
* 3」 결의안, 국가선도기술 제안, 정책위원회 기고 반영의 진행 단계 중 해당하는 사항을 기재합니다.

ㅇ 오픈소스 연계 표준개발

번호	구분	표준문서 및 오픈소스 정보							승인(채택) 일자	과제검증 시험 결과서 번호[4]
		표준화 기구명	표준화 분과명[1]	표준 종류[2]	표준단계		반영(채택)된 표준[3]			
					구분	단계명	표준번호	표준명		
1	표준	*3GPP*	*SG5/WP1/Q2*	*제정*	*제안*	*NWI*				
	오픈소스	프로젝트명			반영 소스명				승인(Commit) 일자	
		O-RAN								

* 1」 해당 표준을 진행한 표준화기구 분과명 및 분과번호를 하위 조직까지 기재합니다.
* 2」 제정 또는 개정 중 해당하는 사항을 기재합니다.
* 3」 제안(기고)한 표준문서가 제안/개발/승인 문서에 반영(채택)되었을 경우, 반영(TD/Recommendation)된 표준문서 정보를 기재합니다.
* 4」 표준문서와 오픈소스의 정합에 대하여 TTA에서 발급한 시험 결과서 번호를 기재합니다.

ㅇ 표준특허

번호	표준특허 구분[1]	표준						특허				
		표준화 기구	표준 단계[2]		표준명	표준번호	승인/개발 일자	IPR 선언 일자	특허 단계 구분[3]	특허명	특허번호	국명	출원/등록 일자
			구분	단계명									
1	*국제표준 특허승인*	*3GPP*	*승인*	*TS*					*등록*				

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

* 1」 국내/국제 표준특허 승인 또는 후보 중 해당하는 사항을 기재합니다.
* 2」 국내/국제표준 진행 단계 중 해당하는 사항을 기재합니다.
* 3」 특허 출원, 등록 중 해당하는 사항을 기재합니다.

ㅇ 표준 국제협력

번호	의장단 수임						위원회/그룹 신설			국제회의 국내유치		
	표준화 기구명	표준화 분과명[1]	의장단 직위[2]	신규/계속 여부	수임자	수임기간	표준화 기구명	표준화 분과명[1]	신설일자	표준화 기구명	표준화 회의명	회의일자
1	*ITU-T*	*SG5/WP1 /Q2*	*라포처*	*신규*			*ITU-T*	*SG5/WP1 /Q2*		*ITU-T*	*FG abc*	

* 1」 해당 표준을 진행한 표준화기구 분과명 및 분과번호를 하위 조직까지 기재합니다.
* 2」 의장단 수임 직위를 의장, 부의장, 라포처, 컨비너, 에디터, 프로젝트리더 중에서 해당하는 사항으로 기재합니다.

[경제적 성과]

□ 시제품 제작

번호	시제품명	출시/제작일	제작 업체명	설치 장소	이용 분야	사업화 소요 기간	인증기관 (해당 시)	인증일 (해당 시)
1	Qufa Studio (데이터 품질 및 공정성 통합 시스템)	2022.12.09	㈜프람트테크놀로지	-	데이터 처리 분야	30개월	-	-
2	Data Hunter (원천데이터 적재 시스템)	2022.11.23	㈜프람트테크놀로지	-	데이터 처리 분야	30개월	-	-

□ 기술 실시(이전)

번호	기술 이전 유형	기술 실시 계약명	기술 실시 대상 기관	기술 실시 발생일	기술료 (해당 연도 발생액)	누적 징수 현황
1	노하우	적대적 생성 신경망(GAN) 기반의 모조 빅데이터 생성기법 및 도구	㈜아이소프트	2022.10.24	10,000,000	10,000,000
2	노하우이전	정형데이터 품질 개선 기술	㈜프람트테크놀로지	2022.12	10,000,000	10,000,000

* 내부 자금, 신용 대출, 담보 대출, 투자 유치, 기타 등

□ 사업화 투자실적

번호	추가 연구개발 투자	설비 투자	기타 투자	합계	투자 자금 성격*

□ 사업화 현황

번호	사업화 방식[1]	사업화 형태[2]	지역[3]	사업화명	내용	업체명	매출액		매출 발생 연도	기술 수명
							국내 (천원)	국외 (달러)		
1	자기실시	기존 공정 개선	국내	SRT 승차권 데이터 확인 서비스 구축(개방DB 품질 진단 및 개선)	SRT 승차권 데이터 확인 서비스 구축 사업을 통해 구축된 개방DB를 대상으로 다양한 형태의 품질 진단 및 진단 결과를 토대로 한 개선 작업 수행	㈜프람트테크놀로지	72,000	-	2022	10년
2	자기실시	기존제품개선	국내	임상 데이터 확보/연계를 위한 임상 연구 데이터 시스템(CDW) 및 바이오뱅크 임상 연구 데이터 시스템 모델(CDM)구축	데이터 품질평가기반 데이터 고도화 및 데이터셋 보정 기술 가시화 등 진행	아이소프트	84,000	-	2022	10년

* 1」 기술이전 또는 자기실시
* 2」 신제품 개발, 기존 제품 개선, 신공정 개발, 기존 공정 개선 등
* 3」 국내 또는 국외

□ 매출 실적(누적)

사업화명	발생 연도	매출액	합계	산정 방법

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		국내(천원)	국외(달러)		
임상 데이터 확보/연계를 위한 임상 연구 데이터 시스템(CDW) 및 바이오뱅크 임상 연구 데이터 시스템 모델(CDM)구축	2022	84,000		84,000	
합계					

□ 사업화 계획 및 무역 수지 개선 효과

성과					
사업화 계획	사업화 소요기간(년)				
	소요예산(천원)				
	예상 매출규모(천원)		현재까지	3년 후	5년 후
	시장 점유율	단위(%)	현재까지	3년 후	5년 후
		국내			
		국외			
	향후 관련기술, 제품을 응용한 타 모델, 제품 개발계획				
무역 수지 개선 효과(천원)	수입대체(내수)		현재	3년 후	5년 후
	수출				

□ 고용 창출

순번	사업화명	사업화 업체	고용창출 인원(명)			합계
			2020년	2021년	2022년	
1	고품질 데이터 서비스를 위한 오픈소스 API 관리시스템	㈜프람트테크놀로지	2	-	2	4
2	임상 데이터 확보/연계를 위한 임상 연구 데이터 시스템(CDW) 및 바이오뱅크 임상 연구 데이터 시스템 모델(CDM)구축	아이소프트	-	-	3	3
합계			2	0	5	7

□ 고용 효과

구분			고용 효과(명)
고용 효과	개발 전	연구인력	
		생산인력	
	개발 후	연구인력	
		생산인력	

□ 비용 절감(누적)

순번	사업화명	발생연도	산정 방법	비용 절감액(천원)
합계				

□ 경제적 파급 효과

(단위: 천원/년)

구분	사업화명	수입 대체	수출 증대	매출 증대	생산성 향상	고용 창출 (인력 양성 수)	기타
해당 연도	고품질 데이터 서비스를 위한 오픈소스 API 관리시스템	-	-	-	180,000	2	-
기대 목표		-	-	-	180,000	2	-

□ 산업 지원(기술지도)

순번	내용	기간	참석 대상	장소	인원

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

□ 기술 무역

(단위: 천원)

번호	계약 연월	계약 기술명	계약 업체명	계약업체 국가	기 징수액	총 계약액	해당 연도 징수액	향후 예정액	수출/ 수입

[사회적 성과]

□ 법령 반영

번호	구분 (법률/시행령)	활용 구분 (제정/개정)	명 칭	해당 조항	시행일	관리 부처	제정/개정 내용

□ 정책활용 내용

번호	구분 (제안/채택)	정책명	관련 기관 (담당 부서)	활용 연도	채택 내용

□ 설계 기준/설명서(시방서)/지침/안내서에 반영

번호	구 분 (설계 기준/설명서/지침/안내서)	활용 구분 (신규/개선)	설계 기준/설명서/ 지침/안내서 명칭	반영일	반영 내용

□ 전문 연구 인력 양성

번호	분류	기준 연도	현황										
			학위별				성별		지역별				
1	학위	2020	박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
				3			2	1	3				
2	학위	2021	박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
				3	1		2	1	3		1		
3	학위	2022	박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
			1	3			4		2		1		1

□ 산업 기술 인력 양성

번호	프로그램명	프로그램 내용	교육 기관	교육 개최 횟수	총 교육 시간	총 교육 인원

□ 다른 국가연구개발사업에의 활용

번호	중앙행정기관명	사업명	연구개발과제명	연구책임자	연구개발비

□ 국제화 협력성과

번호	구분 (유치/파견)	기간	국가	학위	전공	내용

□ 홍보 실적

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	홍보 유형	매체명	제목	홍보일
1	웹 기반 모달링크	기관별 웹 페이지	공식 저장소(QuFa) 링크	상시
2	동영상 홍보	QuFa 유튜브 공식채널	QuFa(Data Quality and Fairness)	상시
3	학술대회 논문홍보	2022 융합학술발표대회& 학부논문경진대회 발표논문집	데이터 공정성 도구 및 시각화 비교 연구	상시

□ 포상 및 수상 실적

번호	종류	포상명	포상 내용	포상 대상	포상일	포상 기관
1	2021 한국통신학회 학술대회 우수논문	우수논문상	한국어 텍스트 임베딩 모델의 개선을 위한 예비 연구	조새롬, 김한준	2021.06.16	한국통신학회
2	2021 한국전자거래학회 학술대회 우수논문	우수논문상	공간 정보를 가지는 데이터셋의 자동 융합 기법	윤종찬, 김한준	2021.07.02	한국통신학회
3	제3회 빅데이터 인공지능 경진대회	우수상	수요예측 모델개발 부문 우수상	변경수, 강대원	2021.12.24	한국가스공사
4	2022년 한국컴퓨터종합학술대회 논문집	우수논문상	데이터셋의 편향제거를 위한 알고리즘에 관한 연구	변경수, 권준호, 김구	2022.6.30	한국정보과학회
5	2022년도 한국전자거래학회 춘계학술대회	우수논문상	관계형 테이블의 임베딩을 통한 준자동 데이터 융합	윤종찬, 김한준	2022.07.01	한국전자거래학회

[인프라 성과]

□ 연구시설・장비

구축기관	연구시설/ 연구장비명	규격 (모델명)	개발여부 (○/×)	연구시설・장비 종합정보시스템* 등록여부	연구시설・장비 종합정보시스템* 등록번호	구축일자 (YY.MM.DD)	구축비용 (천원)	비고 (설치 장소)

* 「과학기술기본법 시행령」 제42조제4항제2호에 따른 연구시설・장비 종합정보시스템을 의미합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[그 밖의 성과]

가) MOU 에 따른 기존의 제안 외 추가 데이터셋을 대상으로 연구개발 산출물 적용 및 검증

■ 업무협력(MOU) 목표

- 데이터 품질 개선을 위한 데이터 분석 및 보정
  - ✓ 실제 산업 데이터의 품질 고도화를 통한 서비스의 부가가치 향상
  - ✓ 연구개발 협력을 통해 산업현장이 요구하는 연구기술의 현장 활용성 증대
- 정형 및 관측 시계열 데이터에서 비정상 이상 데이터 탐지
- 목표 속성 데이터들의 특정 시점 이후의 값 예측 수행

[공공기관 데이터셋]

■ 한국공항공사 – 부산대 – 서울시립대 간 MOU 체결

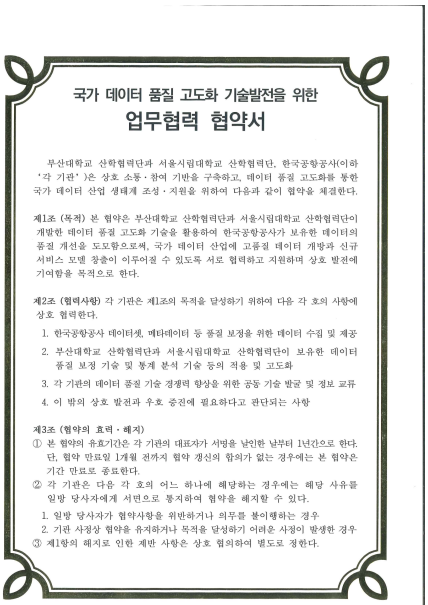

국가 데이터 품질 고도화 기술발전을 위한
업무협력 협약서

부산대학교 산학협력단과 서울시립대학교 산학협력단, 한국공항공사(이하 '각 기관')은 상호 소통·참여 기반을 구축하고, 데이터 품질 고도화를 통한 국가 데이터 산업 생태계 조성·지원을 위하여 다음과 같이 협약을 체결한다.

제1조 (목적) 본 협약은 부산대학교 산학협력단과 서울시립대학교 산학협력단이 개발한 데이터 품질 고도화 기술을 활용하여 한국공항공사가 보유한 데이터의 품질 개선을 도모함으로써, 국가 데이터 산업에 고품질 데이터 개방과 신규 서비스 모델 창출이 이루어질 수 있도록 서로 협력하고 지원하며 상호 발전에 기여함을 목적으로 한다.

제2조 (협력사항) 각 기관은 제1조의 목적을 달성하기 위하여 다음 각 호의 사항에 상호 협력한다.

1. 한국공항공사 데이터셋, 메타데이터 등 품질 보정을 위한 데이터 수집 및 제공
2. 부산대학교 산학협력단과 서울시립대학교 산학협력단이 보유한 데이터 품질 보정 기술 및 통계 분석 기술 등의 적용 및 고도화
3. 각 기관의 데이터 품질 기술 경쟁력 향상을 위한 공동 기술 발굴 및 정보 교류
4. 이 밖의 상호 발전과 우호 증진에 필요하다고 판단되는 사항

제3조 (협약의 효력·해지)
① 본 협약의 유효기간은 각 기관의 대표자가 서명을 날인한 날부터 1년간으로 한다. 단, 협약 만료일 1개월 전까지 협약 갱신의 합의가 없는 경우에는 본 협약은 기간 만료로 종료한다.
② 각 기관은 다음 각 호의 어느 하나에 해당하는 경우에는 해당 사유를 일방 당사자에게 서면으로 통지하여 협약을 해지할 수 있다.
1. 일방 당사자가 협약사항을 위반하거나 의무를 불이행하는 경우
2. 기관 사정상 협약을 유지하거나 목적을 달성하기 어려운 사정이 발생한 경우
③ 제1항의 해지로 인한 제반 사항은 상호 협의하여 별도로 정한다.

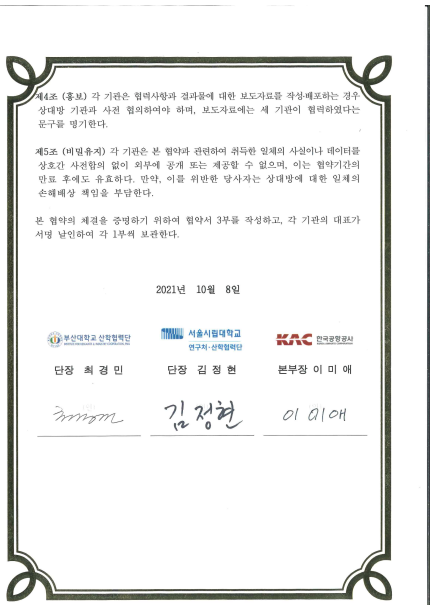

제4조 (홍보) 각 기관은 협력사항과 결과물에 대한 보도자료를 작성·배포하는 경우 상대방 기관과 사전 협의하여야 하며, 보도자료에는 세 기관이 협력하였다는 문구를 명기한다.

제5조 (비밀유지) 각 기관은 본 협약과 관련하여 취득한 일체의 사실이나 데이터를 상호간 사전합의 없이 외부에 공개 또는 제공할 수 없으며, 이는 협약기간의 만료 후에도 유효하다. 만약, 이를 위반한 당사자는 상대방에 대한 일체의 손해배상 책임을 부담한다.

본 협약의 체결을 증명하기 위하여 협약서 3부를 작성하고, 각 기관의 대표가 서명 날인하여 각 1부씩 보관한다.

2021년 10월 8일

부산대학교 산학협력단 단장 최 경 민
서울시립대학교 연구처·산학협력단 단장 김 정 현
KAC 한국공항공사 본부장 이 미 애

[민간기관 데이터셋]

■ ㈜그리드위즈 – 부산대 간 MOU 체결

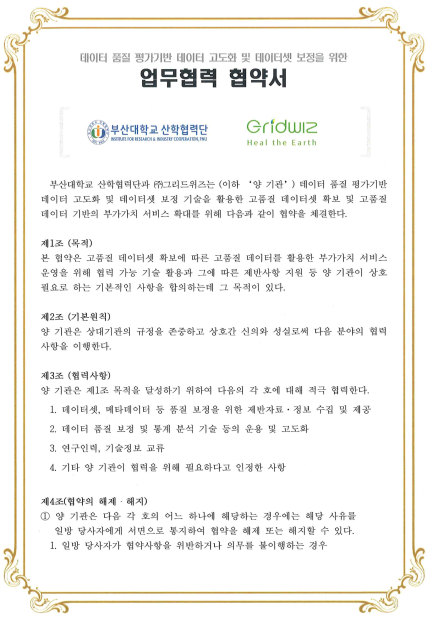

데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정을 위한
업무협력 협약서

부산대학교 산학협력단 Gridwiz Heal the Earth

부산대학교 산학협력단과 ㈜그리드위즈는 (이하 '양 기관') 데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술을 활용한 고품질 데이터셋 확보 및 고품질 데이터 기반의 부가가치 서비스 확대를 위해 다음과 같이 협약을 체결한다.

제1조 (목적)
본 협약은 고품질 데이터셋 확보에 따른 고품질 데이터를 활용한 부가가치 서비스 운영을 위해 협력 가능 기술 활용과 그에 따른 제반사항 지원 등 양 기관이 상호 필요로 하는 기본적인 사항을 합의하는데 그 목적이 있다.

제2조 (기본원칙)
양 기관은 상대기관의 규정을 존중하고 상호간 신의와 성실로써 다음 분야의 협력 사항을 이행한다.

제3조 (협력사항)
양 기관은 제1조 목적을 달성하기 위하여 다음의 각 호에 대해 적극 협력한다.

1. 데이터셋, 메타데이터 등 품질 보정을 위한 제반자료·정보 수집 및 제공
2. 데이터 품질 보정 및 통계 분석 기술 등의 운용 및 고도화
3. 연구인력, 기술정보 교류
4. 기타 양 기관이 협력을 위해 필요하다고 인정한 사항

제4조(협약의 해제·해지)
① 양 기관은 다음 각 호의 어느 하나에 해당하는 경우에는 해당 사유를 일방 당사자에게 서면으로 통지하여 협약을 해제 또는 해지할 수 있다.
1. 일방 당사자가 협약사항을 위반하거나 의무를 불이행하는 경우

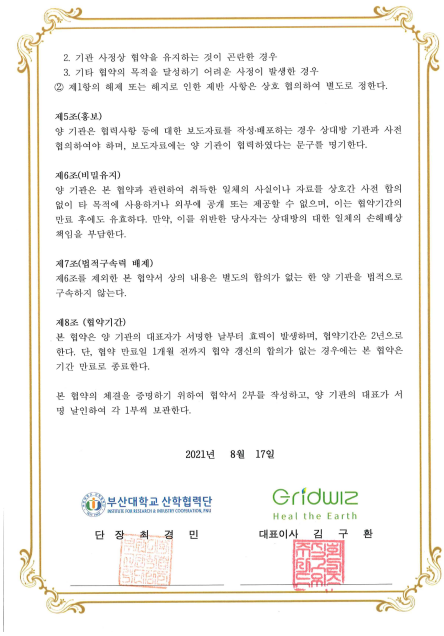

2. 기관 사정상 협약을 유지하는 것이 곤란한 경우
3. 기타 협약의 목적을 달성하기 어려운 사정이 발생한 경우
② 제1항의 해제 또는 해지로 인한 제반 사항은 상호 협의하여 별도로 정한다.

제5조(홍보)
양 기관은 협력사항 등에 대한 보도자료를 작성·배포하는 경우 상대방 기관과 사전 협의하여야 하며, 보도자료에는 양 기관이 협력하였다는 문구를 명기한다.

제6조(비밀유지)
양 기관은 본 협약과 관련하여 취득한 일체의 사실이나 자료를 상호간 사전 합의 없이 타 목적에 사용하거나 외부에 공개 또는 제공할 수 없으며, 이는 협약기간의 만료 후에도 유효하다. 만약, 이를 위반한 당사자는 상대방의 대한 일체의 손해배상 책임을 부담한다.

제7조(법적구속력 배제)
제6조를 제외한 본 협약서 상의 내용은 별도의 합의가 없는 한 양 기관을 법적으로 구속하지 않는다.

제8조 (협약기간)
본 협약은 양 기관의 대표자가 서명한 날부터 효력이 발생하며, 협약기간은 2년으로 한다. 단, 협약 만료일 1개월 전까지 협약 갱신의 합의가 없는 경우에는 본 협약은 기간 만료로 종료한다.

본 협약의 체결을 증명하기 위하여 협약서 2부를 작성하고, 양 기관의 대표가 서명 날인하여 각 1부씩 보관한다.

2021년 8월 17일

부산대학교 산학협력단 단 장 최 경 민
Gridwiz Heal the Earth 대표이사 김 구 환

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나) 빅데이터 플랫폼/센터 데이터셋 연계를 위한 노력

[빅데이터 플랫폼/센터의 데이터셋 연계 및 활용]

■ 헬스케어 빅데이터 플랫폼 '**암예방-진단 라이프스타일 데이터 센터**'의 암 검진(질병 위험도 진단 평가(합성)) 데이터셋 연계에 따른 데이터 품질개선/공정성보정/프로파일링/특징공학을 위한 연구개발 원천 알고리즘 활용

▪ 공동연구기관 중 수요기업(프람트테크놀로지, 아이소프트) 및 신규 사업화기업(디렉스)의 데이터 연계 및 활용

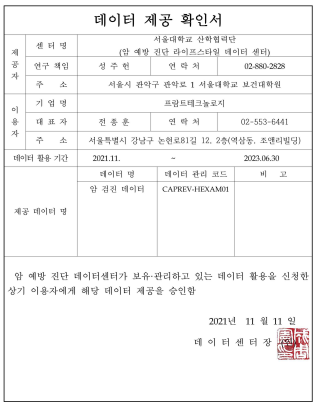

데이터 제공 확인서

제공자	센 터 명	서울대학교 산학협력단 (암 예방 진단 라이프스타일 데이터 센터)		
	연구 책임	성 주 헌	연 락 처	02-880-2828
	주 소	서울시 관악구 관악로 1 서울대학교 보건대학원		
이용자	기 업 명	프람트테크놀로지		
	대 표 자	전 홍 훈	연 락 처	02-553-6441
	주 소	서울특별시 강남구 논현로81길 12, 2층(역삼동, 조앤리빌딩)		
데이터 활용 기간		2021.11. ~ 2023.06.30		
제공 데이터 명		데이터 명	데이터 관리 코드	비 고
		암 검진 데이터	CAPREV-HEXAM01	

암 예방 진단 데이터센터가 보유·관리하고 있는 데이터 활용을 신청한 상기 이용자에게 해당 데이터 제공을 승인함

2021년 11 월 11 일

데 이 터 센 터 장

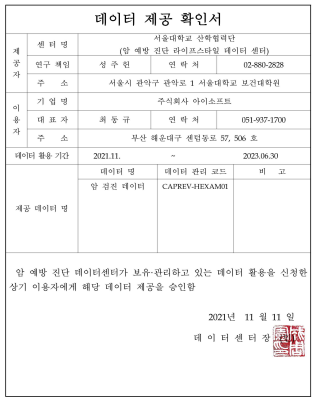

데이터 제공 확인서

제공자	센 터 명	서울대학교 산학협력단 (암 예방 진단 라이프스타일 데이터 센터)		
	연구 책임	성 주 헌	연 락 처	02-880-2828
	주 소	서울시 관악구 관악로 1 서울대학교 보건대학원		
이용자	기 업 명	주식회사 아이소프트		
	대 표 자	최 동 규	연 락 처	051-937-1700
	주 소	부산 해운대구 센텀동로 57, 506 호		
데이터 활용 기간		2021.11. ~ 2023.06.30		
제공 데이터 명		데이터 명	데이터 관리 코드	비 고
		암 검진 데이터	CAPREV-HEXAM01	

암 예방 진단 데이터센터가 보유·관리하고 있는 데이터 활용을 신청한 상기 이용자에게 해당 데이터 제공을 승인함

2021년 11 월 11 일

데 이 터 센 터 장

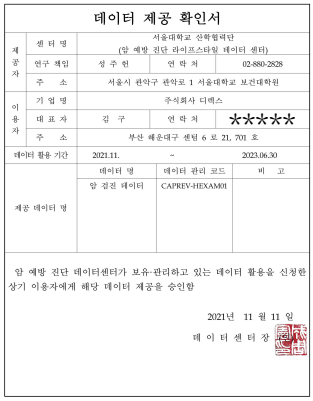

데이터 제공 확인서

제공자	센 터 명	서울대학교 산학협력단 (암 예방 진단 라이프스타일 데이터 센터)		
	연구 책임	성 주 헌	연 락 처	02-880-2828
	주 소	서울시 관악구 관악로 1 서울대학교 보건대학원		
이용자	기 업 명	주식회사 디렉스		
	대 표 자	김 구	연 락 처	★★★★★
	주 소	부산 해운대구 센텀 6 로 21, 701 호		
데이터 활용 기간		2021.11. ~ 2023.06.30		
제공 데이터 명		데이터 명	데이터 관리 코드	비 고
		암 검진 데이터	CAPREV-HEXAM01	

암 예방 진단 데이터센터가 보유·관리하고 있는 데이터 활용을 신청한 상기 이용자에게 해당 데이터 제공을 승인함

2021년 11 월 11 일

데 이 터 센 터 장

[빅데이터 플랫폼/센터의 데이터셋 추가 연계/활용을 위한 준비]

■ 해양수산 빅데이터 플랫폼의 항만물류빅데이터센터 – 부산대 간 MOU 체결

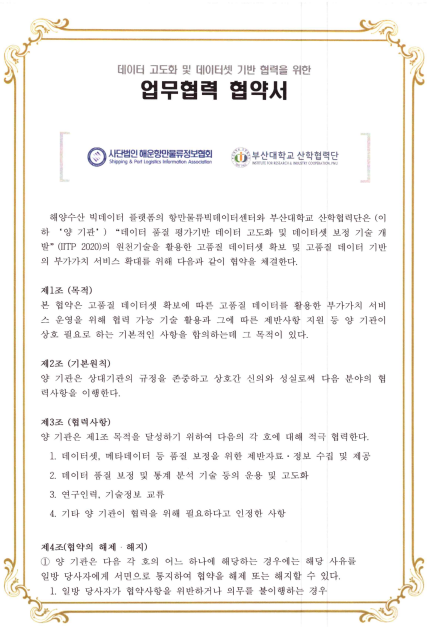

데이터 고도화 및 데이터셋 기반 협력을 위한

업무협력 협약서

사단법인 해운항만물류정보협회 Shipping & Port Logistics Information Association

부산대학교 산학협력단

해양수산 빅데이터 플랫폼의 항만물류빅데이터센터와 부산대학교 산학협력단은 (이하 '양 기관') "데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발" (IITP 2020)의 원천기술을 활용한 고품질 데이터셋 확보 및 고품질 데이터 기반의 부가가치 서비스 확대를 위해 다음과 같이 협약을 체결한다.

제1조 (목적)
본 협약은 고품질 데이터셋 확보에 따른 고품질 데이터를 활용한 부가가치 서비스 운영을 위해 협력 가능 기술 활용과 그에 따른 제반사항 지원 등 양 기관이 상호 필요로 하는 기본적인 사항을 합의하는데 그 목적이 있다.

제2조 (기본원칙)
양 기관은 상대기관의 규정을 존중하고 상호간 신의와 성실로써 다음 분야의 협력사항을 이행한다.

제3조 (협력사항)
양 기관은 제1조 목적을 달성하기 위하여 다음의 각 호에 대해 적극 협력한다.
1. 데이터셋, 메타데이터 등 품질 보정을 위한 제반자료 · 정보 수집 및 제공
2. 데이터 품질 보정 및 통계 분석 기술 등의 운용 및 고도화
3. 연구인력, 기술정보 교류
4. 기타 양 기관이 협력을 위해 필요하다고 인정한 사항

제4조(협약의 해제 · 해지)
① 양 기관은 다음 각 호의 어느 하나에 해당하는 경우에는 해당 사유를 일방 당사자에게 서면으로 통지하여 협약을 해제 또는 해지할 수 있다.
1. 일방 당사자가 협약사항을 위반하거나 의무를 불이행하는 경우

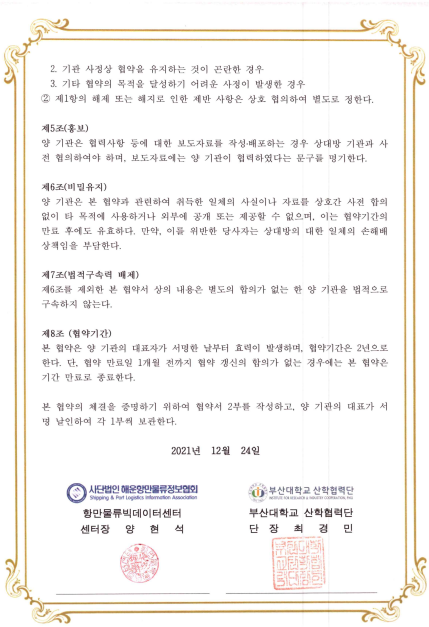

2. 기관 사정상 협약을 유지하는 것이 곤란한 경우
3. 기타 협약의 목적을 달성하기 어려운 사정이 발생한 경우

② 제1항의 해제 또는 해지로 인한 제반 사항은 상호 협의하여 별도로 정한다.

제5조(홍보)
양 기관은 협력사항 등에 대한 보도자료를 작성·배포하는 경우 상대방 기관과 사전 협의하여야 하며, 보도자료에는 양 기관이 협력하였다는 문구를 명기한다.

제6조(비밀유지)
양 기관은 본 협약과 관련하여 취득한 일체의 사실이나 자료를 상호간 사전 합의 없이 타 목적에 사용하거나 외부에 공개 또는 제공할 수 없으며, 이는 협약기간의 만료 후에도 유효하다. 만약, 이를 위반한 당사자는 상대방의 대한 일체의 손해배상책임을 부담한다.

제7조(법적구속력 배제)
제6조를 제외한 본 협약서 상의 내용은 별도의 합의가 없는 한 양 기관을 법적으로 구속하지 않는다.

제8조 (협약기간)
본 협약은 양 기관의 대표자가 서명한 날부터 효력이 발생하며, 협약기간은 2년으로 한다. 단, 협약 만료일 1개월 전까지 협약 갱신의 합의가 없는 경우에는 본 협약은 기간 만료로 종료한다.

본 협약의 체결을 증명하기 위하여 협약서 2부를 작성하고, 양 기관의 대표가 서명 날인하여 각 1부씩 보관한다.

2021년 12월 24일

사단법인 해운항만물류정보협회 Shipping & Port Logistics Information Association
항만물류빅데이터센터
센터장 양 현 석

부산대학교 산학협력단
부산대학교 산학협력단
단 장 최 경 민

▪ 항만물류빅데이터센터 보유의 다양한 데이터셋 제공/연계 확약에 따라 활용 예정인 데이터셋의 품질 및 공정성 보정 실시

(4) 계획하지 않은 성과 및 관련 분야 기여사항(해당사항 없음)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 목표 달성 수준

구분	추 진 목 표	달 성 내 용	달성도(%)
부산대	○ 교통 데이터 품질 지표분석	○ 교통 데이터 지표를 설정한 후 해당 지표에 AHP분석을 실시하여 평가 대상을 선정함	100
	○ 비정형 이미지 데이터 품질지표 평가 모델링	○ 참조 기반 및 블라인드 기반 품질 진단을 실실하여 이미지 품질을 측정함	100
	○ 품질 성능지표 체계화	○ 데이터 품질지표 평가 모델의 일반적인 방법론을 정의함	100
	○ 데이터셋 공정성 보정	○ 공정성 보정을 위한 Data compensationv1.0 (데이터 보정기)를 구현함	100
	○ 데이터셋 구성 요소 분석	○ 데이터셋 공정성에 영향을 주는 요소 분석 ○ 데이터 공정성 지표 분석	100
	○ 데이터셋 공정성 보정 고도화	○ 데이터셋 내의 편향의 종류 분석 및 정의 ○ 데이터셋의 편향 확인/분석 ○ 편향 제거를 위한 공정성 보정기 고도화 설계 및 구현	100
	○ 배치 기반 데이터 셋 공정성 보정 기술	○ 배치 데이터셋의 편향 확인 및 검증 ○ 배치 데이터셋의 편향 제거를 위한 공정성 보정기 설계 및 구현 ○ 스파크 및 카프카를 활용한 배치 처리 기법 설계 ○ 공정성 보정기와 결합 및 웹서비스 구현, 가시화 설계	100
	○ 점증적 데이터 셋 보정 기술 개발 및 고도화	○ 점증적 데이터 셋을 위한 람다 아키텍처 구축 ○ 람다 아키텍처 내 점증적 데이터 공정성 보정 알고리즘 설계 및 구현 ○ 편향 제거를 통해 공정성 보정이 어려울 경우를 위한 모조 데이터 생성기 설계 및 구현 ○ 데이터 반전 모듈 및 데이터 생성기 구현	100
	○ 공정성 보정 기술 통합	○ 점증적 데이터 셋 처리 및 공정성 보정 기술 통합 ○ 점증적 데이터 셋 아키텍처 구축 공정성 보정기 통합 설계 ○ 공정성 보정 통합 기술 시각화	100
	○ 빅데이터 플랫폼 연계 통합 관리	○ 빅데이터 플랫폼 연계 및 통합 관리를 위한 API 정의 및 서버구축	100
서울대	○ 보건 데이터 품질 지표 분석 및 보건분야 품질관리를 위한 지표데이터	○ 헬스케어 분야에 최적화된 데이터 품질지표를 분석하고 개별변수와 특성을 기반으로 한 지표를 개발하여 기술문서로 제시함	100
	○ 공정성 지표 분석 및 정의	○ 데이터 공정성의 개념과 공정성의 다양한 측면을 정량적인 지표를 통해서 평가할 수 있는 지표의 원리와 산출방법 등에 대한 종합적인 내용을 기술 문서로 제시함	100
	○ 고차원 데이터 패턴 시각화 방안	○ 공정성 등 지표를 통해서 주로 제시되는 지표의 직관적인 이해를 돕기 위해 공정성 일반은 물론 다양한 고차원 데이터의 특성을 시각화 할 수 있는 t-SNE 및 UMAP등의 시각화 방법에 대해서, 원리와 수식 이를 구현하기 위한 기본 코딩지침 등의 기술문서 제시	100
	○ AI 기반 비정형데이터 품질지표 평가 모델링	○ 주요 비정형자료인 의료영상 (유방촬영영상)의 자동화된 정규화 및 이상치 제거, 유방암 위험도 제시를 위한 deep learning 모형 (CNN기반) 등을 개발하여 국내 및 국제(PCT)특허 출원 각 1건 수행 ○ 인공지능 기반 (generative model)의 데이터생성 기법을 적용하여 개인정보에서 자유로운 생성자료 개발 및 이를 통한 평가	100

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	○ 공정성 지표의 자동산출방안	○ 총 30개 이상의 공정성관련 정량지표를 평가하고, 이 중 8개의 핵심 지표를 통해 지정된 민감변수 별로 공정성 지표 자동 산출방식 개발. 기술문서 2건 및 개발된 QUFA 소프트웨어에 포함	100
	○ 공정성 지표 기반의 민감변수간 공정성 자동보정방법 개발	○ 3단계 (pre-, in-, post-) 에 걸친 보정 방법을 각각 명시하고, 해당 보정 방법이 실제 QUFA에 포함되도록 알고리듬화. 기술문서 2건	100
	○ 고차원데이터 특성 시각화 방법의 API화	○ 1단계에서 개발된 t-SNE/UMAP등의 고차원특성 시각화 방법을 표준화하고, REST API기반으로 시각화의 방법을 고도화. 대표적인 비정형자료인 의료영상의 질적평가가 가능한 modified Tversky index 방법에 대한 특허출원 1건	100
서울시립대	○ 자동화된 데이터 품질 분석 및 개선	○ 문화관광 도메인 데이터셋 400여개 수집 및 DB 구축 ○ 문화관광 데이터의 품질 측정 및 분석 결과를 바탕으로 4개 데이터 품질 척도 정의 및 품질 개선 모듈 개발	100
	○ 데이터 품질 개선 자동화 기반 설계	○ 데이터 생애주기를 고려한 AI 학습데이터 클라우드 서비스 프레임워크 설계 ○ 테이블 임베딩 기반 데이터 준자동 융합 모듈 개발 ○ 딥러닝(어텐션 내재) 기반 정형 데이터 품질 개선 알고리즘 및 모듈 개발 ○ 시계열 데이터에 대한 이상치 제거 및 결측치 보완 알고리즘 및 모듈 개발	100
	○ 비정형 데이터 품질 개선 기술 개발	○ 딥러닝 기반 비정형 데이터 정제기술 개발: Noise 제거 기술 ○ 2차원 큐보이드 모델 기반 비정형 데이터 품질 강화 기술 개발	100
	○ AI 기반 품질 개선 기술 개발	○ AI (머신러닝) 기반 품질 개선 프로세스 개발 ○ 시계열 데이터 품질 개선 기술 개발 ○ 정형 학습데이터 증강 기술 개발	100
이화여대	○ 특징 공학 기반 오류 탐지 및 보정 기술 개발	○ 특징 공학 도구로서 qufafeat 오픈소스 S/W 개발 및 공개 ○ 비전문가도 간편하게 고품질의 기계학습용 훈련데이터를 생산할 수 있도록 특징 공학 파이프라인 완전자동화 구현	100
	○ 특징 공학 연산자 고도화	○ 특징 연산자 87개(계획: 80개) 개발	100
	○ 특징 공학 기반 오류 탐지 및 보정 기술 개발	○ 기계학습 대상 내용특성 5종 지원	100
	○ AI 기반 오류 탐지 내용특성 3종 및 관계특성 2종, 보정연산자 3종 지원	○ 기계학습 대상 관계특성 3종 지원 ○ 보정연산자 3종 지원	100
한성대	○ 데이터 프로파일링을 위한 메타데이터 분류 및 관리체계 설계	○ 재난안전 데이터 품질지표분석 ○ 데이터 프로파일링 분류 및 관리체계 설계	100
	○ 메타데이터 수집 기술 개발	○ 원천 데이터 관리 기술 개발 ○ 메타정보 항목 자동 결정 기술 개발 ○ 원천 데이터로부터 프로파일 추출 및 자동생성 기술 개발	100
	○ 메타데이터 변환 및 편집, 저장 기술 개발	○ 이기종 데이터로부터 생성된 프로파일 저장 및 관리모듈 기술 개발 ○ 오픈 포맷을 지원하는 메타데이터 서비스 기술 개발 ○ 마이크로 아키텍처를 지원하기 위한 스프링부트 환경의 restful API 서비스 기술 개발	100
	○ 메타데이터 검색 및 활용 기술	○ 메타데이터 검색 지원을 위한 주문형 프로파일링 서비스	100

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	개발	개발 ○ 다중 컬럼, 다중 테이블에 대한 프로파일링 기능 제공 ○ 타입 자동인식의 성능을 개선하기 위한 적응형 샘플링 방법 개발	
프람텍	○ 피드백 지원 품질 평가도구 개발	○ 피드백 지원 품질 평가 모델 설계 ○ 피드백 지원 품질 평가 도구 개발	100
	○ 데이터 품질 분석 도구 제품화	○ 데이터 품질 대시보드 구현 ○ 데이터 프로파일링 자동 수행 구현	100
	○ 데이터 오류 보정 도구 설계 및 개발	○ 오류 보정 도구 기능 분석	100
	○ 데이터 품질 개선 솔루션 통합	○ 데이터 품질 개선 솔루션 통합	100
	○ 데이터 품질 개선 솔루션 통합 및 고도화	○ 데이터 품질 개선 솔루션 신규 기능 추가 통합 ○ 데이터 품질 개선 솔루션 고도화	100
	○ 데이터맵 기술 개발	○ 융합 데이터셋 검색 및 시각화 기능 개발	100
아이소프트	○ 빅데이터 품질 수준 현황 조사	○ 5종의 데이터 도메인별 품질척도 및 품질 수준 현황 조사 ○ 5종의 데이터 도메인별 품질 진단 위한 모델링 등의 방법 분석	100
	○ 공정성 분석기 및 패턴 시각화 도구 설계	○ 1차년 교통 데이터셋 분석 및 분석결과 가시화 웹페이지 개발 ○ 데이터셋의 로드 및 로드된 데이터의 컬럼 및 컬럼값 기반의 분석 결과 웹서비스 가시화 설계	100
	○ 공정성 분석기 도구 개발	○ 웹기반(장고) 인공지능 학습 데이터 처리 구현 ○ 검증 모델 선택 및 파일 로딩기능 ○ 데이터 구조분석 가시화 기능모듈 개발 ○ 데이터 검증모듈 탑재 ○ 데이터 공정성 보정 알고리즘 연동	100
	○ 데이터 패턴 시각화 도구 개발	○ 자바스크립트를 이용한 교통 및 의료 데이터 구조 가시화(sunburst) 기능 모듈 설계 및 구현 ○ t-SNE 및 UMAP 차트 구현 ○ 공정성 데이터의 직관적 가시화를 위한 차트 개발	100
	○ 공정성 도구 통합	○ Traffic 데이터 & Health 데이터 분석 가시화 통합 디자인 ○ 기계학습 구분 기반의 공정성 검증 웹 FLOWCHART ○ 공정성 가시화 API 개발	100
	○ 공정성 도구 고도화 및 통합	○ 정적데이터 공정성 보정 기술 가시화 통합 개발 ○ 동적데이터 공정성 보정 기술 가시화 통합 개발 ○ QUFA Studio 통합을 위해 API 개발	100
	○ 빅데이터 플랫폼 연계 검증	○ 보라매 데이터 센터 API 연계하여 보건 데이터 수집 및 보정 요청 구현 ○ API 서버 구축하여 항만물류 데이터 센터 연계 구현	100

4. 목표 미달 또는 미흡한 사항에 대한 원인분석(해당사항 없음)

5. 연구개발성과의 관련 분야에 대한 기여 정도

■ 연구개발의 최종성과 기반

▪ 기술적 측면

✓ 빅데이터의 성공적 적용 사례로 활용

• 4차 산업혁명의 핵심인 빅데이터 산업을 육성하기 위한 정부차원의 여러가지

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

지원 사업에도 불구하고 해당 분야 실질적인 혁신 성공사례는 찾아보기 힘든 실정. 본 사업 결과물의 상용확가 성공적으로 수행된다면 빅데이터 핵심 기초기술 개발 및 사업화에 성공한 사례가 될 수 있으며, 기타 분야로의 기술 확산에 긍정적 영향을 줄 수 있음

✓ 딥러닝을 포함한 머신러닝 기반 국산 시스템의 상용화 촉진

- 본 과제에서 개발한 프로파일링과 특징공학 기술은 다양한 소스의 데이터의 품질을 보장/융합한 모델에 기반 하기 때문에 범용성, 확장성이 크며 인공지능 학습 데이터 전처리 전용 솔루션으로 별도 상용화가 가능함 ⇒ 다양한 산업계와의 연계를 통해 빅데이터 처리 기능을 가진 머신러닝 기반 시스템의 상용화 가능성이 매우 큼

✓ 국내외 데이터 제공 플랫폼과의 연계를 위한 확장성

- 탑재된 데이터셋에 대한 표준(예, DCAT, schema.org, CSV on the Web 등) 기반의 메타데이터를 연계하여 사용자가 요청한 특정 데이터셋의 품질 측정 및 개선을 위한 개발 모듈에 연결하여 서비스 형태로 제공 ⇒ 본 사업의 참여기업인 ㈜프람트테크놀로지가 현재 운영과 개편 사업을 진행 중인 공공데이터포털(data.go.kr)의 경우 메타데이터 제공을 위한 별도 API가 존재하기 때문에 이를 활용하여 메타데이터를 연계하는 방식으로 시스템을 운영, 기타 한국데이터진흥원의 데이터스토어나 AI 학습데이터 포털인 Alhub.or.kr에도 전용 Crawler를 제작하여 메타데이터를 수집 연계하여 시스템을 운영하는 방안으로 적용할 수 있음

▪ 경제적, 산업적 측면

✓ 신시장 창출 및 수입대체 효과

- 단순 단발성 빅데이터 품질평가 및 분석 대행 프로젝트나 시스템 구축 위주로 형성되어 있는 빅데이터 시장에, 빅데이터 분석 클라우드 서비스라는 신규 비즈니스 모델을 기반으로 대상 데이터 사이즈에 따른 과금 전략을 도입 신규 시장을 형성하여 진입

▪ 사회적 측면

✓ 시민급 빅데이터 분석가 양성 효과

- 본 개발 기술은 유통, 금융, 제조업, 마케팅 등의 다양한 산업 및 공공 분야에 활용될 수 있으므로, 빅데이터 품질평가 및 분석 전문가로서 이를 전문적으로 운용할 수 있는 인력이 점차적으로 증가할 것으로 예상

✓ 데이터 과학자 인력의 양성 효과

- 본 사업 수행 결과물은 데이터 과학자가 수행하는 전사적 과정을 지원하기 때문에 자연스럽게 이를 운용하는 데이터 과학자 인력을 창출하는 효과를 가짐

■ 데이터 공정성 측면

▪ 공정성 지표의 검증과 시각화

✓ 공정성은 추상적인 개념으로 주로 제시되거나, 두 변수간의 차이를 기계적으로 없애는 공학적 알고리듬의 양 극단으로 주로 다루어져 왔으나, 본 연구팀은 적절한 공정성이 문제가 되는 실례 (심혈관질환 위험도 평가의 남-녀 간 성능차이)를 기반으로, 불공정성을 확인하고, 이를 보정하기 위한 방법을 적용하는 과정에서 다양한 공정성 지표의 변화를 제시하고, 결과적으로 원래 목표로 한 알고리듬 (심혈관질환 위험도 평가 알고리듬)에서 실제로 남-녀 간의 차별성이 줄어듦을 실증적으로 확인하였음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- ✓ 데이터의 공정성 보정의 정량적 방법론 개발은 물론, 공정성 지표의 개선을 단계별로 확인 할수 있는 방법 제시함
- ✓ 현실생활에서 중요한 실례를 통해서 시각화와 지표의 통합적 인해 가능
- ✓ 표준화된 지표와 산출방법 및 보정방법을 제시함으로써 자동화 솔루션으로 개발

▪ 헬스케어 분야 비정형 자료의 품질관리 기술

- ✓ 헬스케어분야는 비정형 자료의 비중이 매우 높은 분야이며, 의료영상 등의 이미지데이터는 인공지능형 분석방법 적용이 장점을 가지고 있는 분야임. 반면, 복수의 제조사들이 서로 특허를 피하는 과정에서 상이한 품질과 특성의 영상자료를 생성하여, 분석 이전에 품질관리가 매우 중요한 분야임
- ✓ 본 연구에서는 유방영상에 특화된 segmentation 및 normalization, pixel단위의 품질평가 기술등을 제시하였음

▪ 헬스케어 분야에서 인공지능기반 생성데이터의 개발과 활용

- ✓ 헬스케어 분야는 특히 개인정보가 문제되는 분야이며, 다양한 방법 (익명화, 암호화, 데이터변형 등)을 통한 개인정보 보호가 중요 issue임. 본 연구에서는 데이터의 특성 특히 training능력을 그대로 보존하면서도 가상의 생성데이터를 작성하여 (generative model) 적용함. 10만명의 생활습관, 운동 및 건강행태, 기본건강진단결과 및 10대질환 위험도 등의 생성자료 제시
- ✓ 본 연구에서는 generative model을 통해 생성된 자료를 통해 공정성과 품질지표 실증적인 평가 수행

■ 공정성 가시화 측면

▪ 데이터 가시화 기술 개발은 데이터 품질 및 공정성 개선을 시각화를 통해 변화 추이와 개선 정도를 직관적으로 판단할 수 있게 하는 주요 필수 분야

▪ 본 과제에서 다양한 가시화 기법을 개발하고, 다양한 분야의 데이터를 가시화하는 최적의 방안에 접근하는 연구임

■ 데이터 품질측면

▪ 데이터 확보/가공/분석/활용 全 단계를 딥러닝 기반 데이터 품질 제어 메커니즘 내에서 통합적으로 접근, Attention 및 GAN을 포함한 최신 딥러닝 기술을 활용하여 다양한 도메인 데이터에 대하여 안정적이며 신뢰도가 높은 품질개선 모델 및 환경을 구축

▪ AI 학습데이터를 생성하기 이전인 데이터 준비영역에서는 데이터셋 (거시적) 단위로 품질 여부를 판단하고, 고품질 데이터는 기계학습 영역에서 레코드 (미시적) 단위로 품질 제어

▪ 고성능 AI 학습모델을 구성하기 위해 학습데이터 품질평가/개선은 필수적 작업이며, 본 과제에서 “딥러닝 기반 데이터 품질개선 메커니즘”을 빅데이터 분석서비스와 결합할 수 있는 클라우드 환경을 구축하였음

- ✓ Attention 및 GAN 기반 Multi-task Learning 기반 데이터 품질개선 기술 개발: 기존의 컬럼별로 개별적인 학습모델을 다수개 구축하는 비효율성을 극복하기 위해, 하나의 테이블에 대해 동시다발적으로 결측값 자동 보완을 수행하는 어텐션 기반 딥러닝 아키텍처를 개발함으로써 데이터 품질개선의 효율성 및 생산성을 동시에 높였음
- ✓ GAN 및 LSTM 기반 시계열 데이터 품질개선 기술 개발: IoT 환경에서 생성된 시계열 데이터에 대한 품질 개선을 위해서, GAN 및 LSTM 기반 허용범위 밴드를 구성하여 결측치 보완 및 이상치 탐지를 동시에 수행하는 기법을 개발함으로써, IoT 시계열 데이터 기반 예측모델의 성능 향상에 크게 기여함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 특징공학 측면
- 특징공학 자동화도구인 qufafeat은 비전문가도 학습데이터의 품질을 간편하게 개선하여 기존 인공지능 모델을 활용하여 사회 문화 현상에 대한 다양한 예측 엔진을 구현할 수 있음

■ 데이터 프로파일링 측면
- 오픈 API 형태의 데이터 프로파일링 서비스를 최초로 시도
  - ✓ 기존의 대부분의 데이터 프로파일링 정보를 제공하는 소프트웨어는 품질평가/개선 소프트웨어나 데이터 시각화 소프트웨어 등에 일부 기능으로 제공되는 경우가 대부분임
  - ✓ 본 연구에서는 특정환경에 종속되지 않은 독립적인 프로파일링 서비스가 가능하도록 설계하여 타 시스템과의 연계와 통합이 용이하도록 지원
  - ✓ restful API형태의 데이터 프로파일링 서비스는 최초의 시도이며, 향후 관련/유사 소프트웨어의 개발시 참조모델이 될 수 있음

6. 연구개발성과의 관리 및 활용 계획

■ 연구개발 핵심알고리즘 성과적 측면
- 자동화된 품질관리 솔루션에 공정성의 개념과 지표 적용
- 자동화된 공정성 개선방법의 적용과정에서 공정성 지표의 개선을 지표 및 시각화 도구를 통해서 직관적으로 확인 가능한 솔루션 개발
- 공정성 지표의 개선이 전체 품질개선에 미치는 영향 평가 수행
- 인공지능기반의 품질개선 방법을 의료영상 분야를 포함한 다양한 비정형 분야, 특히 유전체 분야로 확대
- 연구개발의 성과가 필요한 수요자가 적극적으로 활용할 수 있도록, 맞춤화된 평가방법을 제공하는 방안을 마련
- 특징 공학 자동화 도구인 qufafeat의 업스트림 프로젝트인 featuretools 프로젝트와의 연계 강화를 위하여 확장 기능들에 대하여 Pull 요청을 통한 저장소 동기화
- 사용자 확보를 위하여 github Wiki 페이지내의 튜토리얼 페이지 보강
- Kaggle 내의 Competition 데이터를 중심으로 검증 데모 예제 강화

■ 연구개발 성과의 사업화적 측면
- 국내 계획
  - ✓ 사업 진입시 초기에는 POC사업과 공공시장 및 지자체를 중심으로 영업 및 마케팅을 병행하여 실시
  - ✓ 공공데이터 포털 등에 데이터를 제공하는 제공기관 리스트(참여기관인 ㈜프람트테크놀로지에서 리스트를 기확보)를 잠재고객 리스트로 활용하여 방문 영업
  - ✓ 공공기관 빅데이터 품질검증 대행업체 들을 대상으로 Indirect 영업 및 마케팅을 병행 실시
  - ✓ 점진적으로 금융권 카드사, 이동 통신사, 유통 분야 등으로 확대 영업, 초기에는 소량의 빅데이터 품질검증을 POC 형태의 단발 프로젝트 형식으로 진행하는 방식으로 유도
  - ✓ 개발 종료 후 2년 시점에는 엔터프라이즈 설치용 버전을 별도로 개발 상용화하여 시장에 출시하여 신규 매출 채널로 활용하는 open source와 상용버젼의 dual license 전략 추구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

▪ 국외 계획

✓ LA County, LA City의 Clean Street Index (빅데이터 수집 분석을 통해 도로 별 청결지수를 설정하고 이를 관리 및 개선시키기 위한 R&D 프로젝트, 출처: https://www.meetup.com/ko-KR/RMDS_LA/events/230190106/?eventId=230190106) 프로젝트에 ㈜프람트테크놀로지와 USC (University of Southern California) 빅데이터 연구센터인 Integrated Media Systems Center (MediaQ: 빅데이터 수집·저장·처리 기술 활용)가 협업하여 참여하기 위해 협의 중에 있음

(단위 : 억원)

구 분			사업화년도 (2023)년 (개발종료 후 1년)	(2024)년 (개발종료 후 2년)	(2025)년 (개발종료 후 3년)
사업화품목			(빅)데이터 품질개선 클라우드 서비스	좌동 + 엔터프라이즈버젼	좌동
투자계획	인건비		4	6	10
	재료비 및 설비투자비		4.1	12.3	31
	경상운영비		0.5	0.6	0.75
	계		8.6	18.9	41
판매계획 (단위:억원)		**국내 판매액**	**11.5**	**28.3**	**86.2**
		국내점유(%)	0.72%	1.47%	3.58%
		해외 판매액	**3.5**	**7.8**	**21.5**
		국외점유(%)	-	-	-
		판매액 합계	**15.0**	**36.1**	**107.7**

▪ 목표 시스템 구축 계획 및 역할

✓ 사업화를 위한 최종 목표 시스템 이행 구축 및 수요기업에 기술이전

✓ 과제 결과물을 바탕으로 2023년 목표 시스템 구축을 위한 통합 및 오픈소스化

✓ 참여기관(수요기업)인 ㈜프람트테크놀로지가 최종목표 시스템 통합/구축 및 사업화 추진에 주도적 역할을 수행함

< 연구개발성과 활용계획표 >

구분(정량 및 정성적 성과 항목)		연구개발 종료 후 5년 이내
국외논문	SCIE	1
	비SCIE	1
	계	2
국내논문	SCIE	1
	비SCIE	5
	계	6
특허출원	국내	2
	국외	0
	계	2
특허등록	국내	3
	국외	0
	계	3
인력양성	학사	8
	석사	4
	박사	1
	계	13
사업화	상품출시	2023년 데이터 품질 통합 솔루션 오픈소스화 1건 2024년 데이터 품질 통합 솔루션 엔터프라이즈

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		버젼 상용화 1건
	기술이전	
	공정개발	
제품개발	시제품개발	
국제 표준화	기고서 제출	
	기고서 채택	
	표준안 채택	
국내 표준화	기고서 제출	
	기고서 채택	
	표준안 채택	
성과홍보		2
포상 및 수상실적		
정성적 성과 주요 내용		

1) 향후 5년간 성과활용·확산 활용방안 및 계획(활동계획)

o 프로그램 상용화

- 쿠파 스튜디오와 다양한 빅데이터 플랫폼/센터간 데이터 연계를 위한 기술 보강에 따른 프로그램 상용화 api 작업진행
- 상용화를 위해 실제 사용자 편의성을 고려한 기능과 UI/UX 작업진행

o 핵심 기술 패키징

- 주요 핵심기술인 프로파일링, 특징공학, 품질 및 공정성 보정 기술 등을 패키징하여, 관련 산업분야에 응용하여 사용할 수 있는 라이센스형 엔진S/W 패키징
- 빅데이터 분석, 인공지능 학습 분야에서 사용할 수 있도록 패키징

o 핵심 기술을 활용한 커스트마이징

- 본 개발 성과물은 데이터 전처리 공정 어디에든 확대 적용할 수 있는 원천기술로써 각 산업분야에서 필요한 모든 데이터 전처리 컴포넌트 및 모듈 등에 적용 조합하여 새로운 제품유형으로 확대 가능

<연도별 주요 활동계획(요약표)>

구분	종료+1 (2023년)	종료+2 (2024년)	종료+3 (2025년)	종료+4 (2026년)	종료+5 (2027년)
기술 상용화 추진계획	상용화	상용화 및 고도화	패키징(핵심)	패키징(핵심, 커스텀)	패키징(커스텀)
기술 사업화활동	비즈모델 개발	솔루션 판매	정부지원사업 등 통한 확대	국내외 전시참여,홍보	영업, 비즈니스지원 전담 운영
후속연구	트러블슈팅에 따른 안정화	글로벌 언어팩지원	크라우드化	라이브러리化	글로벌 플랫폼 연계 멀티어댑터

2) 주요 성과활용 (기대)성과목표

(1) 정성적 목표

o 국내 플랫폼 2개소를 대상으로 테스트베드 구축

- 빅데이터 플랫폼과의 협업에 따른 테스트베드 구축

o 기술고도화 진행

- 본 개발기술의 고도화를 통해 글로벌 경쟁력 확보

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 정량적 목표

<연도별 성과활용 (기대)성과목표(요약표)>

구분	종료+1 (2023년)	종료+2 (2024년)	종료+3 (2025년)	종료+4 (2026년)	종료+5 (2027년)
매출액	1억	2억	4억	6억	8억
고용	3명	5명	5명	5명	5명
특허	2건	2건	2건	2건	2건
신규제품등록	1건	1건	1건	1건	1건

3) 성과활용·관리 추진체계

구분		역할
품질팀	서울시립대	▪ 테스트 결과에 대한 분석 ▪ 트러블슈팅 실시 ▪ 원천기술 안정화를 위한 구현 ▪ 고도화를 위한 지속적 테스트 수행
	이화여대	
	한성대	
공정성팀	부산대	
	서울대	
사업화팀	㈜프람트테크놀로지	▪ 테스트 수행에 따른 리포팅 ▪ 서비스 사업화
	㈜아이소프트	

4) 기타 (해당사항 없음)

7. 연구개발성과에 대한 후속연구 및 추가 개발 계획

- 연구개발 컨소시움의 수요기업인 ㈜프람트테크놀로지와 ㈜아이소프트를 통해 산출물의 안정화 및 고도화 실시
- 연구개발 컨소시움의 대학들을 통해 원천기술의 테스트 등에 따른 트러블슈팅 수행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8. 연구개발비 사용실적

8-1. 부산대학교 산학협력단

1) 연구개발비 사용명세서

(단위 : 원, %)

구분 / 항목		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	266,667,000	0	98,790	266,765,790	263,252,363	3,513,427	98.68	3,513,427
	현물	0	11,067,000	0	0	11,067,000	11,067,000	0	100	0
	소계	0	277,734,000	0	98,790	277,832,790	274,319,363	3,513,427	98.73	3,513,427
1) 인건비	현금	0	153,833,000	4,398,300	0	158,231,300	158,170,736	60,564	99.96	60,564
	현물	0	11,067,000	0	0	11,067,000	11,067,000	0	100	0
2) 학생인건비	현금	0	27,960,000	-2,811,000	0	25,149,000	25,149,000	0	100	0
3) 연구시설・장비비	현금	0	2,100,000	2,941,930	0	5,041,930	5,041,930	0	100	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1」]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	51,502,000	-4,529,230	98,790	47,071,560	43,618,697	3,452,863	92.66	3,452,863
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	31,272,000	0	0	31,272,000	31,272,000	0	100	0
나. 간접비	현금	0	53,333,000	0	0	53,333,000	53,333,000	0	100	0
	소계	0	53,333,000	0	0	53,333,000	53,333,000	0	100	0
합계	현금	0	320,000,000	0	98,790	320,098,790	316,585,363	3,513,427	98.90	3,513,427
	현물	0	11,067,000	0	0	11,067,000	11,067,000	0	100	0
	합계	0	331,067,000	0	98,790	331,165,790	327,652,363	3,513,427	98.93	3,513,427

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	98,790	과제산입	98,790	0
연구개발기간 후 발생이자	0	-	0	0
합계	98,790	0	98,790	0

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	3,513,427	0	3,513,427	연구개발기간 중	0	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	3,513,427	0	3,513,427	소계(D)	0	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	3,513,427	0	3,513,427	정부지분액(E=D×B)	0	3,513,427

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-2. 서울대학교 산학협력단

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	156,250,000	0	5,730	156,255,730	156,253,211	2,519	99.99	2,519
	현물	0	11,040,000	0	0	11,040,000	11,040,000	0	100	0
	소계	0	167,290,000	0	5,730	167,295,730	167,293,211	2,519	99.99	2,519
1) 인건비	현금	0	63,496,000	0	0	63,496,000	63,496,000	0	100	0
	현물	0	11,040,000	0	0	11,040,000	11,040,000	0	100	0
2) 학생인건비	현금	0	75,000,000	0	0	75,000,000	75,000,000	0	100	0
3) 연구시설・장비비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1」]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	5,754,000	0	5,730	5,759,730	5,757,211	2,519	99.95	2,519
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	12,000,000	0	0	12,000,000	12,000,000	0	100	0
나. 간접비	현금	0	43,750,000	0	0	43,750,000	43,750,000	0	100	0
	소계	0	43,750,000	0	0	43,750,000	43,750,000	0	100	0
합계	현금	0	200,000,000	0	5,730	200,005,730	200,003,211	2,519	99.99	2,519
	현물	0	11,040,000	0	0	11,040,000	11,040,000	0	100	0
	합계	0	211,040,000	0	5,730	211,045,730	211,043,211	2,519	99.99	2,519

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	5,730	과제산입	5,730	0
연구개발기간 후 발생이자	0	-	0	0
합계	5,730	-	5,730	0

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	2,519	0	2,519	연구개발기간 중	0	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	2,519	0	2,519	소계(D)	0	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	2,519	0	2,519	정부지분액(E=D×B)	0	2,519

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-3. 서울시립대학교 산학협력단

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	156,018,411	0	48,268	156,066,679	156,040,466	26,213	99.98	26,213
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100	0
	소계	0	204,018,411	0	48,268	204,066,679	204,040,466	26,213	99.98	26,213
1) 인건비	현금	0	0	0	0	0	0	0	0	0
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100	0
2) 학생인건비	현금	0	97,200,000	0	0	97,200,000	97,200,000	0	100	0
3) 연구시설・장비비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	3,000,000	0	0	3,000,000	2,995,310	4,690	99.84	4,690
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	26,778,411	0	48,268	26,826,679	26,805,156	21,523	99.91	21,523
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	29,040,000	0	0	29,040,000	29,040,000	0	100	0
나. 간접비	현금	0	43,981,589	0	0	43,981,589	43,981,589	0	100	0
	소계	0	43,981,589	0	0	43,981,589	43,981,589	0	100	0
합계	현금	0	200,000,000	0	48,268	200,048,268	200,022,055	26,213	99.98	26,213
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100	0
	합계	0	248,000,000	0	48,268	248,048,268	248,022,055	26,213	99.98	26,213

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	48,268	과제산입	26,745	21,523
연구개발기간 후 발생이자	0	-	0	0
합계	48,268	-	26,745	21,523

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	4,690	0	4,690	연구개발기간 중	21,523	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	4,690	0	4,690	소계(D)	21,523	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	4,690	0	4,690	정부지분액(E=D×B)	21,523	26,213

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-4. 이화여자대학교 산학협력단

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	123,648,000	0	29,435	123,677,435	123,675,822	1,613	99.99	1,613
	현물	0	9,120,000	0	0	9,120,000	9,120,000	0	100	0
	소계	0	132,768,000	0	29,435	132,797,435	132,795,822	1,613	99.99	1,613
1) 인건비	현금	0	0	0	0	0	0	0	0	0
	현물	0	9,120,000	0	0	9,120,000	9,120,000	0	100	0
2) 학생인건비	현금	0	56,600,000	0	0	56,600,000	56,600,000	0	100	0
3) 연구시설・장비비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	3,122,000	0	0	3,122,000	3,120,690	1,310	99.95	1,310
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	50,782,000	0	29,435	50,811,435	50,811,132	303	99.99	303
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	13,144,000	0	0	13,144,000	13,144,000	0	100	0
나. 간접비	현금	0	36,352,000	0	0	36,352,000	36,352,000	0	100	0
	소계	0	36,352,000	0	0	36,352,000	36,352,000	0	100	0
합계	현금	0	160,000,000	0	29,435	160,029,435	160,027,822	1,613	99.99	1,613
	현물	0	9,120,000	0	0	9,120,000	9,120,000	0	100	0
	합계	0	169,120,000	0	29,435	169,149,435	169,147,822	1,613	99.99	1,613

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	29,435	과제산입	29,435	0
연구개발기간 후 발생이자	0	-	0	0
합계	29,435	-	29,435	0

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	1,613	0	1,613	연구개발기간 중	0	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	1,613	0	1,613	소계(D)	0	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	1,613	0	1,613	정부지분액(E=D×B)	0	1,613

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-5. 한성대학교 산학협력단

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	77,520,000	0	29,369	77,549,369	77,515,657	33,712	99.95	33,712
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100.00	0
	소계	0	125,520,000	0	29,369	125,549,369	125,515,657	33,712	99.97	33,712
1) 인건비	현금	0	0	0	0	0	0	0	0	0
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100.00	0
2) 학생인건비	현금	0	28,800,000	0	0	28,800,000	28,800,000	0	100.00	0
3) 연구시설・장비비	현금	0	7,000,000	0	0	7,000,000	6,996,000	4,000	99.94	4,000
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	26,420,000	1,200,000	29,369	27,649,369	27,619,657	29,712	99.89	29,712
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	15,300,000	-1,200,000	0	14,100,000	14,100,000	0	100.00	0
나. 간접비	현금	0	22,480,000	0	0	22,480,000	22,480,000	0	100.00	0
	소계	0	22,480,000	0	0	22,480,000	22,480,000	0	100.00	0
합계	현금	0	100,000,000	0	29,369	100,029,369	99,995,657	33,712	99.96	33,712
	현물	0	48,000,000	0	0	48,000,000	48,000,000	0	100.00	0
	합계	0	148,000,000	0	29,369	148,029,369	147,995,657	33,712	99.97	33,712

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	29,369	과제산입	0	29,369
연구개발기간 후 발생이자	0	-	0	0
합계	29,369	-	0	29,369

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	4,343	0	4,343	연구개발기간 중	29,369	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	4,343	0	4,343	소계(D)	29,369	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	4,343	0	4,343	정부지분액(E=D×B)	29,369	33,712

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-6. ㈜프람트테크놀로지

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	378,000,000	0	315,708	378,315,708	378,177,205	138,503	99.96	138,503
	현물	0	24,000,000	0	0	24,000,000	24,000,000	0	100	0
	소계	0	402,000,000	0	315,708	402,315,708	402,177,205	138,503	99.96	138,503
1) 인건비	현금	0	344,194,000	0	0	344,194,000	344,194,000	0	100	0
	현물	0	24,000,000	0	0	24,000,000	24,000,000	0	100	0
2) 학생인건비	현금	0	0	0	0	0	0	0	0	0
3) 연구시설・장비비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	33,806,000	0	315,708	34,121,708	33,983,205	138,503	99.59	138,503
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	0	0	0	0	0	0	0	0
나. 간접비	현금	0	2,000,000	0	0	2,000,000	2,000,000	0	100	0
	소계	0	2,000,000	0	0	2,000,000	2,000,000	0	100	0
합계	현금	0	380,000,000	0	315,708	380,315,708	380,177,205	138,503	99.96	138,503
	현물	0	24,000,000	0	0	24,000,000	24,000,000	0	100	0
	합계	0	404,000,000	0	315,708	404,315,708	404,177,205	138,503	99.96	138,503

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	315,708	과제산입	177,205	138,503
연구개발기간 후 발생이자	0	-	0	0
합계	315,708	-	177,205	138,503

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	0	0	0	연구개발기간 중	138,503	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	0	0	0	소계(D)	138,503	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	0	0	0	정부지분액(E=D×B)	138,503	138,503

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8-7. ㈜아이소프트

1) 연구개발비 사용명세서

(단위 : 원, %)

항목 \ 구분		연구개발비 현황					사용 금액 ⑥	사용 잔액 (⑤-⑥)	사용률 (⑥/⑤ ×100)	불용금액 (해당 시)
		전단계 이월액 (해당 시) ①	당초 연구개발비 ②	변경 연구개발비 ③	발생이자 중 연구개발비 산입금 ④	소계 ⑤ (①+②+③+④)				
가. 직접비	현금	0	237,000,000	0	0	237,000,000	233,238,623	3,761,377	98.41	3,761,377
	현물	0	9,300,000	0	0	9,300,000	9,300,000	0	100	0
	소계	0	246,300,000	0	0	246,300,000	242,538,623	3,761,377	98.47	3,761,377
1) 인건비	현금	0	232,000,000	0	0	232,000,000	228,479,859	3,520,141	98.48	3,520,141
	현물	0	9,300,000	0	0	9,300,000	9,300,000	0	100	0
2) 학생인건비	현금	0	0	0	0	0	0	0	0	0
3) 연구시설・장비비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
4) 연구재료비	현금	0	0	0	0	0	0	0	0	0
	현물	0	0	0	0	0	0	0	0	0
5) 위탁연구개발비[1]	현금	0	0	0	0	0	0	0	0	0
6) 국제공동연구개발비	현금	0	0	0	0	0	0	0	0	0
7) 연구개발부담비	현금	0	0	0	0	0	0	0	0	0
8) 연구활동비	현금	0	5,000,000	0	0	5,000,000	4,758,764	241,236	95.17	241,236
	현물	0	0	0	0	0	0	0	0	0
9) 연구수당	현금	0	0	0	0	0	0	0	0	0
나. 간접비	현금	0	3,000,000	0	0	3,000,000	3,000,000	0	100	0
	소계	0	3,000,000	0	0	3,000,000	3,000,000	0	100	0
합계	현금	0	240,000,000	0	0	240,000,000	236,238,623	3,761,377	98.43	3,761,377
	현물	0	9,300,000	0	0	9,300,000	9,300,000	0	100	0
	합계	0	249,300,000	0	0	249,300,000	245,538,623	3,761,377	98.49	3,761,377

* 1」 위탁연구개발비 현황 및 사용금액은 주관연구개발기관만 기재합니다.

2) 발생이자 사용명세서

(단위 : 원)

구분	발생금액 (A)	사용용도	사용금액 (B)	사용잔액 (A-B)
연구개발기간 중 발생이자	231,273	국고반납	0	231,273
연구개발기간 후 발생이자	0	-	0	0
합계	231,273	-	0	231,273

3) 반납액 명세서

(단위 : 원, %)

연구개발비 반납액				발생이자 반납액		총 반납액 (C+E)
구분	현금	현물	소계			
사용잔액	3,761,377	0	3,761,377	연구개발기간 중	231,273	-
불인정 사용금액	0	0	0	연구개발기간 후	0	-
소계(A)	3,761,377	0	3,761,377	소계(D)	231,273	-
정부지분율(B)	100	0	100	정부지분율(B)	100	-
정부지분액(C=A×B)	3,761,377	0	3,761,377	정부지분액(E=D×B)	231,273	3,992,650

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 1. 사업화대상기술별 기술명세서(해당과제 작성)

1. 과제정보

과 제 명	국문	데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발				
	영문	Development of data improvement and dataset correction technology based on data quality assessment				
기술분류	대분류	빅데이터	중분류	ICT	소분류	지식추출
주관기관	부산대학교 산학협력단		연구책임자	권준호		
연락처(책임자)	사무실 : 051-510-3149		이메일(책임자)	jhkwon@pusan.ac.kr		

2 사업화대상기술 목록

순번	개발기술(Product)명 (관련 기술의 Know-how 및 특허 등)		보유특허(기술별로 중복기재 가능)		
			특허		발명의 명칭
			출원번호	등록번호	
1	국문	인공지능 학습 데이터 세트의 공정성 보장과 시각화를 위한 서비스	1020200185398	1023217350000	다차원의 부분집합 연관 분석에 기반한 인공지능 학습 데이터셋 공정성을 보장하는 장치 및 이를 이용한 인공지능 학습 데이터셋 공정성을 보장하는 방법
	영문	Services for ensuring fairness and visualization of artificial intelligence learning datasets			APPARATUS FOR ENSURING FAIRNESS OF AI LEARNING DATASETS BASED ON MULTIDIMENSIONAL SUBSET ASSOCIATION ANALYSIS AND METHOD FOR ENSURING FAIRNESS OF AI LEARNING DATASETS THEREOF
2	국문	유방영상 자동처리에 의한 인공지능기반 유방암 발병위험도 진단	10-2021-0106592		유방암 위험도 평가 시스템 및 방법
	영문	Predicting Breast Cancer Risk from Automated Mammography Analysis using Deep Learning	PCT/KR2021/013806		유방암 위험도 평가 시스템 및 방법
3	국문	딥러닝 기반 정형데이터 결측치 보간 기술	10-2021-0150649	10-2021-0150649	수치형 변수 및 범주형 변수를 포함하는 혼합형 결측데이터에 대한 데이터보간
	영문	Deep Learning-based Interpolation Technique for Missing Values in Structured Data			Apparatus and method for performing for mixed-type missing data including numeric variable and categorical variable
4	국문	기계학습 데이터 품질향상 특징공학 자동화 파이프라인	10-2022-0146508		기계 학습 모델의 학습 데이터 품질 향상을 위한 특징 공학 파이프라인 방법 및 장치
	영문	Automated Feature Engineering			

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		Pipeline Improving The Quality of Machine Learning Data			
5	국문	데이터 프로파일링 서비스 소프트웨어	10-2022-0138955		데이터 프로파일링 서비스를 제공하는 서버 및 방법
	영문	Data Profiling Service S/W			
6	국문	아이소프트 데이터 수집기	10-2022-0135781		인공지능 학습 데이터셋의 공정성 시각화 장치 및 방법
	영문	I-SOFT Data Collector			Apparatus and Method for Fairness Visualization of AI Learning Dataset

* 보유특허 란은, 기술예고의 경우 작성하지 않고 사업화대상기술은 반드시 작성
* 사업화대상기술의 경우, 기술이전·사업화가 가능한 핵심 요소기술로 관련 특허번호가 있는 경우에만 출원·등록된 기술을 작성
* 하나의 기술에 다수의 특허 또는 여러 기술에 하나의 특허 중복 작성 가능

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3. 사업화 대상기술

개발기술 1	국문	인공지능 학습 데이터 세트의 공정성 보장과 시각화를 위한 서비스
	영문	Services for ensuring fairness and visualization of artificial intelligence learning datasets

공개	☑	비공개	☐ (사유)

① (예상) 결과물

개발목표 시기	2026.3		기술성숙도 (TRL)	개발 전	개발 후
				5	7
결과물 형태	SW-Platform, Patent, Service		검증방법	자체검증, 시험성적서, GS인증	
색인어 (Keywords)	국문	인공지능, 데이터, 편향, 공정성, 데이터 품질			
	영문	Artificial intelligence, data, bias, fairness, data quality			
외부 기술요소	100% 개발기술 / Open Source 사용		권리성	특허, SW저작권	

② 기술의 개념(Concept) 및 구성

영문

Title	Services for ensuring fairness and visualization of artificial intelligence learning datasets		
Concept	Techniques to analyze the structure of the data and eliminate bias present in the data to ensure fairness		
Service Offering			
Comparative Advantage	The proposed technique is an undersampling technique that removes bias existing in the data, and unlike other processability correction techniques, it does not change the structure of the data and is not generated or derived data, so it can be applied to all algorithms without a separate process.		
Patents (Domestics)	Application(v) Registration(v)	Patents (International)	Application( ) Registration( )

※ 본 서식에 대해 ETRI는 작성, 타 기관은 필요시(선택사항) 작성

국문

☐ (기술의 개념)

○ 본 기술의 목표는 다양한 도메인의 대용량 데이터를 자동화된 서비스를 통해 공정성을 보정하고 시각화하는 것을 목표로 함

○ 제시하는 서비스는 빅데이터의 공정성을 보장하고 활용성 증대를 위해 데이터 구조분석, 데이터 편향 제거 및 공정한 데이터 셋 추출, 검증 및 시각화 수행함

○ 검증에는 4가지 공정성 평가지표인 균등기회, 균등확률, 인구통계 패리티, 균등 대우 사용하여 데이터 공정성 검증함

○ 이를 통하여 여러 도메인에서 발생하는 다양한 형태의 입력 빅데이터를 공정성이 보정된 고품질의 데이터로 변환하여 제공

○ 기존 연구는 학습 방법을 통해 모델의 공정성을 보정하는 연구가 주를 이

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

루고 있는 반면, 제시하는 서비스는 데이터 자체의 공정성을 보정하는 것으로 초기 데이터와 같은 모양의 공정성이 보정된 데이터 셋을 결괏값으로 출력함

○ 제안하는 기술은 데이터 내 존재하는 편향을 제거하는 언더 샘플링 기법으로 다른 공정성 보정 기술과 달리 데이터의 구조를 변경하지 않으며 생성되거나 파생된 데이터가 아니므로 별도의 과정 없이 모든 알고리즘에 적용이 가능함

○ 인공지능이 여러 분야에 접목되어 사용됨에 따라 인공지능의 학습에 쓰이는 데이터의 중요성 또한 증가하고 있으므로 인공지능 학습에 악영향을 주는 편향을 제거하여 공정성을 보정하는 기술은 시장성을 가질 수 있음

<기술개념도>

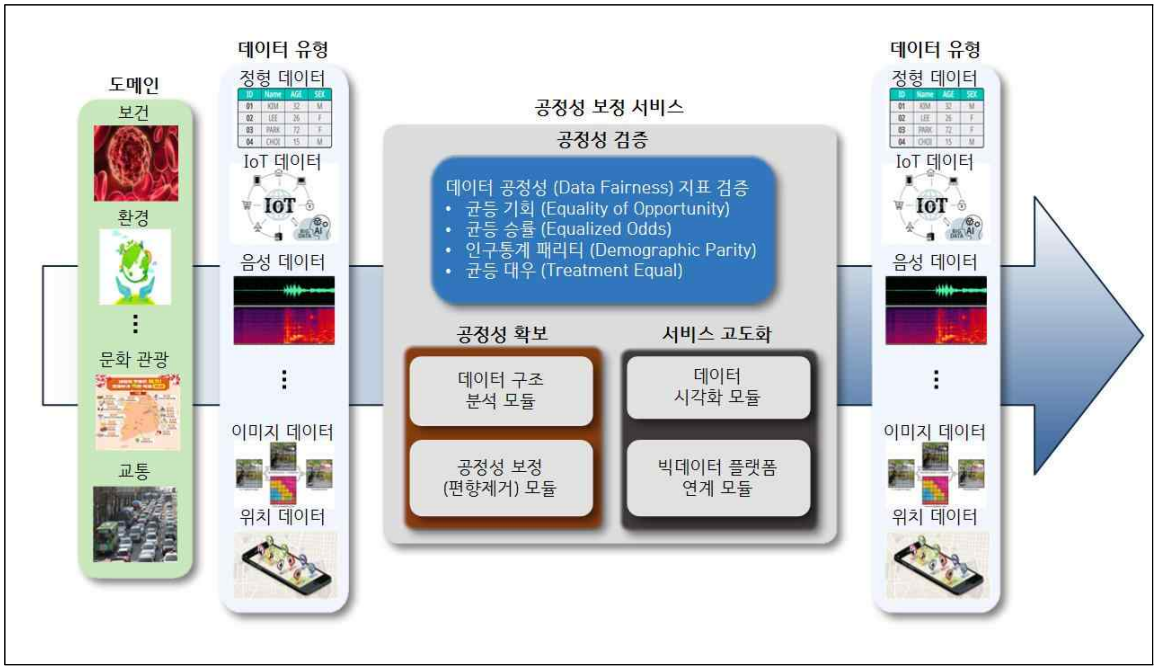

③ 기술적 경쟁력

○ 기술의 특성 및 성능

- 제안하는 기술은 데이터 내 존재하는 편향을 제거하는 언더 샘플링 기법으로 데이터 수준에서 공정성을 보정하는 기법임
- 따라서 기존 데이터가 가지는 구조(Structure)와 속성(Feature)을 변경하지 않으면서 편향만 제거된 데이터 셋을 도출하므로 추가적인 과정 없이 기존 알고리즘에 적용할 수 있음
- 출력 데이터 셋은 생성 및 파생된 데이터가 아니며 기존 데이터 셋 추출(Sampling)된 데이터로 인공지능 알고리즘에 적용 시 학습 데이터에 대한 별도의 설명이 불필요함
- 제안하는 서비스는 공정성 검증을 위해 잘 알려진 공정성 평가지표인 균등기회, 균등확률, 인구통계 패리티, 균등 대우를 사용하며 공개 데이터셋인 COMPAS, Adult Cencus Dataset 등에서 기존 연구 대비 우수하게 공정성이 보정됨을 확인함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 경쟁기술/대체기술 동향 및 현황 (우수성 및 차별성)

경쟁기술	본 기술의 우수성/차별성
IBM AIF360 (출처 : https://aif360.mybluemix.net/)	제안하는 서비스는 기존 데이터에서 언더 샘플링(Under Sampling) 기법을 활용하여 편향을 제거함으로써 데이터의 공정성을 보정하는 기술임. 데이터의 속성(Feature)과 구조(Structure)를 변경하여 공정성을 보정하는 방법을 사용한 IBM AIF360과 달리 본 기술은 데이터의 속성 및 구조를 변경하지 않으므로 공정성 보정 후 별도의 과정 없이 활용이 가능하다는 강점이 있음.
FairGAN+ (출처 : https://ieeexplore.ieee.org/document/9006322)	FairGAN+는 기존 데이터를 기반으로 모조 데이터를 생성하여 공정성을 확보하는 기법으로 소량의 데이터에도 적용할 수 있다는 장점이 있으나 생성된 데이터에 대해 추가적인 설명이 필요한 반면 제안하는 서비스는 기존 데이터에서 편향을 제거하는 기법으로 초기 데이터와 동일한 데이터이므로 추가적인 설명이 불필요한 장점이 있다.
FairBatch (출처 : https://arxiv.org/abs/2012.01696)	FairBatch는 인공지능 모델의 학습 알고리즘에 옵티마이저를 추가하여 공정성을 최적화하는 기법으로 별도의 전처리 과정을 거치지 않는 장점이 있으나 학습 모델의 수정이 불가능할 경우 사용이 어렵다는 한계가 있다. 제안 서비스는 데이터 수준에서 공정성을 보정하는 전처리 기법으로 알고리즘의 수정이 불필요하며 모든 모델에 사용이 가능한 장점이 있다.

④ 표준화 및 특허

(1) 국내 표준화 현황

표준화 기구	표준화 내용
ISO	ISO 8000-60, 2017, Data Quality Management: Overview (데이터 품질관리 개요 프로세스 참조모델 성숙 모델 평가 프레임워크 개선 모델 예제 모델 등으로 구성)
ISO	ISO 8000-150, 2011, Mster Data: Quality Management Framework (마스터 데이터의 품질관리 위한 절차 및 역할을 정의한 프레임워크)

(2) 국외 표준화 현황

표준화 기구	표준화 내용
ISO	ISO 8000-63, Data Quality Management: Process Measurement (개발중 데이터 품질관리프로세스 측정 영국)
ISO	ISO 8000-64,Data Quality Management: Organizational Process maturity assessment: 개발중 Application of the test process improvement method(데이터 품질관리 조직 프로세스 성숙도 평가 테스트 프로세스 개선 방법의 응용 독일)
ISO	ISO 8000-65, Data Quality Management: Process measurement questionnaire (개발중 데이터 품질관리 프로세스 측정 질문지 프랑스)

○ 관련 보유특허 ※ 대외 공개 가능한 특허만 작성

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	한국	10-2022-0173278(2022.12.13)	출원	인공지능 학습 데이터의 공정한 보장을 위한 대칭 구조 기반 모조 데이터 생성 장치 및 방법
2	한국	10-2021-0147606(2021.11.01)	출원	실시간 배치셋 기반으로 인공지능 학습 데이터셋의 공정성을 보정하는 장치 및 그 방법

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑤ 시장성

○ 국내 시장동향 및 전망

- 데이터 처리 및 관리 솔루션 개발·공급업 시장규모는 2020년 2조 5,133억 원으로 2019년 대비 20.8% 성장하였으며, 2019년부터 2021년 예상 매출까지 3개년 연평균 증감률(CAGR)은 21.2%로 데이터산업 전체 성장세(17.1%)보다 높게 나타남

데이터 처리 및 관리 솔루션 개발·공급업 시장규모(2021 데이터 산업 현황조사)

- 2020년 기준 데이터 처리 및 관리 솔루션 개발·공급업 시장의 부문별 매출 비중을 살펴보면, 데이터베이스 관리 시스템 솔루션 시장이 35.7%를 차지하고 있으며, 다음으로 데이터 관리 솔루션(24.0%), 빅데이터 통합 플랫폼 솔루션(11.4%)이 뒤를 이음

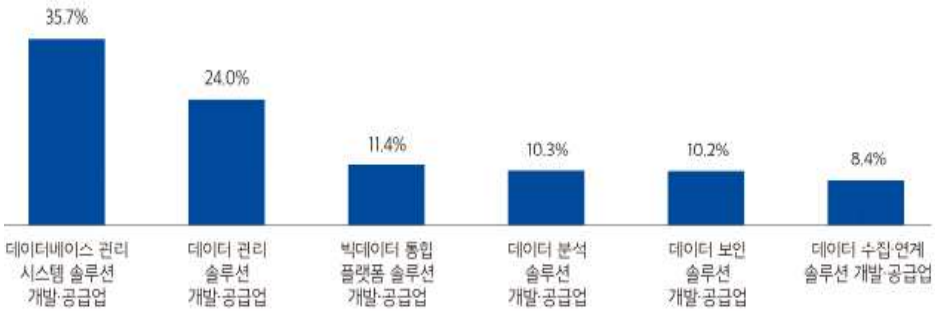

2020년 데이터 처리 및 관리 솔루션 개발·공급업 중분류별 시장규모(2021 데이터 산업 현황조사)

○ 국외 시장동향 및 전망

- 미국의 데이터 시장은 세계적으로 가장 큰 규모를 보이고 있으며, 시장의 성장세 또 20년~2022(E)까지 연평균 성장률 12.4%로 높게 나타났다. 미국은 시장 규모가 2019년 2,093억 달러에서 2022년에는 2,975억 달러의 시장 형성이 예상되는 등 지속적으로 두 자릿수 성장세를 보이고 있음
- 유럽연합(EU)의 데이터 시장은 연평균 성장률 4.9% 수준으로 상대적으로 성장세가 약함
- 유럽연합 시장 규모 내에서는 2020년 기준으로 '독일, 프랑스, 이탈리아, 네덜란드, 스페인'이 약 2/3의 비중을 차지하고 있으며, ICT 기술에 대한 지출액 및 경제력과 상관관계가 높은 특징을 가짐

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

글로벌 데[이터 시장 규모(2019 ~ 2022년) (2022 데이터 산업 백서)

○ 국내외 공정성 도구 현황

수요처	국명	수요량	관련제품
KAIST 공정성연구센터	대한민국	-	MSIT AI FAIR 2022
IBM	미국	-	AIF360
MicroSoft	미국	-	Fairlearn
Google	미국	-	What ifTool

○ 제품화 및 활용분야

활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	보험보상범위 결정 서비스	보험 데이터의 경우 보험보상 지급 데이터와 비교하면 보험보상 미지급 데이터가 많이 수집되므로 모델 학습 시 데이터 불균형으로 인한 오분류를 예방할 수 있도록 보험보상 데이터의 공정성을 보장하여 보험보상 범위를 결정하고 올바른 보상이 가능하도록 함
2	암 진단 서비스 고도화	암 진단 데이터의 경우 악성과 비교하면 양성이 훨씬 많이 수집되므로 기존 모델은 양성으로 예측해도 높은 정확도를 가지는 문제가 있다. 따라서 수집되는 데이터의 공정성을 보장하여 기존 모델의 가진 한계점을 개선하고 고도화할 수 있음

※ 해당기술이 적용/활용될 수 있는 소재/부품/제품/서비스 등을 최대한 기재

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 억원				
		2023	2024	2025	2026	2027
1	보험보상범위 결정 서비스	3	5	10	15	20
2	암 진단 서비스 고도화	5	7	15	17	30

※ 관련자료 등을 참고로 과제책임자가 예상치 기재

⑥ 기술이전 조건 및 고려사항 ※ **해당된 경우, 해당항목에** √하여 주시기 바랍니다. 복수 선택 가능

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
			v					
기술이전 금액	무료 -5백만원 이하	5백만원 초과 -1천만원 이하	1천만원 초과 -2천만원 이하	2천만원 초과 -3천만원 이하	3천만원 초과 -5천만원 이하	5천만원 초과 -1억원 이하	1억원 초과	기타
		v						

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
				V		

⑦ 기대효과

○ 기술도입으로 인한 경제적 효과

- 보험보상범위 결정 서비스: 과도한 보험료 청구나 보험사기 등에 대한 예방
- 암 진단 서비스 고도화: 암 질환의 예방

○ 기술사업화로 인한 파급효과

- 보험보상범위 결정 서비스: 과도한 보험료 청구나 보험사기 등에 대한 예방
- 암 진단 서비스 고도화: 암 질환의 예방

⑧ 기술사업화 적용 및 제약사항 (해당사항 없음)

⑨ 기타

기술세미나 발표 가능 여부(O/X)	o	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	o

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	-	-	-	-	-
	연구자	권준호	부산대학교	교수	051 510 3149	jhkwon@pusan.ac.kr

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발기술 2	국문	유방영상 자동처리에 의한 인공지능기반 유방암 발병위험도 진단
	영문	Predicting Breast Cancer Risk from Automated Mammography Analysis using Deep Learning

공개	■	비공개	□ (사유)

① (예상) 결과물

개발목표 시기	2023년 중반경 기술이전 가능한 API화		기술성숙도 (TRL)	개발 전	개발 후
				2	3-4
결과물 형태	1) 유방암의 위험도진단능력 개선이 검증된 발병위험 진단기술 알고리즘 2) 표준 의료영상이 dcm 및 범용 이미지 파일(jpg, bmpf등)의 자동입력 가능한 입출력 모듈 3) REST API로 표준화된 알고리즘 4) 출력 결과의 개인별 위험정보제공 시각화 5) 앱개발 설계도		검증방법	자체 검증 및 기술이전을 원하는 기업체 등의 3자 검증	
색인어 (Keywords)	국문	유방암, 유방영상, 의료영상자동분석기술, 인공지능, 암발생위험, 정밀의학, 맞춤형예방, 비정형자료 자동 품질관리			
	영문	breast cancer, automatic medical image analysis, artificial intelligence, cancer risk, precision medicine, personalized prevention, automatic quality control of unstructured data			
외부 기술요소	Open Source사용 100% 자체개발 기술 License 학술적 논문으로 진단능력 검증		권리성	국내 특허 (출원중) 국제특허 (PTC 출원중)	

② 기술의 개념(Concept) 및 구성

영문				
	Title	Automatic risk prediction from mammography image		
	Concept	- **breast area is segmented excluding any bone, muscle, and skin area** - **automatic quality control for semantic and image conditions are made** - **multi-level mammographic density (white, bright, non-dense) is automatically classified and calculated as %density** - **a deep learning algorithm estimate (trained for predict future breast cancer occurrence) the risk of breast cancer** - **combined algorith to maximize the predictive power of multi-level and**		
	Service Offering	- individual risk of future breast cancer occurrence at 5 grades		
	Comparative Advantage	- predictive value (AUROC ~0.77) is superior (compared with AUROC 0.6-0.68 of other methods) to previous methods - it only requires the mammographic image data		
	Patents (Domestics)	Application(0) Registration( )	Patents (International)	Application(0) Registration( )
	※ 본 서식에 대해 ETRI는 작성, 타 기관은 필요시(선택사항) 작성			

국문	□ (기술의 개념) ○ 유방암의 매우 강력한 예측요인으로 규명된 유방치밀도를 더욱 세분화하여 3단계의 서로 다른 정보를 자동추출함 ○ 해당 과정에서 일반적으로 제거되지 않는 피부, 근육등의 비유방조직을 제거하고, 자동 영상품질관리를 수행하는 기술 포함 ○ 별도의 deep learning 기술로 유방암의 발병위험관련 feature를 평가하고

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

점수화

○ 3단계의 유방 치밀도 자동평가결과와 Deep Learning 위험점수를 결합하여 위험도예측을 고도화하는 알고리즘

○ 개인의 유방촬영 영상 (암이 아닌 정상영상)을 입력하면 자동으로 위험도 평가결과가 산출되고 위험도의 정도와 향후 관리방안을 추천하는 시각화 알고리즘

<기술개념도>

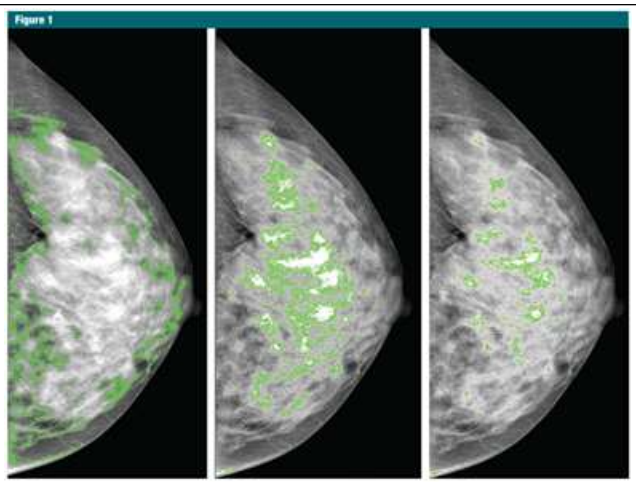

자동 평가된 3단계의 유방밀도 (왼쪽-일반적인 치밀도, 중앙-고밀도, 오른쪽 – 초고밀도부위 자동평가)

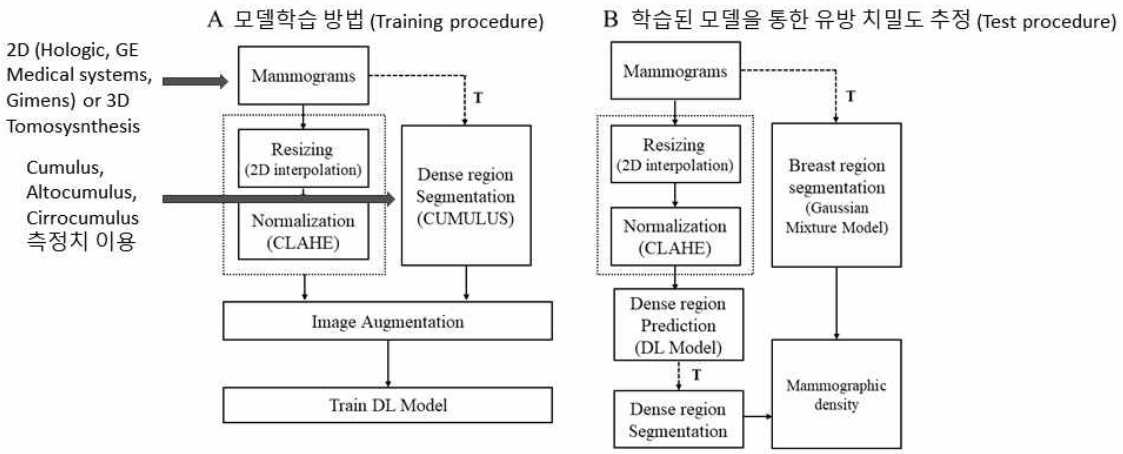

③ 기술적 경쟁력

○ 기술의 특성 및 성능

- 기존의 유방암 예측은 매우 예측력이 낮아서 실용화 되지 못하고 있음
- 유방암의 예측력을 비약적으로 높일 수 있는 방법인 유방영상 분석은 전문가의 수동 판독이 필요하여 역시 대규모의 인구에게 적용하기 어려움
- 기존에는 인공지능기반의 병변부위 발굴기술이 중심으로 정상유방의위험도 예측기술은 매우 제한적임

○ 경쟁기술/대체기술 동향 및 현황

- 서양의 Libra 등 회사에서 자동화 기술개발 중이나 예측력은 아직 높지 못한상황임
- 동양인의 유방암위험도와 위험도 feature가 서양과 달라서 대규모 한국인 자료에서 학습된 알고리즘의 강점이 예상됨

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
1) 유방암 병변부위 진단기술 2) Cumlus (전문가의 수동 유방밀도를 통한 위험도 평가방법) 3) deep learning기반 위험도 평가방법 4) 서양인 중심의 개발기술	1) 정상인 유방영상에서도 미래 위험도 평가가능 2) 자동화된 평가, 3단계의 밀도 자동평가 (특히 초고밀도가 유방암의 위험도와 가장 관련성 높음) 3) Deep learning 위험도 결과와 다중 밀도평가 결과를 종합하여 예측력을 높이는 알고리즘 포함 4) 서양인 자료는 물론 한국인의 대규모 자료로 학습됨

④ 표준화 및 특허

○ 표준화 동향

- 수동 측정방법인 Cumlus는 표준화가 이루어져 있으나, 자동평가 방법은 아직 표준화 되어 있지 않음

○ 관련 보유특허

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	대한민국	10-2021-0106592	출원	유방암 위험도 평가 시스템 및 방법
2	PCT	PCT/KR2021/013806	출원	유방암 위험도 평가 시스템 및 방법

⑤ 시장성

○ 국내외 시장동향 및 전망

- 유방암은 우리나라 여성에서 가장 빈발하면서도 치명율-장애율이 높은암이고, 현재도 계속 증가가 유지되며 젊은 여성에서 호발하는 암으로 예방과 위험도 진단의 필요성이 계속 증가

○ 제품화 및 활용분야 (해당사항 없음)

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 억원				
		2020	2021	2022	2023	2024
1	개인맞춤형 위험진단*	3,000	3,500	4,000	5,000	8,000

* ㈜ 산업경제리서치 2022년 바이오-의약품 바이오소재 시장분석자료

⑥ 기술이전 조건 및 고려사항

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
				√				
기술이전	무료	5백만원 초과	1천만원 초과	2천만원 초과	3천만원 초과	5천만원 초과	1억원 초과	기타

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

금액	-5백만원 이하	-1천만원 이하	-2천만원 이하	-3천만원 이하	-5천만원 이하	-1억원 이하		
					√	√		

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	√	√	√	√		

○ **고려사항** (해당사항 없음)

⑦ 기대효과

○ **기술도입으로 인한 경제적 효과**

- 증가하는 유방암의 예방수단 개발로 맞춤형 건강증진 시장의 선점

○ **기술사업화로 인한 파급효과**

- 유방암을 비롯한 다른 건강위험요인의 동반진단 및 관리를 위한 과정의 부가상품 발생

⑧ 기술사업화 적용 및 제약사항

○ **사업화 적용실적**

- 해당 없음

○ **사업화 제약사항**

- 해당 없음

○ **지원 필요사항**

- 해당 없음

⑨ 기타

기술세미나 발표 가능 여부(O/X)	X	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	X

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)					
	연구자	성주헌	서울대학교	교수	02) 880-2712	jsung@snu.ac.kr

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발기술 3	국문	정형데이터 품질 개선을 위한 디노이징 셀프어텐션 기술
	영문	De-noising Self-Attention Network Technique for Enhancing Tabular Data Quality

공개	■	비공개	□ (사유)

① (예상) 결과물

개발목표 시기	기술 완성 시기: 2021.09		기술성숙도 (TRL)	개발 전	개발 후
				3단계	5단계
결과물 형태	SW-System		검증방법	시험인증	
색인어 (Keywords)	국문	머신러닝, 딥러닝, 데이터 품질, 결측값, 데이터 정제, 어텐션			
	영문	machine learning, deep learning, data quality, missing values, data imputation, attention			
외부 기술요소	100% 개발기술		권리성	특허, SW	

② 기술의 개념(Concept) 및 구성

영문

Title			
Concept	(설명) 그림 또는 기술에 대한 간략한 요약문		
Service Offering			
Comparative Advantage			
Patents (Domestics)	Application ( ) Registration(O)	Patents (International)	Application( ) Registration( )

※ 본 서식에 대해 ETRI는 작성, 타 기관은 필요시(선택사항) 작성

국문

□ (기술의 개념)

○ 본 기술(명칭: De-noising Self-Attention Network (DSAN))은 수치형과 범주형 변수가 공존하는 정형 데이터에 대해 직접적으로 적용 가능한 결측값 보간 모델로서 테이블 형태의 데이터의 품질 개선을 성취함

- 본 기술은 디노이징(De-noising) 기법과 셀프 어텐션(Self-attention) 네트워크를 결합하여 견고한 문맥적 특징 추출을 수행하고, 이를 기반으로 각 컬럼 특성에 맞는 대체값을 생성함

<기술개념도>

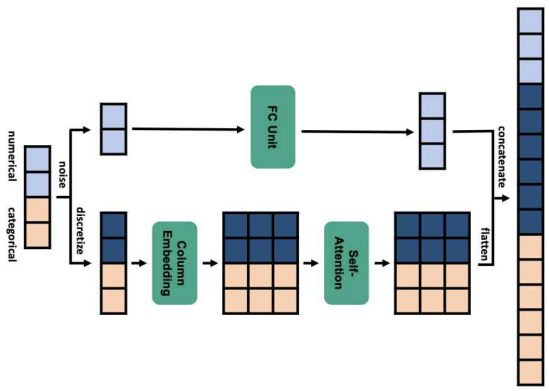

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	• DSAN 구조는 크게 3단계의 영역으로 구분되면, 첫째 영역은 특징 표현 모듈에서 이산화한 수치형 변수와 범주형 변수를 활용하여 문맥적 특징을 학습 및 추출, 둘째 영역은 공유 레이어 모듈에서 각 변수별 예측에 공통적으로 필요한 파라미터를 학습함, 셋째 영역은 태스크 개별 레이어 모듈에서 각 변수에 적합한 독립적인 파라미터를 학습 및 대체값을 예측함

③ 기술적 경쟁력

○ 기술의 특성 및 성능

- 본 기술(DSAN)은 수치형과 범주형 변수가 공존하는 혼합형 데이터에 대해 별도의 가공 과정 없이 바로 활용 가능한 데이터 보간 기술이며, 이는 셀프 어텐션(Self-Attention) 기반 특징 표현 기법과, 디노이징 기법을 결합하여 입력 데이터 내 결측 데이터에 대해 견고한(robust)한 특징을 학습하고, 멀티태스크 학습(Multi-task Learning) 개념을 반영하여 변수별 대체값을 자동 생성함
- 비교 기법인 MissForest 대비 본 기술이 평균적으로 7% 향상된 성능을 보임

○ 경쟁기술/대체기술 동향 및 현황

- 통계 기반의 보간 기법은 평균값, 최빈값과 같은 기초 통계량을 대체값으로 사용하는 방식과 회귀모델을 만들어 대체값을 예측하는 방식을 포함하고 있음. 기초 통계량 기반 보간 기법은 쉽고 빠르게 적용할 수 있는 장점이 있지만, 데이터의 크기가 커질수록 유효성이 떨어지는 문제점이 있고, 회귀모델 기반 보간 기법은 수치형 변수에만 적용되고 그 정확도가 높지 못하는 문제점을 안고 있음
- 통계 및 회귀모델 기반의 문제점을 보완하기 위해 최근 k-최인접이웃(k-Nearest Neighbors), 지지벡터머신(Support Vector Machine), 랜덤포레스트(Random Forest), 인공신경망(Neural Networks)과 같은 머신러닝 기반의 보간 기법들이 연구되고 있음
- 머신러닝 기반 보간 기법은 결측값이 존재하는 변수에 출현한 관측값을 가지고 학습모델을 만들어 대체값을 추정하는 형태가 일반적인데, 대표적인 머신러닝 기반 보간 기법인 MissForest는 각 관측 변수를 이용하여 결측 변수별로 Random Forest 기반의 모델을 구축하여 대체값을 예측함
- 인공신경망 기반 보간 기법의 경우 GAIN, HIVAE와 같은 생성 모델을 이용하여 결측값에 대한 대체 값을 생성하는데, 생성 모델은 연속적인 수치형 변수만을 생성하기 때문에, 이는 영상 보간 문제에는 적합하지만 테이블 데이터와 같이 범주형 변수가 존재하는 혼합형 데이터의 경우 적합하지 않음

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
• 생성모델 기반 GAIN, HIVAE 기법은 수치형 변수에만 활용될 수 있음 • Random Forest 기반 MissForest 보간기법은 변수별로 모델을 구축하여 대체값을 예측	• 수치형 및 범주형 변수가 동시에 포함된 테이블 데이터에 대하여 하나의 모델을 생성하여, 결측치가 포함된 변수(컬럼)내 존재하는 결측치를 동시에 보완할 수 있음 • 수치형 변수에 대하여 이산화 과정을 거쳐 모든 변수(컬럼)를 이용한 문맥적 특징을 추출함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	• 디노이징 기법과 멀티 태스크 러닝 기법을 활용하여 결측값 보간 문제를 해결함

④ 표준화 및 특허

○ 표준화 동향

- 다양한 분야에서 인공지능의 성능을 보장할 수 있는 고품질 AI학습데이터 확보가 AI 예측/분류/인식 모델 개발의 주요 관건 중의 하나로 부상하고 있음
- ISO/IEC JTC 1 SC42 인공지능 분과 위원회에서는 빅데이터 분석 및 기계학습 분야에 사용되는 데이터에 대한 품질 표준 개발이 활발히 논의되고 있음
- 데이터 품질 국제 표준은 ISP TC 184/SC 4/WG 13에서 진행중인 ISP 8000(데이터 품질) 프로젝트로 개발된 표준이 대표적이며, 2022년 12월 현재 22개의 데이터 품질 표준이 제정되었음
- 마스터 데이터 분야인 ISO 8000-100 시리즈와 제품 데이터 분야인 ISO 8000-311은 데이터 중심의 품질 개선 방법을, ISO 8000-60 시리즈와 ISO 8000-150은 프로세스 중심의 품질 개선 방법을 제시하고 있음
- ISPO/IEC JTC 1/SC 7(소프트웨어 및 시스템공학)은 소프트웨어 제품 품질 요구사항 및 측정 표준의 일환으로 데이터 품질 모델 ISO/IEC 25012 표준을 제정하여 정확성, 완전성 등 15개의 데이터 품질 특성을 정의하고 있음

○ 관련 보유특허 ※ 대외 공개 가능한 특허만 작성

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	대한민국	10-2408655 (2022.06.09.)	등록	수치형 변수 및 범주형 변수를 포함하는 혼합형 결측데이터에 대한 데이터보간

⑤ 시장성

○ 국내외 시장동향 및 전망

- 글로벌 데이터 품질 도구 시장은 2022년에 19억 8천만 달러의 가치에 이르렀으며, 향후 2023~2029년 동안 19.2%의 성장세를 보여 2029년까지 47억 달러에 이를 것으로 예상됨
- 데이터 품질 도구 시장 보고서에 주로 등장하는 업체는 다음과 같음: Informatica, International Business Machines Corporation, Talend, Oracle Corporation, SAP SE, Information Builders, Experian PLC, Pitney Bowes Inc., SAS Institute Inc., Microsoft Corporation.
- 국내 데이터 품질 도구 관련 대표 업체인 ㈜위세아이텍은 빅데이터 활용 가치 향상을 위해 빅데이터 특성을 고려한 지표와 평가방법을 개발하고, 데이터 전처리부터 품질개선까지의 전 과정을 지원할 수 있는 AI 기반 빅데이터 품질평가 도구를 개발하고, 이를 법률, 의료, 금융 및 공공분야에 시범적용함으로서 개발된 도구의 실효성을 검증하고 있음

○ 제품화 및 활용분야

활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	데이터 품질 개선	기존 정보시스템 내에 존재하는 데이터베이스 업그레이드
2	데이터 개방	데이터포털에 탑재/개방되는 데이터에 대한 품질 개선

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3	AI학습데이터 구축	초기 구축된 AI학습데이터에 대한 품질 개선을 통해 학습모델 성능 개선

※ 해당기술이 적용/활용될 수 있는 소재/부품/제품/서비스 등을 최대한 기재

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 억원				
		2020	2021	2022	2023	2024
1	데이터 품질 도구	13.8억달러	16.5억달러	20억달러	24억달러	28.5억달러

※ 관련자료 등을 참고로 과제책임자가 예상치 기재

⑥ 기술이전 조건 및 고려사항 ※ **해당된 경우, 해당항목에0** √하여 주시기 바랍니다. 복수 선택 가능

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
				√				
기술이전 금액	무료 -5백만원 이하	5백만원 초과 -1천만원 이하	1천만원 초과 -2천만원 이하	2천만원 초과 -3천만원 이하	3천만원 초과 -5천만원 이하	5천만원 초과 -1억원 이하	1억원 초과	기타
				√				

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	O					

○ 고려사항 ※ 기술이전시 기타 고려사항

- 기술이전시 딥러닝에 대한 기술력이 적정 수준 이상이 업체가 활용 가능한데, 이는 결측값을 생성하기 위한 딥러닝 모델을 지속적으로 갱신해줘야 하기 때문임

⑦ 기대효과

○ 기술도입으로 인한 경제적 효과

- 데이터 분석 비용의 획기적 절감: 기존의 데이터 융합, 탐지, 검색, 전처리 등에 큰 비용이 소요된 점에 비추어볼 때, 본 연구결과는 데이터 분석시장에서 관련 비용을 획기적으로 절감할 수 있을 기회를 제공할 수 있음
- AI학습데이터 빅데이터 활용서비스 시장이 확산 기여: 본 개발 개술은 다양한 도메인의 데이터 품질 개선에 적용하여 산업계와의 연계를 통해 빅데이터 처리 기능을 가진 AI를 비롯한 빅데이터 분석/예측 시스템의 상용화 가능성이 매우 큼
- 효율적인 의사결정을 지원하는 서비스 개발 및 시장 수요 창출: 단발성 빅데이터 분석 대행 프로젝트나 시스템 구축 위주로 형성되어 있는 빅데이터 시장에, 다중 도메인의 융합 데이터 탐색/융합 기술이 적용될 경우 클라우드 서비스와 결합하여 신규 비즈니스 모델에 기반한 시장이 확대될 것으로 기대됨

○ 기술사업화로 인한 파급효과

- 고품질 초고속 데이터 정제 서비스의 사업화: 도메인별 데이터 정제 서비스에 대한 레퍼런스를 구축, 금융/정보통신/유통 등 산업별 정제 서비스 기술 및 솔루션을 활용하여 예측모델을 확보하고 이를 활용하여 부수적인 서비스 및 매출 창구 마련
- 단순 빅데이터 저장소를 넘어선 고품질 빅데이터 관리 서비스의 실현: 다양한 종

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

류의 데이터를 분석목적에 맞게 정제/변환/가공하여 데이터레이크에 저장하고, 이들에 대한 초고속 데이터 융합 서비스를 지원함으로써 빅데이터에 기반한 새로운 서비스의 창출, 또한 데이터 분석가의 입장에서 분석 이전의 데이터 준비 과정에 소요되는 시간을 단축하고 분석에 필요한 다양한 데이터들을 데이터레이크에서 쉽게 구할 수 있음. 데이터 엔지니어/과학자 입장에서 데이터 파이프라인의 일관된 체계를 구축함으로써, 지속가능한 데이터 분석 서비스를 실현할 수 있음

⑧ 기술사업화 적용 및 제약사항

- ○ **사업화 적용실적: 해당사항없음**
- ○ **사업화 제약사항: 해당사항없음**
- ○ **지원 필요사항: 해당사항없음**

⑨ 기타

기술세미나 발표 가능 여부(O/X)	O	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	X

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)					
	연구자	김한준	서울시립대학교	교수	02-6490-2339	khj@uos.ac.kr

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발기술 4	국문	기계학습 데이터 품질향상 특징공학 자동화 파이프라인
	영문	Automated Feature Engineering Pipeline Improving The Quality of Machine Learning Data

공개	■	비공개	□ (사유)

① (예상) 결과물

개발목표 시기	2023.12		기술성숙도 (TRL)	개발 전	개발 후
				4	6
결과물 형태	SW-Platform		검증방법	자체검증	
색인어 (Keywords)	국문	특징 공학, 학습데이터품질, 기계 학습, 자동화 파이프라인			
	영문	Feature Engineering, Quality Of Training Data, Maching Learning, Automated Pipiline			
외부 기술요소	Open Source 사용		권리성	특허, SW	

② 기술의 개념(Concept) 및 구성

영문

Title	Automated Feature Extraction Pipeline For Machine Learningv Data		
Concept	**Automatically extract key features for raw training data**		
Service Offering	Improved Machine Learning Performance		
Comparative Advantage	No human configuration required		
Patents (Domestics)	Application(○) Registration( )	Patents (International)	Application( ) Registration( )

※ 본 서식에 대해 ETRI는 작성, 타 기관은 필요시(선택사항) 작성

국문

□ (기술의 개념)

○ 기계학습용 훈련데이터로부터 학습에 유리한 특징을 추출하여 기계학습의 정확도와 학습 속도를 개선

- 통상의 학습데이터 형태인 Excel/CSV로부터 자동화된 파이프라인을 통해 기계학습 성능 개선을 보장하는 파생 특징으로 구성된 학습데이터 생성
- 전문가의 수작업 없이도 일반인도 잘 알려진 학습 모델을 통하여 다양한 기계학습 수행 가능
- 파이프라인 단계는 CSV를 계층화된 형태의 자료 구조로 자동정규화를 수행하고, 특징 연산자들과 컬럼의 조합을 통해 다양한 특징들을 자동으로 추출하여 최적의 특징들을 선택하는 과정임

<기술개념도>

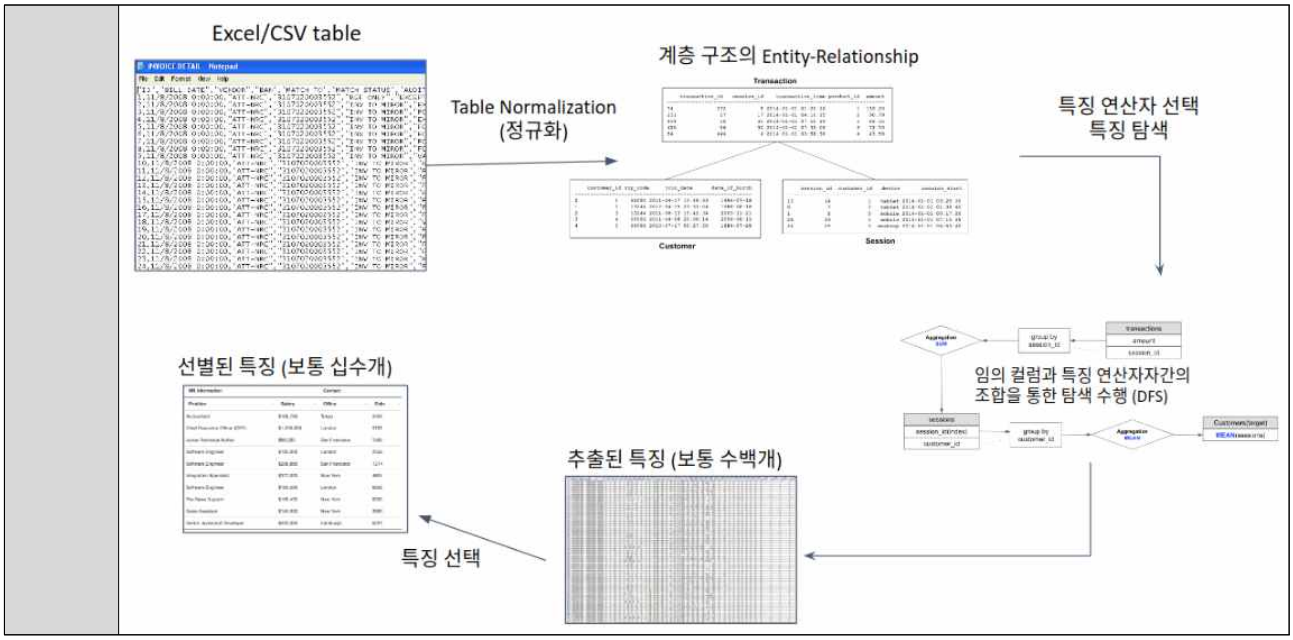

③ 기술적 경쟁력

○ 기술의 특성 및 성능

- 분류나 회귀와 같은 잘 알려진 학습 모델에 대해 학습데이터에 내재된 특징을 기반으로 학습 성능을 개선함
- 모델이나 학습에 대한 전문적 지식 없이 확보된 학습데이터만으로 본 도구를 적용
- 전문가를 통한 학습데이터 전처리 경우의 학습 성능의 평균 80%까지 도출 가능

○ 경쟁기술/대체기술 동향 및 현황

- 기존 특징공학 파이프라인은 본 기술과 같이 완전 자동화된 도구는 존재하지 않음
- 오픈소스 도구인 featuretools를 산업계와 학계에서 많이 활용하고 있으나, 비전문가가 사용하기에 매우 어려운 도구이며, 오용될 경우 원시 학습 데이터보다 성능이 떨어질 수도 있음

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
- featuretools - AutoFeat - TSFresh - OneBM - Cognito	- 입력소스로부터 출력까지의 전체 파이프라인 자동화 단계를 제공 - 입력 소스외의 별도의 파라미터 설정없이도 동작 가능

④ 표준화 및 특허

○ 표준화 동향

- 특별한 표준화 동향 없음

○ 관련 보유특허 ※ 대외 공개 가능한 특허만 작성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	대한민국	10-2022-0146508(23.11.4)	출원	기계 학습 모델의 학습 데이터 품질 향상을 위한 특징 공학 파이프라인 방법 및 장치

⑤ 시장성

○ 국내외 시장동향 및 전망

- 프로그래밍 실력을 갖춘 전문가를 통하여 학습 데이터 전처리를 수행하여 특징공학 도구를 통한 학습데이터 전처리 수요가 현재로서는 크지 않음
- 그러나, 향후 우수한 학습 모델들이 계속 개발됨에 따라 기계학습의 성능이 훈련데이터의 의존될 것이며, 결국 특징공학 도구 등을 활용한 사례들이 지속증가하여 관련 도구에 대한 시장 수요가 증대 될 것으로 전망됨

○ 제품화 및 활용분야

활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	매출 예측 서비스	매출 관련 데이터를 입력하면, 자동으로 특징을 추출하여 향후 매출을 자동 예측

※ 해당기술이 적용/활용될 수 있는 소재/부품/제품/서비스 등을 최대한 기재

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 억원				
		2023	2024	2025	2026	2027
1	매출 예측 서비스	1,000	2,300	5,000	12,000	35,000

※ 관련자료 등을 참고로 과제책임자가 예상치 기재

⑥ 기술이전 조건 및 고려사항 ※ **해당된 경우, 해당항목에** √하여 주시기 바랍니다. 복수 선택 가능

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
			√					
기술이전 금액	무료 -5백만원 이하	5백만원 초과 -1천만원 이하	1천만원 초과 -2천만원 이하	2천만원 초과 -3천만원 이하	3천만원 초과 -5천만원 이하	5천만원 초과 -1억원 이하	1억원 초과	기타
						√		

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	√					

○ 고려사항

- 없음

⑦ 기대효과

○ 기술도입으로 인한 경제적 효과

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 학습데이터 품질 향상을 위한 전문 인력에 소요되는 고정비용을 절감

○ **기술사업화로 인한 파급효과**

- 본 기술은 CSV 자동 정규화, 특징 추출/선택 등의 세부 요소 기술을 바탕으로 빅데이터 처리, 텍스트 마이닝 분야로 확장 가능함

⑧ 기술사업화 적용 및 제약사항

○ **사업화 적용실적**

- 해당 사항 없음

○ **사업화 제약사항**

- 해당 사항 없음

○ **지원 필요사항**

- 오픈소스 FeatureTools 기반의 제품으로, 당해 SW와의 공개 SW 라이선스 검토가 심층적으로 필요함

⑨ 기타

기술세미나 발표 가능 여부(O/X)	O	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	O

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)					
	연구자	조경운	이화여자대학교	연구교수	02-3277-4247	oslab@oslab.ewha.ac.kr

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발기술 5	국문	데이터 프로파일링 서비스 시스템
	영문	Data Profiling Service S/W

공개	■	비공개	□ (사유)

① (예상) 결과물

개발목표 시기	2024.03		기술성숙도 (TRL)	개발 전	개발 후
				5	6
결과물 형태	Open Source SW-System, Service		검증방법	자체검증 및 공공사업에 시법적용	
색인어 (Keywords)	국문	데이터 프로파일링, 마이크로서비스 아키텍처, 레스트풀 API, 데이터 품질, 메타데이터			
	영문	Data Profiling, MicroService Architecture, Restful API, Data Quality, Metadata			
외부 기술요소	Open Source사용		권리성	특허, SW	

② 기술의 개념(Concept) 및 구성

영문

Title			
Concept			
Service Offering			
Comparative Advantage			
Patents (Domestics)	Application( ) Registration( )	Patents (International)	Application( ) Registration( )

국문

□ 데이터 프로파일링 소프트웨어

○ 시간 장소에 제약을 받지 않는 데이터 프로파일링 서비스
- RESTful API로 프로파일링 요청 및 결과에 대한 명세 및 서비스 지원
- 마이크로서비스 아키텍처 기반 환경에 제약 없이 서비스 가능
- 기존의 데이터 품질 소프트웨어에 선쉽게 통합 가능

○ 기존의 단일컬럼 프로파일링을 확장하여 멀티 컬럼, 컬티 테이블 프로파일링 서비스 지원
- 데이터 내의 위존성 분석 및 테이블 간의 참조관계 분석까지 확장된 서비스 지원

<기술개념도>

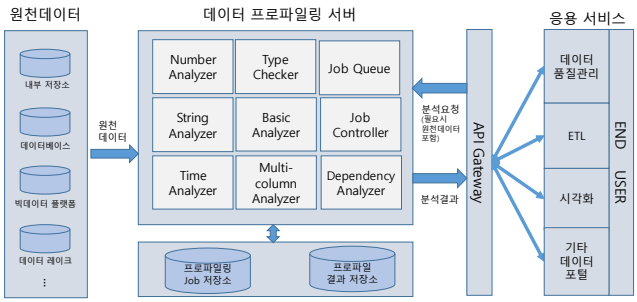

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

③ 기술적 경쟁력

○ 기술의 특성 및 성능

- 현존하는 데이터 프로파일링 서비스 중 유일하게 Restful API 형태로 서비스
- 대용량 원천 데이터에 대해서 샘플링 통한 빠른 프로파일링 제공

○ 경쟁기술/대체기술 동향 및 현황

- 국외는 Infomatica, Talend로 대표되는 고비용의 품질관리 도구에서 프로파일링 서비스를 제공. Data Cleaner와 같은 일부 오픈소스 품질관리 도구는 제한된 서비스로 제공됨
- 국내는 일부 회사에서 데이터 품질관리 도구에서 일부 서비스로 제공되고 있으나, 고비용이며, csv와 같은 오픈 데이터 포맷형식에 대한 서비스는 제공하지 못함

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
기존의 Infomatica, Talend와 같은 데이터 품질관리도구의 부품으로 프로파일링 기능이 일부 제공되는 형태	독립된 소프트웨어 형태로 제공되며, 기존의 데이터 품질관리 도구를 비롯한 다양한 소프트웨어에 손쉽게 연계 통합되는 환경을 제공

④ 표준화 및 특허

○ 표준화 동향

○ 관련 보유특허 ※ 대외 공개 가능한 특허만 작성

No.	국가	출원.등록번호(출원.등록일)	상태	명칭
1	한국	10-2022-0138955(2022.10.26)	출원	데이터 프로파일링 서비스를 제공하는 서버 및 방법

⑤ 시장성

○ 국내외 시장동향 및 전망

- 국내 공공기관을 중심으로 데이터품질관리에 대한 인식이 높아지고 있어 관련 프로파일링에 대한 서비스 요구도 같이 증가할 것으로 기대
- 점차 기업 데이터에 대한 품질관리에 영향을 미쳐 공공사업 뿐만 아니라 민간에서의 시장 창출도 크게 성장할 것으로 기대

○ 제품화 및 활용분야

활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	데이터 품질관리 SW	- 데이터 품질관리 및 개선 소프트웨어 - 데이터 레이크 소프트웨어
2	빅데이터 포털	- 데이터 프로파일링 정보 제공

※ 해당기술이 적용/활용될 수 있는 소재/부품/제품/서비스 등을 최대한 기재

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 억원				
		2020	2021	2022	2023	2024
1	데이터 품질관리 SW	20	25	25	25	30

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2	빅데이터 포털	10	10	10	10	20

⑥ 기술이전 조건 및 고려사항 ※ **해당된 경우, 해당항목에** √하여 주시기 바랍니다. 복수 선택 가능

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
					√			
기술이전 금액	**무료 -5백만원 이하**	**5백만원 초과 -1천만원 이하**	**1천만원 초과 -2천만원 이하**	**2천만원 초과 -3천만원 이하**	**3천만원 초과 -5천만원 이하**	**5천만원 초과 -1억원 이하**	**1억원 초과**	**기타**
							√	

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	√	√		√		

○ **고려사항**

- 해당사항없음

⑦ 기대효과

○ **기술도입으로 인한 경제적 효과**

- 공공 민간 관리 데이터에 대한 전반적인 품질향상으로 인한 데이터 관리 비용 절감
- 빅데이터 플랫폼들의 데이터 품질 개선 비용 절감

○ **기술사업화로 인한 파급효과**

- 데이터 프로파일링 기술에 대한 인식 확산
- 국내외 빅데이터 플랫폼이나 데이터 레이크 환경에서 프로파일링 기술 적용 확산가능

⑧ 기술사업화 적용 및 제약사항

○ **사업화 적용실적**

- 해당사항없음

○ **사업화 제약사항**

- 해당사항없음

○ **지원 필요사항**

- 해당사항없음

⑨ 기타

기술세미나 발표 가능 여부(O/X)	X	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	X

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)					
	연구자					

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발기술 6	국문	아이소프트 데이터 수집기
	영문	I-SOFT Data Collector

공개	□	비공개	■	(사유) 자체솔루션

① (예상) 결과물

개발목표 시기	2022.12		기술성숙도 (TRL)	개발 전	개발 후
				6	7
결과물 형태	SW-System		검증방법	자체검증, 시범사업	
색인어 (Keywords)	국문	임상 데이터 연계, 데이터 품질 보정, 데이터 품질 검증			
	영문	clinical data linkage, data quality calibration, data quality verification			
외부 기술요소	100% 개발기술, Open Source사용		권리성	SW, 설계도	

② 기술의 개념(Concept) 및 구성

영문

Title			
Concept			
Service Offering			
Comparative Advantage			
Patents (Domestics)	Application( ) Registration( )	Patents (International)	Application( ) Registration( )

※ 본 서식에 대해 ETRI는 작성, 타 기관은 필요시(선택사항) 작성

국문

□ (기술의 개념)

○ 데이터 수집/연계 하고 데이터 품질 보정

- 원본 DB 데이터를 타겟 DB 저장소에 이관 및 데이터 품질 보정

<기술개념도>

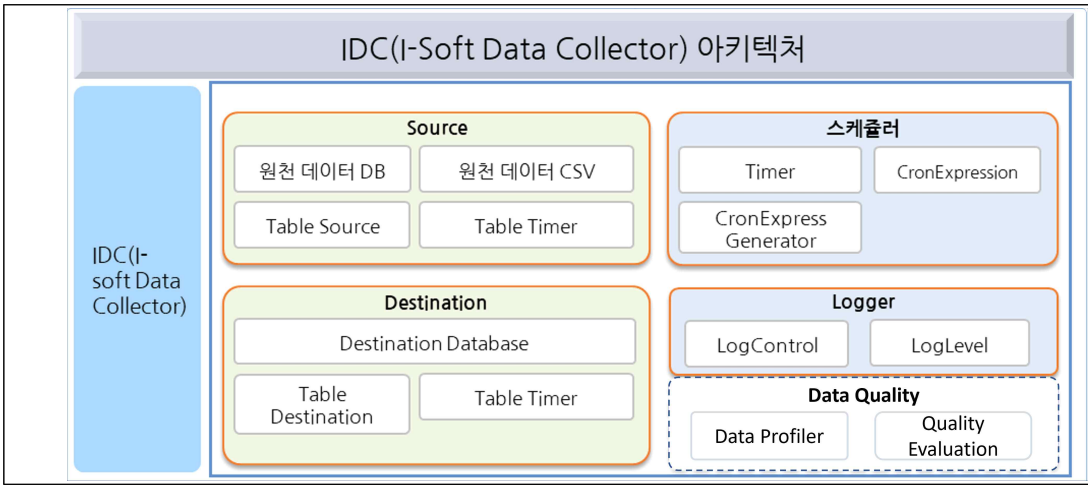

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

③ 기술적 경쟁력

○ 기술의 특성 및 성능

-. DB(tibero6, cubrid 10.2, MySQL, Oracle, PostgreSQL 등), CSV 파일 전송 가능
-. 타이머 설정으로 주기적인 데이터 전송 가능
-. DB Table 별로 별도 주기 제어 가능, query 지정 가능 및 증분 조건 가능
-. 관리용 log level 정하여 관리 가능

○ 경쟁기술/대체기술 동향 및 현황

-. 글로벌 클라우드 마이그레이션 서비스 시장 규모는 지속적으로 증가
-. Naver, KT, NHN 등 대기업 위주의 산업이 형성되어 있음
-. 가상머신, 컨테이너, 스토리지, 데이터베이스 등 클라우드 마이그레이션 기술을 지원

○ 우수성 및 차별성

경쟁기술	본 기술의 우수성/차별성
- 단순 DB to DB tool - Flyway, Liquibase	- 의료 데이터 특화 - 데이터 품질 보정

④ 표준화 및 특허

○ 표준화 동향

○ 관련 보유특허 ※ 대외 공개 가능한 특허만 작성

No.	국가	출원.등록번호(출원.등록일)	상태	명칭

⑤ 시장성

○ 국내외 시장동향 및 전망

-. 시장조사기관 가트너에 따르면 세계 클라우드 시장 규모는 22년 4,820억 달러(약 593조원)에서 25년 8,375억 달러(약 1,032조원)에 이를 전망
-. 시장조사기관 IDC는 국내 클라우드 시장이 22년 4~5조, 25년 11조 6,000억원 규모로 급성장 할 것으로 예상

○ 제품화 및 활용분야

활용분야(제품/서비스)		제품 및 활용분야 세부내용
1	데이터 이관	데이터 이관 및 데이터 품질 검증

※ 해당기술이 적용/활용될 수 있는 소재/부품/제품/서비스 등을 최대한 기재

○ 시장규모(추정치)

활용분야(제품/서비스)		관련 시장 규모(5년), 단위: 10억 달러				
		2020	2021	2022	2023	2024
1	글로벌 클라우드 마이그레이션 서비스	8.8	9.2	12	14	18

※ 출처: https://www.snsinsider.com/reports/cloud-migration-services-market-1225

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑥ 기술이전 조건 및 고려사항 ※ **해당된 경우, 해당항목에** √하여 주시기 바랍니다. 복수 선택 가능

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
			√		√			
기술이전 금액	무료 -5백만원 이하	5백만원 초과 -1천만원 이하	1천만원 초과 -2천만원 이하	2천만원 초과 -3천만원 이하	3천만원 초과 -5천만원 이하	5천만원 초과 -1억원 이하	1억원 초과	기타
		√						

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
			√			

○ 고려사항: 없음

⑦ 기대효과

○ 기술도입으로 인한 경제적 효과

-. 의료 데이터에 특화된 중소규모 데이터 마이그레이션 사업이 활성화 할 것으로 기대

-. 중소규모 데이터 마이그레이션 사업에 활용돼어 시간과 비용 절감

○ 기술사업화로 인한 파급효과

-. 개인 식별 정보 비활성화로 의료 데이터에 대한 연구활성화에 기여할것으로 기대

-. 의료 빅데이터 기술 개발에 기여할것으로 기대

⑧ 기술사업화 적용 및 제약사항

○ 사업화 적용실적

-. 인제대학교 부산백병원: 임상 데이터확보/연계를 위한 임상 연구 데이터 시스템(CDW) 및 바이오뱅크 임상 연구 데이터 시스템 모델(CDM) 구축

○ 사업화 제약사항: 없음

○ 지원 필요사항: 없음

⑨ 기타

기술세미나 발표 가능 여부(O/X)	x	매칭 희망 여부(O/X) (R&D 바우처 사업 등)	x

담당	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	최홍규	아이소프트	상무	051-931-1700	hgchoi@i-soft.kr
	연구자					

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 3. 공개 SW 요약서 (공개SW과제만 작성)

공개 SW명	QuFa (Data Quality and Fairness)	
분류		
기술분류	기반SW・컴퓨팅/빅데이터/빅데이터 수집・저장・관리・분석(마이닝)・예측	
최종 업데이트일	2023년 1월 16일	
공개 SW 정보		
개요 (공개 SW요약)	데이터 품질 평가기반 데이터 고도화 및 데이터셋 보정 기술 개발(IITP 2020) 사업의 도메인별 데이터 품질/공정성/프로파일링/특징공학 알고리즘/통합(QuFa Framework) 및 실제 활용 데이터셋의 공개	
저장소별 주소	**QuFa(공식 저장소)**	▪ https://gitlab.com/qufa/qufa ▪ 도메인별 데이터셋 및 데이터 품질/공정성/통합(QuFa Framework) 구현
	Qufa_dataHunter	▪ https://gitlab.com/qufa/qufa_datahunter ▪ 원천 데이터를 프로젝트 DB내에 로드 ▪ 원천 데이터의 Meta data reading
	QuFa_dataReviewer Server	▪ https://gitlab.com/qufa/qufa_datareviewerserver ▪ 피드백 지원도구(백엔드) ▪ REST API 활용 ▪ 파일 데이터, Database 정보를 통해 데이터를 API로 자동 변환
	QuFa_dataReviewer Client	▪ https://gitlab.com/qufa/qufa_datareviewerclient ▪ 피드백 지원도구(프론트엔드) ▪ Designer-Server와 연동 ▪ React Framework 기반의 Web Frontend 프로젝트
	QuFa_dataFeat	▪ https://github.com/oslab-ewha/qufafeat ▪ 데이터 특징공학 툴
	QuFa_dataCloud	▪ https://drive.google.com/drive/folders/15-z-NWTicGJeEkYsbKUXaoBcwZJT9IKC ▪ 환경 데이터셋 저장소 클라우드
	QUFA_dataQuality	▪ https://gitlab.com/qufa-ptech/imputation ▪ QUFA Imputation & Remove outlier
	QUFA_dataProfiler	▪ https://gitlab.com/qufa-ptech/qufa-profiler ▪ QUFA data Profiler 프로젝트
	QUFA_Feat	▪ https://gitlab.com/qufa-project/qufafeat ▪ QUFA feat : Automated feature engineering pipeline
	QUFA_Studio	▪ https://gitlab.com/qufa-project/qufa-studio ▪ QUFA Studio : 데이터 품질/공정성 통합 관리 시스템
구글 등 검색여부	Y	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

버전	안정화 버전	버전명	v2.0	날짜	2021.12
	최종 버전	버전명	v3.0	날짜	2022.12
라이선스		Apache Licence 2.0			
공개SW 실적	Commit	목표 : 600건(누적)		실적 : 3,695건(누적)	
	Fork	목표 : 25건(누적)		실적 : 39건(누적)	
	저장소	목표 : 5건(누적)		실적 : 10건(누적)	
	기여자	목표 : 6명(누적)		실적 : 24명(누적)	
	홍보	목표 : 1건(누적)		실적 : 3건(누적)	
	실적 관리자	소속: 부산대, 이름: 김구, 연락처: ******* ,E-Mail: *******			
활용 사례1					
활용 기관명		㈜프람트테크놀로지, 공동연구기관(수요기업)			
활용 목적		사업화(상용화)를 위한 연구개발 원천 알고리즘 활용에 따른 서비스 구축			
활용 상세		▪ 웹 기반 애플리케이션 서비스 구축 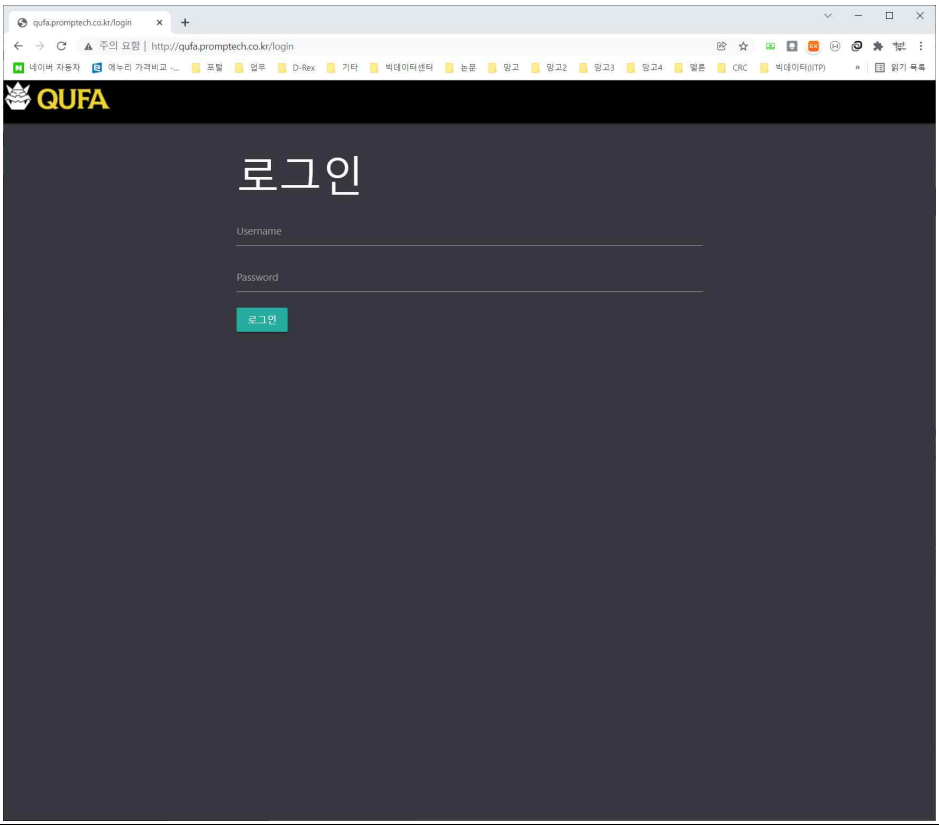			

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

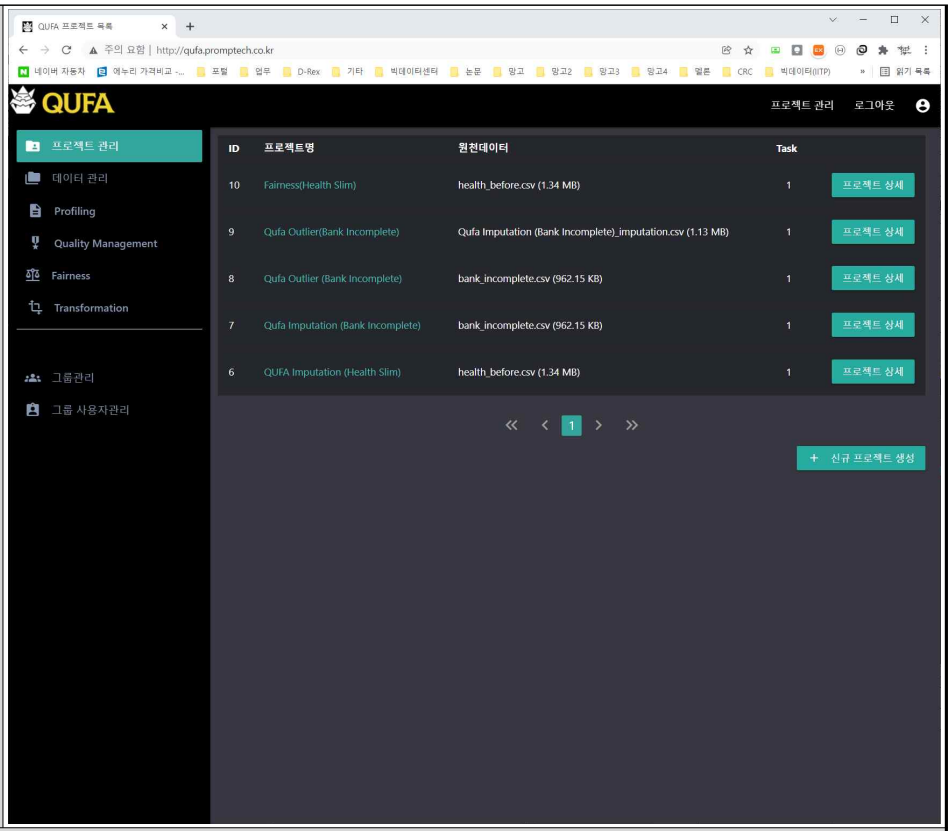

활용 사례2	
활용 기관명	㈜디렉스(상) / ㈜아이소프트(하)
활용 목적	공개 원천기술을 활용한 데이터 품질/공정성 보정 서비스 제공
활용 상세	▪ 공개 저장소의 데이터셋의 통계 분석 서비스 구현 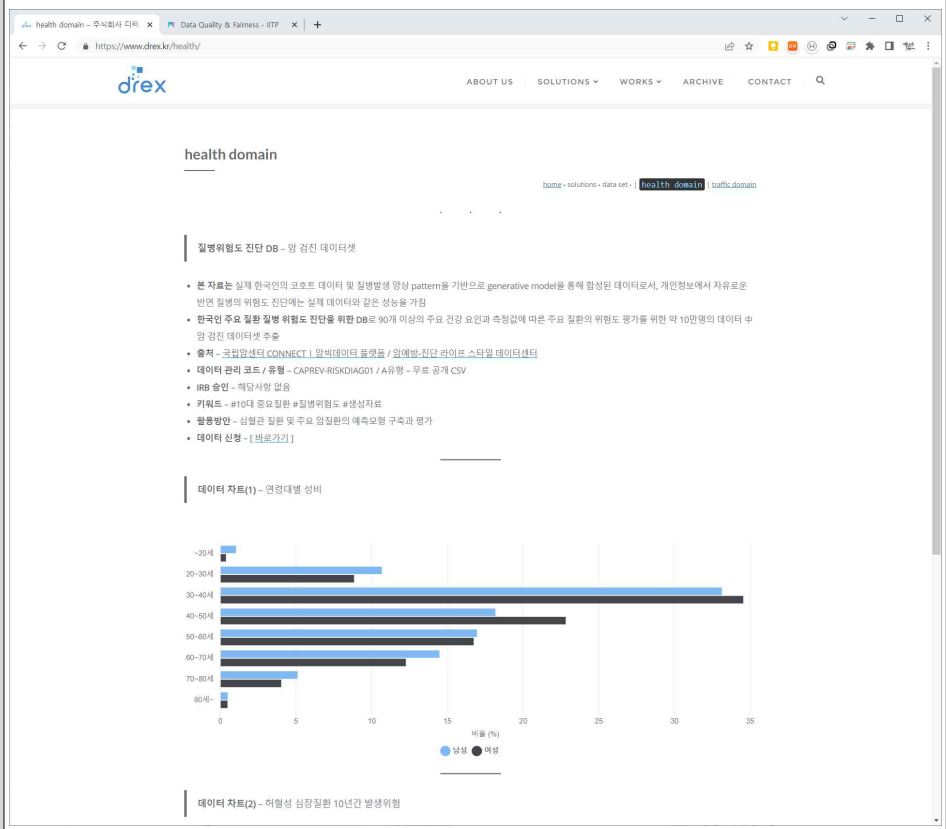 ▪ 공개 된 원천 알고리즘을 활용한 공정성 보정 웹 가시화 서비스 제공

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

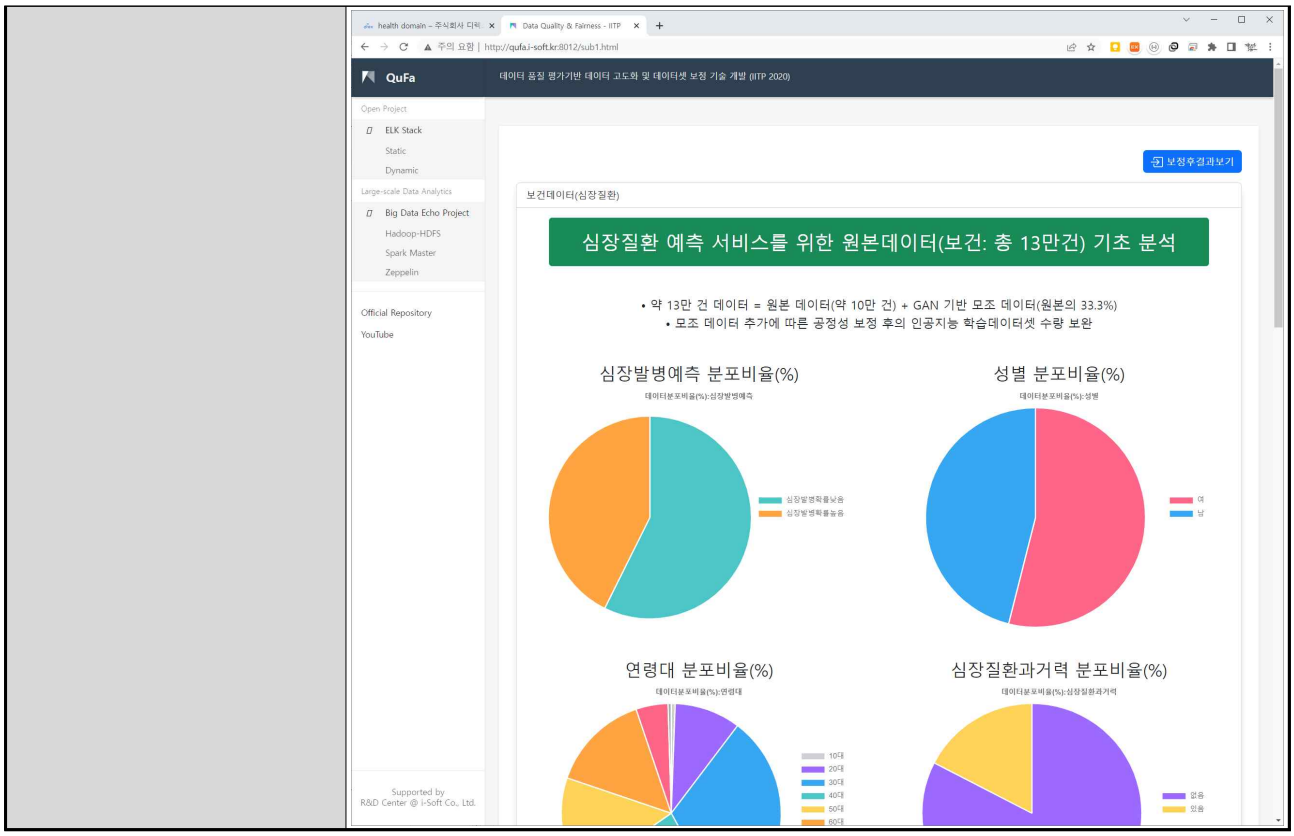

* 실적치에 대한 깃허브 등 저장소에 대한 증빙자료 필수 제출(캡쳐 등)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

주 의

1. 이 보고서는 과학기술정보통신부에서 시행한 정보통신 · 방송연구개발사업의 ○○연구개발과제 최종보고서이다.

2. 이 연구개발내용을 대외적으로 발표할 때에는 반드시 과학기술정보통신부(정보통신기획평가원)에서 시행한 정보통신 · 방송연구개발사업의 결과임을 밝혀야 한다.

3. 국가과학기술 기밀 유지에 필요한 내용은 대외적으로 발표 또는 공개하여서는 안 된다.