국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

과제번호 NRF-2017M3C4A7083279

차세대정보컴퓨팅기술개발사업

이종 빅데이터 통합 분석 메타러닝 기술 개발

(Development of Meta-Learning Technology for Integrated Analysis of Heterogeneous Big Data)

동국대학교

과 학 기 술 정 보 통 신 부

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

총괄 과제

이종 빅데이터 통합 분석 메타러닝 기술개발

·제 1세부과제명 : 이종 빅데이터 통합 분석을 위한 메타러닝 모델 및 응용 연구

·제 2세부과제명 : 딥러닝 기법을 이용한 이종 빅데이터 통합 처리 모델 개발

·제 3세부과제명 : 이종 빅데이터 통합 분석 메타러닝 소프트웨어 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

이 보고서를 “이종 빅데이터 통합 분석 메타러닝 기술 개발” 과제의 1단계 보고서로 제출합니다.

2018. 02. 26

주관연구기관명 : 동국대학교
주관연구책임자 : 김 준 태

공동연구기관명 : 중앙대학교
공동연구책임자 : 임 창 원

공동연구기관명 : (주)비아이매트릭스
공동연구책임자 : 황 선 민

협동연구기관명 : 덕성여자대학교
협동연구책임자 : 유 견 아

협동연구기관명 : 동국대학교
협동연구책임자 : 이 영 섭

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

보고서 요약서

<table>
<tr><td>과제고유번호</td><td>NRF-2017
M3C4A708
3279</td><td>해 당 단 계
연 구 기 간</td><td>2017.11.01. ~
2018.02.28</td><td>단 계
구 분</td><td>(1) / (2)</td></tr>
<tr><td rowspan="2">연 구 사 업 명</td><td>중 사 업 명</td><td colspan="4">차세대정보컴퓨팅기술개발사업</td></tr>
<tr><td>세부사업명</td><td colspan="4">차세대정보컴퓨팅기술개발사업</td></tr>
<tr><td rowspan="2">연 구 과 제 명</td><td>대 과 제 명</td><td colspan="4">이종 빅데이터 통합 분석 메타러닝 기술개발</td></tr>
<tr><td>세부과제명</td><td colspan="4"></td></tr>
<tr><td rowspan="2">연 구 책 임 자</td><td rowspan="2">김준태</td><td>해당단계
참 여
연구원수</td><td>총 : 24 명
내부 : 17 명
외부 : 7 명</td><td>해당단계
연 구 비</td><td>정부 : 110,000천원
기업 : 8,750 천원
계 : 118,750천원</td></tr>
<tr><td>총연구기간
참 여
연구원수</td><td>총 : 35명
내부 : 23명
외부 : 12명</td><td>총연구비</td><td>정부 : 1,934,000천원
기업 : 209,750천원
계 : 2,143,750천원</td></tr>
<tr><td>연구기관명 및
소 속 부 서 명</td><td colspan="2">동국대학교 컴퓨터공학과
중앙대학교 통계학과</td><td>참여기업명</td><td colspan="2">㈜비아이매트릭스</td></tr>
<tr><td>국제공동연구</td><td colspan="2">상대국명 :</td><td colspan="3">상대국연구기관명 :</td></tr>
<tr><td>위 탁 연 구</td><td colspan="2">연구기관명 :</td><td colspan="3">연구책임자 :</td></tr>
<tr><td colspan="4">요약</td><td>보고서면수</td><td>58면</td></tr>
<tr><td colspan="6">

- 본 1단계 연구는 연구과제의 최종 연구 목표인 “이종 빅데이터를 효과적으로 통합 분석하기 위한 메타러닝 방법론과 통계학습 및 기계학습 방법을 연구하여 이종 빅데이터 통합 분석 소프트웨어 원천 기술을 확보 (TRL 4)” 를 위한 기획연구임
- 제1세부에서는 이종 빅데이터 통합 표현 방법, 메타러닝 방법론, 강화학습 방법론을 연구하고 기초 실험을 수행하였음
- 제2세부에서는 이종 빅데이터 통합 처리를 위한 다양한 딥러닝 기법을 포함한 통계학습과 기계학습 방법론과 학습모델 정교화 방법을 연구하였음
- 제3세부에서는 이종 빅데이터 통합 분석을 위한 플랫폼 조사 연구와 라이브러리 및 소프트웨어 설계를 연구하였음
- 본 연구 수행 결과는 향후 2단계 연구 수행의 기초연구로 활용될 예정이며, 최종 연구 결과는 멀티모달 분류, 크로스모달 검색, 심층신경망 최적화, 음성 및 영상 데이터 통합 처리, 이종 빅데이터 분석 메타러닝 플랫폼 구축 등에 활용할 예정임

</td></tr>
<tr><td rowspan="2">색 인 어
(각 5개 이상)</td><td>한 글</td><td colspan="4">이종 빅데이터, 메타러닝, 통계 학습, 기계학습, 심층신경망, 정교화, 빅데이터 플랫폼, DLVM</td></tr>
<tr><td>영 어</td><td colspan="4">Heterogeneous Big Data, Meta Learning, Statistical Learning, Machine Learning, Deep Neural Network, Refinement, Big Data Platform, DLVM</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

요 약 문

Ⅰ. 제 목

이종 빅데이터 통합 분석 메타러닝 기술개발

Ⅱ. 연구개발의 목적

본 연구과제의 최종 연구 목표는 이종 빅데이터를 효과적으로 통합 분석하기 위한 메타러닝 방법론과 통계학습 및 기계학습 방법을 연구하여 이종 빅데이터 통합 분석 소프트웨어 원천 기술을 확보하는 것이다.

Ⅲ. 연구개발의 내용 및 범위

본 연구는 1단계 연구로서 각 세부과제별로 이종 빅데이터 통합 분석을 위한 기초조사 및 연구기획, 이종 빅데이터 통합 처리를 위한 이론 및 방법론 연구, 이종 빅데이터 통합 분석 라이브러리 조사 연구 및 소프트웨어 구조 설계를 수행하고 향후 2단계 연구를 위한 연구계획을 체계적으로 정립한다.

Ⅳ. 연구개발결과

본 연구를 통하여 1세부과제에서는 이종 빅데이터 통합 표현 방법, 메타러닝 방법론, 강화학습 방법론을 연구하고 기초 실험을 수행하였다. 2세부과제에서는 이종 빅데이터 통합 처리를 위한 다양한 딥러닝 기법을 포함한 통계학습과 기계학습 방법론과 학습모델 정교화 방법을 연구하였다. 3세부과제에서는 이종 빅데이터 통합 분석을 위한 플랫폼 조사 연구와 라이브러리 및 소프트웨어 설계를 연구하였다.

Ⅴ. 연구개발결과의 활용계획

본 연구 수행 결과는 향후 2단계 연구 수행의 기초연구로 활용될 예정이며, 최종 연구 결과는 멀티모달 분류, 크로스모달 검색, 심층신경망 최적화, 음성 및 영상 데이터 통합 처리, 이종 빅데이터 분석 메타러닝 플랫폼 구축 등에 활용할 예정이다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

S U M M A R Y

Ⅰ. Title

Development of Meta-Learning Technology for Integrated Analysis of Heterogeneous Big Data

Ⅱ. Purpose

The final goal of this research project is to develop the original software technology for integrated analysis of heterogeneous big data by studying the meta learning methodology, statistical learning and machine learning techniques.

Ⅲ. Contents and Scope

This study is the first stage of the project, and each subproject conducts basic research and planning, study of theory and methodology, study of library and software structure design for integrated analysis of heterogeneous big data, then establishes research plans for the next stages of the project.

Ⅳ. Research Results

Through this study, the first subproject studied the heterogeneous big data integration method, the meta learning methodology, and the reinforcement learning methodology, and conducted preliminary experiments. The second subproject studied statistical learning, machine learning methodology and learning model refinement method including various deep learning methods for heterogeneous big data integration processing. Third subproject studied platforms, libraries and software design for heterogeneous data integrated analysis.

Ⅴ. Utilization of research results

The results of this study will be used as a basic study for carrying out the second stage of the project. The final research result will be applied to multi-modal classification, cross-modal retrieval, deep neural network optimization, audio and video data integration processing, and building heterogeneous data analysis meta learning platform.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

C O N T E N T S

Chapter 1 Overview of R&D project ····· 7
Section 1 Goal of Research ····· 7
Section 2 Necessity of Research ····· 8

Chapter 2 Current technologies and research status ····· 9
Section 1 Domestic research ····· 9
Section 2 Overseas research ····· 10

Chapter 3 Research results ····· 12
Section 1 Research in the aspects of Computer Science ····· 12
1. Study on the meta-learning methodology for heterogeneous big data integrated analysis ····· 12
2. Experimental research for the integration of heterogeneous big data ····· 16
Section 2 Research in the aspects of Statistics ····· 19
1. Statistical learning and machine learning theory for heterogeneous big data integration processing ····· 19
2. Study on the deep learning method for heterogeneous big data integration processing ·· 22
3. Study on the learning model refinement method for heterogeneous big data processing ····· 24
Section 3 Research in the aspects of Software Development ····· 25
1. Study on the platforms for heterogeneous big data integrated analysis ····· 25
2. Study on the libraries and software design ····· 26

Chapter 4 Achievement of the goal and contribution to related fields ····· 29
Section 1 Research goals and evaluation focus ····· 29
Section 2 Evaluation of the achievement and their contribution ····· 30

Chapter 5 Utilization of research results ····· 32

Chapter 6 Overseas science and technology information collected ····· 35

Chapter 7 References ····· 36

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

목 차

제 1 장 연구개발과제의 개요 ····· 7
제 1 절 연구 개발의 목적 ····· 7
제 2 절 연구 개발의 필요성 ····· 8

제 2 장 국내외 기술개발 현황 ····· 9
제 1 절 국내 연구 동향 ····· 9
제 2 절 국외 연구 동향 ····· 10

제 3 장 연구 개발 수행 내용 및 결과 ····· 12
제 1 절 컴퓨터과학(Computer Science) 측면에서의 연구 내용 ····· 12
1. 이종 빅데이터 통합분석을 위한 메타러닝 방법론 연구 ····· 12
2. 이종 빅데이터 통합을 위한 실험적 연구 ····· 16
제 2 절 통계학(Statistics) 측면에서의 연구 내용 ····· 19
1. 이종 빅데이터 통합 처리를 위한 통계학습과 기계학습 이론 연구 ····· 19
2. 이종 빅데이터 통합 처리를 위한 딥러닝 기법 연구 ····· 22
3. 이종 빅데이터 처리를 위한 학습 모델 정교화 방법 탐색 ····· 24
제 3 절 소프트웨어 개발(Software Development) 측면에서의 연구 내용 ····· 25
1. 이종 빅데이터 통합분석을 위한 플랫폼 연구 ····· 25
2. 라이브러리 및 소프트웨어 설계 연구 ····· 26

제 4 장 목표달성도 및 관련분야에의 기여도 ····· 29
제 1 절 기획연구 연구목표 및 평가착안점 ····· 29
제 2 절 연구개발목표 달성도 및 기여도 평가 ····· 30

제 5 장 연구개발결과의 활용계획 ····· 32

제 6 장 연구개발과정에서 수집한 해외과학기술정보 ····· 35

제 7 장 참고문헌 ····· 36

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 1 장 연구개발과제의 개요

제 1 절 연구개발의 목적

본 연구과제의 최종 연구 목표는 이종 빅데이터를 효과적으로 통합 분석하기 위한 메타러닝 방법론과 통계학습 및 기계학습 방법을 연구하여 이종 빅데이터 통합 분석 소프트웨어 원천 기술을 확보하는 것이다. 이에 따른 각 세부과제의 연구 목표는 다음과 같다.

- 제1세부과제: 이종 빅데이터 통합 분석을 위한 메타러닝 방법론 및 응용 연구 (TRL 4)
  - 이종 빅데이터를 효율적으로 통합 분석할 수 있는 모델을 개발하고, 학습 모델의 성능을 최적화 시키는 다양한 메타러닝(meta-learning) 방법론을 연구하여 연구 개발의 결과를 다양한 도메인에 응용할 수 있는 원천 기술을 개발한다.
- 제2세부과제: 딥러닝을 이용한 독창적인 이종 빅데이터 통합 처리 모델 개발 (TRL 3)
  - 딥러닝 기법을 이용하여 이종 빅데이터 통합·처리를 효율적으로 하기 위한 모델을 개발한다. 이를 위하여 통계학습과 기계학습 방법에 대한 다양한 기법들을 연구하고 개발된 모델을 정교화하여 빅데이터 통합·처리기술을 고도화함으로써 최종적으로는 독창적인 이종 빅데이터 통합·처리를 위한 소프트웨어 개발의 원천기술이 되게 한다.
- 제3세부과제: 이종 빅데이터 통합 분석 메타러닝 소프트웨어 개발 (TRL 5)
  - 딥러닝 기법을 활용한 고급 분석 기능과 메타러닝 라이브러리를 개발하고 실제 응용할 수 있는 노드 형태로 패키징하여 당사 데이터분석 소프트웨어에 세부과제에서 연구 개발된 기술을 적용할 수 있는 Plug-in 모듈로 개발한다. 최종적으로 클라우드 플랫폼 환경에서 동작하는 응용 프로그램으로 개발하여 실제 산업계에서 사용 가능하도록 한다.

이에 본 1단계 기획연구에서는 향후 2단계 3개년의 체계적인 연구계획 정립을 위하여 세부 과제별로 다음과 같은 목표를 가지고 연구를 수행하였다.

🔳 제1세부과제 : 이종 빅데이터 통합 분석을 위한 기초조사 및 연구기획
- 이종 빅데이터 통합 표현 방법 탐색
- 이종 빅데이터 통합 분석을 위한 메타러닝 방법론 탐색
- 이종 빅데이터 통합 분석을 위한 딥러닝 모델 및 강화학습 방법론 탐색

🔳 제2세부과제 : 이종 빅데이터 통합·처리를 위한 이론 및 방법론 연구
- 이종 빅데이터 통합·처리 기술 이론 연구
- 이종 빅데이터 통합·처리를 위한 통계학습과 기계학습 이론 및 방법론 연구
- 신경망 모델과 딥러닝 기법 연구
- 이종 빅데이터 처리를 위한 학습모델 정교화 방법 탐색

🔳 제3세부과제 : 이종 빅데이터 통합 분석 라이브러리 조사 연구 및 SW 구조 설계를 위한 기초조사 및 연구기획
- 이종 빅데이터 통합 분석 플랫폼 조사 연구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 오픈소스 기반 머신러닝 라이브러리 조사 연구
- 이종 빅데이터 통합 분석 소프트웨어 구조 설계

제 2 절 연구개발의 필요성

Social media, e-commerce, health-care 등 다양한 분야에서 생산되는 데이터의 양이 폭증하고 유형이 다양화되면서 이러한 데이터를 수집, 처리, 분석하여 새로운 가치를 창출하는 빅데이터 분야에 대한 연구 개발이 활발히 진행되고 있다. 이종 빅데이터란 형태가 서로 다른 여러 종류 데이터들이 빅데이터를 이루고 있는 것을 말하는 것으로, 과거에는 빅데이터 분석 방법론과 관련하여 주로 수치화된 정형(structured) 데이터를 분석하는 데이터마이닝 방법들이 연구되었으나, 최근에는 텍스트, 이미지, 오디오, 비디오 등 다양한 형태의 비정형(unstructured) 데이터에 대한 처리 및 분석 기술에 대한 연구의 필요성이 점차 증가하고 있다. 이에 따라 경영, 의료, 과학, 보안 등 여러 분야에서 다양한 형태의 정형 및 비정형 데이터를 통합적으로 활용하려는 시도를 하고 있다. 하지만 대부분의 경우 서로 다른 종류의 데이터를 개별적으로 분석한 뒤, 그 결과를 통합하는 방식을 취하고 있으며, 이종 빅데이터를 통합적으로 분석하는 방법에 대한 연구는 아직까지 많이 이루어지지 않고 있는 실정이다.

이종 빅데이터 분석을 위해 기존 방법들의 여러 가지 문제점들을 해결하여 성능을 개선시키는 알고리즘의 개발도 중요하며, 이종 빅데이터 통합 분석을 위한 새로운 학습 모델의 개발도 필요하다. 또한 이종 데이터 분석에 사용되는 다양한 학습 모델들은 대량의 학습 데이터를 사용하므로 학습의 효율을 높이며 동시에 성능 또한 향상시키는 새로운 기술에 대한 연구가 필요고, 빠른 성능과 신뢰성이 요구되는 이러한 환경에 적합하고 다양한 형태의 이종 데이터를 처리할 수 있는 소프트웨어 플랫폼에 대한 연구도 필요하다.

이미지, 텍스트 등의 이종의 데이터에 대한 기계학습 기술로는 다양한 심층신경망 모델들이 우수한 성과를 보이며 집중적으로 연구되고 있다. 데이터 분석을 위한 심층신경망 기반의 기계 학습에 대한 연구가 어느 때보다 활발하게 이루어지면서 심층신경망의 학습 효율을 향상시킬 수 있는 '학습하는 방법을 학습하는' 메타러닝에 대한 관심도 점차 높아지고 있으며, 기계학습 분야의 새로운 연구 방향으로 부각되고 있다. 기계학습 분야 주요 학회인 ICLR, CVPR, ICML 등 주요 학회의 2017년도 논문의 키워드로는 학습(learning)이 가장 부분을 차지하며, 이외의 주요 연구키워드로는 적대(adversarial), 전이(transfer), 최적화(optimization), 강화학습(reinforcement learning) 등이 있다. 메타러닝은 기계학습의 모델을 학습시키는 방법을 학습하는 방법론으로서 학습방법의 최적화를 포함할 뿐 아니라, 구체적으로 강화학습, 전이학습 등을 통해 수행되기 때문에 최근의 연구 트렌드의 한 가운데에 있음을 확인할 수 있다.

특히 서로 다른 데이터타입으로 구성되는 이종 빅데이터의 효율적인 통합 분석을 위한 메타러닝 적용 방법은 미래 빅데이터 분석에 있어서 매우 중요한 핵심 기술이 될 것으로 예상된다. 이미 Google, Facebook, IBM 등의 글로벌 기업들은 미래의 혁신적인 IT 서비스를 창출하기 위하여 SNS 텍스트, 사진, 동영상, 소셜 네트워크 연결 정보 등 다양한 이종의 데이터를 통합하여 이용하는 기술들을 활용하고 연구하고 있으며, 따라서 이러한 분야의 새로운 원천기술을 확보해 나가는 것은 매우 시급하고도 중요한 연구개발 과제이다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 2 장 국내외 기술개발 현황

제 1 절 국내 연구동향

빅데이터와 관련된 국내 연구는 주로 정형 데이터의 저장, 처리, 분석과 관련된 연구들이 진행되고 있으며, 아직 이종 빅데이터의 통합 분석 방법론에 관한 연구는 활발히 이루어지지 않고 있다. 메타러닝(meta learning)과 관련해서는 전이학습, 강화학습, 생성적대 신경망 등이 최근에 연구주제로 부각되고 있고, 멀티뷰 러닝(multi-view learning)과 관련하여 딥러닝 모델을 응용한 연구들이 진행된 바 있으며, 이종 데이터 처리를 위한 분산 미들웨어에 대한 연구가 진행된 바 있다. 하지만 아직까지 비정형 이종 빅데이터에 대해서 통합 분석과 응용, 이종 빅데이터에 대한 분산 처리 플랫폼 등에 대한 연구는 미흡한 실정이다.

메타러닝 기법을 적용한 연구로 [11]에서는 전이학습과 강화학습, 생성적 적대 모델 등이 연구되었으며, 불균형 데이터 학습의 어려움을 극복하고자 전이학습을 적용하여 데이터 불균형의 문제를 해결하는 방법이 제안되었다. 강화학습 방법론을 적용하여 특정 모델 등을 최적화 하는 방법론의 한 예로 강화학습 방법론을 이용하여 토목 공정의 최적화를 수행하는 방안이 제시된 바 있으며 [12], 합성곱 신경망과 생성적대 신경망의 성능을 비교 분석하기 위하여 각 모델의 최대 신호 대 잡음비를 비교한 뒤, 각 모델의 특성과 한계점 등을 제시한 연구결과도 발표된 바 있다[13]. 이종 빅데이터 응용에 관한 연구로 추천시스템과 관련된 연구에서는 심층신경망 기반 저널 추천 시스템을 제안하여 기존 모델보다 추천 성능이 약 10%가량 우수한 결과를 제시하기도 하였다[16].

국내에서도 심층신경망 모델에 관해서는 다양한 연구들이 소개되고 있는데. 그 중에서도 멀티모달 이종 빅데이터와 관련된 몇몇 연구들이 제안된 바 있다. 먼저, 오디오 데이터와 관련하여 [14]에서는 멀티모달 딥러닝을 이용한 음악 장르 분류 연구에서 딥러닝 구조를 이용한 분류 모델을 제안하고 음악의 스펙트로그램 이미지에 대한 분석을 위해 CNN을, 음원의 연속적인 데이터에 대해 RNN을 사용하여 기존의 단일 딥러닝 방법보다 성능이 향상된 모델을 제시하였다. 비디오 데이터의 분류와 관련하여 멀티모달 개념 계층 모델을 이용한 만화비디오 콘텐츠 학습을 통한 등장인물 기반 비디오 자막 생성 연구에서는 영상 내 자막과 이미지로부터 얻은 이종 데이터를 결합하여, 등장인물들의 특성을 고려한 자막 생성 방법을 제시하고 이 과정에 순차적 베이지안 학습을 활용하였다[10].

이외에도 심층신경망 기반의 사운드 이벤트 분류[133], 생성적대망을 이용한 차량 번호판의 화질 개선[134], 딥러닝 기반 반복적 크롭핑을 이용한 사진 구도 개선 연구[135] 등 딥러닝을 다양한 비정형 데이터 분석에 사용한 연구들이 있다. 이종 빅데이터 분산 처리와 관련된 연구로는 MySQL 및 Hadoop 분산 시스템 기반의 하이브리드 분산 미들웨어를 개발하는 연구[9]가 수행된 바 있다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 2 절 국외 연구동향

국외에서는 메타러닝과 관련하여 인간의 학습 방법론을 모방한 다양한 종류의 k-shot 학습 계열의 학습 방법론들이 제안되고 있으며, 동종 및 이종 전이학습과 생성적대망에 대한 연구도 활발히 수행되고 있다. 또한 여러 형태의 이종 빅데이터 통합과 관련된 다양한 심층신경망 기반의 모델이 제안되고 있으며, 이종 빅데이터를 처리하기 위한 플랫폼 개발도 활발히 진행되고 있다.

대표적인 이종 빅데이터 통합 모델을 살펴보면 사전에 학습된 단어 벡터를 이용하여 이미지 데이터를 입력받은 신경망이 의미적으로 유사한 단어와 가깝게 임베딩되도록 학습되는 모델이 제안된 바 있다[17]. 또한, 이미지와 텍스트 데이터의 특성을 반영하여 이미지는 합성곱신경망을 이용하고 텍스트데이터는 완전연결신경망을 이용하는 이종 빅데이터 통합 임베딩 모델도 제안된 바 있다[18]. 최근 많은 주목을 받고 있는 생성적 적대 모델을 이용한 이종 빅데이터 통합 임베딩 모델이 제시되기도 하였다[19].

메타러닝 모델들로는 특정 레이블이 포함되지 않은 학습데이터를 이용해서 모델을 학습하더라도 테스트 데이터에 학습데이터에서 없었던 레이블에 대한 데이터가 입력되었을 때 분류할 수 있는 zero-shot 학습 방법론들이 제안된 바 있으며[20], 기존의 기계학습 또는 딥러닝에서 대량의 데이터로 학습을 수행하는 관점에서 전화하여 단 한 번의 학습으로도 효율적인 학습이 이루어질 수 있는 one-shot 학습 방법론이 제안되기도 하였다[4]. 메타러닝은 학습모델 이외에 메타 학습모델을 이용하는 경우도 있는데, one-shot 학습 방법론과 관련해서는 외부기억장치와 읽기 및 쓰기 기능을 갖춘 neural turing machine을 대상으로 one-shot 학습을 수행하여 필요로 하는 정보를 안정적으로 보존하는 것이 가능한 모델을 제안되기도 하였다[21]. 이러한 모델 기반 메타러닝 방법론 중 대표적인 연구로서 강화학습 방법론을 이용하여 메타 조절기를 학습시키는 형식으로 신경망의 최적의 구조를 찾는 방법이 제안되었다[22].

멀티뷰, 멀티모달 데이터의 처리와 관련하여, DGCCA (Deep Generalized Canonical Correlation Analysis) 알고리즘을 통해 임의적으로 많은 데이터 뷰(view)의 비선형 변환을 학습하여 뷰(view) 간에 최대한 정보를 제공하는 방법에 대한 연구가 수행된 바 있다[81]. 기존에는 비선형 두 개의 뷰(view) 표현 학습 (Deep CCA) 및 선형 다시점 표현 학습 (Generalized CCA)에 대한 방법이 존재하였지만 DGCCA는 Deep CCA의 비선형적 표현의 유연성과 독립적인 뷰(view)로부터 정보를 추출할 수 있는 통계적인 방법의 결합을 시도한 알고리즘이며, 기존 CCA 기반 알고리즘들이 두 개의 뷰(view)에 대한 학습에 머물렀지만 DGCCA는 두 개 이상의 뷰(view)를 학습 할 수 있는 방법을 제시하였다. [120]에서는 데이터의 형태마다 다른 통계적 특성이 존재한다고 보고 여러 개의 양식에 적용가능한 생성적인 멀티모달(Multi-modal) DBM을 제시하였고, 멀티모달 DBM을 통해 여러 개의 양식의 특징 추출이 가능하다고 주장하였다. MIR-flickr의 이미지와 텍스트, 오디오와 비디오 데이터에 대해 실험을 진행하여 Multiple-Kernel을 이용한 SVM이나 다른 신경망 알고리즘보다 뛰어난 성능을 보이고 있다.

새로운 이미지 캡션을 생성하기 위해 m-RNN(multi-modal Recurrent Neural Network) 모델을 제시한 연구에서는 이전 단어와 이미지가 주어진 단어를 생성하는 확률 분포를 직접 모델링하였다[108]. 문장에 대한 Deep RNN과 이미지 학습을 위한 Deep CNN으로 구성된 두 가지 네트워크가 서로 상호 작용하여 전체 m-RNN 모델을 형성하는 방식으로 학습을 하며, m-RNN 모델을 사용하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

여 이미지 또는 문장 검색을 위한 추출 작업을 위해 목적함수를 직접 최적화하는 하는 방법을 제시하였다. Autoencoder를 이용한 모델로는 휴대 전화가 위치 정보 액세스를 잃거나 센서가 충전 중일 때와 같은 상황에서 데이터 손실로 인해 데이터에 결측값이 있는 경우에 사용할 수 있는 멀티모달 Autoencoder(MMAE) 알고리즘이 제시된 바 있다[97]. 이 연구에서는 MMAE에서 특화된 디노이징 Autoencoder를 사용해 다중 양식(멀티모달) 데이터에서 결측값을 처리할 수 있다고 주장하였으며, MMAE를 사용하여 PCA(principal component analysis)보다 다중 양식 데이터의 결측값에 대해서 특징값(feature value)들을 예측함에 있어 더 좋은 예측력을 보여준다.

한 편으로는 딥러닝 모델에서 신경망의 응용효율성을 향상시키기 위한 신경망 압축(weight compression)기법 등이 연구되고 있다. 신경망 압축과 관련해서는 신경망 구조의 가지치기(pruning), 연결가중치의 양자화(quantization), 양자화된 가중치의 허프만 부호화(Huffman coding) 등의 일련의 신경망 압축과정을 통해 학습된 신경망 구조를 최적화하는 연구를 성공적으로 수행하여 신경망 응용에 있어서의 효율을 높인 결과가 제시되기도 하였다[23].

이종 빅데이터를 처리 플랫폼과 관련하여 최근에는 딥러닝을 효율적으로 수행하기 위한 프레임워크에 대한 연구 개발이 활발하게 이루어지고 있다[136][137]. 대표적인 딥러닝 프레임워크로는 Apache MLlib, H20, Google TensorFlow, Amazon Machine Learning, Caffe2, Microsoft DMTK 등이 있으며, 분산 플랫폼으로 Apache SINGA가 제안된 바 있다[138]. 딥러닝 모델은 언어 환경에 따라 새로운 라이브러리를 습득해야 하고 최적의 코드를 개발하기에 많은 시간을 필요로 한다. 또한 딥러닝 알고리즘은 대규모 데이터 집합을 사용하여 모델을 훈련하기 때문에 다량의 계산력과 성능, 신뢰성을 필요로 한다. 여러 가지 딥러닝 언어 환경에 구애받지 않고 해석 및 분석할 수 있으며, 수많은 이종 데이터 및 환경에 대해서 빠르게 처리하기 위해 딥러닝 프레임워크와 LLVM 기술을 적용한 DLVM(Deep Learning Virtual Machine)에 대한 연구가 이루어지고 있다[139].

딥러닝 프레임워크는 다량의 계산력, 성능 신뢰성을 확보하기 위해 내부적으로 계산 그래프(Computation Graph)를 보유하는 것이 필수적이다. 계산 그래프를 사용하기 위해서는 CPU와 GPU를 통합하여 사용하는 것이 보통이다. 과거에는 이 다량의 계산력을 사용하기 위해서 개발자들이 DSL(Domain, Specific Language)를 사용하여 계산 그래프를 직접 생성하였으나, 딥러닝이 발전하면서 계산 그래프를 사용하기 위한 GPU 활용가능 컴파일러 개발에 대한 연구의 필요성이 높아지고 있다. DLVM과 관련된 오픈소스 프로젝트로는 Google’s XLA, Amazon’s NNVM, Intel’s NGraph, HP’s CCT, IBM’s SystemML 등이 있다[141][142]

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 3 장 연구개발수행 내용 및 결과

본 연구과제는 이종 빅데이터를 통합 분석하기 위한 컴퓨터과학 측면에서의 연구(제1세부과제)와 통계학 측면에서의 연구(제2세부과제), 그리고 소프트웨어 개발 측면에서의 연구(제3세부과제)로 구성되어 있다. 이 장에서는 각 세부과제의 연구수행 내용을 간략히 정리하였다.

제 1 절 컴퓨터과학(Computer Science) 측면에서의 연구 내용

제1세부과제에서는 이종 빅데이터의 통합 분석을 위한 컴퓨터과학 측면에서의 연구로서, 메타러닝(Meta learning)의 개념을 중심으로 이종 데이터의 통합 임베딩 방법과 메타러닝 적용 방법에 대한 이론적인 연구와, 2단계 연구의 기초연구로서 실험적인 구현을 수행하였다. 주요 연구 내용은 다음과 같다.

- 이종 빅데이터 통합 방법론, 메타러닝(meta learning) 방법론, 강화학습(reinforcement) 및 양자화(quantization)를 이용한 학습 효율성(efficiency) 향상 등 이종 빅데이터 통합 분석을 위한 메타러닝 방법론 이론 연구
- Zero-shot 학습 기반 이종 빅데이터 통합 임베딩(embedding) 실험, 빅데이터 분석 성능향상을 위한 메타러닝 방법 적용, 심층신경망 효율성 제고를 위한 연결가중치 양자화, 이종 빅데이터 통합 분석을 위한 데이터셋 구축 등 이종 빅데이터 통합을 위한 실험적 연구

1. 이종 빅데이터 통합 분석을 위한 메타러닝 방법론 연구

본 연구에서는 우선 이종 빅데이터 통합 분석을 위한 기초 이론 연구로서 이종 빅데이터 통합 방법론, 메타러닝 방법론, 강화학습 및 양자화를 이용한 학습 효율성 향상 방법론 등 이종 빅데이터 통합 분석을 위한 메타러닝 관련 여러 방법론들을 조사 분석하였다. 그 내용을 요약하면 다음과 같다.

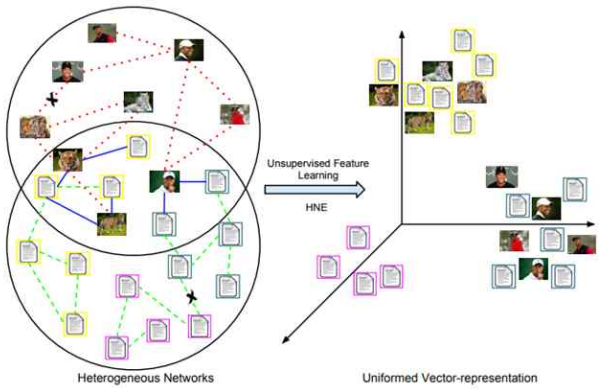
1) 이종 빅데이터 통합 방법론

- 이종 빅데이터를 통합 분석하기 위해서는 서로 다른 형식과 분포를 가진 데이터들을 그 의미적 관계를 유지하며 하나의 벡터 공간으로 매핑(mapping)시키는 작업이 필요한데, 이를 일반적으로 이종 빅데이터 통합 임베딩이라고 함.
- 특히 최근에는 심층신경망에 관한 연구가 활발히 수행되고 있으며, 입력되는 데이터의 특성에 따라 다양한 심층신경망 모델을 이용하여 이종 빅데이터 통합 임베딩을 수행하고 있음. [그림 1]은 이러한 이종 데이터의 임베딩 개념을 나타냄.
- 본 연구에서는 이러한 이종 빅데이터 통합 모델들에 대한 조사 연구를 수행하였음. 대표적인 방법으로 대량의 텍스트로부터 사전 학습된 단어들의 분산 벡터와 심층신경망으로 구성된 이미지 인식모델의 출력값이 서로 가까워지도록 학습을 수행하는 모델, 이미지 데이터의 경우에는 합성곱 신경망을 활용하고, 텍스트 데이터의 경우에는 완전연결 신경망 구조를 이용하여 ‘이

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

미지-이미지', '이미지-텍스트', '텍스트-텍스트' 등의 관계를 바탕으로 학습을 수행하는 모델 등이 있음.

- 한편으로 CM-GAN과 같이 생성적대 신경망을 기반으로, 이미지 생성 모델에서는 이미지 데이터를 입력받아 의미 표현을 얻고, 텍스트 생성 모델은 텍스트 데이터를 입력받아 의미표현을 얻은 후, 판별모델이 입력데이터의 출처를 구분하지 못하도록 학습함으로써 도메인 구분 없이 의미만을 반영하는 벡터로 표현하는 방식의 여러 모델이 있음.



[그림-1] 이종 빅데이터의 통합 임베딩

2) 메타러닝 방법론

- 메타러닝은 '학습하는 방법을 학습(learning to learn)' 한다는 의미로서, 학습 시스템이 경험을 통해 효율성을 증가시킬 수 있는 방법에 대한 연구라고 할 수 있음. 본 연구에서는 이종 빅데이터 통합 분석에 메타러닝의 여러 기법들을 적용시키기 위하여 앙상블 방법(ensemble methods), 전이학습(transfer learning), k-shot 학습(k-shot learning), 강화학습(reinforcement learning) 등 메타러닝의 여러 방식에 대한 조사 연구를 수행하였음.

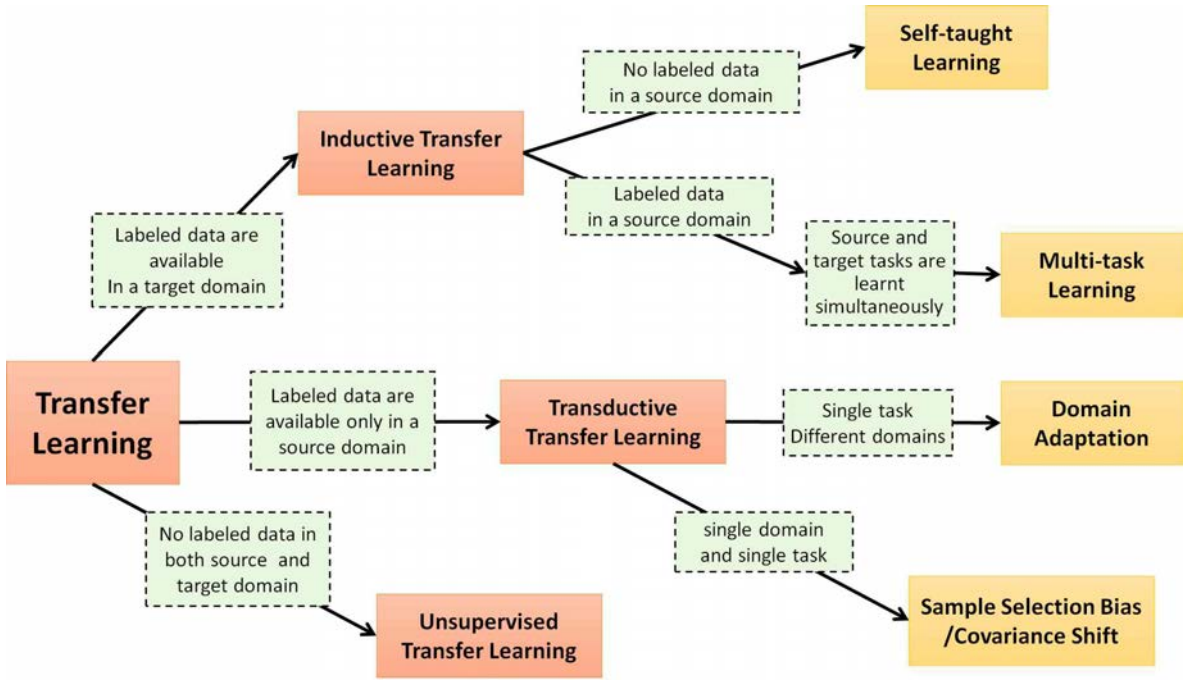
[표-1] 메타러닝의 주요 접근방식 및 핵심개념

접근방식	핵심개념
앙상블 방법 (ensemble methods)	어떤 문제에 대해 적용 가능한 학습 알고리즘이 여러 개 존재할 때 여러 학습 모델들의 조합하여 사용하는 방법
전이학습 (transfer learning)	학습 지식을 하나의 태스크 도메인으로부터 다른 도메인으로 전이시켜 학습을 수행하는 방법
k-shot 학습 (k-shot learning)	새로운 개념을 학습하는데 있어서 k개의 적은 학습데이터 만을 이용하는 학습 방법론
강화학습 (reinforcement learning)	데이터 중심 학습방식과 달리 에이전트가 행동에 대한 상태값과 보상값 등을 바탕으로 학습 모델을 학습하는 방법론

- 앙상블이란 어떤 문제에 대해 적용 가능한 학습 알고리즘이 여러 개 존재할 때 여러 학습 모델들의 조합을 사용하는 방법으로, 하나의 알고리즘을 선택하는 대신 이러한 조합을 사용하여 결과의 전부 또는 일부를 조합함으로써 전체 학습의 성능을 높일 수 있음. 앙상블의 주요방법론으로는 배깅(bagging), 부스팅(boosting), 스태킹(stacking) 등이 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 전이학습은 한 도메인에서 얻은 학습 모델을 이용하여 새로운 도메인에서의 학습을 향상시키는 방법으로, 학습데이터가 타겟 도메인에서 이용가능한지의 여부에 따라 귀납적 전이학습(inductive transfer learning)과 전환적 전이학습(transductive transfer learning)으로 구분할 수 있음. 귀납적 전이학습은 도메인에 관계없이 타겟 태스크가 소스 태스크와 다른 경우를 말하며, 전환적 전이학습은 소스 태스크와 타겟 태스크는 같으나, 소스 도메인과 타겟 도메인이 다른 경우를 말함. [그림 2]는 이러한 전이학습의 분류 체계를 나타냄.



[그림-2] 전이학습의 분류[5]

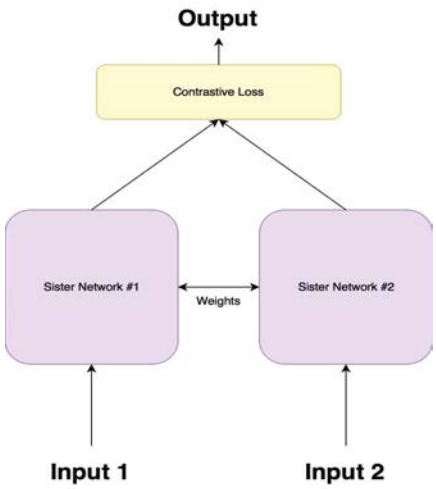
- 전이학습 중 도메인 적응(domain adaptation)은 타겟 도메인의 레이블되지 않은 데이터에 대한 분류기를 학습하기 위해 하나 이상의 소스 도메인에서 레이블된 데이터를 활용하는 전이학습의 특별한 경우에 해당하며, 다중언어 텍스트 분류나, 조건이 다른 이미지로부터의 물체 인식 등 다양한 문제에서 연구되고 있음.

- 동종전이학습은 소스와 타겟 도메인에서 속성 공간(feature space)은 동일하고 주변 확률 분포가 다른 경우 전이학습을 수행하는 것을 말하며 인스턴스 재가중치(instance reweighting), 파라미터 적응(parameter adaptation), 속성 보강 및 정렬(feature augmentation or alignment), 속성 변환(feature transformation) 등 다양한 방식에 대한 연구가 있음,

- 이종전이학습은 소스 및 타겟 도메인의 데이터가 다른 속성 공간을 가지고 있거나, 이미지 대 텍스트와 같이 다른 형식(modality)을 갖는 경우의 전이학습을 말함. 일반적으로 이종전이학습에 사용되는 방법들은 보조 데이터를 사용하며, 텍스트와 이미지의 동시 발생 데이터(co-occurrence data)에 기초하여 타겟 데이터를 소스 도메인의 시맨틱 공간(semantic space)으로 변환 하거나, 각 도메인을 공통 잠재 토픽(common latent topic)으로 매핑하는 방법 등을 사용함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 최근에는 딥러닝 모델들을 이용한 다양한 도메인 적응 방법들이 연구되고 있으며, 특히 전이학습을 위해 새롭게 고안된 딥러닝 모델을 사용하는 방법들이 많이 연구되고 있음. 이들은 많은 경우에 소스 및 타겟을 위한 두 개의 네트워크를 사용하는 Siamese 아키텍처와 유사한 구조를 가짐 [그림 3]. 불일치 기반(discrepancy-based) 방법은 Siamese 아키텍처의 두 개의 네트워크 활성층 사이의 불일치를 줄이는 방법이고, 적대 판별(Adversarial discriminative) 모델은 GAN의 개념을 이용하여 도메인 사이의 구분을 어렵게 하는 것이며, 파라미터 전이(Parameter transfer) 모델은 두 네트워크 사이의 일부 파라미터의 차이를 최소화 시키는 방법임.



[그림-3] Siamese 아키텍처 개념

- k-shot 학습 방법론은 zero-shot, one-shot, few-shot 등의 학습 방법론을 통칭하여 일컫는 개념임. Zero-shot 학습 방법론은 특정 모델의 학습 시 한 번도 학습한 적 없는 개념에 대해서 새롭게 입력되는 데이터를 처리할 수 있도록 학습하는 방법론을 의미하며, one-shot 학습과 few-shot 학습은 하나 또는 매우 적은 수의 학습데이터를 사용하여 학습을 수행하는 방법을 의미함.

- One-shot 학습을 위한 matching networks 등은 일종의 k-근접 이웃 분류기와 유사한 개념으로, 다른 클래스들의 데이터로 학습된 신경망에 새로 학습하려는 서브셋 학습 데이터를 제공하고 다른 쪽에서는 새롭게 분류하려는 데이터를 입력한 뒤, 입력 데이터에 대해 가장 유사한 서브셋 벡터의 레이블을 최종 레이블로 결정하는 방식을 사용함.

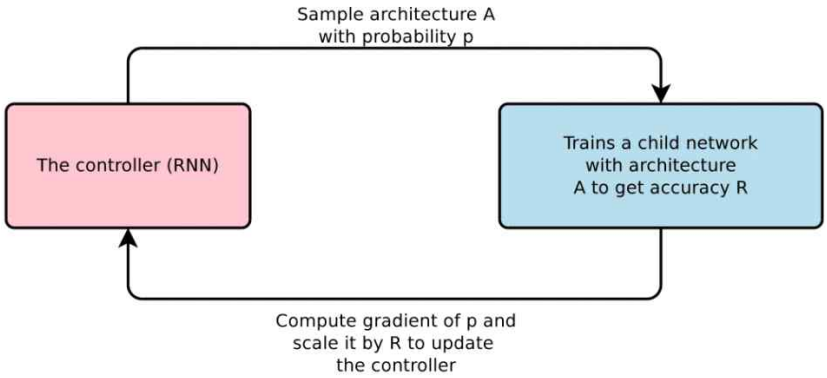
3) 강화학습 및 양자화를 이용한 학습 효율성 향상 방법

- 학습의 효율을 향상시키기 위하여 학습 모델의 파라미터들을 최적화하는 다양한 방법들이 연구되고 있음. 예를 들어 model-agnostic meta-learning은 메타러닝을 진행함에 따라 각 학습 단계의 매개 변수가 새로운 태스크의 최적의 매개 변수에 가까워지도록 최적화하는 방법임.

- 강화학습 방식은 학습의 최적화 뿐 아니라 가장 효율적인 학습모델의 구조 등을 찾는 방법론에도 적용될 수 있음. 강화학습 기반의 메타러닝 방법론은 최적의 학습모델 구조를 찾기 위해 학습모델의 성능을 강화학습의 보상(reward)으로 설정하고 에이전트의 액션을 메타러닝 조절기

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(controller)의 입력값으로 하여 학습모델의 학습 파라미터를 수정하는 방식으로 학습을 수행함. [그림 4]는 이러한 학습의 개념을 나타냄.



[그림-4] 최적의 신경망 구조를 찾기 위한 강화학습 기반 메타러닝

- 이종 빅데이터 통합 분석을 위한 심층신경망 기반의 다양한 모델들은 대용량의 데이터를 활용하여 모델을 학습시키고 응용하는 것이기 때문에 학습 연산량과 응용의 효율성 등은 필수적으로 고려해야하는 주요 연구 대상임. 이를 위해 신경망의 가중치를 양자화하여 단순하게 표현함으로써 계산량을 줄이려는 여러 연구들이 있음.

2. 이종 빅데이터 통합을 위한 실험적 연구

본 연구에서는 또한 이론적 연구내용을 바탕으로 크게 세 가지 실험적 연구를 진행하였다. 각 실험적 연구는 2단계 연구계획의 방향설정 및 검증을 위해 진행되었으며, 이러한 실험적 연구를 진행함으로써 향후 3개년의 연구계획을 보다 체계적으로 정리할 수 있었다. 실험적 연구에서는 정량적인 실험결과를 토대로 연구결과를 논문으로 정리하여 발표하였다. 첫 번째 실험적 연구는 zero-shot 학습이 가능한 이종 빅데이터 통합분석 임베딩 모델을 개발하는 것이다. 두 번째 실험적 연구는 전이학습의 측면에서 메타러닝 방법론을 이용하여 불균형 빅데이터 상황에서 학습모델의 학습효율을 향상시키기 위한 방법을 제안하였다. 마지막 연구는 신경망의 효율성 향상을 위한 신경망 연결가중치 양자화 방법을 제안하고 실험하였다.

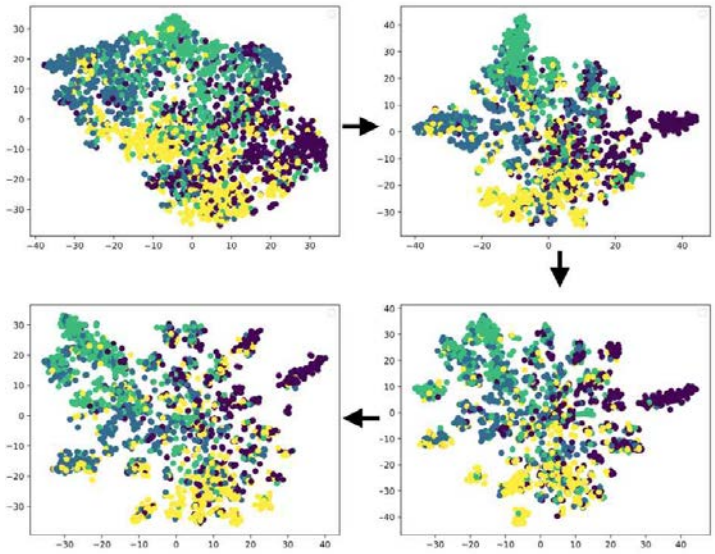
1) Zero-shot 학습 기반 이종 빅데이터 통합 임베딩

- 본 연구에서는 이미지 데이터와 텍스트 데이터를 통합 임베딩하는 모델을 Glove와 VGG19 변형 모델을 활용하여 구현한 후 실험을 수행하였음. 이미지 학습 모델은 합성곱 연산과 풀링 연산을 반복적으로 수행한 후 완전연결층을 거쳐 200차원의 벡터로 변환하였으며, 텍스트 학습 모델은 wikipedia 데이터와 Gigaword5 데이터를 활용하여 200차원의 벡터로 구성되었음. 이미지 벡터와 텍스트 벡터는 교차 엔트로피에 기반한 손실값에 따라 같은 대상을 의미하는 벡터의 거리는 가까워지도록 학습됨.

- 본 실험에서는 CIFAR-100 이미지 데이터셋의 6000개 이미지와 100개 클래스에 해당하는 텍스트 벡터를 사용하여 임베딩 실험을 수행하였으며, 학습 과정에서 이미지 벡터가 해당 클래스의

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

텍스트 벡터에 가까워지는 과정을 보이기 위하여 t-SNE를 이용하여 2차원 상에 결과를 시각화 하였음. [그림 5]는 시각화 결과의 일부로서 학습된 100개의 클래스에 대한 데이터 중 4개의 클래스에 해당하는 이미지 벡터들에 대해 임베딩이 진행되는 과정을 나타냄.

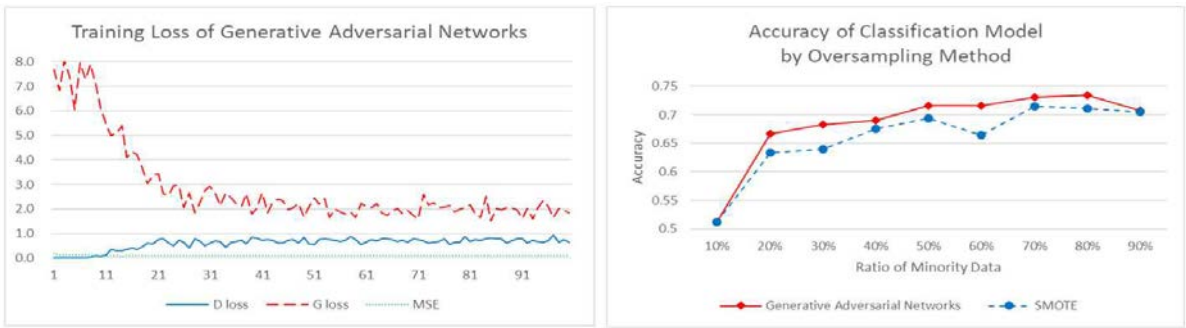


[그림-5] 텍스트 벡터와 같은 공간으로 이미지 벡터가 임베딩 되는 과정

2) 불균형 빅데이터 분석모델 성능향상을 위한 메타러닝 방법론

- 이종 빅데이터의 불균형성은 다양한 경우에서 발생하며, 학습모델의 성능을 하락시키는 주요한 원인 중 하나가 됨. 본 연구에서는 이러한 데이터 불균형의 문제를 해결하기 위하여 생성적 적대 신경망 모델을 이용한 학습 성능 향상 방법을 제안하고 실험하였음. 이 과정에서 생성모델의 손실값에 실제 데이터의 정보를 반영하여 그 차이가 최대화 되도록 하는 메타러닝의 기법을 적용하였음.

- 실험에서는 MNIST 필기체 숫자 데이터를 분류하는 학습모델의 학습 성능을 높이는 방법론을 비교하였으며, [그림 6]은 SMOTE(Synthetic Minority Over-sampling Technique)을 적용한 경우와 제안하는 방법론을 적용한 경우를 비교한 것으로, 불균형 비율을 10%에서 90%까지 변화시켜 학습했을 때 제안하는 모델의 성능이 더 높음을 확인할 수 있음.



[그림-6] 제안하는 모델의 학습로스 그래프(좌) 및 오버샘플링 방법 별 학습 성능비교(우)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3) 심층신경망 응용효율성 제고를 위한 연결가중치 양자화

- 이종 빅데이터 통합 분석을 위한 메타러닝 모델의 응용 효율성을 향상시키기 위한 신경망 연결가중치 양자화 방법론에 대하여 연구를 진행하였음. 제안하는 k-means 군집화 기반의 하이브리드 양자화 방법론은 학습된 신경망의 연결가중치를 추출하여 균일 양자화와 비균일 양자화를 순차적으로 수행함.

- 양자화에 관련된 실험은 AlexNet을 이용하여 양자화 방법론 별 객체인식모델의 성능비교를 수행하였다. 아래 표는 양자화 비트 및 양자화 방법론 별 객체인식모델의 성능을 나타내는 것으로서, 4비트의 양자화 비트에서도 원본 객체인식의 성능과 큰 차이가 나지 않는 것을 확인할 수 있음. 이와 같은 신경망 압축기법을 통해 본 연구에서 개발하는 이종 빅데이터 통합 모델의 응용 효율성을 향상시킬 수 있음.

[표-2] 양자화 비트 및 양자화 방법론 별 객체인식 모델 성능 비교

Quantization Bit	Quantizer	Quantization Error	Top-1 Accuracy (%)	Top-5 Accuracy (%)
-	Original	-	54.38	78.15
5bit	quantization	50157	50.6	76.05
	k-means	16348	53.91	77.72
	hybrid quantizer	17808	53.93	77.81
4bit	quantization	100276	6.48	15.99
	k-means	31362	51.94	76.06
	hybrid quantizer	32625	52.6	76.98
3bit	quantization	197422	0.17	0.55
	k-means	59103	31.65	55.38
	hybrid quantizer	59676	28.95	51.77
2bit	quantization	286478	0.13	0.42
	k-means	106499	0.59	2.29
	hybrid quantizer	108093	0.54	2.13

4) 이종 빅데이터 통합 분석을 위한 데이터셋 구축

- 이종 빅데이터 통합 연구를 수행하기 위해 이미지, 텍스트, 오디오, 비디오 등을 포함하고 있는 Microsoft COCO, NUS-wide, Flickr30k, XMedia, Yelp, NIH Chest X-ray, AudioSet 등 공개 데이터들을 수집하여 데이터셋을 구축하였음. 또한 CIFAR-10 이미지 데이터셋과 Google의 AudioSet 오디오 데이터를 결합하여 이미지, 텍스트, 오디오가 결합된 실험용 데이터셋을 구축하였음.

- 본 연구에서는 또한 한국어 텍스트를 포함한 이종 빅데이터 통합 연구 개발에 활용하기 위하여 한국어, 영어 각각에 대해 새로운 데이터셋들을 구축하는 과정을 진행하였음. 데이터는 웹 스크래핑(Web Scraping) 기법을 이용하여 수집하였으며, 한국어 데이터셋은 일반 사물 및 여행지에 대한 총 10만 건의 이종 데이터를 Twitter와 Instagram에서 수집하였고, 영어 데이터셋은 일반

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

사물 및 여행지에 대한 총 100만 건의 이종 데이터를 Flickr로부터 수집하였음.

제 2 절 통계학(Statistics) 측면에서의 연구 내용

제2세부과제에서는 이종 빅데이터의 통합 분석을 위한 통계학 측면에서의 연구로서, 멀티뷰 학습(Multi-view learning)의 개념을 중심으로 이종 빅데이터 통합 처리를 위한 통계학습과 기계학습 이론 연구와, 딥러닝 기법 연구, 그리고 이종 빅데이터 처리를 위한 학습 모델 정교화 방법 연구를 수행하였다. 주요 연구 내용은 다음과 같다.

- 이종 빅데이터 통합 처리 기술 이론, 정준상관분석(Canonical Correlation Analysis, CCA), 공동훈련(co-training), 교차 양식 순위(cross-modal ranking), 시공간 자료 분석(Spatial-temporal data analysis) 등 이종 빅데이터 통합 처리를 위한 통계학습과 기계학습 이론 연구
- 심층 정준상관분석(Deep Canonical Correlation Analysis, DCCA), 심층 교차 뷰 임베딩(Deep cross view embedding), 다중 양식 순환 신경망(Multi-modal RNN), 다중 양식 심층 볼츠만 머신(Multi-modal DBM) 등 이종 빅데이터 통합 처리에 딥러닝 기법을 활용하기 위한 연구
- 파라미터 최적화(Parameter Optimization), 통계적 방법을 이용한 모형 개선, 정규화(regularization)을 통해 과적합(overfitting) 문제 해결 등 이종 빅데이터 처리를 위한 학습 모델 정교화 방법 연구

1. 이종 빅데이터 통합 처리를 위한 통계학습과 기계학습 이론 연구

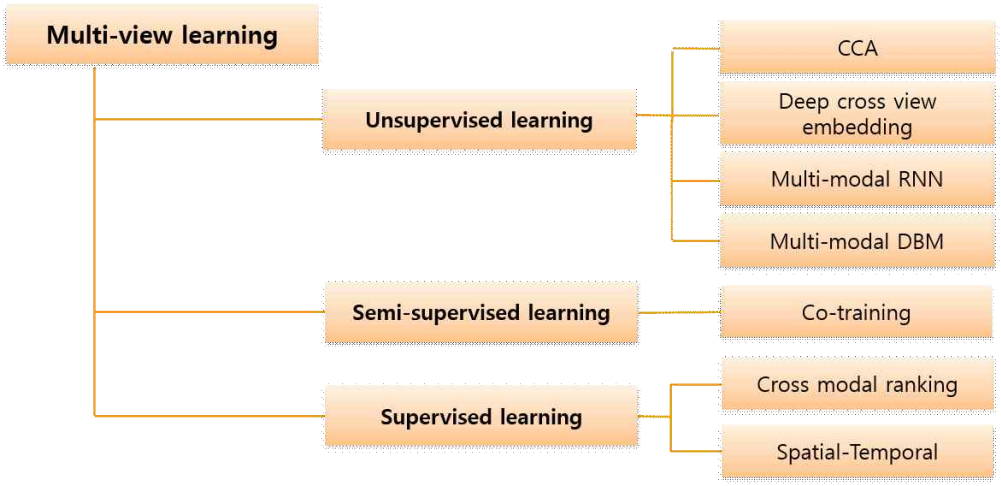
통계학습은 통계적인 모델을 이용하여 데이터를 학습시키고 특정 결과를 얻어내는 방법이다. 그리고 기계학습은 인공지능의 한 분야로 컴퓨터가 학습할 수 있도록 하는 알고리즘과 기술을 개발하는 분야이다. 이러한 방법론들을 통해 이종 빅데이터 통합·처리를 위한 여러 알고리즘이 활발히 연구 중이지만 상황마다 다른 학습 알고리즘을 사용해야하기 때문에 여러 알고리즘들에 대한 연구가 필요한 실정이다. 추후 이종 빅데이터 통합·처리의 기법 연구의 기반을 만들기 위해 기존 알고리즘들의 연구를 진행하였다. 그 내용을 요약하면 다음과 같다.

1) 이종 빅데이터 통합·처리 기술 개요 및 분류

- 멀티뷰 학습(Multi-view learning)은 이종 데이터 통합 처리를 위한 방법 중 하나이며 멀티뷰 데이터를 이용한 학습 방법임. 멀티뷰 데이터란 하나의 관측치를 여러 개의 특징(feature)들로 표현한 데이터로서, 이러한 멀티뷰 데이터를 통합하고 처리하는 멀티뷰 기법들이 연구되어지고 있음.
- 기계학습 방법론은 데이터에 대한 목표값(label)이 주어지지 않은 상태에서 데이터가 어떻게 구성되었는지를 학습할 때 사용하는 비지도 학습(Unsupervised learning), 목표값(label)이 표시된 데이터와 표시되지 않은 데이터를 모두 훈련에 사용하는 방법인 준지도 학습(Semi-supervised learning), 분류(classification)와 회귀(regression)를 위해 훈련 데이터(training data)로부터 하나의 함수를 유추해내는 방법인 지도 학습(Supervised Learning) 등 세 가지 관점에서 접근할 수 있

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

음. [그림 7]은 기존 멀티뷰 기법들을 기계학습 방법론에 따라 분류한 것임.



[그림-7] 멀티뷰 학습 기법의 분류

2) 정준상관분석(Canonical Correlation Analysis, CCA)

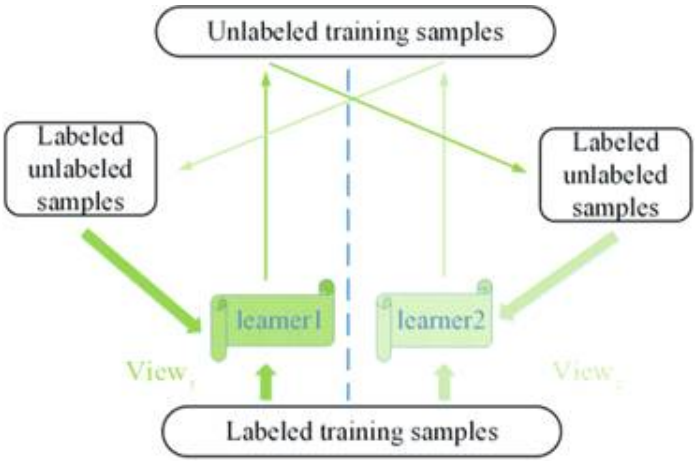
- 정준상관분석은 전통적인 통계 방법으로 다변량 데이터에서 두 변수 집단 사이에 존재하는 상관관계를 설명하는데 주로 사용됨. 이 기법은 이종데이터에서 여러 가지의 뷰 사이의 관련성을 효과적으로 모형화 하는데 사용될 수 있음. 아래 식을 보면 정준상관분석은 뷰1과 뷰2에 대해 각각 선형적인 상관관계를 최대화하는 가중치 벡터 w_x, w_y를 찾는 알고리즘임.

$$p = corr(w_x^T X, w_y^T Y) = \frac{w_x^T C_{xy} w_y}{(w_x^T C_{xx} w_x)(w_y^T C_{yy} w_y)}$$

3) 공동훈련(co-training)

- 공동훈련 알고리즘은 준지도학습에서 사용하는 전통적인 알고리즘이며 레이블(목표값)이 적은 데이터를 통해 레이블이 없는 데이터의 레이블을 학습 할 때 사용할 수 있는 방법임. 각 데이터의 뷰(View)를 두 개의 다른 뷰로 나누어 두 가지의 충분성(sufficiency)과 조건부 독립성(conditional independency)을 가정하고 각 뷰마다 각각의 분류기(Classifier)를 학습 시켜 데이터마다 다른 특징(feature)을 학습하게 됨. [그림 8]은 공동훈련 알고리즘의 학습 과정을 나타냄.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림-8] 공동훈련 알고리즘의 학습 과정

3) 교차 양식 순위(cross-modal ranking)

- 지도 학습 기법인 교차 양식 순위는 멀티뷰 학습을 검색 시스템에 적용한 방법으로, SSI(Supervised Semantic Indexing)는 교차 양식 순위 방법 중 하나임. SSI는 어떤 검색어를 입력했을 때 해당 단어를 가장 잘 반영하는 이미지를 찾는 것을 목적으로 함. 아래 수식은 SSI의 기본적인 모형으로서 f는 텍스트 쿼리 q벡터와 이미지 벡터 d와의 유사성(similarity)을 측정하는 함수로 가중치 W를 결합함으로써 계산됨. 가중치 W는 아래 수식을 최소화함으로써 텍스트와 관련이 있는 이미지인 d+의 함수 값이 텍스트와 관련 없는 d- 함수 값보다 크게 되는 방향으로 학습됨.

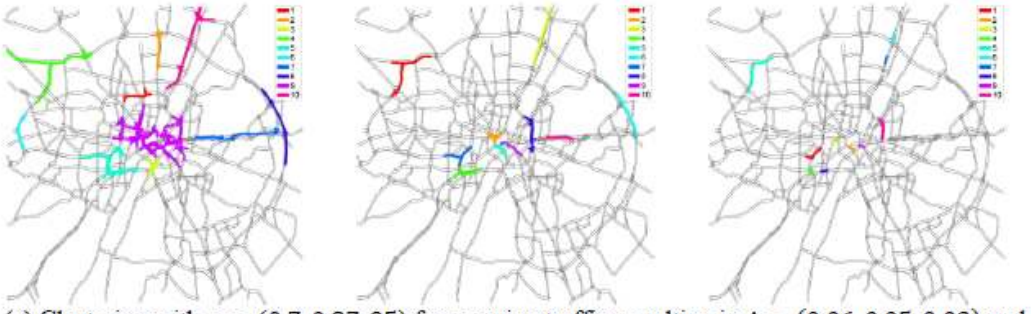
$$f(q,d)=q^{T}Wd=\sum_{i=1}^{m}\sum_{j=1}^{n}q_{i}W_{ij}d_{j},\ \ q\in R^{m},d\in R^{n},\ \ f(q,d^{+})>f(q,d^{-})$$

$$\sum_{(q,d^{+},d^{-})}\max(0,1-q^{T}Wd^{+}+q^{T}Wd^{-})$$

4) 시공간 자료 분석(Spatio-temporal data analysis)

- 시공간 자료 분석은 다양한 문제에 적용되며, 예를 들어 지역 교통역학(traffic dynamics)은 주어진 시공간 데이터를 통해 교통의 혼잡도를 인식하고 사전의 네트워크를 구축하려는 영역의 연구임. 개별의 혼잡 지역들(segments)을 파악하고 이 혼잡한 지역들을 연결한 구간인 pocket을 그리고, 그 구간들이 공통으로 나타나는 지역을 찾는 방법을 사용하여 클러스터링을 수행함. [그림 9]는 뮌헨의 교통 데이터를 이용해 교통 혼잡도를 파악한 예임.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



(a) Clustering with $\alpha = (0.7, 0.87, 95)$ for morning traffic, resulting in $\Delta = (0.06, 0.05, 0.03)$ and $\rho = (0.97, 0.97, 0.93)$

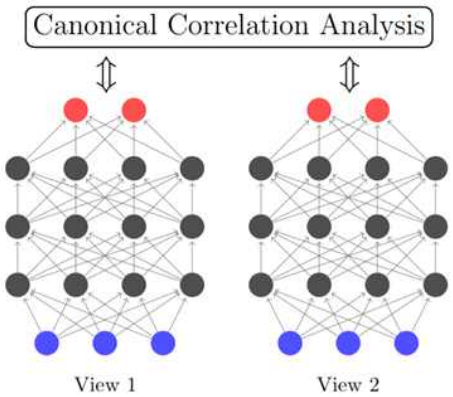
[그림-9] 교통 혼잡도 클러스터링

2. 이종 빅데이터 통합 처리를 위한 딥러닝 기법 연구

딥러닝 기법은 신경망을 기반으로 심층적인 표상을 학습할 수 있어 분야마다 다양한 알고리즘이 뛰어난 성능을 보이고 있다. 이와 마찬가지로 이종 빅데이터 통합·처리에 있어서 딥러닝 기법을 통해 학습의 성능을 향상시킬 수 있는 방안을 연구하였다.

1) 심층 정준상관분석(Deep Canonical Correlation Analysis, DCCA)

- 심층 정준상관분석은 두 개의 뷰에 대해 동시에 두 개의 심층적인 비선형 맵핑을 통해 두 뷰 간의 연관성을 최대화하는 방법을 학습함. [그림 10]은 심층 정준상관분석의 학습 도안으로 각각의 뷰를 딥러닝 알고리즘을 통해 학습한 후 그 출력값의 상관성을 극대화하는 학습과정을 나타냄.



[그림-10] 심층 정준상관분석의 학습도안

2) 심층 교차 뷰 임베딩(Deep cross view embedding)

- 심층 교차 뷰 임베딩이란 심층신경망 등의 다양한 딥러닝모형을 이용하여 서로 다른 데이터 형태를 결합하는 방법임. 두 개의 데이터 형태에서 학습된 각각의 심층신경망을 통합, 연결하는 모델로서 주로 이미지(image)와 텍스트(text)에 대한 연구가 진행되어 왔음. 시각적 모델과 언어 모델의 결합에서의 학습은 아래와 같은 loss function을 적용할 수 있음. 여기서 v(image)는 시각 모델의 출력이고, t는 텍스트의 행벡터, M은 선형변환 행렬임.

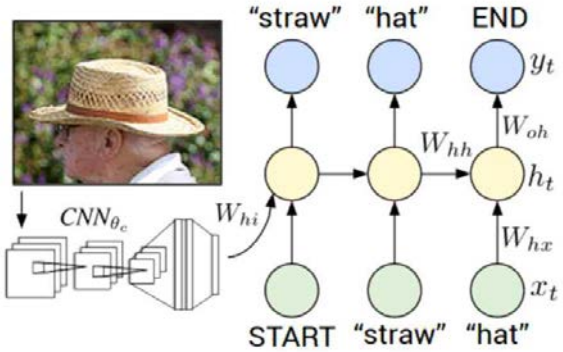
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

$$loss(image, label) = \sum_{j \neq label} \max[0, margin - \vec{t}_{label} M\vec{v}(image) + \vec{t}_j M\vec{v}(image)]$$

3) 다중 양식 순환 신경망(Multi-modal RNN)

- RNN encoder-decoder 모형은 RNN과 multi-modal sequence를 결합하여 개발된 모형임. 제안된 모델의 encoder와 decoder는 연속성을 갖는 입력 데이터가 주어졌을 때 연속성을 갖는 타겟 데이터의 조건부 확률을 최대화하기 위해 공동으로 학습을 수행함.

- Multi-modal RNN은 이미지(image)와 주석(text)이 함께 존재하는 데이터의 학습을 통해서 이미지가 주어졌을 때 변수 크기의 연속적인 예측을 할 수 있는 모형임. 일반적인 Multi-modal learning과의 차이점은 입력 이미지의 내용에 대한 생성 프로세스를 추가로 조건 한다는 것임. [그림 11]은 Multi-modal RNN의 예시를 나타냄.



[그림-11] Multimodal RNN의 예시

4) 다중 양식 심층 볼츠만 머신(Multi-modal DBM)

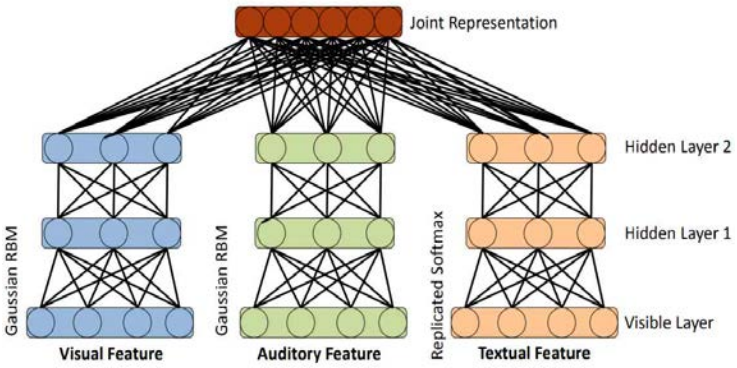
- Multi-modal DBM(Deep Boltzmann Machine)은 2개 이상의 이종 데이터의 특징(feature)을 추출한 후 결합하여 여러 데이터 형식 간의 상관관계를 학습하는 알고리즘임. 학습된 알고리즘은 분류와 정보 검색에 유용하며, 각 데이터 형식에 대한 조건부 분포에서 샘플링을 수행하면 일부 데이터 형식이 누락된 경우에도 표현(Representation)을 생성할 수 있다는 장점이 있음.

- 학습 과정은 Multi-modal DBM의 각 RBM구성 요소에서 계층별로 사전훈련을 하여 미리 학습한 다음 학습된 매개변수를 사용하여 Multi-modal DBM의 모든 계층의 매개변수를 초기화하고, Multi-modal DBM은 서로 다른 양식을 통합된 방법으로 미세 조정(fine tune)하도록 학습됨. 아래 수식은 Multi-modal 입력에 대한 결합 분포로서 이 분포를 기반으로 할 때, 로지스틱 함수를 통해 추출한 최종 특징으로 결합 표현 계층에 대한 조건부 분포를 쉽게 유추할 수 있음. [그림 12]는 세 가지 종류의 데이터 특징을 결합한 Multi-modal DBM 모델을 예시임.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

$$P(V^m, V^a, V^t;\theta) =$$

$$\sum_{h^{(2m)},h^{(2a)},h^{(2t)},h^{(3)}} P(h^{(2m)},h^{(2a)},h^{(2t)},h^{(3)})(\sum_{h^{(1m)}} P(v^m,h^{(1m)},h^{(2m)}))(\sum_{h^{(1a)}} P(v^a,h^{(1a)},h^{(2a)}))(\sum_{h^{(1t)}} P(v^t,h^{(1t)},h^{(2t)}))$$



[그림-12] 이미지, 오디오, 텍스트 특징을 결합한 Multi-modal DBM 모델

3. 이종 빅데이터 처리를 위한 학습 모델 정교화 방법 연구

본 연구에서는 이종 빅데이터 처리를 위한 학습 모델의 정교화와 관련하여 파라미터 최적화 방법, 통계적 방법을 이용한 모형 개선 방법, 정규화(regularization)을 통한 과적합(overfitting) 문제 해결 방법 등을 연구하였다.

1) 파라미터 최적화(Parameter Optimization)

- EM 알고리즘은 불완전 데이터(Incomplete Data)에 대해서도 최대 우도 추정치를 찾아 낼 수 있어 결측값을 찾는 데에도 사용할 수 있음. 클래스 레이블을 결측값으로 보면 준지도 학습에도 EM 알고리즘의 적용이 가능함. 이를 멀티뷰 기법에 적용한 co-EM은 뷰1으로 먼저 EM 알고리즘을 이용하여 레이블을 생성한 뷰1의 레이블과 뷰2의 데이터를 이용하여 뷰2의 레이블을 생성할 수 있음.

2) 통계적 방법을 이용한 모형 개선

- 실제 세계에서는 멀티뷰 데이터 간의 비선형성이 존재하는 경우가 많아 선형적인 임베딩이 멀티뷰 데이터의 특성을 잡아내기 어려울 때가 많음. 커널 방법(Kernel Method)은 통계학의 비모수적 방법에서 데이터의 불확실한 분포를 추정할 때 사용하는 방법으로, 커널 추정을 할 때 사용하는 비선형적인 커널 함수로 데이터 간의 비선형적인 관계를 고려할 수 있음.
- 이를 CCA 알고리즘에 접목하여 CCA 알고리즘이 단순히 뷰 사이의 선형성만을 고려하는 문제를 극복할 수 있음. 아래 수식과 같이 KCCA는 CCA의 선형적인 방법에 커널화(Kernelization)를

통한 비선형성을 도입하는 방법으로 CCA의 확장된 방법이라고 할 수 있음.

$$\arg max_{\alpha_x,\alpha_y} \frac{\alpha_x^T K_x K_y \alpha_y}{(\alpha_x^T K_x^2 \alpha_y)(\alpha_x^T K_y^2 \alpha_y)} = \arg max_{\alpha_x^T K_x^2 \alpha_x = \alpha_y^T K_y^2 \alpha_y} \alpha_x^T K_x K_y \alpha_y$$

3) 정규화(regularization)을 통한 과적합(overfitting) 문제 해결

- 모형의 정규화는 기계 학습과 통계 학습에 있어서 모형의 과적합을 피하고 일반적인 상황에도 모형이 잘 작동하도록 하는 방법으로서 모형의 정확성을 보존하면서 모형의 복잡성을 줄일 수 있는 방법임.
- co-regularization은 co-training에서 확장되어 라벨이 되지 않은 데이터에 대해 학습할 때 각각의 뷰에 정규화 항을 추가하여 학습하는 방법으로, 하나의 분류기가 아닌 각각의 관측(View)에서 학습한 분류기를 같이 정규화하여 모형을 구축함. 다음의 수식을 최소화하는 (f_*^1, f_*^2)을 학습함으로써 과적합 문제를 해결할 수 있음.

$$(f_*^1, f_*^2) = \min_{f^1 \in H^1, f^2 \in H^2} \gamma_1 \| f^1 \|_{H^1}^2 + \gamma_2 \| f^2 \|_{H^2}^2 + \mu \sum_{i \in U} [f^1(x_i) - f^2(x_i)]^2 + \sum_{i \in L} V(y_i, f(x_i))$$

제 3 절 소프트웨어 개발(Software Development) 측면에서의 연구 내용

제3세부과제에서는 이종 빅데이터의 통합 분석을 위한 소프트웨어 개발 측면에서의 연구로서, 이종 빅데이터 통합분석을 위한 플랫폼에 대한 연구와, 라이브러리 및 소프트웨어 구조 설계 관련 연구를 수행하였다 주요 연구 내용은 다음과 같다.

- 주요 빅데이터 플랫폼 및 관련 기술 및 가상머신 구조 연구, DLVM(Deep Learning Virtual Machine) 기술 연구 등 이종 빅데이터 통합 분석을 위한 플랫폼에 대한 연구
- DLVM 적용 프레임워크 설계, Apache SINGA, Google XLA, IBM SystemML 등 딥러닝 분산 처리 기술 등 라이브러리 및 소프트웨어 설계 연구

1. 이종 빅데이터 통합 분석을 위한 플랫폼 연구

1) 주요 빅데이터 플랫폼 및 관련 기술

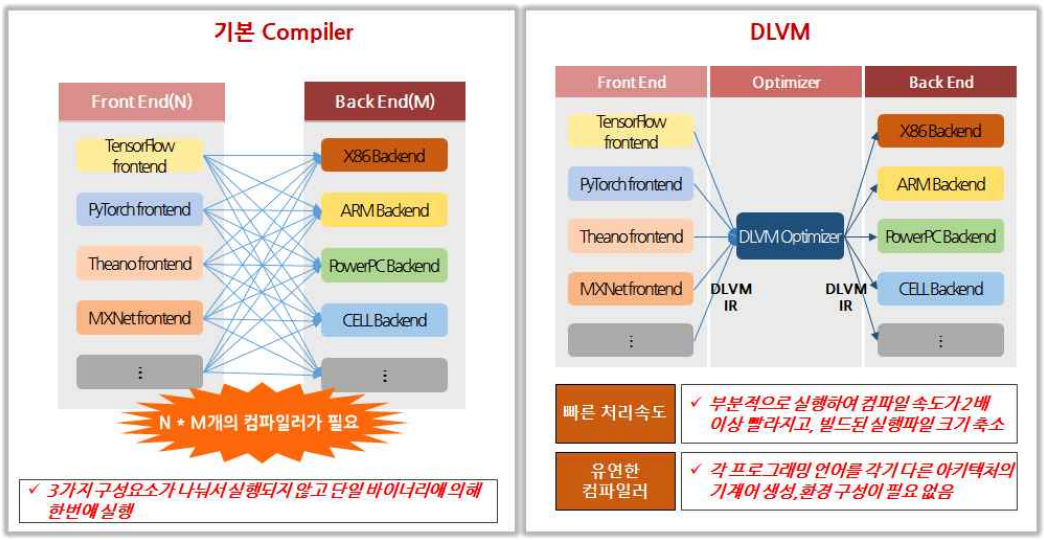
- 아파치 스파크, H20, Apache SINGA, Google TensorFlow, Amazon Machine Learning, Caffe2, 마이크로소프트 DMTK, 삼성 Veles, mlpack2 구조 및 기술 조사를 수행하였음. 초기에는 이종 빅데이터를 수집/저장에 초점이 있었다면 현재는 데이터 분석을 위한 기계학습과 딥러닝 기능을 탑재한 플랫폼이 주류를 이루고 있음. 이종 데이터를 분석하기 위해서 다양한 딥러닝 모델들이 사용되고 있고 수많은 모델들을 지원할 수 있는 빠르고 신뢰성이 높은 플랫폼 개발 필요성이 높아짐.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) DLVM(Deep Learning Virtual Machine) 기술

- 수많은 딥러닝 언어 환경에 구애받지 않고 해석 및 분석을 수행할 수 있으며, 수많은 이종 데이터 및 환경에 대해서 빠르게 처리하기 위해서 DLVM 개발은 필수불가결 함. 딥러닝 프레임워크와 LLVM 기술을 적용한 컴파일러가 혼합되어 DLVM로 발전함. 언어 환경에 구애받지 않을 뿐만 아니라 Back-End의 GPU을 충분히 활용할 수 있도록 하기 위해서 DLVM 기술이 연구되고 있음.

- 기존의 컴파일러는 중간언어가 존재하지 않아 각 코드환경에 맞는 컴파일러가 필요하였으며, Front-End와 Back-End의 수에 따라 기하급수적으로 필요 컴파일러 수가 증가함. DLVM은 중간언어로써 Front End의 환경에 상관없이 Optimizer가 분석하고 각 Back End 환경에 맞는 IR을 생성하여 전송함. 특히 딥러닝은 Back-End CPU를 사용하는 것보다 GPU 환경에서 더 빠른 처리 속도가 나타나고 있어, CPU와 GPU를 통합적으로 사용할 수 있도록 하는 것이 중요함. 각 언어별 각기 다른 아키텍처의 기계어를 생성하거나 환경 구성이 필요 없어 대용량 이종 데이터 분석에는 필수적 요소임. [그림 13]은 기본 컴파일러와 DLVM을 비교하여 나타냄.



[그림-13] 기본 컴파일러와 DLVM 비교

2. 라이브러리 및 소프트웨어 설계 연구

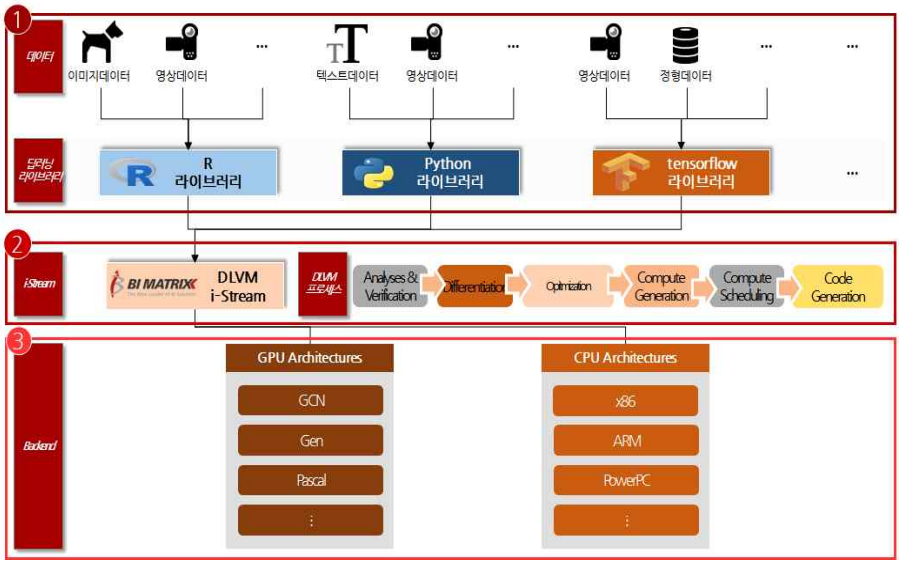
1) DLVM 적용 프레임워크 설계

- 수많은 딥러닝 개발 언어 및 환경이 존재하며, 그에 따른 셀 수 없는 수의 라이브러리가 생성되어 딥러닝 라이브러리 표준화가 필요함. 이종 빅데이터에 대한 라이브러리 표준화를 위해 우선적으로 영상, 음성 데이터의 입출력 컴포넌트 개발하여 데이터 형태와 상관없이 분석할 수 있는 DLVM 적용 컴파일러를 개발하고, 데이터 소스 분석부터 코드 생성까지 처리할 수 있는 표준 프로세스 개발이 필요함.

- 1세부, 2세부 원천 기술을 적용할 수 있는 이종 빅데이터 분석 플랫폼으로 SINGA 플랫폼과 그 외 빅데이터 플랫폼을 분석하여 이종 빅데이터 분석을 위한 기능 및 개발 컴포넌트를 도출하

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

고, Google’s XLA과 IBM’s SystemML의 장점을 통합한 컴파일러 개발 방향을 도출함. [그림 14]는 DLVM 연구개발 프레임워크를 나타냄.

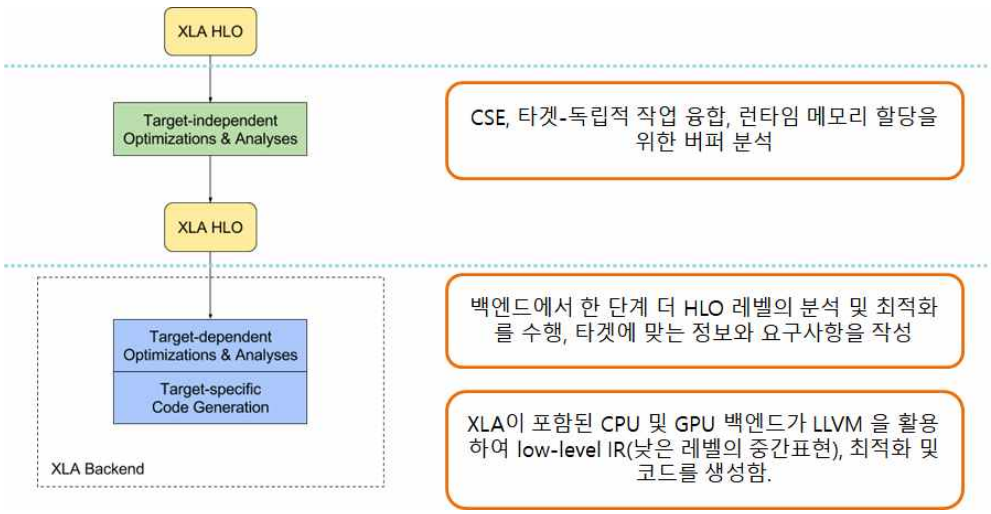


[그림-14] DLVM 연구개발 프레임워크

2) 대표적인 딥러닝 플랫폼 구조 분석

- Google XLA는 효율적인 최적화 및 연산, CPU와 GPU를 활용을 위한 분산 방식을 적용하여 개발된 컴파일러임. 특히 LLVM의 중간 언어 개념을 적용하여 최적화된 Deep learning 컴파일러를 개발하여 실행속도 향상, 메모리 사용향상, 유저 작업 의존도 감소, 이동 용량 감소, 이식성 향상 목적을 달성함.

- XLA는 input 언어인 HLO IR(High Level Optimizer Intermediate Representation)와 Target-independent Optimizations & Analyses, XLA Backend로 구성됨. HLO에서 정의된 계산 그래프를 받아서 다양한 Back-end로 보내기 위해서 컴파일하는 형태임. [그림 15]는 Google XLA의 구조를 나타냄.

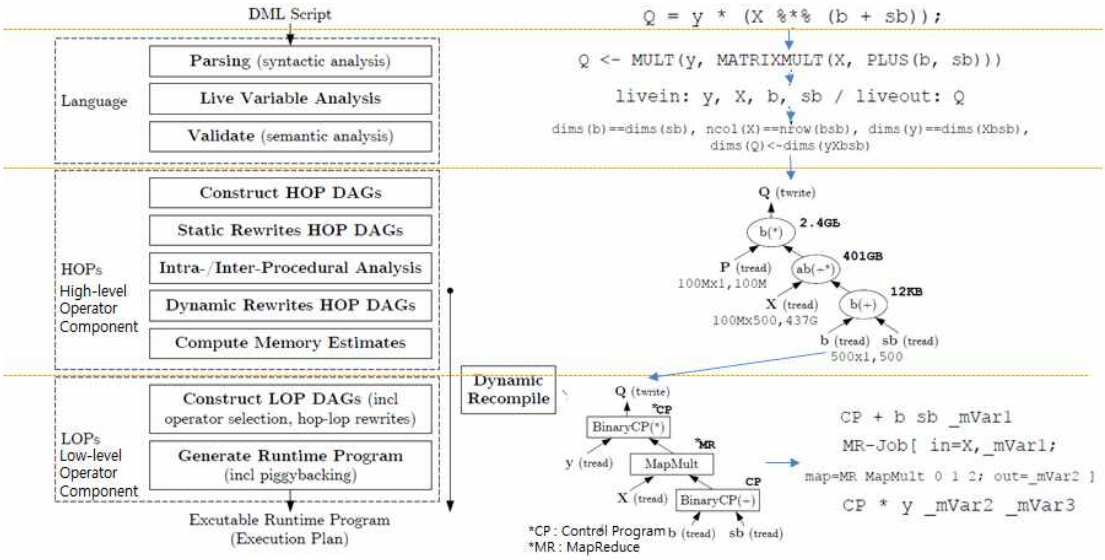


[그림-15] Google’s XLA의 아키텍처

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- Large-scale Machine Learning 중요성이 높아짐에 따라 DML 형태의 언어 환경이 지속적으로 증가하고 있으며, 이에 따라 DML 컴파일 및 Cost Based Rule 재작성 컴파일러가 중요하게 됨. 다양한 데이터를 분석할 수 있는 DML 형태의 도구가 계속적으로 증가하여 이를 표준화하여 어떤 환경의 도구도 컴파일할 수 있는 컴파일러가 필요하게 됨.

- IBM SystemML은 데이터 사이언티스트가 분석한 내용을 Scala 형태로 변환하는 시스템 프로그래머의 역할을 대체하기 위해서 개발됨. 일반적인 기계학습 컴파일은 Script, Operator DAG(Directed Acyclic Graph), Runtime plans으로 구성되어 있으나, SystemML은 DML 형태의 Script, 언어 분석, HOPs(High-level Operator Component), LOPs(Low-level Operator Component), Runtime plan으로 구성됨. [그림 16]은 SystemML의 컴파일에 대한 예시임.



[그림-16] SystemML 컴파일 예시

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 4 장 목표달성도 및 관련분야에의 기여도

제 1 절 기획연구 연구목표 및 평가착안점

이번 1단계 기획연구에서는 향후 3개년의 체계적인 연구계획 정립을 위하여 이종 빅데이터 통합 분석을 위한 기초조사 및 연구기획을 수행하였다. 본 연구에서 계획했던 기획연구 단계에서의 세부연구 목표와 세부연구개발 내용, 그리고 평가목표 및 착안점은 다음의 [표 3]과 같다.

[표-3] 기획연구 단계 세부연구 목표

구분	연구기간	세부연구목표	세부연구개발내용	평가목표 및 착안점	가중치 (연구비)
기획연구	2017.11.01. ~ 2018.02.28. (4개월)	이종 빅데이터 통합 분석을 위한 기초조사 및 연구기획	이종 빅데이터 통합 표현 방법 탐색	이종 빅데이터 통합 표현 방법론을 적절히 연구 하였는가?	10%
			이종 빅데이터 통합 분석을 위한 메타러닝 방법론 탐색	이종 빅데이터 통합 분석을 위한 메타러닝 방법론에 대한 선행연구를 충실히 수행하였는가?	13.3%
			이종 빅데이터 통합 분석을 위한 딥러닝 모델 및 강화학습 방법론 탐색	이종 빅데이터 통합 분석을 위한 딥러닝 모델 및 강화학습 방법론에 대한 선행연구를 충실히 수행 하였는가?	10%
		이종 빅데이터 통합·처리를 위한 이론 및 방법론 연구	이종 빅데이터 통합 · 처리 기술 이론 연구	어떤 과정을 통하여 이종 빅데이터 통합 ·처리 기술의 이론 연구하였는가?	6.7%
			이종 빅데이터 통합·처리를 위한 통계학습과 기계학습 이론 및 방법론 연구	통계학습과 기계학습 이론 및 방법론은 이종 빅데이터 통합·처리에 효율적인가?	10%
			신경망 모델과 딥러닝 기법 연구	어떤 과정을 통해 신경망 모델과 딥러닝 기법을 연구하였는가?	10%
			이종 빅데이터 처리를 위한 학습모델 정교화 방법 탐색	탐색한 학습모델 정교화 방법은 이종 빅데이터 처리에 적절한가?	6.7%
		이종 빅데이터 통합 분석 라이브러리 조사 연구 및 SW 구조 설계를 위한 기초조사 및 연구기획	이종 빅데이터 통합 분석 플랫폼 조사 연구	이종 빅데이터 통합 분석을 위한 기능은 적합한가?	8.3%
			오픈소스 기반 머신러닝 라이브러리 조사 연구	소프트웨어 개발에 적합한 프레임워크는 무엇인가?	8.3%
			이종 빅데이터 통합 분석 소프트웨어 구조 설계	세부과제에서 연구된 이론적 아이디어를 수용할 수 있는가?	16.7%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 2 절 연구개발목표 달성도 및 기여도 평가

기획연구 단계에서의 각 세부 연구개발목표별 달성도 및 기여도를 평가한 내용을 다음 [표 4]에 정리하였다.

[표-4] 연구개발목표별 달성도 및 기여도 평가

연구개발목표	달성도 (가중치)	달성도 설명 및 기여도 평가
이종 빅데이터 통합 표현 방법 탐색	100 (10%)	-이종 빅데이터 통합 임베딩 방법론에 관한 이론적 연구를 충실히 수행 및 zero-shot 학습 모델 기반의 이종 빅데이터 통합 임베딩 모델 기획 -생성적 적대 모델을 이용하여 텍스트에서 이미지를 생성하거나 이미지에서 텍스트를 생성하는 등의 이종 빅데이터 통합처리 방법론에 관한 연구수행 -이미지와 텍스트의 이종 빅데이터 통합 임베딩 실험 진행 -이미지, 텍스트, 오디오, 비디오 등으로 구성되는 자체 이종 빅데이터를 구축하여 향후 3개년 연구준비
이종 빅데이터 통합 분석을 위한 메타러닝 방법론 탐색	100 (13.3%)	-이종 빅데이터 통합 분석을 위한 메타러닝 방법론에 대한 연구 수행 -메타러닝의 정의 및 접근방식을 정리하고 앙상블 방법론, 전이학습, k-shot 학습 방법론 등의 개념 정립 -2017 한국소프트웨어종합학술대회 논문발표 -2018 International Conference on Big Data and Computing 논문게재 승인 -거리기반 메타러닝 기반의 학습모델 학습효율 향상 방법론을 제안 및 실험
이종 빅데이터 통합 분석을 위한 딥러닝 모델 및 강화학습 방법론 탐색	100 (10%)	-강화학습 방법론에 대한 기초연구 수행 및 강화학습 방법론 기반 메타러닝 방법론에 대한 이론연구 수행 및 공개된 구현 방법론 확보 -심층신경망 압축기법에 대한 연구를 수행하여 목표로 하는 학습모델의 응용효율성을 제고시킬 수 있는 방법론 연구 -메타러닝 기반의 이종 빅데이터 통합분석 원천기술을 바탕으로 한 응용도메인 탐색 및 기획 -2018 IEEE International Conference on Big Data and Smart Computing 논문발표 -심층신경망 양자화 방법론 제안 및 실험을 통해 제안하는 방법론의 우수성 제시
이종 빅데이터 통합 · 처리 기술 이론 연구	100 (6.7%)	-이종 데이터의 통합·처리 기술 이론들을 데이터 특성에 따라 새롭게 분류 -기존 이론의 한계점 파악 및 다소 활용이 부족했던 데이터 활용 부분에 대한 적용 가능성 파악
이종 빅데이터 통합·처리를 위한 통계학습과 기계학습 이론 및 방법론 연구	100 (10%)	-이종 빅데이터 통합·처리를 위한 통계학습과 기계학습 기술 개발을 위한 통계적 이론 및 타당성 검증 -통계학습에서 기존 연구에서 제시한 알고리즘들의 적용 조건 및 가정을 완화시킨 방법에 대한 연구 -단일 도메인에서의 데이터 소스의 차원이 증가함에 따라 발생하는 문제 파악 및 차원 축소를 통한 해결 방안 모색
신경망 모델과 딥러닝 기법 연구	100 (10%)	-딥러닝 기반 이종 빅데이터 통합·처리를 위해 입력 데이터 특성에 따른 인공신경망 모형 연구 -기존 이종 데이터 학습 방법에 깊은 인공신경망 학습을 적용하기 위한 방법 탐색
이종 빅데이터 처리를 위한 학습모델 정교화 방법 탐색	100 (6.7%)	-이종 빅데이터 통합 처리를 위한 파라미터 최적화 기법 연구 -기존 학습 모형 확장을 위한 통계적 방법론 탐색 -정규화를 통한 이종 빅데이터에 대한 과적합 문제 해결 방안 모색

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구개발목표	달성도 (가중치)	달성도 설명 및 기여도 평가
이종 빅데이터 통합 분석 플랫폼 조사 연구	100 (8.3%)	- 아파치 스파크, H20, Apache SINGA, Google TensorFlow, Caffe 등 여러 가지 빅데이터 플랫폼에 대한 현황 조사 - Deep Learning 알고리즘 처리 플랫폼 탐색 - DLVM의 개념과 개발현황 조사(Google, IBM, Amazon, HP, Intel 등 자체 보유의 DLVM) - GPU 활용하기 위해서는 중간언어(LLVM) 개념이 필수적이며, Deep Learning을 위한 LLVM 기술이 적용된 DLVM이 개발되고 있다는 점을 도출
오픈소스 기반 머신러닝 라이브러리 조사 연구	100 (8.3%)	- 다양한 데이터 분석 방안 연구, 다양한 딥러닝 모델 통합, 빠른 학습이 가능한 기술에 대한 선행연구 수행 - 기존 빅데이터의 Deep Learning 알고리즘 처리 방안의 공통점 도출 - Google의 XLA와 IBM의 SystemML의 장점을 조합하여 빠른 성능을 보유한 컴파일러 개발
이종 빅데이터 통합 분석 소프트웨어 구조 설계	100 (16.7%)	- LLVM과 컴파일러의 차이점 연구 - 현재 가장 많이 연구가 진행된 Google ‘s XLA와 IBM’ s SystemML 중심으로 시스템 구조에 대해서 연구 진행 - 머신 클러스터 전반에 걸쳐 딥러닝 네트워크를 학습시키기 위한 간단한 프로그래밍 모델 제공 - 여러 가지 보편적 유형의 Deep Learning 모델뿐만 아니라 특정 문제에 가장 좋은 작업이 어떤 것인가를 파악할 수 있는 메타러닝 알고리즘 탑재 - 현재 기 보유 중인 데이터 분석도구인 i-STREAM용 DLVM 개발 방향 수립
총점	100	각 세부과제 별로 향후 3개년 연구를 위한 기초조사 및 연구기획을 충실히 수행하였으며, 그 과정에서 실험적인 연구를 수행하고 논문 등을 발표하여 의미있는 연구결과를 얻었음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 5 장 연구개발결과의 활용계획

본 1단계 연구에서 연구한 이종 빅데이터 통합 표현 및 처리 방법, 메타러닝 방법론, 강화학습 방법론, 다양한 딥러닝 기법을 포함한 통계학습과 기계학습 방법론, 학습모델 정교화 방법, 이종 빅데이터 분석 플랫폼 및 라이브러리, 소프트웨어 구조 설계 등은 향후 2단계 연구를 위한 기초 연구로 활용될 예정이다. 최종 연구개발 결과의 주요 활용 분야는 다음과 같다.

1. 멀티모달 분류(multi-modal classification)

멀티모달 분류는 다양한 이종 데이터들을 바탕으로 분류를 수행하는 것으로서, 텍스트와 이미지 정보가 같이 있는 뉴스 콘텐츠를 분류하거나 비디오와 오디오를 같이 분석하여 행동이나 감정을 인식하는 것 등 이종의 데이터로 표현된 대상을 분류하는 것과, 이종의 데이터로 학습을 수행하여 새로운 데이터에 대해 적절한 태그를 부여하는 image/audio/video annotation 등을 포함하는 분야라고 할 수 있다. 본 연구에서 수행하는 이종 빅데이터 통합 방법론을 적용하여 다양한 모달리티를 가지는 데이터들 사이에 전이학습을 수행함으로써 멀티모달 분류를 효과적으로 수행할 수 있다.

2. 크로스모달 검색(cross-modal retrieval)

크로스모달 검색은 이미지, 텍스트, 오디오, 비디오 등 이종의 데이터들 사이에 데이터를 검색하는 것을 말한다. 예들 들어 이미지를 질의로 텍스트나 비디오를 검색하거나 텍스트를 질의로 하여 이미지나 오디오를 검색하는 것이다. 할 수 있는 방법론을 의미한다. 본 연구에서 수행하는 이종 빅데이터 통합 방법론을 적용하여 다양한 모달리티를 가지는 이종의 데이터들을 같은 공간으로 임베딩하면 그 맵핑된 데이터를 활용하여 크로스모달 검색을 수행할 수 있다.

3. 멀티모달 추천(multi-modal recommendation)

개인화 추천 시스템은 사용자와 추천 대상 아이템 사이의 관계를 분석하여 개인의 취향과 수요에 맞는 아이템을 제시하는 것으로서, 상품 추천뿐 아니라 뉴스, 음악, 영화, 앱 등 다양한 콘텐츠에 대한 개인화된 서비스에 적용되는 기술이다. 기존의 추천 시스템은 대부분 사용자의 아이템에 대한 평가 정보 또는 구매 정보를 바탕으로 유사한 사용자를 찾아 그 사용자의 평가 정보를 사용하는 협업 필터링(collaborative filtering) 방법이 주로 사용되었다. 그러나 본 연구에서 수행하는 이종 빅데이터 통합 방법론을 적용하면 사용자 및 아이템에 대한 사진, 리뷰 텍스트 등 다양한 이종의 데이터들을 활용한 추천이 가능하다.

4. 심층신경망 최적화(Optimization of deep neural network)

신경망 모형에는 신경망의 가중치 등 수 많은 매개변수(parameter)가 존재해 매개변수를 최적화하는 것이 쉽지 않다. 심층신경망은 신경망 모형의 은닉층을 늘려 심층적인 학습을 가능하게 하는 모형이기 때문에 일반적인 신경망 모형보다 더 많은 매개변수를 가지게 된다. 신경망 모형의 매개

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

변수를 최적화할 때 은닉층이 늘어날수록 학습을 하는 과정에서 그래디언트가 사라지게 되는 문제(vanishing gradient)가 발생할 수 있고 매개변수에 대한 업데이트가 진행될 때 초기치를 잘못 설정하게 되면 수렴이 되지 않거나 수렴 속도가 늦어지기 때문에 초기치를 설정하는 일이 중요하다. 또한 매개변수가 많이 존재하는 신경망 모형의 특성상 모델의 과적합 문제가 발생한다. 이러한 신경망 모형의 문제점들이 심층신경망 모형에서는 더 극명하게 나타나게 된다. 본 연구에서 수행하는 연구 결과로 심층신경망 최적화에 활용하여 이종 빅데이터 통합 처리를 위한 알고리즘에 적용하고자 한다.

5. 한글 텍스트 연계 및 시공간 형태의 이종 빅데이터 통합

텍스트 데이터의 경우 한글 텍스트를 대상으로 한 연구가 미흡한 실정이다. 한글 텍스트는 언어학 구조상 영어 텍스트 데이터와는 성격이 다르기 때문에 다른 방식의 처리가 필요하다. 예를 들어, 영문 텍스트의 경우 어근 처리(stemming)를 통해 전처리를 하지만 한글 텍스트의 경우 형태소 분석을 통한 전처리를 진행한다. 따라서 기존 이종데이터 통합·처리 기법을 이용하여 한글 텍스트와 다른 종류의 데이터의 통합에 적용하고자 한다. 시공간 자료 분석의 경우 시간적 자료와 공간적 자료를 결합하여 분석해야하기 때문에 분석이 쉽지 않다. 기존에는 통계학적, 기계학적 방법론을 통해 시공간 자료에 대한 연구가 이루어졌지만 좋은 성과를 거두지 못한 경우가 많았다. 본 연구의 결과를 시간과 공간이라는 특성이 다른 두 데이터를 통합하여 활용하는데 적용한다.

6. 음성 및 영상 통합 처리

최근 인터넷이나 이동통신망 등의 데이터 통신의 발달로 많은 사람들이 인터넷을 통해 다양한 음성 자료를 손쉽게 접할 수 있게 되었다. 인터넷 등을 통해 유통되는 음원이 증가함에 따라 음성을 인식하여 다양한 음성자료를 매칭하여 찾아주는 기술이 많이 적용되고 있다. 또한 현대사회에서 각종 CCTV, SNS, 블랙박스, 인공위성 등에서 수집되는 영상자료의 양도 매우 방대해졌고 이에 대한 분석도 Google, IBM 등에서 활발히 이루어지고 있다. 영상자료는 시간과 공간에 대한 정보와 사진, 음성, 텍스트 자료의 특성을 모두 갖고 있어 다양한 데이터 형태에 따른 분석을 적용할 수 있다는 장점이 있다. 본 연구의 결과는 음성 자료와 영상 자료 형태들과 다른 자료 형태 간의 이종데이터 통합 처리 기법에 활용될 예정이다.

7. 최신 HW기반 DB 병렬 처리 최적화

본 연구에서 개발된 DLVM IR기술을 실무에서 바로 활용할 수 있는 방법으로 이종 데이터베이스에서 저장된 프로시저를 DLVM IR로 변환하여 JIT 중간 코드로 생성 후 질의를 수행하고, 그 과정에서 DLVM 실행 엔진을 이용하여 GPU에 맞는 실행 코드 생성하여 최적의 질의 결과를 얻을 수 있다. 예를 들면, 오라클 PL/SQL 프로시저와 MySQL 프로시저를 동시에 GPU에 맞는 실행 코드를 통합하고 동시에 최적화하여 병렬 실행할 수 있다. 이렇게 되면 기존 코드를 활용하여 GPU로 데이터분석을 효율적으로 수행할 수 있다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

8. 워크벤치 기반 이종 빅데이터 분석 메타러닝 플랫폼

본 연구에서 개발된 기술과 모델을 데이터분석 소프트웨어 i-STREAM에 plug-in 형태로 모듈화하여 다양한 데이터 소스가 존재하는 환경에서 이종 빅데이터 기반 통합 데이터 솔루션으로 활용될 수 있다. 세부과제에서 연구 개발된 모델들을 실제 응용할 수 있는 노드 형태로 패키징 하고, 다양한 데이터 소스에 존재하는 데이터를 추출/취합하여 데이터를 분석할 수 있도록 이종 데이터 소스에 대한 통합 처리 및 활용 기능을 제공한다.

9. metaX 라이브러리 구축 및 오픈

1단계 및 2단계 연구를 통하여 개발된 이종 빅데이터 통합 분석 기술들은 metaX 라이브러리로, 자체적으로 수집하여 구축한 이미지, 텍스트, 오디오, 비디오 등 실험용 이종 빅데이터 집합은 metaK 데이터셋으로 각각 오픈할 예정이다. 향후 2단계 연구가 진행되며 metaX 라이브러리의 기능이 지속적으로 추가될 예정이며, metaK 데이터셋 모듈을 포함하여 오픈한다. metaX 라이브러리에 포함 예정인 주요 내용은 다음과 같다.

- Heterogeneous embedding
- k-shot learning with heterogeneous data
- Heterogeneous transfer learning
- NN structure generation RL
- NN weight quantization
- Co-training
- Co-regularization
- Cross-modal ranking
- Spatial-temporal data analysis
- Deep Canonical Correlation Analysis
- Kernel Canonical Correlation Analysis
- Multi-modal RNN
- Multi-modal DBM

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 6 장 연구개발과정에서 수집한 해외과학기술정보

기계학습 분야 주요 학회를 통한 메타러닝과 관련된 주요 연구동향 및 DLVM과 관련된 오픈소스에 관한 내용 등은 각 세부 과제에 기술하였음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 7 장 참고문헌

[1] C.L. Philip Chen, Chun-Yang Zhang, “Data-intensive applications, challenges, techniques and technologies: A survey on Big Data” Information Sciences, Volume 275, (2014): 314-347.

[2] Vilalta, Ricardo, and Youssef Drissi. “A perspective view and survey of meta-learning.” Artificial Intelligence Review 18.2 (2002): 77-95.

[3] Kalra, Monika, and Niranjan Lal. “Data mining of heterogeneous data with research challenges.” Colossal Data Analysis and Networking (CDAN), Symposium on. IEEE, 2016.

[4] Vinyals, Oriol, et al. “Matching networks for one shot learning.“ Advances in Neural Information Processing Systems. 2016.

[5] Pan, Sinno Jialin, and Qiang Yang. “A survey on transfer learning.“ IEEE Transactions on knowledge and data engineering 22.10 (2010): 1345-1359.

[6] Goodfellow, Ian, et al. “Generative adversarial nets.” Advances in neural information processing systems. 2014.

[7] Zoph, Barret, and Quoc V. Le. “Neural architecture search with reinforcement learning.” arXiv preprint arXiv:1611.01578 (2016).

[8] Zhou, Shuchang, et al. “DoReFa-Net: Training low bitwidth convolutional neural networks with low bitwidth gradients.“ arXiv preprint arXiv:1606.06160 (2016).

[9] 양현식, 백나은, 김희준, 장재우, “이종데이터 처리를 위한 MySQL 및 Hadoop 기반의 하이브리드 분산 미들웨어 개발”, 한국정보과학회 학술발표논문집, 2015, pp.1418-1420.

[10] 김경민, 하정우, 이범진, 장병탁. (2015). “멀티모달 개념계층모델을 이용한 만화비디오 컨텐츠 학습을 통한 등장인물 기반 비디오 자막 생성”. 정보과학회논문지, 42(4), 451-458.

[11] 서수민, 부석준, 조성배, “가짜문장의 전이학습을 이용한 소규모 불균형 데이터의 욕설문장 분류방법”, 한국정보과학회 학술발표논문집, 2017, pp1340-1342.

[12] 박준건, 지민기, 김도형, 정요한, 이한선, 박진규, 문일철, “강화학습을 통한 토목 공정 최적화”, 한국경영과학회 학술대회논문집, 2017, pp2172-2179

[13] 이승빈, 김현곤, 신광수, 낭종호, “슈퍼 해상도를 위한 Convolution 신경망과 Generative Adversarial 신경망에 대한 성능 분석”, 한국정보과학회 학술발표논문집, 2017, pp.931-933.

[14] 김선훈, 김대식, 서봉원. (2016). “멀티모달 딥러닝을 이용한 음악 장르 분류. 한국HCI학회 학술대회”, pp.389-395.

[15] 김도현, 이정헌, 양지훈. (2016). “텐서플로우로 구현한 효과적인 구조의 멀티모달 딥러닝 동영상 분류 시스템”. 한국정보과학회 학술발표논문집, pp.1842-1844.

[16] 이호엽, 윤휘건, 김창욱, “딥러닝을 이용한 저널 추천 시스템”, 대한산업공학회 추계학술대

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

회 논문집, 2015, pp.1247-1267.

[17] Frome, Andrea, et al. “Devise: A deep visual-semantic embedding model.” Advances in neural information processing systems. 2013.

[18] Chang, Shiyu, et al. “Heterogeneous network embedding via deep architectures.” Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2015.

[19] Peng, Yuxin, Jinwei Qi, and Yuxin Yuan. “CM-GANs: Cross-modal Generative Adversarial Networks for Common Representation Learning.” arXiv preprint arXiv:1710.05106 (2017).

[20] Socher, Richard, et al. “Zero-shot learning through cross-modal transfer.” Advances in neural information processing systems. 2013.

[21] Santoro, Adam, et al. “Meta-learning with memory-augmented neural networks.” International conference on machine learning. 2016.

[22] Zoph, Barret, and Quoc V. Le. “Neural architecture search with reinforcement learning.“ arXiv preprint arXiv:1611.01578 (2016).

[23] Han, Song, Huizi Mao, and William J. Dally. “Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding.” arXiv preprint arXiv:1510.00149 (2015).

[24] Globerson, Amir, et al. "Embedding heterogeneous data using statistical models." PROCEEDINGS OF THE NATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE. Vol. 21. No. 2. Menlo Park, CA; Cambridge, MA; London; AAAI Press; MIT Press; 1999, 2006.

[25] Reed, Scott, et al. “Generative adversarial text to image synthesis.” arXiv preprint arXiv:1605.05396 (2016).

[26] Karpathy, Andrej, and Li Fei-Fei. “Deep visual-semantic alignments for generating image descriptions.” Proceedings of the IEEE conference on computer vision and pattern recognition. 2015.

[27] Biggs JB, The role of meta-learning in study process. Br J Educ Psychol 55, pp. 185-212 (1985).

[28] Lemke, C., Budka, M. & Gabrys, “Metalearning: a survey of trends and technologies”, Artificial Intelligence Review, Volume 44, Issue 1, pp 117-130, 2015.

[29] Vanschoren J, (Understanding machine learning performance with experiment databases. PhD thesis, Arenberg Doctoral School of Science, Engineering & Technology, Katholieke Universiteit Leuven, (2010).

[30] Breiman, Leo. “Bagging predictors.” Machine learning 24.2 (1996): 123-140.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[31] Freund, Yoav, and Robert E. Schapire. "A decision-theoretic generalization of on-line learning and an application to boosting." Journal of computer and system sciences 55.1 (1997): 119-139.

[32] Wolpert, David H. "Stacked generalization." Neural networks 5.2 (1992): 241-259.

[33] Raina, Rajat, et al. "Self-taught learning: transfer learning from unlabeled data." Proceedings of the 24th international conference on Machine learning. ACM, 2007.

[34] Csurka, Gabriela. "Domain adaptation for visual applications: A comprehensive survey." arXiv preprint arXiv:1702.05374 (2017).

[35] Gong, Boqing, Kristen Grauman, and Fei Sha. "Learning kernels for unsupervised domain adaptation with applications to visual object recognition." International Journal of Computer Vision 109.1-2 (2014): 3-27.

[36] Prettenhofer, Peter, and Benno Stein. "Cross-language text classification using structural correspondence learning." Proceedings of the 48th annual meeting of the association for computational linguistics. Association for Computational Linguistics, 2010.

[37] Zhou, Joey Tianyi, et al. "Heterogeneous domain adaptation for multiple classes." Artificial Intelligence and Statistics. 2014.

[38] Glorot, Xavier, Antoine Bordes, and Yoshua Bengio. "Domain adaptation for large-scale sentiment classification: A deep learning approach." Proceedings of the 28th international conference on machine learning (ICML-11). 2011.

[39] K. Saenko, B. Kulis, M. Fritz, and T. Darrell, "Adapting visual category models to new domains," in European Conference on Computer Vision (ECCV), 2010.

[40] M. Long, J. Wang, G. Ding, J. Sun, and P. S. Yu, "Transfer feature learning with joint distribution adaptation," in IEEE International Conference on Computer Vision (ICCV), 2013.

[41] L. Duan, D. Xu, and S.-F. Chang, "Exploiting web images for event recognition in consumer videos: A multiple source domain adaptation approach," in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2012.

[42] B. Chidlovskii, S. Clinchant, and G. Csurka, "Domain adaptation in the absence of source domain data," in Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECML PKDD), 2016.

[43] B. Zadrozny, "Learning and evaluating classifiers under sample selection bias," in International Conference on Machine Learning (ICML), 2004.

[44] K.M.Borgwardt, A.Gretton, M.J.Rasch, H.-P.Kriegel,B .Sch ¨ olkopf, and A.J.Smola, "Integrating structured biological data by kernel maximum mean discrepancy," Bioinformatics, vol. 22, pp. 49–57, 2006.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[45] L.Duan, I.W.Tsang, D.Xu, and S.J.Maybank, “Domain transfer SVM for video concept detection,” in IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2009.

[46] Daumé III, Hal. “Frustratingly easy domain adaptation.“ arXiv preprint arXiv:0907.1815 (2009).

[47] B. Fernando, A. Habrard, M. Sebban, and T. Tuytelaars, “‘Unsupervised visual domain adaptation using subspace alignment,” “ in IEEE International Conference on Computer Vision (ICCV), 2013.

[48] Pan, Sinno Jialin, et al. “Domain adaptation via transfer component analysis.“ IEEE Transactions on Neural Networks 22.2 (2011): 199-210.

[49] C. Xu, D. Tao, and C. Xu, “A survey on multi-view learning,” CoRR, vol. arXiv:1304.5634, 2013.

[50] W. Wang, R. Arora, K. Livescu, and J. Bilmes, “On deep multi-view representation learning,” in International Conference on Machine Learning (ICML), 2015.

[51] Y. Zhu, Y. Chen, Z. Lu, S. J. Pan, G.-R. Xue, Y. Yu, and Q. Yang, “Heterogeneous transfer learning for image classification,” in AAAI Conference on Artificial Intelligence (AAAI), 2011.

[52] G.-J. Qi, C. Aggarwal, and T. Huang, “Towards semantic knowledge propagation from text corpus to web images,” in International Conference on World Wide Web (WWW), 2011.

[53] J. Donahue, Y. Jia, O. Vinyals, J. Hoffman, N. Zhang, E. Tzeng, and T. Darrell, “‘Decaf: A deep convolutional activation feature for generic visual recognition,” “ in International Conference on Machine Learning (ICML), 2014.

[54] B. Chu, V. Madhavan, O. Beijbom, J. Hoffman, and T. Darrell, “Best practices for fine-tuning visual classifiers to new domains,” in ECCV Workshop on Transferring and Adapting Source Knowledge in Computer Vision (TASK-CV), 2016.

[55] M. Ghifary, W. B. Kleijn, M. Zhang, and D. Balduzzi, “Domain generalization for object recognition with multi-task autoencoders,” in IEEE International Conference on Computer Vision (ICCV), 2015.

[56] J. Bromley, J. W. Bentz, L. Bottou, I. Guyon, Y. LeCun, C. Moore, E. S ¨ackinger, and R. Shah, “Signature verification using a ” siamese” time delay neural network,” International Journal of Pattern Recognition and Artificial Intelligence, vol. 7, no. 04, pp. 669–688, 1993.

[57] E. Tzeng, J. Hoffman, N. Zhang, K. Saenko, and T. Darrell, “Deep domain confusion: Maximizing for domain invariance,” CoRR, vol. arXiv:1412.3474, 2014.

[58] M. Lon‘g, Y. Cao, J.Wang, and M. Jordan, “Learning transferable features with deep adaptation networks,” in International Conference on Machine Learning (ICML), 2015.

[59] M. Long, J. Wang, and M. I. Jordan, “Deep transfer learning with joint adaptation networks,” CoRR, vol. arXiv:1605.06636, 2016.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[60] E. Tzeng, J. Hoffman, K. Saenko, and T. Darrell, "Adversarial discriminative domain adaptation," in NIPS Workshop on Adversarial Training, (WAT), 2016.

[61] X. Shu, G.-J. Qi, J. Tang, andW. Jingdong, "Weakly-shared deep transfer networks for heterogeneous-domain knowledge propagation," in ACM Multimedia, 2015.

[62] Ravi, Sachin, and Hugo Larochelle. "Optimization as a model for few-shot learning." (2016).

[63] Finn, Chelsea, Pieter Abbeel, and Sergey Levine. "Model-agnostic meta-learning for fast adaptation of deep networks." arXiv preprint arXiv:1703.03400 (2017).

[64] Chen, Xi, et al. "FxpNet: Training a deep convolutional neural network in fixed-point representation." Neural Networks (IJCNN), 2017 International Joint Conference on. IEEE, 2017.

[65] Han, Song, Huizi Mao, and William J. Dally. "Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding." arXiv preprint arXiv:1510.00149 (2015).

[66] Rastegari, Mohammad, et al. "Xnor-net: Imagenet classification using binary convolutional neural networks." European Conference on Computer Vision. Springer, Cham, 2016.

[67] Pennington, Jeffrey, Richard Socher, and Christopher Manning. "Glove: Global vectors for word representation." Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014.

[68] Maaten, Laurens van der, and Geoffrey Hinton. "Visualizing data using t-SNE." Journal of machine learning research 9.Nov (2008): 2579-2605.

[69] Qian, Shengsheng, Tianzhu Zhang, and Changsheng Xu. "Multi-modal multi-view topic-opinion mining for social event analysis." Proceedings of the 2016 ACM on Multimedia Conference. ACM, 2016.

[70] Moran, Sean, and Victor Lavrenko. "A sparse kernel relevance model for automatic image annotation." International Journal of Multimedia Information Retrieval 3.4 (2014): 209-229.

[71] Wang, Xiaosong, et al. "TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-rays." arXiv preprint arXiv:1801.04334 (2018).

[72] Multi modal music mood classification, Research Seminar at National Institute of Informatics, Japan, https://www.slideshare.net/xiaohusmile/multi-modal-music-mood-classification

[73] Huang, Xin, Yuxin Peng, and Mingkuan Yuan. "Cross-modal common representation learning by hybrid transfer network." arXiv preprint arXiv:1706.00153 (2017).

[74] Zhi, Jiale. "PixelBrush: Art Generation from text with GANs"

[75] Qian, Shengsheng, et al. "Cross-domain collaborative learning in social multimedia." Proceedings of the 23rd ACM international conference on Multimedia. ACM, 2015.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[76] Yu, Yonghong, and Xingguo Chen. "A survey of point-of-interest recommendation in location-based social networks." Workshops at the Twenty-Ninth AAAI Conference on Artificial Intelligence. Vol. 130. 2015.

[77] Workshop on Meta-Learning (MetaLearn 2017), http://metalearning.ml/

[78] Akaho, S. (2001). A kernel method for canonical correlation analysis. In International Meeting on Psychometric Society.

[79] Bai,B.,Weston,J.,Grangier,D.,Collobert,R.,Sadamasa,K., Qi, Y., Chapelle, O. & Weinberger, K. Q. (2010) Learning to rank with (a lot of) word features. Information retrieval, 13(3), 291-314.

[80] Bean, R. (2016). Variety, Not Volume, Is Driving Big Data Initiatives. MIT Sloan Management Review, http://sloanreview.mit.edu/article/variety-not-volume-is-driving-big-data-initiatives.

[81] Benton, A., Khayrallah, H., Gujral, B., Reisinger, D., Zhang, S. & Arora, R. (2017). Deep generalized canonical correlation analysis. arXiv preprint arXiv:1702.02519.

[82] Blum,A. & Mitchell, T. (1998). Combining labeled and unlabeled data with co-training. In Proceeding of the 11th Annual Conference on Computational Learning Theory, 92-100.

[83] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv preprint arXiv:1406.1078.

[84] Dong, J., Li, X. & Snoek, C. G. (2016). Word2VisualVec: Cross-media retrieval by visual feature prediction. arXiv preprint arXiv:1604.06838.

[85] Dong, X. L. & Srivastava, D. (2015). Big data integration. Synthesis Lectures on Data Management, 7(1), 1-198.

[86] Fang, H., Gupta, S., Iandola, F., Srivastava, R., Deng, L., Dollár, P. & Zitnick, L. (2015). From captions to visual concepts and back.

[87] Feng, F., Wang, X. & Li, R. (2014). Cross-modal retrieval with correspondence autoencoder. In Proceedings of the 22nd ACM international conference on Multimedia, 7-16.

[88] Friedman,J., Hastie,T. & Tibshirani,R. (2001). The elements of statistical learning. NewYork: Springer series in statistics, 1, 241-249.

[89] Frome, A., Corrado, G. S., Shlens, J., Bengio, S., Dean, J. & Mikolov, T. (2013). Devise: A deep visual-semantic embedding model. In Advances in neural information processing systems, 2121-2129.

[90] Gal, A. (2015). Big data integration. In Keynote speech at international conference on open and big data.

[91] Grais, E. M. & Plumbley, M. D. (2017). Single channel audio source separation using convolutional denoising autoencoders. arXiv preprint arXiv:1703.08019.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[92] Grangier, D. & Bengio, S. (2008). A discriminative kernel-based approach to rank images from text queries. IEEE transactions on pattern analysis and machine intelligence, 30(8), 1371-1384.

[93] Hong, C., Yu, J., Wan, J., Tao, D. & Wang, M. (2015). Multimodal deep autoencoder for human pose recovery. IEEE Transactions on Image Processing, 24(12), 5659-5670.

[94] Hotelling, H. (1936) Relations between two sets of variates. Biometrika, 28(3), 321-377.

[95] Huang, J. & Kingsbury, B. (2013). Audio-visual deep learning for noise robust speech recognition. In Acoustics, Speech and Signal Processing (ICASSP), 2013 IEEE International Conference on IEEE, 7596-7599.

[96] Huang, W., Hong, H., Bian, K., Zhou, X., Song, G. & Xie, K. (2015). Improving deep neural network ensembles using reconstruction error. In Neural Networks (IJCNN), 2015 International Joint Conference on IEEE, 1-7.

[97] Jaques, N., Taylor, S., Sano, A. & Picard, R. (2017). Multimodal Autoencoder: A Deep Learning Approach to Filling In Missing Sensor Data and Enabling Better Mood Prediction. In Proc. International Conference on Affective Computing and Intelligent Interaction (ACII), San Antonio, Texas.

[98] Jiang, X., Wu, F., Li, X., Zhao, Z., Lu, W., Tang, S. & Zhuang, Y. (2015). Deep compositional cross-modal learning to rank via local-global alignment. In Proceedings of the 23rd ACM international conference on Multimedia, 69-78.

[99] KAIST, 모바일 플랫폼용 저전력 딥러닝 반도체칩 세계 최초 개발 (2017.08.28). 검색일 2018년 1월 25일, 출처 전자신문 : http://www.etnews.com/20170828000228

[100] Karpathy, A. & Fei-Fei, L. (2015). Deep visual-semantic alignments for generating image descriptions. In Proceedings of the IEEE conference on computer vision and pattern recognition, 3128-3137.

[101] Kim, K. M., Ha, J. W., Lee, B. J. & Zhang, B. T. (2015). Character-based Subtitle Generation by Learning of Multimodal Concept Hierarchy from Cartoon Videos. Journal of KIISE, 42(4), 451-458.

[102] Kim, S., Kim, D. & Suh, B. (2016). Music Genre Classification using Multimodal Deep Learning. In Proceedings of HCI Korea. Hanbit Media, Inc., 389-395.

[103] 26. Lai, P. L. & Fyfe, C. (2000). Kernel and nonlinear canonical correlation analysis. International Journal of Neural Systems, 10(5), 614.

[104] Lazaridou, A., Pham, N. T. & Baroni, M. (2015). Combining language and vision with a multimodal skip-gram model. arXiv preprint arXiv:1501.02598.

[105] Li, Y., Yang, M. & Zhang, Z. (2016). Multi-view representation learning: A survey from

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

shallow methods to deep methods. arXiv preprint arXiv:1610.01206.

[106] Li, Y., Yang, M. & Zhang, Z. (2016). Multi-view representation learning: A survey from shallow methods to deep methods. arXiv preprint arXiv:1610.01206.

[107] Liang, M. & Hu, X. (2015). Recurrent convolutional neural network for object recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 3367-3375.

[108] Mao, J., Xu, W., Yang, Y., Wang, J., Huang, Z. & Yuille, A. (2014). Deep captioning with multimodal recurrent neural networks (m-rnn). arXiv preprint arXiv:1412.6632.

[109] Mikolov, T., Karafiát, M., Burget, L., Černocký, J. & Khudanpur, S. (2010). Recurrent neural network based language model. In Eleventh Annual Conference of the International Speech Communication Association.

[110] NAVER, AI 딥러닝 데이터센터 구축한다 - 이달 말 설립 마무리 목표 (2017.06.05). 검색일 2018년 1월 23일, 출처 서울경제 : http://www.sedaily.com/NewsView/1OH2XWAI2X/

[111] Norouzi, M., Mikolov, T., Bengio, S., Singer, Y., Shlens, J., Frome, A. & Dean, J. (2013). Zero-shot learning by convex combination of semantic embeddings. arXiv preprint arXiv:1312.5650.

[112] Pang, L., & Ngo, C. W. (2015). Mutlimodal learning with deep boltzmann machine for emotion prediction in user generated videos. In Proceedings of the 5th ACM on International Conference on Multimedia Retrieval, 619-622.

[113] Pinheiro, P. & Collobert, R. (2014). Recurrent convolutional neural networks for scene labeling. In International conference on machine learning, 82-90.

[114] Raeder, T., Lizardo, O., Hachen, D. & Chawla, N. V. (2011). Predictors of short-term decay of cell phone contacts in a large scale communication network. Social Networks, 33(4), 245-257.

[115] Diggle, Peter J. Statistical analysis of spatial and spatio-temporal point patterns. CRC Press, 2013.

[116] Rempe, F., Huber, G. & Bogenberger, K. (2016). Spatio-temporal congestion patterns in urban traffic networks. Transportation Research Procedia, 15, 513-524.

[117] Salakhutdinov, R. & Hinton, G. (2009). Deep Boltzmann Machines. Proceedings of the Twelth International Conference on Artificial Intelligence and Statistics, 5,448-455

[118] Srivastava, N. & Salakhutdinov, R. R. (2012). Multimodal learning with deep boltzmann machines. In Advances in neural information processing systems, 2222-2230.

[119] Srivastava, N. & Salakhutdinov, R. R. (2012). Multimodal learning with deep boltzmann machines. In Advances in neural information processing systems, 2222-2230.

[120] Srivastava, N., Hinton, G. E., Krizhevsky, A., Sutskever, I. & Salakhutdinov, R. (2014).

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Dropout: a simple way to prevent neural networks from overfitting. Journal of machine learning research, 15(1), 1929-1958.

[121] Sun, S. & Jin, F. (2011). Robust co-training. International Journal of Pattern Recognition and Artificial Intelligence, 25(7), 1113-1126.

[122] Sun, S. (2013). A survey of multi-view machine learning. Neural Computing and Applications, 23(7-8), 2031-2038.

[123] Sutskever, I., Vinyals, O. & Le, Q. V. (2014). Sequence to sequence learning with neural networks. In Advances in neural information processing systems, 3104-3112.

[124] Takahashi, N., Gygli, M. & Van Gool, L. (2017). Aenet: Learning deep audio features for video analysis. IEEE Transactions on Multimedia.

[125] Wang, L. & Sng, D. (2015). Deep learning algorithms with applications to video analytics for a smart city: A survey. arXiv preprint arXiv:1512.03131.

[126] Weston,J., Bengio, S. & Usunier, N. (2010). Large scale image annotation: learning to rank with joint word-image embeddings. Machine Learning, 81(1), 21-35.

[127] Wu, Z., Yao, T., Fu, Y. & Jiang, Y. G. (2016). Deep Learning for Video Classification and Captioning. arXiv preprint arXiv:1609.06782.

[128] Xu,C.,Tao,C.& Xu, C. (2013). A survey on multi-view learning. arXiv preprint arXiv:1304.5634.

[129] Xu, R., Xiong, C., Chen, W. & Corso, J. J. (2015). Jointly Modeling Deep Video and Compositional Text to Bridge Vision and Language in a Unified Framework. In AAAI, 5, 6.

[130] Zhao, J., Xie, X., Xu, X. & Sun, S. (2017). Multi-view learning overview: Recent progress and new challenges. Information Fusion, 38, 43-54.

[131] 박미라, 박기호 & 안재성. (2011). 동적 타임 워핑을 통한 시계열적 유사성에 따른 지역 분류방안에 관한 연구. 국토지리학회지, 45(3), 387-395.

[132] 이희열 & 이승호 (2017). 딥러닝을 PC에 적용하기 위한 메모리 최적화에 관한 연구. 전기전자학회논문지, 21(2), 136-141.

[133] 임형준, 김명종 & 김회린 (2016). 깊은 신경망 기반의 전이학습을 이용한 사운드 이벤트 분류. 한국음향학회지, 35(2), 143-148.

[134] 최준명 & 강동중 (2017). 차량 번호판 화질 개선을 위한 GAN 기반의 초해상도 기법. 제어로봇시스템학회 논문지, 23(8), 635-643.

[135] 홍은빈, 전준호 & 이승용 (2016). 사진 구도 개선을 위한 딥러닝 기반 반복적 크롭핑. 정보과학회논문지, 43(12), 1356-1364.

[136] W. Wang, X. Yang, B. C. Ooi, D. Zhang, Y. Zhuang. “Effective Deep Learning Based

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Multi-Modal Retrieval" VLDB Journal – Special issue of VLDB'14 best papers, 2015.

[137] W. Wang, B.C. Ooi, X. Yang, D. Zhang, Y. Zhuang. "Effective MultiModal Retrieval based on Stacked AutoEncoders." Int'l Conference on Very Large Data Bases (VLDB), 2014.

[138] 3. Apache SINGA, https://svn.apache.org/repos/infra/websites/production/singa/content/docs/overview.html#

[139] Richard Wei, Lane Schwartz, Vikram Adve. "DLVM: A MODERN COMPILER INFRASTRUCTURE FOR DEEP LEARNING SYSTEMS", Cornell University. 2017.

[140] Matthias Boehm, Shirish Tatikonda, Berthold Reinwald, Prithviraj Sen, Yuanyuan Tian, Douglas R. Burdick, Shivakumar Vaithyanathan. "Hybrid Parallelization Strategies for LargeScale Machine Learning in SystemML", IBM Research, 2014.

[141] Amol Ghoting, Rajasekar Krishnamurthy, Edwin Pednault, Berthold Reinwald Vikas Sindhwani, Shirish Tatikonda, Yuanyuan Tian, Shivakumar Vaithyanathan. "SystemML: Declarative Machine Learning on MapReduce", IBM Research, 2014.

[142] Matthias Boehm1, Michael W. Dusenberry2, Deron Eriksson2, Alexandre V. Evfimievski1, Faraz Makari Manshadi1, Niketan Pansare1, Berthold Reinwald1, Frederick R. Reiss1,2, Prithviraj Sen1, Arvind C. Surve2, Shirish Tatikonda. "SystemML: Declarative Machine Learning on Spark", IBM Research, 2016.

[143] Matthias Boehm, Douglas R. Burdick, Alexandre V. Evfimievski, Berthold Reinwald,Frederick R. Reiss, Prithviraj Sen, Shirish Tatikonda, and Yuanyuan Tian, Berthold Reinwald, Frederick Reiss, Shirish Tatikonda, Yuanyuan Tian. "SystemML's Optimizer: Plan Generation for Large-Scale Machine Learning Programs",IBM Research, 2014.

[144] Martin Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser. "TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems", Google Research, 2015.

[145] Fredrik Kjolstad, Shoaib Kamil, Stephen Chou, David Lugato, and Saman Amarasinghe. "The Tensor Algebra Compiler", MIT-CSAIL-TR-2017-003, 2017.

[146] Google Developers, local Blog. "https://developers-kr.googleblog.com/2017/03/xla-tensorflow-compiled.html "

[147] TensorFlow official homepage, "https://www.tensorflow.org/performance/xla/"

[148] Shoumik Palkar, James Thomas, Deepak Narayanan, Anil Shanbhagy, Rahul Palamuttam, Holger Pirkz, Malte Schwarzkopfy, Saman Amarasinghey, Samuel Maddeny, Matei Zaharia. "Weld: Rethinking the Interface Between Data-Intensive Libraries",Stanford University, MIT CSAILy, Imperial College London, 2017.