국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

과제번호 2015-0-00579

정보통신·방송 연구개발 사업

빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발

Development of personal information protection technology using unidentifiability technique on big data environment

(주)이지서티

과학기술정보통신부

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

"빅데이터에 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발"
(총 수행기간 : 2015. 06. - 2019. 05.)과제의 최종보고서 8부를 제출합니다.

2019. 07. 15.

주 관 기 관 명 : (주)이지서티 (대표자) 심 기 창

총괄책임자 : 김 동 래

1. 동 보고서상의 기재 내용이 사실임을 확약하며, 만약, 사실이 아닐 경우 과학기술기본법 제 11조의2 및 정보통신·방송 연구개발사업 관리 규정 제 11조에 따라 참여제한·환수 등의 어떠한 불이익도 감수하겠습니다.
2. 정보통신방송연구개발 관리규정 제36조에 따른 보고서 공개·활용에 동의 합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

"빅데이터에 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발"

(총 수행기간 : 2015. 06. - 2019. 05.)과제의 최종보고서 8부를 제출합니다.

2019. 07. 15.

참 여 기 관 명 : (주)보아라 (대표자) 김 지 수 (인)

참여기관책임자 : 강 동 헌 (인)

1. 동 보고서상의 기재 내용이 사실임을 확약하며, 만약, 사실이 아닐 경우 과학기술기본법 제 11조의2 및 정보통신·방송 연구개발사업 관리 규정 제 11조에 따라 참여제한·환수 등의 어떠한 불이익도 감수하겠습니다.

2. 정보통신방송연구개발 관리규정 제35조에 따른 보고서 공개·활용에 동의합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

"빅데이터에 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발"

(총 수행기간 : 2015. 06. ~ 2019. 05.)과제의 최종보고서 8부를 제출합니다.

2019. 07. 15.

참 여 기 관 명 : 아이알링크(주) (대표자) 김 광 원 (인)

참여기관책임자 : 김 대 수 (인)

1. 동 보고서상의 기재 내용이 사실임을 확약하며, 만약, 사실이 아닐 경우 과학기술기본법 제 11조의2 및 정보통신·방송 연구개발사업 관리 규정 제 11조에 따라 참여제한·환수 등의 어떠한 불이익도 감수하겠습니다.

2. 정보통신·방송연구개발 관리규정 제36조에 따른 보고서 공개·활용에 동의합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

"빅데이터에 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발"(총 수행기간 : 2015. 06. ~ 2019. 05.)과제의 최종보고서 8부를 제출합니다.

2019. 07. 15.

참여기관명 :코리아크레딧뷰로 주식회사 (대표자) 감 문 호 (인)

참여기관책임자 : 여 윤 희 (인)

1. 동 보고서상의 기재 내용이 사실임을 확약하며, 만약, 사실이 아닐 경우 과학기술기본법 제 11조의2 및 정보통신·방송 연구개발사업 관리 규정 제 11조에 따라 참여제한·환수 등의 어떠한 불이익도 감수하겠습니다.

2. 정보통신·방송연구개발 관리규정 제36조에 따른 보고서 공개·활용에 동의합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

제 출 문

과학기술정보통신부 장관 귀하

"빅데이터에 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발"

(총 수행기간 : 2015. 06. ~ 2019. 05.)과제의 최종보고서 8부를 제출합니다.

2019. 07. 15.

참 여 기 관 명 : 주식회사 피앤피시큐어 (대표자) 박 천 오 (인)

참여기관책임자 : 박 대 원 (인)

1. 동 보고서상의 기재 내용이 사실임을 확약하며, 만약, 사실이 아닐 경우 과학기술기본법 제 11조의2 및 정보통신·방송 연구개발사업 관리 규정 제 11조에 따라 참여제한·환수 등의 어떠한 불이익도 감수하겠습니다.

2. 정보통신·방송연구개발 관리규정 제36조에 따른 보고서 공개·활용에 동의합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

보고서 요약서

과제번호	2015-0-00579	총 수행기간	2015.06.01 ~ 2019.05.31	단계구분	총 5단계(4년)
세부사업명	정보통신.방송 연구개발 사업				
연구과제명	총괄과제명	빅데이터 처리 고도화 핵심 기술개발사업 총괄 및 고성능 컴퓨팅 기술을 활용한 성능 가속화 기술 개발			
	과제명	(빅데이터-2세부) 빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발			
총괄책임자	김동례	총 연구기간 참여 연구원 수	총: 207명 내부: 207명 외부: 0명	총 연구개발비	정부: 6,400,000천원 민간: 2,133,333천원 계: 8,533,333천원
주관기관명 및 소속 부서명	㈜이지서티 기업부설연구소			참여기관 : ㈜보아라 (구.(주)그리즐리)), 아이알링크㈜,㈜코리아크레딧뷰로 ㈜피앤피씨큐어	
국제공동연구	-			-	
위탁연구	연구기관명: 고려대학교 연세대학교 동덕여자대학교			연구책임자: 정연돈 이원석 전희주	

※ 국내·외의 기술개발 현황은 연구개발계획서에 기재한 내용으로 갈음

연구개발성과의 보안등급 및 사유	-

9대 성과 등록·기탁번호

구분	논문	특허	보고서 원문	연구시설·장비	기술요약 정보	소프트웨어	화합물	생명자원		신품종	
								생명정보	생물자원	정보	실물
등록·기탁번호	1158 6316 등 9건	10-2015-0125483 등 30건	-	-	기술문서 41건	C-2016-019114 등 11건	-	-	-	-	-

'연구성과 관리·유통 전담기관 지정 고시' 참조

국가과학기술종합정보시스템에 등록한 연구시설·장비 현황

구입기관	연구시설·장비명	규격 (모델명)	수량	구입연월일	구입가격 (천원)	구입처 (전화)	비고 (설치장소)	NTIS 등록번호
-	-	-	-	-	-	-	-	-

- 빅데이터에서 텍스트, DB 등 다양한 형태로 표현되는 개인정보 데이터 자동화 고속 식별 기술 개발
- 개인정보 익명처리를 위한 비식별화 정보 생성 기술개발
- 통계적 정확성 유지를 위한 고속 비식별화 정보 생성 및 라이프사이클 관리 기술 개발
- 실시간 통합 관리 및 제어 기술 개발
- 빅데이터 개인정보보호 기술 응용 서비스 개발 및 시연
- 빅데이터 개인정보보호 기술 응용 서비스의 사업화 및 상용화

보고서 면수 :205면

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

요약문

연구의 목적 및 내용	[연구의 목적]  [빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발] o 본 연구개발 과제의 최종 목적은 기업 내 수많은 운영계 시스템들로부터 지속적으로 생산되는 다양한 형태의 많은 데이터에서 민감한 개인정보를 고속으로 탐색하여 개인정보의 사용 목적에 적합한 비식별화 등급 레벨별로 안전하고 신속하게 비식별화하여 빅데이터에서의 개인정보 유출 문제를 원천적으로 해소함으로써, 기업 내부 및 기업 간 빅데이터의 활용을 적극적으로 극대화 할 수 있는 새로운 형태의 빅데이터 개인정보 고속 비식별화 시스템을 개발하고 다수의 공공 데이터 포털에서 사용 중인 플랫폼과 연계를 통하여 공공/민간 데이터 공유 및 유통을 활성화 하는데 있다. [연구개발 내용] o 빅데이터에서 텍스트, DB 등 다양한 형태로 표현되는 개인정보의 자동화 고속 식별 엔진 개발 o 통계적 정확성 유지를 위한 고속 비식별화 정보 생성 및 라이프사이클 관리 엔진 개발 - 프라이버시 보존 비식별화 및 데이터 마이닝 기술 개발 - KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 개발 o 빅데이터 개인정보 실시간 통합 관리 및 제어 엔진 개발 - 비식별화 정보 기반 개인정보 접근제어 및 고속 검색 기술 - 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지/차단 및 정보 조합을 통한 재식별 가능성 검증기술 o 실제 빅데이터 기반 빅데이터 개인정보보호 기술 응용 서비스 개발 및 시연 - 공공 및 민간 데이터와 연계 방안 제시 o 빅데이터 개인정보보호 기술 응용 서비스의 사업화 및 상용화
연구개발성과	o 기술개발 23건 o 상용화 11건 o 논문 9건 o 특허 40건 (국내 등록 10건, 국내 출원 18건, 국제 출원 12건) o 소프트웨어 등록 11건 o 수상 1건

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구개발성과의 활용계획 (기대효과)	o 개인정보 유출로 인한 법적인 문제를 우려하여 기업 내 부서 간 빅데이터 공유가 현실적으로 불가능한 현재의 국내 상황에서 본 과제의 결과물은 국내 기업 내에서 부서 간 빅데이터 연계 분석을 가능하게 하는 최초의 새로운 형태의 빅데이터 솔루션으로 활용될 것으로 예상되며 본 과제의 결과물로 생성되는 비식별화 빅데이터는 재식별 불가능성의 검증을 통해 기업 외부로 유통이 가능하여 다양한 외부 비식별화 빅데이터들을 연계하여 메쉬업 분석이 가능하므로 비식별화 빅데이터의 실질적인 유통 활용을 활성화하는 목적으로 활용할 계획이다. o 특히, 4차산업혁명의 핵심 자원인 데이터 활용을 위해 2019년 정부주도로 공공. 민간이 협업하여 데이터의 생산. 수집. 분석. 유통을 지원하는 “빅데이터 플랫폼 및 네트워크 구축사업”이 추진되고 있다. 이에 대한 데이터 유통 활성화를 위해서 개인정보 비식별 조치는 필수 사항이며 빅데이터 산업을 극대화 시킬 수 있는 기폭제 역할을 할 것이다. o 빅데이터의 활용은 사회의 다양한 영역에 있는 빅데이터를 연계 분석하여 새로운 인사이트를 탐사하는 것으로 모든 정보가 정보시스템에서 관리되는 성숙한 정보화 사회에서 개인정보 보호라는 민감한 사회적 이슈와 강력한 국내 비식별화 방식의 개인정보보호법의 적용으로 인해 국내 빅데이터 활용이 미진한 현실에서 본 과제의 결과물은 빅데이터에서의 개인정보 보호와 활용이라는 상반된 니즈를 동시에 만족시키는 세계 최초의 빅데이터 솔루션으로 국내에서 많은 활용이 예상된다. 또한 본 시스템은 우리나라와 동일한 방식의 개인정보 보호법을 적용하는 유럽과 일본에 활발한 수출이 예상된다.

국문핵심어 (5개 이내)	개인정보	개인정보탐지	비식별화	데이터공유	데이터 유통
영문핵심어 (5개 이내)	Privacy	Privacy Detection	De-identification	Data Share	Data Circultation

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 목 차 〉

1. 연구개발 과제의 개요 ····· 10

2. 연구 수행 내용 및 성과 ····· 45

3. 목표 달성도 및 관련 분야 기여도 ····· 159

4. 연구개발 성과의 활용 계획 등 ····· 170

붙임 1. 사업화대상기술별 기술명세서 ····· 189
붙임 2. 참고 문헌 ····· 199
붙임 3. 자체 보안관리 진단표 ····· 204

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1. 연구개발 과제의 개요

1-1. 연구개발 목적



[그림 1] 빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발

본 연구개발 과제는 빅데이터 수집 및 처리과정에서 발생하는 프라이버시 문제를 비식별화 및 부정사용 방지기법을 통해 해결하는 개인정보보호 연계시스템 개발을 목적으로 한다. 본 연구개발 과제의 최종 목적은 기업 내 수많은 운영계 시스템들로부터 지속적으로 생산되는 다양한 형태의 많은 데이터에서 민감한 개인정보를 고속으로 탐색하여 개인정보의 사용 목적에 적합한 비식별화 등급 레벨별로 안전하고 신속하게 비식별화하여 빅데이터에서의 개인정보 유출 문제를 원천적으로 해소함으로써, 기업 내부 및 기업 간 빅데이터의 활용을 적극적으로 극대화할 수 있는 새로운 형태의 빅데이터 개인정보 고속 비식별화 시스템을 개발하고 다수의 공공데이터 포털에서 사용 중인 플랫폼과 연계를 통하여 공공/민간 데이터 공유 및 유통을 활성화하는데 있다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1-2. 연구개발의 필요성

가. 기술개발의 개요

개인정보 보호의 중요성은 최근 지속적으로 발생하는 개인정보 유출 사례에서 알 수 있듯이 날이 갈수록 중요해 지고 있다. 이러한 상황에서 다양한 데이터 소스에서 이벤트 형태로 고속으로 데이터가 발생하고 있으며 고속 데이터 발생의 소스가 되는 IoT 장치가 2020년까지 500억 개 이상으로 지속적인 폭증이 예상되고 있다. 이런 데이터 발생 소스가 증가하며 발생하는 각종 데이터를 처리하는 빅데이터 시장이 날이 갈수록 증가하고 있다. 개인정보 보호의 중요성과 빅데이터가 연결되면서 빅데이터의 성장을 위해서는 개인정보 보호는 선결되어야 하는 문제점으로 부각되고 있다.

기존의 개인정보 스캐닝/필터링 솔루션들에서 탐지하고 있는 개인정보의 유형은 주민번호, 이메일, 계좌번호 같은 정형의 패턴만을 탐지하는 수준이다. 그러나 패턴화 되지 않는 이름, 지역, 학교, 직업, 직장명 등의 정보를 통하여서도 개인을 식별할 수 있음을 알게 됨으로서 이에 대한 반정형/비정형 타입의 개인정보 탐지 기술이 필요 하다.

개인정보가 포함된 정보에 대해서 방송통신위원회의 2014년 12월 빅데이터 개인정보보호 가이드라인 발표에 따라, 보다 강한 규제가 실시되면서 업계에서는 정보사용에 소극적인 모습을 보이며 개인정보 논란을 피하기 위해 통계 정보 수준의 비식별 데이터를 제공하고 있다.

2016년 6월 정부는 빅데이터 활성화 및 개인정보보호 강화를 위해 (구)행정자치부, (구)미래창조과학부 등 6개 부처가 합동으로 “개인정보 비식별 조치 가이드라인”을 제정했다. 가이드라인에 따라 비식별화 조치한 개인정보는 정보주체의 동의 없이 기업 마케팅 등에 사용할 수 있게 했다. 그리고 이 비식별화 조치를 지원하는 전문기관으로 한국인터넷진흥원, 한국정보화진흥원, 신용정보원, 금융보안원, 사회보장정보원, 한국교육학술정보원을 지정한 바 있다.

그러나 2017년 11월 시민단체는 이 가이드라인에 따라 빅데이터 서비스를 제공한 20개 기업과 비식별화 조치 전문기관 4곳을 개인정보보호법 등 위반으로 검찰에 고발했다. 법적 효력이 없는 가이드라인에 근거해 개인정보를 침해했다는 것이다. 이후 관계부처・기관 및 기업에서는 개인정보 비식별화 및 비식별 정보의 결합・활용 등과 관련한 일체의 활동이 중단되었다.

2018년 11월 국회 4차산업 혁명 특별위원회 활동 후 비식별 조치된 데이터의 활용을 위해 가명정보 개념을 도입한 「개인정보보호법 개정안」이 발의됐지만, 일부 시민단체의 반발에 막혀 국회에 계류 중인 상태이다.

그러나 검찰이 2019년 3월에 시민단체가 고발한 이 사건을 무혐의 처분하며 그동안의 논란

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

을 종식시켰다. 검찰은 빅데이터 서비스를 제공한 24개 기관·기업들이 취급한 비식별 정보 결합물은 ‘개인정보에 암호화 등 적절한 비식별 조치를 취해서 특정 개인을 식별할 수 없는 상태에 이르렀으므로 개인정보보호법에 따른 개인정보가 아니다’고 판단한 것이다. 또한 해당 기관·기업들의 행위는 ‘개인정보 비식별 조치 가이드라인’에 따라 행해져 절차적 문제도 없다고 본 것이다.

이에 빅데이터 환경에서 데이터 유통 및 활용을 위한 개인정보 비식별조치 기술은 활성화 될 시장여건이 형성되었다.

현재 개인정보보호 가이드라인에서 제시되고 있는 비식별화 기술로는 가명처리, 총계처리, 데이터 값 삭제, 범주화, 데이터 마스킹 등이 있으나 이러한 비식별화 기술은 기존 정보의 손실이 크며, 향후 다른 데이터와의 연계 분석 시 어려움이 발생한다. 또한 제시된 비식별화 기술로 변환된 비식별 데이터는 변환 이후에도 특정인에 대한 정보가 다시 식별될 수 있는 재식별 위험성이 존재하며, 이러한 개인정보 유출 위험성을 보완하기 위해 암호화 기법의 솔루션들이 주로 제공되고 있다.

빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술을 개발하기 위해서 이 보유하고 있는 핵심·원천 기술인 개인정보 검색엔진 및 개인정보 탐지 및 노출 방지 기술을 활용하여 다음과 같은 기능을 지원한다.

첫째, 빅데이터에서 정형/반정형/비정형 개인정보 식별 기술 개발
둘째, 재식별 처리가 어려운 개인정보 비식별화 기술 개발
셋째, 프라이버시 정보 오용 및 부정사용에 대한 탐지 기술 개발
넷째, 비식별화된 빅데이터 활용을 고려한 실시간 통합관리 및 제어 기술 개발

이를 통해 빅데이터 수집 및 처리 과정에서 발생하는 프라이버시 문제를 비식별화 및 부정사용 방지기법을 통해 해결하는 개인정보보호 연계 시스템으로 활용 가능하다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 기술개발 대상의 국내외 현황

(1) 국내·외 기술 현황

(가) 빅데이터 분석 기술 현황

빅데이터를 다루기 위해서는 다양한 기술들이 필요하다. 하둡과 NoSQL의 성공으로 인하여 빅데이터라는 개념이 정립된 부분도 크며, 파일 시스템과 분산처리 플랫폼을 넘어 다양한 에코시스템이 구축되면서 산업계 표준으로 자리 잡고 있다.

빅데이터를 다루는데 필요한 기술들은 원본 데이터의 저장과 구조적 데이터의 저장, 배치 분산병렬 처리, 데이터 마이닝 등 다양한 기술이 필요하다. 다음의 [표 1]는 빅데이터 분석기술을 분류별로 정리한 것이다.

분류	기술
원본 데이터 저장	대용량 분산 파일 시스템(Hadoop File System 등)
구조적 데이터 저장	대용량 분산 데이터 저장소(NoSQL-HBase, Cassandra, Mongo DB 등)
배치 분산 병렬 처리	MapReduce(Hadoop), 그래프 분석(Pregel, GoldenORB 등)
데이터 스트리밍 프로세싱	S4, Storm
데이터 마이닝	Mahout
기존 솔루션	BI/DW, RDBMS 등
기타	다양한 데이터 알고리즘, 데이터 분석 기술, 분산관리(ZooKeeper), 분산 큐(Kafka), 분산 캐쉬(Memcached, Redis)

[표 1] 빅데이터 분석기술 분류

① 하둡(Hadoop)

하둡은 분산 시스템 상에서 대용량 데이터 처리 분석을 지원하는 오픈소스 소프트웨어 프레임워크로 구글이 개발한 맵리듀스(MapReduce)를 오픈소스로 구현한 결과물임. 하둡 분산파일시스템은 하드웨어 오작동이나 스트리밍 데이터의 접근, 대용량 데이터 집합, 간단한 결합 모델, 다른 종류의 H/W와 S/W 플랫폼과의 호환성 등을 고려하여 설계되어 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

② 카산드라(Cassandra)

카산드라는 분산 시스템에서 방대한 분량의 데이터를 처리할 수 있도록 디자인된 오픈 소스 데이터베이스 관리시스템으로 페이스북이 개발하였으며, 하둡과 같이 아파치 소프트웨어 재단의 프로젝트로 관리되고 있음.

③ 맵리듀스(MapReduce)

맵리듀스는 분산 시스템 상에서 대용량 데이터 세트를 처리하기 위해서 구글이 제안한 소프트웨어 프레임워크로, 하둡에서도 구현됨.

④ NoSQL

NoSQL은 전통적인 관계형 데이터베이스 관리시스템(DBMS)과는 다르게 설계된 비관계형 DBMS로, 대규모 데이터를 유연하게 처리할 수 있다는 장점을 지니고 있음. 이러한 빅데이터 분석기술을 바탕으로 구글과 페이스북, 애플, 아마존, 이베이 등의 플랫폼 사업자는 이미 오래전부터 자체 시스템에 빅데이터를 활용하고 있으며, 앞으로도 더욱 적극적으로 빅데이터를 서비스에 반영하여 활용할 것으로 전망됨.

이와 같은 기술들이 도입되어야 빅데이터를 처리할 수 있는 시스템이 구축이 되며, 많은 데이터를 효율적으로 처리하기 위해서는 분석한 데이터간의 관계를 찾아서 의미 없는 데이터로부터 의미를 찾아내는 기술이 가장 중요한 기술이라 할 수 있다.

산업에서 빅데이터의 활용은 소비자들의 SNS 구조와 정보전달 패턴을 다양한 마이닝 기법으로 파악해 잠재적 소비자 군을 도출할 수 있으며, 소비자에 대한 보다 깊이 있는 이해도를 바탕으로 효과적인 마케팅 정보를 확보할 수 있다.

이를 위해 기업은 새로운 고객 행동에 대한 이해와 비즈니스 데이터의 자산화, 애널리틱 팩토리[1]의 구축을 포함한 빅데이터 도입전략을 구축해야 한다.

다음의 [표 2]는 빅데이터를 도입하여 활용하고 있는 대표적인 업체의 현황이다.

1) 애널리틱 팩토리는 공장에서 제품을 빨리 생산하듯이, 데이터 분석을 모듈화해서 빨리 대응하겠다는 의미이다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

업체	현황
Google	· 검색엔진 등 대부분의 서비스에 빅데이터를 활용(애드워즈, 애드센스 등) 하고 있으며, 대규모 분산처리 분야에서 널리 쓰이는 하둡의 토대가 되는 프레임워크인 맵리듀스를 개발함. · 외부 이용자가 이용할 수 있게 한 빅데이터 서비스인 빅쿼리(BigQuery)제공
facebook.	· 자사 서비스 플랫폼에 올라오는 글과 그림, 동영상 등을 분석하여 이용자 성향이나 관심사항을 파악하여 맞춤형 광고에 활용 중.
ebay	· 9,000만 명 이상의 활동적인 이용자 지원 및 하루 평균 40TB 규모의 새로운 데이터베이스를 수집함. · 옥션 출품물의 이미지와 설명문의 비구조화된 데이터 분석을 통하여 서비스 이용행태를 예측하고 이를 바탕으로 이용자들에게 효율적인 서비스 제시
amazon.com	· 하둡 프레임워크 기반 대규모 데이터 분석기능인 ‘아마존 엘라스틱 맵리듀스’와 데이터 저장서비스인 ‘아마존‘심플스토리지서비스’와 통합됨 · 관리의 부담이 없고, 간편하며, 저렴한 빅데이터 저장분석 솔루션 NoSQL 데이터베이스 서비스인 ‘다이나모DB’출시함

[표 2] 빅데이터 업체 현황

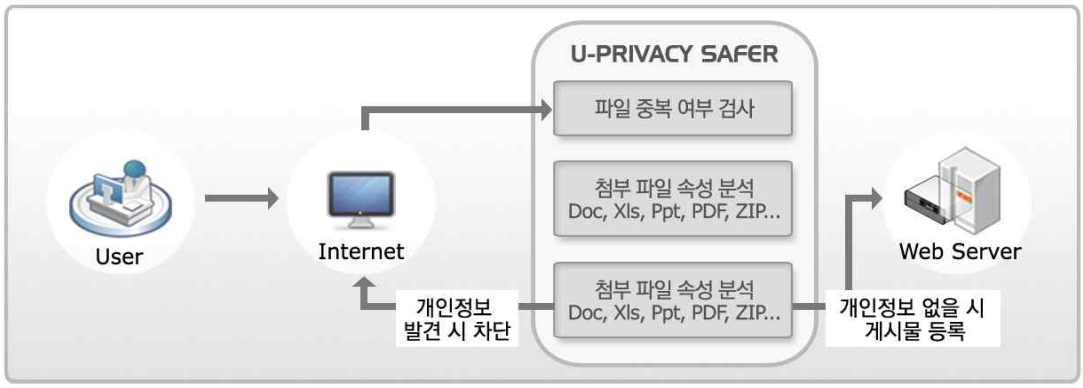
(나) 국내 기술 동향 및 수준(신청 기관 포함)

① 보유 기술 : 이지서티, 개인정보 필터링 솔루션

(주)이지서티는 웹 및 스마트폰에서의 개인정보 검색엔진 기술의 핵심원천기술을 보유(특허등록)하고 있으며 개인정보보호 관련 제품들을 출시하여 시장점유율 1위의 제품으로 시장에 진출한 바 있다. 개인정보보호 분야의 업계 선두의 역할을 위해 연구 및 기술개발을 지속적으로 진행하고 있다. (주)이지서티의 개인정보 보호 제품 중 U-PRIVACY SAFER V3.0은 국내 최초로 CC 인증 EAL 3등급을 획득하였다.

개인정보 보호시스템인 U-PRIVACY SAFER의 주요 특징으로는 주민번호, 신용카드번호, 핸드폰번호, 등 다양한 개인정보 유형에 대한 노출방지를 지원하며, 한글파일, MS-OFFICE 파일 등 각종 파일에 대한 개인정보 포맷 검사, 파일정보 캐싱 기능으로 성능을 향상하였다. 따라서 개인정보의 다양한 정책 및 설치유연성과 서비스 확장성을 확보할 수 있다.

개인정보 보호시스템은 아래와 같이, 웹 방화벽, 방화벽, IDS 같은 네트워크 보안장비와는 별도로 웹 및 첨부파일에서 개인정보 검색 및 차단을 할 수 있는 유일한 시스템이다. 개인정보 보호시스템인 U-PRIVACY SAFER V3.0은 개인정보의 대량 노출 및 유출을 방지할 수 있는 시스템으로 다양한 개인정보 유출 위험에 따른 대응 방안을 제공하는 최적의 솔루션으로 개인정보 패킷 분석 기술 등 다수의 지적 재산권과 첨부파일 필터링 및 다중 보안 필터링(MSF)등에 원천 기술을 보유하고 있다.



[그림 2] U-PRIVACY SAFER 주요기능

② 보유 기술 : 이지서티, PDRA Model(개인정보 분석 모델)

(주)이지서티는 수집된 개인정보를 분석을 위해 PDRA(Privacy Detection and Risk Analysis) 모델을 보유 하고 있다. PDRA 모델은 PC에 기록된 개인정보 항목을 탐지하고 그에 따른 개인정보 중요도를 평가하여 사용자에게 개인정보 유출 시 발생할 수 있는 위험수준을 고지하고, 사용자의 선택에 따라 파일 삭제 혹은 암·복호화를 통해 개인정보를 안전하게 보호할 수 있도록 한다.

PDRA는 총 4가지 구성으로 이루어져 있으며 이에 대해 간략히 살펴보면 다음과 같다.

㉮ PIDM(Privacy Information Detection Mechanism)

사용자가 설정한 경로에서 개인정보 노출 및 오·남용 위험이 있는 일반 text, binary 파일 및 복합문서 등을 추출함.

㉯ PIPM(Privacy Information Patten Analysis & Parsing Mechanism)

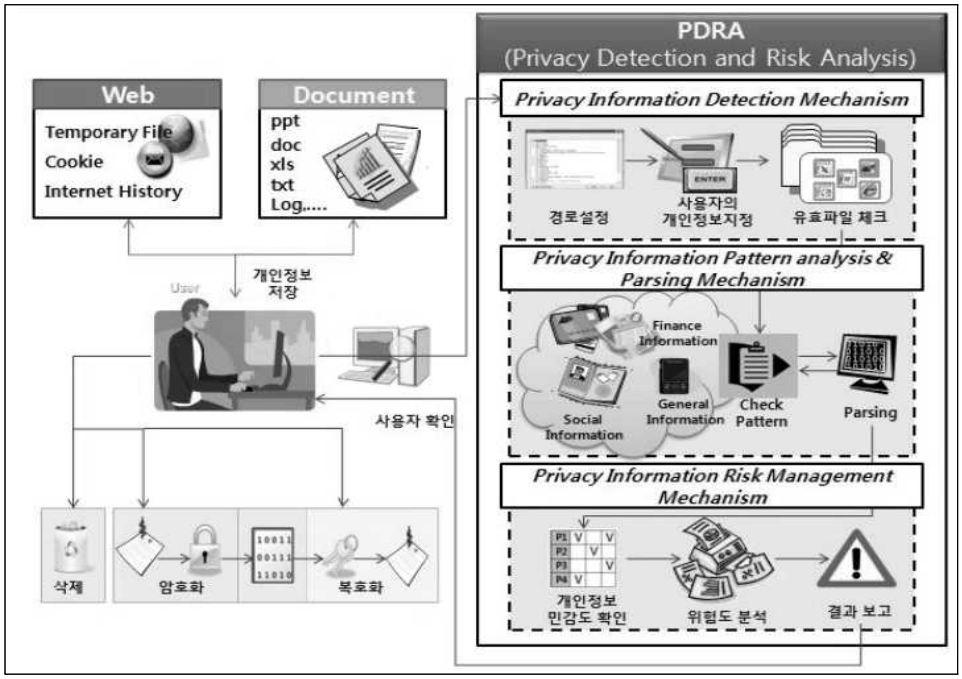
PIDM에서 Gathering된 파일에서 사용자의 사회적 정보, 금융정보 및 일반정보에 대한 항목을 시스템에 설정한 패턴을 통해 탐지함.

㉰ PIRM(Privacy Information Risk Management Mechanism)

각 파일에서 발견된 개인정보에 대해 개인정보 민감도와 개인정보의 조합을 토대로 위험수준을 측정하여 사용자에게 고지함.

㉱ CEM(Crypto Enhanced Mechanism)

사용자의 선택에 따라 개인정보 노출 위험이 있는 파일을 삭제하거나 암호화함으로써, 해킹 및 불법적인 접근을 통한 개인정보 유출을 방지하며, 필요 시 RDCM에서 암호화한 파일을 다시 복호화 하여 파일에 대한 정상적인 접근이 가능하도록 함

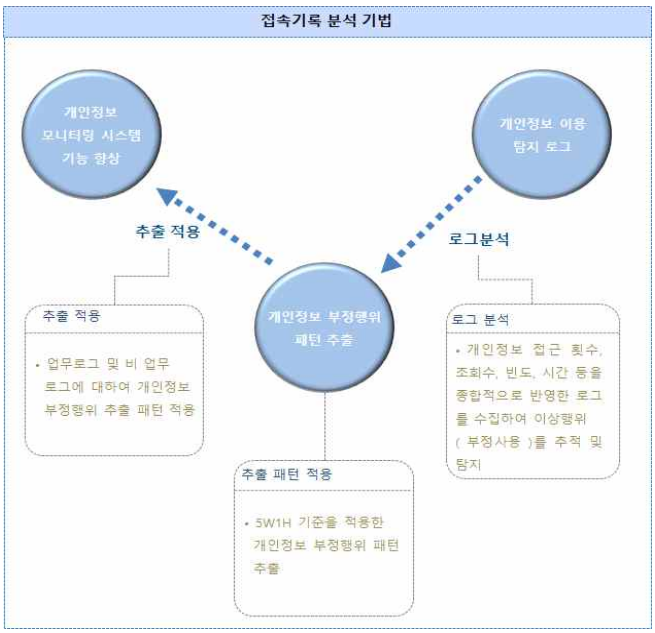


[그림 3]PDRA 모델의 전체 구성도

㈜이지서티는 고유식별정보 및 행정안전부가 기준으로 삼고 있는 개인정보 기본 필터링에 대한 검색 알고리즘을 이미 자체 보유한 상태이다.

③ 개인정보 부정사용 감시

(주)이지서티는 수집된 로그에 대하여 5W1H를 분석하여 도출한 내용을 바탕으로 (주)이지서티가 보유한 개인정보 부정행위 추출 조건에 대입하여 적합한 추출조건을 판단하여 개인정보 수집로그에 적용하여 개인정보 사용행위, 사용자 별 위험분석 및 위험도를 산정하고 부정행위 탐지 기능을 제공한다.



[그림 3] 접속기록 분석 기법

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

o 공신력있는 사업을 구축한 경험으로 보유한 부정행위 탐지 추출 조건(예제)

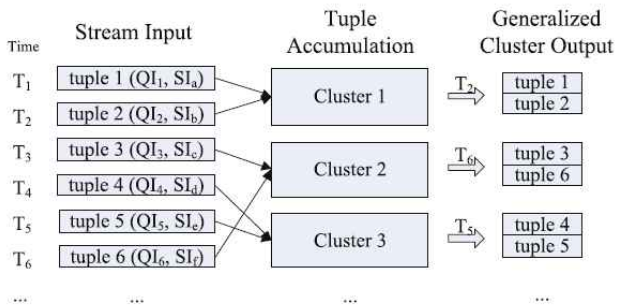
추출 조건 명	설 명
사유 없이 정보과다 열람	업무상의 사유 없이 개인정보를 과다 열람한 경우
직원 비정상 접속	직원이 등록한 소속 이외에 다른IP대역에서 접속한 경우
특정시간대 업무처리	특정시간대 업무를 수행한 경우(공휴일, 휴일, 공단 근무일정 감안)
ID를 다른 IP에서 접속	하나의 ID를 다른 IP에서 접속하는 경우

[표 3] 부정행위 탐지 추출 조건 예제

④ 보유기술 : 이지서티-고려대학교 산학협력단

㉮ 데이터 스트림에서 프라이버시 보호 기술 보유

㉯ 고려대학교 산학협력단에서 개발한 지연 없는 익명화 기법으로 스트림 환경에서 데이터를 익명화 실현



[그림 4] 지연 없는 익명화 기법

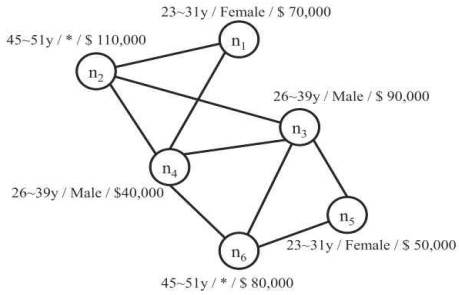
⑤ 보유기술 : 이지서티-고려대학교 산학협력단

㉮ SNS (소셜 네트워크 서비스) 데이터 익명화 기법 연구 기술 보유

㉯ 내용정보와 구조정보를 포함한 SNS 데이터의 익명화 기법

㉰ SNS 데이터 프라이버시 보호 배포를 위한 모델 제안

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 5] SNS 데이터 프라이버시 보호를 위한 모델

⑥ 보유기술 : 국내 대용량 데이터 처리 기술 동향

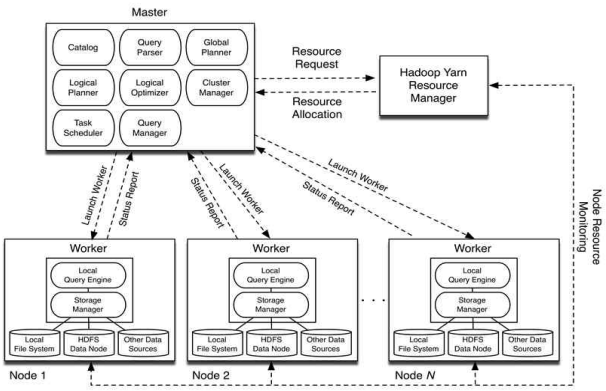
㉮ Tajo : A distributed data warehouse system on large clusters

㉠ 본 연구팀에서 개발한 Hadoop 클러스터 기반 대용량 관계형 데이터 분석시스템

㉡ 국내대학 최초 Apache 오픈소스 프로젝트 선정(현재 Top-level 프로젝트)

㉢ 대용량 데이터의 분산 저장 및 처리 기술 보유

㉣ 자체 개발한 질의 엔진을 사용해 최적화된 분산질의 계획을 설계하며 빠른 처리속도와 낮은 응답 지연시간을 지원



[그림 6] Apache Tajo 시스템의 구조

⑦ 프라이버시 보존 데이터 추출(Privacy Preserving Data Mining) 처리 기술

㉮ 최근 빅데이터 및 IoT 기술의 발전과 함께 개인 프라이버시 보호에 대한 중요성이 제시되었고, 이에 대해서도 기술적인 발전이 필요하다는 의견이 대두되어 학계를 중심으로 프라이버시 보존형 데이터마이닝 기술의 연구가 진행 중

㉯ 연이어 터지는 업계의 개인정보 유출 사건으로 인해 대중의 개인 프라이버시 보호에 대한 관심 또한 높아지고 있으나, 아직 업계에서 데이터 분석 단계에 PPDM 기술을 적용하기에는 성능이나 정확도 측면에서 여러 가지 장벽이 존재

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑧ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술

㉮ 2014년 1월 한국데이터베이스진흥원에서 원본 개인정보 레코드들을 그룹핑하여 대표레코드로 변환하는 비식별화 기술의 재식별 불가능성에 대해 기술 검증을 진행

비식별화 변환 기술	결과 왜곡 가능성	속성 정보 손실 가능성	재식별 가능성	
			역추적기법	연계분석 기법
대표레코드 생성	**X**	**X**	**X**	**X**
암호화	X	X	△	X
총계처리	○	X	X	X
삭제	○	○	X	X
범주화	○	X	X	○

[표 4] 비식별화 변환 기술 비교

㉯ 현재의 비식별화 기술들은 대부분 저장된 레코드에 대하여 적용되는 기술들로 스트림 데이터에 대해서 비식별화를 수행하는 기술연구는 부족

⑨ 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술 현황

목록 / 구분	기관명(년도)	도메인	특징
개인정보 접속 모니터링	㈜이지서티	네트워크 트래픽	
4G망 공격/비정상 트래픽 탐지 및 대응 기술 개발	한국 인터넷 진흥원(2014년)	4G 데이터 망	4G망 트래픽 탐지 및 이상 징후 기술 개발
좀비 PC와 C&C서버간의 통신 지연 시간을 분석하여 C&C 서버와의 역접속을 탐지하는 기술	Wins(국내) 스나이퍼 APTX(2013년)	네트워크 트래픽	신속한 역접속 탐지・차단이 가능
시그네쳐(패턴)에 의한 탐지와 지능형 행위기반 악성코드 분석 엔진 탐지를 연계	NPcore(국내)	네트워크 트래픽	1. 패턴에 의한 악성코드 치료 및 행위기반 악성코드 치료 2. 비정상 트래픽 발생 탐지/차단
사용자 입력 패턴 및 전자 금융 거래 패턴을 이용한 모바일 뱅킹 이상치 탐지 방법	한국인터넷정보학회(2013년)	모바일 사용자 입력 패턴	사용자의 입력 패턴과 거래 패턴 데이터를 이용하여 특정 사용자를 식별한 후 비정상 거래 구분

[표 5] 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술 현황

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(다) 국외 기술 동향 및 수준

① 기본적인 데이터 프라이버시 보호 모델

㉮ k-익명성, l-다양성, t-접근성 등 근본적인 데이터 익명화 모델 개발

㉯ 현재까지 데이터 익명화에 KLT (k-익명성, l-다양성, t-접근성) 비식별화 모델이 우세적으로 이용됨

㉰ Anatomy[2]는 데이터 그룹화 기법을 사용한 통계적 정확성을 유지하는 방향으로 프라이버시 보호

㉱ k-익명성

㉠ 공개 데이터에 대한 연결 공격을 방어하기 위해 2002년 L. Sweeney가 제안한 프라이버시 보호 모델

㉡ 데이터 집합의 일부를 수정하여, 모든 레코드가 자기 자신과 동일한(구별되지 않는) k-1개 이상의 레코드를 가짐

㉲ l-다양성

㉠ k-익명성에 대한 두 가지 공격, 즉 동질성 공격 및 배경지식에 의한 공격을 방어하기 위해 2006년 A. Machanavajjahala 등이 제안한 프라이버시 보호 모델

㉡ 익명화 과정에서, 충분히 다양한 (l개 이상), 서로 다른 민감한 정보를 갖도록 동질 클래스를 구성

㉳ t-근접성

㉠ l-다양성의 취약점(쏠림 공격, 유사성 공격)을 보완하기 위해 2007년 N. Li 등이 제안한 프라이버시 보호 모델

㉡ 민감한 정보의 분포를 고려, 민감한 정보의 의미(semantics)까지 파악하는 프라이버시 모델

	준식별자			민감한 정보
	지역 코드	연령	성별	질병
1	130**	< 30	*	전립선염
2	130**	< 30	*	전립선염
3	130**	< 30	*	고혈압
4	130**	< 30	*	고혈압
5	1485*	> 40	*	위암
6	1485*	> 40	*	전립선염
7	1485*	> 40	*	고혈압
8	1485*	> 40	*	고혈압
9	130**	3*	*	위암
10	130**	3*	*	위암
11	130**	3*	*	위암
12	130**	3*	*	위암

[표 6] k-익명성 모델에 의해 익명화된 의료데이터의 예

	준식별자			민감한 정보
	지역 코드	연령	성별	질병
1	1305*	≤ 40	*	전립선염
4	1305*	≤ 40	*	고혈압
9	1305*	≤ 40	*	위암
10	1305*	≤ 40	*	위암
5	1485*	> 40	*	위암
6	1485*	> 40	*	전립선염
7	1485*	> 40	*	고혈압
8	1485*	> 40	*	고혈압
2	1306*	≤ 40	*	전립선염
3	1306*	≤ 40	*	고혈압
11	1306*	≤ 40	*	위암
12	1306*	≤ 40	*	위암

[표 7] l-다양성 모델에 의해 익명화된 의료데이터의 예

2) Anatomy는 KLT 비식별화 모델에서 이용되는 데이터 일반화 방식이 아닌 데이터 그룹화 기법을 사용한 비식별화 기법으로 KLT 비식별화 모델보다 정보 손실을 최소화 시키는 통계적 정확성 유지 비식별화 기술이다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

	준식별자		민감한 정보	
	지역 코드	연령	급여 (백만원)	질병
1 3 8	4767* 4767* 4767*	≤ 40 ≤ 40 ≤ 40	30 50 90	위궤양 만성 위염 폐렴
4 5 6	4790* 4790* 4790*	≥ 40 ≥ 40 ≥ 40	60 110 80	급성 위염 감기 기관지염
2 7 9	4760* 4760* 4760*	3* 3* 3*	40 70 100	급성 위염 기관지염 만성 위염

[표 8] t-다양성 모델에 의해 익명화된 의료데이터의 예

② 다양한 환경에서의 응용 데이터 프라이버시 보호 모델

㉮ 스트림 데이터 환경에서의 프라이버시 보호 기법이 제안됨

㉯ 그래프 환경에서의 프라이버시 보호 기법으로 소셜 네트워크 서비스 등에서 이용되는 그래프 데이터 프라이버시 보호 기법이 개발됨

③ 프라이버시 보존 데이터 추출(Privacy Preserving Data Mining) 처리 기술

㉮ 법적인 제도의 제약과 함께 프라이버시 보존형 데이터 마이닝의 기술에 대한 연구의 필요성이 1990년대 후반부터 대두되어 옴

㉯ 학계 및 일부 기업 연구소에서 프라이버시 보존형 데이터 마이닝 기술에 대해 관심을 갖고 연구가 진행되어 왔음

㉰ 버클리, 코넬 및 다수의 대학 연구소에서 관련된 기술을 연구

㉱ IBM의 연구소를 중심으로 일부 기업에서 프라이버시 보존형 데이터 마이닝 기술에 대한 연구를 진행

㉲ 학계를 중심으로 PPDM에 관련된 연구가 활발히 진행 중이며 실제 적용 방법으로는 PPDM 알고리즘을 적용하는 방안과 SMC(Secure Multi-parity Computation) 기술을 적용하는 방법이 있음

㉳ PPDM 알고리즘은 크게 Anonymization, Perturbation, Randomized Response, Condensation approach, Cryptography 기반의 접근법으로 나눌 수 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

㉠ PPDM의 알고리즘을 평가하는 기준

평가척도	설명
Performance	알고리즘 자체의 성능
Data Utility	데이터의 정보나 기능적 손실 정도
Uncertainty	민감한 정보의 숨김 정도
Resistance	일반적인 알고리즘과의 오차 정도

[표 9] PPDM알고리즘 평가 척도

㉡ 이중 일부 척도에서 우수한 성능을 보이는 알고리즘이 개발된 바는 있으나 모든 평가 척도에서 다른 알고리즘들의 성능을 뛰어넘는 기술은 아직 개발되지 못한 실정

㉢ 이론적인 발전에도 불구하고 아직 업계에 기술을 적용하기에는 장벽이 존재하여 활발히 사용되고 있지는 않으며, 의료 서비스 업계를 주축으로 프라이버시 보존형 마이닝 기술의 적용 사례가 일부 등장하고 있음

㉠ datafly 등의 제품이 실제 의료계에서 프라이버시 문제없이 데이터를 사용하게 해주는 기술로 사용

④ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술

㉮ 개인정보 보호에 대한 이슈가 커지며 업계에서도 데이터의 비식별화의 필요성이 대두되기 시작하였고, 기존의 DBMS에 연동하여 비식별화 변환을 수행하는 모듈이나 SW 도구가 개발됨

㉠ 오라클의 Data Masking Pack 제품은 오라클 DB 상에서 구동 가능한 애드온 도구로 데이터 마스킹, 교체, 조건성 마스킹 등의 비식별화 기능을 제공

㉡ Informatica의 Data Privacy는 여러 상용 DB 플랫폼들(Oracle, DB2, MS SQL Server, MySQL 등)과 연동되는 tool kit으로 제공되며 이들의 비식별화를 지원

㉢ 글로벌 DB 보안 솔루션 벤더들은 기존의 다양한 보안 기술에 개인 식별정보 암호화 기술을 추가하여 DB 보안 솔루션을 제공하는 추세를 보임

㉣ IBM InfoSphere Data Privacy 솔루션에서는 다양한 보안 이슈 처리와 함께 개인 식별정보에 대한 암호화 기능을 제공하여 분석 시 민감 정보들의 보호가 가능

㉯ 학계에서는 통계적 정확성 유지를 위한 비식별화 기술에 대해 일부 연구가 이루어지고 있으나, 업계에서는 아직까지 주로 가명처리, 총계처리, 데이터 값 삭제, 범주화, 데이터마스킹, 등 간단히 적용 가능한 비식별화 기술까지만 활용 중

㉰ 개개인에 대한 micro-data에 대한 요구가 증가하며, Statistical disclosure control 기술에 대한 업계의 관심도 역시 증가하였고, 이러한 문제를 해결하기 위한 공개 패키지가 개발되어 공개됨

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

㉱ 구글, 페이스북등의 인터넷 서비스 기업들은 이용자의 웹 사용 로그를 비식별화하여 광고에 사용하는 리타케팅 기법을 사용하여 이익을 창출하고 있으며, 미국의 경우 이와 관련해 온라인 행태 정보 수집, 이용, 공개를 규제하는 법안 초안이 작성됨

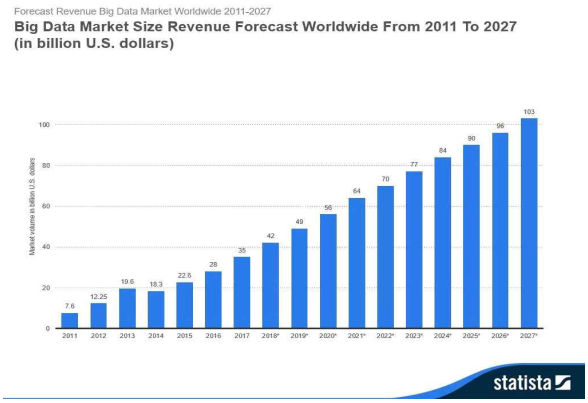
⑤ 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

목록 \ 구분	기관명(년도)	도메인	특징
PAM	IBM(2012년)	각 프로토콜 및 MS오피스 및 PDF 등 문서 파일	기존 패턴매칭의 탐지 방법에서 벗어나 프로토콜을 디코딩하는 방법을 택함
Etrust	Computer Associate	시스템 콜 분석	OS의 취약성을 통한 접근 시도 차단
Intrusion Prevention System Software Blade	Check Point	방화벽	게이트웨이 속도 감소 없는 네트워크 보안

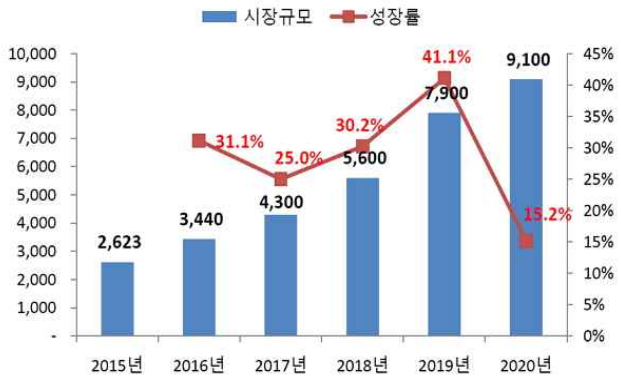
[표 10] 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

(2) 국내·외 시장 현황

(가) 국내·외 시장 규모 및 수출·입 현황



[그림 7] 2011-2027 빅데이터 마켓 성장추이
(출처, BigDataMonthly42, K-ICT, 2018)



[그림 8] 2015-2020 국내 빅데이터 성장 추이
(출처, 국내외빅데이터 시장전망보고서, KRG,2018)

① 국내 빅데이터 시장 전망

K-ICT, 2018 및 IT시장분석기관 KRG이 최근 발간한 보고서에 따르면 빅데이터 시장은 전 세계 규모는 2018년 420억 달러(46조원)에서 2027년 1030억 달러(116조원) 규모로 증가하는 등 소프트웨어 부분에서 가장 빠른 속도로 증가할 것으로 보고 있다. 국내 시장도 2018년 전년대비 30% 증가한 5600억 규모로 예상하고 내년에는 40% 증가한 7,900억대로 늘어날 것으로 보

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

고 있다.

빅데이터를 활용하기 위해서는 개인정보보호법등의 개인정보에 대한 제약 때문에, 여전히 빅데이터를 도입한 기업 중 35%정도는 파일럿 수준이며, 미도입 기업들도 약 42% 향후 도입 계획이 있는 것으로 나타나서, 개인정보에 대한 비식별 시장은 여전히 크고 앞으로도 더욱 성장할 것으로 보인다.

② 국내·외 주요 수요처 현황

㉮ 국내 주요 수요처 현황

시장구분		2015년 (단위: 억 원)	2016년 (단위: 억 원)	성장률
정부/공공 시장		698.0	998.6	43.1%
민간시장	기업의 빅데이터 시스템 투자	1,791.0	2,278.4	27.2%
	빅데이터 분석 대행 서비스 시장	134.0	162.6	21.3%
	소계	1,925.0	2,441.0	26.8%
합계		2,623.0	3,439.6	31.1%

출처: 2016년 빅데이터 시장현황조사 (한국정보화진흥원)

[표 11] 시장영역별 국내 빅데이터 시장 규모

공공부문에서는 행정안전부에서는 공공기관이 생성 또는 취득하여 보유하고 있는 공공데이터를 한 곳에서 제공하는 통합창구로 공공데이터 포털을 운영하고 있다. 2013년 5,272건에서 2017년 12월 24,636건으로 5배가량 늘어났다. 더 많은 공공부문에서도 데이터 공개에 따라 더 많은 시장이 열릴 것이다. 민간부문에서는 네이버(네이버 데이터 랩) 와 SK(SK 빅데이터 허브) 등과 같이 다른 데이터와 결합하여 분석, 활용할 수 있는 시장을 더 키워가고 있다.

(3) 국내·외 경쟁기관 현황

(가) 본 기술/제품과 직접적 경쟁관계에 있는 국내·외 기관·기업 현황

① 데이터 프라이버시 관련 소프트웨어를 개발하는 기업 현황

㉮ IBM

㉠ IBM Infosphere Optim software를 개발하여 데이터 프라이버시를 위한 시스템 개발

㉯ Privacy Analytics

㉠ 2007년 설립되어 의료 데이터 익명화를 위한 PARAT software 개발

② 연구 목적으로 데이터 프라이버시 관련 시스템을 개발하는 연구기관 현황

㉮ TU München

㉠ k-익명성, l-다양성, t-근접성을 적용시킨 오픈소스 ARX-Powerful Data Anonymization

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Tool을 배포

㉯ UT Dallas Data Security and Privacy Lab

㉠ Mondrian, Incognito를 고려한 k-익명성, l-다양성, t-근접성 그리고 Anatomy를 적용시킨 UTD Anonymization ToolBox 개발

㉡ 위 기관들의 기술로는 대용량 데이터 익명화를 빠르게 처리하는 데에 있어 한계 발생

③ 프라이버시 보존 데이터 추출(Privacy Preserving Data Mining) 처리 기술

㉮ (국외) 학계를 중심으로 PPDM에 관련된 연구가 활발히 진행 중이며 PPDM의 기술적인 구분은 크게 Anonymization, Perturbation, Randomized Response, Condensation approach, Cryptography 기반의 접근법으로 나눌 수 있음

㉯ (국외) 최근 들어 일부 의료계나 방법 시스템에 특화되어 사용되고 있던 PPDM 기술의 범위가 실제 다양한 도메인의 데이터에 적용할 수 있도록 지원하는 제품들이 공개 중

㉠ 버클리에서 2012년 PPDM을 위한 오픈소스 플랫폼 GUPT 시스템을 제작 및 공개함

㉡ (국내) 최근 일부 대학 연구소에서 연구가 수행되고 다양한 학회지에 성과를 보고

④ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술

㉮ (국내) 국내의 비식별화 제품이나 솔루션은 대부분 암호화, 마스킹 기술에 치중되어 있으며, 삭제, 총계처리 등의 비식별화 변환 기술을 손쉽게 적용할 수 있는 제품 및 솔루션은 부족

㉠ 국내 기업 중 펜타시큐리티, 이글로벌, 이사인, 소프트포럼, 신시웨이와 같은 벤더에서 DB 암호화 솔루션을 제공

㉡ 웨어벨리, 소만사, 코아인포메이션 등의 벤더들이 데이터 마스킹 기술이 적용된 제품을 제공하고 있으나 실시간 비식별화 변환 기술은 제공되지 않음

⑤ (국외) 글로벌 DB 벤더 회사들은 분석시스템 내에 비식별화 기능이 추가된 솔루션이나 비식별화 기능을 제공하는 제품을 제공하며 IBM을 선두로 하여 실시간 빅데이터 비식별화 기술의 연구 및 상용화가 이루어지고 있음

㉮ IBM에서 제공하는 InfoSphere Data Privacy 솔루션에서 데이터 스트림의 실시간 암호화, 비식별화 변환을 지원

㉯ IRI에서 제공하는 fieldShiled 제품은 SQL 로직을 활용한 반 실시간성의 비식별화 기술이 포함됨

⑥ (국외) 향후 데이터 분석 시 품질유지를 위한 비식별화 기술이 학계에서 다양하게 제보되고 있으며, 업계에서도 이러한 문제를 해결하기 위한 기술 적용의 필요성이 증대됨에 따라 일부 제품이 공개된 상황

㉮ The International Household Survey Network (IHSN)는 microdata 제공 및 사용을 원하는 사람들을 위한 R에서 사용가능한 SDCMicro 오픈소스 패키지를 공개

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

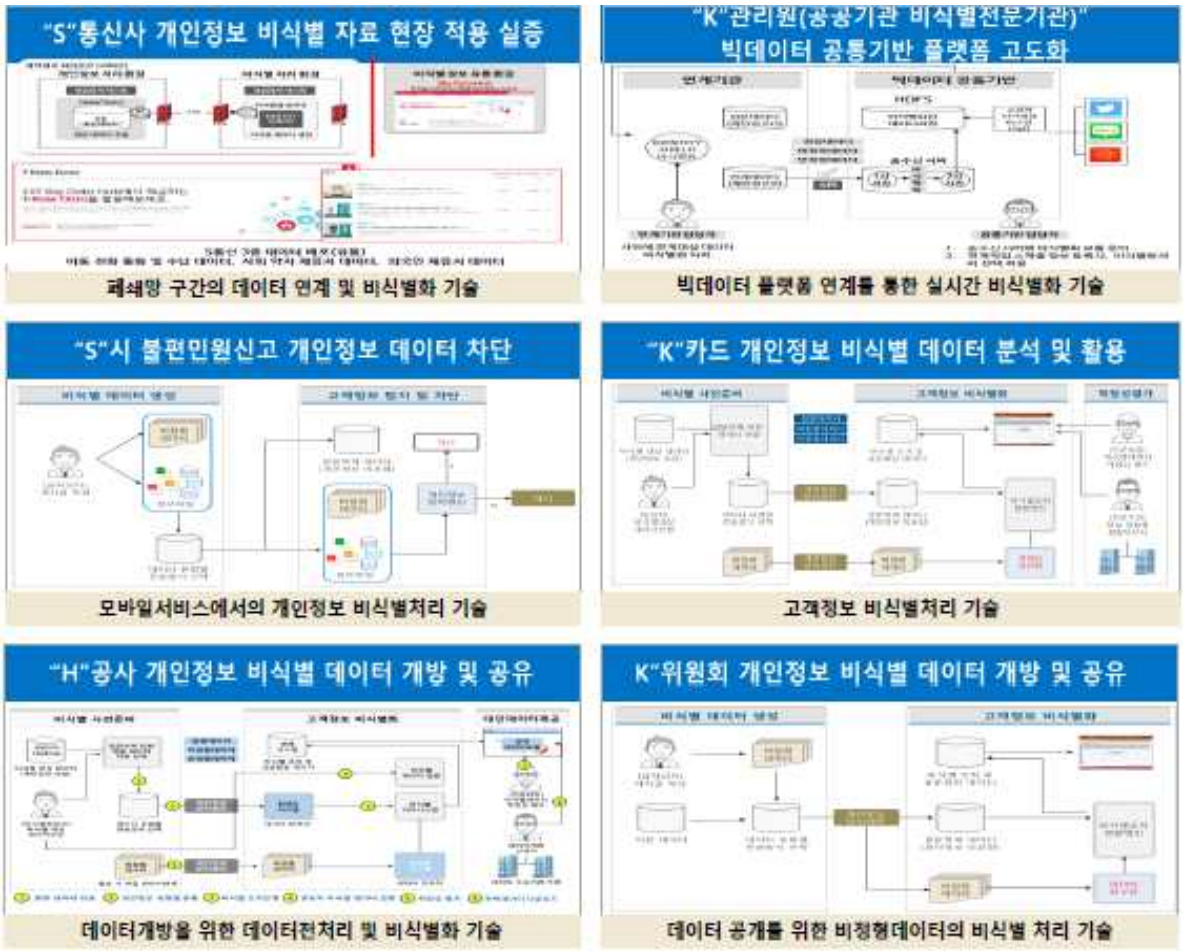
⑦ ㈜이지서티 - 아이덴티티 쉴드 (IDENTITY SHIELD)

㉮ 빅데이터 내의 정형, 비정형 데이터에서 개인정보를 식별하고 가명화, 익명화 등의 고전적 비식별뿐만 아니라 K,L,T 프라이버시모델(K-익명성, L-다양성, T-근접성)을 이용한 비식별화 솔루션



[그림 10] IDENTITY SHIELD (개인정보 비식별조치 솔루션)

㉯ 국내 최대 비식별화 구축 사업 진행



[그림 10] IDENTITY SHIELD 주요 구축사례

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

㈐ 주요특징

㉠ GS 인증(1등급) 획득 2018.8

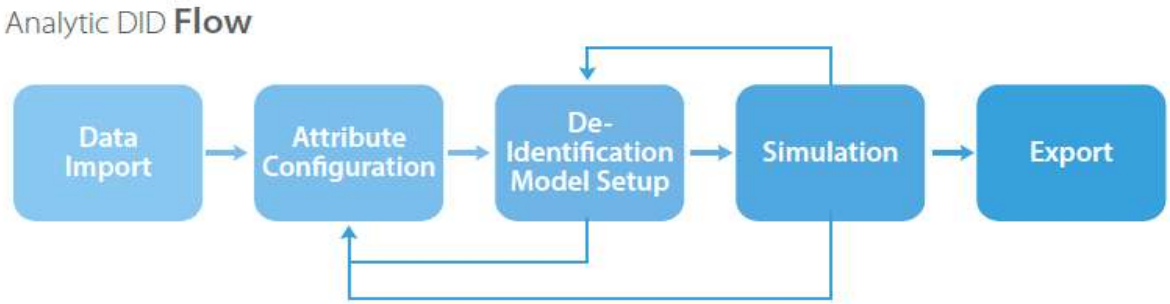
㉡ 비식별 가이드라인 충족

㉢ 공인인증기관 유일 BMT 통과

㉣ 국내 유일 빅데이터 적용

⑧ 파수닷컴 - 애널리틱 디아이디 (Analytic DID)

㉮ 빅데이터 내의 개인정보를 마스킹을 통해 비식별화 솔루션

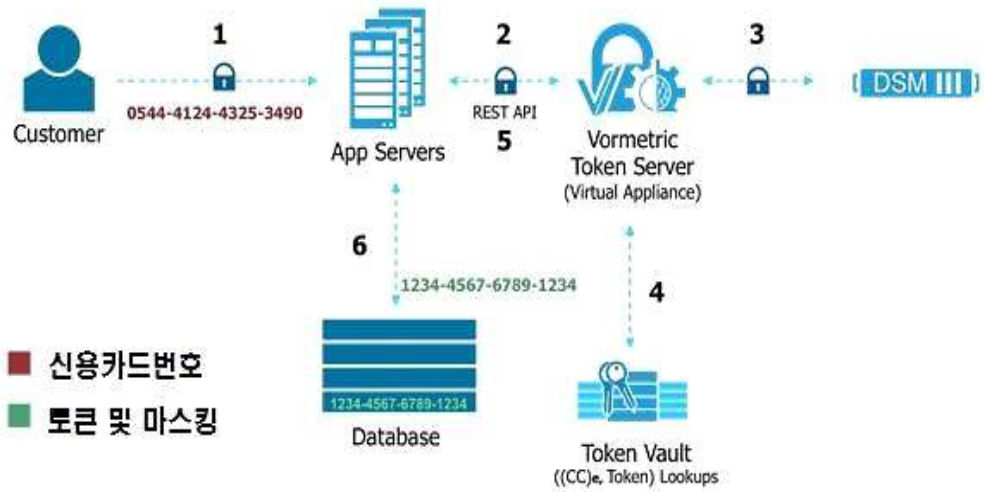


[그림 11] 파수닷컴 - Analytic DID

⑨ 보메트릭 코리아 - 보메트릭 토큰 서버

㉮ 어플리케이션 단계에서의 토큰화 기술을 통해 데이터를 가명 처리 및 마스킹 처리를 하는 기술

㉯ 동적인 데이터 마스킹 및 속성 유지 토큰화 기술을 이용하여 데이터의 형식을 보존하여 성능의 영향 없이 민감한 정보를 보호할 수 있다.



[그림 12] 보메트릭 - 토큰서버

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

⑩ 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

기관 / 구분	제품 명	도메인	특징
㈜이지서티	U-PRIVACY SAFER	네트워크 트래픽	개인정보 탐지 및 차단
㈜이지서티	UBI SAFER- PSM	개인정보처리 시스템	개인정보처리 시스템 접속기록 관리
㈜나솔	SmartXFilter	MS오피스 및 PDF 등 문서 파일	비정상 트래픽 분석 사용
AhnLab	MDS	웹, 이메일, 파일 전송(FTP 등)	정적(static) 및 동적(dynamic) 악성코드 분석 기술과 노하우가 융합된 하이브리드 분석 기술을 통해 알려지지 않은 신종 위협까지 탐지
NPcore	Zombie Zero	네트워크 트래픽	1. 패턴에 의한 악성코드 치료 및 행위기반 악성코드 치료 2. 비정상 트래픽 발생 탐지/차단
Wins	스나이퍼 APTX	네트워크 트래픽	신속한 역접속 탐지・차단이 가능
Computer Associate	Etrust	시스템 콜 분석	OS의 취약성을 통한 접근 시도 차단
IBM	PAM	각 종 프로토콜 및 MS오피스 및 PDF 등 문서 파일	기존 패턴 매칭의 탐지 방법에서 벗어나 프로토콜을 디코딩 하는 방법을 택함

[표 12] 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(4) 국내·외 지식재산권 현황

(가) 관련 기술/제품의 국내 지식재산권(특허 등) 현황

등록국가	등록번호 / 특허번호	출원일자	특허명	특허권자
대한민국	1019049010000	2016.11.24	등록 아이디 발급을 통한 원본 데이터 관리 방법 및 장치	㈜이지서티
대한민국	1020180120444	2017.04.27	비식별화 데이터 셋 결합용 키 생성 장치 및 방법	㈜이지서티
대한민국	1020180120443	2017.04.27	개량된 K-익명성 모델 이용 데이터 셋 비식별화 방법 및 장치	㈜이지서티
대한민국	1017842650000	2016.06.09	빅데이터의 비식별화 처리 방법	주식회사 보아라((구)그리즐리)
대한민국	1015859850000	2015.01.19	개인정보 비식별화 전송장치 및 전송방법	경희대학교 산학협력단
대한민국	1020140117449	2014.09.04	정형 및 비정형 데이터를 포함하는 빅데이터에서의 개인정보 익명화 관리 시스템	주식회사 바넷정보기술
대한민국	1010934200000	2010.01.06	소셜 네트워크에서의 개인정보보호 시스템 및 그 방법	고려대학교 산학협력단
대한민국	1020137002157	2013.01.25	익명화 건강관리 및 기록 시스템	마이크로소프트 코포레이션
대한민국	1011974430000	2010.12.07	K-익명성을 제공하는 정보 보호 방법 및 장치	서울대학교 산학협력단
대한민국	1007882780000	2005.12.20	정보의 익명화를 위한 데이터 저장 시스템 및 방법	주식회사 유케어소프트
대한민국	1017047020000	2016.04.18	태깅 기반의 개인정보 비식별화 시스템 및 방법	(주)케이사인
대한민국	1018044260000	2016.06.17	GPGPU를 이용한 데이터 익명화의 병렬적 처리 방법	고려대학교 산학협력단
대한민국	1017291980000	2016.01.19	개인정보 비식별화 전송장치 및 전송방법	경희대학교 산학협력단
대한민국	1017983780000	2016.06.30	유전알고리즘에 기초한 개인정보의 비식별화 방법 및 절차	(주)파수닷컴
대한민국	1018792660000	2016.09.27	개인정보 비식별화 검증 시스템	(주)조은아이앤에스
대한민국	1018596360000	2017.07.19	보안기능을 가지는 개인정보 비식별화 시스템 및 방법	주식회사 디지털즈

[표 13] 데이터 익명화를 다루는 대표적 기술에 대한 국내 특허 현황

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(나) 관련 기술/제품의 국외 지식재산권(특허 등) 현황

등록국가	등록번호 / 특허번호	출원일자	특허명	특허권자
미국	US8140502 B2	2008.06.27	Preserving individual information privacy by providing anonymized customer data	Microsoft Corporation
미국	US8627483 B2	2008.12.18	Data anonymization based on guessing anonymity	Accenture Global Services Limited
미국	US20140380489 A1	2013.06.20	Systems and methods for data anonymization	Alcatel-Lucent Bell Labs France
미국	US20110113049 A1	2009.11.09	Anonymization of Unstructed Data	International Business Machines Corporation
미국	US20040078238 A1	2002.05.31	Anonymizing tool for medical data	Carson Thomas, Sally Lee, Renuka Uppaluri
미국	US09858699 B2	2017.01.27	Image anonymization using analytics tool	International Business Machines Corporation
미국	US09894063 B2	2016.04.17	Anonymizing biometric data for use in a security system	International Business Machines Corporation
미국	US20160224805 A1	2016.02.01	METHOD AND APPARATUS FOR ANONYMIZED MEDICAL DATA ANALYSIS	Jordan Patti
유럽	EP03166053 A1	2016.10.20	COMPUTER-IMPLEMENTED SYSTEM AND METHOD FOR AUTOMATICALLY IDENTIFYING ATTRIBUTES FOR ANONYMIZATION	Palo Alto Research Center, Incorporated
유럽	EP03136284 A1	2016.07.19	PERSONAL INFORMATION ANONYMIZATION METHOD, PERSONAL INFORMATION ANONYMIZATION PROGRAM, AND INFORMATION PROCESSING APPARATUS	FUJITSU LIMITED
중국	CN107135197 A	2017.03.21	Chain k-anonymous location privacy protection method based on grey prediction	NANJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS
중국	CN107145796 A	2017.04.24	K-anonymity privacy protection method for track data in uncertain environment	CHINA MARITIME POLICE ACADEMY
일본	JP29138991 A	2017.02.17	PERSONAL INFORMATION ANONYMIZATION METHOD, PERSONAL INFORMATION ANONYMIZATION PROGRAM, AND INFORMATION PROCESSING APPARATUS	TERARECON INC

[표 14] 데이터 익명화를 다루는 대표적 기술에 대한 국외 특허 현황

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(다) 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

기관 / 구분	특허 명	도메인	특징
IBM X-FORCE	Shellcode Heuristics (SCH)	파일 포맷	파일 포맷 취약점을 공격하는 Shellcode를 행위 기반으로 인식하여 차단

[표 15] 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

① 데이터 익명화 기법 및 도구들은 지속적으로 연구/개발 되어 왔음
② 데이터 익명화에 따른 정보손실을 최소화하기 위한 연구도 많이 수행 됨
③ 한편, 차세대 하드웨어를 활용한 데이터 익명화 기술과 대용량 데이터를 익명화하는 기법에 관련된 국내·외 지식재산권 등록은 성과가 미비한 현황
   ㉮ 속도 향상을 위한 데이터 익명화 기술은 현재까지 개발이 거의 이루어지지 않음
   ㉯ 대용량 데이터를 익명화 하는 기술은 비교적 기술의 성숙도가 낮고 현재까지 선점된 지식재산권이 매우 드문 상황
④ 본 과제에서 제안하는 소프트웨어 개발은 기존의 특허와 충돌하지 않게 대용량 데이터를 효율적으로 익명화 하는 기법에 중점을 둠
⑤ 이에 본 기술 개발은 데이터 익명화 속도향상 측면과 효과적인 대용량 데이터 익명화 처리의 발전으로 특허 및 지식재산의 선점의 기회가 증가할 것으로 기대

(5) 국내외 표준화 현황

(가) 본 기술/제품과 직접적으로 관련 있는 국내 표준화 현황

① 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

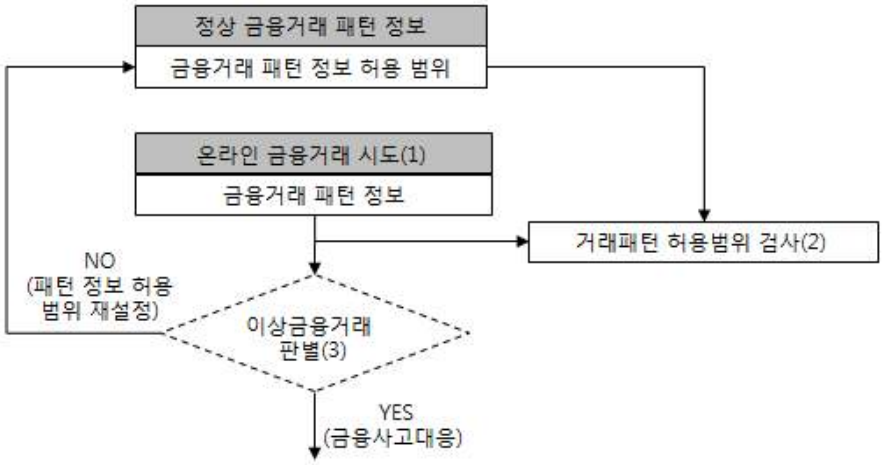
㉮ 이상금융거래 탐지 (TTAK.KO-12.0178)

㉠ 전자금융 이용자의 금융이용 환경, 금융 거래 패턴, 거래 사전 행위 분석을 통해 이상 금융 거래를 정의하고 있으며, 이상 금융 거래의 탐지를 위한 요구 사항들과 금융이용 환경, 금융 거래 패턴, 거래 사전 행위를 통한 이상 금융 거래 탐지 및 대응방법을 제시

㉡ 거래 패턴 기반 탐지 및 방법의 예 : 금융거래패턴에 의한 탐지는 금융거래 이용자의 과거 거래패턴을 기반으로 이상금융거래를 탐지하며, 이상금융거래 탐지 여부에 따라 금융거래 패턴정보는 지속적으로 재설정 되어야 함[3)]

3) 출처 : 이상금융거래 탐지 및 대응 프레임워크, 한국정보통신기술협회(TTA), 2011.11,

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 13] 금융거래 패턴정보 허용범위 재설정

㉯ 침입 탐지 시스템 기능 패키지 (TTAS.KO-12.0026)

㉠ 침입 탐지 시스템의 보안 요구사항을 서술하는 보호 프로파일이나 보안목표 명세서를 작성할 때 참고할 수 있는 기능 패키지

② 금융 빅데이터 환경에서 비식별 처리를 위한 소프트웨어의 구조 및 기능

㉮ 금융보안원 산하 금융보안표준화협회에서 표준화 제정 (2018-12)

㉯ 표준화 제안 : 이지서티, 파수닷컴, 펜타시스템

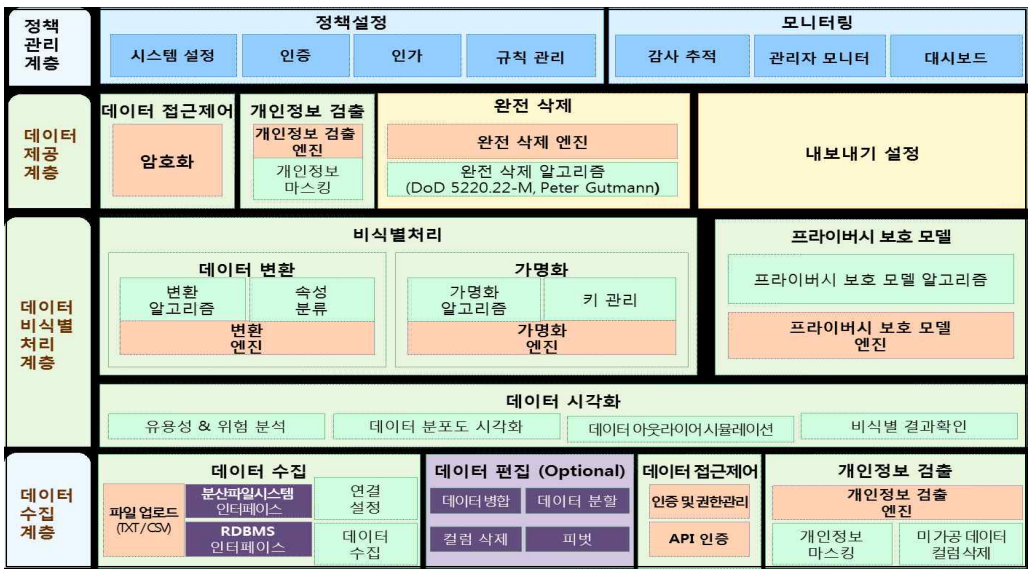
㉰ 목적 및 주요 내용

금융회사는 고객의 요구에 부합하는 다양한 금융서비스 개발 및 확대를 위하여 고객의 금융 데이터 등이 포함된 빅데이터 분석 및 활용을 필요로 한다. 금융회사는 이 과정에서 개인정보보호를 위하여 비식별 처리가 필요하다.

㉠ 비식별처리 소프트웨어 구조

㉡ 비식별처리 소프트웨어 계층별 요구사항

㉢ 비식별처리 소프트웨어 기능



[그림 14] 빅데이터 활용을 위한 비식별 처리 소프트웨어 구조

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(나) 본 기술/제품과 직접적으로 관련 있는 국외 표준화 현황

① 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 기술

㉮ 침입 탐지 시스템

㉠ 취약성 목록에 대한 표준화와 침입 탐지 시스템 자체에 대한 표준화로 구분되어 진행

㉡ CVE(http://www.cve.mitre.org) 에서 FedCIRC, U.S. General Services Administration 등의 재정 지원을 통해 취약성에 대한 용어 표준화를 추진 중[4)]

㉯ Zasmin

㉠ 한국전자통신연구원에서 연구를 수행한 Zasmin 기술이 국제전기통신연합(ITU-T)[5)]에 의해 국제 표준화 과제(X.sisfreq)로 신규 채택된 바 있음

㉰ GDPR

㉠ EU의 개인정보 보호 규정(GDPR, General Data Protection Regulation)이 2016년 4월 14일 유럽의회를 통과했으며, EU 국가 내에서 활동 중인 모든 기업들은 발효인인 2018년 5월부터 새로운 종합 데이터 보호법을 적용해야 함; 영국 정부는 이를 'post-Brexit' 영국 법령집에 적용시킬 것을 발표

다. 기술개발의 중요성

(1) 개발 대상 기술·제품의 중요성

(가) 개인 정보 유출 피해 사례 증가

① 매년 개인 정보 유출 피해가 증가하는 추세 ([그림 15] 참조)



[그림 15] 개인정보침해 신고 상담 건수

② 2011년 네이트의 데이터베이스에 저장된 가입자 3500만 명의 개인정보 유출 사고 (조선일보 2011.07.26.)

㉮ 가입자들의 아이디, 비밀번호, 이름, 주민등록번호, 연락처 등의 개인정보 유출

㉯ 전화 금융사기, 보이스피싱 등 개인정보 유출에 따른 2차 피해 발생

③ 2014년 KB 국민카드, NH 농협카드, 롯데카드가 가지고 있던 약 1억 580만 건의 개인 정보

4) 출처 : 침입탐지시스템 IDS 정리, 2013년 1월 23일, http://we.bit.ac.kr/~phil

5) ITU-T : 국제 표준화 기구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

유출 사태 (헤럴드 경제 2014.01.18.)

㉮ 3사 모두 개인 신상정보 (이름, 주민등록번호 등), 결제계좌, 카드번호, 카드유효기간 등 민감한 정보의 유출

㉯ 3사 통합 카드 재발급 비용(286억 원), 사고수습 비용(173억 원), 탈회 만회 비용(1649억 원), 집단소송 패소 시 발생 비용(1712억 원), 영업정지 손실 비용(1072억 원)등 총 손실액 약 5000억 원 발생 (전자신문 2014.05.27.)

④ 민감한 데이터에 대한 보안 및 프라이버시 문제를 다룰 수 있는 연구는 미비한 단계

(나) 비정형 개인정보 탐지의 필요성

① 기존의 개인정보 탐지 솔루션들은 보유 문서 등에 존재할지 모르는 주민번호, 이메일, 계좌번호 같은 정형의 패턴만을 탐지하는 수준이었다. 그러나 기존의 솔루션으로 탐지 및 필터링하기 어려운 이름, 지역, 학교, 직업, 직장 등의 비정형 정보를 통해서도 개인을 특정할 수 있음이 “Structural SVMs 및 Pegasos 알고리즘을 이용한 한국어 개체명 인식” 연구를 통하여 밝혀졌다.

② 따라서 빅데이터 프라이버시 보호의 일환으로 프리텍스트에서 이들을 탐지하기 위한 비정형 개인정보를 추출하기 위한 문제가 대두된다.

(다) 다양한 분야에서 데이터 익명화의 필요성

① 의료 분야

㉮ EMR(전자의무기록)등을 사용하는 디지털 병원이 늘어나면서 축적된 대량의 의료정보를 수집, 활용하는 빅데이터 연구 수요가 증가

㉯ 의료 데이터는 개인정보 중에서도 민감 정보로 규정 되어 있어 데이터 수집에 어려움이 있음

㉰ 기본적으로 주민등록번호, 전화번호, 주소 등 ‘개인 식별자’를 제거하면 연구 목적의 의료 빅데이터는 활용 가능하나 ‘재식별 공격’으로 인한 프라이버시의 한계는 분명함

㉱ 미국의 경우 의료정보보호법(HIPAA)에 따라 이름, 사회보장번호, 병록번호 등 18개 항목을 민감한 정보로 규정하고 연구 활용 조건으로 데이터 익명화가 가능하지만, 익명화 속도가 느리며 대용량 데이터에서는 활용이 불가능

② 금융 분야

㉮ 카드번호, 카드 유효기간, 카드 거래 내용, 거래 장소 등 민감한 정보 익명화 필요

㉯ 주식 거래 항목 및 내용에 대한 비식별화 기법이 필요함

㉰ 영국의 정보감독위원회에서 개인 정보 보호를 위해 ‘데이터보호규약(Code of practice for data protection)’을 발의함 (2012.11.28.)

③ 위치 정보 분야

㉮ 스마트폰, 웨어러블 디바이스, IoT 등에서 생성되는 개인의 공간 정보를 비식별화하기 위한 기법 필요

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

㉯ 위치기반서비스(LBS: Location Based Service)를 기축으로 정보 프라이버시 보호를 위하여 제정된 위치 정보법은 다양한 디바이스 및 애플리케이션에 직면하여 새로운 국면을 맞이하고 있음

(2) 기존 연구 및 비식별화 기법의 한계

① 기존 익명화 기법들은 차세대 하드웨어에 적합하지 않으며 익명화 시간이 오래 걸린다는 단점이 존재

② 기존 기법들은 단일 머신에 한정되어 대용량 데이터 익명화에 있어 한계를 지님

(3) 최초의 통합 대용량 데이터 익명화 소프트웨어를 제안

① 기존 데이터 프라이버시는 단일 머신에 한정되어 빅데이터의 프라이버시를 다루는데 적합하지 않음

② 최근 웨어러블 디바이스, IoT 등에서 개인의 의료, 금융, 공간 데이터 등이 발생함으로써 빅데이터 프라이버시 보호의 필요성 증가

③ 기존의 프라이버시 기법들을 대용량 데이터에 적용시킬 경우 막대한 비식별화 시간 발생

④ 인메모리 고속, 병렬 익명화 및 서버 클러스터 기반 분산 대용량 데이터 익명화 기법 실현

(4) 관련 학계 발전에 가장 적합한 연구

① 대용량 데이터 익명화 기법은 현재 국내·외를 통틀어 전무한 상황

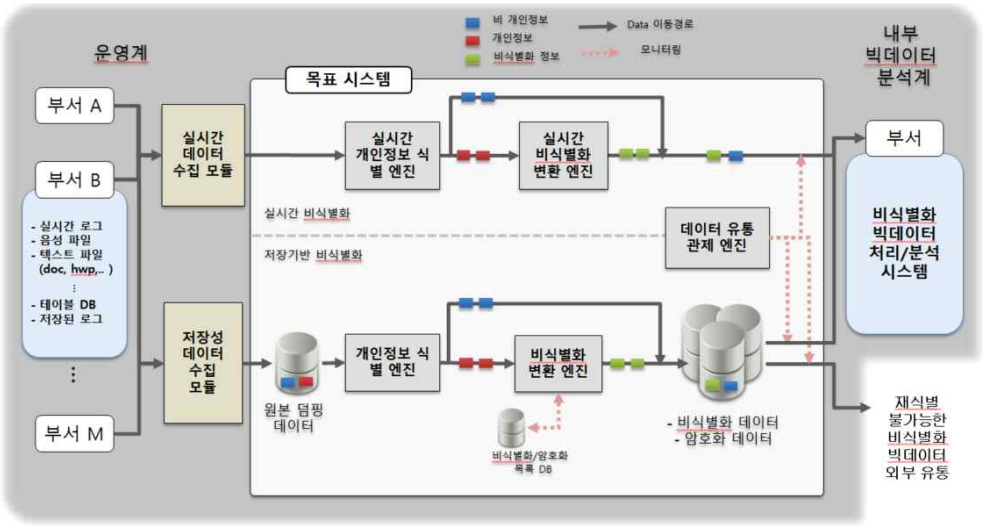
② 실제 수요가 요구되는 연구 분야이므로 핵심기술 선점을 통한 국제 경쟁력 강화 필수

③ 의료, 금융 산업에 데이터 프라이버시 연구를 접목시켜 관련 연구의 발전을 이룩할 수 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1-3. 연구개발 범위

(1) 기술개발의 최종목표 및 세부 목표

구분	내용
최종목표	o 최종목표  [그림 18] 최종개발 목표시스템 o 빅데이터에서 개인정보 식별 엔진 개발 - 개인정보 이용주기, 민감도에 따른 개인정보보호 정책 생성 - 정책 기반의 자동화된 개인정보 선별 기술 - 빅데이터 내 반정형·비정형 개인정보 고속 탐지 기술 o 개인정보 익명처리를 위한 비식별화 정보 생성 엔진 개발 - 개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 및 기술 - 개인정보 유출방지를 위한 영역분리 보안 관리 기술 - 비식별화 정보에 대한 라이프 사이클 관리 기술 - 프라이버시 보존 데이터 추출(Privacy Preserving Data Mining) 처리 기술 - KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 개발 - 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 개발 o 실시간 통합 관리 및 제어 엔진 개발 - 개인정보 제공 요청자에 대한 접근 통제 기술 - 비식별화 정보 기반 개인정보 고속 검색 기술 - 음성에서 추출한 벡터데이터를 화자 분류를 위해 모델링하는 기술 - 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 및 차단 기술 - 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	내용
	o 빅데이터 개인정보보호 기술 응용 서비스 개발 및 시연 - 데이터 준비 및 검증/시연 지원 · 개인정보 비식별화를 위한 대상 데이터 준비 · 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 · 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 검증 - 검증/시연을 위한 시스템 환경 구성 · 정형 및 비정형 데이터 검증을 위한 S/W 및 H/W 구성 - 데이터 사업화 방안 조사 연구 · 개발된 기술을 활용한 공공 및 민간 각 Industry/주제별 사업화 방안 - CKAN 플랫폼과의 연계 수행 · 데이터 유통 활성화를 위해 개발된 기술을 CKAN 플랫폼에 연계 o 빅데이터 개인정보보호 기술 응용 서비스의 상용화 - 기존의 공공 데이터를 비식별화하여 빅데이터 활용 o End Product - 반정형/비정형 개인정보 탐지 알고리즘(SW) - 정형 개인정보 탐지 프로그램(SW) - 반정형/비정형 개인정보 탐지 프로그램(SW) - 정형/반정형/비정형 개인정보 고속 탐지 시스템(SYS) - 개인정보 비정상행위패턴/부적절이용탐지 프로그램(SW) - 개인정보 형식 유지 기반 익명처리 알고리즘(SW) - 탐지된 개인정보 비식별화 시스템(SW) - 비식별화 정보 기반 개인정보 고속 검색 프로그램(SW) - 개인정보 탐지 및 비식별화 시스템(SYS) - 개인정보 실시간 관리 및 제어 시스템(SYS) - 개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 및 기술(SW) - GPGPU를 이용한 인메모리 고속, 병렬 KLT 비식별화 알고리즘(SW) - 대용량 데이터의 KLT 비식별화를 위한 서버 클러스터 기반 분산 알고리즘(SW) - KLT 비식별화 데이터에 대한 인메모리 기반 익명성 측정 알고리즘(SW) - 대용량 KLT 비식별화 데이터에 대한 서버 클러스터 기반 익명성 측정 알고리즘(SW) - 비식별화 데이터의 통계적 유효성 향상 기법(SW) - 개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘(SW) - 개인정보 형식 판별 및 형식 유지 기반 익명처리 기능(SW) - 실시간 유통형 비식별화 패키지(SW) - 실제 빅데이터 (개인신상, 대출개설, 카드개설, 연체정보 등) - 원본 대비 데이터값 정확도/비식별성 검증 소프트웨어 및 결과보고서(SW) - 음성 데이터에서 화자특징 추출 및 모델링 알고리즘(S/W) - 빅데이터 기반 비식별화 솔루션과 CKAN 플랫폼 연계 (S/W)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	내용
세부목표	o 주요 기능  [그림 19]주요 핵심 기술개발 o 빅데이터에서 개인정보 식별 엔진 개발 - 빅데이터 내 프라이버시 정보 검색 및 식별 기능 o 개인정보 익명처리를 위한 비식별화 정보 생성 엔진 개발 - 비식별화 정보생성 기능 - 인메모리 기반 개인정보 고속 비식별화 기능 - KLT 비식별화 데이터에 대한 익명성 측정 기능 - 비식별화 데이터의 Anatomy 기반 통계적 유효성 향상 기능 - 형식 유지 기반 익명처리 기능 - 정형/비정형 데이터의 비식별화 변환 기술 - 개인 시그네쳐 기반 비식별화 데이터 마이닝 기술 o 실시간 통합 관리 및 제어 엔진 개발 - 프라이버시 정보 오용 및 부정 재식별 패턴 및 Rule - 개인정보 유출방지를 위한 영역분리 보안기술 - 실시간 비정상 지수 생성 및 비정상행위 탐지 기술 o 빅데이터 개인정보보호 기술 응용 서비스 개발 및 시연 - 빅데이터 비식별화 검증을 위한 H/W 및 S/W 지원 · 개발 엔진 및 솔루션 결과물인 비식별화 데이터 검증을 위한 H/W 및 S/W 환경 지원 - 개인정보 포함 실제 빅데이터 준비 및 검증/시연 · 신상, 대출개설, 카드개설, 연체정보 등 검증용 실제 빅데이터 제공 · 암호화DB, SAM 파일, LOG데이터 등 다양한 유형의 데이터 제공 · 다양한 비식별화 기법 검증 · 개발 엔진 및 솔루션 결과물인 비식별화 정보의 통계적 유의성 검증 - 빅데이터 유통 사업화 방안 · 개발된 기술을 활용한 공공/민간(금융, 유통, 서비스 등) 사업화 · 공공/민간부문 데이터 공유 및 유통 활성화를 위한 비식별화 기술개발 결과물 · 공공/민간 데이터 연계하여 개인정보 비식별화 제시 o 실시간 프라이버시 보존형 트랜잭션 항목 일반화 기법 연구 - 비식별 트랜잭션의 항목 일반화 계층 구조 매핑 기술 및 실시간

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	내용

Roll-up 일반화 트랜잭션 생성 기술

- 실시간 비식별 데이터 스트림의 사생활 보존 일반화 빈발 패턴 탐사 연구

o 주요 성능치

- 처리속도 및 목표 건수

핵심 기술/제품 성능지표		단위	달성목표	국내최고 수준	세계최고수준 (보유국, 기업/기관명)
1	빅데이터 내 프라이버시 정보 검색 및 식별 성능	EPS	350,000/초	200,000/초	150,000/초 (미국, Splunk)
2	비식별화 정보생성 성능	건수	250,000/초	N/A	200,000/초 (미국, Protegrity)
3	프라이버시 정보 오용 및 부정 재식별 패턴 및 Rule	건수	100개	4개	N/A
4	개인정보 형식 유지 익명처리 성능	건수	250,000/초	N/A	N/A
5	저장 데이터 비식별화 변환 속도	건수	30,000/초	N/A	200,000/초 (미국, Protegrity)
6	실시간 데이터 비식별화 변환 속도	건수	100,000/초	N/A	200,000/초 (미국, Protegrity)
7	비식별화 데이터의 통계적 오차	%	1	N/A	N/A

[표 21] 처리속도 및 목표 건수

- 음성데이터 비식별화 기술의 목표치

기술	성능 지표	단위	요구조건	비고
문장 종속형	오거부율 (False reject rate)	%	≤ 8	문장 종속형 방식, 3초 발성 데이터로 등록, 등록화자 수 1천명 기준 발성 종류 후 인식까지의 처리 시간
	오수락율 (False accept rate)	%	≤ 0.2	
	처리 시간	sec	< 2.0	
문장 독립형	오거부율 (False reject rate)	%	≤ 20	문장 독립형 방식, 화자 등록을 위해 최소 30초 발성 데이터 필요, 인식을 위해 최소 15초 발성 데이터 필요 등록화자 수 1천명 기준
	오수락율 (False accept rate)	%	≤ 0.2	
	처리시간	sec	< 2.0	

[표 22] 음성데이터 비식별화 기술의 목표

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	내용
	o 핵심 기술 - 빅데이터 내 개체명 인식을 통한 비정형 개인정보 탐지 - 재식별이 어려운 개인정보의 비식별화 기술 - 인메모리 비식별화 처리를 위한 데이터 분할 기술 - 서버 클러스터 기반 익명화 데이터 모니터링 기술 - 통계적 유효성 향상을 위한 Anatomy 기반의 비식별화 기법 - 재식별이 불가능한 대표 레코드화 비식별화 기술 - 개인 시그네쳐 기반 비식별화 데이터 마이닝 기술 - 개인정보 내용기반 실시간 비정상 지수 생성 및 비정상 행위 탐지 기술 - 음성데이터의 전처리 및 모델링 기술 **o 적용범위(또는 서비스)** - 각종 빅데이터 사용 시스템의 개인정보 전처리/후처리 시스템에 활용 가능 - 이미 수집되어져 있는 개인정보에 대한 비식별화 처리에 활용 가능 - EMR(전자의무기록) 분석, 의료데이터 기반 의료기관 경영 지원 등 개인 의료정보에 대하여 프라이버시 보호가 필요한 의료 데이터 분석 시스템에 활용 가능 - 신용카드 이용기록, 개인별 주식 거래기록 등 개인 금융거래정보의 프라이버시 보호가 선행되어야 하는 되는 금융 분야의 데이터 마이닝 시스템에 활용 가능 - LBS(위치정보서비스), 웨어러블 디바이스 등 개인 공간 정보를 활용하는 모든 애플리케이션에 활용 가능 - 개인 정보의 재식별이 불가능한 비식별화를 통해보다 안전한 데이터 유통 프레임워크 구축 가능 - 특정한 규칙을 정해 주어야하는 관리자의 개입 없이 정상 상황 학습을 통한 anomaly 탐기 기술 기반으로 비정상적인 개인정보 접근 및 이용의 탐지에 활용 가능 - 음성을 통한 악의적 사용자(사기, 범죄, 허위 이력과 관련된)에 대한 화자그룹의 분류/판별이 필요한 서비스 사업에 활용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 주요 성능 지표 정의 및 목표치 근거

[주요성능치]

빅데이터 내 프라이버시 정보 검색 및 식별 성능 : 350,000EPS/초 이상

o 프라이버시 정보 식별 성능

[성능 지표 정의]

- 프라이버시 정보 식별 시스템이 보장하는 초당 처리 데이터량

[성능목표치 근거]

- 미국 splunk 사의 로그 처리 기술은 최대속도인 150,000 EPS/초를 보유하고 있음, 초당 347 bytes 의 로그를 처리하는 기준
- 목표시스템의 프라이버시 정보 식별 기술은 미국/Splunk 사와 다르게 로그를 처리하는 것 뿐 아니라 프라이버시 정보의 식별이라는 과정으로 인해 로직의 복잡도가 높음
- 이를 감안하여, 병렬 시스템을 이용하여 347 bytes 의 로그를 처리하는 기준으로 350,000건의 식별 성능을 목표로 함

[주요성능치]

비식별화 정보생성 성능 : 250,000건/초 이상

o 비식별화 정보생성 성능

[성능 지표 정의]

- 비식별화 시스템이 보장하는 초당 레코드 생성 건수

[성능목표치 근거]

- 본 연구팀은 스트림 환경에서 100,000건/초 이상의 비식별화 정보생성 성능을 갖는 기반 기술을 보유하고 있음 (“A framework to preserve the privacy of electronic health data streams.” JBI, 2014)
- GPGPU 기술을 비식별화 정보생성(clustering 기반)에 적용하였을 때 수십 ~ 수백배의 성능 향상이 있을 것으로 예상됨 (Li You, et al. “Speeding up k-means algorithm by gpus.“ CIT, 2010)
- GPGPU 활용 비식별화 정보생성기술이 도입기임을 감안하여, 기존 성능보다 수 배 향상된 수치를 목표치로 추산하였음

[주요성능치]

o 개인정보 형식 유지 기반 익명처리 성능 : 250,000건/초 이상

[성능 지표 정의]

- 개인정보 형식 유지 익명처리 시스템이 보장하는 초당 레코드 생성 건수

[성능목표치 근거]

- 미국 Protegrity사의 비식별화 변환기술이 최대 속도인 200,000만 건을 보유하고 있음.
- 목표시스템의 개인정보 형식 유지 익명처리 기법은 변환 당시에 최대한 형식을 유지하며 익명화 하는 과정으로 인하여 로직의 복잡도가 높음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 이를 감안하여, 단일 기존 DB연동의 단일 변환 SW기준으로 100,000건의 변환 속도를 목표로 함

[주요성능치]

o 저장 데이터 비식별화 변환 속도 : 30,000건/초 이상

[성능 지표 정의]

- 저장 데이터를 재식별 불가능한 방식으로 단일 SW을 이용하여 비식별화 변환할 시 초당 변환된 원본 데이터의 건 수를 이야기함

[성능목표치 근거]

- 미국 Protegrity사의 비식별화 변환기술이 최대 속도인 200,000만 건을 보유하고 있음
- 목표시스템의 비식별화 기법은 타사 기술과는 다르게 변환 당시에 재식별 가능성을 완전히 제거하는 과정으로 인해 로직의 복잡도가 높음
- 이를 감안하여, 단일 변환 SW기준으로 30,000건의 변환 속도를 목표로 함

[주요성능치]

o 재식별 위험성

[성능 지표 정의]

- 원본 레코드가 대표 레코드화 및 비식별화 변환된 후 원본 정보로 복원을 시도하여 재식별이 되는 레코드 개수의 비율을 뜻 함

[성능목표치 근거]

- 원본 레코드가 대표 레코드화 및 비식별화 변환된 후 재식별되는 레코드를 수치화하여 판단함
- 5%이내의 재식별 위험성을 갖도록 변환 가능한 기술 개발을 목표로 함

[주요성능치]

o 실시간 데이터 비식별화 변환 속도

[성능 지표 정의]

- 실시간 데이터를 재식별 불가능한 방식으로 인메모리 맵리듀스 기법을 적용하여 비식별화 변환할 시 초당 변환된 원본 데이터의 건수를 이야기 함

[성능목표치 근거]

- 분산 인메모리 맵리듀스 기법을 활용한 실시간 데이터 비식별화 변환의 속도 측정이 필요
- 이를 활용하여 목표시스템은 100,000 건의 처리량을 목표로 산정함

[주요성능치]

o 비식별화 데이터의 통계적 오차

[성능 지표 정의]

- 원본 레코드와 재식별 불가능한 방식으로 변환된 대표레코드 간의 속성값 차이를 통해 측정된 데이터의 통계적 오차를 뜻 함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[성능목표치 근거]

- 원본레코드가 대표 레코드화 비식별화 변환될 때, 손실되는 정보를 속성별로 수치화하여 판단함
- 각 속성별로 1%이내의 오차율을 갖도록 변환 가능한 기술 개발을 목표로 함

[주요성능치]

o 음성 화자그룹 분류/판별 성능 지표

[성능지표 정의]

- 오거부율 (False reject rate) : 등록된 사용자가 거절될 오류율
- 오수락율 (False accept rate) : 비등록 사용자가 승인되거나 다른 사용자로 식별될 오류율
- 처리시간 : 발성 종료 후 식별 시까지의 응답 시간

[성능목표치 근거]

- NIST[6] 화자인식 I-vector challenge의 leaderboard 수치
  . NIST 성능지표 : minDCF(minimum decision cost function)
  = (false-reject-rate)/100 + (false-accept-rate)
  . world-best : minDCF 0.195 (Idiap)
  . 성능목표치 10%, 0.1%를 minDCF로 환산 시 0.2
  . NIST 평가에서는 등록화자 수가 수백명이고, 16kHz 데이터 이용하며, 40 ~ 60초 데이터로 화자모델을 생성한 반면, 본 과제에서는 8kHz 30초 데이터로 화자모델을 생성하고 등록화자 수가 1천명이라는 조건을 감안하여 목표치를 설정함.

6) NIST(**National Institute of Standards and Technology)** : 미국상무부 기술관리국 산하의 각종 표준과 관련된 기술을 담당하는 연구소

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2. 연구수행 내용 및 성과

2.-1. 연구수행 내용

가. 연구개발 목표 및 결과

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
1차 연도 (2015)	빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발	빅데이터 내 반정형 / 비정형 개인정보 고속탐지기술	반정형 / 비정형 개인정보 탐지 기술 개발	- 개인정보 탐지기능은 개인정보 탐지 정책을 통해 탐지 진행. 비정형, 반정형 데이터의 탐지에 공통적으로 적용되는 정책은 개인정보 탐지 정책으로 적용. 비정형, 반정형 데이터의 경우 해당 데이터에서 개인정보가 발견 시 로그 기능을 통하여 체크로그에 기록. 비정형, 반정형 개인정보 발견 시 해당 개인정보 유형의 정책에 따라 비식별화 처리. 개인정보 탐지 정책은 xls, ppt, xlt, ppt, pps의 경우 비정형 데이터로 간주하여 개인정보 비식별화를 위한 컨텐츠 필터링을 통한 탐지를 진행. doc, dot, rtf, hwp, hwt, zip, tar, tar.gz, tgz, odt, ods, odp, pptx, xlsx, docx 형태의 비정형 데이터는 콘텐츠 필터링 사전작업을 위해 콘텐츠를 획득하기 위한 사전 작업을 진행하고 진행된 이후 콘텐츠를 전달받아 정책에 맞는 비식별화를 진행.
		정책기반의 자동화된 개인정보 선별 기술	정책기반의 자동화된 개인정보 선별 기술	- 고유식별정보 4가지와 개인정보 범위에 속해 있는 이메일주소, 은행계좌번호, 전화번호, 휴대전화번호, 카드번호, 의료보험번호의 6가지 개인정보를 정책으로 정하고 탐지시스템과 연동하여 정책 기반으로 탐지하는 시스템 개발
		KLT 비식별화 고속처리 기술 개발	GPGPU를 활용한 비식별화 속도 향상 기법 데이터 비식별화 기법을 위한 메모리 병렬처리 기법	- 기존 익명화 알고리즘을 GPGPU에 맞게 활용하기 위해 병렬도를 높일 수 있도록 수정한 알고리즘을 개발. 병렬처리를 할 때 분기문이 존재할 경우 2배의 실행 시간이 소요. 따라서 분기문을 최소화한 알고리즘을 적용. 또한 CPU-GPU간 데이터 전송을 최소화하여 성능 개선.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
		개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 연구	개인정보 최소 형식 유지 한계 분석	- 개인정보내의 포함되어 있는 정보를 활용하기 위하여 정보를 보존하면서 개인 식별을 막는 최소형식 유지 한계분석을 통해 익명처리 알고리즘을 개발
			개인정보의 형식 유지 한계에 따른 익명처리 알고리즘 개발	
		실시간 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술	개인신상 레코드 통계적 정확성 유지 비식별화 기술	- 개인정보의 N:1 그룹핑 기반의 가상화 기술 및 가상화 대표 레코드 생성 기술 개발 - 가상 레코드의 그룹핑키 분포속성, 그룹핑 분포속성 생성기술 개발
		실시간 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 및 차단 기술	개인정보 정상 접근 프로파일 생성 기술	- 개인정보 접근 로그 정상 프로파일 생성 - 수동적 개입을 최소화한 실시간 개인 정보 접근 로그 상황 학습 - 지속적 상황 관리 수행 및 상황변동에 대한 상황 재학습
		음성 데이터를 개인식별 데이터로 변환하고 식별하는 기술	문장 종속형 개인식별 기반 기술 개발	- 잡음제거, 특징추출 및 특징 정규화, VAD가 포함된 전처리 알고리즘과 전처리 모듈 SW개발 - 5개 방식(HMM, GMM, SVM, JFA, i-Vector)의 개인식별 및 본인인증 알고리즘/시연 SW개발 - 5개의 방식 중 최적의 방식을 선택, 다채널 개인식별이 가능한 SDK 개발
			개인정보 활용 동의 및 마케팅 프로그램 설계	- 개인식별기술을 활용할 TM(텔레마케팅) 어플리케이션 프로세스와테이블 및 UI 설계반영
		비식별화 데이터에 대한 개인 시그네처 기반 실시간 클러스터링 기법 연구	가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행	- 비식별 변환된 대표레코드에 대해 개인 가상화 처리를 통한 가상 개인 시그네처 별 실시간 클러스터 생성
		대표레코드의	실제 개인	- 개인 식별 데이터 기반으로 생성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
		그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구	클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별함	한 개인별 클러스터와 개인 가상화 기반으로 생성된 비식별 클러스터의 유사성을 파악하여 사생활 유사도를 판별
		검증을 위한 실제 빅데이터 준비 및 검증 프로세스 수립	빅데이터 제공 및 검증 시스템 지원 방안 수립	- 빅데이터 비식별화 검증을 위한 실제 빅데이터 준비 및 검증 프로세스 수립
		빅데이터 비식별화 검증을 위한 시스템 환경 구성	빅데이터 준비 및 초기 검증 · 개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건)	- 빅데이터 비식별화 검증을 위하여 KCB의 금융데이터를 적용하여 시스템 환경 구성
			검증/시연을 위한 시스템 환경 준비 및 지원	- 빅데이터 비식별화 검증 및 시연을 위한 시스템 환경 준비 및 지원
3차 연도 (2017)	빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발	반정형/비정형 개인정보 탐지 기술의 속도 향상	개체명 인식에 대한 비정형 개인정보 인식 특화를 통한 속도 향상	- 인메모리 환경에서 개체명 인식에 대한 비정형 개인정보 인식성능 속도 향상 - 인메모리 환경에서 데이터를 활용하여 개인정보를 탐지하고 처리를 할 수 있는 시스템 개발 및 처리 속도 향상 수행 - 분산 병렬처리를 통한 비정형 개인정보 탐지속도 향상 처리
			비 저장성 데이터를 통하여 메모리상에서 개인정보 탐지 기능 개발	
			병렬처리를 통한 비정형 개인정보 탐지 속도 향상	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
		개인정보 제공 요청자에 대한 접근 통제 기술	시스템 감사로그 증적 기능 사용자별/메뉴별/기능별 사용 권한 관리 기능 비정상 행위/부적절 이용 탐지 시 개인정보 제공 요청자의 시스템 이용 통제	- 시스템 감사로그 증적 및 사용 권한에 따른 관리 기능을 시스템에 추가적용 - 개인정보 비정상 오남용 및 부정 사용에 대한 탐지 시 개인정보 제공 요청자에게 알람을 주어 시스템 이용 통제 적용
		비식별화 정보 기반 개인정보 고속 검색 기술	비식별화 정보 기반 개인정보 검색 시스템 인터페이스 개발 비식별화된 개인정보간의 매칭 정보를 통하여 검색 기능 개발 매칭정보의 인덱스화 및 병렬화를 통하여 고속 검색 기능 개발	- 비식별화 정보 기반 개인정보 검색시스템 인터페이스 개발 - 비식별화된 개인정보 간의 매칭정보를 통하여 검색 기능 개발 - 개인정보간의 매칭 정보를 인덱싱, 병렬화 처리하여 검색 속도 향상
		비정상 행위/부적절 이용 탐지 및 차단 기술	비정상 행위 패턴, 부적절 이용 탐지 기능의 결과에 따른 특정 사용자에 대한 시스템 이용 차단 기능 탐지된 행위에 대한 이력 관리 시스템 개발 비정상 행위별 위험도 부여 및 위험도를 통한 경계 대상자 알림 시스템 개발	- 비정상 행위 패턴과 부적절한 이용이 감지되었을 경우 해당 사용자에 대한 로그인 차단 및 정보보안 담당자에게로의 자동알람 기능 개발 - 탐지된 행위에 대한 이력 관리 시스템 개발 - 비정상 행위별 위험도 개발 - 비정상 행위 위험도에 따른 경계 대상자 알림 시스템 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
		익명화 정도 및 재식별 가능성 측정 모델 개발 및 구현	비식별 처리된 데이터의 익명화 정도를 측정하는 모델 개발	- 비식별화된 데이터가 얼마나 익명화 되어 있는지 익명화 정도 측정 모델 개발 - 비식별 처리된 데이터에 대한 재식별 가능성 측정을 위한 알고리즘 개발 및 측정 모델 개발 - 익명성과 재식별 가능성을 인메모리 환경과 분산 환경에서 측정하는 알고리즘 개발
			비식별 처리된 데이터에 대하여 특정 배경지식을 사용한 추론 공격시 예상되는 재식별 가능성 측정 모델 개발	
			익명화 정도 및 재식별 가능성 측정 소프트웨어 개발(in-memory 및 분산 클러스터 환경)	
		유통형 비식별화 변환된 유통용 빅데이터의 재식별 불가성 검증 기술 연구	비식별 변환의 핵심 제거 성질(유일성, 동일성, 유사성) 검증 기술 개발	- 유사성 제거 검증 기술 개발 - 유일성 제거 검증 기술 개발 - 동일성 제거 검증 기술 개발 - 추상화 과정 내 Differential privacy 기술 적용 - 유사도 기반 대표레코드 그루핑 기술 개발 - 대표레코드 유사도 최적화 기술 개발
		비식별 데이터의 분석 품질 향상을 위한 비식별화 데이터 품질 고도화 기술 개발	대표레코드 생성 시 유사도 기반 그루핑 기술 연구	
			그루핑 유사도 최적화 기술 연구	
		고객 상담 서비스를 모델로 한 화자그룹분류/판별 시스템 개발	화자변곡점(speaker change point) 검출 및 데이터 군집화 기술 및 문장 독립형 화자그룹분류/판별개발	- 화자변곡점 검출, 화자 군집화, 화자모델 학습 기술 개발 문장 독립형 화자 또는 화자그룹의 분류/판별 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
			실시간 상담 데이터에 대한 화자그룹분류/판별 기술 및 화자그룹 분류/판별을 위한 서버형 다채널 SW 개발	- 실시간 i-vector 추출 및 사기자/유의자 모델과의 비교 기술 구현 - 서버형 다채널 실시간 화자/화자그룹 판별을 위한 요구사항 분석 및 SW 구조 설계
		실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙 탐사 기법 연구	개인 시그네처 그룹 기반 실시간 빈발패턴/연관규칙 탐사 기법 연구	- 사생활 유사도를 기반으로 실시간 빈발패턴/연관규칙 알고리즘을 적용하여 데이터를 분석 수행
			실시간 빈발패턴/연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구	- 사생활 유사도 기반의 비식별 데이터 스트림 분석 결과의 정확도 향상을 위해 그룹 기반의 지지도 및 신뢰도 보정 기법을 연구하여 적용할 경우 유사도가 80% 수준으로 나타남
		검증/시연을 위한 시스템 환경 구성	엔진 설치 등을 위한 하드웨어/장비 설치 및 물리적 검증 환경 구성	- 비식별화 개인정보보호기술 검증을 위한 하드웨어/장비 설치 및 물리적 검증 환경 구성(개인정보가 있는 데이터를 시험하기에 폐쇄망안에서 구성환경 구축)
		빅데이터 준비 및 검증/시연 지원	검증용 데이터 추출 및 File/Table 생성 및 (기술개발 테스트 요청 시) 결과 검증 및 유의성 평가	- 검증데이터 준비 및 비식별 검증 절차서 마련

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
4차 연도 (2018)	빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발	반정형/비정형 개인정보 탐지 기술의 성능 검증	인-메모리, 병렬화를 통한 개인정보 탐지 기술에 대해 빅데이터를 대상으로 하여 기술 성능 검증 수행	- 전체 180,000,000건에 대한 개인정보 탐지 성능을 측정 - 180,000,000건÷152초 = 1,184,210/초
		개인정보 탐지기능과 비식별화 기능 융합을 통한 통합 개인정보보호 솔루션 구축 및 상용화 준비	통합 개인정보보호 솔루션 구축 관점에서 비식별화 S/W 내 고객 Legacy System 게시판 및 e-mail 본문과 첨부파일에 대한 개인정보 탐지 및 차단, 모니터링 기능 융합 수행 비정상 행위 및 부적절 이용 탐지이력 분석 및 모니터링 기능 고도화를 통한 통합 데이터베이스 접근제어 기능 모듈화 및 상용화 준비	- 비식별화 S/W에 텍스트 혹은 파일 내 개인정보 탐지 및 마스킹 기능 개발 - 비식별화 S/W 내 고객 Legacy System 게시판 및 e-mail 본문과 첨부파일에 대한 개인정보 탐지 및 차단, 모니터링 기능 융합 수행 - 비정상 행위 및 부적절 이용 탐지이력 분석 및 모니터링 기능 고도화를 통한 통합 데이터베이스 접근제어 기능 모듈화 및 사업화 진행 - 개인정보 접근 통제 시스템을 융합한 통합 개인정보보호 솔루션을 구축하고 상용화하여 분리발주 사업 진행
		데이터 보안 솔루션과 CKAN 플랫폼과의 연계 수행	데이터 연계 플랫폼인 CKAN을 통해 제공될 비정형/반정형/정형 데이터에 대한 개인정보 탐지 및 비식별 처리를 위한 기능 개발	- CKAN SODAS에서 제공하는 데이터를 비식별 처리하고 이에 대한 이력 관리 및 검증 수행 기능을 개발하였으며, 5차 년도에는 연동 기능 보완 - 개인정보 탐지 및 비식별 처리 데이터의 이력관리 및 검증 수행 기능 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
			개인정보 탐지 및 비식별 처리 데이터의 이력관리 및 검증 수행 기능 개발	
		스키마 스캔 및 메타정보 시각화를 통한 빅데이터 플랫폼(Super Hadoop)과 비식별화 S/W 연계 기술 ※ Super Hadoop : (총괄)빅데이터 처리 고도화 핵심 기술 활용	스키마 스캔을 통한 빅데이터 플랫폼(Super Hadoop) 내 메타정보 시각화 기술 개발	- Hadoop System 상에서 Working하는 고속 SQL 처리코드의 결과물을 비식별화하는 연계기술 개발 완료 - 스키마 스캔을 통한 빅데이터 플랫폼(Hadoop)내 메타 정보 시각화 기술개발 - 선택된 정보 요소에 대한 결합 및 추출, 분할, 그룹화, Pivoting 등 다양한 전처리 인터페이스 기술 개발 - H전력공사 빅데이터 플랫폼(Hadoop)에서 구현 및 실증 - 총괄 산출물인 Hadoop System 상에서 Working하는 고속 SQL 처리코드를 활용하여 전처리 기능 별 SQL 처리코드 생성 알고리즘 개발 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 개발 - H전력공사에서 Hadoop System 상에서 Working하는 고속 SQL 처리코드를 활용하여 전처리 기능 별 SQL 처리코드 생성 알고리즘 적용 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 적용 - 총괄과제와 연계 편의성을 위한 기술 개발
			선택된 정보요소에 대한 결합 및 추출, 분할, 그룹화, Pivoting 등 다양한 전처리 Interface 기술 개발	
			총괄 산출물인 Hadoop System 상에서 Working하는 고속 SQL 처리코드를 활용하여 전처리 기능 별 SQL 처리코드 생성 알고리즘 개발 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 개발	
		정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술	기존 정보 손실을 줄이기 위한 비식별화 기술 및 모델 분석	- 기존 정보 손실 감소를 위한 비식별화 기술 및 모델 분석 - 통계적 유효성을 향상시키기 위하여 테이블 분리 기반 비식별화 기법 개발 - 추가적으로 일반화 기반 비식별화 기법 간의 성능 비교 진행
			테이블 분리 기반 비식별화 기법 개발	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
			일반화 기반 비식별화 기법과 테이블 분리 기반 비식별화 기법의 통계적 유효성 비교	
		실시간 프라이버시 보존형 트랜잭션 항목 일반화 기법 연구	빅데이터에서 비식별 트랜잭션 항목 일반화 기법 연구	- 실시간으로 들어오는 트랜잭션 항목에 대해 일반화 계층 테이블을 구성하고 일반화 정도를 선택하여 각 항목 계층 이동
			실시간 일반화된 비식별 트랜잭션 빈발패턴 마이닝 기법 연구	- 실시간으로 일반화 트랜잭션의 빈발패턴을 구하기 위해 스파크 스트림을 이용하여 FP-growth 알고리즘 구현하고 비식별화 처리시 제거된 항목의 통계치를 이용하여 빈발패턴 결과를 보정할 경우 유사도가 80% 수준으로 나타남
		기술활용을 통한 분야별 사업화 방안 조사 연구 (비식별화 데이터의 통계적 활용의 유효성에 대한 검증 방법 개발 및 사례 검증 수행)	비식별 방법론에 대한 검토 및 활용 사례 탐색	- 비식별화는 일반적으로 식별정보 또는 준식별정보에 대해 수행하며 이러한 정보들은 예측모형에 큰 영향을 주지 않으므로, 모형구축 측면에서 비식별화에 따른 데이터의 유용성의 훼손은 미미함
			비식별 데이터 유효성 검증 방법론에 대한 문헌 고찰	
			사례분석을 위한 데이터 탐색 및 기초 분석	
			예측 모형 비교를 통한 KLT 비식별화 데이터의 통계적 유효성 간접적 검증	
		빅데이터 처리 엔진 기반의 병렬 익명화 처리 모듈 구현	Apache Spark 엔진 기반의 원본레코드 RDD 파티셔닝 최적화 기법	- Apache Spark 엔진 기반의 원본레코드 RDD파티셔닝 최적화 기법 연구를 통해 SQL을 활용한 추상화 로직 구현 - 해당 spark 추상화 모듈은 single

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
			연구	node mode/ cluster mode 모두 연동 가능하며, 기존 MASQUI와 통합 완료 - RDD 파티셔닝의 wide dependency를최소화 진행
			Apache spark SQL을 활용한 추상화 로직 구현	
			RDD partition의 wide dependency를최소화하는 최적화 lineage 연구	
		빅데이터 처리 엔진 기반의 병렬 익명화 레코드 연계 모듈 구현	Apache Spark 엔진 기반의 병렬 동기화 기술 개발	- Apache Spark 엔진 기반의 병렬 동기화 모듈 개발 - 추상화 원본 RDD 파티셔닝 최적화 기법 연구 - 해당 spark 동기화 모듈은 single node mode/ cluster mode 모두 연동 가능하며, 기존 MASQ UI와 통합 완료
			비식별화(추상화) 원본 RDD 파티셔닝 최적화 기법 연구	
			동기화 수준 별 Spark SQL의 Join operation(비식별 데이터 연계 시 가장 큰 병목 지점) 최적화 기술 연구	
5차 연도 (2019)	빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술 개발	각 요소 기술 통합 및 기능 테스트	각 요소별 구현 기술 통합	- 각 요소별 구현 기술 통합 - 각 요소별 기능 테스트
			각 요소별 기능 테스트	
		빅데이터 개인정보보호 솔루션 사업화 수행	통합 개인정보보호 솔루션	- 비식별화 기법을 이용한 개인정보보호 통합 솔루션 런칭
			공공기관 공공데이타 개방 사업 및 영리기관의 빅데이타 유통	- 마케팅 및 홍보를 위한 홍보물 제작 및 홍보 활동 계획 수립 - 공공/민간 데이터 비식별화 사업에 제품으로 제안 참여 기수행했던 사업의 성과를 적극 홍

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분(연도)	세부 과제명	세부 연구 목표	연구개발 수행 내용	연구 결과
			및 비식별화 사업, 클라우드 기반의 개인정보 비식별화 사업 참여	보하여 타 제품과의 차별점 강조
		추상화 비식별화 기법의 실시간 병렬 고속화 기술 개발	빅데이터 처리 엔진 기반의 실시간 병렬 추상화 비식별화 변환 기술 개발	- Apache Spark structured steaming 기반 실시간 추상화 모듈 개발 및 Apache kafka 등 다양한 source/sink와의 연동 지원, single node mode/ cluster mode 기반의 병렬화 지원
		실시간 비식별 데이터 스트림의 사생활 보존 일반화 연관 규칙 탐지기법 연구	항목 일반화 계측 구조 기반 실시간 다레벨 연관 규칙 발견 기법 연구	- 4차년도에 개발한 실시간 다레벨 연관 규칙 발견 기법 연구 보강

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	빅데이터 내 비정형 개인정보 고속탐지기술
연구개발 수행 내용	비정형 개인정보 탐지 기술개발
연구결과	• 개인정보 탐지기능은 개인정보 탐지 정책을 통해 탐지 진행 • 비정형, 데이터의 경우 해당 데이터에서 개인정보가 발견 시 로그 기능을 통하여 체크로그에 기록 됨 • 비정형, 반정형 개인정보 발견 시 해당 개인정보 유형의 정책에 따라 비식별화 처리 됨 • 비정형, 데이터의 탐지에 공통적으로 적용되는 정책은 개인정보 탐지 정책; • xls, ppt, xlt, ppt, pps의 경우 비정형 데이터로 간주하여 개인정보 비식별화를 위한 컨텐츠 필터링을 통한 탐지 • doc, dot, rtf, hwp, hwt, zip, tar, tar.gz, tgz, odt, ods, odp, pptx, xlsx, docx 형태의 비정형 데이터는 콘텐츠 필터링 사전작업을 위해 콘텐츠를 획득하기 위한 사전작업을 진행하고 진행된 이후 콘텐츠를 전달받아 정책에 맞는 비식별화 진행
구체적인 내용	• 고정된 필드에 저장되어 있는 데이터인 정형 데이터 및 XML, HTML과 같은 메타데이터나 스키마를 포함하는 데이터인 반정형 데이터, 고정된 필드가 없고, 사진과 오디오, 대화내용 등 유형이 정해져 있지 않은 데이터인 비정형 데이터를 패턴기반의 컨텍스트 매칭을 통해 데이터를 탐지 하는 기술을 개발. • 개인정보를 탐지 할 수 있는 현재 기술들에 대하여 기존 기법들을 분석하여 개체명 인식, 데이터 추상화, 내용기반 필터링, 패턴기반 등의 다양한 기법을 분석하고 적합성을 확인하였으며 패턴기반의 컨텍스트 매칭기법을 이용하여 빅데이터 내의 개인정보를 탐지 하는 기술을 고도화 개발.

세부 연구목표	정책기반의 자동화된 개인정보 선별 기술
연구개발 수행 내용	정책기반의 자동화된 개인정보 선별 기술
연구결과	• 고유식별정보 4가지와 개인정보 범위에 속해 있는 이메일주소, 은행계좌번호, 전화번호, 휴대전화번호, 카드번호, 의료보험번호의 6가지 개인정보를 정책으로 정하고 탐지시스템과 연동하여 정책기반으로 탐지하는 시스템 개발
구체적인 내용	• 개인정보 정책으로 고유 식별자 4가지 및 개인정보의 범위에 속하는 6가지의 정보를 각 개인정보의 유형별로 탐지시스템과의 정책을 연동하여 관리 할 수 있는 시스템을 개발.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	K.L.T 비식별화 고속처리 기술개발
연구개발 수행 내용	GPGPU를 활용한 비식별화 속도 향상 기법 데이터 비식별화 기법을 위한 메모리 병렬처리 기법
연구결과	• 기존 익명화 알고리즘을 GPGPU에 맞게 활용하기 위해 병렬도를 높일 수 있도록 수정한 알고리즘 개발 • 병렬처리를 할 때 분기문이 존재할 경우 2배의 실행 시간이 소요되어 분기문을 최소화한 알고리즘 적용 • CPU-GPU간 데이터 전송을 최소화하여 성능 개선
구체적인 내용	• 기존 데이터 비식별화 기법들은 기법을 적용하는데 있어 속도가 느리며 대용량 데이터를 처리함에 있어서 한계를 지닌다. 차세대 하드웨어인 GPGPU를 이용하여 처리속도를 향상하여 기존 비식별화 기법의 한계를 극복 가능 • GPGPU는 병렬 처리에 적합한 연산에서 뛰어난 연산 속도를 낸다. 하지만 기존 비식별화 기법은 병렬도가 현저히 낮다. 또한 GPGPU는 SIMT 모델을 사용하기 때문에 분기문이 존재할 경우 2배의 실행 시간이 소요된다. 따라서 기존 비식별화 알고리즘의 병렬도를 높이고 분기문을 최소화하는 비식별화 기법을 개발.

세부 연구목표	개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 연구
연구개발 수행 내용	개인정보 최소 형식 유지 한계 분석 개인정보의 형식 유지 한계에 따른 익명처리 알고리즘 개발
연구결과	• 개인정보내의 포함되어 있는 정보를 활용하기 위하여 정보를 보존하면서 개인 식별을 막는 최소형식 유지 한계분석을 통해 익명처리 알고리즘 개발
구체적인 내용	• 개인정보가 포함된 데이터를 분석하기 위해서는 개인정보 내에 포함되어 있는 정보를 이용해야 보다 더 신뢰가 높은 분석을 할 수 있다. 따라서 개인정보 내에 포함되어 있는 정보를 최대한 손상 시키지 않고 익명처리를 할 필요성 있음. • 주민등록번호, 운전면허번호와 같은 개인정보를 익명처리하기 위해서는 앞의 생년월일과 뒤 첫 자리인 성별부분을 유지하고 나머지 식별 정보를 익명처리 하는 방법으로 운전면허번호는 앞의 지역 코드를 제외하고 익명 처리하는 방법을 통해 알고리즘을 개발하는 연구를 진행.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	실시간 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술
연구개발 수행 내용	개인신상 레코드 통계적 정확성 유지 비식별화 기술
연구결과	• 개인정보의 N:1 그룹핑 기반의 가상화 기술 및 가상화 대표 레코드 생성 기술 개발 • 가상 레코드의 그룹핑키 분포속성, 그룹핑 분포속성 생성기술 개발
구체적인 내용	• 개인정보에 대한 N:1 그룹핑 기반의 가상화 기술 및 가상화 대표 레코드 생성 기술개발 A. N:1 가상화 기술 - N개의 원본 레코드들을 묶어 유사한 속성값들을 가지는 N명의 개인들에 해당하는 레코드를 1명의 레코드로 가상화 수행 . 가상 레코드 생성 . 가상화된 N개의 레코드의 각각의 속성에 대하여 대표성을 띌 수 있는 최소값, 최대값, 평균, 중앙값 등 선정함수를 사용자가 선택 • 분포속성 생성 기술 개발 - 가상화된 N개 레코드에 각 속성에 대한 분포속성 생성 기술 개발 - 가상 레코드의 재식별 가능성 제어 검증 - 유일성 제거 - 개별 개체를 특정할 수 있는 속성을 제거함 - 동일성 제거 - 가상 레코드와 개별 레코드 간 값이 불일치하게 함 - 연속성 제거 - 반복적인 비식별화 변환 시 개인정보 역추적을 불가능 하게 함 • 정형 식별정보 및 비식별 결과 시각화 개발 - 데이터 분포확인 - 범주형 데이터는 파이차트로 속성의 분포 확인 - 수치형 데이터는 라인차트 및 바차트로 속성의 분포 확인 - 원본과 가상화 레코드의 시각화를 통하여 분포비교 수행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	실시간 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 및 차단 기술
연구개발 수행 내용	개인정보 정상 접근 프로파일 생성 기술
연구결과	• 개인정보 접근 로그 정상 프로파일 생성 • 수동적 개입을 최소화한 실시간 개인 정보 접근 로그 상황 학습 • 지속적 상황 관리 수행 및 상황변동에 대한 상황 재학습
구체적인 내용	• 개인정보 접근 로그 정상 프로파일 생성 기술 개발 - 개인정보 접근 로그 정상 프로파일 생성 - 원천 데이터 프로파일 - 분석을 원하는 단위시간을 시간(hour) 단위로 구분하여 개인정보 접근 로그 정상 프로파일 구축 - 0시~23시까지 총 24개 단위시간별 통계 자료 추출 - 실시간 데이터에 대한 정상 행위 판별 기준이 됨 - 정상 행위 판별 - 실시간으로 들어오는 t시점의 개인정보 접근 로그 프로파일을 같은 시점의 정상 패턴(개인정보 접근)과 비교하여 해당 데이터가 정상 범주에 포함되어 있는지 판별 - 정상 프로파일 - 시간대별로 정상행위 데이터 값 요약, 관리 - 개인정보 접근 로그에 대한 시간대별 집계를 하나의 속성 값에 대해 통계(합계, 제곱값, 횟수, 평균, 표준편차) 저장 • 수동적 개입을 최소화한 실시간 개인정보 접근 로그 상황 학습 기술 개발 - 실시간 CEP 엔진을 연계하여 개인정보 접근 로그 정상 프로파일 관리 및 상황 학습 기술 개발 - 개인정보 접근 로그 정상 프로파일 관리 모듈 - 실시간 CEP 엔진 모듈과 연계하여 파일 형태로 프로파일 저장 - 새로 생성되는 데이터를 기반으로 프로파일 최신화 갱신 • 지속적 상황 관리 수행 및 특정 상황 변동에 대한 상황 재학습 기술 연구 - 지속적 상황 관리 수행 및 특정 상황 변동에 대한 상황 재학습 기술 연구 - 점진적 상황 재학습 (refresh) - 계속된 학습을 통해 빈번하게 발생하는 비정상 행위는 정상 행위로 간주 - 실시간 CEP 엔진 연계를 통한 상황 관리 - 개인정보 접근 로그 정상 프로파일이 생성됐는지 확인하고, Time Series Database에 데이터 전달 - Dashboard로 실시간 정상 프로파일링 시각화 - 개인정보 접근 로그 정상 프로파일을 실시간으로 모니터링 하여 정상 상황 관리 - 시간 단위를 설정하고, 설정한 시간까지의 정상 프로파일 실시간 모니터링 - 과거부터 현재까지 실시간으로 들어온 개인정보 접근 로그 정상 프로파일 건수의 최소값, 최대값, 평균값, 현재값, 누적값 모니터링 - 라인 그래프, 막대그래프, 점그래프로 시각화 표현

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	음성 데이터를 개인식별 데이터로 변환하고 식별하는 기술
연구개발 수행 내용	문장 종속형 개인식별 기반 기술 개발 개인정보 활용 동의 및 마케팅 프로그램 설계
연구결과	• 잡음제거, 특징추출 및 특징 정규화, VAD가 포함된 전처리 알고리즘과 전처리 모듈 SW개발 • 5개 방식(HMM, GMM, SVM, JFA, i-Vector)의 개인식별 및 본인인증 알고리즘/시연 SW개발 • 5개의 방식 중 최적의 방식을 선택, 다채널 개인식별이 가능한 SDK 개발 • 개인식별기술을 활용할 TM(텔레마케팅)어플리케이션 프로세스와 테이블 및 UI 설계
구체적인 내용	• 마케팅 프로그램 프로세스 설계 - 개인정보활용 동의를 위한 샘플 음성 수집 프로그램 요구사항 정의 및 프로세스 설계 - 음성 수집 장치 고도화 요구사항 정의 및 프로세스 설계 - 음성 수집 장치 유지보수 및 안정화, 유지보수 매뉴얼 작업 - 음성 수집 API 고도화 요구사항 정의 및 프로세스 설계 - 개인 식별 적용을 위한 응용 프로그램 개발 요구사항 정의 및 프로세스 설계 - 개인정보 활용 동의 및 마케팅 프로그램 시스템 및 네트워크 구축 설계 - 문장 종속형 개인 식별을 위한 미들웨어 설계 • 마케팅 프로그램 테이블 설계 - 개인정보활용 동의를 위한 샘플 음성 수집 프로그램 테이블 설계 - 개인 식별 적용을 위한 응용 프로그램 개발 테이블 설계 - 문장 종속형 개인 식별을 위한 미들웨어 테이블 설계 • 마케팅 프로그램 UI 설계 - 마케팅 프로그램 UI 설계

세부 연구목표	비식별화 데이터에 대한 개인 시그네처 기반 실시간 클러스터링 기법 연구
연구개발 수행 내용	가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행
연구결과	• 비식별 변환된 대표레코드에 대해 개인 가상화 처리를 통한 가상 개인 시그네처 별 실시간 클러스터 생성
구체적인 내용	• 비식별 데이터의 개인 특성 분석으로 다수의 개인을 하나의 가상 개인 그룹으로 맵핑 • 맵핑된 다수의 개인 데이터 속성 범위 정규화 과정 및 데이터 전처리를 통해 그리드 기반 분포를 파악 • 실시간으로 데이터 분포 내에서 사용자가 입력한 밀도 임계치 이상인 고밀도 그리드 집합 트랙킹 • 실시간으로 생성된 고밀도 그리드를 저장하여 고밀도 그리드에 대한 정보를 나타내는 롱텀(Long-term) 프로파일 갱신 • 인접 고밀도 그리드를 통합한 클러스터 탐색

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	대표레코드의 그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구
연구개발 수행 내용	실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별함
연구결과	• 개인 식별 데이터 기반으로 생성한 개인별 클러스터와 개인 가상화 기반으로 생성된 비식별 클러스터의 유사성을 파악하여 사생활 유사도 판별
구체적인 내용	• 개인 식별 데이터 기반으로 생성된 클러스터 내에 밀집한 그리드 셋 탐색 • 개인 가상화 기반으로 생성된 클러스터 내에 밀집한 그리드 셋 탐색 • 탐색된 각각의 그리드 셋을 아래와 같은 수식을 통해 비교 분석 • $A =$ 개인식별데이터기반그리드$Sets$, $B =$ 개인가상화기반그리드$Sets$ 유사도 $= \frac{Count(A \cap B)}{Count(A)}$, $false-negative = \frac{Count(B-A)}{Count(B)}$, $false-positive = \frac{Count(A-B)}{Count(A)}$

세부 연구목표	검증을 위한 실제 빅데이터 준비 및 검증 프로세스 수립
연구개발 수행 내용	빅데이터 제공 및 검증 시스템 지원 방안 수립
연구결과	• 관련 사업 및 기존 연구보고서 등을 참고하여 빅데이터 제공 및 검증시스템 지원 방안 수립서 작성 • 빅데이터 준비
구체적인 내용	• 주관기관 및 참여사 요구사항 반영 • (신용정보를 바탕으로) 검증용 빅데이터 생성 로직 적용 및 데이터 Set 준비

세부 연구목표	빅데이터 비식별화 검증을 위한 시스템 환경 구성
연구개발 수행 내용	빅데이터 준비 및 초기 검증 · 개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건)
	검증/시연을 위한 시스템 환경 준비 및 지원
연구결과	• 검증/지원 시스템 인프라 준비 • 검증/지원 시스템 구성도
구체적인 내용	• 신용정보법 및 개인정보법 등 관련법령의 허가된 범위 내, 실질적으로 실제 데이터를 검증할 수 있는 환경 및 시스템 구현

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 2차 년도(2016)

세부 연구목표	반정형/비정형 개인정보 탐지기술의 정확도 향상
연구개발 수행 내용	반정형/비정형 개인정보 탐지기술의 정확도 향상
연구결과	• 비정형 데이터의 고유 식별 정보의 패턴향상을 통한 속도 6% 증가함 데이터의 양이 증가하더라도 현재단계에서 초당 약 1만7천건 개인정보 탐지 가능 CPU 기반 Multi-Threading 및 In-Memory 병렬처리 연구개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 반정형/비정형 개인정보 탐지 학습데이터 구축 • 다양한 데이터 도메인에 대한 적응성 향상 • 형태소 기반 자연어처리를 통한 개인정보 탐지 정확도 향상
구체적인 내용	• 반정형/비정형 데이터의 개인정보 식별 성능 향상을 위한 오탐 Data_base 구축 • 오탐 Data_base의 정확도 향상을 위한 학습 데이터 구축 • 금융/의료/행정 등의 도메인에 따른 별도 Data_base를 사용을 통한 적응성 향상 • 형태소 기반 자연어처리를 통한 반정형/비정형 개인정보 탐지 속도 향상

세부 연구목표	개인정보 이용주기, 민감도에 따른 개인정보보호 정책 생성
연구개발 수행 내용	개인정보 이용주기, 민감도에 따른 개인정보보호 정책 생성
연구결과	• 개인정보의 사용되는 이용주기 및 고유 식별자, 식별자, 속성자 등의 구분에 따라 민감도를 설정하고 이에 따른 이용 및 파기 등의 조치를 하는 개인정보보호 정책 설정기능 개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 개인정보 생명주기 (수집, 관리, 이용, 파기)에 따른 관리 시스템 개발 • 개인정보 유형별 관리정책 수립 및 시스템 개발
구체적인 내용	• 비식별화 대상 파일의 수집, 저장, 이용 파기의 생명주기에 따라 접근권한, 저장 위치 분리, 삭제 등 에 대한 관리 시스템 개발 • 고유식별 정보, 성명, 상세주소, 전화번호, 의료기록, 은행기록 등 유형별, 이용여부, 파기여부 등에 따른 민감도 설정 • 민감도 수준 및 이용여부에 따른 3자 제공 제한

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지
연구개발 수행 내용	개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지
연구결과	• 개인정보 접근에 대한 시스템의 설계 방향, 모니터링 대상 정의, 위협에 대한 지표를 설정하고 5W1H를 기준으로 분석하여 비정상 행위 및 부적정 이용에 대한 탐지 기술 개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 비정상 행위/부적절 이용탐지 패턴 개발 • 탐지 패턴 자동화 탐지기능 개발
구체적인 내용	• 비정상 행위/부적정 이용에 대한 5W 1H의 행동 패턴 분석을 통한 탐지 패턴 개발 - WHO : 사용자 (사번, 사원명 등) - WHAT : 사용 개인정보 등 - WHEN : 처리 일시, 로그인 시간 등 - WHY : 열람, 입력, 수정, 삭제 등 - WHERE : 시스템명, 시스템 ID 등 - HOW : 수집된 시스템 명, 요청 URL 등 • 패턴 방향정의, 정보수집, 유효성 검증 절차에 따른 비정상 행위 분석 및 시나리오 도출 • 패턴 방향 정의 - 시스템 개념 정의 - 시스템 설계 방향 정의 • 정보 수집 - 모니터링 대상 정의 - 위험/핵심위험지표 정의 • 유효성 검증 - 행동패턴 추적 검증 - 행동분류 - 행동기반 위협 정의 • 비정상 행위의 시나리오 기반 탐지패턴에 따른 탐지 자동화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	K.L.T 비식별화 고속처리 기술 (분산환경 중심)
연구개발 수행 내용	분산환경 기반 개인정보 고속 비식별화 기능
연구결과	• 기존 익명화 알고리즘을 분산 환경에 맞게 활용하기 위해 병렬처리 및 분산처리 할 수 있도록 수정한 알고리즘 개발 • 기존 단일머신 기반 익명화 알고리즘에서는 대용량의 익명화 처리가 불가능하여,scale-out이 가능하도록 알고리즘 적용
연구 수행 방법 (이론적 · 실험적 접근방법)	• 관련 연구 및 동향 분석 • MapReduce를 이용한 비식별화 알고리즘 설계 • 서버 클러스터 기반 익명화된 데이터 저장 방법 개발 • 익명화 데이터 모니터링 기술 개발 • 서버 클러스터를 이용한 분산 비식별화 처리 기술 개발
구체적인 내용	• 기존 익명화 알고리즘을 분산환경에 맞게 활용하기 위해 병렬처리 및 분산처리 할 수 있도록 수정한 알고리즘을 개발 • 기존 단일머신 기반 익명화 알고리즘에서는 대용량의 익명화 처리가 불가능하여, scale-out이 가능하도록 맵리듀스를 이용하는 익명화 알고리즘을 개발 • 익명화 알고리즘을 맵리듀스에서 효율적으로 수행하기 위한 다양한 최적화 진행

세부 연구목표	개인정보 형식 판별 및 형식 유지 기반 익명처리 기능 개발
연구개발 수행 내용	개인정보 형식 판별 및 형식 유지 기반 익명처리 기능 개발
연구결과	• 재식별의 위험성 평가를 통한 사전적 지식의 수준을 고려하여 형식 유지기반 알고리즘 개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 개인정보의 형식 유지 한계에 따른 익명처리 기능 개발
구체적인 내용	• 개인정보의 형식 유지 한계 정의 및 통계적 유효성에 따른 가명처리, 총계처리, 데이터 마스킹, 등의 익명 처리 기능 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	개인정보 유출방지를 위한 영역분리 보안 관리 기술 개발
연구개발 수행 내용	개인정보 유출방지를 위한 영역분리 보안 관리 기술 개발
연구결과	• 비식별화를 위해 수집된 데이터의 안전한 보관을 위한 별도의 개인정보 데이터 영역 구분 기술 개발 • 일반 데이터 저장 영역과 비식별화를 위한 영역을 물리적으로 분리하여 비식별 로직 개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 일반 빅데이터 영역과 개인정보 데이터 영역 구분 시스템 구성 계획 수립 • 각 영역별 데이터 접근에 대한 절차적 접근 프로세스 개발
구체적인 내용	• 일반 빅데이터 영역과 개인정보 데이터 영역을 별도 H/W을 통한 영역 구분 - 비식별화 수집부분, 비식별화 대상 및 정보 부분, 비식별화 결과, 이용 완료 후 파기 대상 등의 영역 구분 • 수집 대상, 이용 대상, 저장 대상, 파기 대상에 따른 데이터 영역의 접근 권한 설정

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	반정형 로그 데이터의 추상로그데이터화(대표로그데이터화) 비식별화 기술 개발
연구개발 수행 내용	로그성 반정형 데이터의 정형화 기술 연구
	추상레코드별 반정형 로그 데이터의 그룹화 기술 연구
	로그 데이터의 통합 기술 연구
	비식별화된 추상 레코드 테이블 간의 데이터 동기화(연계) 기술 연구
연구결과	• 반정형 트랜잭션 개인 로그 데이터의 정형화 기술개발 • 개인 로그 데이터의 그룹핑 및 생성된 그룹별 로그 데이터 매핑 기술개발 • 그룹별 로그데이터에 대해 비식별화 수행 및 timestamp / 그룹별 추상 로그 데이터 생성 기술개발 • 2개의 동기화 대상 추상화 결과 테이블에 대해 공통된 속성을 선정하여 동기화 속성으로 지정하고 동기화 속성을 이용하는 동기화(연계) 기술개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 로그성 반정형 데이터의 정형화 기술 연구 • 추상레코드별 반정형 로그 데이터의 그룹화 기술 연구 • 로그 데이터의 통합 기술 연구 • 비식별화된 추상 레코드 테이블 간의 데이터 동기화(연계) 기술 연구
구체적인 내용	• 로그성 반정형 데이터의 정형화 기술 연구 - 반정형 트랜잭션 형태의 개인로그 데이터에 대한 비식별화 • 수행을 위해 트랜잭션 레코드를 디트랜잭션화 • (de-transactionize)하여 정형화 변환 • 추상레코드별 반정형 로그데이터의 그룹화 기술 연구 - 정형화 로그 레코드에 대해 개인 신상 데이터의 그룹핑정보를 연결 - 그룹별 로그 데이터를 매핑 및 추출 • 로그 데이터의 통합 기술 연구 - 그룹 별 로그 데이터의 단일 항목 속성에 대해 속성별 빈도수 계산 - 개인 식별 가능성이 있는 항목 제거 - 분석에 필요한 최소한의 항목들을 보존할 수 있도록 비식별 총계 처리 • 비식별화된 추상 레코드 테이블간의 데이터 동기화(연계) 기술연구 - 2개의 동기화 대상 추상화 결과 테이블에 대해서 공통된 속성을 선정하여 동기화 속성으로 지정 - 공통 동기화 속성을 대상으로 통계적 매칭 알고리즘을 수행하여 동기화 결과 레코드 생성 - 레코드 연결의 정확도를 높이기 위해 공통 동기화 속성의 최대, 최소, 평균, 표준편차 등의 분포속성을 사용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	개인정보 내용기반 Anomaly 탐지 기법 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발
연구개발 수행 내용	실시간 행위도 산출 기술개발 비정상 지수생성 기술연구 실시간 비정상 탐지 기술연구
연구결과	• 실시간 분석 엔진을 통해 생성된 개인정보 접근 프로파일 기반 실시간 행위도 산출 기술개발 • 개인정보 접근 로그 프로파일과 실시간 개인정보 접근 로그 데이터를 비교하여 실시간 모니터링 수행하고, 비정상 지수생성 • 산출된 행위도 및 비정상 지수를 통해, 실시간으로 비정상 탐지 및 시각화
연구 수행 방법 (이론적 · 실험적 접근방법)	• 실시간 행위도 산출 기술개발 • 비정상 지수 생성 기술 연구 • 실시간 비정상 탐지 기술 연구
구체적인 내용	• 실시간 행위도 산출 기술 개발 - 실시간 개인정보 접근 프로파일 생성 · 개인정보 접근 로그 데이터(학습용 데이터)를 입력 받아 데이터 전처리 · 실시간 분석 엔진을 통해 정상적인 상황 학습 · 학습 결과로 실시간 개인정보 접근프로파일 생성 • 실시간 행위도 산출 · 실시간 개인정보 접근 로그 데이터 (모니터링용 데이터)를 입력 받아 데이터 전처리 · 실시간 분석 엔진을 통해 실시간 개인정보 접근 프로파일을 기반으로 모니터링 결과 추출 · 모니터링 결과로 실시간 행위도 계산, 도출 · 행위도(B-Score) 계산 수식 : $\frac{x-\mu}{2\sigma}$ (x: 입력 수치, μ: 평균, σ: 표준편차) 행위도의 판단 범주 : $\mu-2\sigma \le x \le \mu+2\sigma$ ($\fallingdotseq -1 \le B-Score \le 1$) ② 비정상 지수 생성 기술 연구 - 비정상 지수 생성 · 실시간으로 들어오는 t 시점의 개인정보 접근 로그 프로파일과 실시간 데이터(개인정보 접근 로그 데이터)와 비교하여 실시간 모니터링 수행하고, 비정상 지수 생성 - 비정상 판단 · 실시간으로 입력되는 개인정보 접근 로그 데이터를 정상 프로파일과 비교하여 비정상 범주에 포함되는 데이터를 비정상으로 판단 - 비정상 정도의 구간 · 비정상 판단된 데이터는 좌, 우측으로 나뉘어 통계치를 산출하고, 이를 기반으로 비정상 정도의 구간을 3단계로 정의(비정상 정도가 낮은 경우, 보통인 경우, 높은 경우로 구분하고, 각각 순서대로 예외레벨 0, 1, 2라고 정의)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구체적인 내용	- 비정상 정도의 구간 ・비정상 지수 계산 수식: $\frac{x-\mu'}{2\sigma'}$ (x: 데이터 수치, μ': 비정상 프로파일평균, σ': 비정상 프로파일 표준편차) ・예외레벨 0의 판단 범주 : $-2\sigma' \leq x \leq 2\sigma'$ ・예외레벨 1의 판단 범주 :$-3\sigma' \leq x < -2\sigma'$ 또는 $2\sigma' < x \leq 3\sigma'$ ・예외레벨 2의 판단 범주 : $x < -3\sigma'$ 또는 $x > 3\sigma'$ ・실시간 비정상 탐지 기술 연구 - 실시간 비정상 탐지 ・Anomaly dectection 기술을 기반으로 생성된 개인정보 정상 접근 프로파일과 실시간 데이터(개인정보 접근 로그 데이터)를 비교하여 실시간 모니터링 수행 ・모니터링 결과로 산출된 실시간 행위도 및 비정상 지수를 통해, 실시간으로 비정상 행위 탐지 - 비정상 탐지 결과 시각화 ・실시간으로 비정상 탐지 결과를 Dashboard로 시각화하여 모니터링 ・과거부터 현재까지 실시간으로 들어온 행위도의 최소값, 최대값, 평균값, 현재값, 누적값 모니터링

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	문장종속형 화자그룹분류/판별을 위한 상용화 기술 개발
연구개발 수행 내용	녹음 등에 의한 오용 방지기술 개발 환경 또는 신체적 변화에 의한 음질 변이 시의 화자그룹분류/판별 성능개선 상용화를 위한 다채널 방식의 화자그룹분류/판별 SW 개발
연구결과	• 합성음, 녹취 재생음 등에 의한 오용을 방지할 수 있는 대응기술 개발 • 사용자의 내적 발화변이 및 외부 환경요인들에 의한 음질의 변이 보상기술개발 • 다채널 서버용 SW 개발
연구 수행 방법 (이론적 · 실험적 접근방법)	• 녹음 등에 의한 오용 방지기술 개발 • 환경 또는 신체적 변화에 의한 음질 변이 시의 화자 그룹분류 /판별 성능개선 • 상용화를 위한 다채널 방식의 화자그룹분류 /판별 SW 개발
구체적인 내용	• 개인 음성생체정보 등록 및 인증 시스템에서의 도용 사례 - 음성생체정보 등록 시에 합성음, 녹취재생음을 통한 등록 - 음성생체정보 인증 시에 흉내음, 변조음, 녹취 재생음을 통한인증 시도 • 개인 음성생체인식 상용화를 위한 오용방지 대응기술 - 사용자가 음성생체인증에 의한 본인 인증시에 최근의 사용자 음성입력 프로파일 데이터와의 비교를 통한 녹취 재생음 판별 - 개인 음성생체정보 등록 시에 반복 발성 및 발성 간 유사도 비교에 의한 합성음 및 녹취재생음 판별 • 음성생체인증에서 성능에 영향을 미치는 요인들 - 화자의 발화 변이: 신체/정신적 상태, 감정상태 - 외부환경에 의한 변이: 녹음 채널(마이크/유선전화/휴대폰), 배경잡음 등 • 개인 내적, 및 외부 환경적 변이 요인들에 의한 음질 변이에 대한 보상 기술 - 전처리 단계: 잡음제거, 반향제거 - 음성특징추출 단계: 특징보상, 특징변환 등 - 화자모델 단계: 모델의 세션변이 보상기법, 시간 변화에 따른 화자모델 적응. • 음성생체인증기술의 상용화를 위한 요구기능 정의 및 SW • 설계/구현 - 다채널 음성생체인증 SW의 요구기능정의 - 다채널 음성생체인증 SW의 구조 설계, API 정의 및 구현 - 다채널 SW에서의 메모리 요구량 및 처리시간 최적화 - 다채널 음성생체인증 SW의 동작 안정화 • 화자그룹 분류/판별 응용을 위한 필요기술 개발 - 개인정보 비식별화 (고수준/저수준)에 의한 개인 음성생체 정보 비식별화 및 그룹화 기술적용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	마케팅 프로그램 개발
연구개발 수행 내용	마케팅 프로그램 구현
연구결과	• TM(텔레마케팅) 어플리케이션 프로그램 개발
구체적인 내용	• 음성기반의 인/아웃바운드 TM상담기능 - 웹기반의 클릭투 콜 • 아웃바운드 캠페인 설정 및 DB배분기능 • 콜이력 조회 및 녹취기능 제공 • 콜통계 기능 제공

세부 연구목표	개인 시그네쳐 기반 비식별화 데이터 빈발패턴, 연관규칙 탐사 기법 연구
연구개발 수행 내용	빅데이터 처리 엔진(hadoop.등) 기반의 빈발패턴, 연관규칙 탐사 기법 연구
	개인 시그네쳐 및 대표레코드/대그룹 트랜잭션 기반 빈발패턴/연관규칙 탐사 기법 연구
연구결과	• Hadoop Spark 환경에서 실행하는 빈발패턴/연관규칙 알고리즘을 사용하여 비식별된 트랜잭션의 빈발패턴/연관규칙 탐사 • 비식별된 트랜잭션으로 개인 시그네쳐 및 대표 레코드/데그룹 트랜잭션으로 변환 시, 제거된 트랜잭션의 아이템 통계수치를 이용하여, 비식별된 트랜잭션으로 찾은 빈발패턴/연관규칙의 정확도 향상
구체적인 내용	• Hadoop Spark 환경에서 실행하는 빈발패턴연관규칙 알고리즘을 사용하여 비식별된 트랜잭션의 빈발패턴/연관규칙 연구 • 비식별된 트랜잭션으로 개인 시그네쳐 및 대표레코드/데그룹 트랜잭션으로 변환 시, 제거된 트랜잭션의 아이템 통계수치를 이용하여, 비식별 된 트랜잭션으로 찾은 빈발패턴/연관규칙의 정확도 향상

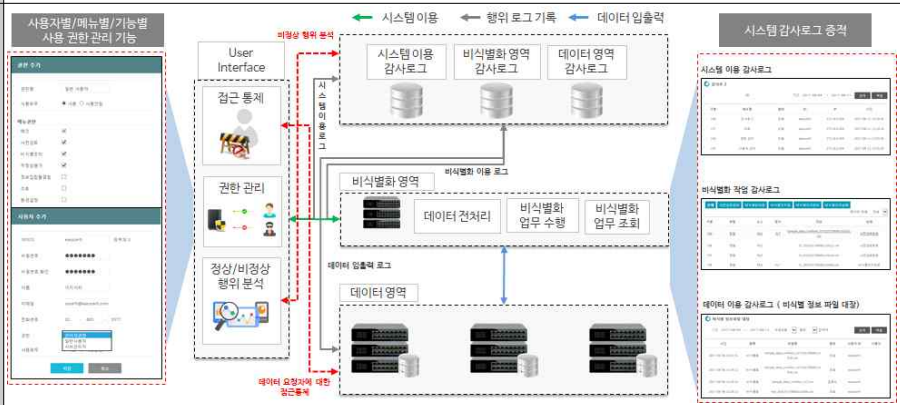
세부 연구목표	빅데이터 비식별화 검증을 위한 시스템 및 시연 환경 제공
연구개발 수행 내용	빅데이터 준비 및 초기 검증・개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건)
	검증/시연을 위한 시스템 환경 준비 및 지원
연구결과	• 주관기관 및 참여사 요구사항반영 • (신용정보를 바탕으로) 검증용 빅데이터 생성 로직 적용 및 • 데이터 Set 준비

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 3차 년도(2017)

<table>
<tr><td>세부 연구목표</td><td>반정형/비정형 개인정보 탐지 기술의 속도 향상</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>개체명 인식에 대한 비정형 개인정보 인식 특화를 통한 속도 향상</td></tr>
<tr><td>비 저장성 데이터를 통하여 메모리상에서 개인정보 탐지 기능 개발</td></tr>
<tr><td>병렬처리를 통한 비정형 개인정보 탐지 속도 향상</td></tr>
<tr><td>연구결과</td><td>• 인메모리 환경에서 데이터를 활용하여 개인정보를 탐지하고 처리를 할 수 있는 시스템 개발 및 처리 속도 향상 수행</td></tr>
<tr><td>구체적 내용</td><td>• 개인정보 개체명 태그 셋을 별도 정의
• 정의한 개인정보에 대한 인식률을 높여 속도 향상 및 정확도를 향상

<table>
<tr><th>번호</th><th>범주</th><th>Tag</th></tr>
<tr><td>1</td><td>PERSON</td><td>PS</td></tr>
<tr><td>2</td><td>LOCATION</td><td>LC</td></tr>
<tr><td>3</td><td>ORGANIZTION</td><td>OG</td></tr>
<tr><td>4</td><td>DATE</td><td>DT</td></tr>
<tr><td>5</td><td>TIME</td><td>TI</td></tr>
<tr><td>6</td><td>CIVILIZTION</td><td>CV</td></tr>
<tr><td>7</td><td>QUANTITY</td><td>QT</td></tr>
<tr><td>8</td><td>MATERIAL</td><td>MT</td></tr>
</table>
[표 23]개인정보 개체명 태그셋 구분</td></tr>
</table>

<table>
<tr><td>세부 연구목표</td><td>개인정보 제공 요청자에 대한 접근 통제 기술</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>시스템 감사로그 증적 기능</td></tr>
<tr><td>사용자별/메뉴별/기능별 사용 권한 관리 기능</td></tr>
<tr><td>비정상 행위/부적절 이용탐지 시 개인정보 제공 요청자의 시스템 이용 통제</td></tr>
<tr><td>연구결과</td><td>• 시스템 감사로그 증적 및 사용 권한에 따른 관리 기능을 시스템에 추가</td></tr>
<tr><td>구체적 내용</td><td> 

개인정보 요청자 접근 제어 기능</td></tr>
</table>

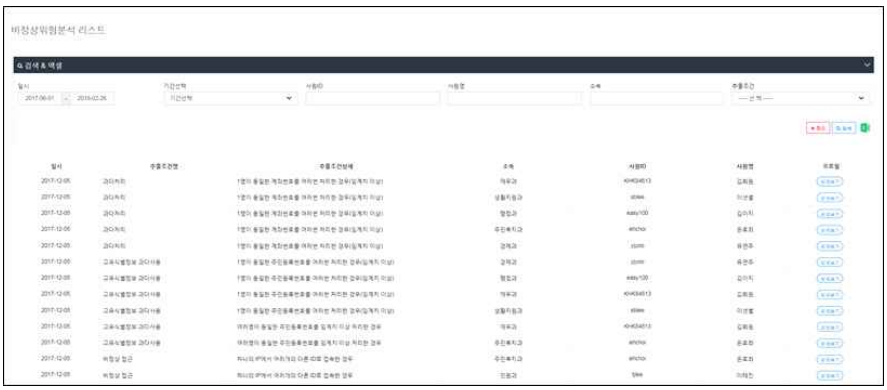
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

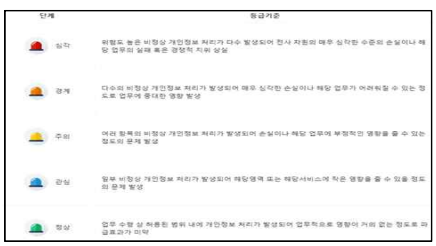
<table>
<tr><td>세부 연구목표</td><td>비식별화 정보 기반 개인정보 고속 검색 기술</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>비식별화 정보 기반 개인정보 검색 시스템 인터페이스 개발</td></tr>
<tr><td>비식별화된 개인정보간의 매칭 정보를 통하여 검색 기능 개발</td></tr>
<tr><td>매칭정보의 인덱스화 및 병렬화를 통하여 고속 검색 기능 개발</td></tr>
<tr><td>연구결과</td><td>• 개인정보간의 매칭 정보를 인덱싱, 병렬화 처리하여 속도 향상</td></tr>
<tr><td>구체적 내용</td><td>• 비 저장성 데이터 인-메모리 기반 개인정보 탐지
- 실시간으로 들어오는 개인정보 데이터에 대해 메모리 내부에서 처리가 가능하도록 시스템 개발
· 메모리 내부처리를 통한 개인정보 탐지 수행
· 기존 대비 약 20%의 처리 속도 단축
<table><tr><th>데이터 건수</th><th>2차년도 개인정보 검색 처리 속도</th><th>3차년도 개인정보 검색 처리 속도 (자체 평가)</th></tr><tr><td>20,000,000건</td><td>1259(sec)</td><td>963(sec)</td></tr></table>고속 검색기술 수행 속도</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>세부 연구목표</td><td>비정상 행위/부적절 이용 탐지 및 차단 기술</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>비정상 행위 패턴, 부적절 이용 탐지 기능의 결과에 따른 특정 사용자에 대한 시스템 이용 차단 기능</td></tr>
<tr><td>탐지된 행위에 대한 이력 관리 시스템 개발</td></tr>
<tr><td>비정상 행위별 위험도 부여 및 위험도를 통한 경계 대상자 알림 시스템 개발</td></tr>
<tr><td>연구결과</td><td>• 비정상 행위 패턴과 부적절한 이용이 감지되었을 경우 해당 사용자에 대한 로그인 차단 및 정보보안 담당자에게로의 자동알람 기능 개발</td></tr>
<tr><td>구체적 내용</td><td>• 비정상 행위 패턴, 부적절 이용 탐지 기능의 결과에 따른 특정 사용자에 대한 시스템 이용 차단 기능
- 업무시스템 사양 및 환경분석
- 각 업무단위 별 업무에 따라 임계치 조절
- 사용자 별 임계치 조절
 

[그림 21] 비정상행위/부적절 이용 탐지 및 차단 작업 흐름도

· 탐지된 행위에 대한 이력 관리 시스템 개발
 
[그림 22] 탐지된 행위에 대한 이력 관리 시스템 개발

· 비정상 행위별 위험도 부여 및 위험도를 통한 경계 대상자 알림 시스템 개발
 
[그림 23]비정상 행위/패턴 위험도 기준 설정
 
[그림 24] 경계 대상자 알림 시스템</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	익명화 정도 및 재식별 가능성 측정 모델 개발 및 구현
연구개발 수행 내용	비식별 처리된 데이터의 익명화 정도를 측정하는 모델 개발
	비식별 처리된 데이터에 대하여 특정 배경지식을 사용한 추론 공격 시 예상되는 재식별 가능성 측정 모델 개발
	익명화 정도 및 재식별 가능성 측정 소프트웨어 개발(in-memory 및 분산 클러스터 환경)
연구결과	• 비식별화된 데이터가 얼마나 익명화 되어 있고, 재식별 공격 가능성이 있는지 측정하기 위하여 익명성과 재식별 가능성 수식 개발 • 익명성과 재식별 가능성을 인메모리 환경과 분산 환경에서 측정하는 알고리즘 개발
구체적 내용	• 익명화 정도 (Degree of Anonymousness, DoA) - 정의: 정해진 k-익명성(또는 l-다양성, t-근접성) 조건에 따라 익명화한 테이블에서 임의의 한 준식별자 조합에 부합하는 레코드를 동일한 준식별자 조합을 가지는 다른 레코드와 구분할 수 있는 정도 ◦ $DoA(r_i) = 1 - \frac{1}{\lvert EC_{r_i} \rvert}$ - 익명화된 테이블의 익명성 정도는 테이블에 존재하는 각 레코드의 익명성 정도의 평균으로 계산 ◦ $DoA(T') = \frac{\sum_{r_i \in T'} DoA(r_i)}{\lvert T' \rvert}$ • 재식별 가능성 (Probability of Re-identification, PoR) - 임의의 공격자가 배경지식으로 k-익명성(또는 l-다양성, t-근접성) 조건에 따라 익명화한 테이블에 존재하는 원본 레코드의 집합을 알고 있을 때, 익명화한 테이블이 k-익명성(또는 l-다양성, t-근접성) 조건을 만족하지 못할 확률 ◦ $PoR(T') = \frac{\lvert DEC(T', R) \rvert}{\lvert EC(T') \rvert}$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	유통형 비식별화 변환된 유통용 빅데이터의 재식별 불가성 검증 기술 연구
	비식별 데이터의 분석 품질 향상을 위한 비식별화 데이터 품질 고도화 기술 개발
연구개발 수행 내용	비식별 변환의 핵심 제거 성질 (유일성, 동일성, 유사성) 검증 기술 개발
	대표레코드 생성 시 유사도 기반 그루핑 기술 연구
	그루핑 유사도 최적화 기술 연구
연구결과	• 유사성 제거 검증 기술개발, 동일성 제거 검증 기술개발, 추상화 과정 내 Differential privacy 기술적용, 유사도 기반 대표레코드 그루핑 기술개발, 대표레코드 유사도 최적화 기술개발
구체적 내용	• 유사성 제거 검증 기술 개발 - 추상화 비식별 레코드와 원본 레코드 간의 유사성 제거가 모두 정확히 수행되었는지 검사하는 모듈 개발 - 유사성 제거 : 원본 - 추상 레코드간 유사도의 [최대 ~ 최소] 범위 불만족 케이스를 모두 제거 함 • 유일성 제거 검증 기술 개발 - 추상화 비식별 레코드와 원본 레코드 간의 유일성 제거가 모두 정확히 수행되었는지 검사하는 모듈 개발 - 유일성 제거 : 원본 레코드 내에서 유일한 값 혹은 유일한 조합을 모두 제거하거나 변환하여 재식별 가능성을 제거 • 동일성 제거 검증 기술 개발 - 추상화 비식별 레코드와 원본 레코드 간의 동일성 제거가 모두 정확히 수행되었는지 검사하는 모듈 개발 - 동일성 제거 : 추상화 비식별화 변환 시 총계처리 대상 속성이 원본 레코드의 속성값과 온전히 동일하게 존재하는 케이스를 제거 함 • 재식별 위험성 평가 방법,자체 평가 - 수치형 속성 3개 / 명목형 3개로 구성된 레코드 100,000건의 원본 레코드 세트를 대상으로 추상화 비식별화 수행 - (추상화 비식별화 과정의 유일성/유사성/동일성 제거 검사 수행) - 원본 레코드 세트 - 추상화 레코드 세트에 대하여 유사성, 유일성, 동일성 제거 검증 모듈을 수행하여 모든 케이스 0건의 확인 결과 확인 - $재식별위험성 = 100 \times \frac{원본정보로재식별된건수}{비식별된전체건수} = 0\%$ 확보 확인 - (유일성/유사성/동일성 제거 모듈의 정확성 검사 수행) - 각 유사성/유일성/동일성 제거 검사 모듈의 결과와 자체 검증 수식을 적용한 수기 검토 결과 간의 비교 결과 모든 케이스가 동일함을 확인

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	고객 상담 서비스를 모델로 한 화자그룹분류/판별 시스템 개발
연구개발 수행 내용	음성모델의 추상화를 활용한 화자그룹분류/판별개발 실시간 상담 데이터에 대한 화자그룹분류/판별 기술 및 화자그룹 분류/판별을 위한 서버형 다채널 SW 개발
연구결과	• 화자변곡점 검출, 화자 군집화, 화자모델 학습 기술개발 • 문장 독립형 화자 또는 화자그룹의 분류/판별 개발 • 실시간 i-vector 추출 및 사기자/유의자 모델과의 비교 기술 구현 진행 • 서버형 다채널 실시간 화자/화자그룹 판별을 위한 요구사항 분석 및 SW 구조 설계
구체적 내용	• 성능지표 정의 - 오거부율 (False reject rate) : 등록된 사용자가 거절될 오류율 - 오수락율 (False accept rate) : 비등록 사용자가 승인되거나 다른 사용자로 식별될 오류율 - 처리시간 : 발성 종료 후 식별 시까지의 응답 시간 • 성능목표치 근거] - NIST[7] 화자인식 I-vector challenge의 leaderboard 수치 - NIST 성능지표 : minDCF(minimum decision cost function) = (false-reject-rate)/100 + (false-accept-rate) - world-best : minDCF 0.195 (Idiap) - 성능목표치 10%, 0.1%를 minDCF로 환산 시 0.2 - NIST 평가에서는 등록화자 수가 수백명이고, 16kHz 데이터 이용하며, 40~60초 데이터로 화자모델을 생성한 반면, 본 과제에서는 8kHz 30초 데이터로 화자모델을 생성하고 등록화자 수가 1천명이라는 조건을 감안하여 목표치를 설정함.

7) NIST(**National Institute of Standards and Technology)** : 미국상무부 기술관리국 산하의 각종 표준과 관련된 기술을 담당하는 연구소

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙탐사 기법 연구
연구개발 수행 내용	개인 시그네처 그룹 기반 실시간 빈발패턴/연관규칙 탐사 기법 연구 실시간 빈발패턴/연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구
연구결과	• 사생활 유사도를 기반으로 실시간 빈발패턴/연관규칙 알고리즘을 적용하여 데이터를 분석 수행 • 사생활 유사도 기반의 비식별 데이터 스트림 분석 결과의 정확도 향상을 위해 그룹 기반의 지지도 및 신뢰도 보정 기법을 연구하여 적용할 경우 유사도가 80% 수준으로 나타남
구체적 내용	• 원본 비식별 트랜잭션과 사생활 유사도 기반 비식별 트랜잭션의 유사도 대비 빈발 패턴 결과 유사도 • 유사도 = (원본 – 비식별 트랜잭션 평균 유사도 / 원본 – 비식별 빈발패턴 평균 유사도) • 예) 원본 트랜잭션과 비식별 트랜잭션의 평균 유사도 = 80%, 원본/비식별 빈발패턴 유사도 = 75%, 원본/비식별 트랜잭션 대비 빈발패턴 유사도 = 0.75 × 0.8 = 0.9375 (즉, 93.75%) • 실험 결과 - 임의의 각 다른 그룹에 속해 있는 4명의 개인에 대하여 개인별 빈발항목 집합의 비식별화 기법을 적용한 원본 비식별 트랜잭션 기반의 빈발항목 집합과 사생활 유사도를 기반으로 보정 기법을 적용한 빈발항목 집합의 유사도를 비교 분석함 - 보정 전의 유사도가 평균적으로 약 20%가량이 높았으며, 보정 후의 유사도는 모든 유사 그룹이 85%이상의 유사도를 나타냄

세부 연구목표	검증/시연을 위한 시스템 환경 구성
연구개발 수행 내용	엔진 설치 등을 위한 하드웨어/장비 설치 및 물리적 검증 환경 구성
연구결과	• 환경구성 완료

세부 연구목표	빅데이터 준비 및 검증/시연 지원
연구개발 수행 내용	검증용 데이터 추출 및 File/Table 생성 및 (기술개발 테스트 요청 시) 결과 검증 및 유의성 평가
연구결과	• 검증데이터 준비 및 비식별 검증절차서 마련

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

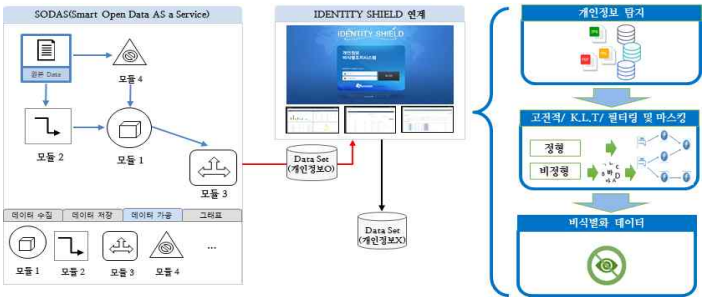
- 4차 년도(2018)

세부 연구목표	반정형/비정형 개인정보 탐지 기술의 성능 검증
연구개발 수행 내용	인-메모리, 병렬화를 통한 개인정보 탐지 기술에 대해 빅데이터를 대상으로 하여 기술 성능 검증 수행
연구결과	• 반정형/비정형 개인정보 180,000,000건 탐지 및 비식별조치 수행 시, 152초 소요
구체적 내용	• 개인정보에 대한 개체명 인식태그 셋을 별도로 정의하여 개인정보에 대한 인식률과 속도 향상 • 인-메모리 처리 기술로 대량의 데이터 처리 속도 향상 • 전체 180,000,000건에 대한 개인정보 탐지 성능을 측정 - 180,000,000건÷152초 = 1,184,210/초 • 성능측정 산술식 $= \frac{\sum \text{개인정보 탐지 건수}}{\text{총 수행시간(sec)}}$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>세부 연구목표</td><td>개인정보 탐지기능과 비식별화 기능 융합을 통한 통합 개인정보보호 솔루션 구축 및 상용화 준비</td></tr>
<tr><td rowspan="2">연구개발 수행 내용</td><td>통합 개인정보보호 솔루션 구축 관점에서 비식별화 S/W 내 고객 Legacy System 게시판 및 e-mail 본문과 첨부파일에 대한 개인정보 탐지 및 차단, 모니터링 기능 융합 수행</td></tr>
<tr><td>비정상 행위 및 부적절 이용 탐지이력 분석 및 모니터링 기능 고도화를 통한 통합 데이터베이스 접근제어 기능 모듈화 및 상용화 준비</td></tr>
<tr><td>연구결과</td><td>• 비식별화 S/W에 텍스트 혹은 파일 내 개인정보 탐지 및 마스킹 기능과 개인정보 접근 통제 시스템을 융합한 통합 개인정보보호 솔루션을 구축하고 상용화하여 분리발주 사업 진행</td></tr>
<tr><td>구체적 내용</td><td>• 비식별화 S/W에 텍스트 혹은 파일 내 개인정보 탐지 및 마스킹 기능과 개인정보 접근 통제 시스템을 융합한 개인정보보호 솔루션을 구축 및 상용화하여 분리발주 사업 진행
 
[그림 25]개인정보 탐지 및 마스킹 요청 이력
- 비식별화 S/W에 텍스트 혹은 파일 내 개인정보 탐지 및 마스킹 기능 추가
· 다양한 개인정보 탐지 및 마스킹 정책설정(개인정보 관리, 첨부파일 관리, 금칙어 관리, 예외 정책 관리)
· 요청한 텍스트 내 개인정보 탐지 및 마스킹
· 요청한 파일 내 개인정보 탐지와 hml 파일 내 개인정보 탐지 및 마스킹
- 비정상 행위 및 부적절 이용 탐지이력 분석 및 모니터링 기능 고도화를 통한 통합 데이터베이스 접근제어 기능 모듈화 및 상용화 준비
· 비정상 행위 및 부적절 이용 탐지이력 분석 기능
· 비정상 행위 및 부적절 이용 모니터링</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>세부 연구목표</td><td>데이터 보안 솔루션과 CKAN 플랫폼과의 연계 수행</td></tr>
<tr><td rowspan="2">연구개발 수행 내용</td><td>데이터 연계 플랫폼인 CKAN을 통해 제공될 비정형/반정형/정형 데이터에 대한 개인정보 탐지 및 비식별 처리를 위한 기능 개발</td></tr>
<tr><td>개인정보 탐지 및 비식별 처리 데이터의 이력관리 및 검증 수행 기능 개발</td></tr>
<tr><td>연구결과</td><td>• CKAN SODAS에서 제공하는 데이터를 비식별 처리하고 이에 대한 이력 관리 및 검증 수행 기능을 개발</td></tr>
<tr><td>구체적 내용</td><td>• CKAN SODAS에서 제공하는 비정형/반정형/정형 데이터 내 개인정보를 탐지 및 비식별 처리하고 이에 대한 이력관리와 검증 기능 개발
 

[그림 26]SODAS와 개인정보 탐지 및 비식별 솔루션 연계 시스템

- Docker Container 기반 구축 과정
・Docker 이미지 Import
 

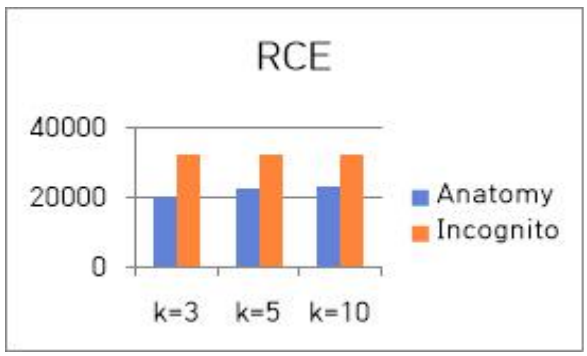
[그림 27]Docker 이미지 Import
・Docker 이미지 확인
 

[그림 28]Doker 이미지 확인</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>세부 연구목표</td><td>스키마 스캔 및 메타정보 시각화를 통한 빅데이터 플랫폼과 비식별화 S/W 연계 기술</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>스키마 스캔을 통한 빅데이터 플랫폼(Super Hadoop) 내 메타정보 시각화 기술 개발</td></tr>
<tr><td>선택된 정보요소에 대한 결합 및 추출, 분할, 그룹화, Pivoting 등 다양한 전처리 Interface 기술 개발</td></tr>
<tr><td>총괄 산출물인 Hadoop System 상에서 Working하는 고속 SQL 처리코드를 활용하여 전처리 기능별 SQL 처리코드 생성 알고리즘 개발 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 개발</td></tr>
<tr><td>연구결과</td><td>• Hadoop System 상에서 Working하는 고속 SQL 처리코드의 결과물을 비식별화하는 연계기술 개발 완료</td></tr>
<tr><td>구체적 내용</td><td>• Hadoop System 상에서 Working하는 고속 SQL 처리코드의 결과물을 비식별화하는 연계기술 개발 완료
- 메타관리를 통한 Legacy 시스템 메타정보 시각화
・빅데이터 플랫폼 등 Legacy 메타정보 연계
・메타정보 시각화를 통한 사용자 인터페이스(UX) 최적화
・Key 값 자동 인식을 통한 하나 이상의 테이블 Join 자동화
- 개방대상 데이터 유형에 따른 I/F 유형 관리
・개방대상 데이터 유형에 따른 I/F 유형 사전 정의
・데이터 개방 담당자가 능동적으로 Raw 데이터 I/F 처리 (업무절차 개선)
・그룹화 기능을 통한 Raw 데이터에 대한 다양한 전처리 수행
 
[그림 29] 빅데이터 플랫폼 등 Legacy 메타정보를 활용한 연계 시각화</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

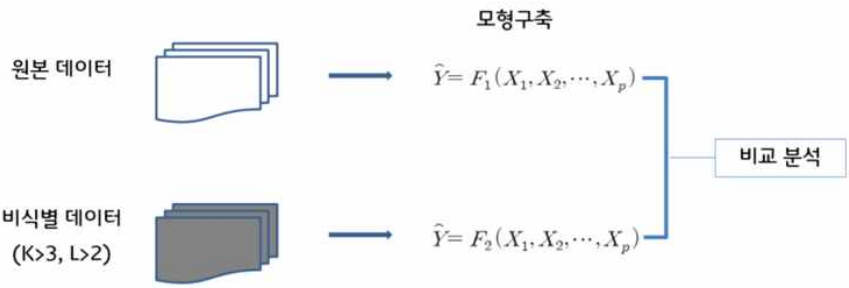
<table>
<tr><td>세부 연구목표</td><td>정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술</td></tr>
<tr><td rowspan="3">연구개발 수행 내용</td><td>기존 정보 손실을 줄이기 위한 비식별화 기술 및 모델 분석</td></tr>
<tr><td>테이블 분리 기반 비식별화 기법 개발</td></tr>
<tr><td>일반화 기반 비식별화 기법과 테이블 분리 기반 비식별화 기법의 통계적 유효성 비교</td></tr>
<tr><td>연구결과</td><td>• 통계적 유효성을 향상 시키기 위하여 테이블 분리 기반 비식별화 기법을 개발하였고, 추가적으로 일반화 기반 비식별화 기법 간의 성능 비교 진행</td></tr>
<tr><td>구체적 내용</td><td>• 가) 평가 방법
- 복원오류 (ReConstruction Error, RCE)
- 각 레코드가 가질 수 있는 민감 속성 값의 확률 밀도 함수와 원본 레코드의 확률 밀도 함수의 차이를 계산하는 측정식
- $RCE = \sum_{\forall t \in T} \int_{x \in DS} (\tilde{D}_t(x) - D_t(x))^2 dx$
- DS는 준식별자와 민감 정보를 포함한 차원 공간
$\tilde{D}_t$는 원본 데이터의 확률 분포 함수
- D_t는 익명화된 데이터의 확률 분포 함수
• 사용데이터
- Adult dataset 데이터를 이용한 실험을 통해 개발한 테이블 분리 기반 비식별화 기술을 통하여 비식별화한 데이터의 복원 오류 측정
- Adult dataset
- 데이터 속성: 7개의 칼럼 (6개의 준식별자, 1개의 민감 정보)
- 30,162개의 레코드
- k=3, 5, 10 사용
- l=2 사용
 

[그림 30]Anatomy와 Incognito의 RCE 비교</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	실시간 프라이버시 보존형 트랜잭션 항목 일반화 기법 연구
연구개발 수행 내용	빅데이터에서 비식별 트랜잭션 항목 일반화 기법 연구 실시간 일반화된 비식별 트랜잭션 빈발패턴 마이닝 기법 연구
연구결과	• 실시간으로 들어오는 트랜잭션 항목에 대해 일반화 계층 테이블을 구성하고 일반화 정도를 선택하여 각 항목 계층 이동 • 실시간으로 일반화 트랜잭션의 빈발패턴을 구하기 위해 스파크 스트림을 이용하여 FP-growth 알고리즘 구현하고 비식별화 처리 시 제거된 항목의 통계치를 이용하여 빈발패턴 결과를 보정할 경우 유사도가 80% 수준으로 나타남
구체적 내용	• 일반화 원본 트랜잭션의 빈발패턴과 일반화 비식별 트랜잭션과의 유사도를 보정 전/후로 나누어 빈발패턴 결과 유사도를 구함 • 보정 전/후 빈발패턴 유사도 = (일반화 원본 트랜잭션 빈발패턴과 일반화 비식별 트랜잭션 빈발패턴 보정 전/후간 유사도) • 실험 결과 - 임의의 각 다른 그룹에 속해 있는 4명의 개인에 대하여 개인별 빈발항목 집합의 비식별화 기법을 적용한 원본 비식별 트랜잭션 기반의 빈발항목 집합과 사생활 유사도를 기반으로 보정 기법을 적용한 빈발항목 집합의 유사도를 비교 분석함 - 보정 전의 유사도가 평균적으로 약 20%가량이 높았으며, 보정 후의 유사도는 모든 유사 그룹이 80%이상의 유사도를 나타냄

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td>세부 연구목표</td><td>기술활용을 통한 분야별 사업화 방안 조사 연구 (비식별화 데이터의 통계적 활용의 유효성에 대한 검증 방법 개발 및 사례 검증 수행)</td></tr>
<tr><td rowspan="4">연구개발 수행 내용</td><td>비식별 방법론에 대한 검토 및 활용 사례 탐색</td></tr>
<tr><td>비식별 데이터 유효성 검증 방법론에 대한 문헌 고찰</td></tr>
<tr><td>사례분석을 위한 데이터 탐색 및 기초 분석</td></tr>
<tr><td>예측 모형 비교를 통한 KLT 비식별화 데이터의 통계적 유효성 간접적 검증</td></tr>
<tr><td>연구결과</td><td>• 비식별 자료는 변수별로 1% 미만이므로 전체 데이터를 이용한 모형 구축에 있어서 비식별화가 미치는 영향은 미미함
• 비식별화는 일반적으로 식별정보 또는 준식별정보에 대해 수행하며 이러한 정보들은 예측모형에 큰 영향을 주지 않으므로, 모형 구축 측면에서 비식별화에 따른 데이터의 유용성의 훼손은 미미함</td></tr>
<tr><td>구체적 내용</td><td>• 예측 모형 비교를 통한 KLT 비식별화 데이터의 통계적 유효성 간접적 검증
- 원본 데이터 기반의 통계적 분류모형과 비식별화 데이터 기반의 분류모형의 비교를 통해 비식별 처리가 통계적 분류모형에 미치는 영향을 파악
 

비식별화 데이터 유효성 검증
- 모집단 자료는 국민건강정보DB로, 국민건강보험공단에서 2002년부터 집계된 건강보험 및 의료급여권자 전체에 대한 진료명세서와 진료내역, 상병내역, 처방전내역 등을 진료개시일 중심으로 2011년에 구축
- 예측 모형 구축을 위한 변수
· 종속변수는 뇌졸중 발병 유무(1, 0) 및 급성심근경색 발병유무(0, 1)
· 독립변수는 준식별자 대상 변수와 종속 변수에 주요한 영향을 미치는 변수 2~3개로 구성
- 모형비교는 정확도, 민감도, 특이도, 정밀도 값을 기반으로 하여 수행
• 예측 모형 관점에서 전체 데이터의 유효성 검증 결과
- 비식별화된 자료는 변수별로 1% 미만이므로 전체 데이터의 유용성은 거의 변화 없음</td></tr>
</table>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	빅데이터 처리 엔진 기반의 병렬 익명화 처리 모듈 구현
연구개발 수행 내용	Apache Spark 엔진 기반의 원본레코드 RDD 파티셔닝 최적화 기법 연구
	Apache spark SQL을 활용한 추상화 로직 구현
	RDD partition의 wide dependency를최소화하는 최적화 lineage 연구
연구결과	• Apache Spark 엔진 기반의 병렬 추상화 비식별화 모듈을 완성하였고, 해당 spark 추상화 모듈은 single node mode/ cluster mode 모두 연동 가능하며, 기존 MASQUI와 통합 완료
구체적 내용	• 빅데이터 처리 엔진 기반의 병렬 익명화 처리 모듈 구현 - Apache Spark 엔진 기반의 추상화 수행 모듈 개발 완료 - 해당 모듈의 요구사항, 설계 문서, 설계 코드 관리 대한 프로젝트 표준 개발 방안 준수 • 빅데이터 처리 엔진 기반의 병렬 익명화 레코드 연계 모듈 구현 - Apache Spark 엔진 기반의 동기화 수행모듈 개발 완료 - 해당 모듈의 요구사항, 설계 문서, 설계 코드 관리 대한 프로젝트 표준 개발 방안 준수 • 저장 데이터 비식별화 변환 속도 평가 방법 및 결과 - 4대의 범용 리눅스 서버를 사용 - 300 바이트 미만의 수치형 속성을 갖는 저장된 데이터셋을 활용 (input : NHIS 공개 데이터를 가공하여 생성한 총 1000만 건의 원본 레코드) - 재식별 불가능한 비식별화 변환 수행 후, 총 input 튜플 수와 처리 시간을 측정 => 초당 평균 변환 속도를 계산 - 처리 속도 목표치인 초당 100,000만건의 2배인 초당 200,000건 처리 달성 (3차년도 단일 서버 평균 처리속도였던 30,000보다 7~8배 향상) • 비식별화 데이터의 통계적 오차 평가 방법 및 결과 - 4대 범용 리눅스 서버를 사용 - 300 바이트 미만의 수치형 속성을 갖는 저장된 데이터셋을 활용 - 재식별 불가능한 비식별화 변환 수행 후, 총 변환된 레코드들에 대해 아래의 지표로 통계적 오차를 계산 $\text{속성 } A\text{의 통계적 오차} = \frac{\lvert \text{비식별화 데이터 평균} - \text{원본데이터의 평균} \rvert}{\text{원본데이터의 평균}} \times 100$ - 모든 속성들에 대해 오차 검증 결과 1% 이내 확보

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

세부 연구목표	빅데이터 처리 엔진 기반의 병렬 익명화 레코드 연계 모듈 구현
연구개발 수행 내용	Apache Spark 엔진 기반의 병렬 동기화 기술 개발
	비식별화(추상화) 원본 RDD 파티셔닝 최적화 기법 연구
	동기화 수준 별 Spark SQL의 Join operation(비식별 데이터 연계 시 가장 큰 병목 지점) 최적화 기술 연구
연구결과	• Apache Spark 엔진 기반의 병렬 동기화 모듈을 완성하였고, 해당 spark 동기화 모듈은 single node mode/ cluster mode 모두 연동 가능하며, 기존 MASQ UI와 통합 완료

- 5차 년도(2019)

세부 연구목표	추상화 비식별화 기법의 실시간 병렬 고속화 기술 개발
수행기관	㈜보아라
연구개발 수행 내용	빅데이터 처리 엔진 기반의 실시간 병렬 추상화 비식별화 변환 기술 개발
연구결과	• Apache Spark structured steaming 기반 실시간 추상화 모듈 개발 • Apache kafka 등 다양한 source/sink와의 연동 지원 • single node mode/ cluster mode 기반의 병렬화 지원

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 기술적 성과

■ 정량적 기대성과 (계획치/실적치)

구분	특허				국내외 논문		기술이전	상용화(백만원)	기술료(백만원)	성과홍보	시제품	S/W 등록	기술문서
	국제		국내		SCI	비SCI							
	출원	등록	출원	등록									
계획	7	-	18	6	2	5	-	-	-	-	-	9	39
실적	12	-	18	10	2	7	-	2,059	-	42	-	11	41

■ 성과지표별 목표치 설정

성과지표	가중치	실적 및 목표치						측정산식	자료수집 방법/출처
		구분	2015	2016	2017	2018	2019		
(1) 등록특허 질적평가 지수(SMART)	0.5	목표	0	4.2	4.5	0	0	∑(특허별 SMART 등급 점수) /전체 특허수	한국발명진흥회 특허평가 시스템
		실적	0	4.5	4.0	4.0	4.0		
(2)(SW컴퓨팅)사업화 매출액(점)	0.5	목표	0	0	0	0	0	사업화매출액의 합/ 당해연도 예산(10억원) * 사업화 매출액 : SW컴퓨팅에서 발생한 사업화 매출액	사업계약서
		실적	0	0.111	0.660	0.067	0.285		
합계	1.0								

※ 목표수량(6개)을 대상으로 산출함

■ 등록특허별 질적평가지수(SMART) 산출

NO	등록인	국명	등록일	등록번호	질적평가지수(SMART)	비고
1	㈜이지서티	개인정보 모니터링 시스템 및 방법	2016.09.29	10-1663288-0000	5(BB)	1차
2	고려대학교 산학협력단	익명화 기법을 이용한 데이터 수집 방법 및 시스템	2016.08.24	10-1652328-0000	4(B)	1차
3	고려대학교 산학협력단	데이터의 유용성 보존을 위한 익명화 장치 및 그 방법	2019.02.11	10-1948603-0000	4(B)	5차
4	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2018.02.26	10-1834503-0000	4(B)	3차
5	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2018.02.26	10-1834505-0000	4(B)	3차
6	㈜이지서티	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	2018.09.28	10-1904901-0000	4(B)	4차

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

NO	등록인	국명	등록일	등록번호	질적평가지수(SMART)	비고
7	아이알링크(주)	콜센터의 개인정보 비식별화 처리 시스템	2019.01.13	10-1946333-0000	1(C)	4차
8	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2017.09.27	10-1784265-0000	2(CC)	3차
9	고려대학교 산학협력단	GPGPU를 이용한 데이터 익명화의 병렬적 처리 방법	2017.11.28	10-1804426-0000	3(CCC)	3차
10	고려대학교 산학협력단	하둡기반 시스템을 위한 캐시 인지 작업 스케줄링 장치 및 방법	2018.12.04	10-1924466-0000	4(B)	4차

■ 성과 내역

(1) 국제 특허 출원

번호	출원인	국명	출원일	출원번호
1	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2016.06.10	PCT/KR2016/006206
2	아이알링크(주)	개인 생체 정보의 비식별화 시스템 및 방법	2017.07.17	PCT/KR2017/007627
3	㈜이지서티	빅 데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2018.02.02	PCT/KR2018/001463
4	㈜이지서티	빅 데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2018.02.02	18833376.9(유럽)
5	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2018.02.12	PCT/KR2018/001847
6	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2018.02.12	18833377.7(유럽)
7	㈜보아라((구)그리즐리)	빅데이터 개인정보의 익명화 및 익명화 데이터의 결합 방법	2018.03.30	PCT/KR2018/003795
8	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2018.12.07	2019-517743(일본)
9	㈜보아라((구)그리즐리)	빅데이터 개인정보의 익명화 및 익명화 데이터의 결합 방법	2018.12.30	PCT/KR2018/016945
10	㈜이지서티	빅 데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2019.04.25	2019-524048(일본)
11	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2019.04.25	2019-524059(일본)
12	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2019.05.31	PCT/KR2019/006586

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 국내 특허 출원

번호	출원인	국명	출원일	출원번호
1	㈜이지서티	개인정보 모니터링 시스템 및 방법	2015.09.04	10-2015-0125483
2	고려대학교 산학협력단	익명화 기법을 이용한 데이터 수집 방법 및 시스템	2015.10.14	10-2015-0143403
3	㈜이지서티	빅 데이터 기반 네트워크 직접 연결 정책 관리 시스템	2016.04.19	10-2016-0047529
4	㈜이지서티	네트워크에서 개인정보 시스템 접근로그 프로파일링을 위한 사용자 아이디 획득 방법	2016.05.09	10-2016-0056559
5	㈜보아라 ((구)그리즐리)	빅데이터의 비식별화 처리 방법	2016.06.09	10-2016-0071747
6	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2016.08.19	10-2016-0106674
7	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2016.08.19	10-2016-0105680
8	㈜이지서티	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	2016.11.24	10-2016-0157286
9	아이알링크(주)	콜센터의 개인 정보 비식별화 처리 시스템	2017.01.13	10-2017-0005982
10	고려대학교 산학협력단	데이터의 유용성 보존을 위한 익명화 장치 및 그 방법	2017.07.21	10-2017-009\344
11	㈜이지서티	빅데이터 비식별화 처리 시스템 및 방법	2018.03.09	10-2018-0027783
12	㈜보아라 ((구)그리즐리)	무정형 빅데이터의 개인정보 비식별화 처리 방법	2018.03.30	10-2018-0037705
13	㈜이지서티	빅데이터의 전처리 방법 및 장치	2018.06.27	10-2018-0074133
14	㈜이지서티	빅데이터 환경에서 데이터 수집을 위한 패킷 해석 방법 및 시스템	2019.01.09	10-2019-0002786
15	㈜이지서티	빅데이터 플랫폼 기반 개인정보 탐지 및 유노출 방지 시스템	2019.01.09	10-2019-0002787
16	연세대학교 산학협력단	비정형 트랜잭션 비식별 데이터의 품질 측정 기법	2019.04.17	10-2019-0045149
17	고려대학교 산학협력단	GPGPU를 이용한 데이터 익명화의 병렬적 처리 방법	2016.06.17	10-2016-0075467
18	고려대학교 산학협력단	하둡 기반 시스템을 위한 캐시 인지 작업 스케줄링 장치 및 방법	2017.08.17	10-2017-0104270

(3) 국내 특허 등록

번호	등록인	국명	등록일	등록번호
1	㈜이지서티	개인정보 모니터링 시스템 및 방법	2016.09.29	10-1663288-0000
2	고려대학교 산학협력단	익명화 기법을 이용한 데이터 수집 방법 및 시스템	2016.08.24	10-1652328-0000
3	아이알링크(주)	콜센터의 개인 정보 비식별화 처리 시스템	2019.01.13	10-1946333-0000
4	고려대학교 산학협력단	데이터의 유용성 보존을 위한 익명화 장치 및 그 방법	2019.02.11	10-1948603-0000
5	㈜보아라 ((구)그리즐리)	빅데이터의 비식별화 처리 방법	2017.09.27	10-1784265-0000
6	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2018.02.26	10-1834503-0000
7	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2018.02.26	10-1834505-0000
8	㈜이지서티	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	2018.09.28	10-1904901-0000
9	고려대학교 산학협력단	GPGPU를 이용한 데이터 익명화의 병렬적 처리 방법	2017.11.28	10-1804426-0000
10	고려대학교 산학협력단	하둡기반 시스템을 위한 캐시 인지 작업 스케줄링 장치 및 방법	2018.12.04	10-1924466-0000

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(4) 국내 및 국외 논문

번호	논문명	학술지명	게재일	주저자명	호	발행기관	비고
1	Utility-preserving anonymization for health data publishing	BMC Medical Informatics and Decision Making	2017.07.11	Lee, Hyukki	17	BMC Medical Informatics and Decision Making	SCI (E)
2	An anonymization protocol for continuous and dynamic privacy-preserving data collection	Future Generation Computer Systems	2017.09.08	Kim, Soohyung,Chung, Yon Dohn	93호 1065-1073p	Future Generation Computer Systems	SCI (E)
3	GPGPU를 이용한 익명화 알고리즘의 병렬 처리 기법 (A Parallel Anonymization Algorithm Using General- purpose Graphics Processing Units)	데이터베이스 연구회	2016.04.30	정기정	32권 제1호	한국정보과학회	비SCI
4	개인정보 집계화를 통한 실시간 모니터링 시스템 설계 및 구현	2016춘계학술대회	2016.05.18	임영훈	2016춘계학술대회 논문집	한국IT서비스학회	비SCI
5	프라이버시 보호 데이터 배포를 위한 모델 조사	정보과학회 논문지	2017.02	김종선	제44권 제2호	한국정보과학회	비SCI
6	k-익명성 보장 비식별 데이터의 빈발패턴 정확도 향상 기술	2017한국IT서비스학회 춘계학술대회	2017.05.30	이원석	한국IT서비스학회 학술대회 논문집 (2017)	한국IT서비스학회	비SCI
7	개인정보보호를 위한 동질 그룹 기반 개인별 실시간 클러스터링 기법	한국정보전자통신기술학회 춘계학술대회 발표논문지	2017.05.27	장연진 이원석	Vol.10 No.1	한국정보전자통신기술학회	비SCI
8	비식별 데이터의 재식별 위험성에 관한 연구	2018추계학술대회	2018.11.30	오현석, 용우석, 강동현, 이원석	2018 한국IT서비스학회 학술대회 논문집	한국IT서비스학회	비SCI
9	통계모형의 정확도에 기반한 비식별화 데이터의 품질 측정	한국콘텐츠학회논문지	2019.05	전희주	제5호	한국콘텐츠학회	비SCI

(5) S/W 등록

번호	저작권 등록번호	제호	창작연월일	공표일자	등록일자
1	C-2016-019114	K-Tiger(케이타이거)	2016.06.30	2016.06.30	2016.08.04
2	C-2017-009429	마케팅프로그램	2017.03.01	-	2017.04.14
3	C-2017-010390	실시간 행위 탐지를 위한 Loarder(로더) 프로그램	2017.04.21	-	2017.04.21
4	C-2017-011968	맵리듀스를 활용한 케이엘티 비식별화 시스템	2017.05.02	2017.05.02	2017.05.23
5	C-2018-006079	텍스트 독립형 화자그룹 식별 프로그램	2018.02.27	-	2018.03.07
6	C-2018-025198	IDENTITY SHIELD V3.0 (개인정보 비식별조치 솔루션 V3.0)	2015.12.01	2015.12.01	2018.09.20

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	저작권 등록번호	제호	창작연월일	공표일자	등록일자
7	C-2018-034900	U-PRIVACY SAFER API V3.0 (개인정보 필터링 API V3.0)	2018.04.30	2018.04.30	2018.11.27
8	C-2018-038897	MASQ(Multi-level Abstraction & Synchronization Quest, 다수준 추상화 & 동기화)	2018.12.01	-	2018.12.19
9	C-2018-039526	테이블 분리 기반 데이터 비식별 시스템	2018.12.07	2018.12.07	2018.12.24
10	C-2019-000087	비식별화 데이터 유효성 검증을 위한 R 통계 프로그램	2018.12.15	2018.12.15	2019.01.02
11	C-2019-002467	실시간 비식별화 빈발패턴 마이닝 엔진	2018.12.05	2019.01.24	2019.01.24

(6) 기술문서

번호	제 목	수행기관
1	빅데이터 탐지, 비식별화 연구 및 동향 분석서	이지서티
2	비정형·반정형 개인정보 탐지기법 설계명세서	이지서티
3	정책에 의한 비정형·반정형 개인정보 탐지기법 기능명세서	이지서티
4	GPGPU를 활용한 KLT 비식별화 고속처리 기술 분석서	이지서티
5	개인정보의 형식유지 한계 개발 대상 개인정보 유형 정의	피앤피시큐어
6	개인정보의 N:1 그룹핑 기술 및 대표 레코드 생성 기술 분석서	그리즐리
7	문장 종속형 개인 식별 기술 개발 요구사항 정의서	아이알링크
8	요구사항 정의서 및 프로세스 설계서(개인정보 활용 동의 마케팅 응용 프로그램 / 문장종속형 개인식별을 위한 미들웨어 개발 / 음성수집 API 고도화 / 음성수집장치 고도화 개발)	아이알링크
9	인터뷰 결과 보고서 (별첨 : K-Format 빅데이터 리스트)	코리아크레딧뷰로
10	총괄 테스트 계획서	이지서티
11	요구사항 정의서	이지서티
12	개인정보 접근 비정상 행위 패턴 및 부적절 이용 탐지 패턴 개발	이지서티
13	형태소 기반 자연어 처리를 통한 개인정보 탐지 정확도 향상	이지서티
14	분산 환경에서 서버 클러스터를 이용한 고속 KLT 비식별화 알고리즘 개발	이지서티
15	반정형 로그 데이터의 추상 로그 데이터화 비식별화 기술 개발문서	그리즐리
16	개인정보 내용 기반 Anomaly 탐지 기법 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발문서	그리즐리
17	요구사항정의서	아이알링크
18	SW설계서	아이알링크
19	이지서티 ID Shield 테스트 수행 결과 보고서	코리아크레딧뷰로
20	빅데이터 컴포넌트와 비식별 시스템의 연동 기술 개발 보고서	이지서티
21	비식별 대상 데이터 전처리 기술개발 보고서	이지서티
22	재식별 가능성에 대한 기술 동향 조사	이지서티
23	텍스트 독립형 화자그룹식별 기술개발 및 성능평가 보고서	IR링크
24	화자변곡점 검출 및 화자분류 기술개발 및 성능평가 보고서	IR링크
25	텍스트 독립형 화자그룹식별 프로그램 요구사항정의서	IR링크
26	유사성 제거 검증 기술 개발 및 성능평가 보고서	그리즐리
27	동일성, 유일성 제거 검증 기술 개발 및 성능평가 보고서	그리즐리
28	유사도 최적화 추상화 기술 개발 및 성능평가 보고서	그리즐리
29	K.L.T Privacy Model 비식별화 기법 기반 비식별 처리 방법론	이지서티
30	데이터 수집을 위한 패킷 해석 방법 및 시스템	이지서티
31	개인정보 탐지 및 마스킹 기능을 융합한 빅데이터 플랫폼 기반 비식별 시스템	이지서티
32	개체명 인식에 대한 비정형 개인정보 인식 특화를 통한 속도 향상	이지서티
33	테이블 분리 기반 데이터 비식별 시스템	고려대
34	통계적 유용성 향상을 위한 비식별화 방법 및 테이블 분리 기반 비식별화 방법	고려대

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	제 목	수행기관
35	실시간 트랜잭션 일반화/비식별화 및 빈발패턴 마이닝 모듈 상세 설계 명세서	연세대
36	비식별데이터의 통계적 유효성 검증	동덕여대
37	MASQ 추상화 Spark application 설계서	그리즐리
38	MASQ 동기화 Spark application 설계서	그리즐리
39	MASQ 추상화 & 동기화 spark 모듈 평가서	그리즐리
40	기술문서_보아라_MASQ 실시간 추상화 Spark 모듈 평가서	그리즐리
41	표준문서 ISO20889에 관한 비식별 조치 기술 동향 조사	이지서티

(7) 사업화 실적

번호	사업명	고객사	기간	금액	비고
1	빅데이터 공통기반 플랫폼 고도화 SW 분리 발주 (개인정보 비식별화 솔루션 도입)	행정자치부 정부통합전산센터	2016.10~2016.12	95.0	구축
2	서울시 빅데이터 캠퍼스 클라우기반 분석환경 조성사업 (2 단계) - 비식별화 솔루션 구축부문	㈜에이텍아이엔에스	2017.01~2017.06	16.5	구축
3	고객정보 비식별화 솔루션 도입	KB 국민카드	2017.08~2017.10	72.5	구축
4	개인정보 비식별화 시스템 구축자재	한국전력공사	2017.10~2018.01	587.7	구축
5	부패방지종합정보시스템 구축 (1 단계) 분리발주 (개인정보 비식별화)	한국정보화진흥원 /국민권익위원회	2018.07~2019.03	67.0	구축
6	보건의료 빅데이터 HW 및 SW 통합 구매 (인프라) (컨소시엄 총 1,994,445,000 원 사업 /이지서티 13% 259,277,850 원)	보건복지부	2019.02~2019.12	285.2	구축
7	두드리소 개인정보필터링 시스템 구매	대구광역시	2019.06~2019.07	27.7	구축
8	문화 빅데이터 플랫폼 구축 사업을 위한 비식별솔루션 구축	한국문화정보원	2019.09~2019.12	156.7	구축
9	NIA 통신 빅데이터 플랫폼 구축 사업 _SW(비식별화 솔루션)	㈜케이티디에스	2019.09~2019.12	165.0	구축
10	카톨릭대학교 개인정보 비식별조치 _비식별화 솔루션	카톨릭대학교	2019.10~2019.12	39.6	구축
11	개인정보 비식별 조치 솔루션 (S/W) 임차계약	경기대학교 산학협력단	2019.11~2019.12	19.9	구축
12	문화 소셜 빅데이터 센터 비식별화 솔루션 구축	㈜데이터마케팅코리아	2019.11~2019.12	44.0	구축
13	메타 데이트에 대한 비식별화 S/W 개발 용역	㈜두잉랩	2019.11~2019.12	44.0	구축
14	환경 빅데이터 플랫폼 (개인정보 비식별화 SW)	한국수자원공사	2019.11~2019.12	145.5	구축
15	문화 빅데이터 센터 비식별화 솔루션 구축	국민체육진흥공단	2019.11~2019.12	40.0	구축
16	문화 빅데이터 센터 비식별화 솔루션 구축	한국문화예술위원회	2019.11~2019.12	44.0	진행중
17	문화 빅데이터 센터 비식별화 솔루션 구축	야놀자	2019.11~2019.12	44.0	진행중
18	문화 빅데이터 센터 비식별화 솔루션 구축	레드타이	2019.11~2019.12	44.0	구축
19	법정 STT 용 IP 미디어컨버터 공급 계약 (전국 법원 12 곳 20 대 설치)	마인즈랩	2018.6.20~12.30	88	구축
20	공항공사용 ZimicX 10 대 납품	유라네트웍스	2019.05.31	33	구축

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다. 연차별 수행 내용 및 성과

(1) 1차 년도 수행 내용(연구기간: 2015.06 ~ 2016.05)

구분	기관명	연구수행내용
주관기관	㈜이지서티	▪ 반정형/비정형 개인정보 탐지 기술 - 기존 정형/반정형/비정형 개인정보 탐지 기법 분석 - 기존 기법 한계에 대한 고찰 - 비정형 개인정보 탐지 기법 연구 - 경량의 개체명 모듈 구현 - 비정형 개인정보 탐지 기술 개발 ▪ 정책 기반의 자동화된 개인정보 선별 기술 - 개인정보 탐지 정책 수립 - 개인정보 탐지 정책 관리 시스템 개발 - 개인정보 탐지 기술과 정책관리 기능의 연동 ▪ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술(인메모리 중심) - GPGPU를 이용한 인메모리 고속, 병렬 KLT 비식별화 알고리즘 개발
참여기관	(주)피앤피시큐어	▪ 개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 연구
	㈜보아라 ((구)그리즐리)	▪ 정형 데이터의 대표레코드 비식별화 기술 개발 ▪ 개인정보 내용기반 실시간 정상 행위 프로파일 생성 기술
	아이알링크(주)	▪ 문장종속형 개인식별을 위한 기반기술 개발 ▪ 개인정보 활용 동의 및 마케팅 프로그램 설계 ▪ 비식별화 데이터에 대한 개인 시그네쳐 기반 실시간 클러스터링 기법 - 가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행 - 실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별
	(주)코리아 크레딧뷰로	▪ 빅데이터 비식별화 검증을 위한 시스템 환경 구성 ▪ 검증을 위한 실제 빅데이터 준비 및 검증 프로세스 수립

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(가) 기관별 연구수행결과 및 성과

① ㈜이지서티

■ 연구수행내용

○ 반정형/비정형 개인정보 탐지 기술

- 기존 정형/반정형/비정형 개인정보 탐지 기법 분석
- 기존 기법 한계에 대한 고찰
- 비정형 개인정보 탐지 기법 연구
- 경량의 개체명 모듈 구현
- 비정형 개인정보 탐지 기술 개발

○ 정책 기반의 자동화된 개인정보 선별 기술

- 개인정보 탐지 정책 수립
- 개인정보 탐지 정책 관리 시스템 개발
- 개인정보 탐지 기술과 정책관리 기능의 연동

○ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술(인메모리 중심)

- GPGPU를 이용한 인메모리 고속, 병렬 KLT 비식별화 알고리즘 개발

○ 관련 연구 및 동향 분석

- 기존 빅데이터 익명화 기법 분석
- GPGPU를 이용한 데이터 처리 기술 분석
- 기존 기법 한계 극복에 관한 고찰

○ GPGPU를 활용한 속도 향상

- 데이터를 익명화 할 때 처리 속도 증진을 위한 GPGPU 활용
- GPGPU 상에서 비식별화 가능한 비식별화 기법 개발

○ 데이터 비식별화 기법의 병렬처리 적용

- 메모리상에서 병렬적으로 수행되는 비식별화 기법 개발
- 데이터 비식별화를 병렬적으로 처리함에 있어 비식별화 시간 단축

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 지식재산권(특허)

번호	출원인	국명	출원일	출원 번호	NTIS 등록번호	기여율
1	㈜이지서티	개인정보 모니터링 시스템 및 방법	2015-09-04	10-2015-0125483	-	100%
2	㈜이지서티	빅데이터 기반 네트워크 직접 연결 정책 관리 시스템	2016-04-19	10-2016-0047529	-	100%
3	㈜이지서티	익명화 기법을 이용한 데이터 수집 방법 및 시스템	2015-10-14	10-2015-0143403	-	100%
4	㈜이지서티	네트워크에서 개인정보 시스템 접근로그 프로파일링을 위한 사용자 아이디 획득 방법	2016-05-09	10-2016-0056559	-	100%

○ 국내 및 국외 논문 게재

번호	기관명	논문명	학술지명	게재일	주저자명	호	국명	발행기관	NTIS 등록번호
1	㈜이지서티	GPGPU를 이용한 익명화 알고리즘의 병렬 처리 기법(A Parallel Anonymization Algorithm Using General-purpose Graphics Processing Units)	데이타베이스 연구회	2016-04-30	정기정	32권 제1호	대한민국	한국정보과학회	11586316

○ 기술문서

번호	기관명	상세 구분
1	㈜이지서티	빅데이터 탐지, 비식별화 연구 및 동향 분석서
2		비정형·반정형 개인정보 탐지기법 설계명세서
3		정책에 의한 비정형·반정형 개인정보 탐지기법 기능명세서
4		GPGPU를 활용한 KLT 비식별화 고속처리 기술 분석서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 경제적 성과

○ 대외적 성과

- 솔루션 전시 및 시연회

번호	구분	참가기관	주최기관	행사명	일시	장소
1	포럼	㈜이지서티	경기도, 서울대학교	2015 빅 포럼(B.I.G Forum)	2015-10-13 ~ 2015-10-15	경기창조경제혁신센터(판교)

· 경기도와 서울대학교가 주최하고 경기콘텐츠진흥원, 한국정보화진흥원이 주관하는 ‘2015 빅포럼(B.I.G Forum : Big data Initiative of Gyeonggi)’의 전시 참가 업체로 빅데이터 내 개인정보 비식별화 제품에 대한 전시 부스 운영. 행사 참여를 통해 빅데이터 비식별화 연구과제의 성과 홍보 및 빅데이터 내 개인정보 비식별화 제품 및 비식별화의 필요성에 대한 대외적인 홍보, 국내의 빅데이터 관련 제품 동향, 연구 성과를 통한 사업화를 위해 국내 시장에서 빅데이터 내 개인정보 비식별화 대한 수요 등을 확인



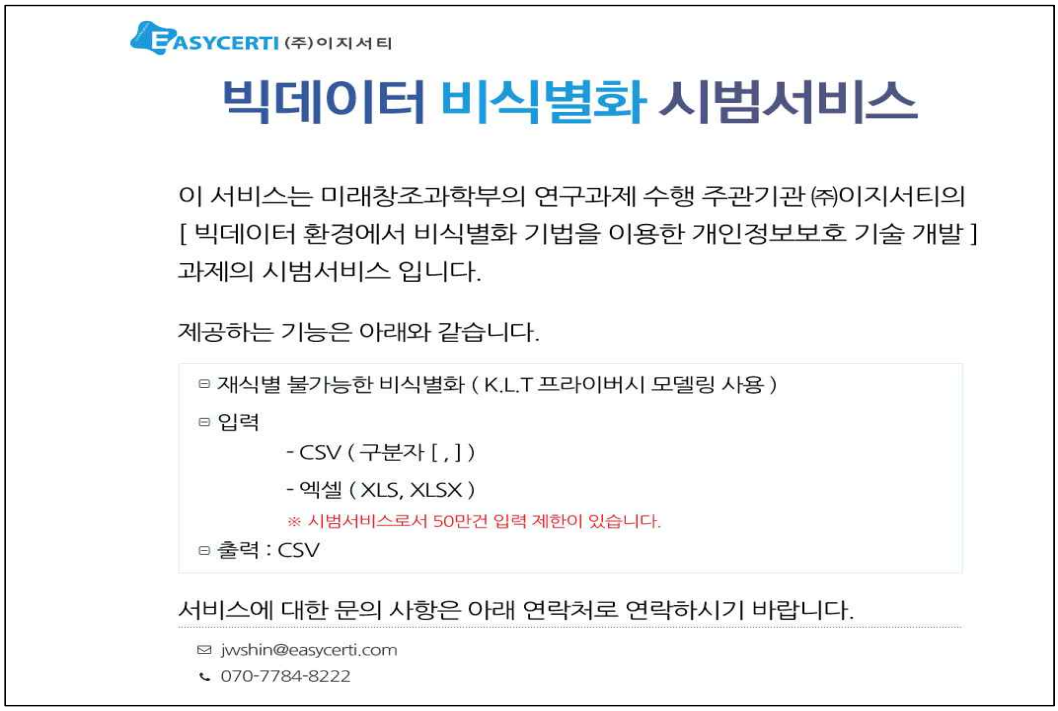
[그림 32] B.I.G 포럼 전시 부스 운영

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- K-ICT 빅데이터 센터 빅데이터 비식별화 시범서비스

· K-ICT 빅데이터 센터는 미래창조과학부와 한국정보화진흥원이 ICT가 선도하는 창조 한국 실현을 위한 핵심 성장 동력으로 ICBMS를 지목하고 이를 전략산업으로 육성하기 위해 설립한 센터로 빅데이터 정책 개발과 실행, 빅데이터 인프라 운영, 전문 인력 양성에 기여하고 있다.

· 2세부 과제의 4차년도에 진행예정인 빅데이터 비식별화의 사업화를 위한 사전 시범서비스를 운영하여 비식별화 서비스에 대한 시장의 반응 및 개인정보가 포함된 빅데이터를 보유하고 있는 기관이 빅데이터를 분석하여 활용할 수 있도록 K-ICT 빅데이터 센터를 통한 빅데이터 비식별화 서비스를 제공.



[그림 33] K-ICT 빅데이터 비식별화 시범 서비스

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

② ㈜보아라((구)그리즐리)

■ 연구수행내용

○ 정형 개인식별 정보에 대해 재식별이 불가능한 비식별화 기술 개발



[그림 34] 추상 레코드 생성 및 분포속성 생성 기술 개요

- 개인정보의 N:1 그룹핑 기술 개발

  · N개의 원본 레코드들을 묶어 1개의 대표레코드를 생성하기 위해, 동일한 범주형 속성들을 갖고 있는 레코드들을 묶어 대그룹 집합을 형성하여 수치형 속성값이 연속적으로 나열되도록 정렬하는 기술을 개발

- 개인정보의 추상 레코드 생성 기술 개발

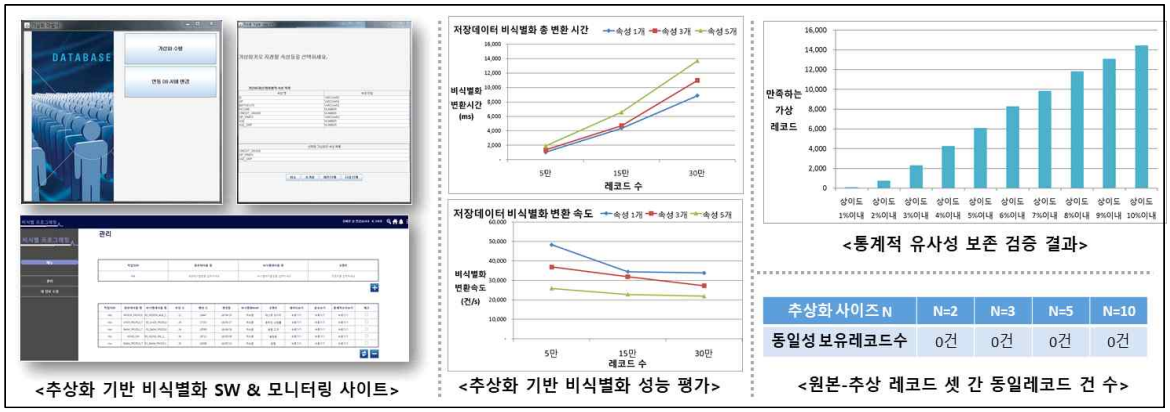
  · 추상화 진행 대상 선정속성으로 로 범주형 및 수치형 타입을 선택할 수 있어야하며 해당하는 타입 별로 소값, 최대값, 평균, 중앙값 등 선정 함수를 사용자가 선택할 수 있도록 맞춤형 비식별화 기술 제공 가능

- 추상레코드의 그룹핑키 분포 속성, 그룹핑 분포속성 생성 기술 개발

  · 그루핑키로 선택된 속성의 집계 함수를 사용자가 선택하여 그루핑키 데이터의 상세값 확인할 수 있도록 하고, 그루핑 분포속성을 통해 사용자가 수치형 속성들에 선정함수를 선택하여 각 수치 데이터 상세값 확인할 수 있도록 개발

- 추상화 기반 비식별화 SW 프로토타입 개발 및 성능평가

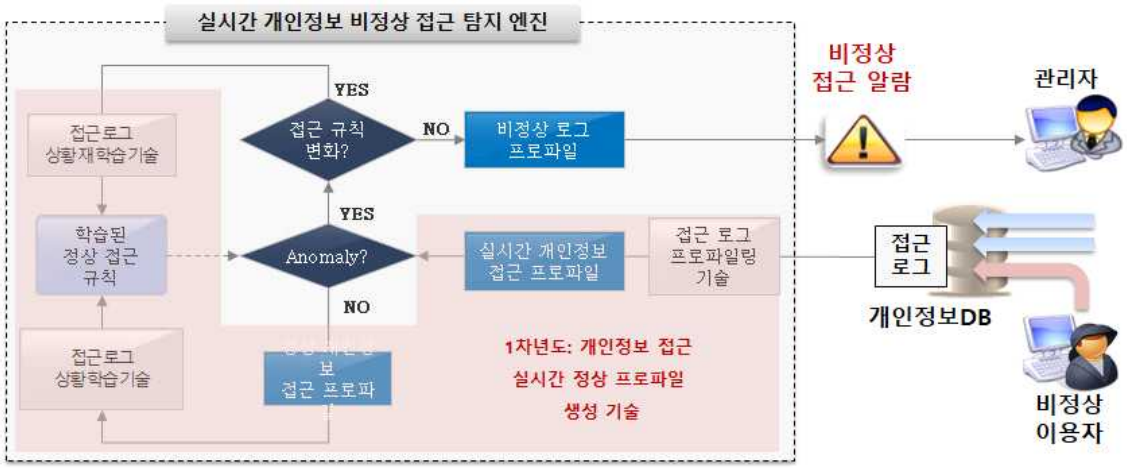
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



<추상화 기반 비식별화 SW & 모니터링 사이트>
<추상화 기반 비식별화 성능 평가>
<통계적 유사성 보존 검증 결과>
<원본-추상 레코드 셋 간 동일레코드 건 수>

[그림 35] 추상화 기반 비식별화 성능 평가

○ 데이터 접근 기록 실시간 정상 프로파일 생성 기술(연구기간: 2015.06 ~ 2016.05)

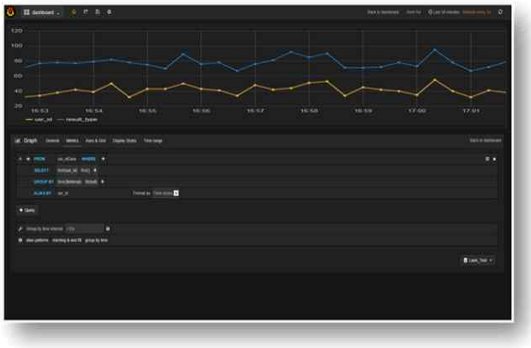


[그림 36] 데이터 접근 기록 실시간 정상 프로파일 생성 기술 개요

- 개인정보 접근 로그 정상 프로파일 생성 기술 개발
- 수동적 개입을 최소화한 실시간 개인정보 접근 로그 상황 학습 기술 개발
- 지속적 상황 관리 수행 및 특정 상황 변동에 대한 상황 재학습 기술 연구
- 정상 프로파일링 기반의 정상 행위 판별 기술 개발
  · 실시간으로 들어오는 t 시점의 개인정보 접근 로그 데이터를 동일 시점의 정상 패턴 프로파일과 비교하여 개인정보 접근 로그 정상 프로파일을 실시간으로 모니터링 하여 정상 상황 관리할 수 있는 기술 개발
  · 기본 시간 단위를 설정하고 개인정보 접근 로그 정상 프로파일 건수의 최소값, 최대값, 평균값, 현재값, 누적값에 대해 설정한 시간까지의 정상 프로파일 실시간 모니터링하는 기술을 개발

· 실시간 모니터링 하고자 하는 패턴들을 라인 그래프, 막대그래프, 점그래프로 시각화 표현

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



<정상 프로파일 모니터링용 Dashboard>

원본레코드 수	10만	20만	30만	40만	50만
실시간 프로파일 생성 속도	7,635.92	7,614.70	7,622.73	7,611.80	7,601.44
원본레코드 수	60만	70만	80만	90만	100만
실시간 프로파일 생성 속도	7,605.81	7,592.60	7,604.49	7,469.44	7,599.59

(2) 평균 수행 시간

※단위 (ms)

원본레코드 수	10만	20만	30만	40만	50만
평균 수행 시간	0.131	0.131	0.131	0.131	0.132
원본레코드 수	60만	70만	80만	90만	100만
평균 수행 시간	0.131	0.132	0.132	0.134	0.132

<정상행위 프로파일 생성 성능 측정 결과>

[그림 37] 정상행위 프로파일 생성 성능 측정 결과

■ 기술적 성과

○ 기술문서

번호	기관명	상세 구분
1	㈜보아라 ((구)그리즐리)	비식별화 변환을 위한 개인정보 그룹핑 및 대표 레코드 생성 기술 구현

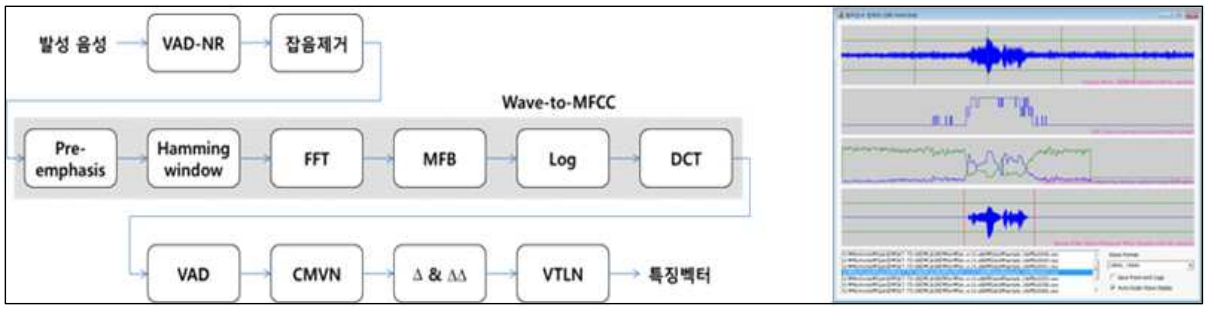
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

③ 아이알링크㈜

■ 연구수행내용

○ 문장종속형 개인식별 기반 기술 개발

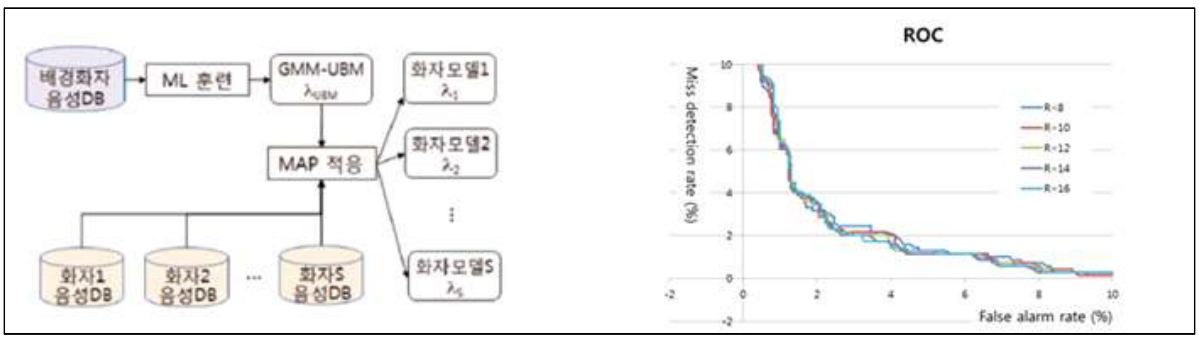
- 개인 식별을 위한 음성 전처리 기술 개발



[그림 38] 잡음제거 알고리즘/기술 및 특징정보추출 기술개발/모듈화

- 패스워드 복수 발성 데이터를 이용한 화자모델 등록기술 개발

· 5가지(HMM, GMM, SVM, JFA, i-Vector) 방식의 화자모델 등록기술 및 본인인증 알고리즘 개발 및 성능비교



[그림 39] 본인인증 알고리즘 및 성능비교

- 패스워드 발성형 개인식별 기술개발

· 5가지 방식 중 최적방식으로 다채널 개인식별용 SDK 개발 및 시연프로그램 제작

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 40] 다채널 개인식별용 SDK 개발
및 시연프로그램

○ 개인정보 활용 동의 마케팅 프로그램 설계

- 개인식별기술 활용목적의 TM(텔레마케팅) 어플리케이션 설계

· 마케팅 프로그램 요구사항 정의 및 프로세스 설계

· 마케팅 프로그램 테이블 및 UI 설계

○ 비식별화 변환된 대표레코드에 대하여 적용 가능한 실시간 클러스터링 기법 연구

- 비식별화 데이터에 대한 개인 시그네쳐 기반 실시간 클러스터링 기법 연구

· 가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행

- 대표레코드의 그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구

· 실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별

■ 기술적 성과

○ 국내 및 국외 논문 게재

번호	기관명	논문명	학술지명	게재일	주저자명	호	국명	발행기관	SCI여부	NTIS등록번호
1	연세대학교	개인정보 집계화를 통한 실시간 모니터링 시스템 설계 및 구현	2016춘계학술대회	2016-05-30	임영훈	2016춘계학술대회 논문집	대한민국	한국IT서비스학회	비SCI	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 기술문서

번호	기관명	상세 구분
1	아이알링크(주)	문장 종속형 개인 식별 기술 개발 요구사항 정의서
2		요구사항 정의서 및 프로세스 설계서 (개인정보 활용 동의 마케팅 응용 프로그램 / 문장종속형 개인식별을 위한 미들웨어 개발 / 음성수집 API 고도화 / 음성수집장치 고도화 개발)

④ ㈜피앤피시큐어

■ 연구수행내용

○ 개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 연구

- 개인정보의 최소 형식 유지 한계 분석

- 개인정보의 형식 유지 한계에 따른 익명처리 알고리즘 개발

■ 기술적 성과

○ 기술문서

번호	기관명	상세 구분
1	㈜피앤피시큐어	개인정보의 형식유지 한계 개발 대상 개인정보 유형 정의

⑤ ㈜코리아크레딧뷰로

■ 연구수행내용

○ 데이터 검증을 위한 H/W 및 S/W 지원

- 검증/시연을 위한 시스템 환경 준비 및 빅데이터 준비 완료

○ 데이터 검증을 위한 실제 빅데이터 준비

- 빅데이터 제공 및 검증 시스템 지원 방안 수립

- 제공정보의 종류 : 개인정보, 대출개설정보, 카드개설정보, 연체정보 등

- 개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 기술문서

번호	기관명	상세 구분
1	㈜코리아 크레딧뷰로	인터뷰 결과 보고서 (K-Format 빅데이터 리스트)

○ 기타 성과

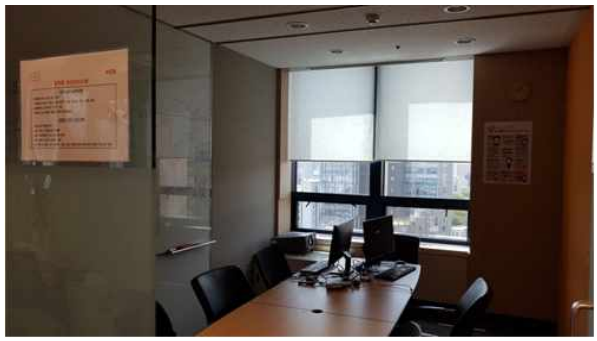
- 개인정보의 노출제어를 위해, 물리적 통제방안(네트워크 차단, 외부연동 불가) 마련과 이를 위한 내부 절차서를 수립하여 향후(금융신용정보 보유기관, 업체에 대한) 사례화 가능성 확인

세부 연구 목표	연구개발 수행 내용
■ 검증을 위한 실제 빅데이터 준비 및 검증 프로세스 수립	· 빅데이터 제공 및 검증 · 시스템 지원 방안 수립
■ 빅데이터 비식별화 검증을 위한 시스템 환경 구성	· 빅데이터 준비 및 초기검증 · 개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건) · 검증/시연을 위한 시스템 환경 준비 및 지원

- 물리적 통제환경 구성 실증사례



[그림 41] 허가된 인력에 대한 출입통제 실시
(지문인증, 출입증 발급)



[그림 42] 별도의 독립된 공간을 할당하여
추가적인 출입통제 강화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 2차 년도 수행 내용(연구기간: 2016.06 ~ 2017.05)

구분	기관명	연구수행내용
주관기관	㈜이지서티	▪ 반정형/비정형 개인정보 탐지 기술의 정확도 향상 ▪ 개인정보 이용주기, 민감도에 따른 개인정보보호 정책 생성 ▪ 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지 ▪ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (분산환경 중심) ▪ 대용량 데이터의 KLT 비식별화를 위한 서버 클러스터 기반 분산 알고리즘 개발 ▪ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 ▪ Anatomy 기반 비식별화를 통한 통계적 유효성 향상 기법 개발 ▪ 개인정보 형식 판별 및 형식 유지 기반 익명처리 기능 개발 ▪ 개인정보 유출방지를 위한 영역분리 보안 관리 기술 개발
참여기관	㈜보아라 ((구)그리즐리)	▪ 비정형 로그 데이터의 대표로그데이터화 비식별화 기술 개발 ▪ 개인정보 내용기반 Anomaly 탐지 기법 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발
	아이알링크㈜	▪ 문장종속형 개인식별을 위한 상용화 기술 개발 ▪ 마케팅 프로그램 개발 ▪ 개인 시그네쳐 기반 비식별화 데이터 빈발패턴, 연관규칙 탐사 기법 연구 - 빅데이터 처리 엔진(hadoop. 등) 기반의 빈발패턴, 연관규칙 탐사 기법 연구 - 개인 시그네쳐 및 대표레코드/대그룹 트랜잭션 기반 빈발패턴/연관규칙 탐사 기법 연구
	(주)코리아 크레딧뷰로	▪ 빅데이터 비식별화 검증을 위한 시스템 및 시연 환경 제공 ▪ 2년차 검증을 위한 실제 빅데이터 준비 ▪ 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(가) 기관별 연구수행결과 및 성과

① ㈜이지서티

■ 연구수행내용

○ 반정형/비정형 개인정보 탐지 기술의 정확도 향상

- 반정형/비정형 개인정보 탐지 학습데이터 구축

- 다양한 데이터 도메인에 대한 적응성 향상

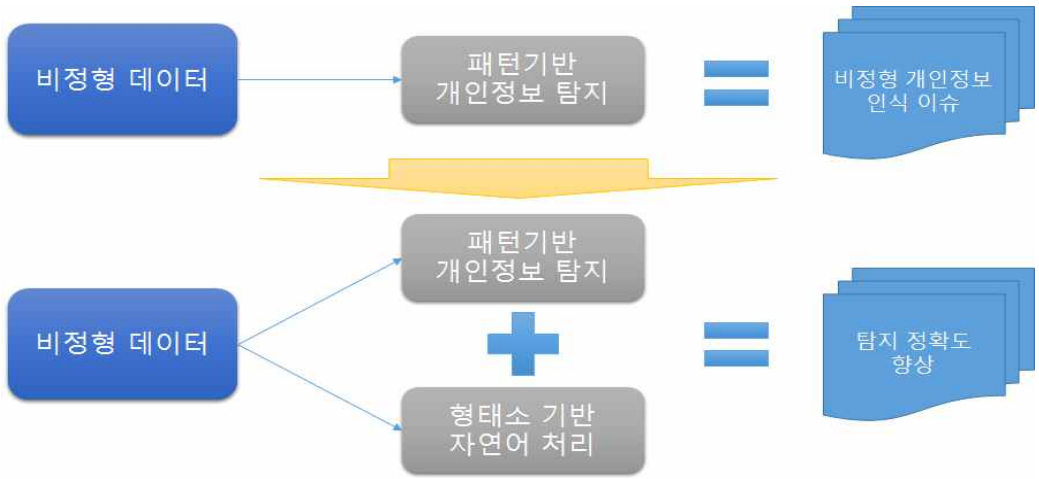
- 형태소 기반 자연어 처리를 통한 개인정보 탐지 정확도 향상

  · 형태소 기반 자연어 처리 기술 분석

  · 패턴탐지 기반 개인정보 탐지와 형태소 기반 자연어 처리기술의 융합에 대한 고찰

  · 패턴탐지 기반 개인정보 탐지 처리 기술과 형태소 기반 자연어 처리 기술의 통합 처리 시스템 설계

  · 시스템 프로토 타입 개발



[그림 43] 형태소기반 자연어 처리를 이용한 비정형 데이터에서의 개인정보 탐지 정확도 향상

○ 개인정보 이용주기, 민감도에 따른 개인정보보호 정책 생성

- 개인정보 생명주기(수집,관리,이용,파기) 에 따른 관리 시스템 개발

- 개인정보 유형별 관리 정책 수립 및 시스템 개발

  · 개인정보 유형별 민감도 설정 기능

  · 민감도에 따른 개인정보 제3자 제공 제한 기능

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지

- 비정상 행위/부적절 이용 탐지 패턴 개발

- 탐지 패턴 자동화 탐지 기능 개발

○ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (분산환경 중심)

- 관련 연구 및 동향 분석

· 대용량 데이터의 분산 처리 기술 분석

· 기존 서버 클러스터 기반 데이터 비식별화 기술 분석

· 기존 데이터 비식별화 기법 한계 분석

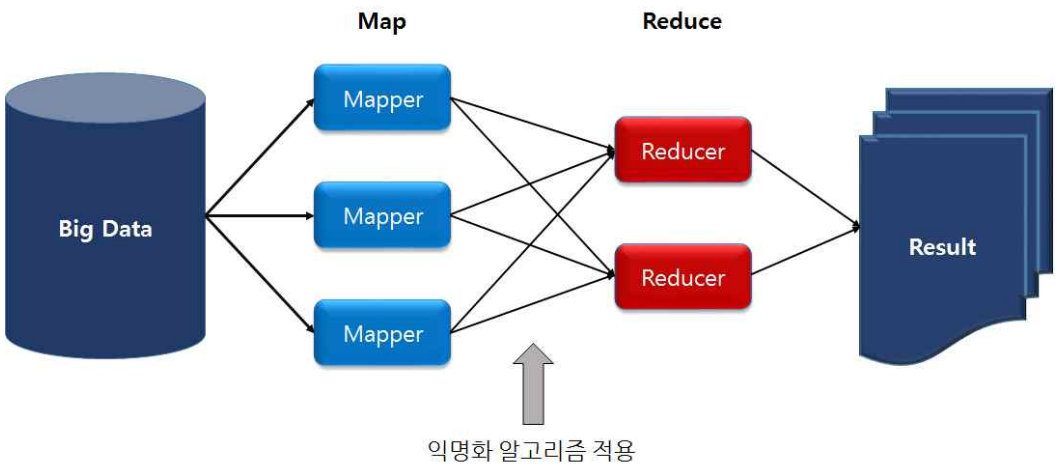
· 기존 기법들의 한계 극복에 대한 고찰

· 서버 클러스터 기반 익명화 알고리즘 설계

- MapReduce를 이용한 비식별화 알고리즘 설계

· Reduce 단계에서 비식별화 기법 적용

(1) 그림 8과 같은 데이터 비식별화 방법에 대한 개략적인 구상



[그림 44] MapReduce를 이용한 데이터 비식별화 기법 설계

- 서버 클러스터 기반 익명화된 데이터 저장 방법 개발

· 데이터 유출 시 프라이버시를 보호하기 위한 저장 기법 개발

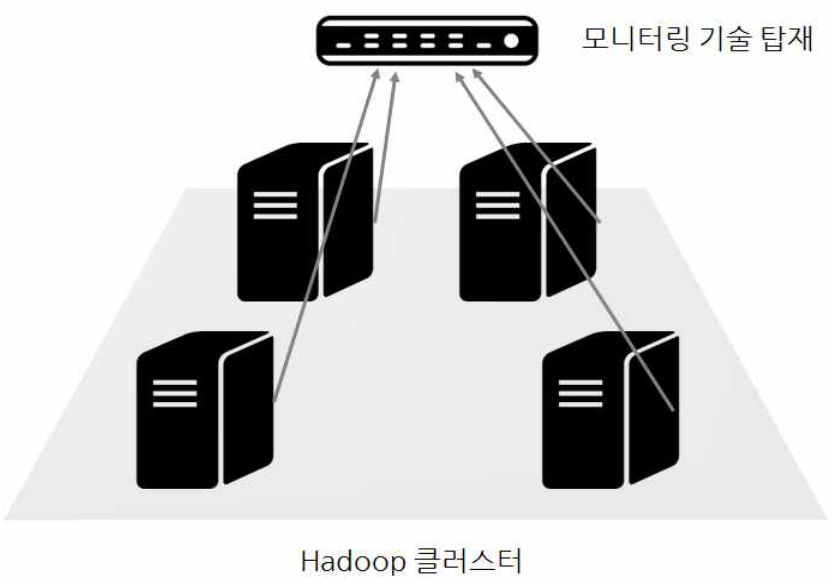
· 데이터의 결합을 통한 프라이버시 노출을 막기 위해 효율적인 분산 저장 기법 연구

- 익명화 데이터 모니터링 기술 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

· 익명화된 데이터의 프라이버시 보호 유지를 위한 모니터링 기술 개발

· 주기적으로 Hadoop 내의 데이터를 관찰 (그림 9 참조)



[그림 45] 데이터 프라이버시 보호 유지를 위한 모니터링

- 서버 클러스터를 이용한 분산 비식별화 처리 기술 개발

· 서버 클러스터 환경 구축

· 대용량 데이터를 분산처리 하기 위한 최적화 알고리즘 설계

· 분산 비식별화 처리를 위한 데이터 분할 실험 및 비식별화 수행

- Anatomy기법의 성능을 향상 시킨 비식별화 기법 개발

· 기존 Anatomy 기법의 한계분석

· 다중 민감한 속성일 경우 Anatomy를 발전시킨 비식별화 기법 성능 향상

· 정보 손실을 최소화하기 위한 최적화

· 그림 10과 같은 익명화 모델의 개략적인 구상

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Age	Sex	Zipcode	Disease	Salary
22	M	47906	flu	30000
22	F	47906	dyspepsia	40000
33	F	47905	bronchitis	30000
52	F	47905	flu	50000
54	M	47302	gastritis	50000
60	M	47302	flu	50000
60	M	47305	dyspepsia	40000
64	F	47305	dyspepsia	30000

원본 데이터

(Age, Sex)	(Zipcode, Disease, Salary)
(22, M)	(47905, flu, 50000)
(22, F)	(47906, dyspepsia, 50000)
(33, F)	(47905, bronchitis, 40000)
(52, F)	(47906, flu, 30000)
(54, M)	(47305, gastritis, 50000)
(60, M)	(47302, flu, 50000)
(60, M)	(47302, dyspepsia, 40000)
(64, F)	(47305, dyspepsia, 30000)

비식별화 기법 적용 후 데이터

[그림 46] 발전된 Anatomy 비식별화 모델 구상

- 유효성을 측정하기 위한 메트릭 개발

  · 데이터의 정보손실 측정을 위한 수식 연구

  · 민감한 속성 집합의 익명화 척도를 측정하는 모델 연구

  · 비식별화 데이터에 대한 정확성과 신뢰성을 측정하기 위한 정보 유용성 메트릭 개발

- 개인정보 형식 판별 및 형식 유지 기반 익명처리 기능 개발

  · 개인정보의 형식 유지 한계에 따른 익명처리 기능 개발

- 개인정보 유출방지를 위한 영역분리 보안 관리 기술 개발

  · 일반 빅데이터 영역과 개인정보 데이터 영역 구분 시스템 구성 계획 수립

  · 각 영역별 데이터 접근에 대한 절차적 접근 프로세스 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 산업재산권(특허, 실용신안, 디자인, 상표)

번호	출원인	국명	출원일	출원번호	NTIS 등록번호	기여율
1	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	2016.08.19	10-2016-0106674	10-1834503-0000	100%
2	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	2016.08.19	10-2016-0105680	10-1834505-0000	100%
3	㈜이지서티	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	2016.11.24	10-2016-0157286	10-1904901-0000	100%

○ 국내 및 국외 논문 게재

번호	기관명	논문명	학술지명	게재일	주저자명	호	국명	발행기관	NTIS 등록번호
1	㈜이지서티	프라이버시 보호 데이터 배포를 위한 모델 조사	정보과학회논문지	2017-02	김종선	제44권 제2호	대한민국	한국정보과학회	-

○ 국내 및 국제학술회의 발표

번호	기관명	회의명칭	발표자	발표일시	장소	국명
1	㈜이지서티	한국 IT 서비스 학회	JIN SHUYAN	2016-05-17.	한국과학기술회관	국내

○ 저작권(소프트웨어)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	㈜이지서티	K-Tiger (케이타이거)	2015.5	㈜이지서티	2016.6	C-2016-019114	㈜이지서티	-	100%
2	고려대학교 산학협력단	맵리듀스를 활용한 케이엘티 비식별화 시스템	2017.3	㈜이지서티	2017.5	C-2017-011968	고려대학교 산학협력단	-	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜이지서티	총괄 테스트 계획서
2		요구사항 정의서
3		분산 환경에서 서버 클러스터를 이용한 고속 KLT 비식별화 알고리즘 개발

■ 경제적 성과

○ 대외적 성과

- 솔루션 전시 및 시연회(2016 DATA MAGIC WEEK)

번호	구분	참가기관	주최기관	행사명	일시	장소
1	컨퍼런스	㈜이지서티	미래창조과학부	2016 Data Magic (Marvelous Analysis & Great Idea Challenge) Week	2016-11-02 ~ 2016-11-04	판교 스타트업캠퍼스

· 미래창조과학부에서 주최하는 2016 Data Magic(Marvelous Analysis & Great Idea Challenge) Week에서 빅데이터 내 개인정보 비식별화 제품에 대한 전시 부스 운영.

· 행사 참여를 통해 빅데이터 내 개인정보 비식별화 제품 및 비식별화의 필요성에 대한 대외적인 홍보, 국내의 빅데이터 관련 제품 동향, 현 국내 시장에서 빅데이터 내 개인정보 비식별화 대한 수요 등을 확인

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

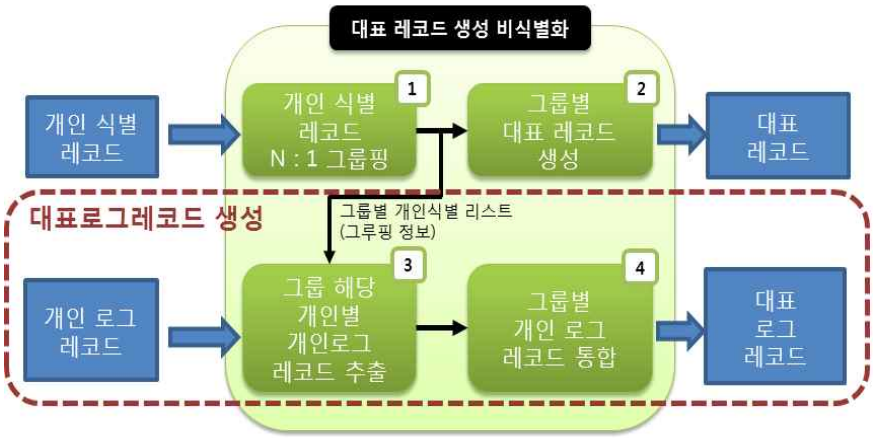


[그림 47] 2016 Data Magic Week 부스 운영

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

② ㈜보아라((구)그리즐리)

○ 반정형 로그 데이터의 대표로그데이터화 비식별화 기술 개발



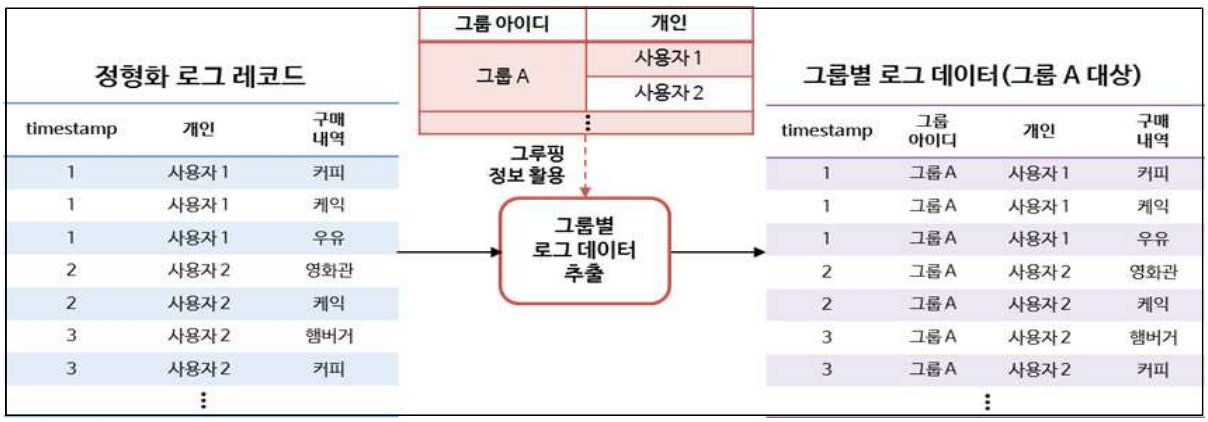
[그림 48] 대표 로그 레코드 생성 기술 개요

- 로그성 반정형 데이터의 정형화 기술 연구

· 개인 로그 데이터 중 비식별화 대상이 반정형 트랜잭션 형태인 경우 비식별화를 수행할 수 있도록 트랜잭션 레코드를 디트랜잭션화(de-transactionize)하여 정형화 변환할 수 있는 기술 개발

- 대표레코드 별 반정형 로그 데이터의 그룹화 기술 연구

· 정형화 로그 레코드에 대해 개인 신상 데이터의 그룹핑 정보를 연결하여 그룹별 로그 데이터를 매핑 및 추출하는 기술을 개발



[그림 49] 대표레코드 별 반정형 로그 데이터의 그룹화 과정

- 로그 데이터의 통합 기술 연구

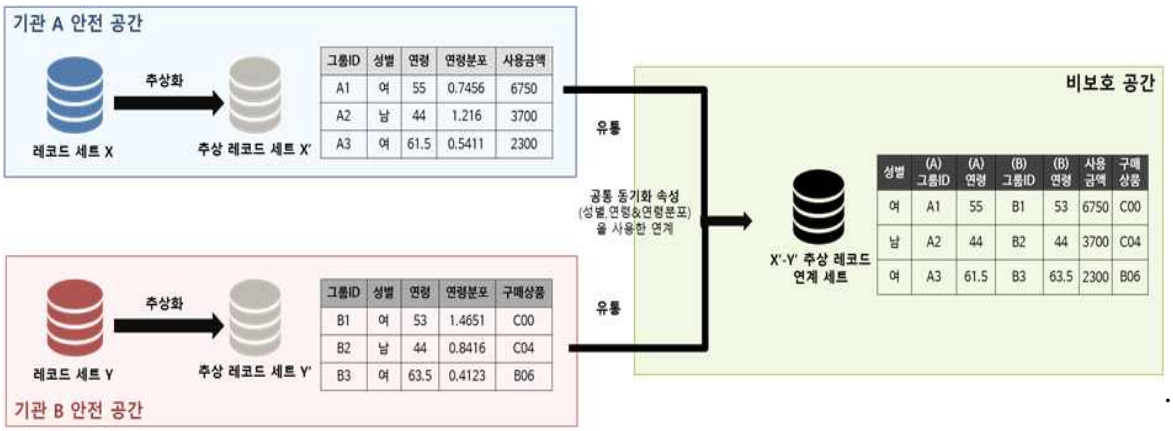
· 그룹별 로그 데이터의 단일 항목 속성에 대해 속성별 빈도수를 계산하고, 개인 식별 가능성이 있는 항목들은 제거하고 분석에 필요한 최소한의 항목들을 보존할 수 있도록 비식별 총계 처리하는 기술 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 50] 로그 데이터의 통합 과정

- 비식별화된 추상레코드 테이블 간의 데이터 동기화(연계) 기술 연구



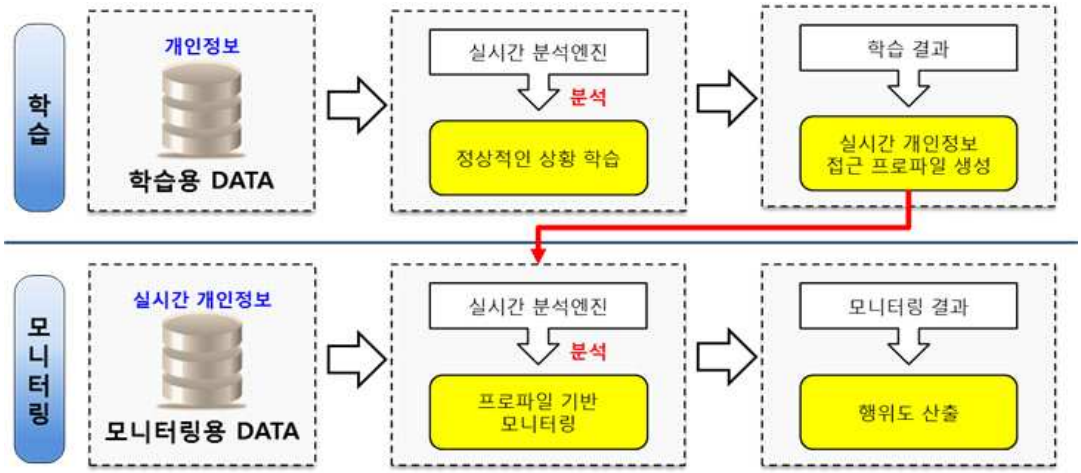
[그림 51] 비식별화된 대표레코드 테이블 간의 데이터 동기화(연계) 개요

· 추상화 기반 비식별화를 통해 데이터 유통 문제를 해결하기 위해 대표레코드의 연계 기술인 동기화 기술을 적용하여 연계된 비식별화 레코드 세트를 생성하는 기술을 개발하였음, 동기화 기술을 비식별 레코드간 통계적 유사성 측정을 기반으로 하는 레코드 연계 기술이며 동기화레코드 세트를 통해 통계 모형을 개발하여 분석 수행이 가능

○ 개인정보 내용 기반 Anomaly 탐지 기술 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발

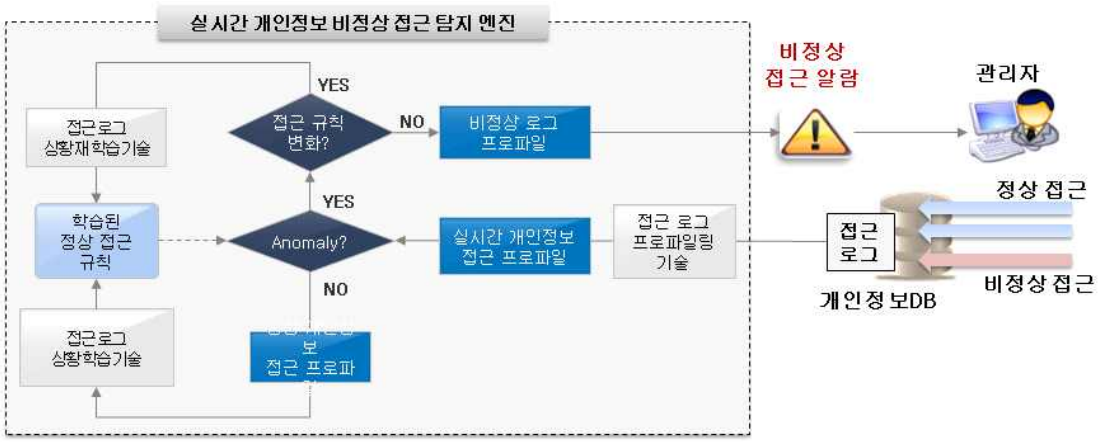
- 실시간 행위도 산출 기술 개발

· 실시간 개인정보 접근 로그 데이터를 입력 받고, 실시간 분석 엔진을 통해 실시간 개인정보 접근 프로파일(1차년도 개발 기술)을 기반으로 추출되어진 모니터링 결과를 통계, 분석하여 실시간 행위도 산출하는 기술을 개발



[그림 52] 실시간 행위도 산출 과정

- 비정상 지수 생성 기술 연구



[그림 53] 실시간 비정상 지수생성 및 비정상 탐지 과정

· 실시간으로 입력되는 개인정보 접근 로그 데이터를 (t-1) 시점까지의 정상 프로파일과 비교하여, 비정상 범주에 포함되는 데이터를 비정상으로 판단하는 기술을 개발함. 비정상 판단된 데이터는 좌, 우측으로 통계치 산출하고 이를 기반으로 비정상 정도 3단계로 정의(비정상 정도가 낮은 경우, 보통인 경우, 높은 경우로 각각 순서대로 예외레벨 0, 1, 2)하는 기술로 확장

- 실시간 비정상 탐지 기술 연구

· Anomaly 탐지 기법을 기반으로 생성된 개인정보 정상 접근 프로파일과 실시간 개인정보 접근 로그 데이터를 비교하여 실시간 모니터링 수행하며, 모니터링 결과로 산출된 실시간 행위도 및 비정상 지수를 통해 실시간으로 비정상 행위를 탐지하고, 그 결과를 시각화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 산업재산권(특허, 실용신안, 디자인, 상표)

번호	출원인	국명	출원일	출원번호	NTIS 등록번호	기여율
1	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2016-06-09	10-2016-0071747	-	100%
2	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	2016-06-10	PCT/KR2016/006206	-	100%

○ 저작권(소프트웨어)

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	㈜보아라((구)그리즐리)	실시간 행위 탐지를 위한 Loader(로더) 프로그램	2017.04.21.	㈜보아라((구)그리즐리)	2017-04-26	C-2017-010390	㈜보아라((구)그리즐리)	-	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜보아라((구)그리즐리)	반정형 로그 데이터의 추상 로그 데이터화 비식별화 기술 개발문서
2		개인정보 내용 기반 Anomaly 탐지 기법 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발문서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

③ 아이알링크(주)

■ 연구수행내용

○ 문장종속형 화자그룹분류/판별을 위한 상용화 기술 개발

- 상용화를 위한 다채널 방식의 화자그룹분류/판별 SW 개발

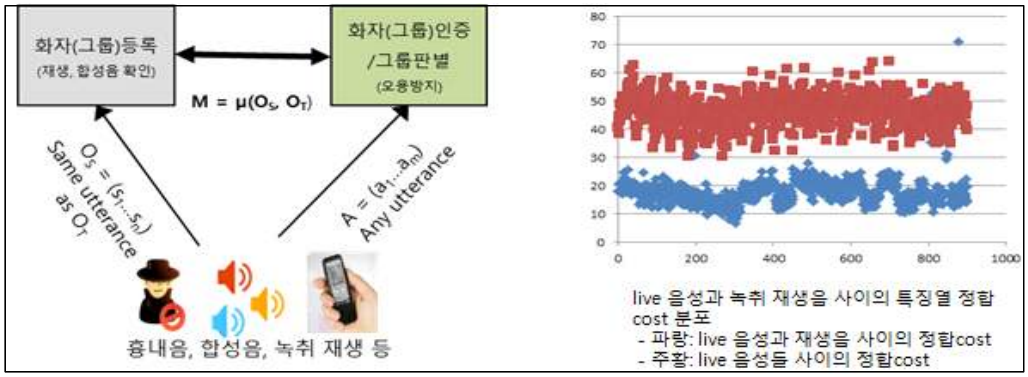
· API 설계 및 다채널 서버 SW 구현. 서버와 클라이언트 사이의 통신 프로토콜 설계 및 구현

- 녹음 등에 의한 오용 방지기술 개발

· 오용방지기술 평가용 DB 제작

· 유사도 비교를 통한 녹취재생음 판별 기술 개발

· 시나리오적 대처 기술 개발



[그림 54] 녹음 등에 의한 오용 방지기술 개발

- 환경 또는 신체적 변화에 의한 음질 변이 시의 화자그룹분류/판별 성능 개선

· 음질 변이 시의 성능 평가용 DB 제작

· 잡음 및 채널변이에 강인한 음성특징 변환 기술 개발

· 정규화(VTLN), 특징 매핑(feature mapping) 기술 개발

음질변이 보상기술 적용 여부	EER (equal error rate, %)
비적용	2.88
환경변이 보상기술 적용	1.62
환경변이 및 발화변이 보상기술 적용	1.47

[그림 55] 음질변이 보상기술 적용에 따른 EER

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 음성정보를 이용한 개인생체정보 비식별화

· 유사한 음성 특성을 보이는 개인들의 그룹핑 기술 개발

· 임의 사용자 음성을 분석하여 그룹을 식별하는 기술 개발

· 화자모델 또는 그룹모델의 비식별화 기술 개발(고수준 및 저수준 추상화)

Speech type	성능지표	원본	고수준 추상화	저수준 추상화
Clean speech	잔존율(%)	-	94.41	90.23
	상이도 평균	-	0.02735	0.130043
	Top-1 식별 성공율(%)	**99.95**	**100.0**	**99.95**
	Top-3 식별 성공율(%)	100.0	100.0	100.0
	EER(%)	0.05	0.04	0.15
	minDCF	0.0009	0.0005	0.0078
Noisy speech	잔존율(%)	-	94.41	90.23
	상이도 평균	-	0.02735	0.130043
	Top-1 식별 성공율(%)	**98.03**	**97.83**	**95.10**
	Top-3 식별 성공율(%)	98.82	98.67	97.53
	EER(%)	1.12	1.23	2.88
	minDCF	0.1052	0.1032	0.1604

[그림 56] Speech type에 따른 지표

○ 마케팅 프로그램 개발

- 마케팅 프로그램 UI 디자인/개발

· 문장 종속형 화자그룹 판별 모듈과 연동한 마케팅프로그램(TM시스템) 구현

· 마케팅프로그램 설계 및 개발 완료 및 SW등록





[그림 57] 마케팅 프로그램 UI

○ 비식별화 변환된 대표로그레코드에 대하여 적용 가능한 빈발패턴/연관규칙 탐사 기법 연구

- 비식별화 트랜잭션 DB 생성 기법 연구

- 빅데이터 처리 엔진(hadoop. 등) 기반의 빈발패턴, 연관규칙 탐사 기법 연구

- 개인 시그네쳐 기반 빈발패턴, 연관규칙 탐사 기법 연구

- 대표레코드/대그룹 레벨별 빈발패턴, 연관규칙 적용 방안 연구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 산업재산권(특허, 실용신안, 디자인, 상표)

번호	출원인	국명	출원일	출원번호	NTIS 등록번호	기여율
1	아이알링크㈜	콜센터의 개인 정보 비식별화 처리 시스템	2017-01-13	10-2017-0005982	-	100%

○ 저작권(소프트웨어)

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	아이알링크㈜	마케팅프로그램	2017-03	아이알링크(주)	2017-04	C-2017-009429	아이알링크㈜	-	100%

○ 기술문서

번호	기관명	상세 구분
1	아이알링크㈜	요구사항정의서(문장 종속형 개인식별 기술을 이용한 텔레마케팅 프로그램 개발)
2		SW설계서(음성 비식별화 기반 사용자 인증 시스템 개발)

○ 국내 및 국외 논문 게재

번호	기관명	논문명	학술지명	게재일	주저자명	호	국명	발행기관	SCI 여부	NTIS 등록번호
1	연세대학교	k-익명성 보장 비식별 빅데이터의 빈발패턴 정확도 향상 기술	2017 한국IT서비스학회 학술대회	2017-05-17	JIN SHUYAN, 이원석	2017 한국IT서비스학회 학술대회 논문집	대한민국	한국IT서비스학회	비SCI	-
2	연세대학교	개인정보 보호를 위한 동질 그룹 기반 개인별 실시간 클러스터링 기법	2017한국정보전자통신기술학회 춘계학술대회	2017-05-27	장연진, 이원석	2017한국정보전자통신기술학회 춘계학술대회 논문집	대한민국	한국정보전자통신기술학회	비SCI	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

④ ㈜코리아크레딧뷰로

■ 연구수행내용

○ 검증 시스템 적정성 검토 및 운영

○ 비식별화 기법, 통계적 유의성 검증

○ 데이터 검증을 위한 실제 빅데이터 준비

- 제공정보의 종류 : 개인정보, 대출개설정보, 카드개설정보, 연체정보 등

- 개인정보(300만건), 대출개설정보(100만건), 카드개설정보(300만건), 연체정보(5만건), 개인신용정보 조회사이트 LOG정보(50만건)

○ 빅데이터 제공 및 검증시스템 지원 방안 수립 보고서 마련

- 빅데이터 및 검증 개념 정립

- 빅데이터 준비 및 검증을 위한 방안 마련 및 선정(안) 제시

- 검증/시연을 위한 시스템 운영관리 기본방향 수립

○ 빅데이터 준비 및 초기검증

- 빅데이터 준비 및 인터뷰 수행

○ 검증/시연을 위한 시스템 환경 준비 및 지원

- 시스템 마련

구분	서버명	CPU	MEMORY	DISK	OS	DB
비식별화DB	tcboto1x	4 CORE	4 GB	188 GB	RHEL 5.10	Oracle 11.2.0.1
비식별화AP#1	tcboto2x	4 CORE	4 GB	188 GB	RHEL 5.10	-
비식별화AP#2	tcboto3x	4 CORE	4 GB	188 GB	RHEL 5.10	-
KCB 데이터 DB	tcbdbs1a	4 CORE	40 GB	3000 GB	AIX 6.1	Oracle 11.2.0.2

[그림 58] 비식별화 테스트 및 검증 시연을 위해 사용자 단말, 어플리케이션 서버 및 데이터베이스 서버 환경 구성

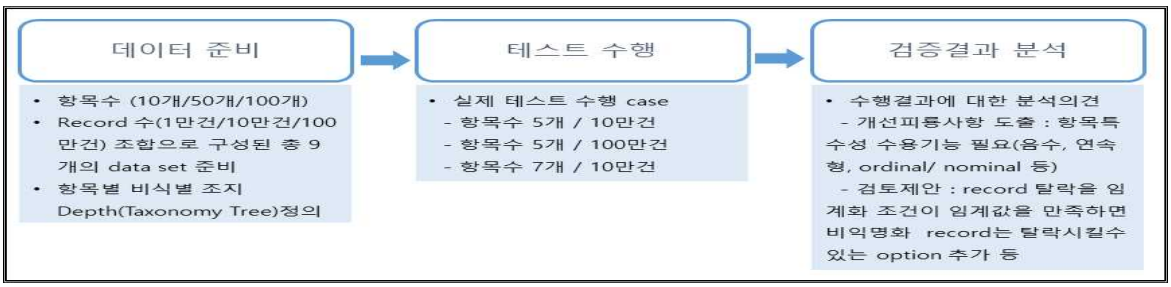
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 검증/지원 시스템 구성도



[그림 59] 실제 금융회사 환경과 동일한, 테스트 환경 구성

- 검증 테스트 절차



[그림 60] 검증 테스트 절차

■ 기술적 성과

번호	기관명	상세 구분
1	㈜코리아크레딧뷰로	㈜이지서티 IDENTITY SHIELD 테스트 수행 결과 보고서

○ 기타

- 대용량 검증을 위한, 양적 확대 및 (검증 데이터)카테고리 세분화

세부 연구 목표	연구개발 수행 내용
■ 빅데이터 비식별화 검증을 위한 시스템 및 시연환경 제공	• 빅데이터 준비 및 초기검증 · 개인정보(100만건), 대출개설정보(50만건), 카드개설정보(100만건), 연체정보(1만건) • 검증/시연을 위한 시스템환경 준비 및 지원
■ 2년차 검증을 위한 실제 빅데이터 준비	• 빅데이터 제공 및 검증 시스템 지원방안 수립

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(3) 3차 년도 수행 내용(연구기간: 2017.06 ~ 2018.03)

구분	기관명	연구수행내용
주관기관	㈜이지서티	▪ 반정형/비정형 개인정보 탐지 기술의 속도 향상 ▪ 개인정보 제공 요청자에 대한 접근 통제 기술 ▪ 비식별화 정보 기반 개인정보 고속 검색 기술 ▪ 비식별화 정보에 대한 라이프 사이클 관리 기술 ▪ 비정상 행위/부적절 이용 탐지 및 차단 기술 ▪ 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술 (인메모리 기반 / 분산환경 기반) ▪ KLT 비식별화 데이터에 대한 인메모리 기반 익명성 측정 알고리즘 개발 ▪ 대용량 KLT 비식별화 데이터에 대한 서버 클러스터 기반 익명성 측정 알고리즘 개발
참여기관	㈜보아라((구)그리즐리)	▪ 유통형 비식별화 변환 데이터의 검증 기술 연구 ▪ 비식별화 변환 연계 품질 및 속도 향상 기술 연구
	아이알링크(주)	▪ 고객상담 서비스를 모델로 한 화자그룹분류/판별 시스템 개발 ▪ 실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙 탐사 기법 연구 - 개인 시그네처 그룹 기반 실시간 빈발패턴/연관규칙 탐사 기법 연구 - 실시간 빈발패턴/연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구
	코리아 크레딧뷰로(주)	▪ 검증 시스템(H/W, S/W) 운영 ▪ 3년차 검증을 위한 실제 빅데이터 준비 ▪ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 검증

(가) 기관별 연구수행결과 및 성과

① ㈜이지서티

■ 연구수행내용

○ 반정형/비정형 개인정보 탐지 기술의 속도 향상

- 개체명 인식에 대한 비정형 개인정보 인식 특화를 통한 속도 향상

- 비 저장성 데이터를 통하여 메모리상에서 개인정보 탐지 기능 개발

- 병렬처리를 통한 비정형 개인정보 탐지 속도 향상

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 개인정보 제공 요청자에 대한 접근 통제 기술

- 시스템 감사로그 증적 기능

- 사용자별/메뉴별/기능별 사용 권한 관리 기능

- 비정상 행위/부적절 이용 탐지시 개인정보 제공 요청자의 시스템 이용 통제

○ 비식별화 정보 기반 개인정보 고속 검색 기술

- 비식별화 정보 기반 개인정보 검색 시스템 인터페이스 개발

- 비식별화된 개인정보간의 매칭 정보를 통하여 검색 기능 개발

- 매칭정보의 인덱스화 및 병렬화를 통하여 고속 검색 기능 개발

○ 비식별화 정보에 대한 라이프 사이클 관리 기술

- 수집, 생성, 이용, 파기의 라이프 사이클에 따른 관리 정책 수립

- 수립 정책에 따른 관리 시스템 개발

○ 비정상 행위/부적절 이용 탐지 및 차단 기술

- 비정상 행위 패턴, 부적절 이용 탐지 기능의 결과에 따른 특정 사용자에 대한 시스템 이용 차단 기능

- 탐지된 행위에 대한 이력 관리 시스템 개발

- 비정상 행위별 위험도 부여 및 위험도를 통한 경계 대상자 알림 시스템 개발

○ 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술 (인메모리 기반 / 분산환경 기반)

○ 인메모리 기반 데이터 익명화 관련 연구 분석

- 기존 인메모리 기반 데이터 익명화 기법 분석

- 효율적인 데이터 익명화를 위한 메모리 구조 분석

○ 인메모리 구조에서 수행 가능한 데이터 익명화 알고리즘 개발

- 처리속도 향상을 위한 인메모리 기반 데이터 익명화 알고리즘 개발

- 메모리상에서 재식별 공격 방지 탐색 속도 향상 구축

○ 병렬 처리 시 재식별 공격 방지 기법 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 데이터 비식별화를 병렬적으로 처리한 후 가능한 재식별 공격 탐색

- 재식별 공격 방지를 위한 기술 개발

○ 알고리즘의 익명화 척도 측정 수식 모델 개발

- 데이터 비식별화 속도 측정 비교 수식 연구

- 재식별 공격 방지 비용을 최소화 하는 모델 연구 및 개발

○ 서버 클러스터 기반 익명화 알고리즘 개발

- 분산 환경에서 가장 널리 사용되는 프레임워크인 Mapreduce를 이용한 비식별화 알고리즘 설계

- 비정형화 데이터를 익명화 가능하게 하는 데이터 비식별화 기법 연구 및 개발

○ 서버 클러스터 기반 재식별 공격 방지 모델 개발

- Reduce 단계에서 익명화 데이터 간 발생하는 재식별 공격 탐지 방법 연구

- Reduce 단계에서 익명화 후 데이터 간 재식별 공격 방지 모델 개발

■ 기술적 성과

○ 지식재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일(등록일)	출원(등록)번호	NTIS 등록번호	기여율
1	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT	2018-02-02	PCT/KR2018/001463	-	100%
2	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	PCT	2018-02-12	PCT/KR2018/001847	-	100%
3	㈜이지서티	빅데이터 비식별화 처리 시스템 및 방법	대한민국	2018-03-09	10-2018-0027783	-	100%
4	㈜이지서티	데이터의 유용성 보전을 위한 익명화 장치 및 그 방법	대한민국	2017-07-21	10-2017-0092344	-	100%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 국내 및 국외 논문 게재

번호	기관명	논문명	학술지명	게재일	주저자명	호	국명	발행기관	NTIS 등록번호
1	고려대학교	An anonymization protocol for continuous and dynamic privacy-preserving data collection	Future Generation Computer Systems	2017-09-08	Soohyung Kim	-	대한민국	Future Generation Computer Systems	-
2	고려대학교	Utility-preserving anonymization for health data publishing	BMC Medical Informatics and Decision Making	2017-07-11	Lee, Hyukki	17	대한민국	BMC Medical Informatics and Decision Making	ISSN/ISBN 1462-6947

○ 기술문서

번호	기관명	상세 구분
1	㈜이지서티	빅데이터 컴포넌트와 비식별 시스템의 연동 기술 개발 보고서
2		비식별 대상 데이터 전처리 기술개발 보고서
3		재식별 가능성에 대한 기술 동향 조사

■ 경제적 성과

○ 전문 연구 인력 양성

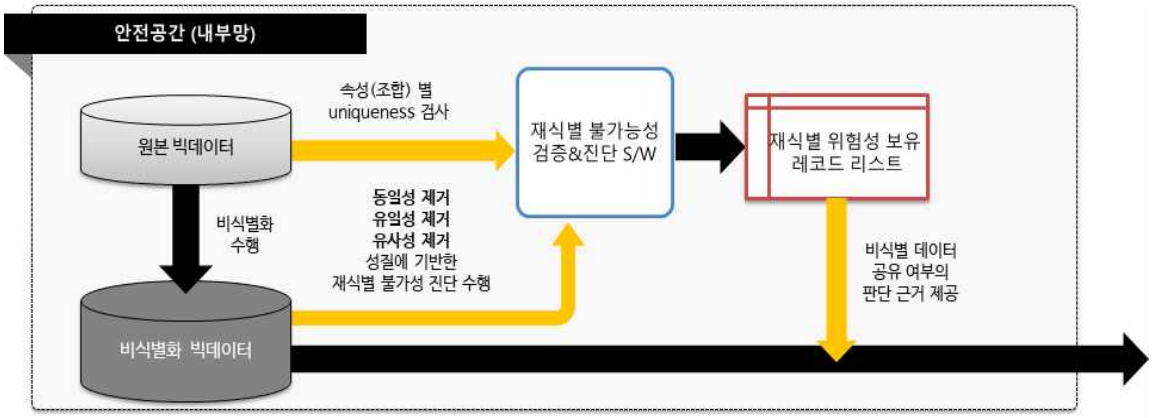
번호	분류	기준연도	현황									
			학위별			성별			지역별				
			박사	석사	학사	기타	남	여	수도권	충청권	영남권	호남권	기타
1	연세대학교	2017	-	3	-	-	2	1	3	-	-	-	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

② ㈜보아라((구)그리즐리)

■ 연구수행내용

○ 유통형 비식별화 변환된 유통용 빅데이터의 재식별 불가성 검증 기술 연구



[그림 61] 비식별화 데이터 재식별 불가성 검증 기술 개요

- 비식별 변환의 핵심 제거 성질 (유일성, 동일성, 유사성, 연속성) 검증 기술 개발

· 원본 데이터 세트에서 유일한 속성값(혹은 속성값 조합)을 동일하게 비식별데이터에 검색했을 때에도 해당 레코드 조합이 유일하게 찾아진다면 상황으로 판단하여 검출하는 기술을 개발. [유사성 제거/ 유일성 제거 / 동일성 제거] 지표를 재식별 불가성 성질로 정의하고 이를 검증하는 기술을 모듈화 하여 개발

· 동일성: 비식별화 변환 시 특정 민감 속성이 원본 레코드의 속성값과 온전히 동일하여 재식별가능성이 존재
=> 동일성 제거: 원본-비식별레코드 간 특정 민감속성 들의 속성값 일치 제거 검증. 추상화 과정에서는 총계처리 속성 값 생성시 동일성 보유 속성값이 생길 경우 속성값을 일부 변환하여 원본을 추측할 수 있는 가능성을 원천 차단

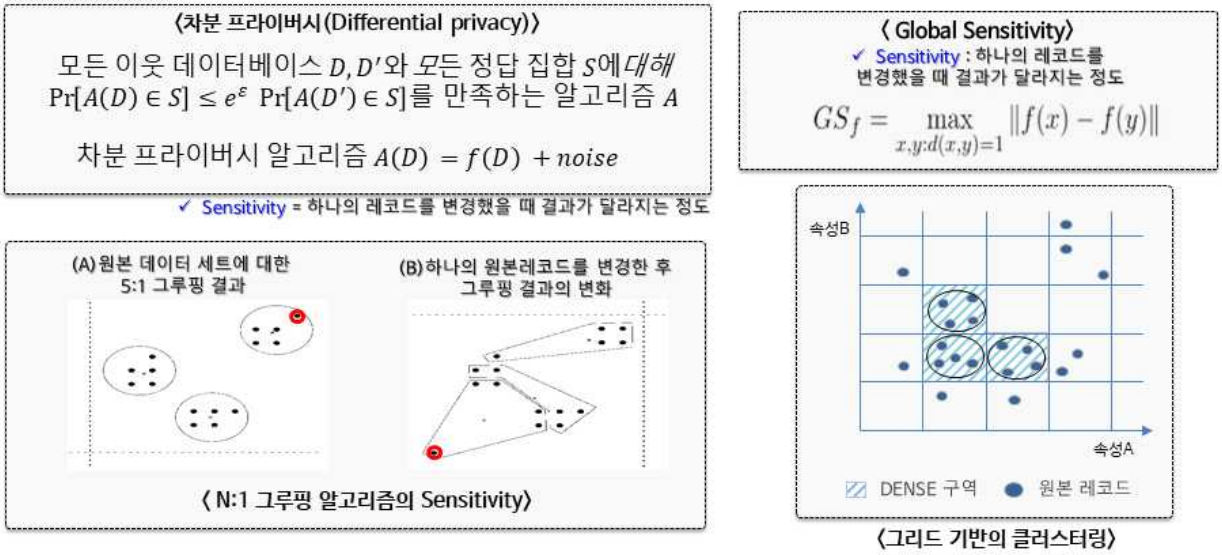
· 유일성: 원본 레코드 내에서 유일한 값(혹은 유일한 조합)이 비식별화 과정에서 모두 제거되거나 변환되지 않아 재식별가능성이 존재
=> 유일성 제거 : 원본 레코드 내에 유일성 보유한 속성값 혹은 속성 값 조합들의 케이스는 비식별레코드 세트에서 모두 제거 혹은 변환-추상화 과정에서는 N:1 레코드 매핑 시 유일성 보유속성조합을 매핑에서 제외

· 유사성 : 최소유사도 만족 검증을 통해 유통용 데이터 최소 식별 가능성을 제거하고,최대유사도 만족 검증을 통해 유통용 데이터의 통계적 유사성을 보장하는 성질
=> 유사성 제거 : 원본 - 추상 레코드간 유사도의 [최대 ~ 최소] 범위 만족 검증-추상화 과정에서는 총계처리 속성 값 생성시 최대/최소 범위 만족을 검증

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 비식별 데이터의 분석 품질 향상을 위한 비식별화 데이터 품질 고도화 기술 개발

- 대표레코드 생성 시 유사도 기반 그루핑 기술 연구

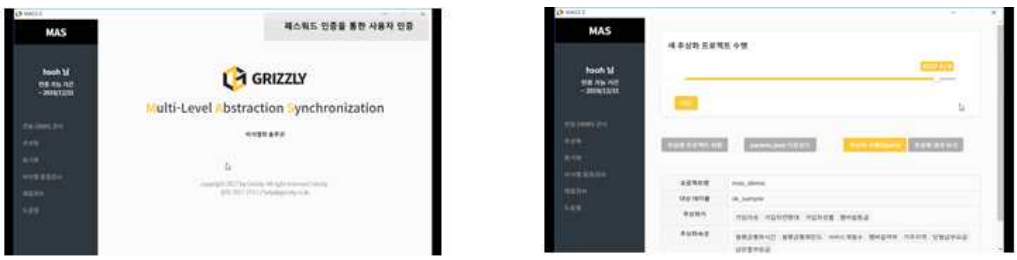


[그림 62] 데표레코드 생성 시 유사도 기반 그루핑 기술 연구

· 추상화 그루핑 시 일부 최적화 대상 속성을 기준으로 그루핑하여 추상 레코드 생성하도록 로직을 변경하였고 차분 프라이버시 (Differential privacy) 모델 적용을 시도함. 그리드 기반 클러스터링 기법을 활용하여 Sensitivity를 최소화하여 Differential privacy 적용 시 Noise를 최소화

- MAS 솔루션 개발 및 성능 평가 수행

· 모든 매핑 원본 레코드의 유사도가 최대~최소 유사도 범주 안에 들어오도록 추상 레코드를 재조정하는 단계를 추가개발하 였고 비식별화를 마친 후 결과 데이터를 검토하는 과정에서 선택적 최적화를 통해 일부 레코드들에 대해서만 레코드 수정이 가해 활용이 가능하게 함. 결과적으로 레코드 손실율을 낮추고, 추상 레코드 세트의 전체적인 유사도를 향상



[그림 63] MAS solution 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 64] 추상화 기술 고도화 및 재식별 불가성 검증

■ 기술적 성과

○ 지식재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일	출원번호	NTIS 등록번호	기여율
1	㈜보아라 ((구)그리즐리)	무정형 빅데이터의 개인정보 비식별화 처리 방법	대한민국	2018-03-30	10-2018-0037705	-	100%
2	㈜보아라 ((구)그리즐리)	빅데이터 개인정보 익명화 및 익명 데이터 결합 방법	PCT	2018-03-30	PCT/KR2018/003795	-	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜보아라 ((구)그리즐리)	유사성 제거 검증 기술 개발 및 성능평가 보고서
2		동일성, 유일성 제거 검증 기술 개발 및 성능평가 보고서
3		유사도 최적화 추상화 기술 개발 및 성능평가 보고서

③ 아이알링크(주)

■ 연구수행내용

○ 고객 상담 서비스를 모델로 한 화자그룹분류/판별 시스템 개발

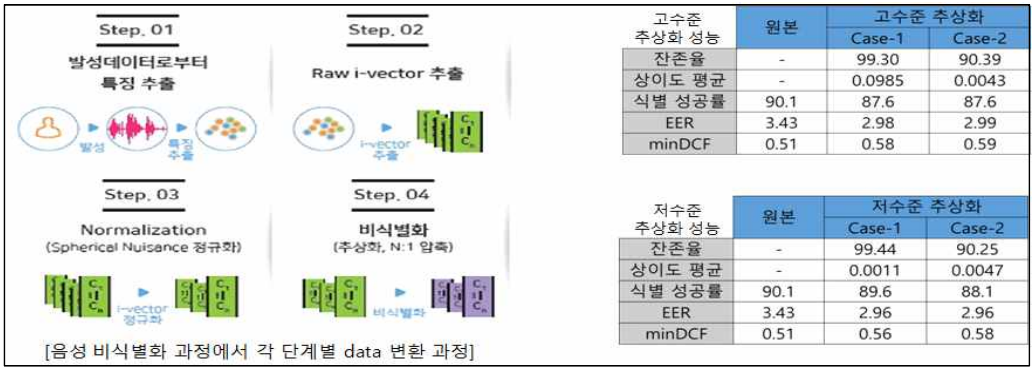
- 음성 모델의 추상화를 활용한 화자그룹 분류/판별 기술 개발

· 개인음성생체정보 모델의 비식별화 진행

· 음성정보의 저수준 및 고수준 추상화를 통한 잔존율 및 상이도 평가

· 문장 독립형 화자그룹 판별 기술과 연계

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



고수준 추상화 성능	원본	고수준 추상화	
		Case-1	Case-2
잔존율	-	99.30	90.39
상이도 평균	-	0.0985	0.0043
식별 성공률	90.1	87.6	87.6
EER	3.43	2.98	2.99
minDCF	0.51	0.58	0.59

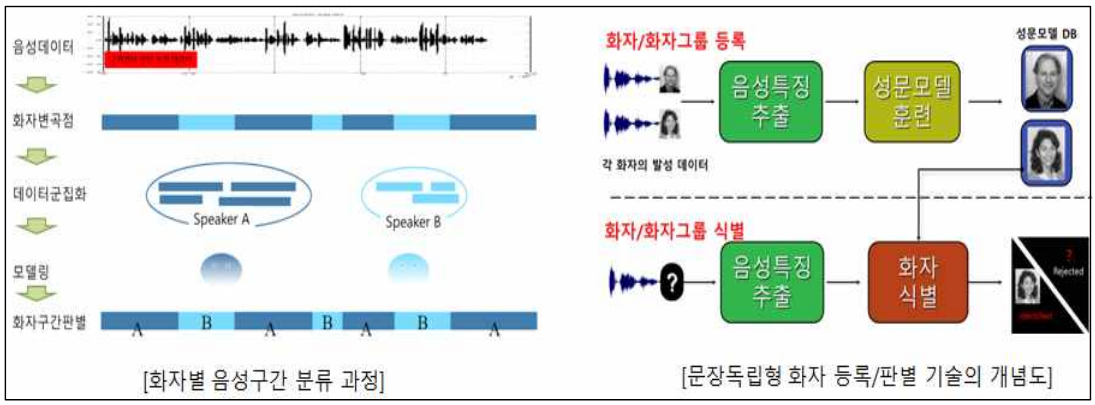
저수준 추상화 성능	원본	저수준 추상화	
		Case-1	Case-2
잔존율	-	99.44	90.25
상이도 평균	-	0.0011	0.0047
식별 성공률	90.1	89.6	88.1
EER	3.43	2.96	2.96
minDCF	0.51	0.56	0.58

[그림 65] 음성 비식별화 과정에서 각 단계별 data 변환 과정

- 화자변곡점 검출 및 문장 독립형 화자그룹 분류/판별 기술 개발

· 상담 녹취파일에서 상대방의 음성 구간만을 자동으로 추출하기 위한 기술 개발

· 임의 텍스트를 발화한 음성으로 화자그룹을 판별할 수 있는 기술 개발



[그림 66] 화자별 음성구간 분류 과정 및 개념도

- 실시간 상담 데이터에 대한 화자그룹 분류/판별 기술 및 서버형 다채널 SW 개발

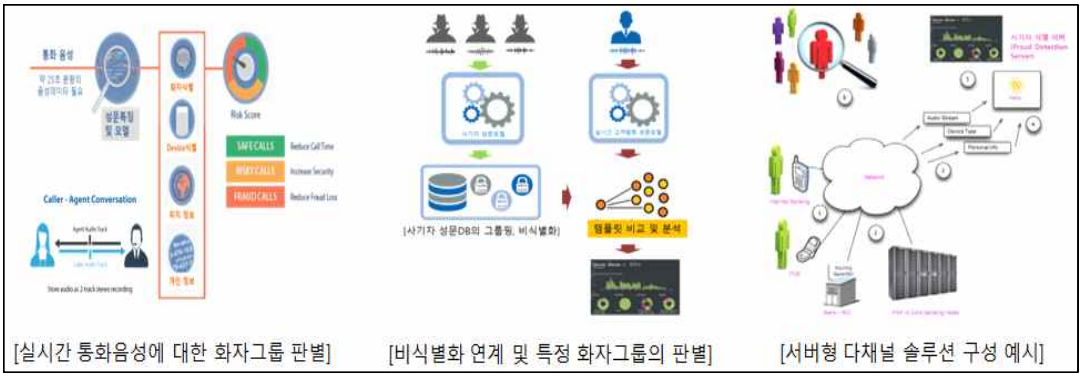
· 실시간 i-vector 추출 및 사기자/유의자 모델과의 비교 기술 구현 진행

· 추출 데이터의 비식별화 연계 및 특정 화자그룹의 판별

· 녹취 전화기 기반 화자분리(Rx,Tx) 녹음의 실시간 전송 기술 개발

· 서버형 다채널 실시간 화자/화자그룹 판별을 위한 요구사항 분석 및 SW 구조 설계

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 67] 실시간 통화음성에 대한 화자그룹 판별 외

○ 비식별화 스트림 데이터 실시간 빈발패턴, 연관규칙 탐사 기법 연구

- 개인 시그네쳐 그룹 기반 실시간 빈발패턴, 연관규칙 탐사 기법 연구

- 실시간 빈발패턴/연관규칙의 개인 시그네쳐 그룹 기반 지지도/신뢰도 보정 기법 연구

■ 기술적 성과

○ 지식재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일	출원번호	NTIS 등록번호	기여율
1	아이알링크(주)	개인 생체 정보의 비식별화 시스템 및 방법	PCT	2017.07.17	PCT/KR2017/007627	-	100%

○ 저작권(소프트웨어)

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	아이알링크(주)	텍스트 독립형 화자그룹식별 프로그램	2017/06~2018/03	김대수 외	2018.02 (예정)	C-2018-006079	아이알링크(주)	-	100%

○ 기술문서

번호	기관명	상세 구분
1	아이알링크(주)	텍스트 독립형 화자그룹식별 기술개발 및 성능평가 보고서
2		화자변곡점 검출 및 화자분류 기술개발 및 성능평가 보고서
3		텍스트 독립형 화자그룹식별 프로그램 요구사항정의서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 경제적 성과

○ 대외적 성과

- 솔루션 전시 및 시연회

번호	구분	참가기관	주최기관	행사명	일시	장소
1	전시회	아이알링크(주)	UBM Japan	CallCenter/CRM Demo & Conference 2018 in Tokyo	2018-11-15 ~ 2018-11-16	Tokyo, Japan

· 일본에서 매년 개최하는 콜센터 전문 전시회로 음성인식과 화자인식 기술을 이용한 발성형 개인식별을 통한 음성인식율 높이는 전처리 제품을 개발 전시하고 전시회를 통해 빅데이터 비식별화 연구과제의 성과 홍보 및 빅데이터 내 음성인식과 화자인식 관련 제품과 그 필요성에 대한 시장성과 상품화 아이디어를 바이어 상담을 통해 얻고자 하였으며, 대외적인 홍보, 국내의 빅데이터 관련 제품 동향, 연구 성과를 통한 사업화를 위해 전시회 참가



[그림 68] 전시회 참가

④ ㈜코리아크레딧뷰로

■ 연구수행내용

○ 비식별화 기법, 통계적 유의성 검증 및 미비점 보완

- 빅데이터 비식별 데이터 검토 사항

  · 데이터 비식별 목적

  · 항목 속성 구분, k-익명성, l-다양성 기준 적용 내용

  · 보안관련 사항

- 비식별 데이터 검증 사례

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

· 항목 속성

구분	속성	위험	비식별조치 예시
고객번호	식별자	식별자로 개인을 특정할 수 있음	삭제
성별	준식별자(k-익명성 적용)	기타정보와 조합하여 개인이 식별될 수 잇음	남/여로 범주화
직업군			내부 분류 기준별 직업구분 범주화
대출약정금액	민감정보(l-다양성 확인)	개인의 신용에 관한 민감한 정보	전체 20개 그룹 분할, 1만원 단위 라운딩
신용여부			미조치(Y/N값)

· k-익명성, l-다양성 기준

분석기법	적용대상(속성자)	평가기준값
k-익명성	성별, 직업구분코드 2개 항목	k≥5
l-다양성 기준	대출약정금액, 카드이용금액 등의 민감정보 항목	l≥2

○ 비식별화 수준 및 한계 등을 확인하기 위한 검증 가능한 신용정보 데이터 확보

- 제공정보의 종류 : 개인정보, 대출개설정보, 카드개설정보, 연체정보 등
- 개인정보(500만건), 대출개설정보(200만건), 카드개설정보(500만건), 연체정보(10만건), 개인신용정보 조회사이트 LOG정보(100만건), 비정형 SAM FILE 카드실적정보(500만건)

○ 물리적/시스템적 검증을 위한 환경 구축 및 유지

- 엔진 설치 등을 위한 하드웨어/장비 설치 및 물리적 검증 환경 구성 완료



[그림 69] 실제 금융회사 환경과 동일한, 테스트 환경 구성

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	서버명	CPU	MEMORY	DISK	OS	DB
비식별화DB	tcboto1x	4 CORE	4 GB	188 GB	RHEL 5.10	Oracle 11.2.0.1
비식별화AP#1	tcboto2x	4 CORE	4 GB	188 GB	RHEL 5.10	-
비식별화AP#2	tcboto3x	4 CORE	4 GB	188 GB	RHEL 5.10	-
KCB 데이터 DB	tcbdbs1a	4 CORE	40 GB	3000 GB	AIX 6.1	Oracle 11.2.0.2

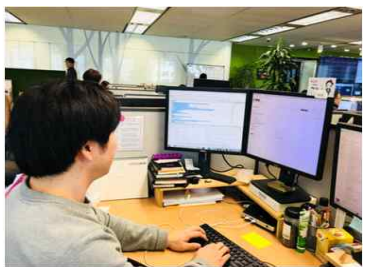
[그림 70] 비식별화 테스트 및 검증 시연을 위해 사용자 단말, 어플리케이션 서버 및 데이터 베이스 서버 환경 구성

○ 빅데이터 준비 및 검증/시연 지원

- 검증용 데이터 추출 및 File/Table 생성 및 (기술개발 테스트 요청시) 결과 검증 및 유의성 평가(검증데이터 준비 및 비식별 검증절차서 마련)

- 출입통제 시설 및 별도로 제공된 테스트 및 시연 장소 제공

- KCB 내부 서버, 테스트 시연을 위한 서버 로그인 및 조회

[그림 71] 검증용 서버 준비 및 로그인

○ KCB 내부 비식별화 적정성 평가 매뉴얼 마련

■ 기술적 성과

○ 기술문서

번호	기관명	상세 구분
1	㈜코리아크레딧뷰로	㈜보아라((구)그리즐리) 테스트결과서

- 수집전문인 K-Format을 통해 금융회사로부터 제공되는 신상정보, 대출개설정보, 카드개설정보, 연체정보 등 정형 데이터를 본 프로젝트 검증용으로 준비

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	검증데이터
1년차	신상정보(100), 대출개설정보(50), 카드개설정보(100), 연체정보(1)
2년차	신상정보(300), 대출개설정보(100), 카드개설정보(300), 연체정보(5), 개인신용정보 조회사이트 LOG 정보(50)
3년차	신상정보(500), 대출개설정보(200), 카드개설정보(500), 연체정보(10), 개인신용정보 조회사이트 LOG 정보(100), sam file 카드실적정보(500)

※ 고유식별정보는 검증용 데이터로 준비하는 데에 제약 있으므로, 대체 key 로 준비

- ㈜보아라((구)그리즐리) MARS방법론 검증요청 및 검증 수행(2018년 2월)

· 보아라((구)그리즐리) MARS(OPT-ON 방법론) 검증결과 요약

구분	내용
데이터	카드, 대출 연체정보 보유자 임의 추출 100,000명
항목	• 공통 식별정보 : ID(연번), 기준연월일, 생년월일 6자리, 성별, 주소, 주소좌표, 핸드폰 번호 • 대출 : 대출금액, 비율, 건수, 기관수 등 36개 항목 • 카드 : 카드 이용금액, 비율, 건수, 기관수 등 26개 항목 • 연체 : 연체여부 항목 4개를 포함한 연체일수, 연체금액 등 총 20개 항목
결과비교	• 잔존율 =비식별화 작업 결과 건수/ 원본 대상건수 : 비식별화 매칭 결과물로 산출된 대상 건수 • 카드정보 87.0%, 대출정보 89.4%, 연체정보 90.6%

(4) 4차 년도 수행 내용(연구기간: 2018.04 ~ 2019.01)

구분	기관명	연구수행내용
주관기관	㈜이지서티	▪ 반정형/비정형 데이터에 대한 개인정보 탐지 기술의 성능 검증 ▪ 개인정보 탐지기능과 비식별화 기능 융합을 통한 통합 개인정보보호 솔루션 구축 및 상용화 준비 ▪ 데이터 보안 솔루션과 CKAN 플랫폼의 연계 수행 ▪ 스키마 스캔 및 메타정보 시각화를 통한 빅데이터 플랫폼(Super Hadoop)과 비식별화 S/W 연계 기술(H전력공사 빅데이터 플랫폼인 Hadoop에서 연계기술 적용 및 실증) ※ Super Hadoop: (총괄)빅데이터 처리 고도화 핵심 기술 활용 ▪ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 (고려대) ▪ 실시간 프라이버시 보존형 트랜잭션 항목 일반화 기법 연구 (연세대) ▪ 비식별 데이터의 통계적 유용성 검증 조사 연구 (동덕여대)
참여기관	㈜보아라 ((구)그리즐리)	▪ 빅데이터 처리 엔진 기반의 병렬 익명화 처리 모듈 구현 ▪ 빅데이터 처리 엔진 기반의 병렬 익명화 레코드 연계 모듈 구현

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(가) 기관별 연구수행결과 및 성과

① ㈜이지서티

■ 연구수행내용

○ 반정형/비정형 개인정보 탐지 기술의 성능 검증

- 인-메모리, 병렬화를 통한 개인정보 탐지 기술에 대해 빅 데이터를 대상으로 하여 기술 성능 검증 수행

○ 개인정보 탐지기능과 비식별화 기능 융합을 통한 통합 개인정보보호 솔루션 구축 및 상용화 준비

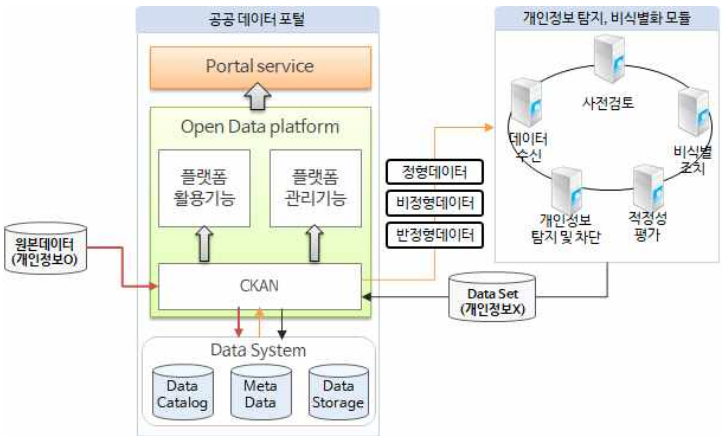
- 통합 개인정보보호 솔루션 구축 관점에서 비식별화 S/W 내 고객 Legacy System 게시판 및 e-mail 본문과 첨부파일에 대한 개인정보 탐지 및 차단, 모니터링 기능 융합 수행

- 비정상 행위 및 부적절 이용 탐지이력 분석 및 모니터링 기능 고도화를 통한 통합 데이터베이스 접근제어 기능 모듈화 및 상용화 준비

○ 데이터 보안 솔루션과 CKAN 플랫폼과의 연계 수행

- 데이터 연계 플랫폼인 CKAN을 통해 제공될 비정형/반정형/정형 데이터에 대한 개인정보 탐지 및 비식별 처리를 위한 기능 개발

- 개인정보 탐지 및 비식별 처리 데이터의 이력관리 및 검증 수행 기능 개발



[그림 72] CKAN 플랫폼과 연계

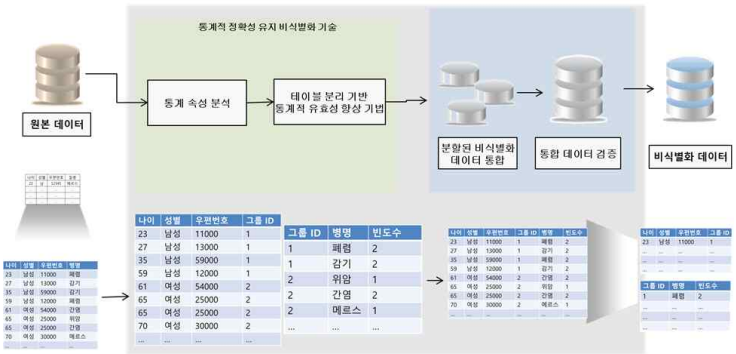
○ 스키마 스캔 및 메타정보 시각화를 통한 빅데이터 플랫폼(Super Hadoop)과 비식별화 S/W 연계 기술

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 스키마 스캔을 통한 빅데이터 플랫폼(Super Hadoop) 내 메타정보 시각화 기술 개발
- 선택된 정보요소에 대한 결합 및 추출, 분할, 그룹화, Pivoting 등 다양한 전처리 Interface 기술 개발
- 총괄 산출물인 Hadoop System 상에서 Working하는 고속 SQL 처리코드를 활용하여 전처리 기능 별 SQL 처리코드 생성 알고리즘 개발 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 개발**(H전력공사 빅데이터 플랫폼인 Hadoop에서 연계기술 적용 및 실증)**

○ 비식별 데이터의 정보 손실을 줄이기 위한 통계적 정확성 유지 비식별화 기술 개발(고려대)

- 통계적 유효성을 고려한 프라이버시 모델을 만족시키는 일반화 기반 비식별화 기법 개발
- 통계적 유효성을 고려한 테이블 분리 기반의 비식별화 기법 개발



[그림 73] 테이블 분리 기반 비식별화

○ 실시간 프라이버시 보존형 트랜잭션 항목 일반화 기법 연구(연세대)

- 비식별 트랜잭션의 항목 일반화 계층 구조 매핑 기술 및 실시간 Roll-up 일반화 트랜잭션 생성 기술
- 실시간 비식별 데이터 스트림의 사생활 보존 일반화 빈발패턴 탐사 연구

○ 비식별 데이터의 통계적 유용성 검증 조사 연구 (동덕여대)

- 원본 데이터 기반의 통계적 분류 모형과 비식별 처리된 데이터의 통계적 분류모형의 비교
- 유용성 검증을 위해 정확도, 민감도, 특이도, 정밀도 측정

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 지식재산권(특허, 상표, 실용신안 등)

- 특허 출원

번호	출원인	명칭	국명	출원일	출원번호	NTIS 등록번호	기여율
1	㈜이지서티	빅 데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT	2018-02-02	18833376.9	-	100%
2	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	PCT	2018-02-12	18833377.7	-	100%
3	㈜이지서티	빅데이터의 전처리 방법 및 장치	대한민국	2018-06-27	10-2018-0074133	-	100%
4	㈜이지서티	빅데이터 환경에서 데이터 수집을 위한 패킷 해석 방법 및 시스템	대한민국	2019-01-09	10-2019-0002786	-	100%
5	㈜이지서티	빅데이터 플랫폼 기반 개인정보 탐지 및 유노출 방지 시스템	대한민국	2019-01-09	10-2019-0002787	-	100%
6	연세대학교 산학협력단	비정형 트랜잭션 비식별 데이터의 품질 측정 기법	대한민국	2019-04-17	10-2019-0045149	-	100%

- 특허 등록

번호	출원인	명칭	국명	등록일	등록번호	NTIS 등록번호	기여율
1	㈜이지서티	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	대한민국	2018-02-26	10-1834503-0000	-	100%
2	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	대한민국	2018-02-26	10-1834505-0000	-	100%
3	㈜이지서티	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	대한민국	2018-09-28	10-1904901-0000	-	100%

○ 표준화

번호	기관명	수행 기관명	표준화 주제	표준화 기구	표준화 단계	관련 번호	제출(채택) 일	국가
1	㈜이지서티	금융보안원	비식별처리 소프트웨어 기능	금융보안 표준화협의회	제정	-	2018.12.	국내

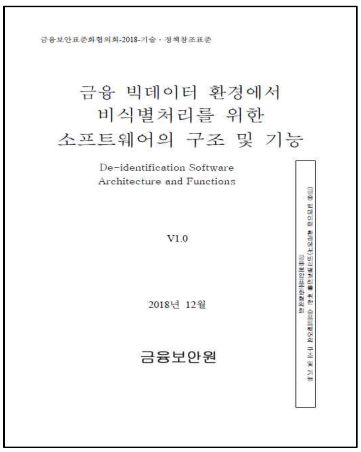
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 금융 빅데이터 환경에서 비식별처리를 위한 소프트웨어의 구조 및 기능

- 2018년 7월 ㈜이지서티 표준화 참여
- 2018년 12월 표준 제정
- 주요 내용
  - 비식별처리 소프트웨어 구조
  - 비식별처리 소프트에어 계층별 요구사항
  - 비식별처리 소프트에어 기능



[그림 74] 제출문



[그림 75]정책 표준

○ 저작권(소프트웨어, 서적 등)

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	㈜이지서티	IDENTITY SHIELD V3.0(개인정보 비식별조치 솔루션 V3.0)	2015-12-01	㈜이지서티	2018-09-20	C-2018-025198	㈜이지서티	-	100%
2	㈜이지서티	U-PRIVACY SAFER API V3.0 (개인정보 필터링 API V3.0)	2018-04-30	㈜이지서티	2019-05-15	C-2018-034900-2	㈜이지서티	-	100%
3	㈜이지서티	테이블 분리 기반 데이터 비식별 시스템	2018-12-07	㈜이지서티	2018-12-24	C-2018-039526	㈜이지서티	-	100%
4	㈜이지서티	실시간 비식별화 빈발패턴 마이닝 엔진	2018-12-05	㈜이지서티	2019-01-24	C-2019-002467	㈜이지서티	-	100%
5	㈜이지서티	비식별화 데이터 유효성 검증을 위한 R 통계 프로그램	2018-12-15	㈜이지서티	2019-01-02	C-2019-000087	㈜이지서티	-	100%

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 기술문서

번호	기관명	상세 구분
1	㈜이지서티	K.L.T Privacy Model 비식별화 기법 기반 비식별 처리 방법론
2		데이터 수집을 위한 패킷 해석 방법 및 시스템
3		개인정보 탐지 및 마스킹 기능을 융합한 빅데이터 플랫폼 기반 비식별 시스템
4	고려대학교	테이블 분리 기반 데이터 비식별 시스템
5	연세대학교	실시간 트랜잭션 일반화/비식별화 및 빈발패턴 마이닝 모듈 상세 설계 명세서
6	동덕여자대학교	비식별데이터의 통계적 유효성 검증

■ 경제적 성과

○ 사업화 현황

번호	기관명	지역	사업화명	내용	수요기관	매출액(원)	매출 발생 연도	기술 수명
						국내		
1	㈜이지서티	국내	부패방지종합정보시스템구축(1단계) 분리발주(개인정보 비식별화)	개인정보 탐지 및 비식별화	국민권익위원회	67,000,000	2018	-
2	㈜이지서티	국내	개인정보 오남용모니터링 시스템 구매	개인정보 탐지 및 오남용모니터링시스템	광주광역시	220,945,455	2018	-
3	㈜이지서티	국내	개인정보보호 및 정보보안 강화를 위한 솔루션 구매	개인정보 탐지 및 비식별화	한국고용정보원	96,181,818	2018	-
4	㈜이지서티	국내	IT센터 전산인프라 구축 및 이전사업	개인정보 탐지 및 비식별화	KDB산업은행	160,000,000	2018	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 대외적 성과

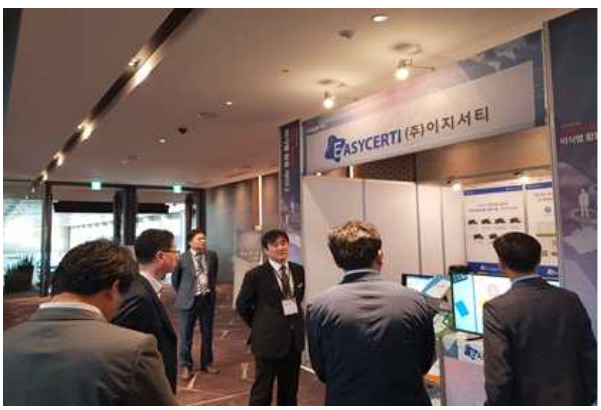
○ 솔루션 전시 및 시연회

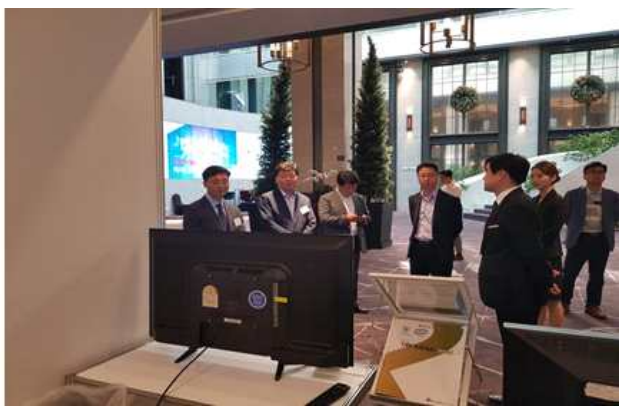
번호	주최기관	행사명	일시	장소
1	KISA	안전한 개인정보 비식별 활용 기술 세미나	2018-05-31 13:00~18:00	소노펠리체 컨벤션 사파이어홀

- 안전한 개인정보 비식별 활용 기술 세미나

  · ㈜이지서티 기술 세미나 부스 운영 및 시연회 진행







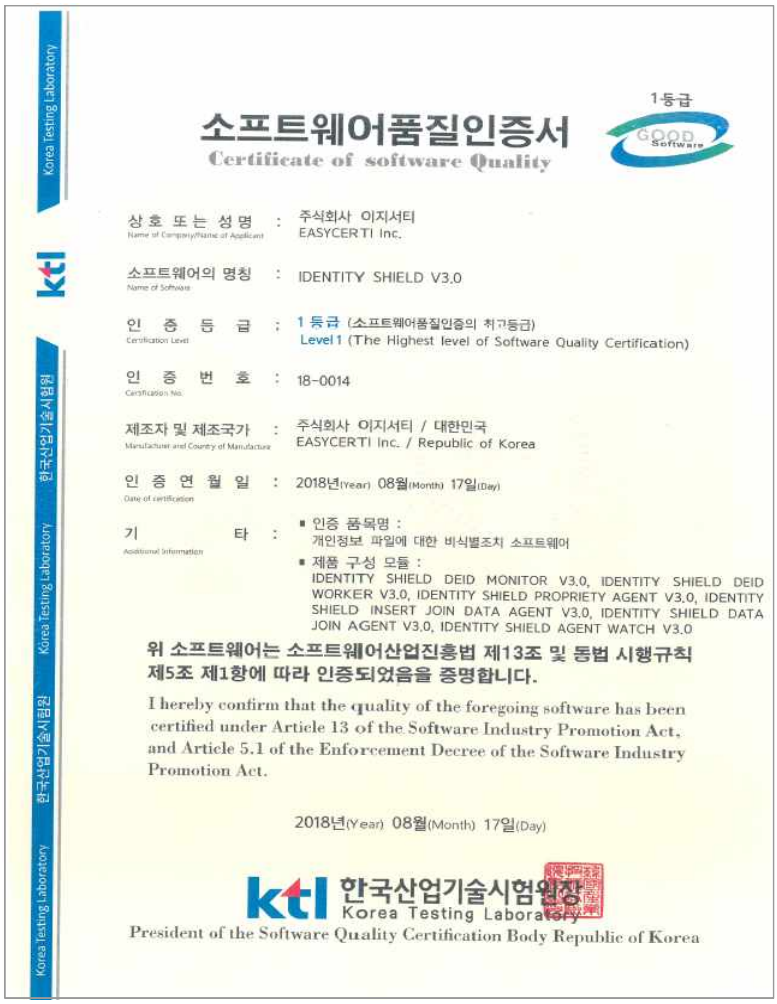
[그림 76] 안전한 개인정보 비식별 활용 기술 세미나

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 인증

번호	기관명	제품명	평가기관	인증명	등급	인증일
1	㈜이지서티	IDENTITY SHIELD V3.0	한국산업기술시험원	소프트웨어 품질인증(GS)	1등급	2018-08-17

- IDENTITY SHIELD V3.0(개인정보 비식별화 솔루션) GS인증 1등급 획득



소프트웨어품질인증서

Certificate of software Quality

1등급 GOOD Software

상호 또는 성명 (Name of Company/Name of Applicant) : 주식회사 이지서티 EASYCERTI Inc.

소프트웨어의 명칭 (Name of Software) : IDENTITY SHIELD V3.0

인 증 등 급 (Certification Level) : 1 등급 (소프트웨어품질인증의 최고등급) Level 1 (The Highest level of Software Quality Certification)

인 증 번 호 (Certification No.) : 18-0014

제조자 및 제조국가 (Manufacturer and Country of Manufacture) : 주식회사 이지서티 / 대한민국 EASYCERTI Inc. / Republic of Korea

인 증 연 월 일 (Date of certification) : 2018년(Year) 08월(Month) 17일(Day)

기 타 (Additional Information) :
- 인증 품목명 : 개인정보 파일에 대한 비식별조치 소프트웨어
- 제품 구성 모듈 : IDENTITY SHIELD DEID MONITOR V3.0, IDENTITY SHIELD DEID WORKER V3.0, IDENTITY SHIELD PROPRIETY AGENT V3.0, IDENTITY SHIELD INSERT JOIN DATA AGENT V3.0, IDENTITY SHIELD DATA JOIN AGENT V3.0, IDENTITY SHIELD AGENT WATCH V3.0

위 소프트웨어는 소프트웨어산업진흥법 제13조 및 동법 시행규칙 제5조 제1항에 따라 인증되었음을 증명합니다.

I hereby confirm that the quality of the foregoing software has been certified under Article 13 of the Software Industry Promotion Act, and Article 5.1 of the Enforcement Decree of the Software Industry Promotion Act.

2018년(Year) 08월(Month) 17일(Day)

ktl 한국산업기술시험원장 Korea Testing Laboratory

President of the Software Quality Certification Body Republic of Korea

Korea Testing Laboratory 한국산업기술시험원 Korea Testing Laboratory 한국산업기술시험원 Korea Testing Laboratory

[그림 77] IDENTITY SHIELD V3.0 소프트웨어 품질 인증서

- 소프트웨어 명칭: IDENTITY SHIELD V3.0
- 인증등급: 1등급
- 인증번호: 18-0014
- 제조자 및 제조국가: ㈜이지서티 / 대한민국
- 인증연월일: 2018년 8월 17일

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 언론 및 미디어

번호	기관명	언론사	기자	기사명	등록일시
1	㈜이지서티	디지털데일리	최민지	이지서티, 개인정보 비식별화 솔루션 GS인증 1등급 획득	2018-09-03 17:17:48

- 이지서티, 개인정보 비식별화 솔루션 GS인증 1등급 획득

이지서티, 개인정보 비식별화 솔루션 GS인증 1등급 획득

2018.09.03 17:17:48 / 최민지 cmj@ddaily.co.kr

EASYCERTI (주)이지서티

[디지털데일리 최민지기자] 이지서티(대표 심기창)는 개인정보 비식별화 솔루션 '아이덴티티 쉴드(IDENTITY SHIELD) V3.0'가 GS인증 1등급을 획득했다고 3일 밝혔다.

GS인증은 국산 소프트웨어(SW) 품질을 증명하는 국가 인증제도이며, 인증을 획득한 제품은 공공기관 사업 발주 때 우선 구매대상으로 지정된다.

아이덴티티 쉴드는 기업 내부 및 기업 간 빅데이터 활용·유통이 가능하도록 '개인정보 비식별 조치 가이드라인'에 따라 빅데이터 내 개인정보를 고전적 비식별 방법과 K.L.T 프라이버시 모델로 비식별화하는 솔루션이다.

또한 개인정보 필터링 원천기술을 활용한 정형·비정형 데이터의 개인정보 자동탐지 기능과 인메모리 및 고속 분산 비식별화 처리기술을 활용한 빅데이터 개인정보 고속 비식별화 기능을 제공한다. 최근 H공공기관에서는 기관이 보유한 2500억건의 실 데이터를 3시간만에 비식별 처리해 고속 분산 비식별화 처리 기술에 대한 성능을 입증한 바 있다.

특히, 아이덴티티 쉴드는 개인정보 비식별 조치 가이드라인의 단계별 비식별 절차에 최적화된 기능을 자동화해 지원한다.

예를 들면, 사전검토 단계에서 제공되는 데이터 분포도 시각화 기능을 통해 비식별 대상 데이터의 분포도를 시각화해 보여줌으로써 사용자가 불필요한 개인정보 및 중요 개인정보 데이터를 확인할 수 있어 데이터 전처리에 소요되는 시간을 줄일 수 있다.

또한 비식별 조치 적정성 평가를 위한 사전검토 자료 입력 및 관리기능 제공을 통해 비식별 조치 이후에 시행되는 적정성 평가 때 필요한 사전검토 자료를 체계적으로 준비할 수 있다. 개인정보 비식별화 솔루션은 무엇보다도 데이터에 대한 안전도가 중요하기 때문에 비식별 조치과정 뿐만 아니라 비식별 조치 이후 사후관리 또한 중요하다.

이에 이지서티는 개인정보 비식별 조치 시스템에 개인정보 탐지기능을 접목한 개인정보보호 통합관리 시스템을 구축해 개인정보 비식별 조치에 따른 안전성을 확보한다. 개인정보 제공 요청자에 대한 접근통제 뿐만 아니라 개인정보를 비식별 처리한 데이터 사용자의 비정상 행위 및 부적절한 이용을 탐지하여 개인정보 유·노출을 사전에 예방하는 것이다.

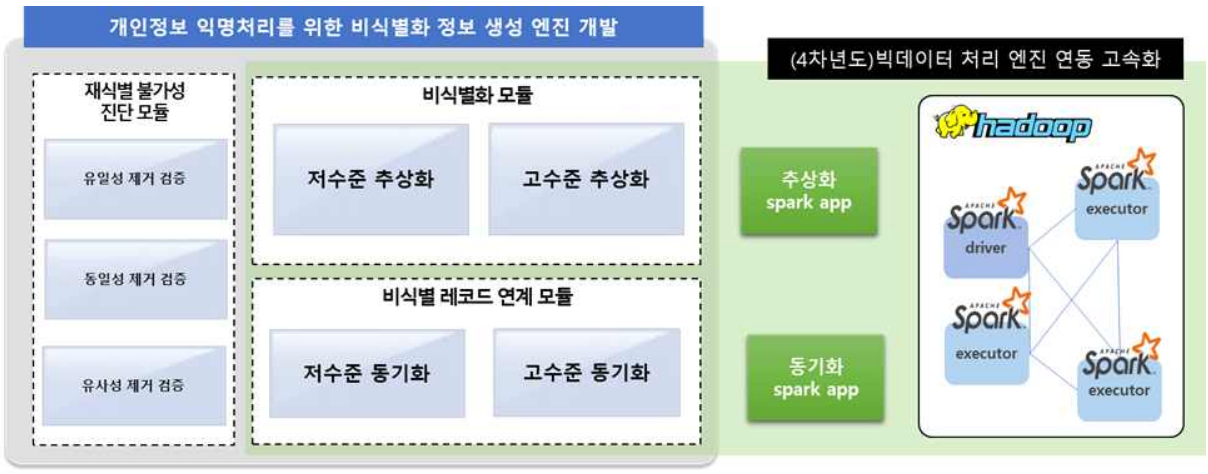
심기창 대표이사는 "아이덴티티 쉴드는 국민권익위원회 소프트웨어(SW) 분리발주 성능시험(BMT)에서 유일하게 비식별 기능에 대한 모든 항목에 적합판정을 받은 검증된 솔루션으로 제품출시이래 금융, 공공, 민간 등 다양한 분야에서 도입문의가 잇따르고 있다"며 "아이덴티티 쉴드는 비식별 솔루션으로서의 성능과 기능을 인정받았으며, 이번 GS인증을 통해 품질 신뢰도까지 확보하며 관련 시장을 더욱 적극적으로 공략할 계획"이라고 말했다.

<최민지 기자> cmj@ddaily.co.kr

[그림 78] 디지털데일리 기사

② ㈜보아라((구)그리즐리)

○ 빅데이터 처리 엔진 기반의 병렬 익명화 처리 모듈 구현

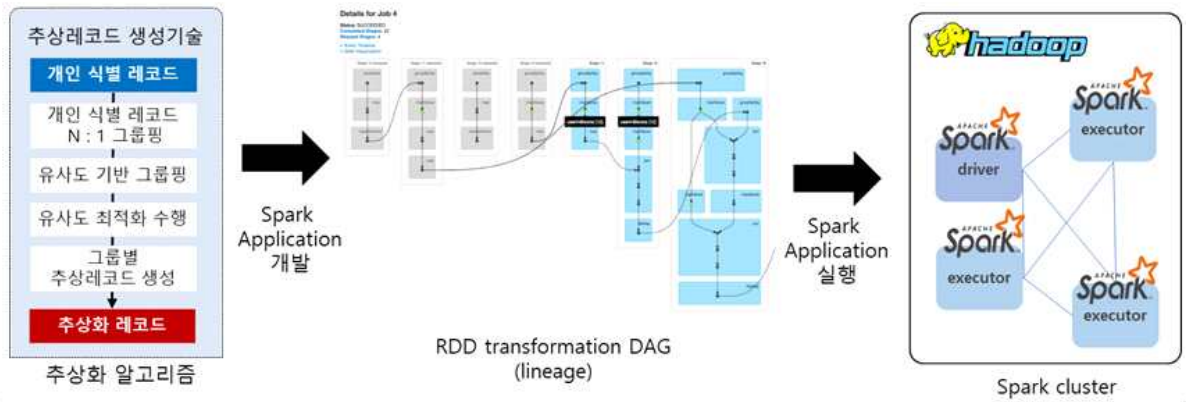


[그림 79] 추상화 기술 전체 기술도와 병렬 추상화 처리 모듈 개요

- 병렬화를 위한 원본레코드 파티셔닝 기법 연구

  · Apache Hadoop 기반의 Apache 스파크 클러스터 환경에서 구동되는 병렬처리 기반의 추상화 기술을 개발함. 이를 위해 원본 데이터를 해야하며 원본 데이터의 스키마 및 분포 고려한 파티셔닝기법에 대해 연구 개발 함 최종적으로 현재 가용한 executor의 memory size & 개수까지 고려하여 실제 구동

- 오픈 소스 빅데이터 처리 엔진 기반의 병렬 추상화 비식별화 변환 기술 개발

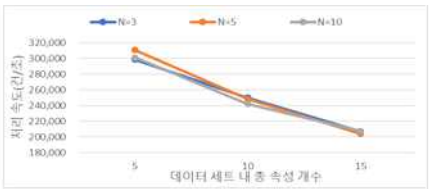


[그림 80] 오픈 소스 빅데이터 처리 엔진 기반의 병렬 추상화 비식별화 변환 단계

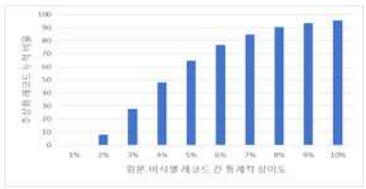
  · Spark API 및 내장 라이브러리를 활용하여 추상화 로직을 스파크 기반으로 포팅하고 로직 내 파티셔닝 최적화로 성능 최적화

- MAS solution 개선 및 성능 평가

Spark cluster 환경	
총 4대 (Master 1 / slave 3)	
CPU	Xeon E5-2680v3 (12core 2.50GHz)
RAM	64GB
SW	Spark 2.3 standalone



Spark 기반 추상화 기술 처리 속도 검증
(총 1,000만 건 사용, NHIS 공개데이터)



추상화 레코드의 통계적 유사도 검증

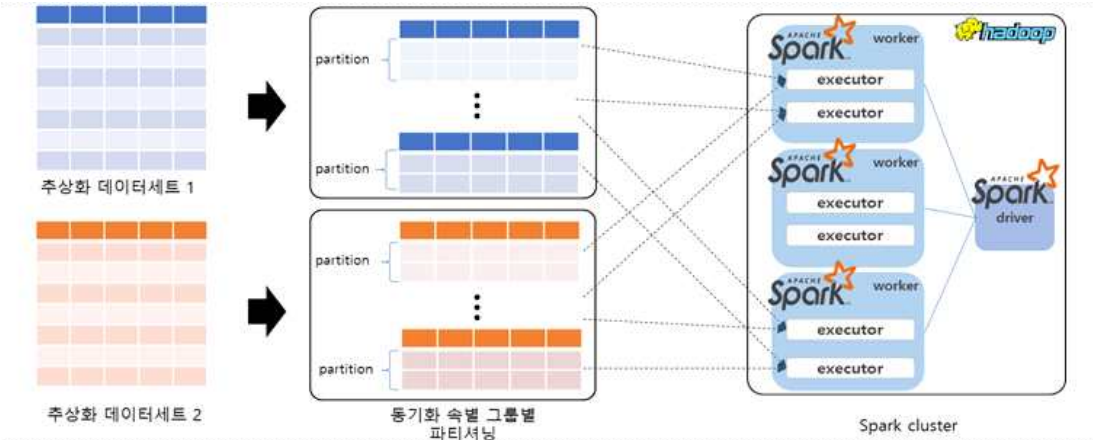


[그림 81] MAS solution UX 개선 : 반자동화, spark 연동UI 추가

○ 빅데이터 처리 엔진 기반의 병렬 익명화 레코드 연계 모듈 구현

- 병렬화 기반의 연계를 위한 추상화 레코드 파티셔닝 기법 연구

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 82] 병렬화 기반의 연계를 위한 추상화 레코드 파티셔닝 기법 과정

· Hadoop 기반 스파크 클러스터의 executor 수 및 memory size와 추상화 데이터 세트 내 선택된 동기화 속성의 분포를 고려한 최적 파티셔닝 기법 개발

- 오픈 소스 빅데이터 처리 엔진 기반의 병렬 동기화 기술 개발

· 실제 동기화 기술의 병목 지점은 join operation(range, exact, cross join, …)이며, Spark SQLlibrary의 DataSetoperation 및 SQL Hint 등 활용한 optimization 기술을 연구 함. 특히 저수준 동기화, 고수준 동기화 별로 활용 되는 join operation이 다르므로 각각의 최적화 로직을 구현

■ 기술적 성과

○ 지식재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일	출원번호	기여율	비고
1	㈜보아라((구)그리즐리)	빅데이터 개인정보의 익명화 및 익명화 데이터의 결합 방법	PCT	2018-12-30	PCT/KR2018/016945	100%	
2	㈜보아라((구)그리즐리)	빅데이터의 비식별화 처리 방법	일본	2018-12-07	2019-517743	100%	
3	㈜보아라((구)그리즐리)	MASQ	대한민국	2018-04-19	40-2018-0053306	100%	상표

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 저작권(소프트웨어)

번호	기관명	저작권명	창작일	저작자명	등록일	등록번호	저작권자명	NTIS 등록번호	기여율
1	㈜보아라((구)그리즐리)	MASQ(Multi-level Abstraction & Synchronization Quest, 다수준 추상화 & 동기화)	2018-12-01	㈜보아라((구)그리즐리)	2018-12-19	C-2018-038897	㈜보아라((구)그리즐리)	-	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜보아라((구)그리즐리)	MASQ 추상화 Spark application 설계서
2	㈜보아라((구)그리즐리)	MASQ 동기화 Spark application 설계서
3	㈜보아라((구)그리즐리)	MASQ 추상화 & 동기화 spark 모듈 평가서

■ 경제적 성과

○ 사업화 현황

번호	기관명	지역	사업화명	내용	수요기관	매출액(원)	매출발생연도	기술수명
						국내		
1	㈜보아라((구)그리즐리)	국내	“비식별화 및 비식별 레코드 연결 library” 판매(에스케이텔레콤㈜ 연구과제 수행용)	소프트웨어 library(MASQ library)	연세대학교 산학협력단	15,000,000	2019	-

○ 솔루션 전시 및 시연회

번호	주최기관	행사명	일시	장소
1	KISA	안전한 개인정보 비식별 활용 기술 세미나	2018-05-31 13:00~18:00	소노펠리체 컨벤션 사파이어홀

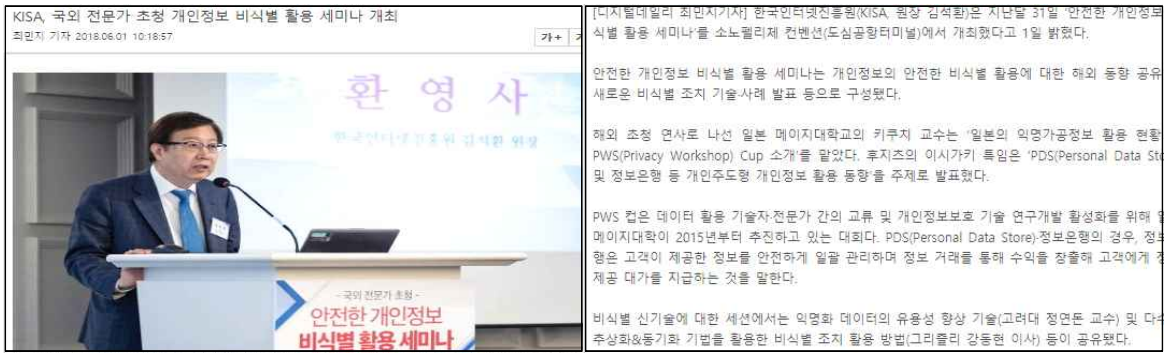
- 안전한 개인정보 비식별 활용 기술 세미나 발표

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

· ㈜보아라((구)그리즐리) “다수준 추상화&동기화 기법을 활용한 비식별 조치 활용 방법” 관련

번호	기관명	언론사	기자	기사명	등록일시
1	㈜보아라((구)그리즐리)	디지털데일리	최민지	KISA, 국외 전문가 초청 개인정보 비식별 활용 세미나 개최	2018-06-01 10:18:57

- KISA, 국외 전문가 초청 개인정보 비식별 활용 세미나 개최


KISA, 국외 전문가 초청 개인정보 비식별 활용 세미나 개최

최민지 기자 2018.06.01 10:18:57

환 영 사

- 국외 전문가 초청 -

안전한 개인정보 비식별 활용 세미나

[디지털데일리 최민지기자] 한국인터넷진흥원(KISA 원장 김석환)은 지난달 31일 '안전한 개인정보 식별 활용 세미나'를 소노펠리체 컨벤션(도심공항터미널)에서 개최했다고 1일 밝혔다.

안전한 개인정보 비식별 활용 세미나는 개인정보의 안전한 비식별 활용에 대한 해외 동향 공유 새로운 비식별 조치 기술·사례 발표 등으로 구성됐다.

해외 초청 연사로 나선 일본 메이지대학교의 키쿠치 교수는 '일본의 익명가공정보 활용 현황 PWS(Privacy Workshop) Cup 소개'를 맡았다. 후지츠의 이시가키 특임은 'PDS(Personal Data St 및 정보은행 등 개인주도형 개인정보 활용 동향'을 주제로 발표했다.

PWS 컵은 데이터 활용 기술자·전문가 간의 교류 및 개인정보보호 기술 연구개발 활성화를 위해 메이지대학이 2015년부터 추진하고 있는 대회다. PDS(Personal Data Store)-정보은행의 경우, 정보 행은 고객이 제공한 정보를 안전하게 일괄 관리하며 정보 거래를 통해 수익을 창출해 고객에게 제공 대가를 지급하는 것을 말한다.

비식별 신기술에 대한 세션에서는 익명화 데이터의 유용성 향상 기술(고려대 정연돈 교수) 및 다 추상화&동기화 기법을 활용한 비식별 조치 활용 방법(그리즐리 강동현 이사) 등이 공유됐다.

[그림 83] 디지털 데일리 기사

○ 인증

번호	제품명	평가기관	인증명	등급	인증일
1	MAS(다수준 추상화 & 동기화) 마법사 v1.0	한국정보통신기술협회	소프트웨어 품질인증(GS)	1등급	2016-11-28

- MAS(다수준 추상화 & 동기화) 마법사 v1.0 GS인증 1등급 획득/ v3.0 GS 1등급 획득


1등급

소프트웨어품질인증서

Certificate of Software Quality

Software

위 소프트웨어는 「소프트웨어산업 진흥법 시행규칙」 제5조제1항에 따라 인증되었음을 증명합니다.

I hereby confirm that the quality of the foregoing software has been certified under Article 5.1 of the Enforcement Decree of the Software Industry Promotion Act.

2016 년(Year) 11 월(Month) 28 일(Day)

TTA 한국정보통신기술협회장

CEO & President

Telecommunications Technology Association

[그림 84] MAS(다수준 추상화 & 동기화) 마법사 v1.0소프트웨어 품질인증서 Ⅱ

· 소프트웨어 명칭: MAS(다수준 추상화 & 동기화) 마법사 v1.0/ v3.0 GS 1등급 획득

· 인증등급: 1등급

· 인증번호: 16-0425

· 제조자 및 제조국가: ㈜보아라((구)그리즐리) / 대한민국

· 인증연월일: 2016년 11월 28일

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(5) 5차 년도 수행 내용(연구기간: 2019.02 ~ 2019.05)

구분	기관명	연구수행내용
주관기관	㈜이지서티	▪ 각 요소 기술 통합 및 기능 테스트 ▪ 빅데이터 개인정보보호 솔루션 사업화 수행
참여기관	㈜보아라((구)그리즐리)	▪ 추상화 비식별화 기법의 실시간 병렬 고속화 기술 개발 ▪ 실시간 비식별 데이터 스트림의 사생활 보존 일반화 연관 규칙 탐지기법 연구

(가) 기관별 연구수행결과 및 성과

① ㈜이지서티

■ 연구수행내용

○ 각 요소 기술 통합 및 기능 테스트

- 각 요소별 구현 기술 통합

- 각 요소별 기능 테스트

○ 빅데이터 개인정보보호 솔루션 사업화 수행

- 통합 개인정보 보호 솔루션

  · 데이터 보안 솔루션과 접속기록 솔루션 통합으로 상품성 높임

- 공공기관 공공데이타 개방 사업 및 영리기관의 빅데이타 유통 및 비식별화 사업, 클라우드 기반의 개인정보 비식별화 사업 참여

  · 마케팅 및 홍보를 위한 홍보물 제작 및 홍보 활동 계획 수립

  · 공공/민간 데이터 비식별화 사업에 제품으로 제안 참여

  · 기수행했던 사업의 성과를 적극 홍보

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 기술적 성과

○ 산업재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일	출원번호	기여율
1	㈜이지서티	빅 데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT	2019-04-25	2019-524048	100%
2	㈜이지서티	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	PCT	2019-04-25	2019-524059	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜이지서티	ISO 20889에 관한 비식별 조치 기술 동향 조사

■ 경제적 성과

○ 사업화 현황

번호	기관명	지역	사업화명	내용	수요기관	매출액(원)	매출 발생 연도	기술 수명
						국내		
1	㈜이지서티	국내	보건의료 빅데이터 HW 및 SW통합구매(인프라)	보건의료 정보 개인정보 탐지 및 비식별화	보건복지부	2,193,889,500	2019	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

■ 대외적 성과

○ 솔루션 전시 및 시연회

번호	주최기관	행사명	일자	장소
1	디지털데일리	클라우드 임팩트 2019	2019-02-21	쉐라톤 서울 디큐브시티 호텔 그랜드볼룸(6F)
2	SECON	2019 세계보안 엑스포 (SECON 2019)	2019-03-6 ~ 2019-03-8	킨텍스 제1전시장
3	행정안전부, 방송통신위원회, 개인정보보호 위원회	개인정보보호 페어 (PIS FAIR 2019)	2019-06-25 ~ 2019-06-26	코엑스 그랜드볼룸
4	㈜이지서티	㈜이지서티 Partner’s Day	2019-05-15	양재동 엘타워 스포타임

- 클라우드 임팩트 2019 컨퍼런스

  · 클라우드 환경에서의 개인정보보호를 위한 개인정보 비식별화 솔루션 부스 운영

  · 클라우드 환경에서의 개인정보보호를 위한 개인정보 비식별화 전략 발표



[그림 85] 클라우드 임팩트 2019 컨퍼런스

- 2019 세계보안 엑스포(SECON 2019)

  · 개인정보보호를 위한 개인정보보호 솔루션 부스 운영

  · 다시보는 개인정보접속기록관리의 중요성’ CPO workshop 발표

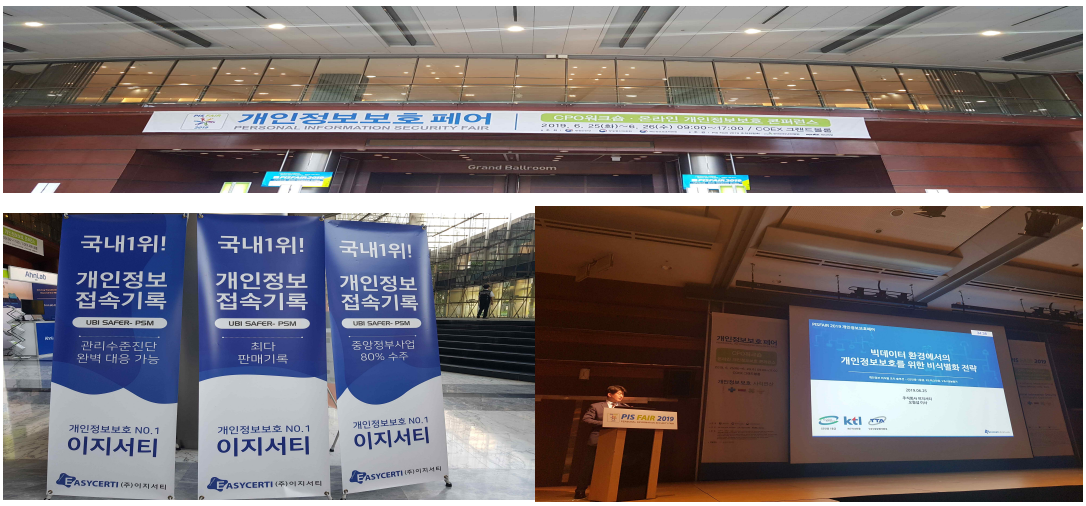


[그림 86] 2019 세계보안 엑스포 - SECON 2019

- 개인정보보호 페어(PIS FAIR 2019)

  · 개인정보보호를 위한 개인정보보호 솔루션 전시 및 시연

  · 빅데이터 환경에서의 개인정보보호를 위한 비식별화 전략 발표



[그림 87] PIS FAIR 2019

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 언론 및 미디어

번호	기관명	언론사	기사명	등록일자
1	㈜이지서티	디지털데일리	[2019 클라우드 임팩트] 공공부문 클라우드 활성화, 개인정보 비식별화 전략도 세워야	2019-02-22
2	㈜이지서티	전자신문	이지서티, '보건의료 빅데이터 플랫폼'에 개인정보 비식별 조치 솔루션 공급	2019-02-27
3	㈜이지서티	보안뉴스	이지서티, 빅데이터와 클라우드 시대의 개인정보보호를 말하다	2019-06-28
4	㈜이지서티	브릿지 경제	이지서티, '파트너스데이' 개최... 보안 협력 견고히 다진다.	2019-05-16

- (기사)공공부문 클라우드 활성화, 개인정보 비식별화 전략도 세워야



[2019 클라우드 임팩트] 공공부문 클라우드 활성화, 개인정보 비식별화 전략도 세워야

2019.02.22 14:20:12 / 홍하나 hhn0626@ddaily.co.kr

관련기사
- [2019 클라우드 임팩트] 디지털 트랜스포메이션을 위한 클라우드 전환 전략 5가지
- [2019 클라우드 임팩트] 클라우드 보안, "공유환경에서 전용환경으로 바꾸는 것"

[디지털데일리 홍하나기자] 올해 공공부문에서 클라우드가 활성화될 전망인 가운데, 개인정보보호 이슈도 함께 부상할 것으로 보인다. 이에 국내 보안기업 이지서티는 개인정보를 가명정보로 비식별화조치하는 과정에서 개인정보보호를 위한 전략을 소개했다.

21일 <디지털데일리> 주최로 웨스틴 서울 디큐브시티 호텔에서 열린 '클라우드 임팩트 2019' 컨퍼런스에서 이장교 이지서티 연구소장은 클라우드 도입과 함께 적절한 비식별화 전략을 취해야 한다고 강조했다.

이 소장은 "지난해 공공부문의 민간 클라우드가 허용됐다"며 "안보, 수사자료 민감정보, 개인정보 영향 평가 대상을 제외하고 대국민 서비스 및 비대국민 민간 클라우드가 허용되면서 앞으로 공공부문에서 클라우드가 활성화될 것"이라고 전망했다.

여기서 중요한 것은 개인정보보호다. 클라우드 컴퓨팅 발전 및 이용자 보호에 관한 법률에 따르면, 개인정보와 관련해서는 '개인정보보호법(개보법)', '정보통신망 이용촉진 및 정보보호등에 관한 법률' 등 관련 법률에서 정하는 바에 따라야 한다.

이 소장은 "법에 따라 개인정보보호 관리를 위해 기술적 조치를 취해야 한다"며 "규정되어 있는 범위에서 개인정보를 활용해야 한다"고 말했다.

최근 개정된 개보법에 따르면, 개인정보를 가명처리함으로써 원상태로 복원하기 위한 추가 정보의 사용, 결합 없이는 특정 개인을 알아볼 수 없는 정보를 가명정보로 일컫는다. 또 가명정보와 가명처리 개념을 도입하면서 개인정보처리자가 통계작성, 과학적연구, 공익적 기록 보존 등을 위해 정보 주체의 동의 없이 가명정보 처리를 할 수 있다. 게다가 특정 개인을 알아보기 위해 사용될 수 있는 정보를 제외하고, 이러한 정보를 제3자에게 제공할 수 있다.

이 소장은 "개인정보를 개인식별이 불가능한 정보로 익명처리 하는 과정을 '비식별화 조치'라고 한다"며 "이 과정을 거치면 가명정보가 되는 것"이라고 설명했다. 그러면서 "비식별화란 수집, 사용, 저장, 공유되는 모든 데이터로부터 개인을 식별하지 못하게 하는 방법으로, 데이터로부터 어떤 개인과도 연결시킬 수 없도록 만드는 것을 목표로 한다"고 말했다.

또 이 소장은 "업계에서 어느 수준까지 비식별조치를 해야 하는지에 대해 고민이 많은데 저희는 K, L, T 프라이버시 모델로 접근한다"고 밝혔다. K는 익명성을 뜻하며, 데이터에 대한 추적결을 방어하기 위해 제안된 프라이버시 보호 모델이다. L는 다양성으로 K의 익명성에 대한 공격을 방어하기 위한 모델, T는 접근성으로 L의 취약점을 보완하기 위한 모델이다.

이지서티는 이같은 상호 보완 작용을 하는 모델을 자사의 솔루션에 적용했다고 밝혔다. 이 소장은 "자사의 개인정보 비식별화 솔루션인 아이덴티티 쉴드'는 다양한 플랫폼에 적용 가능하다"며 "인메모리 기반 고속처리 기술을 기반으로 비식별가이드라인의 모든 항목을 충족하는 시스템"이라고 설명했다.

아이덴티티 쉴드는 비식별조치방법 선택, 비식별조치 진행현황 알림, 비식별조치 결과물에 대한 적정성 평가관리, 정보 집합물의 결합 프로세스 관리화면 등의 주요 기능을 제공한다.

이 소장은 "아이덴티티 쉴드는 비식별화 솔루션 도입 시 고려할 사항을 모두 만족한다"며 "개인정보 비식별 조치 관련해 기술 특허를 보유하고 있으며, 익명성 자동 비식별 기능 특허기술을 보유하고 적용했다"고 강조했다.

<홍하나 기자>hhn0626@ddaily.co.kr

[그림 88] 디지털 데일리 기사 Ⅱ

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- (기사) “이지서티, ‘보건의료 빅데이터 플랫폼’에 개인정보 비식별 조치 솔루션 공급”



이지서티, '보건의료 빅데이터 플랫폼'에 개인정보 비식별 조치 솔루션 공급

발행일 : 2019.02.27

제2회 인공지능 차세대 컨택센터 컨퍼런스 2019(3월 21일, 코엑스)

(주)이지서티

이지서티(대표 심기창)가 보건복지부 '보건의료 빅데이터 플랫폼 구축(인프라)사업'에 개인정보 비식별조치 솔루션 '아이덴티티 쉴드(IDENTITY SHIELD)'를 공급한다.

아이덴티티 쉴드는 개인정보 비식별조치 솔루션으로 GS인증 1등급을 획득했다. 개인정보 필터링 원천기술 활용한 정형·비정형 데이터 개인정보 자동탐지, 인메모리·고속 분산 비식별화 처리기술 활용 빅데이터 개인정보 고속 비식별화를 제공한다.

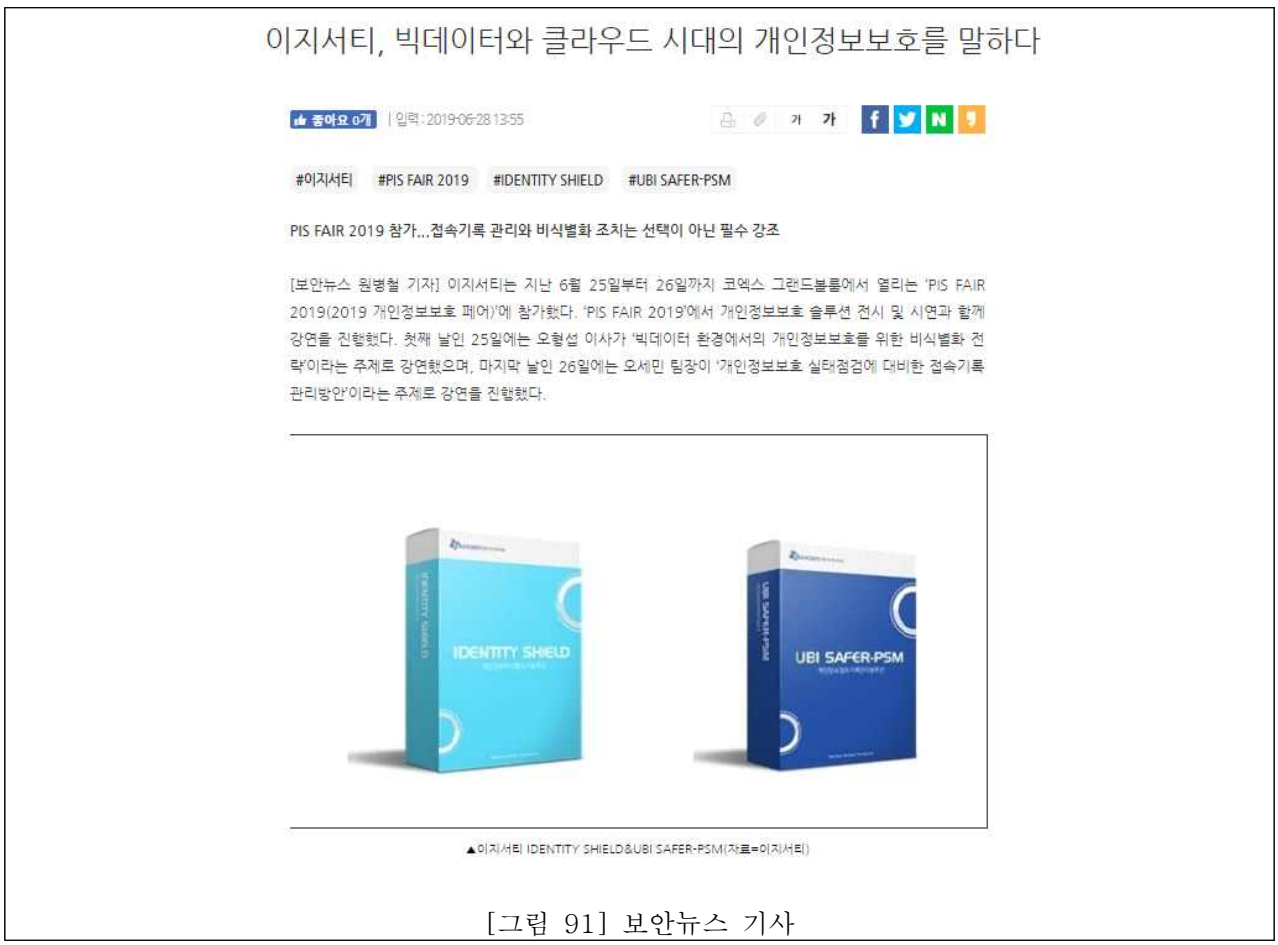
개인정보 비식별조치 가이드라인 비식별 조치 4단계 △사전검토 △비식별조치 △적정성평가 △사후관리를 준수하도록 구성했다. 총계처리, 데이터 삭제, 범주화 등 17가지 고전적 비식별 조치, 개인정보 추론 연결공격(Linked Attacked) 등도 방어 가능하다.

오형섭 이지서티 전략기획본부 이사는 "기업부설연구소 핵심 기술과 업계 내 경험에서 얻은 노하우를 기반으로 보건의료분야뿐 아니라 금융, 통신, 제조, 유통 분야 등에 최적 개인정보 비식별 솔루션을 공급할 계획"이라고 말했다.

정영일기자 jung01@etnews.com

[그림 89] 전자신문 기사

- (기사) “이지서티, 빅데이터와 클라우드 시대의 개인정보보호를 말하다”



이지서티, 빅데이터와 클라우드 시대의 개인정보보호를 말하다

좋아요 0개 | 입력 : 2019-06-28 13:55

#이지서티 #PIS FAIR 2019 #IDENTITY SHIELD #UBI SAFER-PSM

PIS FAIR 2019 참가...접속기록 관리와 비식별화 조치는 선택이 아닌 필수 강조

[보안뉴스 원병철 기자] 이지서티는 지난 6월 25일부터 26일까지 코엑스 그랜드볼룸에서 열리는 'PIS FAIR 2019(2019 개인정보보호 페어)'에 참가했다. 'PIS FAIR 2019'에서 개인정보보호 솔루션 전시 및 시연과 함께 강연을 진행했다. 첫째 날인 25일에는 오형섭 이사가 '빅데이터 환경에서의 개인정보보호를 위한 비식별화 전략'이라는 주제로 강연했으며, 마지막 날인 26일에는 오세민 팀장이 '개인정보보호 실태점검에 대비한 접속기록 관리방안'이라는 주제로 강연을 진행했다.

▲이지서티 IDENTITY SHIELD&UBI SAFER-PSM(자료=이지서티)

[그림 91] 보안뉴스 기사

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- (기사) “2019 이지서티 솔루션 파트너 세미나”



이지서티, ‘파트너스데이’ 개최 … 보안 협력 견고히 다진다

입력 2019-05-16 17:15 수정 2019-05-16 17:15

기사 퍼가기 NEWS Link | Facebook | Tweet | Google + | BAND Band | Print

사진=이지서티

▶ 비아X라 “50배” 효과, 여자 미쳐?

▶ 추적60분 “한국로또망했다” 무더기당첨 속출!!

정보보안 전문기업 이지서티는 15일 양재 엘타워에서 ‘2019 파트너스데이’ 행사를 개최했다고 16일 밝혔다. 이날 행사는 창립 18주년을 맞은 이지서티의 지속 가능한 성장과 파트너와의 동반 성장 등을 도모하자는 취지에서 마련됐다.

인천이사 크리스찬 한솔포장이사

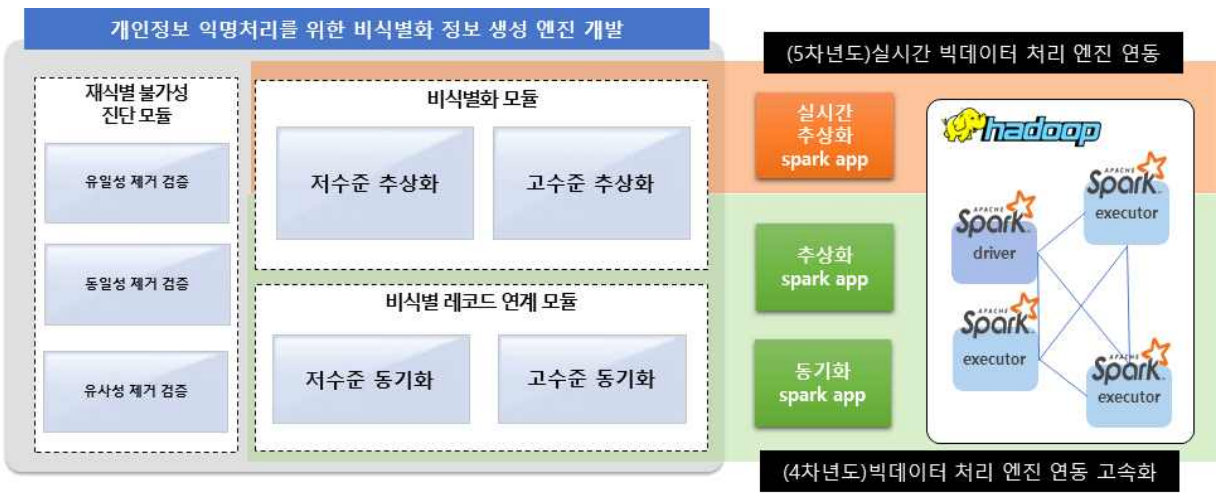
이지서티의 개인정보접속기록관리, 개인정보 필터링, 개인정보 비식별화 솔루션 등을 통한 정보

[그림 92] 브릿지 경제 기사

② ㈜보아라

■ 연구수행내용

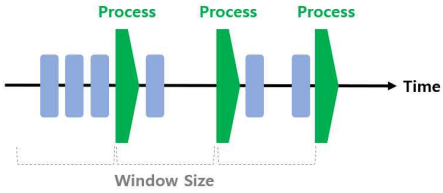
○ 추상화 비식별화 기법의 실시간 병렬 고속화 기술 개발



[그림 93] 추상화 비식별화 기법의 실시간 병렬 고속화 기술 개요

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

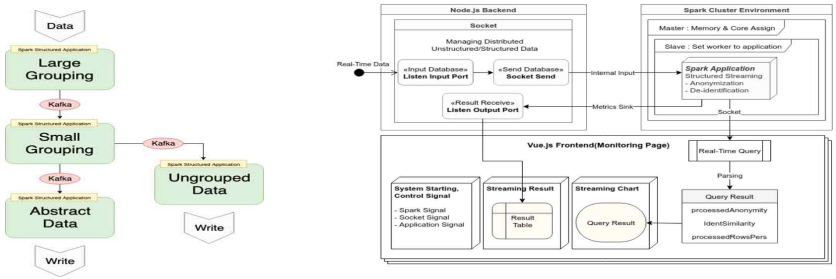
- 실시간 원본레코드 파티셔닝 최적화 기술 연구



[그림 94] 실시간 원본레코드
파티셔닝 최적화 기술 연구

· Timestamp와 spark의 watermark 개념을 도입한 window 관리 기술과 실제 데이터들이 들어오는 속도에 따라 Window size(w)를 적절히 조정하여 최적의 w를 찾고 window 내 데이터를 최적 파티셔닝 하는 기법에 대해 연구

- 실시간화 빅데이터 처리 엔진 기반의 병렬 추상화 비식별화 변환 기술의 연구



[그림 95] 실시간화 빅데이터 처리 엔진 기반의 병렬 추상화
비식별화 변환 기술의 연구

· spark sql library로 구현된 추상화 로직을 spark structured steaming library로 포팅하여 실시간 추상화 모듈을 구현 해당 과정에서 하나의 어플리케이션으로 구현 불가한 부분들이 발견되어 단계별로 하나의 어플리케이션으로 분리하여 개발. 실시간 추상화만을 위한 별도의 UI를 갖춘 SW를 추가 개발

■ 기술적 성과

○ 산업재산권(특허, 상표, 실용신안 등)

번호	출원인	명칭	국명	출원일	출원번호	기여율
1	㈜보아라	빅데이터의 비식별화 처리 방법	국외	2019-05-31	PCT/KR2019/006586	100%

○ 기술문서

번호	기관명	상세 구분
1	㈜보아라((구)그리즐리))	MASQ 실시간 추상화 Spark 모듈 평가서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2-1. SW 품질관리

가. SW 품질관리 활동

(1) 프로젝트 표준 개발방안

- 점증적 개발 방법론을 기반으로 참여연구원 전원에게 동일한 표준 프로세스 적용을 원칙으로 함

- 점증적 개발 방법론은 시스템을 여러 개의 서브시스템으로 분리하여 분석, 설계, 구현의 개발 단계별 주요 활동에 대응하는 테스트 계획을 단계별로 수립하고 이를 대응하는 테스트 활동에 수행하는 방식임

① 개발방법론

[표준 프로세스 영역별 주요 활동 및 적용 범위]

프로세스	주요 활동	적용 범위	
프로젝트 착수 및 계획	S/W 규모, 일정 산정 프로젝트 계획 수립	전 참여연구원	
프로젝트 모니터링 및 통제	이슈 관리 프로젝트 정기 보고	전 참여연구원	
위험관리	위험관리	전 참여연구원	
요구사양 개발 및 관리	S/W 요구사양 정의	전 참여연구원	
S/W 설계	아키텍처 설계 모듈 설계 요구사양 추적 및 관리	전 참여연구원	
S/W 구현	코딩 모듈별 단위 시험 (또는 시나리오 기반 통합 시험으로 대 체) S/W 통합	전 참여연구원	
S/W 시험	S/W 시험 계획 및 설계 S/W 시험 수행	품질 측정	참여연구원
검토	S/W 요구사양 검토 아키텍처 검토 모듈설계 검토 코드 검토 S/W 통합시험 설계 검토	품질 측정	참여연구원
품질보증	프로세스/산출물 품질점검	품질 측정	참여연구원
측정 및 분석	측정데이터 수집/검증/분석	전 참여연구원	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

② 형상 및 변경관리 방안

- 형상관리 수행방안

· 각 수행기관은 수행기관별 형상관리담당자를 지정하고 주관기관에서 가이드하는 형상관리계획에 준하여 형상을 관리한다.

· 수행기관별 형상관리 도구는 SVN을 사용하며, 베이스라인 설정 작업 이후 관리는 수행기관별 개별관리를 한다.

· 각 기관에서 발생한 형상변경사항에 대해서는 주관기관에 주기적으로 공유한다.

세부시스템	품질지표	품질목표	선정사유
형상식별	· 형상관리 대상을 구분하고 관리목록에 번호 부여 · 형상관리 주요 대상 - 프로젝트 계획서, 품질계획서, - 공식 개발 산출물, - 소스코드	주관기관 형상관리자	MS Office
기준선 (베이스라인) 생성	· 작업 완료된 형상 항목에 대해 베이스라인 설정 · 형상관리 환경에 형상항목 등록	전체 형상관리자	기관별 도구사용 SVN
형상통제 (변경관리)	· 형상항목의 변경 발생이 다른 형상에 영향을 줄 수 있으므로 변경을 통제하는 것 · 타 요소의 변경에 영향을 주는 항목의 변경 시 변경 영향 분석을 통한 후 선별 회의에서 변경 승인	전체 형상관리자	MS Office, SVN
형상감사	· 형상계획에 따라 형상항목의 변경이 통제되는지를 감사함	주관기관 형상관리자	MS Office, SVN
형상기록	· 형상 및 변경 관리에 대한 각종 수행결과를 기록하고 관리 대장을 통해 관리함	전체 형상관리자	MS Office, SVN

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 과제 품질목표 및 검증방안

구분	서브 시스템	품질목표	품질 목표	검증방법
사업계획서 목표	빅데이터 비식별화	빅데이터내프라이버시 정보검색 및 식별성능	350,000/초	Σ(식별된 개인정보건수/걸린시간(초), 시험인증 (기관평가)
		비식별화 정보생성기능	250,000 건/초	Σ(식별된 개인정보건수/걸린시간(초), 시험인증 (기관평가)
		프라이버시 정보오용 및 부정재식별 패턴 및 Rule	100 건	비정상요청에 대한 차단기능 (시험인증기관평가)
		GPGPU 기반 처리 서능	150%	$\frac{UTDAnonymization\text{비식별화수행시간}}{\text{개발목표기술의 비식별화수행시간}} \times 100$ (자체평가)
		서버 클러스터 환경기반 처리 성능	Y	지원여부 (자체평가)
		비식별 데이터 재식별 가능성 검증 기능	Y	지원여부 (자체평가)
		비식별 데이터의 통계적 유효성 향상	150%	$\frac{UTDAnonymization\text{의통계적정확성}}{\text{개발목표기술의통계적정확성}} \times 100$
		개인정보 형식판별 및 형식유지기반익명처리	100,000 건/초	Σ(익명처리 개인정보건수/걸린시간(초) (자체평가)
		저장데이터 비식별화 변환속도	30,000 건/초	Σ(익명처리 개인정보건수/걸린시간(초) (자체평가)
		재식별 위험성	<=5%	100 * (원본 정보로 재식별된 건수 / 비식별된 전체 건수)
		실시간 데이터 비식별화변환속도	100,000 건/초	$(\sum_{k=0}^{N} N)/\sec(N = Nmber of\ Tuple)$ (자체평가)
		비식별화데이터의 통계적 오차	1%	$Error_A = \frac{\lvert AVG(A_{변환}) - AVG(A_{ori})\rvert}{AVG(A_{ori})} \times 100$ (자체평가)
	음성데이터 비식별화	문장종속형_오거부율 (False reject rate)	<=8%	100*(등록사용자 정발성의 거절 횟수) / (등록사용자의정발성 시도 횟수 (자체평가)
		문장종속형_오수락율 (False accept rate)	<=0.02%	100*(등록사용자 오발성 또는 비등록자 발성의 승인 횟수) / (등록사용자의

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

구분	서브 시스템	품질목표	품질 목표	검증방법
				오발성 및 비등록자 발성 시도 횟수) (자체평가)
		문장종속형 처리시간	< 1.0%	(총 처리시간)/(개인식별평가데이터 수) (자체평가)
		문장독립형_오거부율 (False reject rate)	<=10%	100*(등록사용자 정발성의 거절 횟수) / (등록사용자의 정발성 시도 횟수) (시험인증기관평가)
		문장독립형_오수락율 (False accept rate)	<=0.1	100*(등록사용자 오발성 또는 비등록자 발성의 승인 횟수) / (등록사용자의 오발성 및 비등록자 발성 시도 횟수) (시험인증기관평가)
		문장독립형 처리시간	< 1.0%	(총 처리 시간) / (개인식별 평가데이터 수) (시험인증기관평가)
수행 품질 목표	전체	요구사항구현율	100%	단계별로 요구사항 반영 검증 - 설계 (SW 설계서) - 구현 (프로그램 ID) - 테스트 (테스트 케이스)
		요구사항변경율	10%	요구사항 변경으로 인한 과제 영향도를 관리하기 위함
		검토 수행율	90%	주요 산출물과 주요 모듈에 대한 품질을 보증하기 위해 동료 검토를 수행
		테스트 수행율(커버리지)	100%	도출된 테스트 케이스에 대해 테스트 수행 커버리지를 확보하기 위함
		결함 조치율	100%	발견된 결함에 대해 조치 완료를 관리하기 위함

(3) 과제 수행 활용 도구

유형	도구	설명(활용용도)
관리	Microsoft Excel	요구사항 관리, 문서작성 설계, 시스템 및 네트워크 아키텍처 설계
	SVN	형상관리, 백업, 버전관리
설계	Microsoft Office	문서 작성, 설계
개발	SVN	소스코드 형상관리
	Eclips	통합 개발 플랫폼
테스트	PMD	소스코드 정적분석

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

3. 목표 달성도 및 관련 분야 기여도

3-1. 목표

빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호기술은 세계최고의 기술을 목표로 하고 있다. 빅데이터 개인정보 식별 엔진 개발, 개인정보 익명처리를 위한 비식별화 정보 생성 엔진 개발, 실시간 통합 관리 및 제어 엔진 개발을 통해 실제 환경에서 빅데이터 기반의 비식별 개인정보보호기술을 실증을 통해 검증받았다. 특히, H공사의 2,500억건의 전력데이터를 비식별 처리함으로써 가장 많은 데이터를 비식별 처리 사례를 실현하였다.

3-2. 목표 달성여부

(가) 당해 (연도・단계) 질적 성과 목표 및 달성도

평가 항목 (주요성능 Spec)	단위	전체 항목에서 차지하는 비중 (%)	세계최고 수준 보유국/ 보유기업 (/)	연구개발 전 국내수준	개발 목표치										평가 방법
			성능수준	성능수준	1차 년도 (2015년)		2차 년도 (2016년)		3차 년도 (2017년)		4차 년도 (2018년)		5차 년도 (2019년)		
					목표	실적	목표	실적	목표	실적	목표	실적	목표	실적	
1. 빅데이터 내 프라이버시 정보 검색 및 식별 성능	EPS	12	150,000/초 (미국/Splunk)	200,000/초	-	-	100,000/초	142,970/초	-	-	350,000/초	1,184,210/초	-	-	공인 인증 기관
2. 비식별화 정보생성 성능	건	20	200,000/초 (미국/Protegrity)	N/A	-	-	250,000/초	142,970/초	-	-	-	1,184,210	-	-	공인 인증 기관
3. 프라이버시 정보 오용 및 부정 재식별 패턴 및 Rule	건	8	N/A	4개	-	-	-	-	-	-	100건	100건	-	-	자체 평가
4. GPGPU 기반 처리 성능	%	4	100%	없음	120	197	-	-	-	-	-	-	-	-	자체 평가
5. 서버 클러스터 환경 기반 처리 가능	지원 여부	2	N/A	없음	-	-	Y	Y	Y	Y	-	-	-	-	자체 평가

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

평가 항목 (주요성능 Spec)	단위	전체 항목에서 차지하는 비중 (%)	세계최고 수준 보유국/ 보유기업 (/)	연구개발 전 국내수준	개발 목표치										평가 방법
			성능수준	성능수준	1차 년도 (2015년)		2차 년도 (2016년)		3차 년도 (2017년)		4차 년도 (2018년)		5차 년도 (2019년)		
					목표	실적	목표	실적	목표	실적	목표	실적	목표	실적	
6. 비식별 데이터 재식별 가능성 검증 기능	지원 여부	2	N/A	없음	-	-	-	-	Y	Y	-	-	-	-	자체 평가
7. 비식별 데이터의 통계적 유효성 향상	%	3	100	없음	-	-	-	-	-	-	150	160.7	-	-	자체 평가
8. 개인정보 형식 판별 및 형식 유지 기반 익명처리	건	2	N/A	없음	100,000 건/초	100,000 건/초	-	-	-	-	-	-	-	-	자체 평가
9. 저장 데이터 비식별화 변환 속도	건	6	200,000/초 (미국/Protegrity)	없음	20,000 /초	21,863 /초	30,000 /초	45,662.1/초	30,000 /초	37,313 /초	100,000/초	207,727/초	-	-	자체 평가
10. 재식별 위험성	%	6	N/A	없음	-	-	-	-	≤ 5	0	-	-	-	-	자체 평가
11. 개인정보 보안 솔루션과 CKAN의 연계	지원 여부	8	N/A	없음	-	-	-	-	-	-	Y	Y	-	-	자체 평가
12. 비식별화 데이터의 통계적 오차	%	2	N/A	없음	10	9.4	5	4.597	3	2.95	1	0.9	-	-	자체 평가
13. 실시간 데이터 비식별화 변환 속도	건	6	200,000/초 (미국/Protegrity)	없음	-	-	-		-	-	-	-	100,000/초	114,218/초	자체 평가
14.문장종속형_오수락율(False accept rate)	%	2	N/A	없음	≤ 0.05	≤ 0.021	≤ 0.02	≤ 0.02	-	-	-	-	-	-	자체 평가
15.문장종속형_처리시간	sec	2	N/A	없음	< 1.5	< 1.23	< 1.0	< 0.18	-	-	-	-	-	-	자체 평가
16.문장독립형_오거부율(False reject rate)	%	3	≤ 10	≤ 20	-	-	-	-	< 20	< 8.7	-	-	-	-	공인 인증 기관
17.문장독립형_오수락율(False accept rate)	%	3	≤ 0.095	≤ 0.115	-	-	-	-	≤ 0.2	≤ 0.0	-	-	-	-	공인 인증 기관

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

평가 항목 (주요성능 Spec)	단위	전체 항목에서 차지하는 비중 (%)	세계최고 수준 보유국/ 보유기업 (/)	연구개발 전 국내수준	개발 목표치										평가 방법
			성능수준	성능수준	1차 년도 (2015년)		2차 년도 (2016년)		3차 년도 (2017년)		4차 년도 (2018년)		5차 년도 (2019년)		
					목표	실적	목표	실적	목표	실적	목표	실적	목표	실적	
18.문장독립형_처리시간	sec	3	< 1.0	없음	-	-	-	-	< 2.0	< 0.5	-	-	-	-	공인 인증 기관
19.원본/비식 별 빈발패턴 상대적 _유사도	%	2	N/A	없음	-	-	-	-	85	88	-	-	-	-	자체 평가
20.실시간 일반화 빈발패턴 탐사 _수행 속도	건	2	N/A	없음	-	-	-	-	-	-	5,000/초	6,000/초	-	-	자체 평가
21.실시간 다레벨 연관규칙 탐사 수행 속도	건	2	N/A	없음	-	-	-	-	-	-	-	-	3,000/초	6,000/초	자체 평가

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(나) 품질목표 측정 및 검증 방법

① 정량적 목표 항목의 평가방법

- 빅데이터 내 프라이버시 정보 검색 및 식별 성능
  - 초당 최소 350,000 건 이상의 로그 처리 성능 확인
  - 정형/반정형/비정형 개인정보 혼합
  - 정확도(%) = 정탐건수 / 전체건수 x 100
- 프라이버시 정보 오용 및 부정 재식별 패턴 및 Rule
  - 상황별 탐지 조건별 해당 비정상 접속 요청 발생
  - 정상 요청과 비정상 요청 동시 진행 중 탐지
  - 비정상 요청에 대한 차단 기능 확인
- 비식별화 처리 성능(GPGPU 기반 처리 성능)
  - 사용자가 비식별화를 요청하고 작업이 완료되는 시점까지의 시간을 측정
  - 대표적인 익명화 도구인 UTD anonymization toolbox(UT Dallas에서 제작하여 오픈소스로 배포)의 성능을 100% 기준으로 하여 아래 식에 의거해 표현
  - $\text{목표기술성능} = \frac{UTD Anonymization \text{ 비식별화수행시간}}{\text{개발목표기술의 비식별화 수행시간}} \times 100$
- Anatomy 기반 비식별화 성능
  - 비식별화된 데이터의 정보 손실(information loss)을 측정
  - 통계적 정확성은 정보 손실의 역수로 간주
  - UTD anonymization toolbox의 Anatomy 방법을 사용하여 비식별화한 데이터의 통계적 정확성을 100%으로 하여 아래 식에 의거해 표현
  - $\text{목표기술성능} = \frac{UTD Anonymization \text{의 통계적 정확성}}{\text{개발목표기술의 통계적 정확성}} \times 100$

- 저장 데이터 비식별화 변환 속도
  - 단일 비식별화 변환 SW를 기준으로 1초당 재식별 불가능한 비식별화 변환 되어지는 정형 레코드 튜플의 수를 측정함
  - 튜플 당 300바이트 미만의 데이터가 입력된다.
  - 재식별 불가능한 비식별화 변환 수행 후, 총 입력된 튜플 수와 걸린 시간을 이용해 초당 평균 입력값을 계산 한 것을 기준으로 함
- 재식별 위험성
  - 변환된 비식별화 데이터에 원본 정보로 재식별된 레코드 개수를 계산
  - $\text{재식별위험성} = 100 \times \frac{\text{원본정보로 재식별된 건수}}{\text{비식별된 전체건수}}$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 비식별화 데이터의 통계적 오차

· 변환된 비식별화 데이터와 원본 데이터간의 각 속성별 오차율을 계산

· $\text{속성 } A\text{의 통계적 오차} = \frac{|\text{비식별화 데이터 평균} - \text{원본데이터의 평균}|}{\text{원본데이터의 평균}} \times 100$

- 실시간 데이터 비식별화 변환 속도

· 전체 비식별화 변환 분산 시스템을 기준으로 1초당 재식별 불가능한 비식별화 변환 되어지는 로그성 반정형 레코드 튜플의 수를 측정함

· 튜플 당 300바이트 미만 크기의 입력 데이터를 사용.

· 재식별 불가능한 비식별화 변환 수행 후, 총 입력된 튜플 수와 걸린 시간을 이용해 초당 평균 입력 값을 계산 한 것을 기준으로 함

- 원본/비식별 빈발 패턴의 상대적 유사도

· 4차년도에서 다음과 같이 원본 트랜잭션과 비식별 트랜잭션의 유사도를 보정 전후로 나누어 빈발패턴 결과 유사도를 구함

· $\text{유사도} = \frac{(\text{원본} - \text{비식별 빈발패턴 보정전/후유사도})}{(\text{원본} - \text{비식별 트랜잭션 평균유사도})}$

- 실시간 다레벨 빈발패턴 탐사 수행 속도

· 실시간으로 발생되는 트랜잭션이 포함하는 계층 구조를 대상으로 다레벨 빈발 패턴 탐사 수행 속도

· 실시간 빈발패턴과 달리 수행하는 레벨의 개수에 따라 처리 되는 속도가 저하 됨

· $\text{수행속도} = \frac{\text{처리된 트랜잭션 개수}}{\text{초} \times \text{레벨 개수}}$

- 일반화 기반 비식별화 기법과 통계적 유효성 비교

· 각 레코드가 가질 수 있는 민감 속성 값의 확률 밀도 함수와 원본 레코드의 확률 밀도 함수의 차이를 계산하는 측정식

· $RCE = \sum_{\forall t \in T} \int_{x \in DS} (\widetilde{D}_t(x) - D_t(x))^2 dx$

- 실시간 비식별 데이터스트림에 대한 빈발패턴의 상대적 유사도 측정

· 일반화 원본 트랜잭션의 빈발패턴과 일반화 비식별 트랜잭션과의 유사도를 보정 전/후로 나누어 빈발패턴 결과 유사도를 구함

· 보정 전/후 빈발패턴 유사도 = (일반화 원본 트랜잭션 빈발패턴과 일반화 비식별 트랜잭션

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

빈발패턴 보정 전/후간 유사도)

- 비식별화 데이터의 통계적 활용의 유효성에 대한 검증 방법 개발 및 사례 검증 수행

  ·원본 데이터 기반의 통계적 분류모형과 비식별화 데이터 기반의 분류모형의 비교를 통해 비식별 처리가 통계적 분류모형에 미치는 영향을 파악

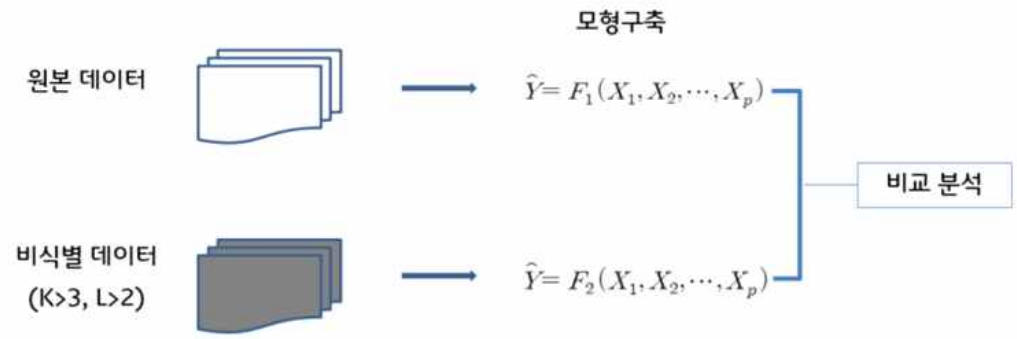


그림 96 비식별화 데이터 유효성 검증

- 음성 화자그룹 분류/판별 성능 지표

  ·오거부율 (False reject rate) : 등록된 사용자가 거절될 오류율

  ·오수락율 (False accept rate) : 비등록 사용자가 승인되거나 다른 사용자로 식별될 오류율

  ·처리시간 : 발성 종료 후 식별 시까지의 응답 시간

· 성능목표치 근거

  - NIST[8] 화자인식 I-vector challenge의 leaderboard 수치

    . NIST 성능지표 : minDCF(minimum decision cost function)

    = (false-reject-rate)/100 + (false-accept-rate)

    . world-best : minDCF 0.195 (Idiap)

    . 성능목표치 10%, 0.1%를 minDCF로 환산 시 0.2

    . NIST 평가에서는 등록화자 수가 수백명이고, 16kHz 데이터 이용하며, 40~60초 데이터로 화자모델을 생성한 반면, 본 과제에서는 8kHz 30초 데이터로 화자모델을 생성하고 등록화자 수가 1천명이라는 조건을 감안하여 목표치를 설정함.

- 실시간 비식별 데이터스트림에 대한 빈발패턴의 상대적 유사도 측정

  · 원본 비식별 트랜잭션과 사생활 유사도 기반 비식별 트랜잭션의 유사도 대비 빈발 패턴

8) NIST(**National Institute of Standards and Technology)** : 미국상무부 기술관리국 산하의 각종 표준과 관련된 기술을 담당하는 연구소

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

결과 유사도

・유사도 = (원본 - 비식별 트랜잭션 평균 유사도 / 원본 - 비식별 빈발패턴 평균 유사도)

(다) 기술개발 추진 전략방법

연차		수행내용	수행방법 (활용・방법)	예측 장애요소	장애 해결방안	계획된 실험과정	비고
1년차(2015년 6월 ~ 2016년 5월)	이지서티	비정형 개인정보 탐지 기술 개발	- 기존 개인정보 탐지 기법 분석 - 비정형 개인정보 탐지 기술 개발	비정형 개인정보의 범위 지정이 어려울 것으로 예상됨	주로 사용되는 시스템구조상에서 정형 개인정보 이외의 비정형 데이터를 기준으로 정의	기존의 데이터베이스 구성 정보 참조로 개발	
		정책 기반의 자동화된 개인정보 선별 기술 개발	- 개인정보 탐지 정책 수립 - 관리 시스템 개발 - 탐지 기술과 정책 관리 기능의 연동	개인정보 탐지 정책에 따른 탐지 기술의 연동이 어려울 것으로 예상됨	탐지 기술 개발 시부터 자동화 탐지에 대한 설계를 같이 진행	자동화된 시스템을 통한 개인정보 탐지	
		KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (인메모리 중심)	연구팀이 구축・보유하고 있는 GPGPU 개발 환경 활용	비식별화 연산 중 일부는 GPU에서 수행하기 어려움	장애요소를 고려한 GPU-CPU 연계 최적화된 비식별화 알고리즘 고안	인메모리 비식별화 처리를 위한 데이터 분할 실험 및 익명화	
	피앤피시큐어	개인정보 형식 판별 및 형식 유지 기반 익명처리 알고리즘 연구	- 개인정보의 최소 형식 유지 한계 분석 - 개인정보의 형식 유지 한계에 따른 익명처리 알고리즘 개발	개인정보의 최소 형식 유지 한계 측정 어려움	다수에 대한 형식 유지 익명화 자료 설문으로 한계 측정	다수에 대한 설문 조사	
	보아라((구)그리즐리)	정형 데이터의 대표레코드화 비식별화 기술 개발	- 상용 DBMS와 연동 가능한 정형 데이터의 비식별화 기술의 개발	연동 가능한 DBMS의 종류 다양성 확보가 어려움	가장 상용화된 MySQL, 오라클을 기본으로 종류를 늘여 나감	기존 DBMS의 데이터와의 연계 및 비식별 데이터 생성 개발	속도 최적화
		데이터 접근 기록 실시간 정상 프로파일 생성 기술	기 개발된 실시간 데이터 분석엔진을 활용한 데이터 접근 기록에 대한 실시간 정상 프로파일 생성	실제 DB 접근 log데이터의 확보가 어려움	자체 서버의 DB접근 log를 활용하거나, 유사한 웹접속 log를 활용	확보한 log data 기반의 프로파일 생성 및 상황 학습 기술 선 개발	정확도 상승에 초점을 맞춤
	IR 링크	개인 시그네쳐 기반 실시간 클러스터링 기법 연구	비식별화 된 대표레코드들에 대하여 적용 가능한 클러스터링 기술 개발	지원 가능한 데이터 타입이 한정	로그성 데이터에 대한 알고리즘은 2차년도에 개발	위탁연구	
		문장 종속형 화자그룹분류/판별 기반기술 개발	개발에 필요한 화자그룹분류용 음성DB 확보 4가지 최신 개인식별 알고리즘의 구현 및 성능 비교	3초 정도의 짧은 발성 데이터에 대한 사용자 검증 목표성능의 달성 여부가 관건	GMM, SVM, JFA, i-vector 4가지 기술에 대한 구현 및 성능 비교로 최적 알고리즘 선정	음성DB 제작 전처리기술 개발 4가지 알고리즘 구현, 성능비교 및 최적화	
		개인정보 활용 동의 및 마케팅 프로그램 설계	마케팅용 App 선별 관련 프로세스 확인 개발을 위한 화면 정의	고객정보 활용 동의를 위한 법률검토	고객정보보호 규정 준수	프로세스 설계 UI설계 관련 법률검토	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연차		수행내용	수행방법 (활용・방법)	예측 장애요소	장애 해결방안	계획된 실험과정	비고
2년차(2016년 6월 ~ 2017년 5월)	이지서티	반정형/비정형 개인정보 탐지 기술의 정확도 향상	- 반정형/비정형 개인정보 탐지 학습데이터 구축 - 다양한 데이터 도메인에 대한 적응성 향상	탐지 학습 데이터 소스 확보가 어려울 것으로 예상됨	참여업체와의 데이터 연계를 통하여 학습데이터 확보	테스트를 위한 빅데이터를 통하여 학습데이터 구축	
		개인정보 접근 비정상 행위 패턴, 부적절 이용 탐지	- 비정상 행위/부적절 이용 탐지 패턴 개발 - 탐지 패턴 자동화 탐지 기능 개발	비정상 행위 정의가 어려울 것으로 예상됨	보유한 솔루션에서 활용하고 있는 개인정보 오남용 행위 패턴 활용		
		KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (분산환경 중심)	연구팀이 구축・보유하고 있는 서버-클러스터 개발 환경 활용, MapReduce를 이용하여 분산 비식별화 알고리즘 구현	데이터가 전체 클러스터 노드에 고르게 분산되지 않는 상황을 고려해야 함 (Load balancing)	비식별화 알고리즘 설계 시 기존 Load balancing 기법 활용	MapReduce의 Reduce 단계에서 비식별화 기법 적용	
		개인정보 형식 판별 및 형식 유지 기반 익명처리 기능 개발	- 개인정보의 형식 유지 한계에 따른 익명처리 기능 개발				
		개인정보 유출방지를 위한 영역분리 보안 관리 기술 개발	- 일반 빅데이터 영역과 개인정보 데이터 영역 구분 시스템 구성 계획 수립 - 각 영역별 데이터 접근에 대한 절차적 접근 프로세스 개발	영역별 데이터 접근 시 성능 저하 우려	불필요한 단계 제거로 최소한의 성능 저하 발생	프로세스 적용 이후 속도 측정	
	보아라((구) 그리즐리)	반정형 로그 데이터의 대표로그데이터화 비식별화 기술 개발	상용 DBMS와 연동 가능한 반정형 로그성 데이터의 비식별화 기술 개발	로직의 복잡도로 인한 변환 속도 저하 문제	재식별 불가능성을 확보하면서도 최적의 성능을 내는 파라미터값에 대해 연구	1차년도 개발된 정형 대표레코드들에 대한 대표로그레코드 생성 및 DBMS연동	
		Anomaly 탐지 기술 기반의 실시간 비정상 지수생성 및 비정상 탐지 기술 개발	생성된 정상상황 프로파일과 실시간 로그의 비교를 통한 비정상 지수 생성 및 비정상 탐지 기술 개발	로그 데이터의 수치화 방법의 문제	수치화 기법의 문제가 있을 경우 패턴화 방법을 이용한 접근법 확보	1차년도 개발된 정상 프로파일과의 비교 알고리즘 개발	
	IR 링크	개인 시그네쳐 기반 빈발패턴, 연관규칙 탐사 기법 연구	비식별화된 대표(로그)레코드들에 대하여 적용 가능한 빈발패턴, 연관규칙 기술 개발	다양한 수준의 알고리즘 적용 단계가 존재할 것으로 예상됨 (대표레코드별, 대표레코드 대그룹별 /유사 대표레코드 그룹별)	가장 좋은 효율을 낼 수 있는 데이터 수준에 대한 연구가 필요	위탁연구	
		문장 종속형 화자그룹분류/판별 상용화 기술 개발	기존 문헌 또는 제품에서 오용 사례 및 극복 방안 조사. 환경적 및 신체적 변이 요인을 대처할 수 있는 기존 기술 조사 및 활용. 상용화를 위한 다채널 SW 제작.	녹음 등에 의한 오용 주변환경 잡음 또는 사용자의 컨디션에 따라 입력 음질의 변화	사용자 등록 시 또는 본인 인증 시의 발성 데이터에 대한 녹음 데이터 재생 판별 기능 추가. 환경적 및 신체적 변이 요인에 대한 화자그룹분류/판별 개선	녹음된 발성 데이터, 흉내낸 데이터 등을 수집 기존 시스템의 취약점 분석 오용 방지 기능 추가. 다채널 SW 구현 및 시스템 평가	
		마케팅 프로그램 개발	개발화면별 흐름과 구조 파악 및 개발진행	App개발에 필요한 인력과 tool	기존 개발인력을 App개발 인력으로 전환	프로그램 개발 및 테스트 진행	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연차		수행내용	수행방법 (활용・방법)	예측 장애요소	장애 해결방안	계획된 실험과정	비고
3년차(2017년 6월~2018년 3월)	이지서티	반정형/비정형 개인정보 탐지 기술의 속도 향상	- 비 저장성 데이터를 통하여 메모리상에서 개인정보 탐지 기능 개발 - 병렬처리를 통한 비정형 개인정보 탐지 속도 향상	병렬 처리 시 병목구간 발생으로 인한 목표 속도 확보가 어려울 것으로 예상됨	검증된 분산처리 기술을 이용하여 탐지 기술의 속도 확보	분산처리 시스템을 통한 개인정보 탐지 성능 측정	
		개인정보 제공 요청자에 대한 접근 통제 기술	- 시스템 감사로그 증적 기능 - 사용자별/메뉴별/기능별 사용 권한 관리 기능 - 비정상 행위/부적절 이용 탐지 시 개인정보 제공 요청자의 시스템 이용 통제	접근통제에 대한 시기 결정이 어려울 것으로 예상됨	시스템 접근에 대한 데이터 플로우의 명확한 이해를 통하여 필요 구간에 대한 접근 통제 구현	접근 통제에 대한 시스템 구현	
		비식별화 정보 기반 개인정보 고속 검색 기술	- 비식별화 정보 기반 개인정보 검색 시스템 인터페이스 개발 - 비식별화된 개인정보간의 매칭 정보를 통하여 검색 기능 개발				
		비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술	1, 2차년도 개발 내용을 기반으로 하여 재식별 가능성 확인	재식별 가능성을 검증하기 위한 적합한 수식 모델 부재	완결한 수식 모델 고안을 위한 수리통계 전문가 초빙	다양한 샘플 데이터셋을 활용한 비교 검증	
	보아라((구)그리즐리)	비식별화 변환 데이터의 검증 기술 연구	비식별화 변환 데이터의 재식별 불가능성 검증 기술 개발	검증의 복잡한 로직으로 전체 변환 수행 시간이 길어질 수 있음	비식별화 변환과 검증 모듈의 분리를 통한 비식별 데이터 생산성 우선 확보	유일성, 동일성, 유사성, 각각의 제거 검증 기술 개발	
		비식별화 변환 연계 품질 및 속도 향상 기술 연구	비식별화 변환된 테이블간의 연계 기술 개발 및 연계 품질 향상 기술 연구	연계를 위한 다양한 데이터 수집의 어려움	테스트 베드 제공 업체 확보 및 협력	대표레코드와 대표로그레코드로 변환 된 비식별 데이터 간의 테이블 연계 방법에 대해 연구 및 실험	
	IR링크	실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙 탐사 기법 연구	개인 시그네처 그룹 기반 실시간 빈발패턴/연관규칙 탐사 및 지지도 보정 기법 연구	실시간에 처리하기에 무거운 알고리즘이 될 수 있음	인메모리 스트림 데이터 엔진의 분산 처리 시스템을 활용하여 분산 처리할 수 있는 방안 모색	위탁연구	
		고객상담 서비스를 모델로 한 화자그룹분류 및 판별 시스템 개발	기존 고객상담 서비스와 같은 실환경 음성데이터 활용. 녹취 음성 데이터로부터 자동 사용자모델 생성	정보보호로 인한 실제 음성파일 반출의 어려움. 발성 데이터 내용에 대한 제한이 없는 상황에서 사용자식별의 어려움.	정부연구기관 전화망 상담DB 활용. 최신의 i-vector 방식과 검증기술 활용.	-테스트 음성준비 -화자변곡점의 특성 관찰 -문장 독립형 사용자 식별 -사용자 식별 성능평가 및 개선	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연차		수행내용	수행방법 (활용・방법)	예측 장애요소	장애 해결방안	계획된 실험과정	비고
4년차(2018년4월~2019년1월)	이지서티	반정형/비정형 개인정보 탐지 기술의 성능 검증	목표 성능 350,000EPS/초 에 대한 성능 측정	성능검증에 필요한 빅데이터 확보 필요	참여기업과의 연계를 통하여 필요 데이터 확보	실제 빅데이터를 이용한 성능 측정	
		개인정보 탐지기능과 비식별화 기능 융합을 통한 통합 개인정보보호 솔루션 구축 및 상용화 준비	통합 개인정보보호 솔루션 구축 관점에서 비식별화 S/W 내 고객 Legacy System 게시판 및 e-mail 본문과 첨부파일에 대한 개인정보 탐지 및 차단, 모니터링 기능 융합 수행	이기종 시스템과의 연계(Legacy System 연계)로 인하여 모듈화 시 어려움이 예상됨	이기종 시스템 유형 별 다양한 연계 Interface 구축		
		CKAN 플랫폼과 데이터 보안 솔루션 연계	CKAN 플랫폼에 게시된 데이터를 공개하기 전 개인정보 탐지 및 비식별 처리를 수행하여 유통대상 데이터에 대한 데이터 보안 측면에서의 안정성 확보	CKAN 플랫폼에 게시되는 다양한 형태의 정형/비정형/반정형 데이터에 대한 개인정보 탐지 및 비식별 처리 UI 구성에 어려움이 예상됨	다양한 형태의 공유 데이터 유형 별 개인정보 탐지 프로세스 및 맞춤형 비식별 처리 UI 정립	CKAN 플랫폼에 게시된 정형/비정형/반정형 데이터에 대한 비식별 처리 수행 및 검증	
		스키마 스캔 및 메타정보 시각화를 통한 빅데이터 플랫폼(Super Hadoop)과 비식별화 S/W 연계 기술 ※ Super Hadoop : (총괄)빅데이터 처리 고도화 핵심 기술 활용	- 스키마 스캔을 통한 빅데이터 플랫폼 내 메타정보 시각화 기술 개발 - 선택된 정보요소에 대한 다양한 전처리 Interface 기술 개발 - 전처리 기능 별 SQL 처리코드 생성 알고리즘 개발 및 이를 통한 빅데이터 플랫폼 내 비식별 대상 데이터 연계기술 개발	총괄 과제인 빅데이터 처리 고도화 핵심 기술 결과물인 Super Hadoop과의 연계 및 고속 SQL 처리코드를 활용하는 관계로 개발진행 일정에 대한 원활한 공유 및 협력관계 구축 필요	총괄 과제 수행사와의 유기적 협력체계 및 기술공유체계 구축		
		정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술	- 통계적 유효성을 고려한 프라이버시 모델을 만족시키는 일반화 기반 비식별화 기법 개발 - 통계적 유효성을 고려한 테이블 분리 기반의 비식별화 기법 개발	통계적 정확성 측정을 위한 표준 모델의 부재	산재되어 있는 다양한 통계적 정확성 측정 모델을 일정한 기준에 맞추어 표준화	통계적 정확성을 측정하는 다양한 Metric을 통한 비교 실험	위탁연구
		실시간 트랜잭션 항목 일반화 기법 연구	비식별 트랜잭션 항목 일반화 계층 구조 매핑 기술 및 실시간 Roll-up 일반화 트랜잭션 생성 및 빈발패턴 탐사 기법 연구	실시간에 처리하기에 무거운 알고리즘이 될 수 있음	인메모리 스트림 데이터 엔진의 분산 처리 기능을 활용하여 수행할 수 있는 방안 모색		위탁연구
		기술활용을 통한 분야별 사업화 방안 조사연구	- 공공기관 정보 공개서비스 등 분야별 사업화 방안 조사 - 유통 및 민간기관 빅데이터 서비스를 통한 분야별 사업화 방안 조사	비식별 처리 및 결합에 대한 시장 이슈가 있어 정보 수집의 어려움 있음	분야별 타켓을 정해 집중하여 정보 수집		위탁연구
	보아라((구)그리즐리)	비식별화 변환의 분산 처리 기술 연구	정형/반정형 데이터의 변환 및 검증기술을 인메모리 기술 기반으로 분산처리 가능한 기술로 전환	인메모리 빅데이터 처리 엔진의 기술적 한계로 인한 로직 이식 불가능	인메모리 빅데이터 처리 엔진의 기술 확보를 통한 필요 기술 반영	변환 및 검증 기술을 분산 처리 가능한 로직 단위로 분할 후 테스트 및 성능 향상 기술 연구	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연차		수행내용	수행방법 (활용・방법)	예측 장애요소	장애 해결방안	계획된 실험과정	비고
5년차(2019년1월~2019년5월)	이지서티	각 요소 기술을 통합 및 기능 테스트	- 각 요소별 구현 기술 통합 - 각 요소별 기능 테스트	기술간 인터페이스가 맞지 않아 통합에 어려움 예상됨	시스템 개발 초기부터 주관기관 과 참여기관과의 긴밀한 연계를 통항 시스템 인터페이스 공유	전체 시스템의 기능 정상 동작	
		빅데이터 개인정보보호 솔루션 사업화 수행	-통합 개인정보보호 솔루션 -비식별 빅데이터 유통서비스 사업화 수행 -마케팅 및 홍보를 위한 홍보물 제작 및 홍보 활동 계획 수립	-개인정보접속 기록 관리 시스템과 유기적 연결 어려움 예상됨 -공공과 민간 데이터를 활용하기 어려움 -홍보 활동 계획이 짧은 시간안에 수행하기 어려움	-공공/민간 비식별 사업화에 상용화 솔루션으로 제안 참여 -기성 제품들과의 차별점을 강조하는 홍보 및 특성화 작업 예정	-공공/민간의 비식별 관련 사업 제안참여 -홍보를 위한 전시회, 세미나등 참가	
	보아라((구)그리즐리)	추상화 비식별화 기법의 실시간 병렬 고속화 기술 개발	정형/반정형 데이터의 변환 및 검증기술을 인메모리 기술 기반으로 분산처리 가능한 기술로 전환	인메모리 데이터 스트림 처리 엔진의 기술적 한계로 인한 로직 이식 불가능	인메모리 데이터 스트림 처리엔진의 기술 확보를 통한 필요 기술 반영	변환 및 검증 기술을 분산 처리 가능한 로직 단위로 분할 후 테스트 및 성능 향상 기술 연구	
		실시간 비식별 데이터 스트림의 사생활 보존 일반화 연관 규칙 탐지기법연구	항목 일반화 계층 구조 기반 실시간 다레벨 연관 규칙 발견 기법 연구	실시간에 처리하기에 무거운 알고리즘이 될 수 있음	인메모리 스트림 데이터 엔진의 분산 처리 기능을 활용하여 수행할 수 있는 방안 모색		

3-3. 목표 미달성 시 원인(사유) 및 차후대책(후속연구의 필요성 등)

o 해당 없음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

용역/위탁 성과 및 실적

■ 위탁기관 별 수행 내용

(1) 고려대학교

가. 연구개발 목표 및 결과

구분	세부 연구 목표	연구개발 수행 내용	연구 결과
1차년도 (2015)	KLT 비식별화 고속처리 기술 개발	GPGPU를 활용한 비식별화 속도 향상 기법 데이터 비식별화 기법을 위한 메모리 병렬처리 기법	- 기존 익명화 알고리즘을 GPGPU에 맞게 활용하기 위해 병렬도를 높일 수 있도록 수정한 알고리즘을 개발. 병렬처리를 할 때 분기문이 존재할 경우 2배의 실행 시간이 소요. 따라서 분기문을 최소화한 알고리즘을 적용. 또한 CPU-GPU간 데이터 전송을 최소화하여 성능 개선.
2차년도 (2016)	KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (분산환경 중심)	분산환경 기반 개인정보 고속 비식별화 기능	- 기존 익명화 알고리즘을 분산 환경에 맞게 활용하기 위해 병렬처리 및 분산처리 할 수 있도록 수정한 알고리즘을 개발 기존 단일머신 기반 익명화 알고리즘에서는 대용량의 익명화 처리가 불가능하여,scale-out이 가능하도록 알고리즘 적용
3차년도 (2017)	익명화 정도 및 재식별 가능성 측정 모델 개발 및 구현	비식별 처리된 데이터의 익명화 정도를 측정하는 모델 개발 비식별 처리된 데이터에 대하여 특정 배경지식을 사용한 추론 공격시 예상되는 재식별 가능성 측정 모델 개발 익명화 정도 및 재식별 가능성 측정 소프트웨어 개발(in-memory 및 분산 클러스터 환경)	- 비식별화된 데이터가 얼마나 익명화 되어 있는지 익명화 정도 측정 모델 개발 - 비식별 처리된 데이터에 대한 재식별 가능성 측정을 위한 알고리즘 개발 및 측정 모델 개발 - 익명성과 재식별 가능성을 인메모리 환경과 분산 환경에서 측정하는 알고리즘 개발
4차년도 (2018)	정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술	기존 정보 손실을 줄이기 위한 비식별화 기술 및 모델 분석 테이블 분리 기반 비식별화 기법 개발 일반화 기반 비식별화 기법과 테이블 분리 기반 비식별화 기법의 통계적 유효성 비교	- 기존 정보 손실 감소를 위한 비식별화 기술 및 모델 분석 - 통계적 유효성을 향상시키기 위하여 테이블 분리 기반 비식별화 기법 개발 - 추가적으로 일반화 기반 비식별화 기법 간의 성능 비교 진행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

다. 수행 결과 요약

○ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술(인메모리 중심)
- GPGPU를 이용한 인메모리 고속, 병렬 KLT 비식별화 알고리즘 개발

○ KLT (k-anonymity, l-diversity, t-closeness) 비식별화 고속처리 기술 (분산환경 중심)

○ 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술 (인메모리 기반 / 분산환경 기반)

○ KLT 비식별화 데이터에 대한 인메모리 기반 익명성 측정 알고리즘 개발

○ 대용량 KLT 비식별화 데이터에 대한 서버 클러스터 기반 익명성 측정 알고리즘 개발

○ 정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술 (고려대)

○ 테이블 분리 기반 비식별화 기술 개발

라. 수행 결과 상세

○ KLT 비식별화 고속처리 기술(인메모리 중심)
- GPGPU를 활용한 속도 향상
- GPGPU에 적합한 병렬도를 높이고 분기문을 최소화하는 비식별화 기법 개발

<표 > Adult dataset 실험결과 (k=5)

# of QID	CPU(sec)	GPU(sec)	CPU/GPU	Data size(KB)	record/sec
3	0.744	0.503	1.479	599	59,964
4	2.712	1.184	2.290	653	25,474
5	5.636	2.258	2.496	635	13,357
6	11.902	4.601	2.587	883	6,556
7	45.304	17.567	2.567	846	1,774

○ 대용량 데이터의 KLT 비식별화를 위한 서버 클러스터 기반 분산 알고리즘 개발
- 분산환경 기반 개인정보 고속 비식별화 기능
- 지속적인 비식별화 데이터 모니터링 기술 개발

○ 비식별화 정보 조합을 통한 재식별 가능성에 대한 검증 기술 (인메모리 기반 / 분산환경 기반)

○ KLT 비식별화 데이터에 대한 인메모리 기반 익명성 측정 알고리즘 개발
- 인메모리 기반 데이터 익명화 기법 분석
- 인메모리에서 수행 가능한 데이터 익명성 측정 알고리즘 개발
- 알고리즘의 익명화 척도 측정 수식 모델 개발

○ 대용량 KLT 비식별화 데이터에 대한 서버 클러스터 기반 익명성 측정 알고리즘 개발
- 서버 클러스터 기반 익명성 측정 알고리즘 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

마. 수행 결과물

○ 국내 및 국외 논문 게재

번호	논문명	학술지명	게재일	주저자명	호	국명	발행기관	NTIS 등록번호
1	GPGPU를 이용한 익명화 알고리즘의 병렬 처리 기법(A Parallel Anonymization Algorithm Using General-purpose Graphics Processing Units)	데이타베이스연구회	2016.04.30	정기정	32권 제1호	대한민국	한국정보과학회	1158 6316
2	프라이버시 보호 데이터 배포를 위한 모델 조사	정보과학회 논문지	2017.02	김종선	제44권 제2호	대한민국	한국정보과학회	-
3	An anonymization protocol for continuous and dynamic privacy-preserving data collection	Future Generation Computer Systems	2017.09.08	Soohyung Kim	93	대한민국	Future Generation Computer Systems	-
4	Utility-preserving anonymization for health data publishing	BMC Medical Informatics and Decision Making	2017.07.11	Lee, Hyukki	17	대한민국	BMC Medical Informatics and Decision Making	ISSN/ISBN 1462-6947

○ 지식재산권(특허)

번호	명칭	국명	출원일(등록일)	출원(등록)번호
1	데이터의 유용성 보전을 위한 익명화 장치 및 그 방법	대한민국	2017.07.21	10-2017-0092344
2	GPGPU를 이용한 데이터 익명화의 병렬적 처리 방법	대한민국	2017.11.28	10-1804426-0000
3	하둡기반 시스템을 위한 캐시 인지 작업 스케줄링 장치 및 방법	대한민국	2018.12.04	10-1924466-0000

○ 기술문서

NO	기술문서명
1	GPGPU를 활용한 KLT 비식별화 고속처리 기술 분석서
2	분산 환경에서 서버 클러스터를 이용한 고속 KLT 비식별화 알고리즘 개발
3	재식별 가능성에 대한 기술 동향 조사
4	테이블 분리 기반 데이터 비식별 시스템

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 연차별 수행 내역 및 성과

- 1차 년도(2015)

세부 연구목표	K.L.T 비식별화 고속처리 기술개발
연구개발 수행 내용	GPGPU를 활용한 비식별화 속도 향상 기법 데이터 비식별화 기법을 위한 메모리 병렬처리 기법
연구결과	• 기존 익명화 알고리즘을 GPGPU에 맞게 활용하기 위해 병렬도를 높일 수 있도록 수정한 알고리즘 개발 • 병렬처리를 할 때 분기문이 존재할 경우 2배의 실행 시간이 소요되어 분기문을 최소화한 알고리즘 적용 • CPU-GPU간 데이터 전송을 최소화하여 성능 개선
구체적인 내용	• 기존 데이터 비식별화 기법들은 기법을 적용하는데 있어 속도가 느리며 대용량 데이터를 처리함에 있어서 한계를 지닌다. 차세대 하드웨어인 GPGPU를 이용하여 처리속도를 향상하여 기존 비식별화 기법의 한계를 극복 가능 • GPGPU는 병렬 처리에 적합한 연산에서 뛰어난 연산 속도를 낸다. 하지만 기존 비식별화 기법은 병렬도가 현저히 낮다. 또한 GPGPU는 SIMD 모델을 사용하기 때문에 분기문이 존재할 경우 2배의 실행 시간이 소요된다. 따라서 기존 비식별화 알고리즘의 병렬도를 높이고 분기문을 최소화하는 비식별화 기법을 개발.

- 2차 년도(2016)

세부 연구목표	K.L.T 비식별화 고속처리 기술 (분산환경 중심)
연구개발 수행 내용	분산환경 기반 개인정보 고속 비식별화 기능
연구결과	• 기존 익명화 알고리즘을 분산 환경에 맞게 활용하기 위해 병렬처리 및 분산처리 할 수 있도록 수정한 알고리즘 개발 • 기존 단일머신 기반 익명화 알고리즘에서는 대용량의 익명화 처리가 불가능하여,scale-out이 가능하도록 알고리즘 적용
연구 수행 방법 (이론적·실험적 접근방법)	• 관련 연구 및 동향 분석 • MapReduce를 이용한 비식별화 알고리즘 설계 • 서버 클러스터 기반 익명화된 데이터 저장 방법 개발 • 익명화 데이터 모니터링 기술 개발 • 서버 클러스터를 이용한 분산 비식별화 처리 기술 개발
구체적인 내용	• 기존 익명화 알고리즘을 분산환경에 맞게 활용하기 위해 병렬처리 및 분산처리 할 수 있도록 수정한 알고리즘을 개발 • 기존 단일머신 기반 익명화 알고리즘에서는 대용량의 익명화 처리가 불가능하여, scale-out이 가능하도록 맵리듀스를 이용하는 익명화 알고리즘을 개발 • 익명화 알고리즘을 맵리듀스에서 효율적으로 수행하기 위한 다양한 최적화 진행

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

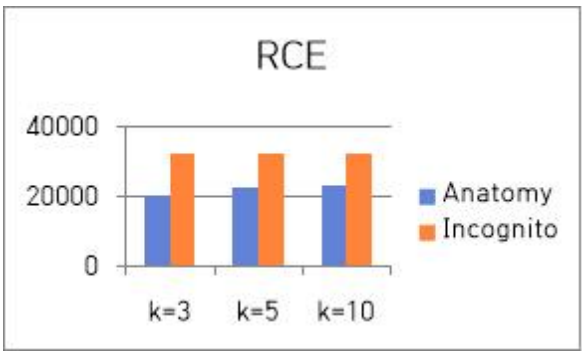
- 3차 년도(2017)

세부 연구목표	익명화 정도 및 재식별 가능성 측정 모델 개발 및 구현
연구개발 수행 내용	비식별 처리된 데이터의 익명화 정도를 측정하는 모델 개발
	비식별 처리된 데이터에 대하여 특정 배경지식을 사용한 추론 공격 시 예상되는 재식별 가능성 측정 모델 개발
	익명화 정도 및 재식별 가능성 측정 소프트웨어 개발(in-memory 및 분산 클러스터 환경)
연구결과	• 비식별화된 데이터가 얼마나 익명화 되어 있고, 재식별 공격 가능성이 있는지 측정하기 위하여 익명성과 재식별 가능성 수식 개발 • 익명성과 재식별 가능성을 인메모리 환경과 분산 환경에서 측정하는 알고리즘 개발
구체적 내용	• 익명화 정도 (Degree of Anonymousness, DoA) - 정의: 정해진 k-익명성(또는 l-다양성, t-근접성) 조건에 따라 익명화한 테이블에서 임의의 한 준식별자 조합에 부합하는 레코드를 동일한 준식별자 조합을 가지는 다른 레코드와 구분할 수 있는 정도 ◦ $DoA(r_i) = 1 - \frac{1}{\lvert EC_{r_i} \rvert}$ - 익명화된 테이블의 익명성 정도는 테이블에 존재하는 각 레코드의 익명성 정도의 평균으로 계산 ◦ $DoA(T') = \frac{\sum_{r_i \in T'} DoA(r_i)}{\lvert T' \rvert}$ • 재식별 가능성 (Probability of Re-identification, PoR) - 임의의 공격자가 배경지식으로 k-익명성(또는 l-다양성, t-근접성) 조건에 따라 익명화한 테이블에 존재하는 원본 레코드의 집합을 알고 있을 때, 익명화한 테이블이 k-익명성(또는 l-다양성, t-근접성) 조건을 만족하지 못할 확률 ◦ $PoR(T') = \frac{\lvert DEC(T', R) \rvert}{\lvert EC(T') \rvert}$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 4차 년도(2018)

세부 연구목표	정보손실 방지를 위한 통계적 정확성 유지 비식별화 기술
연구개발 수행 내용	기존 정보 손실을 줄이기 위한 비식별화 기술 및 모델 분석
	테이블 분리 기반 비식별화 기법 개발
	일반화 기반 비식별화 기법과 테이블 분리 기반 비식별화 기법의 통계적 유효성 비교
연구결과	• 통계적 유효성을 향상 시키기 위하여 테이블 분리 기반 비식별화 기법을 개발하였고, 추가적으로 일반화 기반 비식별화 기법 간의 성능 비교 진행
구체적 내용	• 가) 평가 방법 - 복원오류 (ReConstruction Error, RCE) - 각 레코드가 가질 수 있는 민감 속성 값의 확률 밀도 함수와 원본 레코드의 확률 밀도 함수의 차이를 계산하는 측정식 - $RCE = \sum_{\forall t \in T} \int_{x \in DS} (\widetilde{D}_t(x) - D_t(x))^2 dx$ - DS는 준식별자와 민감 정보를 포함한 차원 공간 $\widetilde{D}_t$는 원본 데이터의 확률 분포 함수 - D_t는 익명화된 데이터의 확률 분포 함수 • 사용데이터 - Adult dataset 데이터를 이용한 실험을 통해 개발한 테이블 분리 기반 비식별화 기술을 통하여 비식별화한 데이터의 복원 오류 측정 - Adult dataset - 데이터 속성: 7개의 칼럼 (6개의 준식별자, 1개의 민감 정보) - 30,162개의 레코드 - k=3, 5, 10 사용 - l=2 사용



[그림 97]Anatomy와 Incognito의 RCE 비교

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 연세대학교

가. 연구개발 목표 및 결과

비고	세부 연구 목표	연구개발 수행내용	연구 결과
1차년도 (2015)	비식별화 데이터에 대한 개인 시그네처 기반 실시간 클러스터링 기법 연구	가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행	- 비식별 변환된 대표레코드에 대해 개인 가상화 처리를 통한 가상 개인 시그네처 별 실시간 클러스터 생성
2차년도 (2016)	대표레코드의 그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구	실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별함	- 개인 식별 데이터 기반으로 생성한 개인별 클러스터와 개인 가상화 기반으로 생성된 비식별 클러스터의 유사성을 파악하여 사생활 유사도를 판별
3차년도 (2017)	개인 시그네처 기반 비식별화 데이터 빈발패턴, 연관규칙 탐사 기법 연구	빅데이터 처리 엔진(hadoop.등) 기반의 빈발패턴, 연관규칙 탐사 기법 연구	- Hadoop Spark 환경에서 실행하는 빈발패턴/연관규칙 알고리즘을 사용하여 비식별된 트랜잭션의 빈발패턴/연관규칙 탐사 - 비식별된 트랜잭션으로 개인 시그네쳐 및 대표 레코드/데그룹 트랜잭션으로 변환 시, 제거된 트랜잭션의 아이템 통계수치를 이용하여, 비식별된 트랜잭션으로 찾은 빈발패턴/연관규칙의 정확도 향상
		개인 시그네쳐 및 대표레코드/대그룹 트랜잭션 기반 빈발패턴/연관규칙 탐사 기법 연구	
4차년도 (2018)	실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/ 연관규칙 탐사 기법 연구	개인 시그네처 그룹 기반 실시간 빈발패턴/ 연관규칙 탐사 기법 연구	- 사생활 유사도를 기반으로 실시간 빈발패턴/연관규칙 알고리즘을 적용하여 데이터를 분석 수행
		실시간 빈발패턴/ 연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구	- 사생활 유사도 기반의 비식별 데이터 스트림 분석 결과의 정확도 향상을 위해 그룹 기반의 지지도 및 신뢰도 보정 기법을 연구하여 적용할 경우 유사도가 80% 수준으로 나타남

나. 수행 결과 요약

○ 비식별화 변환된 대표레코드에 대하여 적용 가능한 실시간 클러스터링 기법 연구

- 비식별화 데이터에 대한 개인 시그네쳐 기반 실시간 클러스터링 기법 연구, 가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행
- 대표레코드의 그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구, 실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

○ 비식별화 변환된 대표로그레코드에 대하여 적용 가능한 빈발패턴/연관규칙 탐사 기법 연구
- 비식별화 트랜잭션 DB 생성 기법 연구
- 빅데이터 처리 엔진(hadoop. 등) 기반의 빈발패턴, 연관규칙 탐사 기법 연구
- 개인 시그네쳐 기반 빈발패턴, 연관규칙 탐사 기법 연구
- 대표레코드/대그룹 레벨별 빈발패턴, 연관규칙 적용 방안 연구

○ 실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙 탐사 기법 연구
- 개인 시트네커 그룹 기반 실시간 빈발패턴/연관규칙 탐사 기법 연구
- 실시간 빈발패턴/연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구

다. 수행 결과 상세

○ 실시간 비식별 데이터스트림에 대한 빈발패턴의 상대적 유사도 측정
- 원본 비식별 트랜잭션과 사생활 유사도 기반 비식별 트랜잭션의 유사도 대비 빈발 패턴 결과 유사도
- 유사도 = (원본 – 비식별 트랜잭션 평균 유사도 / 원본 – 비식별 빈발패턴 평균 유사도)
예) 원본 트랜잭션과 비식별 트랜잭션의 평균 유사도 = 80%, 원본/비식별 빈발패턴 유사도 = 75%, 원본/비식별 트랜잭션 대비 빈발패턴 유사도 = 0.75 × 0.8 = 0.9375 (즉, 93.75%)
- 실험 결과
  · 임의의 각 다른 그룹에 속해 있는 4명의 개인에 대하여 개인별 빈발항목 집합의 비식별화 기법을 적용한 원본 비식별 트랜잭션 기반의 빈발항목 집합과 사생활 유사도를 기반으로 보정 기법을 적용한 빈발항목 집합의 유사도를 비교 분석함
  · 보정 전의 유사도가 평균적으로 약 20%가량이 높았으며, 보정 후의 유사도는 모든 유사 그룹이 85%이상의 유사도를 나타냄
- 일반화 원본 트랜잭션의 빈발패턴과 일반화 비식별 트랜잭션과의 유사도를 보정 전/후로 나누어 빈발패턴 결과 유사도를 구함
- 보정 전/후 빈발패턴 유사도 = (일반화 원본 트랜잭션 빈발패턴과 일반화 비식별 트랜잭션 빈발패턴 보정 전/후간 유사도)

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

마. 수행 결과물

○ 국내 및 국외 논문 게재

번호	논문명	학술지명	게재일	주저자명	호	국명	발행기관	SCI여부
1	개인정보 집계화를 통한 실시간 모니터링 시스템 설계 및 구현	2016춘계학술대회	2016.05.30	임영훈, 이원석	2016춘계학술대회 논문집	대한민국	한국IT서비스학회	비SCI
2	k-익명성 보장 비식별 빅데이터의 빈발패턴 정확도 향상 기술	2017 한국IT서비스학회 학술대회	2017.05.17	JIN SHUYAN, 이원석	2017 한국IT서비스학회 학술대회 논문집	대한민국	한국IT서비스학회	비SCI
3	개인정보 보호를 위한 동질 그룹 기반 개인별 실시간 클러스터링 기법	2017한국정보전자통신기술학회 춘계학술대회	2017.05.27	장연진, 이원석	2017한국정보전자통신기술학회 춘계학술대회 논문집	대한민국	한국정보전자통신기술학회	비SCI
4	비정형 트랜잭션의 비식별 처리 품질 평가	정보보호학회	2018년 동계학술대회	용우석, 이원석	-	대한민국	정보보호학회	비SCI

○ S/W 등록

번호	저작권 등록번호	제호	창작연월일	공표일자	등록일자
1	C-2019-002467	실시간 비식별화 빈발패턴 마이닝 엔진	2018.12.05	2019.01.24	2019.01.24

○ 지식재산권(특허)

번호	출원인	명칭	국명	출원일(등록일)	출원(등록)번호
1	연세대학교 산학협력단	비정형 트랜잭션 비식별 데이터의 품질 측정 기법	대한민국	2019-04-17	10-2019-0045149

○ 기술문서

NO	기술문서명
1	실시간 트랜잭션 일반화/비식별화 및 빈발패턴 마이닝 모듈 상세 설계 명세서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

나. 연차별 수행 내역 및 성과

- 1차 년도(2015)

세부 연구목표	대표레코드의 그루핑 속성/분포속성 기반의 사생활 유사도 판별 기술 연구
연구개발 수행 내용	실제 개인 클러스터와 가상 개인 대표레코드 별로 생성된 그리드 기반 클러스터들과 정확성을 파악하여 사생활 유사도를 판별함
연구결과	• 개인 식별 데이터 기반으로 생성한 개인별 클러스터와 개인 가상화 기반으로 생성된 비식별 클러스터의 유사성을 파악하여 사생활 유사도 판별

세부 연구목표	비식별화 데이터에 대한 개인 시그네처 기반 실시간 클러스터링 기법 연구
연구개발 수행 내용	가상화 데이터 스트림에 대해 시그네처(가상 개인) 별 실시간 그리드 기반 클러스터링 수행
연구결과	• 비식별 변환된 대표레코드에 대해 개인 가상화 처리를 통한 가상 개인 시그네처 별 실시간 클러스터 생성

- 3차 년도(2017)

세부 연구목표	실시간 비식별 데이터 스트림에 대한 사생활 보존 빈발패턴/연관규칙 탐사 기법 연구
연구개발 수행 내용	개인 시그네처 그룹 기반 실시간 빈발패턴/연관규칙 탐사 기법 연구 실시간 빈발패턴/연관규칙의 개인 시그네처 그룹 기반 지지도/신뢰도 보정 기법 연구
연구결과	• 사생활 유사도를 기반으로 실시간 빈발패턴/연관규칙 알고리즘을 적용하여 데이터를 분석 수행 • 사생활 유사도 기반의 비식별 데이터 스트림 분석 결과의 정확도 향상을 위해 그룹 기반의 지지도 및 신뢰도 보정 기법을 연구하여 적용할 경우 유사도가 80% 수준으로 나타남

- 4차 년도(2017)

세부 연구목표	실시간 비식별 트랜잭션 항목 일반화 기법 연구 및 빈발패턴 마이닝
연구개발 수행 내용	빅데이터에서 비식별 트랜잭션 항목 일반화 기법 연구 실시간 일반화된 비식별 트랜잭션 빈발패턴 마이닝 기법 연구
연구결과	• 실시간으로 들어오는 트랜잭션 항목에 대해 일반화 계층 테이블을 구성하고 일반화 정도를 선택하여 각 항목 계층 이동 일반화된 트랜잭션 분석 • 실시간으로 일반화 트랜잭션의 빈발패턴을 구하기 위해 스파크 스트림을 이용하여 FP-growth 알고리즘 구현하고 비식별화 처리 시 제거된 항목의 통계치를 이용하여 빈발패턴 결과를 보정할 경우 유사도가 80% 수준으로 나타남

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(3) 동덕여자대학교

○ 비식별 데이터의 통계적 유용성 검증 조사 연구

- 원본 데이터 기반의 통계적 분류 모형과 비식별 처리된 데이터의 통계적 분류모형의 비교
- 유용성 검증을 위해 정확도, 민감도, 특이도, 정밀도 측정

○ 국내 및 국외 논문 게재

번호	논문명	학술지명	게재일	주저자명	호	국명	발행기관	SCI여부
1	통계모형의 정확도에 기반한 비식별화 데이터의 품질 측정	한국콘텐츠학회논문지	2019.05	전희주	제5호	대한민국	한국콘텐츠학회	비SCI

○ S/W 등록

번호	저작권 등록번호	제호	창작연월일	공표일자	등록일자
1	C-2019-000087	비식별화 데이터 유효성 검증을 위한 R 통계 프로그램	2018.12.15	2018.12.15	2019.01.02

○ 기술문서

NO	기술문서명
1	비식별데이터의 통계적 유효성 검증

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4. 연구개발성과의 활용 계획 등

4-1. 목표향후 5년간 성과활용·확산 활용방안 및 계획(활동계획)

o 4차 산업혁명의 핵심인 빅데이터 플랫폼의 성장으로 인해 필수 요소인 비식별화 기법을 이용한 개인정보보호 기술의 활용은 시장규모가 급증할 것으로 예상된다.

o 금번 과제를 통해 핵심기술인 빅데이터에서 개인정보 식별 엔진개발, 개인정보 익명처리를 위한 비식별화 정보 생성 엔진 개발, 실시간 통합 관리 제어 엔진 개발을 완료하여 실제 시장에서의 “빅데이터 환경에서 비식별화 기법을 이용한 개인정보보호 기술개발”을 실증하였다.

o 빅데이터에서 개인정보 식별엔진 개발을 통해 정형, 비정형에서의 개인정보를 탐지하는 기술개발을 통해 서울시청 및 KDB산업은행 등 다양한 환경에서 적용하였다.

o 개인정보 익명처리를 위한 비식별화 정보 생성 엔진개발을 통해 국민권익위원회의 부패방지종합시스템에 올라오는 많은 민원글들을 익명처리하여 안전한 서비스를 지원하였다.

o 실시간 통합 관리 제어 엔진 개발을 통해 비정상 접근 및 오.남용과 부정사용에 대한 접근 제어 시스템을 구축하여 안전한 서비스 환경을 지원하였다.

o 현장에서 활용도가 높은 기술개발을 통해 다양한 제품군으로 시장에 적용예정이며, 1차적으로 기존 자사가 가지고 있는 고객사에 제품 판매를 고려하고 있다.

o 2018년 5월 25일 시행된 유럽연합 개인정보보호 규정인 GDPR 로 인해 국제적으로 프라이버시 보호에 대한 요구가 이루어지고 있어, 국내.외적으로 비식별처리에 대한 수요가 예상된다

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<연도별 주요 활동계획(요약표)>

구분	종료+1 (2020년)	종료+2 (2021년)	종료+3 (2022년)	종료+4 (2023년)	종료+5 (2024년)
빅데이터 환경에서의 정형, 비정형 데이터 수집 기술	다양한 로그수집 기술 정리 및 방안 연구	다양한 로그수집 기술 성능향상 연구	AI 기반 비정형 데이터 수집기술	DB 직접 수집 성능향상 기술	빅데이터 환경에서의 정형,비정형 데이터 수집 기술
빅데이터 환경에서의 비정형 개인정보 탐지 기술	이미지 데이터 개인정보 탐지기술	빅데이타 이미지 데이터 AI 기반 개인정보 탐지기술 향상	이미지 데이터 개인정보 탐지기술 성능향상	다양한 비정형이미지 확산	빅데이터환경 비정형 개인정보 탐지기술
인메모리기반 개인정보 비식별화 고속처리 기술	어플라이언스 전용 OS 기반기술 분석	어플라이언스 전용 OS 기반기술 분석	어플라이언스 전용 OS 기반기술 개발	어플라이언스 인메모리기반기술 개발	어플라이언스 인메모리 고속처리개발
개인정보 오용 및 부정 탐지 기술	개인화프로파일링기술	조직과 연계된 부정사용탐지기술	실시간 AI 연계 오남용 추출 기술	복합 AI 기반 오용 및 부정사용 탐지 기술	AI를 통한 통합모니터링 기술
비식별화 데이터에 대한 재식별 검증기술	데이터 유통모델 분석	데이터유통 기반기술 분석	유통데이타 추적기술분석	재식별 검증 기술 모델링	재식별 검증기술 개발
고객상담 서비스를 모델로한 개인식별 기술	실시간 개인정보탐지기술	정보주체자 검색 기술	행위기반분석	AI 연계 식별기술	AI 연계 식별기술
빅데이터 처리엔진기반의 병렬 익명화 처리 기술	빅데이타 병렬 프로세스 분석	빅데이타 병렬 프로세스 분석	빅데이타 병렬 프로세스 분석	병렬 익명화 처리기법	빅데이터 엔진기반 익명화 처리

4-2. 주요 성과활용 (기대)성과목표

(1) 정성적 목표

(가) 빅데이터 기반의 비식별 서비스

㉮ 분야별 비식별 개인정보보호 서비스

o 공공기관의 공공데이타 개방 관련 사업

- 공공 기관의 공공 데이터 개방이 가속화 됨에 따라 솔루션 위주의 개인정보 비식별 시스템 구축이 요구됨
- 기, 사업수행한 국민권익위 부패방지 시스템의 성과를 적극 홍보하여, 공공기관, 지자체에서 운영하고 있는 민원시스템에 개인정보 비식별화 사업을 추진코자 함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기업내 또는 기업 간의 엔터프라이즈형 빅데이터의 공유/연계 분석의 필요성이 지속적으로 증가하고 있음
- 한국전력공사의 개인정보비식별화 사업과 유사한 공공재 데이터, 개인 정보 및 포탈의 연계 서비스 등 엔터프라이즈 형태의 시스템 구축이 요구됨. 이에 따른 민간 분야의 엔터프라이즈 시스템 구축 모형을 제공코자 함.

o 영리기관의 빅데이타기반 데이타 비식별화 서비스
- B2B 비식별화 컨설팅 및 비식별 빅데이터 유통 서비스
- 기업의 개별 부처별로 운영하고 보유한 빅데이터를 어느 정도 수준으로 비식별화하고, 데이터 유용성을 얼마나 보존할 것인지 컨설팅하여 기업이 수행할 빅데이터 분석을 더욱 가치 있게 하는 서비스를 지원코자 함
- 이러한 기업에 비식별화 컨설팅 서비스를 제공하여 해당 기업의 여러 부서들에 분산된 빅데이터를 분석용으로 연계하여 매쉬업한 후 민감한 개인정보를 비식별화하여 개인 재식별이 불가능한 형태로 내부 또는 외부로 유통하는 서비스를 제공하여 수익을 창출코자 함
- 예를 들어, 컨설팅 서비스를 선행하고 컨설팅 결과에 적합한 비식별화 솔루션을 제공할 수 있음

o 클라우드 서비스 개인정보 비식별화
- 스타트업 기업 및 중.소벤처기업의 경우 시스템구축 보다는 클라우드 서비스를 이용한 데이터의 활용 및 분석을 활용함. 이에 클라우드 서비스 상의 개인정보 비식별화를 지원함으로써 다양한 가격정책 및 서비스를 지원할 수 있음.

o 판로확보 및 홍보 전략
- 신기술 홍보 전시회 및 포럼 참가
- 사전 시장 조사의 결과 활용
- 공공 및 민간(금융, 유통, 서비스 등)에 빅데이터 유통 판매 사업화
- 비식별화 개발기술을 통한 빅데이터의 공공목적으로의 활용
- 공공부문에서는 공공기관이 설립한 데이터 거래소나 금융 분야에서 새로이 신설되는 신용정보 집중기관 등에서 활용 예상
- 민간부문 활용방안에서는 민간 기업들에서 생산된 빅데이터를 유통 판매할 때 기본 솔루션으로 역할 기대
- 기업 네트워크를 통한 개인정보 비식별화 기술 추가 실증 및 서비스 제공
- 자체 솔루션 데모 영상 및 가이드 자료 제작을 통한 홍보 및 사업화 루트 개선
- 교육계 협력사와의 협업을 통한 교육 빅데이터 비식별화 기술 실증 수행 및 서비스 제공

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(2) 정량적 목표

<연도별 성과활용 (기대)성과목표(요약표)>

구분	종료+1 (2020년)	종료+2 (2021년)	종료+3 (2022년)	종료+4 (2023년)	종료+5 (2024년)
빅데이터 환경에서의 정형, 비정형 데이터 수집 기술	예상매출:5억 신규고용:2명	예상매출:10억 신규고용:3명	예상매출:15억 신규고용:5명	예상매출:20억 신규고용:6명	예상매출: 30억 신규고용:8명
빅데이터 환경에서의 비정형 개인정보 탐지 기술	예상매출:20억 신규고용:6명	예상매출:30억 신규고용:8명	예상매출:50억 신규고용:10명	예상매출:80억 신규고용:14명	예상매출: 100억 신규고용: 17명
인메모리기반 개인정보 비식별화 고속처리 기술	예상매출:5억 신규고용:6명	예상매출:15억 신규고용:8명	예상매출:30억 신규고용:12명	예상매출:60억 신규고용:20명	예상매출: 100억 신규고용:30명
개인정보 오용 및 부정 탐지 기술	예상매출:30억 신규고용:10명	예상매출:50억 신규고용:20명	예상매출:80억 신규고용:30명	예상매출:120억 신규고용:40명	예상매출:150억 신규고용:50명
비식별화 데이터에 대한 재식별 검증기술	-	-	예상매출:3억 신규고용:1명	예상매출:8억 신규고용:2명	예상매출:15억 신규고용:3명
고객상담 서비스를 모델로 한 개인식별 기술	예상매출:0.8억 신규고용:5명	예상매출:1억 신규고용:3명	예상매출:1.2억 신규고용:3명	예상매출:1.5억 신규고용:3명	예상매출:2억 신규고용:3명
빅데이터 처리엔진 기반의 병렬 익명화 처리기술	예상매출: 5억 신규고용: 5명	예상매출:10억 신규고용:6명	예상매출:15억 신규고용:8명	예상매출:25억 신규고용:10명	예상매출:40억 신규고용:12명

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4-3. 성과활용・관리 추진체계

(1) 기술개발 결과의 활용 방안

o 의료・보건 분야 활용 : 인플루엔자 현황 및 다양한 유행성 질병에 대한 동향, 질병의 위험도, 지역정보, 진료통계 등을 이용하여 유행을 예측하고 대비할 수 있도록 하여 국민 건강증진

o 신규 창업 분야 활용 : 카드 사용 트래픽 데이터 기반 과거 형황분석(과거 점포 이력 분석, 상권분석)등을 통해 미래 예측(업종 추천, 매출예측, 임대 시세 추정, 운영 투자비용 분석, 수익예측)을 통한 신규 창업 유도 및 창업 실패율 감소

(2) 기대효과

(가) 기술적 측면

① 국가 원천 기술 보유의 초석

o 개발하는 시스템은 대용량 데이터 익명화 기술의 집약체

o 대용량 데이터 익명화의 선구자 역할로 미래 IT분야 국가 경쟁력 강화에 기여

o 개체명 인식을 통한 비정형 개인정보 탐지 기술 확보

o 소프트웨어 중심의 연구 활성화 기대

o 분산 시스템 및 클라우드 컴퓨팅 프라이버시 보호 기술 발전에 기여

② 데이터 프라이버시 서비스 발전에 공헌

o 급증하는 데이터를 수용할 수 있는 대용량 데이터 익명화 기법

o 오랜 시간이 걸리는 디스크에서의 대용량 데이터 익명화를 인메모리를 이용한 고속, 병렬 구조에서의 대용량 데이터 익명화로 고속처리 가능

o 의학, 사회학, 경제학 등 다양한 데이터 분석을 필요로 하는 분야에 공헌 가능

③ 데이터 프라이버시 관련 기술 통합의 계기

o 개인정보 탐지에 대한 국가적 기술 기반 마련

o 제안 시스템은 현존하는 대부분의 익명화 기법들을 포함할 수 있음

o 나아가 대용량 데이터 익명화를 처리할 수 있는 기법 개발 및 최적화 실현

o 시스템 측면의 기술 통합 뿐 아니라 학술・이론적 측면으로도 의미 있는 연구 결과물(논문 및 특허) 배출

④ 데이터 프라이버시 처리 전문가 양성 및 배출

o 데이터 프라이버시 분야의 학・석・박사 인력 양성

o 데이터 프라이버시 관련 전문 개발자 양성 및 배출

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(나) 경제적, 산업적 측면

① 데이터 이용 산업 발전 기대

o 빅데이터 이용시 개인정보 유출에 대한 기술적 안전장치 개발비용 절감

o 새로운 데이터 익명화 기법에 따른 관련 기존 산업의 확대

o 분산 시스템에서의 데이터 익명화 기술을 이용한 신흥 산업 창조

o IoT 시대 도래에 따라 파생된 데이터 익명화 서비스 시장 확대

② 관련 기술을 기반으로 하는 차세대 산업의 시발점

o 다양한 데이터의 민감한 정보 비식별화 능력을 갖춘 차세대 대용량 데이터 익명화 시스템의 초석

o 스마트 기기, 센서 등에 적용되어 생성되는 공간 정보 및 관련 데이터 익명화 가능

③ 데이터 프라이버시 관련 일자리 창출

o 지속적인 데이터 증가와 시장규모 확대로 인한 인력 수요 증가 효과

o 신 연구 분야에 따른 이전에 존재하지 않던 일자리 생성

o 다양한 업종에서 데이터 보호를 위한 세부 직종의 등장

④ 데이터 보호에 소모되는 사회적 비용 감소

o 효율적인 데이터 관리 및 처리가 실현 되어 정부기관, 관공서, 기업 등에서 데이터 보호에 발생하는 비용 감소

o 민감한 정보를 관리하는 시스템에 적용되어 개인 정보 유출 피해 및 보상 비용 절감

o 대용량 데이터 익명화 기술의 대중화로 인한 소프트웨어 지출 비용 감소

(다) 사회적 측면

① 데이터 프라이버시의 효율적인 활용으로 인한 사회적 안전 보장 효과

o 대용량 데이터를 보호할 수 있는 시스템 개발로 인한 빠르고 정확한 데이터 익명화가 가능해져 개인 정보 유출 피해 감소에 기여

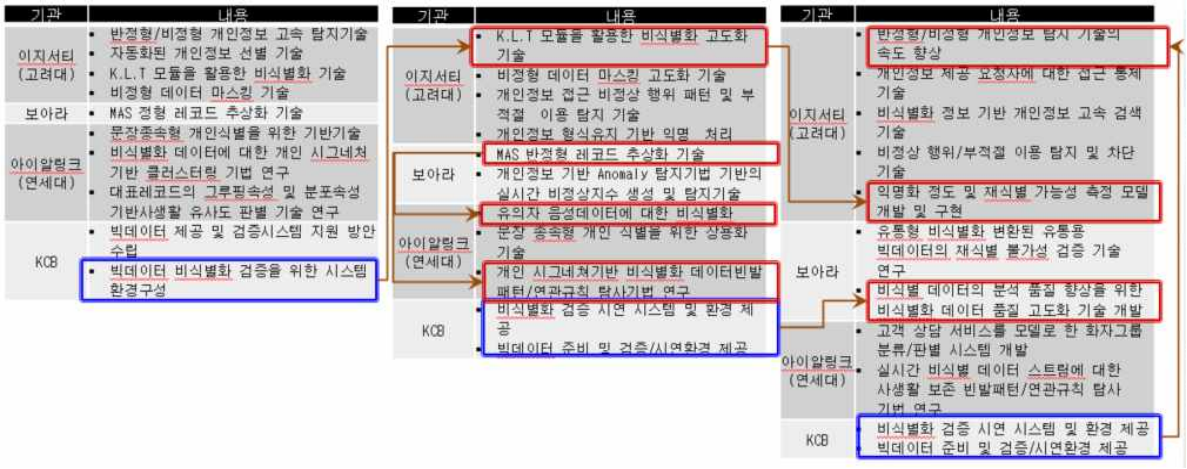
o 대용량 데이터 익명화 시스템 개발을 통해 차세대 디바이스들로부터 생성되는 본인도 인지하지 못하는 개인의 민감한 정보 보호

② 관련 연구 분야 중흥의 계기

o 데이터 프라이버시 연구 분야 확대 및 대용량 데이터 익명화 기법을 활용한 시스템 개발 활성화

o 빅데이터 처리, 서버-클러스터 환경 등 분산 컴퓨팅 프라이버시 분야의 연구 활성화

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



[그림 98] 추진체계

본 과제를 통해 주관기관 및 참여업체와 위탁기관은 다년간 협업하여 연구개발하여 주요 핵심.원천기술을 획득하였음. 결과물을 통해, 상호 유기적으로 연계 및 반영하여 시너지 있는 기술개발, 시스템, 서비스를 창출하였음.

향후, 핵심적인 개발과 서비스는 ㈜이지서티 주관으로 ㈜보아라와 함께 수행되나 가급적 서비스 모형을 통해 다양한 산업분야의 개발사와 협업 함으로써 개발의 효율성을 높이고 개발기간을 단축코자 함.

4-4. 기타

o 해당 없음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

[사업화대상기술 목록]

순번	기술명(국문)	관련특허(기술별로 중복기재 가능)	
		특허등록/출원 번호	특허명
1	빅데이터 환경에서의 정형, 비정형 데이터 수집 기술	PCT/KR2018/001463	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치
		10-2018-0074133	빅데이터의 전처리 방법 및 장치
		PCT/KR2018/001847	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템
		10-2018-0027783	빅데이터 비식별화 처리 시스템 및 방법
2	빅데이터 환경에서 비정형 개인정보 탐지 기술	PCT/KR2018/001463	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치
		10-0961870-0000	네트워크 계층별 검사를 통한 웹 보안 시스템 및 방법(이지서티 기보유 특허 활용)
		10-0991668-0000	보안정보 필터링 시스템 및 방법(이지서티 기보유 특허 활용)
3	인메모리기반 개인정보 비식별화 고속처리 기술	10-2018-0027783	빅데이터 비식별화 처리 시스템 및 방법
		PCT/KR2018/001463	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치
4	개인정보 오용 및 부정탐지 기술	10-1663288-0000	개인정보 모니터링 시스템 및 그 방법
		10-2016-0056559	네트워크에서 개인정보 시스템 접근로그 프로파일링을 위한 사용자 아이디 획득 방법
		10-1904901-0000	아이디 발급을 통한 원본 데이터 관리 방법 및 장치
5	비식별화 데이터에 대한 재식별 검증기술	10-1948603-0000	데이터의 유용성 보존을 위한 익명화 장치 및 그 방법
		10-1652328-0000	익명화 기법을 이용한 데이터 수집 방법 및 시스템
6	빅데이터 처리엔진 기반의 병렬 익명화 처리 기술	PCT/KR2019/006586	빅데이터의 비식별화 처리 방법
		PCT/KR2019/006586	빅데이터 개인정보의 익명화 및 익명화 데이터의 결합 방법
7	반정형 데이터 비식별화 기술	10-2018-0037705	무정형 빅데이터의 개인정보 비식별화 처리 방법
8	고객상담 서비스를 모델로한 개인식별 기술	PCT/KR2017/007627	개인 생체 정보의 비식별화 시스템 및 방법
		10-1946333-0000	콜센터의 개인 정보 비식별화 처리 시스템

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

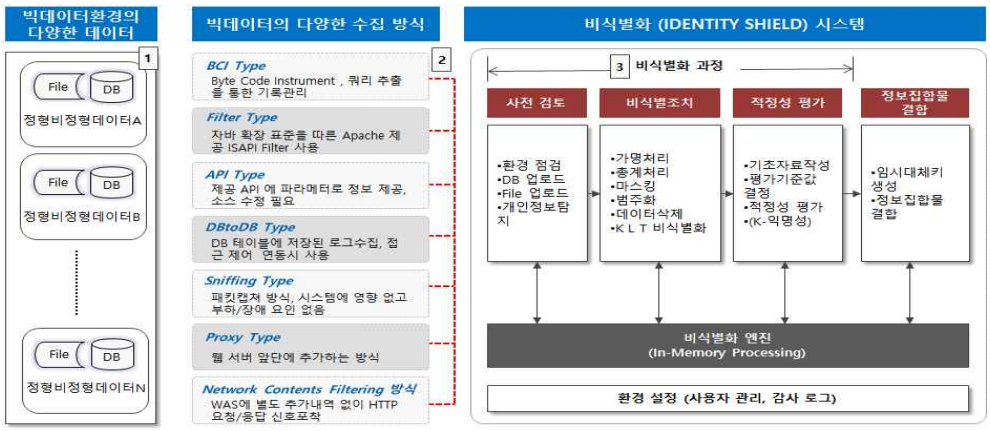
붙임 1. 사업화대상기술별 기술명세서

- 기술1

기술		
	국문	빅데이터 환경에서의 정형, 비정형 데이터 수집 기술
	영문	Formal, unstructured data collection technology in big data environment

기술 개요 및 특징 (이미지 필수)

- 다양한 정형, 비정형, 반정형의 데이터의 로그수집 기술 정리 및 방안 연구
- 다양한 레거시 시스템 및 인터넷의 빅데이터 로그수집 기술 성능향상 연구
- AI기반 비정형 데이터 수집기술DB 직접 수집 성능향상 기술
- 빅데이터 환경에서의 정형, 비정형 데이터 수집 기술



개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
							○	

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
		○				

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건	o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김동례	㈜이지서티	부대표	02-865-5577	drkim@easycerti.com
	연구자	-	-	-	-	-

활용(응용) 분야	o 빅데이터 플랫폼 연계 o 정형, 비정형 데이터 수집 파서 API 제공

관련 특허	발명의 명칭	출원번호	등록번호
	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT/KR2018/001463	10-1834503-0000
	빅데이터의 전처리 방법 및 장치	10-2018-0074133	-
	데이터 순서를 이용한 원본 데이터 확인 방법 및 시스템	PCT/KR2018/001847	10-184505-0000
	빅데이터 비식별화 처리 시스템 및 방법	10-2018-0027783	-

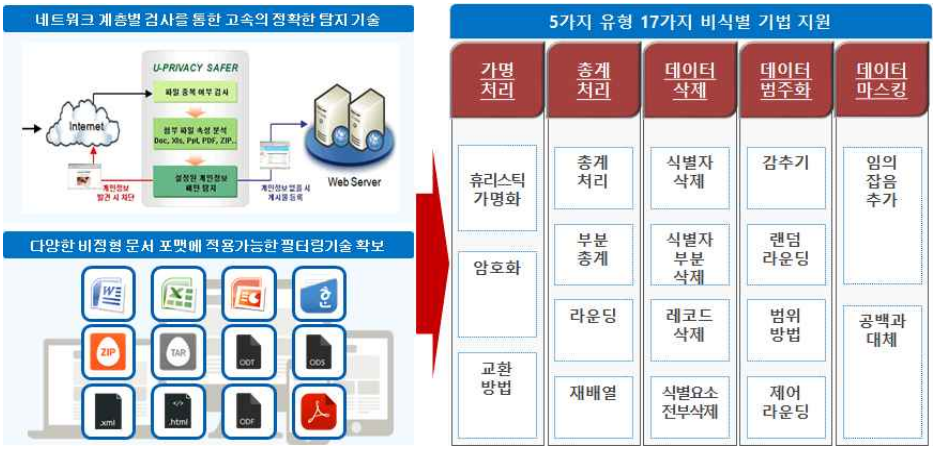
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술2

기술	국문	빅데이터 환경에서 비정형 개인정보 탐지 기술
	영문	Unstructured personal information detection technology in big data environment

기술 개요 및 특징 (이미지 필수)

-. 이미지 데이터 개인정보 탐지기술
-. 데이타 이미지 데이터 AI기반 개인정보 탐지기술 향상
-. 이미지 데이터 개인정보 탐지기술 성능향상
-. 다양한 비정형이미지 확산
-. 빅데이터환경 비정형 개인정보 탐지기술



개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
						○		

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건: o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김동례	㈜이지서티	부대표	02-865-5577	drkim@easycerti.com
	연구자	-	-	-	-	-

활용(응용) 분야: - 빅데이터 플랫폼에서 다양한 형태의 파일에서 개인정보 탐지
- 개인정보 비식별 전처리 단계에서 개인정보 식별

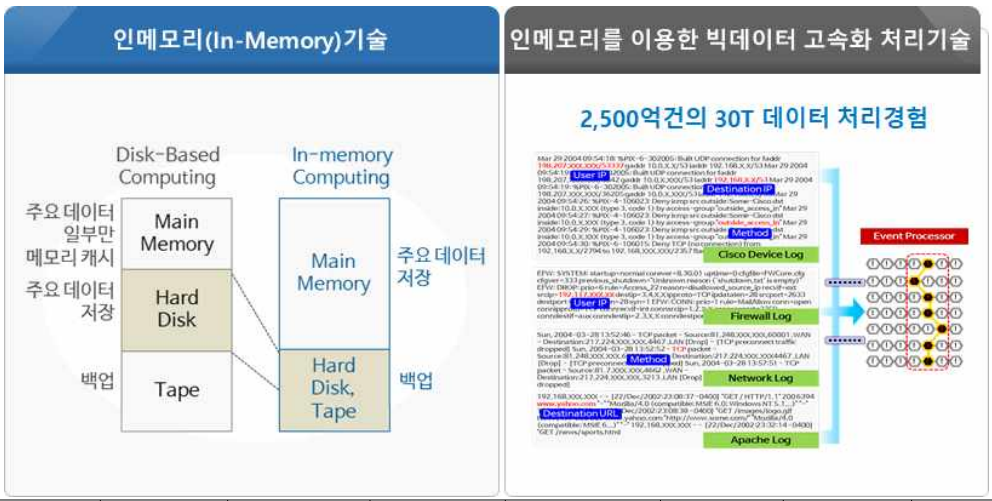
관련 특허	발명의 명칭	출원번호	등록번호
	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT/KR2018/001463	10-1834503-0000
	네트워크 계층별 검사를 통한 웹 보안 시스템 및 방법(이지서티 기보유 특허 활용)	-	10-0961870-0000
	보안정보 필터링 시스템 및 방법(이지서티 기보유 특허 활용)	-	10-0991668-0000

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술3

기술	국문	인메모리기반 개인정보 비식별화 고속처리 기술
	영문	In-memory based personal information non-discrimination high-speed processing technology

기술 개요 및 특징 (이미지 필수)	-. 어플라이언스 전용OS 기반기술 분석 -. 어플라이언스 전용OS 기반기술 개발 -. 어플라이언스 인메모리기반기술 개발 -. 어플라이언스 인메모리 고속처리개발



개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
					○			

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건	o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김동례	㈜이지서티	부대표	02-865-5577	drkim@easycerti.com
	연구자	-	-	-	-	-

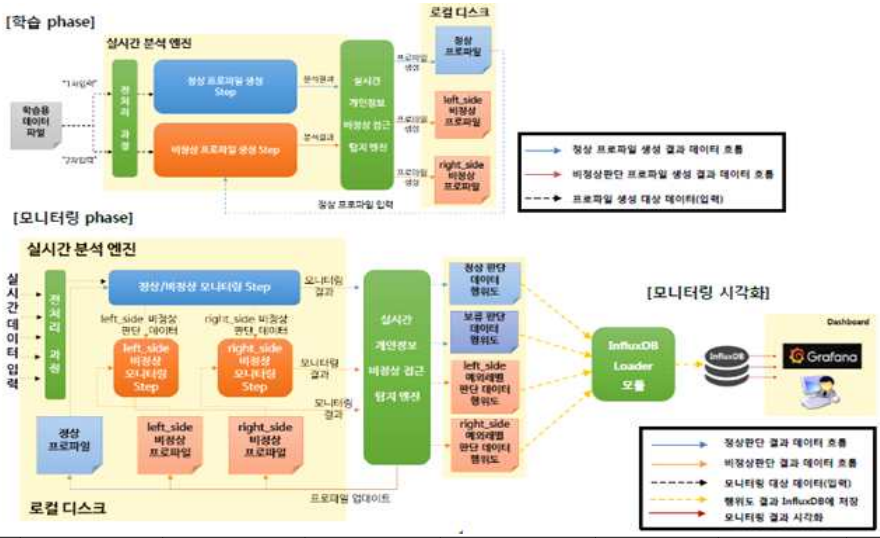
활용(응용) 분야	o 비식별화 및 익명화가 요구되는 산업,공공 분야 o 익명성을 유지하며 데이터 공유 및 연결이 필요한 산업 및 공공 분야

관련 특허	발명의 명칭	출원번호	등록번호
	빅데이터 비식별화 처리 시스템 및 방법	10-2018-0027783	-
	빅데이터 시스템에서 세션별 패킷 수집 기반 로그 생성 방법 및 장치	PCT/KR2018/001463	10-18345030-0000

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술4

기술	국문	개인정보 오용 및 부정탐지 기술
	영문	Personal information misuse and fraud detection technology

기술 개요 및 특징 (이미지 필수)	-. 개인화프로파일링기술 -. 조직과 연계된 부정사용탐지기술 -. 실시간 AI연계 오남용 추출 기술 -. 복합 AI기반 오용 및 부정사용 탐지 기술 -. AI를 통한 통합모니터링 기술 

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
							○	

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	○					

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건	o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김동례	㈜이지서티	부대표	02-865-5577	drkim@easycerti.com
	연구자	-	-	-	-	-

활용(응용) 분야	o 비식별화 및 익명화가 요구되는 산업,공공 분야 o 익명성을 유지하며 데이터 공유 및 연결이 필요한 산업 및 공공 분야

관련 특허	발명의 명칭	출원번호	등록번호
	개인정보 모니터링 시스템 및 그 방법	-	10-1663288-0000
	네트워크에서 개인정보 시스템 접근로그 프로파일링을 위한 사용자 아이디 획득 방법	10-2016-0056559	-
	아이디 발급을 통한 원본 데이터 관리 방법 및 장치	-	10-1904901-0000

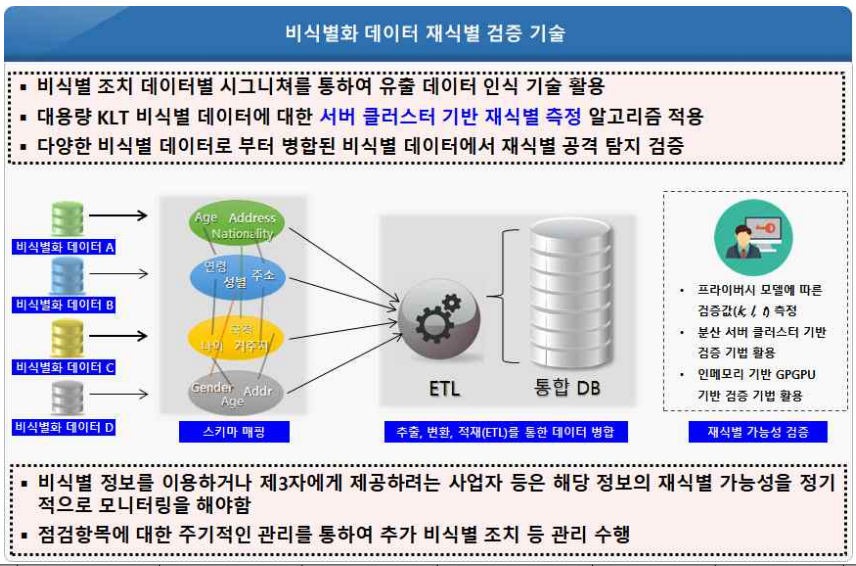
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술5

기술	국문	비식별화 데이터에 대한 재식별 검증기술
	영문	Re-identification verification technique for non-identifying data

기술 개요 및 특징 (이미지 필수)

-. 데이터 유통모델 분석
-. 데이터유통 기반기술 분석
-. 유통데이타 추적기술분석
-. 재식별 검증 기술 모델링
-. 재식별 검증기술 개발



개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
					○			

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
		○				

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건	o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김동례	㈜이지서티	부대표	02-865-5577	drkim@easycerti.com
	연구자	-	-	-	-	-

활용(응용) 분야	o 비식별화 및 익명화가 요구되는 산업,공공 분야 o 익명성을 유지하며 데이터 공유 및 연결이 필요한 산업 및 공공 분야

관련 특허	발명의 명칭	출원번호	등록번호
	데이터의 유용성 보존을 위한 익명화 장치 및 그 방법		10-1948603-0000
	익명화 기법을 이용한 데이터 수집 방법 및 시스템		10-1652328-0000

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술6

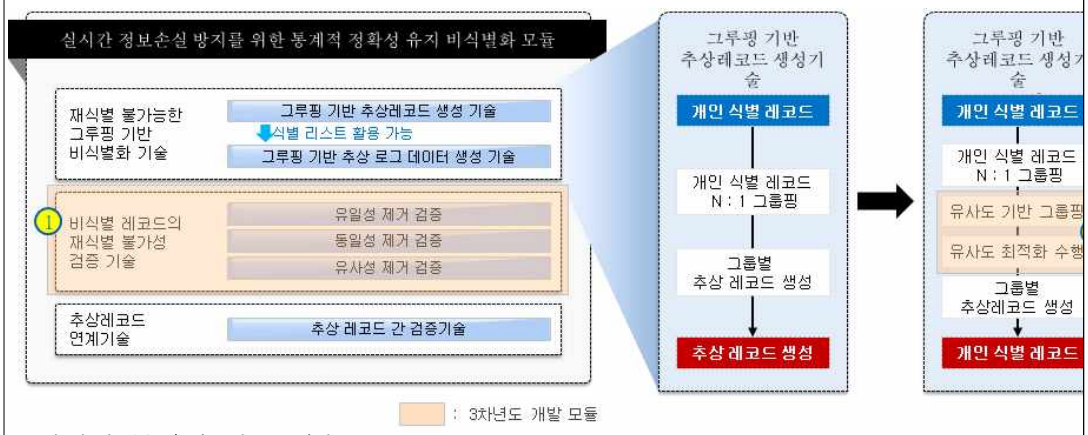
기술	국문	빅데이터 처리엔진 기반의 병렬 익명화 처리 기술
	영문	Abstraction method for de-identification and anonymization

기술 개요 및 특징 (이미지 필수)

o 정형 데이터의 추상레코드화 비식별화 기술
- N개의 원본 레코드들을 묶어 유사한 속성값들을 가지는 N명의 개인들에 해당하는 레코드를 1명의 레코드로 비식별 수행
- 유일성, 동일성, 연속성을 제거하여 대표 레코드의 재식별 가능성 제어를 검증



o 추상화 기술 품질 고도화
- 재식별 가능성 제거 프로세스 내장하고 있고, 유사 레코드 별 그룹화 기술을 기반으로 한[최대~최소] 범주 내 유사도 최적화 기술
- 추후 분석 알고리즘을 고려한 총계처리 함수를 다양화하고, K익명성/L다양성 프라이버시 모델 보장 가능



o 재식별 불가성 검증 기술
- 원본 데이터 세트에서 유일한 속성값(혹은 속성값 조합)을 동일하게 비식별 데이터에 검색했을 때에도 해당 레코드 조합이 유일하게 찾아진다면 상황으로 판단하여 검출
- [유사성 제거/ 유일성 제거 / 동일성 제거] 지표를 재식별 불가성 성질로 정의하고 이를 검증

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
							○	

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	○		○			

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
							○	

기술이전 조건	o 기술료는 기술이전시 협의하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	강동헌	㈜보아라			
	연구자					

활용(응용) 분야	o 비식별화 및 익명화가 요구되는 산업,공공 분야 o 익명성을 유지하며 데이터 공유 및 연결이 필요한 산업 및 공공 분야

관련 특허	발명의 명칭	출원번호	등록번호
	빅데이터 개인정보의 익명화 및 익명화 데이터의 결합 방법	PCT/KR2018/016945	-
	빅데이터의 비식별화 처리 방법	10-2016-0071747	10-1784265

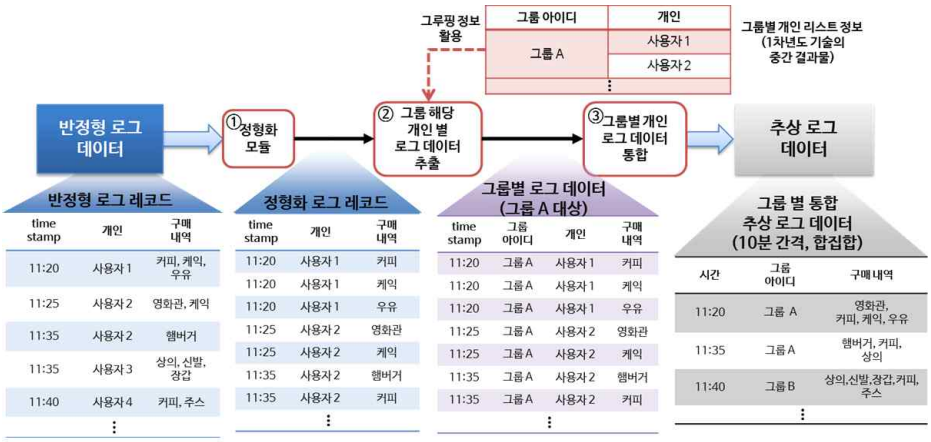
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술7

기술	국문	반정형 데이터 비식별화 기술
	영문	Semi-structured data de-identification method

기술 개요 및 특징 (이미지 필수)

o 반정형 로그 데이터의 추상로그데이터화 비식별화 기술
- 반정형 트랜잭션 형태의 개인 로그 데이터에 대한 비식별화 수행을 위해 트랜잭션 레코드를 디트랜잭션화(de-transactionize) 하여 정형화 변환함
- 정형화 로그 레코드에 대해 개인 신상 데이터의 그룹핑 정보를 연결하고, 그룹별 로그 데이터를 매핑 및 추출함



<반정형 로그 데이터의 추상화 기반 비식별화 예제>

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
					○			

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타
	○		○			

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
						○		

기술이전 조건	o 기술료는 기술이전시 협의하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	강동헌	㈜보아라			
	연구자					

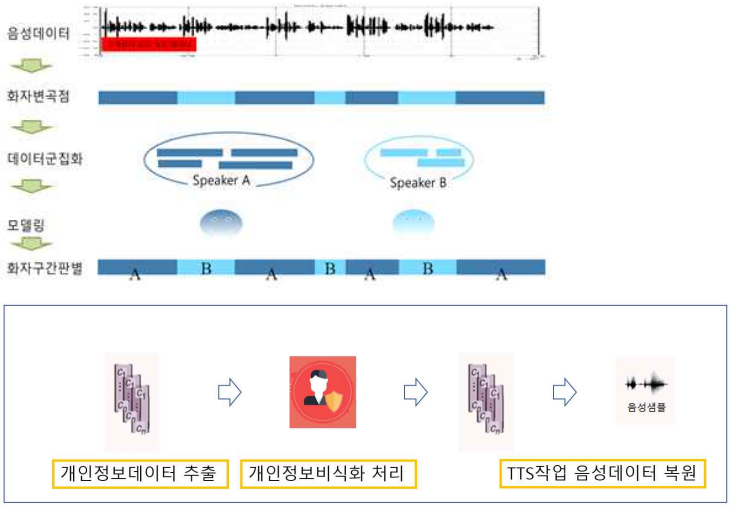
활용(응용) 분야	o 비식별화 및 익명화가 요구되는 산업,공공 분야 o 익명성을 유지하며 데이터 공유 및 연결이 필요한 산업 및 공공 분야

관련 특허	발명의 명칭	출원번호	등록번호
	무정형 빅데이터의 개인정보 비식별화 처리 방법	10-2018-0037705	-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 기술8

기술		
	국문	고객상담 서비스를 모델로 한 개인식별 기술
	영문	Masking personal information in recorded data and converting it back to voice data API

기술 개요 및 특징 (이미지 필수)	음성 데이터는 개인의 생체정보 및 개인정보가 포함되어 있어 유통이 불가능하며 매우 민감한 문제가 있다. 이를 개인 생체 정보의 비식별화 시스템 및 방법을 통해 음성 데이터를 유통 하고자 한다. 음성 파일이 미리 저장되는 음성파일 데이터에서 화자에 관련된 데이터의 화자별 변곡점을 추출하고 데이터를 군집화 하여 모델링을 통해 Text화 하고 파일로 변환하는 STT 엔진(speech to test engine)을 이용하여 변환을 한다. 텍스트 파일에서 개인 정보를 추출하여 마스킹(masking)등의 비식별화 처리를 통하여 데이터에서 개인정보를 변환 한다. 텍스트 파일을 음성 파일로 변환하는 TTS 엔진(text to speech engine) 모듈을 통해 개인 음성 생체 정보를 비식별화 하는 작업을 통해 음성 데이터의 샘플을 만들어 개인의 생체 정보와 개인 정보가 모두 비식별화 되 음성 데이터를 생성한다. 이를 통하여 음성 데이터를 유통 할 수 있다. 

개발상태	아이디어 창안	특허만 신청(등록)	기술개발 진행중	기술개발 완료	시제품 단계	실용화 단계	시장개척 단계	기타
		○			○			

희망거래 유형	기술매매	라이센스	기술협력	기술지도	M&A	기타

기술이전 금액	무료-500만원 이하	500만원 초과-1000만원 이하	1000만원 초과-2000만원 이하	2000만원 초과-3000만원 이하	3000만원 초과-5000만원 이하	5000만원 초과-1억원 이하	1억원 초과	기타
								○

기술이전 조건	o 기술료는 기술이전시 협의 하에 조정가능하며, 기술이전 후 시제품 개발시 기술지도 지원 가능

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

담당자	구분	성명	소속	직위	회사 전화번호	회사 이메일
	판매자 (TLO 등)	김대수	아이알링크(주)	부사장	02-6905-2800	dskim@irlink.co.kr
	연구자	-	-	-	-	-
활용(응용) 분야						
관련 특허	발명의 명칭				출원번호	등록번호
	개인 생체 정보의 비식별화 시스템 및 방법				PCT/KR2017/007627	-
	콜센터의 개인정보 비식별화 처리 시스템				-	10-1946333-0000

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 2. 참고문헌

- L. Sweeney, Uniqueness of simple demographics in the US population, Technical report, Carnegie Mellon University, 2000.
- L. Sweeney, “k-anonymity: A model for protecting privacy,” International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, vol. 10,no. 05, pp. 557-570, 2002.
- A. Machanavajjhala, et al., “l-diversity: Privacy beyond k-anonymity,” In TKDD, 2007.
- A. Meyerson and R. Williams, “On the complexity of optimal k-anonymity,” In SIGMOD, 2004.
- K. LeFevre, et al., “Incognito: Efficient full-domain k-anonymity,” In SIGMOD, 2005.
- K. LeFevre, et al., “Mondrian multidimensional k-anonymity,” In ICDE, 2006.
- J.-W. Byun, et al., “Efficient k-anonymization using clustering techniques,” Advances in Databases: Concepts, Systems and Applications, Springer, pp. 188-200, 2007.
- X. Zhang, et al., “A scalable two-phase top-down specialization approach for data anonymization using mapreduce on cloud,” In TPDS, 2014.
- Y. Hao, et al., “STK-anonymity: k-anonymity of social networks containing both structural and textual information,” Proc. Proceedings of the ACM SIGMOD Workshop on Databases and Social Networks, ACM, pp. 19-24, 2013.
- R. Chen, et al., “Privacy-preserving trajectory data publishing by local suppression,” Information Sciences, vol. 231, pp. 83-97.
- 이동주, 연종흠, 황인범, 이상구, 꼬꼬마: 관계형데이터베이스를활용한세종말뭉치활용도구, 2010, 정보과학회논문지: 컴퓨팅의실제및레터(Journal of KIISE: Computing Practices and Letters), 16(11) (2010), pp.1046-1050
- Jin Li, David Maier, Kristin Tufte, Vassilis Papadimos, Peter A. Tucker, “No pane, No gain: Efficient Evaluation of Sliding-Window Aggregates Over Data Streams”,SIGMOD Record 34(1):39-44,2005
- Nmap, http://nmap.org
- LEE, Hyukki, et al. Utility-preserving anonymization for health data publishing. BMC medical informatics and decision making, 2017, 17.1: 104.
- Holzinger A, Dehmer M, Jurisica I. Knowledge discovery and interactive data mining in bioinformatics-state-of-the-art, future challenges and research directions. BMC Bioinforma. 2014;15(6):1.
- Holzinger A, Jurisica I. Knowledge discovery and data mining in biomedical informatics: The future is in integrative, interactive machine learning solutions. In: Interactive Knowledge Discovery and Data Mining in Biomedical Informatics. Berlin: Springer; 2014. p. 1-18.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- Malle B, Kieseberg P, Schrittwieser S, Holzinger A. Privacy aware machine learning and the right to be forgotten. ERCIM News. 2016;107(10):22–3.
- Sweeney L. k-anonymity: A model for protecting privacy. Int J Uncertain Fuzziness Knowledge-Based Syst. 2002;10(05):557–70.
- Family Educational Rights and Privacy Act. 2015. Available at https://ed.gov/policy/gen/guid/fpco/ferpa.
- Guidelines for De-identification of Personal Data. 2016. Available at http://privacy.go.kr.
- Kieseberg P, Malle B, Fruhwirt P, Weippl E, Holzinger A. A tamper-proof audit and control system for the doctor in the loop. Brain Inform. 2016;3(4):269–79.
- Sweeney L. Achieving k-anonymity privacy protection usinggene ralization and suppression. Int J Uncertain Fuzziness Knowledge-Based Syst. 2002;10(05):571–88.
- Nergiz ME, Gok MZ. Hybrid k-anonymity. Comput Secur. 2014;44:51–63.
- Prasser F, Kohlmayer F, Kuhn KA. Efficient and effective pruning strategies for health data de-identification. BMC Med Inform Decis Making. 2016;16(1):49.
- Fung BC, Wang K, Fu AW-C, Philip SY. Introduction to Privacy-preserving Data Publishing: Concepts and Techniques. Boca Raton: CRC Press; 2010.
- Bayardo RJ, Agrawal R. Data privacy through optimal k-anonymization. In: Proceedings of the 21st International Conference on Data Engineering. Tokyo: IEEE Computer Society; 2005. p. 217–28.
- Iyengar VS. Transforming data to satisfy privacy constraints. In: Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and DataMining. Edmonton: ACM; 2002. p. 279–88.
- Xiao X, Tao Y. Anatomy: Simple and effective privacy preservation. In: Proceedings of the 32nd International Conference on Very Large Data Bases. Seoul: VLDB Endowment; 2006. p. 139–50.
- Xiao X, Tao Y. M-invariance: Towards privacy preserving re-publication of dynamic datasets. In: Proceedings of the 2007 ACM SIGMOD International Conference on Management of Data. Beijing: ACM; 2007. p. 689–700.
- Kohlmayer F, Prasser F, Eckert C, Kemper A, Kuhn KA. Flash: Efficient, stable and optimal k-anonymity. In: Proceedings of the 2012 ASE/IEEE International Conference on Social Computing and 2012 ASE/IEEE International Conference on Privacy, Security, Risk and Trust. Amsterdam: IEEE Computer Society; 2012. p. 708–17.
- El Emam K, Dankar FK, Issa R, Jonker E, Amyot D, Cogo E, Corriveau JP, Walker M, Chowdhury S, Vaillancourt R, et al. A globally optimal k-anonymity method for the de-identification of health data. J Am Med Inform Assoc. 2009;16(5):670–82.
- UCI Repository of Machine Learning Databases. 2013. Available at http://

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

archive.ics.uci.edu/ml.

- Health Insurance Review and Assessment Service in Korea. 2012. Available at http://opendata.hira.or.kr.
- Machanavajjhala A, Kifer D, Gehrke J, Venkitasubramaniam M. l-diversity: Privacy beyond k-anonymity. ACM Trans Knowl Discov Data (TKDD). 2007;1(1):3.
- Li N, Li T, Venkatasubramanian S. t-closeness: Privacy beyond k-anonymity and l-diversity. In: Proceedings of the 21st International Conference on Data Engineering. Istanbul: IEEE Computer Society; 2007. p. 106–15.
- Lin WY, Yang DC, Wang JT. Privacy preserving data anonymization of spontaneous ade reporting system dataset. BMC Med Inform Decis Making. 2016;16(1):58.
- Kohlmayer F, Prasser F, Eckert C, Kemper A, Kuhn KA. Highly efficient optimal k-anonymity for biomedical datasets. In: Computer-Based Medical Systems (CBMS), 2012 25th International Symposium On. Rome: IEEE; 2012. p. 1–6.
- Kohlmayer F, Prasser F, Kuhn KA. The cost of quality: Implementing generalization and suppression for anonymizing biomedical data with minimal information loss. J Biomed Inform. 2015;58:37–48.
- Byun JW, Kamra A, Bertino E, Li N. Efficient k-anonymization using clustering techniques. In: International Conference on Database Systems for Advanced Applications. Berlin: Springer; 2007. p. 188–200.
- LeFevre K, DeWitt DJ, Ramakrishnan R. Mondrian multidimensional k-anonymity. In: Data Engineering, 2006. ICDE'06. Proceedings of the 22nd International Conference On. Atlanta: IEEE; 2006. p. 25–5.
- KIM, Soohyung; CHUNG, Yon Dohn. An anonymization protocol for continuous and dynamic privacy-preserving data collection. Future Generation Computer Systems, 2017.
- K. LeFevre, D.J. DeWitt, R. Ramakrishnan, Incognito: Efficient full-domain k-anonymity, in: Proceedings of the 2005 ACM SIGMOD International Conference on Management of Data, ACM, 2005, pp. 49–60.
- K. LeFevre, D.J. DeWitt, R. Ramakrishnan, Mondrian multidimensional k-anonymity, in: Data Engineering, 2006. ICDE'06. Proceedings of the 22nd International Conference on, IEEE, 2006, pp. 25–25.
- B. Fung, K. Wang, P.S. Yu, Anonymizing classification data for privacy preservation, IEEE Trans. Knowl. Data Eng. 19 (5) (2007) 711–725.
- G. Ghinita, P. Karras, P. Kalnis, N. Mamoulis, Fast data anonymization with low information loss, in: Proceedings of the 33rd International Conference on Very Large Data Bases, VLDB Endowment, 2007, pp. 758–769.
- J.-W. Byun, A. Kamra, E. Bertino, N. Li, Efficient k-anonymization using clustering

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

techniques, in: Advances in Databases: Concepts, Systems and Applications, Springer, 2007, pp. 188–200.

- L. Sweeney, k-anonymity: A model for protecting privacy, Int. J. Uncertain. Fuzziness Knowl.-Based Syst. 10 (05) (2002) 557–570.
- A. Machanavajjhala, D. Kifer, J. Gehrke, M. Venkitasubramaniam, l-diversity: Privacy beyond k-anonymity, ACM Trans. Knowl. Discov. Data. 1 (1) (2007) 3.
- S. Zhong, Z. Yang, R.N. Wright, Privacy-enhancing k-anonymization of customer data, in: Proceedings of the Twenty-Fourth ACM SIGMOD-SIGACTSIGART Symposium on Principles of Database Systems, ACM, 2005, pp. 139–147.
- S. Zhong, Z. Yang, T. Chen, k-anonymous data collection, Inf. Sci. 179 (17) (2009) 2948–2963.
- M. Xue, P. Papadimitriou, C. Raissi, P. Kalnis, H.K. Pung, Distributed privacy preserving data collection, in: Database Systems for Advanced Applications, Springer, 2011, pp. 93–107.
- P. Samarati, Protecting respondents identities in microdata release, IEEE Trans. Knowl. Data Eng. 13 (6) (2001) 1010–1027.
- B. Fung, K. Wang, P.S. Yu, Top-down specialization for information and privacy preservation, in: Data Engineering, 2005. ICDE 2005. Proceedings. 21st International Conference on, IEEE, 2005, pp. 205–216.
- G. Ghinita, P. Karras, P. Kalnis, N. Mamoulis, Fast data anonymization with low information loss, in: Proceedings of the 33rd International Conference on Very Large Data Bases, VLDB Endowment, 2007, pp. 758–769.
- N. Li, T. Li, S. Venkatasubramanian, t-closeness: Privacy beyond k-anonymity and l-diversity, in: Proceedings of IEEE International Conference on Data Engineering, 2007, pp. 106–115.
- J. Cao, P. Karras, P. Kalnis, K.-L. Tan, SABRE: A Sensitive Attribute Bucketization and REdistribution framework for t-closeness, VLDB J. 20 (1) (2011) 59–81.
- Z. Yang, S. Zhong, R.N. Wright, Anonymity-preserving data collection, in: Proceedings of the Eleventh ACM SIGKDD International Conference on Knowledge Discovery in Data Mining, ACM, 2005, pp. 334–343.
- J. Brickell, V. Shmatikov, Efficient anonymity-preserving data collection, in: Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2006, pp. 76–85.
- J. Shi, R. Zhang, Y. Liu, Y. Zhang, Prisense: Privacy-preserving data aggregation in people-centric urban sensing systems, in: INFOCOM, 2010 Proceedings IEEE, IEEE, 2010, pp. 1–9.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- C. Cornelius, A. Kapadia, D. Kotz, D. Peebles, M. Shin, N. Triandopoulos, AnonySense: Privacy-aware people-centric sensing, in: Proceedings of the 6th International Conference on Mobile Systems, Applications, and Services, ACM, 2008, pp. 211–224.
- A. Kapadia, N. Triandopoulos, C. Cornelius, D. Peebles, D. Kotz, AnonySense: Opportunistic and privacy-preserving context collection, in: Pervasive Computing, Springer, 2008, pp. 280–297.
- M. Shin, C. Cornelius, D. Peebles, A. Kapadia, D. Kotz, N. Triandopoulos, AnonySense: A system for anonymous opportunistic sensing, Pervasive Mobile Comput. 7 (1) (2011) 16–30.
- A. Clarke, R. Steele, A smartphone-based system for population-scale anonymized public health data collection and intervention, in: System Sciences, HICSS, 2014 47th Hawaii International Conference on, IEEE, 2014, pp. 2908–2917.
- N. Malpani, J.L. Welch, N. Vaidya, Leader election algorithms for mobile ad hoc networks, in: Proceedings of the 4th International Workshop on Discrete Algorithms and Methods for Mobile Computing and Communications, ACM, 2000, pp. 96–103.
- S. Vasudevan, J. Kurose, D. Towsley, Design and analysis of a leader election algorithm for mobile ad hoc networks, in: Network Protocols, 2004. ICNP 2004. Proceedings of the 12th IEEE International Conference on, IEEE, 2004, pp. 350–360.
- J. Villadangos, A. Cordoba, F. Farina, M. Prieto, Efficient leader election in complete networks, in: Parallel, Distributed and Network-Based Processing, 2005. PDP 2005. 13th Euromicro Conference on, IEEE, 2005, pp. 136–143.
- V.S. Iyengar, Transforming data to satisfy privacy constraints, in: Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2002, pp. 279–288.
- X. Xiao, Y. Tao, Anatomy: Simple and effective privacy preservation, in: Proceedings of the 32nd International Conference on Very Large Data Bases, VLDB Endowment, 2006, pp. 139–150.
- T. Li, N. Li, J. Zhang, I. Molloy, Slicing: A new approach for privacy preserving data publishing, IEEE Trans. Knowl. Data Eng. 24 (3) (2012) 561–574.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

붙임 3. 자체 보안관리 진단표

구분	체크항목	결과 체크 (√표)	비고 (미실시 사유)
보안관리 체계	o 기관 내 보안관리규정을 제정/적용하고 있다	O(√), X( )	
	o 보안관리 조직이 있으며, 자체 보안점검실시 등 잘 운영되고 있다	O(√), X( )	
	o 보안교육을 정기적(1회이상/연)으로 실시하고 있다	O(√), X( )	
	o 보안사고에 대한 방지대책 및 비상시 대응계획이 준비되어 있다	O(√), X( )	
참여연구원 관리	o 참여연구원에 대하여 보안서약서를 받았다	O(√), X( )	
	o 참여연구원에게 보안관리의 중요성 등을 인식시키고 있다	O(√), X( )	
연구개발 내용/결과 관리	o 주요 연구자료 및 성과물의 무단유출 방지대책을 수립하고 있다	O(√), X( )	
	o 보안성 검토 방법 및 절차를 이행하고 있다	O(√), X( )	
	o 기술이전 관련 내부규정 및 절차를 준수하고 있다	O(√), X( )	
연구시설 관리	o 연구시설 보안관련 내부규정 또는 지침을 이행하고 있다	O(√), X( )	
	o 주요 시설에는 보안장비가 설치되어 있다	O(√), X( )	
	o 보호구역이 지정되어 있다	O(√), X( )	
정보통신망 관리	o 정보통신망 보안관련 내부규정 또는 지침이 구비되어 있다	O(√), X( )	
	o 보안관리 책임자의 승인 항목이 구분되어 있다	O(√), X( )	
	o 주요 데이터에 대해 백업을 실시하고 있다	O(√), X( )	
	o 개인용 정보통신장비(노트북, USB메모리)에 대하여 인가/관리중이다	O(√), X( )	
	o 전산망 보호를 위한 HW 및 SW 등을 도입하여 적용하고 있다	O(√), X( )	
	o 직책, 임무별 열람 권한을 차등화하여 부여하고 있다	O(√), X( )	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

주 의

1. 이 보고서는 과학기술정보통신부에서 시행한 정보통신·방송 연구개발사업의 보고서 입니다.

2. 이 보고서 내용을 발표하는 때에는 반드시 과학기술정보통신부에서 시행한 사업의 연구 개발 결과임을 밝혀야 합니다.

3. 국가과학기술 기밀유지에 필요한 내용은 대외적으로 발표 또는 공개하여서는 안됩니다.