국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

중견연구 최종보고서

① 부처사업명(대)	기초연구사업		보안등급(보안, 일반)	일반
② 사 업 명(중)	중견연구		공개가능여부(공개, 비공개)	공개
③ 세부사업명(소)	중견연구			
④ 과제성격(기초, 응용, 개발)	기초	④-1 실용화 대상여부(실용화, 비실용화)		비실용화
⑤ 연구개발과제명	국 문	안전한 인공지능 시스템 구현을 위한 적대적 공격 방어 기술 개발		
	영 문	Development of Effective Defense Techniques against Adversarial Attacks for Secure AI System		
⑥ 주관연구개발기관	서울대학교			
⑦ 연구책임자	성 명	이재욱	직급(직위)	교수
	소속부서	공과대학 산업공학과	전 공	인공지능/전문가시스템응용

⑧ 연구개발비 및 참여연구원수 (**단위: 천원**, M·Y)

연 도	정부지원 연구개발비 (A)	기업체부담금			정부외 출연금 (B)	상대국 부담금 (F)	합계 G=(A+B+E)	참여 연구원수
		현금 (C)	현물 (D)	소계 E=(C+D)				
1년차	150,000			0			150,000	10
2년차	150,000			0			150,000	10
3년차	150,000			0			150,000	11
4년차	150,000			0			150,000	11
5년차	150,000			0			150,000	5
합계	750,000	0	0	0	0	0	750,000	47

⑨ 총연구개발기간	2019.03.01 ~ 2024.02.29 (60개월)

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재 처분 등의 불이익도 감수하겠습니다.

2024 년 3 월 20 일

연구책임자 : 이 재 욱

주관연구개발기관의 장 : 서울대학교 산학협력단장

과학기술정보통신부장관 귀하

※ 전자접수이므로 연구책임자 및 주관연구개발기관의 장 서명(인, 직인)은 생략

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 연구결과 요약문 〉

연구개요	본 연구는 안전한 인공지능 시스템 구현을 위한 적대적 공격의 방어 기술을 개발하는 것을 목표로 함. 최근 자연어 처리, 이미지 처리 등의 딥러닝 기술의 고도화로 인해 딥러닝이 사회 전반에 많은 영향을 끼치고 있음. 하지만, 인공지능 모델은 학습 데이터에 많이 의존하는 경향을 보이며, 이로 인해 악의적인 공격에 취약한 모습을 보임. 실제로 인간의 눈으로는 구별 불가능한 이미지에 아주 작은 차이만을 주어 학습된 모델을 속이는 적대적 공격(adversarial attack) 기술이 밝혀짐.
연구 목표대비 연구결과	본 과제에서는 적대적 공격 방어 기술 개발을 통해 일반화 성능을 개선하고, 적대적 공격에 강건한 통합 모델을 개발함. 또한, 적대적 공격 외에 다양한 공격을 대비할 수 있는 통합 프레임워크를 제안하고자 함. 1차년도에는 표현학습 기술 및 적대적 공격 방어 기술의 개발을 통해 차년도 기반 기술을 확보하였으며, 다양한 보안 문제와 강건성에 대한 연구를 진행함. 2차년도에는 Multi-basin 동적 시스템을 이용한 클래스 최대 분리 임베딩 기술을 개발해 다양한 제약조건에서 안정적으로 작동하는 군집화 방법론을 도입함. 또한, 동형암호 기법을 활용해 알고리즘에 대한 예측할 수 없는 공격에 대해서도 방어를 실현함. 3차년도에는 도메인 적응을 활용한 적대적 공격 방어 알고리즘을 개발하기 위해 강건성을 가지는 모델을 분석하고, 평등성을 해치는 공격에 대한 방어를 위해 평등 군집화 방법을 제안함. 4차년도에는 표현 공간 탐색을 이용해 적대적 예제를 판별하고, 다양한 공격 시나리오를 방지하기 위해 동형암호와 차분 정보보호 기법을 연구함. 순차적 커미티 머신 개발을 위해 시계열 데이터를 포함하는 다양한 공격 시나리오에 대한 통합 방어 시스템을 구축함. 5차년도에는 적대적 공격에 강건한 통합 시스템을 개발하기 위해 강건성과 관련된 지표를 규명하고 새로운 적대적 학습 방법을 제안함. 또한, 다양한 공격 시나리오를 방지하기 위한 개인정보 보호 기법을 개발했으며, 시계열 데이터, 음성 데이터 등 다양한 데이터를 활용한 통합 시스템을 개발함. 본 과제의 정량적 결과로 상위 10% 저널 3편을 포함한 총 25편의 SCI(E), SSCI 논문을 게재하였으며, 특허 등록/출원 9건, 그리고 14회의 국제학회에서 연구결과를 발표함으로써 기존의 연구 목표를 달성함.
연구개발성과의 활용 계획 및 기대효과 (연구개발결과의 중요성)	본 연구개발성과는 향후 인공지능 기술 증가에 따른 사회 및 경제적 변화에 중요한 기여를 할 것으로 기대됨. 특히 적대적 공격에 강건한 안전한 인공지능 모델은 자율주행 자동차 등에서 발생할 수 있는 사회적 문제를 해결하는 데 중요한 역할을 할 것임. 본 연구개발 과제에서 개발된 적대적 공격 방어 기술은 적대적 노이즈 공격을 넘어서 프라이버시 보호 등 노이즈를 활용하는 다양한 연구 분야에서 중요한 역할을 할 것으로 예상됨. 이는 추후 인공지능 분야 연구에서 핵심 기술 중 하나가 될 것으로 예상됨. 또한, 안전한 인공지능 모델 개발을 목표로 하는 본 과제는 표현 학습 및 도메인 적응 분야에서의 기술적 발전을 촉진할 것으로 예상됨. 본 연구결과는 안전한 인공지능 기술을 필요로 하는 관련 기업 및 산업체로의 활용 가능성이 있으며, 관련 기관과의 산학협력을 통해 타 응용 분야로의 파급 효과가 기대됨.

중심어	**국문**	적대적 공격	매니폴드 학습	동적 시스템	도메인 적응	강건성
	영문	Adversarial attack	Manifold learning	Dynamical system	Domain adaptation	Robustness

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 목 차 〉

1. 연구개발과제의 개요 ····· 04
2. 연구개발과제의 수행 과정 및 수행 내용 ····· 06
3. 연구개발과제의 수행 결과 및 목표 달성 정도 ····· 06
4. 연구개발성과의 관련 분야에 대한 기여 정도 ····· 16
5. 연구개발성과의 관리 및 활용 계획 ····· 16
6. 자체점검표 ····· 17
7. 참고문헌 ····· 17

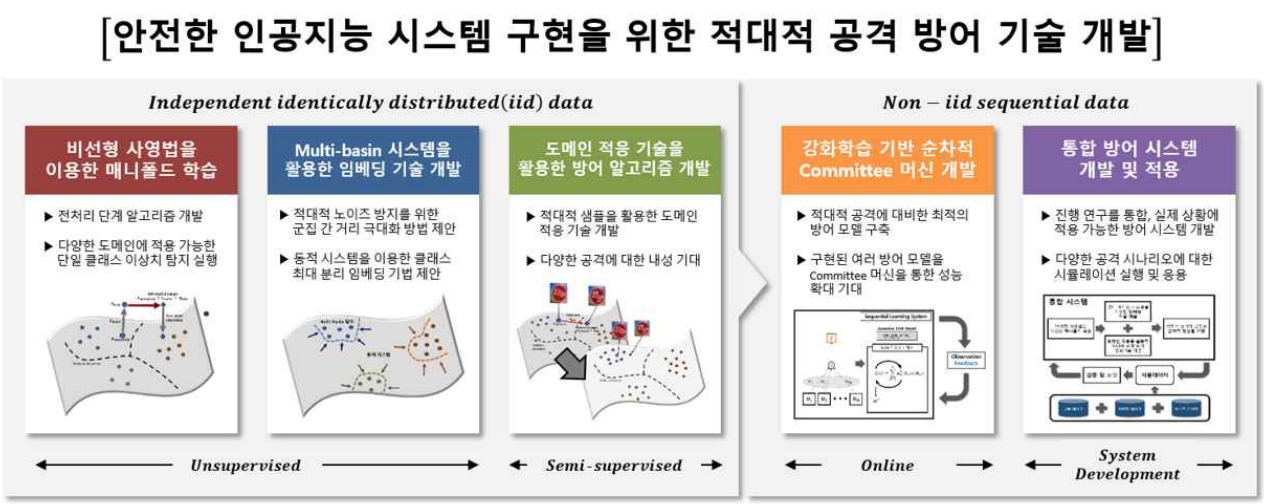
<붙임1 세부 정량적 연구개발성과> ····· 19
<붙임2 연구책임자 대표적 연구실적 및 증빙(요약문 및 사본)> ····· 28

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1. 연구개발과제의 개요

가. 연구개발의 목적

- 본 연구개발의 목적은 안전한 인공지능 시스템 구현임. 최근 딥러닝 기술의 발달 및 대용량 데이터 활용에 대한 필요성 증가로, 인공지능 기반 정보처리 시스템 사용이 늘어나는 추세임.
- 대용량 데이터에 대한 인공지능 모델의 효율적 학습 기술의 발달로 적대적 공격에 대응하는 방어 기술 확보는 필수적임.
- 본 연구진은 비선형 사영법(non-linear projection), 임베딩(embedding), 도메인 적응(domain adaptation) 기술, 시계열 데이터 처리 기반 순처적 커미티 머신, 그리고 통합 방어 시스템 개발을 통해 일반적인 상황에서도 적대적 공격에 강건한 인공지능 시스템을 개발하고자 함.
- 본 연구의 최종 목표와 각 연차별 세부 연구 가설은 다음과 같음.



[그림] 본 연구 과제의 목표

나. 연구개발의 필요성

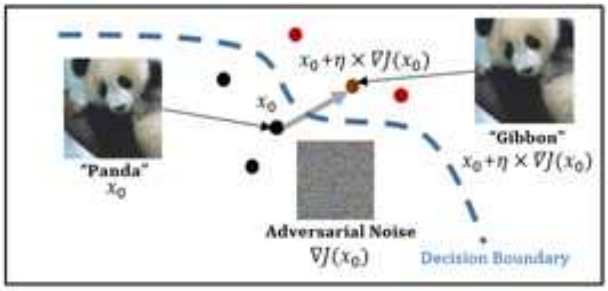
비선형 사영법을 이용한 매니폴드 학습 기술 개발의 필요성

- 인공지능 모델 학습에 사용되는 실제 데이터는 데이터 수집과정이나 전처리 과정 방식에 의해 다양한 형태의 노이즈가 발생하여, 인공지능 모델의 입력값은 매니폴드 상에서 닫힌 형태의 수식으로 표현되기 어려운 노이즈가 추가된 형태임.
- 이러한 상황에서 매니폴드 학습은 주어진 데이터가 원래의 고차원 공간에서 어떻게 생성되었는지를 모델링하는 기술로서, 비선형 사영법을 활용하여 데이터의 복잡한 구조를 파악하고 이를 학습하는 것을 의미함.
- 비선형 사영법 기반 매니폴드 학습을 통해 데이터의 고유한 특징을 추출하고 노이즈에 강건한 표현을 생성할 수 있으며, 이는 적대적 공격으로부터 모델을 보호하는 데 매우 유용함.
- 실제 데이터에 적대적 노이즈를 추가한 적대적 데이터 샘플은 적대적 공격에 강건한 인공지능 모델 구축에 필수적이나, 실제 데이터에 대한 적대적 공격은 모델이 데이터에 적대적 노이즈뿐만이 아닌 다른 어떠한 노이즈가 추가 되었는지 알 수 없기 때문에 효과적인 방어 전략을 구축하기 어려움.
- 따라서, 적대적 샘플을 사영할 수 있는 매니폴드 학습은 안전한 인공지능 모델 개발에 필수적임. 학습된 매니폴드를 바탕으로 multi-basin 탐색, 동적 시스템, 그리고 딥러닝 기술을 적용하여 적대적 공격에 효과적으로 방어할 수 있을 것으로 기대됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Multi-basin 동적 시스템을 이용한 임베딩 기술 개발의 필요성

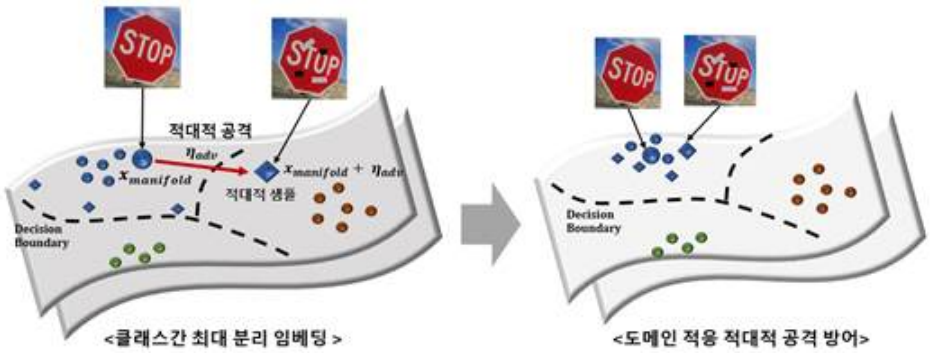
- 아래 그림과 같이 적대적 노이즈를 더해 잠재 공간(latent space)에서 분류기의 결정 경계(decision boundary)에 혼란을 주는 적대적 공격에 방어하기 위하여 군집 간 거리를 떨어뜨리고, 군집 내 데이터 샘플을 수렴하게 할 수 있는 기술이 필요함.
- 이를 가능하게 하기 위하여 multi-basin 탐색 및 동적 시스템 기반 클래스 최대 분리 임베딩 기술이 필요함. 이는 커널 방법론의 특성 변환을 인공 신경망으로 변환하여 고차원으로 확장시키는 알고리즘을 기반으로 함.
- Multi-basin 동적 시스템 기반 임베딩 기술 개발을 통하여 적대적 노이즈가 포함된 데이터의 임베딩을 효과적으로 조작하여 분류기의 결정 경계를 보호할 것으로 기대됨.



[그림] 잠재 공간에서의 적대적 공격 예시

도메인 적응을 활용한 적대적 공격 방어 알고리즘 개발의 필요성

- 도메인 적응은 딥러능 알고리즘을 라벨이 없는 분포가 다른 데이터에도 적용할 수 있게 하는 방법임. 이는 적대적 샘플이 기존의 분류기로 정상 샘플로부터 잘 분리될 수 있도록 하는 기술에 활용될 수 있음.
- 같은 클래스로 분류된 적대적 샘플과 실제 샘플이 같은 결정 경계 내로 분류되는 모델 개발을 통해 적대적 공격 방어에 대한 알고리즘을 개발할 수 있음.
- 이를 통해 아래 그림과 같이 도메인 적응을 활용한 적대적 공격 방어 예상 모식도를 달성할 수 있으며, 강력한 적대적 공격이 와도 같은 결정 경계 내에 적대적 샘플이 분포하는 모델을 구축할 수 있을 것으로 기대됨.



[그림] 도메인 적응 적대적 공격방어의 예상 도식

시계열 데이터 처리 기반 순차적 커미티 머신 개발의 필요성

- 실제 적대적 공격이 들어오는 상황에서의 최적 방어가 가능한 모델 개발을 위하여 순차적 커미티 머신 개발이 필요함. 순차적 커미티 머신은 외부 환경 변화에 대한 대응을 업데이트한다는 점에서, 시계열 데이터와 같은 순차적 특성을 효과적으로 다룰 수 있는 기술이 뒷받침되어야 함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 적대적 공격 방어 인공지능 모델이 개발된 후 실제 상용화 시나리오에서는 실시간으로 적대적 샘플이 업데이트될 것이고, 이렇게 추가적으로 발생하는 데이터는 시계열 데이터의 특성을 따름.
- 따라서 적대적 공격에 안전하며 변화에 유연하게 대응할 수 있는 인공지능 모델을 위하여 시계열 데이터 처리 기반 순차적 커미티 머신 개발은 필수적임.

2. 연구개발과제의 수행 과정 및 수행 내용

● 1차년도: 본 연구진은 안전한 인공지능 시스템 구현을 위한 적대적 공격 방어 기술 개발을 목표로 하여 기반 기술을 확보하고자 하였음. 표현학습 기술 개발 및 적대적 공격에 대한 방어 기술의 개발을 통해 차년도의 기반 기술을 확보하였음. 이를 확장하여 시계열 데이터 도메인에서 발생할 수 있는 보안 문제와 모델의 강건성에 대한 연구를 진행하였음.

● 2차년도: 1차년도의 연구를 바탕으로 multi-basin 동적 시스템을 이용한 클래스 최대 분리 임베딩 기술을 개발하였음. 먼저 같은 클래스의 샘플을 비슷한 위치로 임베딩 시킬 수 있는 방법론을 개발하였음. 그리고 다양한 제약조건에서 안정적으로 작동하는 multi-basin system과 basin을 군집으로 하는 군집화 방법론을 새로이 도입하였음. 또한 동형암호를 활용한 머신러닝 방법론을 multi-basin system으로 확장하여 알고리즘에 대한 예측할 수 없는 공격의 방어를 실현하고자 하였음.

● 3차년도: 본 연구진은 도메인 적응을 활용한 적대적 공격 방어 알고리즘을 개발하였음. 먼저 학습되지 않은 데이터에 대해서도 높은 성능을 보일 수 있는 도메인 적응 방법을 연구하였음. 나아가 확정 구간에서 강건성을 가지는 모델에 대한 분석을 기반으로 기존 방법을 확장시켜 좋은 성능을 달성하였음. 추가적으로 평등성을 해치는 공격에 대한 방어 기법으로 계층 군집화 기법을 바탕으로 하여 새로운 평등 군집화 방법을 제안하였음. 일련의 연구를 바탕으로, 본 연구진은 모델에 대한 다양한 공격을 대비하고자 하였음.

● 4차년도: 적대적 공격 상황에서 방어 가능한 모델을 개발하기 위해 표현 공간 탐색을 이용해 적대적 예제를 판별하는 방법론을 개발하였음. 또한, 적대적 공격 등 다양한 공격 시나리오를 막기 위해 동형암호와 차분 정보보호 기법을 연구하였음. 어떠한 상황에서도 안정적인 성능을 보일 수 있는 인공지능 시스템을 개발하기 위해 일반화 성능을 높이기 위한 연구를 진행하였음. 또한, 시계열 데이터를 포함하는 다양한 공격 시나리오에 대한 통합 방어 시스템 구축을 위해 금융 시계열 데이터를 활용하였음.

● 5차년도: 적대적 공격에 강건한 통합 시스템을 개발하기 위해 강건성이 모델의 어떤 지표와 관련되었는지 확인하고, 새로운 지표를 제안하였음. 또한, 강건성을 부여하는 새로운 적대적 학습 방법을 제안하고, 확률적 경사 하강법의 학습이 일어나는 부분 공간을 밝혔음. 음성, 시계열 데이터 등 다양한 데이터를 활용해 표현 공간을 탐색하고 일반화 성능을 향상시켰으며, 적대적 공격 외에도 다양한 공격 시나리오를 방지하기 위해 차분 프라이버시와 동형암호를 활용한 학습 기술을 개발하였음.

3. 연구개발과제의 수행 결과 및 목표 달성 수준

1) 정성적 연구개발성과(연구개발결과)

1차년도. 비선형 사영법을 이용한 매니폴드 학습

- 딥러닝을 활용한 클래스 의존적 표현학습 기술 개발

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 본 연구진은 딥러닝을 활용하여 적대적 공격 방어 시스템 구축을 위한 표현학습 기술을 개발함. 적대적 공격을 방어하기 위해서는 같은 클래스의 샘플을 비슷한 위치로 임베딩 시켜 적대적 샘플이 들어와도 결정 경계를 넘지 않게 임베딩해야 함. 이를 위해 본 연구진은 아래와 같은 새로운 손실함수를 제안함.

$$q_{ij} = \frac{e^{-\alpha\|z_i-\mu_k\|^2}}{\sum_k e^{-\alpha\|z_i-\mu_k\|^2}}, p_{ij} = \frac{(q_{ik})^n/f_k}{\sum_k (q_{ik})^n/f_k}, L_{suggest} = \sum_i \sum_j (p_{ij}\log\frac{p_{ij}}{q_{ij}})$$

[수식 1] 클래스 의존적 표현학습 손실함수

● 본 연구진은 개발된 표현학습 방법론을 도메인 적응 문제에 적용하였으며, 개발된 표현학습 방법론을 도메인 적응 문제에 적용함. 이러한 매니폴드 학습 기술을 활용하여 적대적 공격에 안전한 인공지능 시스템을 개발함.

- Sliced Wasserstein을 활용한 적대적 공격 방어 기술 개발

● 본 연구진은 적대적 공격 방어 시스템 개발을 위해, 기존의 적대적 학습 방법에 새로운 제약식을 추가하여 적대적 샘플이 들어오더라도 안정적으로 분류를 할 수 있는 방법론을 개발함. 본 연구진은 임베딩 공간에서 적대적 샘플과 정상 샘플의 두 분포 간의 sliced Wasserstein distance(SWD)를 줄이는 손실함수를 활용함. 이러한 방법을 사용할 경우, 적대적 공격에 강건한 매니폴드를 학습할 수 있음. 본 연구는 국제학회 AAAI workshop on EDSMLS에 accept됨.

$$L_{SWD}(X) = \frac{1}{|\Omega|}\sum_{\omega\in\Omega} = \mathrm{W}\left(\mathrm{Q}_\theta(\mathrm{X})^{\omega}, \mathrm{Q}_\theta(\mathrm{X}_{\mathrm{adv}})^{\omega}\right)$$

[수식 2] 정상 샘플과 적대적 샘플의 SWD 손실함수

- 베이지안 인공 신경망을 이용한 적대적 공격 방어 기술 개발

● 본 연구진은 개발된 적대적 공격 방어 기술을 일반적인 모든 인공 신경망에 적용하기 위한 연구로서, 베이지안 인공 신경망에 대한 적용을 목표로 연구를 진행함. 베이지안 인공 신경망에 적대적 공격 이미지를 활용한 적대적 학습을 단순 적용하는 것은 모델의 다양성이 작아지는 현상으로 인해 베이지안 인공 신경망이 가지고 있는 무작위성이란 장점을 극대화하지 못하는 것을 발견함.

● 베이지안 인공 신경망이 다양한 모델을 표현할 수 있도록 DPP(Determinant Point Process)를 도입하여 이러한 문제를 없애고자 하고, 기존 모델보다 안정적인 모델을 만들어 냄. 또한, 동일 연구에서 베이지안 인공 신경망이 가지고 있는 무작위한 정도에 따라 성능이 달라질 수 있음을 확인함. 본 연구의 성과는 APIEMS 2019에서 발표함.

- 시계열 데이터상의 적대적 공격 방어 알고리즘 개발

● 본 연구진은 실시간 적대적 공격이 가해지는 상황에서 최적의 방어 모델을 개발하기 위해 블록체인의 사례를 이용함. 블록체인은 발행된 거래의 유효성을 각 사용자가 검증하는데, 악의적 이용자가 검증될 수 없는 거래를 다량으로 발행하여 체인의 신뢰성을 감소시키는 공격이 가능함. 이를 해결하기 위해 본 연구진은 커미티 머신을 도입함. 거래의 유효성을 판단할 때 거래 자체가 아니라, 거래 발행자의 신뢰성에 주안점을 두어 발행자의 신뢰성을 시간의 흐름에 따라 업데이트하는 방식을 사용함. 이는 기존의 거래 신뢰성에 기반을 둔 마르코프 체인 몬테 카를로 방법보다 더 빠르고, 적은 메모리를 사용하는

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

방법임을 실험을 통하여 확인하였음.

● 노이즈를 갖는 시계열 데이터 분석을 위해, 가상화폐 가격과 연방공개시장위원회 회의와의 연관성 분석 연구를 진행함. 시계열 데이터에서 노이즈를 자기상관성의 계수 중 하나로 사용할 수 있음을 보임. 본 연구의 성과는 Finance Research Letter (IF : 5.596)에 게재됨.

- 동형암호를 활용한 커널 기반 머신러닝 방법론 개발

● 암호화된 데이터에 대한 기계학습 알고리즘에 관한 연구가 최근 많이 이루어지고 있으나, 대부분은 이미 학습된 알고리즘에 대한 평가 단계에서만 암호화를 적용하고 있음. 이는 학습 단계에서 훨씬 많은 연산이 요구되며, 이를 암호화된 상태에서 구현하는 것이 현실적으로 어렵기 때문임. 이에 본 연구진은 동형암호에 친화적이며 학습 단계를 아우르는 서포트 벡터 머신(SVM) 알고리즘을 개발함.

● SVM 알고리즘은 쌍대 문제가 2차 계획 문제로 나타나기 때문에 복잡한 연산을 요구함. 따라서 쌍대 문제가 선형 계획 문제로 표현되는 Least Squares-SVM(LS-SVM) 알고리즘을 사용함. 이때 선형 계획 문제를 풀기 위해서 역행렬을 구하는 것이 암호화된 상태에서는 매우 비효율적이기 때문에 경사 하강법을 사용하여 근사해를 구하는 방법을 사용함. 추가로 행렬곱 등 다양한 연산을 효율적으로 수행하기 위해 다양한 패킹 방법을 제안함. 본 연구는 IEEE Access (IF : 3.367)에 게재됨.

2차년도. Multi-basin 동적 시스템을 이용한 임베딩 기술 개발

- Multi-basin system을 이용한 공정한 군집화 방법론 개발

● 본 연구진은 기존에 있었던 multi-basin system이 다양한 제약조건에서 안정적으로 돌아갈 수 있는 시스템을 개발하기 위해 데이터의 특성에 따라 결과의 차별이 없는 공정한 군집화(fair clustering) 방법론을 개발함. 서포트 벡터 방법을 활용한 유사밀도함수 추정 및 이에 상응하는 multi-basin system의 구축을 통해, 동역학계의 각 basin을 군집으로 하는 군집화 방법론을 새로이 도입함. 이렇게 얻어진 군집화가 공정성을 갖게끔 sample density $\widehat{p_s}$와 가까운 'fair density' $\widehat{p_f}$를 추정하는 방법을 개발함.

- 동형암호를 활용한 multi-basin system 기반 군집화 방법론 개발

● 본 연구진은 1차년도에 개발한 동형암호를 활용한 머신러닝 방법론을 multi-basin system으로 확장하고자 함. 이를 통해 알고리즘에 대한 예측할 수 없는 공격에 대한 방어를 실현할 수 있음. 본 연구진은 암호화된 데이터에 대해 기존의 multi-basin system 기반 군집화 방법론을 적용하고, 궁극적으로 이를 개발된 임베딩 방법론 또는 공정한 군집화 방법론에 적용하고자 함.

● 현재 구현된 동형암호 체계는 덧셈과 곱셈 연산만 효율적으로 지원하므로, 다항함수로 표현되기 힘든 초월함수 또는 논리 연산을 효율적으로 수행하는 것이 어려움. 따라서 기존의 multi-basin system 기반 군집화 방법론에서 핵심이 되는 동적 시스템의 해를 구하기 위한 경사 하강 연산을 암호문에 그대로 적용하는 것이 불가능함. 본 연구진은 보로노이 셀(Voronoi cell) 기반의 방법론을 변형하여 보다 동형암호에 친화적인 알고리즘을 개발함. 본 연구의 성과는 Electronics Letters (IF : 1.314)에 게재됨.

- 결정 경계의 뒤틀림 방지 기법 개발

● 본 연구진은 단일 탐색(Single-step) 적대적 공격을 활용한 학습에서 발생하는 재앙적 과적합

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

(Catastrophic overfitting)에 대해 연구함. 재앙적 과적합은 비교적 빠른 단일 탐색 적대적 공격 학습의 공격에 대한 방어력을 크게 해치는 현상으로 이를 극복하면, 적은 시간 안에 적대적 공격에 강건한 딥러닝 모델을 구축할 수 있음. 본 연구진은 재앙적 과적합이 잠재공간에서의 결정 경계의 뒤틀림으로 인해 발생하는 것을 발견하고, 새로운 단일 탐색 적대적 공격 학습 방법을 제안하여 이를 효과적으로 억제할 수 있음을 보임. 본 연구는 AAAI 2021에서 발표함.

- 연결형 적대적 학습 방법 제안

● 본 연구진은 기존 제안된 각기 다른 적대적 학습 방법이 다른 방식으로 모델의 강건성을 부여함을 확인함. 비록 모델들이 같은 강건성을 가지고 있더라도, 그들은 서로 다른 예제 특성을 가지고 있음을 통계적으로 확인함.

● 본 발견을 기반으로 연구진은 margin과 smoothness를 달성할 수 있는 새로운 적대적 학습 방법인 Bridged Adversarial Training을 제안함. 이는 기존 방법들보다 더 안정적이고 높은 강건성을 도출해 냄. 본 연구의 성과는 Neural Networks (IF=7.800)에 게재됨.

- 확장성을 지닌 효율적으로 검증가능한 적대적 공격 방어 알고리즘 개발

● 기존의 검증 가능한 학습 방법론은 매우 느리고, 딥러닝 시스템과 같이 구조가 큰 모델에 적용하기 어려움. 본 연구진은 이를 해결하고자 층간 전파 기반의 검증가능한 학습 방법론을 통해 빠르고 큰 구조의 모델에 적용가능한 모델을 개발하였음. 더 나아가 기존의 모델보다 더 좋은 상하한을 이용하여 더 나은 검증을 할 수 있음. 본 연구는 NeurIPS 2020에서 발표함.

3차년도. 도메인 적응을 활용한 적대적 공격 방어 알고리즘 개발

- 도메인 적응을 위한 정답 의존적 도메인 유사화 학습 개발

● 머신러닝 및 딥러닝 모델은 학습에 사용된 데이터에 대해서는 높은 성능을 보이지만, 학습에 사용되지 않은 데이터에 대해서는 낮은 성능을 보임. 여러 학습 기법 중 도메인 적응 학습 방법은 학습에 사용되지 않은 혹은 도메인이 다른 데이터에 대한 성능 향상을 가능하게 하므로 인공지능 모델의 현실화에 있어 매우 중요함.

● 기존 도메인 적응 방법은 오분류된 데이터와 그렇지 않은 데이터 모두 가장 가까운 평균으로 표현되도록 학습을 진행하여 오분류된 데이터 역시 다른 정답의 평균에 같은 정도로 수렴함. 본 연구진은 이를 개선하기 위해 오분류될 가능성이 높은 데이터가 평균에서 멀리 떨어져 있다는 사실을 바탕으로 평균에서의 거리에 비례하여 수렴하는 방법을 제안함. 그 결과 기존에는 잘못된 평균으로 수렴하던 오분류 데이터들이 보다 올바른 방향으로 가는 현상을 관측함. 본 연구는 Pattern Recognition (IF : 7.740)에 게재됨.

- 확정 구간 강건 모델의 이해와 개발

● 본 연구진은 보이지 않는 작은 섭동만으로 딥러닝 모델의 예측을 바꿀 수 있는 적대적 공격에 대한 기존 모델의 취약성을 개선함. 학습 손실의 상계를 최소화하는 방향으로 방어하는 방법이 학습 손실의 상계를 최소화하게 하는 것뿐만 아니라 학습 손실이 매끄럽게 학습될수록 학습에 유리하다는 것을 이론적으로 밝힘.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

$$\text{For, } u_t = \frac{\nabla_\theta L^{\epsilon_t}(\theta_t)}{\|\nabla_\theta L^{\epsilon_t}(\theta_t)\|} \text{ where } 0 < \mu \leq \frac{\|\nabla_\theta L^{\epsilon_t}\|^2}{2L^{\epsilon_t}}, \cos(\phi_t) = \frac{\nabla_\theta L^{\epsilon T} \nabla_\theta L^{\epsilon_t}}{\|\nabla_\theta L^{\epsilon}\| \|\nabla_\theta L^{\epsilon_t}\|}, \ \triangle_t = \theta_{t+1} - \theta_t$$

$$\text{and } H_t^\epsilon \text{ satisfies } L^\epsilon(\theta_{t+1}) = L^\epsilon(\theta_t) + \nabla_\theta L^\epsilon(\theta_t)^T \triangle_t + \frac{1}{2} \triangle_t^T H_t^\epsilon \triangle_t \text{ and } \triangle_t^T H_t^\epsilon \triangle_t > 0$$

$$L^\epsilon(\theta_{t+1}) \leq L^\epsilon(\theta_t)(1 - \frac{\mu}{2} cos^2(\phi_t) \|H_t^\epsilon u_t\|^{-1})$$

[수식 1] 섭동 손실함수의 상계와 이계 미분

● 본 연구진은 기존 주어진 섭동 크기(ϵ)에 대해 확정된 구간 내에서의 모델 파라미터(ϵ)에 대한 손실함수(L)의 상한이 손실함수의 이계 미분(H)과 관련이 있음을 위와 같이 증명함. 이를 바탕으로 새로운 학습 방법을 제시하여 기존의 벤치마크 모델들보다 다양한 섭동에 대해서 좋은 성능을 보여준다는 것을 보임. 본 연구 결과는 NeurIPS 2021에서 발표함.

- 평등 군집화를 위한 계층 군집화 기법 개발

● 현실에서 구할 수 있는 데이터는 생성 과정에서 자연스럽게 편향될 수 있음. 예를 들어, 취업에 관한 데이터의 경우 역사적으로 차별에 의한 남성의 성공 사례가 많음. 머신러닝 학습에서 이러한 데이터의 편향이 그대로 반영되어 학습의 결과가 소수 집단에 차별을 가할 수 있음이 알려졌으며, 이를 활용한 적대적 공격은 심각한 사회적 문제를 야기할 수 있음.

● 본 연구는 이러한 차별을 완화할 수 있는 새로운 군집화 알고리즘을 개발함. 개발된 알고리즘은 전체 데이터를 여러 개의 작은 부군집으로 나누고, 각 군집에 속한 각 집단의 비율이 일정하도록 부군집들을 계층적으로 묶어 최종 군집을 산출함. 실험 결과는 개발된 알고리즘이 공정한 군집화 결과를 보이면서 연산적으로도 효율적임을 나타냄. 본 연구 결과는 Information Sciences (IF : 6.795)에 게재됨.

4차년도. 강화학습 기반 순차적 커미티 머신 개발

- 디파이(Defi) 시장의 가상화폐 가격 간의 상관관계 조사

● 본 연구진은 다양한 적대적 공격 시나리오 보완을 위하여 가상화폐, 디파이, NFT 등의 새로운 금융 시장 분석을 위한 연구를 진행함. 이를 위해 새로운 금융 시장들 각각의 특성을 이해할 필요가 있음. 디파이 시장 내 존재하는 가상화폐들의 가격의 co-movement를 알아봄.

● 디파이 토큰들끼리의 co-movement와 디파이 토큰과 다른 토큰들 사이의 co-movement를 정량적으로 측정하기 위해 시간대에 따라 Pearson coefficient, multiple R square를 직접 데이터에 적용함.이를 통해 디파이 시장 내의 토큰들의 가격이 다른 토큰들에 비해 같이 움직이려는 성질이 더 강하다는 결과를 얻음. 또 전통시장의 특성과 비슷하게, 토큰들의 수익률이 안 좋을 때 디파이 토큰들끼리의 co-movement level이 높아진다는 사실을 밝힘. 본 연구는 Applied Economics Letters(IF : 1.60)에 게재됨.

- NFT 자산 시장이 포트폴리오 성능에 미치는 영향 분석

● 본 연구진은 다양한 적대적 공격 시나리오 보완을 위하여 신흥 금융 시장으로 부상하는 NFT 자산 관련 시장에 대한 사전 연구를 진행함. NFT 자산군이 기존 자산군에 대해 diversification effect의 가능

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

성이 있는지를 spillover effect를 통해 확인함. NFT 자산군이 기존 자산군이 포함된 최적 포트폴리오에 추가 되었을때, 포트폴리오의 성능을 통계적으로 유의하게 개선하는 지를 실증적으로 확인함. 본 연구의 성과는 Financial Research Letters (IF : 9.846) 에 게재됨.

- XAI를 활용한 금융 시장 시계열 데이터를 활용하기 위한 사전 분석

● 적대적 공격의 일반화 성능 개선을 위한 금융 시계열 데이터 기반 학습을 위해서는 금융 시장에 대한 전반적인 이해가 필요함. 금융 시장에서 가장 중점적으로 다루어지고 있는 시계열 데이터의 경우, 전통적 시계열 분석 모형들을 활용한 분석들이 아직도 활발히 다루어지고 있음. 본 연구진은 이러한 시계열 분석 모형들을 활용한 가상화폐 시장 사전 분석을 통해 미래 XAI가 금융 시장 내에서 효과적으로 사용될 수 있는 활용 가능성을 타진함.

● 본 연구진은 최근 가상화폐 시장에서 화제가 되었던 테라-루나(Terra-Luna) 사태에 대한 사전 분석을 진행함. 특히, 가상화폐 시장 내 본 사태가 일으킨 스필오버 효과(Spillover effect)를 측정하기 위하여, 시가총액 상위 10개의 가상화폐 가격과 변동성에 대하여 스필오버 인덱스를 측정함.

● 실험 결과 테라-루나 사태가 발생함에 따라 루나가 가상화폐 시장에 미치는 영향력이 급격하게 증가한 것으로 나타남. 또한, 시장 내 투자자 관심(Investor attention)과 가상화폐 가격 및 변동성 간 정보 플로우(Information flow)를 확인하기 위하여 전이 엔트로피(Transfer entropy)를 활용함. 또한, 테라-루나와 같은 대규모 폭락 사태에는 구글 트렌드(Google trends)나 투자자들의 트위터 정보와 같은 감성 정보들은 효과적인 정보 전달자(Information transmitter)의 역할을 하지 못함을 확인함. 본 연구는 현재 SSCI 비즈니스 분야 Finance Research Letters(IF: 9.85)에 게재됨.

- 그래프 기반의 멀티 팩터 자산 모형 개발

● 4차년도의 강화학습 기반 순차적 커미티 머신 개발을 위해서는 앞선 모델의 학습에 추가로 새로운 데이터를 학습하는 방법이 요구됨. 이는 시계열 데이터 처리 분야에서 많이 활용되고 있으며, 특히 금융 시장에서 활발하게 다루어지고 있는 주제임. 따라서, 본 연구진은 금융 분야에서의 연구를 통해 차년도 개발을 준비함.

● 본 연구진은 자산의 회계적 특성 변수와 자산 간 연관성을 바탕으로 리스크 노출도를 측정하는 내재적 멀티 팩터 자산 수익률 평가 모형을 제안함. 본 연구진은 서로 연관성을 갖는 고차원 변수들을 다루기 위해 자산 간 연관성을 자산 초과 수익률 간의 상관관계로 추정하는 그래프 합성곱 신경망 모형을 적용함. 내재적 멀티 팩터 모형을 제시한 최근의 선행 연구들과는 다르게, 본 연구진은 전 단계의 팩터를 보존하며 멀티 팩터를 구축해 나가는 단계적 팩터 구축 알고리즘을 제시함. 미국 개별 주식에 대한 실증 연구 결과, 본 연구에서 제시한 모델은 설명력과 팩터 탄젠시 포트폴리오의 샤프 비율 측면에서 기존의 벤치마크 모델들보다 우수한 성능을 보여 Finance Research Letters(IF : 5.596)에 게재됨.

- 스필오버 인덱스와 그래프 뉴럴 네트워크를 활용한 글로벌 금융 시장 변동성 예측

● 본 연구에서는 글로벌 경제의 재정 연계성 때문에 특정 시장의 충격이 다른 시장에 전달되는 현상인 변동성 스필오버 효과를 다룸. 본 연구진은 공간-시간 그래프 신경망(GNN)을 이용한 글로벌 금융 시장 지수의 변동성 예측 모델을 제안함. 시장 간의 변동성 스필오버 효과는 변동성 스필오버 지수를 사용하여 시장 간 연계를 정량적으로 추정함으로써 모델에 반영됨. 본 연구에서는 여덟 개의 대표적인 글로벌 시장 지수에 대한 실증 분석을 수행함.

● 실증 실험 결과에서 다음과 같은 특징을 발견함. 첫째, 제안된 공간-시간 GNN 스필오버 모델은 단

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

기 및 중기 예측에서 기준 모델들을 능가함. 둘째, 예측 정확도는 높은 변동성 스필오버 효과를 가진 시장 지수의 포함 여부에 크게 의존함. 가장 높은 순 스필오버 지수를 포함하는 S&P500을 포함시킴으로써 다른 시장들의 변동성을 효과적으로 예측하는 데 도움이 됨. 셋째, 투자자는 제안된 모델에서 예측된 변동성을 평균-분산 프레임워크에서 사용함으로써 경제적 이득을 얻을 수 있음. 본 연구의 성과는 Journal of Forecasting (IF: 3.4)에 개제됨.

- 효율적인 서포트 벡터 기반 차분 프라이버시 다중 클래스 분류 기술 개발

● 딥러닝 모델들은 모델에 대한 정보나 데이터가 유출될 시 적대적 예제를 이용한 공격(Adversarial attack)에 취약해질 수 있음. 본 연구진은 머신러닝, 딥러닝 학습에서 발생할 수 있는 프라이버시 유출을 막기 위한 차분 정보보호(Differential privacy) 모델을 개발함.

● 머신러닝 방법 중 하나인 support vector 기반의 모델을 활용해 프라이버시를 보장하면서 기존보다 더 나은 정확도를 갖는 모델을 개발함. 이 방법은 데이터가 많지 않은 환경에도 적용될 수 있다는 장점이 있으며, 데이터가 적은 환경에서는 학습 데이터에 과적합(Overfitting)되는 문제가 발생할 가능성이 높음. 본 연구의 성과는 Information Sciences (IF : 8.233)에 게재됨.

- 음성 분류 모델의 전이 가능한 공격에 대한 강건성 측정 방법 개발

● 본 연구진은 현실 응용 분야에서 음성 분류 모델에 대해 전이 가능한 공격에 대해 탐색함. 기존 음성 분류에 대한 강건성은 Mel-spectrogram 기술에 의존적이며, 최근 개발된 딥러닝 기반의 Wav2vec 기술에 대해서는 알려진 바가 없음. 따라서, 본 연구진은 Mel-spectrogram과 Wav2vec에 대한 광범위한 강건성 분석을 바탕으로, 음성 분류 모델이 현실에 적용될 때의 위험성에 대해 논의함. 나아가, 음성 분류 모델이 보다 취약한 강건성을 가질 수 있음을 새로운 공격을 제안하여 입증함. 본 연구의 성과는 Pattern Recognition (IF=8.000)에 게재됨.

5차년도. 적대적 공격에 대한 통합 방어 시스템 개발

- 동형암호 기반의 로지스틱 회귀 모형 개발

● 최종년도인 5차년도의 적대적 공격에 대한 통합 방어 시스템 개발을 위해서는 모델의 보호뿐만이 아니라, 데이터의 보호도 중요함. 이러한 점에서 최근 등장한 머신러닝 및 딥러닝이 가능한 데이터 보호 기법인 동형암호는 본 연구에서 효과적인 방어 기법으로 작용할 수 있음.

● 동형 암호는 암호화된 데이터에 대한 연산을 가능하게 하므로 높은 보호 수준을 보장함. 동형 암호를 활용한 기존의 머신러닝 학습 연구는 여러 가지 파라미터의 선택을 요구하는데, 암호화된 데이터에 대해서는 파라미터의 값에 대한 선택이 불분명함. 따라서 본 연구는 모델 성능에 중요한 영향을 미치는 파라미터 선택을 최대한 제거한 새로운 암호화된 로지스틱 회귀 모형의 학습 방법을 제안함. 뿐만 아니라 모든 정보를 암호화하는 대신에 일부 더욱 중요한 정보만을 암호화함으로써 더욱 효율적인 연산을 가능하게 함. 본 연구 결과는 NeurIPS 2021에서 발표함.

- 동형암호를 이용하여 프라이버시를 보호하는 개인화된 포트폴리오 최적화 기술

● 본 연구진은 금융 분야에서 개인화된 투자 전략을 제공하는 최신 핀테크 기술인 로보 어드바이저(Robo-advisor) 기술이 고객의 개인 정보를 침해할 수 있다는 점에서 착안하여 연구를 진행함. 암호화된 정보에 대해 연산을 가능하게 하는 동형암호(Homomorphic Encryption) 기술을 이용해, 위험회피 성향(Risk Aversion) 등 민감한 개인정보를 암호화하여 로보 어드바이저로 하여금 민감 정보에 접근할 수

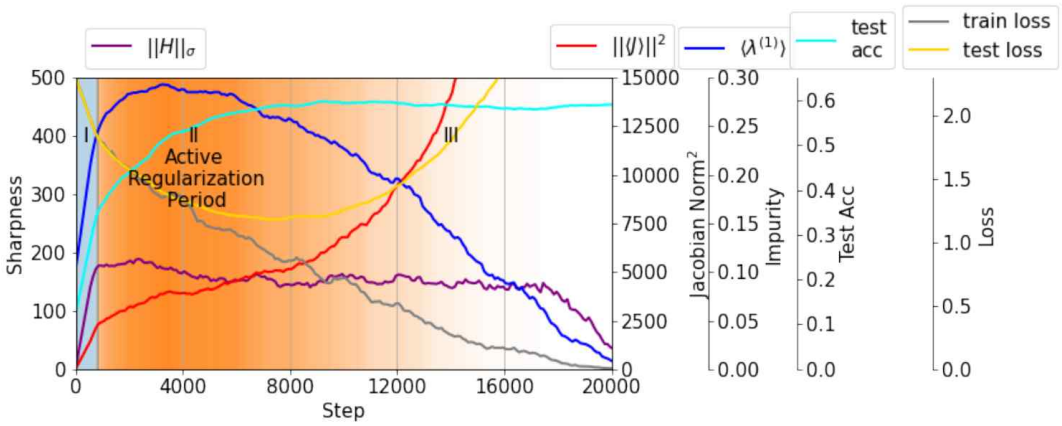
국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

없도록 하면서도 최적 포트폴리오를 찾을 수 있게 하는 기술을 개발함.

● 위 방법은 기존 동형암호를 활용한 연산의 한계점인 연산 효율성 문제를 극복하기 위해, 포트폴리오에 제약이 존재하는 상황에서 기존 방법론에 비해 효율적인 포트폴리오 최적화 방법을 제안함. 결과적으로 합리적인 연산 시간 내에 실제 최적 포트폴리오와 매우 가까운 포트폴리오를 구할 수 있음. 본 연구의 성과는 Finance Research Letters (IF : 9.848)에 게재됨.

- 야코비안 행렬 분해를 통한 불순도 확률 기반 딥러닝 최적화

● 본 연구진은 딥러닝의 근간 알고리즘인 확률적 경사 하강법이 로짓(Logit)-가중치(Weight) 야코비안 행렬로 근사할 수 있음을 처음으로 밝힘. 이 분석을 바탕으로, 확률적 경사 하강법의 학습 단계를 분석하고, 초기 학습과 후기 학습의 차이점을 발견함. 두 번째 단계를 능동적 정규화 단계(Active Regularization Period)라고 부르며 이에 대한 학습 현상을 분석함.



[그림] 학습의 세 단계와 능동적 정규화 단계에서의 실험 결과

● 위 방법은 학습이 실제로 일어나는 부분 공간을 밝히고, 이를 활용한 학습 알고리즘이 최신 최적화 알고리즘을 능가함을 밝힘. 본 연구의 성과는 2023 International Conference on Machine Learning에서 발표함.

- 적대적 공격 예제 방어를 위한 표현 공간 탐색

● 본 연구진은 딥러닝 모델을 취약하게 만드는 적대적 공격에 대한 분석을 위해, 오디오 분야에서의 다양한 표현 공간 방법을 탐색함. 표현 공간 탐색에서 특정 표현 방법에서 생성된 적대적 예제는 상이한 표현 방법에 의해 표현 공간에서 분리가 가능함을 밝혀냄.

● 위의 발견을 활용하여 본 연구진은 다양한 표현 방법을 사용하여 적대적 예제를 검출하는 적대적 공격 방어 기법을 제안함. 다양한 표현 방법에서 나온 확률 정보를 기반으로, 확률 정보의 차이를 통해 정상 예제인지 적대적 예제인지 판별하는 연구를 진행함. 본 연구의 성과는 Exploring Diverse Feature Extractions for Adversarial Audio Detection로 IEEE Access(IF : 3.9)에 게재됨.

- 차분 프라이버시를 만족하는 공정한 군집화 기술

● 공정한 모델을 학습하기 위해 개인의 민감 정보를 사용해야 한다는 문제가 있음. 본 연구진은 차분 프라이버시(Differential Privacy) 기술을 이용하여 개인의 민감 정보를 보호하면서 공정한 군집화 모델을 학습할 수 있는 새로운 방법론을 개발함.

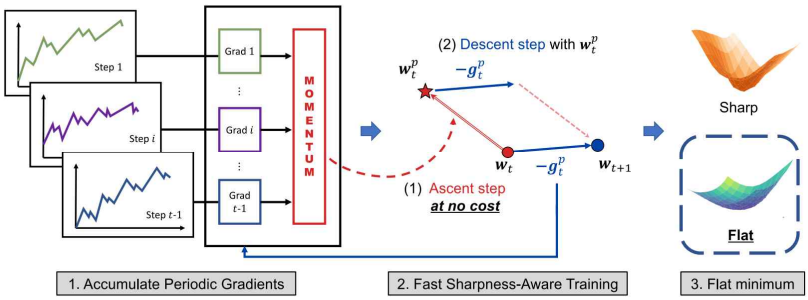
● 개발된 방법론은 밀도기반(Density-based) 공정한 군집화 방법을 확장하여, 최종 군집화 단계에서

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

차분 프라이버시를 만족하면서 각 군집의 공정한 정도를 구할 수 있음. 기존 밀도기반 군집화 방법론의 단점인 연산 비효율성을 개선하기 위하여, 가우시안 혼합 모델(Gaussian Mixture Model)으로 데이터 밀도를 추정하고 보로노이 셀(Voronoi Cell) 기반의 근접성을 사용해 군집화함. 본 연구의 성과는 International Joint Conference on Artificial Intelligence 2023에서 발표함.

- 효율적인 시계열 분류 및 예측의 일반화 성능 향상 기법 개발

● 본 연구진은 금융 데이터에 대한 일반화 성능을 보장하기 위한 연구를 진행함. 손실함수의 기하적 특성을 파악해, 노이즈에 강건한 일반화 성능을 보장하는 손실함수 첨도 기반 알고리즘인 Sharpness-Aware Minimization(SAM)은 일반화 성능 향상을 위해 최근 제안된 알고리즘이지만 기존 기울기 하강법에 비해 2배의 계산이 필요하다는 단점이 존재함. 시계열 데이터의 특성을 바탕으로 이를 해결할 수 있는 방법을 제안함.



[그림] 시계열의 주기성을 활용한 손실함수 첨도 기반 최적화 알고리즘

● 위의 방법을 바탕으로 최근 가장 높은 성능을 보이는 최신 딥러닝 기반 시계열 모델에 적용해 다양한 데이터에서 성능 향상을 이루어냄. 이는 학습에 사용하지 않은 다양한 시계열 데이터에 대한 일반화 성능을 효과적으로 향상시킴. 본 연구의 성과는 Applied Soft Computing (IF : 8.7)에 게재됨.

- 딥러닝 모델의 강건성과 지표 간의 상관관계 탐구

● 기존 강건성은 모델의 margin, smoothness 등 다양한 지표와 연관이 있다고 알려짐. 하지만, 연관성은 수학적으로만 보여지거나, 실험적으로 증명되는 데에는 한계가 있었음. 본 연구진은 다양한 지표들이 실제 모델들의 강건성에 대해 얼마나 상관관계를 내포하고 있는지 확인함.

● 순서 상관관계(Rank correlation)를 기반으로 특정 지표들이 어떻게 강건성의 일반화 성능에 영향을 미치는 지 실험적으로 파악하였으며, 나아가 새로운 지표의 개발을 도출해 냄. 본 논문은 NeurIPS 2023에서 발표함.

- 베이지안 딥러닝 모델을 활용한 적대적 공격에 강건한 모델 개발

● 본 연구진은 베이지안 딥러닝 모델을 활용하여 적대적 공격에 강건한 학습 방법을 개발함. 기존 베이지안 딥러닝 모델은 여러 샘플 모델을 활용하여, 특정 샘플 모델에 대한 공격을 방어하였음. 그러나, 기존 모델은 Expectation Over Transformation(EOT)라는 새로운 공격에 특히 취약하여 강건성을 보장하지 못함. 이를 극복하기 위해 본 연구진은 베이지안 딥러닝 모델의 각 샘플 모델이 다양한 기울기 정보를 탑재하도록 새로운 Regularization을 연구함.

● 위의 방법을 바탕으로 기존 베이지안 딥러닝 모델의 강건성을 높게 향상시킴. 본 연구의 성과는 IEEE Transactions on Pattern Analysis and Machine Intelligence (IF : 23.6)에 게재됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

- 암호화폐 시장에서의 포트폴리오 보험 전략

● 본 연구진은 암호화폐라는 대체 금융 자산 시장에 대해 포트폴리오 보험 전략의 효과에 대한 세계 최초로 실증적 연구를 수행함. 본 연구의 실증 실험 결과 포트폴리오 보험 전략에 의해 변동성이 큰 암호화폐 시장에서의 하방 리스크가 현저히 감소했음을 확인함. 또한, 경제학 기반의 효용 이론을 바탕으로 각 투자자별 효용 함수가 포트폴리오 선택에 어떤 영향을 미치는지를 실증적으로 조사함으로써 암호화폐 자산 투자자들에 대한 새로운 통찰을 제공함.

● 본 연구진의 연구를 통해, 암호화폐 시장에서 포트폴리오 보험의 경제적 이득이 기존 시장에서의 경제적 이득보다 훨씬 높다는 것을 보임으로써, 암호화폐 투자자들이 직면한 하방 위험 관리 문제를 해결할 수 있는 실증적 증거를 확보함. 본 연구의 성과는 Research in International Business and Finance (IF : 6.5)에 게재됨.

- 차분 프라이버시를 만족하는 손실함수 평탄도 학습 알고리즘 개발

● 본 연구진은 차분 프라이버시 하강 경사법(Differentially private stochastic gradient descent, DP-SGD) 상황에서 일반화 성능을 높이는 연구를 진행함. 데이터 접근 횟수에 따른 프라이버시 유출 상황을 개선하는 평탄도 기반 알고리즘 차분 프라이버시 학습 알고리즘 (Differentially private sharpness aware training, DP-SAT)를 개발함.

● 위 방법은 기존 최적화 방법에 비해 노이즈에 강건하고, 그래디언트 크기를 효과적으로 줄일 수 있음을 보임. 본 연구의 성과는 2023 International Conference on Machine Learning에서 발표함.

2) 세부 정량적 연구개발성과: [붙임1] 참조

3) 목표 달성 수준

추 진 목 표	달 성 내 용	달성도 (%)
비선형 사영법을 이용한 매니폴드 학습	전처리 단계 알고리즘을 개발했으며, 다양한 도메인에 적용 가능한 단일 클래스 이상치 탐지를 실행함.	100%
Multi-basin 시스템을 활용한 임베딩 기술 개발	적대적 노이즈 방지를 위한 군집 간 거리 극대화 방법 및 동적 시스템을 이용한 클래스 최대 분리 임베딩 기법을 제안함.	100%
도메인 적응 기술을 활용한 방어 알고리즘 개발	적대적 샘플을 활용한 도메인 적응 기술을 개발함. 이를 통해 다양한 공격에 대한 내성을 기대할 수 있음.	100%
강화학습 기반 순차적 커미티 머신 개발	시계열 데이터의 순차적 학습에 대해 연구하고, 적대적 방어 기법 성능의 도메인 일반화를 진행함.	100%
적대적 공격에 대한 통합 방어 시스템 개발	적대적 공격에 대한 통합 시스템을 개발하기 위해 일반화 성능을 개선하고, 적대적 공격에 강건한 통합 모델을 개발함.	100%

4) 목표 미달 시 원인 분석(해당 시)

4-1) 목표 미달 원인(사유) 자체분석 내용

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

해당 없음

4-2) 자체 보완활동

해당 없음

4-3) 연구개발 과정의 성실성

해당 없음

4. 연구개발성과의 관련 분야에 대한 기여 정도(연구개발결과의 중요성)

● 본 연구과제 결과는 향후 인공지능 기술에 대한 의존도가 높아지는 시대적 흐름에 따라 마주할 산업 구조의 변화 및 사회, 경제적 측면에서 중요한 기여를 할 것으로 기대.

● 적대적 공격에 강건한 인공지능 모델은 자율 주행 자동차로 인한 인명 사고, 알고리즘 트레이딩으로 인한 갑작스런 심장 마비 등 사례에서 볼 때 사회경제적 측면에서 중요성을 지님.

● 본 연구 과제에서 개발된 비선형 사영법을 활용한 임베딩 기술 개발은 적대적 공격을 넘어서 생성 모델 등의 분야에서도 핵심 연구 분야 중 하나로 거론되고 있음. 이를 활용하여 구체적으로는 이상치 탐지, 경고 시스템 등의 분야에서 추가 연구가 가능할 것으로 기대가 되므로 과학 기술적 측면에서도 중요성을 지님.

● 또한, 본 연구 과제에서 다루어진 안전한 인공지능 모델 개발을 위한 Earth Movement Distance, Integral Probability Metric 등의 연구는 표현 학습 및 도메인 적응 분야에서 기초가 되는 기술이므로, 본 연구를 통해 다른 각 세부 분야의 연구 발전에 기여도가 높음.

● 4차년도의 순차적 학습의 경우에도 AI 기술이 상용화되기 위한 필수 과정 중 하나임. 연구 주제인 적대적 공격에 대한 순차적 커미티 머신 학습 기술은 적대적 공격에 강건한 인공지능을 넘어선 다른 인공지능 기술의 상용화에 크게 도움이 될 것으로 기대되므로, 상당한 연구적 중요성을 지니고 있으며 인공지능 기술이 적용될 수 있는 다양한 산업으로의 파급효과가 큼.

5. 연구개발성과의 관리 및 활용 계획

● 본 연구 과제에서 연구 책임자의 풍부한 경력을 바탕으로 연구단 내 활발한 상호 협력 체계를 구축하였으며, 우수 연구 성과에 대한 인센티브를 제공함.

● 본 연구 과제에서 개발한 안전한 인공지능 시스템 구현을 위한 적대적 공격 방어 기술은 다양한 산업 분야에서 활용될 수 있으며, 이를 방어할 수 있는 적대적 공격 방어 기술의 개발은 실제 산업 현장에서 필수적인 요소임.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

● 안전한 인공지능 시스템을 위해 본 연구 과제에서 적대적 공격을 방어하는 기술을 개발했지만, 2020년대에 들어서 ChatGPT 등 생성형 인공지능이 출현함에 따라 안전한 인공지능의 범주가 확장되고 있음.

● 개인의 프라이버시 보호와 모델의 투명성을 확보하는 것 또한 안전한 인공지능의 범주에 포함됨에 따라, 이에 대한 추가 연구가 필요함. 본 연구를 통해 적대적 노이즈에 강건한 모델을 학습했으며, 이는 추후 프라이버시를 보호하기 위한 노이즈를 활용하는 다양한 연구 혹은 노이즈가 포함된 실제 데이터를 학습하여 적대적 공격을 방어할 수 있는 강건한 매니폴드 연구에 응용될 수 있음.

● 본 연구 과제에서 개발한 내용을 바탕으로 국내 우수 기술력을 확보하고 있는 기업체와의 단계적 협력과 시스템 구축을 위한 자문 체제 등을 확립할 수 있음.

6. 자체점검표

구분	아주 우수	우수	보통	미흡	불량	비고
연구성과의 우수성/창의성	√					
연구성과의 파급 효과	√					
연구성과에 대한 활용 가능성	√					
연구수행의 성실도	√					
연구성과에 대한 종합의견 기술	본 과제에서는 안전한 인공지능을 위한 적대적 공격 방어 기술 개발을 위한 세부 목표를 달성함. 과제의 연구결과는 딥러닝 모델의 일반화 성능을 개선하고, 금융 등 다양한 도메인에 활용할 수 있음. 또한 각 연차별 달성한 뛰어난 연구성과는 금융 분야를 넘어 다양한 산업 분야에서의 안전한 인공지능 모델 적용을 기대할 수 있음.					

7. 참고문헌

[1] Kim, K., & Lee, J. (2014). Nonlinear dynamic projection for noise reduction of dispersed manifolds. *IEEE transactions on pattern analysis and machine intelligence, 36*(11), 2303-2309.
[2] Lee, J., & Lee, D. (2005). An improved cluster labeling method for support vector clustering. *IEEE Transactions on pattern analysis and machine intelligence, 27*(3), 461-464.
[3] Lee, J., & Lee, D. (2006). Dynamic characterization of cluster structures for robust and inductive support vector clustering. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 28*(11), 1869-1874.
[4] Lee, D., Jung, K. H., & Lee, J. (2009). Constructing sparse kernel machines using attractors. *IEEE Transactions on Neural Networks*, *20*(4), 721-729.
[5] Lee, D., & Lee, J. (2007). Equilibrium-based support vector machine for semisupervised classification. *IEEE Transactions on Neural Networks*, *18*(2), 578-583.
[6] Lee, J., & Chiang, H. D. (2004). A dynamical trajectory-based methodology for systematically computing multiple optimal solutions of general nonlinear programming problems. *IEEE Transactions on Automatic Control*, *49*(6), 888-899.
[7] Lee, J. (2004). An optimization-driven framework for the computation of the controlling UEP in transient stability analysis. *IEEE transactions on automatic control*, *49*(1), 115-119.
[8] Lee, J. (2003). Dynamic gradient approaches to compute the closest unstable equilibrium point for stability region estimate and their computational limitations. *IEEE transactions on automatic control*, *48*(2), 321-324.
[9] Son, Y., & Lee, J. (2016). Active learning using transductive sparse Bayesian regression. *Information Sciences*, *374*, 240-254.
[10] Jung, K. H., & Lee, J. (2013). Probabilistic generative ranking method based on multi-support vector domain description. *Information Sciences*, *247*, 144-153.
[11] Lee, D., & Lee, J. (2010). Dynamic dissimilarity measure for support-based clustering. *IEEE Transactions*

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

on Knowledge and Data Engineering, 22(6), 900-905.
[12] Kim, K., Son, Y., & Lee, J. (2015). Voronoi cell-based clustering using a kernel support. *IEEE Transactions on Knowledge & Data Engineering*, (4), 1146-1156.
[13] Jung, K. H., Kim, N., & Lee, J. (2011). Dynamic pattern denoising method using multi-basin system with kernels. *Pattern Recognition, 44*(8), 1698-1707.
[14] Lee, D., & Lee, J. (2007). Domain described support vector classifier for multi-classification problems. *Pattern Recognition, 40*(1), 41-51.
[15] Kim, K., & Lee, J. (2014). Sentiment visualization and classification via semi-supervised nonlinear dimensionality reduction. *Pattern Recognition, 47*(2), 758-768.
[16] Son, Y., Lee, S., Park, S., & Lee, J. (2018). Learning representative exemplars using one-class Gaussian process regression. *Pattern Recognition*, *74*, 185-197.
[17] Kim, H. C., & Lee, J. (2007). Clustering based on Gaussian processes. *Neural computation*, *19*(11), 3088-3107.
[18] Jung, K. H., Lee, D., & Lee, J. (2010). Fast support-based clustering method for large-scale problems. *Pattern Recognition*, *43*(5), 1975-1983.
[19] Kim, N., Son, Y., Lee, Y., & Lee, J. (2016). Self-correcting ensemble using a latent consensus model. *Applied Soft Computing*, *47*, 262-270.
[20] Pyo, S., & Lee, J. (2018). Exploiting the low-risk anomaly using machine learning to enhance the Black–Litterman framework: Evidence from South Korea. *Pacific-Basin Finance Journal*.
[21] Yang, S., & Lee, J. (2014). Do affine jump-diffusion models require global calibration? Empirical studies from option markets. *Quantitative Finance*, *14*(1), 111-123.
[22] Kim, N., & Lee, J. (2013). No-arbitrage implied volatility functions: Empirical evidence from KOSPI 200 index options. *Journal of Empirical Finance*, *21*, 36-53.
[23] Lee, J., & Chiang, H. D. (2004). A singular fixed-point homotopy method to locate the closest unstable equilibrium point for transient stability region estimate. *IEEE Transactions on Circuits and Systems II: Express Briefs*, *51*(4), 185-189.
[24] Lee, J., & Chiang, H. D. (2004). A singular fixed-point homotopy method to locate the closest unstable equilibrium point for transient stability region estimate. IEEE Transactions on Circuits and Systems II: Express Briefs, 51(4), 185-189.
[25] Park, S., Hah, J., & Lee, J. (2017). Inductive ensemble clustering using kernel support matching. *Electronics Letters, 53*(25), 1625-1626.
[26] Park, S., Lee, W., & Lee, J. (2018). Learning the Indiscriminate Distribtutions of Document Embeddings for Domain Adaptation. *Intelligent Data Analysis*. Accepted
[27] Hah, J., Lee, W., Lee, J., & Park, S. (2018). Information-based Boundary Equilibrium Generative Adversarial Networks with Interpretable Representation Learning, *Computational Intelligence and Neuroscience*, Accepted
[28] Lee, W., Kim, H., Lee, J. (2018). Self-Training Domain Adaptation for Real World Application of Deep Learning Model, Computers and Industrial Engineering 48
[29] Kim, N., Jung, K. H., Kim, Y. S., & Lee, J. (2012). Uniformly subsampled ensemble (USE) for churn management: Theory and implementation. *Expert Systems with Applications*, *39*(15), 11839-11845.
[30] Yang, S., & Lee, J. (2012). Multi-basin particle swarm intelligence method for optimal calibration of parametric Lévy models. *Expert Systems with Applications*, *39*(1), 482-493.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임1] 세부 정량적 연구개발성과

- 총 연구개발기간동안 발생한 연구성과가 있을 경우 연구사업통합지원시스템(http://ernd.nrf.re.kr)의 성과부분에 논문, 특허 등의 성과를 입력한 후 한글파일로 다운받아 글자크기 등을 편집하여 첨부합니다. 제출 시 가장 앞페이지(총괄표)는 삭제하고 세부리스트만 제출
- **다운로드 방법**: e-R&D 시스템의 성과 > 성과다운로드 > 성과발생기간(**총 연구개발기간으로** 검색 후 한글 다운로드)

※ 연구성과 등록과 다운로드 방법은 함께 첨부된 매뉴얼(최종보고서 제출방법 안내) 참고

※ 작성대상 기간: 총 연구개발기간(첨부한 과제목록에서 총 연구개발기간을 확인하고 작성 요망)

(예시 표) 전문학술지 논문게재, 지식재산권 성과정보

전문학술지 논문게재 성과정보											
과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동 연구논문	기여도

지식재산권 성과정보										
과제번호	출원등록연월	재산권구분	출원등록 구분	발명제목	출원등록인	출원등록국	발명자명	출원등록번호	활용형태	기여도

- 예시 이외에도 조회되는 모든 성과를 복사하여 제출(학술대회 발표, 수상실적, 학위배출인력 등)
- 모든 연구성과는 연구개시일 이후에 이루어진 것만 인정
- 논문은 acknowledgement에 과제번호가 기재된 실적만 인정

※ 허위 성과 보고가 되지 않도록 입력한 성과의 내용이 정확한지 제출 전 확인하시기 바랍니다.

※ accepted/in press인 논문은 필요하다고 판단되면 칸을 추가로 생성하여 작성하시기 바랍니다.

※ 최종보고서 제출 이후에도 과제 종료 후 5년까지 후속 성과를 입력할 수 있으며, 입력한 성과는 조분평 등 성과자료로 활용합니다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

전문학술지 논문게재 성과정보											
과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동연구논문	기여도
2019R1A2C2002358	202002	A Scalable IoT Protocol via an Efficient DAG-based Distributed Ledger Consensus	Son, Bumho; Lee, Jaewook; Jang, Huisu;	SCI	SUSTAINABILITY	12(4)	국외	SCI등재	2.576	아니오	40
2019R1A2C2002358	202003	HE-Friendly Algorithm for Privacy-Preserving SVM Training	Park, Saerom; Byun, Junyoung; Lee, Joohee; Cheon, Jung Hee; Lee, Jaewook;	SCI	IEEE ACCESS	8(0)	국외	SCI등재	3.745	아니오	40
2019R1A2C2002358	202006	Joint Transfer of Model Knowledge and Fairness Over Domains Using Wasserstein Distance	Yoon, Taeho; Lee, Jaewook; Lee, Woojin;	SCI	IEEE ACCESS	8(0)	국외	SCI등재	3.745	아니오	40
2019R1A2C2002358	202007	Stability Analysis of Denoising Autoencoders Based on Dynamical Projection System	Saerom Park; Jaewook Lee	SCI	IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING	33(8)	국외	SCI등재	6.977	아니오	30
2019R1A2C2002358	202011	Do FOMC and macroeconomic announcements affect Bitcoin prices?	Pyo, Sujin; Lee, Jaewook;	직접입력	FINANCE RESEARCH LETTERS	()	국외	SCI등재	3.527	아니오	40
2019R1A2C2002358	202101	Privacy-preserving evaluation for support vector clustering	Byun, J.; Lee, J.; Park, S.;	SCI	ELECTRONICS LETTERS	(0)	국외	SCI등재	1.314	아니오	30
2019R1A2C2002358	202104	Compact class-conditional domain invariant learning for multi-class domain adaptation	Lee, Woojin; Kim, Hoki; Lee, Jaewook;	SCI	PATTERN RECOGNITION	(0)	국외	SCI등재	7.74	아니오	40

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

전문학술지 논문게재 성과정보											
과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동연구논문	기여도
2019R1A2C2002358	202111	Atomic cross-chain settlement model for central banks digital currency	Lee, Yunyoung; Son, Bumho; Jang, Huisu; Byun, Junyoung; Yoon, Taeho; Lee, Jaewook;	SCI	INFORMATION SCIENCES	580(0)	국외	SCI등재	6.795	아니오	40
2019R1A2C2002358	202112	Fair Clustering with Fair Correspondence Distribution	Lee, Woojin; Ko, Hyungjin; Byun, Junyoung; Yoon, Taeho; Lee, Jaewook;	SCI	INFORMATION SCIENCES	581(0)	국외	SCI등재	6.795	아니오	40
2019R1A2C2002358	202201	Graph-based multi-factor asset pricing model	Son, Bumho; Lee, Jaewook;	SSCI	FINANCE RESEARCH LETTERS	44()	국외	SCI등재	9.848	아니오	40
2019R1A2C2002358	202206	The economic value of NFT: Evidence from a portfolio analysis using mean-variance framework	Ko, Hyungjin; Son, Bumho; Lee, Yunyoung; Jang, Huisu; Lee, Jaewook;	직접입력	FINANCE RESEARCH LETTERS	47()	국외	SCI등재	9.846	아니오	50
2019R1A2C2002358	202209	Variational cycle-consistent imputation adversarial networks for general missing patterns	Lee, Woojin; Lee, Sungyoon; Byun, Junyoung; Kim, Hoki; Lee, Jaewook;	직접입력	PATTERN RECOGNITION	()	국외	SCI등재	8.518	아니오	50

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

전문학술지 논문게재 성과정보											
과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동연구논문	기여도
2019R1A2C2002358	202301	Exploring Diverse Feature Extractions for Adversarial Audio Detection	Choi, Yujin; Park, Jinseong; Lee, Jaewook; Kim, Hoki;	SCI	IEEE ACCESS	(0)	국외	SCI등재	3.9	아니오	50
2019R1A2C2002358	202301	Efficient differentially private kernel support vector classifier for multi-class classification	Park, Jinseong; Choi, Yujin; Byun, Junyoung; Lee, Jaewook; Park, Saerom;	SCI	INFORMATION SCIENCES	(0)	국외	SCI등재	8.1	아니오	30
2019R1A2C2002358	202302	Non-fungible tokens: a hedge or a safe haven	Ko Hyungjin; Lee Jaewook;	직접입력	Applied Economics Letters	1(0)	국외	SCI등재	1.157	아니오	50
2019R1A2C2002358	202302	GradDiv: Adversarial Robustness of Randomized Neural Networks via Gradient Diversity Regularization	Lee, Sungyoon; Kim, Hoki; Lee, Jaewook;	SCI	IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE	()	국외	SCI등재	23.6	아니오	100
2019R1A2C2002358	202305	Efficient homomorphic encryption framework for privacy-preserving regression	Byun, Junyoung; Park, Saerom; Choi, Yujin; Lee, Jaewook;	직접입력	APPLIED INTELLIGENCE	53(9)	국외	SCI등재	5.019	아니오	50
2019R1A2C2002358	202305	Dissecting the Terra-LUNA crash: Evidence from the spillover effect and information flow	Lee, Seungju; Lee, Jaewook; Lee, Yunyoung;	SCI	FINANCE RESEARCH LETTERS	53(0)	국외	SCI등재	10.4	아니오	40

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

전문학술지 논문게재 성과정보

과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동연구논문	기여도
2019R1A2C2002358	202305	Generating Transferable Adversarial Examples for Speech Classification	Kim, Hoki; Park, Jinseong; Lee, Jaewook;	SCI	PATTERN RECOGNITION	137(0)	국외	SCI등재	8	아니오	50
2019R1A2C2002358	202306	A Privacy-preserving mean-variance optimal portfolio	Byun, Junyoung; Ko, Hyungjin; Lee, Jaewook;	SCI	FINANCE RESEARCH LETTERS	54(0)	국외	SCI등재	10.4	아니오	30
2019R1A2C2002358	202307	Forecasting global stock market volatility: The impact of volatility spillover index in spatial-temporal graph-based model	Son, Bumho; Lee, Yunyoung; Park, Seongwan; Lee, Jaewook;	직접입력	JOURNAL OF FORECASTING	42(7)	국외	SCI등재	3.4	아니오	50
2019R1A2C2002358	202309	Fast sharpness-aware training for periodic time series classification and forecasting	Park, Jinseong; Kim, Hoki; Choi, Yujin; Lee, Woojin; Lee, Jaewook;	SCI	APPLIED SOFT COMPUTING	144(0)	국외	SCI등재	8.7	아니오	30
2019R1A2C2002358	202310	Bridged adversarial training	Kim, Hoki; Lee, Woojin; Lee, Sungyoon; Lee, Jaewook;	SCI	NEURAL NETWORKS	167(0)	국외	SCI등재	7.8	아니오	50
2019R1A2C2002358	202401 (Accept)	Sequence and longevity risks of South Korean retirees: Insights and potential	Hyungjin Ko, Seungyun Lee		Pacific-Basin Finance Journal		국외	SCI등재	4.0		

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		remedies									
2019R1A2C2002358	202401 (Accept)	A Novel Integration of the Fama-French and Black-Litterman Models to Enhance Portfolio Management	Hyungjin Ko, Bumho Son		Journal of International Financial Markets, Institutions and Money		국외				

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

지식재산권 성과정보

과제번호	출원등록연월	재산권구분	출원등록구분	발명제목	출원등록인	출원등록국	발명자명	출원등록번호	활용형태	기여도
2019R1A2C2002358	20201104	특허	출원	공정 분포 추정을 통한 공정 군집화 방법 및 그의 장치	서울대학교 산학협력단	대한민국	이재욱, 변준영, 윤태호, 고형진, 이우진	10-2020-0146312	보유기관자체활용	50
2019R1A2C2002358	20201104	특허	출원	손실 산입 학습 방법, 그의 장치, 기록 매체 및 이를 적용한 전자 디바이스	서울대학교 산학협력단	대한민국	이재욱, 이성윤, 김호기, 이우진, 변준영	10-2020-0146311	보유기관자체활용	50
2019R1A2C2002358	20201105	특허	출원	클래스 의존적 도메인 유사화 학습 방법, 장치 및 컴퓨터 판독 가능한 기록 매체	서울대학교 산학협력단	대한민국	이재욱, 김호기, 이우진	10-2020-0147036	보유기관자체활용	50
2019R1A2C2002358	20210504	특허	출원	동형 암호를 활용한 사적 변수의 보안 방법 및 장치	서울대학교 산학협력단	대한민국	이재욱, 변준영	10-2021-0057872	보유기관자체활용	100
2019R1A2C2002358	20210824	특허	출원	동형 암호를 활용한 사적 변수의 보안 방법 및 장치	서울대학교 산학협력단	대한민국	이재욱, 변준영	10-2021-0111809	보유기관자체활용	100
2019R1A2C2002358	20220629	특허	출원	동형 암호를 활용한 사적 변수의 보안 방법 및 장치	서울대학교 산학협력단	미국	이재욱, 변준영	17/853798	미활용	100
2019R1A2C2002358	20230625	특허	출원	동형 암호를 이용한 투자 포트폴리오 제공 장치 및 방법	서울대학교 산학협력단	대한민국	이재욱, 변준영, 고형진	10-2023-0080813	미활용	50
2019R1A2C2002358	20230705	특허	출원	적대적 음성 예제 생성 방법 및 시스템	서울대학교 산학협력단	대한민국	이재욱, 박진성, 김호기	10-2023-0087006	미활용	50
2019R1A2C2002358	20230705	특허	출원	적대적 음성 예제를 감지 방법 및 시스템	서울대학교 산학협력단	대한민국	이재욱, 박진성, 김호기, 최유진	10-2023-0087024	미활용	50

학술대회 논문발표 성과정보

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

과제번호	발표년월	학술대회명	저자	논문제목	학술대회구분	개최국	온라인개최
2019R1A2C2002358	202206	2022 대한산업공학회 춘계공동학술대회	이승주, 박진성, 최유진, 정우진, 박성완, 이재욱	사업보고서 기반 국내 주식간 관계 추출 및 시각화	국내학술대회	대한민국	
2019R1A2C2002358	201912	The 20th Asia Pacific Industrial Engineering and Management Systems	Byun, Junyoung; Lee, Jaewook	Improving RL-based Sequence Generation Network with Additional Value Function	국제학술대회	일본	
2019R1A2C2002358	201912	The 20th Asia Pacific Industrial Engineering and Management Systems	Kim, Hoki; Yoon, Taeho; Lee, Jaewook	Defending Against Adversarial Attack via Bayesian Neural Network	국제학술대회	일본	
2019R1A2C2002358	202002	The AAAI-20 Workshop on Engineering Dependable and Secure Machine Learning Systems	Woojin Lee; Sungyoon Lee; Hoki Kim; Jaewook Lee	Sliced Wasserstein Adversarial Training for Defending Against Adversarial Attacks,	국제학술대회	미국	
2019R1A2C2002358	202012	Thirty-fourth Conference on Neural Information Processing Systems	Sungyoon Lee; Jaewook Lee; Saerom Park	Lipschitz-Certifiable Training with a Tight Outer Bound	국제학술대회	캐나다	Y
2019R1A2C2002358	202102	The 35th AAAI Conference on Artificial Intelligence	Hoki Kim; Woojin Lee; Jaewook Lee	Understanding Catastrophic Overfitting in Single-step Adversarial Training	국제학술대회		Y
2019R1A2C2002358	202112	Thirty-fifth Conference on Neural Information Processing Systems	Sungyoon Lee; Woojin Lee; Jinseong Park; Jaewook Lee	Towards Better Understanding of Training Certifiably Robust Models against Adversarial Examples	국제학술대회		Y
2019R1A2C2002358	202112	Thirty-fifth Conference on Neural Information Processing Systems	Junyoung Byun; Woojin Lee; Jaewook Lee	Parameter-free HE-friendly Logistic Regression	국제학술대회		Y
2019R1A2C2002358	202209	ECML-PKDD 2022 MIDAS Workshop	Hyungjin Ko; Bumho Son; Jaewook Lee	Examining the Spillover and Diversification Effect of Non-Fungible Token Market	국제학술대회	프랑스	
2019R1A2C2002358	202209	ECML-PKDD 2022 MIDAS Workshop	Bumho Son; Hyungjin Ko; Jaewook Lee	Latent Factor Model for Empirical Asset Pricing via Graph Convolutional Network	국제학술대회	프랑스	
2019R1A2C2002358	202307	International Conference on Machine Learning (ICML)	Lee, Sungyoon; Park, Jinseong; Lee	Implicit Jacobian regularization weighted with impurity of	국제학술대회	미국	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

			Jaewook;	probability output			
2019R1A2C2002358	202307	International Conference on Machine Learning (ICML)	Park, Jinseong; Kim, Hoki; Choi, Yujin; Lee, Jaewook;	Differentially Private Sharpness-Aware Training	국제학술대회	미국	
2019R1A2C2002358	202308	International Joint Conference on Artificial Intelligence (IJCAI)	Byun, Junyoung; Lee, Jaewook;	Fast and Differentially Private Fair Clustering	국제학술대회	마카오	
2019R1A2C2002358	202312	Advances in Neural Information Processing Systems 36 (NeurIPS 2023)	Kim, Hoki; Park, Jinseong; Choi, Yujin; Lee, Jaewook;	Fantastic Robustness Measures: The Secrets of Robust Generalization	국제학술대회	미국	

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임2-1] 연구책임자(해당 시 참여연구자(공동) 포함) 대표적 연구실적

○ 논문 및 특허 실적(최대 5개 작성)(파란색 글자는 예시임)

번호	구분 (논문/특허)	논문명/특허명	소속기관명	역할	논문게재지/특허등록국가	논문게재일/특허등록일	특기사항
1	논문	Fair Clustering with Fair Correspondence Distribution	서울대학교	교신저자	Information Sciences	2021.09	
2	논문	Variational cycle-consistent imputation adversarial networks for general missing patterns	서울대학교	교신저자	Pattern Recognition	2022.09	
3	논문	GradDiv: Adversarial Robustness of Randomized Neural Networks via Gradient Diversity Regularization	서울대학교	교신저자	IEEE Transactions on Pattern Analysis and Machine Intelligence	2023.02	
4	논문	Generating Transferable Adversarial Examples for Speech Classification	서울대학교	교신저자	Pattern Recognition	2023.05	
5	논문	Bridged adversarial training	서울대학교	교신저자	Neural Networks	2023.10	

○ 기타 실적(논문 및 특허 외 기타 실적 입력)

해당 없음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

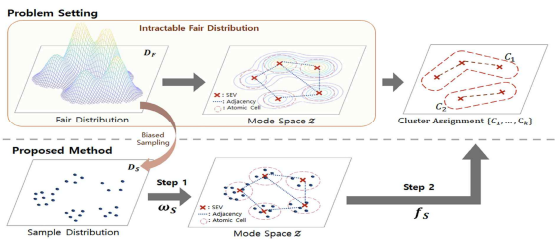
※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임2-2] 주관연구책임자(해당 시 참여연구자(공동) 포함) 대표적 논문·특허실적 요약문

연구실적 유형		논문(O) 특허( )		
연구책임자 성명		이재욱		
논문/특허명		Fair Clustering with Fair Correspondence Distribution		
논문실적정보 ▣	게재지(저널명)	Information Sciences		
	SCI 등재 여부	등재	인용횟수(SCI)	9회 (Google 학술검색 기준)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	9회 (Google 학술검색 기준)
	ISSN	0020-0255	게재년월	202109
	역할(제1, 교신, 참여)	교신저자	참여자수	5명
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

최근 기계학습 분야에서 공정한 알고리즘에 대한 필요성이 크게 증대되고 있으며, 기계학습의 대표적인 문제인 군집화 문제에서도 이러한 공정한 군집화 알고리즘에 대한 개발이 요구되고 있음. 이러한 문제를 해결하기 위해 본 연구는 차별을 완화할 수 있는 새롭고 창의적인 군집화 알고리즘을 개발함. 구체적으로, 연구진은 사회적으로 편향된 샘플 분포를 고려하여 공정한 대응 분포 내에서 군집을 찾으려는 독창적인 분포 기반 공정 군집 방법론을 개발함. 개발된 알고리즘은 전체 데이터를 여러 개의 작은 부군집으로 나누고, 각 군집에 속한 각 집단의 비율이 일정하도록 부군집들을 계층적으로 묶어 최종 군집을 산출하는 방식으로 작동하여 기존의 방식과는 차별성을 가짐.



[그림] 본 논문에서 제안된 분포 기반 공정 군집 방법론

이때, 군집화 문제에서 공정성이란 각 군집 내에서 다른 민감한 속성값에 대한 데이터 비율을 균형 있게 유지하는 측면에서 정의됨. 제안된 방법론은 지지 벡터 방법과 동적 시스템을 사용하여 전체 데이터 공간을 원자 셀로 나눈 다음 공정하게 재결합하여 군집을 형성하는 기존과는 다른 혁신적인 방식으로 작동함. 본 연구진은 원자 셀이 공정하게 연결될 때, 공정한 대응 분포 내 군집 함수의 일반화 오류 상한을 이론적으로 도출하는 데 성공하였고, 이를 통해 기존 모형들보다 더 큰 공정성을 달성함. 또한 실험 결과는 개발된 알고리즘이 다양한 데이터셋에서 공정성을 성공적으로 향상시킬 수 있으며 기존보다 더욱 최적화된 계산 시간을 가질 수 있음을 실증적으로 보임.

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
현실에서 획득할 수 있는 데이터는 생성 과정에서 자연스럽게 인간 사회에서의 편향성이 내재 될 수 있음. 예를 들어 취업에 관한 데이터의 경우, 역사적으로 남성의 성공 사례가 많아 기계학습 과정에서 이러한 데이터의 편향이 그대로 반영되어 학습의 결과가 소수 집단에 차별을 가할 수 있음. 또 다른 예로는 기계학습 기반 추천 시스템이 군집화 결과를 토대로 맞춤형 광고나 채용 제안을 할 때, 편향된 군집화로 인해 소수 집단의 기회를 박탈할 수 있음. 따라서, 이를 악용한 적대적 공격은 심각한 사회적 문제를 초래할 수 있음. 공정한 학습의 문제는 본 연구과제의 핵심 계획과 밀접한 연관성을 가진다고 할 수 있으며, 긴급한 해결을 요구하는 문제임.	본 연구의 기술적 가치와 중요성은 기존의 방법론의 한계를 해결하는 독창성과 혁신에 있으며, 더욱 적은 계산 비용과 더불어 더 높은 공정성을 확보할 수 있는 등의 효용을 가져옴으로써 관련 분야에 뚜렷하고 진보된 기여를 함. 따라서 본 연구는 해당 학문 분야의 지식과 이해를 풍부하게 할 충분한 잠재력을 가지고 있으며, 더 나아가 이 연구의 함의는 향후 공정한 기계학습에 대한 학문적 발전과 지식 및 이해 증진에 대한 선구적인 연구로써의 영향력에 있음. 따라서, 본 연구는 안전하고 공정한 인공지능의 지속 가능한 통합을 위한 강인하고 편향에 저항력 있는 인공지능 시스템 개발의 초석을 다졌다는 점에 의의가 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Information Sciences 581 (2021) 155–178

Contents lists available at ScienceDirect

Information Sciences

journal homepage: www.elsevier.com/locate/ins

Fair Clustering with Fair Correspondence Distribution

Woojin Lee [c], Hyungjin Ko [a], Junyoung Byun [a], Taeho Yoon [b], Jaewook Lee [a,*]

[a] Industrial Engineering, Seoul National University, 1 Gwanakro, Gwanak-gu, Seoul 08826, Republic of Korea
[b] Mathematical Sciences, Seoul National University, 1 Gwanakro, Gwanak-gu, Seoul 08826, Republic of Korea
[c] School of AI Convergence, Dongguk University-Seoul, 30 Pildong-ro 1-gil, Jung-gu, Seoul 04620, South Korea

ARTICLE INFO

Article history:
Received 31 May 2021
Received in revised form 29 July 2021
Accepted 5 September 2021
Available online 8 September 2021

Keywords:
Fair clustering
Support vector clustering
Fair distribution

ABSTRACT

In recent years, the issue of fairness has become important in the field of machine learning. In clustering problems, fairness is defined in terms of consistency in that the balance ratio of data with different sensitive attribute values remains constant for each cluster.

Fairness problems are important in real-world applications, for example, when the recommendation system provides targeted advertisements or job offers based on the clustering result of candidates, the minority group may not get the same level of opportunity as the majority group if the clustering result is unfair. In this study, we propose a novel distribution-based fair clustering approach. Considering a distribution in which the sample is biased by society, we try to find clusters from a fair correspondence distribution. Our method uses the support vector method and a dynamical system to comprehensively divide the entire data space into atomic cells before reassembling them fairly to form the clusters. Theoretical results derive the upper bound of the generalization error of the corresponding clustering function in the fair correspondence distribution when atomic cells are connected fairly, allowing us to present an algorithm to achieve fairness. Experimental results show that our algorithm beneficially increases fairness while reducing computation time for various datasets.

© 2021 Elsevier Inc. All rights reserved.

1. Introduction

With machine learning increasingly influencing decisions on important aspects of our lives, such as advertising, employment, and criminal justice, the demand for a fair machine learning model has also increased rapidly in recent years. While there is little doubt regarding the effectiveness and versatility of machine learning algorithms, we are increasingly focusing on the objectivity of algorithms. It requires not only high performance but also impartiality toward specified sensitive attributes in a population, such as sex, gender, or race.

A misconception about machine learning is that it is absolutely impartial. However, as machine learning relies on training data, algorithms may exhibit biases toward specific demographic groups because of biased samples. For example, facial recognition shows a better accuracy on white, male faces [9], and a model for criminal recidivism is likely to show a much higher false positive rate for black defendants than white defendants [1]. Additionally, gender stereotypes are reflected in word2vec embeddings [8].

* Corresponding author.
E-mail address: jaewook@snu.ac.kr (J. Lee).

https://doi.org/10.1016/j.ins.2021.09.010
0020-0255/© 2021 Elsevier Inc. All rights reserved.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

4.3.3. Discussion

In most experiments, our algorithm gave more balanced clustering results, than the fairlets-based model. In addition, the execution time of our algorithm was always significantly shorter than that of the fairlets algorithm, which sometimes required hours for an optimization. While the time complexity of our model was consistent with the number of clusters, the fairlets algorithm displayed an exponential growth in time consumption with an increase in k.

Our method is based on SVC, which accurately detects non-convex clusters by sequentially merging the most adjacent cells. However, our method sometimes combines atomic cells that are sub optimal in terms of adjacency, to find balanced clusters. Hence, the clustering results might deviate from the intuitive image of an ideal clustering. Nevertheless, it is a natural consequence of the trade-off between fairness and performance in machine learning models.

We have applied our method on three real-world dataset (Recruitment, Heart, and Stroke) from Kaggle, and our method has successfully obtained fair clustering results. Fair clustering results can be widely used when having a decision making on policies or strategies. For example, fair clustering results on Recruitment dataset can be used when the government plans to provide social aids to job applicants based on clustering results. Or it can be used for companies are trying to hire based on clustering results while considering fairness issues.In addition, the results for the Heart and Stroke dataset can be utilized when governments are trying to provide social assistance based on individual health care datasets with the majority and minority ratios maintained.

5. Conclusion

In this study, we presented a new perspective to address the fair clustering problem based on data distribution. We hypothesized that a fair clustering can be achieved by tracing a fair correspondence distribution from the sample distribution, which is considered biased because of real-world problems. Based on the theoretical results, we proposed an efficient cluster labeling framework at an atomic-cell level with an upper bound on the generalization error of the resulting clustering function.

Our study can be extended in several ways. Here we propose a greedy amalgamation of sub-clusters, grounded on the precision guarantee for an optimal labeling method over the mode space. However, it may be possible to improve this methodology through a direct approximation of the fair density. In addition, the time complexity may be reduced further if we choose different methods for density estimation. We anticipate that distribution-based approach can be naturally applied to other important tasks such as fair classification, in addition to the fair clustering problems treated here.

At last, the term 'balance' used in fair clustering is focused on binary variable. As a result, various previous works and our paper only considered the sensitive attributes on binary cases. However, recently using binary attributes is not modern enough. For example, 'sex' should be considered as a complex point of view [27]. For future work, we will work on suggesting an algorithm that can consider various types of sensitive attributes.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgement

This work was supported by the National Research Foundation of Korea (NRF) grant funded by the Korean government (MSIT) (NRF- 2019R1A2C2002358).

Appendix A. Definitions, Proof of Theorems, and Additional Explanations

First we will provide basic definitions related with generalization error and PAC learning as in [26]. Given a hypothesis $h \in \mathcal{H}$, a target concept $c : \mathcal{X} \to \mathcal{Y}$, a loss function $L : \mathcal{Y} \times \mathcal{Y} \to \Re^+$, and an underlying distribution D,

(i) the *generalization error* or *risk* of h is defined by

$$\begin{aligned} R_D(h) &= \mathbb{E}_{x\sim D}[L(h(x), c(x))] \quad \text{(regression)} \\ &= \mathbb{P}_{x\sim D}[h(x) \neq c(x)] = \mathbb{E}_{x\sim D}\left[1_{h(x)\neq c(x)}\right] \quad \text{(binary classification)} \end{aligned}$$

(ii) the *empirical error* or *empirical risk* of h for a sample $\hat{\mathcal{D}}_N = \{x_1, .., x_N\}$ is defined by

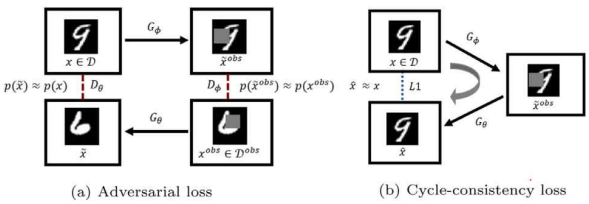
$$\begin{aligned} \widehat{R}_{\hat{D}_N}(h) &= \frac{1}{N}\sum_{i=1}^{N}[L(h(x_i), c(x_i))] \quad \text{(regression)} \\ &= \frac{1}{N}\sum_{i=1}^{N}\left[1_{h(x_i)\neq c(x_i)}\right] \quad \text{(binary classification)} \end{aligned}$$

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구실적 유형		논문(O) 특허( )		
연구책임자 성명		이재욱		
논문/특허명		Variational cycle-consistent imputation adversarial networks for general missing patterns		
논문실적정보 ■	게재지(저널명)	Pattern Recognition		
	SCI 등재 여부	등재	인용횟수(SCI)	4회 (Google 학술검색 기준)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	4회 (Google 학술검색 기준)
	ISSN	0031-3203	게재년월	202209
	역할(제1, 교신, 참여)	교신저자	참여자수	5명
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 연구는 누락된 데이터의 보완 문제를 해결함. 이전의 보완 모델들은 특정한 누락 데이터 분포를 가정하여 문제를 해결했지만, 실제로는 누락 데이터의 분포가 알려지지 않았기 때문에 가장 일반적인 누락 패턴을 고려해야 함. 본 연구에서는 이러한 누락 패턴을 밀접하게 발견하기 위해 순환 일관성 보완 적대 네트워크를 제시하고, 적대적 학습을 사용하여 가장 일반적인 누락 패턴을 성공적으로 학습함. 이 방법은 다양한 보완 문제에 적용될 수 있으며, 수치 및 이미지 데이터로 실험적으로 평가한 결과, 정량적 및 정성적으로 높은 성능을 나타냄.



[그림] 본 논문에서 제안된 Cycle-GAN Imputation 방법

본 연구의 주요 기여도는 다음과 같음. 제안된 모델은 누락 패턴에 대한 가정 없이 모든 유형의 데이터 누락 패턴을 학습할 수 있어, 다양한 보완 문제에 적용될 수 있음. 나아가, 변분 접근 방식에 기반한 이론적 배경을 제공함. 변분 추론의 관점에서, 이 방법은 불완전 데이터와 완전 데이터 사이의 결합 분포를 근사하며, 완전 데이터에 접근할 수 있고 모델이 수렴할 때 누락 및 보완 프로세스를 학습할 수 있음을 보여줌. 마지막으로, 제안된 모델은 교차 도메인 변환의 프레임워크를 도입함으로써 최신 모델들을 능가함. 수치 데이터셋뿐만 아니라 이미지 데이터셋에서도 우수한 성능을 정량적으로 보여주며, 누락 패턴을 성공적으로 학습하고 누락된 데이터를 보완하는 것을 정성적으로 시각화함.

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 연구는 데이터의 매니폴드를 찾고, 이를 형성하는 과정에서 본 연구 과제와 밀접한 연관이 있음. 본 연구의 목표는 데이터의 누락 패턴을 밀접하게 발견하여 학습하는 것임. 데이터의 누락된 패턴을 잘 학습한 모델이 있다면 데이터의 매니폴드를 구성하고 이를 임베딩하여 적대적 공격에 강건한 매니폴드를 구성하는 데 큰 도움이 될 수 있음.	본 연구의 접근 방식은 고차원 데이터에서 누락된 데이터의 매니폴드를 탐색하고 학습하는 데 중요한 역할을 할 수 있음. 불완전 데이터와 완전 데이터 사이의 관계를 모델링하고, 이를 통해 누락된 데이터를 보완하는 과정에서 데이터의 본질적인 구조를 학습하는데, 이는 매니폴드 학습의 개념과 일치하며, 추후 딥러닝을 통해 누락된 데이터의 복잡한 구조를 효과적으로 해석하고 재구성하는 데 기여할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Pattern Recognition 129 (2022) 108720

Contents lists available at ScienceDirect

Pattern Recognition

journal homepage: www.elsevier.com/locate/patcog

Variational cycle-consistent imputation adversarial networks for general missing patterns

Woojin Lee[a], Sungyoon Lee[b], Junyoung Byun[c], Hoki Kim[c], Jaewook Lee[c,*]

[a] School of AI Convergence, Dongguk University-Seoul, 30 Pildong-ro 1-gil, Jung-gu, Seoul 04620, Republic of Korea
[b] Center for Artificial Intelligence and Natural Sciences, Korea Institute for Advanced Study (KIAS), 85 Hoegiro, Dongdaemun-gu, Seoul 02455, Republic of Korea
[c] Industrial Engineering, Seoul National University, Gwanakro 1, Seoul 08826, Republic of Korea

ARTICLE INFO

Article history:
Received 20 October 2020
Revised 2 September 2021
Accepted 18 April 2022
Available online 20 April 2022

Keywords:
Imputation
Missing data
Cycle-consistent

ABSTRACT

Imputation of missing data is an important but challenging issue because we do not know the underlying distribution of the missing data. Previous imputation models have addressed this problem by assuming specific kinds of missing distributions. However, in practice, the mechanism of the missing data is unknown, so the most general case of missing pattern needs to be considered for successful imputation. In this paper, we present cycle-consistent imputation adversarial networks to discover the underlying distribution of missing patterns closely under some relaxations. Using adversarial training, our model successfully learns the most general case of missing patterns. Therefore our method can be applied to a wide variety of imputation problems. We empirically evaluated the proposed method with numerical and image data. The result shows that our method yields the state-of-the-art performance quantitatively and qualitatively on standard datasets.

© 2022 Elsevier Ltd. All rights reserved.

1. Introduction

Deep learning society has grown tremendously in recent years, leading to increasing demand for large amounts of data. However, since procuring complete data is rarely feasible in the real world, it is very important to recover at least enough information to analyze from incomplete data [1,2]. A common method to deal with this problem is to build an appropriate algorithm to impute the missing data.

There are three types of missing pattern assumptions used according to the dependency: (1) The data is missing completely at random (MCAR) if its missingness occurs completely randomly regardless of the value of the data. Assuming the missing pattern to be MCAR is a simple approach, but an unrealistically strong assumption in practice. (2) The data is missing at random (MAR) if the missing data depends on observed data but not on unobserved data. (3) The last type of missing pattern is missing not at random (MNAR), where the missing data depends on unobserved data as well as observed data [3]. It is the most general case of missing, since it can encompasses all types of missing patterns. In the real world, since the true missing pattern is unknown, the most general case of missing pattern needs to be considered for successful imputation.

Previous approaches to missing data imputation are based on a sequential equation [4] or the EM algorithm [5]. Recently, deep learning has been widely adopted in missing data imputation [6–11]. Deep learning-based methods have extended their imputation applications to high-dimensional image data [12].

Constructing an missing value imputation model is a different and more challenging problem than standard learning procedures, due to two main reasons. First, there are no complete and incomplete data pairs, i.e., it is impossible to know the true value of missing part of the incomplete data. Therefore it is infeasible to train a model that predicts the missing value because the true value is not recorded in data. Second, it is hard to know the missing pattern of the data. If we can identify the missing pattern of the data, it will be able to generate a synthetic pair of complete and incomplete data.

Learning-based imputation methods can be categorized as either reconstruction or adversarial training. Reconstruction based approach focuses on reconstructing a predicted sample similar to the original data, by generating synthetic missing data from complete data. Adversarial training based approach tries to generate a realistic imputed sample, by using GAN [13] based loss functions.

* Corresponding author. Industrial Engineering, Seoul National University, Gwanakro 1, Seoul 08826, Republic of Korea
E-mail address: jaewook@snu.ac.kr (J. Lee).

https://doi.org/10.1016/j.patcog.2022.108720
0031-3203/© 2022 Elsevier Ltd. All rights reserved.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

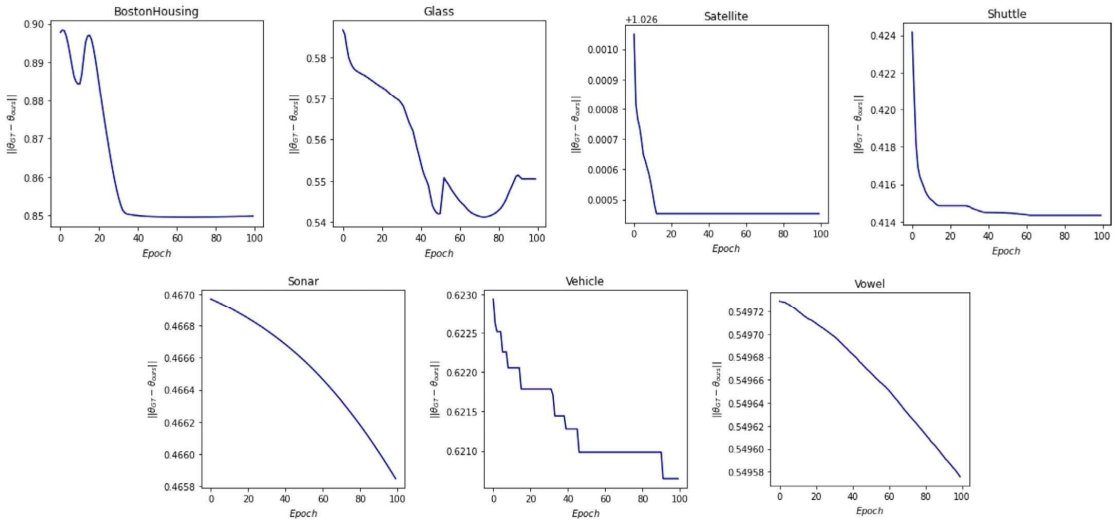


Fig. 10. L2 distance between the ground-truth missing parameter θ_{gt} and our parameter θ_{ours}.

parameter θ_{gt} so that θ_{gt} is the parameter we want to estimate.

Then, we apply our method on this setting, where we set our missing generator G_θ as the same structure as Eq. (19), as follows:

$$G_\theta = \mathrm{ReLU}(x\theta_{ours}), \tag{20}$$

where θ_{ours} is the parameter that will be optimized by Algorithm 1.

Fig. 10 shows the L2 distance between θ_{gt} and θ_{ours} during the training process. In all seven datasets, we can find that during training, the distance between two parameters decreases. It implies that our proposed method has successfully estimated the ground-truth missing mechanism G_θ by optimizing the weights θ_{ours}.

6. Discussion and future work

In this paper, we have proposed a effective imputation method that can be applied to various types of missing data patterns, including data. Our model learns to generate fake incomplete data indistinguishable from real missing data, and thus better impute the incomplete data by considering the missing pattern.

Our theoretical analysis approximates the ground-truth joint distribution of the complete and incomplete data $q_\phi(x, x^{obs})$ through a variational joint $p_\theta(x, x^{obs})$ as shown in Eq. (12). However, since the two processes q_ϕ and p_θ are estimated jointly with adversarial loss and cycle-consistency loss function as in Algorithm 1, it is not theoretically proved that our proposed method can converge to the ground-truth missing parameters. In response, we have done experiments in Section 5.5, showing that our method can estimate the ground-truth missing patterns in synthetic Gaussian experiments and real-world experiments. However, even though we observed that the proposed model can successfully model the underlying missing distribution, more theoretical analysis must be performed.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Acknowledgements

Sungyoon Lee is supported by a KIAS Individual Grant (AP083601) via the Center for AI and Natural Sciences at Korea Institute for Advanced Study. This work was supported by the National Research Foundation of Korea (NRF) grant funded by the Korean government (MSIT) (NRF-2019R1A2C2002358). This work was supported by Institute of Information & communications Technology Planning & Evaluation (IITP) grant funded by the Korea government (MSIT) (No.2021-0-02068, Artificial Intelligence Innovation Hub).This research was supported by the MSIT (Ministry of Science and ICT), Korea, under the ITRC (Information Technology Research Center) support program (IITP-2022-2020-0-01789) supervised by the IITP (Institute for Information & Communications Technology Planning & Evaluation).

Appendix A. Proofs of theoretical results

Proof of Theorem 1

Proof. From the definition of $\mathcal{L}_{NELP}(\theta, \phi)$ and by the assumption $p_\theta(x|x^{obs}) = \mathcal{N}(x|G_\theta(x^{obs}), \frac{1}{2\gamma}I)$, we have

$$\begin{aligned}
\mathcal{L}_{NELP}(\theta,\phi) &= \mathbb{E}_{q^*(x)p(\epsilon)}[-\ln p_\theta(x|G_\phi(x,\epsilon))] \\
&= \gamma\,\mathbb{E}_{q^*(x)p(\epsilon)}[||x - G_\theta(G_\phi(x,\epsilon))||_2^2] + \frac{d}{2}\ln(\pi/\gamma) \\
&= \gamma V_{cyc}(G_\phi, G_\theta) + \frac{d}{2}\ln(\pi/\gamma) \\
&\simeq \gamma\frac{1}{m}\sum_{i=1}^{m}[||x_i - G_\theta(G_\phi(x_i,\epsilon_i))||_2^2] \\
&\quad + \frac{d}{2}\ln(\pi/\gamma) \text{ as } m \to \infty
\end{aligned}$$

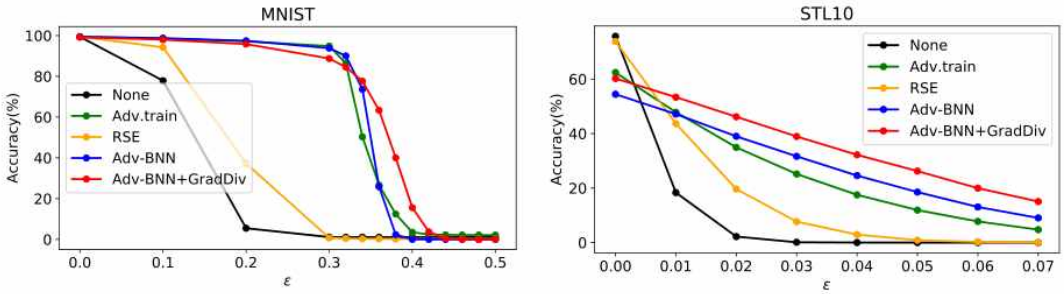
□

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구실적 유형		논문(O) 특허( )		
연구책임자 성명		이재욱		
논문/특허명		GradDiv: Adversarial Robustness of Randomized Neural Networks via Gradient Diversity Regularization		
논문실적정보 ▣	게재지(저널명)	IEEE Transactions on Pattern Analysis and Machine Intelligence		
	SCI 등재 여부	등재	인용횟수(SCI)	36회 (Google 학술검색 기준)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	36회 (Google 학술검색 기준)
	ISSN	0162-8828	게재년월	202302
	역할(제1, 교신, 참여)	교신저자	참여자수	3명
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 연구는 무작위 신경망의 적대적 강인성을 향상시키기 위한 Gradient Diversity(GradDiv) 정규화 기술을 제안하여, 기존 방법들이 실패한 영역에 새로운 접근 방식을 제시함. 본 연구는 기존의 방어 방법들이 적대적 공격에 취약하다는 문제를 해결하기 위해 새로운 시각을 제시하고 있으며, 이를 통해 무작위 신경망의 적대적 강인성을 향상시키는 새로운 방향성을 제시함. 또한, 이 연구는 신경망의 그래디언트 분포와 적대적 공격 간의 관계를 분석하고, 이를 통해 적대적 공격이 덜 효과적인 것을 보여줌으로써 과학기술적으로 중요한 결과를 도출함.



[그림] MNIST와 STL10 데이터셋에서 GradDiv를 적용한 Adv-BNN과 기존 방법 간의 적대적 공격의 세기에 대한 강건성 비교

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 연구 실적은 연구 과제와 밀접한 연관이 있음. 적대적 공격을 방어하기 위해서 본 연구를 통해 적대적 공격을 방어할 수 있는 새로운 시각을 제공하여, 적대적 공격에 더욱 강건한 모델을 학습할 수 있게 됨.	본 연구는 기존의 방어 방법들이 방어에 실패한 원인을 분석하고, 이를 보완하기 위한 새로운 정규화 기술을 제안함으로써, 연구의 창의성과 독창성을 입증함. 또한, 이러한 새로운 방법이 관련 학문 분야의 지식과 이해를 증진시키고 향후 학문 발전에 기여할 수 있음.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

GradDiv: Adversarial Robustness of Randomized Neural Networks via Gradient Diversity Regularization

Sungyoon Lee, Hoki Kim, and Jaewook Lee

Abstract—Deep learning is vulnerable to adversarial examples. Many defenses based on randomized neural networks have been proposed to solve the problem, but fail to achieve robustness against attacks using proxy gradients such as the Expectation over Transformation (EOT) attack. We investigate the effect of the adversarial attacks using proxy gradients on randomized neural networks and demonstrate that it highly relies on the directional distribution of the loss gradients of the randomized neural network. We show in particular that proxy gradients are less effective when the gradients are more scattered. To this end, we propose Gradient Diversity (GradDiv) regularizations that minimize the concentration of the gradients to build a robust randomized neural network. Our experiments on MNIST, CIFAR10, and STL10 show that our proposed GradDiv regularizations improve the adversarial robustness of randomized neural networks against a variety of state-of-the-art attack methods. Moreover, our method efficiently reduces the transferability among sample models of randomized neural networks.

Index Terms—Adversarial robustness, defense against adversarial attacks, randomized neural networks, directional analysis

1 Introduction

Deep learning has achieved successful performance in many applications which deal with natural images. However, it has been shown that a small adversarially-designed perturbation to a natural image can fool deep neural networks [1]. Such perturbed images are called adversarial examples. Subsequent research has been conducted on generating adversarial examples and defending against these adversarial attacks [2], [3], [4], [5].

One attempt to defend against adversarial attacks is to construct a randomized neural network which uses different networks for each inference [6], [7], [8]. By doing so, even in the white-box setting, where the adversary has full access to the network and the defense strategy implemented, it is infeasible to utilize the gradient of the inference model to construct adversarial examples since the adversary cannot specify the model used in the inference phase.

However, the attack algorithm Expectation over Transformation (EOT) successfully circumvents the previous randomized defenses by using the expected gradient over the randomization as an alternative to the true gradient of the inference model [9], [10]. EOT approximates the expected gradient by the sample mean using Monte Carlo estimation with sample models from the randomized network. EOT can be considered as a kind of substitute-based transfer attack in the sense that the adversary has no direct access to the inference model to be randomly sampled, utilizes the averaged classifier of the randomized network as a substitute and transfers its adversarial examples to attack the inference model. Therefore, the success of EOT can be attributed to the high transferability among sample models of randomized networks that measures how one model is vulnerable to adversarial examples generated from another.

There has been a line of work on understanding transferability and measuring the effectiveness of transfer attacks [11], [12], [13], [14]. One explanation of the transferability is that it comes from the similarity between the gradients of the target and surrogate model [12]. In particular, sample models of a randomized network tend to have highly aligned gradients as shown in Fig. 1 (left, black).

In this paper, we aim to answer the following question: *"How can we build a robust randomized neural network against adversarial attacks?"* To answer this question, we first investigate the effect of adversarial attacks using proxy gradients on the randomized neural networks and find that the expected gradient used in the EOT attack is locally the optimal direction to maximize the expected loss increase. Next, we demonstrate that the expected loss increase caused by proxy gradients is upper bounded by the Mean Resultant Length (MRL) of the loss gradients. Intuitively, in the extreme case in which the gradient directions are uniformly distributed (zero MRL), any proxy gradient (for example, the sample mean used in the EOT attack) is meaningless in constructing adversarial examples. Therefore, we propose regularizations called *GradDiv* to disperse the gradient distribution as in Fig. 1 (right, red). In this way, we could build a robust randomized network against adversarial attacks.

To summarize, the main contributions are as follows:

- We analyze the relationship between a randomized neural network's gradient distribution and its robustness against adversarial attacks using proxy gradients and show that the adversarial attacks are less effective when the gradients are more scattered.
- We propose regularization methods collectively called GradDiv which encourage a randomized network's gradient dispersal by penalizing concentration.
- We test GradDiv on MNIST, STL10, and CIFAR10, and empirically demonstrate that GradDiv successfully leads to gradient dispersion and improves the robustness of the randomized network. Moreover, GradDiv makes sample models of the randomized network significantly less transferable to each other.

2 Literature Review

*Stochastic Defenses.*Many methods [6], [7], [8], [15], [16], [17], [18], [19] have been proposed to defend against adversarial attacks by introducing randomness into the classifier. However, they have been broken by a stronger adaptive proxy-gradient-based attack [10], [20], [21].

One line of work introduced random transformations to the inputs before feeding them into the classifier. Guo *et al.* [6] used input transformations such as bit-depth reduction, JPEG compression, total variation minimization, and image quilting, and Xie *et al.* [7] used the transformation that resizes the input to a random size and randomly pads the resized input with zeros. However, Athalye *et al.* [10] have shown that these defenses [6], [7] rely on obfuscated gradients and can be completely broken by the EOT attack.

Another line of work proposed to introduce randomness on the layerwise input/activation or the weight. Dhillon *et al.* [8] proposed to prune a random subset of activations and compensate

- *Sungyoon Lee is with the Center for Artificial Intelligence and Natural Sciences, Korea Institute for Advanced Study (KIAS), Seoul 02455, South Korea. E-mail: sungyoonlee@kias.re.kr.*
- *Hoki Kim and Jaewook Lee are with the Department of Industrial Engineering, Seoul National University, Seoul 08826, South Korea. E-mail: {ghrl9613, jaewook}@snu.ac.kr.*

Manuscript received 4 July 2021; revised 26 Jan. 2022; accepted 9 Apr. 2022. Date of publication 21 Apr. 2022; date of current version 6 Jan. 2023.
The work of Sungyoon Lee was supported in part by a KIAS Individual under Grant AP083601 via the Center for AI and Natural Sciences at Korea Institute for Advanced Study. This work was supported in part by the National Research Foundation of Korea (NRF) grant funded in part by Korean Government (MSIT) under Grant NRF-2019R1A2C2002358.
(Corresponding author: Jaewook Lee.)
Recommended for acceptance by A.K. Roy-Chowdhury.
Digital Object Identifier no. 10.1109/TPAMI.2022.3169217

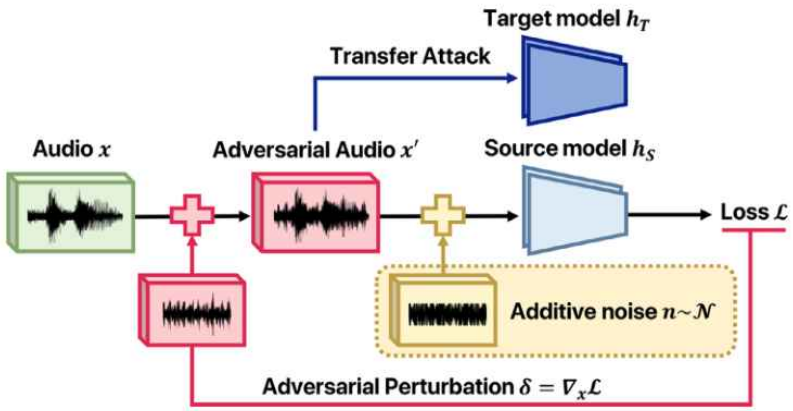
0162-8828 © 2022 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See https://www.ieee.org/publications/rights/index.html for more information.
Authorized licensed use limited to: Seoul National University. Downloaded on January 11,2024 at 15:46:16 UTC from IEEE Xplore. Restrictions apply.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구실적 유형		논문(O) 특허( )		
연구책임자 성명		이재욱		
논문/특허명		Generating Transferable Adversarial Examples for Speech Classification		
논문실적정보 ▣	게재지(저널명)	Pattern Recognition		
	SCI 등재 여부	등재	인용횟수(SCI)	8회 (Google 학술검색 기준)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	8회 (Google 학술검색 기준)
	ISSN	0031-3203	게재년월	202305
	역할(제1, 교신, 참여)	교신저자	참여자수	3명
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 연구는 음성 인식 기술의 취약성과 이에 대한 적대적 공격의 가능성을 탐구하고, 다양한 구조와 조건에서 오디오 적대적 예제의 전이성(transferability)을 조사하여, 음성 인식 기술의 강건성 향상에 대한 인사이트를 제공함.



[그림] 본 논문에서 제안된 noise injected attack (NIA) 방법

과학기술적 관점에서 본 연구의 가장 큰 가치는, 기존의 음성 인식 기술이 적대적 공격에 취약하다는 것을 밝히고, 이를 해결하기 위한 새로운 적대적 공격 방법을 제안하였다는 점임. 기존의 적대적 공격 방법과는 차별화된 노이즈 감수성(noise sensitivity) 개념을 도입하여, 오디오 적대적 예제의 전이성을 향상시킴. 이러한 새로운 방법은 음성 인식 기술의 강건성 향상에 큰 기여를 할 것으로 기대됨. 또한, 본 연구는 기존 연구와는 차별화된 새로운 시각을 제시함. 기존의 연구는 대부분 이미지 분야에서 이루어졌으며, 음성 분야에서의 적대적 공격에 대한 연구는 상대적으로 적은 편임. 본 연구는 이러한 부족한 연구를 보완하고, 음성 분야에서의 적대적 공격에 대한 이해를 높이는 데 큰 역할을 함.

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
연구 계획과 본 실적은 서로 긴밀하게 연관되어 있음. 본 연구는 기존 연구에서는 다루지 않았던 노이즈 감수성 개념을 도입하여, 오디오 적대적 예제의 전이성을 향상시키는 방법을 제안함.	본 방법의 우수성은 다양한 구조와 조건에서 실험을 통해 검증되었으며, 이를 통해 음성 인식 기술의 강건성 향상에 대한 인사이트를 제공함. 또한, 본 연구는 음성 분야에서의 적대적 공격에 대한 이해를 높이는 데 큰 역할을 험. 이러한 결과는 향후 음성 인식 기술의 보안 강화에 큰 도움이 될 것으로 예상됨.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Pattern Recognition 137 (2023) 109286

Contents lists available at ScienceDirect

Pattern Recognition

journal homepage: www.elsevier.com/locate/patcog

Generating Transferable Adversarial Examples for Speech Classification

Hoki Kim, Jinseong Park, Jaewook Lee*

Seoul National University, Gwanakro 1, Seoul, South Korea

ARTICLE INFO

Article history:
Received 22 November 2021
Revised 4 August 2022
Accepted 27 December 2022
Available online 30 December 2022

Keywords:
Speech classification
Adversarial attack
Transferability

ABSTRACT

Despite the success of deep neural networks, the existence of adversarial attacks has revealed the vulnerability of neural networks in terms of security. Adversarial attacks add subtle noise to the original example, resulting in a false prediction. Although adversarial attacks have been mainly studied in the image domain, a recent line of research has discovered that speech classification systems are also exposed to adversarial attacks. By adding inaudible noise, an adversary can deceive speech classification systems and cause fatal issues in various applications, such as speaker identification and command recognition tasks. However, research on the transferability of audio adversarial examples is still limited. Thus, in this study, we first investigate the transferability of audio adversarial examples with different structures and conditions. Through extensive experiments, we discover that the transferability of audio adversarial examples is related to their noise sensitivity. Based on the analyses, we present a new adversarial attack called *noise injected attack* that generates highly transferable audio adversarial examples by injecting additive noise during the gradient ascent process. Our experimental results demonstrate that the proposed method outperforms other adversarial attacks in terms of transferability.

© 2023 Elsevier Ltd. All rights reserved.

1. Introduction

Deep neural networks have shown a promising performance in a wide range of tasks, from image classification to speech recognition. Despite their success, neural networks have been shown to be vulnerable to *adversarial examples* [1,2] generated by adding imperceptible noise to the original example [3]. Recently, researchers have found that adversarial attacks can also be applied to speech classification tasks [4–6]. Considering that speech classification is commercialized in many products, adversarial attacks within the audio domain pose a very high risk.

Similar to the vision domain, adversarial attacks on the audio domain can be roughly classified into three categories: white-box attacks, gray-box attacks and black-box attacks. In white-box settings, information of the speech recognition system is fully accessible so that the attacker knows all the details such as model structure, parameters and defense techniques. In gray-box settings, attacker knows only specific details except some information such as defense techniques. In black-box settings, the attacker can not access to any information except the output prediction of the model. In real-world, black-box attacks are more realistic and thus pose a higher risk since models typically do not reveal their information publicly.

Perhaps more importantly, in black-box settings, adversarial examples generated from a specific model can be used to attack other target model. This type of black-box attack is called *transfer attack*. High transferability indicates that the audio adversarial example generated from a source model can easily deceive other models that have different structures or parameters. However, research into this type of transfer attacks is still limited in the audio domain. Existing audio adversarial attacks exhibit low transferability [7] or only use frequency-based methods for feature extractor [5,8] with a lack of understanding of the transferability for the latest Wav2vec-based feature extractor [9].

Thus, in this study, we provide a thorough evaluation on the transferability of audio adversarial examples between various models under both silent and noisy conditions. We discover that the transferability of audio adversarial examples is related to the noise sensitivity. Based on these observations, We propose a novel attack that generates highly transferable audio adversarial examples by intentionally adding noise during the gradient ascent process. Fig. 1 illustrates the proposed adversarial attack. Compared to existing adversarial attacks, the proposed method *adds additive noise* during the gradient ascent process at *every step* (yellow-colored). By doing this, the proposed method successfully increases the loss

* Corresponding author.
E-mail address: jaewook@snu.ac.kr (J. Lee).

https://doi.org/10.1016/j.patcog.2022.109286
0031-3203/© 2023 Elsevier Ltd. All rights reserved.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Table 10
Original manual transcription of two randomly sampled speech and corresponding prediction generated by NIA.

Manual Transcription	DeepSpeech → Wav2vec 2.0	Wav2vec 2.0 → DeepSpeech
Beware of making that mistake	Beware of making that nestake	Hevven where otw may benrep liedaing
No my little son she said	No my little fund you say	We know o my little withon mitl ta

output the target sentence. However, as shown in Table 10, when we transfer the adversarial examples to the other model, they make target models output a wrong prediction rather than the target sentence. We presume that this is because speech-to-text is a more complicated task and there is a large difference between two feature extractors (Mel-spectrogram versus Wav2vec 2.0). Our future work will also include this phenomenon to enhance the transferability between different feature extractors in ASR systems.

6. Conclusion

In this study, we provided a thorough evaluation on the transferability of audio adversarial examples with different structures and conditions. We unrevealed the underlying connection between transferability and noise sensitivity. This also can be Based on the observations, we proposed a new attack called NIA that enhances the transferability of audio adversarial examples by adding additive noise during the gradient ascent process at every step.

The results of our work can be effectively used to develop a new adversarial attack or defense method in consideration of additive noise in the audio domain. We recommend that future adversarial attacks within the audio domain should also be evaluated with different feature extractions and diverse conditions. For future works, we will conduct further research in broader ASR systems. We look forward that a noise-aware attack method can provide deeper understanding of adversarial vulnerability of ASR systems.

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Data availability

Data will be made available on request.

Acknowledgment

This work was supported by the National Research Foundation of Korea (NRF) grant funded by the Korean government (MSIT) (No. 2019R1A2C2002358) and the Institute of Information & communications Technology Planning & Evaluation (IITP) grant funded by the Korea government (MSIT) (No. 2022-0-00984, Development of Artificial Intelligence Technology for Personalized Plug-and-Play Explanation and Verification of Explanation).

References

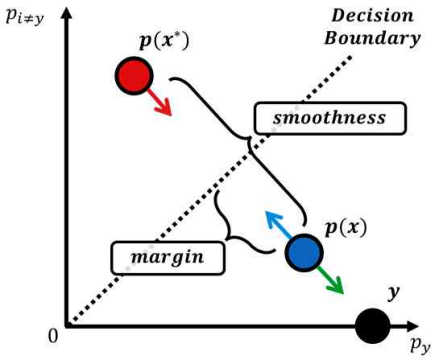
[1] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, Intriguing properties of neural networks, Int. Conf. Learn. Represent. (2014).
[2] I.J. Goodfellow, J. Shlens, C. Szegedy, Explaining and harnessing adversarial examples, Int. Conf. Learn. Represent. (2015).
[3] B. Biggio, F. Roli, Wild patterns: ten years after the rise of adversarial machine learning, Pattern Recognit. 84 (2018) 317–331.
[4] M. Alzantot, B. Balaji, M. Srivastava, Did you hear that? adversarial examples against automatic speech recognition, arXiv preprint arXiv:1801.00554 (2018).
[5] N. Carlini, D. Wagner, Audio adversarial examples: Targeted attacks on speech-to-text, in: 2018 IEEE Security and Privacy Workshops (SPW), IEEE, 2018, pp. 1–7.
[6] M. Cisse, Y. Adi, N. Neverova, J. Keshet, Houdini: fooling deep structured prediction models, Adv. Neural Inf. Process. Syst. 30 (2017).
[7] Z. Yang, B. Li, P.-Y. Chen, D. Song, Characterizing audio adversarial examples using temporal dependency, Int. Conf. Learn. Represent. (2019).
[8] H. Yakura, J. Sakuma, Robust audio adversarial example for a physical attack, in: IJCAI, 2019, pp. 5334–5341.
[9] S. Schneider, A. Baevski, R. Collobert, M. Auli, wav2vec: Unsupervised pre-training for speech recognition, in: INTERSPEECH, ISCA, 2019, pp. 3465–3469.
[10] A. Hannun, C. Case, J. Casper, B. Catanzaro, G. Diamos, E. Elsen, R. Prenger, S. Satheesh, S. Sengupta, A. Coates, et al., Deep speech: scaling up end-to-end speech recognition, arXiv preprint arXiv:1412.5567 (2014).
[11] Q. Wang, B. Zheng, Q. Li, C. Shen, Z. Ba, Towards query-efficient adversarial attacks against automatic speech recognition systems, IEEE Trans. Inf. Forensics Secur. 16 (2020) 896–908.
[12] A. Baevski, Y. Zhou, A. Mohamed, M. Auli, Wav2vec 2.0: a framework for self-supervised learning of speech representations, Adv. Neural Inf. Process. Syst. 33 (2020).
[13] D. Amodei, S. Ananthanarayanan, R. Anubhai, J. Bai, E. Battenberg, C. Case, J. Casper, B. Catanzaro, Q. Cheng, G. Chen, et al., Deep speech 2: End-to-end speech recognition in english and mandarin, in: International conference on machine learning, 2016, pp. 173–182.
[14] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, Towards deep learning models resistant to adversarial attacks, Int. Conf. Learn. Represent. (2018).
[15] N. Carlini, D. Wagner, Towards evaluating the robustness of neural networks, in: 2017 ieee symposium on security and privacy (sp), IEEE, 2017, pp. 39–57.
[16] X. Yuan, Y. Chen, Y. Zhao, Y. Long, X. Liu, K. Chen, S. Zhang, H. Huang, X. Wang, C.A. Gunter, Commandersong: A systematic approach for practical adversarial voice recognition, in: 27th {USENIX} Security Symposium ({USENIX} Security 18), 2018, pp. 49–64.
[17] F. Kreuk, Y. Adi, M. Cisse, J. Keshet, Fooling end-to-end speaker verification with adversarial examples, in: 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), IEEE, 2018, pp. 1962–1966.
[18] D. Iter, J. Huang, M. Jermann, Generating adversarial examples for speech recognition, Stanford Technical Report (2017).
[19] Y. Gong, C. Poellabauer, Crafting adversarial examples for speech paralinguistics applications, arXiv preprint arXiv:1711.03280 (2017).
[20] R. Taori, A. Kamsetty, B. Chu, N. Vemuri, Targeted adversarial examples for black box audio systems, in: 2019 IEEE Security and Privacy Workshops (SPW), IEEE, 2019, pp. 15–20.
[21] F. Tramèr, N. Papernot, I. Goodfellow, D. Boneh, P. McDaniel, The space of transferable adversarial examples, arXiv preprint arXiv:1704.03453 (2017).
[22] W. Wu, Y. Su, X. Chen, S. Zhao, I. King, M.R. Lyu, Y.-W. Tai, Boosting the transferability of adversarial samples via attention, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 1161–1170.
[23] C. Xie, Z. Zhang, Y. Zhou, S. Bai, J. Wang, Z. Ren, A.L. Yuille, Improving transferability of adversarial examples with input diversity, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019, pp. 2730–2739.
[24] Y. Dong, T. Pang, H. Su, J. Zhu, Evading defenses to transferable adversarial examples by translation-invariant attacks, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019, pp. 4312–4321.
[25] J. Hang, K. Han, H. Chen, Y. Li, Ensemble adversarial black-box attacks against deep learning systems, Pattern Recognit. 101 (2020) 107184.
[26] D. Li, J. Zhang, K. Huang, Universal adversarial perturbations against object detection, Pattern Recognit. 110 (2021) 107584.
[27] P. Warden, Speech commands: a dataset for limited-vocabulary speech recognition, arXiv preprint arXiv:1804.03209 (2018).
[28] P. Foggia, N. Petkov, A. Saggese, N. Strisciuglio, M. Vento, Reliable detection of audio events in highly noisy environments, Pattern Recognit. Lett. 65 (2015) 22–28.
[29] A. Demontis, M. Melis, M. Pintor, M. Jagielski, B. Biggio, A. Oprea, C. Nita-Rotaru, F. Roli, Why do adversarial attacks transfer? explaining transferability of evasion and poisoning attacks, in: 28th {USENIX} Security Symposium ({USENIX} Security 19), 2019, pp. 321–338.
[30] W. Zhou, X. Hou, Y. Chen, M. Tang, X. Huang, X. Gan, Y. Yang, Transferable adversarial perturbations, in: Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 452–467.
[31] E. Wong, L. Rice, J.Z. Kolter, Fast is better than free: revisiting adversarial training, Int. Conf. Learn. Represent. (2020).
[32] H. Kim, J. Park, J. Lee, Comment on transferability and input transformation with additive noise, arXiv preprint arXiv:2206.09075 (2022).
[33] H. Kim, W. Lee, J. Lee, Understanding catastrophic overfitting in single-step adversarial training, in: AAAI, AAAI Press, 2021, pp. 8119–8127.
[34] C. Veaux, J. Yamagishi, K. MacDonald, Cstr vctk corpus: english multi-speaker corpus for cstr voice cloning toolkit, University of Edinburgh (2017).
[35] Z. Li, Y. Wu, J. Liu, Y. Chen, B. Yuan, Advpulse: Universal, synchronization-free, and targeted audio adversarial attacks via subsecond perturbations, in: Pro-

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

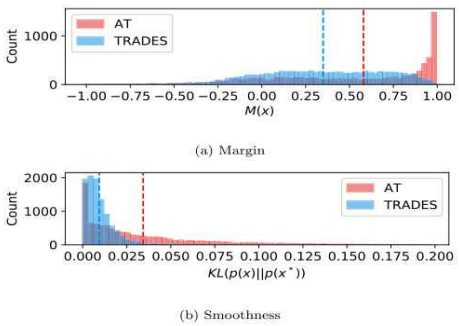
연구실적 유형		논문(O) 특허( )		
연구책임자 성명		이재욱		
논문/특허명		Bridged adversarial training		
논문실적정보 ■	게재지(저널명)	Neural Networks		
	SCI 등재 여부	등재	인용횟수(SCI)	5회 (Google 학술검색 기준)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	5회 (Google 학술검색 기준)
	ISSN	0893-6080	게재년월	202310
	역할(제1, 교신, 참여)	교신저자	참여자수	4명
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 연구는 강건성을 개선하기 위한 새로운 방법인 bridged adversarial training(BAT)을 제안하고, 이를 통해 적대적 학습 방법으로 도출된 모델들의 마진(margin)과 부드러움(smoothness)의 특성을 분석함. 이러한 성과는 다음과 같은 과학기술적 가치와 중요성을 지니고 있음. 첫째, 본 연구는 기존 적대적 학습 방법 기술들과는 차별화된 새로운 방법을 제안하여 향후 다수의 적대적 방어 기법으로 확장 적용이 가능함. 나아가, 제안된 방법인 BAT가 강건성을 개선하는 데 효과적임을 실험적으로 입증함. 둘째, 이 논문은 마진(margin)과 부드러움(smoothness)의 특성을 실험적, 수학적으로 분석하여 적대적 학습 방법의 특성을 더 잘 이해할 수 있게 함.



[그림] 적대적 학습에서 마진(margin)과 부드러움(smoothness)의 설명.



[그림] CIFAR10 이미지 데이터셋에 대한 기존 AT와 TRADES 적대적 학습 방법들의 차이점.

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
이러한 과학기술적 가치와 중요성은 연구 계획과도 밀접한 관련이 있음. 본 연구에서는 BAT 제안을 통해 적대적 학습 모델들이 원래 예제와 적대적 예제와의 차이를 줄이는 매니폴드(manifold)를 학습하게 되어, 적대적 공격에 대한 강건성을 높일 수 있게 됨.	기존 방법에선 마진(margin)과 부드러움(smoothness) 둘 중 하나에만 의존하였지만 본 연구에서는 마진(margin)과 부드러움(smoothness)을 함께 고려하여 차별성을 지님. 본 방법이 실제로 CIFAR-10, CIFAR-100, SVHN, ImageNet 데이터셋에서 강건성을 높이는 데에 효과적임을 실험적으로 입증함.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

Neural Networks 167 (2023) 266–282

Contents lists available at ScienceDirect

Neural Networks

journal homepage: www.elsevier.com/locate/neunet

Bridged adversarial training

Hoki Kim [a], Woojin Lee [b], Sungyoon Lee [c], Jaewook Lee [d,*]

[a] Institute of Engineering Research, Seoul National University, Gwanak-gu 08826, Republic of Korea
[b] School of AI Convergence, Dongguk University-Seoul, Jung-gu 04620, Republic of Korea
[c] Department of Computer Science, Hanyang University, Seongdong-gu 04763, Republic of Korea
[d] Department of Industrial Engineering, Seoul National University, Gwanak-gu 08826, Republic of Korea

ARTICLE INFO

Article history:
Received 30 August 2021
Received in revised form 7 June 2023
Accepted 13 August 2023
Available online 22 August 2023

Keywords:
Neural networks
Adversarial robustness
Adversarial training
Adversarial defense

ABSTRACT

Adversarial robustness is considered a required property of deep neural networks. In this study, we discover that adversarially trained models might have significantly different characteristics in terms of margin and smoothness, even though they show similar robustness. Inspired by the observation, we investigate the effect of different regularizers and discover the negative effect of the smoothness regularizer on maximizing the margin. Based on the analyses, we propose a new method called bridged adversarial training that mitigates the negative effect by bridging the gap between clean and adversarial examples. We provide theoretical and empirical evidence that the proposed method provides stable and better robustness, especially for large perturbations.

© 2023 Elsevier Ltd. All rights reserved.

1. Introduction

Deep neural networks are vulnerable to adversarial examples, which are intentionally perturbed to cause misclassification (Szegedy et al., 2013). Since deep neural networks can be applied to various fields, defense techniques against adversarial attacks are now considered an important research area. To improve the robustness of neural networks against adversarial attacks, many defense methods have been proposed (Goodfellow, Shlens, & Szegedy, 2014; Kim, Lee, & Lee, 2021; Madry, Makelov, Schmidt, Tsipras, & Vladu, 2017; Tramèr et al., 2017; Zhang et al., 2019). Among these, adversarial training (AT) (Madry et al., 2017) and TRADES (Zhang et al., 2019) are considered powerful base methods to achieve high adversarial robustness (Gowal, Qin, Uesato, Mann, & Kohli, 2020; Wu, Xia, & Wang, 2020). In this paper, while AT and TRADES have similar robustness, we discover that they have totally different *margin* and *smoothness*.

Margin, in general, corresponds to the distance from an example to the decision boundary. For example, given a clean example $\boldsymbol{x}$ and its probability output $\boldsymbol{p}(\boldsymbol{x})$, the adversarial margin can be defined as the difference between the probability with respect to the true label y and the other most probable class, $\boldsymbol{p}(\boldsymbol{x})_y - \max_i \boldsymbol{p}(\boldsymbol{x})_{i\neq y}$ (Liu, Han et al., 2021) as shown in Fig. 1. A Larger distance indicates a better margin. AT tries to maximize the margin of an adversarial example $\boldsymbol{x}^*$, which corresponds to the red arrow in Fig. 1.

Smoothness corresponds to the insensitiveness of the output to the input perturbation. The $\mathcal{L}_2$ distance $\|\boldsymbol{p}(\boldsymbol{x}) - \boldsymbol{p}(\boldsymbol{x}^*)\|_2$ (Kannan, Kurakin, & Goodfellow, 2018) or the Kullback–Leibler divergence $\mathrm{KL}(\boldsymbol{p}(\boldsymbol{x})\|\boldsymbol{p}(\boldsymbol{x}^*))$ (Zhang et al., 2019) can be easily used to estimate smoothness. TRADES tries to maximize the margin of an clean example $\boldsymbol{x}$ (green arrow), while minimizes the smoothness between $\boldsymbol{p}(\boldsymbol{x})$ and $\boldsymbol{p}(\boldsymbol{x}^*)$ (red and blue arrows).

Inspired by the observation that AT and TRADES have totally different margin and smoothness, we investigate the characteristics of the regularizers of AT and TRADES, and find that there exists the negative effect of the smoothness regularizer (blue arrow) on maximizing the margin. From the analyses, we propose a novel method to mitigate the negative effect and provide stable performance by bridging the gap between clean and adversarial examples.

2. Related work and background

2.1. Notations

We consider a c-class classification task with a neural network $f_\theta : \mathcal{X} \to \mathbb{R}^c$. The network f_θ classifies a sample $\boldsymbol{x} \in \mathcal{X}$ as $\arg\max_{i\in\mathcal{Y}}[f_\theta(\boldsymbol{x})]_i$, where $\mathcal{Y} = \{0, \dots, c-1\}$. We denote the true label with respect to $\boldsymbol{x}$ by y and the corresponding one-hot representation by $\boldsymbol{y} \in \{0,1\}^c$. That is, $y_i = \mathbf{1}\{i = y\}, \forall i \in \mathcal{Y}$, with an indicator function $\mathbf{1}\{C\}$ which outputs 1 if the condition C is true and 0 otherwise. Then the probability function $\boldsymbol{p}_\theta = \mathrm{softmax} \circ f_\theta : \mathcal{X} \to [0,1]^c$ outputs a c-dimensional probability vector whose elements sum to 1.

Given two probability vectors $\boldsymbol{p}, \boldsymbol{q}$ in the c-dimensional probability simplex, we define the following values: $H_{\boldsymbol{p}}(\boldsymbol{q}) = -\boldsymbol{p}^T \log \boldsymbol{q}$

* Corresponding author.
E-mail address: jaewook@snu.ac.kr (J. Lee).

https://doi.org/10.1016/j.neunet.2023.08.024
0893-6080/© 2023 Elsevier Ltd. All rights reserved.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

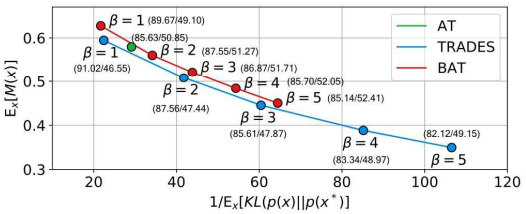


Fig. 9. Sensitivity of β in terms of margin and smoothness. x-axis denotes the inverse of the expectation of the KL divergence and y-axis denotes the expectation of the margin. The clean accuracy and robust accuracy against AutoAttack of each point in parentheses. Each expectation is calculated on the test set. For margin and smoothness, higher is better for both axes.

$m = 2$ is enough to mitigate the negative effect and achieve balance between margin and smoothness.

6. Conclusion

In this paper, we investigated the existing adversarial training methods from the perspective of margin and smoothness of the network. We found that AT and TRADES have different characteristics in terms of margin and smoothness due to their different regularizers. We mathematically proved that the regularization term designed for smoothness has a negative effect on training a larger margin. To this end, we proposed a new method that mitigates the negative effect by bridging the gap between clean and adversarial examples and achieved stable and better performance. It is important to note that AT and TRADES still serve as strong baselines and many of the state-of-the-art methods combine these techniques with newer approaches to achieve the highest performance. For example, the current state-of-the-art performance model also use TRADES with images generated by diffusion models (Wang et al., 2023). Regarding this trend, we believe that our findings can be easily extended and incorporated into future research. We believe that our investigation on margin and smoothness can provide a new perspective to better understand the adversarial robustness and to design a robust model.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

Data availability

Data will be made available on request

Acknowledgments

This work was supported by the National Research Foundation of Korea (NRF) grant funded by the Korean government (MSIT) (No. 2019R1A2C2002358; No. 2022R1F1A1074393; RS-2023-00244896), the Institute of Information & communications Technology Planning & Evaluation (IITP) grant funded by the Korea government (MSIT) (No. 2022-0-00984, Development of Artificial Intelligence Technology for Personalized Plug-and-Play Explanation and Verification of Explanation; No.RS-2023-002206284, Artificial intelligence for prediction of structure-based protein interaction reflecting physicochemical principles), and Hanyang University (HY-202300000000552).

Appendix A. Proofs of theoretical results

A.1. Proof of Proposition 1

Proof of Proposition 1 [Restated]. Let $\boldsymbol{p} = \boldsymbol{p}_\theta(\boldsymbol{x})$, $\boldsymbol{p}^* = \boldsymbol{p}_\theta(\boldsymbol{x}^*)$, $\nabla = \nabla_\theta$. Assume the binary case, where $\boldsymbol{p} = [p, 1-p]$ and $\boldsymbol{p}^* = [p^*, 1-p^*]$. Then, $-\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*)$ has a gradient direction opposite to $\nabla M(\boldsymbol{x})$.

$$\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) = \frac{1}{2}\left(\log\frac{p}{p^*} - \log\frac{1-p}{1-p^*}\right)\cdot\nabla M(\boldsymbol{x}) + \boldsymbol{c}$$

Here, $\boldsymbol{c}$ is a linear combination of other gradient directions. Since $p > p^*$, $\log\frac{p}{p^*} - \log\frac{1-p}{1-p^*}$ is always positive. Thus, minimizing $\mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*)$ hinders the increase in $M(\boldsymbol{x})$.

Proof. First, $\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*)$ can be formalized as follows:

$$\begin{aligned}
\mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) &= p\log p + (1-p)\log(1-p) \\
&\quad - p\log p^* - (1-p)\log(1-p^*) \\
\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) &= \frac{\partial \mathrm{KL}}{\partial p}\cdot\nabla p + \frac{\partial \mathrm{KL}}{\partial p^*}\cdot\nabla p^* \\
&= \left(\log\frac{p}{p^*} - \log\frac{1-p}{1-p^*}\right)\cdot\nabla p \\
&\quad + \left(-\frac{p}{p^*} + \frac{1-p}{1-p^*}\right)\cdot\nabla p^* \\
&= \left(\log\frac{p}{p^*} - \log\frac{1-p}{1-p^*}\right)\cdot\nabla p + \boldsymbol{c}
\end{aligned}$$

In addition, $\nabla M(\boldsymbol{x}) = 2\nabla p$, since $M(\boldsymbol{x}) = p - (1-p) = 2p - 1$. Thus,

$$\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) = \frac{1}{2}\left(\log\frac{p}{p^*} - \log\frac{1-p}{1-p^*}\right)\cdot\nabla M(\boldsymbol{x}) + \boldsymbol{c}. \quad \square$$

A.2. Proof of Proposition 2

Proof of Proposition 2 [Restated]. Let the correct label y, $t = \arg\max_{i\neq y} p_i^*$ and $\alpha_i = p_i/p_i^*$. Assume that $p_y > p_y^*$ and $p_t < p_t^*$. Then, $-\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*)$ is aligned with a gradient direction that penalizes p_i with the scale of $\log\alpha_i$, which minimizes the margin $M(\boldsymbol{x})$.

$$\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) = (\nabla \boldsymbol{p})^T \log\boldsymbol{\alpha} + \boldsymbol{c}$$

Here, $\boldsymbol{c}$ is a linear combination of other gradient directions. By the assumption, $\log\alpha_y > 0$ and $\log\alpha_t < 0$ so that $-(\nabla p_y)^T\log\alpha_y - (\nabla p_t)^T\log\alpha_t$ minimizes the margin $M(\boldsymbol{x})$.

Proof.

$$\begin{aligned}
&\nabla \mathrm{KL}(\boldsymbol{p}\|\boldsymbol{p}^*) \\
=&\nabla\left(\boldsymbol{p}^T\log\boldsymbol{p} - \boldsymbol{p}^T\log\boldsymbol{p}^*\right) \\
=&(\nabla\boldsymbol{p})^T\log\boldsymbol{p} + (\nabla\boldsymbol{p})^T\mathbf{1} - (\nabla\boldsymbol{p})^T\log\boldsymbol{p}^* - (\nabla\boldsymbol{p}^*)^T\frac{\boldsymbol{p}}{\boldsymbol{p}^*} \\
=&(\nabla\boldsymbol{p})^T\log\frac{\boldsymbol{p}}{\boldsymbol{p}^*} - (\nabla\boldsymbol{p}^*)^T\frac{\boldsymbol{p}}{\boldsymbol{p}^*} \\
=&(\nabla\boldsymbol{p})^T\log\boldsymbol{\alpha} - (\nabla\boldsymbol{p}^*)^T\boldsymbol{\alpha}. \qquad \text{(A.1)}
\end{aligned}$$

which leads to the conclusion with $\boldsymbol{c} = -(\nabla\boldsymbol{p}^*)^T\boldsymbol{\alpha}$ $\square$

A.3. Proof of Theorem 1

To give a self-contained overview, we follow (Bartlett, Jordan, & McAuliffe, 2006). In the binary classification case, given a sample $\boldsymbol{x} \in \mathcal{X}$ and a label $y \in \{-1, 1\}$, a model can be denoted as