국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

생애첫연구 최종보고서

① 부처사업명(대)	기초연구사업		보안등급(보안, 일반)	일반
② 사 업 명(중)	생애첫연구		공개가능여부(공개, 비공개)	공개
③ 세부사업명(소)	생애첫연구			
④ 과제성격(기초, 응용, 개발)	기초	④-1 실용화 대상여부(실용화, 비실용화)		비실용화
⑤ 연구개발과제명	국 문	6G 무선 네트워크를 위한 설명가능한 지능형 무선 자원 관리 기법 연구		
	영 문	Explainable Artificial Intelligence (XAI) for Radio Resource Management in 6G Wireless Networks		
⑥ 주관연구개발기관	세종대학교			
⑦ 연구책임자	성 명	이현석	직급(직위)	조교수
	소속부서	AI로봇학과	전 공	무선통신

⑧ 연구개발비 및 참여연구원수 (**단위: 천원**, M·Y)

연 도	정부지원 연구개발비 (A)	기업체부담금			정부외 출연금 (B)	상대국 부담금 (F)	합계 G=(A+B+E)	참여 연구원수
		현금 (C)	현물 (D)	소계 E=(C+D)				
1년차	31,300			0			31,300	7
2년차	31,300			0			31,300	10
3년차	31,300			0			31,300	6
4년차				0			0	
5년차				0			0	
합계	93,900	0	12	0	0	0	93,900	23

⑨ 총연구개발기간	2021. 03. 01 ~ 2024. 02. 29 (36개월)

이 최종보고서에 기재된 내용이 사실임을 확인하며, 만약 사실이 아닌 경우 관련 법령 및 규정에 따라 제재 처분 등의 불이익도 감수하겠습니다.

2024 년 3 월 25 일

연구책임자 : 이현석

주관연구개발기관의 장 : 유상호

과학기술정보통신부장관 귀하

※ 전자접수이므로 연구책임자 및 주관연구개발기관의 장 서명(인, 직인)은 생략

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 연구결과 요약문 〉

연구개요	미래 무선 네트워크를 위해 딥러닝 모델이 적극적으로 활용되고 있으나, 딥러닝 모델의 불투명성을 해결하기 위해 무선 네트워크 분야의 도메인 지식을 심도있게 고려한 설명 가능한 인공지능 기술에 관한 연구는 국내·외에서 찾아보기 어려움. 본 연구에서는 무선 네트워크의 도메인 지식을 고려하여 미래 무선 네트워크를 위해 활용될 수 있는 새로운 설명 가능한 인공지능 기반 자원 관리 기법을 개발하는 연구를 진행함
연구 목표대비 연구결과	□ 본 연구의 최종 목표: 대규모 무선 네트워크에서의 설명 가능한 지능형 무선 자원 관리 기법의 개발 - 다수 셀로 구성된 대규모 시스템에서는 중앙집중적으로 모든 셀의 무선 자원을 할당 및 관리하기 어려워 효율적인 기술 개발을 위해서는 분산적/계층적 접근이 요구되며, 아래 1~3차년도의 단계적 연구를 통해 최종 목표를 성공적으로 달성하였음 □ 1차년도 목표: 단일 셀 무선 네트워크 시스템에서 설명 가능한 지능형 무선 자원 할당 알고리즘 개발 - 무선 네트워크 시스템의 기본 요소인 단일 셀 내의 네트워크 성능을 최대화하기 위한 지능형 무선 자원 할당 기술과 수학적 이론에서 추출한 도메인 지식을 기반으로 해당 기술의 해석 모듈에 관한 연구를 진행하였고, 이를 통해 1차년도 연구 목표를 성공적으로 달성함 □ 2차년도 목표: 다수 셀 무선 네트워크 시스템에서 설명 가능한 지능형 셀 간 간섭 조절 알고리즘 개발 - 무선 네트워크 시스템에 다수의 셀이 존재하는 환경에서 전년도에서 개발된 단일 셀 지능형 무선 자원 할당 알고리즘의 분석 및 이해, 그리고 셀 간 간섭 조절 관련 이론에서 추출한 도메인 지식을 기반으로 셀 간 간섭을 조절하는 알고리즘과 해당 기술의 해석 모듈에 관한 연구를 진행하였고, 이를 통해 2차년도 연구 목표를 성공적으로 달성함 □ 3차년도: 대규모 시스템에서의 설명 가능한 통합형/지능형 무선 자원 관리 알고리즘 개발 - 단일 셀 자원 할당 분산적으로 통합한 무선 자원 관리 알고리즘을 기반으로 설명 가능한 통합형/지능형 무선 자원 관리 알고리즘을 개발하는 것을 목표로 하며, 이를 위해 앞선 연구를 통합하면서 동시에 통합형/지능형 알고리즘을 위한 해석 모듈에 관한 연구를 진행하였고, 이를 통해 3차년도 연구 목표를 성공적으로 달성함
연구개발성과의 활용 계획 및 기대효과 (연구개발결과의 중요성)	□ 기술적 파급효과: 딥러닝 모델을 활용한 융합기술에서 설명 가능한 인공지능 관련 연구는 여전히 미미한 실정으로, 본 연구를 통해 개발된 선도적인 설명 가능한 지능형 무선 자원 관리 기법을 통해 관련 분야에서 핵심 기술을 확보함 □ 학문적 파급효과: 기존의 무선 네트워크와 인공지능의 융합 기법은 설명이 어려운 불투명한 딥러닝 기법의 한계로 인해 기법의 개발 이후 개선 및 활용에 제한이 있었음. 본 연구에서 개발된 프레임워크는 지능형 알고리즘들의 분석 및 이해를 가능하게 하였으며, 추후 이를 바탕으로 새로운 영역의 연구를 진행할 수 있을 것으로 기대됨 □ 산업·경제적 파급효과: 본 연구를 통해 설명 가능한 지능형 무선 자원 관리 핵심 기술을 확보하였으므로, 추후 관련한 기술을 다양한 분야의 산업계에서 실제로 활용할 수 있도록 하여 다양한 인공지능 응용 분야의 기술력 제고에 도움이 될 수 있음. 더 나아가 인공지능 융합 산업 관련 기술로의 확장 등 미래 무선 네트워크의 시장 개척에 도움을 줄 수 있음 □ 사회적 파급효과: 본 연구는 미래 무선 네트워크에서의 mission-critical 서비스에 적용되어 해당 서비스들을 더욱 높은 신뢰도로 지원할 수 있게 할 것으로 기대됨. 해당 서비스는 재난 통신, 철도 통신, 자율주행차 등 삶의 질을 향상시킬 수 있는 미래 기반 기술 개발 측면에서 사회적 공헌이 가능할 것으로 생각됨

중심어	**국문**	미래 무선 네트워크	설명 가능한 인공지능	무선 자원 관리	기계학습	6G 이동통신
	영문	Future Wireless Networks	Explainable AI	Radio Resource Management	Machine Learning	6G Communications

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 목 차 〉

1. 연구개발과제의 개요 ····· 4
2. 연구개발과제의 수행 과정 및 수행 내용 ····· 4
3. 연구개발과제의 수행 결과 및 목표 달성 정도 ····· 12
4. 연구개발성과의 관련 분야에 대한 기여 정도 ····· 13
5. 연구개발성과의 관리 및 활용 계획 ····· 13
6. 자체점검표 ····· 14
7. 참고문헌 ····· 14

<붙임1 세부 정량적 연구개발성과> ····· 15
<붙임2 연구책임자 대표적 연구실적 및 증빙(요약문 및 사본)> ····· 17

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

1. 연구개발과제의 개요

연구과제 최종 목표: 대규모 6G 미래 무선 네트워크에서 활용될 수 있는 무선 네트워크 도메인 지식 기반 설명 가능한 지능형 무선 자원 관리 기법 개발

□ 미래 무선 네트워크를 위해 딥러닝 모델이 적극적으로 활용되고 있으나, 딥러닝 모델의 불투명성을 해결하기 위해 무선 네트워크 분야의 도메인 지식을 심도있게 고려한 설명 가능한 인공지능 기술에 관한 연구는 국내·외에서 찾아보기 어려움. 본 연구에서는 **무선 네트워크의 도메인 지식**을 고려하여 **미래 무선 네트워크를 위해 활용될 수 있는 새로운 설명 가능한 인공지능 기반 자원 관리 기법**을 개발하는 연구를 진행함

○ 설명 가능한 인공지능이란 학습된 인공지능 모델의 동작을 사람이 이해할 수 있는 일반적인 형태로 표현하는 기술을 의미함 [1]. 본 연구에서는 **인공지능 기술을 기반으로 무선 자원을 효율적으로 관리하면서 동시에 그 동작원리에 관한 설명과 정보를 제공하는 기법**을 개발함. 따라서 본 기술은 **지능형 무선 자원 관리 기법**과 해당 기법의 동작을 설명하는 **해석 (interpretability) 모듈**로 구성됨

○ 이 같은 설명 가능한 인공지능 기술을 통해 자원 관리 기법의 동작원리를 도메인 지식을 활용하여 사용자(네트워크 엔지니어)가 이해할 수 있는 형태로 제공함. 이를 통해 해당 기법에 관한 보다 직관적인 분석을 가능케하고, 사용자가 딥러닝 모델의 오류를 해결하는 등 모델을 개선하여 **신뢰할 수 있는 지능형 무선 자원 관리 기법을 개발**하는 것을 목표로 함

2. 연구개발과제의 수행 과정 및 수행 내용

1) 주요 연구 변경사항

해당 사항 없음

2) 연구과제의 수행 과정 및 수행 내용

1차년도 개발 목표: 단일 셀 무선 네트워크 시스템에서 알고리즘의 동작원리를 설명 가능한 지능형 무선 자원 할당 알고리즘 개발

□ 본 연구는 대규모 무선 네트워크에서의 설명 가능한 지능형 무선 자원 관리 기법의 개발을 목표로 하며, 효율적인 기법 개발을 위해서는 분산적/계층적 접근이 요구됨. 이를 위해 1차년도에서는 대규모 무선 네트워크의 기본 요소인 단일 셀에서의 설명 가능한 지능형 자원 할당 알고리즘에 관한 연구를 우선적으로 진행함

□ 구체적으로 1차년도 연구에서는 단일 셀 무선 네트워크 시스템에서 무선 자원 할당 알고리즘을 마르코프 결정 프로세스 (Markov Decision Process; MDP)로 정의하고 이를 강화학습 기반으로 해결함. 이 과정에서 '서술적인 정책 (Descriptive Policy)' 라고 하는 설명 가능성을 제공하는 새로운 정책 구조를 제안하고 활용하여 설명 가능한 지능형 무선 자원 할당 알고리즘을 개발함

(1) 단일 셀 무선 네트워크 시스템 무선 자원 할당 문제 정의

먼저 단일 셀 무선 네트워크 시스템에서 무선 자원 할당 문제를 정의한다. 본 연구에서는 W Hz의 대역폭을 갖는 TDMA 무선 네트워크 시스템 환경을 고려한다. 따라서 무선 자원은 timeslot $t \in \{0,1,2,...\}$ 단위로 관리되며, 각 timeslot별 무선 자원은 셀 내에 존재하는 사용자 중 하나에게 할당하며 전송전력 등의 추가적인 사항을 결정한다. 무선 네트워크 시스템의 셀 내에는 총 N명의 사용자가 존재함을 가정하며, 사용자는 $n \in \{1,2,...,N\}$로 표기한다.

주어진 단일 셀 무선 네트워크 시스템에서 MDP 형태로 무선 자원 할당 문제를 정의하기 위해서는 시스템의 상태를 나타내는 state와 자원 할당 결정을 나타내는 action에 관한 정의가 필요하다. 본 연구에서는 일반화된 문제를 고려하기 위하여 시스템의 상태를 구체화하지 않고 일반화하여 표현한다. 각 사용자가 갖는 시스템 상태 정보의 개수를 K라고 정의하면 timeslot t에서 각 사용자 n의 시스템 상태 정보는 $h_n^t = (h_{n,1}^t,...,h_{n,K}^t)$와 같이 표현된다. 각 시스템 상태정보는 채널 품질 지시자, 버퍼 상태, 서비스 품질 만족도 등으로 구성될 수 있다. State는 모든 사용자의 시스템 상태 정보를 표현하도록 정의될 수 있으며 timeslot t에 관하여 $s^t \in \mathcal{S}$와 같이 표기한다. 이 때, $\mathcal{S}$는 시스템 상태 정보 공간을 나타낸다. 또한 timeslot t에서 시스템의 무선 자원 할당의 경우 앞서 언급한대로

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

무선 자원이 할당될 사용자 및 전송전력 등의 추가적인 사항들의 결정으로 구성된다. Action은 이와 같은 결정 사항을 표현하도록 정의될 수 있으며 timeslot t에 관하여 $a^t \in \boldsymbol{A}$와 같이 표기한다. 앞선 수식에서 $\boldsymbol{A}$의 경우 무선 자원 할당 결정 공간을 나타낸다. 마지막으로 시스템 상태 정보 (state)를 기반으로 어떤 무선 자원 할당 (action)을 선택할 것인지를 결정하는 함수를 정책 (policy)라 하며 $\pi : \boldsymbol{S} \rightarrow \boldsymbol{A}$와 같이 나타낸다.

일반적으로 시스템의 무선 자원 할당을 통해 달성하고자 하는 목표는 시스템의 유틸리티 함수로 표현할 수 있고 유틸리티 함수의 함수값은 시스템 상태 정보와 무선 자원 할당에 따라 결정된다. 따라서 이를 $u(s,a)$와 같이 표기하며 해당 유틸리티 함수의 합을 최대화하도록 무선 자원 할당을 결정함으로써 시스템의 목표를 달성할 수 있게 된다. 예를 들어, 총 무선 전송률을 최대화하고자 하는 경우에는 유틸리티 함수를 달성 무선 전송률로 설정하여 이를 달성할 수 있다. 유틸리티 함수를 활용한 무선 자원 할당 문제를 수식으로 나타내면 아래 식과 같다.

$$\underset{\pi:\mathcal{S}\rightarrow\mathcal{A}}{\text{maximize}} \; U^{\pi}(s) = \mathbb{E}\left[\sum_{t=0}^{\infty}(\gamma)^t u(s^t,\pi(s^t)) \middle| s^0 = s\right] \qquad \text{식 (1)}$$

이때, γ는 0과 1사이의 값을 갖는 discount factor로, 예측의 불확실성이 큰 먼 미래의 reward보다 비교적 예측의 불확실성이 더 작은 가까운 미래의 reward에 가중치를 두는 역할을 수행한다. 또한 위의 식에 추가로 다양한 제약 조건을 고려할 수 있다. 예를 들어, 각 사용자의 최소 평균 전송률 요구조건 등을 고려할 수 있다. 위 무선 자원 할당 문제를 해결한다는 것은 식 (1)에서 주어진 누적 discounted 유틸리티 함수의 기댓값, 즉, 가치함수 $U^{\pi}(s)$를 최대화하는 것을 의미하며 이를 수식으로 표현하면 $J^*(s) = \max_{\pi} U^{\pi}(s), \; \forall s \in \boldsymbol{S}$와 같고, 이를 달성하는 최적 정책을 수식적으로 정의하면 $\pi^* = \text{argmax}_{\pi} \text{U}^{\pi}(\text{s}), \; \forall \text{s} \in \text{S}$와 같다.

(2) 서술적인 정책 (Descriptive Policy) 구조 및 학습 방법

서술적인 정책은 '어떤 상태를 갖는 사용자가 무선 자원 할당의 목적을 달성하기 위해 더 높은 우선순위를 가져야하는가' 로 표현되는 무선 자원 할당 원리를 학습할 수 있도록 구조가 정의된다 [2]. 이같은 접근 방식은 결국 선택된 사용자가 무선 자원 할당의 목적을 달성하기 위해 더 나은 상태가 무엇인지 학습하여 알고리즘이 왜 그런 선택을 했는지 설명할 수 있도록 하는 장점이 있다.

먼저 서술적인 상태 정보 (Descriptive State)를 정의한다. 서술적인 상태 정보는 각 timeslot에 어떤 상태를 갖는 사용자가 셀에 존재하는지 여부를 나타내도록 정의한다. 이를 위해 각 k번째 상태 정보의 상태공간을 H_k개의 서로소인 구간으로 나눈다. 그렇게하면 각 사용자가 갖는 상태는 각 상태 정보 구간의 조합 (combination)으로 표현할 수 있다. 이때, 상태정보가 이산적인 (discrete) 특성을 가질때는 상태공간을 나눌 필요가 없으며, 상태 공간은 상태 정보 특성에 따라 다양한 방식으로 나눌 수 있다. k번째 상태 정보의 구간 인덱스를 $h_k \in \boldsymbol{H}_k = \{1,2,...,H_k\}$로 표현하고 해당 인덱스에 해당하는 구간을 $D(h_k)$로 표기한다. 앞선 정의를 이용하여 timeslot t에서의 서술적인 상태 정보 $\bar{s}^t$를 K-차원 행렬로 정의한다. 해당 행렬의 크기는 $\prod_{k\in\{1,...k\}} H_k$로 주어지며 행렬의 각 원소는 구간 인덱스의 조합으로 표현되므로 각 사용자가 갖는 상태를 의미하여 해당하는 상태의 사용자가 시스템에 존재하면 1, 존재하지 않으면 0의 값을 갖는다. 서술적인 상태의 상태 공간은 $\overline{\boldsymbol{S}} = \{0,1\}^{\prod_{k\in\{1,...K\}} H_k}$로 주어진다.

그 다음으로 서술적인 무선 자원 할당 결정 (Descriptive Action)을 정의한다. 서술적인 자원 할당 결정은 앞서 언급한 대로 자원이 할당될 사용자와 전송전력 등의 추가 결정사항을 표현한다. 이때, 서술적인 자원 할당 결정에서는 서술적인 상태 정보에서의 구간 인덱스를 이용하여 무선 자원이 할당될 사용자의 상태를 서술적으로 나타낸다. Timeslot t에서의 서술적인 자원 할당 결정을 수식으로 표현하면 $\bar{a}^t = (h_1^t,...,h_K^t,m_1^t,...,m_L^t)$와 같이 표현할 수 있으며, m_l^t는 timeslot t에서의 l번째 추가 결정사항을 나타내고, L은 전체 추가 결정사항의 개수를 나타낸다. 서술적인 무선 자원 할당 결정 공간은 $\overline{\boldsymbol{A}} = \prod_{k\in\{1,...,K\}} \boldsymbol{H}_k \times \prod_{l\in\{1,...,L\}} \boldsymbol{M}_l$와 같이 정의되며 $\boldsymbol{M}_l$은 l번째 추가 결정사항의 결정 공간을 의미한다. 또한 각 timeslot마다 사용자의 상태에 따라 선택 가능한 사용자가 달라지므로 timslot t에서 선택 가능한 결정공간은 $\overline{\boldsymbol{A}}(s^t) = \{\bar{a}^t \in \overline{\boldsymbol{A}} | s^t(h^t) = 1\}$와 같이 구할 수 있다.

서술적인 정책을 이용하여 앞서 식(1)에서 정의한 무선 자원 할당 문제를 해결하기 위해서는, 해

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

당 문제에 관한 최적의 서술적인 정책을 학습해야 한다. 이는 일반적인 강화학습 기법을 활용하여 학습이 가능하며, 구체적으로 시스템을 서술적인 상태 정보로 표현하고 그에 따른 서술적인 무선 자원 할당 결정을 선택하는 과정을 반복하면서 그에 따른 상태 정보 변화 및 관찰한 유틸리티 값을 기반으로 최적의 서술적인 정책을 학습하여 문제를 해결할 수 있다. 하지만 서술적인 정책의 경우 서술적인 상태 정보 표현을 위한 상태 정보 구간을 나누는 과정에서 상태 정보의 일반화(generalization)이 수행되며, 이를 표현하기 위하여 상태 정보 s를 서술적인 상태 정보 $\bar{s}$로 변환하는 함수를 $d_s : \boldsymbol{S} \rightarrow \overline{\boldsymbol{S}}$로 정의하고, 반대로 서술적인 무선 자원 할당 결정 $\bar{a}$를 자원 할당 결정 a로 변환하는 함수를 $d_a : \overline{\boldsymbol{A}} \rightarrow \boldsymbol{A}$로 정의한다.

(3) 서술적인 정책 (Descriptive Policy)의 설명 가능성 및 이론적 성능 분석

설명 가능한 인공지능 기술에서 설명 가능성의 핵심은 의사결정의 근거를 제공하는 것으로, 인공지능이 어떤 이유로 그와 같은 의사결정을 수행했는지 사람이 이해할 수 있는 형태의 정보로 표현할 수 있어야 한다. 기존의 정책구조에서는 이와 같은 근거를 파악하기 어려운 문제가 있었으나, 본 연구에서 제안하는 서술적인 정책은 의사결정의 근거를 자연스럽게 제공하는 특성을 갖는다. 서술적인 정책은 서술적인 상태 정보 및 서술적인 무선 자원 할당 결정 구조를 바탕으로 해당 기법이 어떤 스케줄링 원칙에 기반하여 스케줄링을 수행하는지를 표현할 수 있다. 구체적으로, 서술적인 정책 구조에서 학습된 행동-상태 가치 함수를 살펴보면 상태 정보와 자원 할당 목적 달성 간의 중요도 및 관계를 파악할 수 있다. 따라서 이와 같은 관계를 통해 서술적인 정책 구조는 무선 자원 할당 결정을 설명할 수 있으며, 이는 실험에서 구체적으로 보인다. 또한 본 연구 과제에서 제안한 서술적인 정책은 이론적으로 최적 성능을 달성할 수 있음을 보였으며, 해당 분석은 연구성과 [2]에서 발표되었다.

(4) 실험 결과

3차년도에서 1차년도 및 2차년도 연구 결과를 통합하여 실험을 진행하였으므로, 본 최종보고서에서는 3차년도의 실험 결과로 1차년도의 실험 결과를 대신한다.

2차년도 개발 목표: 다수 셀 무선 네트워크 시스템에서 동작원리를 설명 가능한 지능형 셀 간 간섭 조절 알고리즘 개발

- 본 연구는 대규모 무선 네트워크에서의 설명 가능한 지능형 무선 자원 관리 기법의 개발을 목표로 하며, 효율적인 기법 개발을 위해서는 분산적/계층적 접근이 요구됨. 이를 위해 2차년도에서는 다수 셀을 갖는 대규모 무선 네트워크에서 동작원리를 설명 가능한 지능형 셀 간 간섭 조절 알고리즘에 관한 연구를 진행함
- 다수의 셀로 구성된 무선 네트워크 시스템에서는 셀 간 간섭으로 인해 각 셀의 네트워크 성능이 저하될 수 있음 [3]. 따라서 본 연구에서는 다수 셀 무선 네트워크 시스템에서 동작원리를 설명 가능한 지능형 셀 간 간섭 조절 알고리즘을 개발함. 셀 간 간섭 조절은 각 셀 사용자들의 채널 상황, 간섭 상황 등을 종합적으로 고려하여 조절되므로, 각 상황이 얼마나 간섭 조절에 영향을 미치는지 확인할 수 있는 기법을 개발함

(1) 다수 셀 무선 네트워크 시스템 셀 간 간섭 조절 문제 정의

먼저 다수 셀을 갖는 무선 네트워크 시스템에서 셀 간 간섭 조절 문제를 정의한다. 본 연구에서는 W Hz의 대역폭을 갖는 TDMA 무선 네트워크 시스템 환경을 고려하며, K개의 셀이 해당 대역폭을 함께 활용함을 가정한다. 구체적으로 무선 자원은 timeslot $t \in \{0,1,2,\ldots\}$ 단위로 관리되며, 각 timeslot별 무선 자원은 셀 내에 존재하는 사용자 중 하나에게 할당된다. 본 셀 간 간섭 조절 문제에서는 매 timeslot에서 각 셀이 이미 자원 할당을 수행한 상황을 가정한다. 즉, 각 셀은 해당하는 timeslot에서 서비스 될 사용자를 선택한 상황이며, 이 같은 자원 할당은 전년도 단일 셀 무선 자원 할당 알고리즘 등의 기법에 기반하여 수행될 수 있다.

본 연구에서는 위와 같은 시스템에서 각 timeslot에서 셀 간 간섭을 조절을 위해 각 셀에서 서비스 될 사용자를 고려하여 각 셀의 전송 전력을 결정한다. 결국 셀 간 간섭은 매 timeslot에 독립적으로 이루어지므로 본 연구에서는 timeslot 인덱스 t를 생략한다. 보다 간편한 문제 정의를 위해 앞서 설명한 다수 셀 셀 간 간섭 상황을 K개의 단일 안테나 송수신쌍이 존재하는 환경으로 고려한다. 먼저 k번째 셀의 기지국-사용자 간 전송 채널을 h_{kk}로 정의한다. 또한 j번째 셀로부터 k번째 셀의 사용자로의 간섭 채널을 h_{kj}로 정의한다. 모든 채널은 주어진 timeslot 내에서는 일정한 값이 유지된다고 가정한다. 각 셀 k의 전송전력을 p_k로 나타내고, 잡음 전력을 σ^2으로 표현한다. 위와 같은

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

상황에서 셀 k 사용자의 신호대간섭·잡음비 (signal to interference-plus-noise ratio, SINR)은 다음과 같이 정의된다.

$$\mathrm{SINR}_k = \frac{|h_{kk}|^2 p_k}{\sum_{j=1, j\neq k}^{K} |h_{kj}|^2 p_j + \sigma^2} \quad \text{식 (2)}$$

위 SINR에 기반한 각 셀의 전송률은 아래와 같이 정의된다.

$$r_k = \log(1 + SINR_k) \quad \text{식 (3)}$$

셀 간 간섭의 목적으로 무선 네트워크 시스템의 대표적인 성능지표인 총 전송률을 최대화하도록 한다. 구체적으로 본 연구에서 고려하는 셀 간 간섭 문제의 목적은 각 셀에서 서비스하도록 선택된 사용자들의 채널 상황을 고려하여 총 전송률을 최대화할 수 있도록 각 셀의 전송 전력을 결정하는 것으로 정리된다. 이를 수식으로 표현하면 아래와 같다.

$$\underset{\{p_1, p_2, \ldots, p_K\}}{\text{maximize}} \sum_{k=1}^{K} r_k = \log\left(1 + \frac{|h_{kk}|^2 p_k}{\sum_{j=1, j\neq k}^{K} |h_{kj}|^2 p_j + \sigma^2}\right) \quad \text{식 (4)}$$

$$\text{subject to } 0 \le p_k \le p_{\max}, \forall\, k = 1, 2, \ldots, K$$

위 제약조건에서 $p_{\max}$는 각 셀의 최대 전송 전력을 의미한다.

(2) 심층신경망을 활용한 셀 간 간섭 조절 및 설명 가능한 셀 간 간섭 조절 프레임워크 구성

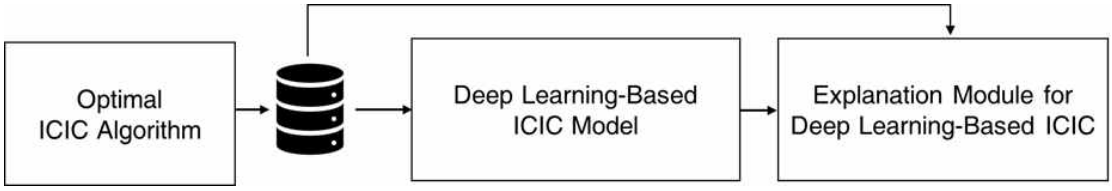
식 (4)에서 정의된 다수 셀에서의 셀 간 간섭 조절 문제는 nonconvex 문제로써 간단히 해결할 수 있는 문제는 아니다 [4]. 하지만 해당 문제를 해결할 수 있는 알고리즘에 관한 연구가 지금까지 다수 진행되어 왔다 [5]. 이를 위한 대표적인 알고리즘으로 weighted minimum mean squared error (WMMSE) 알고리즘이 있다. 해당 알고리즘은 위의 셀 간 간섭 조절 문제를 더 높은 차원의 결정 공간을 갖지만 더 해결하기 용이한 형태의 weighted sum-rate maximization 문제로 변형시켜 문제를 해결한다. 구체적으로 해당 문제는 아래와 같다.

$$\underset{\{w_k, u_k, v_k\}_{k=1}^{K}}{\text{maximize}} \sum_{k=1}^{K} w_k e_k - \log(w_k) \ \text{ subject to } 0 \le v_k \le \sqrt{p_{\max}}, \forall\, k = 1, 2, \ldots, K \quad \text{식 (5)}$$

위 문제에서 $e_k = (u_k |h_{kk}|^2 v_k - 1)^2 + \sum_{j\neq k} (u_k |h_{kj}| v_j)^2 + \sigma^2 u_k^2$이다. WMMSE 알고리즘에서는 위와 같은 문제를 해결할 수 있는 block coordinate descent method를 적용하여 문제를 해결하고 해결된 결과를 바탕으로 각 셀 k의 전송 전력을 $p_k = (v_k)^2$과 같이 결정한다. 앞서 소개한 전통적인 형태의 셀 간 간섭 조절 알고리즘은 셀 간 간섭 조절 문제를 최적으로 해결할 수 있으나 반복적인 연산을 통해 문제를 해결하여 계산 복잡도가 높다는 문제가 있다 [6]. 이 같은 문제는 알고리즘을 실행하는데 소요되는 시간이 길어 알고리즘을 실제 시스템에 적용하기 어렵게 만든다. 이를 해결하기 위해 본 연구에서는 전통적인 형태의 알고리즘 동작을 모사할 수 있는 심층 신경망 모델을 학습시켜 활용하는 방안을 고려한다.

딥러닝 기법은 큰 표현용량을 갖는 심층 신경망에 입력과 출력 간의 관계를 학습시킨다. 따라서 심층 신경망 기반의 셀 간 간섭제어 기법에서는 전통적인 셀 간 간섭 조절 알고리즘이 갖는 모든 채널 정보 (입력)에 대한 각 셀의 전송 전력 (출력) 간의 관계를 심층 신경망이 학습하도록 한다. 이를 통해 심층 신경망은 해당 알고리즘의 동작을 모사할 수 있고, 결국 학습된 심층 신경망을 이용하면 알고리즘의 복잡한 계산 없이도 주어진 채널 정보에 기반한 각 셀의 적절한 전송 전력을 구할 수 있게 된다. 이같은 심층 신경망 기반의 지능형 셀 간 간섭 조절 접근 방식에서의 문제점은 심층 신경망 모델의 설명 불가능성으로 인해 발생한다. 예를 들어, 학습 후 검증 과정에서 심층 신경망 모델의 셀 간 간섭 조절 결과의 오류가 크게 나타날 경우 심층 신경망 모델이 어떤 이유로 인해 그와 같은 결과를 출력했는지 알 수 없으므로 이미 널리 알려진 도메인 지식을 이용하여 모델을 개선하는데 어려움이 있을 수 있다. 이 같은 문제를 해결하기 위해 본 연구는 심층 신경망 기반의 셀 간 간섭 조절 알고리즘과 함께 설명 가능한 인공지능 기술을 이용하여 해당 모델을 설명할 수 있는 셀 간 간섭 조절 심층 신경망 학습 프레임워크를 제안한다. 해당 프레임워크는 아래 그림과 같이 정리된다.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



<심층신경망을 활용한 셀 간 간섭 조절 및 설명가능한 셀 간 간섭 조절 프레임워크 개요도>

이제 제안한 프레임워크에 관하여 설명한다. 먼저 위 그림에서 최적 셀 간 간섭 조절 (inter-cell interference coordination, ICIC) 알고리즘은 앞서 언급한 WMMSE 알고리즘이 해당된다. (다른 형태의 알고리즘도 얼마든지 사용될 수 있다.) 최적 셀 간 간섭 조절 알고리즘의 동작을 모사하는 심층 신경망의 학습을 위해서는 먼저 데이터셋을 구성해야한다. 이를 위해 임의의 자원 할당 상황에서 해당 알고리즘을 활용하여 셀 간 간섭 조절을 수행하는 과정을 반복하고, 그에 따른 해당 채널 상황 (입력값) 및 셀 전송 전력 (출력값)을 저장하여 최적 셀 간 간섭 조절 알고리즘 데이터를 생성한다. 구체적으로 알고리즘에서 사용되는 입력값은 모든 채널 값으로, $H=\{h_{kj}\}_{\forall k,j=1,2,...,K}$와 같고, 주어진 채널 값을 이용하여 WMMSE 알고리즘을 수행하면 모든 셀에 대한 전송 전력 $P=\{p_k\}_{\forall k=1,2,...,K}$가 구해진다. i번째 임의의 자원 할당 상황의 학습 데이터 샘플은 (H_i,P_i)와 같이 나타낸다. 이 같은 데이터 샘플을 반복적으로 획득하여 WMMSE 알고리즘의 동작을 학습하기 위한 학습데이터를 $D=\{(H_i,P_i)\}_{\forall i=1,2,...,N}$와 같이 획득한다. 여기서 N은 총 데이터 샘플의 개수를 의미하며, H_i와 P_i는 심층 신경망 학습을 위한 특징 정보와 목표값에 각각 대응된다.

일반적인 딥러닝 기법과 해당 데이터셋을 활용하여 심층 신경망을 학습시키면, 심층 신경망은 최적 셀 간 간섭 조절 알고리즘의 작동을 모사하여 임의의 주어진 채널 상황에 대한 최적 셀 간 간섭 조절 결과 (즉, 각 기지국의 전송 전력)을 예측한다. 정리하면 WMMSE 알고리즘의 동작을 $P_i=f(H_i)$와 같은 함수형태로 나타낼 때, 심층 신경망은 함수 f를 학습화여 임의의 H에 대한 P를 구할 수 있도록 한다. 본 연구에서는 이 같은 심층 신경망 기반 셀 간 간섭 조절 모델에 설명 가능한 인공지능 기법을 적용하여 신경망을 설명할 수 있도록 한다. 구체적으로 설명 가능한 인공지능 기법 중 Shapley additive explnanations (SHAP) [7]이라고 하는 기법을 주요 기법으로 활용하였다. 해당 기법은 게임이론의 Shapley value 등의 이론적 배경을 기반으로 신경망 모델의 출력값이 어떤 입력 특징에 영향을 받아 결정되었는지 정량적으로 표현해주는 특징 중요성 (feature importance) 분석 기능을 수행한다. 또한 본 연구에서는 주요 기법으로 고려되지 않았으나, 설명가능한 인공지능 기법으로 SHAP과 같은 입력 특징 중요성 분석 기법뿐만 아니라 conformal prediction [8]과 같은 불확실성 정량화 기법 등도 함께 적용될 수 있다.

(3) 실험 결과

3차년도에서 1차년도 및 2차년도 연구 결과를 통합하여 실험을 진행하였으므로, 본 최종보고서에서는 3차년도의 실험 결과로 2차년도의 실험 결과를 대신한다.

3차년도 개발 목표: 대규모 시스템에서의 설명 가능한 통합형/지능형 무선 자원 관리 알고리즘 개발

- 본 연구에서는 대규모 무선 네트워크에서의 설명 가능한 지능형 무선 자원 관리 기법의 개발을 목표로 하며, 효율적인 기법 개발을 위해서는 분산적/계층적 접근이 요구됨. 이를 위해 본 연차에서는 이전 연차에서 진행된 단일 셀에서의 설명 가능한 지능형 자원 할당 알고리즘과 설명 가능한 지능형 셀 간 간섭 조절 알고리즘을 통합하여 대규모 시스템에서의 설명 가능한 지능형 무선 자원 관리 알고리즘에 관한 연구를 진행함
- 다수의 셀로 구성된 무선 네트워크 시스템에서의 무선 자원 관리 문제에서 결정해야하는 관리 대상은 다음과 같이 구성됨. 1) 각 단일 셀 내에서의 무선 자원 할당 문제. 2) 다수 셀 간 간섭 조절을 위한 각 셀의 전송 전력 결정 문제. 따라서 본 연구에서는 다수 셀 무선 네트워크 시스템에서 동작 원리를 설명 가능한 지능형 단일 셀 내 무선 자원 할당 알고리즘 및 설명 가능한 지능형 셀 간 간섭조절 알고리즘을 통합하여 대규모 시스템에서의 설명 가능한 무선 자원 관리 기법을 개발함

(1) 다수 셀 무선 네트워크 시스템 무선 자원 관리 문제 정의

먼저 다수 셀을 갖는 무선 네트워크 시스템에서 셀 간 간섭 조절 문제를 정의한다. 본 연구에서는 W Hz의 대역폭을 갖는 TDMA 무선 네트워크 시스템 환경을 고려하며, K개의 셀이 해당 대역폭을 함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

께 활용함을 가정한다. 이때, 각 셀은 $k \in \{1,2,\cdots,K\}$로 표기한다. 구체적으로 무선 자원은 timeslot $t \in \{0,1,2,...\}$ 단위로 관리되며, 각 timeslot별 무선 자원은 셀 내에 존재하는 사용자 중 하나에게 할당된다. 무선 네트워크 시스템의 셀 k 내에는 총 N_k명의 사용자가 존재함을 가정하며, 사용자는 $n \in \{1,2,...,N_k\}$로 표기한다. 각 timeslot에서 각 셀의 무선 자원이 특정 사용자에게 할당되면 시스템에서는 셀 간 간섭을 조절을 위해 각 셀에서 서비스될 사용자를 고려하여 각 셀의 전송 전력을 결정한다.

주어진 다수 셀 무선 네트워크 시스템에서 MDP 형태로 무선 자원 관리 문제를 정의하기 위해서 시스템의 상태를 나타내는 state와 자원 할당 결정을 나타내는 action에 관한 정의를 수행한다. 본 연구에서는 일반화된 문제를 고려하기 위하여 시스템의 상태를 구체화하지 않고 일반화하여 표현한다. 각 사용자가 갖는 시스템 상태 정보의 개수를 L라고 정의하면 timeslot t에서 셀 k 내 사용자 n의 시스템 상태 정보는 $h_{k,n}^t = (h_{k,n,1}^t,...,h_{k,n,L}^t)$와 같이 표현된다. 각 시스템 상태정보는 채널 품질 지시자, 버퍼 상태, 서비스 품질 만족도 등으로 구성될 수 있다. Timeslot t에서 셀 k 내 모든 사용자의 시스템 상태 정보를 s_k^t라고 표기하면, 전체 시스템의 state는 모든 셀의 시스템 상태 정보를 표현하도록 $s^t = (s_1^t,\cdots,s_K^t) \in \boldsymbol{S}$와 같이 정의된다. 이 때, $\boldsymbol{S}$는 시스템 상태 정보 공간을 나타낸다. 또한 timeslot t에서 시스템의 무선 자원 관리의 경우 앞서 언급한대로 각 셀 내에서 무선 자원이 할당될 사용자 및 전송전력의 결정으로 구성된다. 셀 k의 action은 이와 같은 결정 사항을 표현하도록 정의될 수 있으며 timeslot t에 관하여 a_k^t와 같이 표기한다. 이 때, 전체 시스템의 action은 $a^t = (a_1^t,\cdots,a_K^t) \in \boldsymbol{A}$와 같이 표기한다. 앞선 수식에서 $\boldsymbol{A}$의 경우 무선 자원 할당 결정 공간을 나타낸다. 마지막으로 시스템 상태 정보 (state)를 기반으로 어떤 무선 자원 할당 (action)을 선택할 것인지를 결정하는 함수를 정책 (policy)라 하며 $\pi : \boldsymbol{S} \rightarrow \boldsymbol{A}$와 같이 나타낸다.

일반적으로 시스템의 무선 자원 관리를 통해 달성하고자 하는 목표는 각 셀의 유틸리티 함수의 합으로 표현할 수 있고 유틸리티 함수의 함수값은 시스템 상태 정보와 무선 자원 할당에 따라 결정된다. 따라서 셀 k의 유틸리티 함수를 $u_k(s,a)$와 같이 표기하며 해당 유틸리티 함수의 합을 최대화하도록 무선 자원 할당을 결정함으로써 시스템의 목표를 달성할 수 있게 된다. 본 연구에서는 유틸리티 함수로 무선 전송률을 사용하고, 각 사용자의 최소 평균 전송률 제약조건을 고려하는 대표적인 무선 자원 관리 문제를 고려한다. 해당 문제를 수식으로 표현하면 아래와 같다.

$$\begin{aligned} &\underset{\pi:\mathcal{S}\rightarrow\mathcal{A}}{\text{maximize}} \; U^{\pi}(s) = \mathbb{E}\left[\sum_{t=0}^{\infty}\sum_{k=1}^{K}\sum_{n=1}^{N_k}(\gamma)^t r_{k,n}(s^t,\pi(s^t))\,\middle|\, s^0 = s\right] \\ &\text{subject to } \frac{1}{T}\sum_{t=0}^{\infty} r_{k,n}(s^t,\pi(s^t)) \le R_{k,n},\ \forall k,n \end{aligned} \qquad \text{식 (6)}$$

위의 식에서 $r_{k,n}$은 셀 k 내 사용자 n의 전송률 함수를 의미하며 시스템 상태 정보에 해당하는 기지국과의 전송 채널, 다른 기지국으로부터의 간섭 채널과 무선 자원 관리 결정에 관련된 해당 사용자에 자원이 할당되었는지 여부, 전송 전력으로 결정된다.

(2) 자원 할당 및 셀 간 간섭을 위한 설명 가능한 지능형 무선 자원 관리 프레임워크 구성

위 식 (6)의 문제를 설명 가능한 지능형 기법으로 해결할 수 있는 프레임워크를 구성한다. 위의 무선 자원 관리 문제를 한꺼번에 해결하기에는 문제의 복잡도가 너무 높으므로, 본 연구에서는 단일 셀 내 자원 할당 문제 및 전송 전력 결정 문제로 분할하여 해당 문제를 해결한다. 먼저, 셀 k의 단일 셀 자원 할당 문제는 아래와 같이 정의된다.

$$\begin{aligned} &\underset{\pi_k:\mathcal{S}_k\rightarrow\mathcal{A}_k}{\text{maximize}} \; U_k^{\pi}(s_k) = \mathbb{E}\left[\sum_{t=0}^{\infty}\sum_{n=1}^{N_k}(\gamma)^t r_{k,n}(s_k^t,\pi_k(s_k^t))\,\middle|\, s_k^0 = s_k\right] \\ &\text{subject to } \frac{1}{T}\sum_{t=0}^{\infty} r_{k,n}(s_k^t,\pi_k(s_k^t)) \le R_{k,n},\ \forall n \end{aligned} \qquad \text{식 (7)}$$

위의 문제에서 state s_k는 셀 내 사용자의 전송 채널로 구성되고, action a_k는 셀 내에서 어떤 사용자에게 무선 자원을 할당할지를 나타낼 수 있도록 정의한다. 위의 문제는 제약 조건이 있는 MDP 문제로써, Lagrange 접근법을 활용하여 해결할 수 있다. 구체적으로, 제약 조건의 만족을 위해 매

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

timeslot마다 각 사용자의 전송률 결과를 바탕으로 각 사용자의 제약 조건별 multiplier를 업데이트 하면서 문제를 해결한다. 본 연구에서는 1차년도 연구 결과에서와 같이 해당 방식을 이용하여 문제를 해결하기 위해 상태 정보를 전송 채널 상태와 사용자 별 요구조건 multiplier로 구성하였다. 이때, multiplier의 값은 해당하는 사용자의 요구조건의 만족도가 낮을수록 커지는 값으로 해당 사용자에 대한 가중치로 생각할 수 있다.

단일 셀 내 자원 할당 문제를 위와 같이 정의하여 매 timeslot에서의 각 셀 내 자원 할당을 결정하면, 셀 간 간섭을 고려하여 전송 전력을 결정해야한다. Timeslot t에서 각 셀 k 내 자원이 할당된 사용자를 n_k^t라고 나타내고, 셀 k의 기지국-사용자 n_k^t 간 전송 채널을 h_{kk}^t로 정의한다. 또한 셀 j로부터 셀 k의 사용자 n_k^t로의 간섭 채널을 h_{kj}^t로 정의한다. 모든 채널은 주어진 timeslot 내에서는 일정한 값이 유지된다고 가정한다. 각 셀 k의 timeslot t에서의 전송전력을 p_k^t로 나타내고, 잡음 전력을 σ^2으로 표현한다. 위와 같은 상황에서 timeslot t의 셀 k 내 사용자 n_k^t가 갖는 신호대간섭잡음비(signal to interference-plus-noise ratio, SINR)은 다음과 같이 정의된다.

$$\mathrm{SINR}_k^t = \frac{|h_{kk}^t|^2 p_k^t}{\sum_{j=1, j\neq k}^{K} |h_{kj}^t|^2 p_j^t + \sigma^2} \qquad \text{식 (8)}$$

SINR을 이용하여 셀 k 사용자 n_k^t의 전송률을 표현하면 $r_{k,n_k^t} = \log\left(1 + SINR_k^t\right)$와 같고, 이를 이용하여 전송 전력 조절 문제를 수식으로 표현하면 아래와 같다.

$$\underset{\{p_1, p_2, \ldots, p_K\}}{\text{maximize}} \sum_{k=1}^{K} \lambda_{k,n_k^t}^t r_{k,n_k^t} \text{ subject to } 0 \le p_k \le p_{\max}, \forall k = 1,2,\ldots,K \qquad \text{식 (9)}$$

위의 수식에서 $\lambda_{k,n_k^t}^t$는 timeslot t에서 셀 k 내 사용자 n_k^t의 multiplier 값을 의미하고, $p_{\max}$는 각 셀의 최대 전송 전력을 의미한다. 위와 같이 multiplier를 고려함으로써 셀 간 간섭 조절 시 각 사용자의 목표 평균 전송률을 효과적으로 달성할 수 있다 [9].

본 연구에서 제안하는 프레임워크는 대규모 시스템에서의 자원 관리 문제를 각 셀의 자원 할당 문제와 셀 간 간섭을 고려한 전송 전력 결정 문제로 계층적, 분산적으로 분할하여 해결함으로써 효율적으로 자원 관리를 수행할 수 있도록 한다. 또한 단일 셀의 자원 할당 문제와 셀 간 간섭 조절을 위한 전송 전력 결정 문제는 1차년도와 2차년도에서 설명 가능한 지능형 알고리즘을 통해 해결한 바 있으므로, 앞서 연구한 알고리즘을 통합적으로 활용하여 대규모 시스템에서의 자원 관리 문제를 지능적으로 해결할 수 있다. 앞서 설명한 프레임워크를 그림으로 나타내면 아래와 같다.



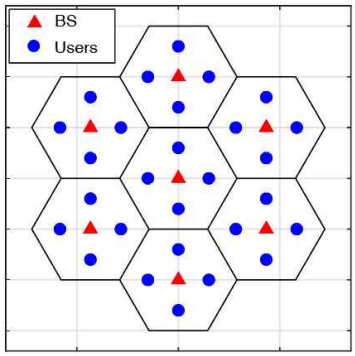
<계층적 & 분산적 설명 가능한 지능형 무선 자원 관리 프레임워크>

(3) 실험 결과

본 연구에서 제안한 설명 가능한 지능형 무선 자원 관리 프레임워크를 검증하기 위해 모의실험을 진행하였다. 다수 셀 환경에서의 셀 간 간섭 알고리즘을 검증할 필요가 있으므로 총 7개의 기지국으로 구성된 환경을 고려한다. 각 셀의 토폴로지는 오른쪽 그림과 같고 각 기지국 간의 거리는 150m로, 기지국과 사용자와의 거리는 60m로 설정하였다. 중앙에 있는 기지국이 간섭이 가장 강한 기지국으로, 이를 기지국 0으로 설정한다. 사용자의 평균 요구 전송률은 3Mbps로 주어진다. 또한 과제의 연속적인 연구를 위해 단일 셀 내의 실험 환경은 작년도 실험 환경과 유사하게 결정하였다. 구체적으로, 시스템의 대역폭은 5 MHz, noise density -150 dBm/Hz로 설정하고, pathloss exponent 3.76의 감쇄 및 6 dB 표준편차를 갖는 log-normal shadowing을 고려하였다. 각 기지국의 최대 전송 전력은 5 W로 주어지며, 각 기지국은 심층 강화학습 기반 서술적인 정책을 이용하여 각 사용자의 평균 전송

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

률을 만족시키면서 총 전송률을 최대화하도록 무선 자원을 할당하며, 시스템은 자원이 할당된 사용자를 기반으로 셀 간 간섭 제어를 수행한다. 본 실험에서의 서술적인 정책은 상태 정보로 채널 상태와 사용자 별 요구조건 multiplier을 갖는다. 마지막으로 서술적인 정책의 정의를 위해 채널 공간을 [-30,-50] dB로 프로젝션한 후 5개의 부구간으로 분할하였고, multiplier 공간 또한 [0,2]의 구간으로 프로젝션한 후 10개의 부구간으로 분할하였다.



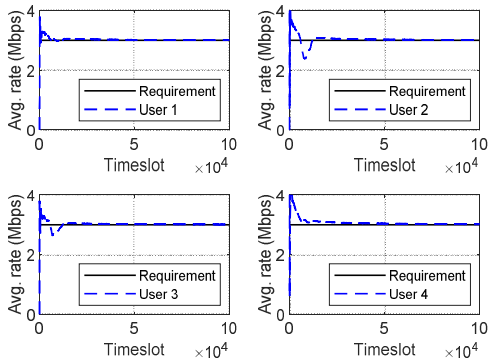
<모의실험 셀 토폴로지>

실험을 위해 위의 실험 환경에서 7개의 기지국은 독립적으로 심층 강화학습을 이용하여 설명 가능한 무선 자원 정책을 10^6 timeslot동안 학습한다. 각 timeslot에서는 각 기지국에서 결정된 무선 자원 할당 결과 및 각 기지국 사용자의 Lagrange multiplier를 이용하여 WMMSE 알고리즘으로 최적 셀 간 간섭 제어를 수행하여 채널 및 multiplier에 따른 셀 간 간섭 제어 데이터셋을 구성하였다. 그 중 90,000개의 샘플을 학습 데이터로 활용하고, 나머지 10,000개의 샘플은 테스트 데이터로 활용하였다. 학습에 사용될 심층 신경망은 유닛 개수 [400,400,100,100]를 갖는 4개의 은닉층으로 구성되어 있는 fully-connected 신경망으로 구성하였고, 손실 함수는 MSE를 사용하였다. 또한 최적화 알고리즘으로는 Adam optimizer를 사용하고, 학습률은 0.001로 설정하였다.

먼저 설명 가능한 지능형 무선 자원 관리 프레임워크의 성능을 평가한다. 이를 위해 각 기지국의 지능형 무선 자원 할당 알고리즘과 최적 셀 간 간섭 제어 알고리즘인 WMMSE를 사용한 경우, 모든 기지국의 최대 전송 전력을 사용하는 Max Power를 사용한 경우, 각 기지국이 임의의 전송 전력을 사용하는 Random Power를 사용한 경우와 제안 프레임워크의 성능을 비교한다. 성능지표는 모든 셀의 sum-rate를 사용한다. 성능 평가는 100,000 timeslot 동안 무선 자원 할당을 진행하며 sum-rate를 평가하여 이루어진다. 실험 결과는 아래와 같이 정리된다.

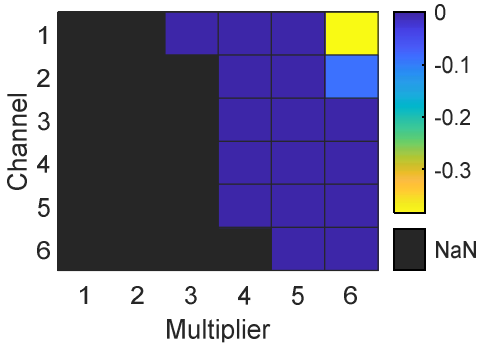
	WMMSE	DNN	Max Power	Random Power
Sum-Rate	31.140	30.817	27.765	26.641
최적성능달성비율	100%	98.962%	89.160%	85.552%

위 결과에서 sum-rate는 실험이 진행된 timeslot에서의 평균 sum-rate를 의미한다. 결과를 살펴보면, 심층 신경망 기반의 지능형 셀 간 간섭 조절 모델의 성능이 최적 셀 간 간섭 제어 알고리즘인 WMMSE와 거의 근접한 수준의 성능을 보여주는 것을 확인할 수 있다. 반면 Max Power와 Random Power의 sum-rate는 그에 미치지 못한다. 또한 우측 그림들은 제안 프레임워크를 사용한 경우에서 강한 간섭을 갖는 기지국 0 내 사용자들의 평균 전송률을 나타낸다. 본 결과에서는 제안 프레임워크를 사용하는 경우 DNN 기반의 셀 간 간섭제어를 활용하여 전송 전력을 결정했음에도 전체 기지국의 총 전송률을 최대화하면서 동시에 효과적으로 평균 전송률 요구조건을 만족하는 것을 확인할 수 있다.



<기지국 0 사용자 평균 전송률>

각 기지국에서 학습하는 서술적인 정책의 설명가능성을 보이기 위하여 기지국 0의 행동-상태 가치 함수의 근사값 (Q-approximation)을 오른쪽 그림에 나타낸다. 구체적으로 이를 통해 채널 상황과 서비스 품질 불만족도를 표현하는 multiplier가 각각 무선 네트워크 시스템의 자원 할당 목적과 어떤 관계가 있는지 설명할 수 있음을 보일 수 있다. 일반적으로 무선 네트워크 환경에서 서술적인 상태 정보의 경우 사용자의 수가 모든 가능한 상태 정보 조합보다 작으므로 주어진 상태를 갖는 사용자가 존재하지 않는 선택 불가능한 서술적인 무선 자원 할당 결정의 경우에는 NaN 값으로 표기하였다. 해당 그림에서 채널 상태 정보의 인덱스는 작을수록 좋은 채널 상태를 갖는 것을 의미하고, multiplier 상태 정보의 인덱스는 작을수록 서비스 품질 요구조건을 잘 만족시켜주고 있다는 것을 의미한다. 각 상태 정보는

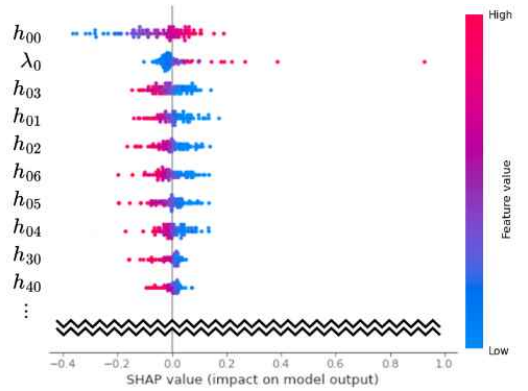


<기지국 0 행동-상태 가치 함수 근사>

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

실제 실험에서 발생한 부분에 관하여 나타내었다. 위의 그림에서 서술적인 상태 정보에 따른 가치 함수 근사값은 좋은 채널 상태를 갖고 (낮은 채널 인덱스) 서비스 품질 요구조건 만족도가 낮은 (높은 multiplier 인덱스) 사용자를 높은 우선순위로 자원 할당을 수행하는 것을 확인할 수 있고, 이를 통해 서술적인 정책이 어떤 경향을 가지고 자원 관리를 수행하는지 알 수 있다.

위에서 각 기지국의 지능형 무선 자원 할당의 설명 가능성을 살펴보았고, 이제 지능형 셀 간 간섭 제어 모델에서 전송 전력을 어떻게 결정하는지 설명할 수 있는 모델의 결과를 살펴본다. 이를 통해 심층 신경망 기반 셀 간 간섭 조절 모델이 널리 알려진 도메인 지식에 부합하는 형태로 간섭 조절 결정을 내리는지 확인할 수 있다. SHAP 기법 [7]을 활용하여 채널 정보 H_{kj} 및 multiplier λ_k 들이 전송 전력을 결정하는데 어떻게 영향을 미쳤는지 파악한다. 오른쪽 그림은 0번째 기지국의 전송 전력에 관한 분석으로, 0번째 기지국의 전송 전력을 결정하는데 가장 큰 영향을 미친 10개의 채널 정보를 표시하였다. 그래프의 각 점은 데이터 샘플 하나를 의미하며, 점의 색은 해당하는 채널의 크기를 나타낸다. 그리고 SHAP value의 경우 양의 값은 전송 전력 값을 크게 만드는데 기여했다는 것을 의미하고 음의 값은 작게 만드는게 기여했다는 것을 의미한다. 위의 결과를 보면 0번째 기지국의 전송 전력에 가장 영향을 크게 미치는 정보는 해당 기지국-사용자 간의 전송채널 (h_{00})과 자원이 할당된 사용자의 multiplier 값 (λ_0)임을 알 수 있다. 전송채널 값과 multiplier 값은 모두 전송 전력값과 양의 상관관계를 가지며, 이는 전송 채널이 클수록, 사용자가 요구 전송률을 만족하지 못하는 정도가 클수록 더 큰 전송 전력을 사용한다는 것을 의미한다. 또한 0번째 기지국이 간섭을 주는 채널 및 0번째 셀 사용자가 간섭을 받는 채널이 그 뒤를 잇는 것을 확인할 수 있고, 해당 채널들은 전송 전력과 음의 상관관계를 갖는 것을 볼 수 있다.



<셀 간 간섭조절 모델의 특징 중요성 분석 결과>

3. 연구개발과제의 수행 결과 및 목표 달성 수준

1) 정성적 연구개발성과(연구개발결과)

□ **1차년도**: 단일 셀 무선 네트워크 시스템에서 알고리즘의 동작원리를 설명 가능한 지능형 무선 자원 할당 알고리즘 개발을 목표로 연구를 수행하였고, 이를 달성할 수 있는 새로운 정책 구조인 서술적인 정책 (Descriptive Policy)를 제안하고 그 성능을 이론적으로 분석함. 서술적인 정책의 설명 가능성 고찰을 통해 해당 정책 구조가 무선 자원 할당을 선택하는 데 있어 설명을 제공할 가능성을 제시하고 위의 실험 결과를 통해 실제적으로 자원 할당의 설명을 제공함을 보였음. 결과적으로 연구의 목표인 **단일 셀 무선 네트워크 시스템에서 알고리즘의 동작원리를 설명 가능한 지능형 무선 자원 할당 알고리즘 개발을 성공적으로 달성**함

□ **2차년도**: 다수 셀 무선 네트워크 시스템에서 알고리즘의 동작원리를 설명 가능한 지능형 셀 간 간접 조절 알고리즘 개발을 목표로 연구를 수행하였고, 이를 달성할 수 있도록 심층신경망 기반의 셀 간 간접 조절 알고리즘과 간섭 조절 결과의 근거를 제공하는 설명가능한 인공지능 모듈을 함께 활용하는 프레임워크를 제안하였음. 또한 실험을 통해 실제적으로 셀 간 간섭의 설명을 제공함을 보였음. 결과적으로 연구의 목표인 **다수 셀 무선 네트워크 시스템에서 알고리즘의 동작원리를 설명 가능한 지능형 셀 간 간섭 조절 알고리즘 개발을 성공적으로 달성**함

□ **3차년도**: 다수 셀 대규모 무선 네트워크 시스템에서 설명 가능한 지능형 무선 자원 관리 프레임워크의 개발을 목표로 연구를 수행하였고, 이를 달성할 수 있도록 1차년도 및 2차년도 연구 결과를 통합적으로 고려하여 계층적, 분산적 지능형 무선 자원 관리 프레임워크를 제안하였음. 각 기지국은 분산적으로 지능형 무선 자원 할당을 수행하고, 무선 자원 할당 정보를 바탕으로 심층신경망 기반의 셀 간 간섭 조절 알고리즘을 통해 무선 네트워크 시스템에서 각 기지국의 전송 전력을 결정함. 실험을 통해 구체적으로 설명 가능한 인공지능 프레임워크를 활용하여 지능형 알고리즘들의 각 기지국의 무선 자원 할당과 셀 간 간섭 제어 결과의 설명을 관찰하였고, 해당 설명이 도메인 지식과 일치함을 확인함. 또한, 제안 기법의 경우 무선 자원 관리가 분산적, 계층적으로 이루어져 대규모 시스템에 적합함. 결과적으로 연구의 최종 목표인 **대규모 시스템에서의 설명 가능한 통합형/지능형 무선 자원 관리 알고리즘 개발을 성공적으로 달성**함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

2) 세부 정량적 연구개발성과: [붙임1] 참조

3) 목표 달성 수준

추 진 목 표	달 성 내 용	달성도 (%)
단일 셀 무선 네트워크 시스템 내 설명 가능한 지능형 무선 자원 할당 알고리즘 개발	- 무선 자원 할당 관련 도메인 지식 분석 및 자료 조사 - 지능형 단일 셀 설명 가능한 무선 자원 할당 알고리즘 개발 - 지능형 단일 셀 무선 자원 할당 알고리즘 성능 및 설명 가능성 검증	100%
다수 셀 무선 네트워크 시스템 내 설명 가능한 지능형 셀 간 간섭 조절 알고리즘 개발	- 셀 간 간섭 조절 관련 도메인 지식 분석 및 자료 조사 - 지능형 다수 셀 간 간섭 조절 해석 모듈 및 알고리즘 개발 - 지능형 다수 셀 간 간섭 조절 알고리즘 및 해석 모듈 검증	100%
대규모 시스템에서의 설명 가능한 통합형/지능형 무선 자원 관리 알고리즘 개발	- 계층적 단일 셀 무선 자원 할당 및 셀 간 간섭 조절 기법 조사 - 지능형 무선 자원 할당 및 셀 간 간섭 조절 기법 통합화 - 대규모 네트워크 지능형 무선 자원 관리 해석 모듈 개발 - 대규모 네트워크 지능형 무선 자원 관리 해석 모듈 검증	100%

4) 목표 미달 시 원인 분석(해당 시)

- 목표 달성으로 해당 없음

4. 연구개발성과의 관련 분야에 대한 기여 정도(연구개발결과의 중요성)

□ 기술적 파급효과: 선행 연구를 통한 설명 가능한 지능형 무선 자원 관리 핵심 기술의 확보

○ 국내 무선 네트워크 분야 연구진의 기술력은 세계적인 수준이지만 딥러닝 모델을 활용한 융합기술에서 설명 가능한 인공지능 관련 연구는 여전히 미미한 실정임. 본 연구를 통해 개발된 선도적인 설명 가능한 지능형 무선 자원 관리 기법을 통해 관련 분야에서 핵심 기술을 확보함

□ 학문적 파급효과: 무선 네트워크와 인공지능 융합 기법의 설명 가능성 증명

○ 기존의 무선 네트워크와 인공지능의 융합 기법은 설명이 어려운 불투명한 딥러닝 기법의 한계로 인해 기법의 개발 이후 개선 및 활용에 제한이 있었음. 본 연구에서 개발된 무선 네트워크에서의 인공지능 융합 기술을 설명할 수 있는 프레임워크는 지능형 알고리즘들의 분석 및 이해를 가능하게 하였으며, 추후 이를 바탕으로 새로운 영역의 연구를 진행할 수 있을 것으로 기대됨

□ 산업·경제적 파급효과: 핵심 기술 확보를 통한 국내 인공지능/무선 네트워크 융합 산업의 경쟁력 제고

○ 본 연구를 통해 설명 가능한 지능형 무선 자원 관리 핵심 기술을 확보하였으므로, 추후 관련한 기술을 다양한 분야의 산업계에서 실제로 활용할 수 있도록 하여 국내 무선 네트워크 및 다양한 인공지능 응용 분야의 기술력 제고에 도움이 될 수 있음. 더 나아가 무선 네트워크/인공지능 융합 산업 관련 기술로의 확장 등 미래 무선 네트워크의 시장 개척에 도움을 줄 수 있음

□ 사회적 파급효과: 미래 무선 네트워크에서의 mission-critical 서비스 신뢰도 증대를 통한 사회적 공헌

○ 본 연구는 미래 무선 네트워크에서의 mission-critical 서비스에 적용되어 해당 서비스들을 더욱 높은 신뢰도로 지원할 수 있게 할 것으로 기대됨. 해당 서비스는 재난 통신, 철도 통신, 자율주행차 등 삶의 질을 향상시킬 수 있는 미래 기반 기술에 필수적으로 요구되므로 추후 미래 기술의 보급을 더욱 앞당기는 측면에서 사회적 공헌이 가능할 것으로 생각됨

5. 연구개발성과의 관리 및 활용 계획

□ **(설명 가능한 지능형 스케줄링 활용 분야 및 활용 방안)** 최근 활발히 연구중인 6G 무선 통신 네트워크의 경우 인공지능 기술과의 통합이 주요 고려사항으로, 본 연구성과는 무선 네트워크에서 인공지능 기술의 동작을 설명하여 통신과 인공지능이 결합된 인공지능-네이티브 통신의 실현에 활용될 수 있음

□ **(설명 가능한 지능형 스케줄링 확장 연구의 필요성)** 지능형 스케줄링 기술의 단순한 설명 가능성에서 보다 발전된 형태로써 설명된 결과를 활용하는 자가 개선형 인공지능 기반 스케줄링 기술, 자가 진화형 인공지능 기술 등 다양한 형태의 확장 연구의 기초 연구로써 본 연구성과를 활용할 예정임

□ **(설명 가능한 지능형 스케줄링 기술의 타 분야 응용)** 인공지능 기반 스케줄링은 통신 분야 뿐만 아니라, 스마트그리드, 스마트팩토리 등 다양한 산업 분야에서 공통적으로 연구되는 분야임. 따라서 본 연구 과제의 설명 가능한 지능형 스케줄링 기술은 타 분야에 응용되어 기술이전 등이 가능함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

6. 자체점검표

구분	아주 우수	우수	보통	미흡	불량	비고
연구성과의 우수성/창의성	√					
연구성과의 파급 효과	√					
연구성과에 대한 활용 가능성	√					
연구수행의 성실도	√					
연구성과에 대한 종합의견 기술	본 연구과제에서는 미래 무선 통신 네트워크에서 주요하게 연구되는 인공지능, 그 중에서도 설명가능한 인공지능에 관련된 여러 연구성과를 달성하였음. 정성적으로 연구 과제에서 목표로 했던 사항을 모두 달성하였고, 정량적으로도 다수의 논문을 출판하여 우수한 연구성과로 평가할 수 있음. 특히 연구성과들은 무선 통신 네트워크, 인공지능 분야에서 매우 우수한 논문지, 국제 학술대회에서 발표되어 연구성과의 파급효과 및 활용 가능성이 우수하다는 것을 객관적으로 확인할 수 있음					

7. 참고문헌

[1] Arrieta, Alejandro Barredo, et al. "Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI." Information fusion 58 (2020): 82-115.

[2] Lee, Hyun-Suk. "System-agnostic meta-learning for MDP-based dynamic scheduling via descriptive policy." International Conference on Artificial Intelligence and Statistics. PMLR, 2022.

[3] Zhang, Heli, et al. "Interference management for heterogeneous networks with spectral efficiency improvement." IEEE Wireless Communications 22.2 (2015): 101-107.

[4] Shi, Qingjiang, et al. "An iteratively weighted MMSE approach to distributed sum-utility maximization for a MIMO interfering broadcast channel." IEEE Transactions on Signal Processing 59.9 (2011): 4331-4340.

[5] Papandriopoulos, John, and Jamie S. Evans. "SCALE: A low-complexity distributed protocol for spectrum balancing in multiuser DSL networks." IEEE Transactions on Information Theory 55.8 (2009): 3711-3724.

[6] Sun, Haoran, et al. "Learning to optimize: Training deep neural networks for interference management." IEEE Transactions on Signal Processing 66.20 (2018): 5438-5453.

[7] Lundberg, Scott M., and Su-In Lee. "A unified approach to interpreting model predictions." Advances in neural information processing systems 30 (2017).

[8] Romano, Yaniv, Evan Patterson, and Emmanuel Candes. "Conformalized quantile regression." Advances in neural information processing systems 32 (2019).

[9] Asadi, Arash, and Vincenzo Mancuso. "A survey on opportunistic scheduling in wireless communications." IEEE Communications surveys & tutorials 15.4 (2013): 1671-1688.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임1] 세부 정량적 연구개발성과

사업명	생애 첫 연구	연구책임자	이현석	주관기관	세종대학교
과제번호	2021R1G1A1004796	과제명	6G 무선 네트워크를 위한 설명가능한 지능형 무선 자원 관리 기법 연구		

※산학강좌,기술이전 및 기술평가는 현재 입력 받지 않는 항목입니다.

과학기술/학술적 연구성과(단위 : 건)

전문학술지 논문게재				초청 강연 실적	학술대회 논문발표		지식재산권				수상 실적	출판실적		표준		신기술 지정	기술 제품 인증
국내논문		국외논문			국내	국제	출원		등록			저역서	보고서	국내	국제		
SCI	비SCI	SCI	비SCI				국내	국외	국내	국외							
0	0	8	1	0	0	1	0	0	0	0	0	0	0	0	0	0	0

전문학술지 논문게재 성과정보

과제번호	게재연월	논문제목	총저자명	출처	학술지명	권(호)	학술지구분	sci여부	impact Factor	국제공동 연구논문	기여도
2021R1G1A1004796	202112	Adaptive Transmission Scheduling in Wireless Networks for Asynchronous Federated Learning	Lee, Hyun-Suk; Lee, Jang-Won;	SCI	IEEE JOURNAL ON SELECTED AREAS IN COMMUNICATIONS	(0)	국외	SCI등재	9.144	아니오	20
2021R1G1A1004796	202112	Channel Metamodeling for Explainable Data-Driven Channel Model	Lee, Hyun-Suk;	SCI	IEEE WIRELESS COMMUNICATIONS LETTERS	10(0)	국외	SCI등재	4.348	아니오	100
2021R1G1A1004796	202203	Resource allocation in wireless networks with federated learning: Network adaptability and learning acceleration	Lee, Hyun-Suk; Lee, Da-Eun;	직접입력	ICT EXPRESS	8(1)	국외	SCI등재	4.754	아니오	50
2021R1G1A1004796	202207	Radio and Energy Resource Management in Renewable Energy-Powered Wireless Networks With Deep Reinforcement Learning	Lee, Hyun-Suk; Kim, Do-Yup; Lee, Jang-Won;	SCI	IEEE TRANSACTIONS ON WIRELESS COMMUNICATIONS	21(7)	국외	SCI등재	8.346	아니오	50
2021R1G1A1004796	202209	Contextual-Learning-Based Waveform Scheduling for Wireless Power Transfer With Limited Feedback	Kim, Kyeong-Won; Lee, Hyun-Suk; Zhang, Rui; Lee, Jang-Won;	SCI	IEEE INTERNET OF THINGS JOURNAL	9(17)	국외	SCI등재	10.238	예	20
2021R1G1A1004796	202212	Device Selection and Resource Allocation for Layerwise Federated Learning in Wireless Networks	Lee, Hyun-Suk;	SCI	IEEE SYSTEMS JOURNAL	16(4)	국외	SCI등재	4.802	아니오	50
2021R1G1A1004796	202403	Universal dynamic pilot allocation for beam alignment based on multi-armed bandits	Lee, Hyun-Suk; Kim, Do-Yup; Min, Kyungsik	직접입력	IEEE WIRELESS COMMUNICATIONS LETTERS	13(3)	국외	SCI등재	6.3	아니오	50
2021R1G1A1004796	202403	Collaborative policy learning for dynamic scheduling tasks in cloud-edge-terminal IoT	Kim, Do-Yup; Lee, Da-Eun;	직접입력	IEEE INTERNET OF THINGS JOURNAL	9(17)	국외	SCI등재	10.6	아니오	50

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

		networks using federated reinforcement learning	Kim, Ji-Wan; Lee, Hyun-Suk								
2021R1G1A1004796	202306	Packet-based fronthauling in 5G networks: Network slicing-aware packetization		직접입력	IEEE Communications Standards Magazine	7(2)	국외	SCI미등재		아니오	50

학술대회 논문발표 성과정보

과제번호	발표년월	학술대회명	저자	논문제목	학술대회구분	개최국	온라인개최
2021R1G1A1004796	202203	The 25th International Conference on Artificial Intelligence and Statistics (AISTATS)	Hyun-Suk Lee	System-agnostic meta-learning for MDP-based dynamic scheduling via descriptive policy	국제학술대회		Y

학위배출인력 성과정보

과제번호	학위취득연월	학위구분	학위취득자				진로
			성명	성별	대학	학과	
2021R1G1A1004796	202301	학사	김지완	남성	세종대학교	스마트기기공학전공	석사과정진학
2021R1G1A1004796	202301	학사	이다은	여성	세종대학교	스마트기기공학전공	석사과정진학
2021R1G1A1004796	202301	학사	이재훈	남성	세종대학교	스마트기기공학전공	취업준비중
2021R1G1A1004796	202301	학사	홍성현	남성	세종대학교	데이터사이언스	석사과정진학
2021R1G1A1004796	202401	학사	김규식	남성	세종대학교	스마트기기공학전공	석사과정진학

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임2-1] 연구책임자 대표적 연구실적

○ 논문 및 특허 실적(최대 5개 작성)

번호	구분 (논문/특허)	논문명/특허명	소속기관명	역할	논문게재지/ 특허등록국가	논문게재일 /특허등록일	특기사항 (I.F. 등)
1	논문	Adaptive Transmission Scheduling in Wireless Networks for Asynchronous Federated Learning	세종대학교	제1저자	IEEE JOURNAL ON SELECTED AREAS IN COMMUNICATIONS	2021.12	16.4 (JCR2022)
2	논문	Channel Metamodeling for Explainable Data-Driven Channel Model	세종대학교	제1저자	IEEE WIRELESS COMMUNICATIONS LETTERS	2021.12	6.3 (JCR2022)
3	논문	System-agnostic meta-learning for MDP-based dynamic scheduling via descriptive policy	세종대학교	제1저자	The 25th International Conference on Artificial Intelligence and Statistics (AISTATS)	2022.03	AI분야 우수국제학술대회
4	논문	Radio and Energy Resource Management in Renewable Energy-Powered Wireless Networks With Deep Reinforcement Learning	세종대학교	제1저자	IEEE TRANSACTIONS ON WIRELESS COMMUNICATIONS	2022.07	8.346 (JCR2022)
5	논문	Collaborative policy learning for dynamic scheduling tasks in cloud-edge-terminal IoT networks using federated reinforcement learning	세종대학교	교신저자	IEEE INTERNET OF THINGS JOURNAL	2024.03 (연구기간 중 게재확정)	10.6 (JCR2022)

○ 기타 실적(논문 및 특허 외 기타 실적 입력)

해당사항 없음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

※ 필수제출 자료입니다. 임의로 서식을 삭제하지 마시고 반드시 작성하여 제출해 주시기 바랍니다.

[붙임2-2] 주관연구책임자 대표적 논문·특허실적 요약문

연구실적 유형		논문(V) 특허( )		
연구책임자 성명		연구책임자(이현석)		
논문/특허명		Adaptive Transmission Scheduling in Wireless Networks for Asynchronous Federated Learning		
논문실적정보 ■	게재지(저널명)	IEEE JOURNAL ON SELECTED AREAS IN COMMUNICATIONS		
	SCI 등재 여부	등재	Impact Factor 및 인용횟수(SCI)	16.4(18회)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	20회
	ISSN	0733-8716	게재년월	202112
	역할(제1, 교신, 참여)	제1저자	참여자수	2
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 논문은 하나의 액세스 포인트 (Access Point)와 장치들로 구성된 무선 네트워크 환경에서 비동기 연합학습에 관하여 연구한 논문으로, 각 장치가 자신의 지역 데이터를 비동기 연합학습을 이용하여 효과적으로 사용할 수 있도록 시간에 따라 변화하는 채널 이득과 각 장치의 지역 데이터 도착을 고려하여 전송 스케줄링을 결정하는 비동기 연합학습을 위한 적응적 전송 스케줄링을 알고리즘을 개발하였음. 비동기 연합학습 환경에서 채널 이득과 지역 데이터 도착, 무선 네트워크의 한정된 자원을 효과적으로 고려할 수 있도록 유효성 점수 (effectivity score)라는 지표를 제안하였음. 해당 지표는 비동기 연합학습으로부터 얻을 수 있는 학습의 양을 표현함. 구체적으로 비동기 연합학습을 위한 전송 스케줄링을 수행하는 ALSA-PI, BALSA, BALSA-PO라는 알고리즘을 개발하였음. 각 알고리즘은 시스템의 불확실성에 관한 통계적 정보 유무에 따라 통계적 정보를 활용하거나 직접 학습하여 최적의 스케줄링 혹은 최적에 가까운 스케줄링을 수행할 수 있고, 특히 매우 제한적인 피드백 정보만을 갖는 실제적인 환경에서도 전송 스케줄링 문제를 해결할 수 있음. 본 논문의 알고리즘은 Bayesian 학습에 기반하여 해당 지표를 최대화할 수 있도록 개발되었음. 따라서 통계적 정보가 없는 경우에도 학습을 통해 최적 성능을 달성할 수 있고, 이를 개발된 알고리즘의 이론적인 성능을 수학적으로 분석하여 증명하였음. 마지막으로 실험을 통해 개발한 알고리즘이 이상적인 알고리즘과 유사한 성능을 달성함을 보였고, 모델 정확도, 학습 손실, 학습 속도, 학습의 견고함과 같은 주요 특성들에 관하여 현재 수준의 다른 전송 스케줄링 알고리즘들보다 좋은 성능을 달성하였음

- **연구 실적과 관련된 타 연구 과제**
  - 정보통신방송혁신인재양성, 메타버스 자율트윈 핵심기술 연구 (연구책임자 김재호)
  - 개인기초연구(중견연구자지원사업), mmWave massive MIMO 무선 네트워크를 위한 지능형 융·복합 시스템레벨 시·공간-주파수 자원 관리 기법 연구 (연구책임자 이장원)

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 논문은 무선 통신 네트워크의 자원 관리 기법에 관한 연구라는 점, 또한 인공지능 기반의 응용 연구라는 점, 인공지능과 무선 통신 네트워크의 융합 연구라는 점에서 본 연구내용과 깊은 연관성을 가지고 있음	본 논문에서 제안한 유효성 점수 지표와 적응적인 전송 스케줄링 전략의 우수한 성능은 해당 지표와 스케쥴링 전략이 비동기 연합학습을 위해 효과적인 전략이라는 것을 의미하며, 무선 네트워크에서의 비동기 연합학습 스케줄링에 관한 기준을 제시하여 관련 응용분야에서 활용될 수 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 대표적 연구실적 사본 〉

Adaptive Transmission Scheduling in Wireless Networks for Asynchronous Federated Learning

Hyun-Suk Lee and Jang-Won Lee, *Senior Member, IEEE*

***Abstract*— In this paper, we study asynchronous federated learning (FL) in a wireless distributed learning network (WDLN). To allow each edge device to use its local data more efficiently via asynchronous FL, transmission scheduling in the WDLN for asynchronous FL should be carefully determined considering system uncertainties, such as time-varying channel and stochastic data arrivals, and the scarce radio resources in the WDLN. To address this, we propose a metric, called an effectivity score, which represents the amount of learning from asynchronous FL. We then formulate an Asynchronous Learning-aware transmission Scheduling (ALS) problem to maximize the effectivity score and develop three ALS algorithms, called ALSA-PI, BALSA, and BALSA-PO, to solve it. If the statistical information about the uncertainties is known, the problem can be optimally and efficiently solved by ALSA-PI. Even if not, it can be still optimally solved by BALSA that learns the uncertainties based on a Bayesian approach using the state information reported from devices. BALSA-PO suboptimally solves the problem, but it addresses a more restrictive WDLN in practice, where the AP can observe a limited state information compared with the information used in BALSA. We show via simulations that the models trained by our ALS algorithms achieve performances close to that by an ideal benchmark and outperform those by other state-of-the-art baseline scheduling algorithms in terms of model accuracy, training loss, learning speed, and robustness of learning. These results demonstrate that the adaptive scheduling strategy in our ALS algorithms is effective to asynchronous FL.**

***Index Terms*— Asynchronous learning, distributed learning, federated learning, scheduling, wireless network.**

I. Introduction

NOWADAYS, a massive amount of data is generated from devices, such as mobile phones and wearable devices, which can be used for a wide range of machine learning (ML) applications from healthcare to autonomous driving. As the computational and storage capabilities of such distributed devices keep growing, distributed learning has become attractive to efficiently exploit the data from devices and to address privacy concerns. Due to the emergence of the need for distributed learning, federated learning (FL) has been widely studied as a potentially viable solution for distributed learning [1], [2]. FL allows to learn a shared central model from the locally trained models of distributed devices under the coordination of a central server while the local training data at the devices is not shared with the central server.

In FL, the central server and the devices should communicate with each other to transmit the trained models. For this, a wireless network composed of one AP and multiple devices has been widely considered [3]–[11], and the AP in the network plays the role of the central server in FL. FL is operated in multiple rounds. In each round, first, the AP broadcasts the current central model. In typical FL, *all* devices substitute their local models into the received central one and train them using their local training data. Then, the locally trained model of each device is uploaded to the AP and the AP aggregates them into the central model. This enables training the central model in a distributed manner while avoiding privacy concerns because it does not require each device to upload its local training data.

However, as FL has been implemented in wireless networks, the limited radio resources of wireless networks have been raised as a critical issue since the radio resources restrict the number of devices that can upload the local models to the AP simultaneously [7], [8]. To address the issue, in [5]–[11], device scheduling procedures for FL have been proposed in which the AP schedules the devices to train their local models and upload them considering the limited radio resources. Then, in each round, only the scheduled devices do so and the AP aggregates the local models uploaded from the scheduled devices. On the other hand, the not-scheduled devices do not train their local models and their local data that have been arrived during the round is stored for future use. Hence, every locally trained model in each round is synchronously aggregated into the central model in the round (i.e., once a device trains its local model in a round, it must be aggregated into the central model in that round and its use in future rounds is not allowed), and such FL is called *synchronous* FL in the literature.

Device scheduling procedures in synchronous FL have effectively addressed the issue of the limited radio resources in wireless networks, but at the same time, they may cause the inefficiency of utilizing local computation resources and the loss of local data due to too much pileup [12], [13]. These issues are raised because of the not-scheduled devices in each round that do not train their local models. Hence, to address them, we can allow even the not-scheduled devices

Manuscript received February 26, 2021; revised July 22, 2021; accepted August 27, 2021. Date of publication October 6, 2021; date of current version November 22, 2021. The work of Hyun-Suk Lee was supported in part by the National Research Foundation of Korea (NRF) Grant through the Korea Government (MSIT) under Grant 2021R1G1A1004796 and in part by the ICT Research and Development Program of MSIT/IITP (Research on Core Technology of Autonomous Twins for Metaverse) under Grant IITP-2021-0-01816. The work of Jang-Won Lee was supported by the NRF Grant through the Korea Government (MSIT) under Grant 2019R1A2C2084870. *(Corresponding author: Jang-Won Lee.)*

Hyun-Suk Lee is with the School of Intelligent Mechatronics Engineering, Sejong University, Seoul 05006, South Korea (e-mail: hyunsuk@sejong.ac.kr).

Jang-Won Lee is with the Department of Electrical and Electronic Engineering, Yonsei University, Seoul 03722, South Korea (e-mail: jangwon@yonsei.ac.kr).

Digital Object Identifier 10.1109/JSAC.2021.3118353

0733-8716 © 2021 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: Sejong Univ. Downloaded on January 23,2024 at 14:11:41 UTC from IEEE Xplore. Restrictions apply.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

연구실적 유형		논문(V) 특허( )		
연구책임자 성명		연구책임자(이현석)		
논문/특허명		Channel Metamodeling for Explainable Data-Driven Channel Model		
논문실적정보 ■	게재지(저널명)	IEEE WIRELESS COMMUNICATIONS LETTERS		
	SCI 등재 여부	등재	Impact Factor 및 인용횟수(SCI)	6.3(2회)
	SCOPUS 등재 여부	등재	인용횟수(SCOPUS)	2회
	ISSN	2162-2337	게재년월	202112
	역할(제1, 교신, 참여)	제1저자	참여자수	1
특허실적정보 □	구분		등록(출원) 국가	
	등록(출원) 번호		등록(출원)일	
	등록(출원)자 성명		발명자 성명	

요 약 문

본 논문은 무선 통신 네트워크에서의 채널 모델링에 관한 연구로써, 최근 다양하게 연구되고 있는 기계학습 기술을 활용한 데이터 드리븐 채널 모델을 설명 가능하도록 만들어주는 방법을 제안하였음. 데이터 드리븐 채널 모델은 무선 채널을 측정하여 얻은 측정 데이터를 이용하여 채널 모델을 구축하는 방법을 의미하며, 최근 딥러닝 기술의 발전으로 딥러닝 모델을 측정 데이터로 학습시켜 딥러닝 모델이 채널 모델로써 기능하는 기계학습 기반 채널 모델링 방식이 다수 연구되었음. 하지만 딥러닝 모델은 그 예측의 동작을 설명할 수 없는 블랙박스 특성을 가져 무선 채널 모델을 학습하더라도 그 채널의 특성을 이해하고 설명하기 어려운 문제가 있음. 따라서 본 논문에서는 해당 블랙박스 데이터 드리븐 채널 모델을 설명 가능한 수학적 표현으로 나타내는 방법에 관한 연구를 진행하였음. 구체적으로 해당 방법은 대표적인 기호 함수 근사 (symbolic function approximation) 방법인 Meijer G-function 및 기호 회귀 (symbolic regression) 기반 방법들을 이용하여 데이터 드리븐 채널 모델을 특정 변수를 갖는 수식으로 근사하여 표현함. 해당 방법들은 데이터 드리븐 채널 모델을 수식으로 표현함으로써 무선 채널을 결정하는데 어떤 매개변수가 주요한지, 각 매개변수들 간의 관계는 어떤지 등의 정보를 얻을 수 있도록 함. 본 연구에서는 실제 채널 모델로부터 발생시킨 데이터와 실제 무선 채널 측정 데이터셋을 이용하여 설명 가능한 수식 형태의 채널 모델도 데이터 드리븐 채널 모델과 유사한 수준으로 정확하게 무선 채널을 모델링 할 수 있음을 보였음. 추가적으로 설명 가능한 채널 모델로부터 채널 모델링에 주요한 매개변수 정보를 확인하고, 해당 정보가 널리 알려진 도메인 지식과 일치함을 확인하였음

- **연구 실적과 관련된 타 연구 과제**
  - 해당없음

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 논문은 무선 통신 네트워크 분야에서 설명가능한 인공지능 기술을 활용한 연구라는 측면에서 본 연구 과제의 연구내용과 깊은 연관성을 가짐. 특히 채널 모델의 경우 무선 자원 관리를 위한 기초연구로써 기능하며, 딥러닝 기반의 데이터 드리븐 채널 모델은 미래 무선 통신 네트워크에서 주요하게 고려되므로 설명가능한 형태의 데이터 드리븐 채널 모델은 본 연구과제에서 고려하는 미래 통신 네트워크에서의 채널 모델링을 위한 연구로 고려되어 추후 활용될 여지가 있음	미래 무선 통신 네트워크에서는 사용되는 무선 채널이 점차 다양해지는 추세에 있으며, 따라서 무선 채널이 가질 수 있는 수많은 환경을 위해 항상 직접 무선 채널 모델을 구축하여 활용하기 어려워 딥러닝 기반 데이터 드리븐 채널 모델에 관한 연구가 활발히 이루어짐. 본 연구는 이 같은 딥러닝 기반 데이터 드리븐 채널 모델이 갖는 설명 불가능성이라는 문제를 해결할 수 있으므로 미래 무선 통신 네트워크에 활용될 가능성이 매우 높다고 할 수 있음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 대표적 연구실적 사본 〉

Channel Metamodeling for Explainable Data-Driven Channel Model

Hyun-Suk Lee

***Abstract*—Machine learning can produce accurate data-driven channel models, but their black-box nature makes it harder to explain the models and to understand underlying channel characteristics. In this letter, we propose a channel metamodeling approach for such a black-box data-driven channel model. Our approach enables us to express the data-driven channel model in terms of transparent mathematical expressions based on symbolic function approximation methods. Through experiments with synthetic and real datasets, we demonstrate that our approach produces a channel metamodel of the data-driven channel model for each dataset that is highly accurate and allows us to easily explain the data-driven channel model and to understand the underlying channel characteristics.**

***Index Terms*—Channel model, data-driven, deep learning, explainable AI, symbolic metamodeling.**

I. Introduction

With the coming of future wireless communications, scenarios have become more diverse and complicated due to mmWave, massive antennas, and various vertical services [1]. In traditional channel modeling, channel characteristics are usually investigated through data processing, and then, a channel model is constructed based on the channel characteristics. However, new scenarios make data processing more challenging and expensive due to their increased diversity and complexity. To resolve this issue, recently, as in other areas in wireless communications [1], [2], machine learning (ML) techniques have been widely applied for channel modeling in the name of data-driven channel modeling [3]–[8]. In data-driven channel modeling, the channel model is directly learned from channel measurement data without any prior data processing.

A. Data-Driven Channel Model and Its Black-Box Nature

For data-driven channel models, channel measurement datasets and/or simulation datasets are usually used [9]. A dataset is composed of physical parameters, such as the Tx and Rx coordinates, the Tx-Rx distances, and the carrier frequency, labeled by the corresponding radio measurements. The data-driven channel model is trained using the dataset and ML techniques to predict channel statistical properties, such as the received power, root mean square (RMS) delay spread, and RMS angle spread, according to given physical parameters [3]. To describe this, we denote a vector of the input features of the channel model (i.e., physical parameters of the dataset) as $\mathbf{x} = (x_1, \ldots, x_K)^\top \in \mathcal{X}$, where K is the number of the input features and $\mathcal{X}$ is the feature space. We denote a vector of the outputs of the channel model (i.e., channel statistical properties) as $\mathbf{y} = (y_1, \ldots, y_L)^\top \in \mathcal{Y} \subseteq \mathbb{R}^L$, where L is the number of the outputs that the channel model will predict and $\mathcal{Y}$ is the output space.[1] Without loss of generality, we assume that the feature space $\mathcal{X}$ is the unit hypercube (i.e., $\mathcal{X} = [0,1]^K$). Then, the true relationship between the inputs and outputs can be expressed as $\mathbf{y} = H(\mathbf{x})$, where $H : \mathcal{X} \to \mathcal{Y}$ represents a physical wireless medium in the environment.

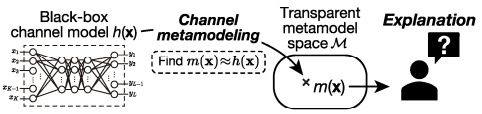


Fig. 1. An illustration of channel metamodeling for explainable data-driven channel model.

The data-driven channel modeling approach based on deep learning trains a DNN $h : \mathcal{X} \to \mathcal{Y}$ by using typical ML techniques in order to approximate the relationship (i.e., $h(\mathbf{x}) \approx H(\mathbf{x}),\ \forall \mathbf{x} \in \mathcal{X}$) as illustrated in Fig. 1.[2] Deep learning is typically used for data-driven channel modeling [3]–[7] because of the large representational capacity of the DNN and the great regularization and learning performance of state-of-the-art ML techniques. However, at the same time, it makes harder to explain the internal mechanism of the trained model, i.e., it is not clear why the DNN works well. Due to this nature of typical DNNs, they are usually called a *black-box* model. Hence, for such a channel model, we can access the outputs of the channel model $\mathbf{y} = h(\mathbf{x})$ for any given feature vector $\mathbf{x}$ only, and it is challenging to investigate underlying channel characteristics, such as the nonlinearity of channel and contributions of physical parameters, which are usually discovered via prior data processing in traditional channel modeling [11]. However, in general, such underlying channel characteristics are still required for further researches such as system design and network management. Thus, we need to interpret the data-driven channel model h into an understandable form to humans [11].

B. Channel Metamodeling and Our Contributions

To address the issue raised due to the black-box nature of DNNs, in this letter, we propose a channel metamodeling approach for data-driven channel models illustrated in

Manuscript received July 25, 2021; accepted September 7, 2021. Date of publication September 13, 2021; date of current version December 9, 2021. This work was supported by the National Research Foundation of Korea (NRF) Grant through Korea Government (MSIT) under Grant 2021R1G1A1004796. The associate editor coordinating the review of this article and approving it for publication was L. Zhang.

The author is with the School of Intelligent Mechatronics Engineering, Sejong University, Seoul 05006, South Korea (e-mail: hyunsuk@sejong.ac.kr).

Digital Object Identifier 10.1109/LWC.2021.3111874

[1]For generality, here we do not explicitly define the input features and the outputs of the channel model.

[2]In this letter, we do not specify the DNN since the channel metamodeling approach proposed in this letter is model-agnostic, which implies that it can be applied to data-driven channel models based on any types of black-box models such as DNN [3]–[7] and SVM [10].

2162-2345 © 2021 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: Sejong Univ. Downloaded on December 10,2021 at 01:44:20 UTC from IEEE Xplore. Restrictions apply.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td colspan="2">연구실적 유형</td><td colspan="3">논문(V) 특허( )</td></tr>
<tr><td colspan="2">연구책임자 성명</td><td colspan="3">연구책임자(이현석)</td></tr>
<tr><td colspan="2">논문/특허명</td><td colspan="3">System-agnostic meta-learning for MDP-based dynamic scheduling via descriptive policy</td></tr>
<tr><td rowspan="5">논문실적정보
■</td><td>게재지(저널명)</td><td colspan="3">Proceedings of Machine Learning Research, The 25th International Conference on Artificial Intelligence and Statistics (AISTATS)</td></tr>
<tr><td>SCI 등재 여부</td><td>미등재</td><td>Impact Factor 및 인용횟수(SCI)</td><td>-</td></tr>
<tr><td>SCOPUS 등재 여부</td><td>미등재</td><td>인용횟수(SCOPUS)</td><td>1회</td></tr>
<tr><td>ISSN</td><td>2640-3498</td><td>게재년월</td><td>202203</td></tr>
<tr><td>역할(제1, 교신, 참여)</td><td>제1저자</td><td>참여자수</td><td>1</td></tr>
<tr><td rowspan="3">특허실적정보
□</td><td>구분</td><td></td><td>등록(출원) 국가</td><td></td></tr>
<tr><td>등록(출원) 번호</td><td></td><td>등록(출원)일</td><td></td></tr>
<tr><td>등록(출원)자 성명</td><td></td><td>발명자 성명</td><td></td></tr>
</table>

요 약 문

본 논문은 마르코프 결정 프로세스 기반의 동적 스케줄링 문제를 다룸. 동적 스케줄링 문제는 장기적인 목표 달성을 위해 매 시간마다 달라지는 아이템의 특성을 고려하여 여러개의 아이템 중 하나의 아이템을 선택하는 문제로 일반화되고, 해당 문제는 큐잉, 추천시스템, 무선 네트워크 등 다양한 응용분야에서 공통적으로 주요하게 고려됨. 이 같은 동적 스케줄링 문제를 해결하기 위한 기존의 접근 방법들은 각 시스템의 주어진 통계적 특성을 고려하여 해당 시스템의 최적 정책을 찾는 형태로 연구되어옴. 본 논문에서는 시스템의 특성에 의존적인 특성을 갖는 기존의 접근방식에서 탈피한 새로운 설명적인 정책 구조를 제안하여 서로 다른 통계적인 특성을 갖는 시스템들에 범용적으로 사용될 수 있는 동적 스케줄링 문제의 메타학습을 달성함. 구체적으로, 본 논문에서 제안한 설명적인 정책은 시스템의 주어진 통계적 특성과 무관하게 "목표를 달성하기 위해서는 어떤 조건을 갖는 아이템을 선택해야하는가?"라는 것의 해답을 표현하는 스케줄링 원리를 학습할 수 있는 특징을 가짐. 설명적인 정책의 이같은 범용적인 특징은 시간에 따라서 시스템의 통계적인 특성이 변화하는 상황에서도 설명적인 정책을 적용할 수 있도록 하며, 스케줄링 원리 자체를 학습하므로 기존에 학습한 경험이 없는 새로운 시스템 환경에서도 추가적인 학습 없이 성공적인 스케줄링을 수행할 수 있고, 여러 시스템에서 공통된 신경망 구조를 갖게 설계되어 지역적으로 학습된 정책을 쉽게 결합하는 연합학습을 수행할 수 있음. 또한 설명적인 정책은 정책 구조 자체가 의사 결정의 근거를 표현하는 특징을 가지고 있어 인공지능 기반 스케줄링 의사결정의 근거를 설명할 수 있는 능력을 가지는 등 기존의 접근에 비해 스케줄링 결정에 관한 설명이 가능한 특징이 있음. 본 연구에서는 실험을 통해 제안한 설명적인 정책은 시스템에 무관하게 적용할 수 있는 특성을 가지면서도 서로 다른 시스템에서 우수한 성능을 가짐을 보였음

- **연구 실적과 관련된 타 연구 과제**
  - 해당없음

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 논문은 설명 가능한 동적 스케줄링 정책에 관한 연구이며, 본 연구 과제에서 다루는 무선 통신 네트워크의 자원 관리 문제는 대표적인 동적 스케줄링 문제임. 따라서 본 논문의 연구 내용은 본 연구과제의 설명 가능한 무선 통신 네트워크 자원 관리 알고리즘을 개발하는데 활용한 기술이며, 해당 기술을 일반화하여 발표하였음	본 연구실적은 동적 스케줄링 측면에서 범용성을 달성하는 메타학습, 의사결정의 설명가능성을 달성할 수 있는 특성을 갖고 있어 동적 스케줄링을 수행하는 다양한 응용분야에 적용될 수 있는 인공지능 핵심 기술 연구임. 이같은 우수성을 인정받아 인공지능/기계학습 이론분야에서 가장 권위있는 학회 중 하나인 AISTATS에 발표되었음

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 대표적 연구실적 사본 〉

System-Agnostic Meta-Learning for MDP-based Dynamic Scheduling via Descriptive Policy

Hyun-Suk Lee
Sejong University

Abstract

Dynamic scheduling is an important problem in applications from queuing to wireless networks. It addresses how to choose an item among multiple scheduling items in each timestep to achieve a long-term goal. Conventional approaches for dynamic scheduling find the optimal policy for a given specific system so that the policy from these approaches is usable only for the corresponding system characteristics. Hence, it is hard to use such approaches for a practical system in which system characteristics dynamically change. This paper proposes a novel policy structure for MDP-based dynamic scheduling, a descriptive policy, which has a system-agnostic capability to adapt to unseen system characteristics for an identical task (dynamic scheduling). To this end, the descriptive policy learns a system-agnostic scheduling principle–in a nutshell, "which condition of items should have a higher priority in scheduling". The scheduling principle can be applied to any system so that the descriptive policy learned in one system can be used for another system. Experiments with simple explanatory and realistic application scenarios demonstrate that it enables system-agnostic meta-learning with very little performance degradation compared with the system-specific conventional policies.

1 INTRODUCTION

Dynamic scheduling is a general issue that has been important, from the past to the present, in various applications from recommender systems (Shani et al., 2005; Huang et al., 2021; Lu and Yang, 2016) to communication networks (Ferrá et al., 2003; Wei et al., 2018). Traditionally, dynamic scheduling problems have been often modeled based on Markov decision process (MDP) (Shani et al., 2005; Huang et al., 2021; Lu and Yang, 2016; Ferrá et al., 2003; Wei et al., 2018; Stidham and Weber, 1993; Chang et al., 2000; Ye et al., 2019; Xu et al., 2017; Han and Liu, 2008) since scheduling is typically sequential decision-making. To solve them, most conventional approaches find the optimal policy for a given system. However, in practice, they may be useless since system characteristics dynamically change in general.

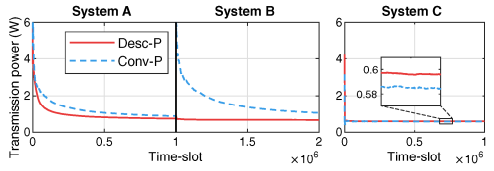
As a viable solution to this issue, meta-reinforcement learning (RL) can be considered (Hospedales et al., 2020). Most state-of-the-art meta-RL methods focus on unseen tasks with identical dynamics (Lin et al., 2020). On the other hand, meta-RL for dynamic scheduling should consider an identical task (scheduling) but unseen dynamics from the change of system characteristics. To distinguish them, we name the meta-RL for dynamic scheduling *system-agnostic* meta-learning since it addresses the different system dynamics.

1.1 Motivation with MDP-based Dynamic Scheduling

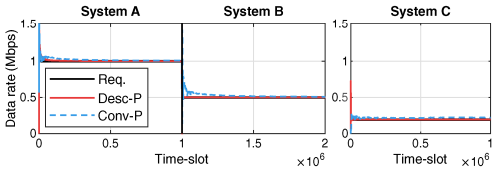
We consider a general scheduling problem for dynamic systems consisting of a scheduler and multiple scheduling items (e.g., queue, users, devices, and so on) to be scheduled. The scheduling items are indexed as $n \in \mathcal{N} = \{1, 2, ..., N\}$, where N is the total number of the items in the system. We assume a dynamic system that operates over a discrete time horizon $t \in \{1, 2, ... \}$. We call the information that describes the condition of the system feature information. We define the vector of feature information of item n in timestep t as $f_n^t = (f_{n,1}^t, ..., f_{n,K}^t)$, where $f_{n,k}^t$ denotes k-th feature information of item n in timestep t (e.g., current queue length in queue scheduling and channel condition in wireless networks) and K is the number of types of features. Then, the feature information in timestep t represents the system state in timestep t. Without loss

Proceedings of the 25th International Conference on Artificial Intelligence and Statistics (AISTATS) 2022, Valencia, Spain. PMLR: Volume 151. Copyright 2022 by the author(s).

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다



(a) Average transmission power.



(b) Average data rate of the user at a distance of 80 m.

Figure 3: Simulation results of realistic application in wireless networks.

the user is the farthest one from the BS, which implies the most challenging user to satisfy the data rate requirement among the users. The result shows that the Desc-P satisfies the data rate requirements in all system characteristics. It is worth emphasizing that system characteristics C has different requirements from those in system characteristics A and B and the Desc-P is trained by only using the experiences from system characteristics A and B. This clearly shows that the extended descriptive policy described in Section 3.1 learns the scheduling principle to satisfy the requirements.

6 CONCLUSION

In this paper, we have studied explainable system-agnostic meta-learning for MDP-based dynamic scheduling. The policy proposed, descriptive policy, describes the condition of items in the state and action, which makes the policy system-agnostic and explainable. The descriptive policy enables system-agnostic meta-learning for dynamic scheduling by learning the scheduling principle that can be used in any system. Experiments with simple explanatory and realistic application scenarios demonstrate that the descriptive policy achieves similar performance to the optimal one while enjoying its advantages.

Acknowledgements

This work was supported by the National Research Foundation of Korea (NRF) grant through the Korea Government (MSIT) under Grant 2021R1G1A1004796. We thank all reviewers for their comments and suggestions.

References

Altman, E. (1998). *Constrained Markov Decision Processes*. Chapman and Hall/CRC.

Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., et al. (2020). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58:82–115.

Atrey, A., Clary, K., and Jensen, D. (2020). Exploratory not explanatory: Counterfactual analysis of saliency maps for deep reinforcement learning. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

Bertsekas, D. P. et al. (2000). *Dynamic programming and optimal control: Vol. 1*. Athena scientific Belmont.

Chang, H. S., Givan, R., and Chong, E. K. (2000). Online scheduling via sampling. In *Proceedings of the International Conference on Artificial Intelligence Planning and Scheduling (AIPS)*, pages 62–71.

Duan, Y., Schulman, J., Chen, X., Bartlett, P. L., Sutskever, I., and Abbeel, P. (2016). RL^2: Fast reinforcement learning via slow reinforcement learning. *arXiv preprint arXiv:1611.02779*.

Ferrá, H. L., Lau, K., Leckie, C., and Tang, A. (2003). Applying reinforcement learning to packet scheduling in routers. In *Proceedings of The Innovative Applications Conference on Artificial Intelligence (IAAI)*, pages 79–84.

Florensa, C., Held, D., Geng, X., and Abbeel, P. (2018). Automatic goal generation for reinforcement learning agents. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 1515–1528. PMLR.

Ghadimi, S. and Lan, G. (2012). Optimal stochastic approximation algorithms for strongly convex stochastic composite optimization I: A generic algorithmic framework. *SIAM Journal on Optimization*, 22(4):1469–1492.

Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep learning*. MIT press.

Greydanus, S., Koul, A., Dodge, J., and Fern, A. (2018). Visualizing and understanding atari agents. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 1792–1801. PMLR.

Gupta, A., Mendonca, R., Liu, Y., Abbeel, P., and Levine, S. (2018). Meta-reinforcement learning of structured exploration strategies. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5307–5316.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td colspan="2">연구실적 유형</td><td colspan="3">논문(V)　　특허(　　)</td></tr>
<tr><td colspan="2">연구책임자 성명</td><td colspan="3">연구책임자(이현석)</td></tr>
<tr><td colspan="2">논문/특허명</td><td colspan="3">Radio and Energy Resource Management in Renewable Energy-Powered Wireless Networks With Deep Reinforcement Learning</td></tr>
<tr><td rowspan="5">논문실적정보
■</td><td>게재지(저널명)</td><td colspan="3">IEEE TRANSACTIONS ON WIRELESS COMMUNICATIONS</td></tr>
<tr><td>SCI 등재 여부</td><td>등재</td><td>Impact Factor 및 인용횟수(SCI)</td><td>10.4(10회)</td></tr>
<tr><td>SCOPUS 등재 여부</td><td>등재</td><td>인용횟수(SCOPUS)</td><td>11회</td></tr>
<tr><td>ISSN</td><td>1536-1276</td><td>게재년월</td><td>202207</td></tr>
<tr><td>역할(제1, 교신, 참여)</td><td>제1저자</td><td>참여자수</td><td>3</td></tr>
<tr><td rowspan="3">특허실적정보
□</td><td>구분</td><td></td><td>등록(출원) 국가</td><td></td></tr>
<tr><td>등록(출원) 번호</td><td></td><td>등록(출원)일</td><td></td></tr>
<tr><td>등록(출원)자 성명</td><td></td><td>발명자 성명</td><td></td></tr>
</table>

요 약 문

본 논문은 신재생에너지로부터 전력을 공급받는 무선 네트워크에서 심층 강화학습을 이용하여 무선 자원과 에너지 자원을 모두 관리하는 방법을 다룸. 구체적으로, 본 네트워크의 기지국은 신재생에너지원과 전력계통으로부터 전력을 얻을 수 있고, 기지국 간 에너지의 공유가 가능한 환경을 다룸. 대규모 무선 네트워크에서 에너지 및 무선 자원을 효과적으로 관리하기 위해 심층 강화학습을 이용한 자원관리 프레임워크를 제안함. 제안 프레임워크는 각 사용자의 전송률 요구조건을 만족시키면서 전력계통으로부터의 에너지 소모를 최소화함. 이를 달성하기 위해 프레임워크에서는 각 기지국의 최대 전송 전력을 제한하는 셀 간 간섭제어 정책, 각 기지국의 무선 자원 할당 및 전력 전송 제어를 담당하는 자원 관리 정책, 각 기지국에서 수확된 에너지 자원을 기지국 간 어떻게 공유할지 결정하는 셀 간 에너지 공유 정책과 같은 세 가지 정책을 계층적이고 분산적으로 활용하여 효과적으로 문제를 해결하였음. 신재생에너지를 고려한 무선 통신 네트워크 자원 관리 문제를 다룬 기존의 연구들은 문제의 복잡도로 인해 전력 관리, 자원 할당, 에너지 공유, 셀 간 간섭 조절 등의 세부 관리 문제들 중 일부만을 고려함. 하지만 본 논문에서 연구된 프레임워크의 경우 심층 강화학습을 기반으로 각 문제들의 정책을 독립적으로 구성하고, 해당 정책들이 계층적이고 분산적으로 적용되어 모든 세부 관리 문제들을 함께 해결할 수 있게 설계되었음. 또한 학습 과정에서 각 정책 사이의 상호작용을 통해 무선 자원 관리, 전송 전력 제어, 에너지 자원 관리 사이의 관계가 학습에 반영됨. 이를 통해

▪ **연구 실적과 관련된 타 연구 과제**

- 개인기초연구(중견연구자지원사업), mmWave massive MIMO 무선 네트워크를 위한 지능형 융·복합 시스템레벨 시·공간-주파수 자원 관리 기법 연구 (연구책임자 이장원)
- 개인기초연구(중견연구자지원사업), 기계학습 기반 신재생에너지를 활용한 통신 시스템의 에너지 자립 연구 (연구책임자 이장원)

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 논문은 신재생에너지를 활용하는 대규모 무선 네트워크에서 인공지능 기술을 활용하여 무선 자원 관리를 수행하는 연구로써, 무선 자원 관리 알고리즘을 개발하는 연구라는 점, 인공지능 기술을 이용하여 무선 자원 관리를 수행한다는 점 등이 본 연구 과제의 연구내용과 깊은 연관성을 가지며, 본 연구 과제에서의 인공지능 기반 대규모 무선 자원 관리 프레임워크 연구의 기반이 되었음	본 논문의 프레임워크는 무선 통신 네트워크에서의 무선 자원과 에너지 자원 간의 관계를 효과적으로 고려하여 기존 기술 대비 외부에너지를 적게 사용하면서도 오히려 시스템의 전체적인 통신 성능을 개선하는 결과를 얻었고, 에너지 또한 자원으로 고려하여 에너지 효율성을 달성할 수 있음을 제시하여 미래 통신 네트워크의 에너지 효율성 측면에서 파급효과가 클 것으로 예상됨

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 대표적 연구실적 사본 〉

Radio and Energy Resource Management in Renewable Energy-Powered Wireless Networks With Deep Reinforcement Learning

Hyun-Suk Lee, Do-Yup Kim, *Graduate Student Member, IEEE*, and Jang-Won Lee, *Senior Member, IEEE*

***Abstract*— In this paper, we study radio and energy resource management in renewable energy-powered wireless networks, where base stations (BSs) are powered by both on-grid and renewable energy sources and can share their harvested energy with each other. To efficiently manage those resources, we propose a hierarchical and distributed resource management framework based on deep reinforcement learning. The proposed framework minimizes the on-grid energy consumption while satisfying the data rate requirement of each user. It is composed of three different policies in a distributed and hierarchical way. An inter-cell interference coordination policy constrains the transmission power at each BS to coordinate the intercell interference among the BSs. Under the power constraints, a distributed radio resource allocation policy of each BS determines its own user scheduling and power control. Lastly, an energy sharing policy manages the energy resources of the BSs by sharing the harvested energy via power lines between them. Through the simulation, we demonstrate that the proposed framework can effectively reduce the on-grid energy consumption while satisfying the data rate requirements.**

***Index Terms*— Deep learning, reinforcement learning, renewable energy, resource management, wireless networks.**

I. Introduction

RECENTLY, with the explosive growth of mobile traffic and number of terminals, wireless networks have become more and more complex to support them [1]. Accordingly, various problems in wireless networks, such as beamforming, channel estimation, modulation, and radio resource management, become much more complex as well so that it is more challenging to solve them effectively. To address such a large complexity of the problems, deep learning methods have been widely applied [2]–[6] since they can deal with such a complex problem thanks to a large representational capability of deep neural networks (DNNs) [6].

Especially, deep reinforcement learning (DRL) has been widely used to address radio resource management which is typically formulated as a stochastic optimization problem [7]–[15], since DRL is one of the representative methods to solve stochastic problems. They determine the power control and/or user scheduling for each base station (BS) to maximize their own metrics that correspond to the network performance or to satisfy the QoS requirements of users in wireless networks. In [7]–[12], radio resource management is addressed in a centralized manner thanks to the large representational capability of deep learning. However, as pointed out in [13], even if deep learning methods are used, the centralized radio resource management for multi-cell networks may become too complex in practice. Such a large computational complexity makes the centralized algorithm require more dataset, computation power, and time to train the DNNs. Hence, to mitigate the complexity issue, in [13]–[15], distributed radio resource management algorithms are proposed. In those algorithms, the radio resources are managed by multiple DRL-based resource managing instances, each of which is in charge of each BS or each wireless link in the wireless networks. The DRL-based radio resource management algorithms are summarized in Table I.

Meanwhile, the growth of mobile traffic not only makes wireless networks complex but also makes their energy consumption keep growing [16], [17]. Hence, it is expected that the carbon footprint emission due to the electricity energy consumption by wireless networks will continue to grow as well [18]. As a viable solution to reduce the carbon footprint, renewable energy harvesting technologies have been emerged [16], [17]. They allow us to utilize green renewable energy, such as solar and wind energy, which does not emit carbon footprints instead of on-grid energy which does [17]. In wireless networks, the renewable energy harvesting technologies have been widely applied to reduce the carbon footprint [8], [11], [15]–[21]. Such wireless networks powered by renewable energy sources are called green wireless networks.

In typical green wireless networks, BSs are powered by both on-grid and renewable energy sources, and can store their surplus harvested energy in their batteries for future use. To more effectively utilize the surplus harvested energy,

Manuscript received July 15, 2021; revised November 12, 2021; accepted December 30, 2021. Date of publication January 12, 2022; date of current version July 12, 2022. The work of Hyun-Suk Lee was supported by the Korea Government [Ministry of Science and ICT (MSIT)] through the National Research Foundation of Korea (NRF) under Grant NRF-2021R1G1A1004796. The work of Do-Yup Kim and Jang-Won Lee was supported in part by the Korea Government (MSIT) through NRF under Grant NRF-2017R1A2B4006908 and Grant NRF-2019R1A2C2084870. The associate editor coordinating the review of this article and approving it for publication was O. Ozel. *(Corresponding author: Jang-Won Lee.)*

Hyun-Suk Lee is with the School of Intelligent Mechatronics Engineering, Sejong University, Seoul 05006, South Korea (e-mail: hyunsuk@sejong.ac.kr).

Do-Yup Kim and Jang-Won Lee are with the Department of Electrical and Electronic Engineering, Yonsei University, Seoul 03722, South Korea (e-mail: danny.doyup.kim@yonsei.ac.kr; jangwon@yonsei.ac.kr).

Color versions of one or more figures in this article are available at https://doi.org/10.1109/TWC.2022.3140731.

Digital Object Identifier 10.1109/TWC.2022.3140731

1536-1276 © 2022 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: Sejong Univ. Downloaded on January 23,2024 at 14:11:42 UTC from IEEE Xplore. Restrictions apply.

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

<table>
<tr><td colspan="2">연구실적 유형</td><td colspan="3">논문(V) 특허( )</td></tr>
<tr><td colspan="2">연구책임자 성명</td><td colspan="3">연구책임자(이현석)</td></tr>
<tr><td colspan="2">논문/특허명</td><td colspan="3">Collaborative policy learning for dynamic scheduling tasks in cloud-edge-terminal IoT networks using federated reinforcement learning</td></tr>
<tr><td rowspan="5">논문실적정보
■</td><td>게재지(저널명)</td><td colspan="3">IEEE INTERNET OF THINGS JOURNAL</td></tr>
<tr><td>SCI 등재 여부</td><td>등재</td><td>Impact Factor 및 인용횟수(SCI)</td><td>10.6(0회)</td></tr>
<tr><td>SCOPUS 등재 여부</td><td>등재</td><td>인용횟수(SCOPUS)</td><td>1회</td></tr>
<tr><td>ISSN</td><td>2327-4662</td><td>게재년월</td><td>202403</td></tr>
<tr><td>역할(제1, 교신, 참여)</td><td>교신저자</td><td>참여자수</td><td>4</td></tr>
<tr><td rowspan="3">특허실적정보
□</td><td>구분</td><td></td><td>등록(출원) 국가</td><td></td></tr>
<tr><td>등록(출원) 번호</td><td></td><td>등록(출원)일</td><td></td></tr>
<tr><td>등록(출원)자 성명</td><td></td><td>발명자 성명</td><td></td></tr>
</table>

요 약 문

본 논문은 클라우드-에지-단말이 고려된 사물인터넷 네트워크에서 연합 강화학습을 이용하여 무선 통신 스케줄링, 에너지 전송 스케줄링, 데이터 수집 스케줄링 등과 같은 여러 에지에서 공통적으로 수행해야하는 다양한 동적 스케줄링 작업을 위한 정책을 협력적으로 학습하는 방법을 다룸. 구체적으로 본 논문에서 제안하는 프레임워크에서는 클라우드 서버에서 각 작업을 위한 중앙 정책을 구성하고, 해당 중앙 정책은 실제 작업을 수행하는 에지에서 활용되어 각 에지가 스케줄링 정책을 처음부터 학습해야하는 부담을 줄여줌. 또한 사물인터넷의 계층적 구조를 고려하여 연합 강화학습을 적용함으로써 각 에지에서 얻어지는 경험들을 클라우드 서버에서 취합하여 중앙 정책을 협력적인 형태로 학습할 수 있도록 함. 본 논문에서는 서로 다른 에지로부터 학습되는 지역적 작업 정책을 협력적으로 학습할 수 있도록 하는 정책 구조를 제안하였으며 효과적인 협력 학습을 위해 각 작업의 학습 정도와 작업 간 학습 공평성을 고려한 학습 알고리즘을 개발하였음. 본 논문에서 연구된 프레임워크는 기존 동적 스케줄링 작업 정책 학습과 다른 특성을 갖는데, 기존 정책 학습의 경우 각 에지의 환경에 따라 서로 다른 정책을 학습하도록 설계되어옴. 하지만 본 프레임워크의 경우 각 에지의 환경에 범용적인 정책 구조를 활용하고 클라우드-에지-단말로 구성된 사물인터넷 네트워크 환경의 계층적인 구조를 적극적으로 활용하여 클라우드 서버에 구성된 범용적인 정책 구조를 갖는 중앙 정책을 활용하고 연합 강화학습을 통해 해당 정책을 여러 에지가 협력적으로 학습함. 이 과정에서 정책 학습의 공평성을 고려하여 학습의 효율성을 증대하였음. 본 논문에서는 실험을 통해 제안 프레임워크가 위와 같은 특성을 가짐을 명확히 보였음

▪ **연구실적과 관련된 연구 과제**

- 정보통신방송혁신인재양성, 메타버스 자율트윈 핵심기술 연구 (연구책임자 김재호)

연구 목표 및 연구내용과의 연관성	기대성과 및 파급 효과
본 연구실적은 인공지능 기반의 응용 연구라는 점, 스케줄링 작업을 고려한다는 점, 스케줄링 정책이 여러 환경에 관한 범용성을 가진다는 점 등이 본 연구 과제의 연구내용과 깊은 연관성을 가짐. 특히, 본 연구실적에서 여러 환경에 관한 범용성을 위한 정책 구조를 설계하기 위하여 본 연구과제의 설명가능한 정책 구조를 활용하는 등 본 연구 과제의 연구 성과를 활용하여 본 연구실적의 프레임워크가 개발되었음	본 논문의 경우 기존 에지 네트워크의 스케줄링 정책 학습 연구와 다르게 수많은 에지 네트워크를 위한 개별적인 정책을 학습할 필요가 없이 중앙 정책을 효율적으로 이용할 수 있도록 함. 특히, 본 프레임워크는 수많은 에지 네트워크가 알고리즘의 계산복잡도를 높이는 것이 아니라 오히려 얻어지는 경험을 협력 학습을 통해 효과적으로 활용할 수 있는 새로운 인공지능 기반 정책 활용 방식을 제시함

국가연구개발 보고서원문 성과물 전담기관인 한국과학기술정보연구원에서 가공·서비스 하는 연구보고서는 동의 없이 상업적 및 기타 영리목적으로 사용할 수 없습니다

〈 대표적 연구실적 사본 〉

Collaborative Policy Learning for Dynamic Scheduling Tasks in Cloud–Edge–Terminal IoT Networks Using Federated Reinforcement Learning

Do-Yup Kim, *Member, IEEE*, Da-Eun Lee, Ji-Wan Kim, and Hyun-Suk Lee

***Abstract*—In this article, we examine cloud–edge–terminal Internet of Things (IoT) networks, where edges undertake a range of typical dynamic scheduling tasks. In these IoT networks, a central policy for each task can be constructed at a cloud server. The central policy can be then used by the edges conducting the task, thereby mitigating the need for them to learn their own policy from scratch. Furthermore, this central policy can be collaboratively learned at the cloud server by aggregating local experiences from the edges, thanks to the hierarchical architecture of the IoT networks. To this end, we propose a novel collaborative policy learning framework for dynamic scheduling tasks using federated reinforcement learning. For effective learning, our framework adaptively selects the tasks for collaborative learning in each round, taking into account the need for fairness among tasks. In addition, as a key enabler of the framework, we propose an edge-agnostic policy structure that enables the aggregation of local policies from different edges. We then provide the convergence analysis of the framework. Through simulations, we demonstrate that our proposed framework significantly outperforms the approaches without collaborative policy learning. Notably, it accelerates the learning speed of the policies and allows newly arrived edges to adapt to their tasks more easily.**

***Index Terms*—Agnostic policy, cloud computing, dynamic scheduling, edge networks, federated learning, Internet of Things (IoT) networks, reinforcement learning (RL).**

I. Introduction

With the recent explosive development of Internet of Things (IoT) applications, a hierarchical architecture for IoT networks has been widely studied to ensure agility, flexibility, and scalability [1], [2], [3]. In this hierarchical architecture, IoT networks can be decomposed into edges and a cloud-edge network, as illustrated in Fig. 1. Each edge forms its own network, called an edge network, comprising an access point (AP) and IoT terminal devices, while the cloud-edge network consists of a cloud server and edge networks. Such hierarchical IoT networks are typically referred to as cloud–edge–terminal IoT networks, as they consist of a cloud server, edges, and IoT terminal devices.

In this hierarchical architecture, edges in IoT networks carry out numerous *tasks*, such as inference, prediction, planning, and scheduling, to support various IoT applications and services. In particular, a variety of *dynamic scheduling tasks* have been widely considered as major tasks in IoT networks. Dynamic scheduling tasks typically involve a problem, where an item is chosen from multiple items to achieve a goal, which has been widely considered in various applications, from recommendation [4], [5], [6] to resource scheduling [7], [8], [9], [10], [11], [12], [13] to queueing [14], [15], [16], [17]. In IoT networks, different edge functionalities, such as radio resource management [18], [19], [20], [21], data gathering [22], [23], [24], and wireless power transfer [25], [26], [27], correspond to this problem, in which an edge selects an IoT terminal device from multiple IoT terminal devices for the corresponding functionalities. It is worth emphasizing that in typical IoT networks, multiple edges share common dynamic scheduling tasks since these functionalities are generally used in IoT networks. For example, most edge nodes should conduct radio resource management tasks to serve IoT terminal devices. Additionally, in most sensor applications, each edge node carries out data aggregation scheduling tasks, which schedule IoT terminal devices to effectively aggregate data from each IoT terminal device.

A. Related Work

1) Deep Reinforcement Learning for Dynamic Scheduling Tasks in IoT Networks: To efficiently address dynamic scheduling tasks in IoT networks, deep learning, especially deep reinforcement learning (DRL), has been widely applied for various applications, such as resource allocation [18], [20], [21], data aggregation [22], [23], [24], and wireless power transfer [25], [26], [27]. DRL is one of the representative methods for solving complex stochastic problems, thanks to the large representational capability of deep learning. Specifically, in DRL-based approaches, an agent directly learns a policy represented by a deep neural network

Manuscript received 29 August 2023; accepted 13 October 2023. Date of publication 25 October 2023; date of current version 7 March 2024. This work was supported in part by the National Research Foundation of Korea (NRF) Grant through the Korea Government (MSIT) under Grant 2021R1G1A1004796, and in part by the MSIT under the Information Technology Research Center (ITRC) Support Program supervised by the Institute for Information and Communications Technology Planning and Evaluation (IITP) under Grant IITP-2023-2021-0-01816. *(Corresponding author: Hyun-Suk Lee.)*

Do-Yup Kim is with the Department of Information and Telecommunication Engineering, Incheon National University, Incheon 22012, South Korea (e-mail: doyup@inu.ac.kr).

Da-Eun Lee is with the Department of Aritificial Intelligence Application, Hanyang University, Seoul 04763, South Korea (e-mail: kjs990516@naver.com).

Ji-Wan Kim and Hyun-Suk Lee are with the Department of Intelligent Mechatronics Engineering, Sejong University, Seoul 05006, South Korea (e-mail: jiwan1228@naver.com; hyunsuk@sejong.ac.kr).

Digital Object Identifier 10.1109/JIOT.2023.3327495

2327-4662 © 2023 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: Sejong Univ. Downloaded on March 21,2024 at 06:00:17 UTC from IEEE Xplore. Restrictions apply.